

数据挖掘


杨柳

智能与计算学部

yangliuyl@tju.edu.cn



1. **数据清理** (消除噪音或不一致的数据)
2. **数据集成** (多种数据源组合到一起)
3. **数据选择**
(从数据库中提取与分析任务相关的数据)
4. **数据变换**
(变换或统一成合适挖掘的形式)
5. **挖掘算法设计**
(使用智能方法提取数据模式, 关联规则及机器学习的分类、聚类、回归)
6. **性能评估**
(根据某种兴趣程度度量识别提供知识的真正有趣的模式)
7. **知识表示**
(向用户提供挖掘的知识)



第 2 章 认识数据



2 认识数据



2.1 数据对象与属性类型 

2.2 数据的基本统计描述

2.3 数据可视化

2.4 度量数据的相似性和相异性

2.1 数据对象与属性类型




序号	头发颜色	籍贯	A成绩	B成绩	类别
1	黑色	天津	90	C	1
2	黄色	北京	70	A	0
3	紫色	北京	91	A	?

序号	头发颜色	籍贯	A成绩	B成绩	类别
1	0	022	90	3	1
2	1	010	70	5	0
3	9	010	91	5	

A成绩	B成绩	类别
90	3	1
70	5	0
91	5	?

A成绩	B成绩	类别
90	60	1
70	100	0
91	100	?



2.1 数据对象与属性类型



数据集

值通过逗号分隔

Data set concerning bridges in USA

E13,A,33,CRAFTS,HIGHWAY,?,2,N,THROUGH,WOOD,?,S,WOOD
E15,A,28,CRAFTS,RR,?,2,N,THROUGH,WOOD,?,S,WOOD
E16,A,25,CRAFTS,HIGHWAY,MEDIUM,2,N,THROUGH,IRON,MEDIUM,S-F,SUSPEN
E17,M,4,CRAFTS,RR,MEDIUM,2,N,THROUGH,IRON,MEDIUM,?,SIMPLE-T
E18,A,28,CRAFTS,RR,MEDIUM,2,N,THROUGH,IRON,SHORT,S,SIMPLE-T
E19,A,29,CRAFTS,HIGHWAY,MEDIUM,2,N,THROUGH,WOOD,MEDIUM,S,WOOD
E20,A,32,EMERGING,HIGHWAY,MEDIUM,2,N,THROUGH,WOOD,MEDIUM,S,WOOD
E21,M,16,EMERGING,RR,?,2,?,THROUGH,IRON,?,?,SIMPLE-T
E23,M,1,EMERGING,HIGHWAY,MEDIUM,?,?,THROUGH,STEEL,LONG,F,SUSPEN
E22,A,24,EMERGING,HIGHWAY,MEDIUM,4,G,THROUGH,WOOD,SHORT,S,WOOD
E24,O,45,EMERGING,RR,?,2,G,?,STEEL,?,?,SIMPLE-T
E25,M,10,EMERGING,RR,?,2,G,?,STEEL,?,?,SIMPLE-T
E27,A,39,EMERGING,RR,?,2,G,THROUGH,STEEL,?,F,SIMPLE-T
E26,M,12,EMERGING,RR,MEDIUM,2,G,THROUGH,STEEL,MEDIUM,S,SIMPLE-T
E30,A,31,EMERGING,RR,?,2,G,THROUGH,STEEL,MEDIUM,F,SIMPLE-T
E29,A,26,EMERGING,HIGHWAY,MEDIUM,2,G,THROUGH,STEEL,MEDIUM,?,SUSPEN
E28,M,3,EMERGING,HIGHWAY,MEDIUM,2,G,THROUGH,STEEL,MEDIUM,S,ARCH
E32,A,30,EMERGING,HIGHWAY,?,2,G,THROUGH,IRON,MEDIUM,F,SIMPLE-T
E31,M,8,EMERGING,RR,MEDIUM,2,G,THROUGH,STEEL,MEDIUM,S,SIMPLE-T
E34,O,41,EMERGING,RR,LONG,2,G,THROUGH,STEEL,LONG,F,SIMPLE-T
E33,M,19,EMERGING,HIGHWAY,MEDIUM,?,G,THROUGH,IRON,MEDIUM,F,SIMPLE-T
E36,O,45,MATURE,HIGHWAY,?,2,G,THROUGH,IRON,SHORT,F,SIMPLE-T
E35,A,27,MATURE,HIGHWAY,MEDIUM,2,G,THROUGH,STEEL,MEDIUM,F,SIMPLE-T
E38,M,17,MATURE,HIGHWAY,?,2,G,THROUGH,IRON,MEDIUM,F,SIMPLE-T
E37,M,18,MATURE,RR,MEDIUM,2,G,THROUGH,STEEL,MEDIUM,S,SIMPLE-T
E39,A,25,MATURE,HIGHWAY,?,2,G,THROUGH,STEEL,MEDIUM,F,SIMPLE-T
E4,A,27,MATURE,AQUEDUCT,MEDIUM,1,N,THROUGH,WOOD,SHORT,S,WOOD
E40,M,22,MATURE,HIGHWAY,?,2,G,THROUGH,STEEL,MEDIUM,F,SIMPLE-T
E41,M,11,MATURE,HIGHWAY,?,2,G,THROUGH,IRON,MEDIUM,F,SIMPLE-T
E42,M,9,MATURE,HIGHWAY,LONG,2,G,THROUGH,STEEL,LONG,F,SIMPLE-T

2.1 数据对象与属性类型



岩土参数数据集

depth	description	class	w _n	w _l	w _p	I _p	I _l	ρ _b	ρ _d	c _u	φ'	m _v	C _c
			%	%	%	%		Mg/m ³	Mg/m ³	kN/m ²	°	m ² /MN	
1		CL						2.11			0		
6.5	soft grey marine	CV	39					1.81	1.31	11.00	0		0.20
27.5	soft grey marine	CV	50	83	29	54	0.39	1.66	1.11	41.00	0		0.72
6.5	v soft grey mar	CV	49	78	29	49	0.41	1.62	1.07	12.00	0		0.52
9.6	v soft grey mar	CV	58	83	29	54	0.54	1.59	1.00	7.00	25.00		
12.5	v soft grey mar	CV	67	81	28	53	0.74	1.49	0.89	5.00	0.00		
21.5	stiff silty clay	CH	26	63	24	39	0.05	1.94	1.54				0.17
12.5	v soft grey mar	MV	47	90	42	48	0.10	1.57	1.07				0.77
30.5	v soft grey mar	CV	48	76	28	48	0.42	1.69	1.15				0.49
8.0	v stiff clayey si	CL	22	30	20	10	0.19	1.12	1.74	26.00	3.50		
12.7	v soft grey mar	CE	58	93	22	71	0.51	1.66	1.05	25.00	0.00	0.52	0.69
18.6	firm grey silty c	CH	33	65	22	43	0.26	1.93	1.45	87.00	4.00		
21.7	v soft grey mar	CV	45	84	22	62	0.36	1.78	1.23	17.00	0.00	0.33	
24.7	v stiff grey silty	CH	25	55	22	33	0.09	1.99	1.57	46.00	5.60		
27.7	firm dark grey s	CH	43	58	22	36	0.57	1.81	1.27	40.00	3.00		0.58
17.1	v soft grey mar	CH	27	57	22	35	0.14	1.98	1.56	107.00	5.00		
26.2	soft grey clay	CH	50					1.67	1.13			0.28	0.61
30.7	stiff silty clay	CH	30	58	22	36	0.21	1.96	1.51	58.00	4.80		
12.5	soft grey clay	CV	61	84	29	55	0.58	1.57	0.98	19.00	0.00		0.68
27.5	soft grey clay	CV	49	71	26	45	0.51	1.66	1.11	17.00	0.00		0.56
21.5	clayey silt with	CL	22	33	15	18	0.39	1.95	1.59	22.00	0.00		0.16
20.7	v soft grey mar	CV	48	82	22	60	0.43	1.76	1.19	29.00	0.00	0.37	0.16
11.2	soft grey marine	CL	58.3					1.66	1.05	20.00	0.00	0.62	0.67

直接取自电子表格的格式

2.1 数据对象与属性类型



□ 数据


- 数据是指对客观事件进行记录并可以鉴别的符号，是对客观事物的性质、状态以及相互关系等进行记载的物理符号或这些物理符号的组合。
- 数据可能存储在数据库、数据仓库和其他信息资料库中。

□ 类型

- 连续型：数值
- 离散型：标称、二元、序数

□ 主要问题

- 不一致、错误、缺失 等



2.1.1 数据对象



- 数据集由数据对象 (data objects)组成。
- 一个数据对象代表一个实体。
 - 销售：顾客、商品或者销售记录
 - 医疗：患者、药品
 - 大学：学生、老师、课程
- 数据对象用属性来描述。
- 数据对象可以是一个记录、数据点、实体、样本、实例或者对象等。如果数据对象存放在数据库中，它们是数据元组。即数据库中行对应数据对象，列对应于属性。

2.1.1 数据对象



行 -> 数据对象;

列 -> 属性.

Attributes

<i>Tid</i>	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Objects

2.1.2 数据属性



- 一个属性是一个域，表示一个数据对象的一个特征。
- “属性”、“维度”、“特征”和“变量”这些词在语义上是可交换的。“维度”通常被用在数据仓库中，机器学习中倾向于使用“特征”；统计学倾向使用“变量”，数据挖掘和数据库经常使用“属性”。属性描述一个顾客对象，如：顾客ID，姓名，地址。
- 对给定属性的可观察值被称为**观察**。刻画一个给定对象的属性集合被称为**属性向量**（或**特征向量**）。

2.1.2 数据属性



□ 数据属性

- 标称属性
- 二元属性
- 序数属性
- 数值属性

□ 离散属性vs连续属性

- 标称属性的值是事物的标号或者名称。
- 每一个值表示类别、编码或者状态。
- 值没有次序信息。
- 在计算机领域，也可以称为枚举型。
- 举例
 - Hair_color = {black, blond, brown, grey, red, white}
 - marital status = {single, married, divorced, widowed}
 - Occupation = {teacher, dentist, programmer, farmer, and so on}
- 数学运算 → 有没有意义？

{black---1, blond---2, brown---3,
grey---4, red---5, white---6}



□ 二元属性只有两个类别或状态 (0 and 1)

- 0通常表示该属性不出现, 1表示出现


□ 布尔属性: true,false

例如: smoker (1-smokes, 0-not); medical test (1-positive, 0-negative)

注意, 二元属性是标称属性的特例

➤ 对称的二元属性 (Symmetric binary): 它的两种状态具有同等价值并携带相同的权重

- e.g., gender (性别)



➤ 非对称的二元属性 (Asymmetric binary): 其状态的结果不是同样重要的

- e.g., 疾病化验(positive vs. negative)
- Convention: assign 1 to most important outcome (e.g., HIV positive)

□ 数学运算 → 有没有意义?

□可能的值之间具有有意义的序或秩评定(ranking)

□但是相继值之间的差是未知的

■ $\text{Size} = \{\text{small, medium, large}\},$

■ $\text{Grade} = \{A+, A-, A, B+, \dots\}$

■ 序数属性可以用来记录不能客观度量的主观质量评估



在调查中常用来排序。

例如，参与者作为顾客，他们的满意度可以是：

0非常不满意，1有点不满意，2中立，3满意，4很满意

□数学运算→ 有没有意义？

- 定性的，描述对象的特征，而不给出实际大小或数量。
- 定性属性通常是代表类别的词。
- 如果使用整数，则代表类别的编码，而不是测量的量。

□ 定量的 (整数或实数):

■ 区间标度属性 (Interval-scale attributes)

- 用相等的单位尺度度量
- 区间属性的值有序，可以为正，0，负，允许定量评估值之间的差
- 没有真正的零值


例如：摄氏温度没有真正的零点，即： 0°C 不表示“没有温度”，尽管可以计算温度值之差，但是不能说一个温度值是另一个的倍数。

温度 10°C 比 5°C 高出 5°C ，但是可以说 10°C 比 5°C 温暖2倍吗？

摄氏温标

18世纪，瑞典人**摄尔修斯**提出：

如果把冰水混合物的温度设定为 0° 度，烧开的水是 100° 度，中间分成一百份，这样就得到了温度的计量标准。



由于他姓摄，这种温度单位就叫**摄氏度**。

但是，摄氏度毕竟是人为设定的。后来**开尔文**提出用**绝对零度**为起点，建立了更科学的**开尔文温度**，

开氏度(K)=摄氏度($^{\circ}\text{C}$)+273.15。

□ 定量的 (整数或实数):

■ 比率标度属性 (Ratio-scale attributes)

➤ 具有固定零点的数值属性

例如：开氏温标、字数、货币数量、工作年限

➤ 有序

➤ 可以说一个值是另一个的倍数 (或比率)

($10 K^{\circ}$ 是 $5 K^{\circ}$ 的两倍, 100元比1元富有100倍)

□ 离散属性

- 具有有限或无限可数个值
- 可以用或不用整数表示
 - 例如：发色、是否吸烟、医学检查结果、饮料尺寸、邮政编码、电话号码等

□ 连续属性

- 连续值是实数
- 实数值用有限位数字表示
- 连续属性一般用浮点变量表示
- 如果值不是离散的，则是连续的。数值属性或者连续属性是含义上是一样的。
 - 例如：温度、高度、宽度等

□ 离散属性：定性的

- 标称属性
- 二元属性
- 序数属性


□ 连续属性：定量的

- 数值属性
 - 区间标度属性
 - 比率标度属性

属性的特性

The type of an attribute depends on which of the following properties it possesses:

- Distinctness: $= \neq$
- Order: $< >$
- Addition: $+ -$
- Multiplication: $* /$



- 标称属性: distinctness
- 序数属性: distinctness & order
- 区间标度属性: distinctness, order & addition
- 比率标度属性: all 4 properties

示例1



预测是否适合打高尔夫球

Day	Outlook	Temperature	Humidity	Windy	Play Golf?
1	Sunny	85	85	False	No
2	Sunny	80	90	True	No
3	Overcast	83	78	False	Yes
4	Rainy	70	96	False	Yes
5	Rainy	68	80	False	Yes
6	Rainy	65	70	True	No
7	Overcast	64	65	True	Yes
8	Sunny	72	95	False	No
9	Sunny	69	70	False	Yes
10	Rainy	75	80	False	Yes
11	Sunny	75	70	True	Yes
12	Overcast	72	90	True	Yes
13	Overcast	81	75	False	Yes
14	Rainy	71	80	True	No

□ 数据属性

- 标称属性
- 二元属性
- 序数属性
- 数值属性

□ 离散属性

连续属性



移动设备用户年龄和性别预测

特征字段	字段描述
device_id	用户对应设备号, 唯一表示, 无重复
gender	用户性别, 0为男性, 1为女性
age	用户年龄
phone_brand	手机品牌
device_model	手机型号
event_id	事件id
app_id	应用程序id
is_installed	是否安装
is_active	是否激活

device_id	gender	age	phone_bra	device_model
0	0	35	0	0
1	1	37	1	1
2	0	32	1	2
3	1	28	1	2
4	0	75	2	3
5	0	25	0	4
6	0	27	3	5

event_id	app_id	is_installed	is_active	device_id	tag_list	date
280934	224	1	0	1	[1012]	4
280934	375	1	1	1	[713, 704, 548, 756, 761, 777, 782, 787, 25]	4
280934	1	1	1	1	[713, 704, 548]	4
280934	458	1	1	1	[549, 713, 724, 548, 704, 130]	4
280934	2	1	0	1	[549, 710, 704, 548, 172]	4

示例3



房价预测

	A	B	C	D	E	F
1	link	title	model	community	built	region
2	https://sh.lianjia.com/ersh	中凯城市之光(静安) 2室1	2室1厅 79.47平米 南	中凯城市之光(静安)	中楼层(共34层)2003年建	南京西路
3	https://sh.lianjia.com/ersh	中凯城市之光(静安) 2室1	2室1厅 83.79平米 南	中凯城市之光(静安)	中楼层(共34层)2003年建	南京西路
4	https://sh.lianjia.com/ersh	古美小区 2室1厅 285万	2室1厅 59.82平米 南	古美小区	高楼层(共6层)1990年建板	古美
5	https://sh.lianjia.com/ersh	荣乐小区 2室1厅 205万	2室1厅 55.1平米 南	荣乐小区	低楼层(共6层)1986年建板	松江老城
6	https://sh.lianjia.com/ersh	稀 缺房源 中高区大三房	3室2厅 144平米 西南	慧芝湖花园	中楼层(共36层)2009年建	大宁
7	https://sh.lianjia.com/ersh	云舫小区 2室2厅 460万	2室2厅 75.41平米 东	云舫小区	低楼层(共18层)1989年建	北外滩
8	https://sh.lianjia.com/ersh	2+1户型+产权车位+地铁	3室2厅 130.31平米	苏堤春晓名苑	中楼层(共32层)2005年建	长寿路
9	https://sh.lianjia.com/ersh	银都新村(1至7区) 2室1厅	2室1厅 65.44平米 南	银都新村(1至7区)	低楼层(共6层)1995年建板	颛桥
10	https://sh.lianjia.com/ersh	品质小区, 精装修, 有产	3室2厅 115.22平米	海华花园	低楼层(共33层)1994年建	打浦桥
11	https://sh.lianjia.com/ersh	香樟小区 2室1厅 380万	2室1厅 62.75平米 南	香樟小区	中楼层(共6层)1995年建板	张江

G	H	I	J
num	traffic	price	单价 (每平米)
414人关注 / 共269次带看	距离2号线南京西路站649	750	94376
147人关注 / 共193次带看	距离2号线南京西路站596	850	101445
322人关注 / 共49次带看 /	距离12号线东兰路站649	285	47643
75人关注 / 共34次带看 /	距离9号线松江体育中心	205	37206
10人关注 / 共11次带看 /	距离1号线上海马戏城站	1320	91667
88人关注 / 共62次带看 /	距离4号线大连路站378米	460	61000
52人关注 / 共28次带看 /	距离7号线长寿路站892米	1130	86717
80人关注 / 共49次带看 /	房本满五年	275	42024
95人关注 / 共117次带看 /	距离9号线打浦桥站237米	890	77244
71人关注 / 共47次带看 /	距离2号线广兰路站1151	380	60558
39人关注 / 共41次带看 /	距离1号线新闸路站294米	1380	91409
17人关注 / 共64次带看 /	距离1号线上海体育馆站	1050	92773

2 认识数据



2.1 数据对象与属性类型

2.2 数据的基本统计描述 

2.3 数据可视化

2.4 度量数据的相似性和相异性

2.2 数据的基本统计描述



统计描述的目标是为了更好地理解数据

▣ 2.2.1 中心趋势度量(Central tendency)

度量数据分布的中部或中心位置

均值、中位数、中列数、众数


▣ 2.2.2 度量数据散布(Spread)

数据如何分散

(1) 极差、分位数、四分位数、四分位数极差

(2) 五数概括

(3) 方差和标准差



2.2.1 中心趋势度量——均值



- 均值(algebraic measure):

$$\bar{x} = \frac{\sum_{i=1}^N x_i}{N} = \frac{x_1 + x_2 + \cdots + x_N}{N}$$


- 加权算术均值或加权平均 (Weighted arithmetic mean) :

$$\bar{x} = \frac{\sum_{i=1}^N w_i x_i}{\sum_{i=1}^N w_i} = \frac{w_1 x_1 + w_2 x_2 + \cdots + w_N x_N}{w_1 + w_2 + \cdots + w_N}$$

权重 w 代表的是重要性、发生频率等

- 截尾均值 (Trimmed mean) :

丢弃高低极端值后的均值



2.2.1 中心趋势度量——中位数



□ Median（中位数）

- 按顺序排列的一组数据中居于中间位置的数，代表一个样本、种群或概率分布中的一个数值，其可将数值集合划分为相等的上下两部分。
- 对于有限的数集，可以通过把所有观察值**高低排序**后找出正中间的一个作为中位数。
- 如果观察值有偶数个，通常取**最中间的两个数值的平均数**作为中位数。
- 找出这组数据：23、29、20、32、23、21、33、25
的中位数
?

Median (中位数)

- 当观测的数量很大时，中位数的计算开销很大。对于数值属性，很容易用插值计算出中位数的近似值。

$$median = L_1 + \left(\frac{\frac{N}{2} - (\sum freq)_l}{freq_{median}} \right) width$$

公式中， L_1 是中值区间的最低值， N 是数据值的个数， $(\sum freq)_l$ 是所有低于中值区间的所有区间的频率之和。 $freq_{median}$ 是中值区间的频率，width是中值区间的宽度（极差）。



年龄	频数
1~3	100
4~10	250
11~20	2000
21~30	600
31~60	850
61~80	66

□ 中列数：



- 是数据集中最大值和最小值的平均值。
- 可以用来评估数值型数据的中心性趋势。

2.2.1 中心趋势度量——众数



□ 众数 (Mode)

- 集合中出现最频繁的值
- 可能最高频率对应多个不同值，导致多个众数
- 单峰的、双峰的、三峰的
- 极端的情况下，如果每个值都仅出现一次，则没有众数



2.2.1 中心趋势度量——众数



□ Mode（众数）

- 是一组数据中出现次数最多的数值，有时众数在一组数中有好几个，是在统计分布上具有明显集中趋势点的数值，代表数据的一般水平。

□ 均值，中位数，众数区别

1、平均数是通过全部数据计算得到的，因此它会因每一个数据的变化而变化。

2、中位数是通过排序得到的，它不受最大、最小两个极端数值的影响。部分数据的变动对中位数没有影响，当一组数据中的个别数据变动较大时，常用它来描述这组数据的集中趋势。

3、众数也是数据的一种代表数，反映了一组数据的集中程度。日常生活中诸如“最佳”、“最受欢迎”、“最满意”等，都与众数有关系，它反映了一种最普遍的倾向。

0, 1, 5, 5, 6, 8, 100

0, 1, 5, 5, 6, 8, 10

2.2.1 中心趋势度量



□ 标称属性:

{black---1, blond---2, brown---3,
grey---4, red---5, white---6}

□ 序数属性: 0非常不满意, 1有点不满意, 2中立, 3满意, 4很满意

□ 区间标度属性: 摄氏温度 $0C^{\circ}$ 、 $5C^{\circ}$ 、 $10C^{\circ}$

□ 比率标度属性: 分数60、70、80

■ 计算这些值有意义吗?

➤ 众数 (?)

1 1 2 3 1

➤ 中位数 (?)

➤ 均值 (?)

80 81 60 90 80

➤ 计算值之间的差 (?)


➤ 比率(?)

Attribute Type	Description	Examples	Operations
标称 Nominal	The values of a nominal attribute are just different names, i.e., nominal attributes provide only enough information to distinguish one object from another. (=, ≠)	zip codes, employee ID numbers, eye color, sex: { <i>male</i> , <i>female</i> }	mode
序数 Ordinal	The values of an ordinal attribute provide enough information to order objects. (<, >)	hardness of minerals, { <i>good</i> , <i>better</i> , <i>best</i> }, grades, street numbers	Mode, median
区间 Interval	For interval attributes, the differences between values are meaningful, i.e., a unit of measurement exists. (+, -)	calendar dates, temperature in Celsius or Fahrenheit	Mode, median, mean, standard deviation
比率 Ratio	For ratio variables, both differences and ratios are meaningful. (*, /)	temperature in Kelvin, monetary quantities, counts, age, mass, length, electrical current	Mode, median, mean, standard deviation, ratio


2.2.1 中心趋势度量




- 在具有完全对称的数据分布的单峰频率曲线中，均值、中位数和众数都是相同的中心值。
- 在大部分实际应用中，数据都是不对称的。它们可能是正倾斜的，其中众数出现在小于中位数的值上；或者是负倾斜的，众数出现在大于中位数的值上。



a) 对称数据



b) 正倾斜数据



c) 负倾斜数据

2.2.2 度量数据散布




考察评估数值数据散布或发散的度量。

- 极差 (Range)
- 分位数 (quantiles)
- 四分位数 (quartiles)
- 四分位数极差 (interquartile range)
- 五数概括
- 方差
- 标准差

2.2.2 度量数据散布



- **极差**表示的是最大值和最小值的差
- **分位数 (quantile)** 是取自数据分布的每隔一定间隔上的点，把数据划分成基本上大小相等的连贯集合。
- **四分位数 (quartile)** : Q_1 (25th percentile), Q_3 (75th percentile)
- **四分位数极差**: $IQR = Q_3 - Q_1$



如何计算四分位数？

□ 1) 对所有数据进行排序

□ 2) 计算 $(n+1)*f\% = j+q$

其中 n 是数据个数, f 是分位数, j 是个整数

■ 如果 $q=0$, $x(j)$ 是 $f\%$ 的分位数

■ 如果 q 不等于 0, $\text{quantile } f\% = 0.5*x(j) + 0.5*x(j+1)$

2.2.2 度量数据散布



练习：

□ Example 1: 3,5,7,6,4,8,9

排序: 3,4,5,6,7,8,9

$n=7$

$f^0\%=25\%$: $(n+1)*f^0\%=8*25\%=2$ $j=2$ $q=0$ $x(j)=x(2)=4$

$f^0\%=50\%$: $(n+1)*f^0\%=8*50\%=4$ $j=4$ $q=0$ $x(j)=x(4)=6$

$f^0\%=75\%$: $(n+1)*f^0\%=8*75\%=6$ $j=6$ $q=0$ $x(j)=x(6)=8$

2.2.2 度量数据散布



Example 2: 2,6,5,3,4,7

如果 q 不等于0, quantile $f\% = 0.5 * x(j) + 0.5 * x(j+1)$

排序: 2,3,4,5,6,7

$n=6$

$f\%=25\%$: $(n+1)*f\%=7*25\%=1.75$ $j=1$ $q=0.75$ 2.5


$f\%=50\%$: $(n+1)*f\%=7*50\%=3.5$ $j=3$ $q=0.5$ 4.5

$f\%=75\%$: $(n+1)*f\%=7*75\%=5.25$ $j=5$ $q=0.25$ 6.5

2.2.2 度量数据散布




□ 五数概括 (Five number summary): min, Q_1 , median, Q_3 , max



2.2.2 度量数据散布



- 一个通用的鉴别可疑的**离群点**的规则是挑选出落在 Q_3 以上或者 Q_1 以下至少 $1.5 \times IQR$ 以上的数据值




□ 方差和标准差

方差: (algebraic, scalable computation)

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^n (x_i - \mu)^2$$

标准差 σ 是 σ^2 的平方根。

- 方差和标准差 → 散布程度
- 均值 → 中心
- $\sigma = 0$, no spread; $\sigma > 0$
- 方差越小数据稳定性越强



2 认识数据



2.1 数据对象与属性类型

2.2 数据的基本统计描述

2.3 数据可视化 

2.4 度量数据的相似性和相异性

2.3.1 数据可视化概述




- 大数据时代的到来，每时每刻都有海量数据在不断生成，可视化成为大数据分析的重要一环。
- 20世纪50年代，随着计算机出现和计算机图形学发展，利用计算机技术在电脑屏幕上绘制出各种图形图表，可视化技术开启了全新发展阶段。



2.3.1 数据可视化概述



- 将大型数据集中的**数据以图形图像形式**表示，并利用数据分析和开发工具发现其中未知信息的处理过程，并以图展示出来。
- 将数据的**各个属性值以多维数据的形式**表示，可以从不同的维度观察数据，从而对数据进行更深入的分析。




2.3.1 数据可视化概述



2.3.1 数据可视化概述



分析数据



霍乱地图分析了霍乱患者分布与水井分布之间的关系，发现在有一口井的供水范围内患者明显偏多，据此找到了霍乱爆发的根源是一个被污染的水泵

反映霍乱患者分布与水井分布的地图

2.3.1 数据可视化概述



增强数据吸引力

地铁花费悬殊， 大约占月收入的 1%-18%

如果以普通上班族每天坐两趟地铁坐 **22 个工作日**，每月买 **44 张地铁票**来算，在不同的城市要花多少钱呢？



注：


票价和收入统一兑换为人民币；收入数据说明：广州为 2013 年居民平均收入；纽约为 2013 年居民月收入中值；香港、新德里、东京为 2012 年服务行业平均收入。



广州

分段计价 **2-14 元**

月花费 **88-616 元**
月平均收入 **5952 元**



东京

分段计价 **9.6-17.5**

月花费 **422-770 元**
月平均收入 **28792 元**



纽约

统一票价 **15 元** 任意换乘

月花费 **660 元**
月平均收入 **29386 元**



新德里

分段计价 **0.8-3 元**

月花费 **18-66 元**
月平均收入 **1276 元**



香港


分段计价：现金支付 **3.5-44 元**
刷卡支付 **3.3-37 元**

月花费 **145-1936 元**
月平均收入 **10278 元**



一个可视化的图表新闻实例

2.3.1 数据可视化概述




Capable language models can outgrow the benefits of collaboration, Nature Machine Intelligence, 2026

2.3.1 数据可视化概述




增强数据吸引力



A foundation model to predict and capture human cognition, Nature, 2025

2.3.1 数据可视化概述






Explainable deep learning improves human mental models of self-driving cars, Nature, 2026

2.3.2 数据可视化图表




图表	维度	应用场景
柱状图	二维	指定一个分析轴进行数据大小的比较 只需比较其中一维
折线图	二维	按照时间序列分析数据的变化趋势 适用于较大的数据集
饼图	二维	指定一个分析轴进行所占比例的比较 只适用于反映部分与整体的关系
散点图	二维或三维	有两个维度需要比较
气泡图	三维或四维	其中只有两维能够精确辨识
雷达图	四维以上	数据点不超过6个



2.3.2.1 盒图



- Boxplot(盒图): Q_1, Q_2, Q_3 , 须, 离群点 (Univariate, Bivariate)
- 盒的端点一般在四分位数上
- 箱子的长度是四分位数极差IQR
- 中位数是箱子中间的线
- 箱子外面的两根须是观察的最小值和最大值



须的规则:

最大值 $< Q_3 + 1.5 * IQR$, 扩展到最大值

最小值 $> Q_1 - 1.5 * IQR$, 扩展到最小值

最大值 $> Q_3 + 1.5 * IQR$, 扩展到 $Q_3 + 1.5 * IQR$

最小值 $< Q_1 - 1.5 * IQR$, 扩展到 $Q_1 - 1.5 * IQR$


或者 $[Q_1 - 1.5 * IQR, Q_3 + 1.5 * IQR]$ 正常范围内的最大值或最小值

2.3.2.1 盒图




- 四分位数 (quartile) : Q_1 (25th percentile), Q_3 (75th percentile)
- 四分位数极差: $IQR = Q_3 - Q_1$

3 4 5 6 7 8 9




3 4 5 6 7 8 30



2.3.2.2 直方图



- 直方图(histogram)或频率直方图(frequency histogram) 是单数据值
- 数据区间x-axis 表示值, y-axis表示频次
 - 如果 X 是标称的, 对于 X 的每一个已知值, 画一个柱或竖直线, 条的高度标示 X 值出现的频率, 更多地称作条形图。
 - 如果 X 是数值的, 更多使用直方图。 X 的值域被划分为不相交连续子域, 子域称作桶(bucket)或者箱(bin), 桶的范围称作宽度, 通常桶是等宽的。




2.3.2.2 直方图



数据:


1,1,5,5,5,5,5,8,8,10,10,10,10,12,14,14,14,15,15,15,15,15,15,18,18,18,18,18,18,18,18,20,20,20,20,20,20,20,21,21,21,21,25,25,25,25,25,28,28,30,30,30



2.3.2.3 散点图




- 每个值对视为一个代数坐标对，并作为一个点画在平面上。
- 一种观察**双变量数据**的有用的方法，用于观察点簇和离群点。
- 可以观察两个变量之间的关系、趋势等信息。




2.3.2.3 散点图



- 两个属性X和Y，如果一个属性蕴含另一个，则它们是相关的。相关可能是正、负或零相关。



正相关：从左下到右上倾斜，意味着X的值随Y的值增加而增加



负相关：从左上到右下倾斜，意味着X的值随Y的值减小而增加




不相关：两个属性之间不存在相关关系。

2.3.2.3 散点图




Edgar Anderson's Iris Data




Matrix of scatterplots (x-y-diagrams) of the k -dim. data [total of $(k*(k-1)/2)$ scatterplots]

2.3.2.4 平行坐标(高维)




2.3.2.5 思维导图




Dendrogram

家狗的不同物种
的单倍体基因序
列的比较分析



Kerstin Lindblad-Toh et al. *Nature* 438, 803-819 (8 December 2005)



2.3.3 数据可视化工具




- ❑ Echarts
- ❑ D3
- ❑ Tableau
- ❑ Google Chart API
- ❑ CiteSpace、Gephi
- ❑ t-SNE
- ❑ Power BI
- ❑ Plotly、Dash
- ❑ Flourish
- ❑ Datawrapper
- ❑ Observable Plot
- ❑ Apache Superset
- ❑ PyGWalker
- ❑ Grafana

2.3.3.1 ECharts




百度公司前端数据可视化团队研发的图表库，可以流畅地运行在PC和移动设备上，兼容当前绝大部分浏览器（IE8/9/10/11、Chrome、Firefox、Safari等），底层依赖轻量级的、Canvas类库ZRender，可提供直观、生动、可交互、可高度个性化定制的数据可视化图表

ECharts提供非常丰富的图表类型，包括常规的折线图、柱状图、散点图、饼图、K线图，用于统计的盒形图，用于地理数据可视化的地图、热力图、线图，用于关系数据可视化的关系图、treemap，用于多维数据可视化的平行坐标，以及用于BI的漏斗图、仪表盘，并支持图与图之间的混搭，能满足用户大部分分析数据的图表制作需求




2.3.3.2 D3



D3 的全称是（Data-Driven Documents），是一个 JavaScript 的函数库，使用它主要是用来做数据可视化的。D3提供的可视化图表-Voronoi图、树形图、圆形集群和单词云

2.3.3.3 Tableau



Tableau是桌面系统中最简单的商业智能工具软件
适合企业和部门进行日常数据报表和数据可视化分析工作

2.3.3.4 时间线



Timetoast

Timetoast是在线创作**基于时间轴**事件记载服务的网站，提供个性化时间线服务，可用不同的时间线来记录你某个方面的发展历程、心理路程、进度过程等Timetoast基于flash平台，操作简单

时间线图




Xtimeline

Xtimeline 是一个免费的绘制时间线的在线工具网站，操作简便，用户通过添加事件日志的形式构建时间表，同时也可给日志配上相应的图表。Xtimeline是一个社区类型的间轴网站


2.3.3.5 Google Chart API




How Much Pizza I Ate Last Night - 饼图 3D




Age vs. Weight comparison - 散点图




Monthly Coffee Production by Country - 组合图




Company Performance - 折线图




Company Performance - 条图



Company Performance - 柱状图



Company Performance - 面积图



蜡烛图




通过浏览器在线查看Google Chart统计图表

2.3.3.6 CiteSpace





CiteSpace又翻译为“引文空间”，是一款着眼于分析科学分析中蕴含的潜在知识，是在科学计量学、数据可视化背景下逐渐发展起来的引文可视化分析软件。由于是通过可视化的手段来呈现科学知识的结构、规律和分布情况，因此也将通过此类方法分析得到的可视化图形称为“科学知识图谱”。




2.3.3.7 Gephi



是一款开源免费跨平台基于JVM的复杂网络分析软件，其主要用于各种网络和复杂系统，动态和分层图的交互可视化与探测开源工具。






2.3.3.9 深度模型画图工具



<https://cbovar.github.io/ConvNetDraw/>



2 认识数据



2.1 数据对象与属性类型



2.2 数据的基本统计描述

2.3 数据可视化

2.4 数据的相似性和相异性




2.4 相似性和相异性



很多的算法越来越依赖于在输入空间给定的好的度量。

例如K-means、K近邻方法、SVM、深度学习等算法需要给定好的度量来反映数据间存在的一些重要关系。



2.4 相似性和相异性



2.4 相似性和相异性



□ 相似性(similarity)

- 描述两个数据对象的相似程度
- 当两个数据对象更相似时，值更高
- 通常落在 $[0,1]$ 范围内

□ 相异性(e.g., distance)

- 描述两个数据对象的差异程度
- 当两个数据对象更相似时，值更低
- 最小相异度通常为0

□ 相似性和相异性都称邻近性

2.4 相似性和相异性



- 2.4.1 数据矩阵与相异性矩阵
- 2.4.2 标称属性的邻近性度量
- 2.4.3 二元属性的邻近性度量
- 2.4.4 序数属性的距离
- 2.4.5 数值属性的距离
- 2.4.6 余弦相似度
- 2.4.7 度量学习
- 2.4.8 多模态对齐中的相似度
- 2.4.9 大模型嵌入与 RAG 检索
- 2.4.10 视觉文档 RAG 的细粒度相关度

2.4.1 数据矩阵与相异性矩阵



□ n 个对象, p 个属性

$$\begin{bmatrix} x_{11} & \cdots & x_{1f} & \cdots & x_{1p} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{i1} & \cdots & x_{if} & \cdots & x_{ip} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{n1} & \cdots & x_{nf} & \cdots & x_{np} \end{bmatrix}$$

甲状腺病人与正常人5项指标及归类

样品	v1	v2	v3	v4	v5	归类
1	-1.31	0.80	0.78	-0.70	-0.61	1
2	-0.63	0.75	1.94	-0.61	-0.42	1
3	0.70	1.48	1.04	-0.66	-0.73	1
4	-0.97	0.87	0.01	-0.64	-0.61	1
5	-1.42	0.63	0.78	-0.65	-0.71	1
6	-1.31	1.50	-0.63	-0.70	-0.58	1
7	-0.97	1.09	0.91	-0.70	-0.57	1
8	-0.28	0.58	1.43	-0.69	-0.52	1
9	0.74	-1.10	-0.89	0.51	-0.21	-1
10	0.17	0.00	0.66	0.04	1.54	-1
11	0.06	-0.73	-0.63	1.01	-0.43	-1
12	2.56	-0.30	0.27	-0.06	0.09	-1
13	1.19	-1.29	-1.27	0.20	-0.60	-1
14	-0.06	-0.78	-0.12	0.13	2.15	-1
15	0.17	-1.19	-1.14	0.66	0.67	-1
16	0.06	-1.46	-1.14	3.58	0.52	-1

2.4.1 数据矩阵与相异性矩阵



□ 数据矩阵

- 二模矩阵(行和列分别代表不同的个体)
- 由两种实体或“事物”组成,即行(对象)和列(属性)

$$\begin{bmatrix} x_{11} & \dots & x_{1f} & \dots & x_{1p} \\ \dots & \dots & \dots & \dots & \dots \\ x_{i1} & \dots & x_{if} & \dots & x_{ip} \\ \dots & \dots & \dots & \dots & \dots \\ x_{n1} & \dots & x_{nf} & \dots & x_{np} \end{bmatrix}$$

□ 相异性矩阵

- 单模矩阵
- 只包含一类实体

$$\begin{bmatrix} 0 & & & & \\ d(2,1) & 0 & & & \\ d(3,1) & d(3,2) & 0 & & \\ \vdots & \vdots & \vdots & & \\ d(n,1) & d(n,2) & \dots & \dots & 0 \end{bmatrix}$$

2.4.2 标称属性的邻近性度量



- 可以取两个或者多个状态, e.g., 头发的颜色有黑色、红色、黄色、棕色等
- 方法 1: 简单的匹配

- 距离

$$d(i, j) = \frac{p - m}{p}$$

- 相似度

$$\text{sim}(i, j) = 1 - d(i, j) = \frac{m}{p}$$

m : 匹配的数目 (即 i 和 j 取值相同状态的属性数)

p : 刻画对象的属性总数

2.4.2 标称属性的邻近性度量



□ 举例:*hair-color, country, smoking status*

$d_1 = \{\text{red, China, smoker}\}$

$d_2 = \{\text{black, China, non-smoker}\}$

$d(1,2)=?$

$\text{sim}(1,2)=?$

2.4.2 标称属性的邻近性度量



□ 方法2: one-hot编码

■ 采用0-1值代表 M 个状态

□ Example: *hair-color, country, smoking status*

$d_1 = \{\text{red, not China, smoker}\}$

$d_2 = \{\text{black, China, non-smoker}\}$

$d_3 = \{\text{yellow, China, non-smoker}\}$

$d_1 = \{001, 01, 01\}$

$d_2 = \{010, 10, 10\}$

$d_3 = \{100, 10, 10\}$

2.4.3 二元属性的邻近性度量



Name	Gender	Fever	Cough
Jack	1	1	0
Mary	0	1	0
Jim	1	0	1

表 2.3 二元属性的列联表

		对象 j		
		1	0	sum
对象 i	1	q	r	$q + r$
	0	s	t	$s + t$
	sum	$q + s$	$r + t$	p

□ 当两个状态是同等重要时：

对称的二元相异性

$$d(i, j) = \frac{r + s}{q + r + s + t}$$

□ 当两个状态不是同等重要时：

■ 非对称的二元相异性

$$d(i, j) = \frac{r + s}{q + r + s}$$

■ 非对称的二元相似性

$$\text{sim}_{\text{Jaccard}}(i, j) = \frac{q}{q + r + s}$$

q 是在对象 i 和 j 都取1的属性数, r 是在对象 i 中取1, 在 j 中取0的属性数, s 是在对象 i 中取0, 在 j 中取1的属性数, t 是对象 i 和 j 都取0的属性数

2.4.3 二元属性的邻近性度量



对象标识符		对称属性		非对称二元属性			
Name	Gender	Fever	Cough	Test-1	Test-2	Test-3	Test-4
Jack	M	Y	N	P	N	N	N
Mary	F	Y	N	P	N	P	N
Jim	M	Y	P	N	N	N	N

只按非对称属性计算，
Y, P取1，N取0

$$d(i, j) = \frac{r + s}{q + r + s}$$

$$d(jack, mary) = \frac{0 + 1}{2 + 0 + 1} = 0.33$$

$$d(jack, jim) = \frac{1 + 1}{1 + 1 + 1} = 0.67$$

$$d(jim, mary) = \frac{1 + 2}{1 + 1 + 2} = 0.75$$

2.4.4 序数属性的距离



- 序数属性的值之间具有有意义的序或排位，相继值之间的量值未知。
- 数值属性的值域可以映射到具有 M_f 个状态的序数属性 f .
 - 第 i 个对象的 f 值为 x_{if} ，属性 f 有 M_f 个有序状态，用对应的排位 $r_{if} \in \{1, \dots, M_f\}$ 取代 x_{if}
 - 将每个属性的值域映射到 $[0, 1]$ 上，以便每个属性都有相同的权重。


$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

- 采用任意一种数值属性的距离度量计算。

2.4.4 序数属性的距离



point	attribute 1
x1	Excellent
x2	fair
x3	good
x4	Excellent



point	attribute 1	
x1	Excellent	3
x2	fair	1
x3	good	2
x4	Excellent	3



point	attribute 1	
x1	Excellent	1
x2	fair	0
x3	good	0.5
x4	Excellent	1

欧式
距离

L2	x1	x2	x3	x4
x1	0			
x2	1	0		
x3	0.5	0.5	0	
x4	0	1	0.5	0


- 欧几里得距离（欧式距离）（Euclidean Distance）
- 曼哈顿距离（Manhattan Distance）
- 闵可夫斯基距离（Minkowski Distance）

2.4.5数值属性的距离



欧几里得距离：两点间的直线距离。即平时生活中默认使用的距离。

勾股定理：如果直角三角形两个直角边长度为a和b，斜边长度为c，那么 $a^2+b^2=c^2$



欧几里得距离

(1)二维平面上两点 $A(x_1, y_1)$ 与 $B(x_2, y_2)$ 间的欧氏距离:

$$d_{12} = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

(2)三维空间两点 $A(x_1, y_1, z_1)$ 与 $B(x_2, y_2, z_2)$ 间的欧氏距离:

$$d_{12} = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2}$$

(3)两个 n 维向量 $A(x_{11}, x_{12}, \dots, x_{1n})$ 与 $B(x_{21}, x_{22}, \dots, x_{2n})$ 间的欧氏距离:


$$d_{12} = \sqrt{\sum_{k=1}^n (x_{1k} - x_{2k})^2}$$

注意: 如果两个点的范围差别较大, 需要标准化

2.4.5数值属性的距离



欧几里得距离



Data Matrix

point	attribute1	attribute2
x_1	1	2
x_2	3	5
x_3	2	0
x_4	4	5

Dissimilarity Matrix

(with Euclidean Distance)

	x_1	x_2	x_3	x_4
x_1	0			
x_2	3.61	0		
x_3	2.24	5.1	0	
x_4	4.24	1	5.39	0

2.4.5数值属性的距离




曼哈顿距离 (Manhattan Distance)

也称作城市街区距离(City Block distance), 用以标明两个点在标准坐标系上的绝对轴距总和。

想象你在曼哈顿要从一个十字路口开车到另外一个十字路口, 驾驶距离是两点间的直线距离吗? 显然不是, 除非你能穿越大楼。实际驾驶距离就是这个“曼哈顿距离”。

图中红线代表曼哈顿距离, 绿色代表欧式距离, 也就是直线距离, 蓝色和黄色代表等价的曼哈顿距离。



2.4.5数值属性的距离




曼哈顿距离

(1) 二维平面两点 $a(x_1, y_1)$ 与 $b(x_2, y_2)$ 间的曼哈顿距离


$$d_{12} = |x_1 - x_2| + |y_1 - y_2|$$

(2) 两个 n 维向量 $a(x_{11}, x_{12}, \dots, x_{1n})$ 与 $b(x_{21}, x_{22}, \dots, x_{2n})$ 间的曼哈顿距离

$$d_{12} = \sum_{k=1}^n |x_{1k} - x_{2k}|$$



Manhattan



Euclidean

2.4.5数值属性的距离



欧几里得距离和曼哈顿距离满足如下数学性质：

$d(i, j)$ 是 i 和 j 的距离

- $d(i, j) > 0$ if $i \neq j$ (非负性)
- $d(i, j) = 0$ (同一性)
- $d(i, j) = d(j, i)$ (对称性)
- $d(i, j) \leq d(i, k) + d(k, j)$ (三角不等式)

满足这些条件的测度称作是度量

2.4.5数值属性的距离



闵可夫斯基距离 (Minkowski distance)
是欧几里得距离和曼哈顿距离的推广

$$d(i, j) = \sqrt[h]{|x_{i1} - x_{j1}|^h + |x_{i2} - x_{j2}|^h + \cdots + |x_{ip} - x_{jp}|^h}$$

$i = (x_{i1}, x_{i2}, \dots, x_{ip})$ 和 $j = (x_{j1}, x_{j2}, \dots, x_{jp})$ 表示两个数据对象，
 h 是个实数，也被称作 L_h 范数，有些书上习惯称作 L_p 范数

2.4.5数值属性的距离



闵可夫斯基距离的特例

□ $h = 1$: 曼哈顿距离 (城市块距离, L_1 范数)

■ E.g., the Hamming distance: the number of bits that are different between two binary vectors

$$d(i, j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \dots + |x_{ip} - x_{jp}|$$

□ $h = 2$: 欧几里得距离 (L_2 范数)

$$d(i, j) = \sqrt{(|x_{i1} - x_{j1}|^2 + |x_{i2} - x_{j2}|^2 + \dots + |x_{ip} - x_{jp}|^2)}$$

□ $h \rightarrow \infty$. 上确界距离 ($L_{\max}$ 范数, L_{∞} 范数)

■ This is the maximum difference between any component (attribute) of the vectors

$$d(i, j) = \lim_{h \rightarrow \infty} \left(\sum_{f=1}^p |x_{if} - x_{jf}|^h \right)^{\frac{1}{h}} = \max_f |x_{if} - x_{jf}|$$


2.4.5数值属性的距离



距离矩阵

Manhattan (L_1)

point	attribute 1	attribute 2
x1	1	2
x2	3	5
x3	2	0
x4	4	5



Euclidean (L_2)

Supremum

2.4.5数值属性的距离




距离矩阵

Manhattan (L_1)

point	attribute 1	attribute 2
x1	1	2
x2	3	5
x3	2	0
x4	4	5

L	x1	x2	x3	x4
x1	0			
x2	5	0		
x3	3	6	0	
x4	6	1	7	0

Euclidean (L_2)



L2	x1	x2	x3	x4
x1	0			
x2	3.61	0		
x3	2.24	5.1	0	
x4	4.24	1	5.39	0

Supremum

L_∞	x1	x2	x3	x4
x1	0			
x2	3	0		
x3	2	5	0	
x4	3	1	5	0

2.4.6余弦相似性



$$\text{sim}(v_1, v_2) = \frac{v_1 \cdot v_2}{|v_1| |v_2|}$$

- 通常用于文本挖掘中，向量 v 中第 j 个数值就是相应文档中第 j 个项的量度。

$$v_1 = \{ 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0 \}$$

$$v_2 = \{ 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 0, 0, 0, 0, 0, 0 \}$$

$$v_3 = \{ 1, 1, 1, 0, 1, 0, 1, 1, 1, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0 \}$$

2.4.6 余弦相似性



$$v_1 = \{ 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0 \}$$

$$v_2 = \{ 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 1, 1, 1, 1, 1, 0, 0, 0, 0, 0, 0, 0 \}$$

$$v_3 = \{ 1, 1, 1, 0, 1, 0, 1, 1, 1, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0 \}$$



$$\text{sim}(v_1, v_2) = \frac{v_1 \cdot v_2}{|v_1| |v_2|} = \frac{0}{\sqrt{11} \times \sqrt{5}} = 0 \quad \text{sim}(v_2, v_3) = \frac{v_2 \cdot v_3}{|v_2| |v_3|} = \frac{0}{\sqrt{5} \times \sqrt{8}} = 0$$

$$\text{sim}(v_1, v_3) = \frac{v_1 \cdot v_3}{|v_1| |v_3|} = \frac{7}{\sqrt{11} \times \sqrt{8}} = \frac{7}{9.38} = 0.75$$


2.4.7 度量学习



Isometric Mapping等度量映射



Isomap (0.62 sec)





Tenenbaum J B, De V S, Langford J C. A global geometric framework for nonlinear dimensionality reduction.[J]. Science, 2000, 290(5500):2319-2323.

Isometric Mapping等度量映射

Isomap算法核心在于发现并利用流形空间的特点，引入测地线距离和提出对应的距离计算方法。


流形是在局部区域与欧氏空间同胚的空间，即在局部区域具有欧氏空间的性质，能用欧氏距离来进行距离计算。



2.4.7 度量学习



Isometric Mapping等度量映射




“测地距离”即A中沿曲实线的两点之间的距离，欧氏距离即如A中虚直线的两点之间的直线距离。B图即A的近邻图，C图即B图的低维映射结果，C图中红线为它的“测地距离”而蓝线则为欧氏距离。

对每个点基于欧氏距离找出近邻点，然后建立一个近邻图。于是计算两点之间测地距离的问题就变成了计算近邻图上两点之间的最短路径问题。

2.4.7 度量学习




Large Margin Nearest Neighbor (LMNN)



Weinberger, K. Q.; Blitzer J. C., Saul L. K. Distance Metric Learning for Large Margin Nearest Neighbor Classification, Advances in Neural Information Processing Systems 18 (NIPS). 2006: 1473–1480.

Large Margin Nearest Neighbor (LMNN)



$$\epsilon_{\text{pull}}(\mathbf{L}) = \sum_{j \rightsquigarrow i} \|\mathbf{L}(\vec{x}_i - \vec{x}_j)\|^2.$$

$$\epsilon_{\text{push}}(\mathbf{L}) = \sum_{i, j \rightsquigarrow i} \sum_l (1 - y_{il}) [1 + \|\mathbf{L}(\vec{x}_i - \vec{x}_j)\|^2 - \|\mathbf{L}(\vec{x}_i - \vec{x}_l)\|^2]_+$$


$$\epsilon(\mathbf{L}) = (1 - \mu) \epsilon_{\text{pull}}(\mathbf{L}) + \mu \epsilon_{\text{push}}(\mathbf{L}).$$

Weinberger, K. Q.; Blitzer J. C., Saul L. K. Distance Metric Learning for Large Margin Nearest Neighbor Classification, Advances in Neural Information Processing Systems 18 (NIPS). 2006: 1473–1480.

2.4.7 度量学习



Deep Metric Learning




Deep Metric Learning

- (1) 对比损失
- (2) 三元组损失 (Triplet loss)
- (3) 四元组损失(Quadruplet loss)
- (4) 难样本采样三元组损失(Triplet loss with batch hard mining, TriHard loss)
- (5) 边界挖掘损失(Margin sample mining loss, MSML)

2.4.8多模态对齐中的相似度



目标：让配对的图像与文本在共享空间中更接近，让不配对样本更远



归一化

$$z_i^I = f^I(x_i) / \|f^I(x_i)\|_2$$
$$z_j^T = f^T(t_j) / \|f^T(t_j)\|_2$$

相似度与 Sigmoid 损失

$$s_{ij} = \tau \langle z_i^I, z_j^T \rangle + b$$
$$L = 1/B^2 \sum_i \sum_j \log[1 + \exp(-y_{ij} s_{ij})]$$

$y_{ij} = +1$ 表示匹配， -1 表示不匹配； τ 为可学习温度系数。



SigLIP 2 (2025) 的前沿改进

- **成对二分类**：用 Sigmoid 损失独立判断每个图文对，避免 CLIP 对全批次 Softmax 的依赖。
- **局部语义增强**：加入图像描述、局部定位、自蒸馏与掩码预测，使图像块特征也具有语义。
- **应用**：跨语言图文检索、零样本分类、开放词汇检测与视觉语言模型的视觉编码。

2.4.9大模型嵌入与 RAG 检索



大模型需要在内部计算“注意力相似度”，也需要在外部检索中计算“语义距离”



从单一余弦相似度到混合相关度

$$s_rank = w_1s_dense + w_2s_lex + w_3s_mul$$

- **Dense:** 归一化句向量的内积，适合语义近似但措辞不同的文本。
- **Lexical:** 根据共同词项及其学习权重计算稀疏匹配，保留关键词精确匹配。
- **Multi-vector:** 保留词元级向量并采用晚交互，捕捉查询与长文档的细粒度关系。

代表工作

NV-Embed: LLM+潜在注意力池化+两阶段对比指令微调 (ICLR 2025 Spotlight)

M3-Embedding: 统一 dense、sparse 与 multi-vector, 支持100余种语言和最长8192词元


2.4.10视觉文档 RAG 的细粒度相关度




ColPali: 查询按词元表示，文档页按图像块表示，再用 *MaxSim* 完成晚交互

查询词元向量 $E_q \in \mathbb{R}^{N_q \times 128}$

文档页面图像块 $E_d \in \mathbb{R}^{N_d \times 128}$



图像中的文字、表格、图形和版式都转化为 *patch* 向量



晚交互相关度

- **MaxSim:** 每个查询词元选择最相似的页面图像块，再将各词元的最大相似度求和。
- **优点:** 比单向量更能保留局部语义，可直接检索含表格、图形和复杂版式的PDF页面。
- **RAG作用:** 先找到与问题最相关的页面，再把页面内容交给多模态大模型生成答案。

- 数据对象与属性类型：
 - 标称、二元、序数、数值属性
 - 离散、连续属性
- 统计描述
 - 度量中心趋势：均值、中位数、众数
 - 度量数据散布：极差、四分位数、方差、标准差
- 数据可视化
 - 盒图、直方图、散点图等
 - 可视化工具
- 度量数据的相似性和相异性
 - 标称属性、二元属性、序数属性
 - 数值属性：欧几里得距离、余弦相似性、度量学习

THE END

