



天津大学
Tianjin University

数据挖掘

杨柳

智能与计算学部

yangliuyl@tju.edu.cn



第 3 章 数据预处理



- 数据质量：为什么要对数据预处理？
 - 数据不规范
 - 数据维度高
 - 数据数量大
 - ...
- 怎么解决这些问题呢？

3 数据预处理



□ 3.1 数据预处理: 概述



□ 3.2 数据清洗


□ 3.3 数据集成

□ 3.4 数据归约

□ 3.5 数据变换

□ 3.6 小结

3.1 数据预处理:概述



	A	B	C	D	E	F
1	Missing data					
2						
3	Id	reading	science	history	math	medicine
4	1	12	27	10	x	44
5	2	11	x	14	13	43
6	3	x	56	17	23	60
7	4	15	37	22	19	x
8	5	22	31	x	21	42
9	6	18	x	11	22	43
10	7	15	50	13	x	56
11	8	21	x	20	28	46
12	9	20	39	19	25	x
13	10	x	36	20	23	56

有缺失


不一致

Member Code	Name	Address	BookCode
PV001	Eric Clifford	12, Kensington Terrace	AB012
PV002	Rachel Leigh	32, West Port	AB092
PV001	Eric Clifford	17, Kensington Terrace	AB221
PV002	Rachel Leigh	32, West Port	AB323
PV007	Keith Jennings	120, East Road	AB172

Welcome to the real world !!!



有噪声



高维

数据质量：为什么要对数据预处理？


□ 数据质量：

- **完整性**: not recorded, unavailable, ...
- **有噪声**: noises, outliers, eg. Salary = “-100”
- **一致性**: Age = “42” vs. Birthday = “01/09/1985”
- **准确性**: correct or wrong, accurate or not
- **时效性**: timely update?
- **可信性**: how trustable the data are correct?
- **可解释性**: how easily the data can be understood?
- relevance

数据挖掘关注什么

- 数据质量问题的检测与纠正
- 能容忍数据质量差的算法的使用

3.1.2 数据预处理的主要任务



3.1.2 数据预处理的主要任务



完成数据的如下工作：

□清洗（Data cleaning）

空缺、噪声数据处理等

□集成（Data integration）

数据合并、汇总、过滤等

□降维（data reduction）

将高维数据降低到低维空间中

□转换（Data transformation）

重新格式化和转换

3.1.2 数据预处理的主要任务



整理前的数据特点：

- ❑ 质量较差，例如缺失、噪声等；
- ❑ 数据来源多样；
- ❑ 属性维度灾难；
- ❑ 规范程度不一，依赖于数据来源。

↓ 目标：为决策支持应用提供一个高质量的数据源。 ↓

经过整合集成之后的数据具有以下特点：

- ❑ **数据清洗**：质量可控制的；
- ❑ **数据集成**：统一的数据集；
- ❑ **数据降维**：低维表示；
- ❑ **数据转换**：规范化的。

3 数据预处理



- 3.1 数据预处理: 概述

- 3.2 数据清洗



- 3.3 数据集成

- 3.4 数据归约

- 3.5 数据变换

- 3.6 小结

3.2 数据清洗



- 现实世界的数据一般是脏数据：许多潜在的不正确的数据，e.g., 仪器故障，人为或电脑错误，传输错误
 - **不完整**: 缺少属性值，缺少某些感兴趣的属性
 - e.g., *Occupation*=" " (missing data)
 - **有噪声**: 包含噪声、误差或异常值
 - e.g., *Salary*="−10" (an error)
 - **不一致**: 包含代码或名称上的差异, e.g.,
 - *Age*="40", *Birthday*="03/07/2010"
 - Was rating "1, 2, 3", now rating "A, B, C"
 - discrepancy between duplicate records

3.2.1 缺失值



□ 数据并不总是完整的

缺少属性值，缺少某些感兴趣的属性。

例如：数据库表中，很多条记录的对应字段没有相应值，比如销售表中的顾客收入

□ 数据丢失可能是由于：

- 设备异常
- 人为的失误
- 在输入时，有些数据因得不到重视而没有被输入
- 不适用 **Not Applicable** (N/A)

□ 空缺值要经过推断而补上

EMPLOYEE_ID	EMPLOYEE_A	CITY	ZIP
	2100 STANFORD AVE SUITE B14	MOCKEY	95050
	4801 E. HAYES	MOCKEY	95050
	2000 STANFORD	MOCKEY	95050
	1000 STANFORD	MOCKEY	95050
	1000 STANFORD AVENUE #101	MOCKEY	95050
	1400 J STREET	MOCKEY	95050
	1377 SYLVAN AVE	MOCKEY	95050
	1100 GARDNER RD	MOCKEY	95050
	1000 YOSEMITE BLVD	MOCKEY	95050
	351 E HAYES ROAD	MOCKEY	95050
	304 14TH STREET	MOCKEY	95050
	428 14TH ST	MOCKEY	95050
	120 S. EMERALD	MOCKEY	95050
	2120 MC HENRY AVE	MOCKEY	95050
	CONTINENTAL PET TOWNSHIP BARRETT BUSINESS CENTER, INC.		
	"WORKING WITH PETITION" PER HEASER		
	AUL PRODUCTS, INC.		
	AUL A.P. OF AMERICA "ZAPCO"		
	ACE LATHING, INC.		
	ADVANCED ROOF SAVING TECH, INC.		
	ALL VALLEY PACKING, INC.		
	ALPHA POULTRY AND LIVESTOCK EQUIP., INC.		
	ALPHA PANEL, INC.		
	AMPM PRESTIGE STATIONS, INC.		
	AMERICAN CUSTOM FORDS, INC.		
	AMERICAN MEALS, INC.		
	AMERICAN MEDICAL RESPONSE, INC.		
	AMERINE SYSTEMS, INC.		
	ANGEL R. MARTINEZ, FARM LABOR		
	ART TO HEAR, INC.		
	ASSOC. CLEANING SVC, INC.		
	ATTARCO MOTOR, INC.		
	AUTO PARTS DISTRIBUTORS, INC.		
	AUTO PARTS DISTRIBUTORS, INC.		

3.2.1 缺失值



例子：如何处理空缺值？

	A	B	C	D	E	F
1	Missing data					
2						
3	Id	reading	science	history	math	medicine
4	1	12	27	10	x	44
5	2	11	x	14	13	43
6	3	x	56	17	23	60
7	4	15	37	22	19	x
8	5	22	31	x	21	42
9	6	18	x	11	22	43
10	7	15	50	13	x	56
11	8	21	x	20	28	46
12	9	20	39	19	25	x
13	10	x	36	20	23	56

如何处理空缺值？

□ 1. 忽略有缺失值的样本

假定挖掘任务设计为分类或描述时，有缺失值的样本通常被忽略。当属性缺失值比较多时，挖掘算法的效果非常差。

□ 2. 人工填写空缺值

重新采集、利用领域知识等方法。工作量大，枯燥乏味，可行性低


□ 3. 使用以下方法自动填充

- 使用一个全局常量填充空缺值：比如使用“unknown”或 $-\infty$
- 使用属性的平均值填充空缺值
- 使用与给定样本属同一类的所有样本的平均值
- 建模预测：使用像Bayesian公式或判定树这样的基于推断的方法、回归的方法、矩阵补全等



3.2.1 缺失值




插值法



最邻近插值法





线性插值



3.2.1 缺失值




图像恢复



3.2.1 缺失值



关系补全



nature communications



Article | Article in Press

<https://doi.org/10.1038/s41467-026-77922-1>

Dynamics-informed machine learning for recovering extensive missing systems dynamics


Received: 27 February 2026

Accepted: 9 September 2026


Tao Wu^{1,2}✉, Xiangyun Gao^{3,4}✉, Ying Tang^{5,6}, Feng An⁷, Xiaotian Sun⁸, Kazuyuki Aihara², Haizhong An^{3,4,9}✉ & Jürgen Kurths¹⁰

时间序列缺失90%仍能重构，前提是留住一条完整序列


3.2.1 缺失值




3.2.1 缺失值









3.2.1 缺失值




3.2.1 缺失值




3.2.1 缺失值



3.2.1 缺失值



3.2.1 缺失值



如何处理空缺值？

- Niels Ipsen, Pierre-Alexandre Mattei, Jes Frellsen. How to deal with missing data in supervised deep learning? - ICML Workshop on the Art of Learning with Missing Values, 2020.
- Y. Fortuin, D. Baranchuk, G. Rätsch, S. Mandt. GP-VAE: Deep Probabilistic Time Series Imputation - International Conference on Artificial Intelligence and Statistics (AISTATS), 2020.
- Yusuke Tashiro, Jiaming Song, Yang Song, Stefano Ermon. CSDI: Conditional Score-based Diffusion Models for Probabilistic Time Series Imputation - Advances in Neural Information Processing Systems (NeurIPS), 2021.
- Wenjie Du, David Côté, Yan Liu. SAITS: Self-Attention-based Imputation for Time Series - Expert Systems with Applications, Volume 219, Article 119619, 2023.
- Hengrui Zhang, Liancheng Fang, Qitian Wu, Philip S. Yu. DiffPuter: Empowering Diffusion Models for Missing Data Imputation - International Conference on Learning Representations (ICLR), 2025.
- Zeqi Ye, Minshuo Chen. Diffusion Transformers for Imputation: Statistical Efficiency and Uncertainty Quantification - Advances in Neural Information Processing Systems (NeurIPS), 2025.
- Md. Atik Ahamed, Qiang Ye, Qiang Cheng. RefiDiff: Progressive Refinement Diffusion for Efficient Missing Data Imputation - Proceedings of the AAAI Conference on Artificial Intelligence (AAAI), 2026, 40(24), 19551–19559.
- Tao Tong, Xiaofeng Zhu, Jiangzhang Gan. Meta-GAIN for Missing Data Imputation - Proceedings of the AAAI Conference on Artificial Intelligence (AAAI), 2026, 40(31), 25975–25982.

3.2.2 噪声数据




- 噪声：一个测量变量中的随机错误或偏差。
- 引起不正确属性值的原因：
 - 数据收集工具的问题
 - 数据输入错误
 - 数据传输错误
 - 技术限制

如何处理噪声数据？

□ 分箱 (Binning)

- 1. 按递增顺序对数据进行排列
- 2. 分到 (等频的) 箱子中
- 3. 使用光滑技术
 - 用箱均值光滑,
 - 用箱中位数光滑,
 - 用箱边界光滑, 等等



如何处理噪声数据？

□ Example: 4, 8, 15, 21, 21, 24, 25, 28, 34

- 首先排序，并划分到大小为3的等频的箱中（即每个箱包含3个值）

用箱均值光滑

用箱边界光滑


- | | | |
|----------------------|------------|------------|
| ■ bin 1: 4, 8, 15; | 9, 9, 9 | 4, 4, 15 |
| ■ bin 2: 21, 21, 24; | 22, 22, 22 | 21, 21, 24 |
| ■ bin 3: 25, 28, 34 | 29, 29, 29 | 25, 25, 34 |

3.2.2 噪声数据



离群点是具有与数据集中的大多数其他数据对象有很大不同的特征的数据对象。


离群点不等于异常点。



如何处理离群点？

□ 聚类

将联系松散的数据当作离群点，监测并且去除离群点。
聚类集合之外的点即为离群点。




3.2.2 噪声数据



如何处理离群点？

□ 回归

通过让数据适应回归函数来平滑数据（线性回归或非线性回归）。



如何处理离群点？

□ 盒图

通过盒图画出离群点。

□ 计算机和人工检查结合

计算机检测可疑数据，然后对它们进行人工判断。

例子： 光滑& 确定离群点

□ 年龄：



13,15,16,16,19,20,20,21,22,22,25,25,25,25,30,33,33,35,
35,35,35,36,40,45,46,52,70

□ 使用大小为3的用箱均值光滑

□ 如何确定数据中的离群点？

□ 箱线图，四分位范围， $1.5 * IQR$

3.2.2 噪声数据




3.2.2 噪声数据



如何处理数据噪声？

图像去噪算法 DnCNN



模型的主要任务是，根据噪声图像 y ，估计干净图像 x ，但是，模型的直接输出并不是 x ，而是噪声图像 v ，最终干净图的获取过程用公式表达就是 $x = y - \mathcal{R}(y)$ ，这里 $\mathcal{R}$ 就相当于模型，且 $\mathcal{R}(y) \approx v$ 。作者把这种方式称作残差学习（Residual Learning），并通过实验证实了残差学习对于提高训练稳定性和去噪效果的好处。

模型训练时，输出的误差图和真实误差图之间，采用SME损失函数进行约束。对于训练数据 $\{(x_i, y_i)\}_{i=1}^N$ ，损失函数定义为

$$l(\theta) = \frac{1}{2N} \|\mathcal{R}(y_i; \theta) - (y_i - x_i)\|$$

这里 θ 实际上就是DnCNN的网络参数，训练集的信息就保存在这里面。模型使用SDG或Adam方式进行模型参数更新。


3.2.2 噪声数据




如何处理数据噪声？

- Zero-shot learning enables instant denoising and super-resolution in optical fluorescence microscopy, Nature Communications, 2024
- Robust self-supervised denoising of voltage imaging data using CellMincer, npj | imaging, 2024
- Statistically unbiased prediction enables accurate denoising of voltage imaging data, nature methods, 2023

a Training phase



b Inference phase



3.2.2 噪声数据



如何处理数据噪声？

- Image Classification with Deep Learning in the Presence of Noisy Labels: A Survey
- A Survey on Deep Learning with Noisy Labels: How to train your model when you cannot trust on the annotations?
- Learning From Noisy Data: An Unsupervised Random Denoising Method for Seismic Data Using Model-Based Deep Learning, 2022
- Gaoxia Jiang, Jia Zhang, Xuefei Bai, Wenjian Wang, Deyu Meng. Which Is More Effective in Label Noise Cleaning, Correction or Filtering? - AAAI, 2024.
- Xichen Ye, Yifan Wu, Weizhong Zhang, Xiaoqiang Li, Yifan Chen, Cheng Jin. Optimized Gradient Clipping for Noisy Label Learning - AAAI, 2025.
- Jiye Liang, Yixiao Li, Junbiao Cui. Label Noise Correction via Fuzzy Learning Machine - AAAI, 2025.
- Marzi Heidari, Hanping Zhang, Yuhong Guo. Learning to Clean: Reinforcement Learning for Noisy Label Correction - NeurIPS, 2025.
- Gaoxia Jiang, Fan Lei, Wenjian Wang. A Multi-Model Dynamic Filtering of Label Noise for Regression - Pattern Recognition, Volume 169, Article 111887, 2026.

3 数据预处理




- 3.1 数据预处理: 概述
- 3.2 数据清洗
- 3.3 数据集成 
- 3.4 数据归约
- 3.5 数据变换
- 3.6 小结

数据集成:

将多个数据源中的数据合并，存放在一个数据存储中。如放在数据仓库中。

数据集成



数据集成有助于减少结果数据集的冗余和不一致，提高挖掘过程的准确性和速度。

数据集成存在的问题

- 实体识别问题
- 属性冗余和相关性
- 样本重复
- 数据值冲突的检测与处理

- 从多个数据源识别现实世界的实体, 如: Bill Clinton = William Clinton
- 模式集成和对象匹配可能需要技巧, 例如如何让计算机识别 customer_id 和另外一个数据库的 cust_number 是同一属性?
- 利用元数据, 每个属性的元数据包括名字、含义、数据类型和属性的值的允许范围, 以及处理空值的规则。这些元数据可以用来帮助避免模式集成的错误, 还有助于变化数据。

3.3 数据集成



Customer (source 1)

<i>CID</i>	<i>Name</i>	<i>Street</i>	<i>City</i>	<i>Sex</i>
11	Kristen Smith	2 Hurley Pl	South Fork, MN 48503	0
24	Christian Smith	Hurley St 2	S Fork MN	1


Client (source 2)

<i>Cno</i>	<i>LastName</i>	<i>FirstName</i>	<i>Gender</i>	<i>Address</i>	<i>Phone/Fax</i>
24	Smith	Christoph	M	23 Harley St, Chicago IL, 60633-2394	333-222-6542 / 333-222-6599
493	Smith	Kris L.	F	2 Hurley Place, South Fork MN, 48503-5998	444-555-6666

Customers (integrated target with cleaned data)

<i>No</i>	<i>LName</i>	<i>FName</i>	<i>Gender</i>	<i>Street</i>	<i>City</i>	<i>State</i>	<i>ZIP</i>	<i>Phone</i>	<i>Fax</i>	<i>CID</i>	<i>Cno</i>
1	Smith	Kristen L.	F	2 Hurley Place	South Fork	MN	48503-5998	444-555-6666		11	493
2	Smith	Christian	M	2 Hurley Place	South Fork	MN	48503-5998			24	
3	Smith	Christoph	M	23 Harley Street	Chicago	IL	60633-2394	333-222-6542	333-222-6599		24

3.3 数据集成



First	Last	Address	ID	Key
Sal	Stolfo	123 First Street	45678987	STLSAL123FRST456
Sal	Stolfo	123 First Street	45678986	STLSAL123FRST456
Sal	Stolpho	123 First Street	45688987	STLSAL123FRST456
Sal	Stiles	123 Forest Street	45654321	STLSAL123FRST456

数据集成还包含数据值冲突的检测和解析。

- 对于现实世界的同一实体，来自不同数据源的属性值可能不同。
 - 价格的单位：元、千元
 - 表示、尺度或编码不同。如：metric vs. British units
 - 体重属性在一个系统中可能以公制单位存放而在另一个中以英制单位存放。
 - 学校之间交换信息的时候，每个学校有自己的课程设置和等级模式。一个大学可能的等级从A+到F，另一个可能是等级从1到10。很难制定两所大学精确的课程——等级转换规则，交换信息很困难。

3.3 数据集成



- ❑ Maroua Masmoudi, Sana Ben Abdallah Ben Lamine, Mohamed Hedi Karray, Bernard Archimede, Hajer Baazaoui Zghal. Semantic Data Integration and Querying: A Survey and Challenges - ACM Computing Surveys, Volume 56, Issue 8, Article 209, 2024.
- ❑ Xuanqing Liu, Runhui Wang, Yang Song, Luyang Kong. GRAM: Generative Retrieval Augmented Matching of Data Schemas in the Context of Data Security - KDD, 2024.
- ❑ Nabeel Seedat, Mihaela Van Der Schaar. Bootstrapping Self-Improvement of Language Model Programs for Zero-Shot Schema Matching - ICML, 2025.
- ❑ Haoteng Yin, Jinha Kim, Prashant Mathur, Krishanu Sarker, Vidit Bansal. How to Talk to Language Models: Serialization Strategies for Structured Entity Matching - Findings of NAACL, 2025.
- ❑ Lin-yao Yang, Hongyang Chen, Xiao Wang, Jing Yang, Fei-Yue Wang, Han Liu. Integrating Knowledge from Knowledge Graphs and Large Language Models for Explainable Entity Alignment - Information Fusion, 2026.
- ❑ Shivam Chourasia, Hitesh Kapoor, Nilesh Patil. Structure-Guided Entity Resolution: Fine-Tuning LLMs for Robust Name Matching in Complex Linguistic Contexts - ACL, 2026.

3 数据预处理



□ 3.1 数据预处理: 概述

□ 3.2 数据清洗

□ 3.3 数据集成


□ 3.4 数据归约



□ 3.5 数据变换

□ 3.6 小结

3.4 数据归约



**data reduction:
turning big data
into information**

学生膳食结构和缺钙调查表


学生	鸡肉	猪肉	牛肉	羊肉	鱼肉	鸡蛋	青菜	番茄	牛奶	健康情况
1	0	1	1	0	1	0	1	0	1	不缺钙
2	0	0	0	0	1	1	1	1	1	不缺钙
3	1	1	1	1	1	0	1	0	0	缺钙
4	1	1	0	0	1	1	0	0	1	不缺钙
5	1	0	0	1	1	1	0	0	0	缺钙
6	1	1	1	0	0	1	0	1	0	缺钙
7	0	1	0	0	0	1	1	1	1	不缺钙
8	0	1	0	0	1	1	1	1	0	缺钙
9	0	1	0	0	0	1	1	1	1	不缺钙
10	1	0	1	1	1	1	0	1	0	缺钙

3.4 数据归约



决策树


采用不同的属性策略将会生成不同的决策树



3.4 数据归约



□ 决策树




3.4 数据归约




数据归约：用来获得数据集的归约表示。

- 1) 属性个数更小
- 2) 对象数量更小
- 3) 但仍然接近于保持原始数据的完整性



为什么要数据归约呢？维数灾难

存储量
计算量
准确率



3.4 数据归约



□ 3.4.1 数据归约策略的概述



□ 3.4.2 属性子集选择 属性选择

□ 3.4.3 主成分分析 属性重构

□ 3.4.4 其他降维方法

属性归约

□ 3.4.5 回归模型：参数化数据归约

□ 3.4.6 直方图

□ 3.4.7 聚类

□ 3.4.8 抽样

非参数化数据归约

数量归约

属性归约

- 属性子集选择方法：删除不相干的属性(或维)
 - 过滤式选择
 - Wrapper选择
 - 嵌入式选择
- 属性重构方法：对属性进行重构
 - 主成分分析Principal Component Analysis (PCA)
 - 非负矩阵分解Nonnegative Matrix Factorization(NMF)
 - 线性判别分析Linear Discriminant Analysis (LDA)
 - 隐狄利克雷分配 Latent Dirichlet Allocation(LDA)
 - 独立成分分析Independent Component Analysis (ICA)
 - Isomap、Locally Linear Embedding (LLE)、t-SNE



3.4.1 数据归约策略




数量归约

通过删除冗余的对象，减少数据量

- 回归模型
- 直方图
- 聚类
- 抽样



数量减少



3.4 数据归约



□ 3.4.1 数据归约策略的概述

□ 3.4.2 属性子集选择



属性选择

□ 3.4.3 主成分分析

属性重构

□ 3.4.4 其他降维方法

属性归约

□ 3.4.5 回归模型：参数化数据归约

□ 3.4.6 直方图

□ 3.4.7 聚类

□ 3.4.8 抽样

非参数化数据归约

数量归约

3.4.2 属性子集选择



- ❑ 目标：找出最小属性集，使得数据类别的分布尽可能接近使用所有属性的原始分布。
- ❑ 好处：减少属性的数目，使得模式更易于理解。

学生	高数上	高数下	数据挖掘	综合成绩	羊肉	牛肉	鸡蛋	青菜	牛奶	健康情况
1	90	92	80	85	1	1	0	1	1	不缺钙
2	60	65	90	75	1	1	1	1	1	不缺钙
3	95	91	92	93	1	1	0	1	0	缺钙

3.4.2 属性子集选择




□ 属性子集选择方法

- Wrapper选择
- 过滤式选择
 - 协方差、相关系数、卡方检验、Relief
- 嵌入式选择
 - 信息增益、互信息
 - 正则化

3.4.2.1 wrapper选择



- ❑ 包裹式特征选择直接把最终将要使用的模型的性能作为特征子集的评价标准。
- ❑ 包裹式特征选择的目的是为给定的模型选择最有利于其性能的特征子集。
- ❑ 从最终模型的性能来看，包裹式特征选择比过滤式特征选择更好，但需要多次训练模型，因此计算开销较大。



3.4.2.1 wrapper选择



▣ 拉斯维加斯包裹法 (Las Vegas Wrapper, LVW)

从原始特征中随机选择特征子集，经学习器训练后，利用评价函数观察学习器性能，若性能优于之前的，则保留该特征子集，否则重复之前的步骤直至达到停止标准，循环停止，此时的特征子集即为所求。


▣ 递归特征消除法 (Recursive Feature Elimination, RFE)

利用一个模型训练全部特征，经过一轮训练后将权值系数未达到阈值的特征从特征集中删除，由此生成一个新的特征集，继续对新特征集进行训练直至达到停止标准，此时的特征集就是经过递归特征消除法筛选的特征子集。特征子集被删除的次序即为特征按优先级排序次序。

3.4.2.2 过滤式选择



- 过滤式方法先对数据集进行特征选择，然后再训练模型，特征选择过程与后续模型训练无关
- Filter 方法常用的特征子集评价标准包括：协方差、相关系数、Relief、卡方检验等



3.4.2.2 过滤式选择——协方差



两个数值型属性 A 和 B ， n 个样本 $\{(a_1, b_1), \dots, (a_n, b_n)\}$ 。
属性 A 和属性 B 的均值，即期望值为：

$$E(A) = \bar{A} = \frac{\sum_{i=1}^n a_i}{n} \quad E(B) = \bar{B} = \frac{\sum_{i=1}^n b_i}{n}.$$

则属性 A 和 B 的协方差为：

$$\text{Cov}(A, B) = E((A - \bar{A})(B - \bar{B})) = \frac{\sum_{i=1}^n (a_i - \bar{A})(b_i - \bar{B})}{n}.$$

可以看到，

$$\text{Cov}(A, B) = E(A \cdot B) - \bar{A}\bar{B}.$$

3.4.2.2 过滤式选择——协方差



对于一起发生变化的属性A和B，如果A大于 $\bar{A}$ 时，B也可能大于 $\bar{B}$ 。因此，A和B之间的协方差为正。如果一个属性的值在均值以下时另一个倾向于在均值以上，则协方差为负。

如果A和B相互独立（没有关联），则协方差为0。但反过来并不成立。即一些随机变量对的协方差值为0，但并不独立。只有在一些额外的假设（如数据满足多元正态分布）时协方差为0表明独立性。

3.4.2.2 过滤式选择——协方差



这是一个观察到的5次AllElectronics和HighTech公司的股票价格。如果股票是被同一个公司的趋势影响，那么它们的价格是否一起涨落呢？

Stock Prices for *AllElectronics* and *HighTech*

<i>Time point</i>	<i>AllElectronics</i>	<i>HighTech</i>
t1	6	20
t2	5	10
t3	4	14
t4	3	5
t5	2	5

3.4.2.2 过滤式选择——协方差



□ 计算均值：

$$E(AllElectronics) = \frac{6 + 5 + 4 + 3 + 2}{5} = \frac{20}{5} = \$4$$

$$E(HighTech) = \frac{20 + 10 + 14 + 5 + 5}{5} = \frac{54}{5} = \$10.80.$$

□ 则协方差为：

$$Cov(A, B) = E(A \cdot B) - \bar{A}\bar{B}.$$

$$\begin{aligned} Cov(AllElectronics, HighTech) &= \frac{6 \times 20 + 5 \times 10 + 4 \times 14 + 3 \times 5 + 2 \times 5}{5} - 4 \times 10.80 \\ &= 50.2 - 43.2 = 7. \end{aligned}$$

□ 协方差值为正，因此，可以说两个公司的股票同时上涨。

3.4.2.2 过滤式选择——相关系数



□ 相关系数
$$r_{A,B} = \frac{\sum_{i=1}^n (a_i - \bar{A})(b_i - \bar{B})}{(n)\sigma_A\sigma_B} = \frac{\sum_{i=1}^n (a_i b_i) - n\bar{A}\bar{B}}{(n)\sigma_A\sigma_B}$$

其中， n 是样本的个数， $\bar{A}$ 和 $\bar{B}$ 分别是 A 和 B 的均值， σ_A 和 σ_B 分别是 A 和 B 的**标准差**，而 $\sum(a_i b_i)$ 是 AB 叉积和（即对于每个样本， A 的值乘以该样本 B 的值）

- 如果 $r_{A,B}$ 大于0，则 A 和 B 是正相关的，这意味着 A 值随 B 值的增加而增加。该值越大，相关性越强（即每个属性蕴涵另一个的可能性越大）。
- 如果 $r_{A,B}$ 等于0，则 A 和 B **不存在线性相关关系**。
- 如果 $r_{A,B}$ 小于0，则 A 和 B 是负相关的，一个值随另一个减少而增加。

3.4.2.2 过滤式选择——相关系数



- 在概率理论和统计学中，**相关系数**和**协方差**是评价两个属性是否一起发生变化的两种相似的测量。
- 相关系数（又称皮尔逊积矩系数）

$$r_{A,B} = \frac{Cov(A,B)}{\sigma_A \sigma_B},$$

可以反映两个变量变化时是同向还是反向，如果同向变化就为正，反向变化就为负。

相关系数是标准化后的协方差，它消除了两个变量变化幅度的影响，而只是单纯反应两个变量每单位变化时的相似程度。

3.4.2.2 过滤式选择——相关系数



obj₁ obj₂ obj₃ obj₄ obj₅ obj₆

□ Attribute *A*: 11 7 14 11 43 38

□ Attribute *B*: 11 13 17 13 51 46

□ Attribute *C*: 9 11 20 9 69 76

$$r_{A,B} = \frac{\sum_{i=1}^n (a_i - \bar{A})(b_i - \bar{B})}{(n)\sigma_A\sigma_B} = \frac{\sum_{i=1}^n (a_i b_i) - n\bar{A}\bar{B}}{(n)\sigma_A\sigma_B}$$

1.0000 0.9928 0.9782


0.9928 1.0000 0.9867

0.9782 0.9867 1.0000

3.4.2.2 过滤式选择——相关系数



散点图可以用来可视化属性之间的关联关系。



表示从-1到1的相似性的散点图

$r_{A,B} = 1$: 正相关;

$r_{A,B} = -1$: 负相关;

$r_{A,B} = 0$:

它们之间**没有线性关系**

3.4.2.3 嵌入式选择



□ 嵌入式特征选择是将特征选择过程与学习器训练过程融为一体，两者在同一个优化过程中完成，即在学习器训练过程中自动地进行了特征选择。


- 决策树：信息增益、互信息
- 正则化： L_1 范数和 L_2 范数

3.4.2.3 嵌入式选择——信息增益




计算信息增益(举例)

子节点熵 $-\left(\frac{13}{17} \cdot \log_2 \frac{13}{17}\right) - \left(\frac{4}{17} \cdot \log_2 \frac{4}{17}\right) = 0.787$



父节点熵 $-\left(\frac{14}{30} \cdot \log_2 \frac{14}{30}\right) - \left(\frac{16}{30} \cdot \log_2 \frac{16}{30}\right) = 0.996$

子节点熵 $-\left(\frac{1}{13} \cdot \log_2 \frac{1}{13}\right) - \left(\frac{12}{13} \cdot \log_2 \frac{12}{13}\right) = 0.391$



条件熵: 子节点加权熵 $\left(\frac{17}{30} \cdot 0.787\right) + \left(\frac{13}{30} \cdot 0.391\right) = 0.615$

3.4.2.3 嵌入式选择——信息增益



□ 熵：描述数据的不确定性

$$H(X) = - \sum_{i=1}^n p(x_i) \log_b p(x_i)$$

$$H(S) = -0.5 \cdot \log_2 0.5 - 0.5 \cdot \log_2 0.5 = 1.0$$

$X: \{a = \text{"喝牛奶"}; b = \text{"不喝牛奶"}\}$

$$H(S|X = a) = -1 * \log_2 1 - 0 * \log_2 0 = 0$$


$$H(S|X = b) = -0 * \log_2 0 - 1 * \log_2 1 = 0$$

$$H(S|X) = 0.5 H(S|X = a) + 0.5 * H(S|X = b) = 0$$


□ 信息增益：引入属性X之后不确定程度减少的程度

$$\text{Gain}(S, X) = H(S) - H(S|X) = 1$$

信息增益IG：如果IG越大，说明消除不确定的程度越大



3.4.2.3 嵌入式选择——信息增益




3.4.2.3 嵌入式选择——信息增益



$$H(X) = - \sum_{i=1}^n p(x_i) \log_b p(x_i)$$

$$H(S) = -0.5 \cdot \log_2 0.5 - 0.5 \cdot \log_2 0.5 = 1.0$$

$X: \{a = \text{"Non-Smoker"}; b = \text{"Smoker"}\}$



$$H(S \mid X = a) = -0.8 \cdot \log_2 0.8 - 0.2 \cdot \log_2 0.2 = 0.7219$$

$$H(S \mid X = b) = -0.05 \cdot \log_2 0.05 - 0.95 \cdot \log_2 0.95 = 0.2864$$

$$H(S \mid X) = 0.6 \cdot H(S \mid X = a) + 0.4 \cdot H(S \mid X = b) = 0.5477$$

$$\text{Gain}(S, X) = H(S) - H(S \mid X) = 0.4523$$

3.4 数据归约



□ 3.4.1 数据归约策略的概述

□ 3.4.2 属性子集选择

属性选择

□ 3.4.3 主成分分析



属性重构

□ 3.4.4 其他降维方法

属性归约

□ 3.4.5 回归模型：参数化数据归约

□ 3.4.6 直方图


□ 3.4.7 聚类

□ 3.4.8 抽样

非参数化数据归约

数量归约


3.4.3 主成分分析：PCA



3.4.3 主成分分析：PCA




- 搜索 k 个最能代表数据的 d 维正交向量，其中 $k \leq d$
- 原数据投影到一个更小的空间上，导致属性归约
- 目标是创建一个替换的、较小的变量集“组合”属性



3.4.3 主成分分析：PCA




- 数据：Gaussian分布
- 方差
- 椭圆：长轴与短轴
- 选择与长轴相对应的属性



3.4.3 主成分分析: PCA




2D Example



3.4.3 主成分分析: PCA



2D Example



3.4.3 主成分分析: PCA



目标: $S(Y)$ 对角线上的项是非零的, 且所有非对角线元素均为零

$$Y = PX \quad \longrightarrow \quad S(Y) = \frac{1}{n-1} YY^T \quad \longrightarrow \quad YY^T = (PX)(PX)^T = PXX^T P^T.$$

$$(n-1)S(Y) = PXX^T P^T$$

$$= PQDQ^T P^T$$

$$= (PQ)D(PQ)^T$$

$$XX^T = QDQ^T$$

特征分解

$$P = Q^T$$

3.4 数据归约



□ 3.4.1 数据归约策略的概述

□ 3.4.2 属性子集选择 属性选择

□ 3.4.3 主成分分析 属性重构

□ 3.4.4 其他降维方法 

属性归约

□ 3.4.5 回归模型：参数化数据归约

□ 3.4.6 直方图

□ 3.4.7 聚类

□ 3.4.8 抽样

非参数化数据归约



数量归约

3.4.4.1 线性判别分析LDA



□ 线性判别分析（Linear Discriminant Analysis，简称LDA）

- 经典的有监督数据降维方法。
- LDA的主要思想是将一个高维空间中的数据投影到一个较低维的空间中，且投影后要保证各个类别的类内方差小而类间均值差别大，这意味着同一类的高维数据投影到低维空间后**相同类别的聚在一起，而不同类别之间相距较远**。



3.4.4.1 线性判别分析LDA




LDA与PCA的异同：

□ 相同点：

- 两者均可以对数据进行降维。
- 两者在降维时均使用了矩阵特征分解的思想。
- 两者都假设数据符合高斯分布。

□ 不同点：

- LDA是有监督的降维方法，而PCA是无监督的降维方法。
- LDA选择分类性能最好的投影方向，而PCA选择样本点投影具有最大方差的方向。





3.4.4.2 隐狄利克雷分配LDA



Latent Dirichlet Allocation主题模型

是Blei等人于2003年提出的基于概率模型的主题模型算法，LDA是一种非监督机器学习技术，可以用来识别大规模文档集或语料库中的潜在隐藏的主题信息。该方法假设每个词是由背后的一个潜在隐藏的主题中抽取出来。



3.4.4.2 隐狄利克雷分配LDA



Topics

gene	0.04
dna	0.02
genetic	0.01
...	

life	0.02
evolve	0.01
organism	0.01
...	

brain	0.04
neuron	0.02
nerve	0.01
...	

data	0.02
number	0.02
computer	0.01
...	

Documents

Seeking Life's Bare (Genetic) Necessities

COLD SPRING HARBOR, NEW YORK—How many genes does an organism need to survive? Last week at the genome meeting here,* two genome researchers with radically different approaches presented complementary views of the basic genes needed for life. One research team, using computer analyses to compare known genomes, concluded that today's organisms can be sustained with just 250 genes, and that the earliest life forms required a mere 128 genes. The other researcher mapped genes in a simple parasite and estimated that for this organism, 800 genes are plenty to do the job—but that anything short of 100 wouldn't be enough.

Although the numbers don't match precisely, those predictions

"are not all that far apart," especially in comparison to the 75,000 genes in the human genome, notes Siv Andersson, a biologist at Uppsala University in Sweden, who arrived at the 800 number. But coming up with a consensus answer may be more than just a genetic numbers game, particularly as more and more genomes are completely sequenced and analyzed. "It may be a way of organizing any newly sequenced genome," explains Arcady Mushegian, a computational molecular biologist at the National Center for Biotechnology Information (NCBI) in Bethesda, Maryland. Comparing an




* Genome Mapping and Sequencing, Cold Spring Harbor, New York, May 8 to 12.

Stripping down. Computer analysis yields an estimate of the minimum modern and ancient genomes.

SCIENCE • VOL. 272 • 24 MAY 1996

Topic proportions and assignments




非负矩阵分解(Nonnegative Matrix Factorization), 简称NMF, 是由Lee和Seung于1999年在《Nature》上提出的一种矩阵分解方法, 它使分解后的所有分量均为非负值(要求纯加性的描述), 并且同时实现非线性的维数约减。

给定数据 $X \in R^{M \times N}$ 和非负整数 $k < \min\{M, N\}$

NMF的目标函数是 $\min_{W, H} f(W, H) = \|X - WH\|_F^2$

s.t. $W \geq 0, H \geq 0$



NMF of a set of images

$$\begin{array}{c} X = (x_1, x_2, \dots, x_n) \\ \text{Matrix of images} \end{array} = \begin{array}{c} \text{Grid of image patches} \\ \times \\ \text{Weight matrix } W \end{array}$$

$H = (h_1, h_2, \dots, h_k)$

$W = (w_1, w_2, \dots, w_k)$

文本数据的向量空间模型


$$\begin{array}{c} \text{term}_1 \\ \text{term}_2 \\ \dots \\ \text{term}_m \end{array} \begin{bmatrix} \text{doc}_1 & \text{doc}_2 & \dots & \text{doc}_n \\ v_{11} & v_{12} & \dots & v_{1n} \\ v_{21} & v_{22} & \dots & v_{2n} \\ \dots & \dots & v_{ij} & \dots \\ v_{m1} & v_{m2} & \dots & v_{mn} \end{bmatrix} \xrightarrow{\hspace{1cm}} v_{ij} \geq 0$$

非负矩阵分解可以用在数据降维、文本聚类等问题上

3.4.4.4 t-SNE



t 分布随机邻近嵌入 (t-Distribution Stochastic Neighbour Embedding) 是一种用于降维的机器学习方法，主要的优势就是保持局部结构的能力。



3.4 数据归约



□ 3.4.1 数据归约策略的概述

□ 3.4.2 属性子集选择

□ 3.4.3 主成分分析

□ 3.4.4 其他降维方法

属性归约

□ 3.4.5 回归模型


□ 3.4.6 直方图

□ 3.4.7 聚类


□ 3.4.8 抽样

数量归约

3.4 数据归约



数量减少




通过选择可选的、更小的数据表示形式来减少数据量

- 参数化方法 (e.g., 回归)
- 非参数化方法
 - 不需要假设模型
 - 主要有：直方图、聚类、抽样

□ 回归模型可以用来近似给定的数据。

1. 假设数据适合某个模型
2. 预测模型参数
3. 只存储参数，并丢弃数据
(可能的异常值除外)



3.4.6 直方图分析




- 直方图使用分箱来近似数据分布

- 划分规则：等宽

将范围划分为 N 个大小相等的间隔：均匀网格



1,1,5,5,5,5,5,8,8,10,10,10,10,12,14,14,14,15,15,15,15,15,15,
18,18,18,18,18,18,18,18, 20,20,20,20,20,20,20,21,21,21,21,
25,25,25,25,25,28,28,30,30,30



3.4.7 聚类



聚类技术把数据元组看做对象，将对象划分为群或簇，使得在一个簇中的对象相互“相似”，而与其他簇中的对象“相异”。通常，相似性基于距离函数。




3.4.8 抽样




- 抽样可以作为作为一种数据归约的技术使用。
- 抽样：允许用数据**小得多**的随机样本（子集）表示大型数据集。
- 关键原则：选择数据的一个**代表性**子集

如果样本与原始数据集具有近似相同的（感兴趣的）属性，则该样本具有代表性。


- 简单随机抽样
- 簇抽样
- 分层抽样




样本大小和数据质量



8000 points




2000 Points




500 Points

需要研究自适应抽样方法


不平衡数据分布



需要研究不平衡抽样方法



Faces [Zhang et al. 2017]



Species [Van Horn et al. 2019]

- Jayoung Kim, Yehjin Shin, Jeongwhan Choi, Hyowon Wi, Noseong Park. Polynomial-based Self-Attention for Table Representation Learning - ICML, 2024.
- Jing Wu, Suiyao Chen, Qi Zhao, Renat Sergazinov, Chen Li, Shengjie Liu, Chongchao Zhao, Tianpei Xie, Hanqing Guo, Cheng Ji, Daniel Cociorva, Hakan Brunzell. SwitchTab: Switched Autoencoders Are Effective Tabular Learners - AAAI, 2024.
- Myung Jun Kim, Leo Grinsztajn, Gael Varoquaux. CARTE: Pretraining and Transfer for Tabular Learning - ICML, 2024.
- Jiahuan Yan, Bo Zheng, Hongxia Xu, Yiheng Zhu, Danny Chen, Jimeng Sun, Jian Wu, Jintai Chen. Making Pre-trained Language Models Great on Tabular Prediction - ICLR, 2024.
- Moonjung Eo, Kyungeun Lee, Hye-Seung Cho, Dongmin Kim, Ye Seul Sim, Woohyung Lim. Representation Space Augmentation for Effective Self-Supervised Learning on Tabular Data - AAAI, 2025.
- Xinyi He, Yihao Liu, Mengyu Zhou, Yeye He, Haoyu Dong, Shi Han, Zejian Yuan, Dongmei Zhang. TableLoRA: Low-rank Adaptation on Table Structure Understanding for Large Language Models - ACL, 2025.
- Yuchen Zeng, Tuan Dinh, Wonjun Kang, Andreas C. Mueller. TabFlex: Scaling Tabular Learning to Millions with Linear Attention - ICML, 2025.

3 数据预处理




- 3.1 数据预处理: 概述
- 3.2 数据清洗
- 3.3 数据集成
- 3.4 数据归约
- 3.5 数据变换 
- 3.6 小结

3.5.1 数据编码



□ 标称数据转成one-hot编码




3.5.2 数据规范化




- 由于数据的标准、区间范围差别较大，需要进行数据转换。
- 数据变换是数据从一种表示形式变为另一种表现形式的过程。

身高(m)	体重(kg)
1.65	55
1.75	70
1.72	75
1.60	52
1.83	89



身高	体重
1.65	0.55
1.75	0.70
1.72	0.75
1.60	0.52
1.83	0.89

平时成绩 (十分制)	期末成绩 (百分制)
5	70
6	60
9	80
10	95



平时成绩 (百分制)	期末成绩 (百分制)
50	70
60	60
90	80
100	95

3.5.2 数据规范化



最小—最大规范化:对原始数据进行线性变换,使得数据落在 new_max_A, new_min_A 区间内。

$$v' = \frac{v - min_A}{max_A - min_A} (new_max_A - new_min_A) + new_min_A$$

max_A, min_A :属性 A 的最大与最小值

new_max_A, new_min_A :属性 A 变换后区间的最大与最小值

例: (一般映射到 $[0, 1]$ 区间) 工资在700~12000之间, 则工资7830规范化后为:

$$V' = (7830 - 700) / (12000 - 700) * (1 - 0) + 0 = 0.7430$$


最小—最大值标准化**保留了原有数据值的关系**。如果后来的输入的标准化的数据落在了原有数据区间的外面, 将会发生过界的错误。

3.5.2 数据规范化



举例：

	obj1	obj2	obj3	obj4	obj5	obj6
Attribute 1:	11	7	14	11	43	38
Attribute 2:	11	13	17	13	51	46
Attribute 3:	9	11	20	9	69	76



Attribute 1:	$4/36$	0	$7/36$	$4/36$	1	$31/36$
Attribute 2:	0	$2/40$	$6/40$	$2/40$	1	$35/40$
Attribute 3:	0	$2/67$	$11/67$	0	$60/67$	1

3.5.2 数据规范化



- **z-score规范化:**基于属性 A 的平均值和标准差规范化。

$$v' = \frac{v - \bar{A}}{\sigma_A}$$

其中 $\bar{A}$ 和 σ_A 是属性 A 的均值和标准差。

这种方法在实际的最小值和最大值未知时很有用，或者离群点主导了最小—最大值的标准化。

标准差可以用均值绝对偏差替换。

- **小数定标规范化:**通过移动属性 A 的小数点位置进行规范化。

$$v' = \frac{v}{10^j}$$

其中 j 是使得 $\max(|v'|) < 1$ 的最小整数。

3.5.3 数据离散化



原因：

- 易于组织成更高层次的概念
- 某些模型只能使用离散属性

例如：决策树



ID	天气	温度	湿度	刮风	玩
3	overcast	83	86	☐	☒
4	rainny	70	96	☐	☒
5	rainny	68	80	☐	☒
6	rainny	65	70	☒	☐
7	overcast	64	65	☒	☒
8	sunny	72	95	☐	☐



ID	天气	温度	湿度	刮风	玩
3	3	3	2	1	2
4	2	1	2	1	2
5	2	1	1	1	2
6	2	1	1	2	1
7	3	1	1	2	2
8	1	2	2	1	1

3.5.3 数据离散化



- 属性的形式：
 - 离散—标称、二元、序数
 - 连续—数值
- 离散化：将连续属性的范围划分为区间
 - 区间标签可用来替换实际的数据值
 - 通过离散化减少数据取值的个数
- 方法：
 - 分箱：并不使用类信息，是一种非监督的离散化技术。对用户制定的箱个数很敏感，也容易受离群点的影响。
 - 聚类：将数值划分成簇。

3.5.3 数据离散化——分箱



■ 按价格排序的数据（美元）：4, 8, 9, 15, 21, 21, 24, 25, 26, 28, 29, 33


分成等频(等深为4)的箱子:

- Bin 1: 4, 8, 9, 15
- Bin 2: 21, 21, 24, 25
- Bin 3: 26, 28, 29, 33

分成等宽(等宽为10)的箱子:

- Bin 1: 4, 8, 9
- Bin 2: 15, 21, 21
- Bin 3: 24, 25, 26, 28, 29, 33

3.5.3 数据离散化（分箱 vs. 聚类）



4组
2个离群点
y-axis随机分布




等宽分箱
等频率分箱
K-means聚类

3.5.3 离散化（分箱 vs. 聚类）




问题：在这个数据集上，哪个方法比较好？

等宽分箱



等频率分箱



K-means聚类

- 某些敏感信息通过脱敏规则进行数据的变形，实现敏感隐私数据的可靠保护。
- 在涉及客户安全数据或者一些商业性敏感数据的情况下，在不违反系统规则条件下，对真实数据进行改造并提供测试使用，如身份证号、手机号、卡号、客户号等个人信息都需要进行数据脱敏。
- 通过数据脱敏产品，可以有效防止企业内部对隐私数据的滥用，防止隐私数据在未经脱敏的情况下从企业流出。满足企业既要保护隐私数据，同时又保持监管合规，满足企业合规性。

- 替换方法是数据脱敏中最基本的方法之一。它通过将原始数据中的敏感信息替换为虚拟值来保护数据的隐私。以下是几种常见的替换方法：
 - 通用化：是一种常用的替换方法，它将原始数据中的敏感信息替换为通用的占位符，这种方法简单易行，但可能会导致数据的失真。
 - 随机化：是一种更复杂的替换方法，它将原始数据中的敏感信息替换为随机生成的值。这可以有效保护数据的隐私，但需要注意生成的随机值必须在统计上与原始数据相似，以保持数据的有效性。

- 删除方法是另一种常用的数据脱敏方法，它直接从数据中删除敏感信息。这种方法可以有效保护敏感信息，但也可能导致数据的有效性下降。
- 整行删除：这是一种极端的方法，它将包含敏感信息的整行数据从数据集中删除。这可以确保敏感信息不会泄露，但也可能损失大量有用的数据。
- 列删除：是一种更精细的方法，它只删除包含敏感信息的列，而保留其他列。这样可以保留更多的数据，但依然可能导致数据的有效性问题。

- 掩盖方法是一种将敏感信息部分掩盖或模糊的数据脱敏方法。这样可以保护敏感信息，同时保留数据的有效性。
- 部分隐藏：将敏感信息的一部分字符替换为占位符，例如将信用卡号的中间数字用星号代替。这种方法可以保护部分敏感信息，但仍然有一定的风险。
- 模糊化：这是一种将敏感信息进行模糊处理的方法，例如对日期进行模糊化，只保留年份或月份。这可以在一定程度上保护数据，但也可能导致数据的有效性问题的。

- 加密方法是一种将数据转化为密文的数据脱敏方法。只有授权用户能够解密数据，从而保护敏感信息的安全。
- 对称加密方法：使用相同的密钥来加密和解密数据。这种方法效率高，但需要确保密钥的安全。
- 非对称加密方法：使用一对密钥，一个用于加密，一个用于解密。这提高了数据的安全性，但也增加了计算开销。

- 哈希方法是一种将数据转化为固定长度的哈希值的数据脱敏方法。哈希值不可逆，但相同的输入始终产生相同的哈希值。
- 单向哈希方法：将数据转化为不可逆的哈希值，这可以用于保护密码等敏感信息。但哈希碰撞（多个输入映射到相同的哈希值）可能存在一定风险。
- 盐值哈希方法：在单向哈希的基础上增加一个随机盐值，以增加哈希值的复杂性。这提高了安全性，但也增加了管理成本。

3.5.5 数据变换最新方法



- ❑ Jiahuan Yan, Bo Zheng, Hongxia Xu, Yiheng Zhu, Danny Chen, Jimeng Sun, Jian Wu, Jintai Chen. Making Pre-trained Language Models Great on Tabular Prediction - ICLR, 2024.
- ❑ Myung Jun Kim, Leo Grinsztajn, Gael Varoquaux. CARTE: Pretraining and Transfer for Tabular Learning - ICML, 2024.
- ❑ Md Mahadi Hasan Nahid, Davood Rafiei. NormTab: Improving Symbolic Reasoning in LLMs Through Tabular Data Normalization - Findings of EMNLP, 2024.
- ❑ Jing Wu, Suiyao Chen, Qi Zhao, Renat Sergazinov, Chen Li, Shengjie Liu, Chongchao Zhao, Tianpei Xie, Hanqing Guo, Cheng Ji, Daniel Cociorva, Hakan Brunzell. SwitchTab: Switched Autoencoders Are Effective Tabular Learners - AACL, 2024.
- ❑ Juyong Kim, Chandler Squires, Pradeep Ravikumar. Knowledge-Enriched Machine Learning for Tabular Data - International Conference on Neuro-symbolic Systems, 2025.
- ❑ Xinyi He, Yihao Liu, Mengyu Zhou, Yeye He, Haoyu Dong, Shi Han, Zejian Yuan, Dongmei Zhang. TableLoRA: Low-rank Adaptation on Table Structure Understanding for Large Language Models - ACL, 2025.
- ❑ K. Xiong, C. A. Huang, M. Wybrow, Y. Wu. TableCanoniser: Interactive Grammar-Powered Transformation of Messy, Non-Relational Tables to Canonical Tables - CHI, 2025.
- ❑ Mengshi Chen, Yuxiang Sun, Tengchao Li, Jianwei Wang, Kai Wang, Xuemin Lin, Ying Zhang, Wenjie Zhang. Empowering Tabular Data Preparation with Language Models: Why and How? - ACL, 2026.

3 数据预处理



- 3.1 数据预处理: 概述
- 3.2 数据清洗
- 3.3 数据集成
- 3.4 数据归约
- 3.5 数据变换
- 3.6 小结



- 数据清理：如：空缺值/噪声数据，离群点
- 数据集成：合并多个数据源
- 数据归约：
 - 属性归约
 - 数量归约
- 数据变换：
 - 规范化
 - 离散化
 - 脱敏



天津大学
Tianjin University

THE END

