天津大学
Tianjin University

数据挖掘

王煜

人工智能学院

wang.yu@tju.edu.cn



回顾

第4章 频繁模式挖掘

- Apriori算法
- FP-growth算法

第 5 章　分类

5 分类

- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.6 评估
- 5.7 长尾分布建模

5.1.1 有监督与无监督

- 有监督：

用于分类或者回归，需要有训练集和测试集。

在已知训练集的前提下，对测试样本根据它的特征，把它与训练集中的样本进行对比，把它分到对应的那类中。



- 无监督：

用于聚类



有一堆数据，将这堆数据按照它们自身内部的相似性，自动地聚成几类。

5.1.2 分类

图像分类示例





苹果







香蕉

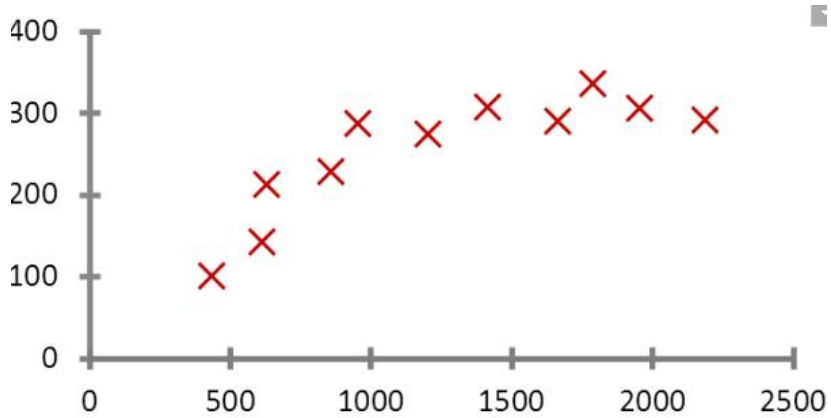
5.1.3 回归

- “回归”一词是1855年由英国生物学家高尔顿（Galton）在研究孩子的身高与他们父母身高关系时提出的。
- 当时他正研究这样一个问题：高个子人生的子女一般偏高，照这样看，各代人在身高分布上将有两级分化的趋势，个子很高和很矮的会越来越多，而处在中间状态的会越来越少。
- 研究发现，父母个子高，其子代一般也高，但不如父母那么高；父母个子矮，其子代一般也矮，但不如父母那么矮。下一代身高有向中间值回归的趋势。这种趋于中间值的趋势被称为“回归效应”，而他提出的这种研究两个数值变量关系的方法称作回归分析。

5.1.3 回归

- 属于有监督学习范畴
- 回归问题的目标是给定D维输入变量x，并且每一个输入矢量x都有对应的值y，要求对于新来的数据预测它对应的连续的目标值t。
- 房屋估值问题
- 股票预测
- 风速预报





5.1.4 分类 VS. 回归

- 分类和回归是两种数据分析形式，用于提取描述重要数据类或预测未来的数据趋势的模型
  - 分类：
    - 预测类对象的分类标号（或离散值）
    - 根据训练数据集和类标号属性，构建模型来分类现有数据，并用来分类新数据
    - 银行贷款员需要分析数据，来弄清哪些贷款申请者是安全的，哪些是有风险的（将贷款申请者分为“安全”和“有风险”两类）
  - 回归：
    - 建立连续函数值模型
    - 比如预测空缺值，或者预测顾客在计算机设备上的花费
    - 银行贷款员需要预测贷给某个顾客多少钱是安全的

5.1.5 聚类

图像聚类








5.1.5 聚类

图像聚类



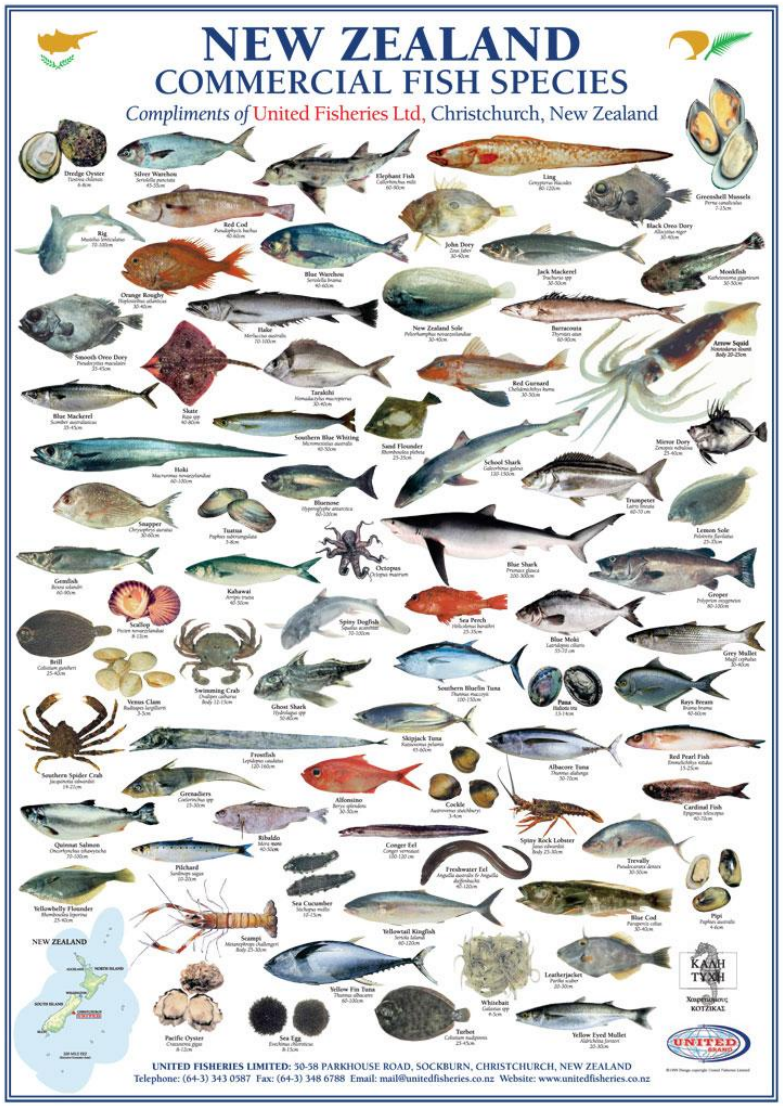


5 分类

- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.5 评估
- 5.6 长尾分布建模

5.2分类的应用案例

“物以类聚，人以群分”，在自然科学和社会科学中，存在着大量的分类问题。







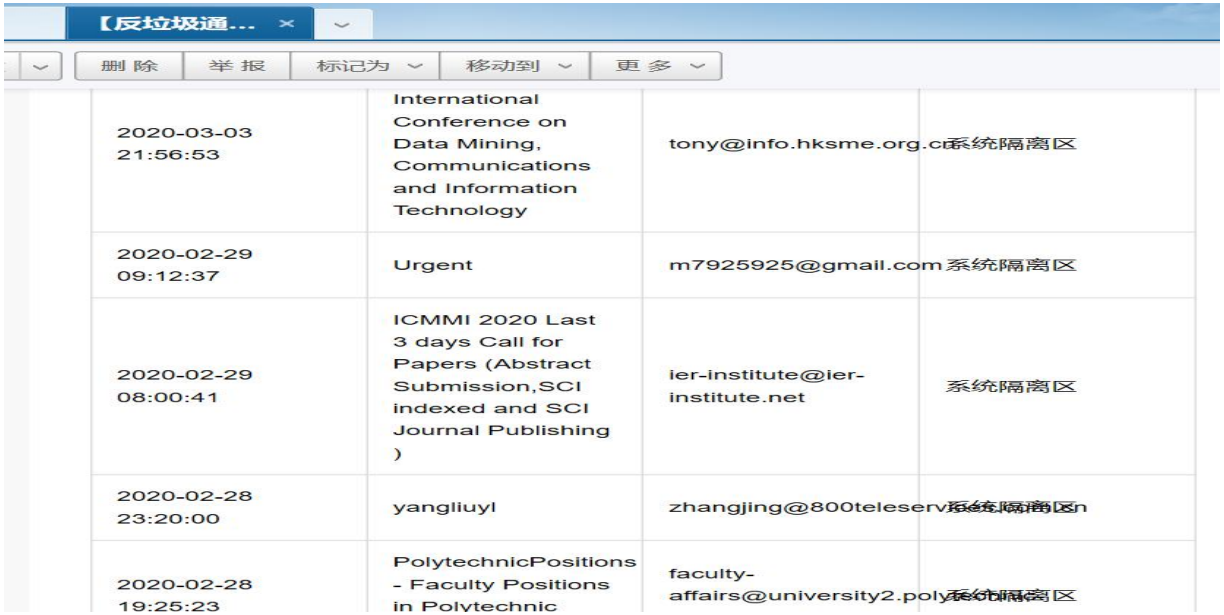




5.2分类的应用案例

垃圾邮件处理

- 案例阐述：对于企业和个人，如何处理垃圾邮件都是很头疼的一件事情。如果没有足够的容量来容纳垃圾邮件，或者没有过滤掉的垃圾邮件仍然会造成糟糕的用户体验。
- 表述问题：如何对每个邮箱中收到的每封邮件进行处理，将有用邮件保留而过滤掉垃圾邮件是用户关心的一大问题。



5.2分类的应用案例

- 解决问题：目前的垃圾邮件过滤方法主要是采用文本挖掘技术(text mining)，作为数据挖掘的重要分支，文本挖掘在数据挖掘传统方法的基础上引入了语义处理等其他学科知识。
- 在垃圾邮件过滤的分类技术中最常见的是贝叶斯分类法。贝叶斯分类法主要是通过对邮件的信封标题，主题和内容进行扫描和判别。
- 因为垃圾邮件发送方式随着各家企业邮箱的开发商的反垃圾技术的提升而变化，通过附件（PDF，图像等）方式发送垃圾邮件的专业户也越来越多，所以扫描的内容又增加了一项检查附件的工作。

5.2分类的应用案例

信用卡分级

- 案例阐述：现如今金融行业的竞争异常激烈。在美国，出现在每一家邮箱里最多的信件恐怕就是信用卡邀请信。如何吸引合适的用户来使用信用卡，以及准确分析申请人的信用风险，是每个商业银行最关注也是最头痛的事情。银行要不惜一切代价吸引低风险高价值的客户，但是对于高风险的信用卡申请者要尽量避免。
- 表述问题：如何把信用卡申请者分类为低、中、高风险。



5.2分类的应用案例

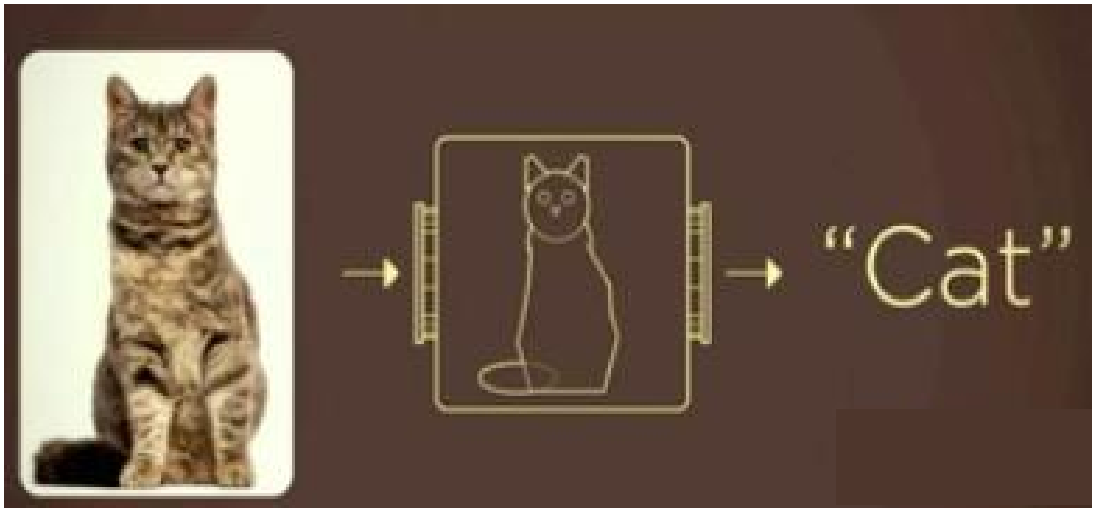
- 解决问题：需要建设客户风险模型来对客户的风险进行分类。因为行业的特殊性，申请表中包含了大量关于用户的个人信息，再加上通常会做的客户信用查询，可以用来参考的数据维度要多一些，所以相对来说建模的精准度也会高不少。

姓名	年龄	收入	学生	信誉	电话	地址	邮编	风险
张三	23	4000	否	良	281-322-0328	2714 Ave. M	77388	中
李四	34	2800	否	优	713-239-7830	5505 Holly Cr	78755	中
王二	50	1000	否	良	281-242-3222	2000 Bell Blvd.	70244	高
赵五	18	900	是	良	281-550-0544	100 Main Street	70244	中
刘兰	34	2500	否	优	713-239-7430	505 Holly Ct	78555	中
杨俊	27	8900	否	优	281-355-7990	233 Rice Blvd.	70388	低
张毅	38	9500	否	优	281-555-0544	399 Sugar Rd.	78244	低
。。。								

5.2分类的应用案例

计算机视觉

- 图像分类：针对给定的图像，利用数据挖掘算法使得计算机具备将其预测为某一类别的能力。



5 分类

- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念 
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.5 评估

5.3.1分类

把数据样本映射到一个事先定义的类中的学习过程，即给定一组输入的属性向量及其对应的类，用机器学习算法得出分类。

描述属性

类别属性

Age	Salary	Class
30	high	c_1
25	high	c_2
21	low	c_2
43	high	c_1
18	low	c_2
33	low	c_1
…	…	…

5.3.1分类

- 描述属性：连续型属性或离散型属性
- 类别属性：离散型属性

- 连续型属性是指在某一个区间或者无穷区间内该属性的取值是连续的。

  例如：属性“Age”
- 离散型属性是指该属性的取值是不连续的。

  例如：属性“Salary”和“Class”

5.3.2分类模式

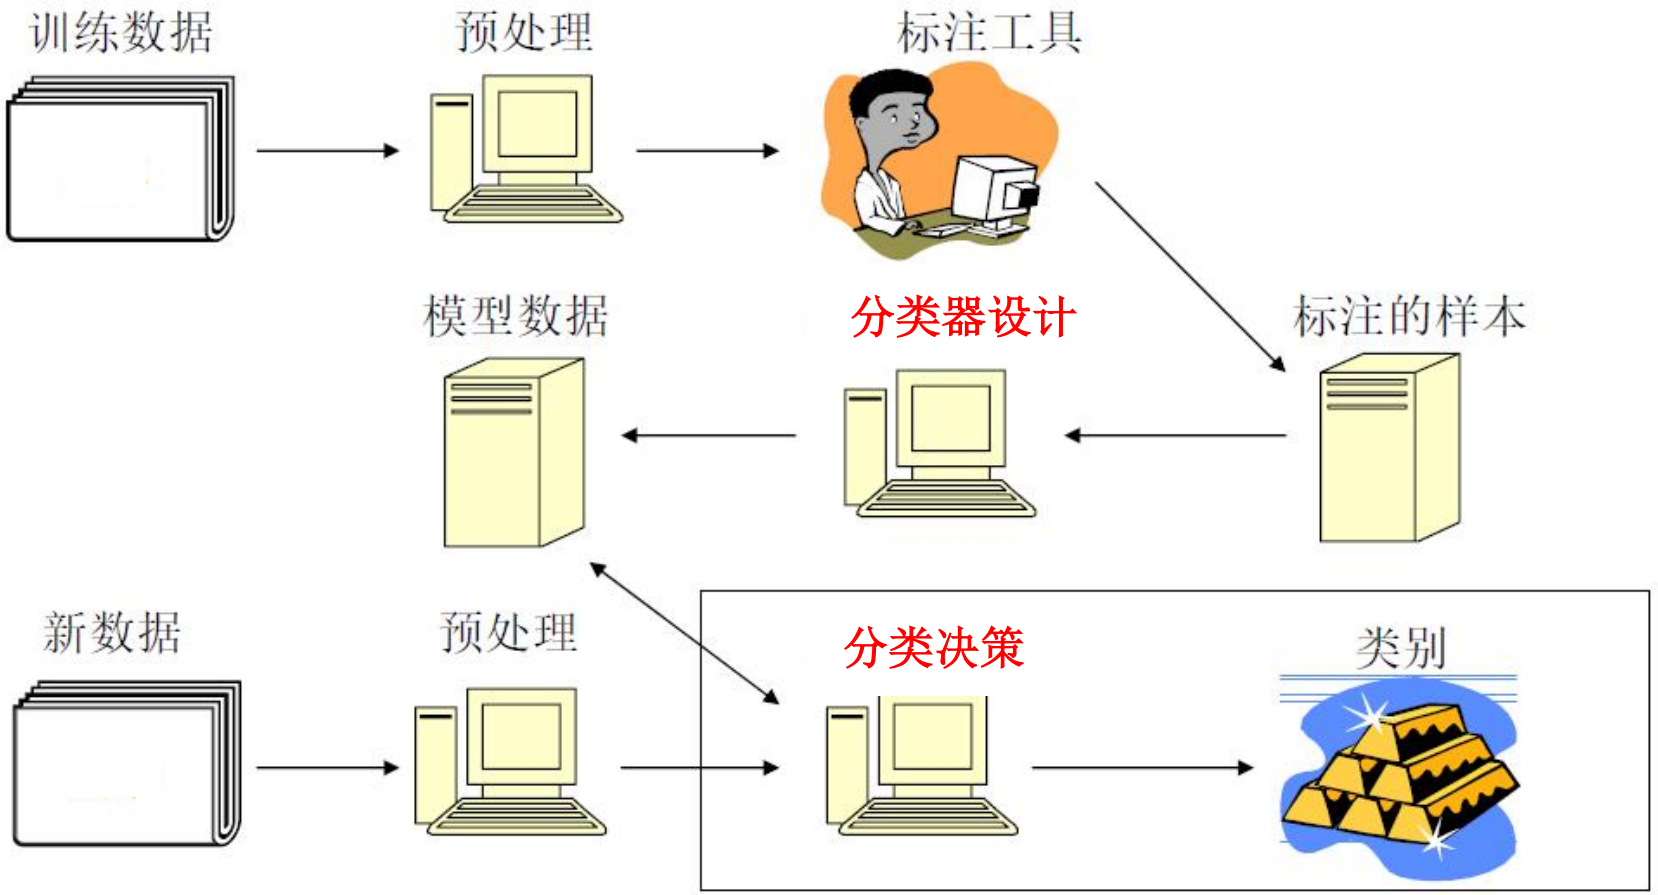
分类模式

- 二类问题，属于或不属于(binary)
- 多类问题，多个类别(multi-class)
- 多标签问题 (multi-label)



- 是（是否风景）
- 海边（海边、市内、高速等多类中的一类）
- 天空、白云、沙滩、树、山

5.3.3 分类过程



5.3.3 分类过程

训练集

Age	Salary	Class
30	high	c_1
25	high	c_2
21	low	c_2
43	high	c_1

x y

测试集

Age	Salary	Class
18	low	
33	low	?
…	…	

5.3.3 分类过程

训练集

NAME	RANK	YEARS	TENURED
Mike	Assistant Prof	3	no
Mary	Assistant Prof	7	yes
Bill	Professor	2	yes
Jim	Associate Prof	7	yes
Dave	Assistant Prof	6	no
Anne	Associate Prof	3	no

x y

测试集

NAME	RANK	YEARS	TENURED
Tom	Assistant Prof	2	
Merlisa	Associate Prof	7	?
George	Professor	5	
Joseph	Assistant Prof	7	

5.3.3 分类过程

关键步骤：

- 获取数据

  输入数据、对数据进行量化

- 预处理
  - 去除噪声数据、对空缺值进行处理
  - 数据集成或者变换
- 学习阶段

  划分数据集、在训练集上构造分类器

- 测试阶段

  对未知类标号的测试数据样本进行分类

5.3.3 分类过程

- 学习阶段：目标是建立描述预先定义的数据类或概念集的分类器
  - 监督学习



Learning

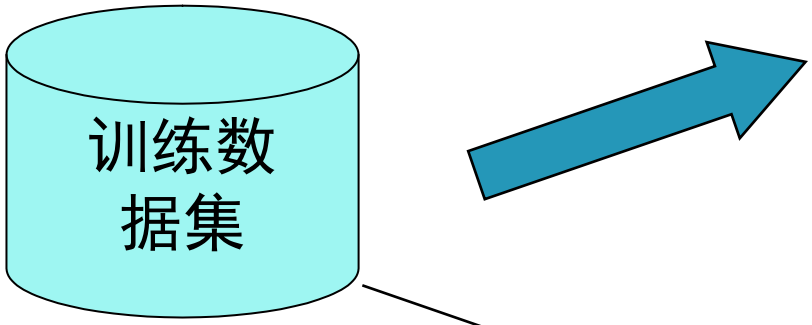




5.3.3 分类过程

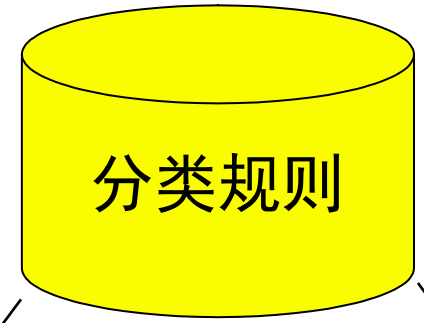
- 学习阶段：目标是建立描述预先定义的数据类或概念集的分类器
  - 监督学习
  - 训练集：由数据样本（用d维属性向量表示）和他们相对应的类标号组成
  - 训练样本：训练数据集中的单个样本；假定每个样本属于一个预定义的类
  - 分类算法通过分析或从训练集“学习”来构造分类器
  - 学习一个映射或函数$y=f(X)$
  - 学习模型可以用分类规则、决策树或数学公式等形式

5.3.3 分类过程



分类算法



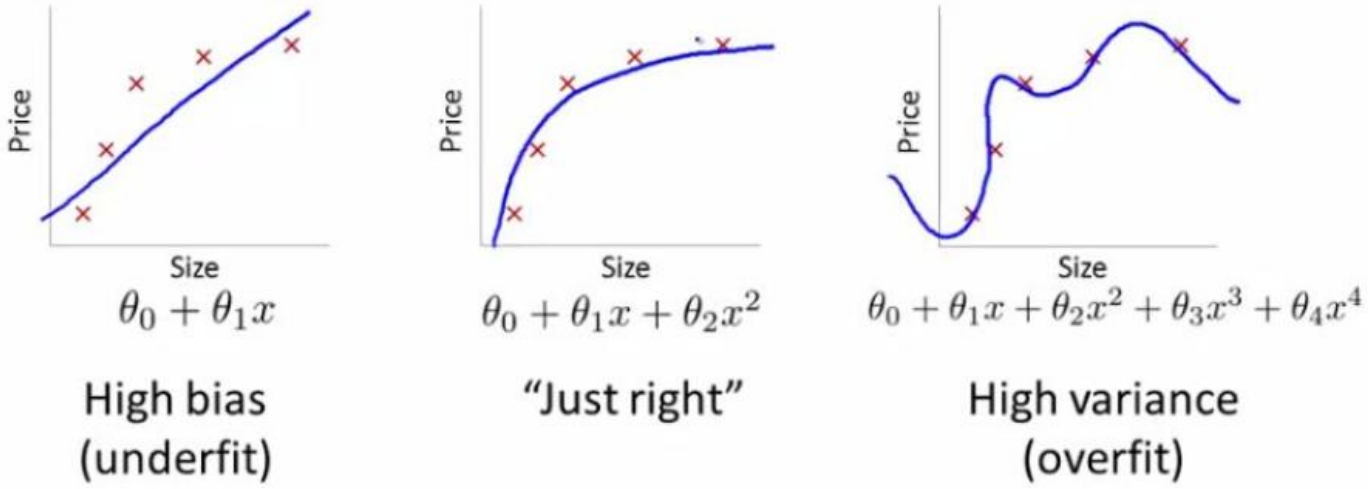


NAME	RANK	YEARS	TENURED
Mike	Assistant Prof	3	no
Mary	Assistant Prof	7	yes
Bill	Professor	2	yes
Jim	Associate Prof	7	yes
Dave	Assistant Prof	6	no
Anne	Associate Prof	3	no

IF rank = ‘professor’
OR years > 6
THEN tenured = ‘yes’

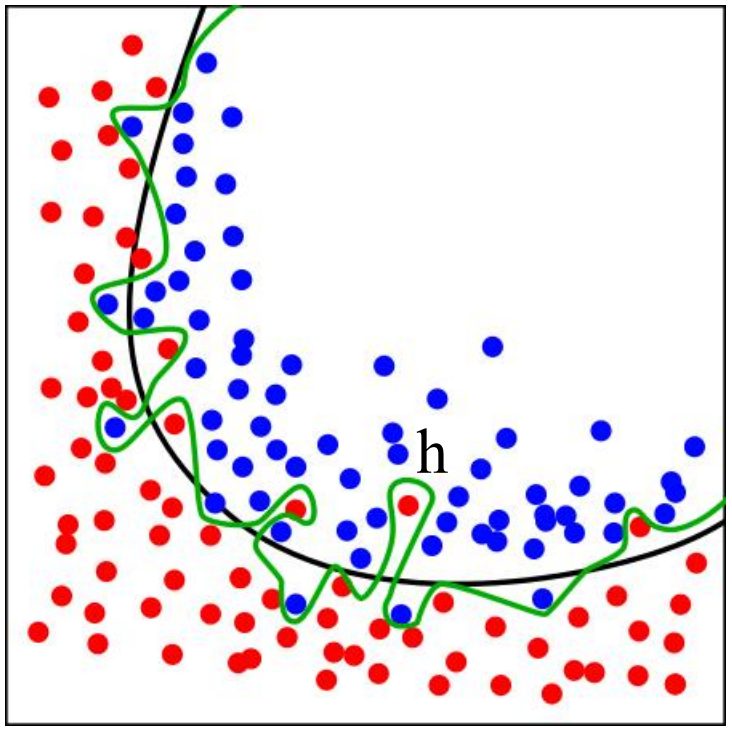
5.3.3 分类过程

- 测试阶段，使用模型，对将来的或未知的对象进行分类
  - 评估模型的预测准确率
    - 对每个测试样本，将已知的类标号和该样本的学习模型类预测比较
    - 准确率是正确被模型分类的测试样本的百分比
  - 测试集要独立于训练样本集，否则会出现“过分拟合”(overfitting)的情况



5.3.3 分类过程

过拟合：给定一个假设空间H，一个假设h属于H，如果存在其他的假设h’属于H，使得在训练样例上h的错误率比h’小，但在整个实例分布上h’比h的错误率小，那么就说假设h过度拟合训练数据。 ——《Machine Learning》Tom M.Mitchell



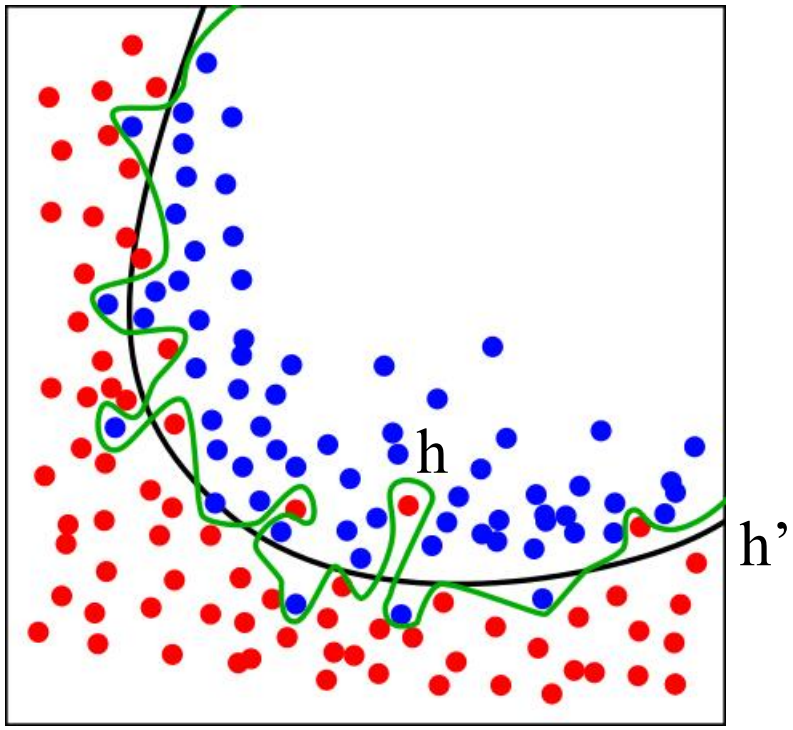
产生原因：

- 建模样本抽取错误，包括样本数量太少，抽样方法错误，抽样时没有足够正确考虑业务场景或业务特点，等等导致抽出的样本数据不能有效足够代表业务逻辑或业务场景；
- 样本里的噪音数据干扰过大，大到模型过分记住了噪音特征，反而忽略了真实的输入输出间的关系；
- 建模时的“逻辑假设”到了模型应用时已经不能成立了。例如假设建模数据与后来的应用数据是相似的等等。
- 参数太多、模型复杂度高。

…

5.3.3 分类过程

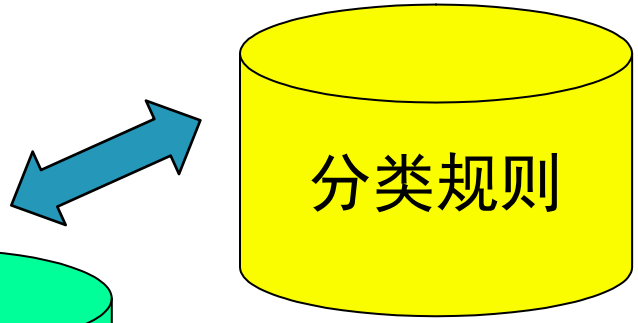
过拟合：给定一个假设空间H，一个假设h属于H，如果存在其他的假设h’属于H，使得在训练样例上h的错误率比h’小，但在整个实例分布上h’比h的错误率小，那么就说假设h过度拟合训练数据。 ——《Machine Learning》Tom M.Mitchell

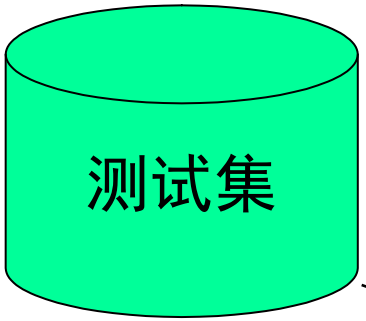


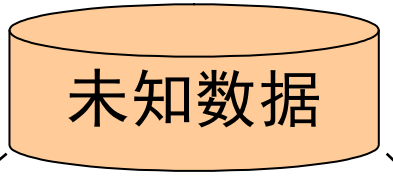
解决方案：

- 交叉验证
- 添加正则项
  - L1正则更加容易产生稀疏解
  - L2正则倾向于让参数w趋向于0
- 针对树模型
  - 在树过于大之前便停止生长
  - 等树生长到足够大之后进行修剪
  - …

5.3.3 分类过程







(George, Professor, 5)

NAME	RANK	YEARS	TENURED
Tom	Assistant Prof	2	no
Merlisa	Associate Prof	7	no
George	Professor	5	yes
Joseph	Assistant Prof	7	yes

Tenured?



Yes

5.3.4分类数学定义

- 给定：

  分类问题中使用的数据集（训练集）$X=\{(\boldsymbol{x}_i,y_i)|i=1,2,\ldots,N\}$

  - $\boldsymbol{x}_i=(x_{i1},x_{i2},\ldots,x_{id})$，其中$x_{i1},x_{i2},\ldots,x_{id}$分别对应$d$个描述属性$A_1,A_2,\ldots,A_d$的具体取值
  - y_i表示数据样本$\boldsymbol{x}_i$的类标号，假设给定数据集包含m个类别，则$y_i\in\{c_1,c_2,\ldots,c_m\}$，其中$c_1,c_2,\ldots,c_m$是类别属性$C$的具体取值

- 确定一个分类函数$y=f(X)$
- 未知类标号的数据样本集（测试集）中的测试样本$\boldsymbol{x}'$用d维特征向量$\boldsymbol{x}'=(x_1,x_2,\ldots,x_d)$表示，得到其所属的类别

5 分类

- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.5 评估
- 5.6 长尾分布建模

5.4 常用的分类方法

分类技术是一种根据输入数据集建立分类模型的系统方法。分类技术一般是用一种学习算法确定分类模型，该模型可以很好地拟合输入数据中类标号和属性集之间的联系。

学习算法得到的模型不仅要很好拟合输入数据，还要能够正确地预测未知样本的类标号。因此，训练算法的主要目标就是要建立具有很好的泛化能力模型，即建立能够准确地预测未知样本类标号的模型。

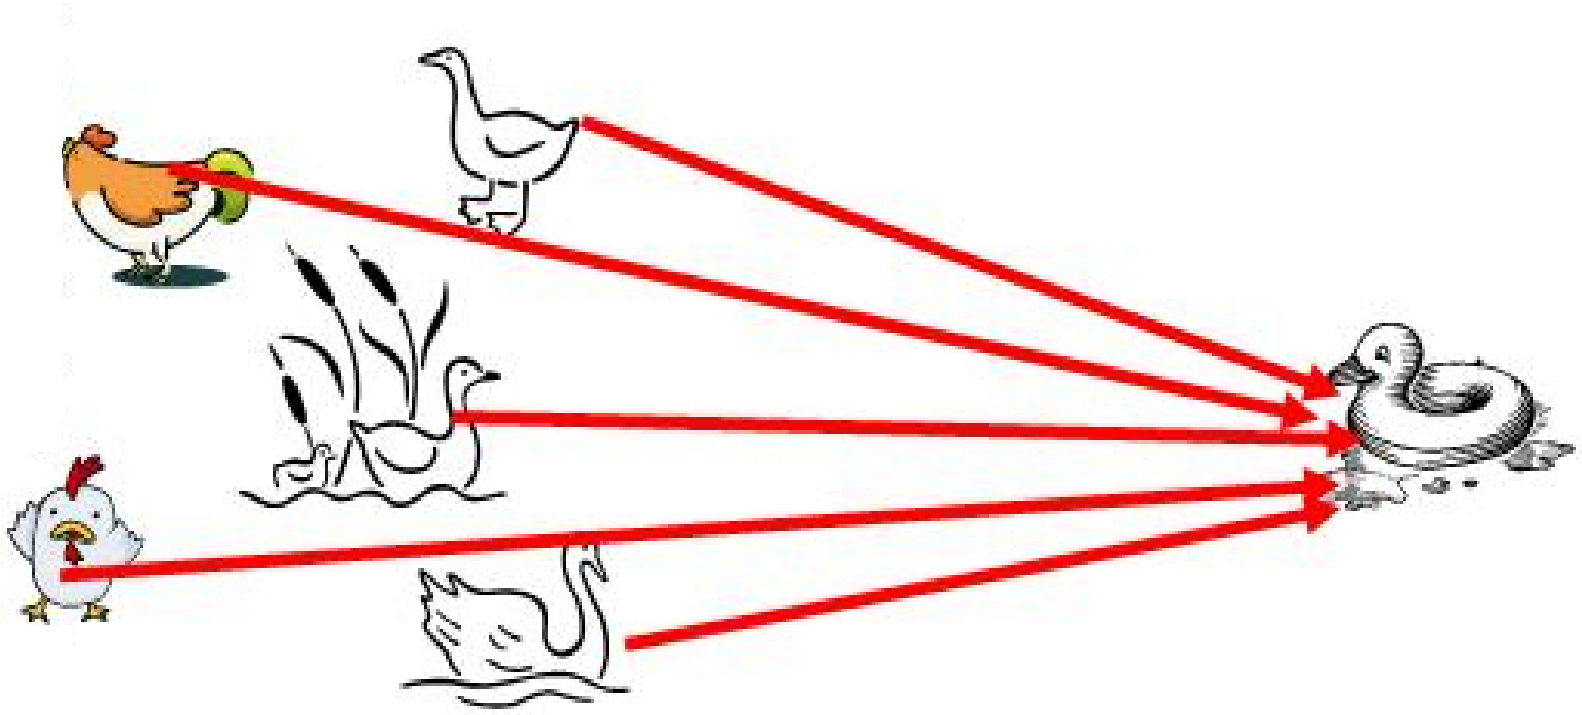
分类方法的实例包括：决策树、支持向量机、神经网络、k-近邻方法、朴素贝叶斯分类方法等。

数据挖掘领域的十大经典算法ICDM'06

- #1: C4.5 (51 votes) (分类)
- #2: K-Means (50 votes) (聚类)
- #3: SVM (58 votes) (分类)
- #4: Apriori (52 votes) (关联规则)
- #5: EM (48 votes)
- #6: PageRank (45 votes)
- #7: AdaBoost (45 votes)
- #7: kNN (45 votes) (分类)
- #7: Naive Bayes (45 votes) (分类)
- #10: CART (34 votes) (分类)

5.4.1 K-近邻

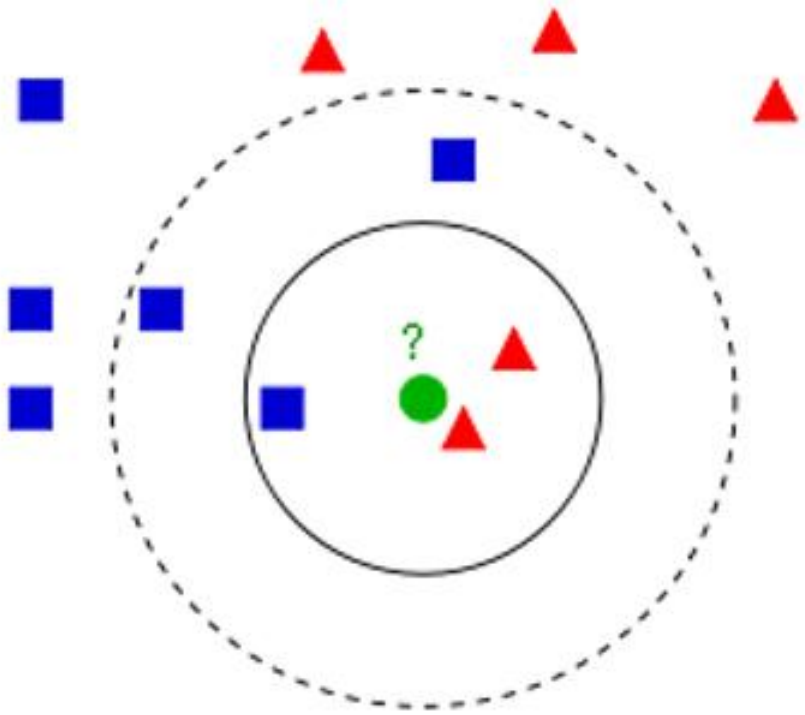
给定一个未知样本，k-最近邻分类法搜索模式空间，找出最接近未知样本的k个训练样本；然后使用k个最临近者中最公共的类来预测当前样本的类标号



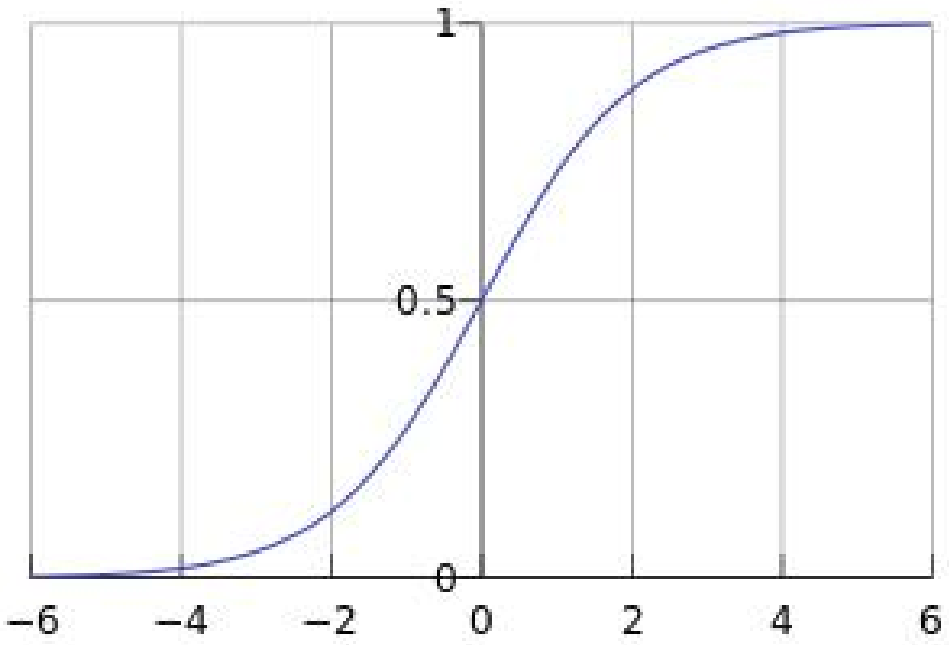
5.4.1 K-近邻

研究点：

- 近邻个数的选取
- 近邻的度量方法



5.4.2 Logistic回归方法



$$\mathcal{L}(\boldsymbol{w}) = \sum_{n=1}^{N} \left[-y^{(n)} \log \pi \left(\boldsymbol{x}^{(n)} \right) - \left(1 - y^{(n)} \right) \log \left(1 - \pi \left(\boldsymbol{x}^{(n)} \right) \right) \right]$$

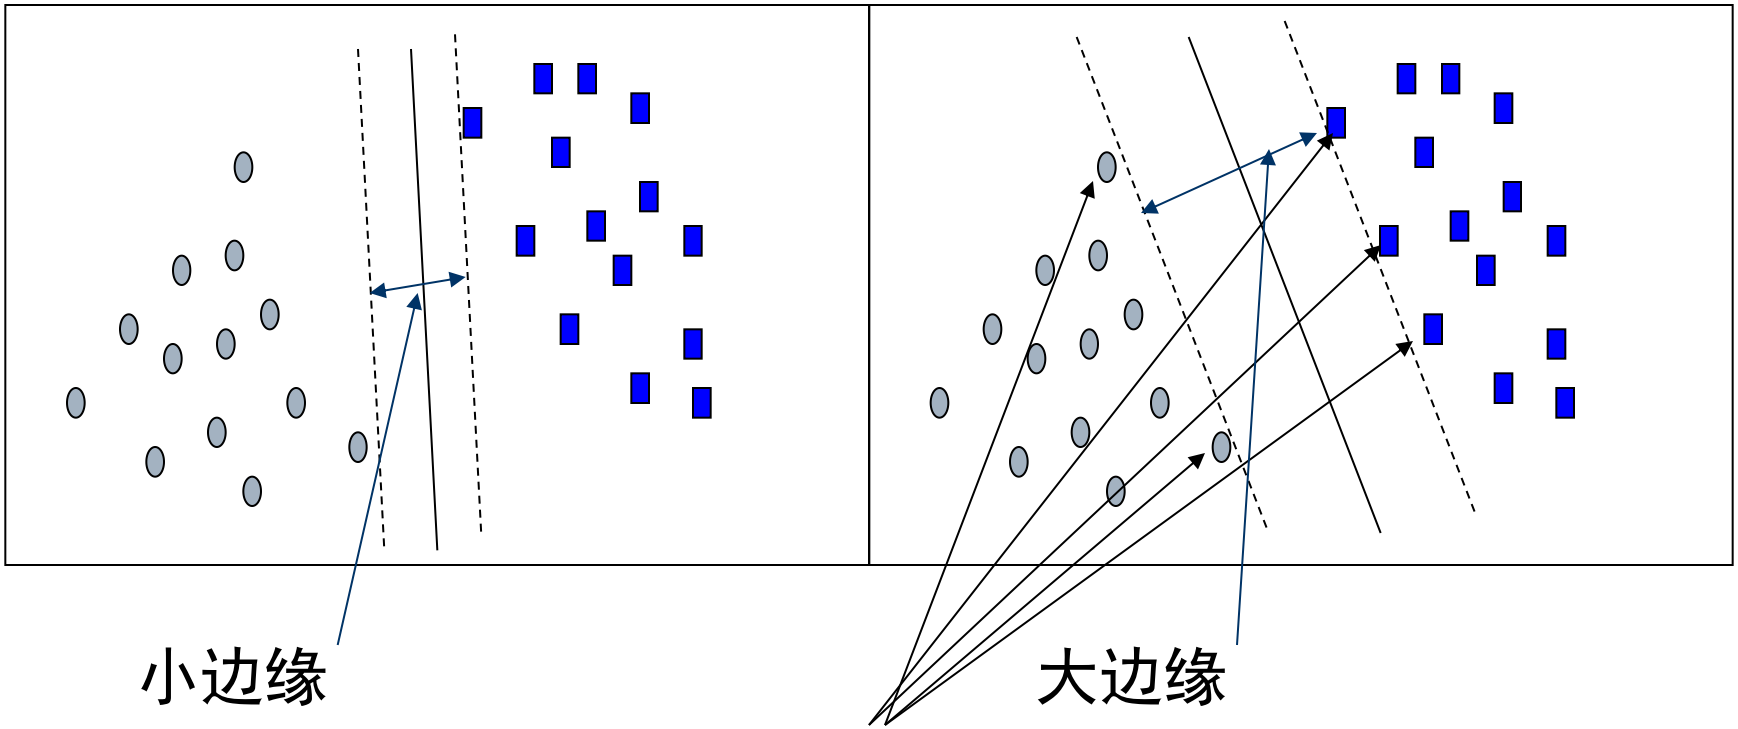
$$= \sum_{n=1}^{N} \left[-y^{(n)} \left(\boldsymbol{w}^T \boldsymbol{x}^{(n)} \right) + \log \left(1 + \exp \left(\boldsymbol{w}^T \boldsymbol{x}^{(n)} \right) \right) \right]$$

5.4.3 支持向量机

- 一个数据被认为是d维向量，数据在这d维向量空间中被分为两类；SVM的目的是找到一个d-1维的超平面，来划分d维向量空间的数据
- 其决策边界是对学习样本求解的最大边距超平面（maximum-margin hyperplane）
- SVM可以通过核方法（kernel method）进行非线性分类，是常见的核学习（kernel learning）方法之一

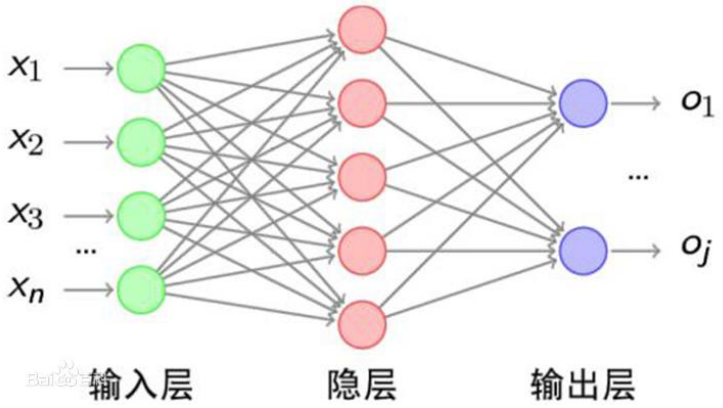
5.4.3 支持向量机

一般原理



5.4.4 神经网络

- 神经网络是一组连接的输入/输出单元，每个连接都与一个权相连。在学习阶段，通过调整神经网络的权，使得能够预测输入样本的正确标号来学习。
- 优点
  - 预测精度总的来说较高
  - 健壮性好，训练样本中包含错误时也可正常工作
  - 输出可能是离散值、连续值或者是离散或量化属性的向量值
- 缺点
  - 训练（学习）时间长
  - 蕴涵在学习的权中的符号含义很难理解
  - 很难结合专业领域知识

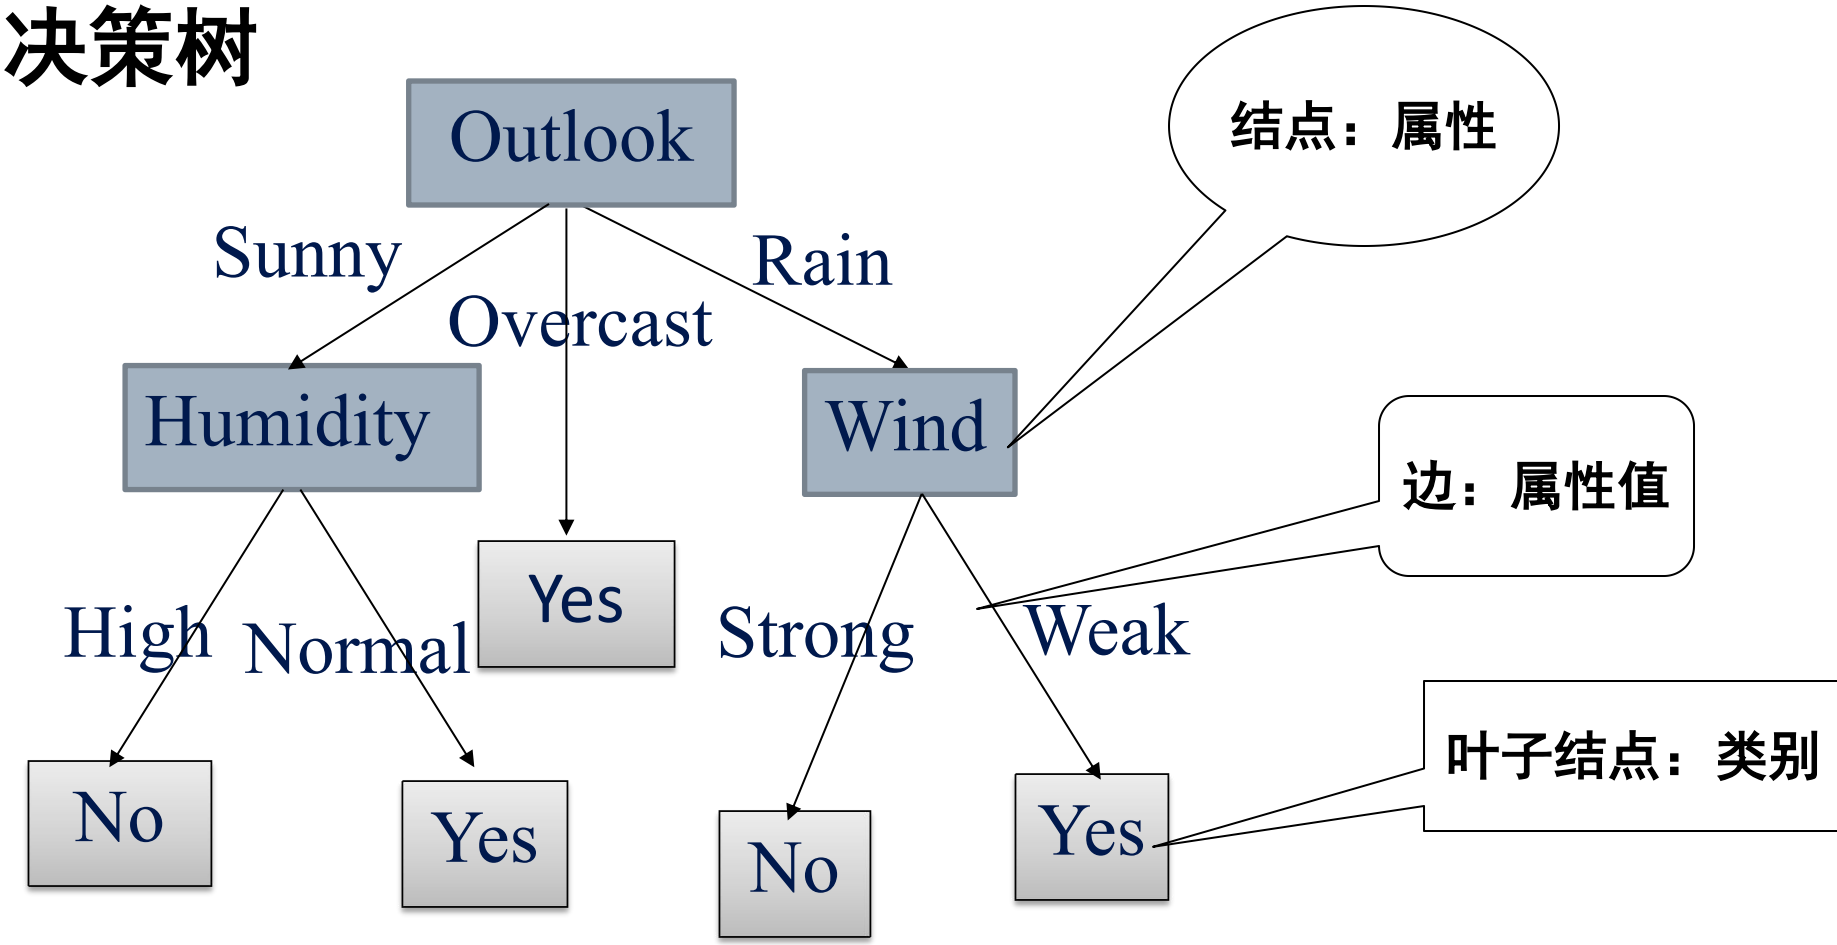


5.4.5 决策树

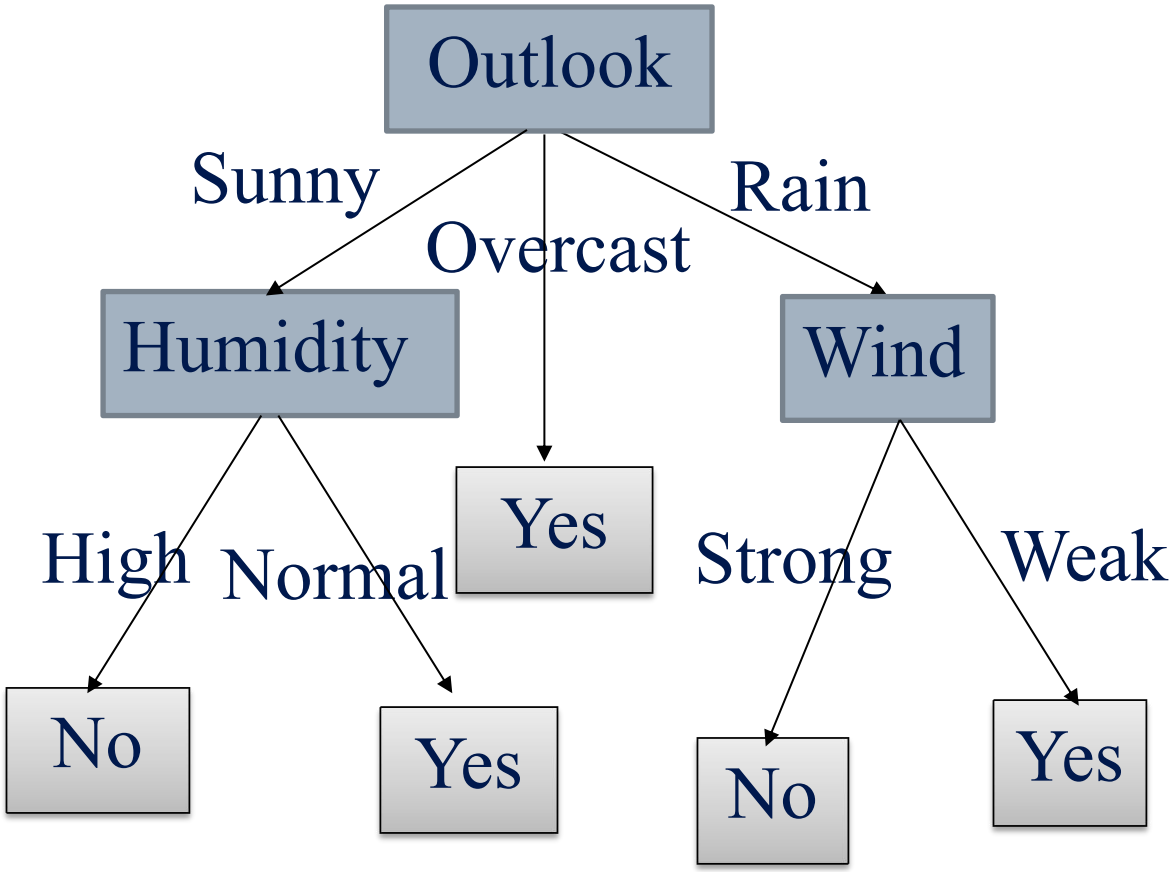
Day	Outlook	Temperature	Humidity	Wind	Play Tennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

5.4.5 决策树

决策树


Outlook
Sunny
Overcast
Rain
Humidity
Yes
Wind
High
Normal
Strong
Weak
No
Yes
No
Yes
结点：属性
边：属性值
叶子结点：类别

5.4.5 决策树



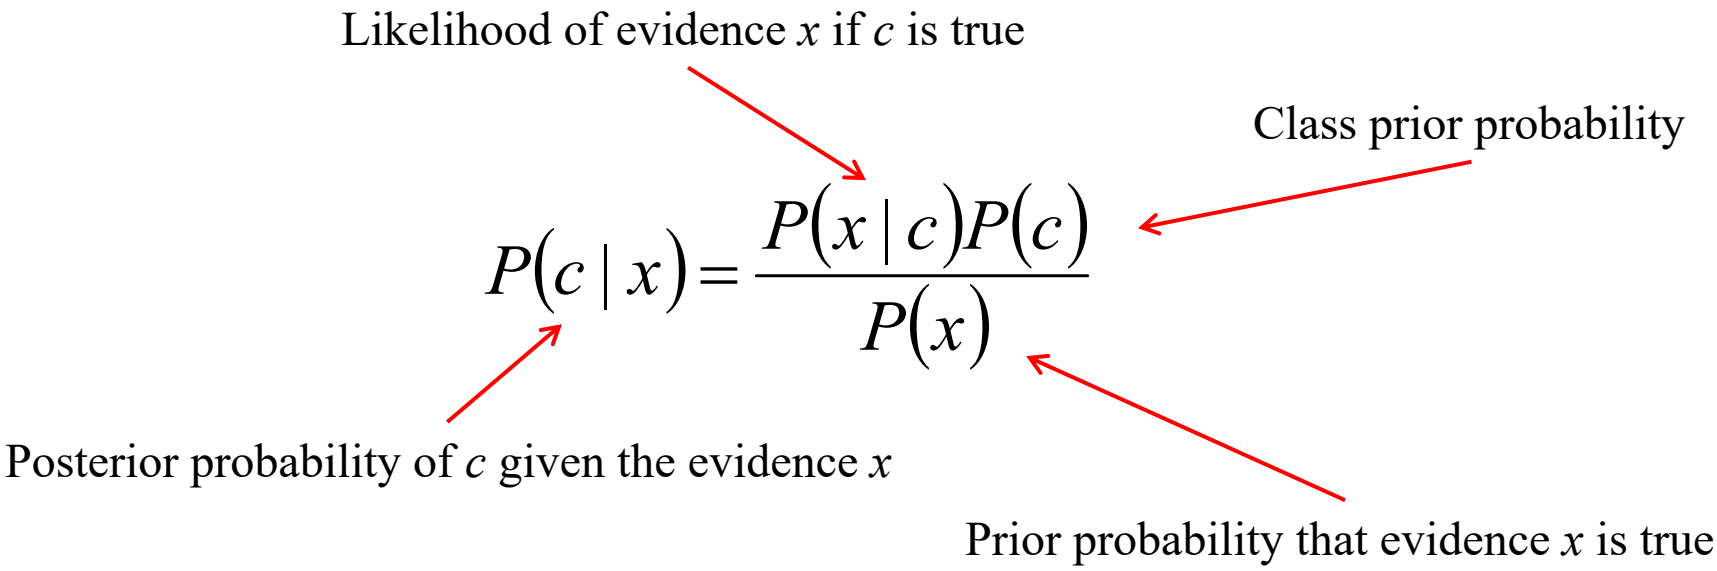
合取的析取表达式

（Outlook=Sunny AND Humidity=Normal) OR (Outlook=Overcast) OR (Outlook=Rain AND Wind=Weak)

关键问题是如何选择属性的顺序，可以采用信息增益、增益率、Gini指标等

5.4.5 贝叶斯分类

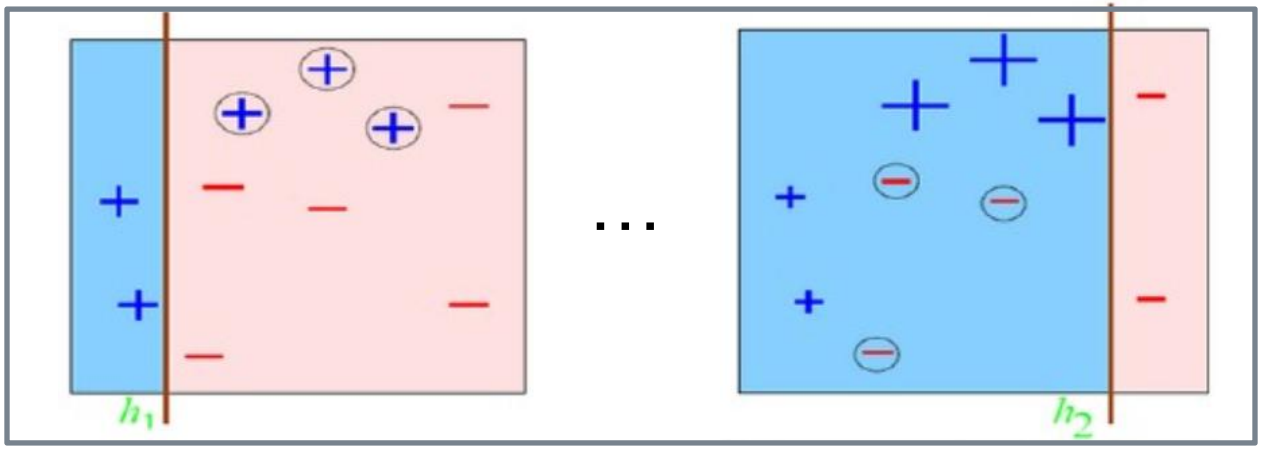
- 贝叶斯分类利用统计学中的贝叶斯定理，来预测类成员的概率，即给定一个样本，计算该样本属于一个特定的类的概率。
- 朴素贝叶斯分类：假设每个属性之间都是相互独立的，并且每个属性对非类问题产生的影响都是一样的。

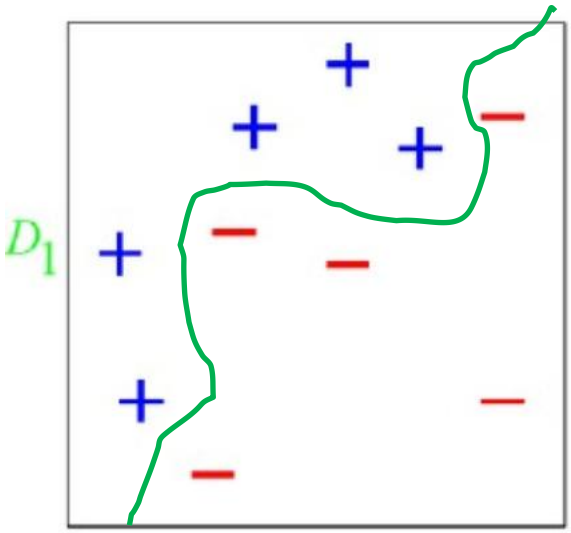


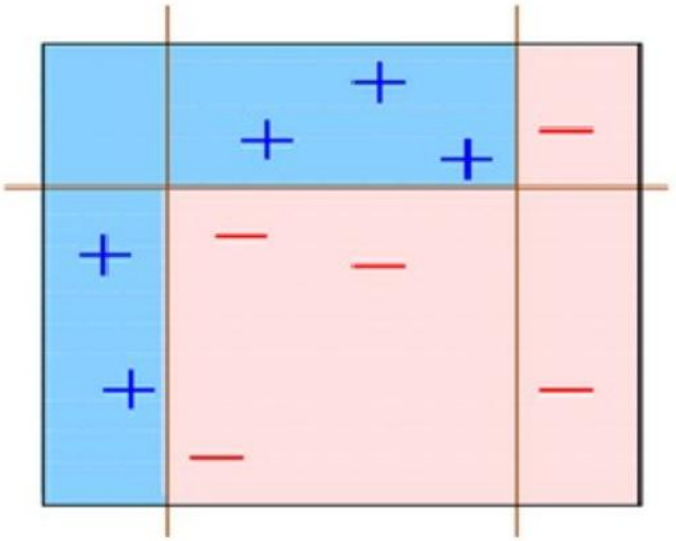
5 分类

- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.5 评估
- 5.6 长尾分布建模

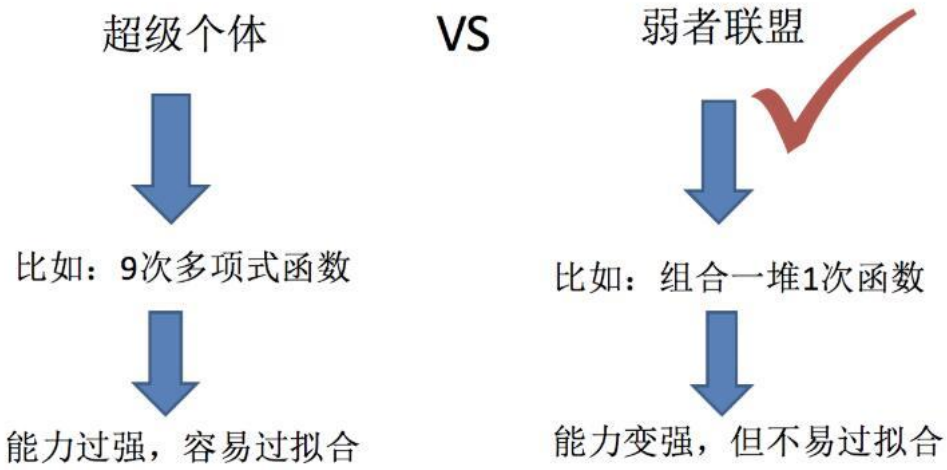
5.5 集成学习

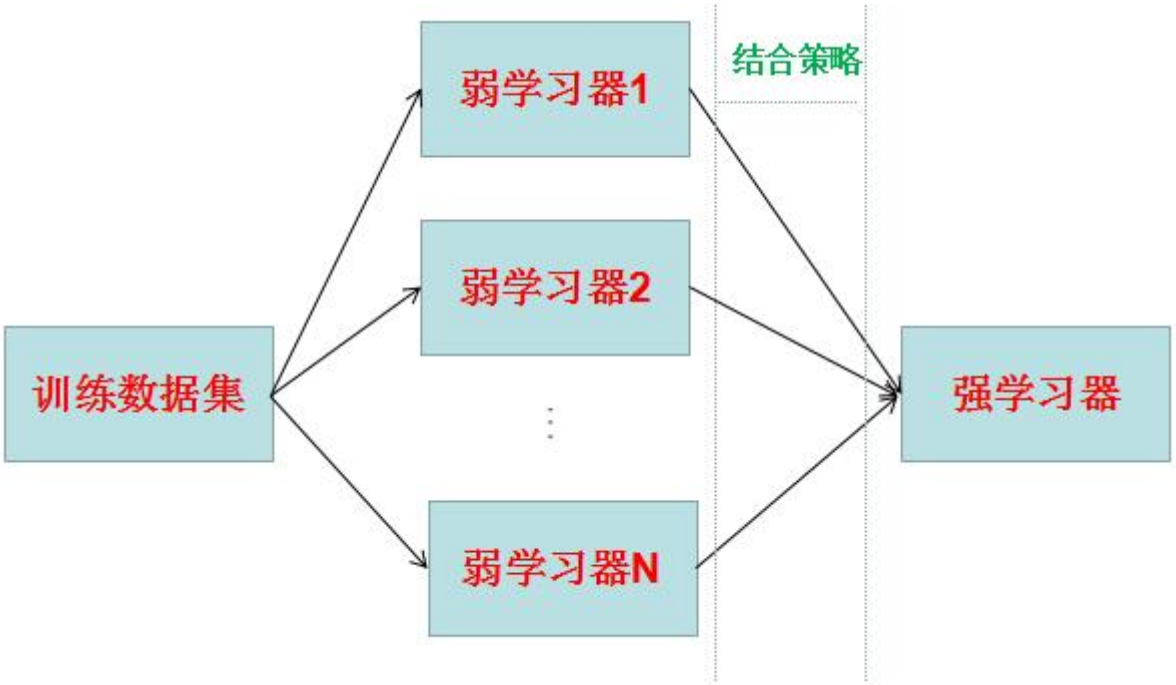




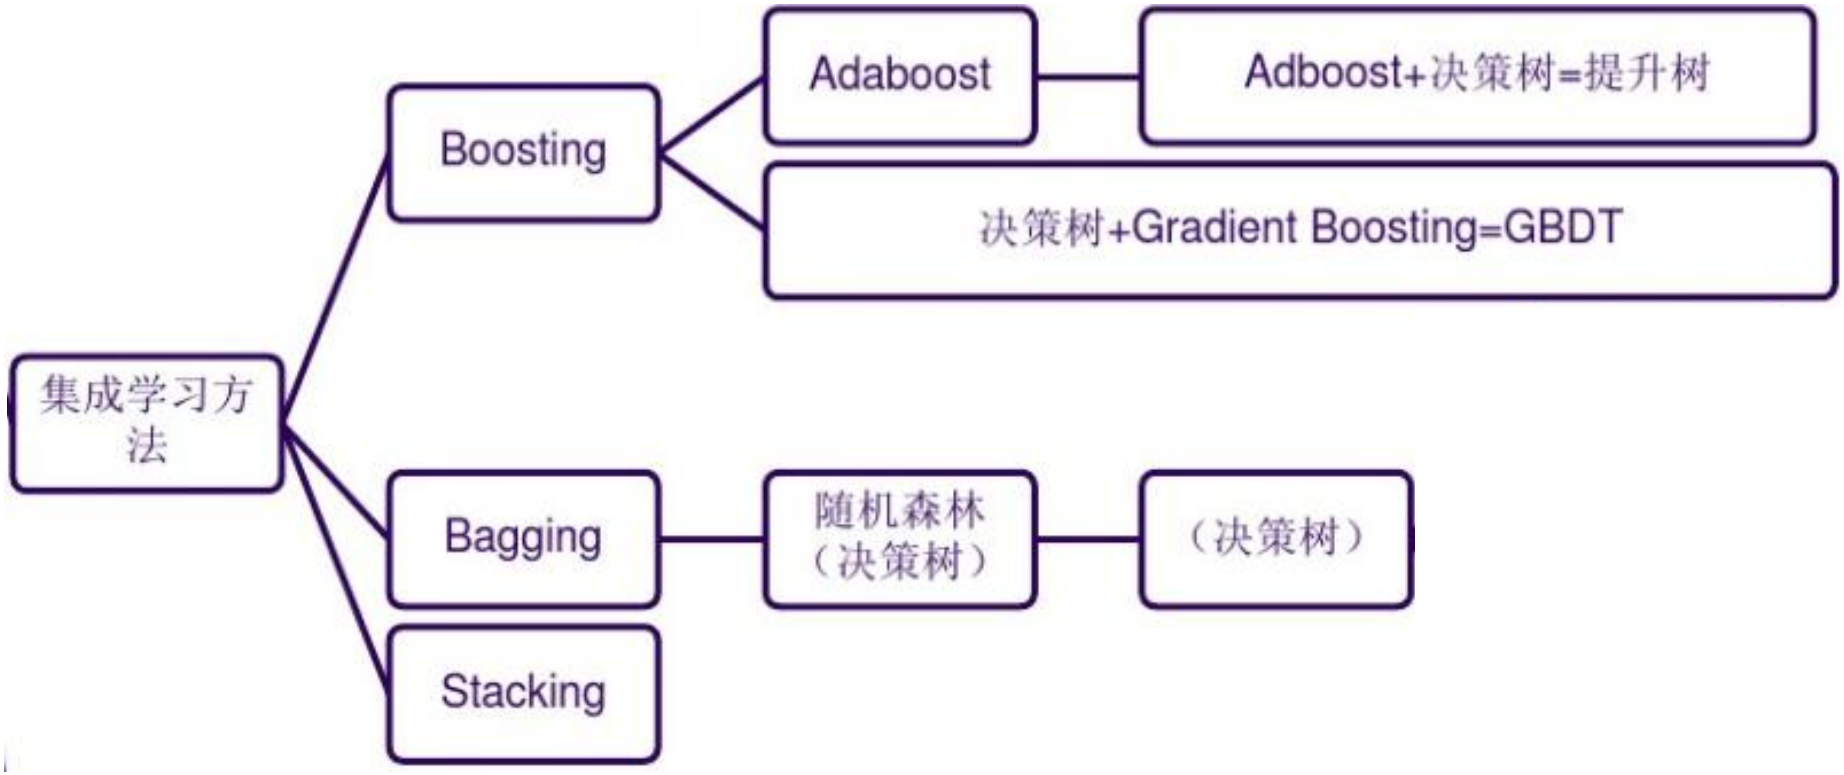


5.5 集成学习

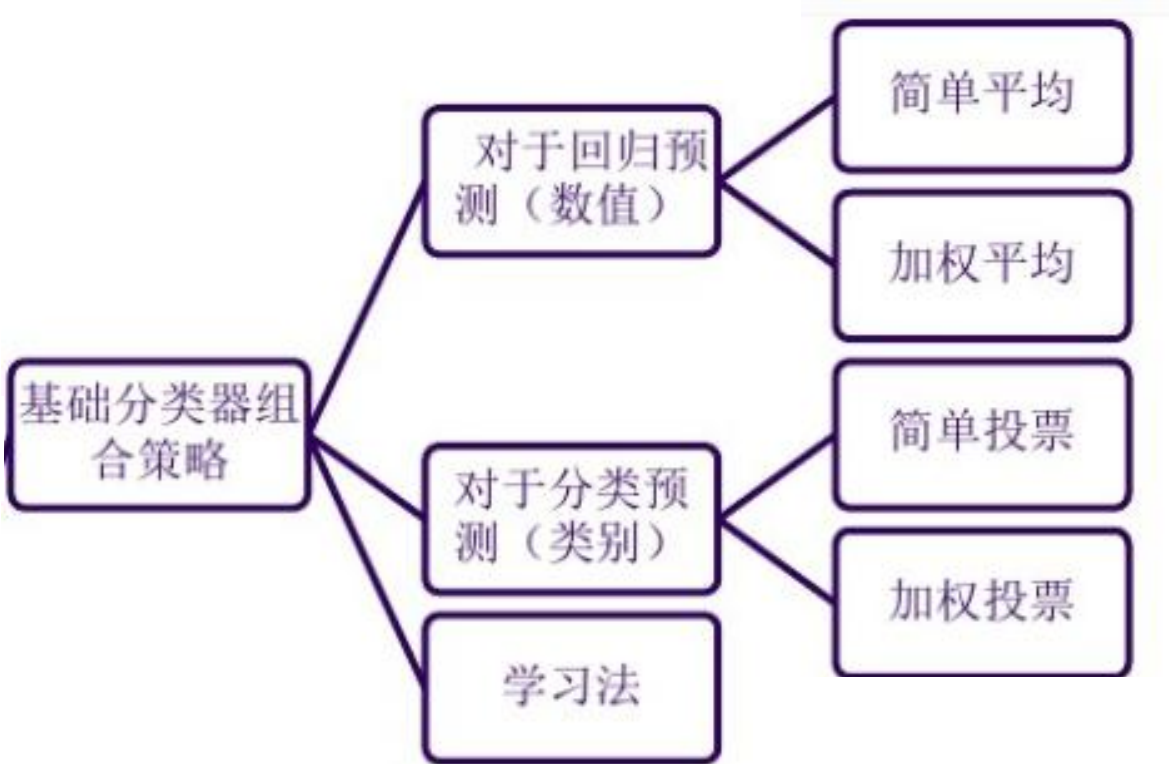

超级个体
VS
弱者联盟
比如：9次多项式函数
比如：组合一堆1次函数
能力过强，容易过拟合
能力变强，但不易过拟合


结合策略
弱学习器1
弱学习器2
弱学习器N
训练数据集
强学习器

5.5 集成学习

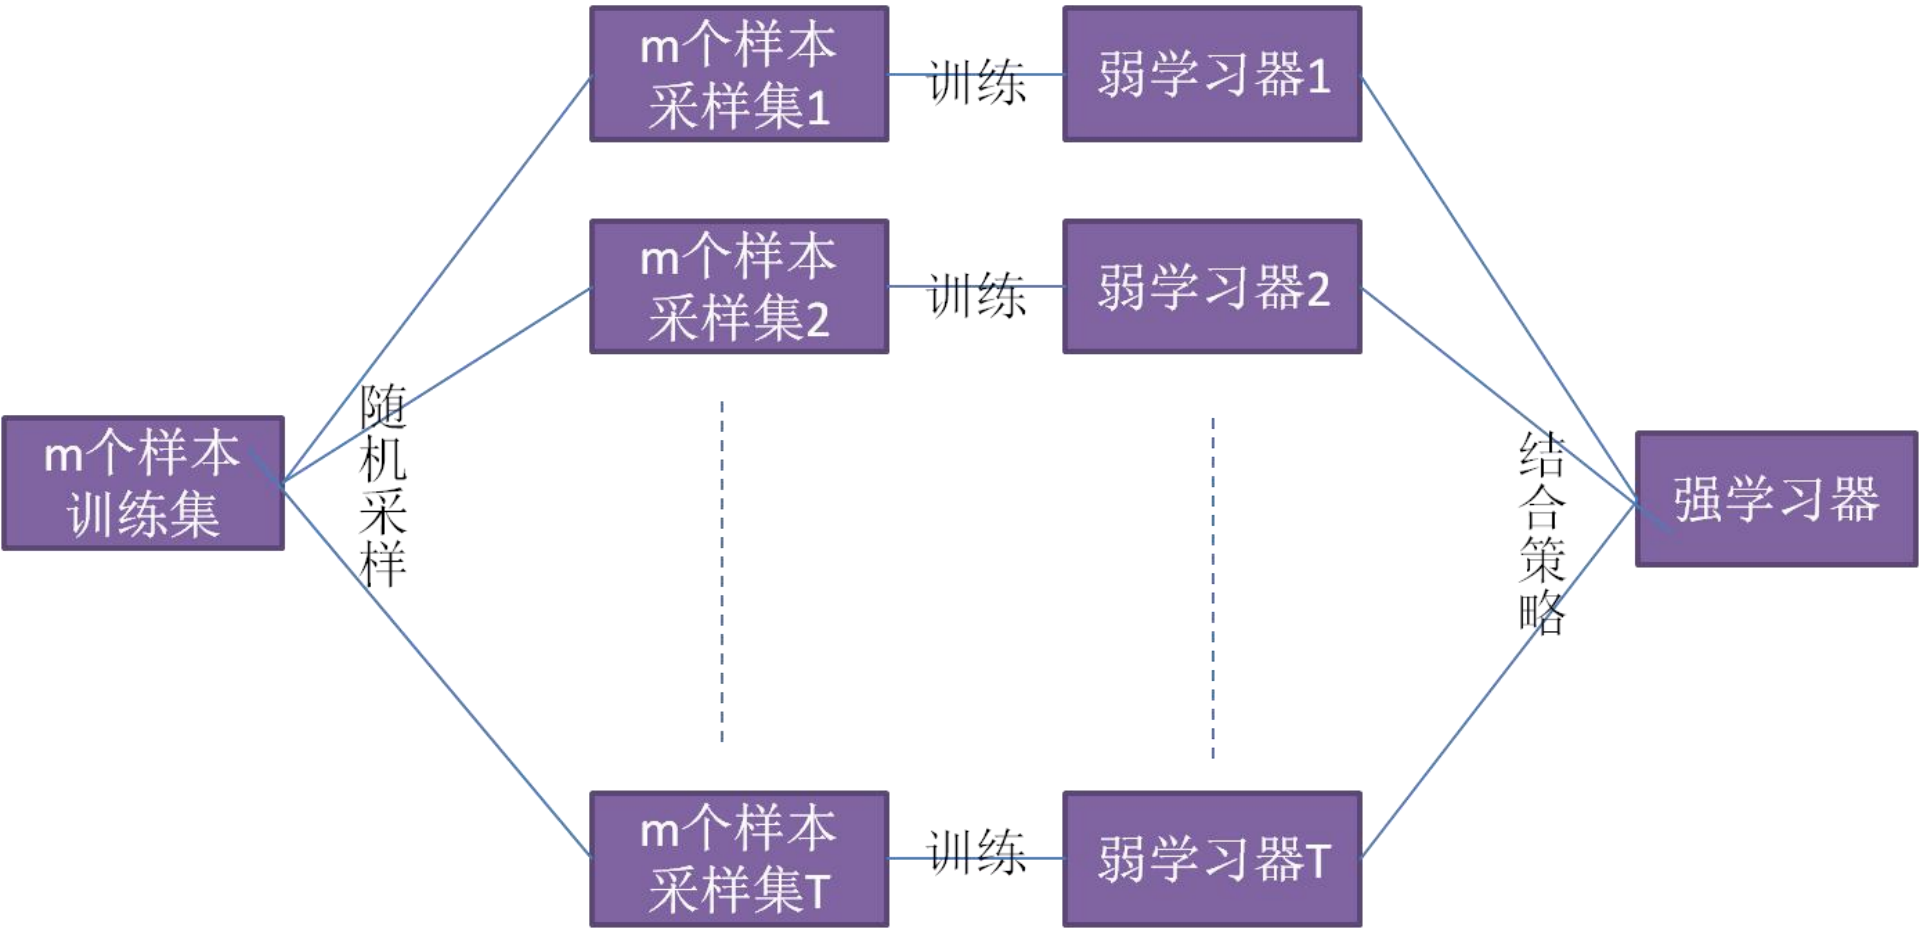

集成学习方法
Boosting
Adaboost
Adboost+决策树=提升树
决策树+Gradient Boosting=GBDT
Bagging
随机森林（决策树）
（决策树）
Stacking

5.5 集成学习



“三个臭皮匠，顶个诸葛亮”

5.5.1 Bagging


m个样本
训练集
随机采样
m个样本
采样集1
m个样本
采样集2
m个样本
采样集T
训练
训练
训练
弱学习器1
弱学习器2
弱学习器T
结合策略
强学习器

5.5.1 Bagging

Bagging即套袋法，算法过程如下：

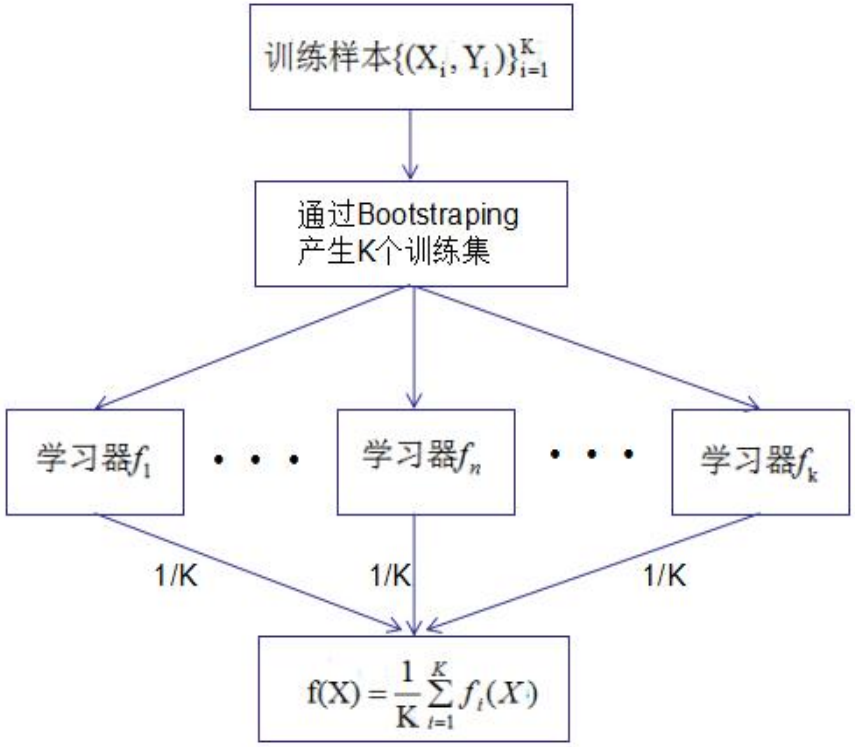
（1） 从训练样本集中随机可放回抽样（Bootstrapping)N次，得到与训练集相同大小的训练集，重复抽样K次，得到K个训练集 。

（2） 每个训练集得到一个最优模型，K个训练集得到K个最优模型。

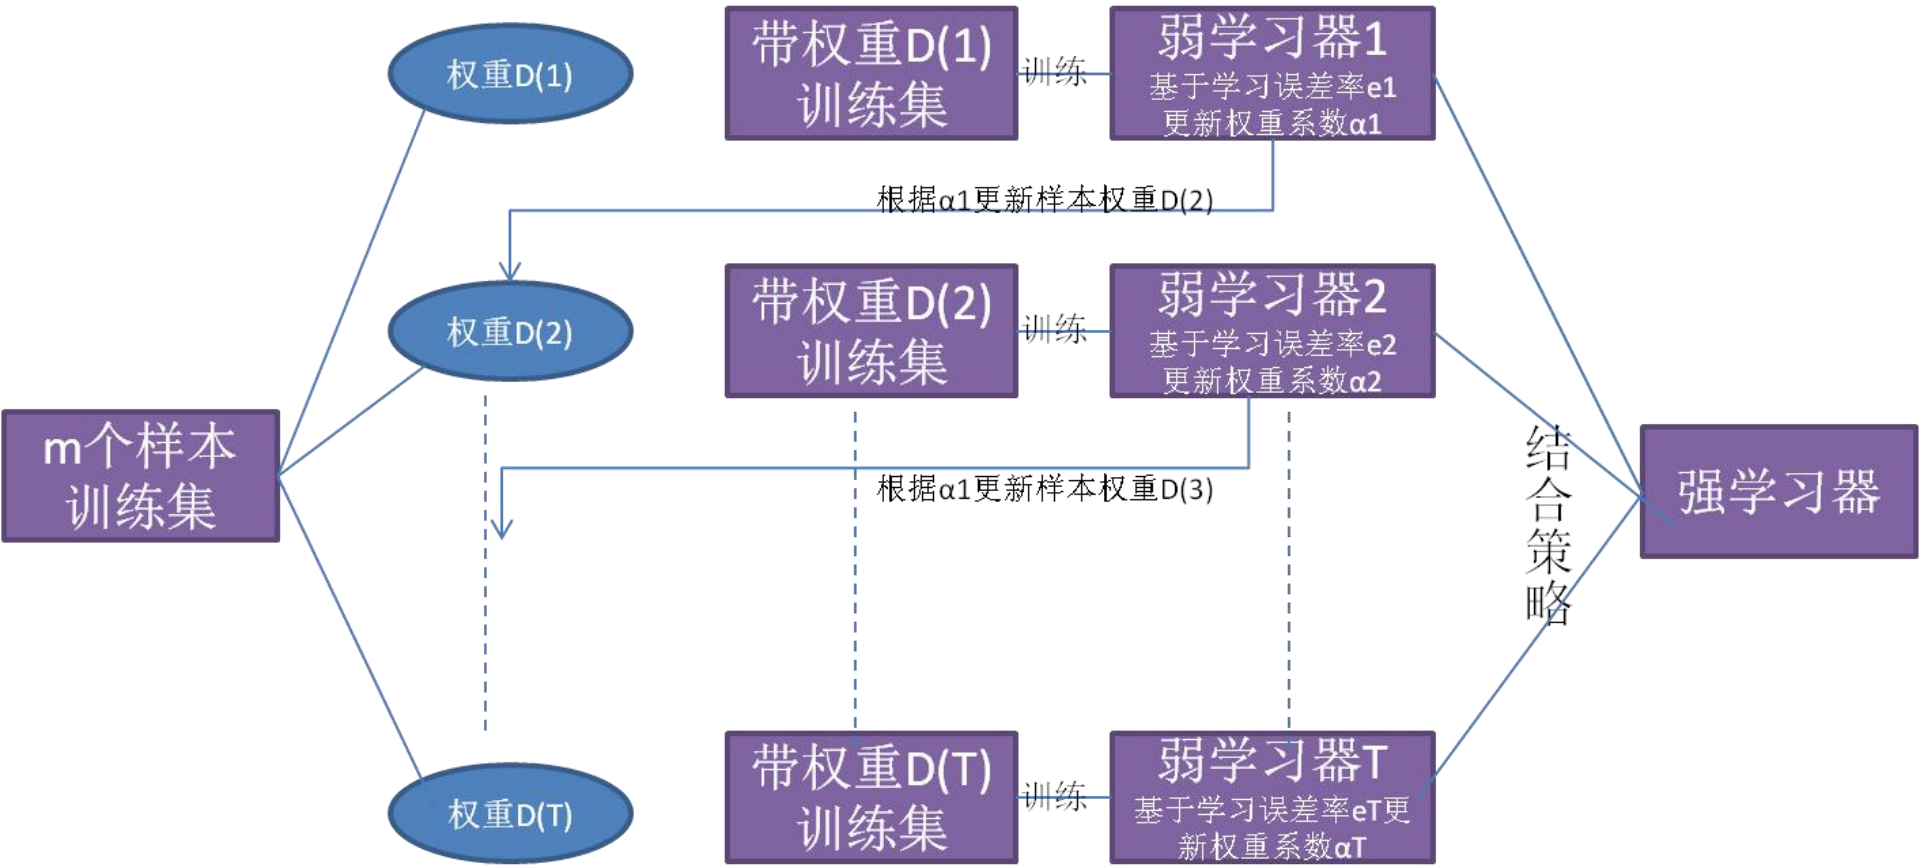
（3） 分类问题：对K个模型采用投票的方式得到分类结果；

回归问题：对K个模型的值求平均得到分类结果。



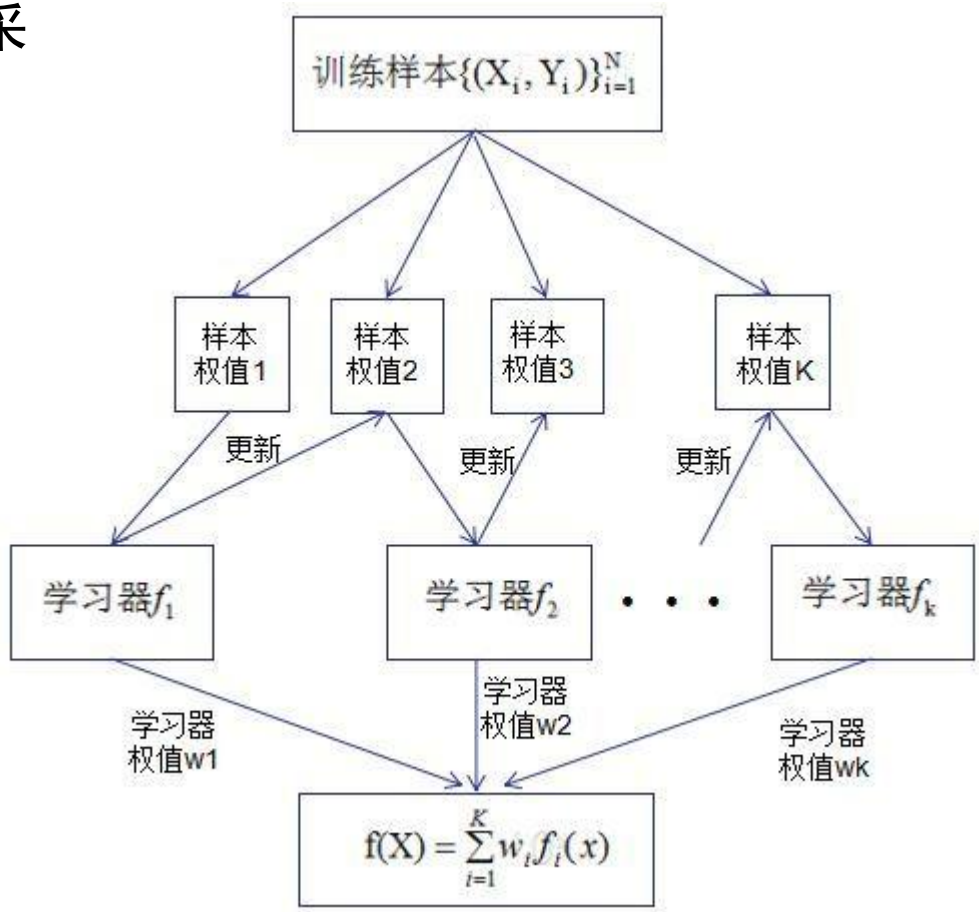


5.5.2 Boosting



5.5.2 Boosting

- Adaboost (Adaptive Boosting) 算法采用调整样本权重的方式来对样本分布进行调整。
- 提高前一轮个体学习器错误分类的样本的权重，而降低那些正确分类的样本的权重，这样就能使得错误分类的样本可以受到更多的关注，从而在下一轮中可以正确分类，使得分类问题被一系列的弱分类器“分而治之”。
- 对于组合方式，AdaBoost采用加权多数表决的方法，加大分类误差率小的若分类器的权值，减小分类误差率大的若分类器的权值，从而调整他们在表决中的作用。



5.5 集成学习

- 训练样本集

Bagging：训练集是有放回抽样，从原始集中选出的K组训练集是相互独立的。

Boosting：每一次迭代的训练集不变。

- 训练样本权重

Bagging：每个训练样本的权重相等，即1/N。

Boosting：根据学习器的错误率不断调整样例的权值，错误率越大，权值越大。

- 预测函数的权重：

Bagging：K组学习器的权重相等，即1/K。

Boosting：学习器性能好的分配较大的权重，学习器性能差的分配较小的权重。

- 并行计算

Bagging：K组学习器模型可以并行生成。

Boosting：K组学习器只能顺序生成，因为后一个模型的样本权值需要前一个学习器模型的结果。

5.5 集成学习

- 常用刷榜算法：
  - 随机森林(前身是bagging或者随机抽样）(并行算法)
  - Adaboost(串行算法)
  - GBDT(gradient boosting decision tree梯度提升树) (串行算法)
  - Xgboost(eXtreme Gradient Boosting)，是经过优化的分布式梯度提升树，旨在高效、灵活且可移植。
- 参考资料：
  - 集成学习基础与算法，周志华，电子工业出版社，2020
  - Introduction to boosted trees, Tianqi Chen
  - Introduction to Boosted Trees — xgboost 1.5.0-dev documentation

5 分类

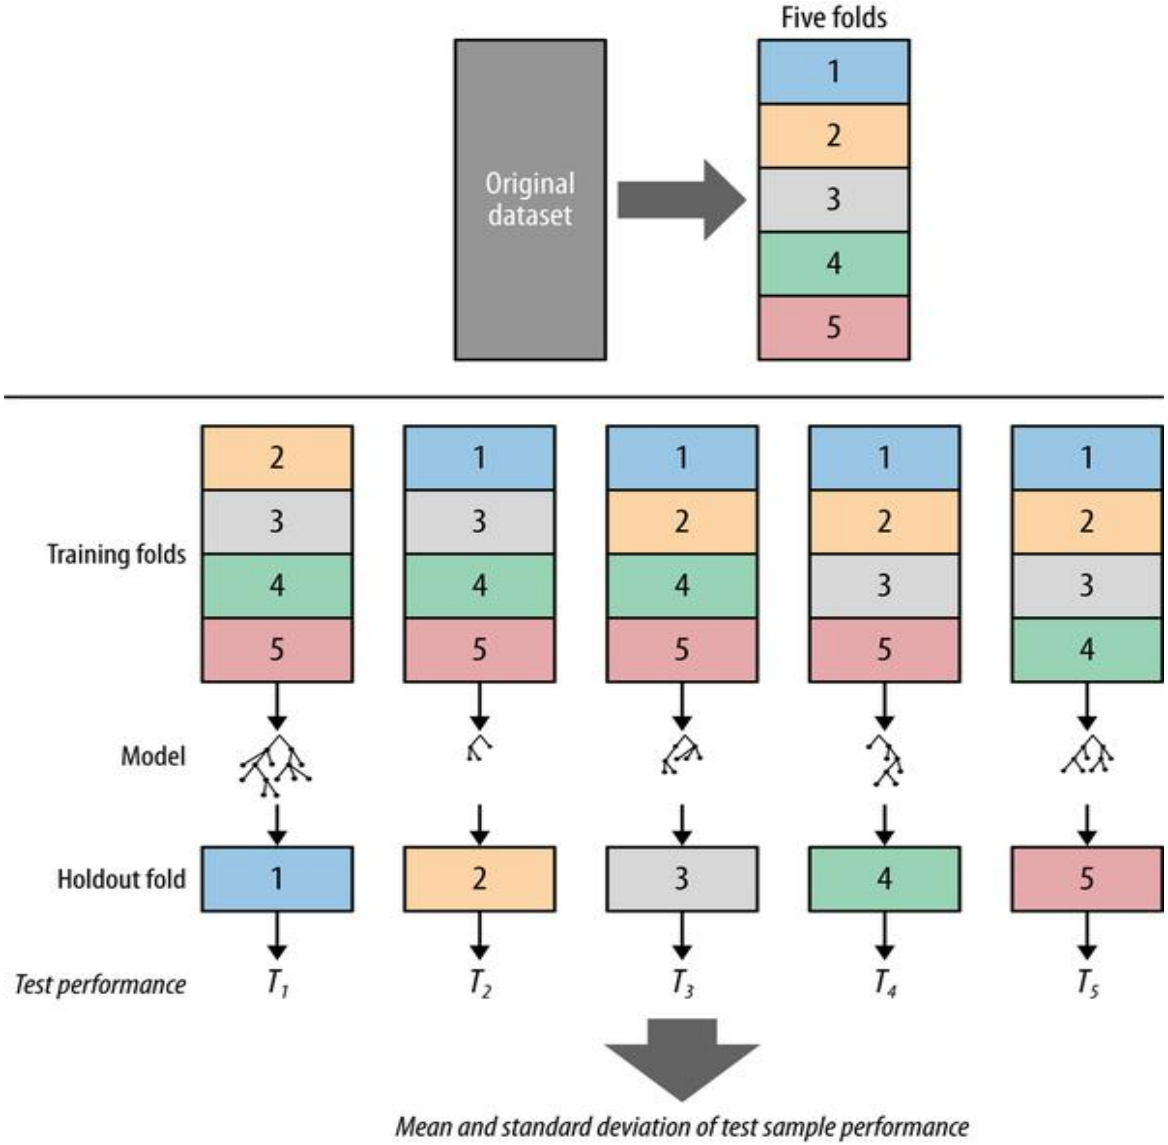
- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.5 评估
- 5.6 长尾分布建模

5.5.1 分类的评价方法

- 训练测试法(training-and-testing)
  - 把数据随机分成训练集和测试：训练集 (e.g., 2/3) 用于模型构建；测试 (e.g., 1/3) 用于评估准确率
- 交叉验证法(cross-validation)
  - 例如，十折交叉验证。即是将数据集分成十份，轮流将其中9份做训练1份做测试，10次的结果的均值作为对算法精度的估计。
  - 一般还需要进行多次10折交叉验证求均值，例如10次10折交叉验证，更精确一点。

5.5.1 分类的评价方法

- 交叉验证法(cross-validation)



5.5.1 分类的评价方法

举例

Outlook	Temperature	Humidity	Windy	Play?
sunny	hot	high	false	No
sunny	hot	high	true	No
overcast	hot	high	false	Yes
rain	mild	high	false	Yes
rain	cool	normal	false	Yes
rain	cool	normal	true	No
overcast	cool	normal	true	Yes
sunny	mild	high	false	No
sunny	cool	normal	false	Yes
rain	mild	normal	false	Yes
sunny	mild	normal	true	Yes
overcast	mild	high	true	Yes
overcast	hot	normal	false	Yes
rain	mild	high	true	No

训练测试法

14*(2/3) （大约10个）用于训练模型；

4 个样本用于测试

随机采样: 可以重复k次，取k次的平均值

十折交叉验证

14/10 equals 1.4

10次取的测试样本的个数分别为

1 1 1 1 2 2 2 2 2；

其余样本组成训练集。

5.5.2 分类的评价准则

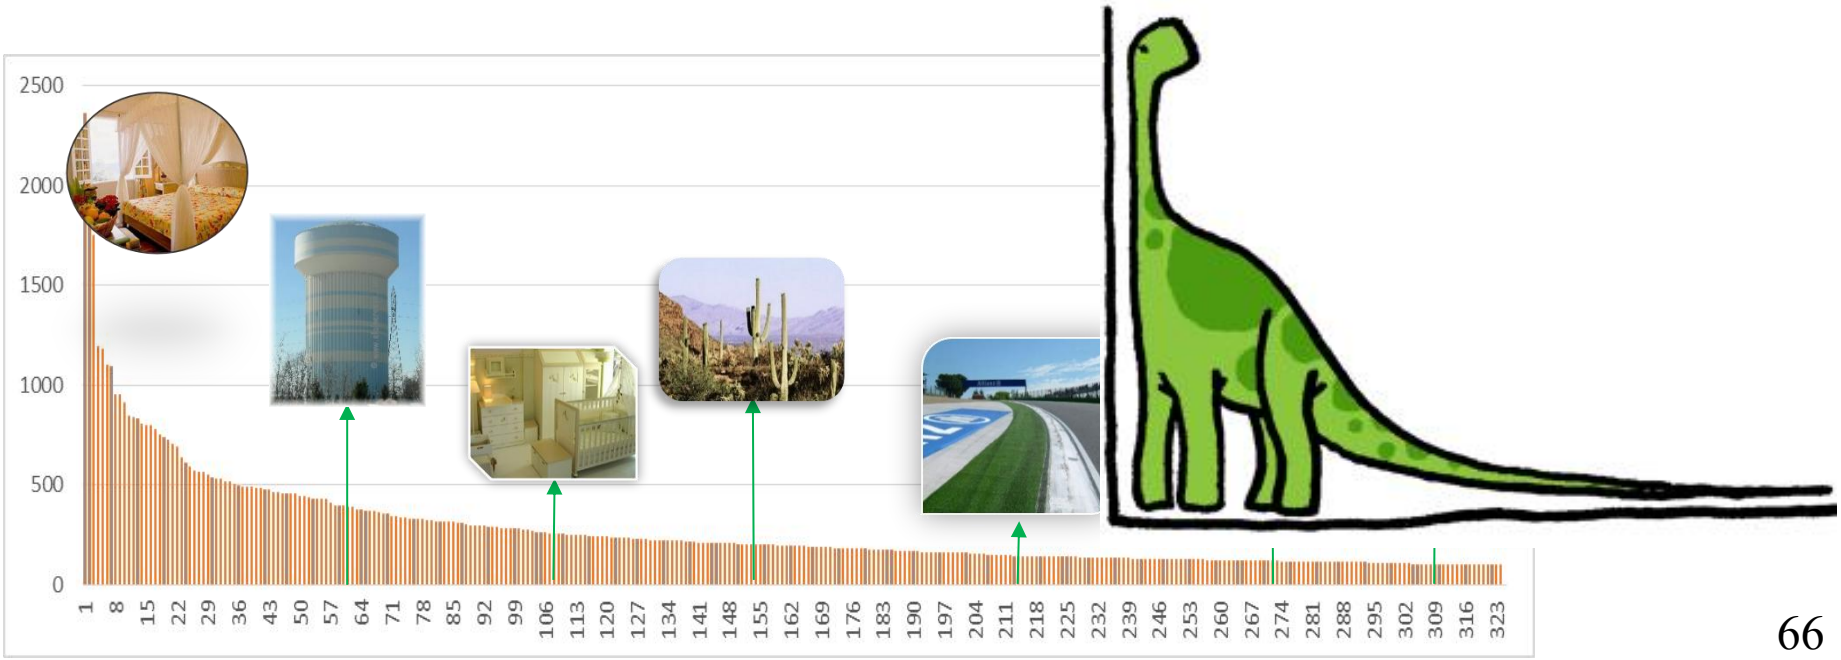
- 准确度：指模型正确地预测新的或先前未见过的数据的类标号的能力。
- 速度：指产生和使用模型的计算花费。
  - 建模的速度
  - 分类的速度
- 鲁棒性：指给定噪声数据或具有缺失值的数据，模型正确分类的能力。
- 可解释性：指模型的解释能力。

5 分类

- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.5 评估
- 5.6 长尾分布建模 

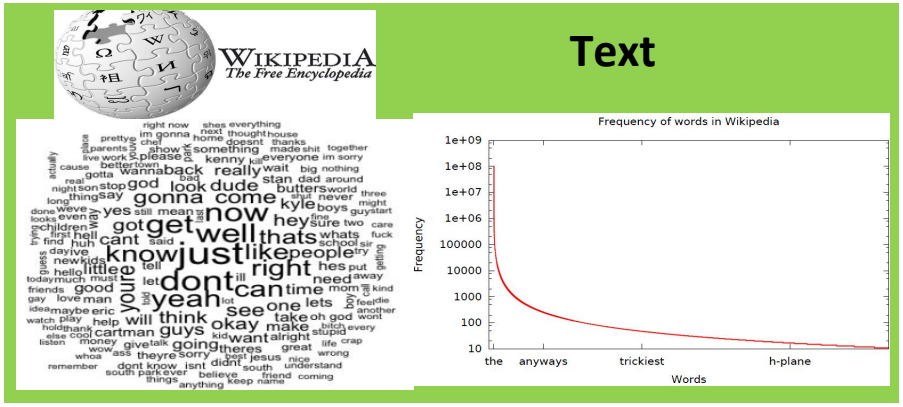
5.6.1 长尾分布定义

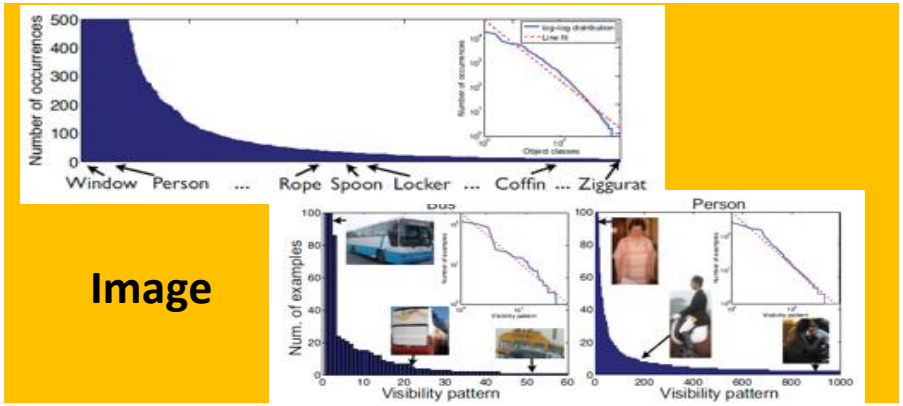
- 现实应用中，一部分类别常常出现，样本众多；更多的类别较为罕见，每个类别样本较少。
- **80/20法则：** 20%的人的掌握着80%的社会财富。
- 80%的样本分布在20%的头部类别上，大量尾部类别样本稀少，呈现一种极端不平衡分布。



5.6.1 长尾分布定义

- 常见场景和数据中均存在长尾分布。







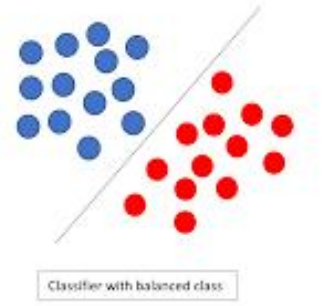


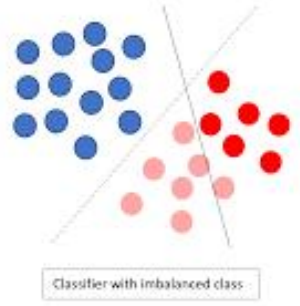
[1] S. Bengio. **The battle against the long tail.** Talk on Workshop on Big Data and Statistical Machine Learning. 1, 2, 2015.
[2] Zhu X, Anguelov D, Ramanan D. **Capturing long-tail distributions of object subcategories.** CVPR, 2014: 915-922.
[3] http://www.phirda.com/newsinfo.aspx?id=14339

5.6.2 长尾分布挑战

- **极度不均衡问题**，传统机器学习模型偏向于头部类别进行建模，尾部类别由于难以学习鲁棒有效的表示造成识别困难的问题
- **尾部类别数量极多**，严重影响任务整体的分类与识别性能
- 某些关键场景（自动驾驶、疾病诊断、科学发现）中**尾部类别重要性更高**







5.6.3 长尾分布建模

- 长尾分布问题本质上是“大多数”和“少数”兼容性上的矛盾
- 当前解决长尾分布问题主要从以下三个思路进行

重采样方法
Re-sampling

- 头部类别欠采样或尾部类别过采样
- 人为形成更均衡的数据分布

重加权方法
Re-weighting

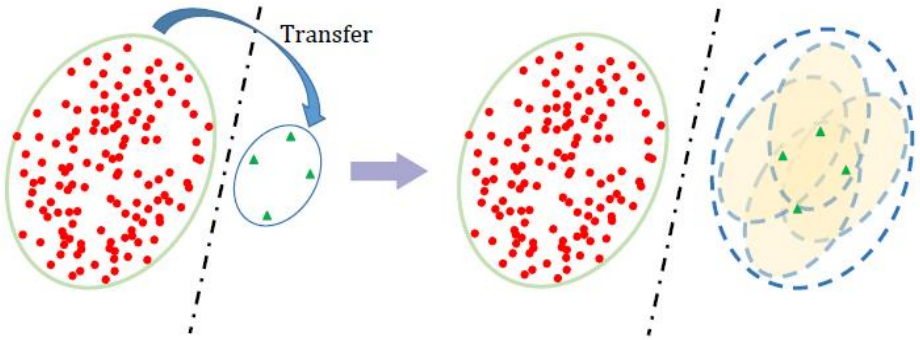
- 减小头部类学习权重，增大尾部类学习权重
- 模型在学习过程中的损失更新更加均衡

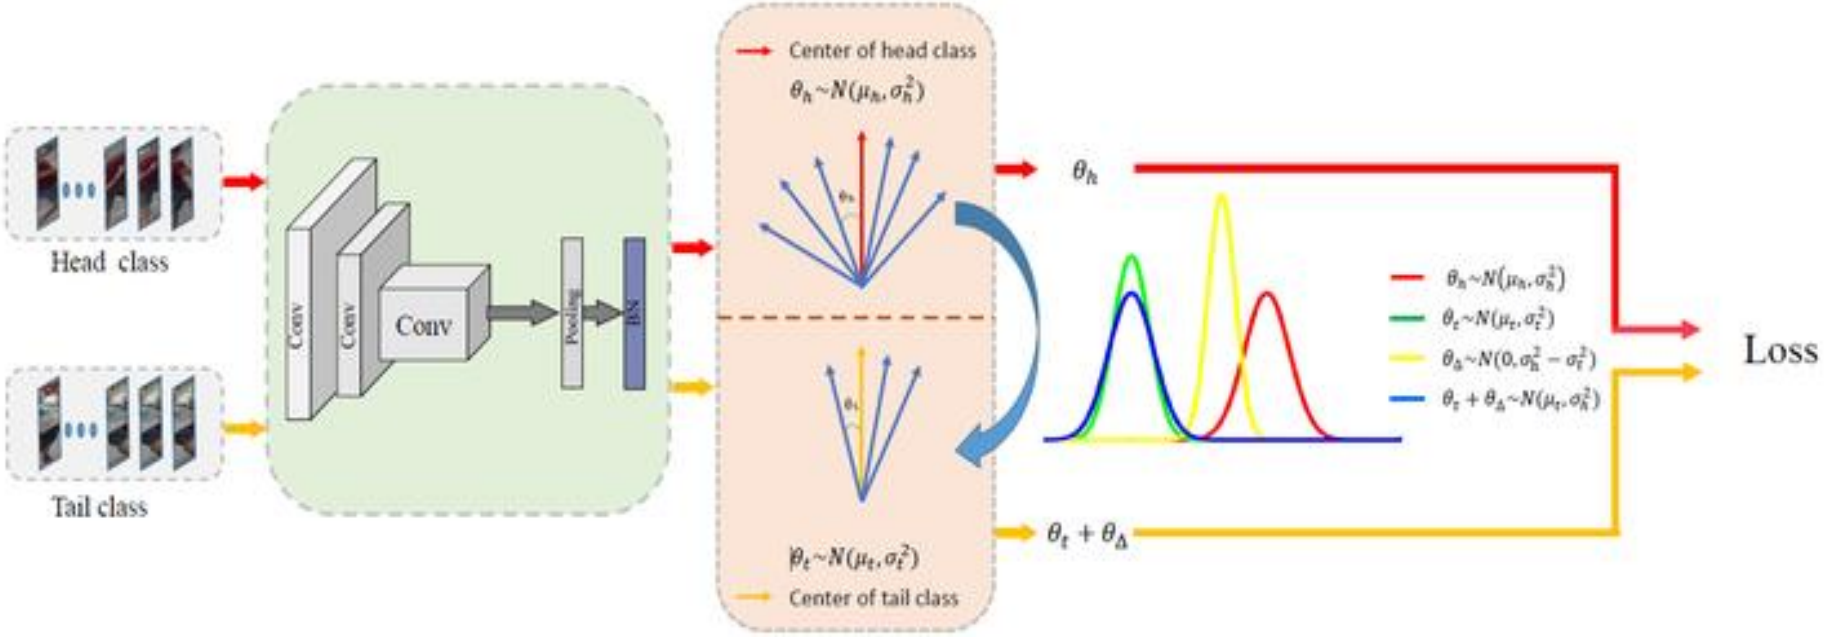
头尾知识迁移
Head-to-tail Transfer

- 迁移头部类别中的知识协助尾部类别的学习
- 尾部类别基于头部提供的先验知识补充学习

5.6.3 长尾分布建模

- **重采样方法：**利用头部数据分布信息生成尾部样本，从而缩小数据量上的头尾差距

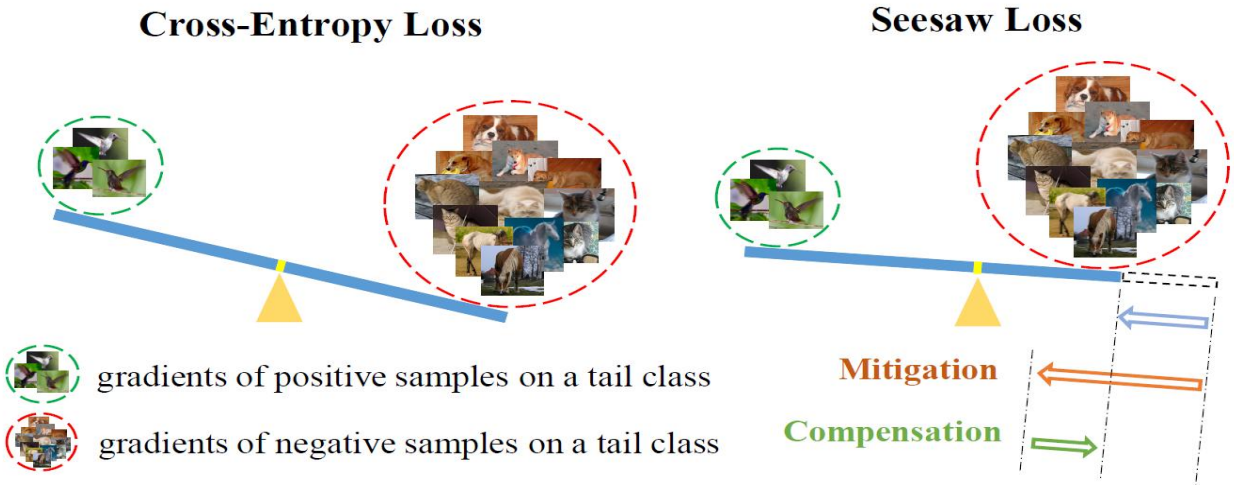


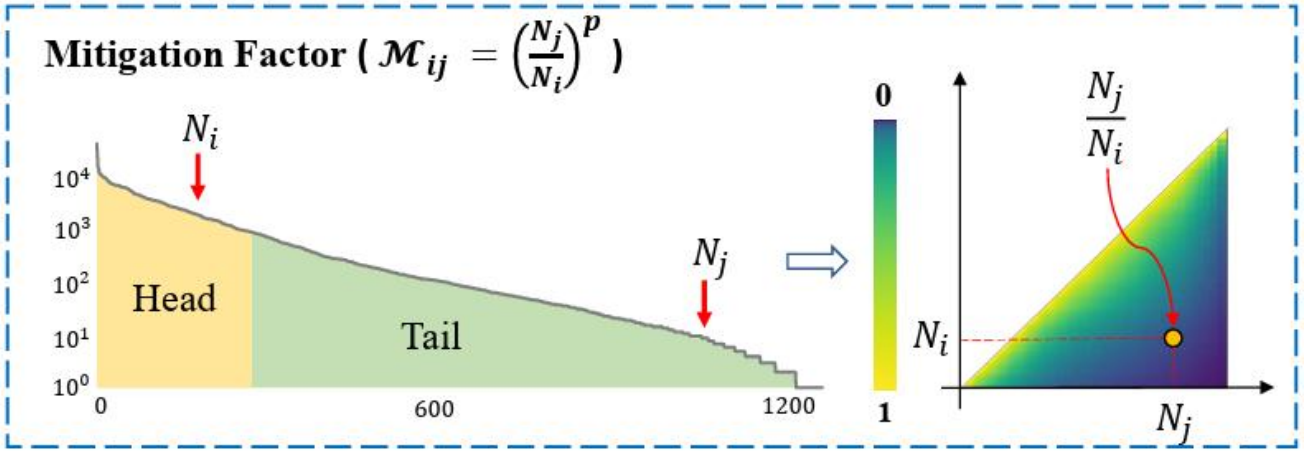


[1] Liu, et al. **Deep Representation Learning on Long-tailed Data: A Learnable Embedding Augmentation Perspective**. CVPR, 2020.

5.6.3 长尾分布建模

- **重加权方法：**学习中减小头部样本权重，增大尾部样本权重

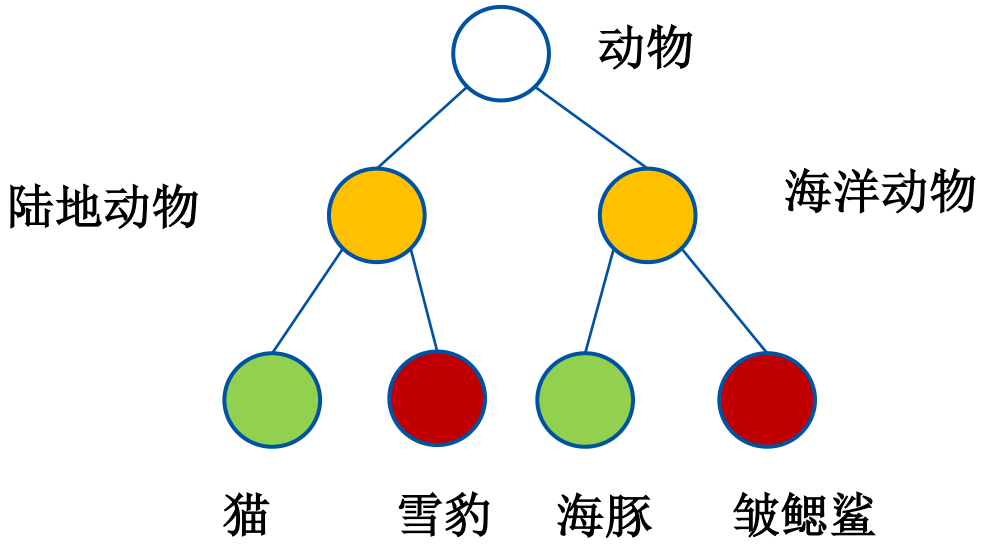




[1] Wang, et al. **DSeesaw Loss for Long-Tailed Instance Segmentation**. CVPR, 2021.

5.6.3 长尾分布建模

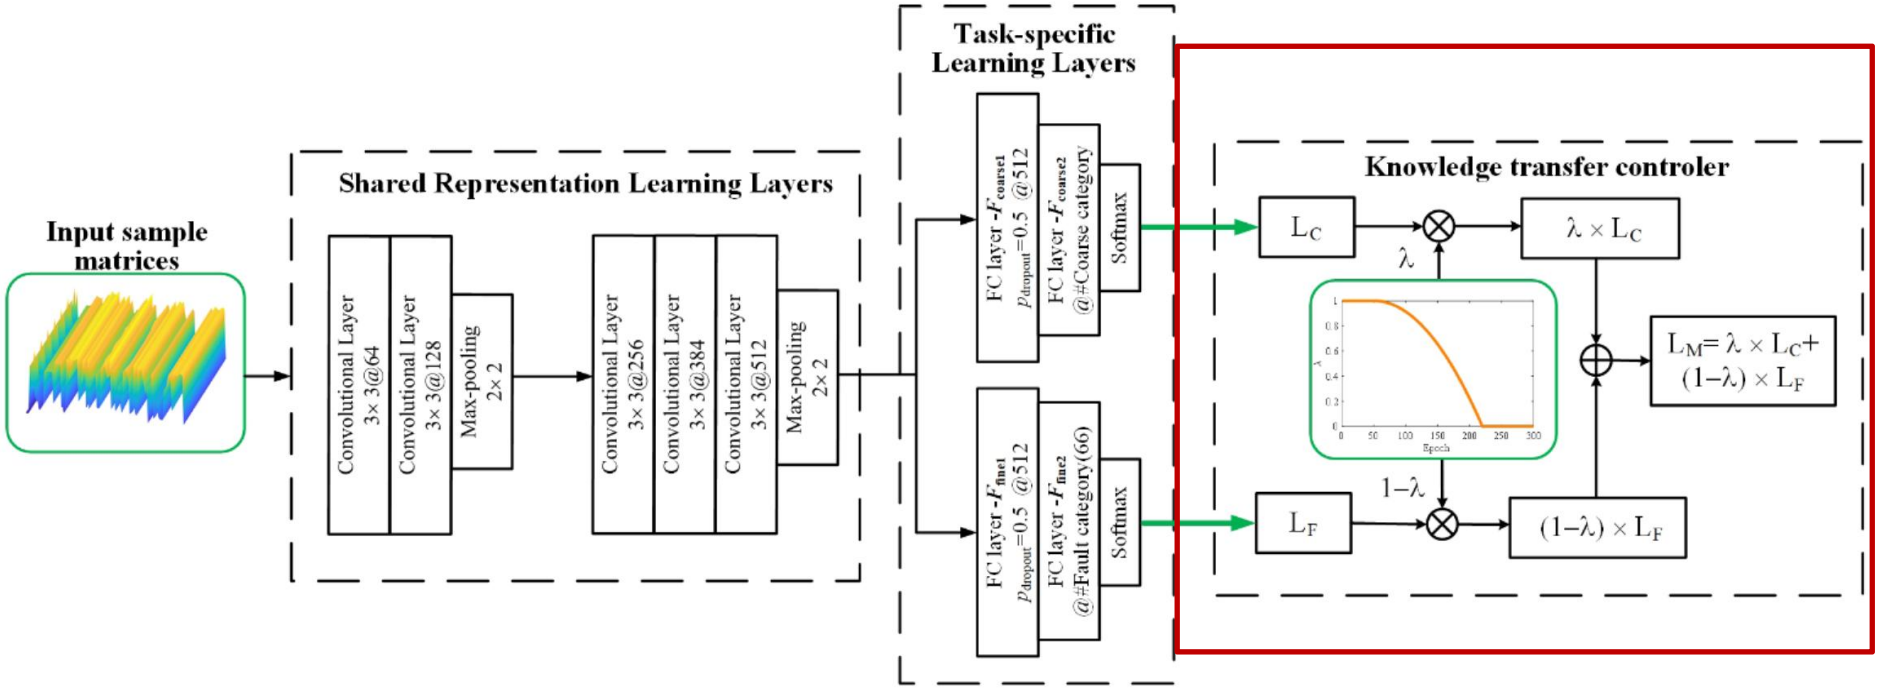
- **头尾知识迁移方法：**利用头部所学习的信息和知识帮助尾部进行建模，从而解决尾部类因数据少造成的建模难问题
- **如何形成知识?**
- **形成知识后如何迁移?**



[1] Yu Wang, et al. **Coarse-to-Fine: Progressive Knowledge Transfer Based Multi-Task Convolutional Neural Network for Intelligent Large-Scale Fault Diagnosis**. IEEE TNNLS, 2023.

5.6.3 长尾分布建模

- **聚类形成分层知识结构：**基于类均值的谱聚类
- **多粒度知识迁移：**上下层异步学习，上层知识逐步迁移到下层，帮助下层更好学习



[1] Yu Wang, et al. **Coarse-to-Fine: Progressive Knowledge Transfer Based Multi-Task Convolutional Neural Network for Intelligent Large-Scale Fault Diagnosis**. IEEE TNNLS, 2023.

天津大学
Tianjin University

THE END

