天津大学
Tianjin University

数据挖掘

王煜

人工智能学院

wang.yu@tju.edu.cn



回顾

- 分类、回归与聚类
- 分类的方法
  - k-近邻
  - 支持向量机
  - 神经网络
  - 决策树

回顾

1.分类：

有监督的，需要有训练集和测试集。

在已知训练集的前提下，对测试样本根据它的特征，把它与训练集中的样本进行对比，把它分到对应的那类中。

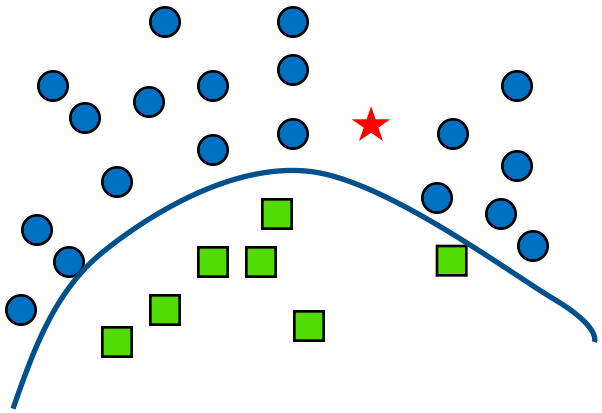
2.聚类：

无监督的

有一堆数据，将这堆数据按照它们自身内部的相似性，自动地聚成几类。

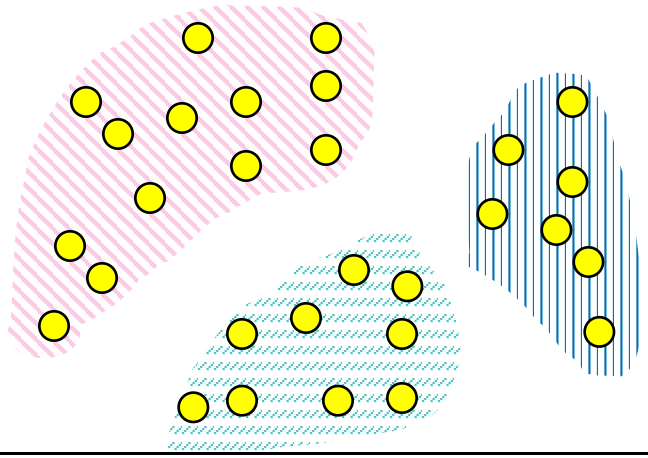
物以类聚、人以群分

分类 vs. 聚类



分类：有监督学习

Learns a method for predicting the instance class from pre-labeled (classified) instances



聚类：无监督学习

Finds “natural” grouping of instances given un-labeled data

没有事先定义的类

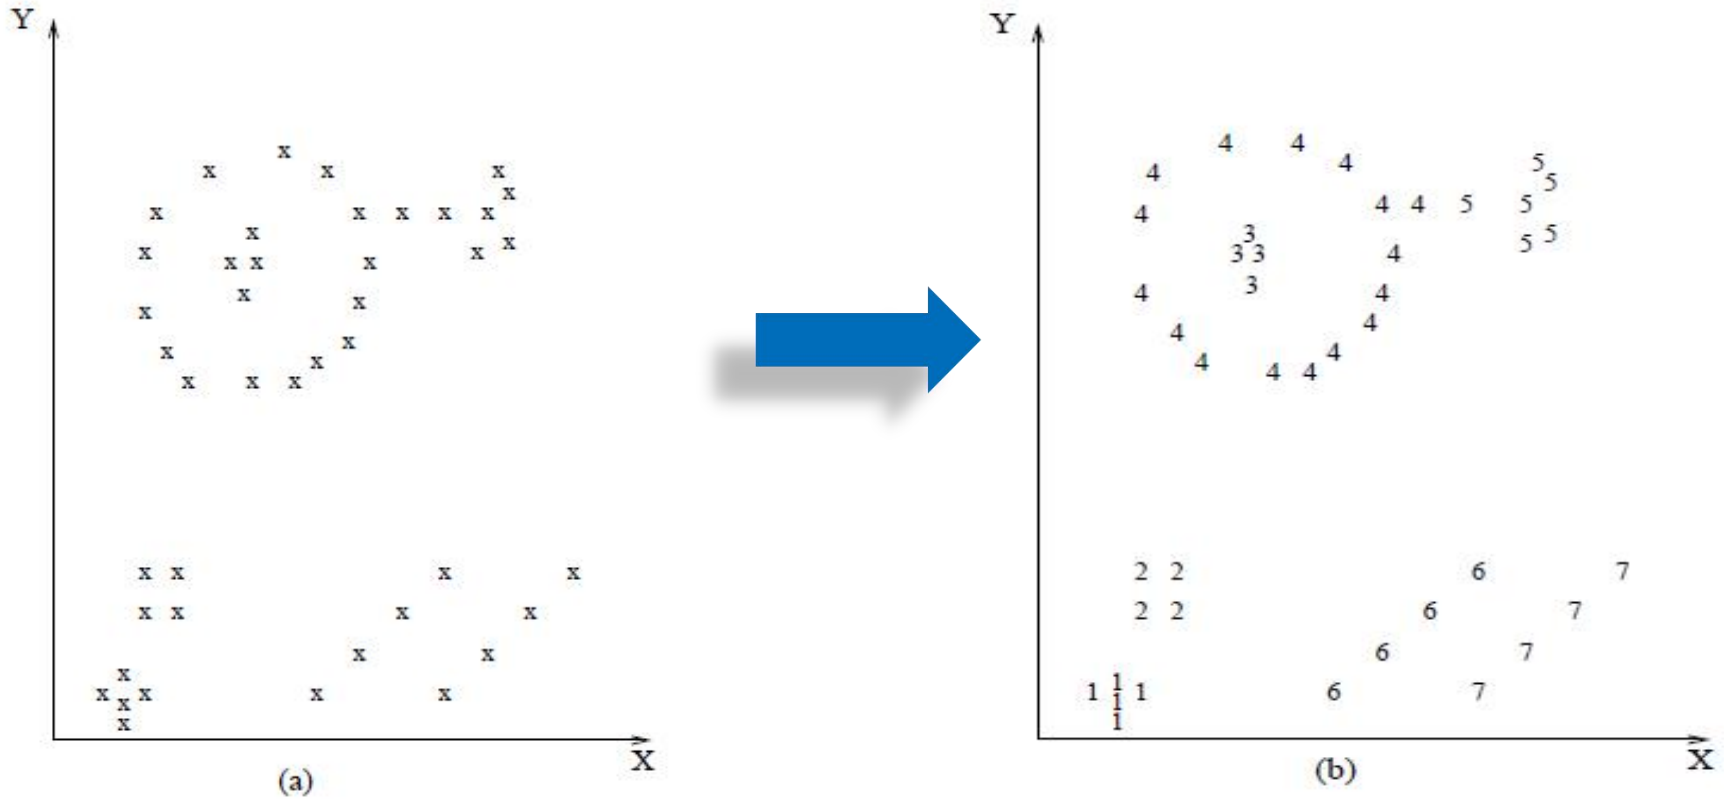
第 7 章　聚类

7 聚类

- 7.1 聚类分析
- 7.2 典型聚类应用
- 7.3 k-means聚类方法
- 7.4 典型聚类方法
- 7.5 评估

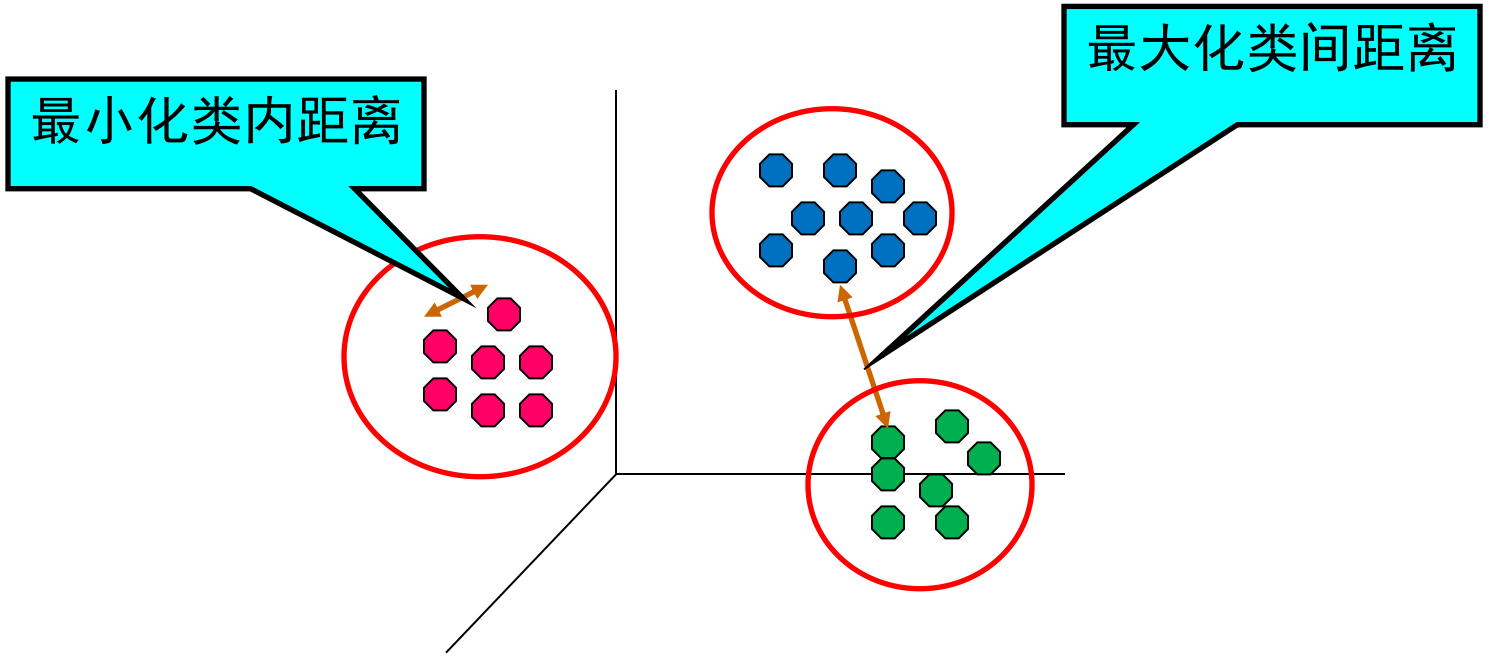
7.1 聚类分析

- 聚类分析Cluster analysis，简称聚类Clustering，是一个把数据对象划分为子集的过程。



7.1 聚类分析

- 簇Cluster：每一个子集是一个簇
  - 在同一个聚类（簇）中的对象彼此相似
  - 不同簇中的对象则相异



7.1 聚类分析

- 聚类是一种无指导的学习：没有预定义的类编号
- 一个好的聚类分析方法会产生高质量的聚类
  - 高类内相似度
  - 低类间相似度
- 聚类方法中主要的因素是距离或相似度
- 聚类分析的数据挖掘功能
  - 作为一个独立的工具来获得数据分布的情况
  - 作为其他算法（如：特征和分类）的预处理步骤

7.1 聚类分析

聚类分析示例数据集

样本序号	描述属性1	描述属性2
x_1	1	3
x_2	1	7.5
x_3	1.5	4
x_4	4.5	7.5
x_5	4	8.5
x_6	5.5	9
x_7	4.5	8

聚类分析的数据集
没有类别属性
没有训练集

7 聚类

- 7.1 聚类分析
- 7.2 典型聚类应用
- 7.3 k-means聚类方法
- 7.4 典型聚类方法
- 7.5 评估

7.2典型聚类应用

图像像素聚类

Original image



$K = 10$



$K = 3$



$K = 2$







7.2典型聚类应用

- 图像数据分析
  - 对相似区域进行聚类，产生主题地图
  - 图像数据集聚类
- 商务数据分析
  - 帮市场分析人员发现不同的顾客群
  - 企业信用等级聚类
- 万维网数据分析
  - 对WEB上的文档进行聚类
  - 对WEB日志的数据进行聚类，以发现相同的用户访问模式

7.2典型聚类应用

经济领域

- 帮助市场分析人员从客户数据库中发现不同的客户群，并且用购买模式来刻画不同的客户群的特征
- 对住宅区进行聚类，确定自动提款机ATM的安放位置
- 股票市场板块分析，找出最具活力的板块龙头股

生物学领域

- 推导植物和动物的分类
- 对基因聚类，获得对种群的认识

数据挖掘领域

- 作为其他数学算法的预处理步骤，获得数据分布状况，集中对特定的类做进一步的研究
- 离群点检测、数据归约

7.2典型聚类应用

- 客户数据集包含10,000条客户数据
- 特征(属性) 分别为:
  - Bank No(银行代码，其值有：004,024,077等)
  - Account num(账户代码)
  - Short Name(客户名字)
  - First Contact Date(第一次接触日期)
  - account open date(账户开户日期)
  - account balance(账户当前余额)
  - account low balance(账户曾经最低余额)
  - account high balance(账户曾经最高余额)
  - balance category(余额类型)
  - Statement Low Balance(最低交易账目，有正有负)
  - ……

7.2典型聚类应用

- 目标
  - 目的是对客户进行分群，从而使银行可以对不同群体的客户提供不同的服务。因此聚类分析是对客户进行自动分群的有效方法。
- 方法
  - k-means算法
- 选取的特征
  - 从31个原始属性值中选取23个属性用作聚类（都是数值型或标称型的）
- 聚类参数
  - 在经过规格化处理后的数据集中，用k-means算法在选定的23个属性上进行聚类，设定聚类数为10。

7.2典型聚类应用

- 各聚类所包含的客户数量如下表

聚类	客户数量
聚类1	145
聚类2	69
聚类3	133
聚类4	6183
聚类5	1985
聚类6	213
聚类7	46
聚类8	446
聚类9	413
聚类10	368

7.2典型聚类应用

对聚类大小的分析

聚类	客户数量
聚类1	145
聚类2	69
聚类3	133
聚类4	6183
聚类5	1985
聚类6	213
聚类7	46
聚类8	446
聚类9	413
聚类10	368

- 各聚类有大有小，且大小悬殊，但也合乎客户关系处理的目的。客户关系管理的往往是找出一小部分的特殊客户（占20%左右）来进行特别地对待。
- 在表中所示的10个聚类中，除去最大的聚类4后其余9个聚类的客户数达3818人，占总客户量的38.18%；除去最大的两个聚类（聚类4和聚类5）后其余8个聚类的客户数达1833人，占总客户量的18.33%。

7.2典型聚类应用

对聚类大小的分析

聚类	客户数量
聚类1	145
聚类2	69
聚类3	133
聚类4	6183
聚类5	1985
聚类6	213
聚类7	46
聚类8	446
聚类9	413
聚类10	368

大聚类可以再继续细分（作为一个数据集再继续进行聚类操作，或直接提高聚类个数）

对各聚类结果的处理

- 聚类后的各聚类结果的数据是规格化处理后的数据的结果，我们要直观地分析各聚类的特点，必须把规格化的数据还原为原始数据。例如，最小值为-10,000，最大值为1,000,000的当前账户余额规格化为[0,1]后就难以理解各账户间存在的巨大差距，只有把它还原为原始的[-10,000, 1,000,0000]才能使人直观地理解其存在的差距。
- 把各聚类的数据集还原为原始数据后，再计算各特征的均值和标准差（数值型的特征）；或者各标称量的数量（标称型的特征）。

聚类结果分析(账户当前余额)

- 下表所示为10个聚类中各聚类的账户当前余额的正负及账户当前余额的均值和标准差

聚类	当前余额正负		当前余额值	
	+	–	均值	标准差
聚类1	145	0	24445.50	73408.73
聚类2	69	0	29164.41	78077.97
聚类3	133	0	152882.48	604633.58
聚类4	6182	1	5571.17	23957.76
聚类5	1985	0	22102.61	64825.42
聚类6	119	94	8432.82	18680.66
聚类7	46	0	2093.91	5798.48
聚类8	380	66	7729.67	33233.11
聚类9	0	413	-24728.68	61844.23
聚类10	368	0	36264.24	93389.14

7.2典型聚类应用

聚类	当前余额正负		当前余额值	
	+	–	均值	标准差
聚类1	145	0	24445.50	73408.73
聚类2	69	0	29164.41	78077.97
聚类3	133	0	152882.48	604633.58
聚类4	6182	1	5571.17	23957.76
聚类5	1985	0	22102.61	64825.42
聚类6	119	94	8432.82	18680.66
聚类7	46	0	2093.91	5798.48
聚类8	380	66	7729.67	33233.11
聚类9	0	413	-24728.68	61844.23
聚类10	368	0	36264.24	93389.14

聚类3的客户群，该聚类的当前余额均值达十五万左右，比其他聚类的当前余额均值高出一个数量级。

初步判断该聚类的客户是存款额高或者说是高收入的客户群。

该聚类当前余额的标准差也很大，这说明在富有的客户群中各客户的收入差距也很大，有的达百万、千万、甚至上亿。

7.2典型聚类应用

聚类	当前余额正负		当前余额值	
	+	–	均值	标准差
聚类1	145	0	24445.50	73408.73
聚类2	69	0	29164.41	78077.97
聚类3	133	0	152882.48	604633.58
聚类4	6182	1	5571.17	23957.76
聚类5	1985	0	22102.61	64825.42
聚类6	119	94	8432.82	18680.66
聚类7	46	0	2093.91	5798.48
聚类8	380	66	7729.67	33233.11
聚类9	0	413	-24728.68	61844.23
聚类10	368	0	36264.24	93389.14

聚类9客户群：该客户群中的413个客户当前账户余额都为负值，且其均值达负两万多元。

可以认定该客户群是高透支的客户群。后面还会分析的透支额、透支次数、透支时间等属性的分析同样可以印证我们这个结论。

7.2典型聚类应用

聚类	当前余额正负		当前余额值	
	+	–	均值	标准差
聚类1	145	0	24445.50	73408.73
聚类2	69	0	29164.41	78077.97
聚类3	133	0	152882.48	604633.58
聚类4	6182	1	5571.17	23957.76
聚类5	1985	0	22102.61	64825.42
聚类6	119	94	8432.82	18680.66
聚类7	46	0	2093.91	5798.48
聚类8	380	66	7729.67	33233.11
聚类9	0	413	-24728.68	61844.23
聚类10	368	0	36264.24	93389.14

聚类4是占61.81%的最大的普通客户群，该客户群中几乎所有的客户的当前余额都为正值，其均值为五千多，标准差为两万多不会太小，说明该庞大的客户群还是可以再继续细分的。

7.2典型聚类应用

聚类	当前余额正负		当前余额值	
	+	–	均值	标准差
聚类1	145	0	24445.50	73408.73
聚类2	69	0	29164.41	78077.97
聚类3	133	0	152882.48	604633.58
聚类4	6182	1	5571.17	23957.76
聚类5	1985	0	22102.61	64825.42
聚类6	119	94	8432.82	18680.66
聚类7	46	0	2093.91	5798.48
聚类8	380	66	7729.67	33233.11
聚类9	0	413	-24728.68	61844.23
聚类10	368	0	36264.24	93389.14

聚类5是占19.85%的第二大客户群，该客户群比最大的客户群聚类4来说它的当前余额均值高很多，可达两万多元。

聚类5是大量普通客户中的中等存款额度的账户（不包括低存款额度账户）。

7.2典型聚类应用

聚类	当前余额正负		当前余额值	
	+	–	均值	标准差
聚类1	145	0	24445.50	73408.73
聚类2	69	0	29164.41	78077.97
聚类3	133	0	152882.48	604633.58
聚类4	6182	1	5571.17	23957.76
聚类5	1985	0	22102.61	64825.42
聚类6	119	94	8432.82	18680.66
聚类7	46	0	2093.91	5798.48
聚类8	380	66	7729.67	33233.11
聚类9	0	413	-24728.68	61844.23
聚类10	368	0	36264.24	93389.14

聚类7是账户当前余额为正值但存款额度较低客户群。

聚类1，2，6，8和10这五个聚类在当前账户余额这一属性上不能发现其明显的特征，我们将在后续的其他属性上的分析发现其聚类特征。

7 聚类

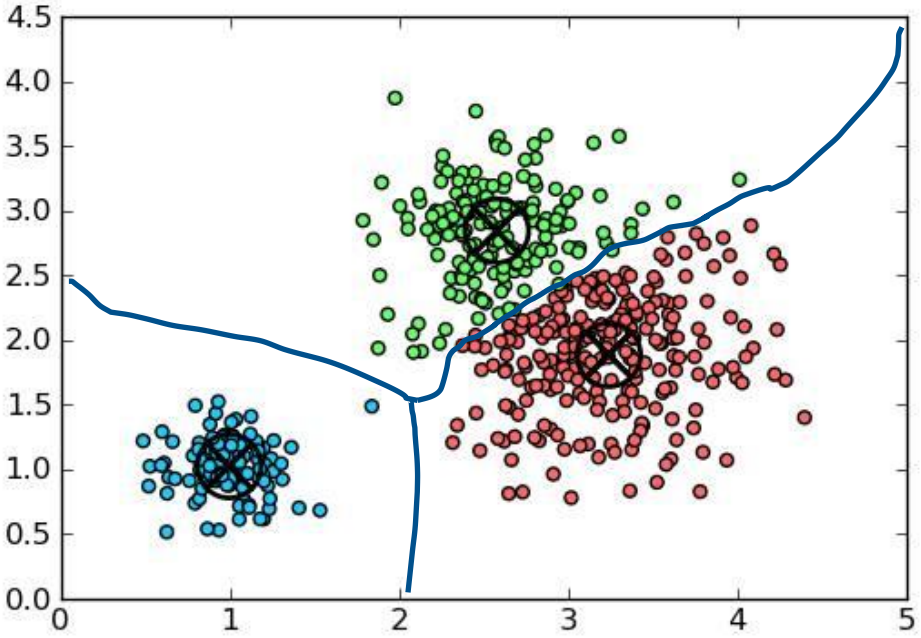
- 7.1 聚类分析
- 7.2 典型聚类应用
- 7.3 k-means聚类方法
- 7.4 典型聚类方法
- 7.5 评估

7.3 k-means聚类方法

- 划分聚类方法
  - 选择合适的初始代表点将数据样本进行初始聚类，之后通过不断迭代的过程对聚类的结果进行不断的调整，直到满足聚类评价的准则为止。
  - 通常通过计算对象间距离进行划分

7.3 k-means聚类方法

- 划分聚类方法
  - 选择合适的初始代表点将数据样本进行初始聚类，之后通过不断迭代的过程对聚类的结果进行不断的调整，直到满足聚类评价的准则为止。
  - 通常通过计算对象间距离进行划分



7.3 k-means聚类方法

- 划分聚类方法
  - 选择合适的初始代表点将数据样本进行初始聚类，之后通过不断迭代的过程对聚类的结果进行不断的调整，直到满足聚类评价的准则为止。
  - 通常通过计算对象间距离进行划分
- 典型的划分方法
  - k-means
  - k-中心点
  - 以上两种方法的变种

7.3 k-means聚类方法

划分聚类方法对数据集聚类时的三个要点

- 选定某种距离作为数据样本间的相似性度量

可以根据实际需要选择欧氏距离、曼哈顿距离或者明考斯基距离中的一种来作为算法的相似性度量，其中最常用的是欧氏距离。

- 选择评价聚类性能的准则函数

误差平方和准则函数表示数据集中的所有样本与相应聚类中心的方差之和，该准则的值达到最优时可以便各个聚类类内尽可能地紧凑，而各个聚类之间则尽可能地分开。

- 选择某个初始分类，之后用迭代方法得到聚类结果，使得评价聚类的准则函数取得最优值

为了得到最优的聚类结果，首先要对给定数据集进行初始划分，通常的做法是事先从数据集中选择各个聚类的代表点，之后把其余的数据样本按照某种方式归类到相应的聚类中去。

数据挖掘领域的十大经典算法ICDM'06

- #1: C4.5 (61 votes) (分类)
- #2: k-means (60 votes) (聚类)
- #3: SVM (58 votes) (分类)
- #4: Apriori (52 votes) (关联规则)
- #5: EM (48 votes)
- #6: PageRank (46 votes)
- #7: AdaBoost (45 votes)
- #7: kNN (45 votes) (分类)
- #7: Naive Bayes (45 votes) (分类)
- #10: CART (34 votes) (分类)

7.3.1 k-means聚类步骤

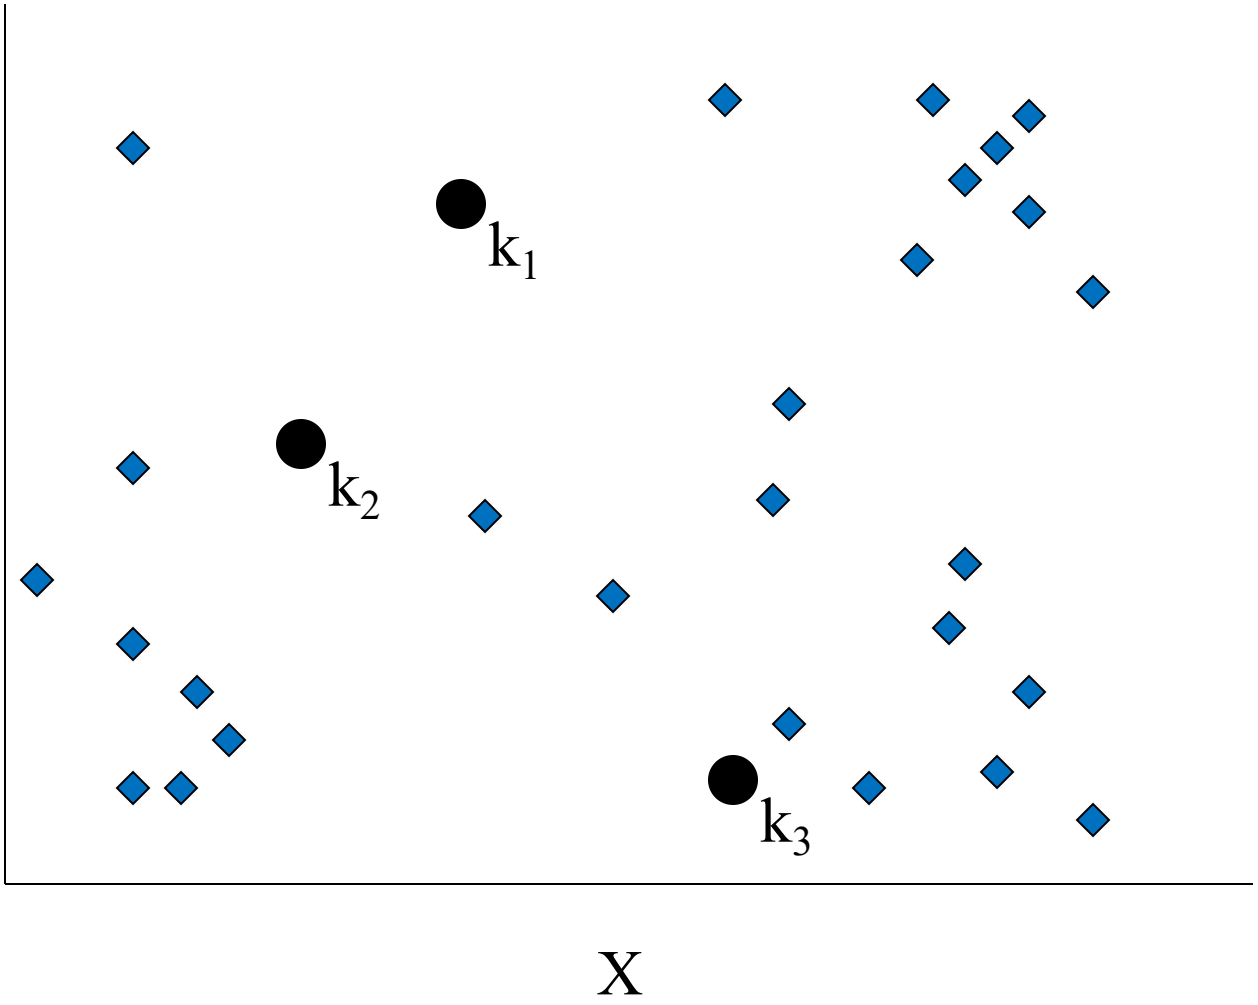
- k-means聚类算法是划分聚类方法中最常用、最流行的经典算法，许多其他的方法都是k-means聚类算法的变种。
- k-means聚类算法将各个聚类子集内的所有数据样本的均值作为该聚类的代表点，算法的主要思想是通过迭代过程把数据集划分为不同的类别，使得评价聚类性能的准则函数达到最优，从而使生成的每个聚类类内紧凑，类间独立。
- k-means聚类算法不适合处理离散型属性，但是对于连续型属性具有较好的聚类效果。

J. MacQueen (1967): Some Methods for Classification and Analysis of Multivariate Observations, *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, vol.1, pp. 281-297. (引用次数32127)

7.3.1 k-means聚类步骤

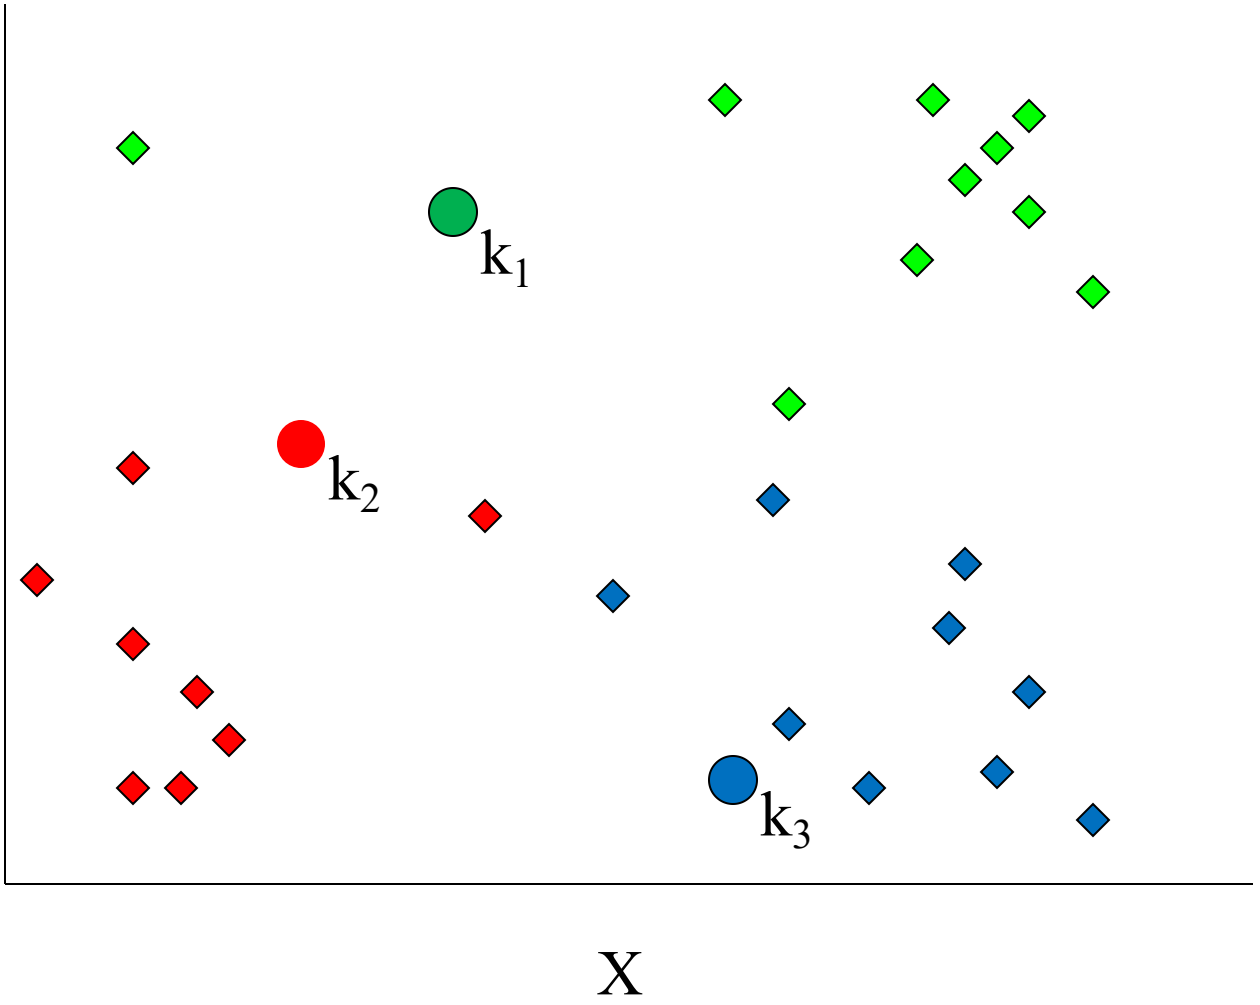
k-means样例, 步骤 1

随机选择3个样本点作为初始的聚类中心



7.3.1 k-means聚类步骤

k-means样例, 步骤 2

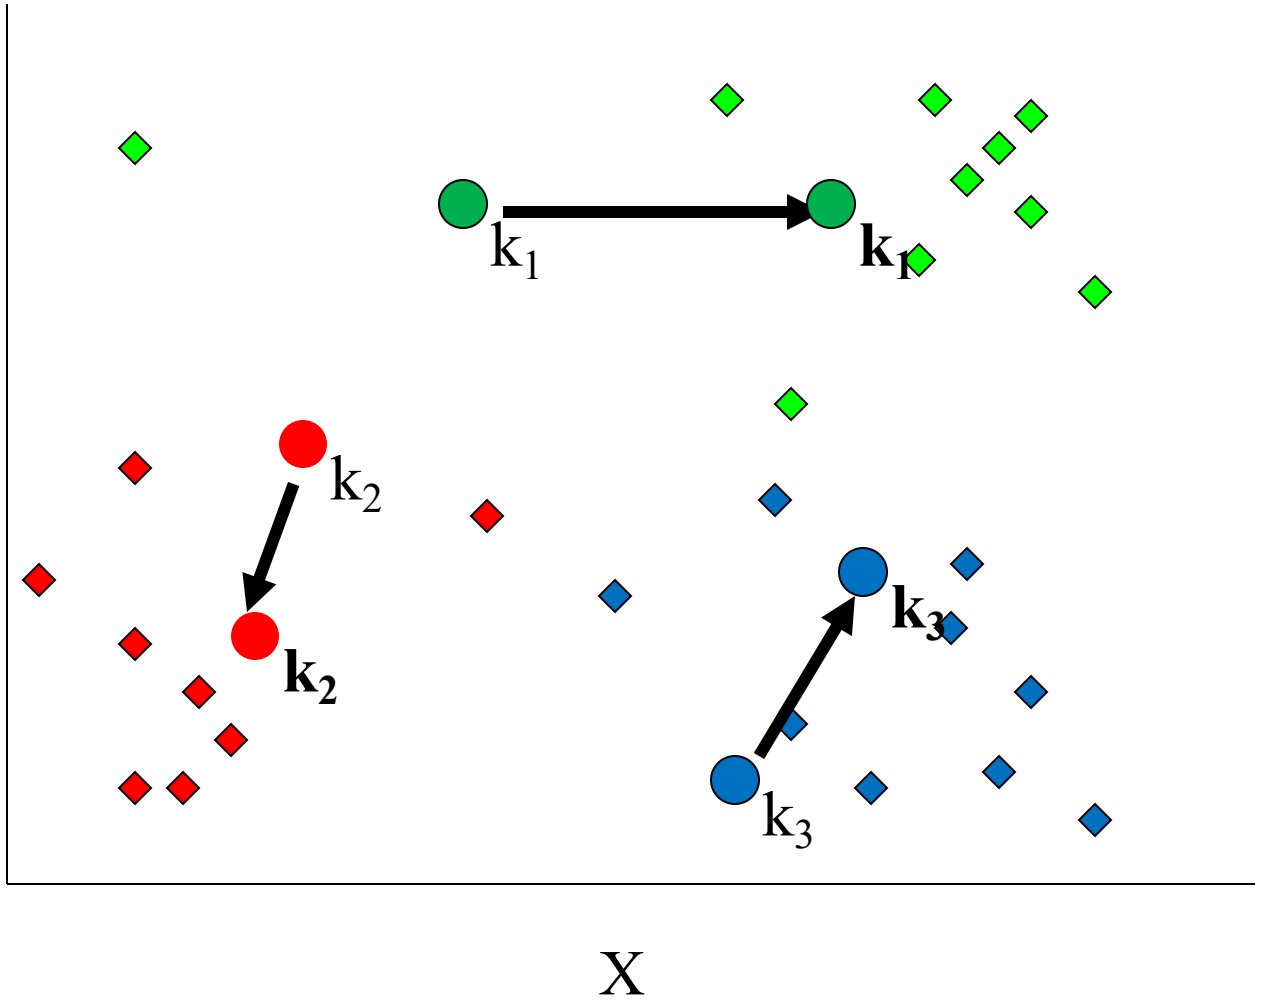


把每个点分到离它最近的类中

7.3.1 k-means聚类步骤

k-means样例, 步骤 3

计算每个类的均值，移动类中心

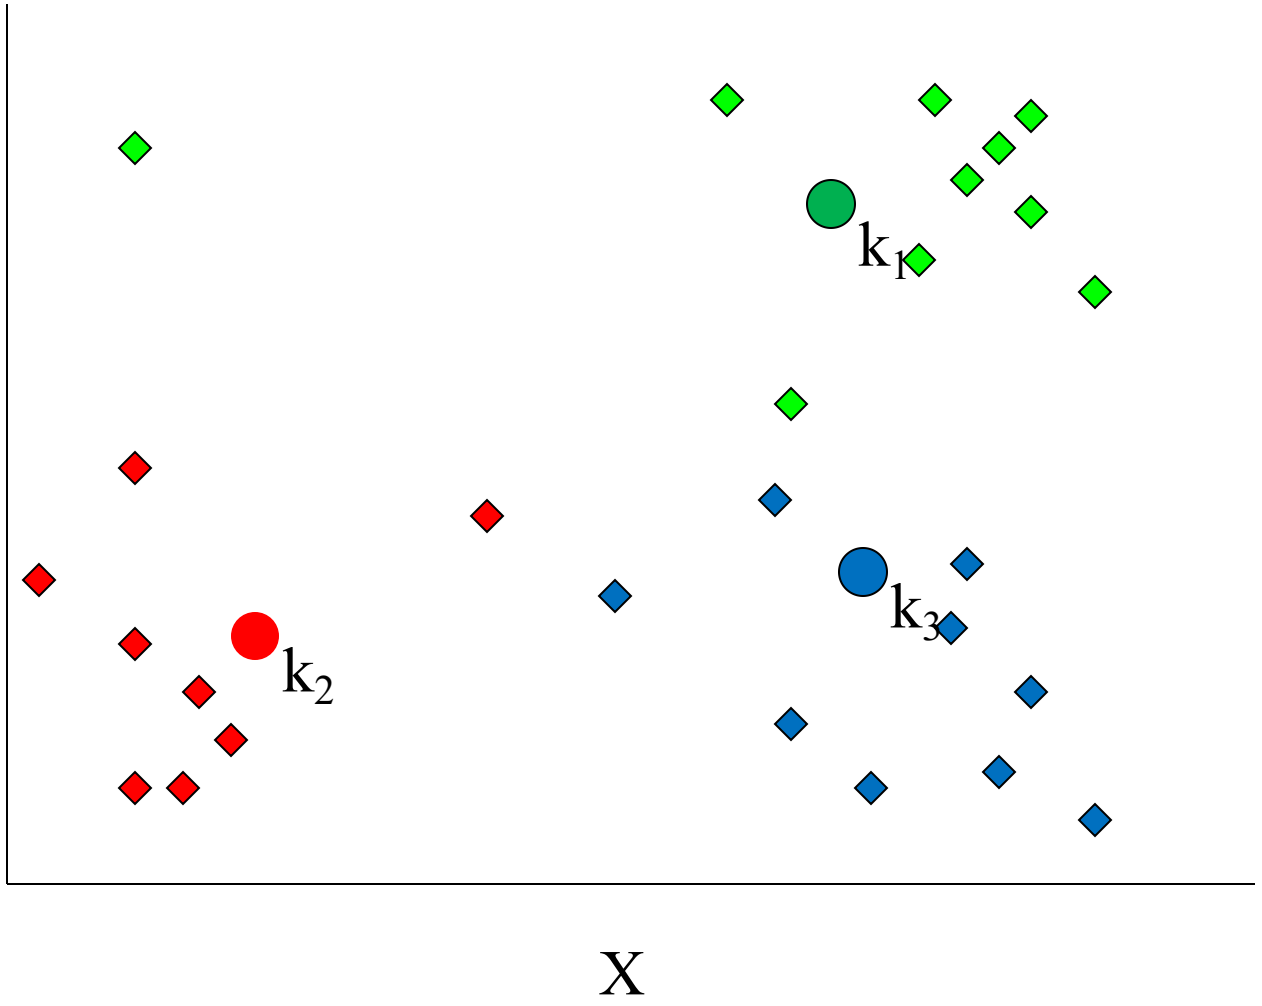


7.3.1 k-means聚类步骤

k-means样例, 步骤 4

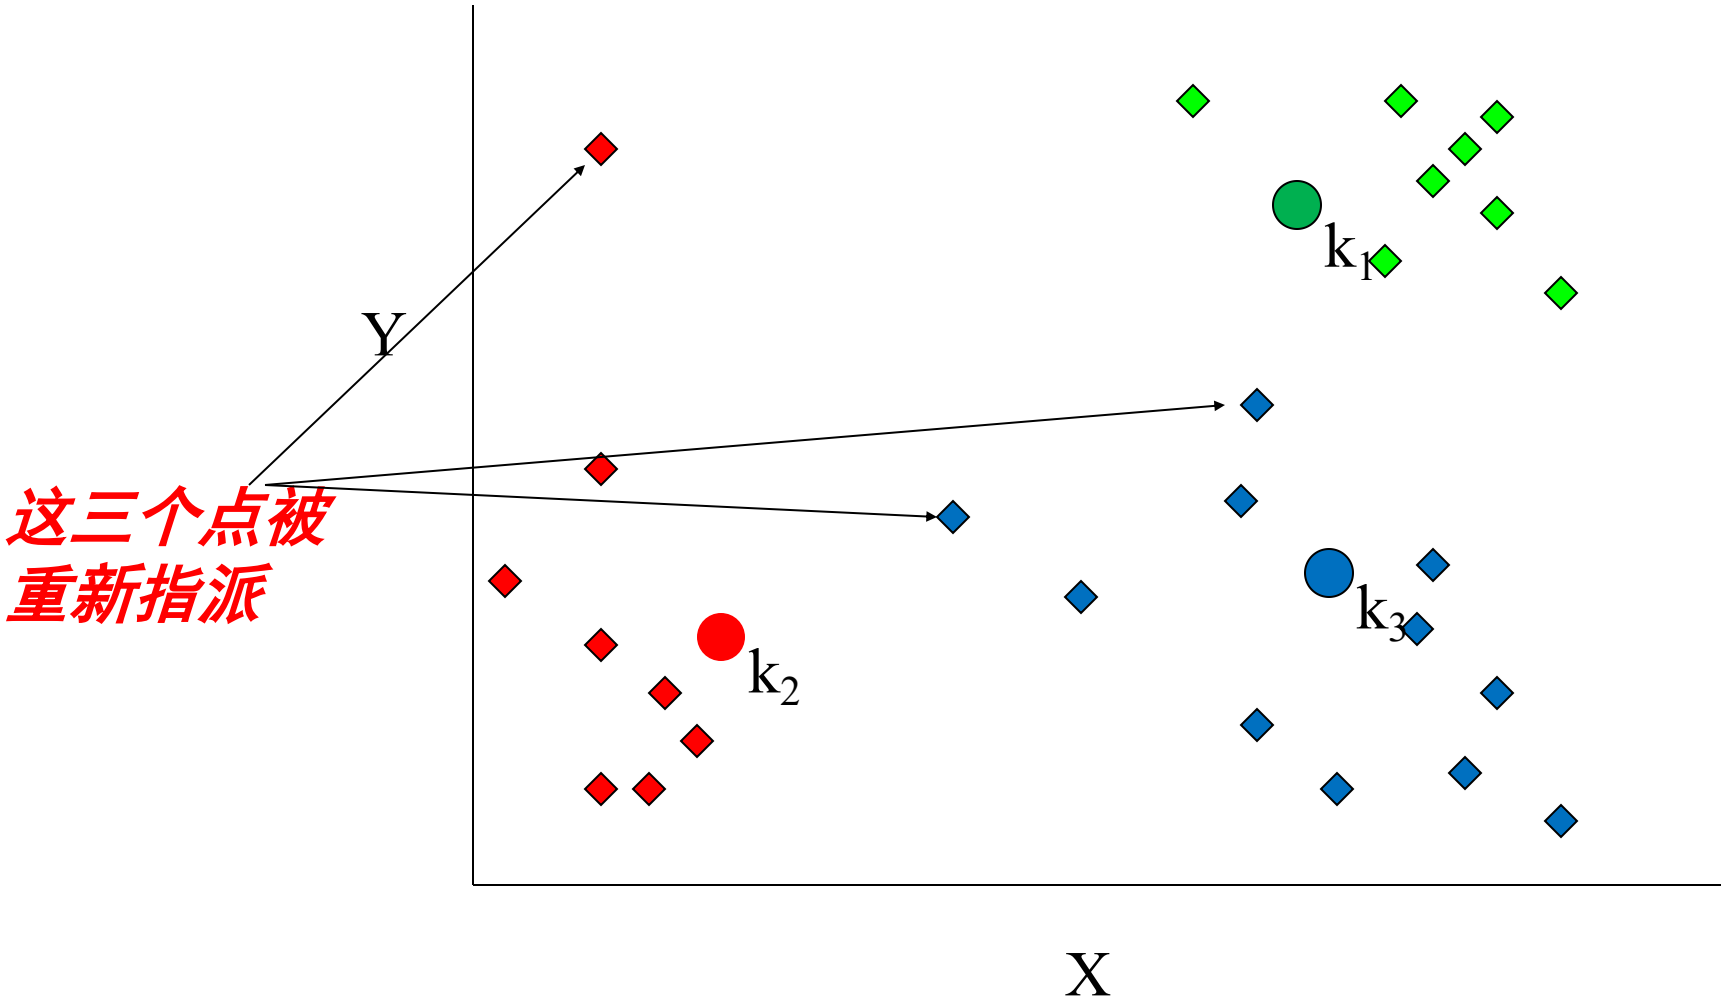
重新给每个样本指派其所属的类别

哪些点被重新分配?



7.3.1 k-means聚类步骤

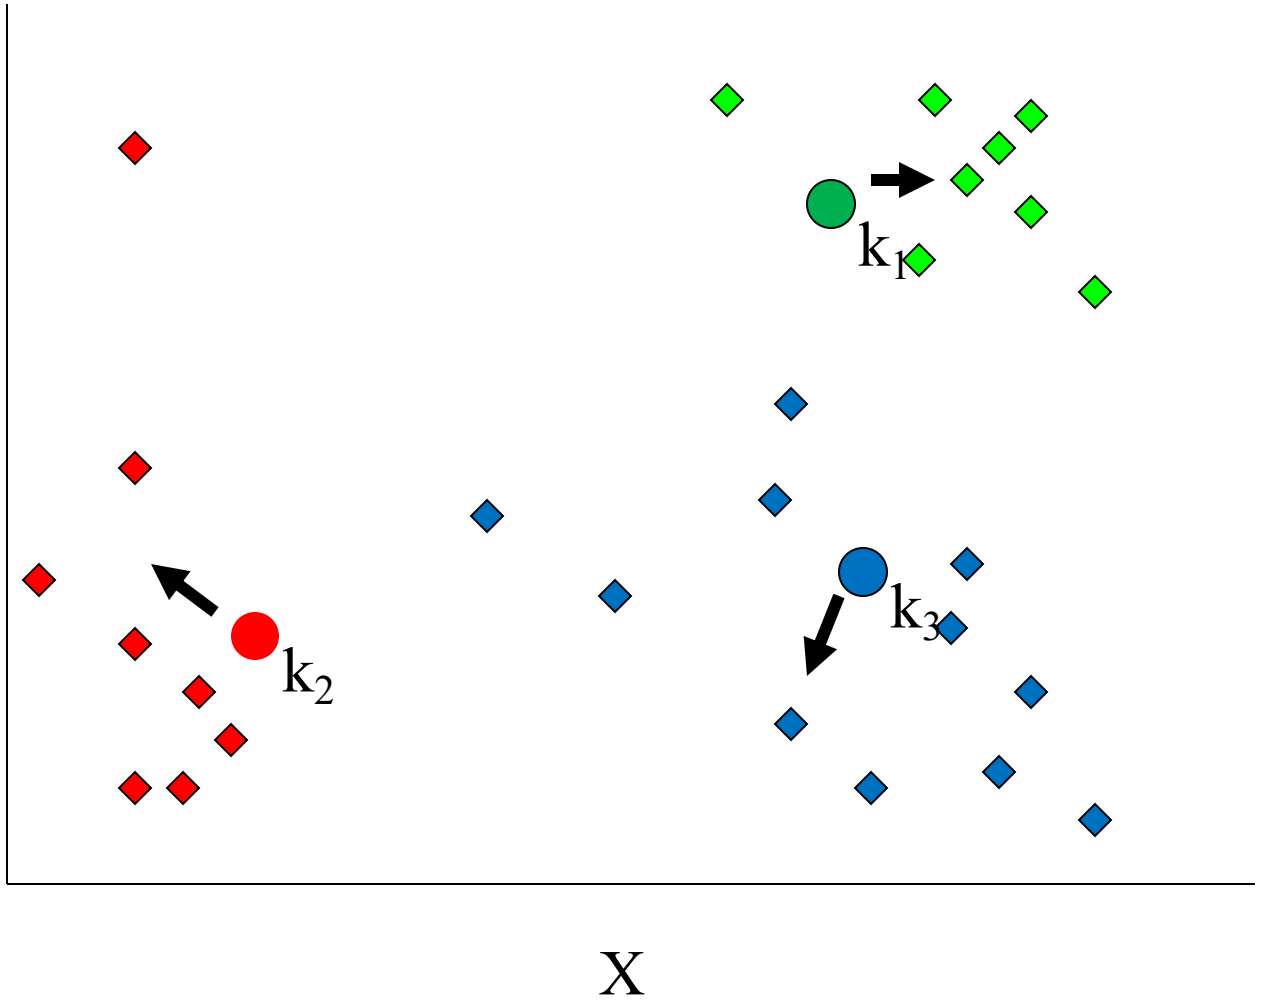
k-means样例, 步骤 4



7.3.1 k-means聚类步骤

k-means样例, 步骤 5

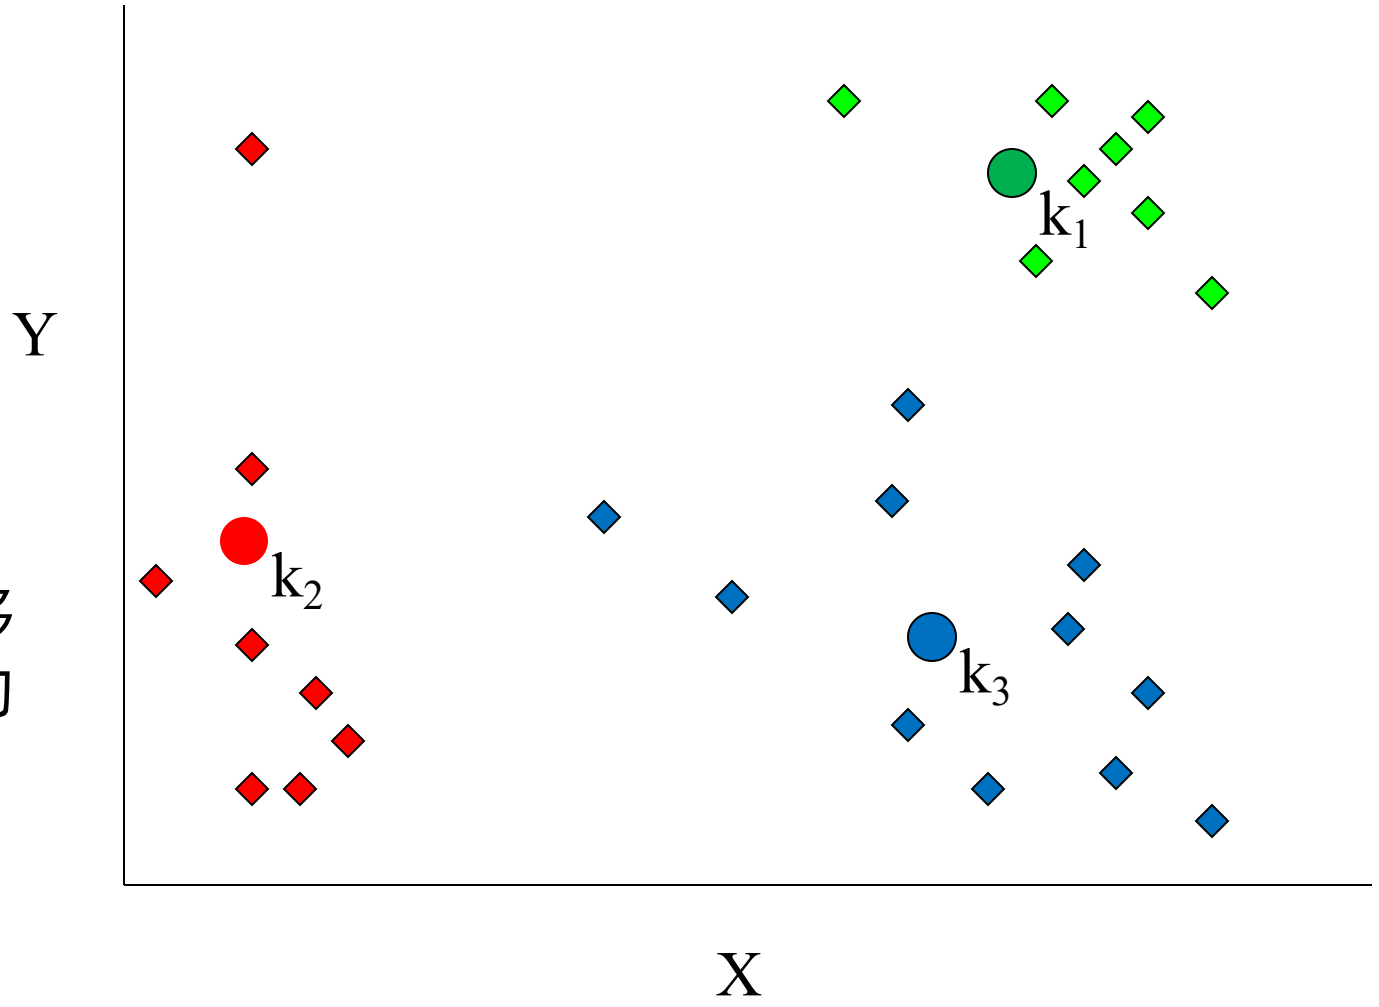
重新计算每一类的均值



7.3.1 k-means聚类步骤

k-means样例, 步骤 5

把类中心移动到均值的位置



7.3.1 k-means聚类步骤

k-means聚类算法的操作步骤

输入：数据集$X=\{\boldsymbol{x}_j|j=1,2,...,\text{total}\}$，其中的数据样本也只包含描述属性，不包含类别属性；聚类个数k。

输出：使误差平方和准则最小的k个聚类。

（1）从数据集X中随机地选择k个数据样本作为聚类的初始代表点，每一个代表点表示一个类别。

（2）对于X中的任一数据样本$\boldsymbol{x}_j$，$(1\leq j\leq \text{total})$，计算它与$k$个初始代表点的距离，并且将它划分到距离最近的初始代表点所表示的类别中。

（3）完成数据样本的划分之后，对于每一个聚类，计算其中所有数据样本的均值，并且将其作为该聚类的新的代表点，由此得到k个均值代表点。

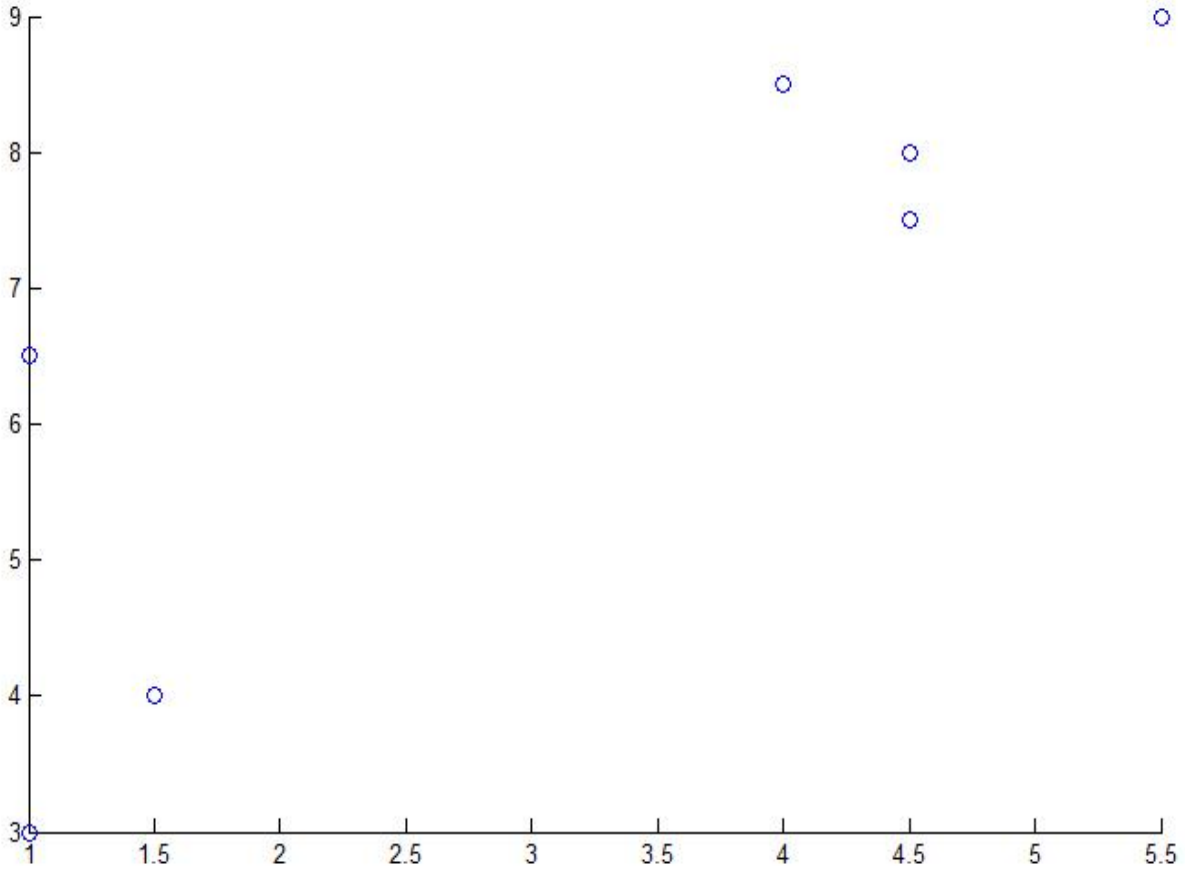
（4）对于X中的任一数据样本$\boldsymbol{x}_j$，$(1\leq j\leq \text{total})$，计算它与$k$个均值代表点的距离，并且将它划分到距离最近的均值代表点所表示的类别中。

（5）重复步骤（3）和（4），直到各个聚类不再发生变化为止，即误差平方和准则函数的值达到最优。

7.3.1 k-means聚类步骤

k-means实例

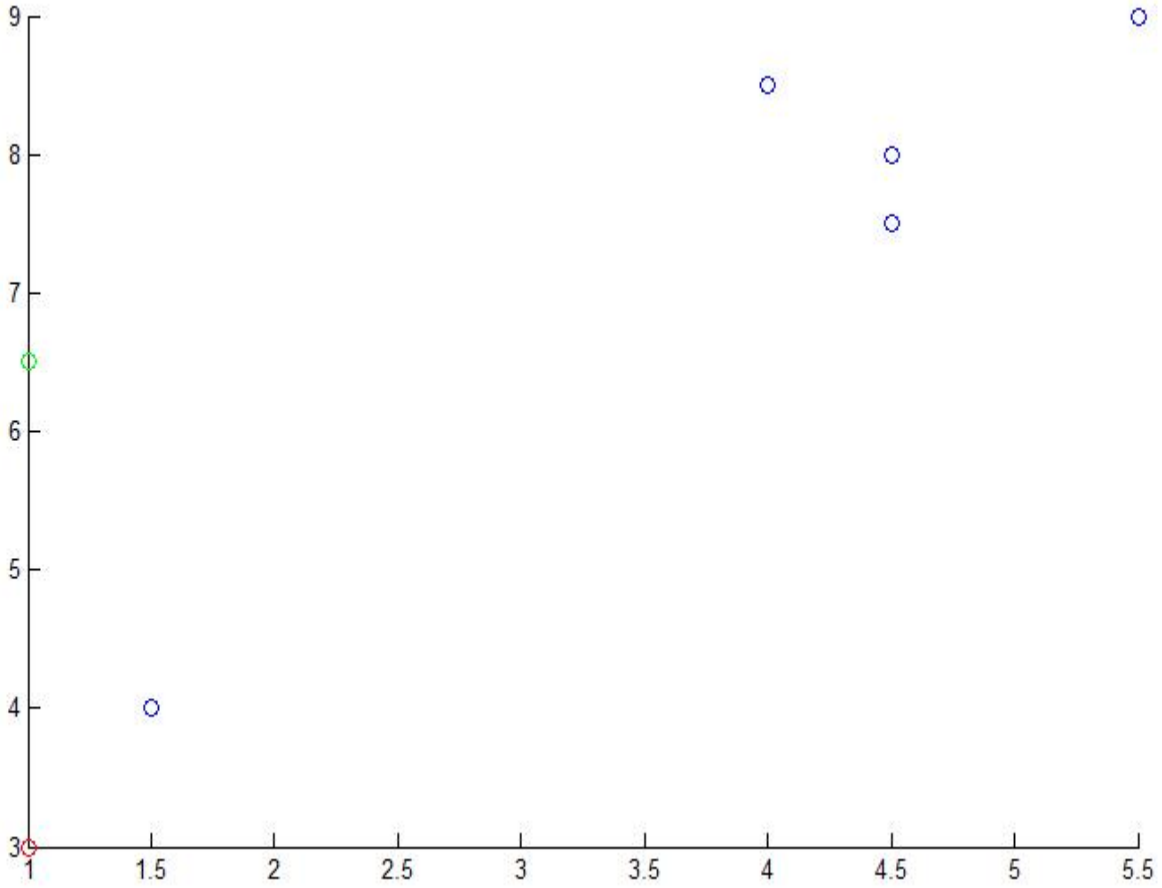
1	3
1	6.5
1.5	4
4.5	7.5
4	8.5
5.5	9
4.5	8



7.3.1 k-means聚类步骤

随机选择初始点

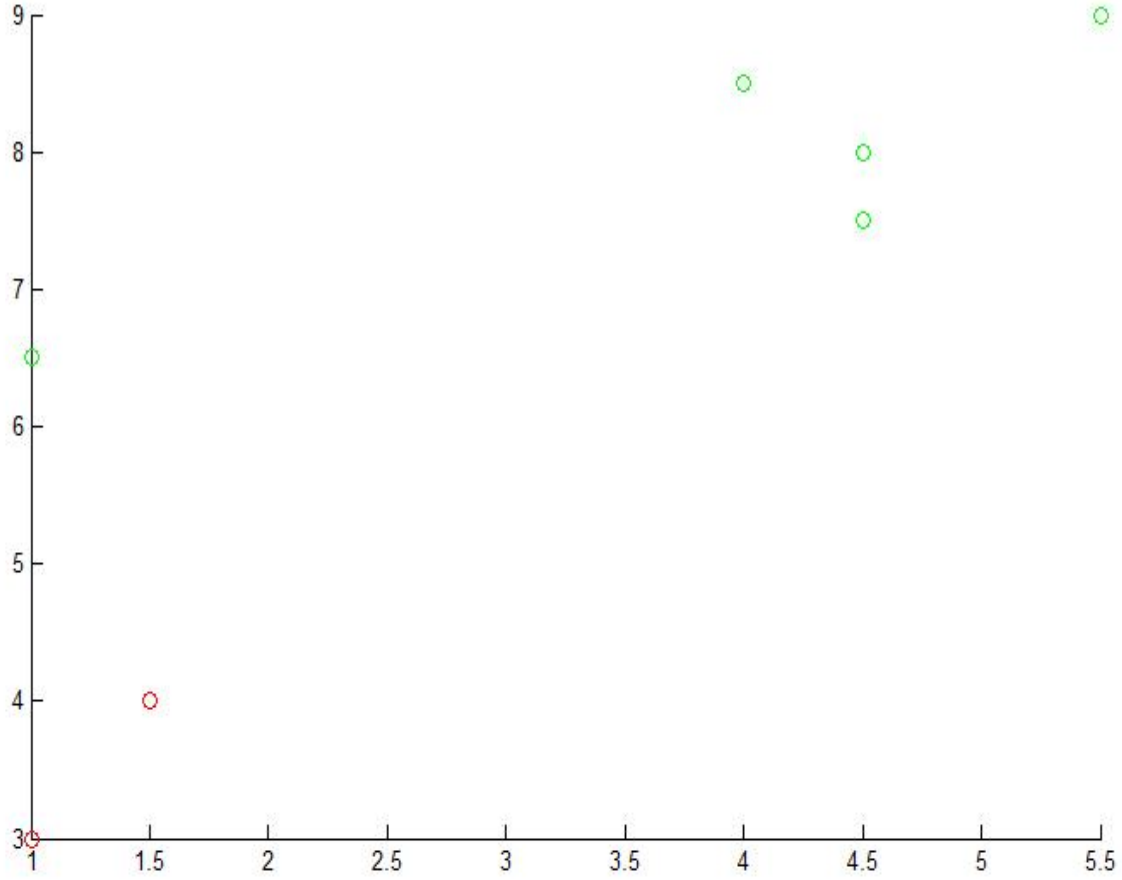
1	3
1	6.5



7.3.1 k-means聚类步骤

计算每个样本到中心的距离，进行指派

0	12.3
12.3	0
1.25	6.5
32.5	13.3
39.3	13
56.3	26.5
37.3	14.5

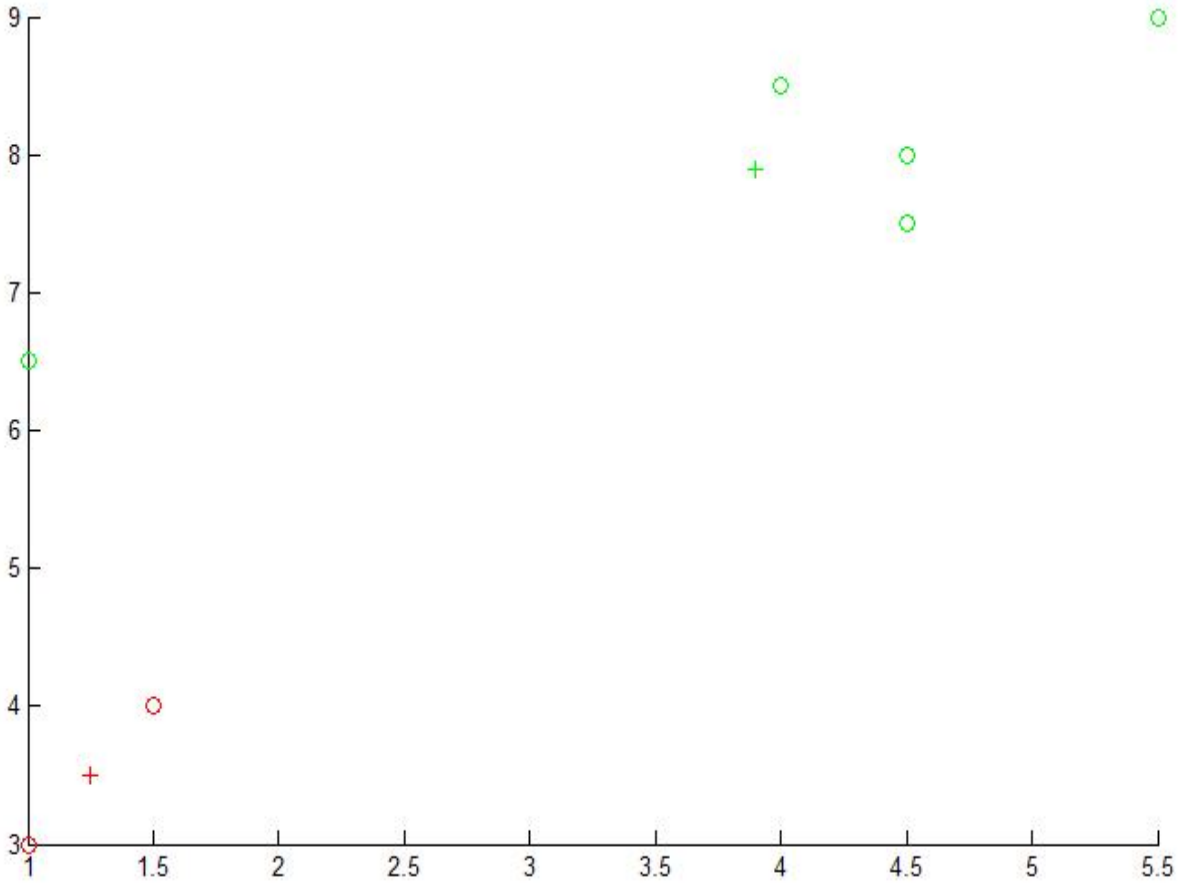


1
2
1
2
2
2
2

7.3.1 k-means聚类步骤

重新计算中心点

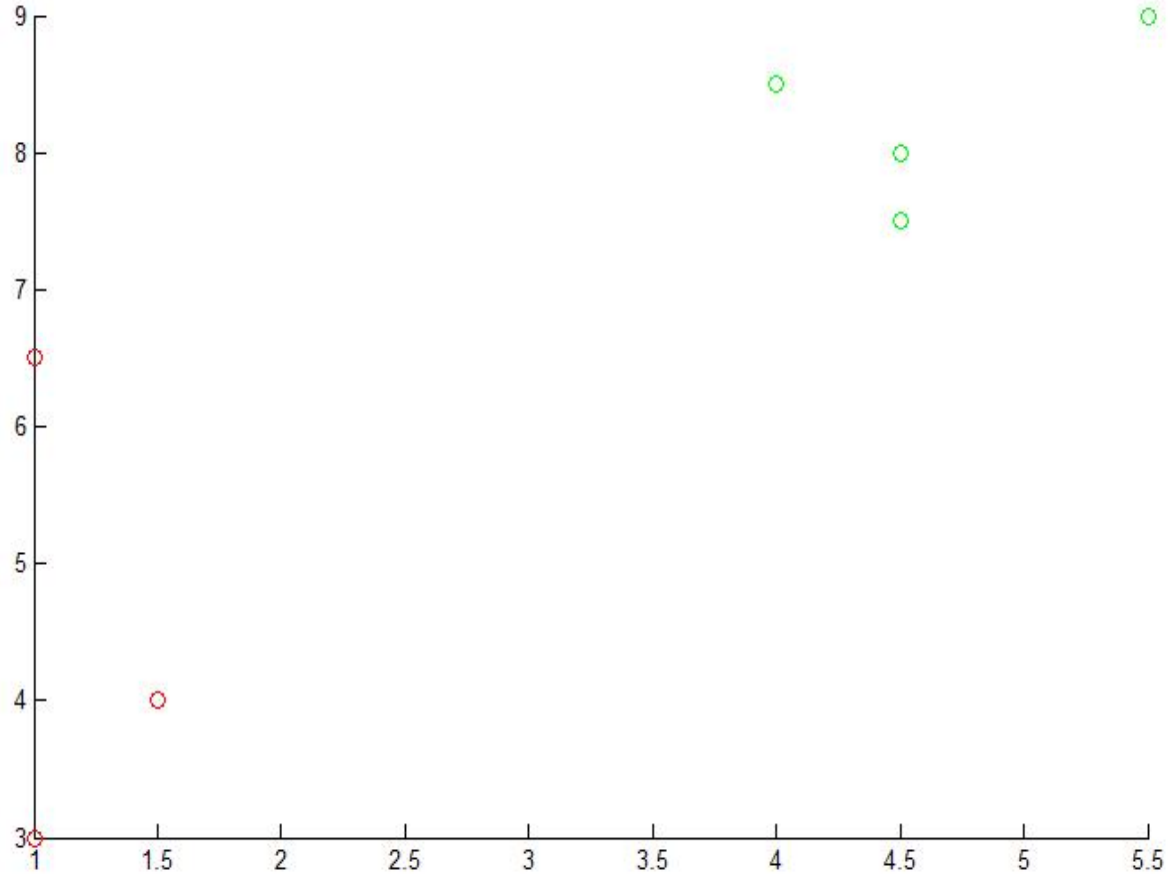
1.25	3.5
3.9	7.9



7.3.1 k-means聚类步骤

计算每个样本到中心的距离，进行指派

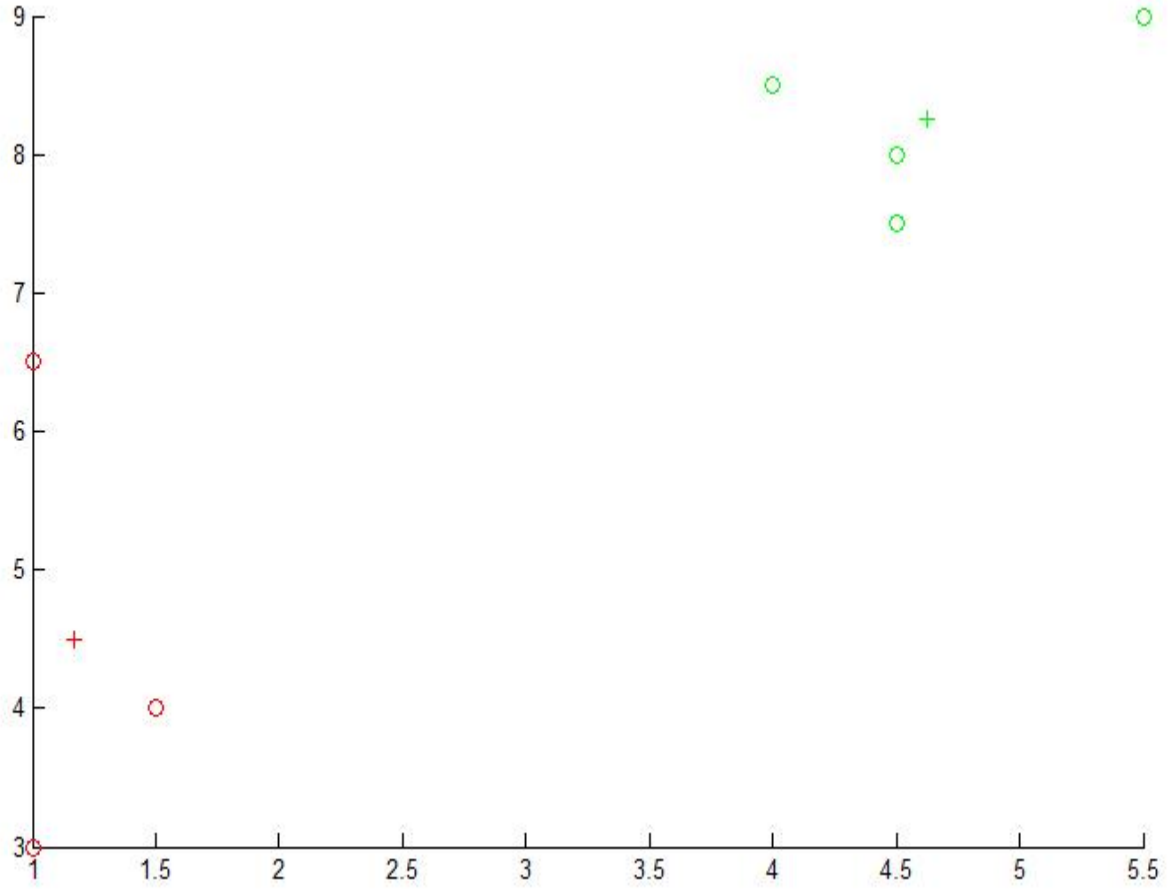
0.31	32.4	1
9.06	10.4	1
0.31	21	1
26.6	0.52	2
32.6	0.37	2
48.3	3.77	2
30.8	0.37	2



7.3.1 k-means聚类步骤

重新计算中心点

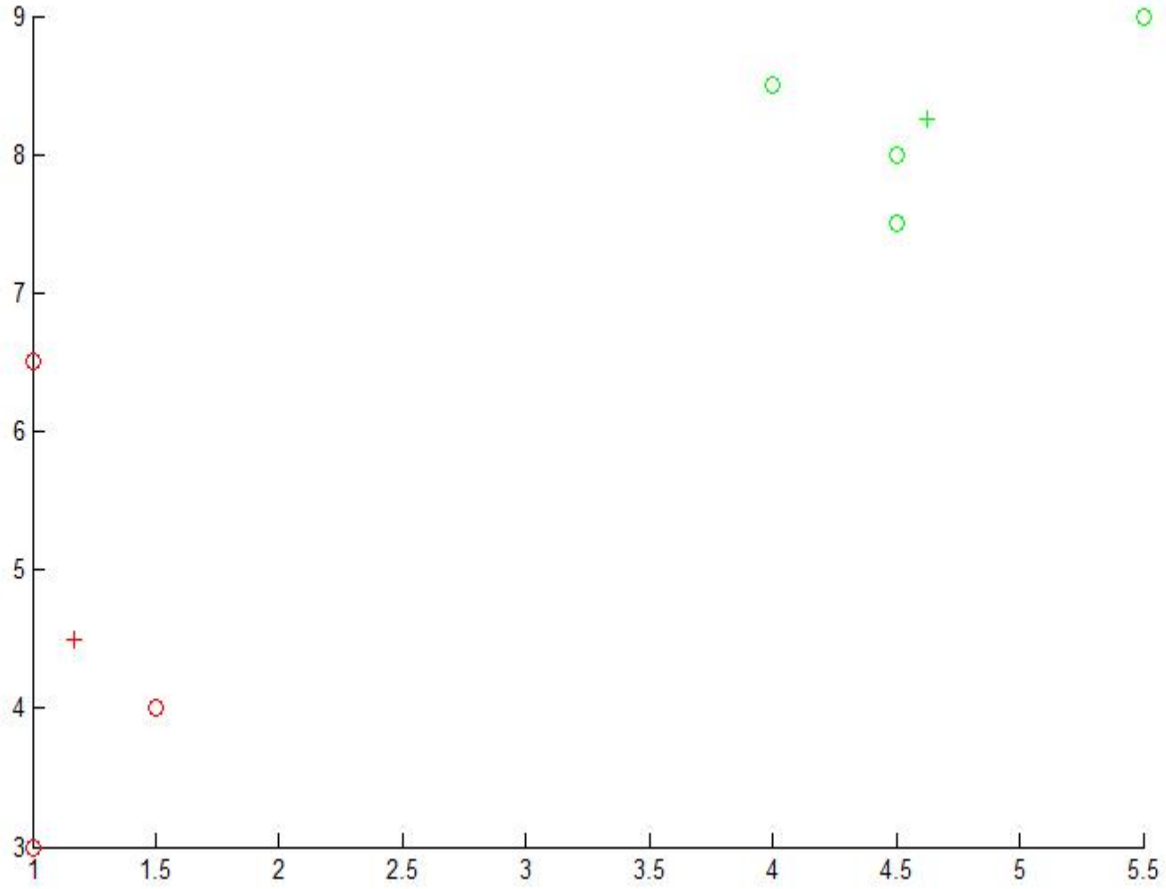
1.17	4.5
4.63	8.25



7.3.1 k-means聚类步骤

计算每个样本到中心的距离，进行指派

2.28	40.7	1
4.03	16.2	1
0.36	27.8	1
20.1	0.58	2
24	0.45	2
39	1.33	2
23.4	0.08	2



7.3.1 k-means聚类步骤

- k-means聚类算法按照数据样本间的相似性把数据集聚类为若干个子集，聚类的结果使评价聚类性能的误差平方和准则函数的值达到最优。

$$J_e = \sum_{i=1}^{c} \sum_{x \in D_i} \left\| x - m_i \right\|^2, \qquad m_i = \frac{1}{n_i} \sum_{x \in D_i} x$$

- 聚类过程中通常使用欧氏距离作为样本间的相似性度量，从而把给定数据集的特征空间划分为若干个子区间，每一个子区间相当于一个聚类。

7.3.2 k-means聚类方法的优点

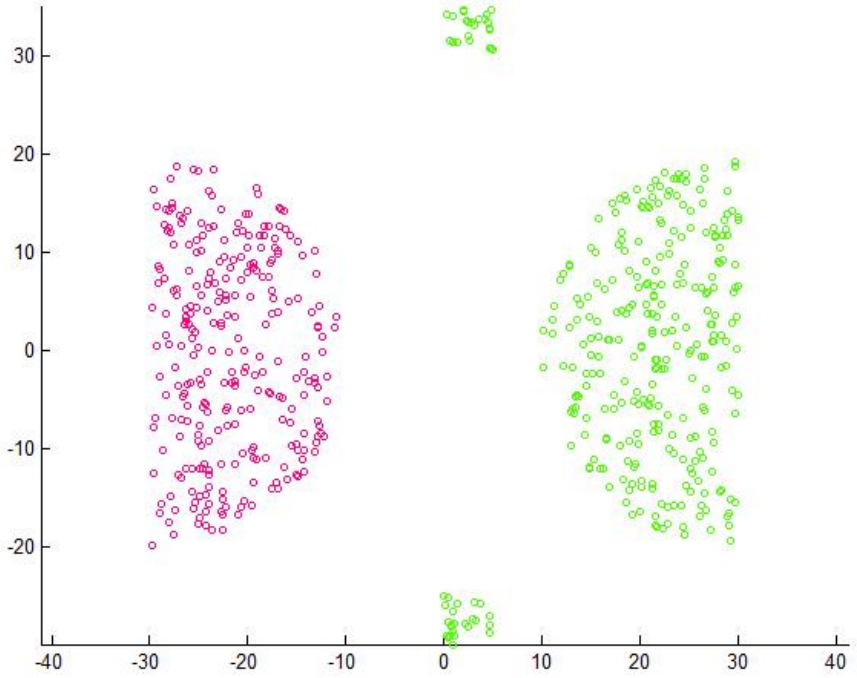
- 与层次聚类相比，k均值可以得到更紧密的簇，尤其是对于球状簇。
- 对大数据集，是可伸缩和高效率的。
- 算法尝试找出使平方误差函数值最小的k个划分。当结果簇是密集的，而簇与簇之间区别明显的时候，效果较好。

7.3.3 k-means聚类方法的缺点

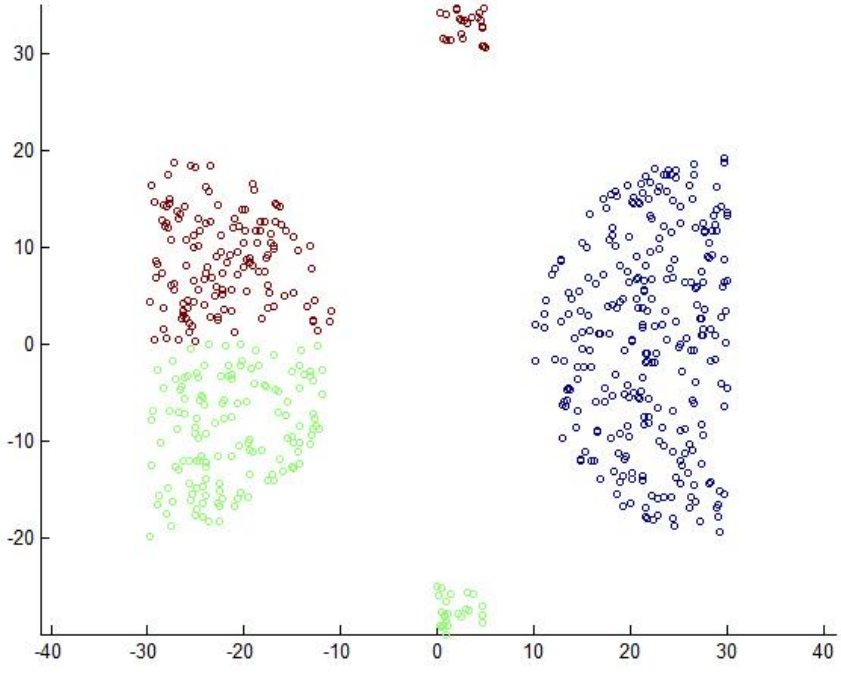
- 1. 聚类的个数
- 2. 对初始值敏感
- 3. 对噪声点非常敏感

7.3.4 k-means聚类的改进方法

1. 聚类的个数



K=2时的聚类结果



K=3时的聚类结果

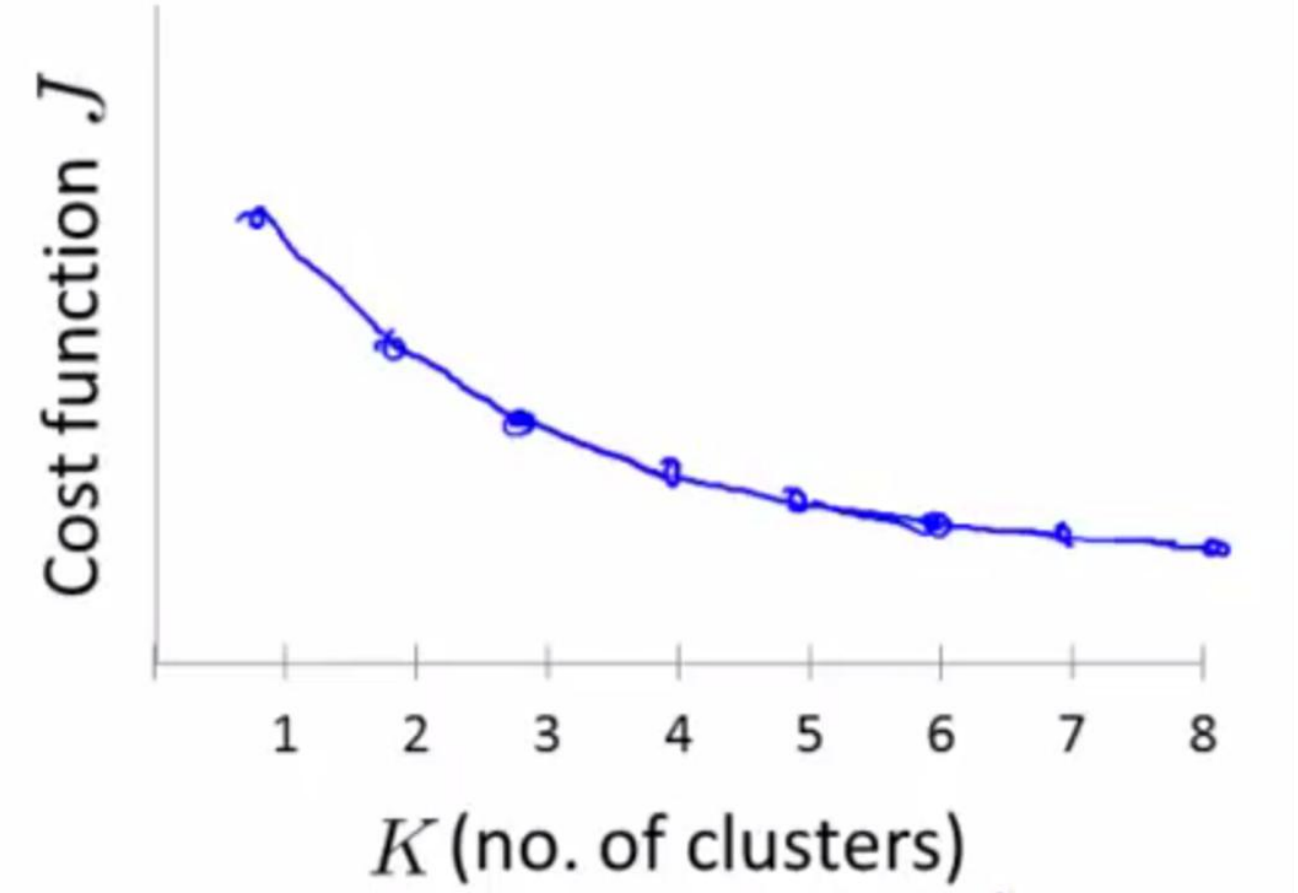
7.3.4 k-means聚类的改进方法

k-means聚类算法中聚类子集的个数k是事先给定的，在此基础上再试图得到一个最优的聚类性能。

- 首先采用层次凝聚算法决定结果簇的数目，并找到一个初始聚类，然后用迭代重定位来改进该聚类。
- 当聚类子集的个数不能确定时，可以对不同的k值使用多次k-means聚类算法，随着k值的增加，评价聚类性能的误差平方和准则函数的值会相应减小。由此，根据k值的变化可以得到一个误差平方和准则函数变化的曲线，从曲线的变化规律，结合实际问题的经验，找到一个相对最合适的聚类个数。

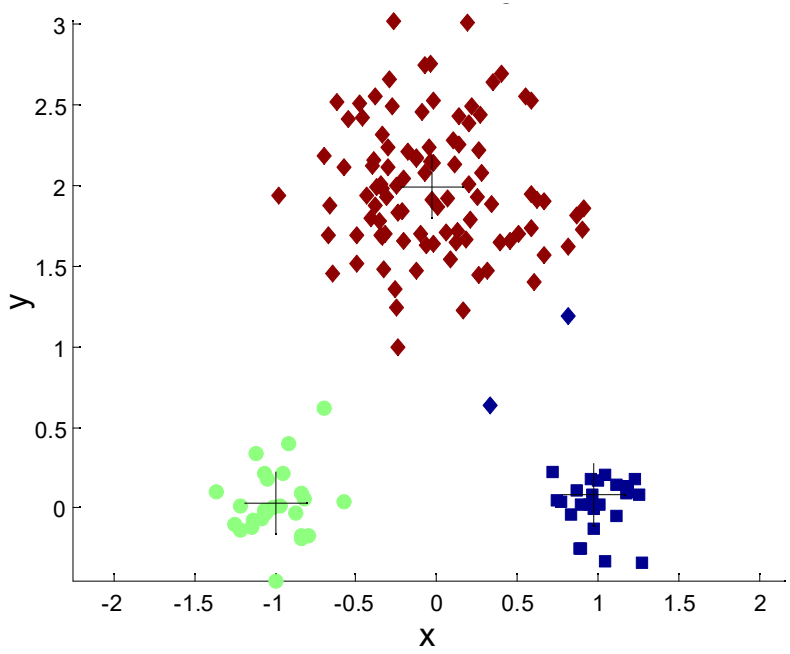
7.3.4 k-means聚类的改进方法

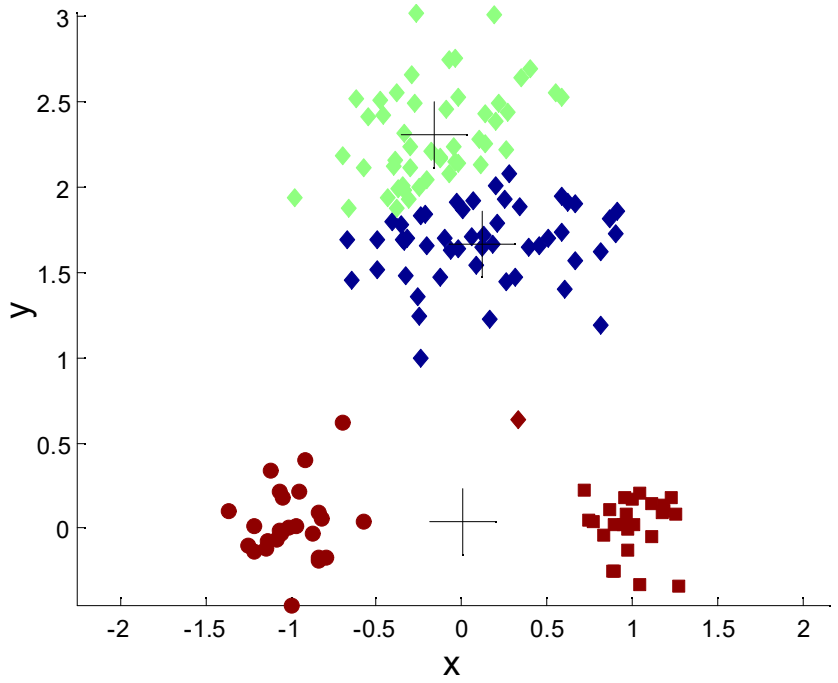
绘制目标函数的损失值对应的质心点数的折线图



7.3.4 k-means聚类的改进方法

2. 对初始值敏感





7.3.4 k-means聚类的改进方法

关于聚类初始代表点的选择，一般有以下几种方法。

- 根据实际问题的特点，按照经验来确定聚类子集的数量，从数据中找出从直观上看来是比较合适的k个聚类的初始代表点。
- 随机地选择k个数据样本作为聚类的初始代表点。
- 将数据集随机地分成k个聚类，之后计算每个聚类的均值，并且将这些均值作为各个聚类的初始代表点。
- 在k-means之前先进行一轮k-means，找到一个初始聚类，然后用迭代重定位来改进该聚类。

聚类初始代表点的选择往往会影响聚类的最终性能，即得到的是局部最优解而不是全局最优解。

7.3.4 k-means聚类的改进方法

3. 对噪声点非常敏感

改进措施：

- 样本数据预处理。计算样本对象两两之间的距离，筛掉与其它所有样本的距离和最大的m个对象。
- 初始聚类中心的选择。如不采用簇中的平均值作为参考点，而选用簇中位置最靠近中心的对象。这样可以避免孤立点的影响。

7.3.4 k-means聚类的改进方法

改进的算法：k-中心点(k-medoids) 方法。选取一个对象叫做mediod来代替上面的中心的作用，这样的一个medoid就标识了这个类。

k-medoids和k-means不一样的地方在于中心点的选取

- 在k-means中，将中心点取为当前cluster中所有数据点的平均值
- 在 k-medoids算法中，将从当前cluster 中选取这样一个点——它到其他所有（当前cluster中的）点的距离之和最小——作为中心点

7 聚类

- 7.1 聚类分析
- 7.2 典型聚类应用
- 7.3 k-means聚类方法
- 7.4 典型聚类方法
- 7.5 评估

数据类型

- 中心型Center-based

  簇的中心通常在簇中所有点的平均值附近



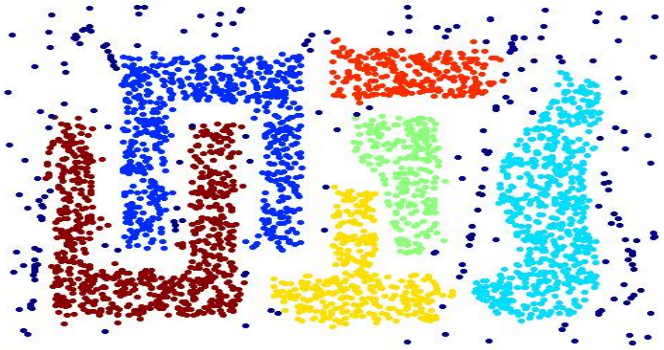
4 center-based clusters

7.4 典型聚类方法

数据类型

- 密度型Density-based
  - A cluster is a dense region of points, which is separated by low-density regions, from other regions of high density.
  - Used when the clusters are irregular or intertwined, and when noise and outliers are present.





数据类型

- 连续型Contiguous Cluster (Nearest neighbor or Transitive)



5 contiguous clusters

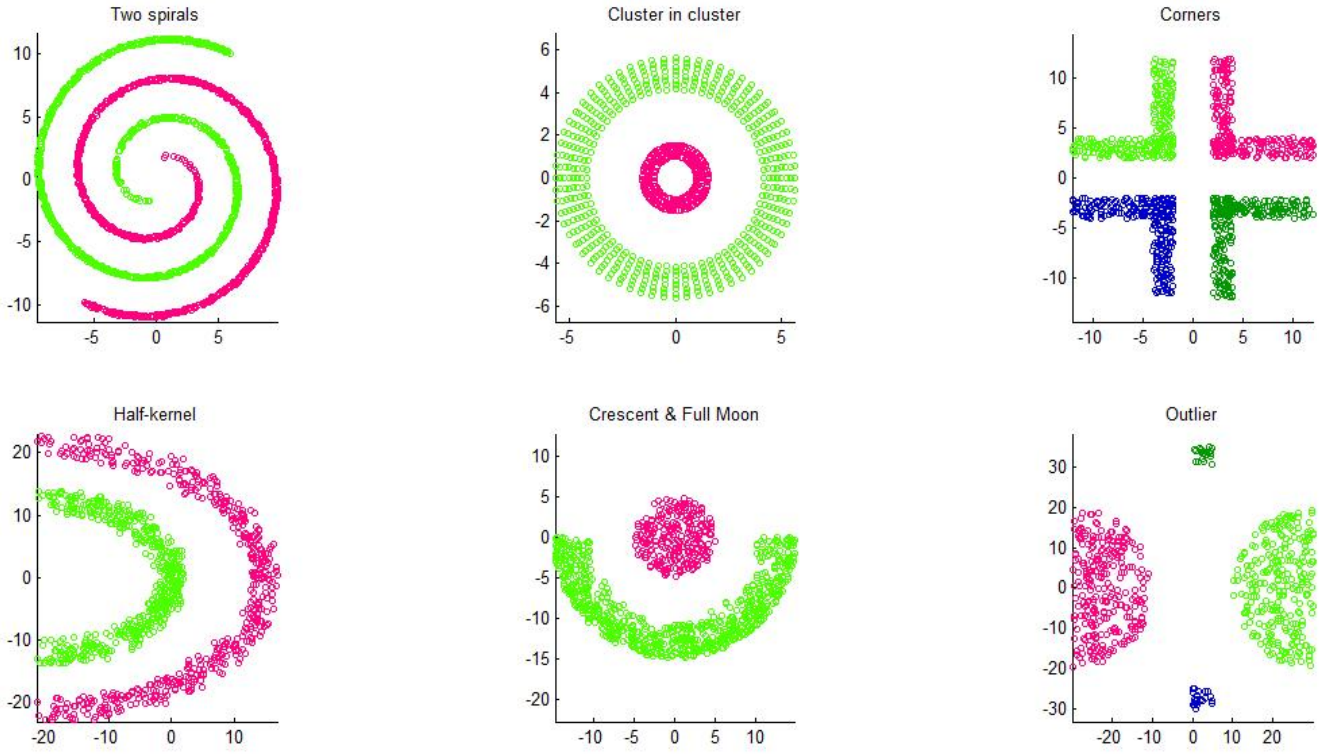
7.4 典型聚类方法

数据挖掘对聚类分析的要求

- 处理不同数据类型的能力
  - 数值型、二元型、标称型、序数型等等
- 发现任意形状的能力
  - 基于距离的聚类算法往往发现的是球形的聚类，其实现实的聚类是任意形状的
- 减小对先验知识和用户自定义参数的依赖性
  - 对于高维数据，参数很难决定，聚类的质量也很难控制
- 处理噪声数据的能力
  - 对空缺值、离群点、数据噪声不敏感
- 可解释性和可用性
  - 聚类要和特定的语义解释和应用相联系

7.4 典型聚类方法

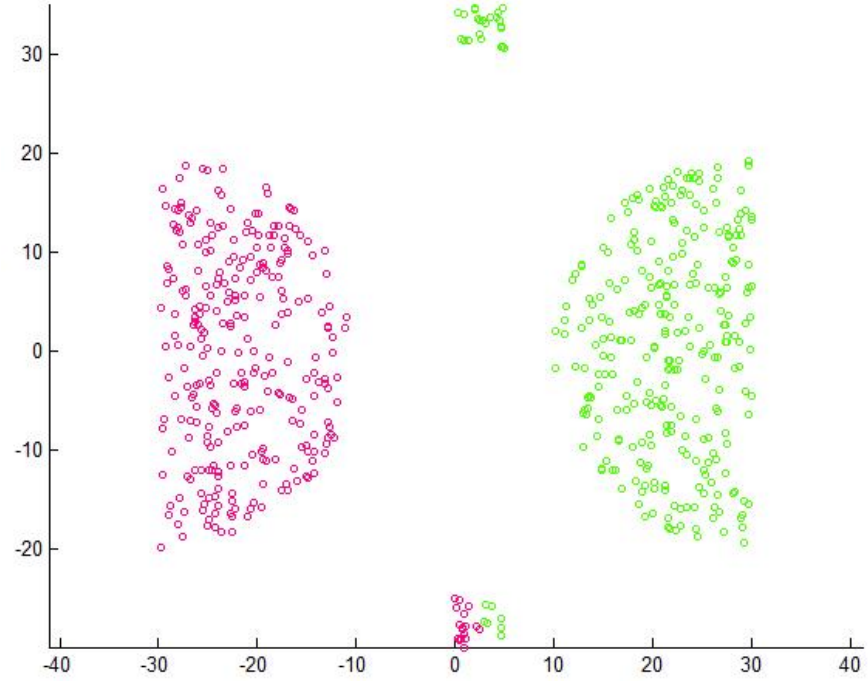
- 数据挖掘技术对聚类分析的要求
  - 发现任意形状聚类的能力

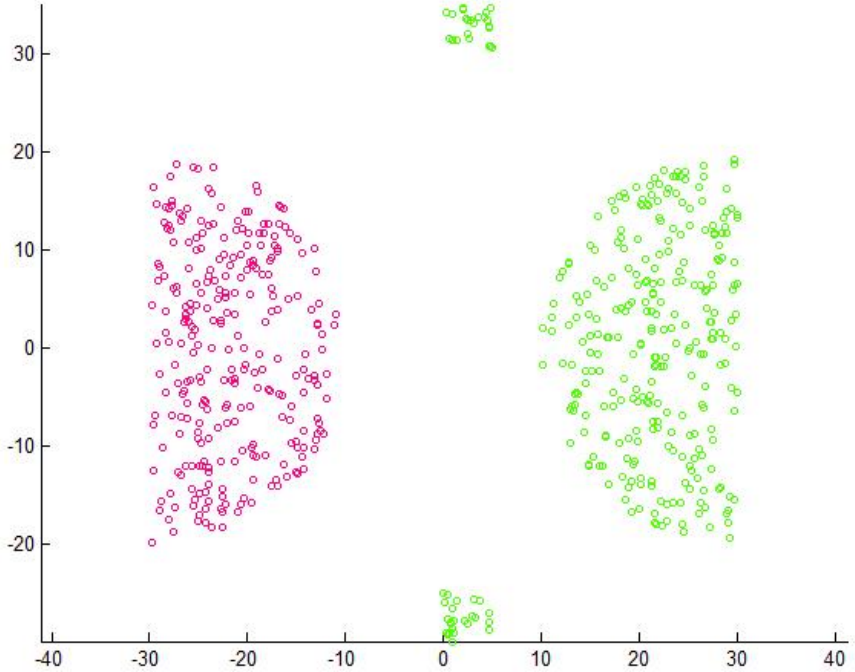


7.4 典型聚类方法

- 数据挖掘技术对聚类分析的要求
  - 减小对先验知识和用户自定义参数的依赖性

初始值

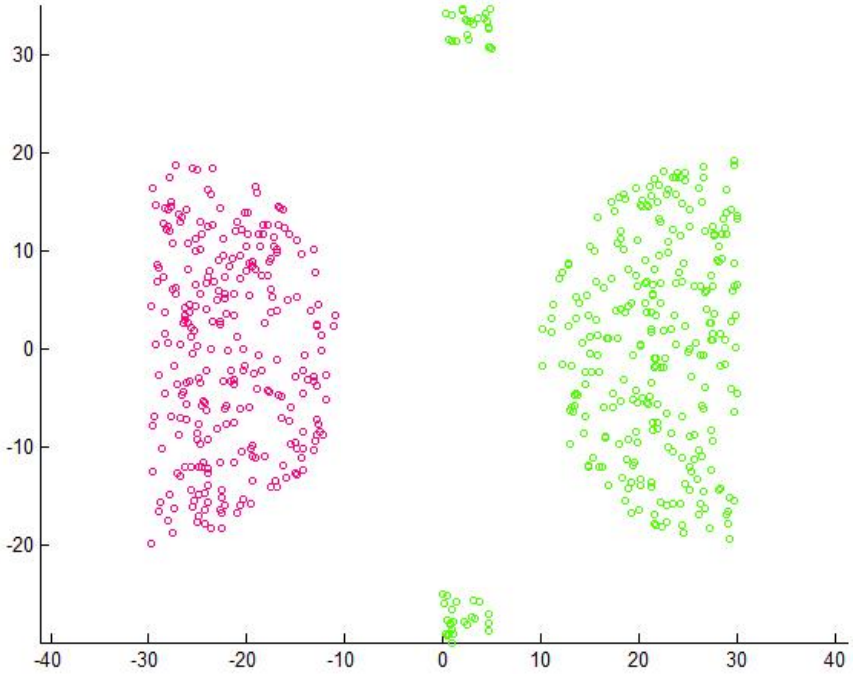


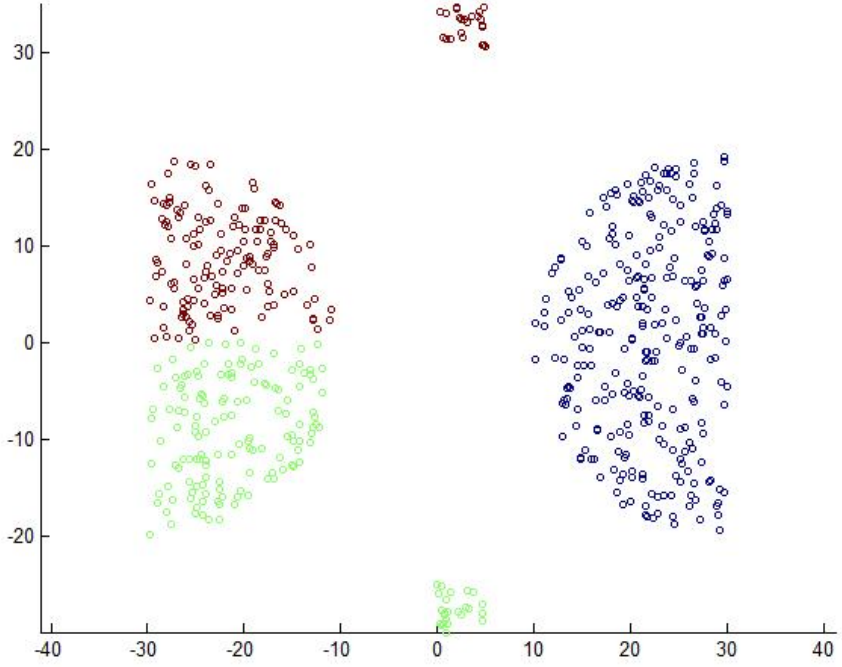


7.4 典型聚类方法

- 数据挖掘技术对聚类分析的要求
  - 减小对先验知识和用户自定义参数的依赖性

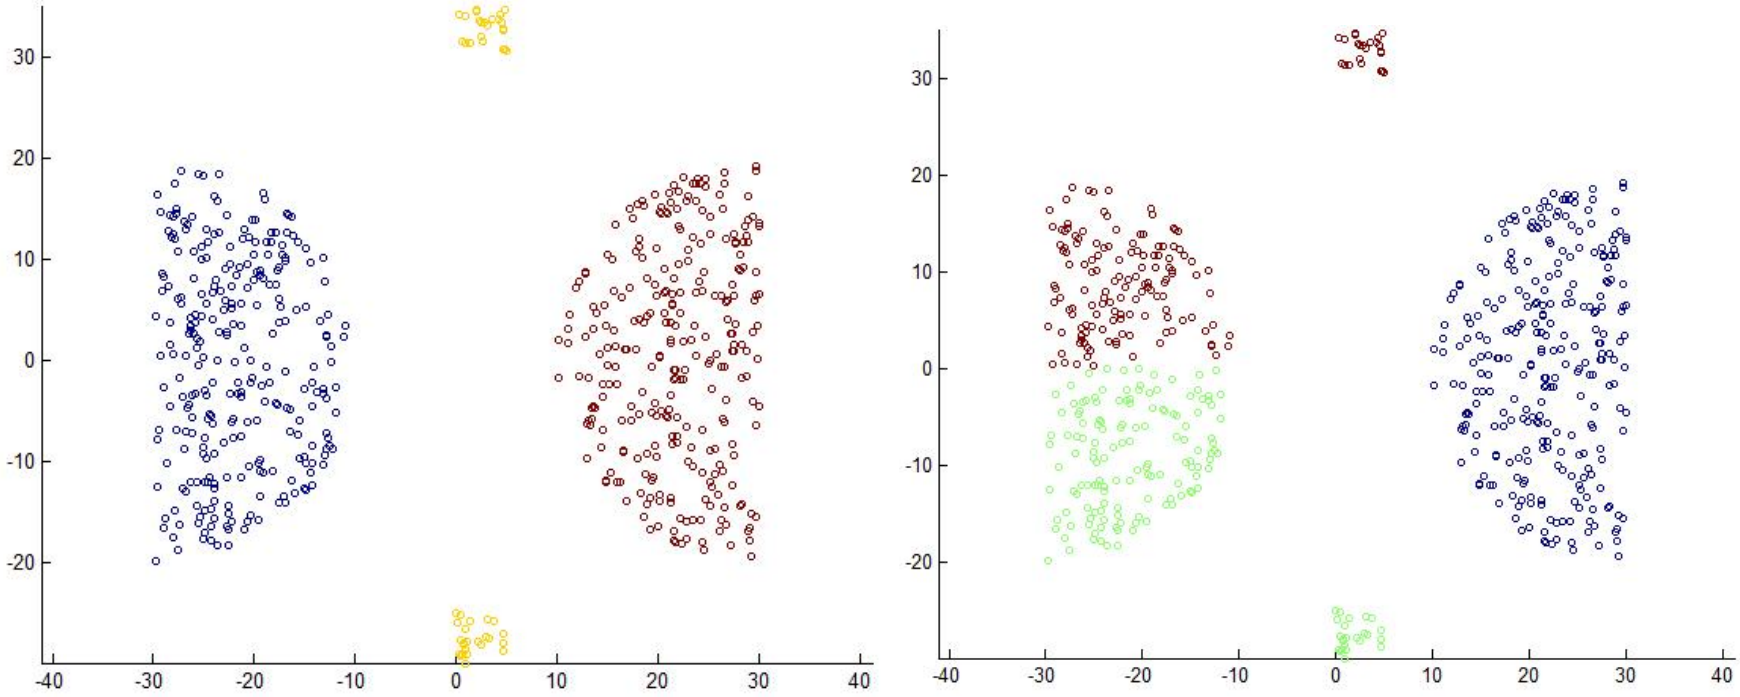
聚类个数





7.4 典型聚类方法

- 数据挖掘技术对聚类分析的要求
  - 处理噪声数据的能力



7.4 典型聚类方法

- 数据挖掘技术对聚类分析的要求
  - 可解释性和实用性

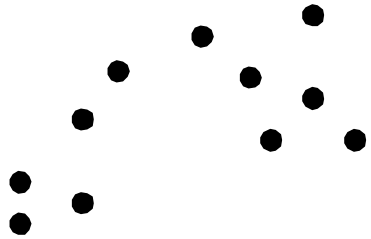
用户往往希望聚类结果是可解释的并且可用的，在低维情况下，可以借助于可视化手段来展示聚类结果，在高维情况下很难被可视化，这时对数据降低维度会有所帮助。根据具体的应用问题，选择合适的聚类算法。

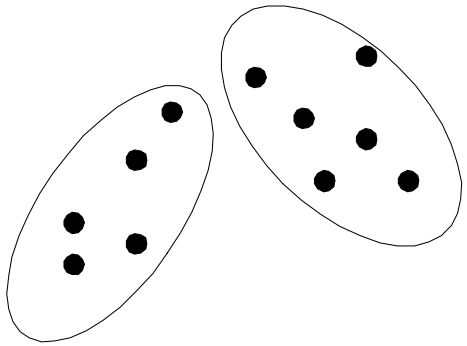
7.4 典型聚类方法

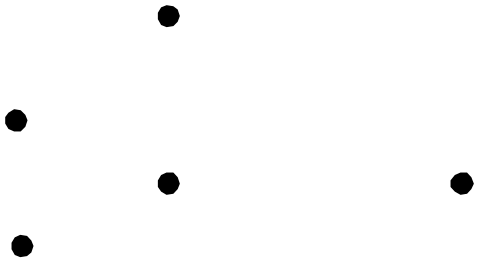
- 7.4.1划分方法
- 7.4.2密度方法
- 7.4.3图的方法
- 7.4.4层次方法

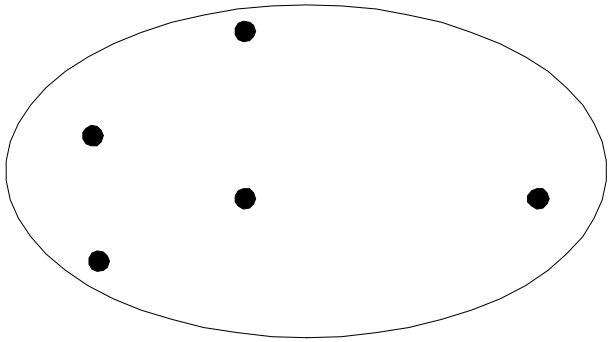
7.4.1 划分聚类方法

- 划分聚类方法







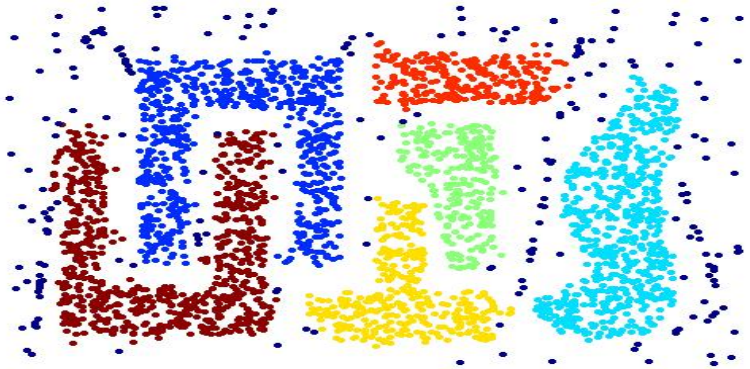


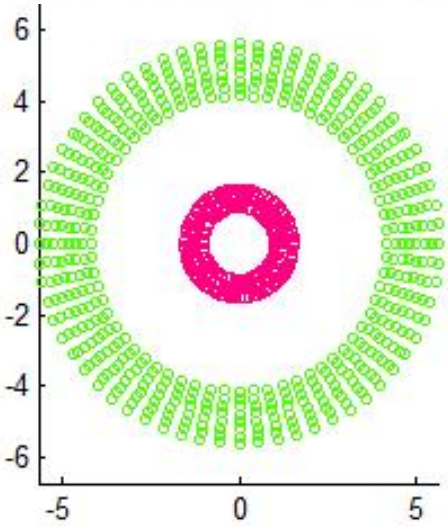
Original Points　　A Partitional Clustering

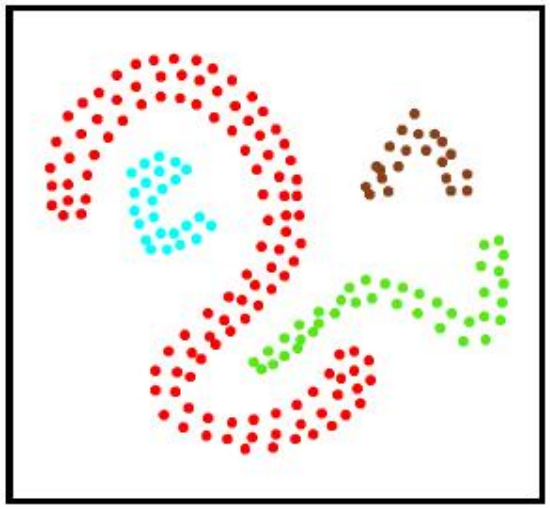
适合发现球形的聚类结构

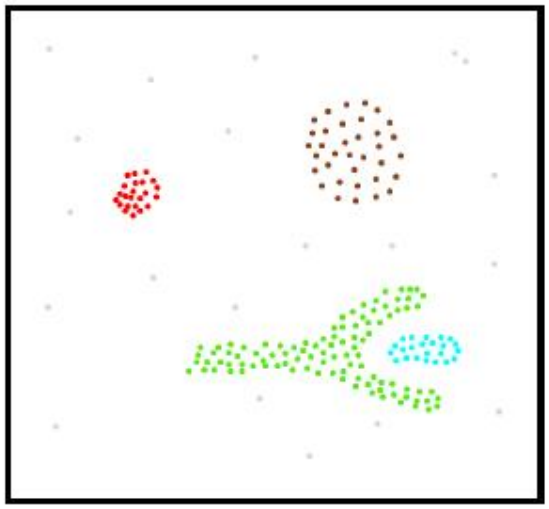
7.4.2 密度聚类方法







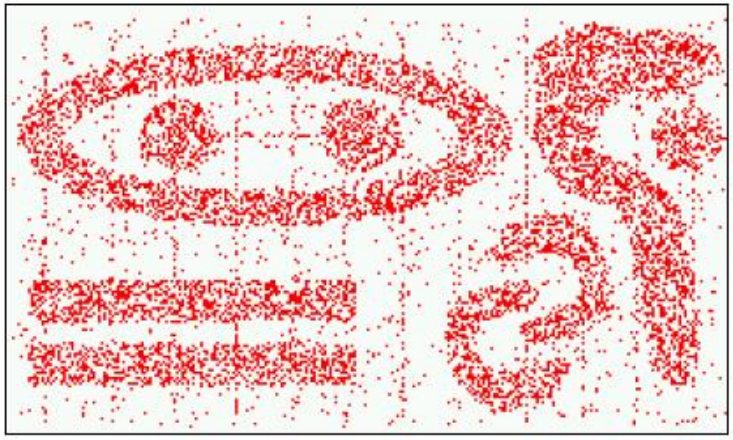




适合发现任意形状的聚类结构

7.4.2 密度聚类方法

- 基于样本之间的距离的聚类方法只能发现球状的簇。
- 密度方法可用来过滤“噪声”孤立点数据，以发现任意形状的簇。
- 主要思想：只要临近区域的密度（样本的数目）超过某个阈值则继续聚类。即对于给定簇中的每个样本，在一个给定范围的区域中必须至少包含某个数目的样本。



7.4.2 密度聚类方法

- 主要特征
  - 可以发现任意形状的簇
  - 可以去除噪声
  - 需要参数作为终止条件
- 主要方法
  - DBSCAN: Ester, et al. (KDD’96)
  - OPTICS: Ankerst, et al (SIGMOD’99).
  - DENCLUE: Hinneburg & D. Keim (KDD’98)
  - CLIQUE: Agrawal, et al. (SIGMOD’98) (more grid-based)

7.4.2 密度聚类方法

- 基于密度的聚类方法以数据集在空间分布上的稠密程度为依据进行聚类，无需预先设定簇的数量，因此特别适合对于未知内容的数据集进行聚类。
- 密度聚类方法的指导思想是，只要一个区域中的点的密度大于某个域值，就把它加到与之相近的聚类中去。对于簇中每个对象，在给定的半径ε的邻域中至少要包含最小数数目（MinPts）个对象。
- 这类算法能克服基于距离的算法只能发现“类圆形”的聚类的缺点，可发现任意形状的聚类，且对噪声数据不敏感。

7.4.2 密度聚类方法

动画演示

7.4.2 密度聚类方法

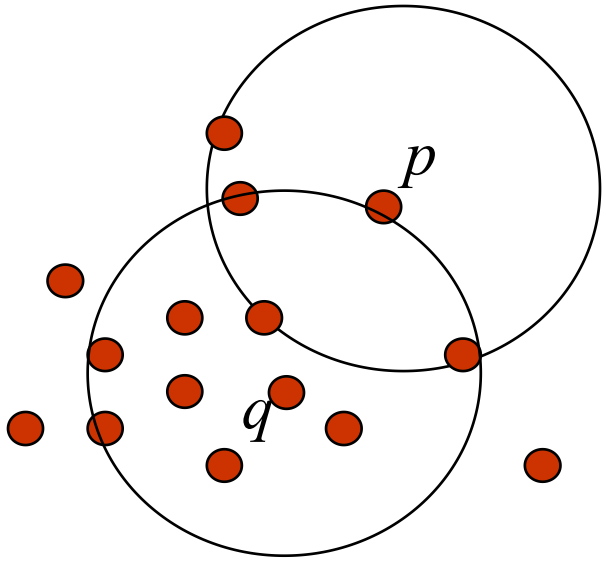
- 优点
  - 能克服基于距离的算法只能发现“类圆形”的聚类的缺点，可发现任意形状的聚类，有效地处理数据集中的噪声数据，数据输入顺序不敏感。
- 缺点
  - 输入参数敏感。确定参数ε，MinPts困难，若选取不当，将造成聚类质量下降。由于在DBSCAN算法中，变量ε，MinPts是全局惟一的， 当空间聚类的密度不均匀、聚类间距离相差很大时，聚类质量较差。
  - 计算密度单元的计算复杂度大，需要建立空间索引来降低计算量，且对数据维数的伸缩性较差。这类方法需要扫描整个数据库，每个数据对象都可能引起一次查询，因此当数据量大时会造成频繁的I/O操作。

DBSCAN

- DBSCAN（Density-Based Spatial Clustering of Applications with Noise）一个比较有代表性的基于密度的聚类算法。与层次聚类方法不同，它将簇定义为密度相连的点的最大集合，能够把具有足够高密度的区域划分为簇，并可在有“噪声”的空间数据库中发现任意形状的聚类。

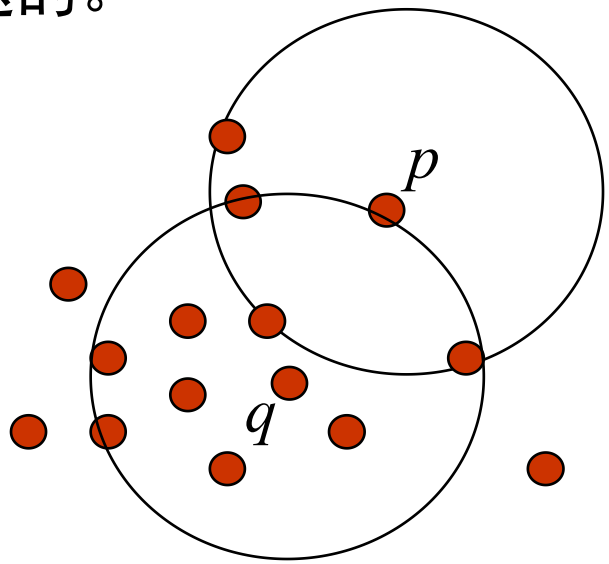
DBSCAN

- 基于中心的密度定义为：
  - 数据集中特定点的密度通过该点ε半径之内的点计数(包括本身)来估计。
  - 密度依赖于半径。



基本术语

- **ε-邻域**：给定对象在半径ε内的区域。
- **核心对象**：如果一个对象的ε-邻域至少包含最小数目MinPts个对象，则称该对象为核心对象。
- **直接密度可达**：给定一个对象集合D，如果p是在q的ε-邻域内，而q是一个核心对象，则对象p从对象q出发是直接密度可达的。



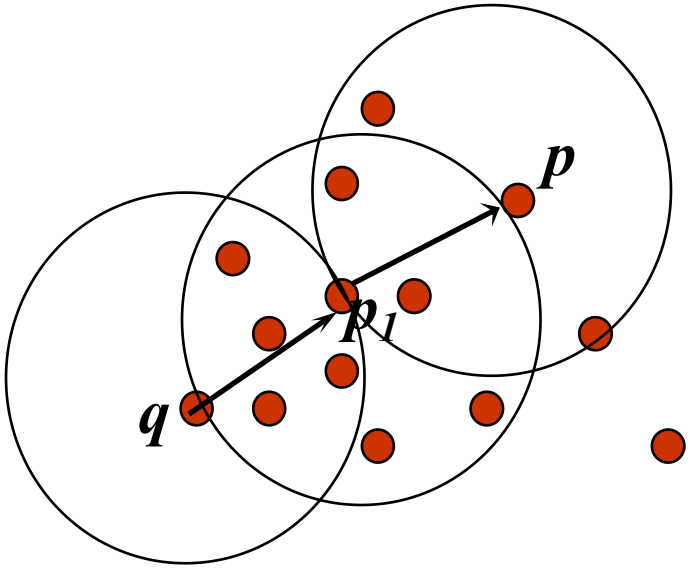
ε=1cm，MinPts=5

q是一个核心对象

对象p从对象q出发是直接密度可达的

基本术语

- **密度可达的**：如果存在一个对象链p_1，p_2，…，p_n，$p_1=q$，$p_n=p$，对$p_i \in D$，（$1<=i<=n$），p_{i+1}是从p_i关于ε和MitPts直接密度可达的，则对象p是从对象q关于ε和MinPts密度可达的。



ε=1cm，MinPts=5

q是一个核心对象

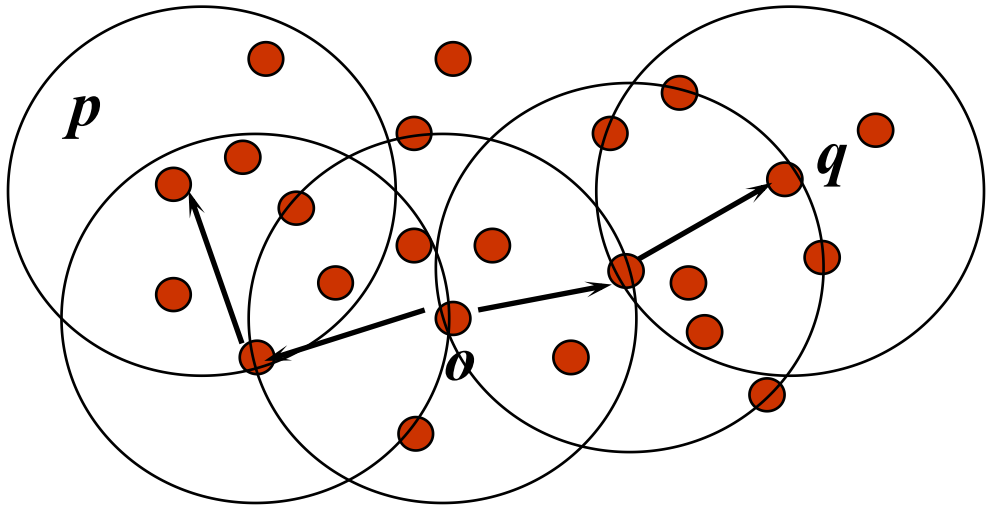
p_1是从q关于ε和MitPts直接密度可达

p是从$p1$关于ε和MitPts直接密度可达

对象p从对象q关于ε和MinPts密度可达的

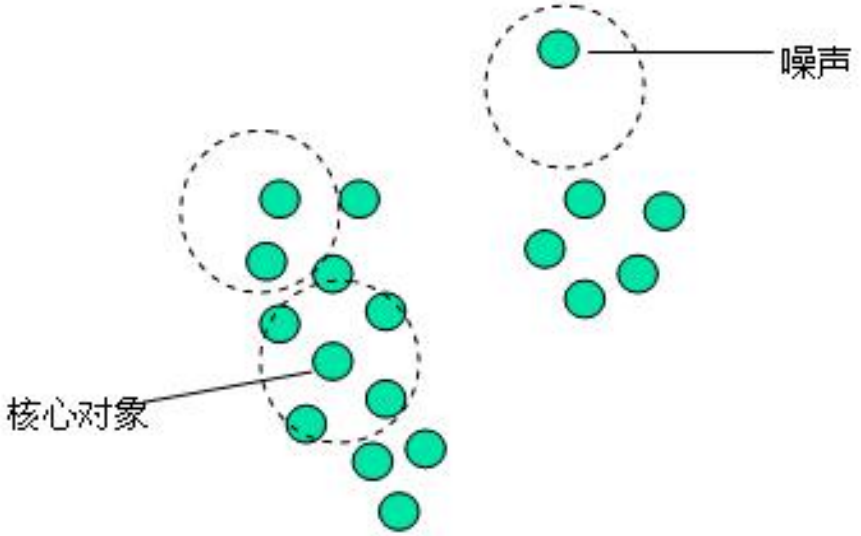
基本术语

- **密度相连的：** 如果对象集合D中存在一个对象o，使得对象p和q是从o关于ε和MinPts密度可达的，那么对象p和q是关于ε和MinPts密度相连的。



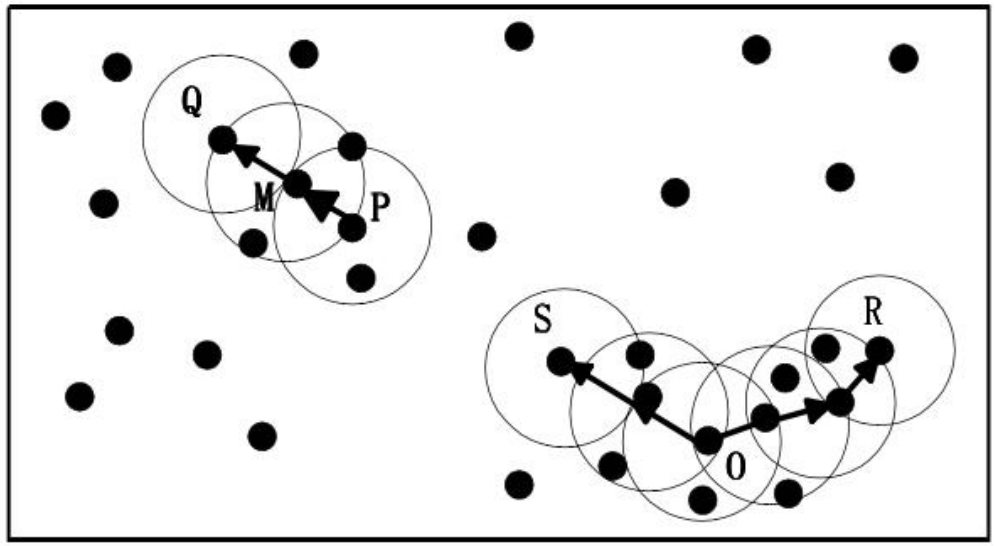
基本术语

- **基于密度的簇**：基于密度可达性的最大的密度相连对象的集合。
- **边界点**：边界点不是核心点，但落在某个核心点的邻域内。
- **噪声**：不包含在任何簇中的对象被认为是“噪声”。噪声就是那些既不是边界点也不是核心点的对象



DBSCAN

- ε 用一个相应的半径表示，设MinPts=3，请分析Q,M,P,S,O,R这5个样本点之间的关系。



由于有标记的各点-M、P、O和R的 ε 近邻均包含3个以上的点，因此它们都是核对象；M-是从P“直接密度可达”；而Q则是从-M“直接密度可达”；基于上述结果，Q是从P“密度可达”；但P从Q无法“密度可达”(非对称)。S和R从O是“密度可达”的；O、R和S均是“密度相连”的。

DBSCAN

- DBSCAN 算法根据以上的定义在数据库中发现簇和噪声。
- 簇可等价于集合D中这个簇核心对象密度可达的所有对象的集合。
- DBSCAN通过检查数据集中每个对象的ε-邻域来寻找聚类。
  - 如果一个点p的ε-邻域包含多于MinPts个对象，则创建一个p作为核心对象的新簇C。
  - 然后，DBSCAN从C中寻找未被处理对象q的ε-邻域，如果q的ε-邻域包含多MinPts个对象，则还未包含在C中的q的邻点被加入到簇中，并且这些点的ε-邻域将在下一步中进行检测。
  - 这个过程反复执行，当没有新的点可以被添加到任何簇时，该过程结束。

DBSCAN

DBSCAN算法描述：

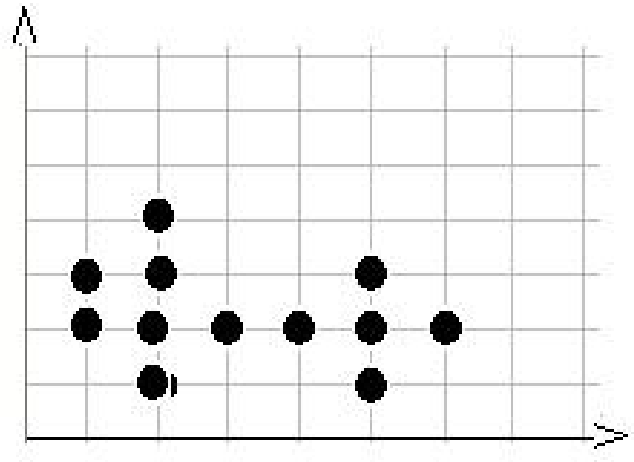
- 输入：包含n个对象的数据库，半径ε，最少数目MinPts。
- 输出：所有生成的簇，达到密度要求。
- 1. REPEAT
- 2. 从数据库中抽取一个未处理过的点；
- 3. IF 抽出的点是核心点 THEN找出所有从该点密度可达的对象，形成一个簇
- 4. ELSE 抽出的点是边缘点(非核心对象)，跳出本次循环，寻找下一点；
- 5. UNTIL 所有点都被处理；

DBSCAN

样本事务数据库

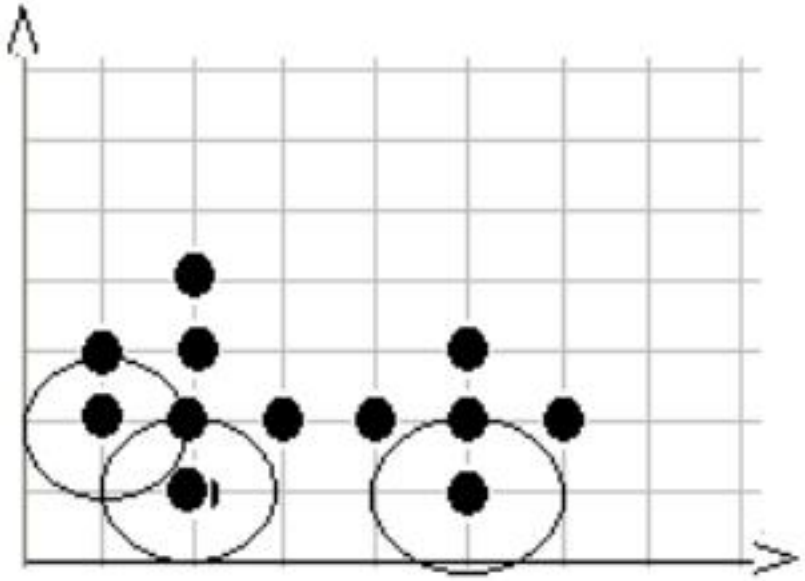
序号	属性 1	属性 2
1	2	1
2	5	1
3	1	2
4	2	2
5	3	2
6	4	2
7	5	2
8	6	2
9	1	3
10	2	3
11	5	3
12	2	4

ε=1， MinPts=4



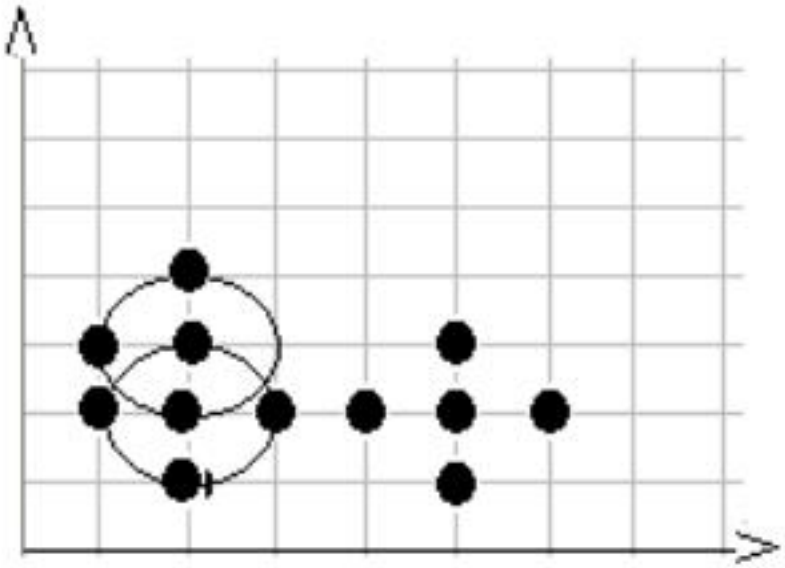
聚类过程

- 第1步，在数据库中选择一点1，由于在以它为圆心的，以1为半径的圆内包含2个点（小于4），因此它不是核心点，选择下一个点。
- 第2步，在数据库中选择一点2，由于在以它为圆心的，以1为半径的圆内包含2个点，因此它不是核心点，选择下一个点。
- 第3步，在数据库中选择一点3，由于在以它为圆心的，以1为半径的圆内包含3个点，因此它不是核心点，选择下一个点。



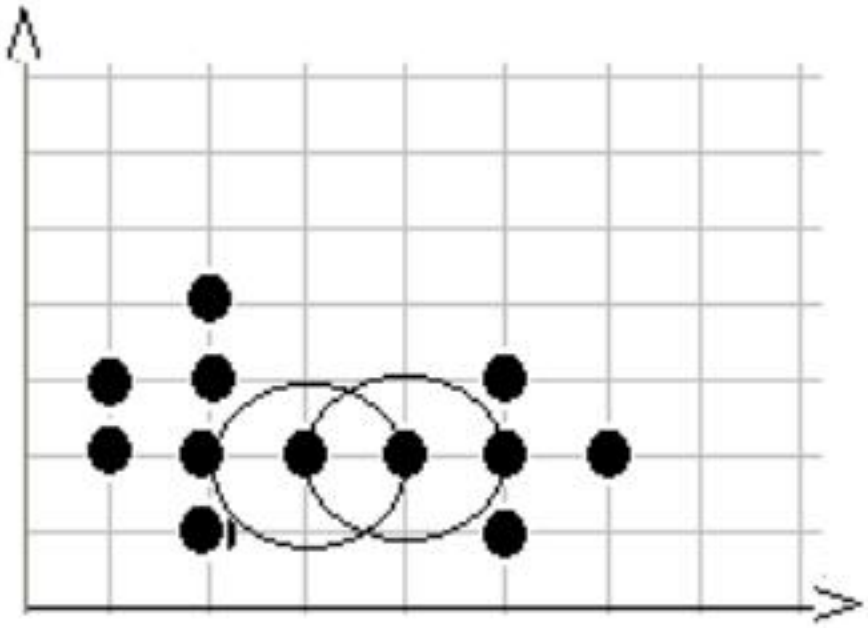
聚类过程

- 第4步，在数据库中选择一点4，由于在以它为圆心的，以1为半径的圆内包含5个点，因此它是核心点，寻找从它出发可达的点（直接可达4个，间接可达2个），聚出的新类{1，3，4，5，9，10，12}，选择下一个点。



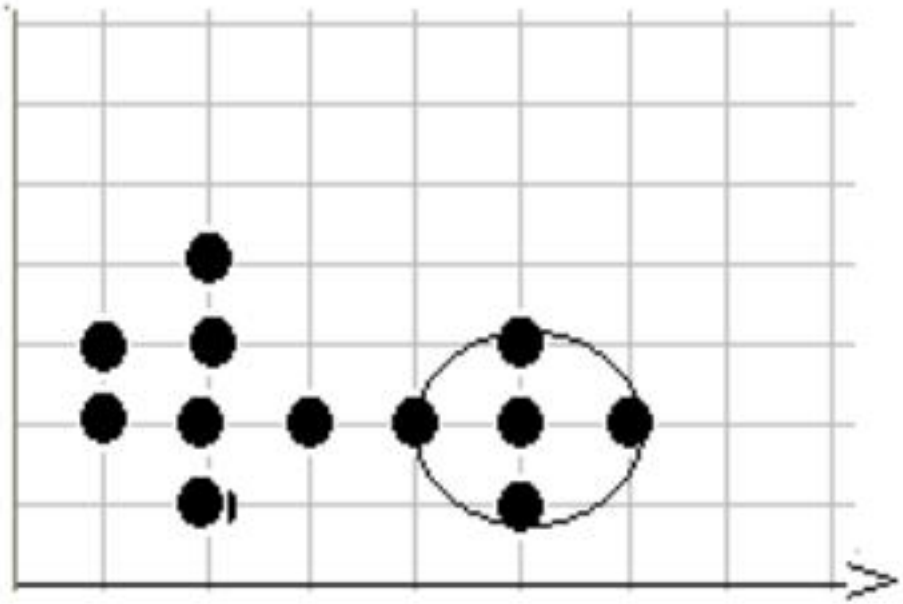
聚类过程

- 第5步，在数据库中选择一点5，已经在簇1中，选择下一个点。
- 第6步，在数据库中选择一点6，由于在以它为圆心的，以1为半径的圆内包含3个点，因此它不是核心点，选择下一个点。



聚类过程

- 第7步，在数据库中选择一点7，由于在以它为圆心的，以1为半径的圆内包含5个点，因此它是核心点，寻找从它出发可达的点，聚出的新类{2，6，7，8，11}，选择下一个点。

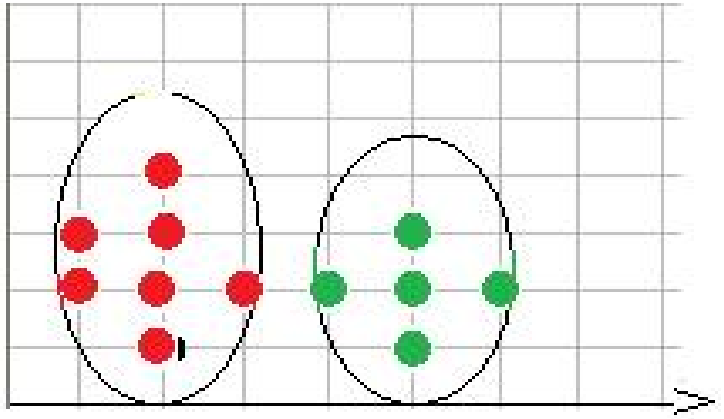


聚类过程

- 第8步，在数据库中选择一点8，已经在簇2中，选择下一个点。
- 第9步，在数据库中选择一点9，已经在簇1中，选择下一个点。
- 第10步，在数据库中选择一点10，已经在簇1中，选择下一个点。
- 第11步，在数据库中选择一点11，已经在簇2中，选择下一个点。
- 第12步，选择12点，已经在簇1中，由于这已经是最后一点所有点都以处理，程序终止。

DBSCAN

步骤	选择的点	在ε中点的个数	通过计算可达点而找到的新簇
1	1	2	无
2	2	2	无
3	3	3	无
4	4	5	簇C_1：{1，3，4，5，9，10，12}
5	5	3	已在一个簇C_1中
6	6	3	无
7	7	5	簇C_2：{2，6，7，8，11}
8	8	2	已在一个簇C_2中
9	9	3	已在一个簇C_1中
10	10	4	已在一个簇C_1中，
11	11	2	已在一个簇C_2中
12	12	2	已在一个簇C_1中



时间复杂度

- DBSCAN算法要对每个数据对象进行邻域检查时间性能较低。
- DBSCAN的基本时间复杂度是 O(N*找出ε领域中的点所需要的时间), N是点的个数。最坏情况下时间复杂度是 O(N^2)
- 在低维空间数据中,有一些数据结构如KD树，使得可以有效的检索特定点给定距离内的所有点，时间复杂度可以降低到O(Nlog$N$)

空间复杂度

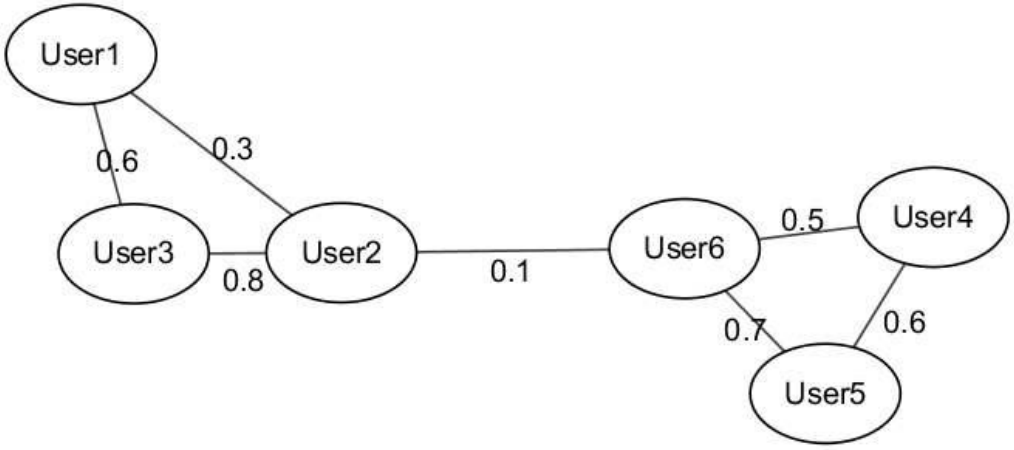
- 在聚类过程中，DBSCAN一旦找到一个核心对象，即以该核心对象为中心向外扩展。此过程中核心对象将不断增多，未处理的对象被保留在内存中。若数据库中存在庞大的聚类，将需要很大的存来存储核心对象信息，其需求难以预料。
- 当数据量增大时，要求较大的内存支持 I/0 消耗也很大；
- 低维或高维数据中，其空间都是O(N)

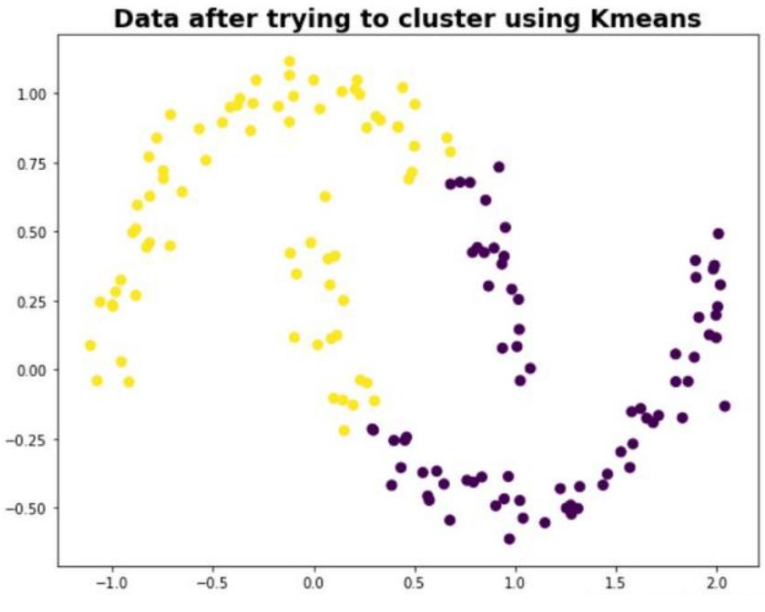
DBSCAN

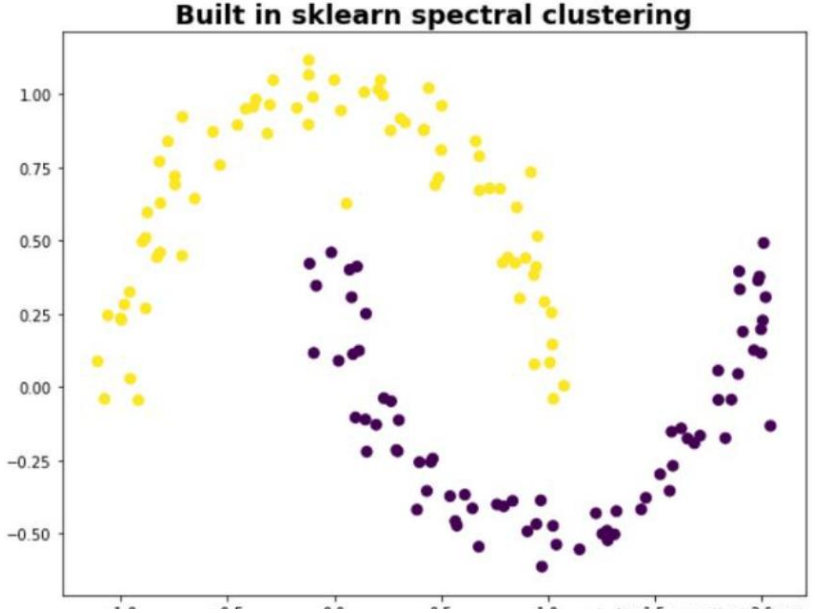
- 优点
  - 能克服基于距离的算法只能发现“类圆形”的聚类的缺点，可发现任意形状的聚类，有效地处理数据集中的噪声数据，数据输入顺序不敏感。
- 缺点
  - 输入参数敏感。确定参数ε，MinPts困难，若选取不当，将造成聚类质量下降。由于在DBSCAN算法中，变量ε，MinPts是全局惟一的， 当空间聚类的密度不均匀、聚类间距离相差很大时，聚类质量较差。
  - 计算密度单元的计算复杂度大，需要建立空间索引来降低计算量，且对数据维数的伸缩性较差。这类方法需要扫描整个数据库，每个数据对象都可能引起一次查询，因此当数据量大时会造成频繁的I/O操作。

7.4.3 图聚类方法

- 基于图的聚类方法







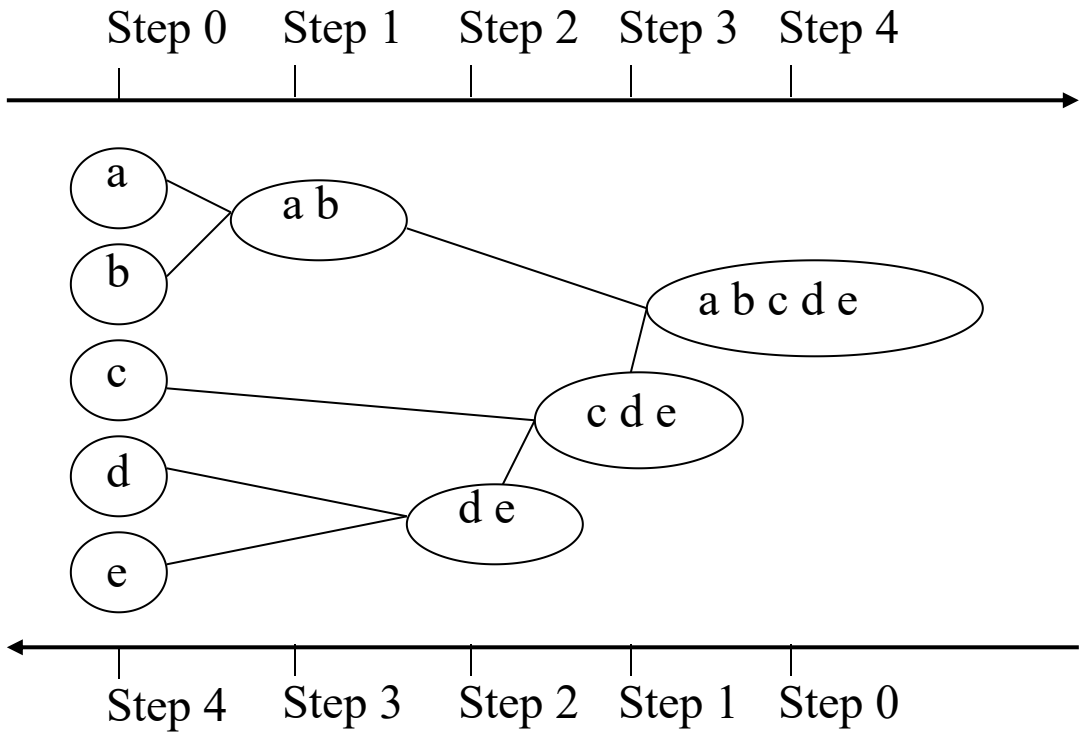
7.4.3 图聚类方法

谱聚类

- 优点：
  - 谱聚类只需要数据之间的相似度矩阵，因此对于处理稀疏数据的聚类很有效。
  - 建立在谱图理论基础上，能在任意形状的样本空间上聚类，适合高维数据的聚类。
- 缺点：
  - 复杂度高。
  - 谱聚类对相似度图的改变和聚类参数的选择非常的敏感。

7.4.4 层次聚类方法

- 对给定数据集分层进行划分，形成一个以各个聚类为结点的树形结构。
- 分成凝聚型和分裂型两种方式。

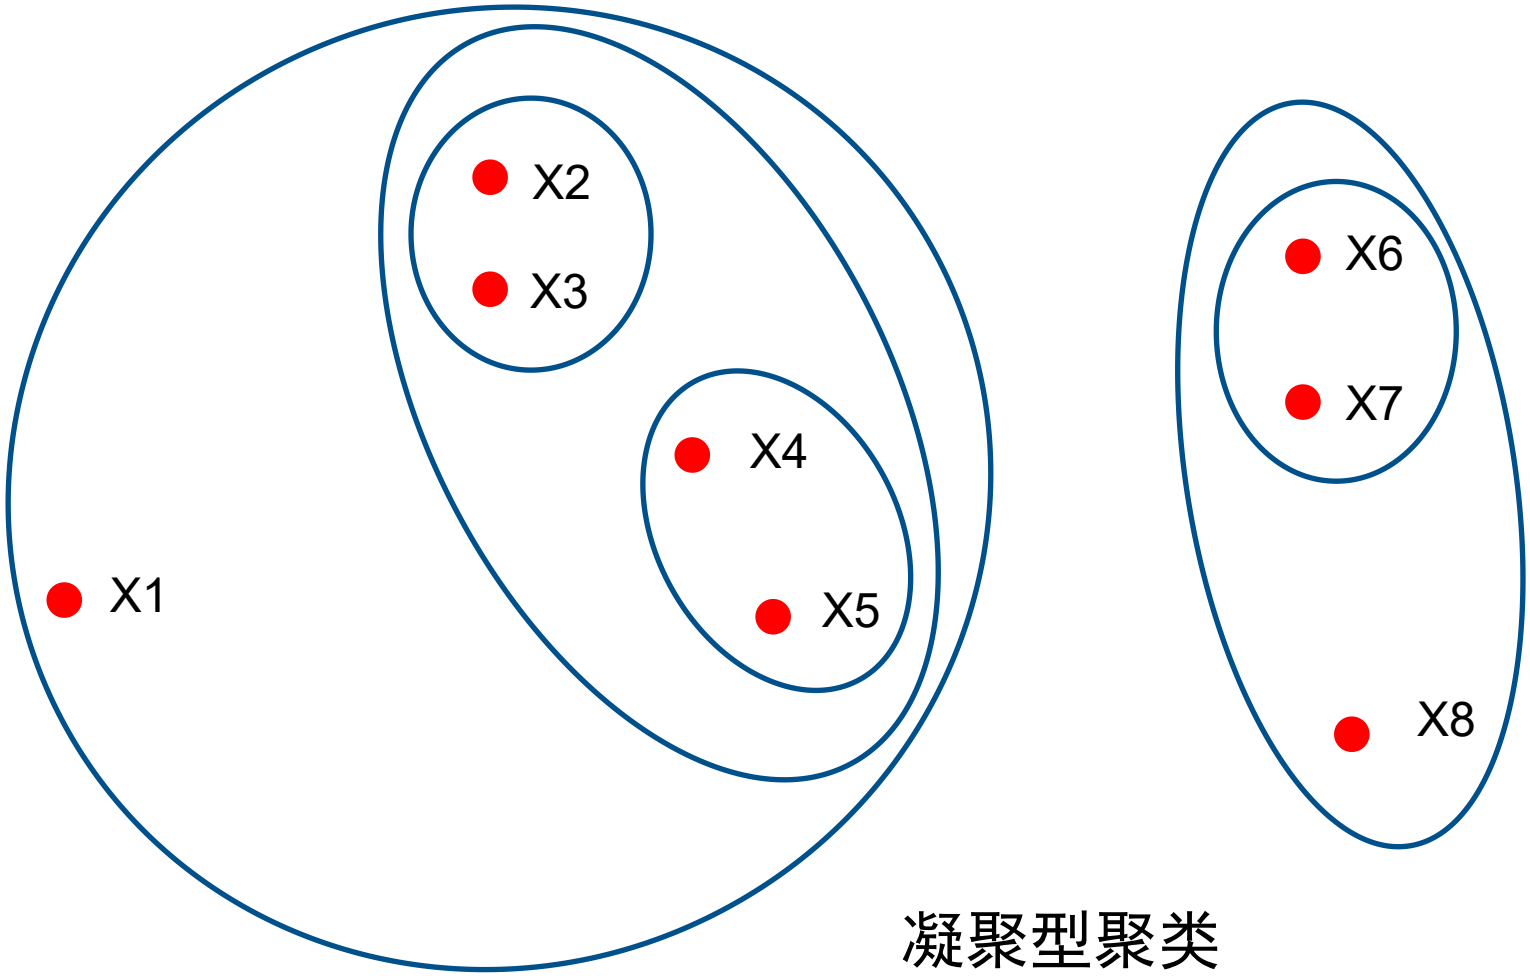


Agglomerative nesting (AGNES)

Divisive analysis (DIANA)

7.4.4 层次聚类方法

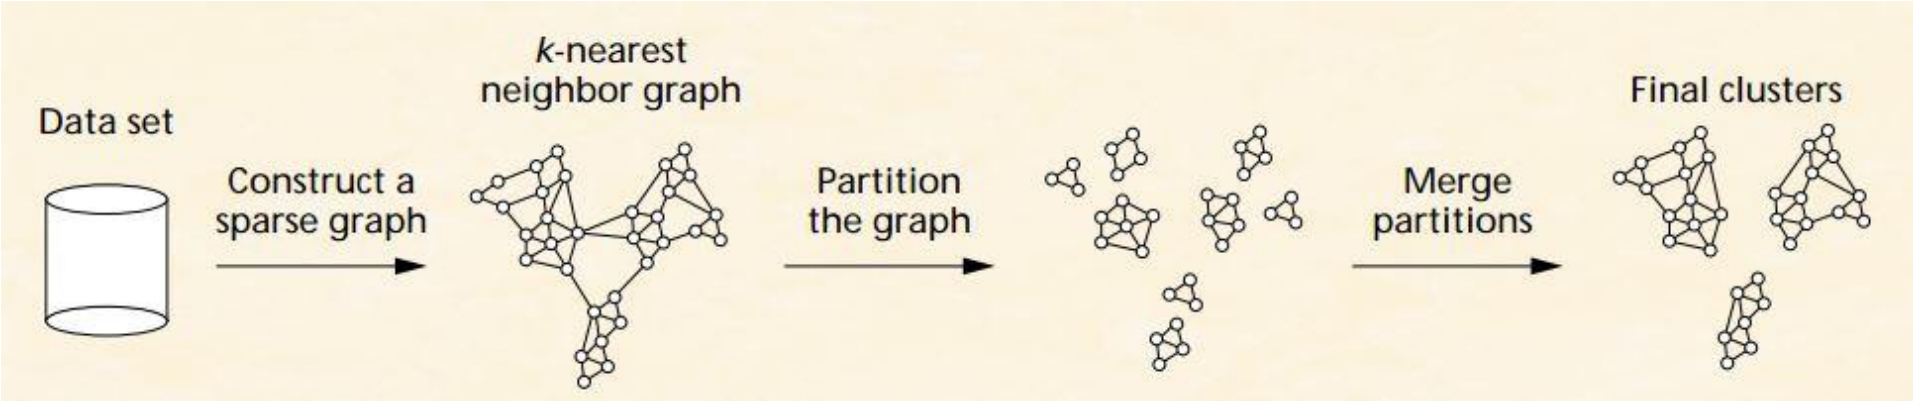
每个样本看成一个类，逐步将样本合并，直到所有样本都在一个类别或者满足终止条件为止



凝聚型聚类

7.4.4 层次聚类方法

- 改进的层次聚类方法：
  - BIRCH利用层次方法的平衡迭代规约和聚类（Balanced Iterative Reducing and Clustering Using Hierarchies）
  - Chameleon（变色龙）多阶段层次聚类



7.4.4 层次聚类方法

- 优点：
  - 简单，易实现，容易理解
- 缺点：
  - 不能纠正错误的合并或者分裂。
  - 不具有很好的可伸缩性，因为合并或分裂的决定需要检查和估算大量的对象或簇。

7 聚类

- 7.1 聚类分析
- 7.2 典型聚类应用
- 7.3 k-means聚类方法
- 7.4 典型聚类方法
- 7.5 评估

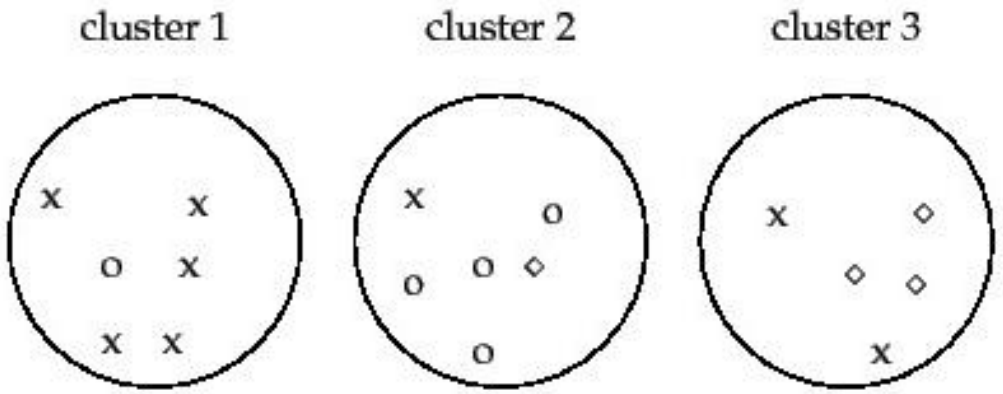
7.5 评估

- 外在方法
  - 当有基准可用时，可以将它与聚类进行比较，评估聚类。
- 内在方法
  - 没有基准可用时，通过考察簇的分离情况和紧凑情况评估聚类。

7.5 评估

纯度purity

purity方法是极为简单的一种聚类评价方法，只需计算正确聚类的样本数占总样本数的比例



$$purity = (3+ 4 + 5) / 17 = 0.71$$

其中第一类正确的有5个，第二个4个，第三个3个，总数17。

purity方法计算简单，值在0～1之间，完全错误的聚类方法值为0，完全正确的方法值为1。

7.5 评估

最小误差

误差平方和准则表示数据集中的所有样本与相应聚类中心的方差之和，该准则的值达到最优时可以便各个聚类类内尽可能地紧凑，而各个聚类之间则尽可能地分开。

Cohesion is measured by the within cluster sum of squares error(SSE)

$$WSS = \sum_{i} \sum_{x \in C_i} (x - m_i)^2$$

Separation is measured by the between cluster sum of squares

$$BSS = \sum_{i} |C_i| (m - m_i)^2$$

Where $|C_i|$ is the size of cluster i , m is the center of all samples.

7.5 评估

- NMI(Normalized Mutual Information) 即归一化互信息
- RI (Rand Index) 将聚类看成是一系列的决策过程
- ARI (Adjusted Rand Index)

小结

- K-means聚类方法
- 典型聚类方法
- 评估

天津大学
Tianjin University

THE END

