天津大学
Tianjin University

数据挖掘



有监督 vs 无监督

- 有监督：

用于分类或者回归，需要有训练集和测试集。

在已知训练集的前提下，对测试样本根据它的特征，把它与训练集中的样本进行对比，把它分到对应的那类中。

- 无监督：

用于聚类

有一堆数据，将这堆数据按照它们自身内部的相似性，自动地聚成几类。

第 6 章　回归分析

6 回归分析

- 6.1 回归概述
- 6.2 应用案例
- 6.3 线性回归
- 6.4 非线性回归
- 6.5 Logistic回归
- 6.6 评估

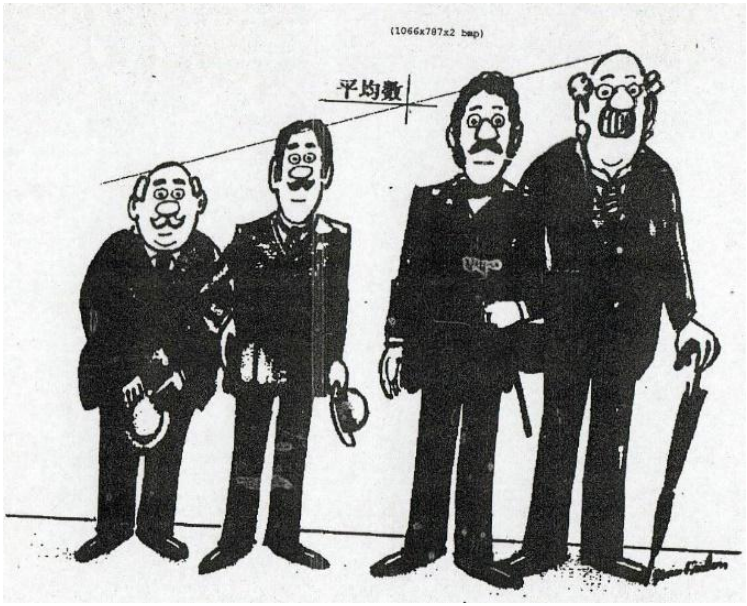
6.1 回归概述

- “回归”一词是1855年由英国生物学家高尔顿（Galton）在研究孩子的身高与他们父母身高关系时提出的。
- 当时他正研究这样一个问题：高个子人生的子女一般偏高，照这样看，各代人在身高分布上将有两级分化的趋势，个子很高和很矮的会越来越多，而处在中间状态的会越来越少。
- 研究发现，父母个子高，其子代一般也高，但不如父母那么高；父母个子矮，其子代一般也矮，但不如父母那么矮。下一代身高有向中间值回归的趋势。这种趋于中间值的趋势被称为“回归效应”，而他提出的这种研究两个数值变量关系的方法称作回归分析。

6.1 回归概述

- 英国高尔顿（Galton）和统计学家 Karl Pearson对上千个家庭的身高、臂长等做了测量，发现：
- 儿子身高（Y，英寸）与父亲身高（X，英寸）存在线性关系

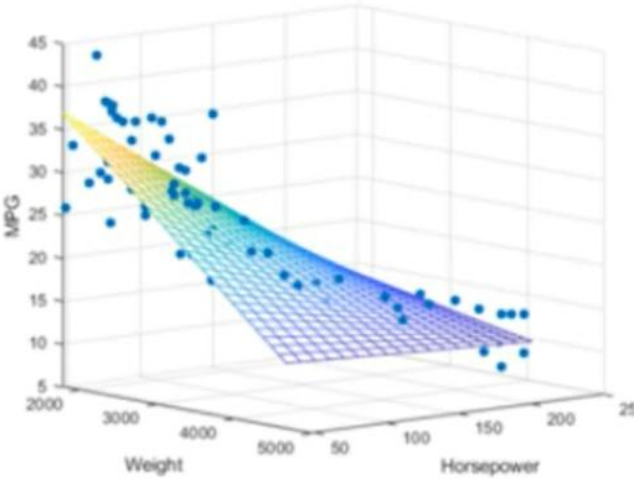
$$\hat{Y} = 33.73 + 0.516X$$

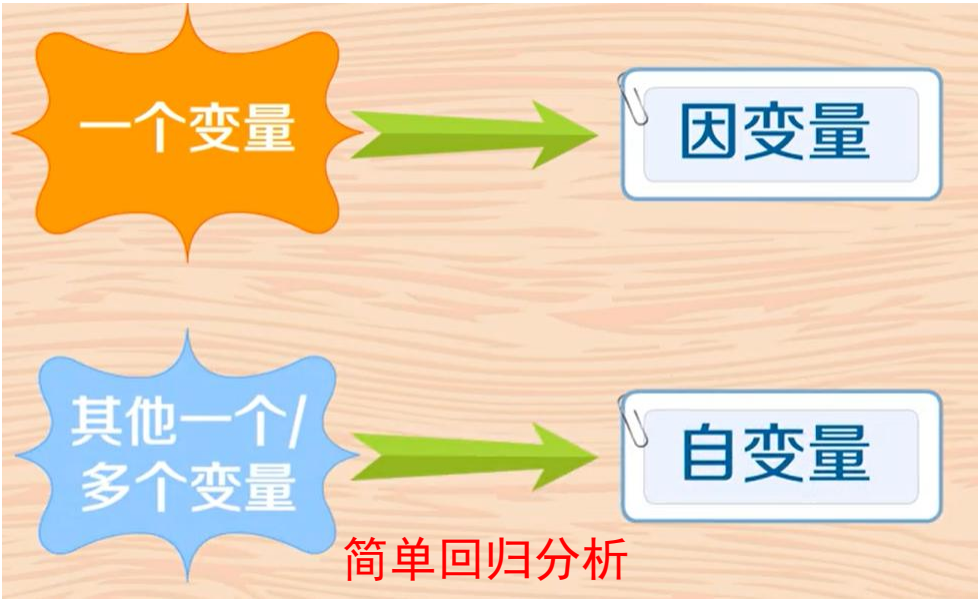


6.1 回归概述

回归分析（regression analysis)指的是确定两种或两种以上变量间相互依赖的定量关系的一种统计分析方法。

- x：自变量
- y：因变量
- 确定y随x的变化情况。





6.1 回归概述

- 按照因变量的多少，可分为简单回归分析和多重回归分析；
- 回归分析按照涉及自变量的多少，分为一元回归和多元回归分析；
- 按照自变量和因变量之间的关系类型，可分为线性回归分析和非线性回归分析。

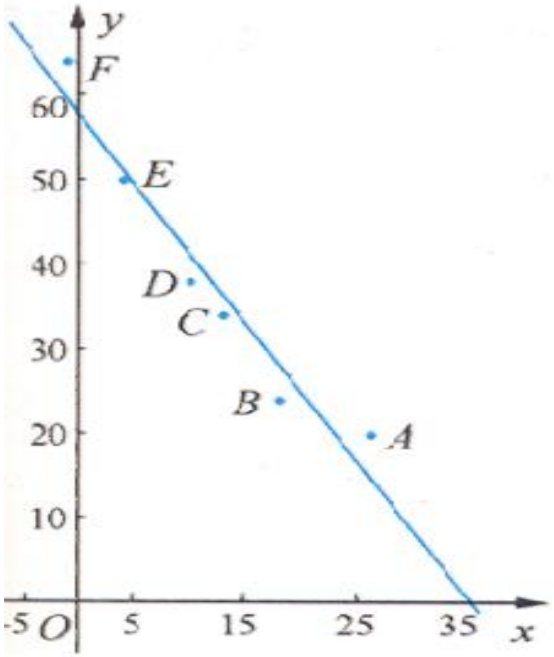
6 回归分析

- 6.1 回归概述
- 6.2 应用案例
- 6.3 线性回归
- 6.4 非线性回归
- 6.5 Logistic回归
- 6.6 评估

6.2 应用案例

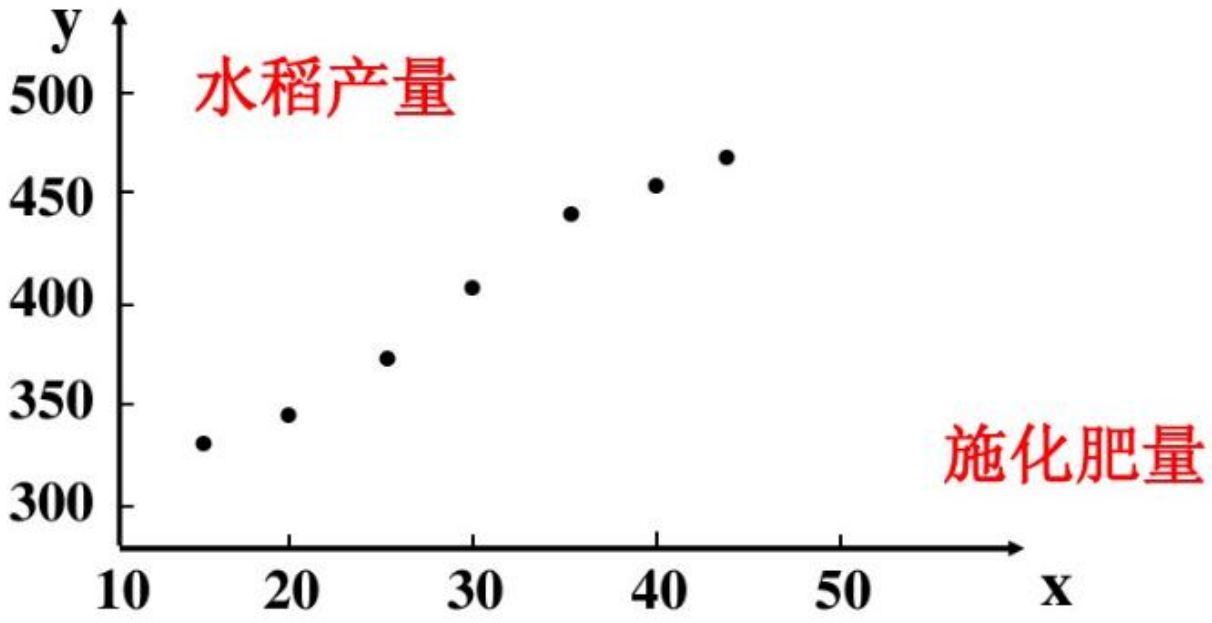
气温与热饮的数据集

气温/^{0}C	26	18	13	10	4	-1
杯数	20	24	34	38	50	64



6.2 应用案例

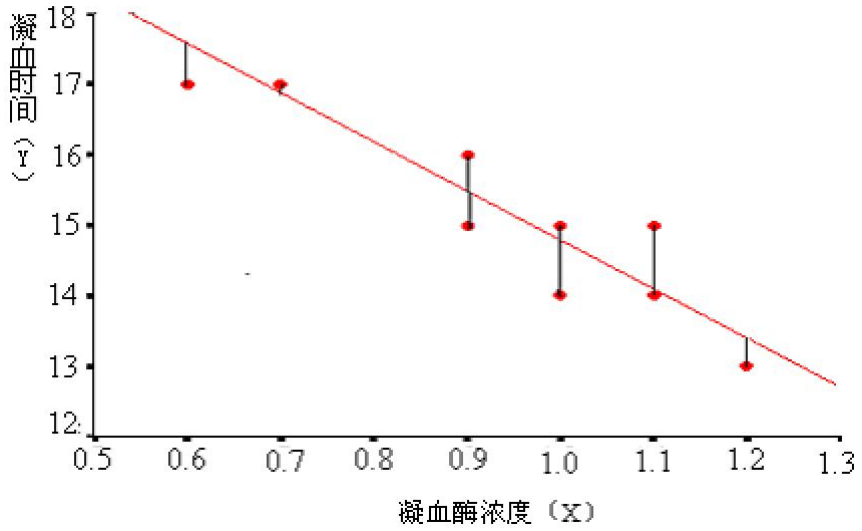
施化肥量x	15	20	25	30	35	40	45
水稻产量y	330	345	365	405	445	450	455



6.2 应用案例

15名健康人凝血酶浓度与凝血时间数据

No.	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
X	1.1	1.2	1.0	0.9	1.2	1.1	0.9	0.6	1.0	0.9	1.1	0.9	1.1	1.0	0.7
Y	14	13	15	15	13	14	16	17	14	16	15	16	14	15	17



6.2 应用案例

年龄预测

通过行为习惯对移动用户人口属性(年龄+性别)进行预测。数据及包含~20万用户数据，分成12组，同时提供了用户行为属性，如:手机品牌、型号、APP的类型等。

device_id	gender	age	group
-8.1E+18	M	35	M32-38
-2.9E+18	M	35	M32-38
-8.3E+18	M	35	M32-38
-4.9E+18	M	30	M29-31
2.45E+17	M	30	M29-31
-1.3E+18	F	24	F24-26
2.37E+17	M	36	M32-38
-8.1E+18	M	38	M32-38
1.77E+17	M	33	M32-38

device_id	phone_brand	device_model
-8.89065E+18	小米	红米
1.27778E+18	小米	MI 2
5.13743E+18	三星	Galaxy S4
3.66946E+18	SUGAR	时尚手机
-5.01928E+18	三星	Galaxy Note 2
3.23801E+18	华为	Mate
-3.88353E+18	小米	MI 2S
-2.9722E+18	华为	G610S
-5.82795E+18	小米	MI One Plus

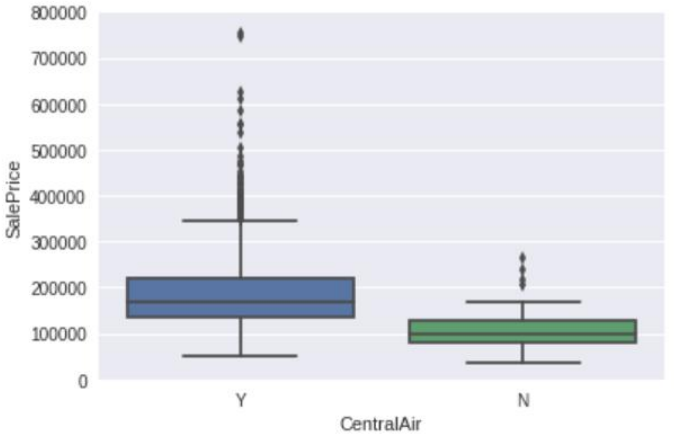
event_id	app_id	is_installed	is_active
2	5.93E+18	1	1
2	-5.7E+18	1	0
2	-1.6E+18	1	0
2	-6.5E+17	1	1
2	8.69E+18	1	1
2	4.78E+18	1	1
2	-8E+18	1	0
2	9.11E+18	1	0
2	-3.7E+18	1	0

6.2 应用案例

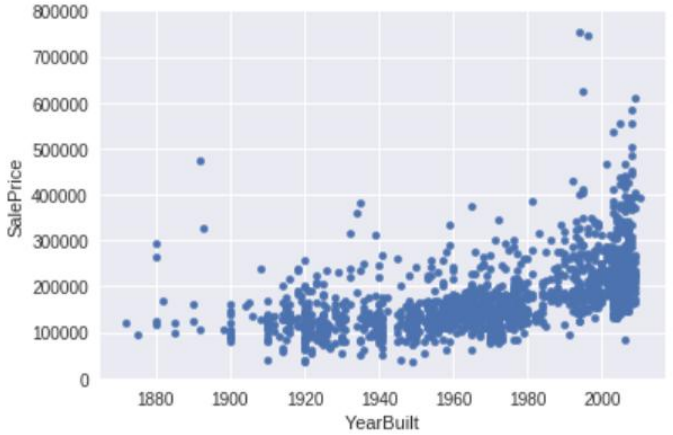
房价预测Kaggle入门项目

https://www.kaggle.com/marsggbo/kaggle/notebook

Variable	Segment	Data Type	Comments
LotArea	1	0	地皮面积
GrLivArea	1	0	生活面积
TotalBsmtSF	1	0	地下室总面积
MiscVal	0	0	其他资产
GarageArea/GarageCars	1	0	车库
YearBuilt	0	1	建造年份
CentralAir	0	1	中央空调
OverallQual	0	1	总体评价
Neighborhood	2	1	地段



中央空调



建造年份

6.2 应用案例

二手车价格预测天池竞赛

https://tianchi.aliyun.com/competition/entrance/231784/information

Field	Description
SaleID	交易ID，唯一编码
name	汽车交易名称，已脱敏
regDate	汽车注册日期，例如20160101，2016年01月01日
model	车型编码，已脱敏
brand	汽车品牌，已脱敏
bodyType	车身类型：豪华轿车：0，微型车：1，厢型车：2，大巴车：3，敞篷车：4，双门汽车：5，商务车：6，搅拌车：7
fuelType	燃油类型：汽油：0，柴油：1，液化石油气：2，天然气：3，混合动力：4，其他：5，电动：6
gearbox	变速箱：手动：0，自动：1
power	发动机功率：范围 [0, 600]
kilometer	汽车已行驶公里，单位万km
notRepairedDamage	汽车有尚未修复的损坏：是：0，否：1
regionCode	地区编码，已脱敏
seller	销售方：个体：0，非个体：1
offerType	报价类型：提供：0，请求：1
creatDate	汽车上线时间，即开始售卖时间
price	二手车交易价格（预测目标）

6.2 应用案例

Kaggle纽约出租车车程用时预测实战

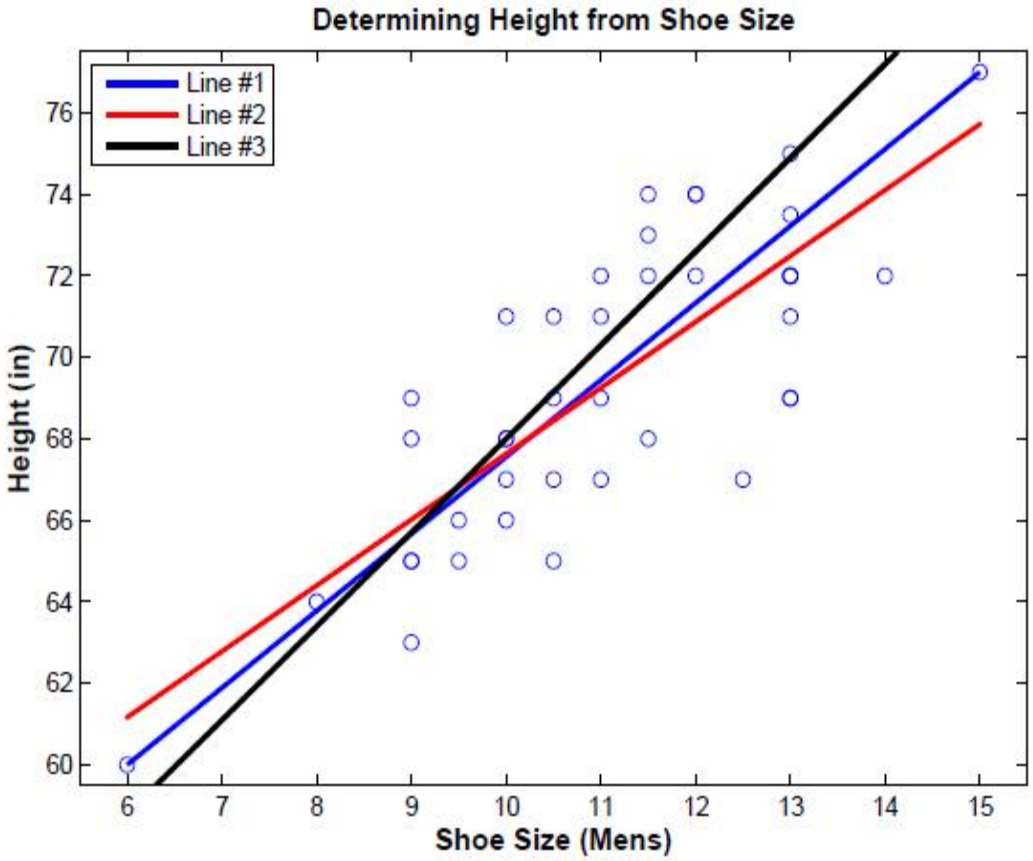
id	vendor_id	pickup_datetime	dropoff_datetime	passenger_	pickup_lon	pickup_lati	dropoff_lo	dropoff_lat	store_and_	trip_duration
id2875421	2	2016/3/14 17:24	2016/3/14 17:32	1	-73.9822	40.76794	-73.9646	40.7656	N	455
id2377394	1	2016/6/12 0:43	2016/6/12 0:54	1	-73.9804	40.73856	-73.9995	40.73115	N	663
id3858529	2	2016/1/19 11:35	2016/1/19 12:10	1	-73.979	40.76394	-74.0053	40.71009	N	2124
id3504673	2	2016/4/6 19:32	2016/4/6 19:39	1	-74.01	40.71997	-74.0123	40.70672	N	429
id2181028	2	2016/3/26 13:30	2016/3/26 13:38	1	-73.9731	40.79321	-73.9729	40.78252	N	435
id0801584	2	2016/1/30 22:01	2016/1/30 22:09	6	-73.9829	40.7422	-73.9921	40.74918	N	443
id1813257	1	2016/6/17 22:34	2016/6/17 22:40	4	-73.969	40.75784	-73.9574	40.7659	N	341
id1324603	2	2016/5/21 7:54	2016/5/21 8:20	1	-73.9693	40.79778	-73.9225	40.76056	N	1551
id1301050	1	2016/5/27 23:12	2016/5/27 23:16	1	-73.9995	40.7384	-73.9858	40.73281	N	255
id0012891	2	2016/3/10 21:45	2016/3/10 22:05	1	-73.981	40.74434	-73.973	40.78999	N	1225
id1436371	2	2016/5/10 22:08	2016/5/10 22:29	1	-73.9827	40.76384	-74.0022	40.73299	N	1274

6 回归分析

- 6.1 回归概述
- 6.2 应用案例
- 6.3 线性回归
- 6.4 非线性回归
- 6.5 Logistic回归
- 6.6 评估

6.3 线性回归

Which line is the *best* estimate?



$$m(x) = \beta_0 + \beta_1 x$$

	β_0	β_1
Line #1	48.6	1.9
Line #2	51.5	1.6
Line #3	45.0	2.3

6.3.1 一元线性回归

$$m(x) = \beta_0 + \beta_1 x$$

RSS残差平方和最小

$$R(\beta_0, \beta_1) = \sum_{i=1}^{n} \left(y_i - \left(\beta_0 + \beta_1 x_i\right)\right)^2$$

$$\frac{\partial R}{\partial \beta_0}\Big|_{=0} \Rightarrow -2\sum_{i=1}^{n}\left(y_i - \left(\beta_0 + \beta_1 x_i\right)\right) = 0$$

$$\Rightarrow \beta_0 = \overline{y} - \beta_1 \overline{x}$$

$$\frac{\partial R}{\partial \beta_1}\Big|_{=0} \Rightarrow -2\sum_{i=1}^{n} x_i\left(y_i - \left(\beta_0 + \beta_1 x_i\right)\right) = 0$$

$$\Rightarrow \sum_{i=1}^{n}\left(x_i y_i - x_i\left(\overline{y} - \beta_1 \overline{x} + \beta_1 x_i\right)\right) = 0$$

$$\Rightarrow \beta_1 = \frac{\sum_{i=1}^{n} x_i y_i - n\overline{x}\,\overline{y}}{\sum_{i=1}^{n} x_i^2 - n\overline{x}^2}$$

6.3.2 多元线性回归

序号	总胆固醇 X_1	甘油三酯 X_2	胰岛素 X_3	糖化血红蛋白 X_4	血糖 Y
1	5.68	1.90	4.53	8.2	11.2
2	3.79	1.64	7.32	6.9	8.8
…	…	…	…	…	…
26	5.84	0.92	8.61	6.4	13.3
27	3.84	1.20	6.45	9.6	10.4

6.3.2 多元线性回归

$$m(x_i) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \ldots + \beta_p x_{id} = \beta_0 + \sum_{k=1}^{d} \beta_k x_{ik}$$

$$\sum_{i}^{n} m(x_i) = \beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + \ldots + \beta_d x_{1d}$$
$$+ \beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + \ldots + \beta_d x_{2d}$$
$$+ \ldots$$
$$+ \beta_0 + \beta_1 x_{n1} + \beta_2 x_{n2} + \ldots + \beta_d x_{nd}$$

$$= \sum_{i=1}^{n} \left(\beta_0 + \sum_{k=1}^{d} \beta_k x_{ik} \right)$$

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1d} \\ 1 & x_{21} & \cdots & x_{2d} \\ \cdots & \cdots & \cdots & \cdots \\ 1 & x_{n2} & \ldots & x_{nd} \end{bmatrix} \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \cdots \\ \beta_d \end{bmatrix}$$

6.3.2 多元线性回归

$$R(\beta)=\left(Y-X\beta\right)^T\left(Y-X\beta\right)$$

$$\frac{\partial R}{\partial \beta}\Big|_{=0} \Rightarrow \frac{\partial}{\partial \beta}\left(Y^TY-Y^TX\beta-\beta^TX^TY+\beta^TX^TX\beta\right)\Big|_{=0}$$

$$\Rightarrow X^TX\beta=X^TY$$

$$\beta=\left(X^TX\right)^{-1}X^TY$$

6.3.2 多元线性回归

$$\beta = \left(X^T X\right)^{-1} X^T Y$$

- $(X^T X)^{-1}$不可逆时无法求出β
- $X^T X$越趋近于0，会使得回归系数趋向于无穷大，此时得到的回归系数是无意义的
  - 岭回归

$$R(\beta) = \left(Y - X\beta\right)^T \left(Y - X\beta\right) + \lambda \left\|\beta\right\|_2$$

  - Lasso回归

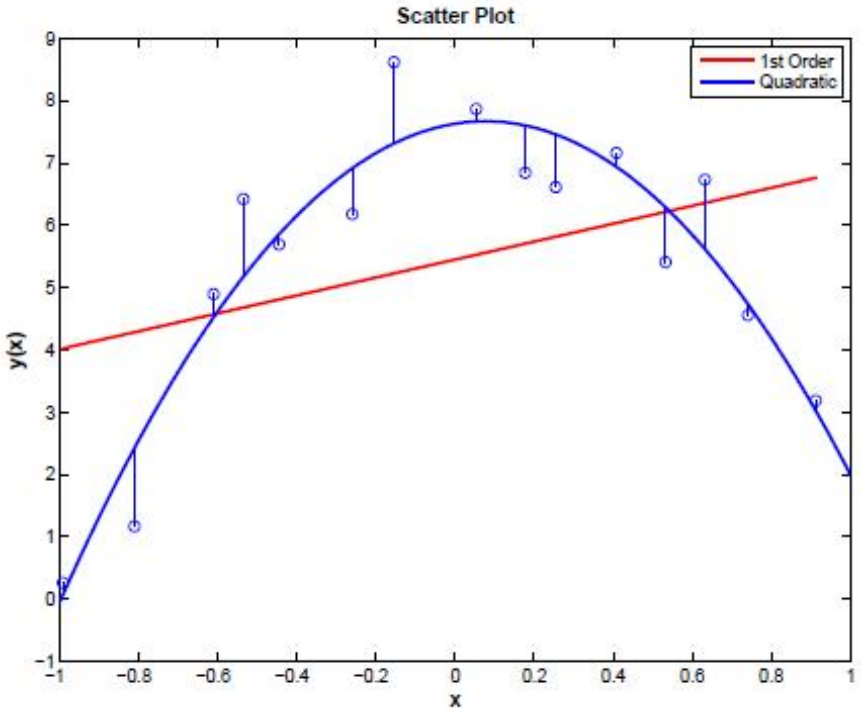
$$R(\beta) = \left(Y - X\beta\right)^T \left(Y - X\beta\right) + \lambda \left\|\beta\right\|_1$$

6.3.3 多项式回归

- 有时候只用一条直线是不充分的。
- 多项式回归Polynomial Regression

$$m(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2^2 + \ldots + \beta_d x_d^d = \beta_0 + \sum_{k=1}^{d} \beta_k x_{ik}^k$$

- 注意过拟合



6.3.3 多项式回归

$$m(x_i) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2}^2 + \ldots + \beta_d x_{id}^d = \beta_0 + \sum_{k=1}^{d} \beta_k x_{ik}^k$$

$$\sum_{i}^{n} m(x_i) = \beta_0 + \beta_1 x_{11} + \beta_2 x_{12}^2 + \ldots + \beta_d x_{1d}^d$$

$$+ \beta_0 + \beta_1 x_{21} + \beta_2 x_{22}^2 + \ldots + \beta_d x_{2d}^d$$

$$+ \ldots$$

$$+ \beta_0 + \beta_1 x_{n1} + \beta_2 x_{n2}^2 + \ldots + \beta_d x_{nd}^d$$

$$= \sum_{i=1}^{n} \left(\beta_0 + \sum_{k=1}^{d} \beta_k x_{ik}^k \right)$$

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 & x_{11} & \ldots & x_{1p}^p \\ 1 & x_{21} & \ldots & x_{2p}^p \\ \ldots & \ldots & \ldots & \ldots \\ 1 & x_{n2} & \ldots & x_{np}^p \end{bmatrix} \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \ldots \\ \beta_d \end{bmatrix}$$

$$R(\beta) = (Y - X\beta)^T (Y - X\beta)$$

6.3.4 如何减少过拟合风险

向量的L1范数与L2范数

L1范数：表示向量中每个元素绝对值的和

$$||x||_1 = \sum_{i=1}^{n} |x_i|$$

L2范数：欧氏距离

$$||x||_2 = \sqrt{\sum_{i=1}^{n} x_i^2}$$

L2范数越小，可以使得w的每个元素都很小，接近于0，但L1范数不同的是他不会让它等于0而是接近于0.

6 回归分析

- 6.1 回归概述
- 6.2 应用案例
- 6.3 线性回归
- 6.4 非线性回归
- 6.5 Logistic回归
- 6.6 评估

6.4 非线性回归

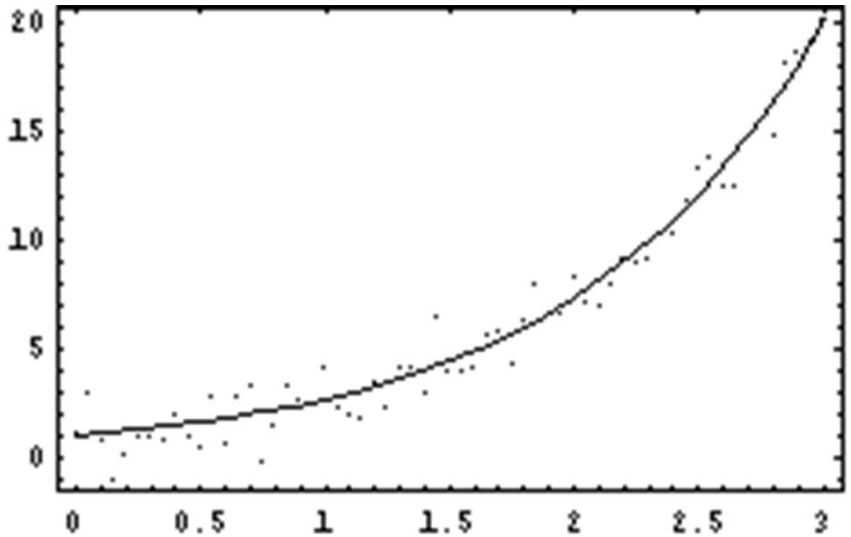
指数函数模型$y_i = ae^{bx_i+u_i}$

对上式等号两侧同取自然对数，得

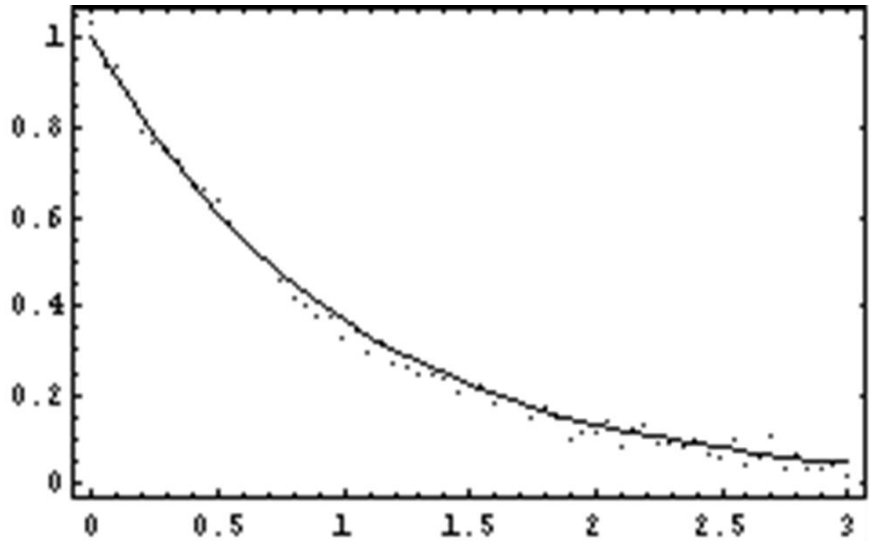
$$\ln y_i = \ln a + bx_i + u_i$$

令$\ln y_i = y_i^*$, $\ln a = a^*$ 则 $y_i^* = a^* + bx_i + u_i$

变量y_i^* 和x_i已变换成为线性关系。其中u_i表示随机误差项。



$b > 0$



$b < 0$

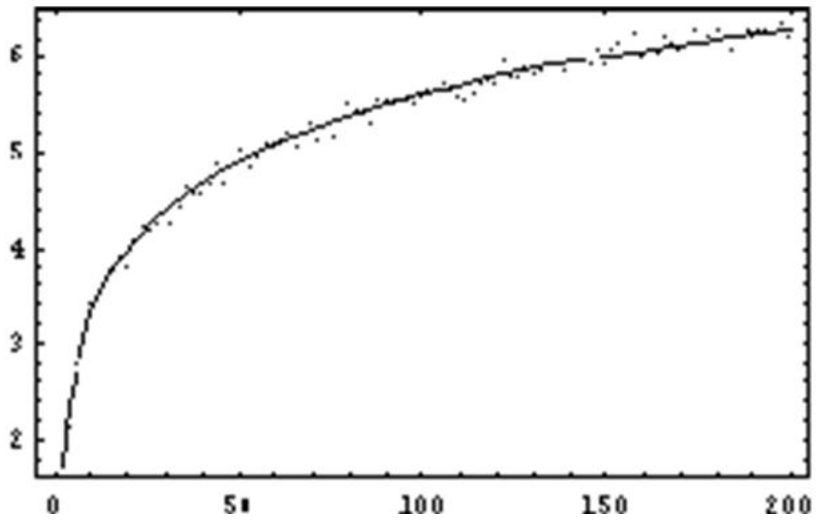
6.4 非线性回归

对数函数模型$y_i = a + \mathrm{b}\ln x_i + u_i$

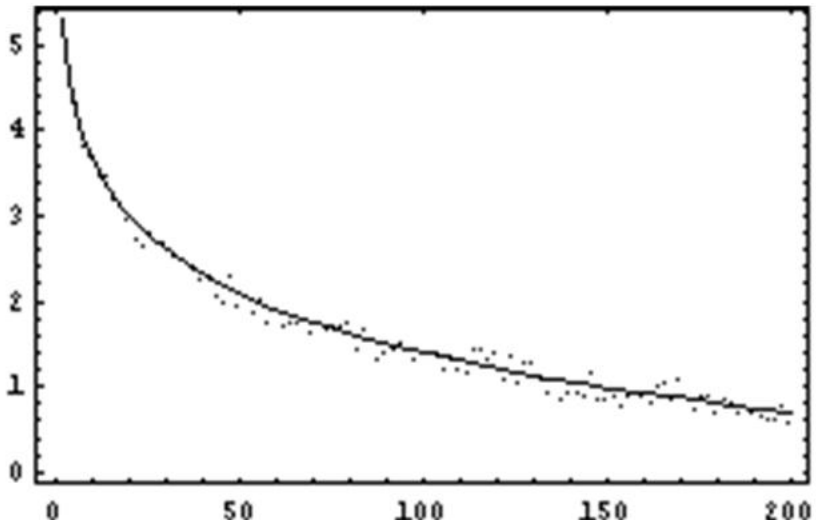
令$x_i^* = \ln x_i$, 则

$$y_i = a + b\,x_i^* + u_i$$

变量y_i 和x_i^* 已变换成为线性关系。



$b > 0$



$b < 0$

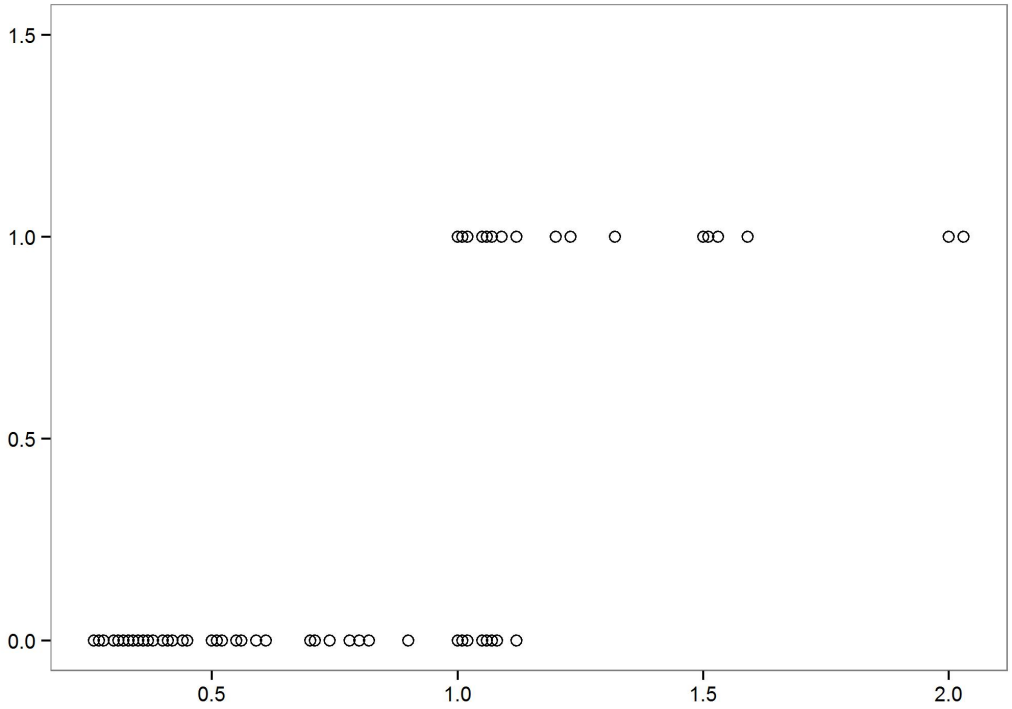
6 回归分析

- 6.1 回归概述
- 6.2 应用案例
- 6.3 线性回归
- 6.4 非线性回归
- 6.5 Logistic回归
- 6.6 评估

6.5 Logistic回归

$$y \in \{0, 1\}$$

$$y \sim \mathbf{X}?$$



6.5 Logistic回归

假设：

$$\begin{cases} P(y=1)=p \\ P(y=0)=1-p \end{cases}$$

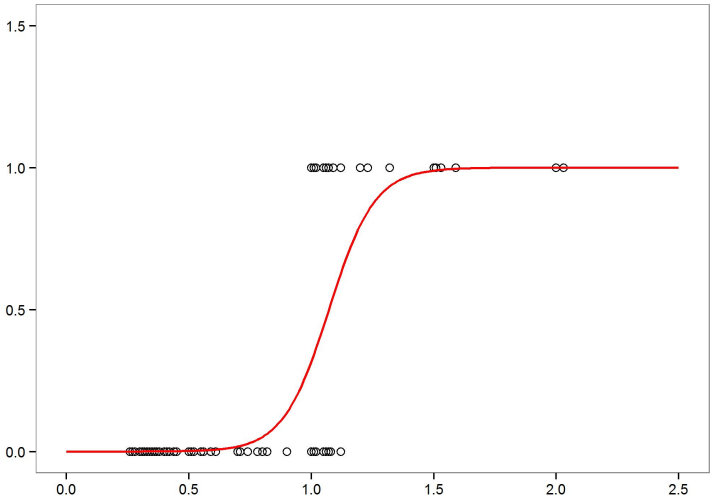
$$p=\frac{1}{1+e^{-(\beta_0+\beta_1 x_1+\beta_2 x_2+\ldots+\beta_d x_d)}}$$

$$\ln\left(\frac{p}{1-p}\right)=\beta_0+\beta_1 x_1+\beta_2 x_2+\ldots+\beta_d x_d$$

对数似然值：

$$L(\boldsymbol{\beta})=\frac{1}{n}\sum_{i=1}^{n}\log p\left(y^{(i)};\boldsymbol{\beta}\right)$$

$$\max(L)$$



6 回归分析

- 6.1 回归概述
- 6.2 应用案例
- 6.3 线性回归
- 6.4 非线性回归
- 6.5 Logistic回归
- 6.6 评估

6.6 评估

- 均方误差：MSE（Mean Squared Error）

$$MSE = \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2$$

- 均方根误差：RMSE（Root Mean Squared Error）

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2}$$

- 平均绝对误差：MAE（Mean Absolute Error）

$$MAE = \frac{1}{n}\sum_{i=1}^{n}\left|y_i - \hat{y}_i\right|$$

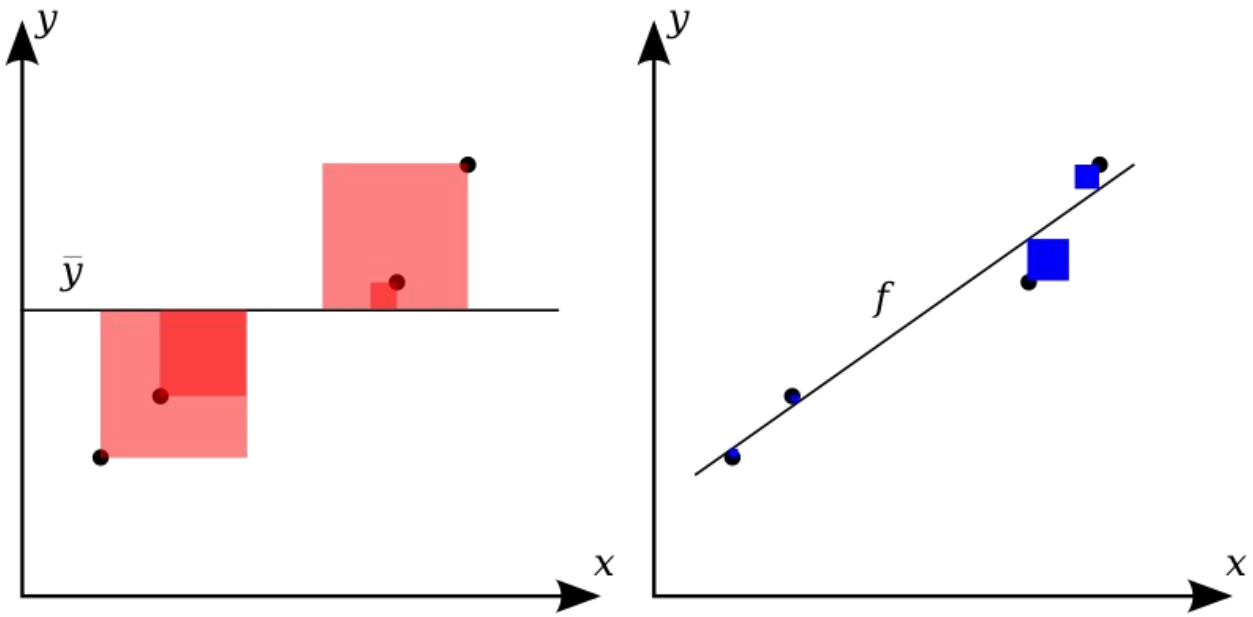
6.6 评估

- 总离差平方和

Sum of Squares Total : $SST = \sum_{i=1}^{n} \left(y_i - \overline{y}\right)^2$

- 回归残差平方和

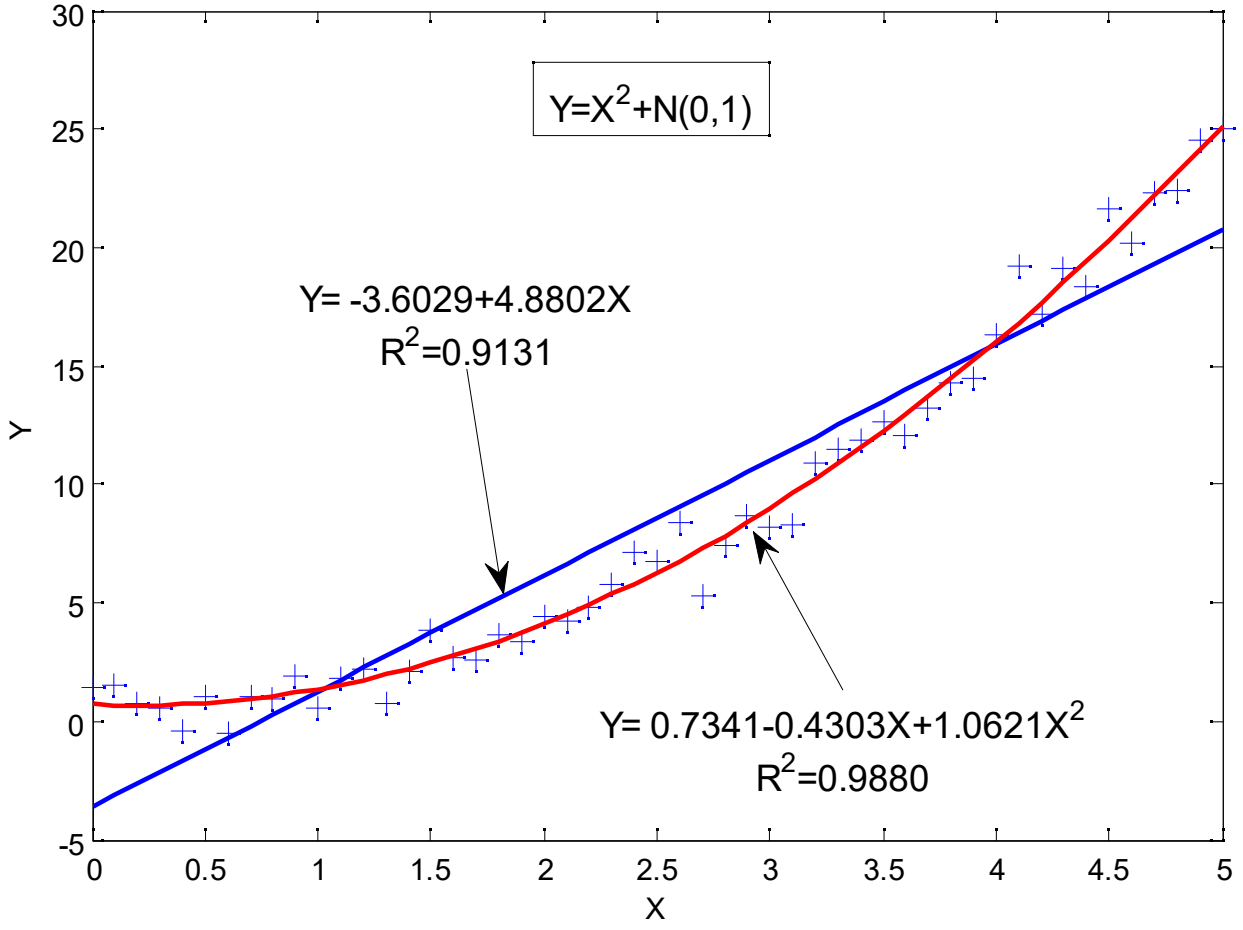
Sum of Squares Error : $SSE = \sum_{i=1}^{n} \left(y_i - \hat{y}_i \right)^2$



6.6 评估

- 决定系数：R^2（R-Square）

$$R^2 = \frac{SST - SSE}{SST} = 1 - \frac{SSE}{SST}$$



天津大学
Tianjin University

THE END

