天津大学
Tianjin University

数据挖掘

杨柳

智能与计算学部

yangliuyl@tju.edu.cn

自我介绍

- 邮箱：yangliuyl@tju.edu.cn
- 实验室：机器学习与数据挖掘
- 方向：社会化机器学习
- 国创赛（互联网+）、挑战杯指导教师
- 办公室：55楼B513

课程相关信息

- 40学时 （24学时授课，16学时上机实验）
- 4-11周（杨柳4-7周，王煜8-11周）
- 平时成绩：考勤、平时作业、实验报告等
- 智慧树： k1001726
- 答疑时间：55楼B513、B519（提前预约）、微信随时

应用场景

	1	2	3	4	5	6
A	4	3			5	
B	5		4		4	
C	4		5	3	4	
D		3				5
E		4				4
F			2	4		5

智能推荐

应用场景

移动设备用户年龄和性别预测

特征字段	字段描述
device_id	用户对应设备号，唯一表示，无重复
gender	用户性别，0为男性，1为女性
age	用户年龄
phone_brand	手机品牌
device_model	手机型号
event_id	事件id
app_id	应用程序id
is_installed	是否安装
is_active	是否激活
tag_list	应用程序的标签列表
date	事件发生日期

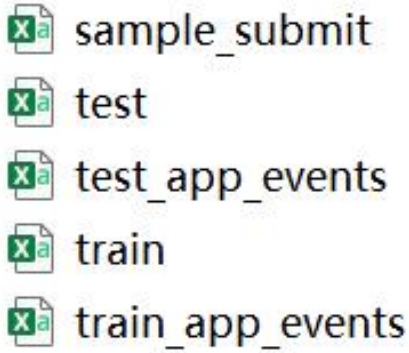

device_id	gender	age	phone_bra	device_model
0	0	35	0	0
1	1	37	1	1
2	0	32	1	2
3	1	28	1	2
4	0	75	2	3
5	0	25	0	4
6	0	27	3	5

event_id	app_id	is_installed	is_active	device_id	tag_list	date
280934	224	1	0	1	[1012]	4
280934	375	1	1	1	[713, 704, 548, 756, 761, 777, 782, 787, 25	4
280934	1	1	1	1	[713, 704, 548]	4
280934	458	1	1	1	[549, 713, 724, 548, 704, 130]	4
280934	2	1	0	1	[549, 710, 704, 548, 172]	4

应用场景

增强子与 RNA 表达的数据预处理

DRAKES / Gosai 数据案例：200 bp DNA 序列与三种细胞的 MPRA 表达活性

735,156 条原始输入记录

原始 ID	染色体	DNA 序列（前 24 bp，完整长度 200 bp）	HepG2	K562	SK-N-SH
0	chr7	CCTGGTCTTTCTTGCTAAATAAAC…	0.2336	0.0608	0.0472
1	chr1	CATAAAGATGAGGCTTGGCAAAGA…	0.0046	0.3796	-0.2444
2	chr1	CATAAAGCCAATCACTGAGATGAC…	0.3845	0.0367	-0.0046
3	chr15	CATAAAGGCAGTGTAGACCCAAAC…	4.1165	4.5088	3.0402

特征字段	字段描述
source_row_id	原始记录编号，用于追溯来源；对应原始文件中无列名的第一列
chrom	序列所在染色体，如 chr1、chr7
seq	完整 DNA 序列，长度为 200 bp
hepg2	序列在 HepG2 细胞中的 MPRA 活性，以 log2FC 表示
k562	序列在 K562 细胞中的 MPRA 活性，以 log2FC 表示
sknsh	序列在 SK-N-SH 细胞中的 MPRA 活性，以 log2FC 表示
gc_fraction	G、C 碱基占序列的比例，预处理新增
k3_AAA ～ k3_TTT	64 种三核苷酸组合的频率，共 64 列，预处理新增

数据来源：Gosai et al. RegLM, Nature, 2024；项目与方法来源：Wang et al. Drakes, ICLR, 2025

应用场景

BCI（非侵入式脑机接口）情感预测

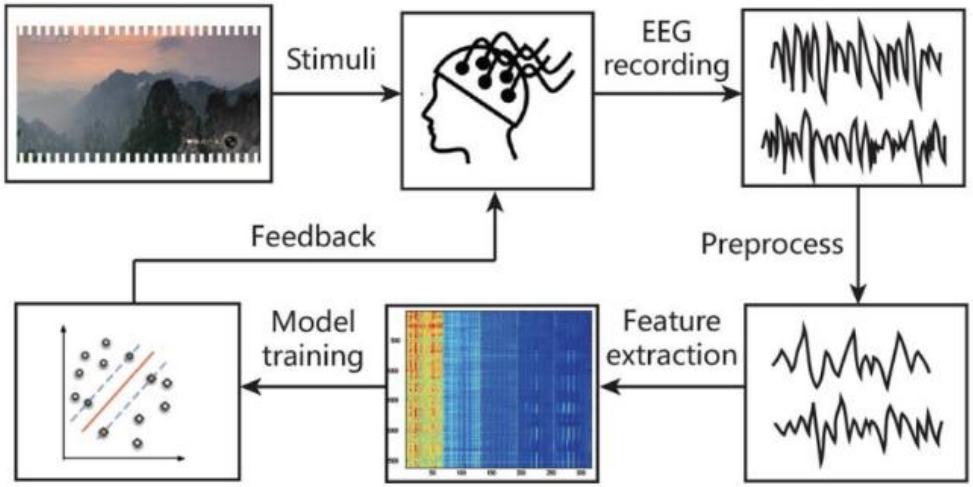

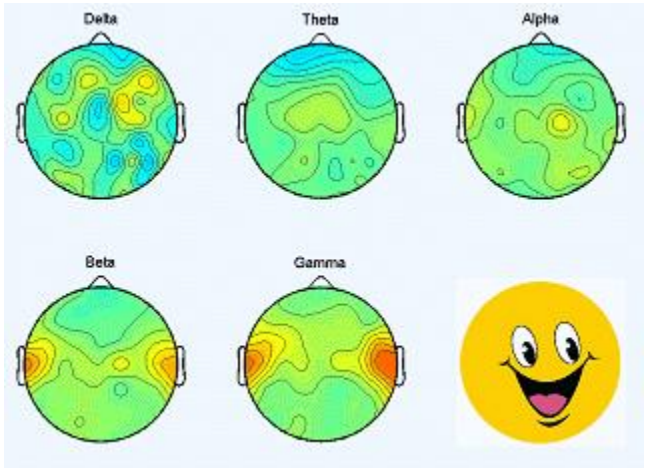

No.	Emotion label	Film clips sources
1	negative	Tangshan Earthquake
2	negative	Back to 1942
3	positive	Lost in Thailand
4	positive	Flirting Scholar
5	positive	Just Another Pandora's Box
6	neutral	World Heritage in China

情感和刺激来源图

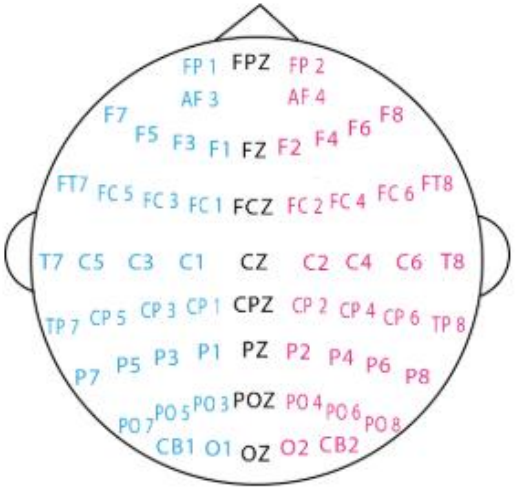

电极位置分布图

应用场景

基于交易图的金融反欺诈与反洗钱

Elliptic 数据案例：比特币交易节点、资金流关系与合法 / 非法标签

203,769 笔交易 · 234,355 条资金流 · 49 个时间步

图数据对象	规模	主要内容	挖掘作用
交易节点	203,769	时间、输入输出数、手续费、金额	待识别主体
资金流边	234,355	BTC 从一笔交易流向下一笔	刻画账户关联
节点特征	166 维	94 个局部特征 + 72 个邻域聚合特征	风险分类输入
交易标签	约 2% 非法	合法约 21%，其余为未知标签	监督学习目标

关键字段

local_features 交易时间、输入输出数、手续费、转账金额等 94 个局部特征

aggregated_features 对一跳邻居统计最大值、最小值、标准差等，共 72 个特征

label licit、illicit、unknown，用于训练交易风险分类模型

挖掘流程

①交易清洗 ②构建资金流图 ③提取局部与邻域特征 ④分类并人工复核

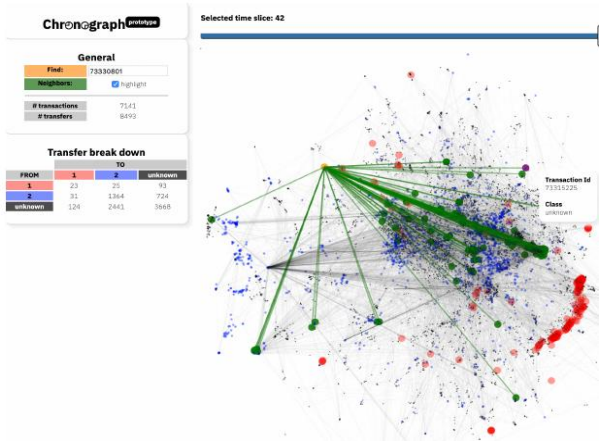

交易图可视化：红色为非法交易，蓝色为合法交易

数据与图片来源：Weber et al., Anti-Money Laundering in Bitcoin, KDD-ADF, 2019；方法综述：Cheng et al., 2024

教材

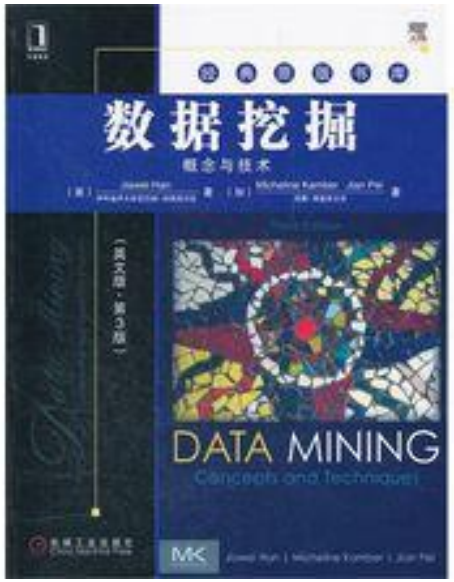

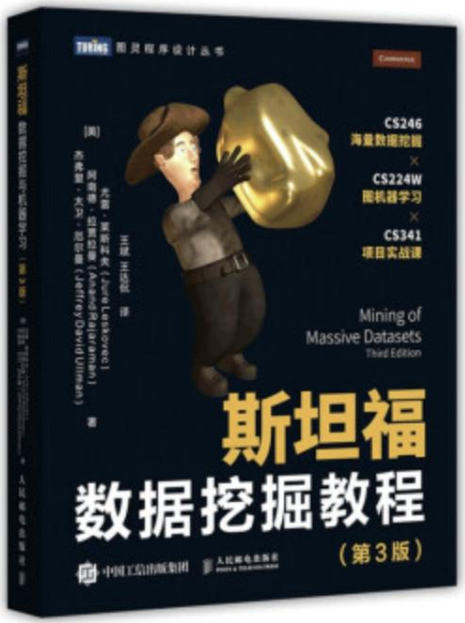

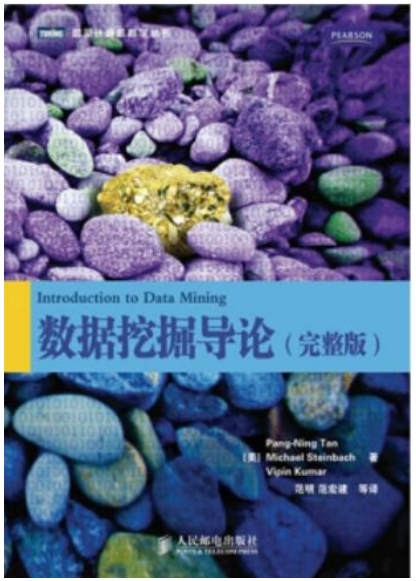

数据挖掘概念与技术（第3版），Jiawei Han等著. 范明等译，机械工业出版社，2012

斯坦福数据挖掘教程（第3版），Jure Leskovec等著. 王斌等译，中国工信出版集团，2021

数据挖掘导论，Pang-Ning Tan等著. 范明等译，人民邮电出版社，2020

数据挖掘科学家

世界顶尖1000名计算机科学家排名

韩家炜是唯一一位进入Top5的华人学者，他是美国伊利诺伊大学香槟分校计算机系教授，IEEE和ACM会士，2009 年获得了麦克道尔奖，这是 IEEE 颁发的最高技术奖。

在数据挖掘领域，韩家炜教授认为要想将现有的无结构的大数据变成有用的知识，首先要做的就是将数据结构化，因为杰出贡献而被冠以「数据挖掘领头人」。

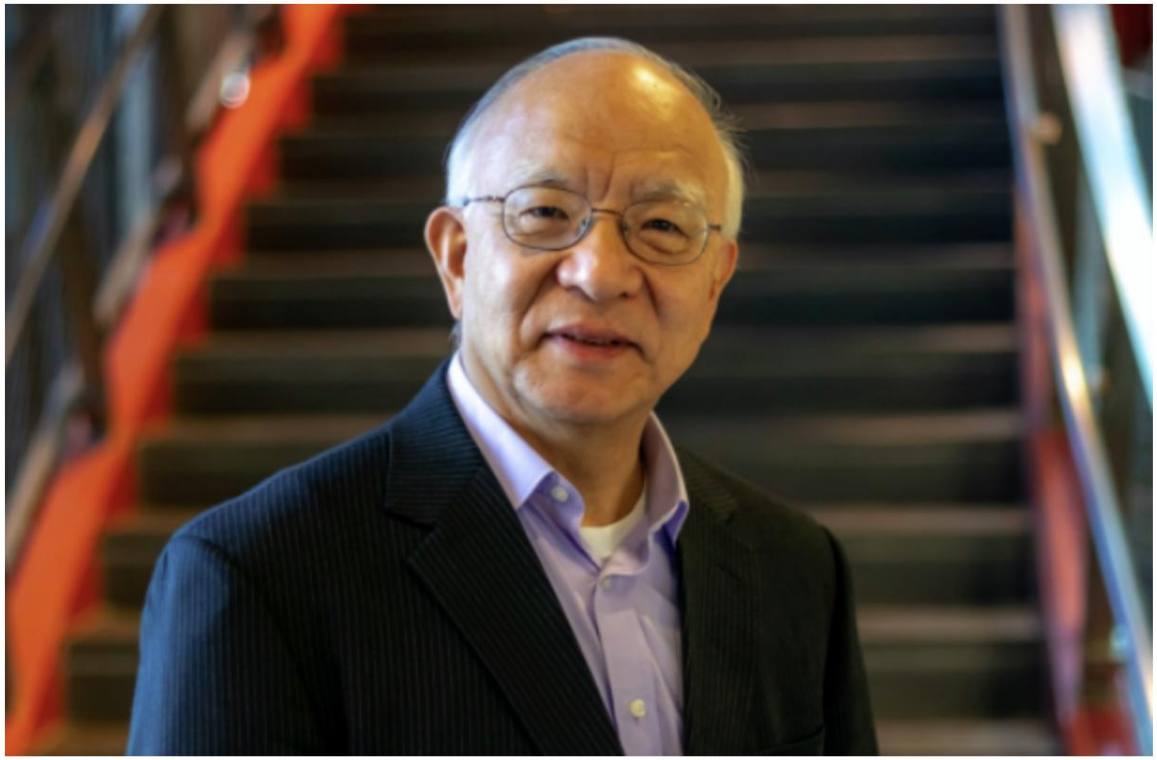

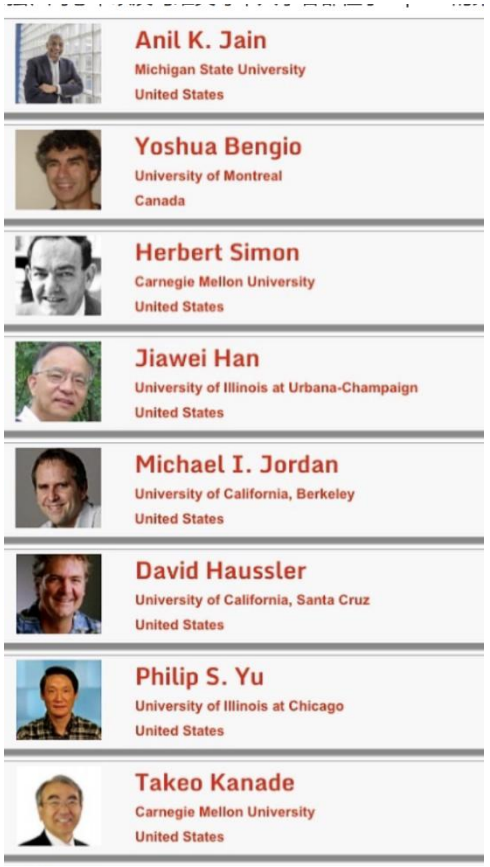

学习资源

- https://www.bilibili.com/video/BV154411Q7mG?p=1

  清华大学深圳研究生院-袁博老师-国家级精品课

- Some lecture notes are adopted from:
  - Jiawei Han (UIUC)

  http://hanj.cs.illinois.edu/bk3/
  - Pang-Ning Tan, Michigan State University

  https://www-users.cs.umn.edu/~kumar001/dmbook/index.php

学习资源——数据库/数据挖掘

ACM Transactions on Database Systems	TODS	期刊
ACM Transactions on Information Systems	TOIS	期刊
IEEE Transactions on Knowledge and Data Engineering	TKDE	期刊
The VLDB Journal	VLDBJ	期刊
ACM Conference on Management of Data	SIGMOD	会议
ACM Knowledge Discovery and Data Mining	SIGKDD	会议
IEEE International Conference on Data Engineering	ICDE	会议
International Conference on Research on Development in Information Retrieval	SIGIR	会议
International Conference on Very Large Data Bases	VLDB	会议

学习资源——人工智能

Artificial Intelligence	AI	期刊
IEEE Trans on Pattern Analysis and Machine Intelligence	TPAMI	期刊
International Journal of Computer Vision	IJCV	期刊
Journal of Machine Learning Research	JMLR	期刊
AAAI Conference on Artificial Intelligence	AAAI	会议
Annual Conference on Neural Information Processing Systems	NeurIPS	会议
Annual Meeting of the Association for Computational Linguistics	ACL	会议
IEEE Conference on Computer Vision and Pattern Recognition	CVPR	会议
International Conference on Computer Vision	ICCV	会议
International Conference on Machine Learning	ICML	会议
International Joint Conference on Artificial Intelligence	IJCAI	会议

学习资源

kaggle

Kaggle 竞赛宝典

UCI Machine Learning Repository

阿里云 | TIANCHI 天池

KDnuggets™

飞桨

数据挖掘领域的十大经典算法ICDM'06

- #1: C4.5 (61 votes) (分类)
- #2: K-Means (60 votes) (聚类)
- #3: SVM (58 votes) (分类)
- #4: Apriori (52 votes) (关联规则)
- #5: EM (48 votes)
- #6: PageRank (46 votes)
- #7: AdaBoost (45 votes)
- #7: kNN (45 votes) (分类)
- #7: Naive Bayes (45 votes) (分类)
- #10: CART (34 votes) (分类)

常用的工具

Kaggle 发布了数据科学和机器学习工具调查结果

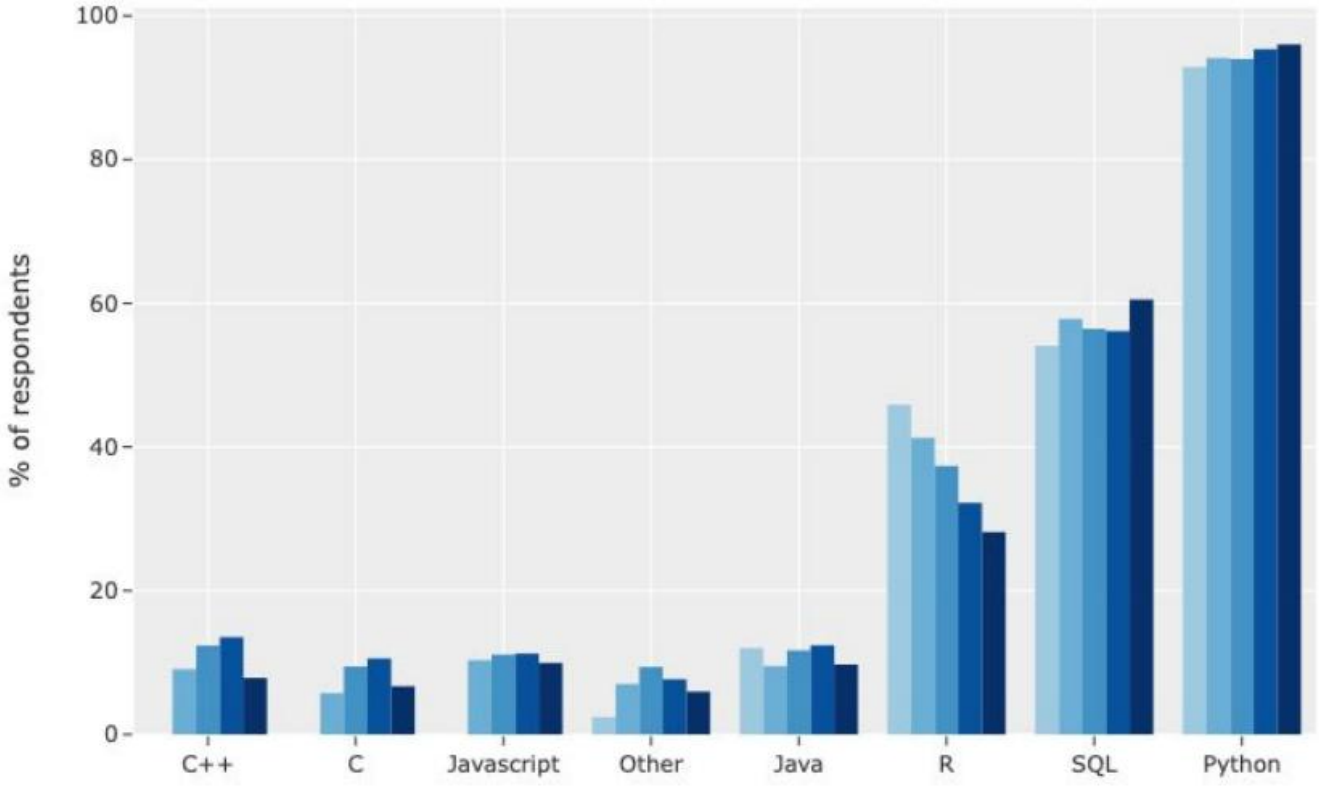

Python成为使用最多的工具，并逐年稳步增长

目标

- 课程目标
  - 基本概念与方法
  - 数据分析的完整流程（what, why, how）
  - 实施和使用数据挖掘方法的经验
- 学习目标
  - 能够实现和应用数据挖掘技术来解决问题
  - 了解数据挖掘的主要问题和核心问题
  - 掌握数据挖掘的研究思路和实践
- 结课目标
  - 对数据挖掘领域有深入了解
  - 有效沟通的能力
  - 独立性和团队精神

第 1 章　概述

主要目标

重点掌握：

- 数据挖掘的概念
- 数据挖掘的任务
- 挖掘过程

1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.1 背景

- 二十世纪末以来，全球信息量以惊人的速度急剧增长——据估计，每二十个月将增加一倍。许多组织机构的IT系统中都收集了大量的数据（信息）。
- 数据的爆炸性增长：从TB到PB
  - 数据的收集和数据的可获得性
    - 自动数据收集工具、数据库系统、WEB、计算机化的社会
  - 丰富数据的来源
    - 商业：WEB、电子商务、交易数据、股市...
    - 科学：遥感、生物信息学、科学模拟
    - 社会及每个人：新闻、数码相机、微信、抖音
- 数据库系统虽然可以高效地实现数据的录入、查询、统计等功能，但无法发现数据中存在的关系和规则，无法根据现有的数据预测未来的发展趋势。

1.1 背景

- 我们被数据所淹没，但却渴望知识
- 为了充分利用现有信息资源，从海量数据中找出隐藏的知识，数据挖掘技术应运而生并显示出强大的生命力。
- 数据挖掘：海量数据的自动分析技术

1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.2.1 数据相关的基本概念

- 1.2.1 数据相关的基本概念
  - 数据
  - 信息
  - 知识
  - 智慧
- 1.2.2 数据挖掘定义

1.2.1 数据相关的基本概念

- 数据
- 信息
- 知识
- 智慧

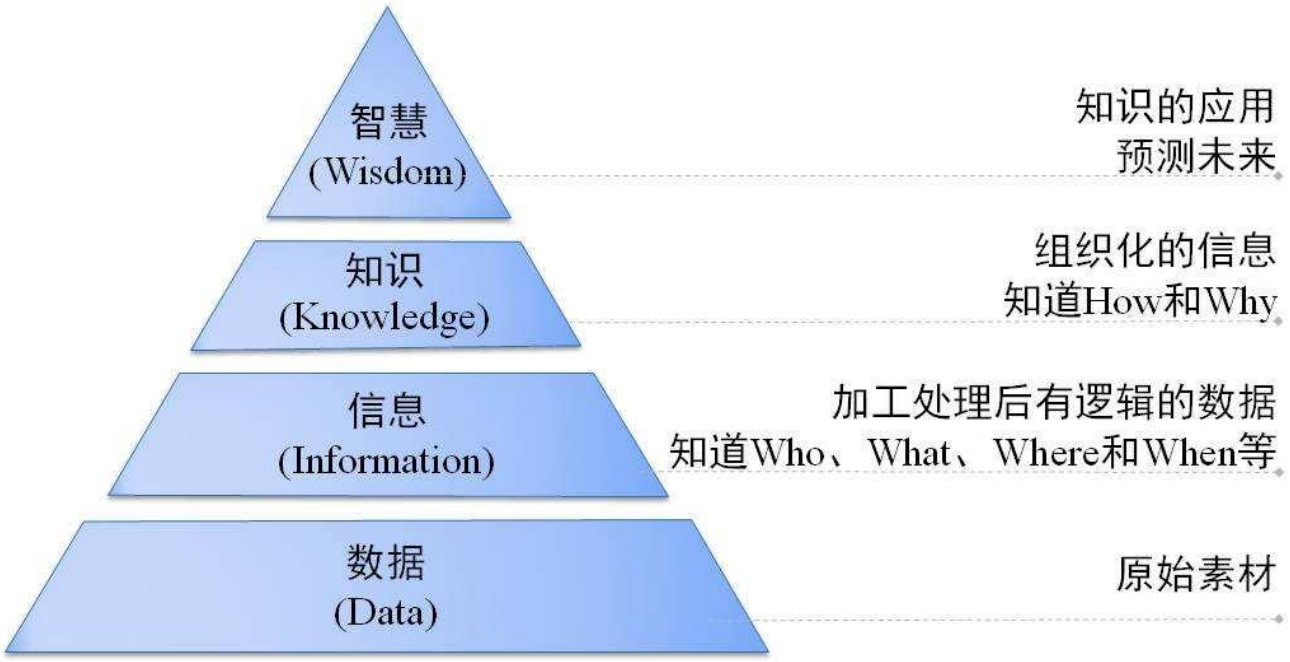

1.2.1 数据相关的基本概念

Fruit
important
ingredient
Nutritional value

An apple a day
keeps the doctor
away

数据 → 信息 → 知识 → 智能

CD player. CD. music book
CD. CD player
CD. music book
CD player . CD. food
Food. Clothes
CD player . CD

If buy CD
players,
then likely buy
CDs

sale on CD players,
raise the sell of CDs

1.2.1.1 数据

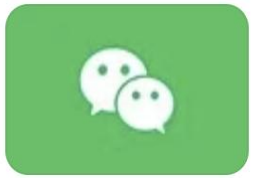

HUAWEI

照明电器
红外控制
Zigbee
开关插座
环境检测
Wi-Fi
蓝牙
开放网关
3/4g
局域网
影音娱乐
安防监控
云
RF433
RF315
环境调节
厨房电器
卫浴电器

收银台

VISA
Maestro
DEBIT CARD
VISA

1.2.1.1 数据

文本

Chapter 4

Painted Faces and Long Hair

Roger and Maurice are walking through a group of littluns, kicking over the things they've made in the sand. They split off, and Roger hides behind a palm tree watching a littlun playing by the water. He begins throwing rocks at the littlun, but he aims to miss, because "the taboos of the old world" are still with him.

Jack comes up behind Roger and asks him to come watch as he puts on a "mask" of painted camouflage in order to hunt pigs better. As Jack smears the clay on his face, the mask is "...a thing on its own, behind which Jack hid, liberated from shame and self-consciousness." The mask allows Jack to not worry about rescue and what he knows is right. Behind it he can do what he likes.

Later, Ralph and the rest of the boys are swimming in the bathing pool and smoke is spotted on the horizon. Ralph looks to the mountain top, but the signal fire has gone out. Running up to the summit, with the others following, Ralph reaches the top and the fire is dead-the watchers absent from duty.

Jack and a crowd of hunters move up to the summit, carrying a dead pig. The hunters are excited about their first kill and begin to explain it all to Ralph. None of them care that the fire

视频

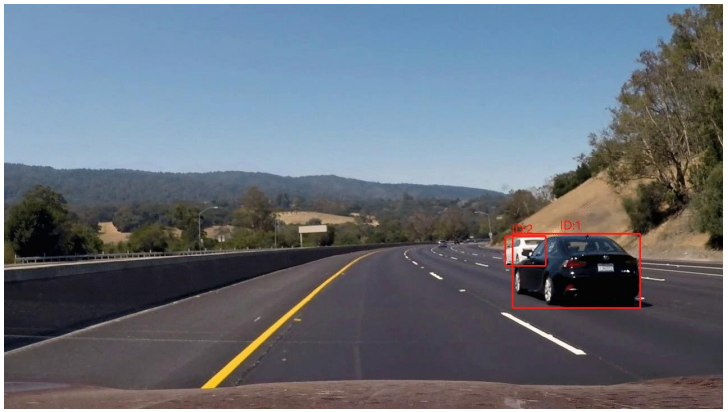

记录

TID	Items
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

event_id	app_id	is_installed	is_active	device_id	tag_list	c
280934	224	1	0	1	[1012]	
280934	375	1	1	1	[713, 704, 548, 756, 761, 777, 782, 787, 25	
280934	1	1	1	1	[713, 704, 548]	
280934	458	1	1	1	[549, 713, 724, 548, 704, 130]	
280934	2	1	0	1	[549, 710, 704, 548, 172]	
280934	3	1	1	1	[548, 549]	
280934	48	1	0	1	[178]	
280934	764	1	0	1	[717, 721, 548, 704]	
280934	6	1	1	1	[302, 303]	

1.2.1.1 数据

- 数据
  - 数据是指对客观事件进行记录并可以鉴别的符号，是对客观事物的性质、状态以及相互关系等进行记载的物理符号或这些物理符号的组合。
  - 数据可能存储在数据库、数据仓库和其他信息资料库中。
- 类型
  - 连续型：数值
  - 离散型：标称、二元
  - 符号、字符
- 主要问题
  - 不一致、错误、缺失 等

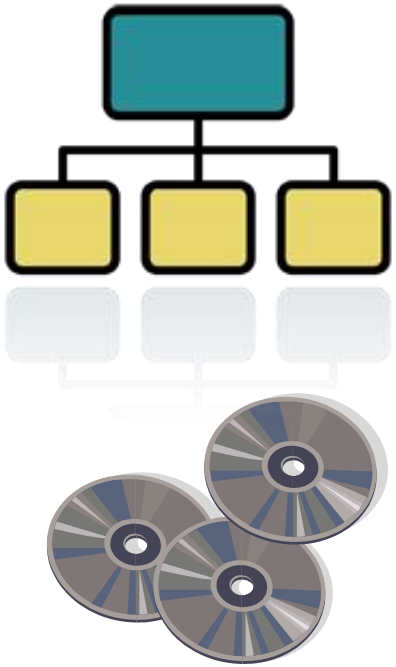

1.2.1.2 信息

- 信息是具有时效性的，有一定含义的，有逻辑的、经过加工处理的、对决策有价值的数据流。

	Data	Information
Meaning	Data is raw, unorganized facts that need to be processed. Data can be something simple and seemingly random and useless until it is organized.	When data is processed, organized, structured or presented in a given context so as to make it useful, it is called information.
Example	Each student's test score is one piece of data.	The average score of a class or of the entire school is information that can be derived from the given data.
Etymology	"Data" comes from a singular Latin word, datum, which originally meant "something given." Its early usage dates back to the 1600s. Over time "data" has become the plural of datum.	"Information" is an older word that dates back to the 1300s and has Old French and Middle English origins. It has always referred to "the act of informing, " usually in regard to education, instruction, or other knowledge communication.

1.2.1.3 知识

- 人们实践经验的结晶且为新的实践所证实的；是关于事物运动的状态和状态变化的规律；是对信息加工提炼所获得的抽象化产物。
- 知识的形式可能是模式、关联、变化、异常以及其他有意义的结构。
- 知识：把有关信息关联在一起所形成的信息结构。
- 知识反映了客观世界中事物之间的关系，不同事物或者相同事物间的不同关系形成了不同的知识。

例如：

“雪是白色的” —— 事实

“如果头痛且流涕，则有可能患了感冒” —— 规则

1.2.1.4 智慧

- 智慧是人类基于已有的知识，针对物质世界运动过程中产生的问题根据获得的信息进行分析、对比、演绎找出解决方案的能力。
- 这种能力运用的结果是将信息的有价值部分挖掘出来并使之成为知识架构的一部分。

1.2.1 数据相关的基本概念

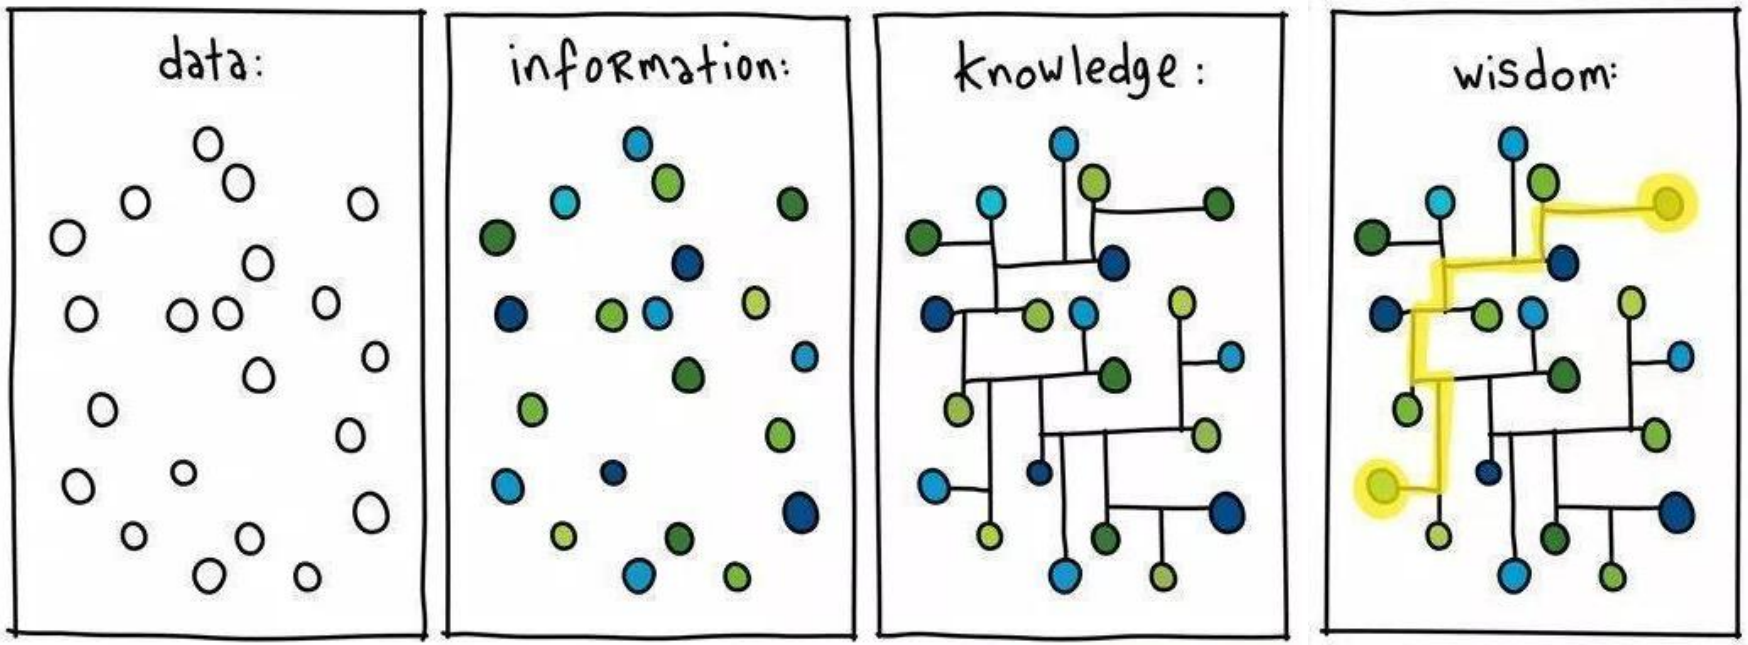

- 数据经过处理和加工，变成了信息。
- 信息之间产生了联系，形成了知识。
- 通过现有知识，发现了一些知识之间的新关系，并且串联起来，形成了智慧。

1.2.2 数据挖掘定义

- **技术角度的定义**
  - 数据挖掘（Data Mining)是从大量的、不完全的、有噪声的、模糊的、随机的实际应用数据中，提取隐含在其中的、人们事先不知道的、但又是潜在有用的信息和知识的过程。
  - 定义中包括的含义：
    - 数据源是真实的、海量的、含噪声的；
    - 发现的是用户感兴趣的知识；发现的知识要可接受、可理解、可运用；
    - 并不要求发现放之四海皆准的知识，仅支持特定的发现问题。

1.2.2 数据挖掘定义

数据挖掘与传统数据分析方法区别

- 海量数据
  - 算法有高度的可扩展性，以有效处理TB级数据
- 高维数据
  - 可高达数万个不同的维
- 数据的高度复杂性、非结构化的
  - 文本、图像、视频和WEB数据
  - 时序数据
  - 图、社会网络、多关系数据
  - 异构数据
- 噪声数据

1.2.2 数据挖掘定义

并非所有和数据相关的任务都是数据挖掘

- 以下不是数据挖掘系统
  - 数据库系统
  - 信息系统
  - 数据统计分析系统
- 相比于上述系统，数据挖掘系统关注更广的范围，是一个多学科的融合
- 数据挖掘是要发现那些不能靠直觉发现的信息或知识，甚至是违背直觉的信息或知识，挖掘出的信息越是出乎意料，就可能越有价值。

1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.3 发展历史

进化阶段	商业问题	支持技术	厂家	产品特点
数据访问 (20世纪80年代)	“在天津去年三月的销售额是多少？”	关系数据库（RDBMS），结构化查询语言（SQL），ODBC Oracle、Sybase、Informix、IBM、Microsoft	Oracle、Sybase、Informix、IBM、Microsoft	在记录级提供历史性的、动态数据信息
数据仓库 (20世纪90年代)	“在天津去年三月的销售额是多少？据此可得出什么结论？”	联机分析处理（OLAP）、多维数据库、数据仓库	Pilot、Comshare、Arbor、Cognos、Microstrategy	在各种层次上提供回溯的、动态的数据信息
大数据分布式处理 (21 世纪 00 年代)	"如何处理社交媒体、移动设备产生的海量异构数据，挖掘用户行为规律？"	Hadoop、NoSQL、分布式存储、MapReduce	Apache、Cloudera、AWS、阿里云	支持 PB 级海量异构数据的分布式批处理，兼容非结构化数据
深度学习与智能自动化 (21 世纪 10 年代)	"如何自动识别海量数据中的复杂模式，实现精准预测与多模态识别？"	深度学习、GPU 加速、流计算、AutoML	Google、NVIDIA、Databricks、Microsoft	自动特征工程，支持文本 / 图像多模态数据，分析精度大幅提升
AI 原生与数据智能 (21 世纪 20 年代至今)	"如何用自然语言直接查询数据，让业务人员无需技术知识就能获取洞察？"	大语言模型、向量数据库、MLOps、湖仓一体	OpenAI、Snowflake、Databricks、Anthropic	自然语言交互，自助式分析，统一数据与 AI 工作流，实现智能决策

1.3 发展历史

- 1989年8月，在美国底特律召开的第11届国际人工智能联合会议的专题讨论会上首次出现数据库中的知识发现（Knowledge Discovery in Database，KDD）这一术语。
- 在1991年、1993年和1994年都举行KDD专题讨论会，汇集来自各个领域的研究人员和应用开发者，集中讨论数据统计、海量数据分析算法、知识表示、知识运用等问题。最初，数据挖掘是作为KDD中利用算法处理数据的一个步骤，其后逐渐演变成KDD的同义词。
- 现在，人们往往不加区别地使用“数据挖掘”和“KDD”。KDD常常被称为数据挖掘（Data Mining）。

1.3 发展历史

□ 大模型

用于从大规模数据中提取有用的信息和知识。大模型可以通过学习更复杂的模式和关系，从而更准确地进行预测和分类。

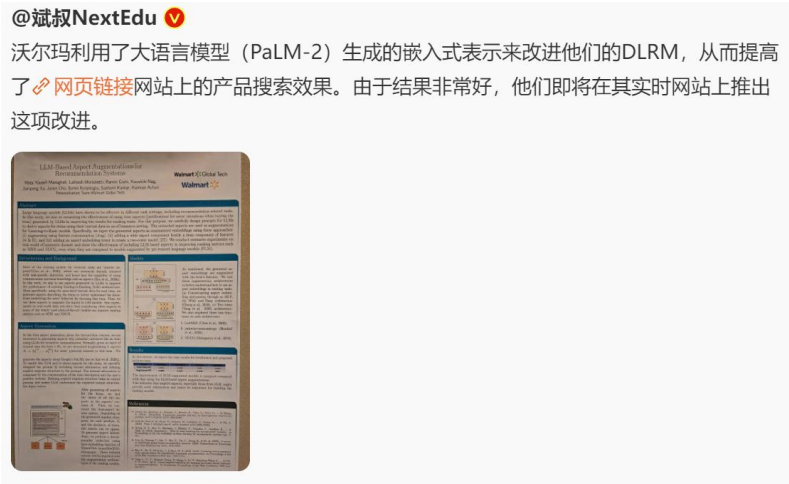

大模型	数据挖掘
文本挖掘	通过分析大量的文本数据，提取出关键词、主题、情感等信息。例如，可以用于舆情监测、产品评论分析等。
图像挖掘	通过分析大量的图像数据，提取出特征、模式和规律。例如，可以用于人脸识别、物体识别、图像搜索等。
社交网络分析	通过分析大规模的社交网络数据，提取出用户之间的关系、社群结构、影响力等信息。例如，可以用于推荐系统、广告投放、市场调研等。
时间序列预测	通过分析大量的时间序列数据，预测未来的趋势和变化。例如，可以用于股票市场预测、气象预报、销售预测等。

1.3 发展历史

- LDM（Large Data Model），即结构化数据基础模型，其瞄准的是生产侧的核心痛点，即如何让基础模型直接学习不同结构化数据中的变量关系、条件关系和生成机制。

•TabPFN-3.5：德国软件SAP发布的面向结构化数据的新一代表格基础模型。经过大规模预训练后，可直接完成分类、回归、时间序列预测和异常检测，大幅减少人工调参与特征工程。直接处理缺失值、异常值、类别变量、高基数特征和文本字段；其原生支持的数据规模已经扩展至百万行级别。

1.3 发展历史

- LDM（Large Data Model），即结构化数据基础模型，其瞄准的是生产侧的核心痛点，即如何让基础模型直接学习不同结构化数据中的变量关系、条件关系和生成机制。

•LimiX-2：国内首个结构化数据通用大模型，清华博士组成的团队，用一个400M参数的结构化数据基础模型。把面向变量关系建模前置为核心目标，学习跨变量、跨样本的联合依赖结构。自建了一套高质量自动化数据合成引擎，先让模型见过足够复杂的数据世界，再去处理真实任务。特别适合初期快速建立高质量基线，也可以与 CatBoost、LightGBM 等模型进行概率加权，形成更强的融合结果。

1.3 发展历史

- 自动化机器学习（AutoML）：可以自动化数据处理、模型选择、超参数优化等步骤，目标在于简化复杂的机器学习流程，使得从数据中提取洞察和构建智能系统变得更加快速和容易。主要算法包括神经架构搜索(NAS)、贝叶斯优化算法、遗传算法、强化学习算法，以及各种元学习算法。

•AutoGluon：自动训练多种模型，并通过 Bagging、Stacking 和加权集成获得稳定的预测结果。同时组合 CatBoost、LightGBM、XGBoost、神经网络和表格基础模型；相比只调一个模型，集成方案更容易获得稳定的交叉验证成绩。

•使用建议：初期使用默认配置快速建立强基线；后期增加训练时间、折数和堆叠层数，并将 AutoGluon 的预测结果与人工模型进行二次融合。

1.3 发展历史

- 自动化特征工程（AutoFE）：进行特征选择、生成和转换，以提取对于问题建模有用的特征。特征化是AutoML工作流中数据预处理的一部分。

•开源自动化特征工程库：如Featuretools、AutoFeat、TSFresh等，适合中小型团队或科研场景，支持Python接口调用，算法丰富但集成能力有限。

•商用低代码自动化平台：如帆软FineDataLink、阿里云DataWorks、腾讯云DataExplorer等，面向企业级场景，强调数据集成、实时同步、可视化开发。

•一站式数据治理与特征处理平台：如FDL、Databricks、Snowflake等，支持多源数据融合、数仓建设、特征自动处理及调度，适合大型企业复杂场景。

1.3 发展历史

- 自动化特征工程（AutoFE）：进行特征选择、生成和转换，以提取对于问题建模有用的特征。特征化是AutoML工作流中数据预处理的一部分。

工具类型	优势	劣势	典型案例
Featuretools等开源	算法丰富、灵活	集成能力弱、无可视化	数据科学实验
商用低代码平台	集成强、可视化、支持实时同步	算子库有限、扩展性需关注	企业级数据分析
一站式平台（FDL）	算法丰富、数据融合、数仓建设能力强	成本略高、需专业团队运维	金融科技项目

1.3 发展历史

- 自动化特征工程（AutoFE）：进行特征选择、生成和转换，以提取对于问题建模有用的特征。特征化是AutoML工作流中数据预处理的一部分。

处理环节	自动化能力	算法支持	平台实践（FDL）
特征提取	多表、整库自动同步	分类、数值、时间	支持多源异构数据
特征转换	自动编码、归一化	One-Hot、标准化	低代码组件
特征选择	自动相关性分析	PCA、筛选算法	算子库丰富
特征交互	自动生成交互特征	分箱、聚合	DAG调度、可视化

1.3 发展历史

- AI数据科学代理：从“辅助写代码”到“自动迭代实验”

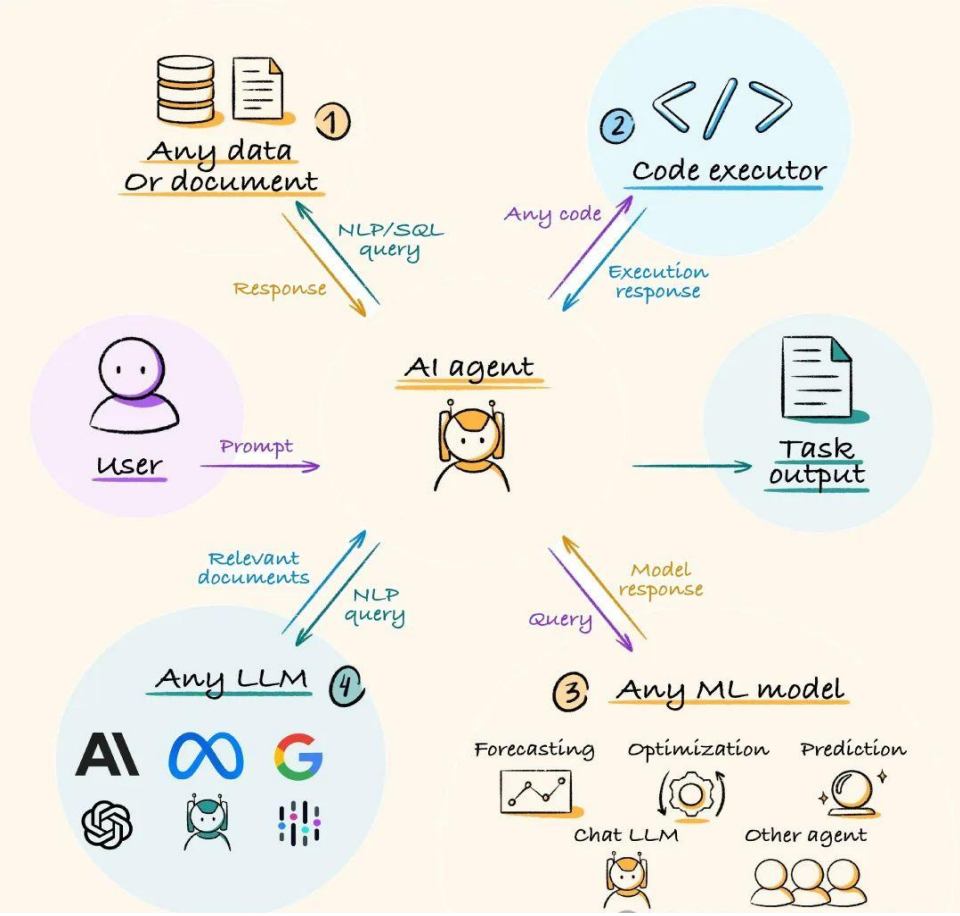

1.3 发展历史

- AI数据科学代理：从“辅助写代码”到“自动迭代实验”

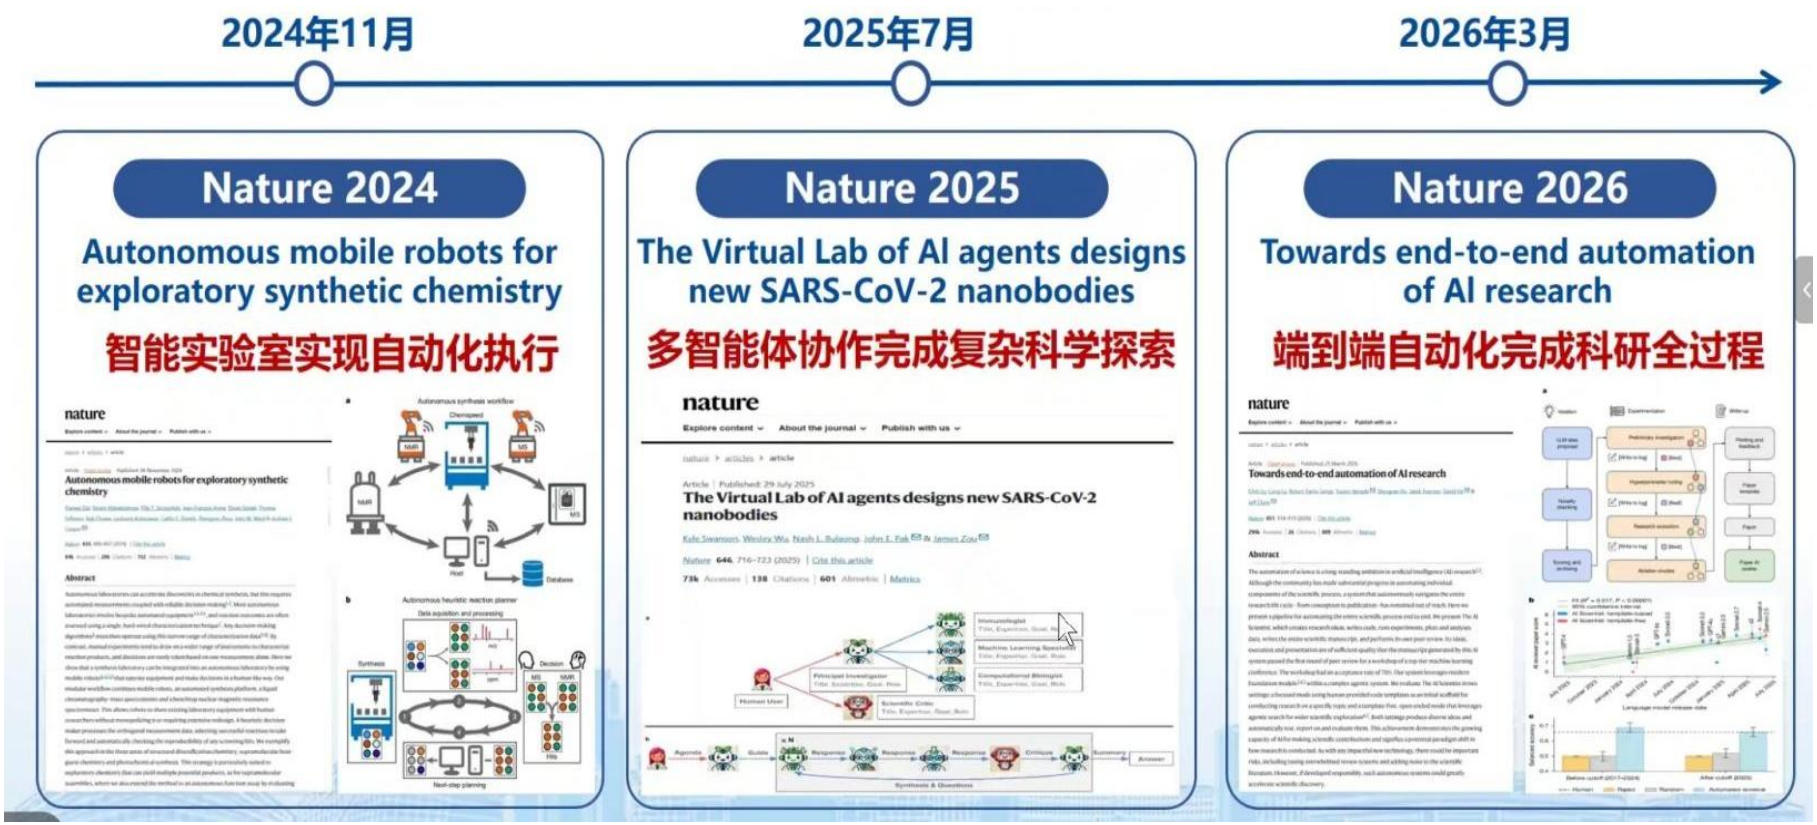

1.3 发展历史

- AI数据科学代理：从“辅助写代码”到“自动迭代实验”

nature

Explore content | About the journal | Publish with us

nature > articles > article

Article | Open access | Published: 19 May 2026

Accelerating scientific discovery with Co-Scientist

Juraj Gottweis, Wei-Hung Weng, Alexander Daryin, Tao Tu, Petar Sirkovic, Artiom Myaskovsky, Grzegorz Gloway, Felix Weissenberger, Alessio Orlandi, Dan Popovici, Anil Palepu, Keran Rong, Ryutaro Tanno, Khaled Saab, Fan Zhang, Jacob Blum, Andrew Carroll, Kavita Kulkarni, Nenad Tomašev, Dina Zverinski, Ivor Rendulic, Elahe Vedadi, Florian Hasler, Luka Rimanic, ... Vivek Natarajan + Show authors

Nature **655**, 487–496 (2026) | Cite this article

nature

Explore content | About the journal | Publish with us

nature > articles > article

Article | Open access | Published: 19 May 2026

A multi-agent system for automating scientific discovery

Ali E. Ghareeb, Benjamin Chang, Ludovico Mitchener, Angela Yiu, Caralyn J. Szostkiewicz, Dmytro Shved, Gavin J. Gyimesi, Jon M. Laurent, Samantha M. Wright, Muhammed T. Razzak, Andrew D. White, Silvia C. Finnemann, Michaela M. Hinks & Samuel G. Rodriques

Nature **655**, 497–505 (2026) | Cite this article

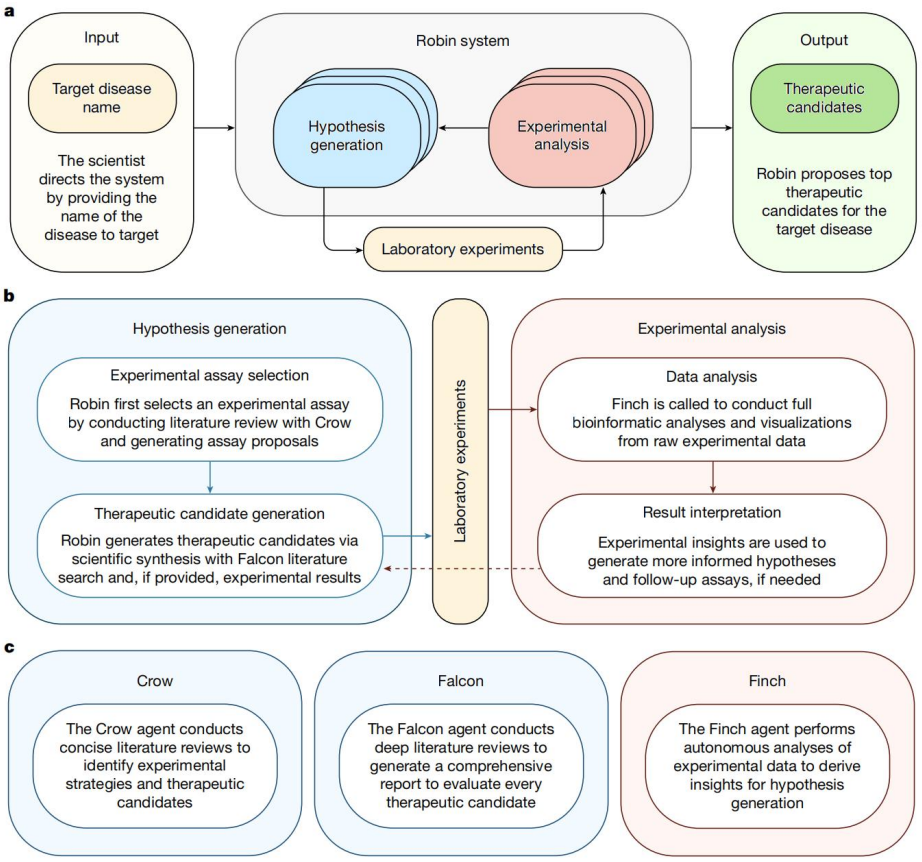

1.3 发展历史

AI数据科学代理：从“辅助写代码”到“自动迭代实验”

•AutoGen是微软发布的智能体协作框架，旨在帮助开发者创建基于大语言模型的复杂应用程序，通过多个智能体之间的协作与交互，实现更加智能和灵活的任务处理。

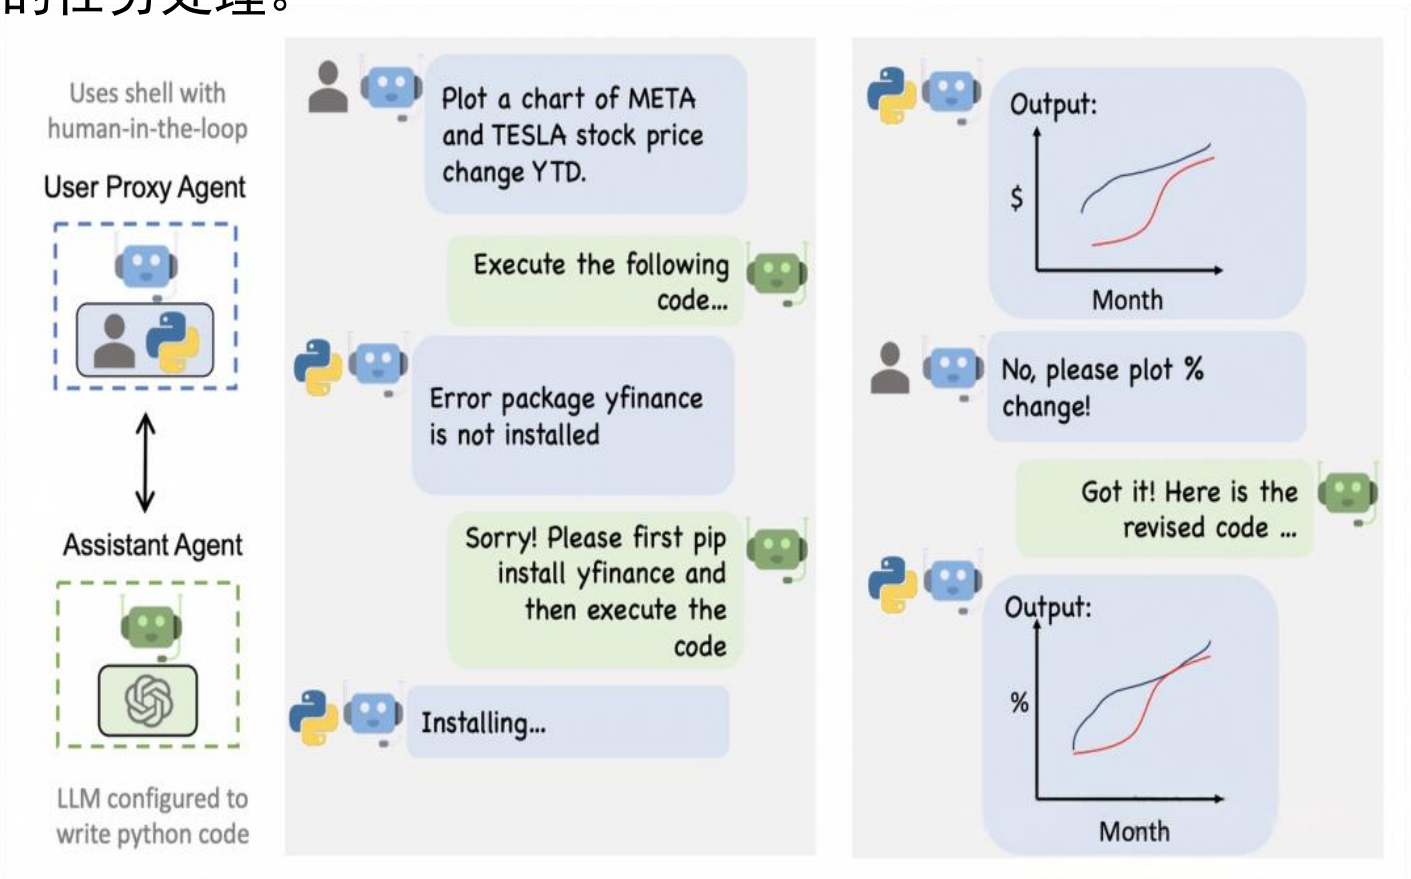

1.3 发展历史

AI数据科学代理：从“辅助写代码”到“自动迭代实验”

•LangGraph专注于自然语言处理的框架，它通过循环控制、状态管理和人机交互等技术，帮助开发者构建复杂的AI Agent。适用于多种应用场景，如智能客服、智能投资顾问等。

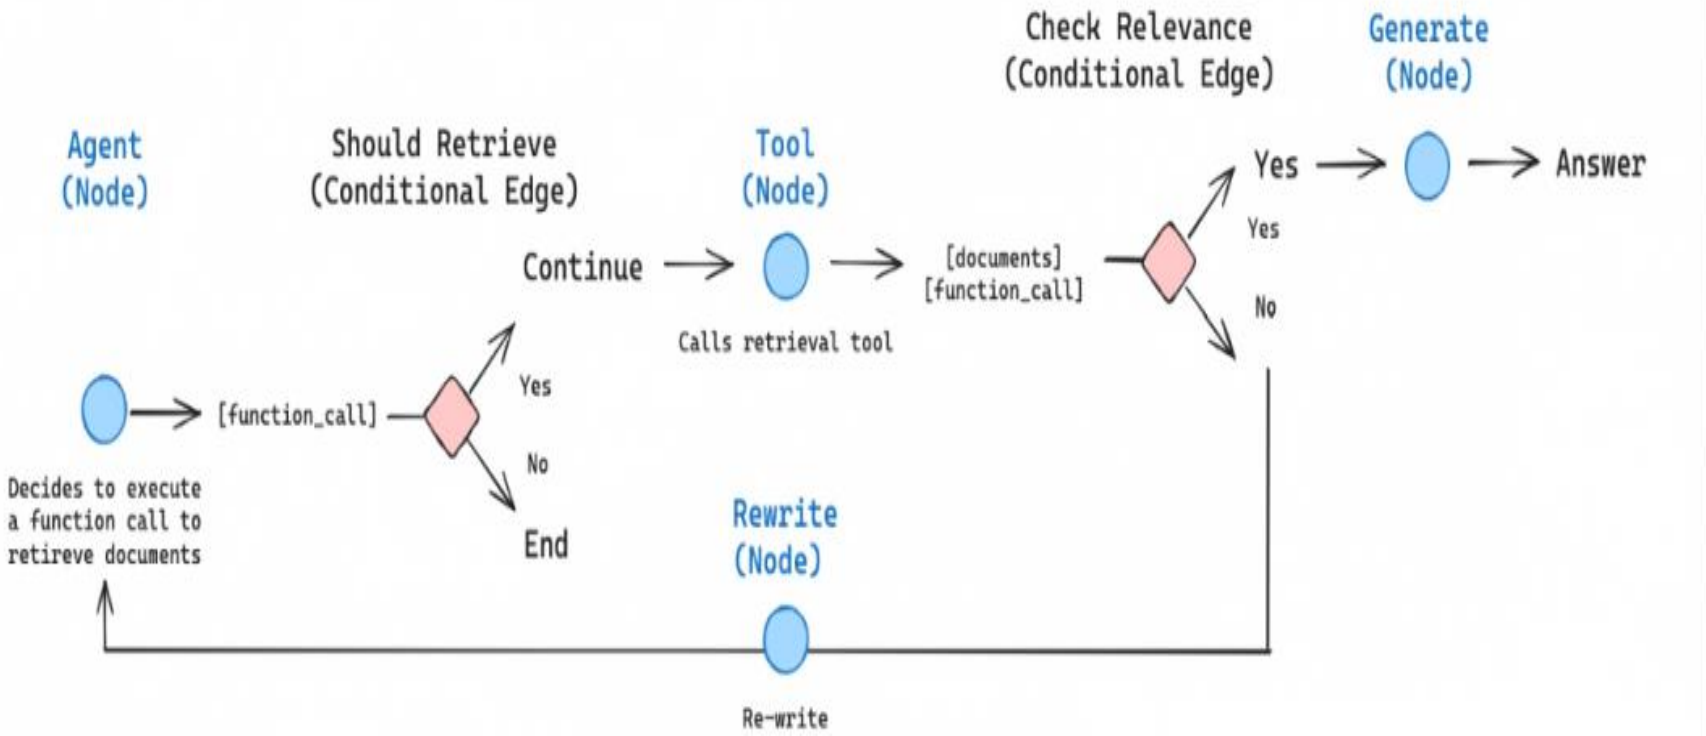

1.3 发展历史

AI数据科学代理：从“辅助写代码”到“自动迭代实验”

•Phidata是一个基于Python的框架，能够将大型语言模型转化为AI产品中的Agent。

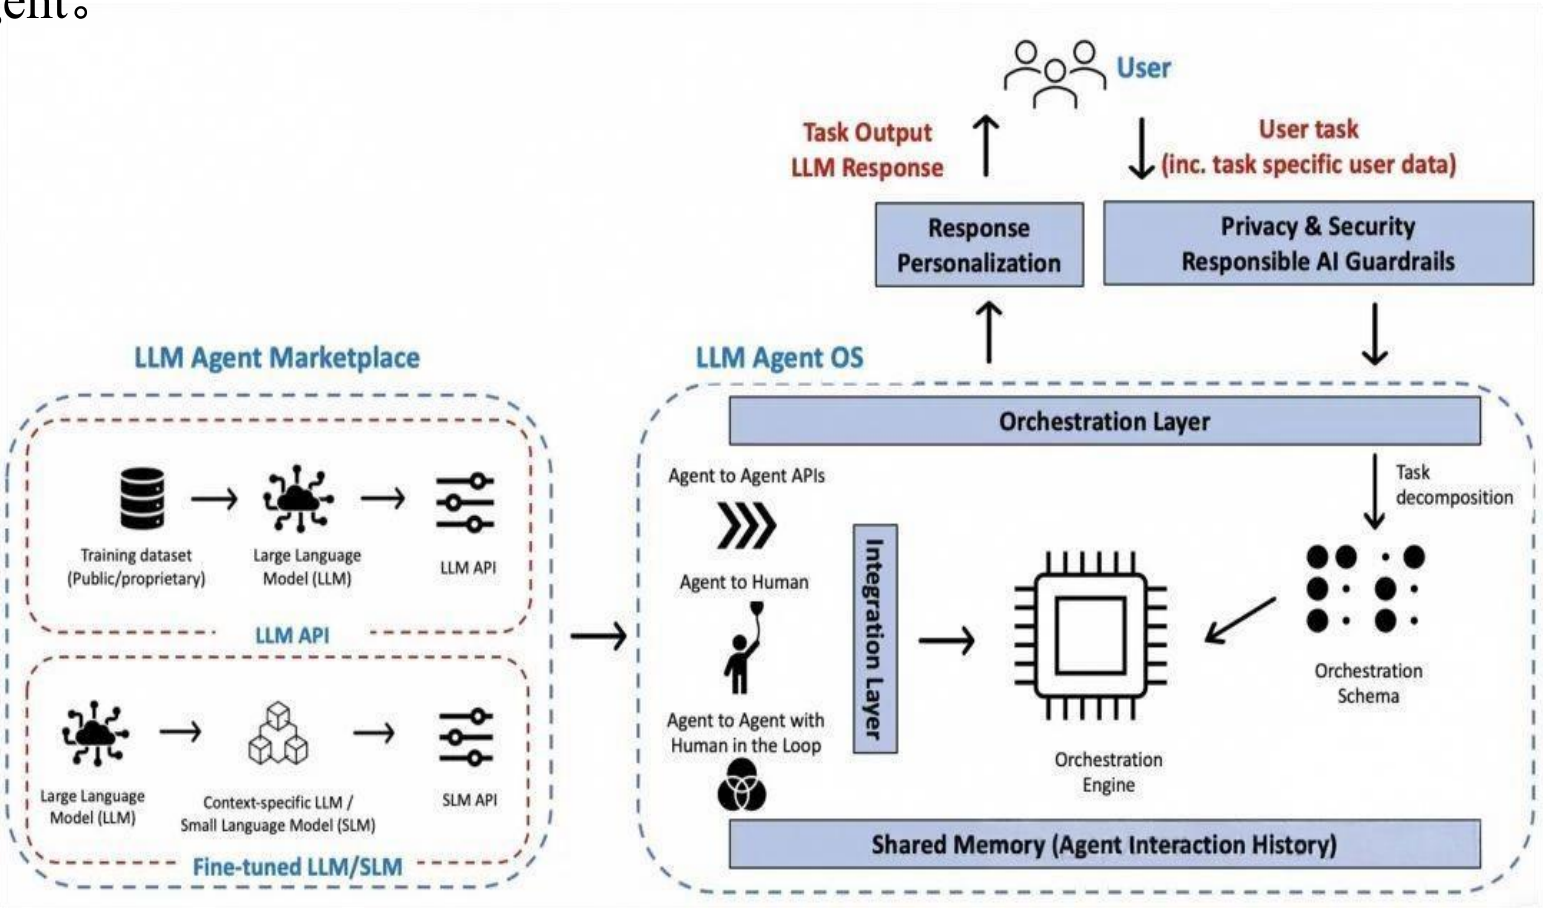

1.3 发展历史

AI数据科学代理：从“辅助写代码”到“自动迭代实验”

•数据科学代理通过迭代规划和验证DS-STAR：谷歌 AI 研究团队采用“数据分析—顺序规划—结果验证—方案修正”的循环机制，适合处理多个表格、文本和异构文件组成的复杂数据分析任务。

•合理定位：AI代理适合自动生成基线、排查报错和批量执行实验，但数据泄漏检查、验证集设计和最终提交仍应由人工审核。

1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.4 挖掘过程

1. 数据清理 （消除噪音或不一致的数据）
2. 数据集成 （多种数据源组合到一起）
3. 数据选择

（从数据库中提取与分析任务相关的数据）

4. 数据变换

（变换或统一成合适挖掘的形式）

5. 挖掘算法设计

（使用智能方法提取数据模式，

关联规则及机器学习的分类、聚类、回归）

6. 性能评估

（根据某种兴趣程度度量识别提供知识的真正有趣的模式）

7. 知识表示

（向用户提供挖掘的知识）

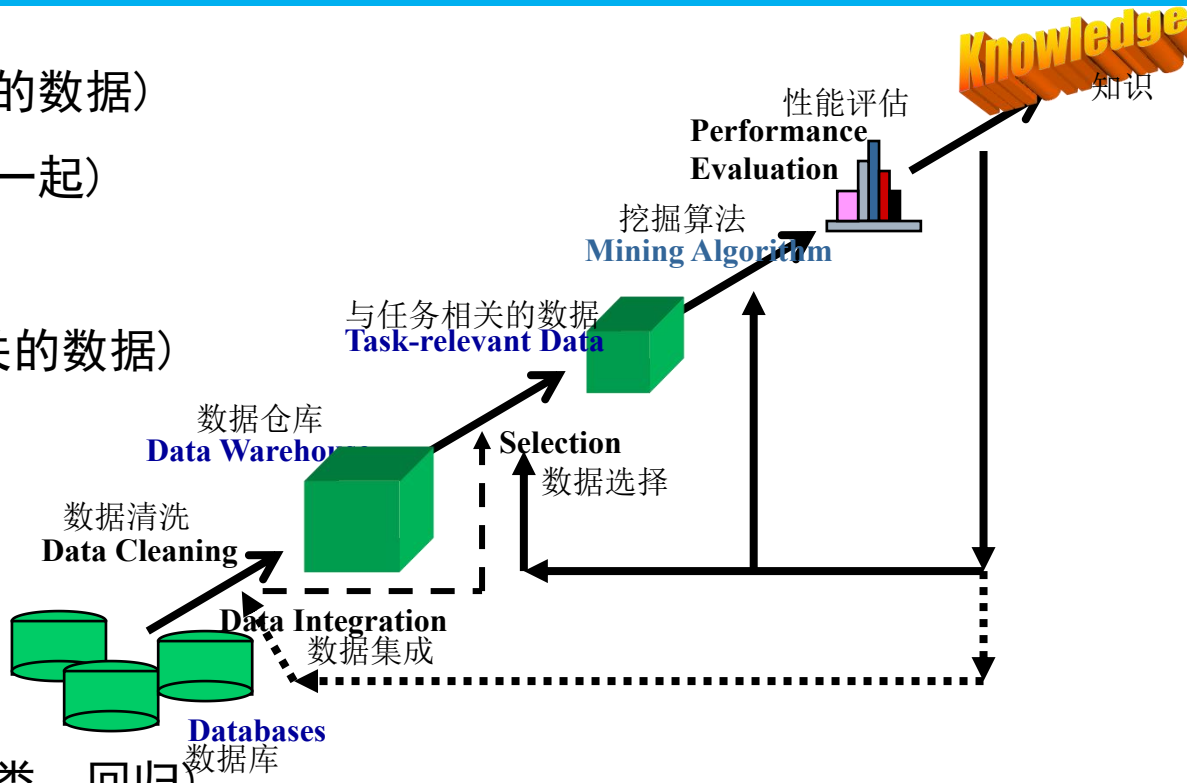

1.4 挖掘过程

- 从KDD对数据挖掘的定义中可以看到当前研究领域对数据挖掘的广义认识

1. 数据清理 (这个可能要占全过程60%的工作量)
2. 数据集成
3. 数据选择
4. 数据变换

数据预处理

5. **挖掘算法设计（适当的算法找到感兴趣的模式或者预测结果）**
6. 性能评估
7. 知识表示

1.4 挖掘过程

数据预处理

- KDD的处理对象是大量的数据，这些数据一般存储在数据库系统中，是长期积累的结果。但往往不合适直接在这些数据上进行知识挖掘，需要做一些准备工作，也就数据的预处理。
- 数据预处理包括数据的选择（选择相关数据）、净化（消除噪音、冗余数据）、推测（推算缺值数据）、转换（离散型数据与连续型数据之间的转换）、数据缩减（减少数据量）等。
- 数据预处理是KDD的第一个步骤，也是比较重要的一个步骤。数据准备得好坏将直接影响数据挖掘的效率和准确度以及最终模式的有效性。

1.4 挖掘过程

挖掘算法设计

- 挖掘算法设计是最为关键的步骤，它根据KDD的目标，选取相应算法的参数，分析数据，得到可能形成知识的模式或者模型。
- 目前采用较多的算法有关联规则、决策树、SVM、神经网络、kmeans、线性回归等。

1.4 挖掘过程

性能评估

通过上面步骤所得到的模式或者预测结果，需要进行性能评估，大部分模式是用数学手段描述的表达式，很难被人理解，还需要将其解释成可理解的方式以呈现给用户。

1.4 挖掘过程

知识表示

知识表示的主要目的是为了运用，如何使知识能被运用也是KDD的步骤之一。

运用知识有两种方法：一种是只需看知识本身所描述的关系或结果，就可以对决策提供支持；另一种是要求对新的数据运用知识，由此可能产生新的问题，而需要对知识做进一步的优化。

KDD过程可能需要多次的循环反复，每一个步骤一旦与预期目标不符，都要回到前面的步骤，重新调整，重新执行。

1.4 挖掘过程

典型数据挖掘系统的体系结构

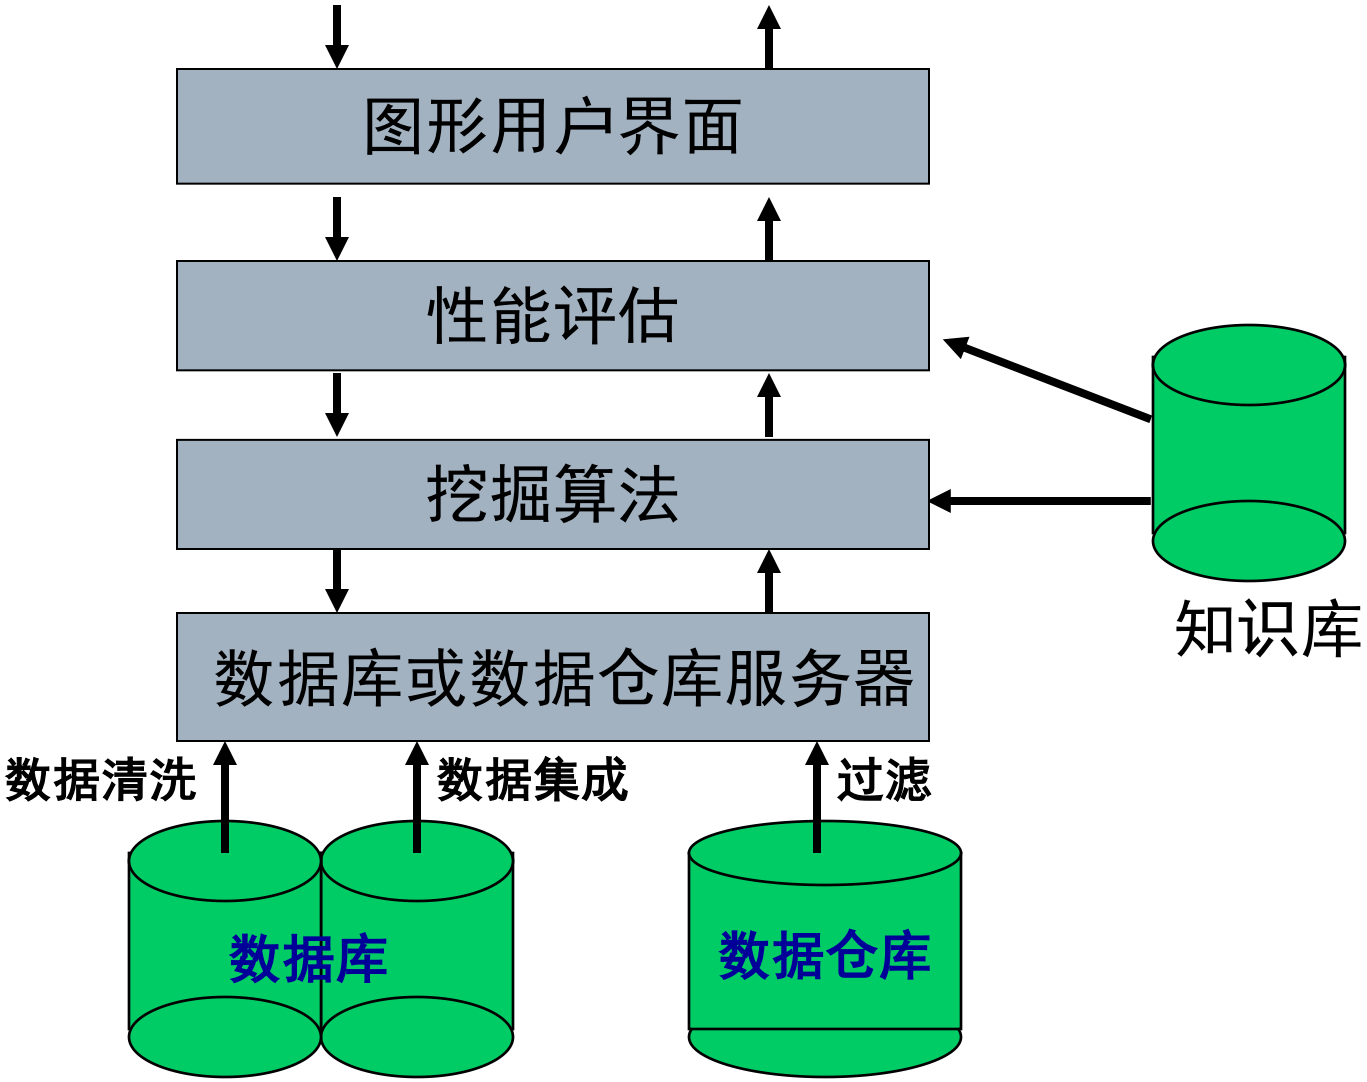

1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.5 主要任务

宏观上的两大类任务

- Prediction Methods 预测性方法
  - 利用已知变量的信息**预测**未知或未来的其它变量
  - 解释变量 → 目标变量
- Description Methods 描述性方法
  - 找到人类**可理解的模式**来描述数据

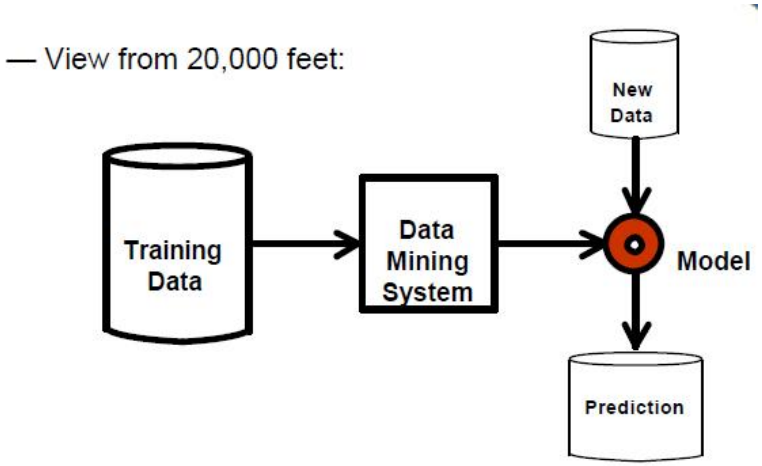

1.5 主要任务

从挖掘模式上数据挖掘可分为：

- 关联分析------推荐系统
- 分类------长尾分布
- 聚类分析------离群点分析
- 回归------时间序列分析

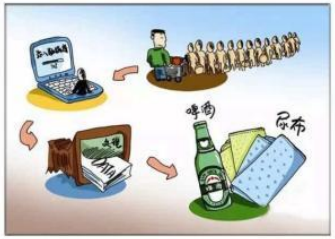

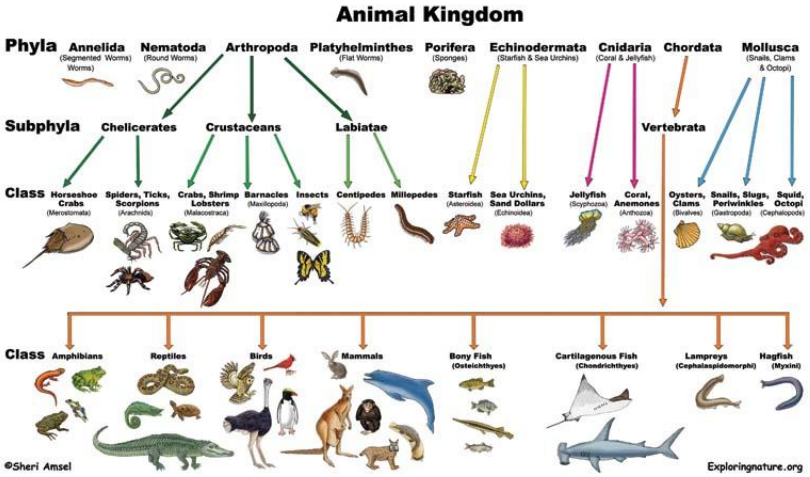

1.5 主要任务

1. 推荐系统（Recommendation system ）

- 利用用户的一些行为，通过一些数学算法，推测出用户可能喜欢的东西

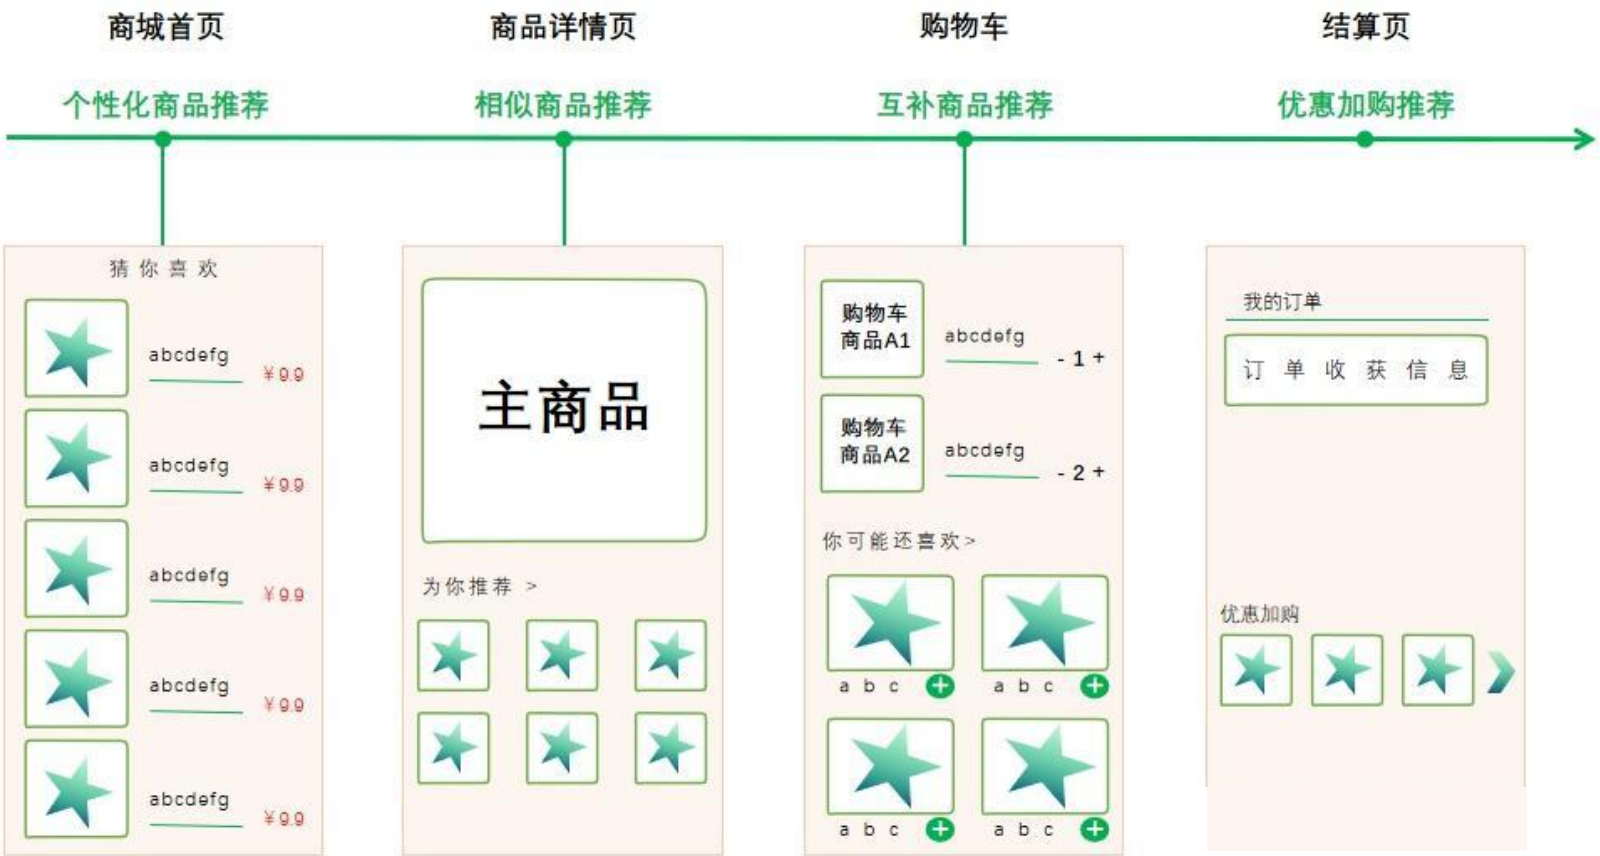

1.5 主要任务

1. 推荐系统（Recommendation system ）

关联分析（Association Analysis）

- 从一个项目集中发现关联规则，该规则显示了给定数据集中经常一起出现的属性－值条件元组。
- 例如：关联规则X=>Y所表达的含义是满足X的数据库元组很可能满足Y。关联分析在交易数据分析、支持定向市场、商品目录设计和其他业务决策等方面有着广泛的应用。

Rule	Support	Confidence
A ⇒ D	2/5	2/3
C ⇒ A	2/5	2/4
A ⇒ C	2/5	2/3
B & C ⇒ D	1/5	1/3

1.5 主要任务

2. 分类（Classification）

- 分类指通过分析一个类别已知的数据集的特征来建立一组模型，该模型可用以预测类别未知的数据项的类别。
- 该分类模型可以表现为多种形式：分类规则（IF-THEN），决策树，神经网络。

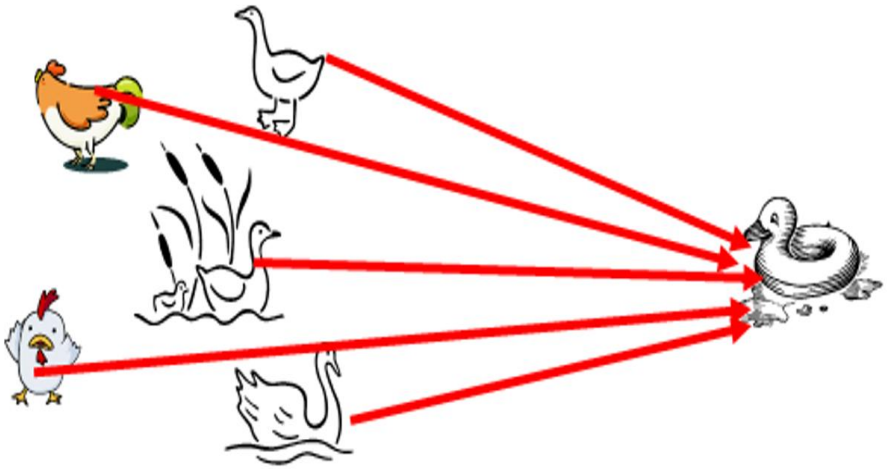

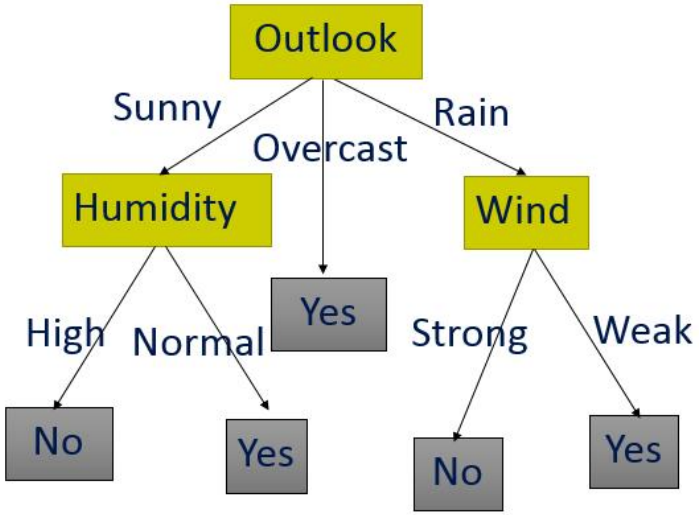

1.5 主要任务

2. 分类（Classification）

长尾分布（Long-tailed distribution）

- **80/20法则：**20%的人的掌握着80%的社会财富。
- 80%的样本分布在20%的头部类别上，大量尾部类别样本稀少，呈现一种极端不平衡分布。

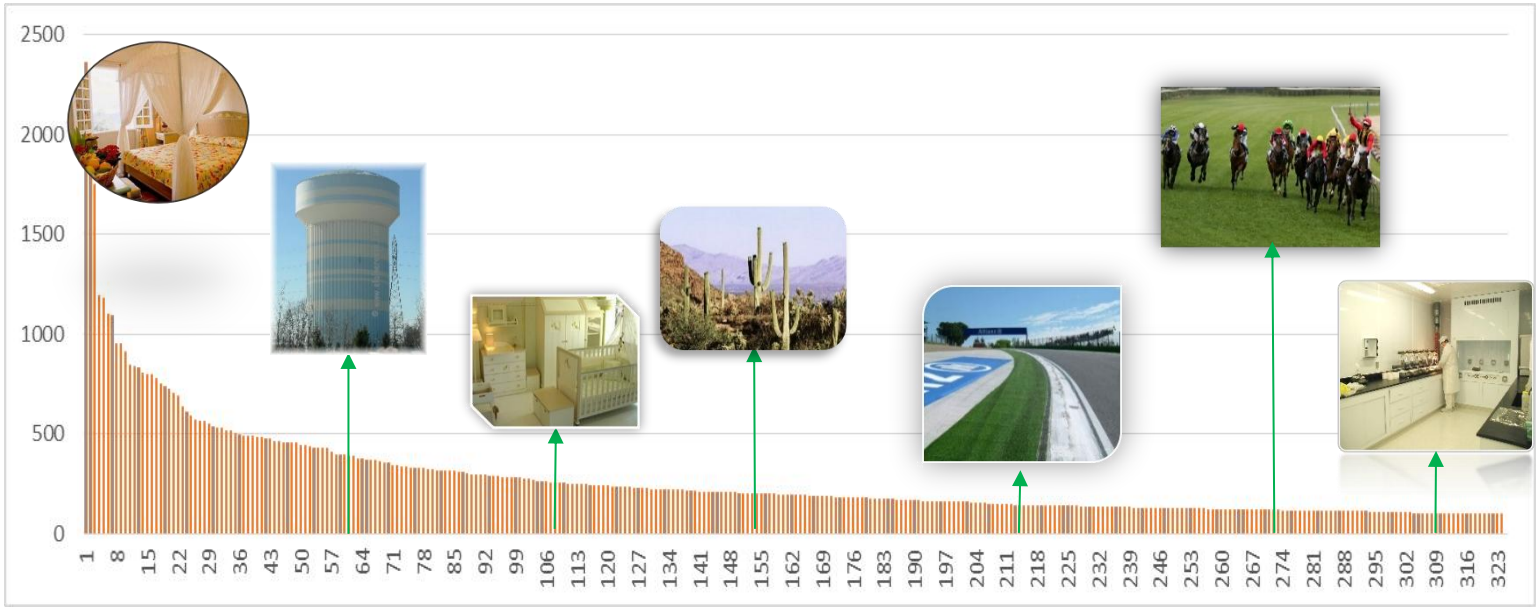

1.5 主要任务

3. 聚类分析（Clustering Analysis）

- 聚类分析又称为“同质分组”或者“无监督的分类”，指把一组数据分成不同的“簇”，每簇中的数据相似而不同簇间的数据则距离较远。相似性可以由用户或者专家定义的距离函数加以度量。
- 好的聚类方法应保证不同类间数据的相似性尽可能地小，而类内数据的相似性尽可能地大。

Original image

$K = 10$

$K = 3$

$K = 2$

1.5 主要任务

3. 聚类分析（Clustering Analysis）

离群点分析

- 离群点：一些与数据的一般行为或模型不一致的孤立数据
- 通常孤立点被作为“噪音”或异常被丢弃，但在欺骗检测中却可以通过对罕见事件进行孤立点分析而得到结论。
- 应用
  - 信用卡欺诈检测
  - 移动电话欺诈检测
  - 客户划分
  - 医疗分析（异常）

1.5 主要任务

4. 回归（Regression）

- 回归与分类类似，只不过它要预测的不是类别，而是一个连续的数值。

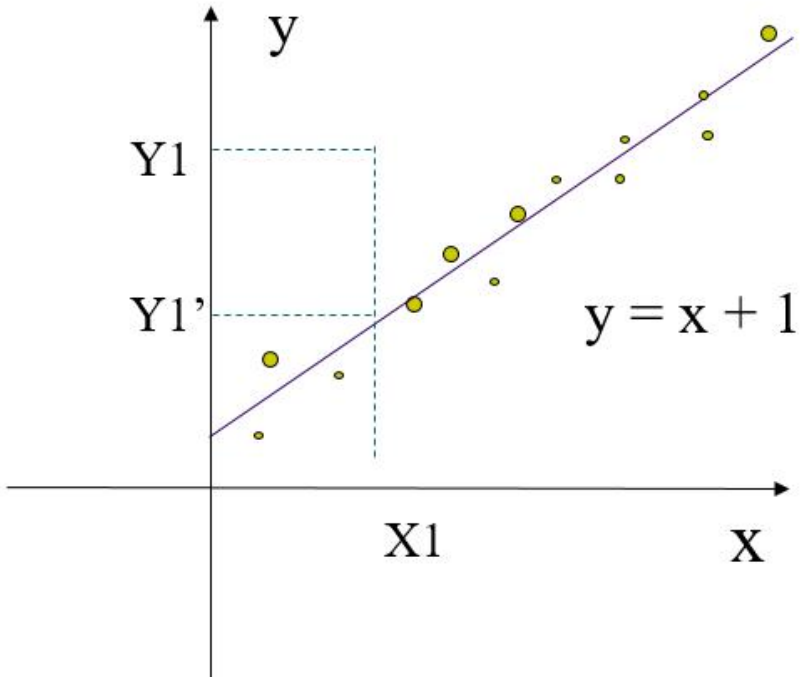

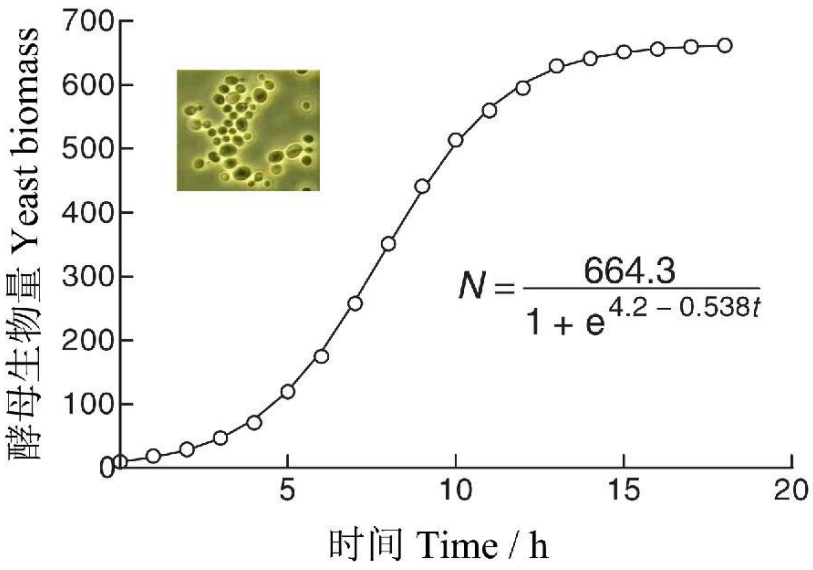

4. 回归（Regression）

时间序列分析（Time-Series Analysis）

通过对大量时间序列数据的分析找到特定的规则和感兴趣的特性，包括搜索相似序列或者子序列，挖掘序列模式、周期性、趋势和偏差。预测的目的是对未来的情况作出估计。

1.5 主要任务

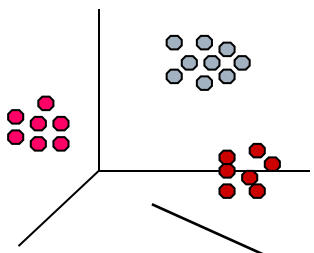

Clustering

Data

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes
11	No	Married	60K	No
12	Yes	Divorced	220K	No
13	No	Single	85K	Yes
14	No	Married	75K	No
15	No	Single	90K	Yes

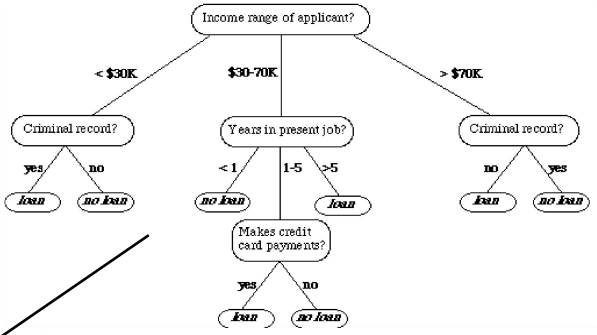

Predictive Modeling

Association Rules

Anomaly Detection

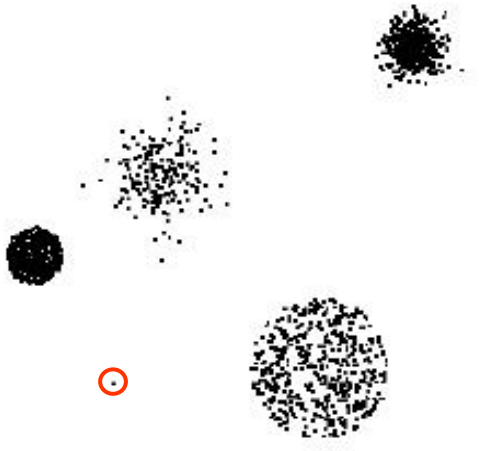

1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.6 与其他学科的关系

- 数据挖掘作为一门交叉学科，涉及数据库系统、统计学、机器学习、可视化、信息检索和高性能计算等诸多领域。
- 此外，还与深度学习、模式识别、空间数据分析、图像处理、自然语言处理、信号处理、概率论、图论和归纳逻辑等等领域关系密切。

1.6 与其他学科的关系

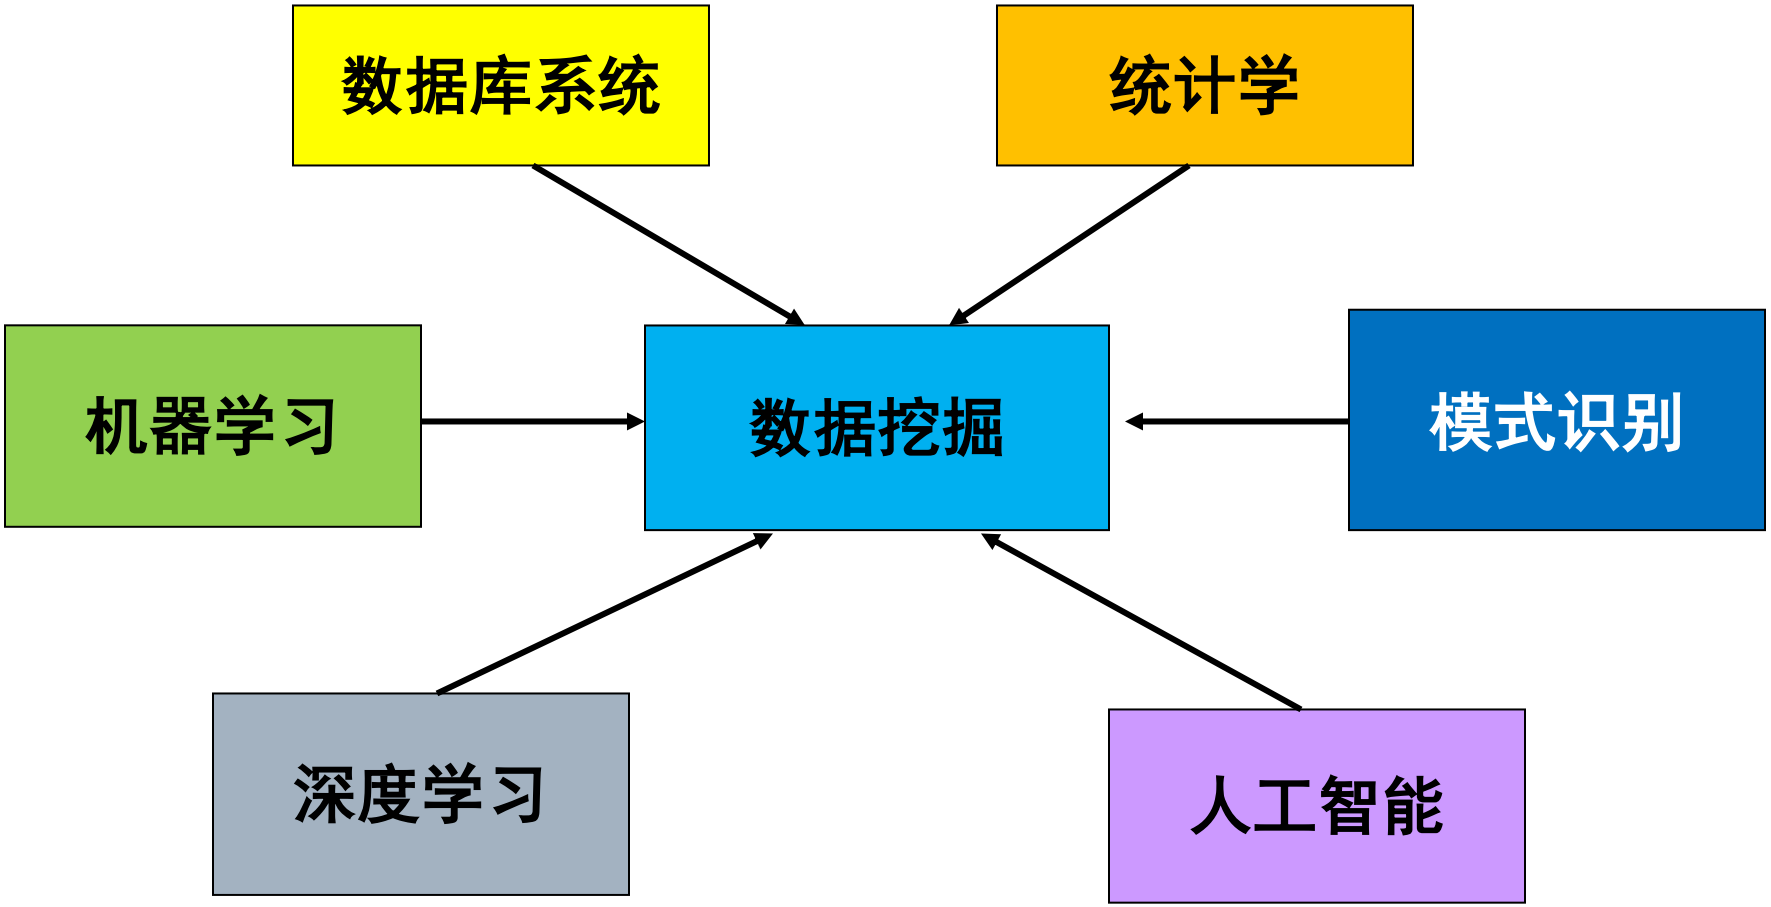

1.6 与其他学科的关系

数据挖掘与数据库的关系

- 数据库主要关注数据建模、查询语言、查询处理与优化方法、数据存储以及索引和存取，处理相对结构化的数据集，可以为数据挖掘提供数据管理技术。
- 数据挖掘任务可以进行分析和预测，扩充已有数据库系统的能力，满足高端用户复杂的数据分析需求。

1.6 与其他学科的关系

数据挖掘与机器学习的关系

- 数据挖掘可以认为是数据库技术与机器学习的交叉
  - 它利用数据库技术来管理海量的数据。
  - 机器学习和统计学为数据挖掘提供数据分析技术。
- 作为一个独立的学科，数据挖掘也有其独特的东西，即：关联分析。

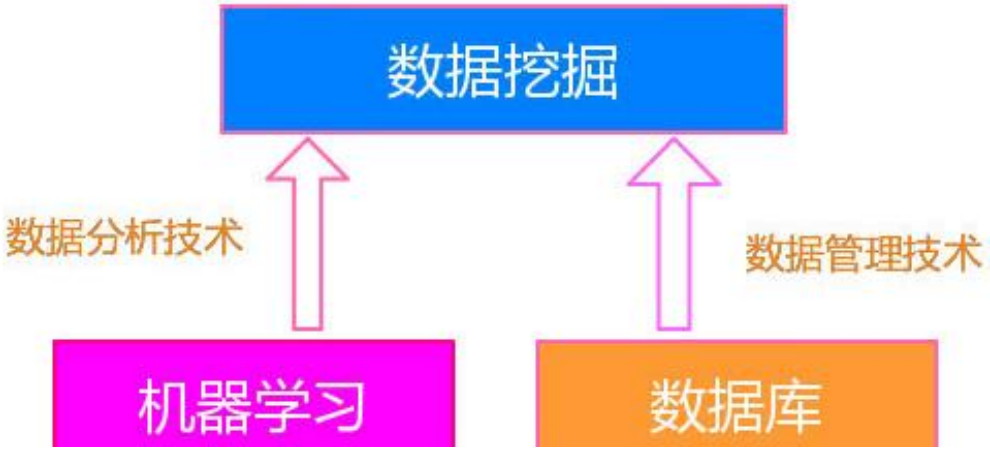

1.6 与其他学科的关系

数据挖掘与统计学的关系

- 关联：

统计学为数据挖掘一些算法设计提供了指导思想，应用统计学对数据挖掘的结果进行评估和验证。

- 共同点：

发现数据中的结构、隐藏的内在规律。

- 不同点：
  - 统计学是抽样样本的研究，从小样本数据分析，推测总体的特征。数据挖掘通常是从海量的数据集中挖掘知识。
  - 统计分析在预测中的应用常表现为一个或一组函数关系式；而数据挖掘在预测应用中的重点在于预测的结果，很多时候并不会从结果中产生明确的函数关系式，有时候甚至不知道到底是哪些变量在起作用，又是如何起作用的。

1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.7 应用

- 数据挖掘技术的产生本身就有其强烈的应用需求背景，在市场分析、业务管理、决策支持等方面有广泛的应用，是实现CRM和BI的重要技术手段之一。
  - 客户信用评分
  - 逾期行为预测
  - 客户流失分析
  - 欺诈甄别
  - 客户群体划分

1.7 应用

□ 消费者人群画像——智能信用评分

中国移动提供的样本数据，包括客户的各类通信支出、欠费情况、出行情况、消费场所、社交、个人兴趣等丰富的多维度数据，运用机器学习和深度学习算法，准确评估用户消费信用分值。

```
Data columns (total 30 columns):
 #   Column                  Non-Null Count   Dtype
---  ------                  --------------   -----
 0   用户编码                  100000 non-null  object
 1   用户实名制是否通过核实       100000 non-null  int64
 2   用户年龄                  100000 non-null  int64
 3   是否大学生客户             100000 non-null  int64
 4   是否黑名单客户             100000 non-null  int64
 5   是否4G不健康客户           100000 non-null  int64
 6   用户网龄（月）             100000 non-null  int64
 7   用户最近一次缴费距今时长（月）  100000 non-null  int64
 8   缴费用户最近一次缴费金额（元）  100000 non-null  float64
 9   用户近6个月平均消费值（元）    100000 non-null  float64
 10  用户账单当月总费用（元）      100000 non-null  float64
 11  用户当月账户余额（元）        100000 non-null  int64
 12  缴费用户当前是否欠费缴费      100000 non-null  int64
 13  用户话费敏感度              100000 non-null  int64
 14  当月通话交往圈人数           100000 non-null  int64
 15  是否经常逛商场的人           100000 non-null  int64
```

1.7 应用

□ 用户逾期行为预测：

通过分析信贷用户的其他行为，来判断用户是否逾期。

	A	B
1	名称	标签
2	CUST_ID	客户号
3	OPEN_ORG_NUM	开户机构
4	IDF_TYP_CD	证件类型
5	GENDER	性别
6	bad_good	个贷是否逾期
7	LAST_OPEN_TENURE_DAYS	信用卡最近开户时长
8	G_OS_PRCP_SUM	贷款账户月余额
9	OS_PRCP_SUM_THREE	三个月内贷款账户月均余额

1.7 应用

有数据的地方，就可能需要数据挖掘技术。

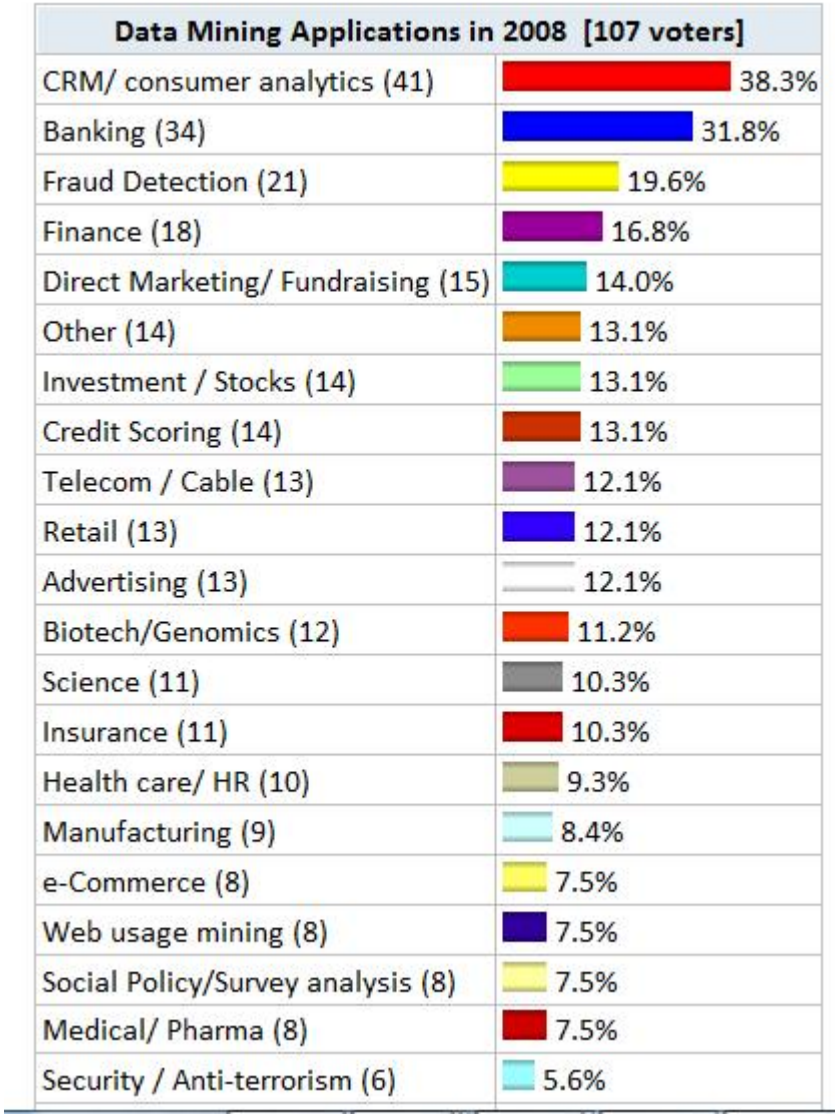

1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.8 研究热点与挑战

□ 大语言模型与数据挖掘的深度融合

语义增强的传统挖掘：将 LLMs 集成到关联规则挖掘中，利用其语义理解能力克服传统方法对符号共现模式的“语义脆弱性”，实现无需本体（Ontology-Free）的语义泛化。

自动化数据探索与分析：LLMs 被用于自动化探索性数据分析（EDA），通过自然语言或 SQL 接口，帮助用户从复杂表格和数据湖中发现关系、生成洞察。

智能数据发现代理：多智能体框架结合 LLMs 的上下文推理能力，用于高效地发现数据湖中可连接（Joinable）的列关系。

1.8 研究热点与挑战

□ 图基础模型与图神经网络（GNNs）的演进

应对真实世界挑战：针对图数据中普遍存在的不平衡、噪声、隐私和分布外（OOD） 问题，设计更鲁棒的 GNN 架构。

图与 LLM 的协同：探索如何利用 LLMs 增强图挖掘，以及如何将图结构知识注入 LLMs，形成一个双向增强的循环。

边缘感知图学习：在图学习中更精细地建模边缘（关系）的属性与影响，以捕获更复杂的依赖关系。

1.8 研究热点与挑战

□ 可信与负责任的数据挖掘

可解释性（XAI）：研究重点从简单的“事后解释”转向内在可解释的模型设计（如可解释的决策树集成、概念瓶颈模型），并建立标准化的基准来量化“准确率-透明度”的权衡。

隐私保护：隐私保护数据挖掘（PPDM） 持续演进，重点包括联邦学习（FL）、分割学习（SL）与差分隐私（DP）等技术的融合，以在分布式和边缘环境中平衡数据效用与隐私安全。

公平性：公平性感知数据挖掘（Fairness-Aware Data Mining）致力于开发能检测和缓解算法偏见的技术，确保数据挖掘结果不加剧社会不平等。

1.8 研究热点与挑战

□ 新兴交叉与融合方向

多模态数据挖掘：整合文本、图像、音频等多种模态的数据，采用基于注意力机制和 Transformer 的早期融合策略成为主流，重点解决跨模态对齐和知识融合问题。

数据挖掘与区块链：两者的结合是一个新兴趋势，旨在利用区块链的安全、透明和不可篡改特性，解决数据挖掘中的信任、隐私和分布式决策问题。

因果推断与数据挖掘的融合：研究正从“预测”走向“干预”。因果机器学习被应用于精准医疗、社会学等领域，致力于在复杂、高维的观测数据中识别异质性处理效应，并构建可解释的因果模型。

小结

- 数据挖掘：从大量的、不完全的、有噪声的、模糊的、随机的实际应用数据中，提取隐含在其中的、人们事先不知道的、但又是潜在有用的信息和知识的过程
- 挖掘过程：数据清理、数据集成、数据选择、数据变换、挖掘算法设计、性能评估、知识表示
- 数据挖掘的任务：关联规则，分类，聚类，回归等
- 应用：where there are data, there are data mining applications

天津大学
Tianjin University

THE END

天津大学
Tianjin University

数据挖掘

杨柳

智能与计算学部

yangliuyl@tju.edu.cn

回顾

1. 数据清理 （消除噪音或不一致的数据）
2. 数据集成 （多种数据源组合到一起）
3. 数据选择

（从数据库中提取与分析任务相关的数据）

4. 数据变换

（变换或统一成合适挖掘的形式）

5. 挖掘算法设计

（使用智能方法提取数据模式，关联规则及机器学习的分类、聚类、回归）

6. 性能评估

（根据某种兴趣程度度量识别提供知识的真正有趣的模式）

7. 知识表示

（向用户提供挖掘的知识）

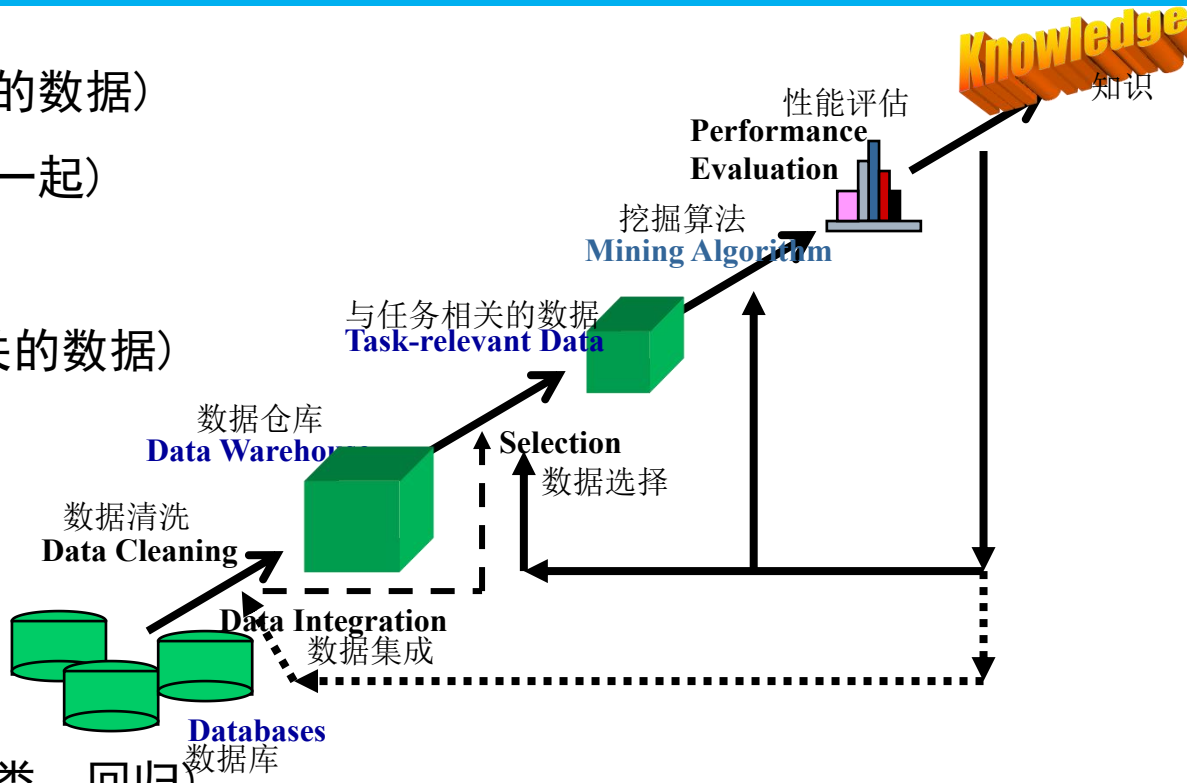

第 2 章　认识数据

2 认识数据

2.1 数据对象与属性类型

2.2 数据的基本统计描述

2.3 数据可视化

2.4 度量数据的相似性和相异性

2.1 数据对象与属性类型

序号	头发颜色	籍贯	A成绩	B成绩	类别
1	黑色	天津	90	C	1
2	黄色	北京	70	A	0
3	紫色	北京	91	A	?

序号	头发颜色	籍贯	A成绩	B成绩	类别
1	0	022	90	3	1
2	1	010	70	5	0
3	9	010	91	5	?

A成绩	B成绩	类别
90	3	1
70	5	0
91	5	?

A成绩	B成绩	类别
90	60	1
70	100	0
91	100	?

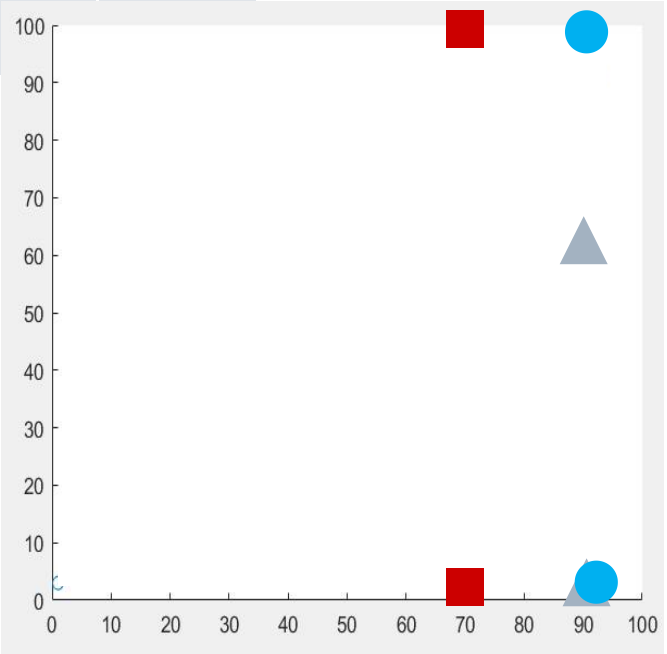

2.1 数据对象与属性类型

- 文本、图像
- 网络
  - World Wide Web
  - 社交网络
  - 分子结构
- 时序数据
  - 视频数据：图像序列
  - 时间数据：时间序列
  - 顺序数据：事务序列
  - DNA序列数据

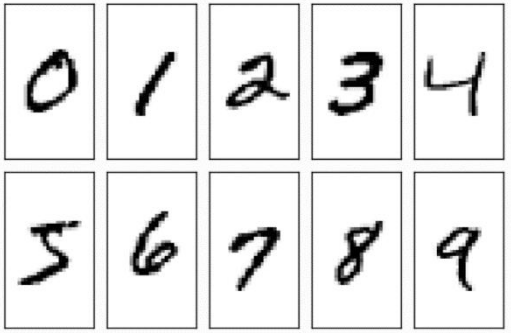

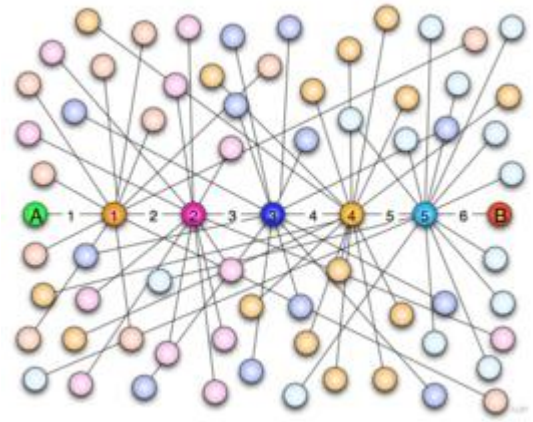

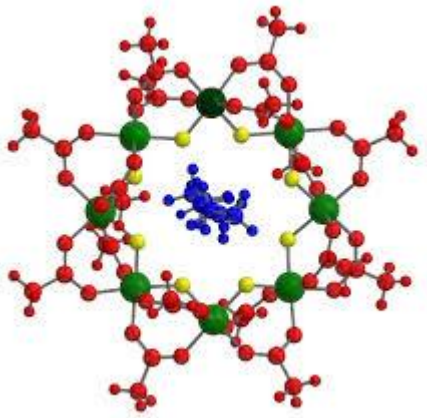

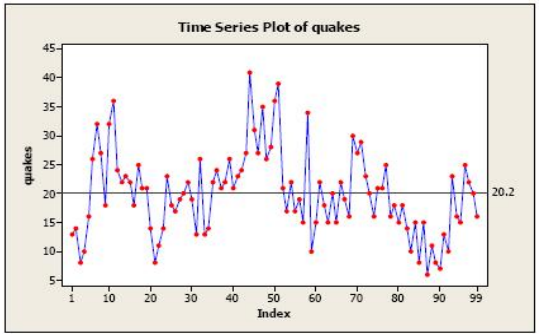

2.1 数据对象与属性类型

Data set concerning bridges in USA

```
E13,A,33,CRAFTS,HIGHWAY,?,2,N,THROUGH,WOOD,?,S,WOOD
E15,A,28,CRAFTS,RR,?,2,N,THROUGH,WOOD,?,S,WOOD
E16,A,25,CRAFTS,HIGHWAY,MEDIUM,2,N,THROUGH,IRON,MEDIUM,S-F,SUSPEN
E17,M,4,CRAFTS,RR,MEDIUM,2,N,THROUGH,IRON,MEDIUM,?,SIMPLE-T
E18,A,28,CRAFTS,RR,MEDIUM,2,N,THROUGH,IRON,SHORT,S,SIMPLE-T
E19,A,29,CRAFTS,HIGHWAY,MEDIUM,2,N,THROUGH,WOOD,MEDIUM,S,WOOD
E20,A,32,EMERGING,HIGHWAY,MEDIUM,2,N,THROUGH,WOOD,MEDIUM,S,WOOD
E21,M,16,EMERGING,RR,?,2,?,THROUGH,IRON,?,?,SIMPLE-T
E23,M,1,EMERGING,HIGHWAY,MEDIUM,?,?,THROUGH,STEEL,LONG,F,SUSPEN
E22,A,24,EMERGING,HIGHWAY,MEDIUM,4,G,THROUGH,WOOD,SHORT,S,WOOD
E24,O,45,EMERGING,RR,?,2,G,?,STEEL,?,?,SIMPLE-T
E25,M,10,EMERGING,RR,?,2,G,?,STEEL,?,?,SIMPLE-T
E27,A,39,EMERGING,RR,?,2,G,THROUGH,STEEL,?,F,SIMPLE-T
E26,M,12,EMERGING,RR,MEDIUM,2,G,THROUGH,STEEL,MEDIUM,S,SIMPLE-T
E30,A,31,EMERGING,RR,?,2,G,THROUGH,STEEL,MEDIUM,F,SIMPLE-T
E29,A,26,EMERGING,HIGHWAY,MEDIUM,2,G,THROUGH,STEEL,MEDIUM,?,SUSPEN
E28,M,3,EMERGING,HIGHWAY,MEDIUM,2,G,THROUGH,STEEL,MEDIUM,S,ARCH
E32,A,30,EMERGING,HIGHWAY,?,2,G,THROUGH,IRON,MEDIUM,F,SIMPLE-T
E31,M,8,EMERGING,RR,MEDIUM,2,G,THROUGH,STEEL,MEDIUM,S,SIMPLE-T
E34,O,41,EMERGING,RR,LONG,2,G,THROUGH,STEEL,LONG,F,SIMPLE-T
E33,M,19,EMERGING,HIGHWAY,MEDIUM,?,G,THROUGH,IRON,MEDIUM,F,SIMPLE-T
E36,O,45,MATURE,HIGHWAY,?,2,G,THROUGH,IRON,SHORT,F,SIMPLE-T
E35,A,27,MATURE,HIGHWAY,MEDIUM,2,G,THROUGH,STEEL,MEDIUM,F,SIMPLE-T
E38,M,17,MATURE,HIGHWAY,?,2,G,THROUGH,IRON,MEDIUM,F,SIMPLE-T
E37,M,18,MATURE,RR,MEDIUM,2,G,THROUGH,STEEL,MEDIUM,S,SIMPLE-T
E39,A,25,MATURE,HIGHWAY,?,2,G,THROUGH,STEEL,MEDIUM,F,SIMPLE-T
E4,A,27,MATURE,AQUEDUCT,MEDIUM,1,N,THROUGH,WOOD,SHORT,S,WOOD
E40,M,22,MATURE,HIGHWAY,?,2,G,THROUGH,STEEL,MEDIUM,F,SIMPLE-T
E41,M,11,MATURE,HIGHWAY,?,2,G,THROUGH,IRON,MEDIUM,F,SIMPLE-T
E42,M,9,MATURE,HIGHWAY,LONG,2,G,THROUGH,STEEL,LONG,F,SIMPLE-T
```

数据集

值通过逗号分隔

2.1 数据对象与属性类型

岩土参数数据集

depth	description	class	w_n	w_l	w_p	I_p	I_l	ρ_b	ρ_d	c_u	ϕ'	m_v	C_c
			%	%	%	%		Mg/m^3	Mg/m^3	kN/m^2	o	m^2/MN	
1		CL						2.11			0		
6.5	soft grey marine	CV	39					1.81	1.31	11.00	0		0.20
27.5	soft grey marine	CV	50	83	29	54	0.39	1.66	1.11	41.00	0		0.72
6.5	v soft grey mar	CV	49	78	29	49	0.41	1.62	1.07	12.00	0		
9.6	v soft grey mar	CV	58	83	29	54	0.54	1.59	1.00	7.00	25.00		
12.5	v soft grey mar	CV	67	81	28	53	0.74	1.49	0.89	5.00	0.00		
21.5	stiff silty clay	CH	26	63	24	39	0.05	1.94	1.54				
12.5	v soft grey mar	MV	47	90	42	48	0.10	1.57	1.07				0.77
30.5	v soft grey mar	CV	48	76	28	48	0.42	1.69	1.15				0.49
8.0	v stiff clayey si	CL	22	30	20	10	0.19	1.12	1.74	26.00	3.50		
12.7	v soft grey mar	CE	58	93	22	71	0.51	1.66	1.05	25.00	0.00	0.52	0.69
18.6	firm grey silty c	CH	33	65	22	43	0.26	1.93	1.45	87.00	4.00		
21.7	v soft grey mar	CV	45	84	22	62	0.36	1.78	1.23	17.00	0.00	0.33	
24.7	v stiff grey silty	CH	25	55	22	33	0.09	1.99	1.57	46.00	5.60		
27.7	firm dark grey s	CH	43	58	22	36	0.57	1.81	1.27	40.00	3.00		0.58
17.1	v soft grey mar	CH	27	57	22	35	0.14	1.98	1.56	107.00	5.00		
26.2	soft grey clay	CH	50					1.67	1.13			0.28	0.61
30.7	stiff silty clay	CH	30	58	22	36	0.21	1.96	1.51	58.00	4.80		
12.5	soft grey clay	CV	61	84	29	55	0.58	1.57	0.98	19.00	0.00		0.68
27.5	soft grey clay	CV	49	71	26	45	0.51	1.66	1.11	17.00	0.00		0.56
21.5	clayey silt with	CL	22	33	15	18	0.39	1.95	1.59	22.00	0.00		0.16
20.7	v soft grey mar	CV	48	82	22	60	0.43	1.76	1.19	29.00	0.00	0.37	0.16
11.2	soft grey marine	CL	58.3					1.66	1.05	20.00	0.00	0.62	0.67

直接取自电子表格的格式

2.1 数据对象与属性类型

数据

- 数据是指对客观事件进行记录并可以鉴别的符号，是对客观事物的性质、状态以及相互关系等进行记载的物理符号或这些物理符号的组合。
- 数据可能存储在数据库、数据仓库和其他信息资料库中。

类型

- 连续型：数值
- 离散型：标称、二元、序数

主要问题

- 不一致、错误、缺失 等

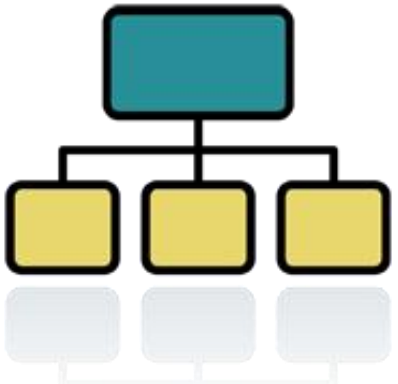

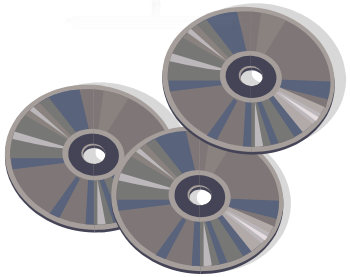

2.1.1 数据对象

- 数据集由数据对象(data objects)组成。
- 一个数据对象代表一个实体。
  - 销售：顾客、商品或者销售记录
  - 医疗：患者、药品
  - 大学：学生、老师、课程
- 数据对象用属性来描述。
- 数据对象可以是一个记录、数据点、实体、样本、实例或者对象等。如果数据对象存放在数据库中，它们是数据元组。即数据库中行对应数据对象，列对应于属性。

2.1.1 数据对象

行 ->数据对象；

列 ->属性.

Attributes

Objects

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

2.1.2 数据属性

- 一个属性是一个域，表示一个数据对象的一个特征。
- “属性”、“维度”、“特征”和“变量”这些词在语义上是可交换的。“维度”通常被用在数据仓库中，机器学习中倾向于使用“特征”；统计学倾向使用“变量”，数据挖掘和数据库经常使用“属性”。属性描述一个顾客对象，如：顾客ID，姓名，地址。
- 对给定属性的可观察值被称为观察。刻画一个给定对象的属性集合被称为属性向量（或特征向量）。

2.1.2 数据属性

- 数据属性
  - 标称属性
  - 二元属性
  - 序数属性
  - 数值属性
- 离散属性vs连续属性

标称属性

- 标称属性的值是事物的标号或者名称。
- 每一个值表示类别、编码或者状态。
- 值没有次序信息。
- 在计算机领域，也可以称为枚举型。
- 举例
  - Hair_color = {black, blond, brown, grey, red, white}
  - marital status={single, married, divorced, widowed}
  - Occupation={teacher, dentist, programmer, farmer, and so on}
- 数学运算→ 有没有意义？

{black---1, blond---2, brown---3,
grey---4, red---5, white---6}

二元属性

- 二元属性只有两个类别或状态 (0 and 1)
  - 0通常表示该属性不出现，1表示出现
- 布尔属性：true,false

  例如: smoker (1-smokes, 0-not); medical test (1-positive, 0-negative)

  注意，二元属性是标称属性的特例

- 对称的二元属性（Symmetric binary）：它的两种状态具有同等价值并携带相同的权重
  - e.g., gender（性别）

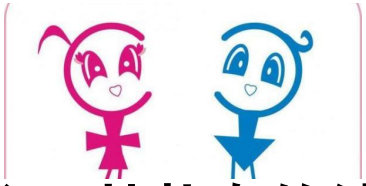

- 非对称的二元属性（Asymmetric binary）：其状态的结果不是同样重要的
  - e.g., 疾病化验(positive vs. negative)
  - Convention: assign 1 to most important outcome (e.g., HIV positive)
- 数学运算→ 有没有意义？

序数属性

- 可能的值之间具有有意义的序或秩评定(ranking)
- 但是相继值之间的差是未知的
  - Size = {small, medium, large},
  - Grade = {A+,A-,A,B+,…}
  - 序数属性可以用来记录不能客观度量的主观质量评估

在调查中常用来排序。

例如，参与者作为顾客，他们的满意度可以是：

0非常不满意，1有点不满意，2中立，3满意，4很满意

- 数学运算→ 有没有意义？

标称、二元和序数属性总结

- 定性的，描述对象的特征，而不给出实际大小或数量。
- 定性属性通常是代表类别的词。
- 如果使用整数，则代表类别的编码，而不是测量的量。

数值属性

- 定量的 (整数或实数):
  - 区间标度属性（Interval-scale attributes）
    - 用相等的单位尺度度量
    - 区间属性的值有序，可以为正，0，负，允许定量评估值之间的差
    - 没有真正的零值

例如：摄氏温度没有真正的零点，即：$0C^{\circ}$不表示“没有温度”，尽管可以计算温度值之差，但是不能说一个温度值是另一个的倍数。

温度$10C^{\circ}$比$5C^{\circ}$高出$5C^{\circ}$，但是可以说$10C^{\circ}$比$5C^{\circ}$温暖2倍吗？

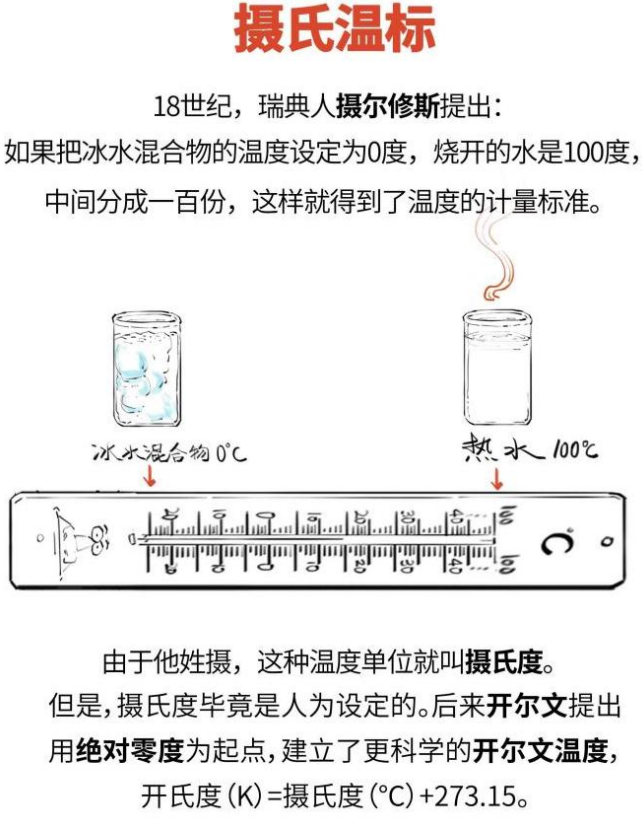

数值属性

- 定量的 (整数或实数):
  - 比率标度属性（Ratio-scale attributes）
    - 具有固定零点的数值属性
      例如：开氏温标、字数、货币数量、工作年限
    - 有序
    - 可以说一个值是另一个的倍数（或比率）
      (10 K° 是5 K°的两倍, 100元比1元富有100倍)

离散 vs 连续属性

- **离散属性**
  - 具有有限或无限可数个值
  - 可以用或不用整数表示
    - 例如：发色、是否吸烟、医学检查结果、饮料尺寸、邮政编码、电话号码等
- **连续属性**
  - 连续值是实数
  - 实数值用有限位数字表示
  - 连续属性一般用浮点变量表示
  - 如果值不是离散的，则是连续的。数值属性或者连续属性是含义上是一样的。
    - 例如：温度、高度、宽度等

离散 vs 连续属性

- 离散属性：定性的
  - 标称属性
  - 二元属性
  - 序数属性
- 连续属性：定量的
  - 数值属性
    - 区间标度属性
    - 比率标度属性

离散 vs 连续属性

属性的特性

The type of an attribute depends on which of the following properties it possesses:

- Distinctness: = ≠
- Order: < >
- Addition: + -
- Multiplication: * /

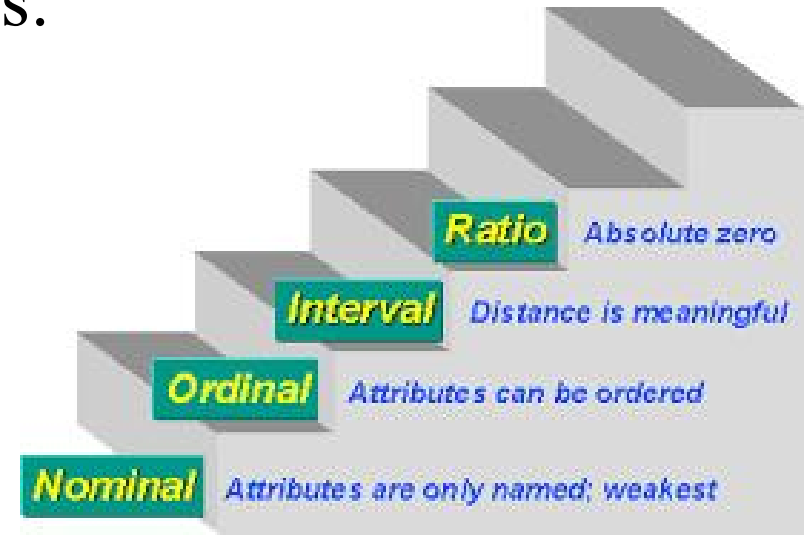

- 标称属性: distinctness
- 序数属性: distinctness & order
- 区间标度属性: distinctness, order & addition
- 比率标度属性: all 4 properties

示例1

预测是否适合打高尔夫球

Day	Outlook	Temperature	Humidity	Windy	Play Golf?
1	Sunny	85	85	False	No
2	Sunny	80	90	True	No
3	Overcast	83	78	False	Yes
4	Rainy	70	96	False	Yes
5	Rainy	68	80	False	Yes
6	Rainy	65	70	True	No
7	Overcast	64	65	True	Yes
8	Sunny	72	95	False	No
9	Sunny	69	70	False	Yes
10	Rainy	75	80	False	Yes
11	Sunny	75	70	True	Yes
12	Overcast	72	90	True	Yes
13	Overcast	81	75	False	Yes
14	Rainy	71	80	True	No

- 数据属性
  - 标称属性
  - 二元属性
  - 序数属性
  - 数值属性
- 离散属性

  连续属性

示例2

移动设备用户年龄和性别预测

特征字段	字段描述
device_id	用户对应设备号，唯一表示，无重复
gender	用户性别，0为男性，1为女性
age	用户年龄
phone_brand	手机品牌
device_model	手机型号
event_id	事件id
app_id	应用程序id
is_installed	是否安装
is_active	是否激活

device_id	gender	age	phone_bra	device_model
0	0	35	0	0
1	1	37	1	1
2	0	32	1	2
3	1	28	1	2
4	0	75	2	3
5	0	25	0	4
6	0	27	3	5

event_id	app_id	is_installed	is_active	device_id	tag_list	date
280934	224	1	0	1	[1012]	4
280934	375	1	1	1	[713, 704, 548, 756, 761, 777, 782, 787, 25	4
280934	1	1	1	1	[713, 704, 548]	4
280934	458	1	1	1	[549, 713, 724, 548, 704, 130]	4
280934	2	1	0	1	[549, 710, 704, 548, 172]	4

示例3

房价预测

	A	B	C	D	E	F
1	link	title	model	community	built	region
2	https://sh.lianjia.com/ersh	中凯城市之光(静安) 2室1	| 2室1厅 | 79.47平米 | 南	中凯城市之光(静安)	中楼层(共34层)2003年建	南京西路
3	https://sh.lianjia.com/ersh	中凯城市之光(静安) 2室1	| 2室1厅 | 83.79平米 | 南	中凯城市之光(静安)	中楼层(共34层)2003年建	南京西路
4	https://sh.lianjia.com/ersh	古美小区 2室1厅 285万	| 2室1厅 | 59.82平米 | 南	古美小区	高楼层(共6层)1990年建板	古美
5	https://sh.lianjia.com/ersh	荣乐小区 2室1厅 205万	| 2室1厅 | 55.1平米 | 南 |	荣乐小区	低楼层(共6层)1986年建板	松江老城
6	https://sh.lianjia.com/ersh	稀 缺房源 中高区大三房	| 3室2厅 | 144平米 | 西南	慧芝湖花园	中楼层(共36层)2009年建	大宁
7	https://sh.lianjia.com/ersh	云舫小区 2室2厅 460万	| 2室2厅 | 75.41平米 | 东	云舫小区	低楼层(共18层)1989年建	北外滩
8	https://sh.lianjia.com/ersh	2+1户型+产权车位+地铁	| 3室2厅 | 130.31平米 |	苏堤春晓名苑	中楼层(共32层)2005年建	长寿路
9	https://sh.lianjia.com/ersh	银都新村(1至7区) 2室1厅	| 2室1厅 | 65.44平米 | 南	银都新村(1至7区)	低楼层(共6层)1995年建板	颛桥
10	https://sh.lianjia.com/ersh	品质小区，精装修，有产	| 3室2厅 | 115.22平米 |	海华花园	低楼层(共33层)1994年建	打浦桥
11	https://sh.lianjia.com/ersh	香榜小区 2室1厅 380万	| 2室1厅 | 62.75平米 | 南	香榜小区	中楼层(共6层)1995年建板	张江

G	H	I	J
num	traffic	price	单价（每平米）
414人关注 / 共269次带看	距离2号线南京西路站649	750	94376
147人关注 / 共193次带看	距离2号线南京西路站596	850	101445
322人关注 / 共49次带看 /	距离12号线东兰路站649	285	47643
75人关注 / 共34次带看 /	距离9号线松江体育中心	205	37206
10人关注 / 共11次带看 /	距离1号线上海马戏城站	1320	91667
88人关注 / 共62次带看 /	距离4号线大连路站378米	460	61000
52人关注 / 共28次带看 /	距离7号线长寿路站892米	1130	86717
80人关注 / 共49次带看 /	房本满五年	275	42024
95人关注 / 共117次带看 /	距离9号线打浦桥站237米	890	77244
71人关注 / 共47次带看 /	距离2号线广兰路站1151	380	60558
39人关注 / 共41次带看 /	距离1号线新闸路站294米	1380	91409
17人关注 / 共64次带看 /	距离1号线上海体育馆站	1050	92773

2 认识数据

2.1 数据对象与属性类型

2.2 数据的基本统计描述

2.3 数据可视化

2.4 度量数据的相似性和相异性

2.2 数据的基本统计描述

统计描述的目标是为了更好地理解数据

- 2.2.1 中心趋势度量(Central tendency)

  度量数据分布的中部或中心位置

  均值、中位数、中列数、众数

- 2.2.2 度量数据散布(Spread)

  数据如何分散

  (1) 极差、分位数、四分位数、四分位数极差

  (2) 五数概括

  (3) 方差和标准差

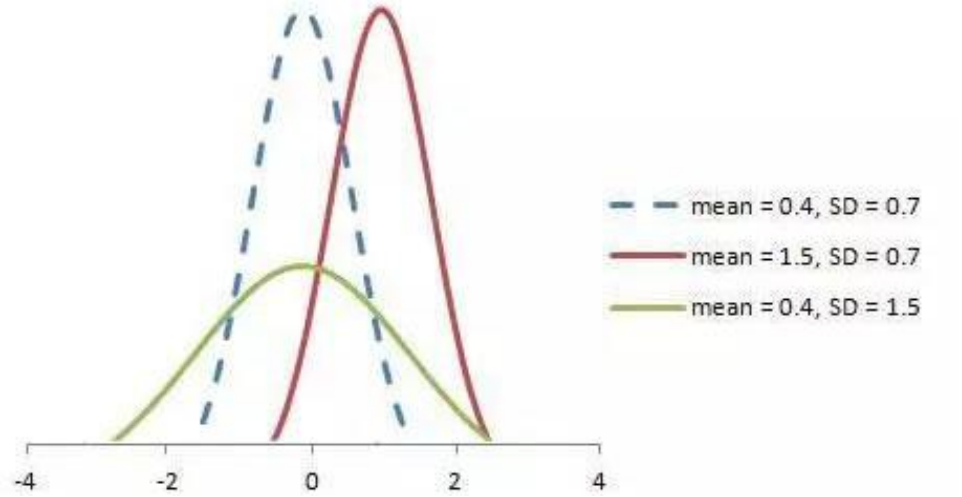

2.2.1中心趋势度量——均值

- 均值(algebraic measure):

$$\bar{x} = \frac{\sum_{i=1}^{N} x_i}{N} = \frac{x_1 + x_2 + \cdots + x_N}{N}$$

- 加权算术均值或加权平均（Weighted arithmetic mean）：

$$\bar{x} = \frac{\sum_{i=1}^{N} w_i x_i}{\sum_{i=1}^{N} w_i} = \frac{w_1 x_1 + w_2 x_2 + \cdots + w_N x_N}{w_1 + w_2 + \cdots + w_N}$$

权重w代表的是重要性、发生频率等

- 截尾均值（Trimmed mean）：

丢弃高低极端值后的均值

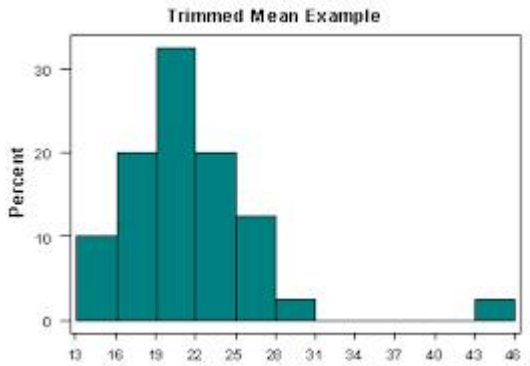

2.2.1中心趋势度量——中位数

- Median （中位数）
  - 按顺序排列的一组数据中居于中间位置的数，代表一个样本、种群或概率分布中的一个数值，其可将数值集合划分为相等的上下两部分。
  - 对于有限的数集，可以通过把所有观察值高低排序后找出正中间的一个作为中位数。
  - 如果观察值有偶数个，通常取最中间的两个数值的平均数作为中位数。
  - 找出这组数据：23、29、20、32、23、21、33、25的中位数 ？

2.2.1中心趋势度量——中位数

- Median （中位数）
  - 当观测的数量很大时，中位数的计算开销很大。对于数值属性，很容易用插值计算出中位数的近似值。

$$median = L_1 + \left(\frac{\frac{N}{2} - (\sum freq)_l}{freq_{median}} \right) width$$

公式中，L_1是中值区间的最低值，N是数据值的个数，$(\sum freq)_l$是所有低于中值区间的所有区间的频率之和。 $freq_{median}$是中值区间的频率，width是中值区间的宽度（极差）。

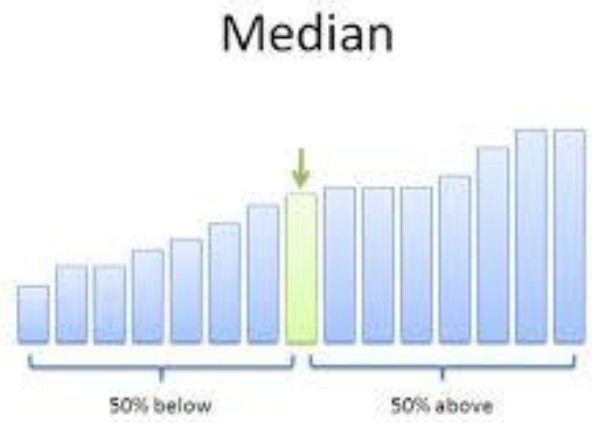

年龄	频数
1~3	100
4~10	250
11~20	2000
21~30	600
31~60	850
61~80	66

2.2.1中心趋势度量——中列数

- 中列数：
  - 是数据集中最大值和最小值的平均值。
  - 可以用来评估数值型数据的中心性趋势。

2.2.1中心趋势度量——众数

- 众数（Mode）
  - 集合中出现最频繁的值
  - 可能最高频率对应多个不同值，导致多个众数
  - 单峰的、双峰的、三峰的
  - 极端的情况下，如果每个值都仅出现一次，则没有众数

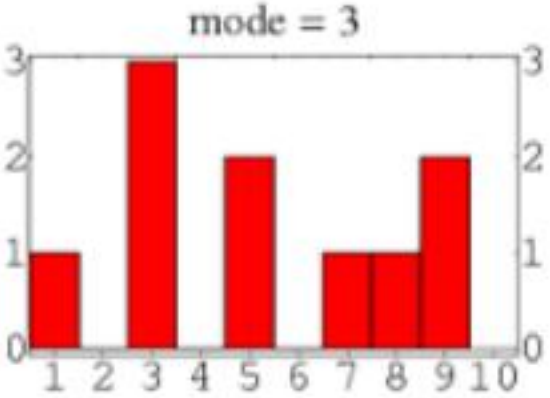

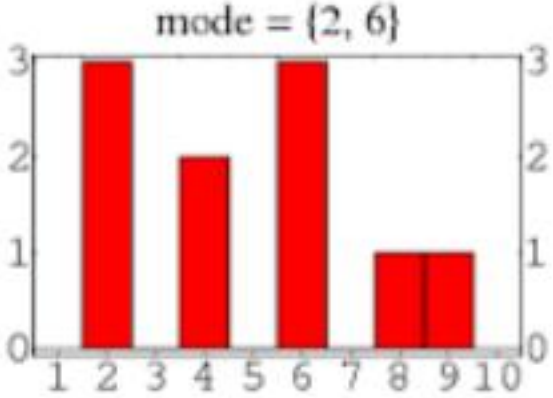

2.2.1中心趋势度量——众数

- Mode（众数）
  - 是一组数据中出现次数最多的数值，有时众数在一组数中有好几个，是在统计分布上具有明显集中趋势点的数值，代表数据的一般水平。

2.2.1中心趋势度量

- 均值，中位数，众数区别

1、平均数是通过全部数据计算得到的，因此它会因每一个数据的变化而变化。

2、中位数是通过排序得到的，它不受最大、最小两个极端数值的影响。部分数据的变动对中位数没有影响，当一组数据中的个别数据变动较大时，常用它来描述这组数据的集中趋势。

3、众数也是数据的一种代表数，反映了一组数据的集中程度。日常生活中诸如“最佳”、“最受欢迎”、“最满意”等，都与众数有关系，它反映了一种最普遍的倾向。

0, 1, 5, 5, 6, 8, 100
0, 1, 5, 5, 6, 8, 10

2.2.1中心趋势度量

- 标称属性: {black---1, blond---2, brown---3, grey---4, red---5, white---6}
- 序数属性: 0非常不满意，1有点不满意，2中立，3满意，4很满意
- 区间标度属性:摄氏温度$0C^{\circ}$、$5C^{\circ}$、$10C^{\circ}$
- 比率标度属性:分数60、70、80
- 计算这些值有意义吗？
  - 众数 (?)
  - 中位数 (?)
  - 均值 (?)
  - 计算值之间的差 (?)
  - 比率(?)

1 1 2 3 1

80 81 60 90 80

Attribute Type	Description	Examples	Operations
标称 Nominal	The values of a nominal attribute are just different names, i.e., nominal attributes provide only enough information to distinguish one object from another. (=, ≠)	zip codes, employee ID numbers, eye color, sex: {*male, female*}	mode
序数 Ordinal	The values of an ordinal attribute provide enough information to order objects. (<, >)	hardness of minerals, {*good, better, best*}, grades, street numbers	Mode, median
区间 Interval	For interval attributes, the differences between values are meaningful, i.e., a unit of measurement exists. (+, -)	calendar dates, temperature in Celsius or Fahrenheit	Mode, median, mean, standard deviation
比率 Ratio	For ratio variables, both differences and ratios are meaningful. (*, /)	temperature in Kelvin, monetary quantities, counts, age, mass, length, electrical current	Mode, median, mean, standard deviation, ratio

2.2.1中心趋势度量

- 在具有完全对称的数据分布的单峰频率曲线中，均值、中位数和众数都是相同的中心值。
- 在大部分实际应用中，数据都是不对称的。它们可能是正倾斜的，其中众数出现在小于中位数的值上；或者是负倾斜的，众数出现在大于中位数的值上。

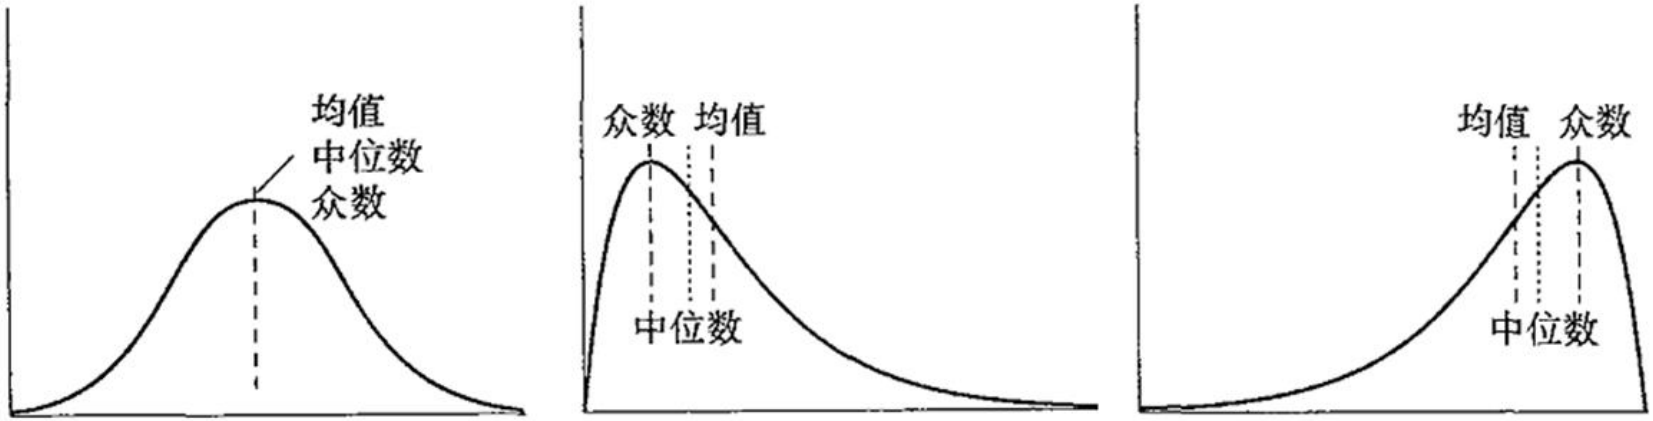

a）对称数据　　b）正倾斜数据　　c）负倾斜数据

2.2.2度量数据散布

考察评估数值数据散布或发散的度量。

- 极差（Range）
- 分位数（quantiles）
- 四分位数（quartiles）
- 四分位数极差（interquartile range）
- 五数概括
- 方差
- 标准差

2.2.2度量数据散布

- 极差表示的是最大值和最小值的差
- 分位数（quantile）是取自数据分布的每隔一定间隔上的点，把数据划分成基本上大小相等的连贯集合。
- 四分位数（quartile）：Q_1 (25th percentile), Q_3 (75th percentile)
- 四分位数极差: $IQR = Q_3 - Q_1$

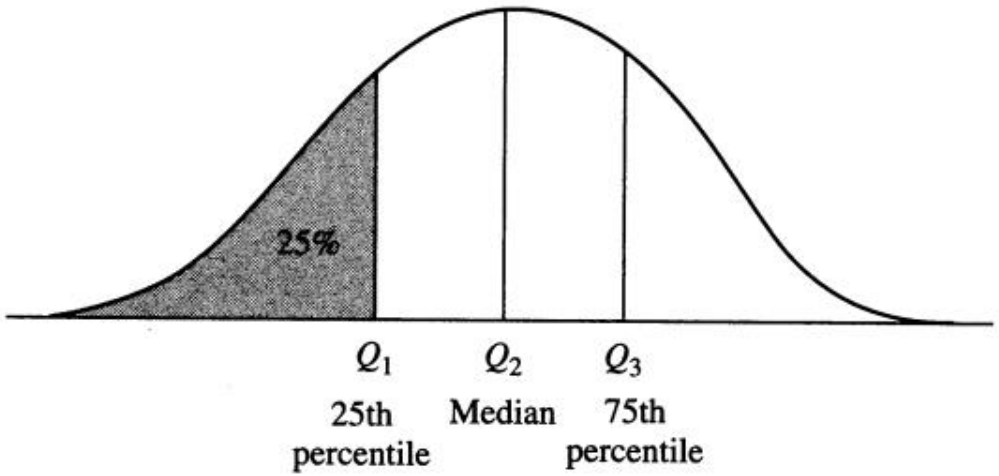

2.2.2度量数据散布

如何计算四分位数？

- 1) 对所有数据进行排序
- 2) 计算$(n+1)*f\%=j+q$

  其中n是数据个数，f是分位数，j是个整数

  - 如果$q=0$, $x(j)$ 是 $f\%$的分位数
  - 如果q不等于0, quantile $f\%=0.5*x(j)+0.5*x(j+1)$

2.2.2度量数据散布

练习：

- Example 1:　3,5,7,6,4,8,9

  排序：3,4,5,6,7,8,9

  n=7

  f%=25%：(n+1)*f%=8*25%=2　　j=2　q=0　$\boldsymbol{x}(j)=\boldsymbol{x}(2)=4$

  f%=50%：(n+1)*f%=8*50%=4　　j=4　q=0　$\boldsymbol{x}(j)=\boldsymbol{x}(4)=6$

  f%=75%：(n+1)*f%=8*75%=6　　j=6　q=0　$\boldsymbol{x}(j)=\boldsymbol{x}(6)=8$

2.2.2度量数据散布

Example 2:　2,6,5,3,4,7

如果q不等于0, quantile f%=0.5*$x(j)$+0.5*$x(j+1)$

排序：2,3,4,5,6,7

n=6

f%=25%：(n+1)*f%=7*25%=1.75　j=1　q=0.75　2.5

f%=50%：(n+1)*f%=7*50%=3.5　j=3　q=0.5　4.5

f%=75%：(n+1)*f%=7*75%=5.25　j=5　q=0.25　6.5

2.2.2度量数据散布

- 五数概括（**Five number summary)**: min, Q_1, median, Q_3, max

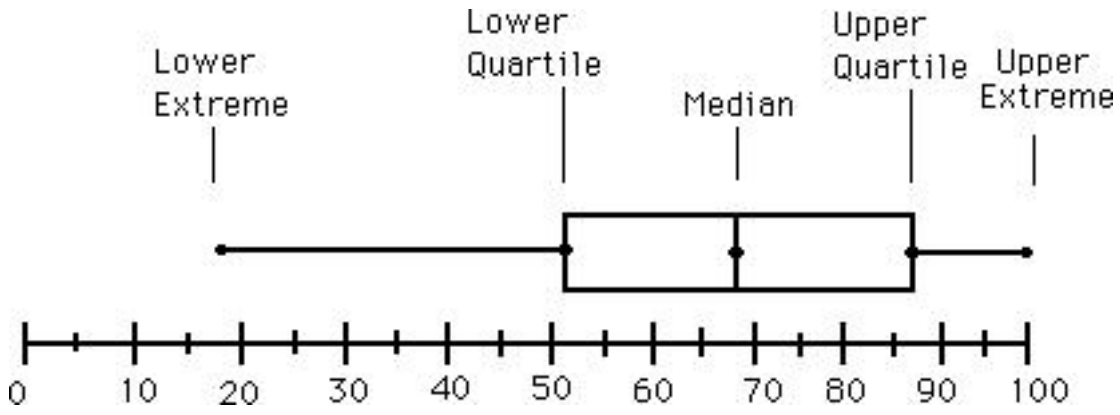

2.2.2度量数据散布

- 一个通用的鉴别可疑的离群点的规则是挑选出落在Q_3以上或者Q_1以下至少1.5*IQR以上的数据值

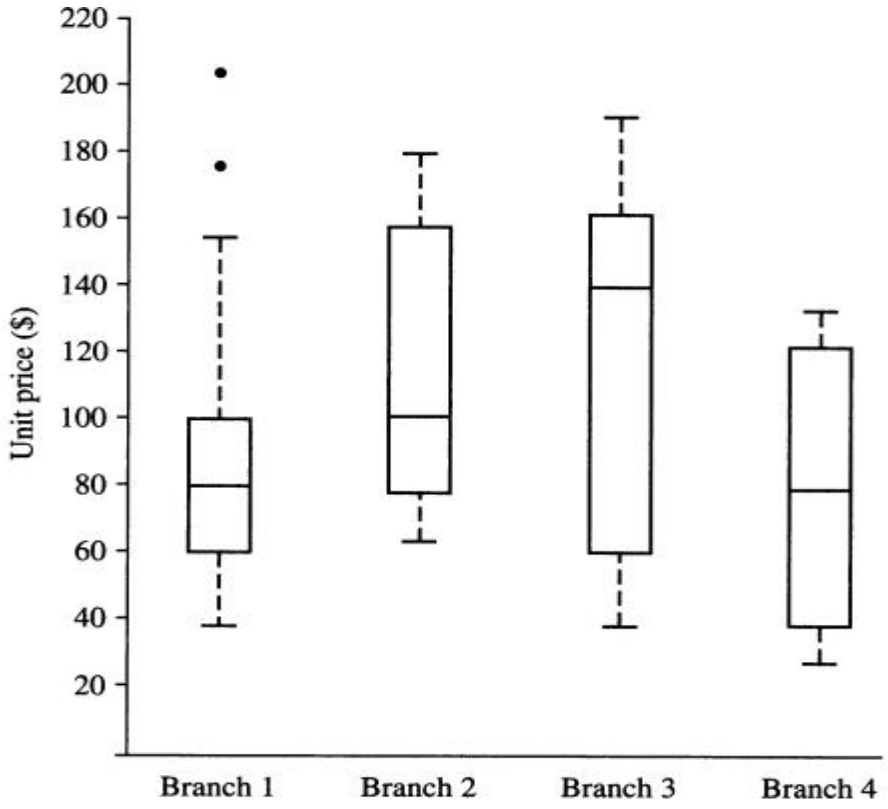

2.2.2度量数据散布

方差和标准差

方差: (algebraic, scalable computation)

$$\sigma^2 = \frac{1}{N}\sum_{i=1}^{n}(x_i - \mu)^2$$

标准差 σ 是 σ^2 的平方根。

- 方差和标准差 → 散布程度
- 均值 → 中心
- $\sigma = 0$, *no spread*; $\sigma > 0$
- 方差越小数据稳定性越强

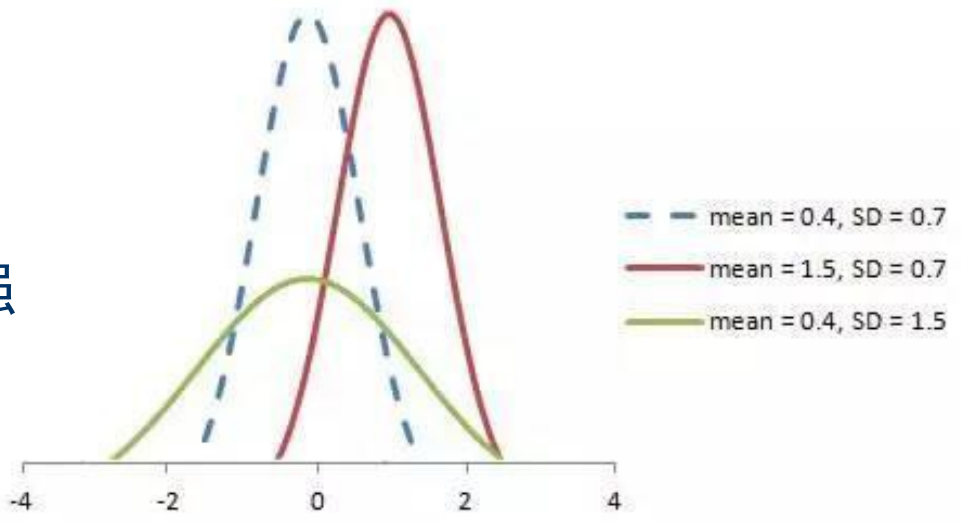

2 认识数据

2.1 数据对象与属性类型

2.2 数据的基本统计描述

2.3 数据可视化

2.4 度量数据的相似性和相异性

2.3.1 数据可视化概述

- 大数据时代的到来，每时每刻都有海量数据在不断生成，可视化成为大数据分析的重要一环。
- 20世纪50年代，随着计算机出现和计算机图形学发展，利用计算机技术在电脑屏幕上绘制出各种图形图表，可视化技术开启了全新发展阶段。

2.3.1 数据可视化概述

- 将大型数据集中的数据以图形图像形式表示，并利用数据分析和开发工具发现其中未知信息的处理过程，并以图展示出来。
- 将数据的各个属性值以多维数据的形式表示，可以从不同的维度观察数据，从而对数据进行更深入的观察和分析。

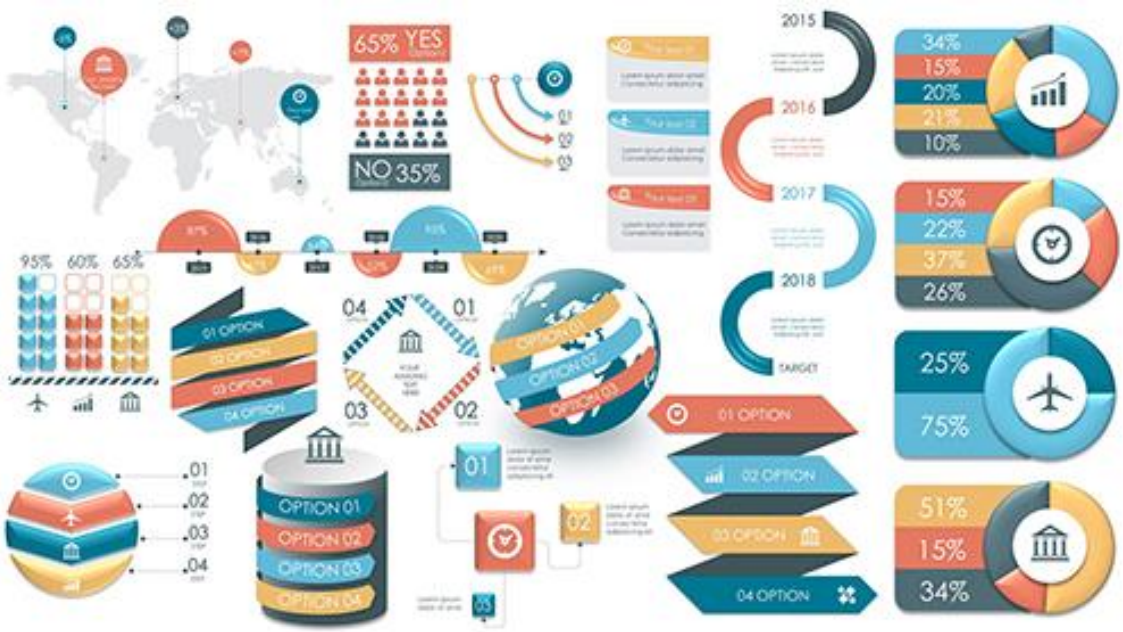

2.3.1 数据可视化概述

2.3.1 数据可视化概述

分析数据

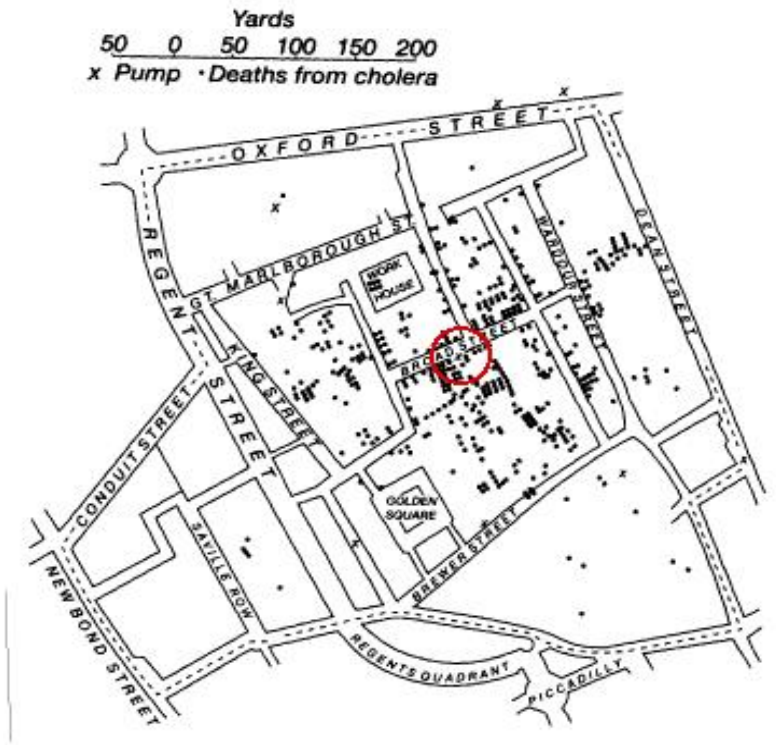

霍乱地图分析了霍乱患者分布与水井分布之间的关系，发现在有一口井的供水范围内患者明显偏多，据此找到了霍乱爆发的根源是一个被污染的水泵

反映霍乱患者分布与水井分布的地图

2.3.1 数据可视化概述

辅助理解数据

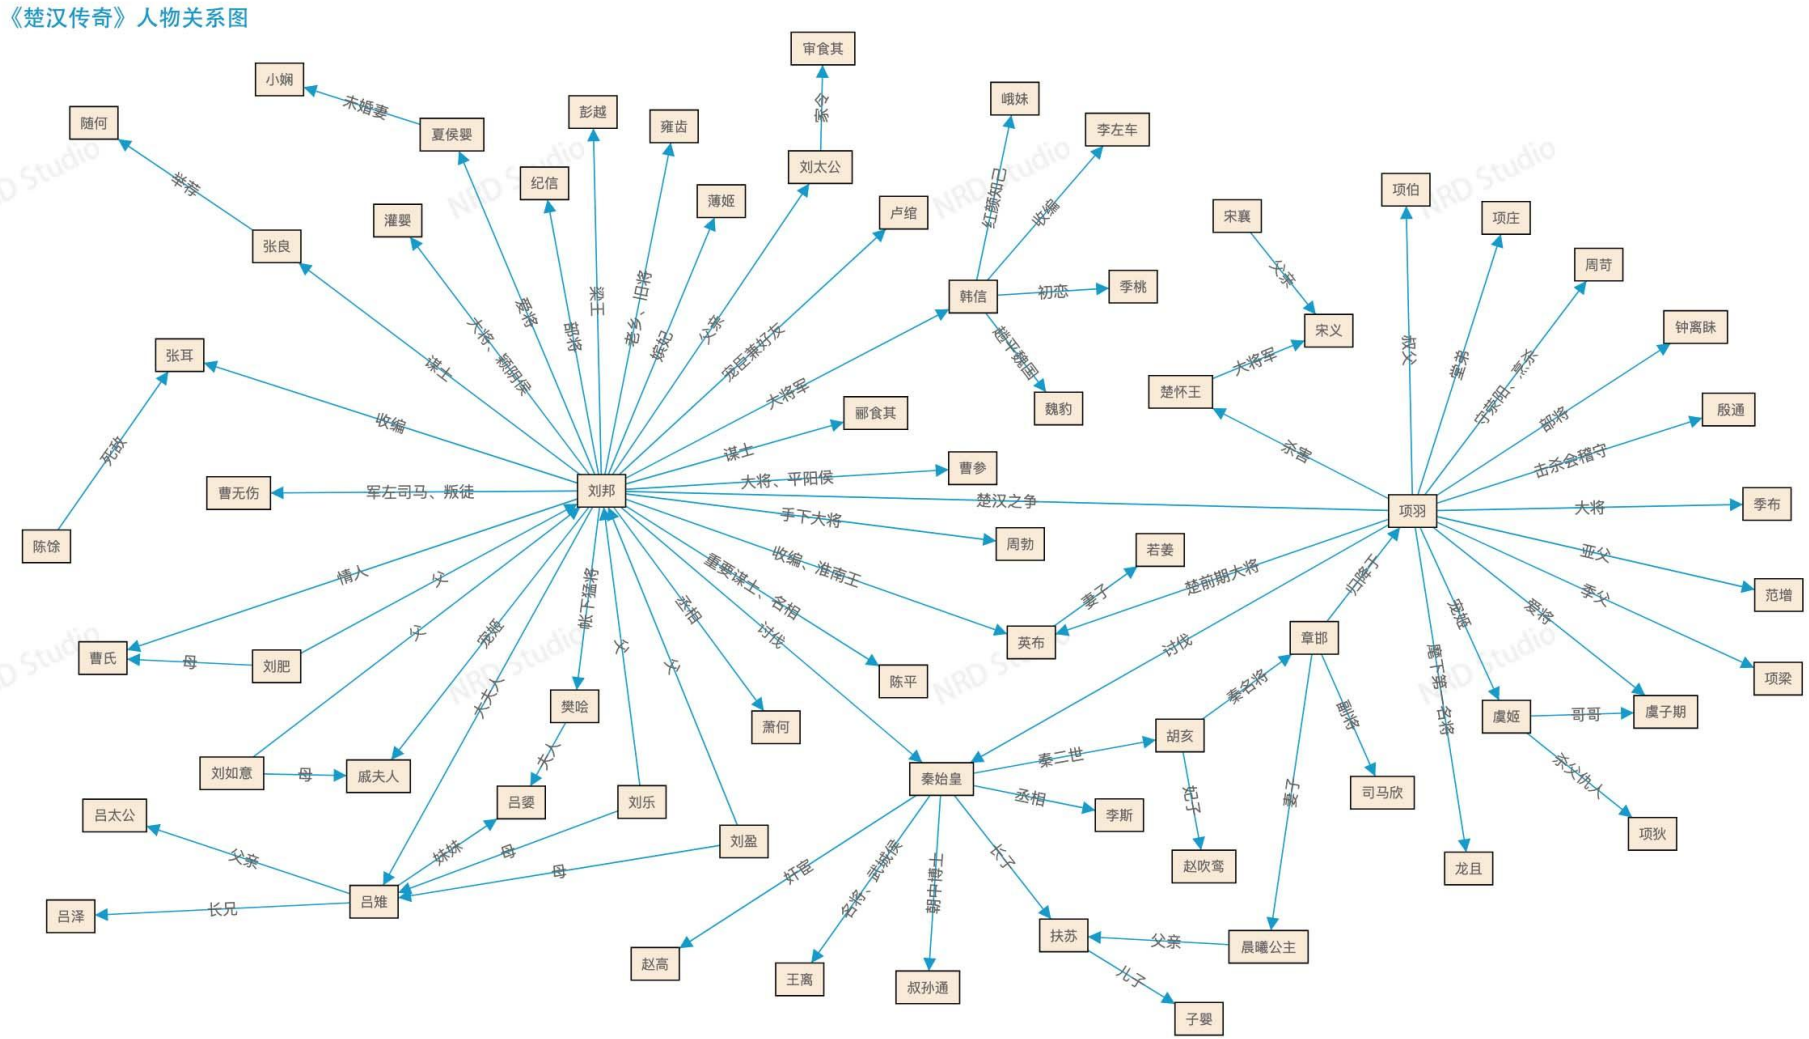

2.3.1 数据可视化概述

增强数据吸引力

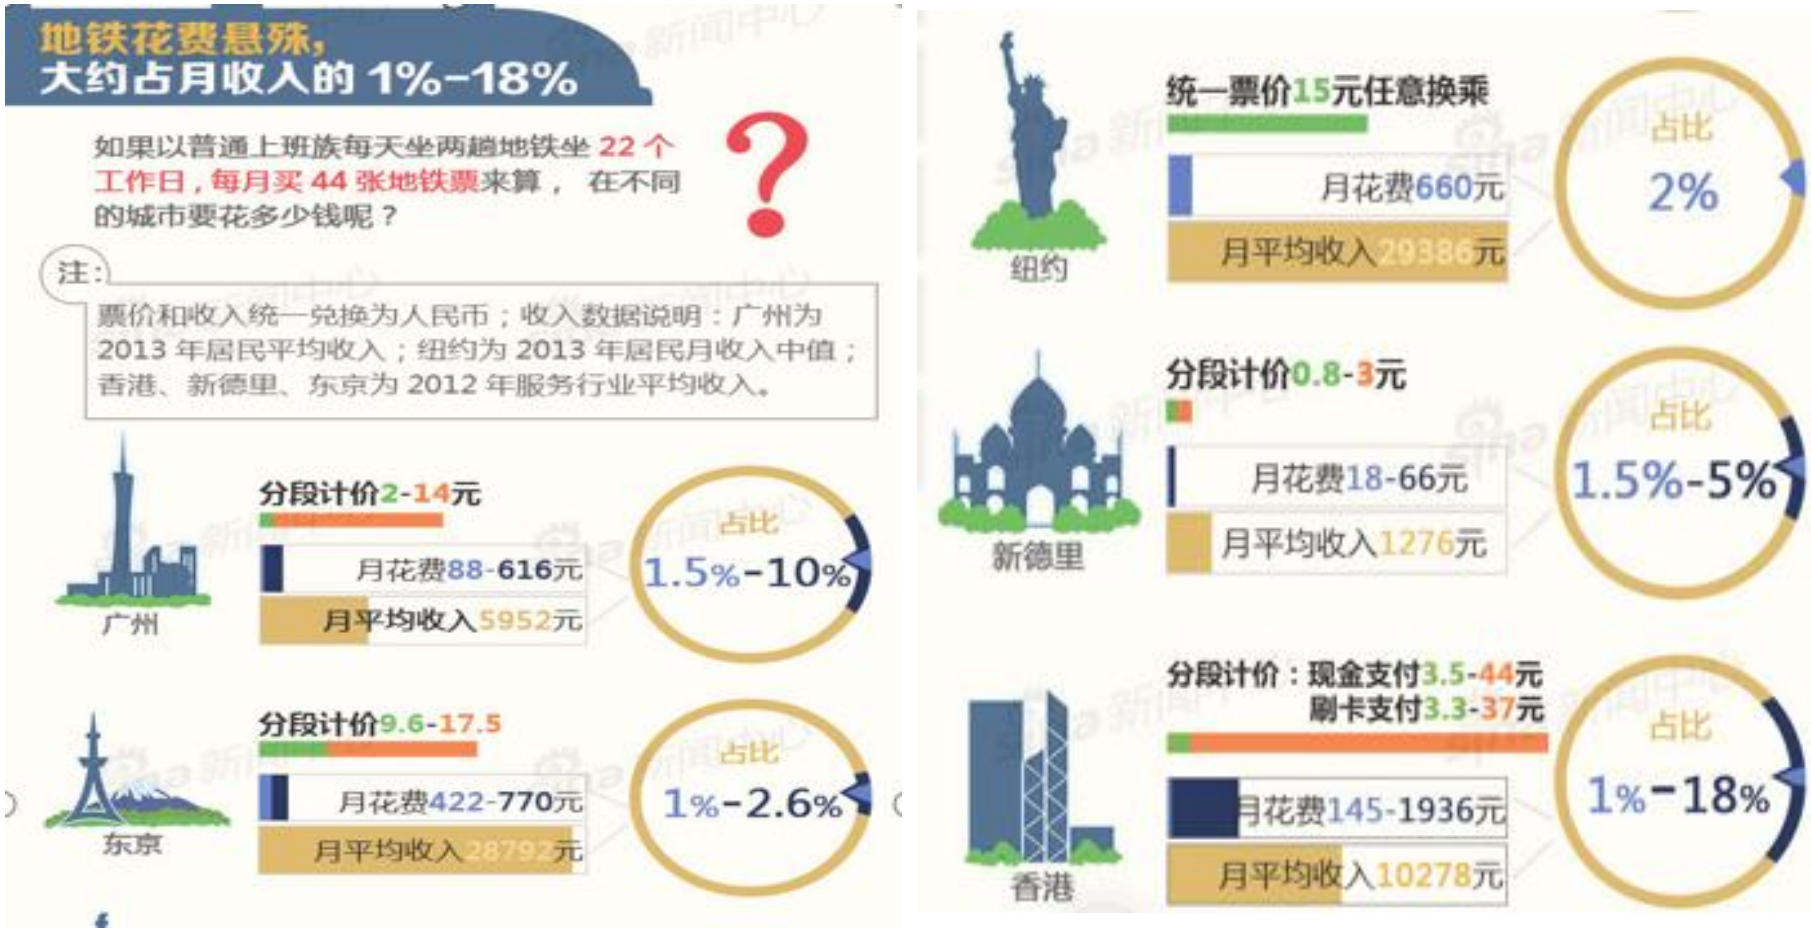

一个可视化的图表新闻实例

2.3.1 数据可视化概述

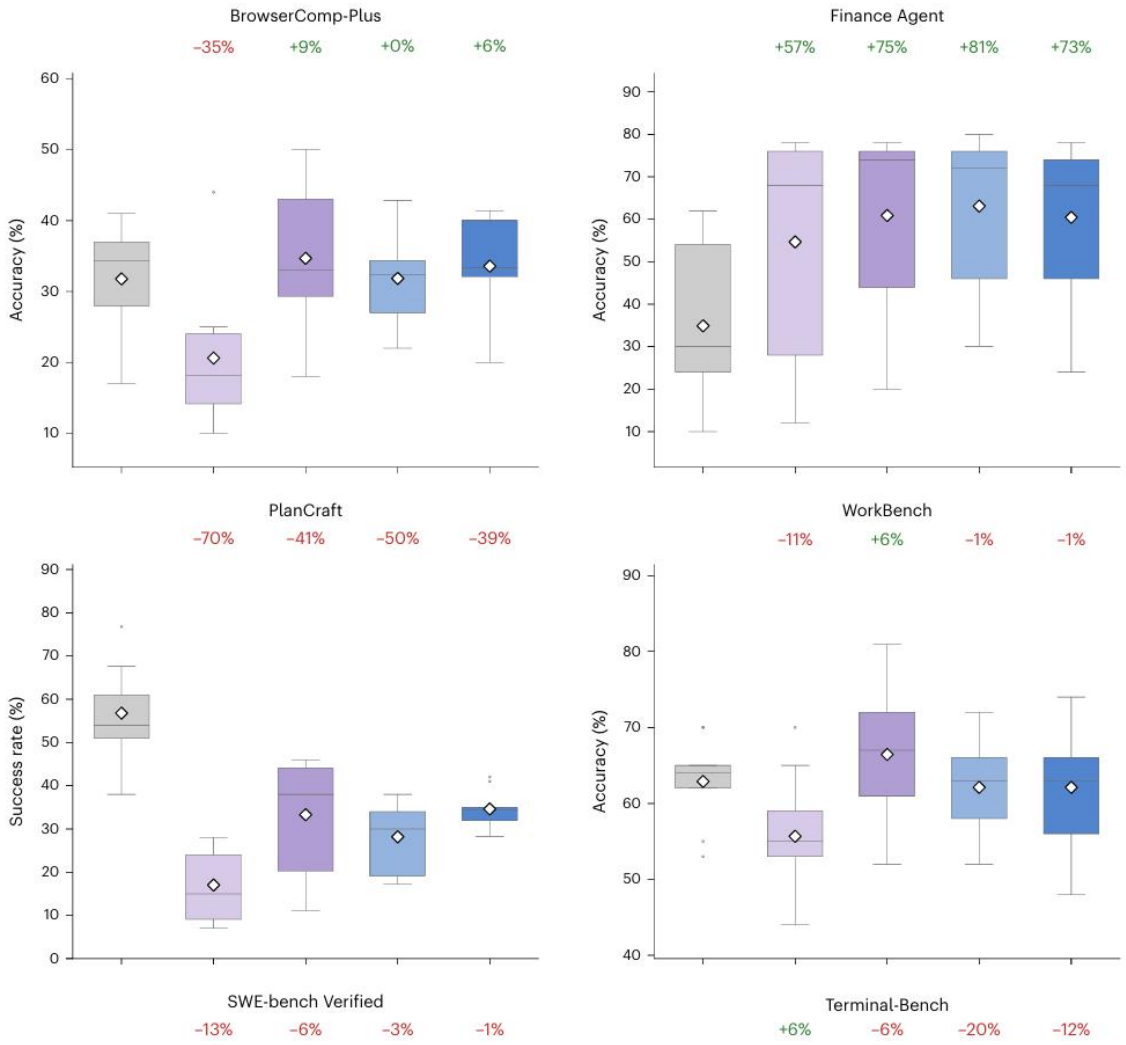

Capable language models can outgrow the benefits of collaboration, Nature Machine Intelligence, 2026

2.3.1 数据可视化概述

增强数据吸引力

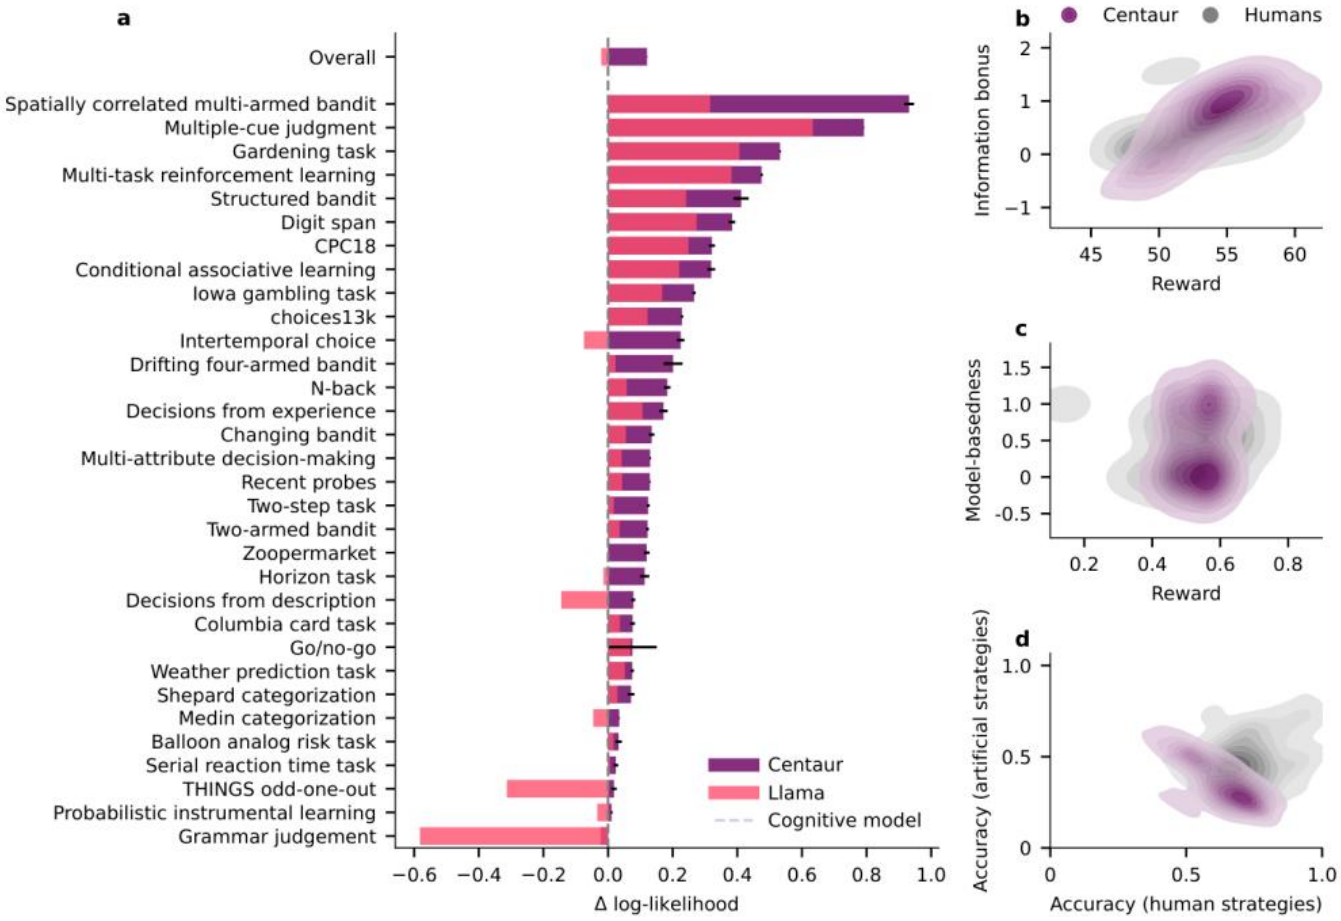

A foundation model to predict and capture human cognition, Nature, 2025

2.3.1 数据可视化概述

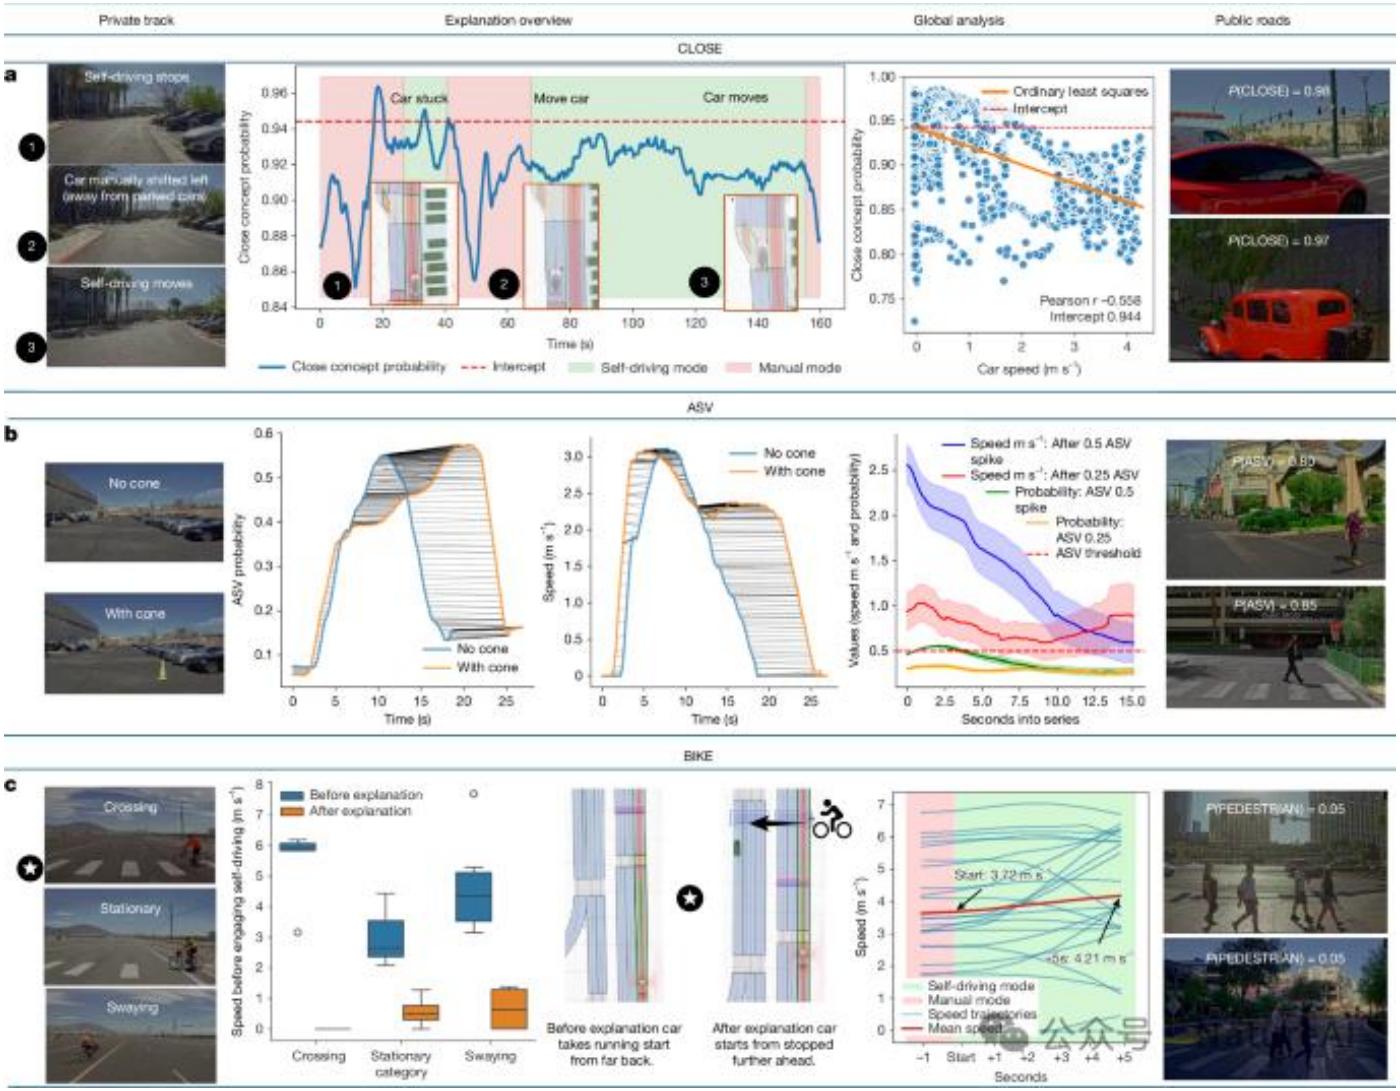

Explainable deep learning improves human mental models of self-driving cars, Nature, 2026

2.3.2 数据可视化图表

图表	维度	应用场景
柱状图	二维	指定一个分析轴进行数据大小的比较 只需比较其中一维
折线图	二维	按照时间序列分析数据的变化趋势 适用于较大的数据集
饼图	二维	指定一个分析轴进行所占比例的比较 只适用于反映部分与整体的关系
散点图	二维或三维	有两个维度需要比较
气泡图	三维或四维	其中只有两维能够精确辨识
雷达图	四维以上	数据点不超过6个

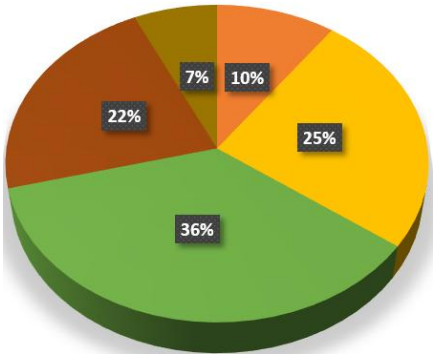

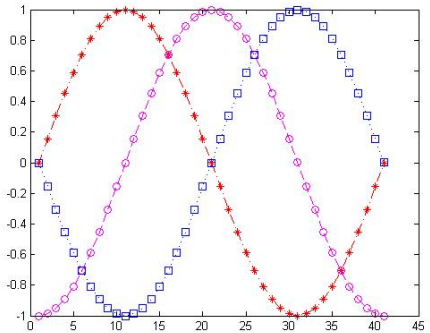

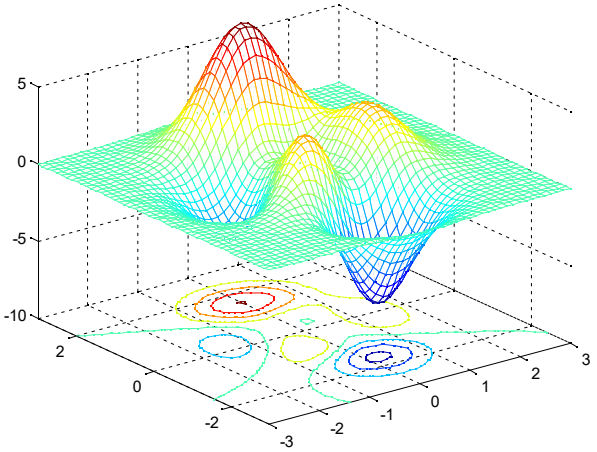

2.3.2.1 盒图

- Boxplot(盒图): Q_1,Q_2,Q_3,须,离群点 (Univariate, Bivariate)
- 盒的端点一般在四分位数上
- 箱子的长度是四分位数极差IQR
- 中位数是箱子中间的线
- 箱子外面的两根须是观察的最小值和最大值

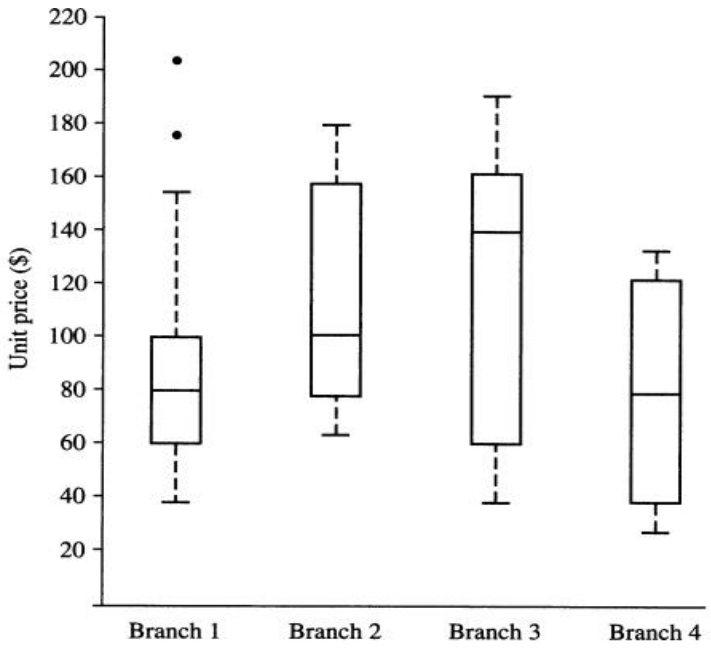

须的规则：

最大值<Q3+1.5*IQR，扩展到最大值

最小值>Q1- 1.5*IQR，扩展到最小值

最大值>Q3+1.5*IQR，扩展到Q3+1.5*IQR

最小值<Q1- 1.5*IQR，扩展到Q1- 1.5*IQR

或者[Q1- 1.5*IQR, Q3+1.5*IQR]正常范围内的最大值或最小值

2.3.2.1 盒图

- 四分位数（quartile）：Q_1 (25th percentile), Q_3 (75th percentile)
- 四分位数极差: $IQR = Q_3 - Q_1$

3 4 5 6 7 8 9

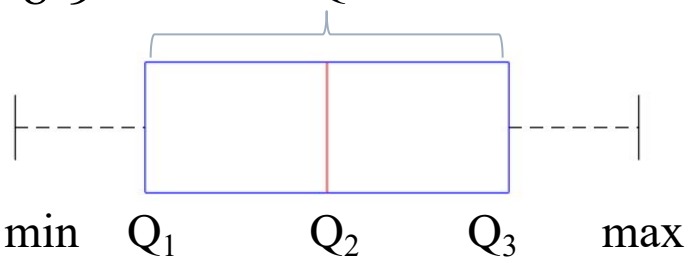

3 4 5 6 7 8 30

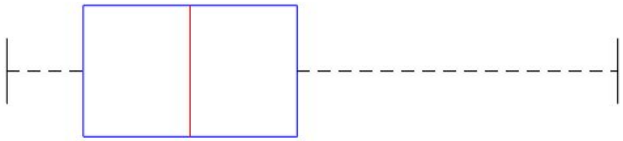

2.3.2.2 直方图

- 直方图(histogram)或频率直方图(frequency histogram) 是单数据值
- 数据区间x-axis 表示值, y-axis表示频次
  - 如果*X*是标称的，对于*X*的每一个已知值，画一个柱或竖直条，条的高度标示X值出现的频率，更多地称作条形图。
  - 如果*X*是数值的，更多使用直方图。*X*的值域被划分为不相交的连续子域，子域称作桶(bucket)或者箱(bin)，桶的范围称作宽度，通常桶是等宽的。

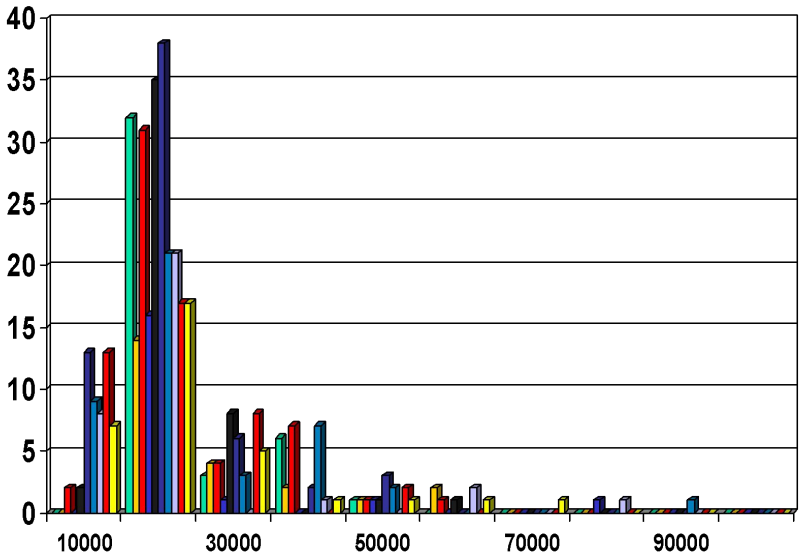

2.3.2.2 直方图

数据:

1,1,5,5,5,5,5,8,8,10,10,10,10,12,14,14,14,15,15,15,15,15,15,18,18,18,18,18,18,18,18,20,20,20,20,20,20,20,21,21,21,21,25,25,25,25,25,28,28,30,30,30

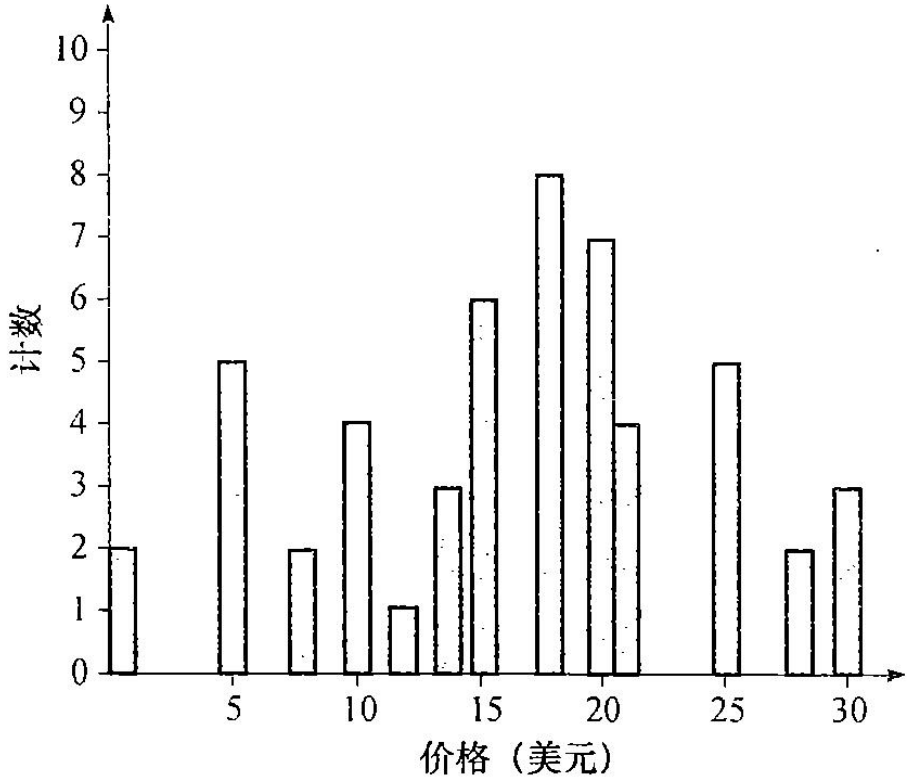

2.3.2.3 散点图

- 每个值对视为一个代数坐标对，并作为一个点画在平面上。
- 一种观察双变量数据的有用的方法，用于观察点簇和离群点。
- 可以观察两个变量之间的关系、趋势等信息。

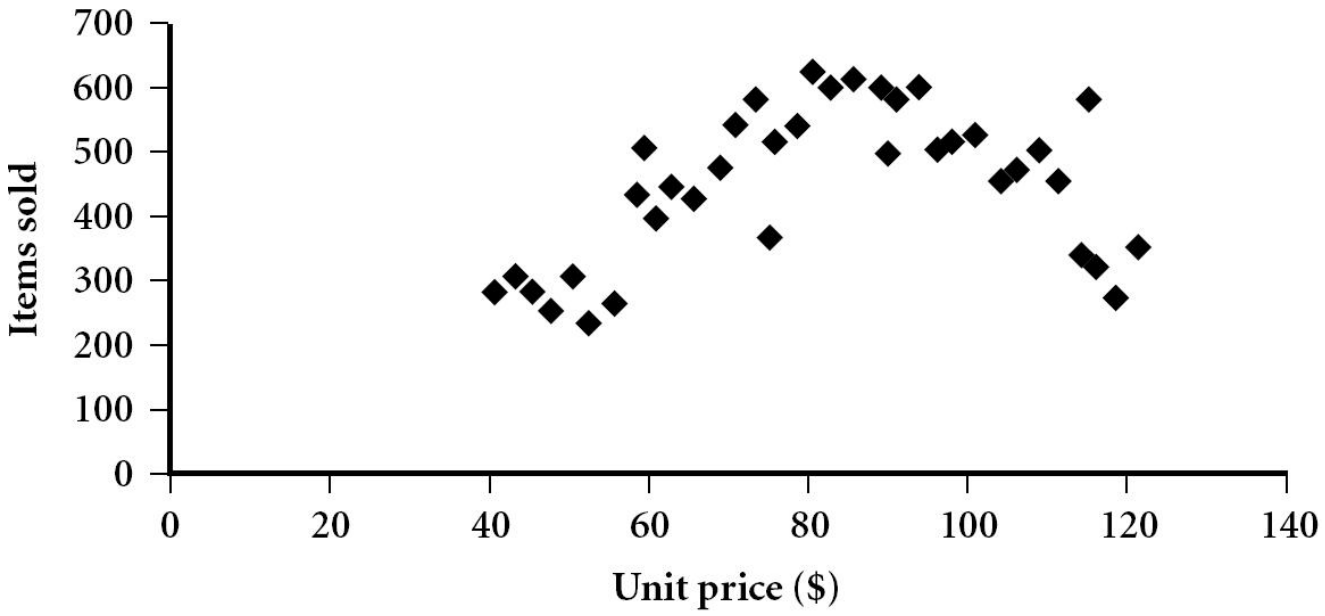

2.3.2.3 散点图

- 两个属性X和Y，如果一个属性蕴含另一个，则它们是相关的。相关可能是正、负或零相关。

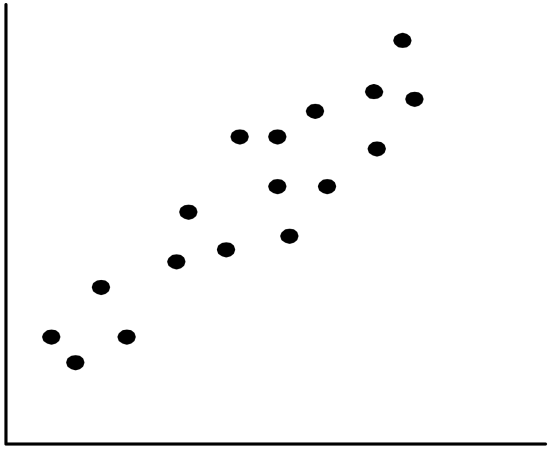

正相关：从左下到右上倾斜，意味着X的值随Y的值增加而增加

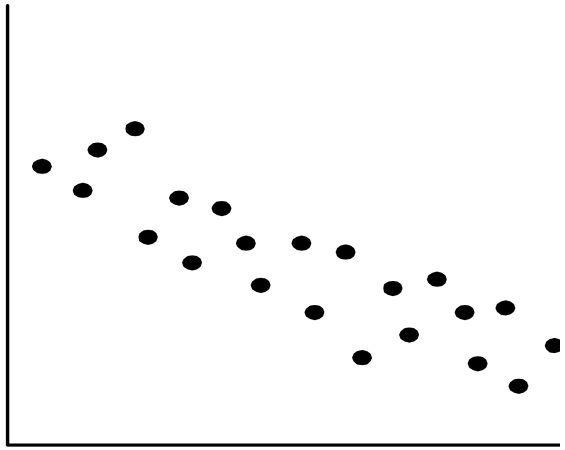

负相关：从左上到右下倾斜，意味着X的值随Y的值减小而增加

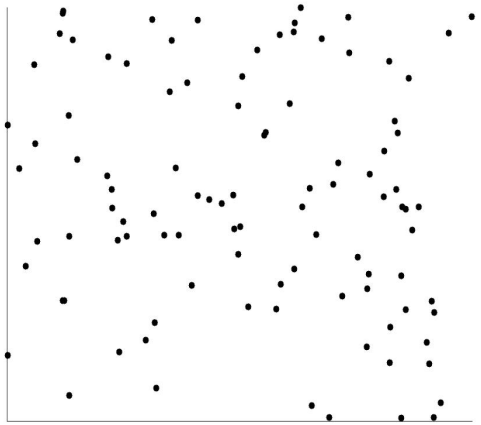

不相关：两个属性之间不存在相关关系。

2.3.2.3 散点图

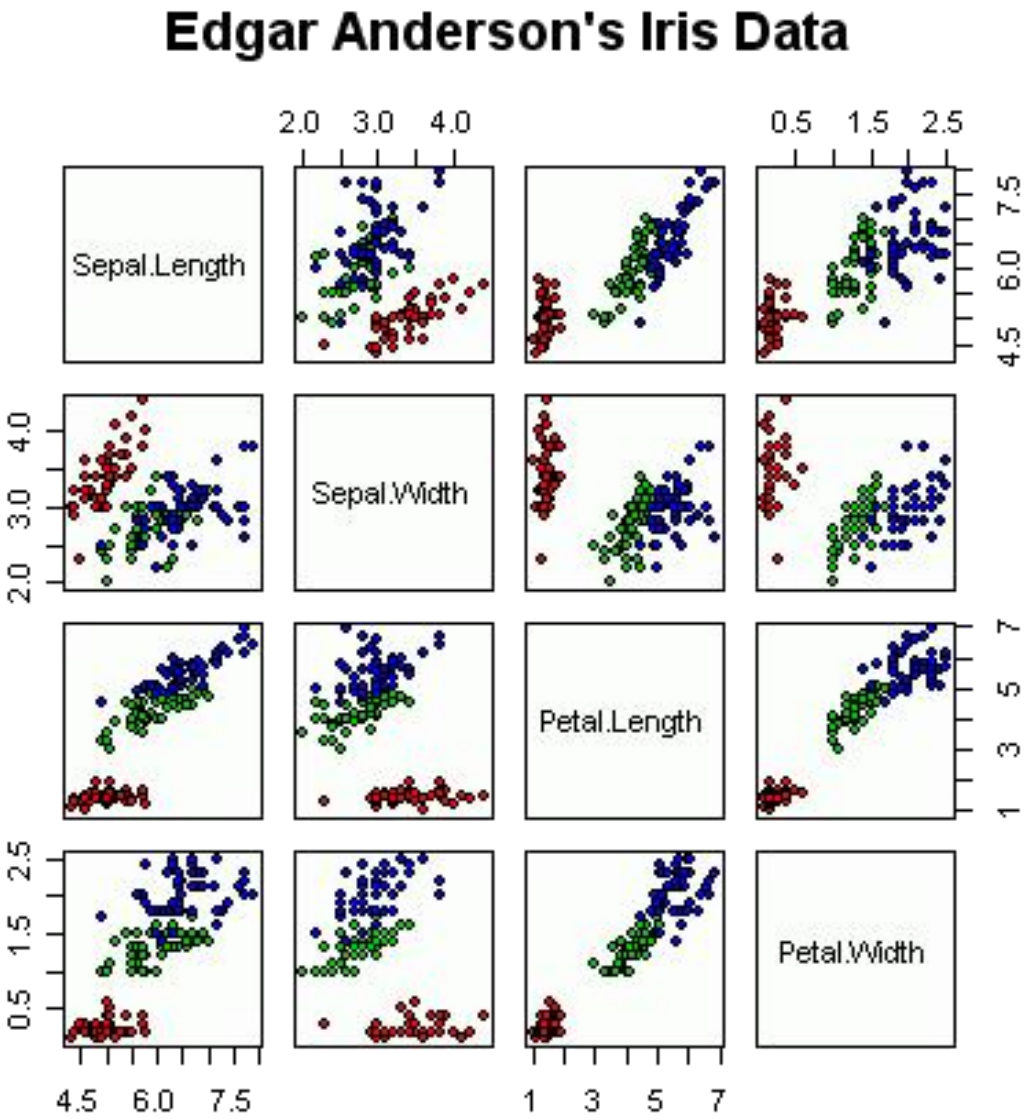

Matrix of scatterplots (x-y-diagrams) of the k-dim. data [total of (k*(k-1)/2) scatterplots]

2.3.2.4 平行坐标(高维)

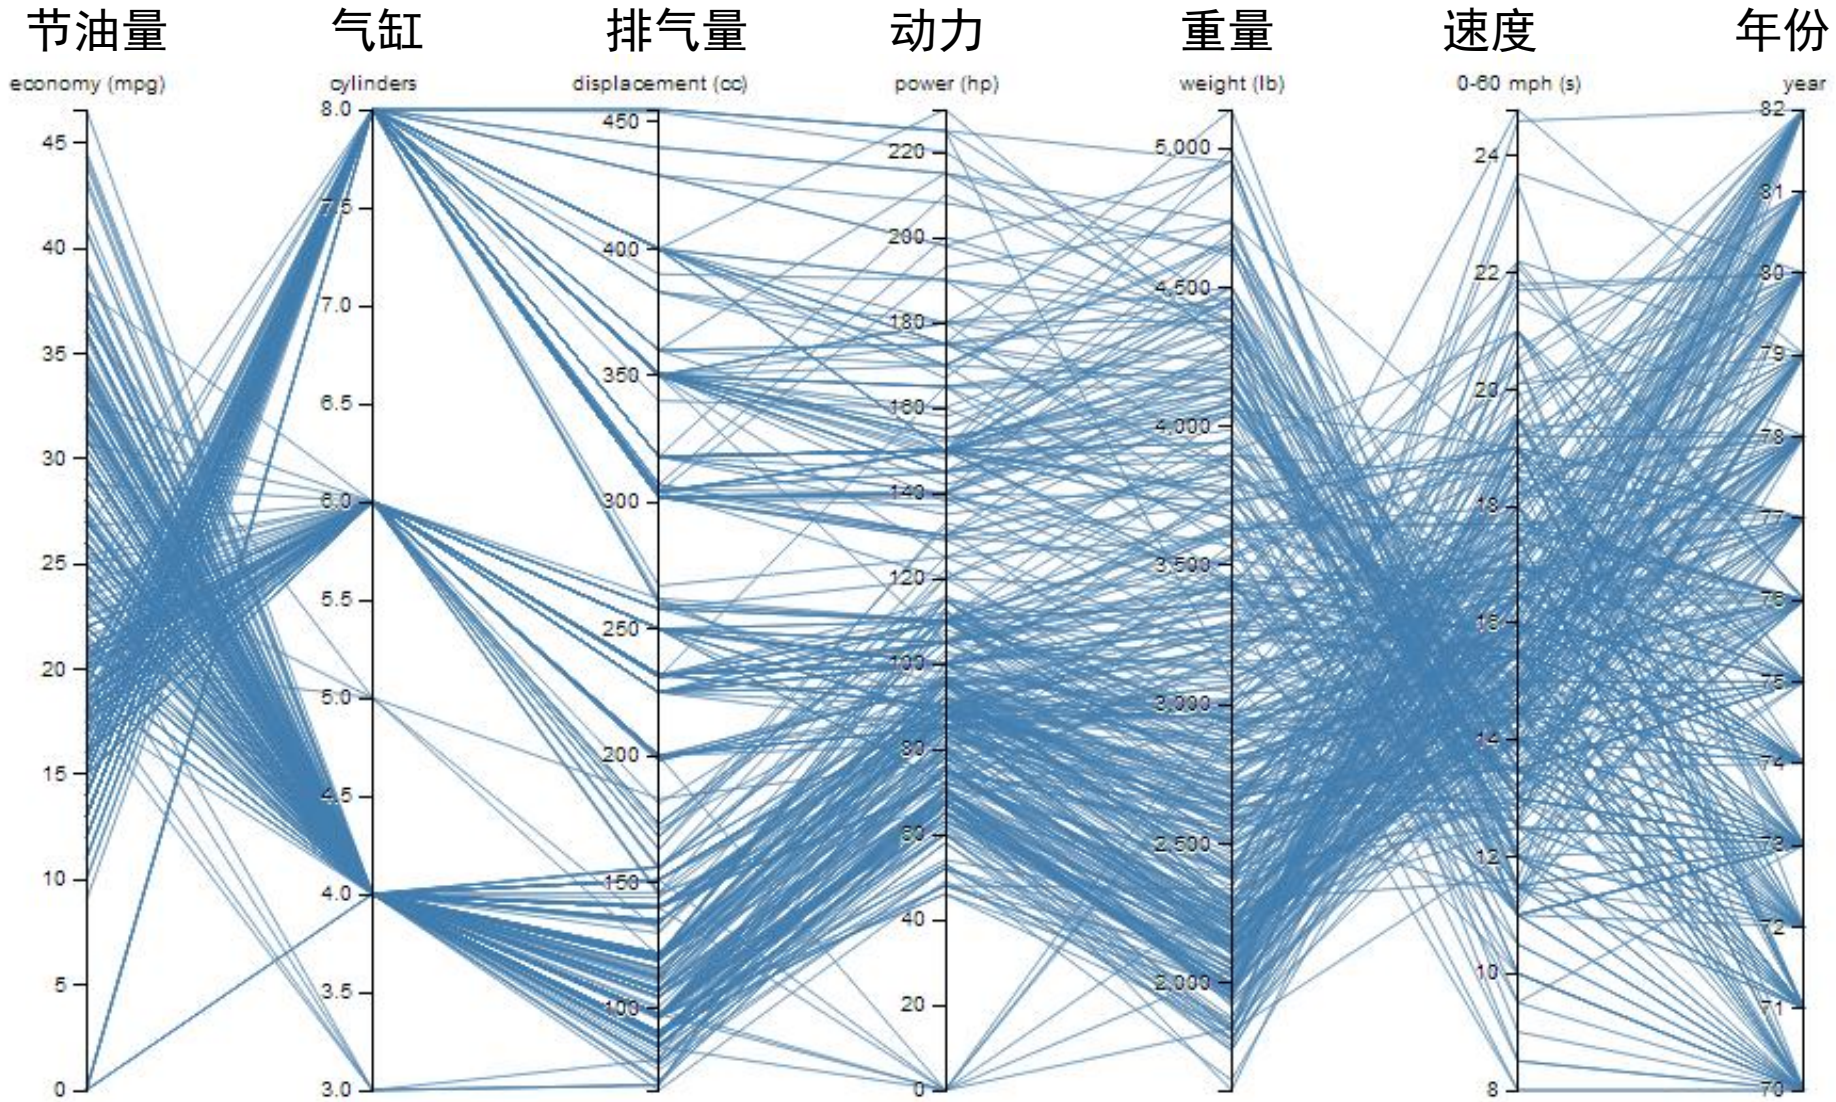
节油量
economy (mpg)
气缸
cylinders
排气量
displacement (cc)
动力
power (hp)
重量
weight (lb)
速度
0-60 mph (s)
年份
year

2.3.2.5 思维导图

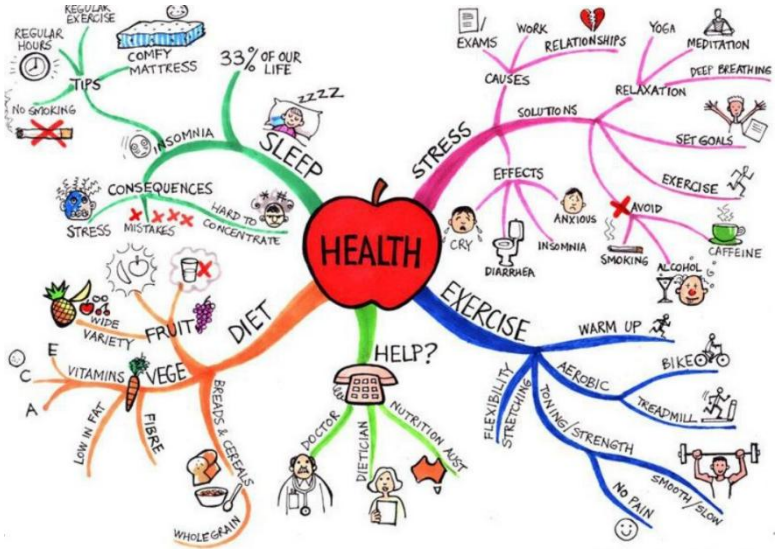
HEALTH
STRESS
EXERCISE
SLEEP
DIET
HELP?
EXAMS
WORK
RELATIONSHIPS
CAUSES
SOLUTIONS
YOGA
MEDITATION
DEEP BREATHING
RELAXATION
SET GOALS
EFFECTS
EXERCISE
AVOID
CRY
ANXIOUS
INSOMNIA
SMOKING
ALCOHOL
CAFFEINE
DIARRHEA
WARM UP
AEROBIC
BIKE
TREADMILL
TONING/STRENGTH
FLEXIBILITY
STRETCHING
NO PAIN
SMOOTH/SLOW
REGULAR HOURS
REGULAR EXERCISE
COMFY MATTRESS
33% OF OUR LIFE
TIPS
NO SMOKING
INSOMNIA
ZZZZ
CONSEQUENCES
STRESS
MISTAKES
HARD TO CONCENTRATE
FRUIT
WIDE VARIETY
VEGE
VITAMINS
FIBRE
LOW IN FAT
BREADS & CEREALS
WHOLEGRAIN
DOCTOR
DIETICIAN
NUTRITION AUST

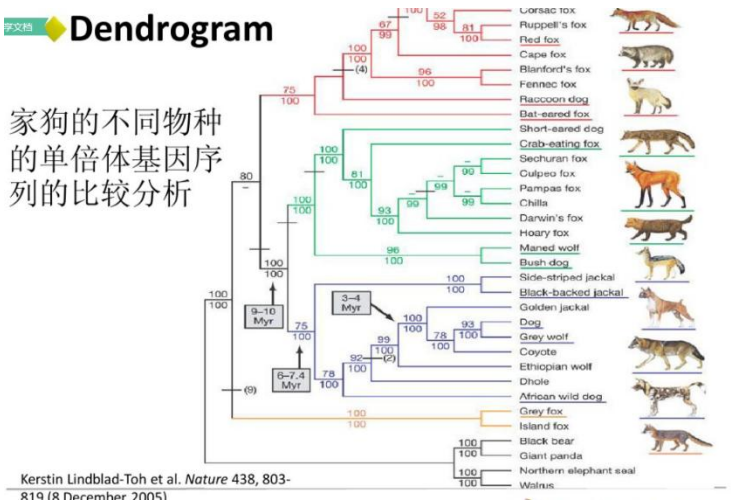
Dendrogram
家狗的不同物种的单倍体基因序列的比较分析
Corsac fox
Ruppell's fox
Red fox
Cape fox
Blanford's fox
Fennec fox
Raccoon dog
Bat-eared fox
Short-eared dog
Crab-eating fox
Sechuran fox
Culpeo fox
Pampas fox
Chilla
Darwin's fox
Hoary fox
Maned wolf
Bush dog
Side-striped jackal
Black-backed jackal
Golden jackal
Dog
Grey wolf
Coyote
Ethiopian wolf
Dhole
African wild dog
Grey fox
Island fox
Black bear
Giant panda
Northern elephant seal
Walrus
9–10 Myr
3–4 Myr
6–7.4 Myr
Kerstin Lindblad-Toh et al. Nature 438, 803-
819 (8 December 2005)

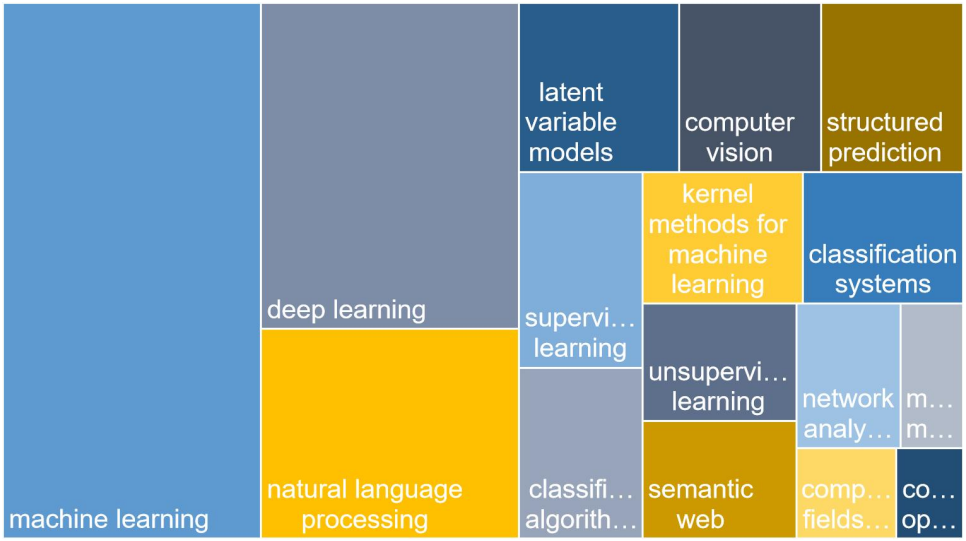
machine learning
deep learning
natural language processing
latent variable models
computer vision
structured prediction
supervi… learning
kernel methods for machine learning
classification systems
unsupervi… learning
network analy…
m… m…
classifi… algorith…
semantic web
comp… fields…
co… op…

2.3.2.6 标签云

DATA
MINING
PATTERNS
LEARNING
ANALYSIS
CUSTOMER
SET
CUSTOMERS
MACHINE
PEOPLE
EXAMPLE
STEP
USE
DISCOVERY
GROUPS
IDENTIFY
APPLICATIONS
DATABASE
INTELLIGENCE
KNOWLEDGE
DECISION
METHODS
MODELING
PROCESS
LEARNED
OFFER
BUSINESS
ASSOCIATION
RULE
USING
RECORDS
SEND
ALGORITHMS
PRE-PROCESSING
PRODUCT
LIKELY
MARKETING
TRAINED
INVOLVES
WITHIN
STRUCTURES
TEST
NUMBER
PRESENT
KNOWN
MANY
DESIRED
LARGE
MODEL
WITHOUT
MUST
DETECTION
INFORMATION
SYSTEM
GENERAL
MARKET
MAKING
FINAL
SUPPORT
ANOTHER
FINALLY
HELP
DETERMINE
CITATION
NEW
SENSING
ARTIFICIAL
OFFERS
ALGORITHM
SOPHISTICATED
TASK
MODELS
E-MAILS
TARGET
PREDICT
NEEDED
COMMON
TERM
VISUALIZATION
MANAGEMENT
MIGHT
BASKET

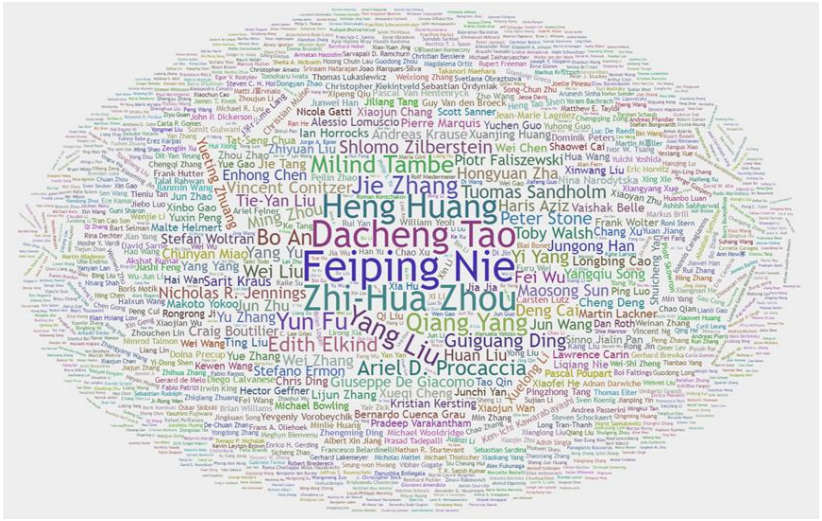
Dacheng_Tao
Feiping_Nie
Zhi-Hua_Zhou
Heng_Huang
Jie_Zhang
Milind_Tambe
Shlomo_Zilberstein
Vincent_Conitzer
Tie-Yan_Liu
Bo_An
Yang_Liu
Fu_Yun
Qiang_Yang
Edith_Elkind
Ariel_D._Procaccia
Stefano_Ermon
Nicholas_R._Jennings
Yufeng_Zhuang
Chunyan_Miao
Enhong_Chen
Piotr_Faliszewski
Tuomas_Sandholm
Peter_Stone
Toby_Walsh
Yi_Yang
Jungong_Han
Longbing_Cao
Fei_Wu
Maosong_Sun
Deng_Cai
Martin_Lackner
Guiguang_Ding
Huan_Liu
Lawrence_Carin
Pascal_Poupart
Xiaofei_He
Pingzhong_Tang
Thomas_Eiter
Kristian_Kersting
Xiaojun_Wan
Yevgeniy_Vorobeychik
Bernardo_Cuenca_Grau
Michael_Bowling
Hector_Geffner
Lijun_Zhang
Xueqi_Cheng
Junchi_Yan
Giuseppe_De_Giacomo
Chris_Ding
Craig_Boutilier
Yu_Zhang
Wei_Liu
Wei_Zhang
Stefano_Ermon
Ting_Liu
Wei_Wang
Kewen_Wang
Zhuhua_Cai
Fabio_Patrizi
Irwin_King
Michael_Wooldridge
Zhengming_Ding
Albert_Xin_Jiang
Prasad_Tadepalli
Sebastian_Sardina
Francesco_Belardinelli
Nathan_R._Sturtevant
Gerhard_Lakemeyer
Nicholas_Mattei
Michael_Thielscher
Xiaokang_Yang
Chaoning_Zhang
Yongdong_Zhang
Frans_A._Oliehoek
Shenglong_Liu
Qiang_Liu
Shuang_Liu
Long_Tran-Thanh
Yong_Yu
Xiangliang_Zhang
Yongzhong_Zhang
Yaohui_Jin
Yanchun_Zhang
Jiangning_Wu
Yevgeniy_Vorobeychik
Bernardo_Cuenca_Grau
Michael_Bowling
Hector_Geffner
Lijun_Zhang
Xueqi_Cheng
Junchi_Yan
Giuseppe_De_Giacomo
Chris_Ding
Craig_Boutilier
Yu_Zhang
Wei_Liu
Wei_Zhang
Stefano_Ermon
Ting_Liu
Wei_Wang
Kewen_Wang
Zhuhua_Cai
Fabio_Patrizi
Irwin_King
Michael_Wooldridge
Zhengming_Ding
Albert_Xin_Jiang
Prasad_Tadepalli
Sebastian_Sardina
Francesco_Belardinelli
Nathan_R._Sturtevant
Gerhard_Lakemeyer
Nicholas_Mattei
Michael_Thielscher
Xiaokang_Yang
Chaoning_Zhang
Yongdong_Zhang
Frans_A._Oliehoek
Shenglong_Liu
Qiang_Liu
Shuang_Liu
Long_Tran-Thanh
Yong_Yu
Xiangliang_Zhang
Yongzhong_Zhang
Yaohui_Jin
Yanchun_Zhang
Jiangning_Wu

Michael_I._Jordan
Geoffrey_Hinton
Yoshua_Bengio
Bernhard_Schölkopf
Robert_J._Tibshirani
Andrew_Zisserman
Vladimir_Vapnik
Rakesh_Agrawal
Jaime_G._Carbonell
Bernhard_Sch?lkopf
Kalyanmoy_Deb
Jiawei_Han
Ronald_Rivest
Eric_S._Lander
Ben_Shneiderman
Zbigniew_Michalewicz
John_R._Koza
Takeo_Kanade
Shizuo_Akira
Ata_Sarajedini
Michael_J._Kearns
Zhihua_Zhou
Rocco_A._Servedio
H._Vincent_Poor
Ilias_Diakonikolas
Pierangela_Samarati
Piero_P._Bonissone
Kathryn_B._Laskey
Jinde_Cao
Peer_Bork
Christos_Faloutsos
Ian_Witten
Paulo_Cesar_G._Da_Costa
Elisa_Bertino
Noboru_Babaguchi
Jon_M._Kleinberg
Nicholas_M._Ball
Huaguang_Zhang
Francisco_Herrera
Trevor_Hastie
Chih-Jen_Lin
Tomaso_Poggio
Luc_De_Raedt
Anil_K._Jain
Hongjie_Dai
Adam_D._Myers
Simon_D._M._White
Trevor_Hastie
Adrian_E._Raftery
PM_Bentler_Ton_De_Jong
Philip_S._Yu
John_Langford
Steffen_Staab
David_B._Dunson
P._M._Bentler
Mengjie_Zhang
Alexander_Maedche
Lorenzo_Bruzzone
Zoubin_Ghahramani
Jitendra_Malik
William_H._Press
Zbigniew_Michalewicz
Daniel_Kahneman
Alexander_D._Maedche
O._L._Mangasarian
George_Davey_Smith
Christopher_D._Manning?
Desmond_G._Higgins
Christopher_D._Manning
Donald_B._Rubin
Andrew_Y._Ng
David_E._Goldberg
Terrence_J._Sejnowski
Thomas_S._Huang
Saul_A._Teukolsky
Riccardo_Poli
Martin_Vetterli
William_T._Vetterling
Stephen_H._Muggleton
Yoneo_Yano
Judea_Pearl
Ross_D._King
Stephen_Boyd
A._C._Fabian

2.3.3 数据可视化工具

- Echarts
- D3
- Tableau
- Google Chart API
- CiteSpace、Gephi
- t-SNE
- Power BI
- Plotly、Dash
- Flourish
- Datawrapper
- Observable Plot
- Apache Superset
- PyGWalker
- Grafana

2.3.3.1 ECharts

百度公司前端数据可视化团队研发的图表库，可以流畅地运行在PC和移动设备上，兼容当前绝大部分浏览器（IE8/9/10/11、Chrome、Firefox、Safari等），底层依赖轻量级的、Canvas类库ZRender，可提供直观、生动、可交互、可高度个性化定制的数据可视化图表

ECharts提供非常丰富的图表类型，包括常规的折线图、柱状图、散点图、饼图、K线图，用于统计的盒形图，用于地理数据可视化的地图、热力图、线图，用于关系数据可视化的关系图、treemap，用于多维数据可视化的平行坐标，以及用于BI的漏斗图、仪表盘，并支持图与图之间的混搭，能满足用户大部分分析数据的图表制作需求

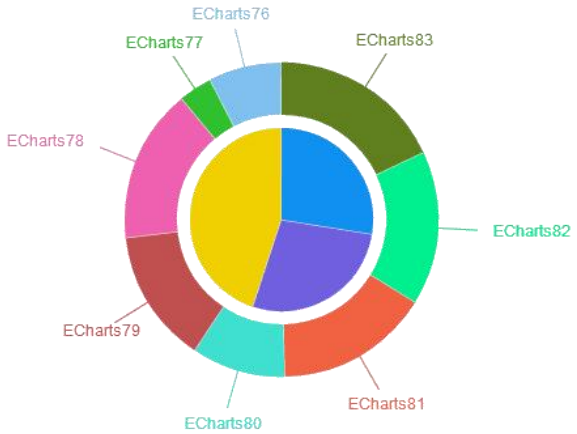

2.3.3.2 D3

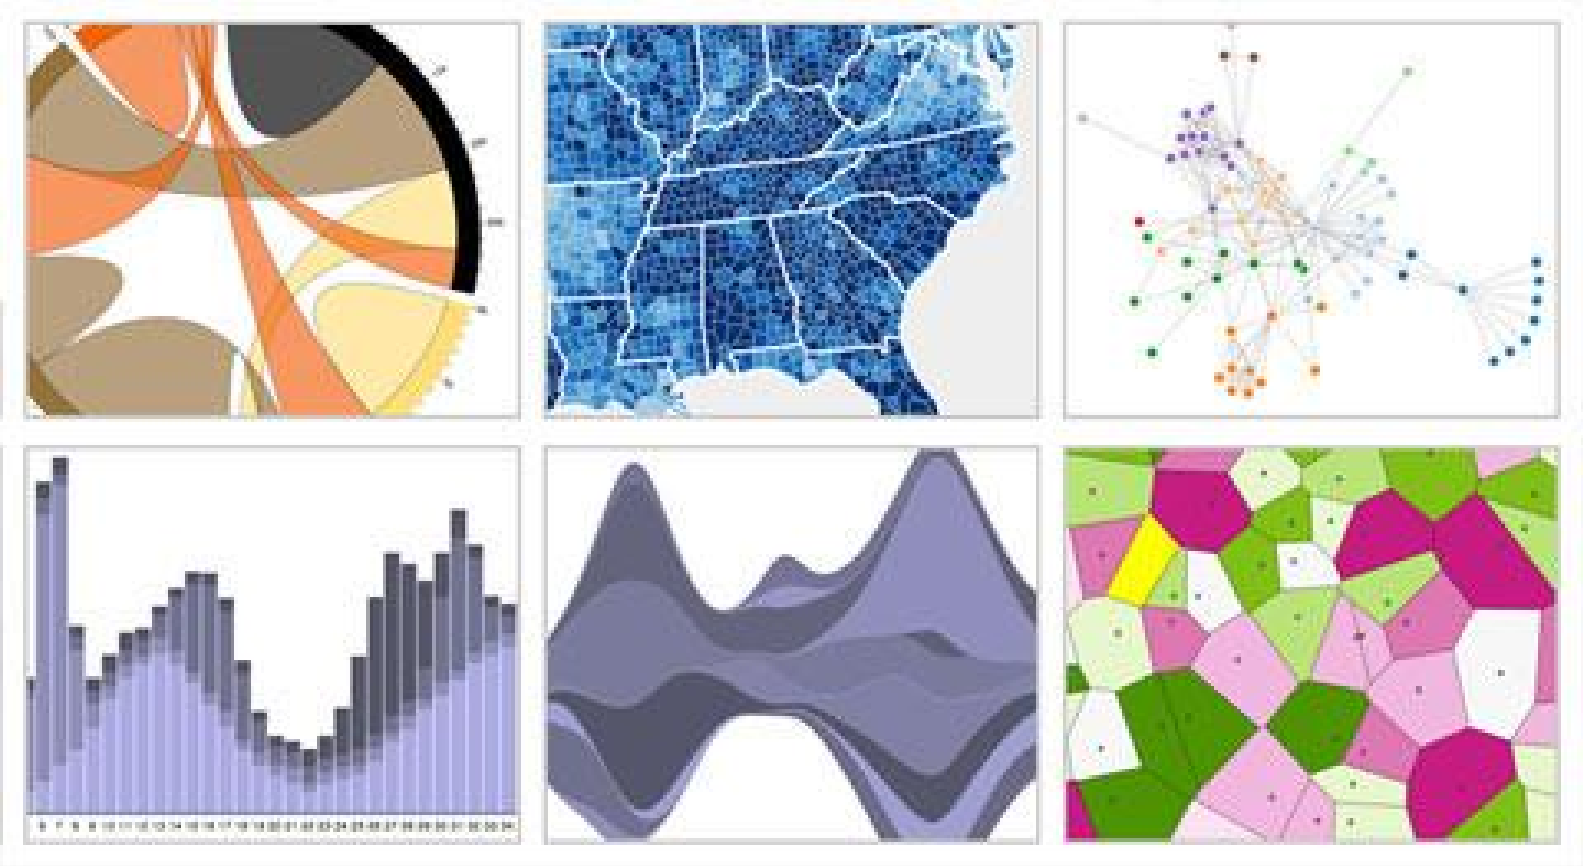

D3 的全称是（Data-Driven Documents），是一个 JavaScript 的函数库，使用它主要是用来做数据可视化的。D3提供的可视化图表-Voronoi图、树形图、圆形集群和单词云

2.3.3.3 Tableau

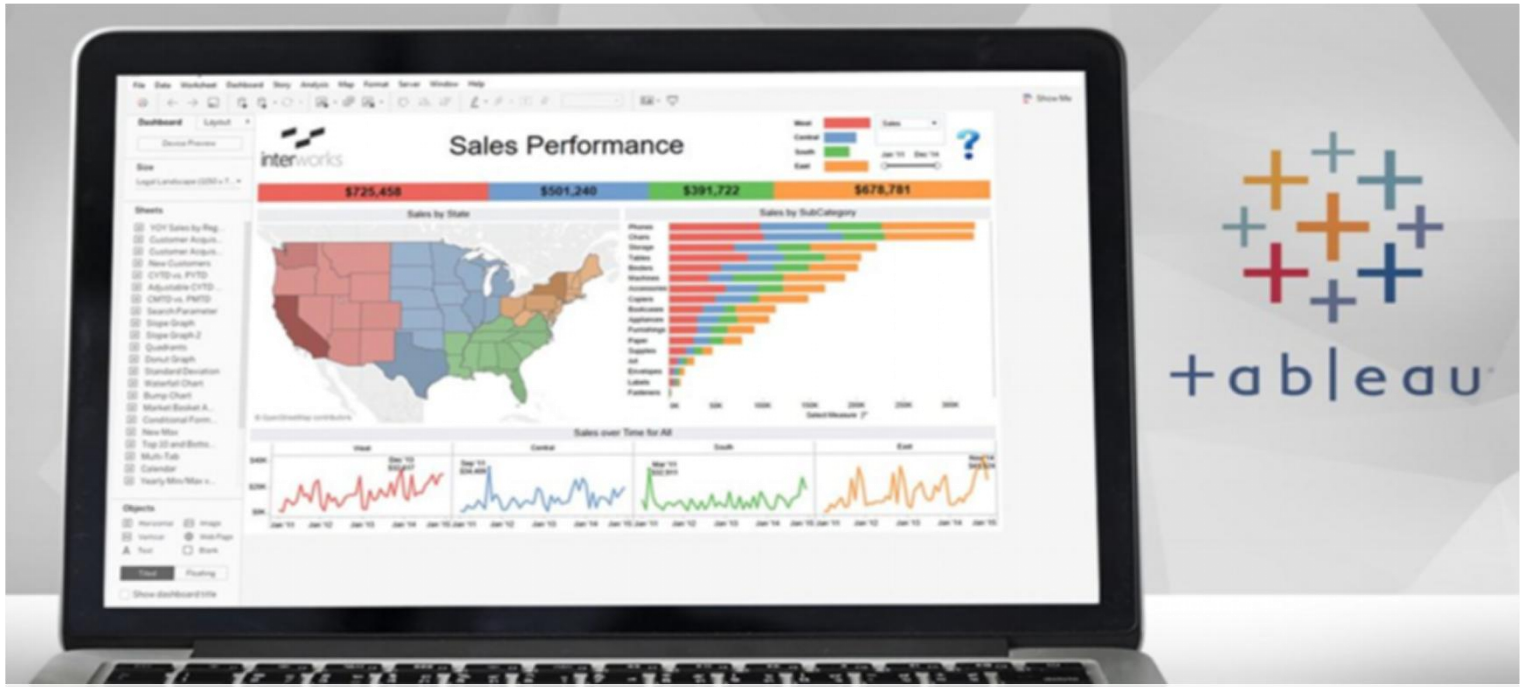

Tableau是桌面系统中最简单的商业智能工具软件

适合企业和部门进行**日常数据报表**和**数据可视化分析**工作

2.3.3.4 时间线

Timetoast

Timetoast是在线创作**基于时间轴**事件记载服务的网站，提供个性化时间线服务，可用不同的时间线来记录你某个方面的发展历程、心理路程、进度过程等Timetoast基于flash平台，操作简单

时间线图

Xtimeline

Xtimeline 是一个免费的绘制时间线的在线工具网站，操作简便，用户通过添加事件日志的形式构建时间表，同时也可给日志配上相应的图表。Xtimeline是一个社区类型的间轴网站

2.3.3.5 Google Chart API

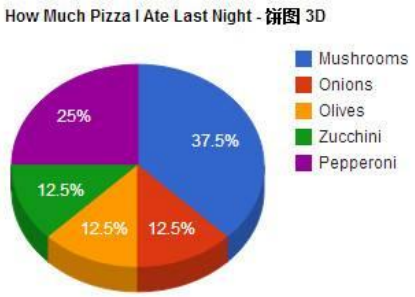

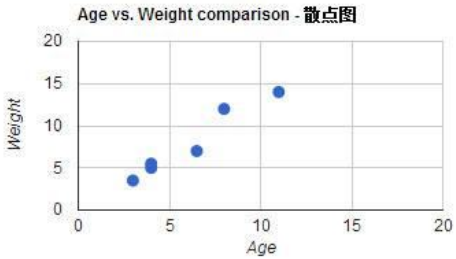

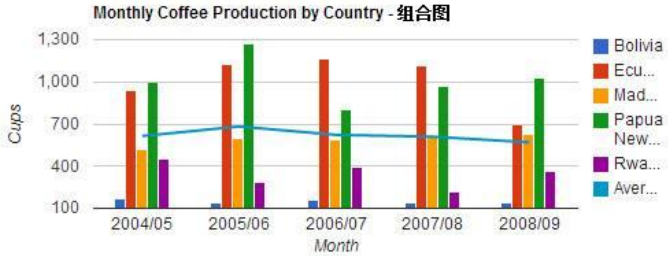

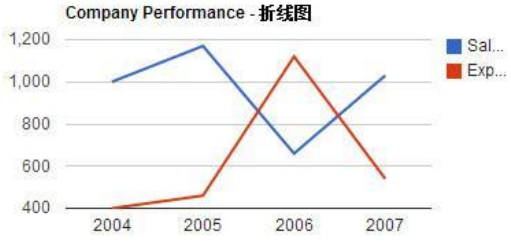

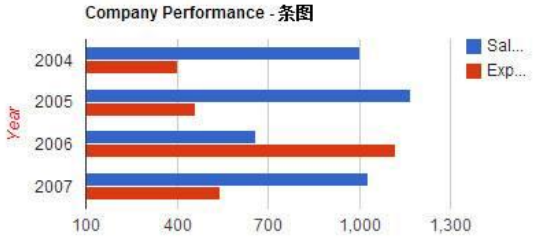

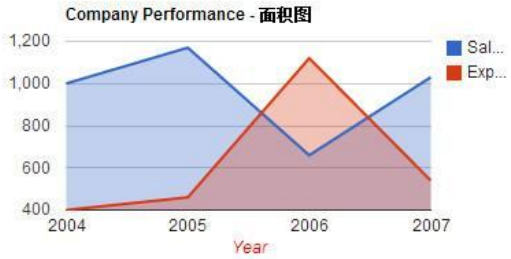

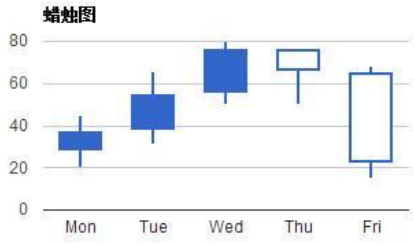

通过浏览器在线查看Google Chart统计图表

2.3.3.6 CiteSpace

CiteSpace又翻译为“引文空间”，是一款着眼于分析科学分析中蕴含的潜在知识，是在科学计量学、数据可视化背景下逐渐发展起来的引文可视化分析软件。由于是通过可视化的手段来呈现科学知识的结构、规律和分布情况，因此也将通过此类方法分析得到的可视化图形称为“科学知识图谱”。

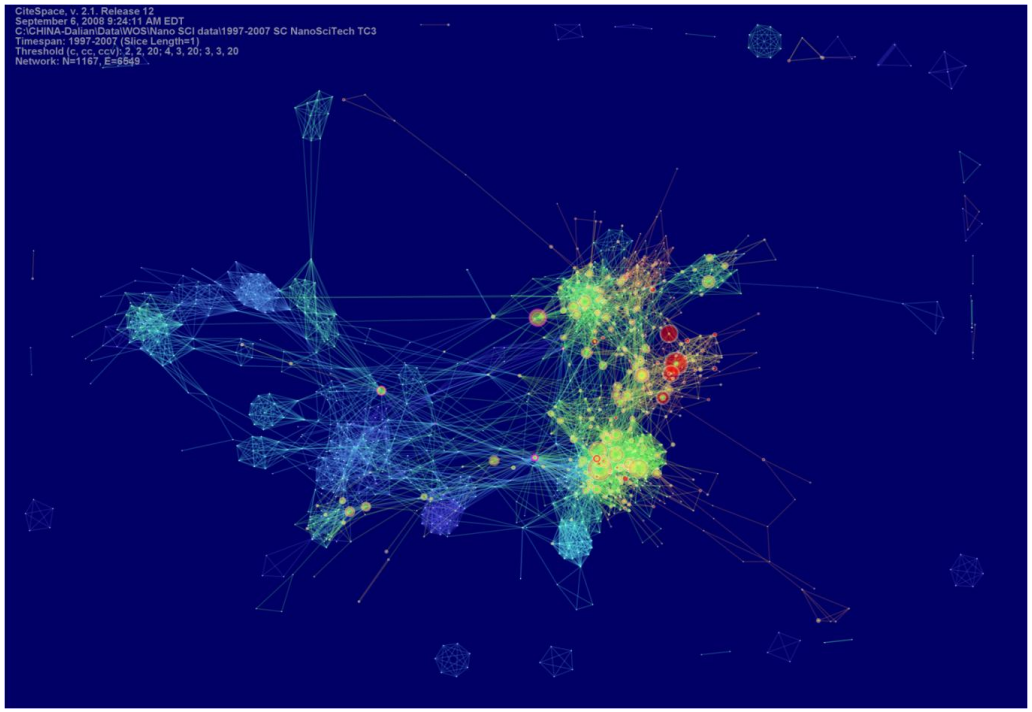

2.3.3.7 Gephi

是一款开源免费跨平台基于JVM的复杂网络分析软件，其主要用于各种网络和复杂系统，动态和分层图的交互可视化与探测开源工具。

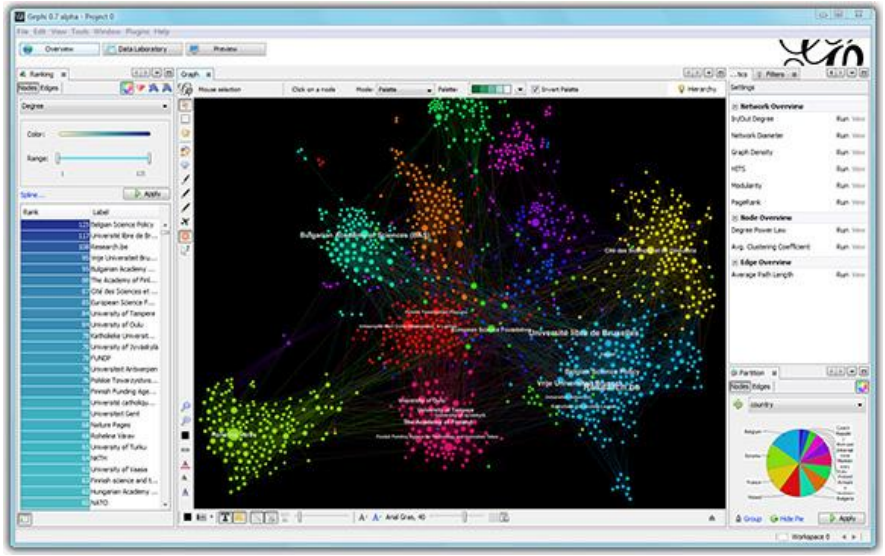

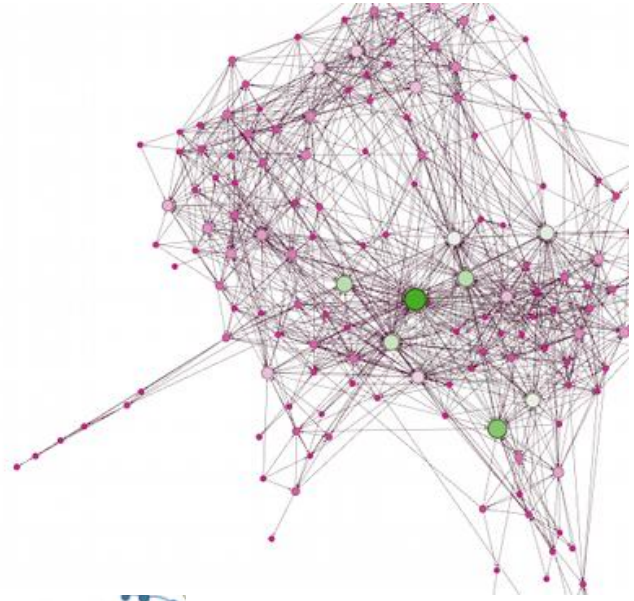

2.3.3.8 t-SNE

t 分布随机邻近嵌入（t-Distribution Stochastic Neighbour Embedding）是一种用于降维的机器学习方法，主要的优势就是保持局部结构的能力。t-SNE 可以生成漂亮的可视化图。

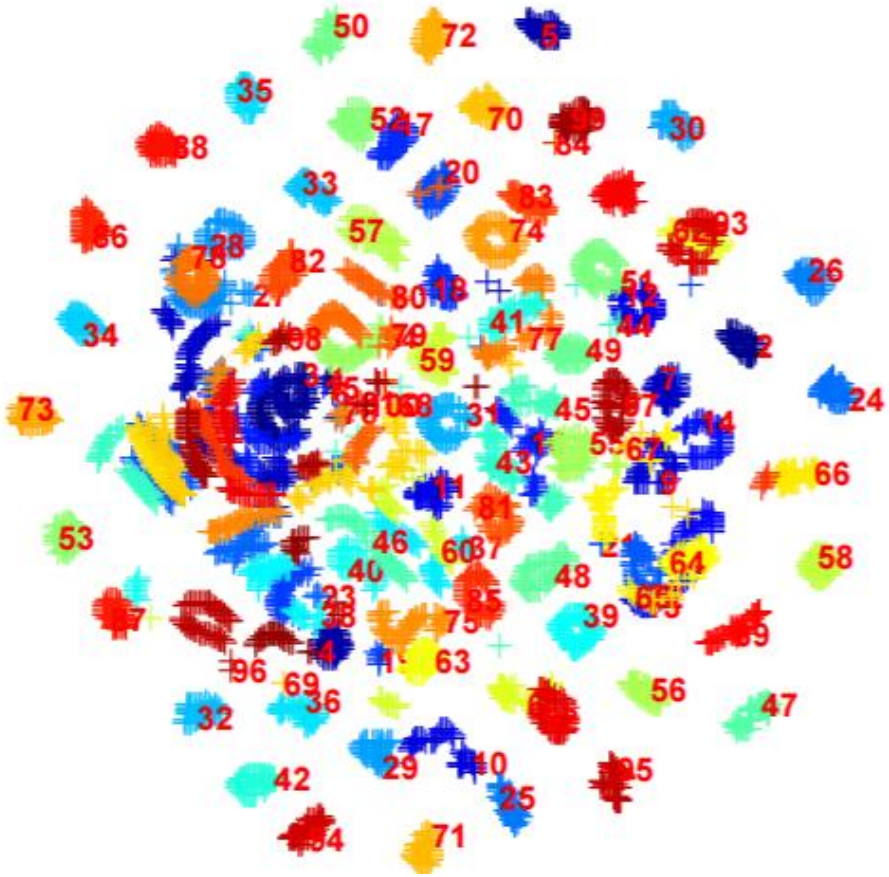

2.3.3.9 深度模型画图工具

https://cbovar.github.io/ConvNetDraw/

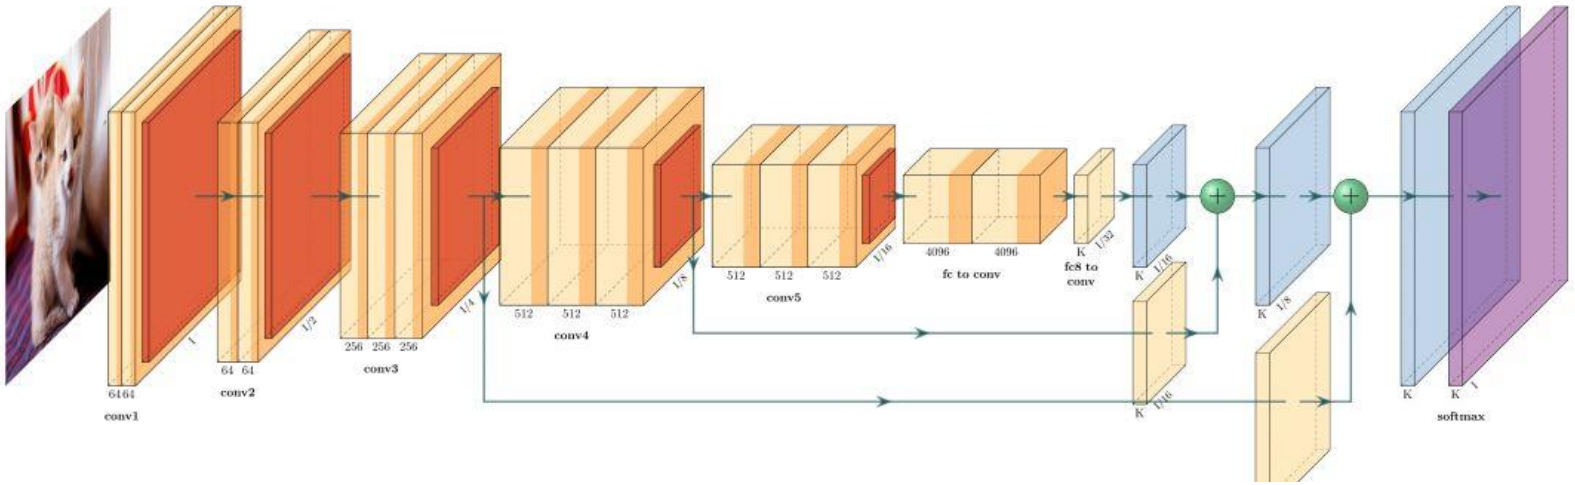

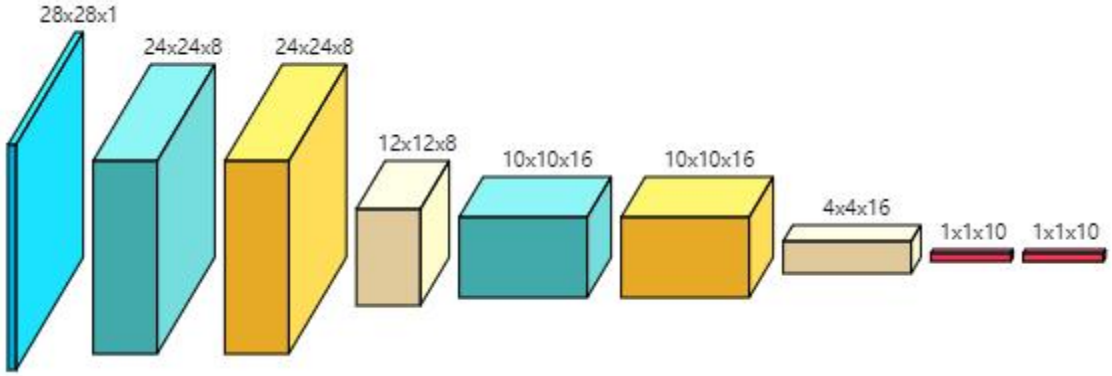

2 认识数据

2.1 数据对象与属性类型

2.2 数据的基本统计描述

2.3 数据可视化

2.4 数据的相似性和相异性

2.4 相似性和相异性

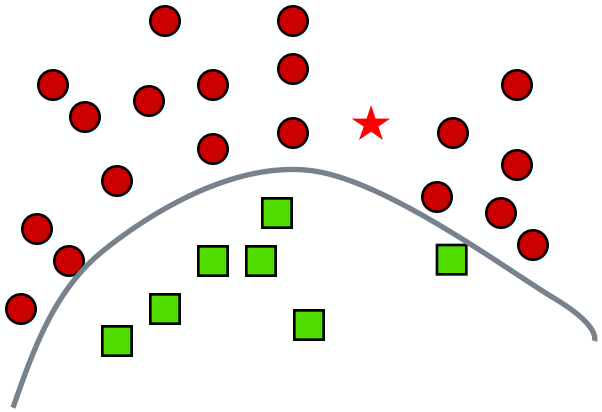

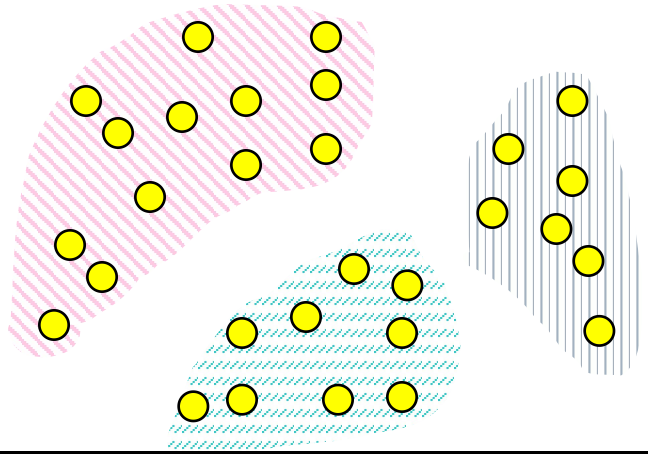

很多的算法越来越依赖于在输入空间给定的好的度量。
例如K-means、K近邻方法、SVM、深度学习等算法需要给定好的度量来反映数据间存在的一些重要关系。

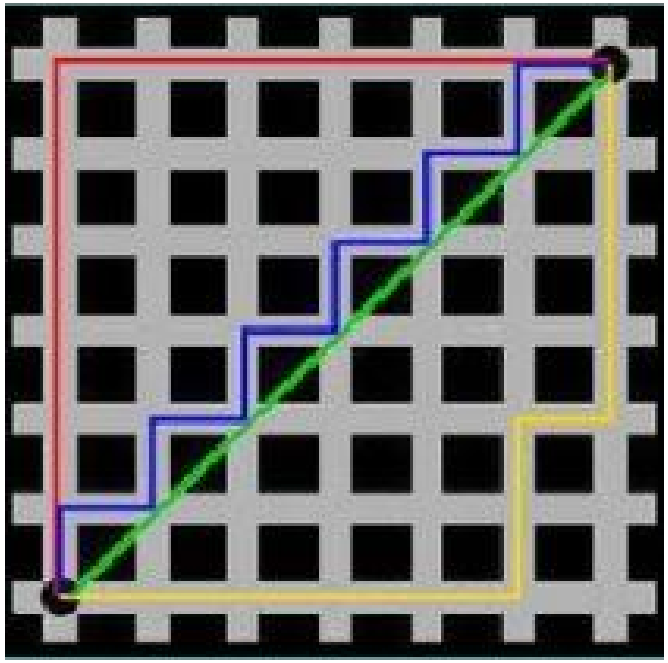

2.4 相似性和相异性

2.4 相似性和相异性

- **相似性(similarity)**
  - 描述两个数据对象的相似程度
  - 当两个数据对象更相似时，值更高
  - 通常落在[0,1]范围内
- **相异性(e.g., distance)**
  - 描述两个数据对象的差异程度
  - 当两个数据对象更相似时，值更低
  - 最小相异度通常为0
- **相似性和相异性都称邻近性**

2.4 相似性和相异性

- 2.4.1 数据矩阵与相异性矩阵
- 2.4.2 标称属性的邻近性度量
- 2.4.3 二元属性的邻近性度量
- 2.4.4 序数属性的距离
- 2.4.5 数值属性的距离
- 2.4.6 余弦相似度
- 2.4.7 度量学习
- 2.4.8 多模态对齐中的相似度
- 2.4.9 大模型嵌入与 RAG 检索
- 2.4.10 视觉文档 RAG 的细粒度相关度

2.4.1 数据矩阵与相异性矩阵

- n个对象, p个属性

$$\begin{bmatrix} x_{11} & \cdots & x_{1f} & \cdots & x_{1p} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{i1} & \cdots & x_{if} & \cdots & x_{ip} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{n1} & \cdots & x_{nf} & \cdots & x_{np} \end{bmatrix}$$

甲状腺病人与正常人5项指标及归类

样品	v1	v2	v3	v4	v5	归类
1	-1.31	0.80	0.78	-0.70	-0.61	1
2	-0.63	0.75	1.94	-0.61	-0.42	1
3	0.70	1.48	1.04	-0.66	-0.73	1
4	-0.97	0.87	0.01	-0.64	-0.61	1
5	-1.42	0.63	0.78	-0.65	-0.71	1
6	-1.31	1.50	-0.63	-0.70	-0.58	1
7	-0.97	1.09	0.91	-0.70	-0.57	1
8	-0.28	0.58	1.43	-0.69	-0.52	1
9	0.74	-1.10	-0.89	0.51	-0.21	-1
10	0.17	0.00	0.66	0.04	1.54	-1
11	0.06	-0.73	-0.63	1.01	-0.43	-1
12	2.56	-0.30	0.27	-0.06	0.09	-1
13	1.19	-1.29	-1.27	0.20	-0.60	-1
14	-0.06	-0.78	-0.12	0.13	2.15	-1
15	0.17	-1.19	-1.14	0.66	0.67	-1
16	0.06	-1.46	-1.14	3.58	0.52	-1

2.4.1 数据矩阵与相异性矩阵

- 数据矩阵
  - 二模矩阵(行和列分别代表不同的个体)
  - 由两种实体或“事物”组成，即行（对象）和列（属性）

$$\begin{bmatrix} x_{11} & \cdots & x_{1f} & \cdots & x_{1p} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{i1} & \cdots & x_{if} & \cdots & x_{ip} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{n1} & \cdots & x_{nf} & \cdots & x_{np} \end{bmatrix}$$

- 相异性矩阵
  - 单模矩阵
  - 只包含一类实体

$$\begin{bmatrix} 0 & & & & \\ d(2,1) & 0 & & & \\ d(3,1) & d(3,2) & 0 & & \\ \vdots & \vdots & \vdots & & \\ d(n,1) & d(n,2) & \cdots & \cdots & 0 \end{bmatrix}$$

2.4.2 标称属性的邻近性度量

- 可以取两个或者多个状态, e.g., 头发的颜色有黑色、红色、黄色、棕色等
- 方法 1: 简单的匹配
  - 距离

$$d(i, j) = \frac{p - m}{p}$$

  - 相似度

$$sim(i,j) = 1 - d(i,j) = \frac{m}{p}$$

m: 匹配的数目（即i和j取值相同状态的属性数）

p: 刻画对象的属性总数

2.4.2 标称属性的邻近性度量

- 举例:*hair-color, country,smoking status*

  d_1 ={**red, China, smoker**}

  d_2 ={**black, China, non-smoker**}

  ***d*(1,2)=?**

  ***sim*(1,2)=?**

2.4.2 标称属性的邻近性度量

- 方法2：one-hot编码
  - 采用0-1值代表M个状态
- Example:*hair-color,country,smoking status*

d_1 ={**red, not China, smoker**}

d_2 = {**black, China, non-smoker**}

d_3 = {**yellow, China, non-smoker**}

d_1 ={**001, 01, 01**}

d_2 ={**010, 10, 10**}

d_3 ={**100, 10, 10**}

2.4.3二元属性的邻近性度量

Name	Gender	Fever	Cough
Jack	1	1	0
Mary	0	1	0
Jim	1	0	1

表 2.3　二元属性的列联表

		对象 j		
		1	0	sum
对象 i	1	q	r	$q+r$
	0	s	t	$s+t$
	sum	$q+s$	$r+t$	p

- 当两个状态是同等重要时：

对称的二元相异性

$$d(i,j)=\frac{r+s}{q+r+s+t}$$

- 当两个状态不是同等重要时：
  - 非对称的二元相异性 $$d(i,j)=\frac{r+s}{q+r+s}$$
  - 非对称的二元相似性 $$sim_{Jaccard}(i,j)=\frac{q}{q+r+s}$$

q是在对象i和j都取1的属性数，r是在对象i中取1，在j中取0的属性数，s是在对象i中取0，在j中取1的属性数，t是对象i和j都取0的属性数

2.4.3二元属性的邻近性度量

对称属性

对象标识符

非对称二元属性

Name	Gender	Fever	Cough	Test-1	Test-2	Test-3	Test-4
Jack	M	Y	N	P	N	N	N
Mary	F	Y	N	P	N	P	N
Jim	M	Y	P	N	N	N	N

只按非对称属性计算，
Y, P取1，N取0

$$d(i,j)=\frac{r+s}{q+r+s}$$

$$d(jack,mary)=\frac{0+1}{2+0+1}=0.33$$

$$d(jack,jim)=\frac{1+1}{1+1+1}=0.67$$

$$d(jim,mary)=\frac{1+2}{1+1+2}=0.75$$

2.4.4序数属性的距离

- 序数属性的值之间具有有意义的序或排位，相继值之间的量值未知。
- 数值属性的值域可以映射到具有 M_f 个状态的序数属性 f.
  - 第i个对象的f 值为 x_{if} ，属性 f 有 M_f 个有序状态，用对应的排位 $r_{if} \in \{1,\ldots, M_f\}$ 取代x_{if}
  - 将每个属性的值域映射到 [0, 1]上，以便每个属性都有相同的权重。

$$z_{if} = \frac{r_{if} - 1}{M_f - 1}$$

  - 采用任意一种数值属性的距离度量计算。

2.4.4序数属性的距离

point	attribute 1
x1	Excellent
x2	fair
x3	good
x4	Excellent

r_{if}

point	attribute 1	
x1	Excellent	3
x2	fair	1
x3	good	2
x4	Excellent	3

z_{if}

point	attribute 1	
x1	Excellent	1
x2	fair	0
x3	good	0.5
x4	Excellent	1

欧式距离

L2	x1	x2	x3	x4
x1	0			
x2	1	0		
x3	0.5	0.5	0	
x4	0	1	0.5	0

2.4.5数值属性的距离

- 欧几里得距离（欧式距离）（Euclidean Distance）
- 曼哈顿距离（Manhattan Distance）
- 闵可夫斯基距离（Minkowski Distance）

2.4.5数值属性的距离

欧几里得距离：两点间的直线距离。即平时生活中默认使用的距离。

勾股定理：如果直角三角形两个直角边长度为a和b，斜边长度为c，那么$a^2+b^2=c^2$

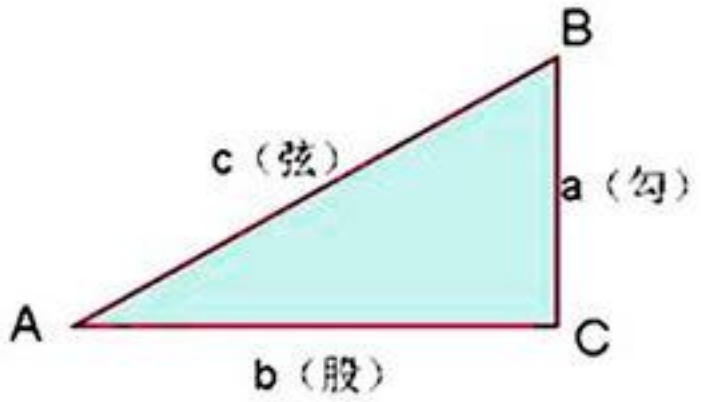

2.4.5数值属性的距离

欧几里得距离

(1)二维平面上两点A(x_1,y_1)与B(x_2,y_2)间的欧氏距离：

$$d_{12} = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

(2)三维空间两点A(x_1,y_1,z_1)与B(x_2,y_2,z_2)间的欧氏距离：

$$d_{12} = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2}$$

(3)两个n维向量A(x_{11},x_{12},…,x_{1n})与 B(x_{21},x_{22},…,x_{2n})间的欧氏距离：

$$d_{12} = \sqrt{\sum_{k=1}^{n} (x_{1k} - x_{2k})^2}$$

注意：如果两个点的范围差别较大，需要标准化

2.4.5数值属性的距离

欧几里得距离

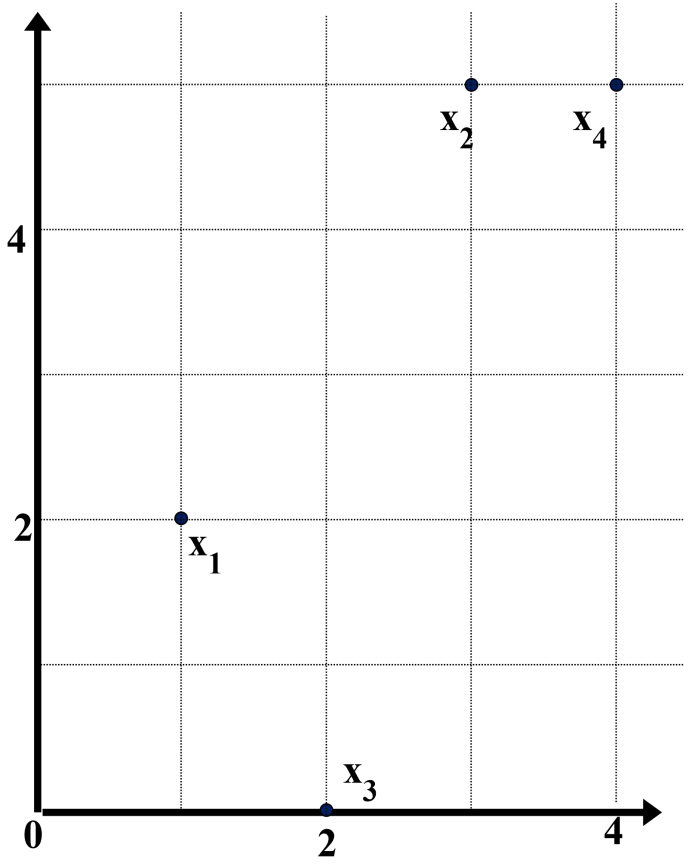

Data Matrix

point	attribute1	attribute2
x_1	1	2
x_2	3	5
x_3	2	0
x_4	4	5

Dissimilarity Matrix

(with Euclidean Distance)

	x_1	x_2	x_3	x_4
x_1	0			
x_2	3.61	0		
x_3	2.24	5.1	0	
x_4	4.24	1	5.39	0

2.4.5数值属性的距离

曼哈顿距离（Manhattan Distance）

也称作城市街区距离(**City Block distance**)，用以标明两个点在标准坐标系上的绝对轴距总和。

想象你在曼哈顿要从一个十字路口开车到另外一个十字路口，驾驶距离是两点间的直线距离吗？显然不是，除非你能穿越大楼。实际驾驶距离就是这个“曼哈顿距离”。

图中红线代表曼哈顿距离，绿色代表欧式距离，也就是直线距离，蓝色和黄色代表等价的曼哈顿距离。

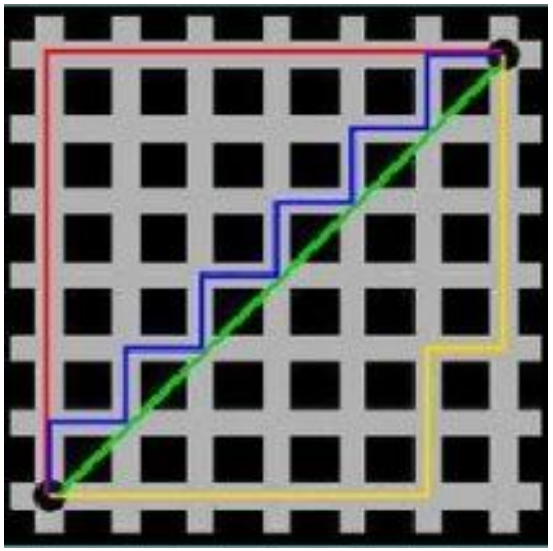

2.4.5数值属性的距离

曼哈顿距离

(1)二维平面两点$a(x_1,y_1)$与$b(x_2,y_2)$间的曼哈顿距离

$$d_{12} = |x_1 - x_2| + |y_1 - y_2|$$

(2)两个n维向量$a(x_{11},x_{12},\ldots,x_{1n})$与 $b(x_{21},x_{22},\ldots,x_{2n})$间的曼哈顿距离

$$d_{12} = \sum_{k=1}^{n} |x_{1k} - x_{2k}|$$

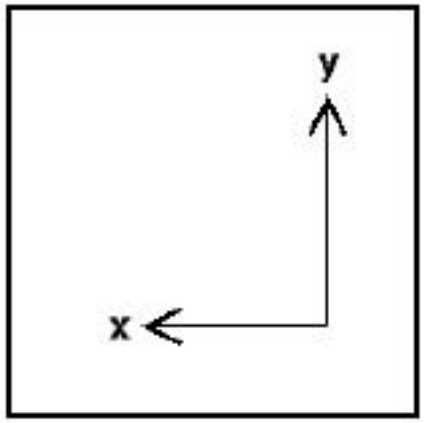

Manhattan

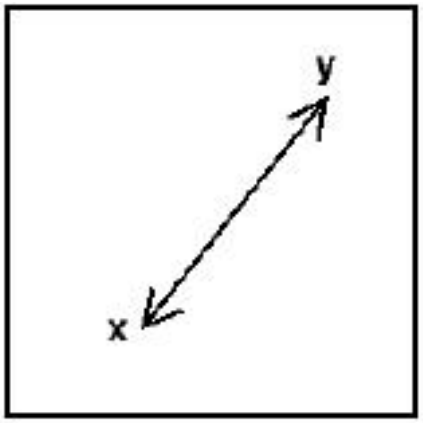

Euclidean

2.4.5数值属性的距离

欧几里得距离和曼哈顿距离满足如下数学性质：

$d(i, j)$ 是i和j的距离

- $d(i, j) > 0$ if $i \neq j$ (非负性)
- $d(i, j) = 0$ (同一性)
- $d(i, j) = d(j, i)$ (对称性)
- $d(i, j) \leq d(i, k) + d(k, j)$ (三角不等式)

满足这些条件的测度称作是度量

2.4.5数值属性的距离

闵可夫斯基距离(Minkowski distance)

是欧几里得距离和曼哈顿距离的推广

$$d(i,j)=\sqrt[h]{|x_{i1}-x_{j1}|^h+|x_{i2}-x_{j2}|^h+\cdots+|x_{ip}-x_{jp}|^h}$$

$i=(x_{i1}, x_{i2}, \ldots, x_{ip})$ 和 $j=(x_{j1}, x_{j2}, \ldots, x_{jp})$ 表示两个数据对象，

h是个实数，也被称作L_h范数，有些书上习惯称作L_p范数

2.4.5数值属性的距离

闵可夫斯基距离的特例

- $h = 1$: 曼哈顿距离 (城市块距离, L_1 范数)
  - E.g., the Hamming distance: the number of bits that are different between two binary vectors

$$d(i,j)=|x_{i_1}-x_{j_1}|+|x_{i_2}-x_{j_2}|+...+|x_{i_p}-x_{j_p}|$$

- $h = 2$:欧几里得距离(L_2 范数)

$$d(i,j)=\sqrt{(|x_{i_1}-x_{j_1}|^2+|x_{i_2}-x_{j_2}|^2+...+|x_{i_p}-x_{j_p}|^2)}$$

- $h \to \infty$. 上确界距离($L_{\max}$ 范数, L_∞ 范数)
  - This is the maximum difference between any component (attribute) of the vectors

$$d(i,j)=\lim_{h\to\infty}\left(\sum_{f=1}^{p}|x_{if}-x_{jf}|^h\right)^{\frac{1}{h}}=\max_{f}^{p}|x_{if}-x_{jf}|$$

2.4.5数值属性的距离

point	attribute 1	attribute 2
x1	1	2
x2	3	5
x3	2	0
x4	4	5

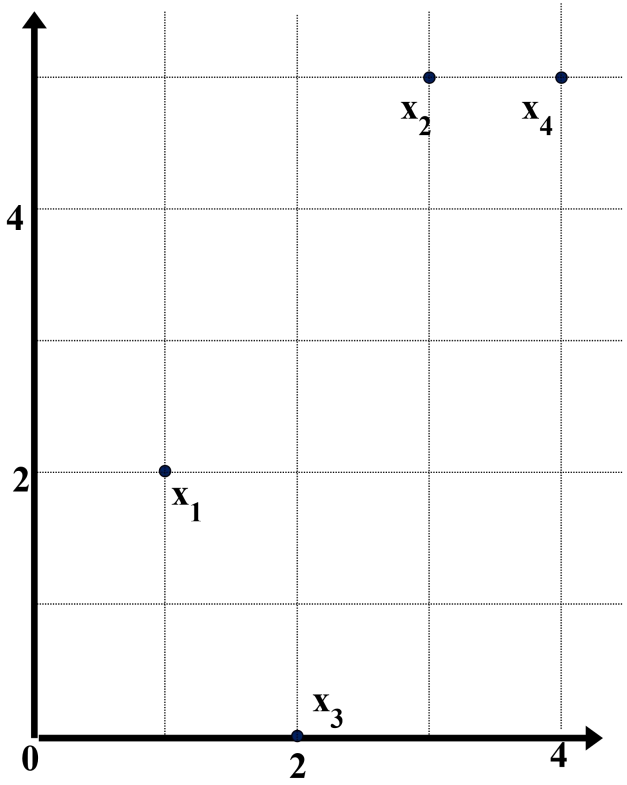

距离矩阵

Manhattan (L_1)

Euclidean (L_2)

Supremum

2.4.5数值属性的距离

point	attribute 1	attribute 2
x1	1	2
x2	3	5
x3	2	0
x4	4	5

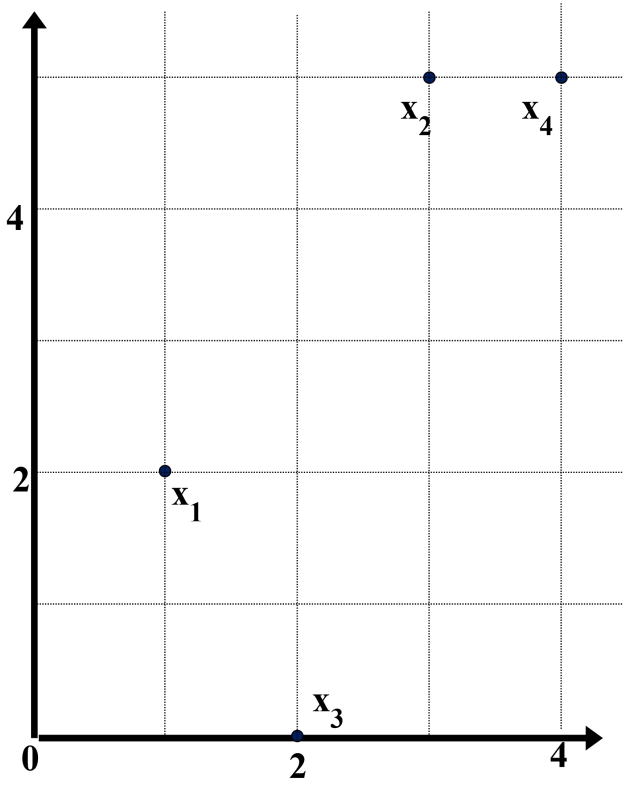

距离矩阵

Manhattan (L_1)

L	x1	x2	x3	x4
x1	0			
x2	5	0		
x3	3	6	0	
x4	6	1	7	0

Euclidean (L_2)

L2	x1	x2	x3	x4
x1	0			
x2	3.61	0		
x3	2.24	5.1	0	
x4	4.24	1	5.39	0

Supremum

L_∞	x1	x2	x3	x4
x1	0			
x2	3	0		
x3	2	5	0	
x4	3	1	5	0

2.4.6余弦相似性

$$sim(v_1, v_2) = \frac{v_1 \cdot v_2}{\|v_1\| \|v_2\|}$$

- 通常用于文本挖掘中，向量v中第j个数值就是相应文档中第j个项的量度。

v_1 = { 1,1,1,1,1,1,1,1,1,1,1,0,0,0,0,0,0,0,0,0,0,0,0,0,0 }

v_2 = { 0,0,0,0,0,0,0,0,0,0,0,0,1,1,1,1,1,0,0,0,0,0,0,0,0 }

v_3 = { 1,1,1,0,1,0,1,1,1,0,0,1,0,0,0,0,0,0,0,0,0,0,0,0,0 }

2.4.6余弦相似性

$v_1 = \{\ 1,1,1,1,1,1,1,1,1,1,1,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0\ \}$

$v_2 = \{\ 0,0,0,0,0,0,0,0,0,0,0,0,0,1,1,1,1,1,0,0,0,0,0,0,0,0\ \}$

$v_3 = \{\ 1,1,1,0,1,0,1,1,1,0,0,1,0,0,0,0,0,0,0,0,0,0,0,0,0,0\ \}$

$$sim(v_1, v_2) = \frac{v_1 \cdot v_2}{|v_1||v_2|} = \frac{0}{\sqrt{11} \times \sqrt{5}} = 0 \qquad sim(v_2, v_3) = \frac{v_2 \cdot v_3}{|v_2||v_3|} = \frac{0}{\sqrt{5} \times \sqrt{8}} = 0$$

$$sim(v_1, v_3) = \frac{v_1 \cdot v_3}{|v_1||v_3|} = \frac{7}{\sqrt{11} \times \sqrt{8}} = \frac{7}{9.38} = 0.75$$

2.4.7度量学习

Isometric Mapping等度量映射

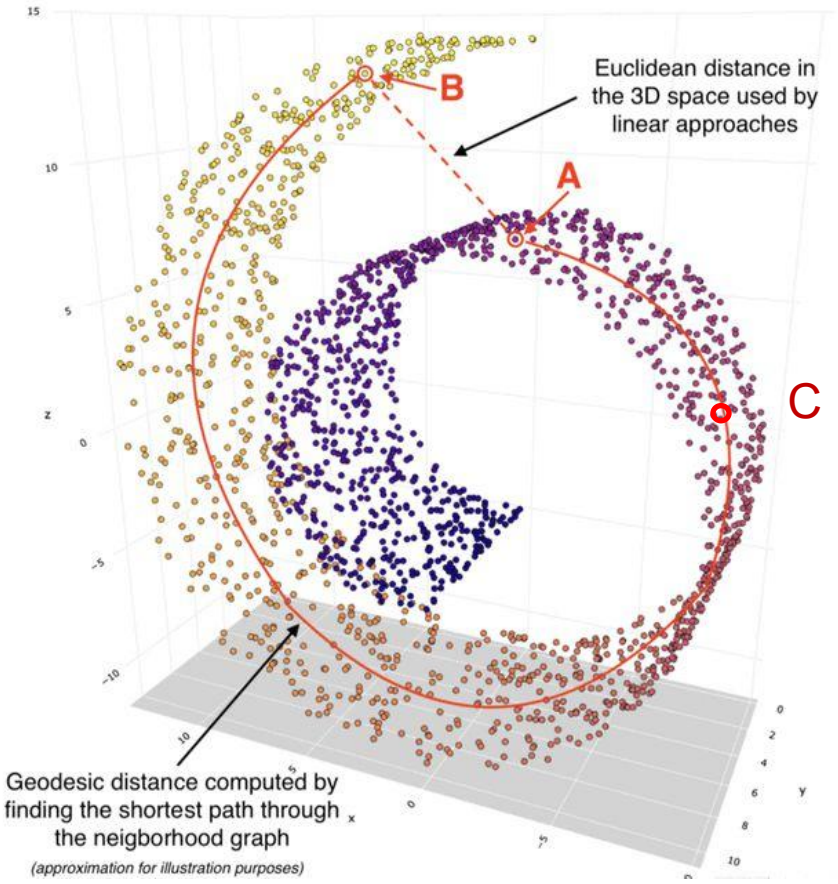

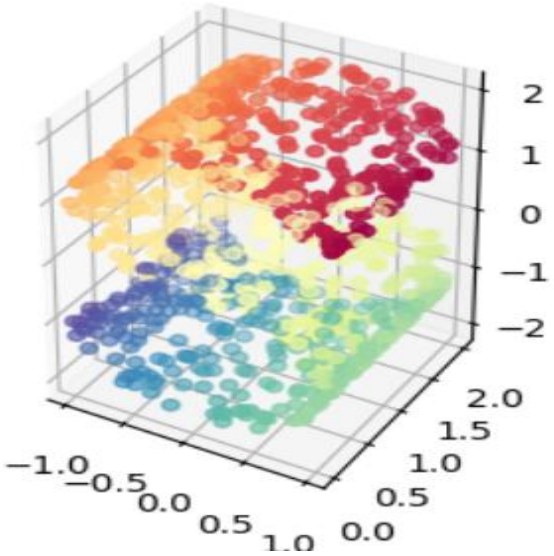

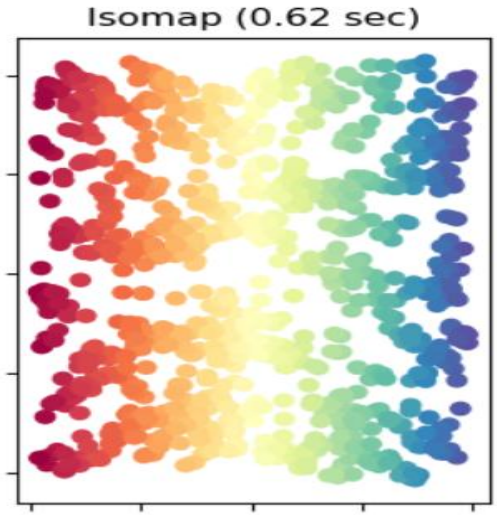

Tenenbaum J B, De V S, Langford J C. A global geometric framework for nonlinear dimensionality reduction.[J]. Science, 2000, 290(5500):2319-2323.

2.4.7度量学习

Isometric Mapping等度量映射

Isomap算法核心在于发现并利用流形空间的特点，引入测地线距离和提出对应的距离计算方法。
流形是在局部区域与欧氏空间同胚的空间，即在局部区域具有欧氏空间的性质，能用欧氏距离来进行距离计算。

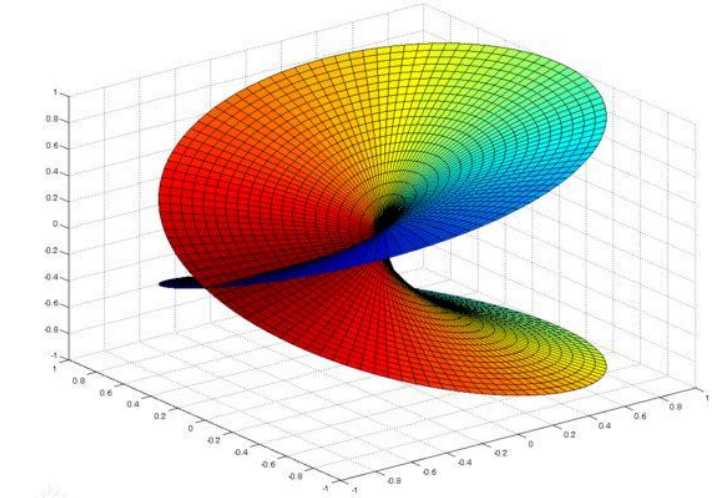

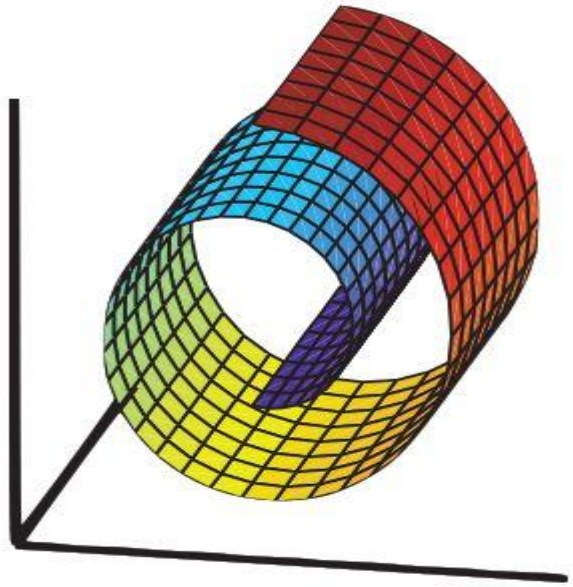

Tenenbaum J B, De V S, Langford J C. A global geometric framework for nonlinear dimensionality reduction.[J]. Science, 2000, 290(5500):2319-2323.

2.4.7度量学习

Isometric Mapping等度量映射

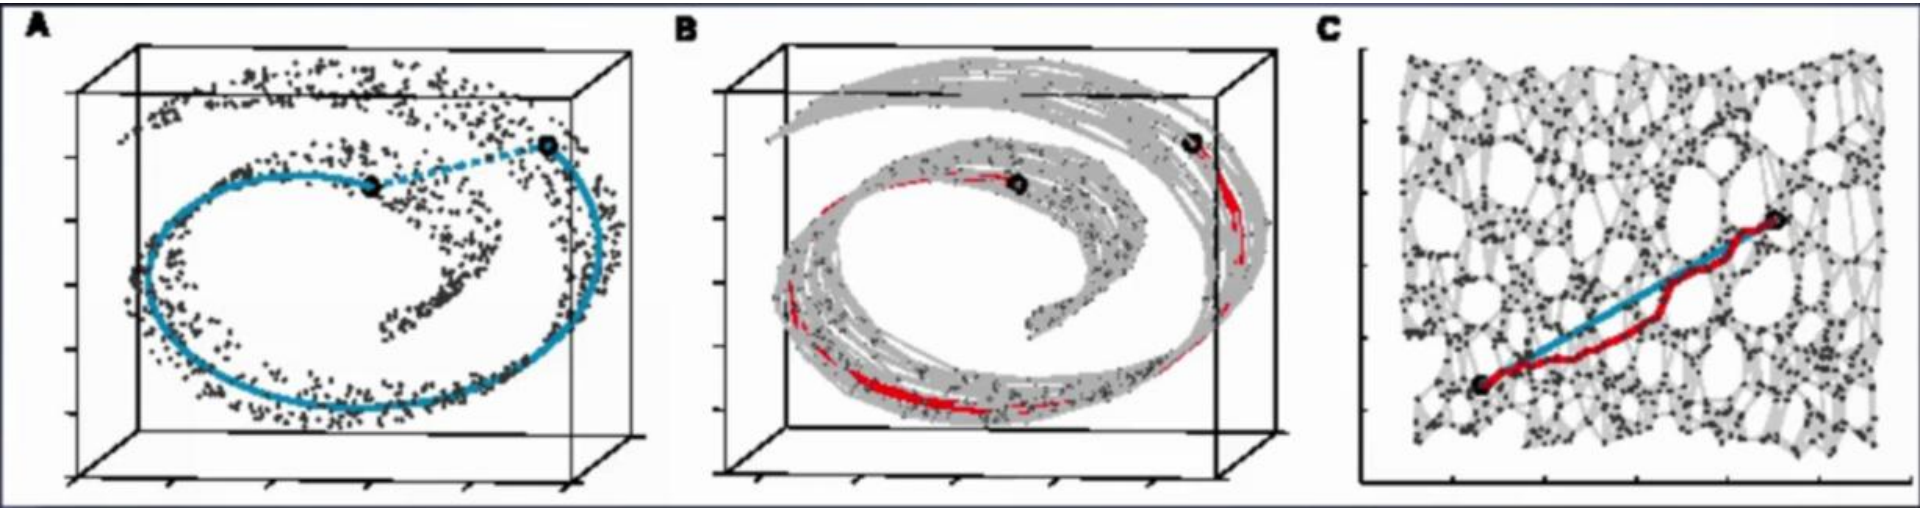

“测地距离”即A中沿曲实线的两点之间的距离，欧氏距离即如A中虚直线的两点之间的直线距离。B图即A的近邻图，C图即B图的低维映射结果，C图中红线为它的“测地距离”而蓝线则为欧氏距离。
对每个点基于欧氏距离找出近邻点，然后建立一个近邻图。于是计算两点之间测地距离的问题就变成了计算近邻图上两点之间的最短路径问题。

Tenenbaum J B, De V S, Langford J C. A global geometric framework for nonlinear dimensionality reduction.[J]. Science, 2000, 290(5500):2319-2323.

Large Margin Nearest Neighbor (LMNN)

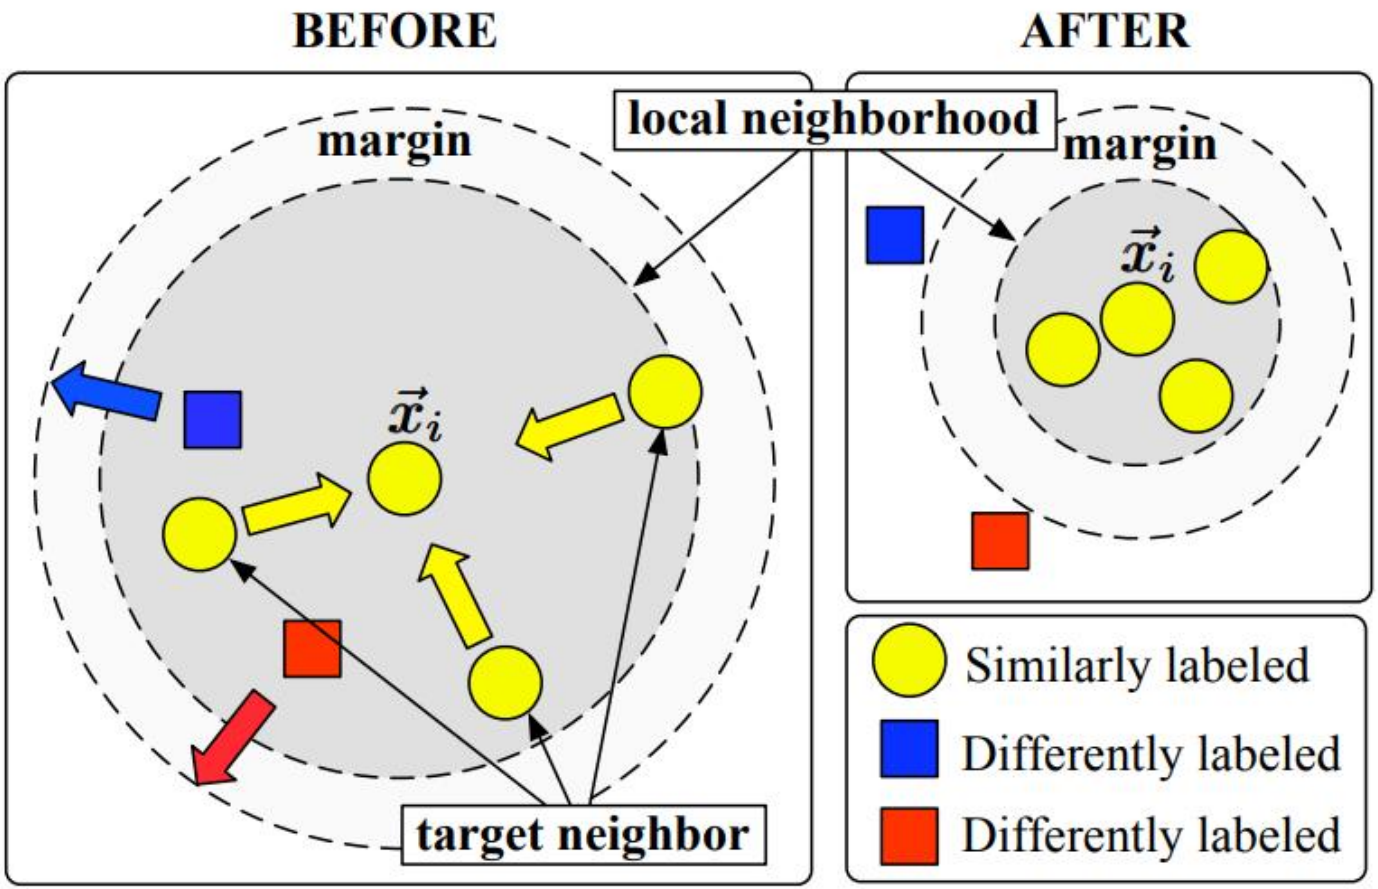

Weinberger, K. Q.; Blitzer J. C., Saul L. K. Distance Metric Learning for Large Margin Nearest Neighbor Classification, Advances in Neural Information Processing Systems 18 (NIPS). 2006: 1473–1480.

Large Margin Nearest Neighbor (LMNN)

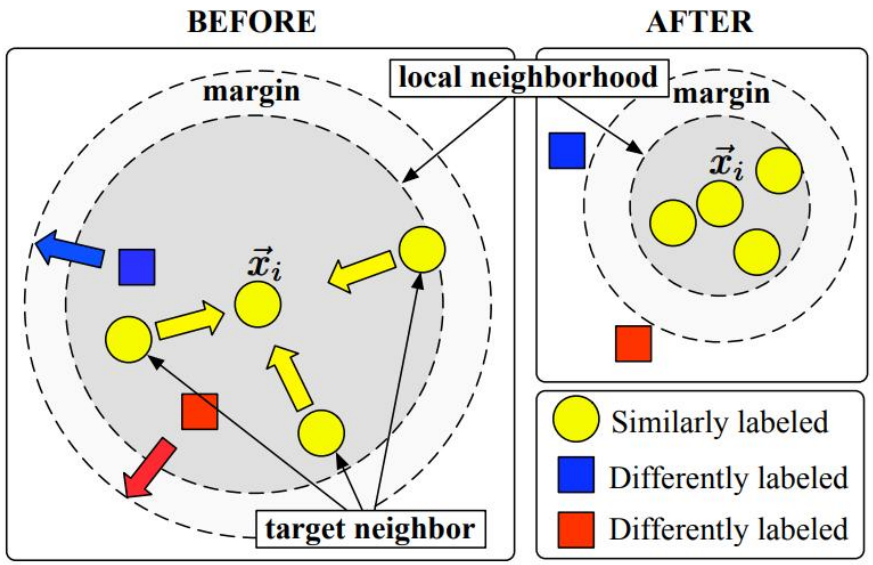

$$\varepsilon_{\text{pull}}(\mathbf{L}) = \sum_{j \rightsquigarrow i} \|\mathbf{L}(\vec{x}_i - \vec{x}_j)\|^2.$$

$$\varepsilon_{\text{push}}(\mathbf{L}) = \sum_{i,j \rightsquigarrow i} \sum_{l} (1 - y_{il}) \left[1 + \|\mathbf{L}(\vec{x}_i - \vec{x}_j)\|^2 - \|\mathbf{L}(\vec{x}_i - \vec{x}_l)\|^2\right]_+$$

$$\varepsilon(\mathbf{L}) = (1-\mu)\,\varepsilon_{pull}(\mathbf{L}) + \mu\varepsilon_{push}(\mathbf{L}).$$

Weinberger, K. Q.; Blitzer J. C., Saul L. K. Distance Metric Learning for Large Margin Nearest Neighbor Classification, Advances in Neural Information Processing Systems 18 (NIPS). 2006: 1473–1480.

2.4.7度量学习

Deep Metric Learning

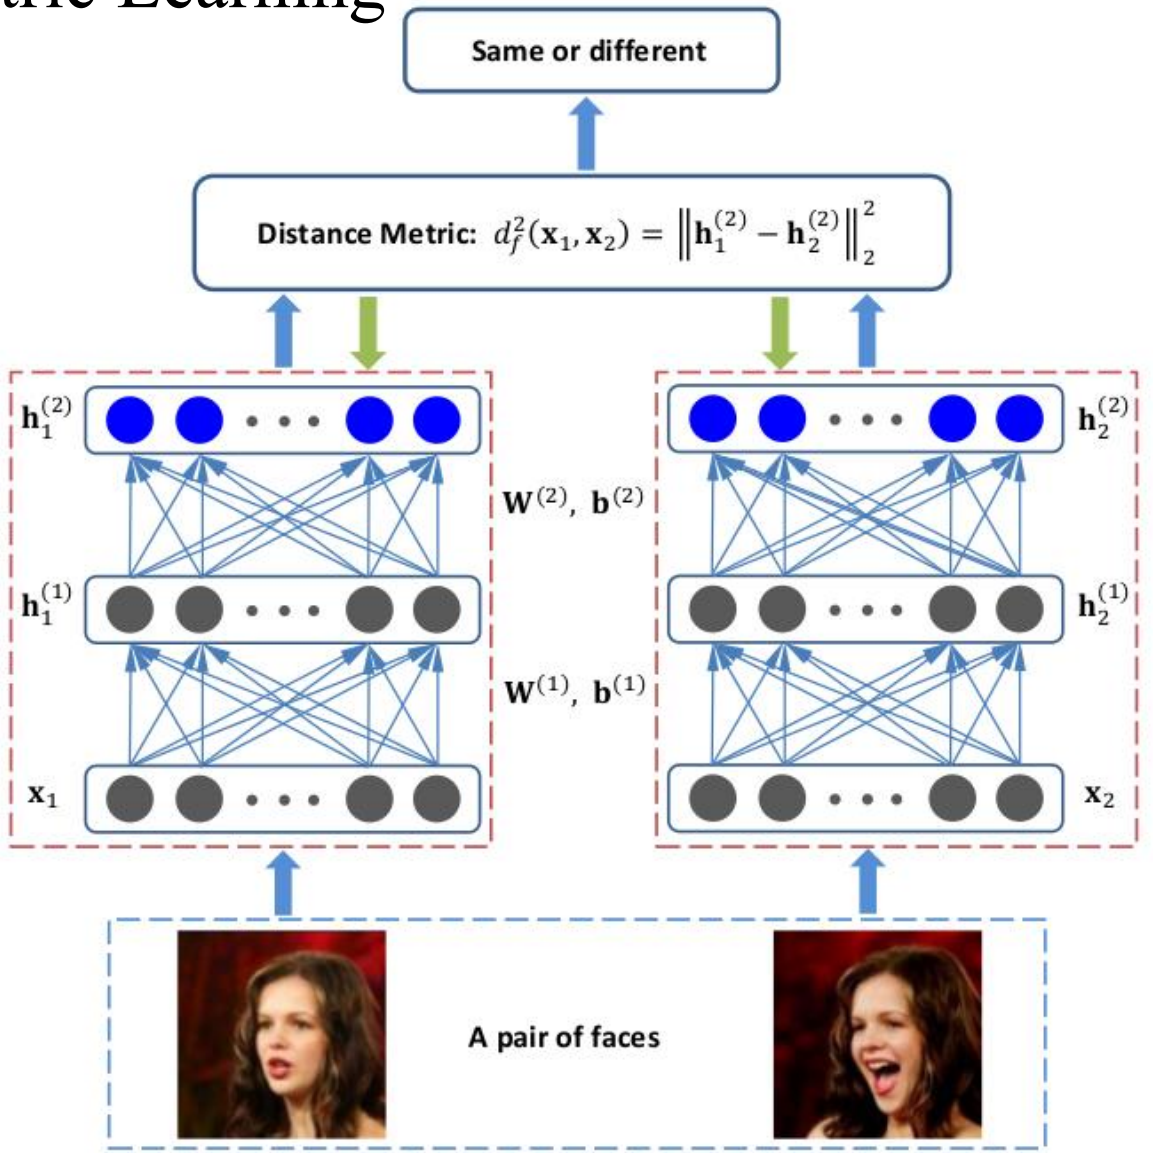

2.4.7度量学习

Deep Metric Learning

（1）对比损失

（2）三元组损失（Triplet loss）

（3）四元组损失(Quadruplet loss)

（4）难样本采样三元组损失(Triplet loss with batch hard mining, TriHard loss)

（5）边界挖掘损失(Margin sample mining loss, MSML)

2.4.8多模态对齐中的相似度

目标：让配对的图像与文本在共享空间中更接近，让不配对样本更远

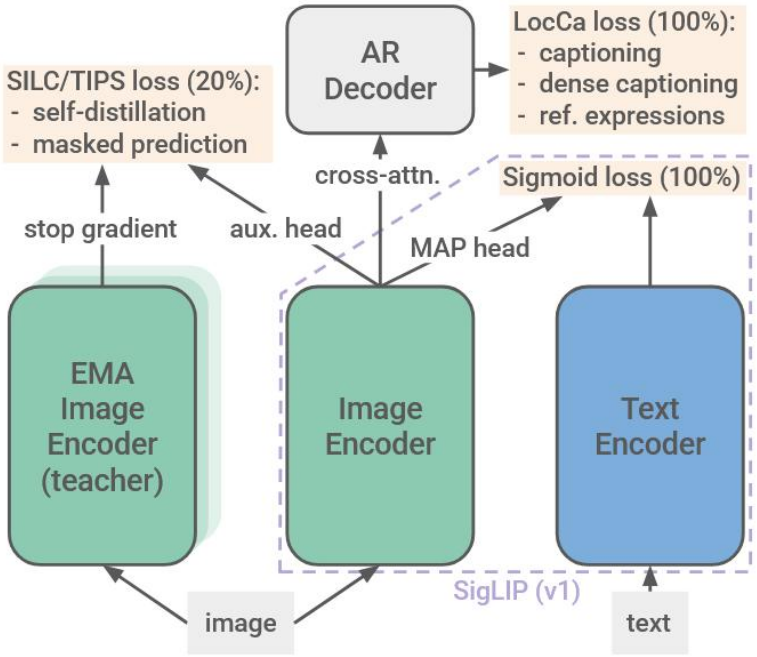

归一化

$$z_i^I = f^I(x_i) / \|f^I(x_i)\|_2$$
$$z_j^T = f^T(t_j) / \|f^T(t_j)\|_2$$

相似度与 Sigmoid 损失

$$s_{ij} = \tau \langle z_i^I, z_j^T \rangle + b$$
$$L = 1/B^2 \sum_i \sum_j \log[1 + \exp(-y_{ij} s_{ij})]$$

y_{ij} = +1 表示匹配，−1 表示不匹配；τ 为可学习温度系数。

SigLIP 2（2025）的前沿改进

- **成对二分类：**用 Sigmoid 损失独立判断每个图文对，避免 CLIP 对全批次 Softmax 的依赖。
- **局部语义增强：**加入图像描述、局部定位、自蒸馏与掩码预测，使图像块特征也具有语义。
- **应用：**跨语言图文检索、零样本分类、开放词汇检测与视觉语言模型的视觉编码。

Zhai et al. Sigmoid Loss for Language-Image Pre-training, ICCV 2023. Tschannen et al. SigLIP 2, arXiv:2502.14786, 2025.

2.4.9大模型嵌入与 RAG 检索

大模型需要在内部计算“注意力相似度”，也需要在外部检索中计算“语义距离”

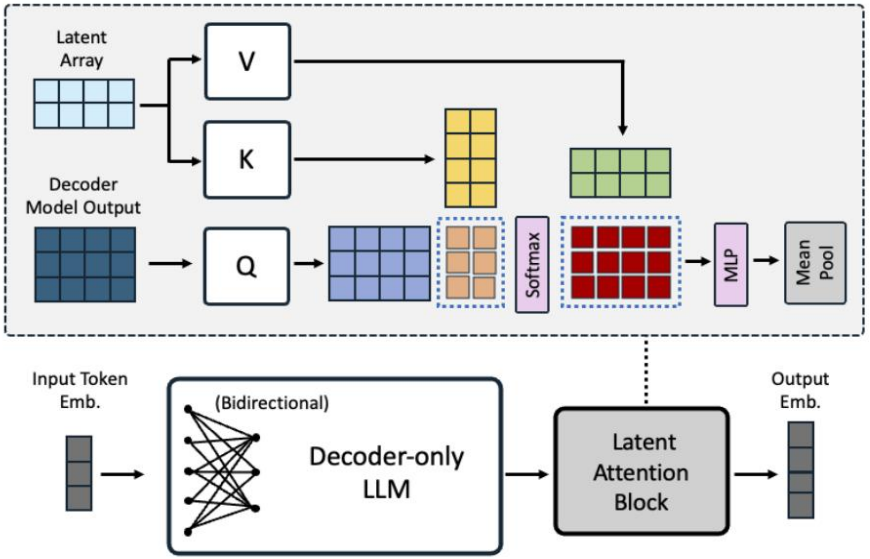

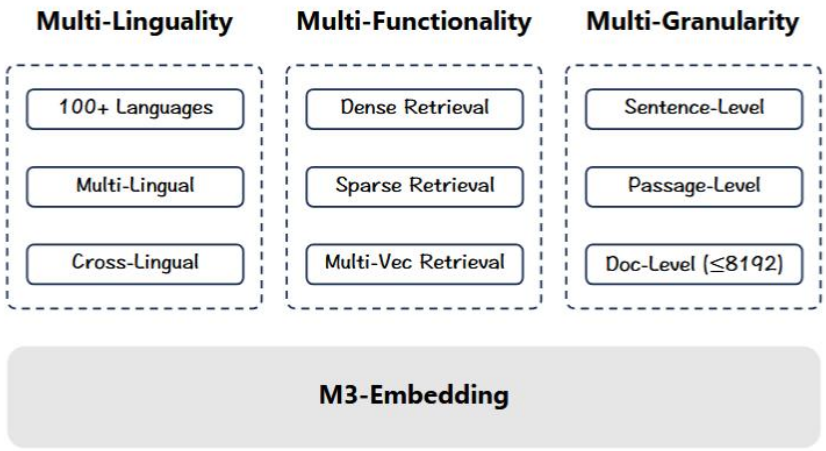

从单一余弦相似度到混合相关度

$$s_rank = w_1 s_dense + w_2 s_lex + w_3 s_mul$$

- **Dense**：归一化句向量的内积，适合语义近似但措辞不同的文本。
- **Lexical**：根据共同词项及其学习权重计算稀疏匹配，保留关键词精确匹配。
- **Multi-vector**：保留词元级向量并采用晚交互，捕捉查询与长文档的细粒度关系。

代表工作

NV-Embed：LLM＋潜在注意力池化＋两阶段对比指令微调（ICLR 2025 Spotlight）

M3-Embedding：统一 dense、sparse 与 multi-vector，支持100余种语言和最长8192词元

Lee et al. NV-Embed. ICLR 2025 Spotlight. Chen et al. M3-Embedding. arXiv:2402.03216, revised 2025.

2.4.10视觉文档 RAG 的细粒度相关度

ColPali：查询按词元表示，文档页按图像块表示，再用 MaxSim 完成晚交互

查询词元向量 $E_q \in \mathbb{R}^{N_q \times 128}$

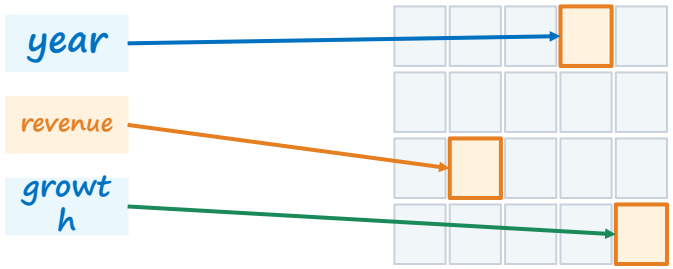

图像中的文字、表格、图形和版式都转化为 patch 向量

文档页面图像块 $E_d \in \mathbb{R}^{N_d \times 128}$

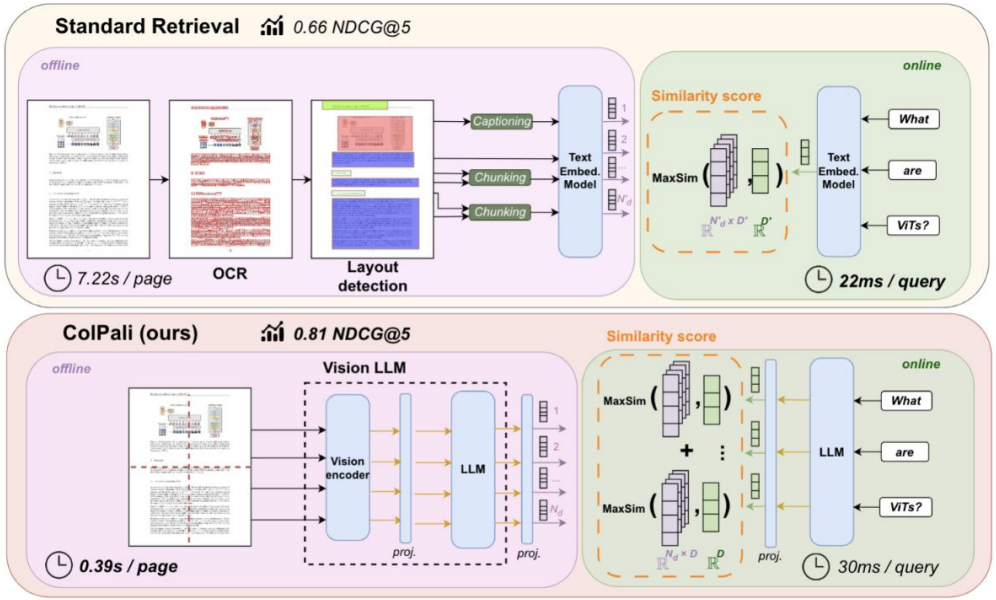

晚交互相关度

- MaxSim：每个查询词元选择最相似的页面图像块，再将各词元的最大相似度求和。
- 优点：比单向量更能保留局部语义，可直接检索含表格、图形和复杂版式的PDF页面。
- RAG作用：先找到与问题最相关的页面，再把页面内容交给多模态大模型生成答案。

小结

- 数据对象与属性类型：
  - 标称、二元、序数、数值属性
  - 离散、连续属性
- 统计描述
  - 度量中心趋势：均值、中位数、众数
  - 度量数据散布：极差、四分位数、方差、标准差
- 数据可视化
  - 盒图、直方图、散点图等
  - 可视化工具
- 度量数据的相似性和相异性
  - 标称属性、二元属性、序数属性
  - 数值属性：欧几里得距离、余弦相似性、度量学习

天津大学
Tianjin University

THE END

天津大学
Tianjin University

数据挖掘

杨柳

智能与计算学部

yangliuyl@tju.edu.cn

第 3 章　数据预处理

3 数据预处理

- 数据质量：为什么要对数据预处理？
  - 数据不规范
  - 数据维度高
  - 数据数量大
  - …
- 怎么解决这些问题呢？

3 数据预处理

- 3.1 数据预处理: 概述
- 3.2 数据清洗
- 3.3 数据集成
- 3.4 数据归约
- 3.5 数据变换
- 3.6 小结

3.1 数据预处理:概述

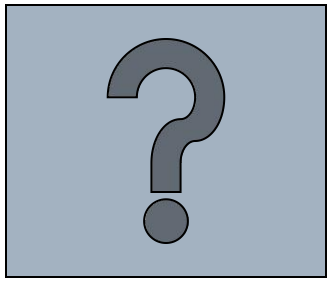

	A	B	C	D	E	F
1	**Missing data**					
2						
3	Id	reading	science	history	math	medicine
4	1	12	27	10	x	44
5	2	11	x	14	13	43
6	3	x	56	17	23	60
7	4	15	37	22	19	x
8	5	22	31	x	21	42
9	6	18	x	11	22	43
10	7	15	50	13	x	56
11	8	21	x	20	28	46
12	9	20	39	19	25	x
13	10	x	36	20	23	56

有缺失

Member Code	Name	Address	BookCode
PV001	Eric Clifford	12, Kensington Terrace	AB012
PV002	Rachel Leigh	32, West Port	AB092
PV001	Eric Clifford	17, Kensington Terrace	AB221
PV002	Rachel Leigh	32, West Port	AB323
PV007	Keith Jennings	120, East Road	AB172

不一致

Welcome to the real world !!!

有噪声

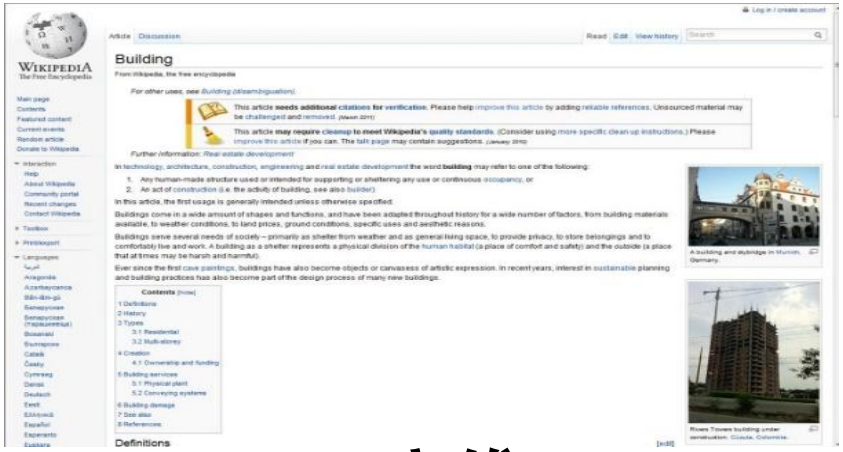

高维

3.1.1 数据质量

数据质量：为什么要对数据预处理？

- 数据质量：
  - 完整性: not recorded, unavailable, …
  - 有噪声: noises, outliers, eg. Salary = “-100”
  - 一致性: Age = “42” vs. Birthday = “01/09/1985”
  - 准确性: correct or wrong, accurate or not
  - 时效性: timely update?
  - 可信性: how trustable the data are correct?
  - 可解释性: how easily the data can be understood?
  - …… relevance

3.1.1 数据质量

数据挖掘关注什么

- 数据质量问题的检测与纠正
- 能容忍数据质量差的算法的使用

3.1.2 数据预处理的主要任务

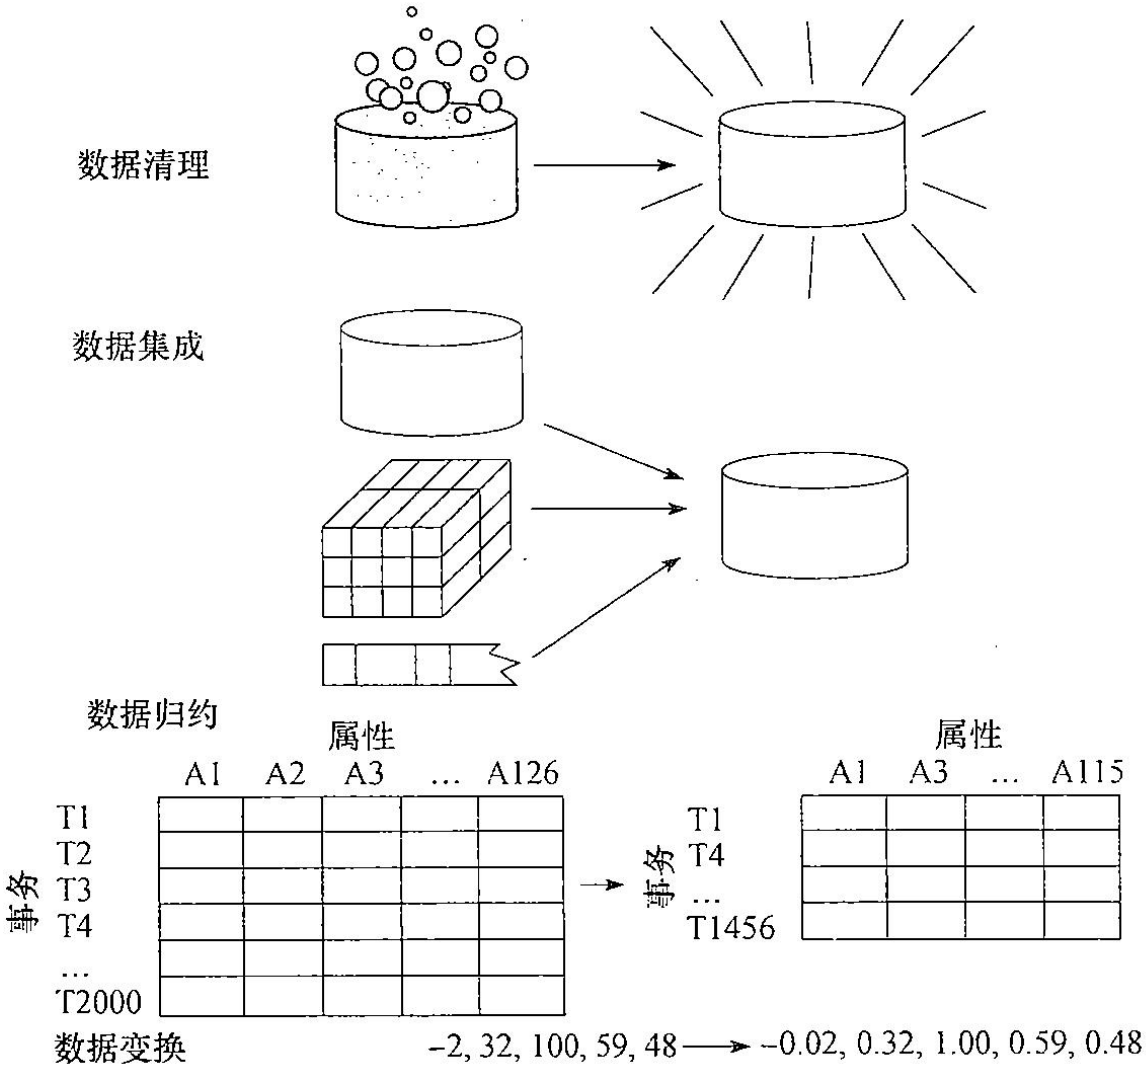

3.1.2 数据预处理的主要任务

完成数据的如下工作：

- 清洗（Data cleaning） 空缺、噪声数据处理等
- 集成（Data integration） 数据合并、汇总、过滤等
- 降维（data reduction） 将高维数据降低到低维空间中
- 转换（Data transformation） 重新格式化和转换

3.1.2 数据预处理的主要任务

整理前的数据特点：

- 质量较差，例如缺失、噪声等；
- 数据来源多样；
- 属性维度灾难；
- 规范程度不一，依赖于数据来源。

目标：为决策支持应用提供一个高质量的数据源。

经过整合集成之后的数据具有以下特点：

- **数据清洗：** 质量可控制的；
- **数据集成：** 统一的数据集；
- **数据降维：** 低维表示；
- **数据转换：** 规范化的。

3 数据预处理

- 3.1 数据预处理: 概述
- 3.2 数据清洗
- 3.3 数据集成
- 3.4 数据归约
- 3.5 数据变换
- 3.6 小结

3.2 数据清洗

3.2 数据清洗

- 现实世界的数据一般是脏数据：许多潜在的不正确的数据，e.g.，仪器故障，人为或电脑错误，传输错误
  - 不完整: 缺少属性值，缺少某些感兴趣的属性
    - e.g., *Occupation*=“ ” (missing data)
  - 有噪声: 包含噪声、误差或异常值
    - e.g., *Salary*=“−10” (an error)
  - 不一致: 包含代码或名称上的差异, e.g.,
    - *Age*=“40”, *Birthday*=“03/07/2010”
    - Was rating “1, 2, 3”, now rating “A, B, C”
    - discrepancy between duplicate records

3.2.1 缺失值

- 数据并不总是完整的

缺少属性值，缺少某些感兴趣的属性。例如：数据库表中，很多条记录的对应字段没有相应值，比如销售表中的顾客收入

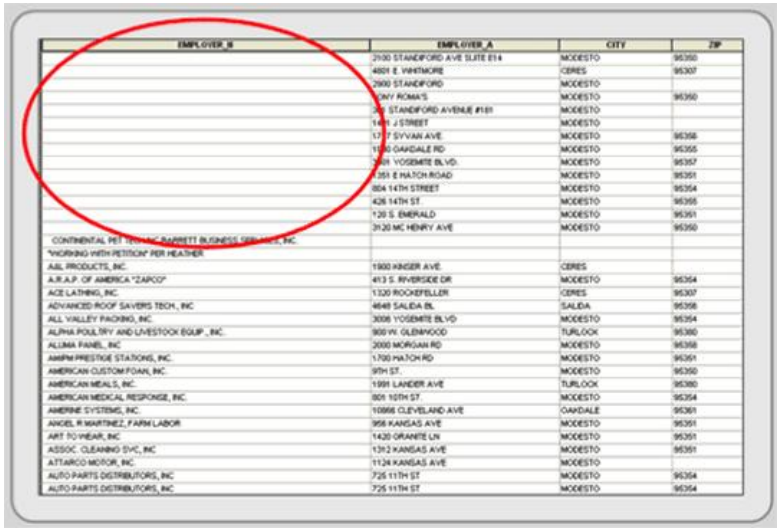

EMPLOYER_ID	EMPLOYER_A	CITY	ZIP
	2100 STANDIFORD AVE SUITE 014	MODESTO	95350
	4801 E. WHITMORE	CERES	95307
	2900 STANDIFORD	MODESTO	
	[illegible]NY ROMA'S	MODESTO	95350
	[illegible] STANDIFORD AVENUE #101	MODESTO	
	1400 J STREET	MODESTO	
	17[illegible]7 SYLVAN AVE	MODESTO	95358
	1[illegible]00 OAKDALE RD	MODESTO	95355
	[illegible] YOSEMITE BLVD.	MODESTO	95357
	[illegible]351 E HATCH ROAD	MODESTO	95351
	804 14TH STREET	MODESTO	95354
	426 14TH ST	MODESTO	95355
	120 S. EMERALD	MODESTO	95351
	3120 MC HENRY AVE	MODESTO	95350
CONTINENTAL PET TECHNIC BARRETT BUSINESS SERVICE, INC			
"WORKING WITH PETSON" PER HEATHER			
A&L PRODUCTS, INC.	1900 KINSER AVE.	CERES	
A.R.A.P. OF AMERICA "ZAPCO"	413 S. RIVERSIDE DR	MODESTO	95354
ACE LATHING, INC.	1320 ROCKEFELLER	CERES	95307
ADVANCED ROOF SAVERS TECH., INC	4648 SALEDA BL	SALIDA	95358
ALL VALLEY PACKING, INC	3008 YOSEMITE BLVD	MODESTO	95354
ALPHA POULTRY AND LIVESTOCK EQUIP., INC.	900 W. GLENWOOD	TURLOCK	95380
ALUMA PANEL, INC	2000 MORGAN RD	MODESTO	95358
AMPM PRESTIGE STATIONS, INC.	1700 HATCH RD	MODESTO	95351
AMERICAN CUSTOM FOAM, INC.	9TH ST.	MODESTO	95350
AMERICAN MEALS, INC.	1991 LANDER AVE	TURLOCK	95380
AMERICAN MEDICAL RESPONSE, INC.	801 10TH ST.	MODESTO	95354
AMERINE SYSTEMS, INC.	10866 CLEVELAND AVE	OAKDALE	95361
ANGEL R MARTINEZ, FARM LABOR	958 KANSAS AVE	MODESTO	95351
ART TO WEAR, INC	1420 GRANITE LN	MODESTO	95351
ASSOC. CLEANING SVC, INC	1312 KANSAS AVE	MODESTO	95351
ATTARCO MOTOR, INC.	1124 KANSAS AVE	MODESTO	
AUTO PARTS DISTRIBUTORS, INC	725 11TH ST	MODESTO	95354
AUTO PARTS DISTRIBUTORS, INC	725 11TH ST	MODESTO	95354

- 数据丢失可能是由于：
  - 设备异常
  - 人为的失误
  - 在输入时，有些数据因得不到重视而没有被输入
  - 不适用Not Applicable (N/A)
- 空缺值要经过推断而补上

3.2.1 缺失值

例子：如何处理空缺值？

	A	B	C	D	E	F
1	Missing data					
2						
3	Id	reading	science	history	math	medicine
4	1	12	27	10	x	44
5	2	11	x	14	13	43
6	3	x	56	17	23	60
7	4	15	37	22	19	x
8	5	22	31	x	21	42
9	6	18	x	11	22	43
10	7	15	50	13	x	56
11	8	21	x	20	28	46
12	9	20	39	19	25	x
13	10	x	36	20	23	56

3.2.1 缺失值

如何处理空缺值？

- 1. 忽略有缺失值的样本

假定挖掘任务设计为分类或描述时，有缺失值的样本通常被忽略。当属性缺失值比较多时，挖掘算法的效果非常差。

- 2. 人工填写空缺值

重新采集、利用领域知识等方法。工作量大，枯燥乏味，可行性低

- 3. 使用以下方法自动填充
  - 使用一个全局常量填充空缺值：比如使用“unknown”或-∞
  - 使用属性的平均值填充空缺值
  - 使用与给定样本属同一类的所有样本的平均值
  - 建模预测：使用像Bayesian公式或判定树这样的基于推断的方法、回归的方法、矩阵补全等

3.2.1 缺失值

插值法

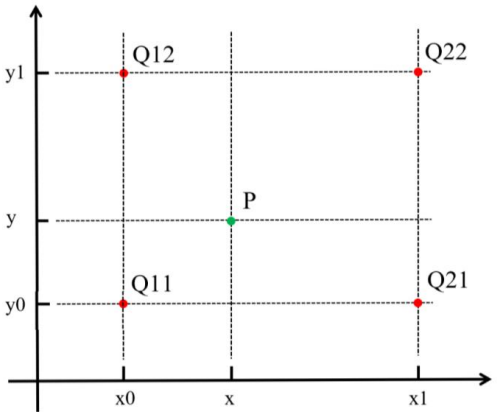

最邻近插值法

56	23	15
65	32	78
12	45	62

→

56	23	15	15
65	32	78	78
12	45	62	62
12	45	62	62

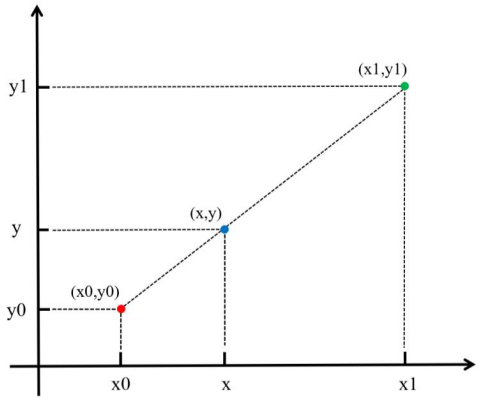

线性插值

0	255

↗

0	0	255	255

↘

0	85	170	255

3.2.1 缺失值

图像恢复

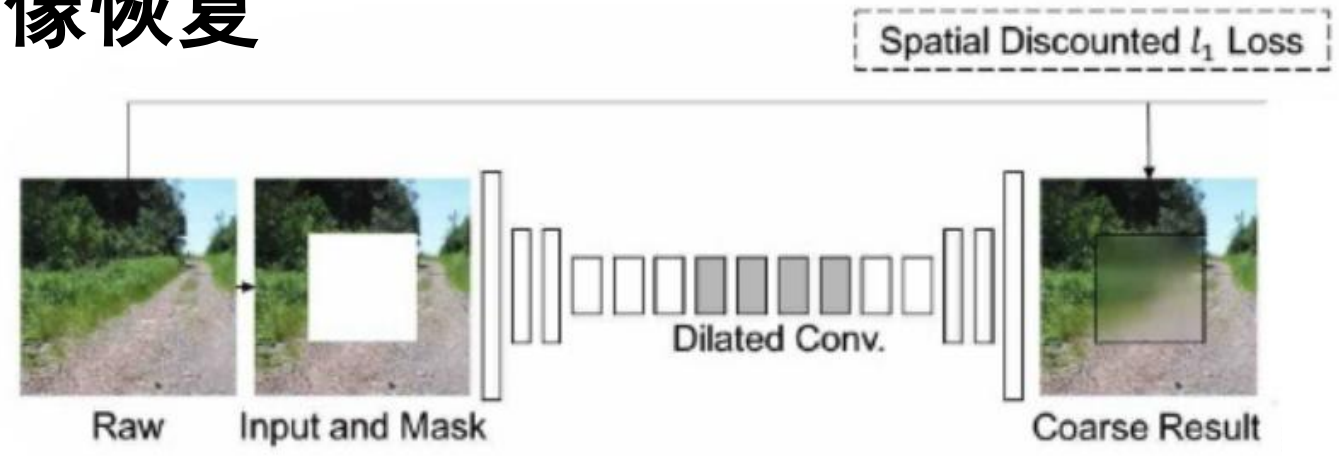
Spatial Discounted l_1 Loss
Raw
Input and Mask
Dilated Conv.
Coarse Result

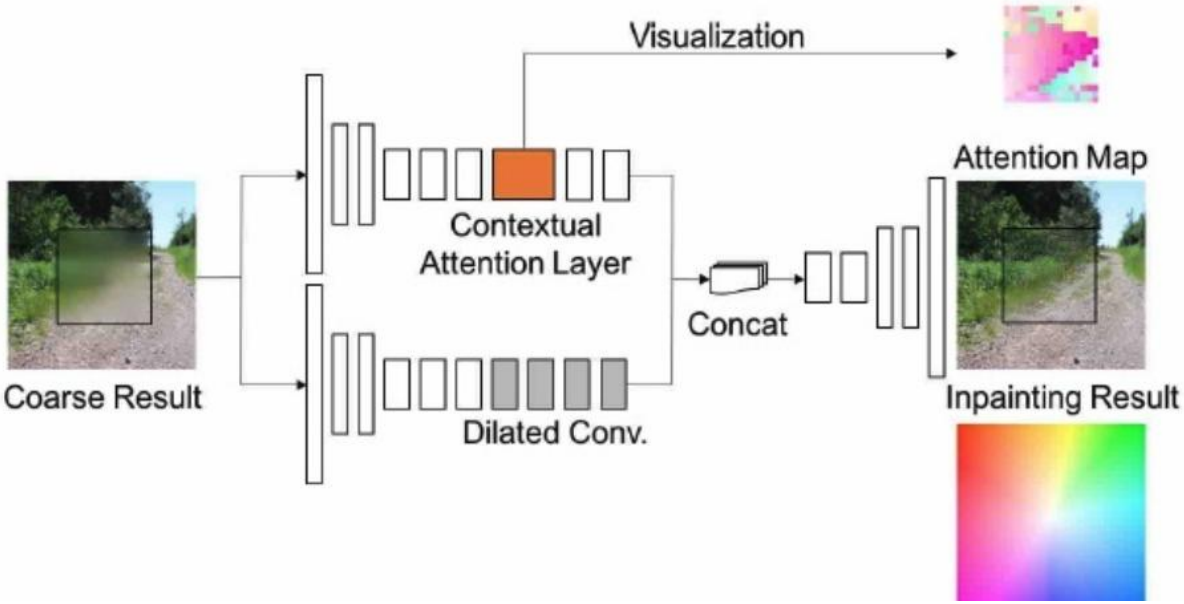
Visualization
Attention Map
Contextual
Attention Layer
Concat
Coarse Result
Dilated Conv.
Inpainting Result

3.2.1 缺失值

关系补全

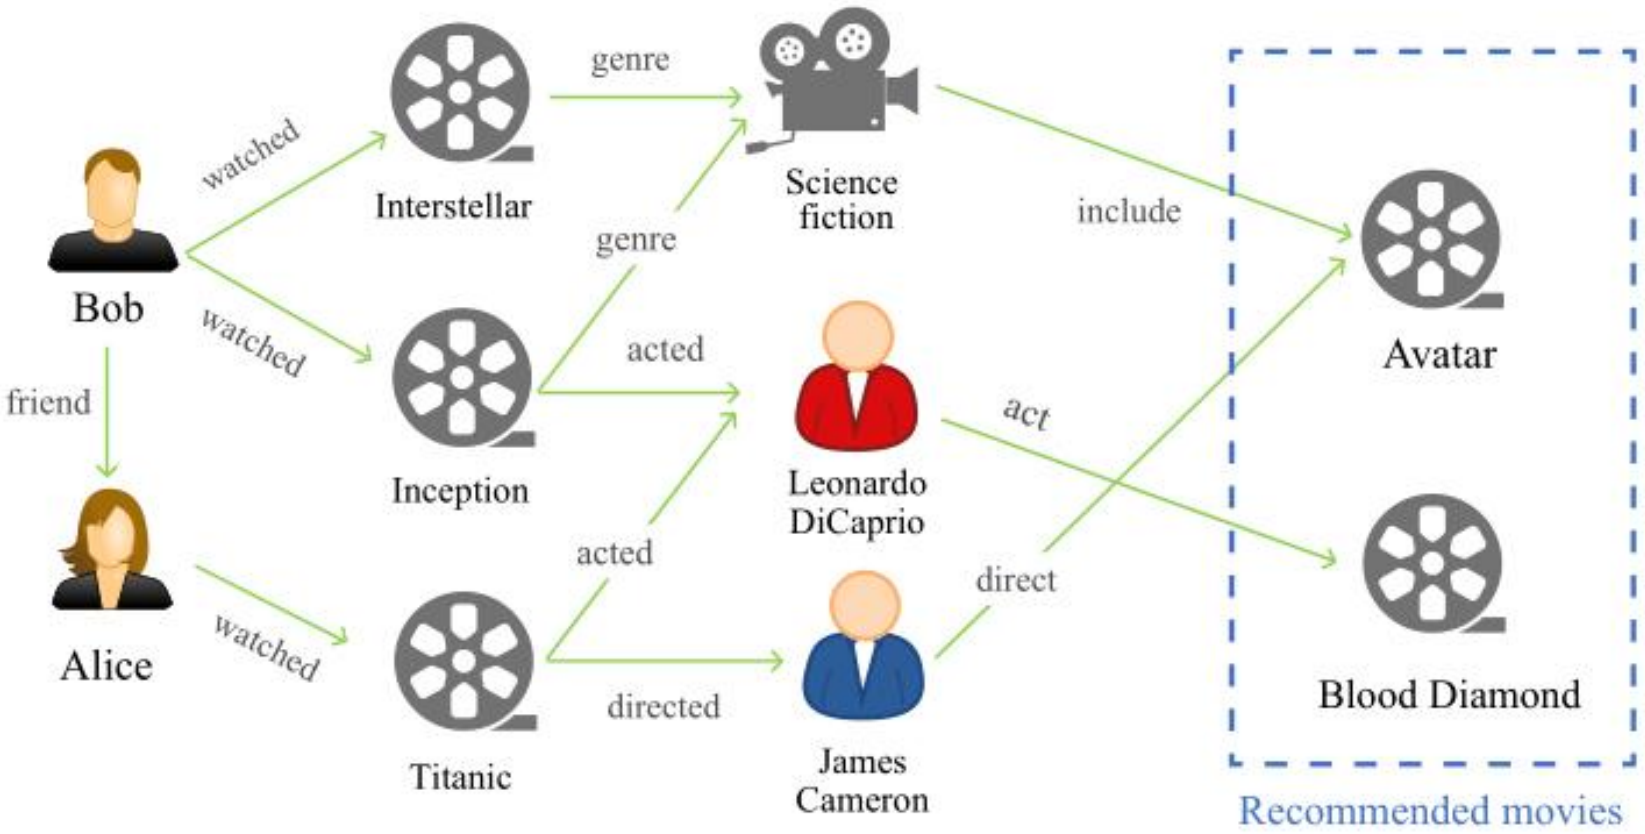
genre
watched
Interstellar
Science fiction
include
genre
Bob
watched
acted
Avatar
friend
act
Inception
Leonardo DiCaprio
acted
direct
watched
Alice
Blood Diamond
directed
Titanic
James Cameron
Recommended movies

3.2.1 缺失值

nature communications

Article | Article in Press

https://doi.org/10.1038/s41467-026-77922-1

Dynamics-informed machine learning for recovering extensive missing systems dynamics

Received: 27 February 2026

Accepted: 9 September 2026

Tao Wu[1,2], Xiangyun Gao[3,4], Ying Tang[5,6], Feng An[7], Xiaotian Sun[8], Kazuyuki Aihara[2], Haizhong An[3,4,9] & Jürgen Kurths[10]

时间序列缺失90%仍能重构，前提是留住一条完整序列

3.2.1 缺失值

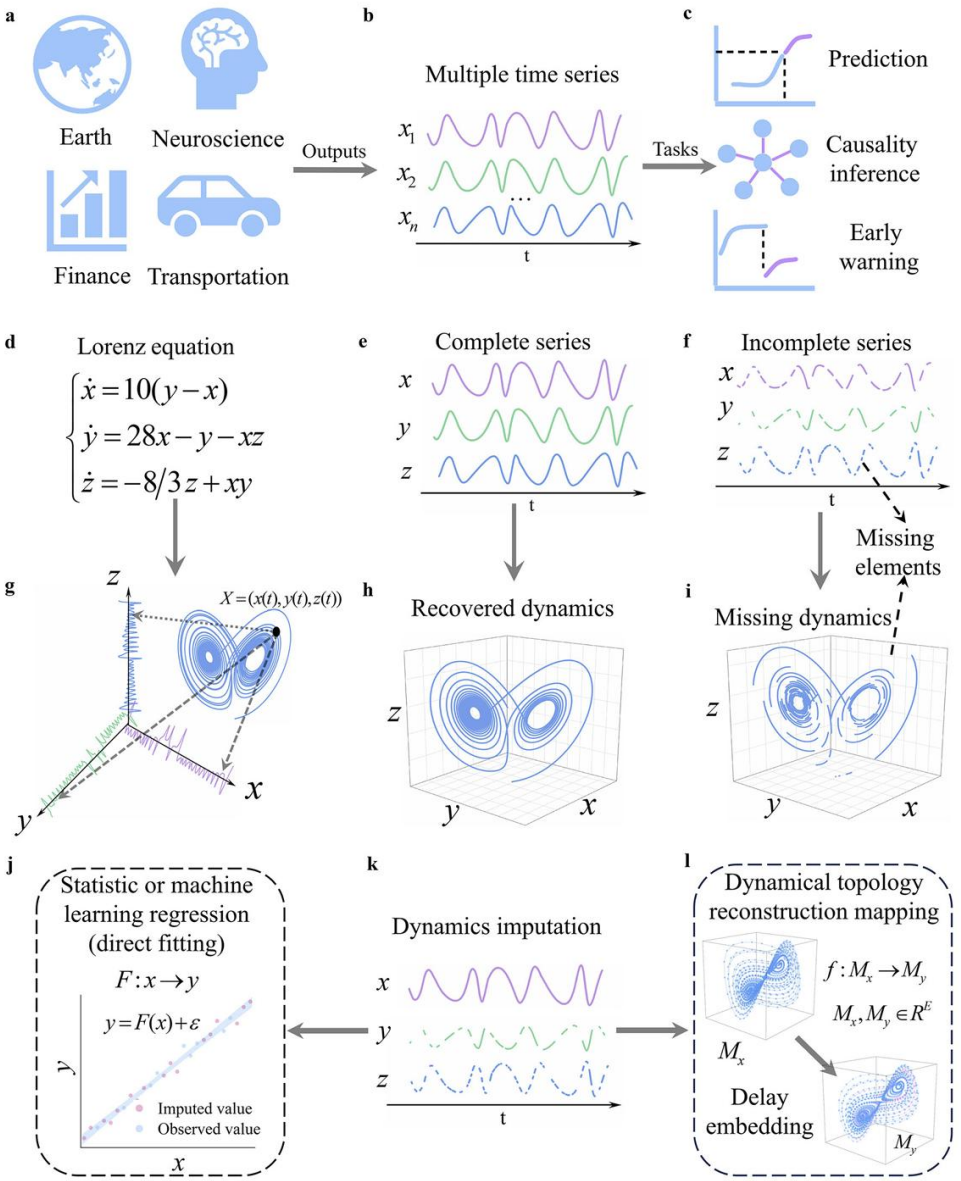
a
Earth
Neuroscience
Finance
Transportation
Outputs
b
Multiple time series
x_1
x_2
x_n
t
Tasks
c
Prediction
Causality inference
Early warning
d
Lorenz equation
$\dot{x}=10(y-x)$
$\dot{y}=28x-y-xz$
$\dot{z}=-8/3\,z+xy$
e
Complete series
x
y
z
t
f
Incomplete series
x
y
z
t
Missing elements
g
z
$X=(x(t),y(t),z(t))$
y
x
h
Recovered dynamics
z
y
x
i
Missing dynamics
z
y
x
j
Statistic or machine learning regression (direct fitting)
$F:x\to y$
$y=F(x)+\varepsilon$
y
Imputed value
Observed value
x
k
Dynamics imputation
x
y
z
t
l
Dynamical topology reconstruction mapping
$f:M_x\to M_y$
$M_x,M_y\in R^E$
M_x
Delay embedding
M_y

3.2.1 缺失值

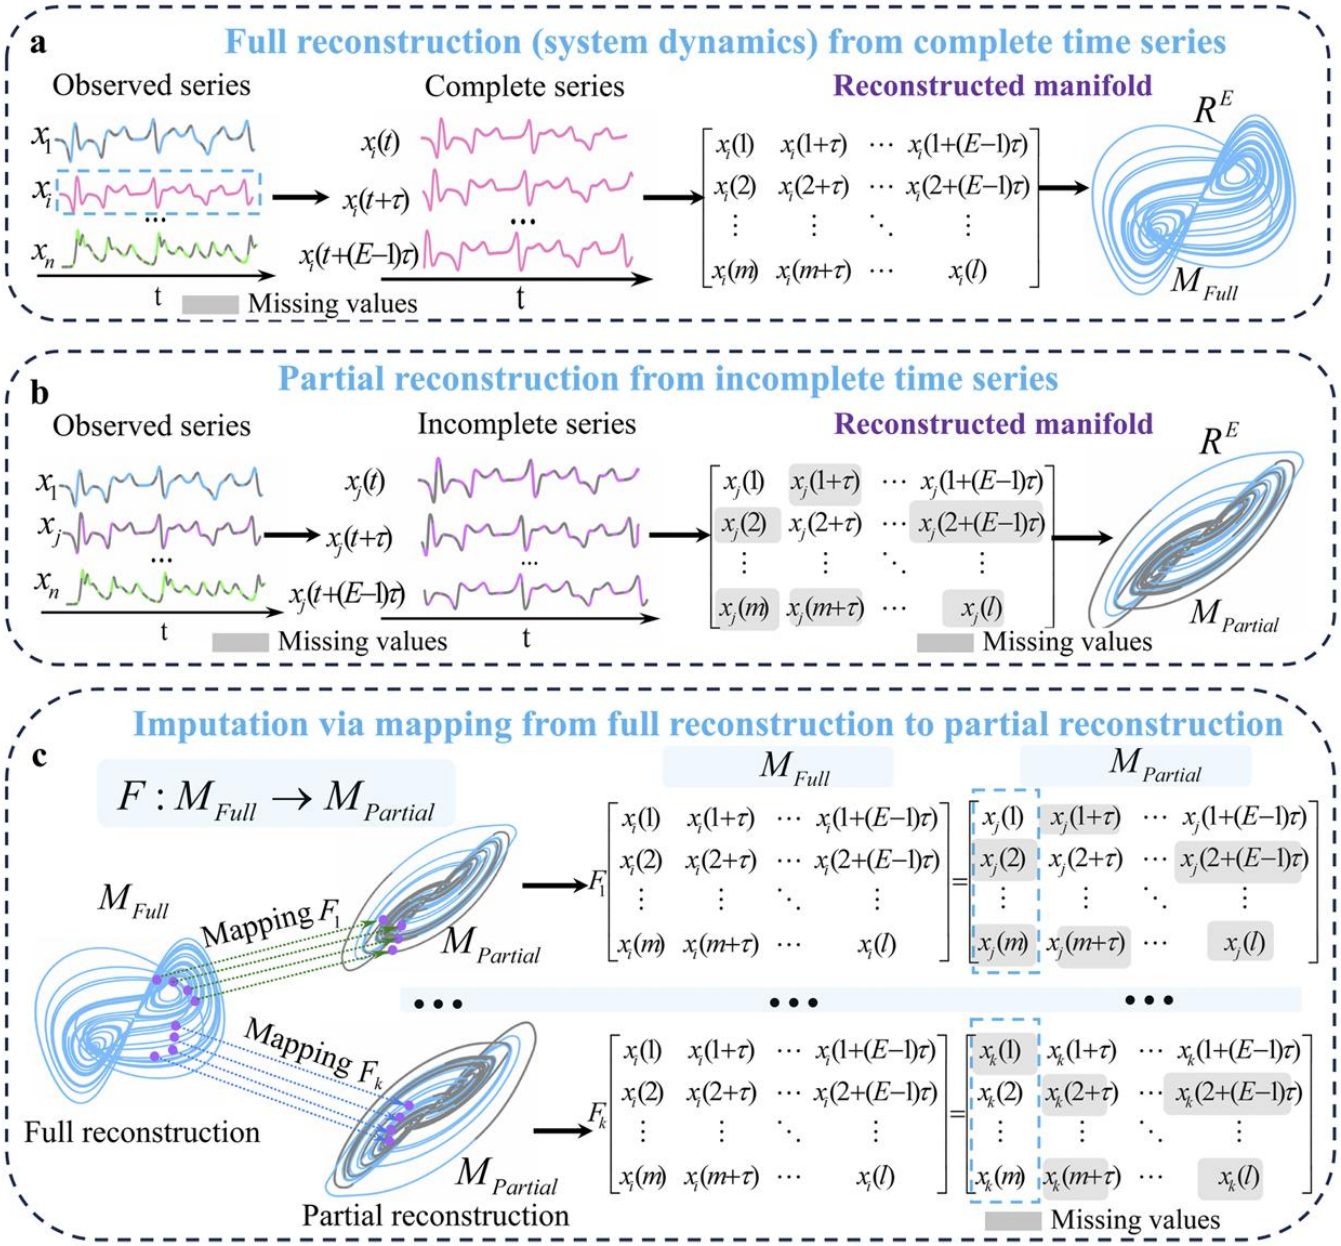
a
Full reconstruction (system dynamics) from complete time series
Observed series
Complete series
Reconstructed manifold
Missing values
b
Partial reconstruction from incomplete time series
Observed series
Incomplete series
Reconstructed manifold
Missing values
c
Imputation via mapping from full reconstruction to partial reconstruction
Mapping F_1
Mapping F_k
Full reconstruction
Partial reconstruction
Missing values

3.2.1 缺失值

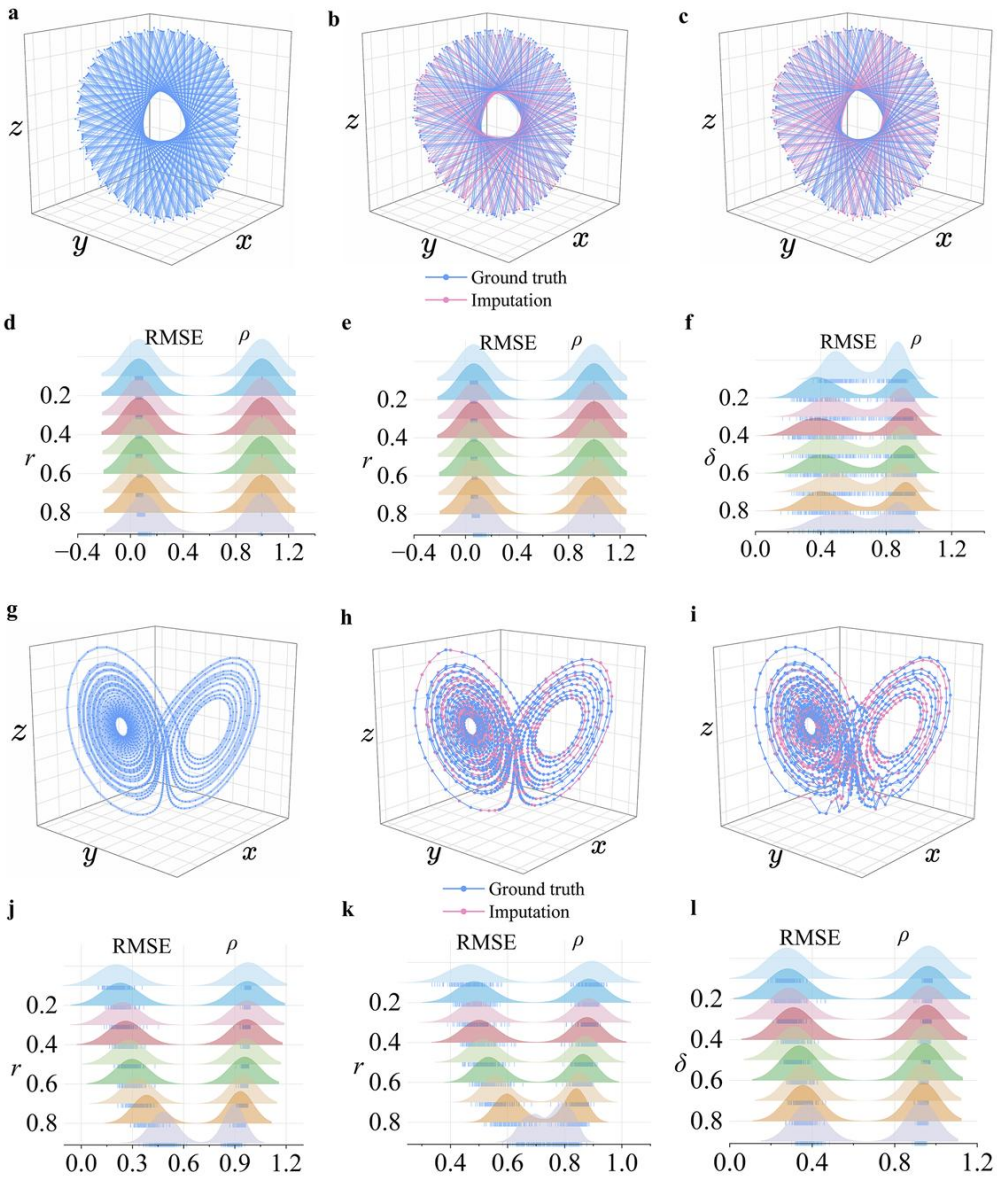
a
b
c
z
y
x
Ground truth
Imputation
d
e
f
RMSE
ρ
r
δ
0.2
0.4
0.6
0.8
−0.4 0.0 0.4 0.8 1.2
0.0 0.4 0.8 1.2
g
h
i
j
k
l
0.0 0.3 0.6 0.9 1.2
0.4 0.6 0.8 1.0

3.2.1 缺失值

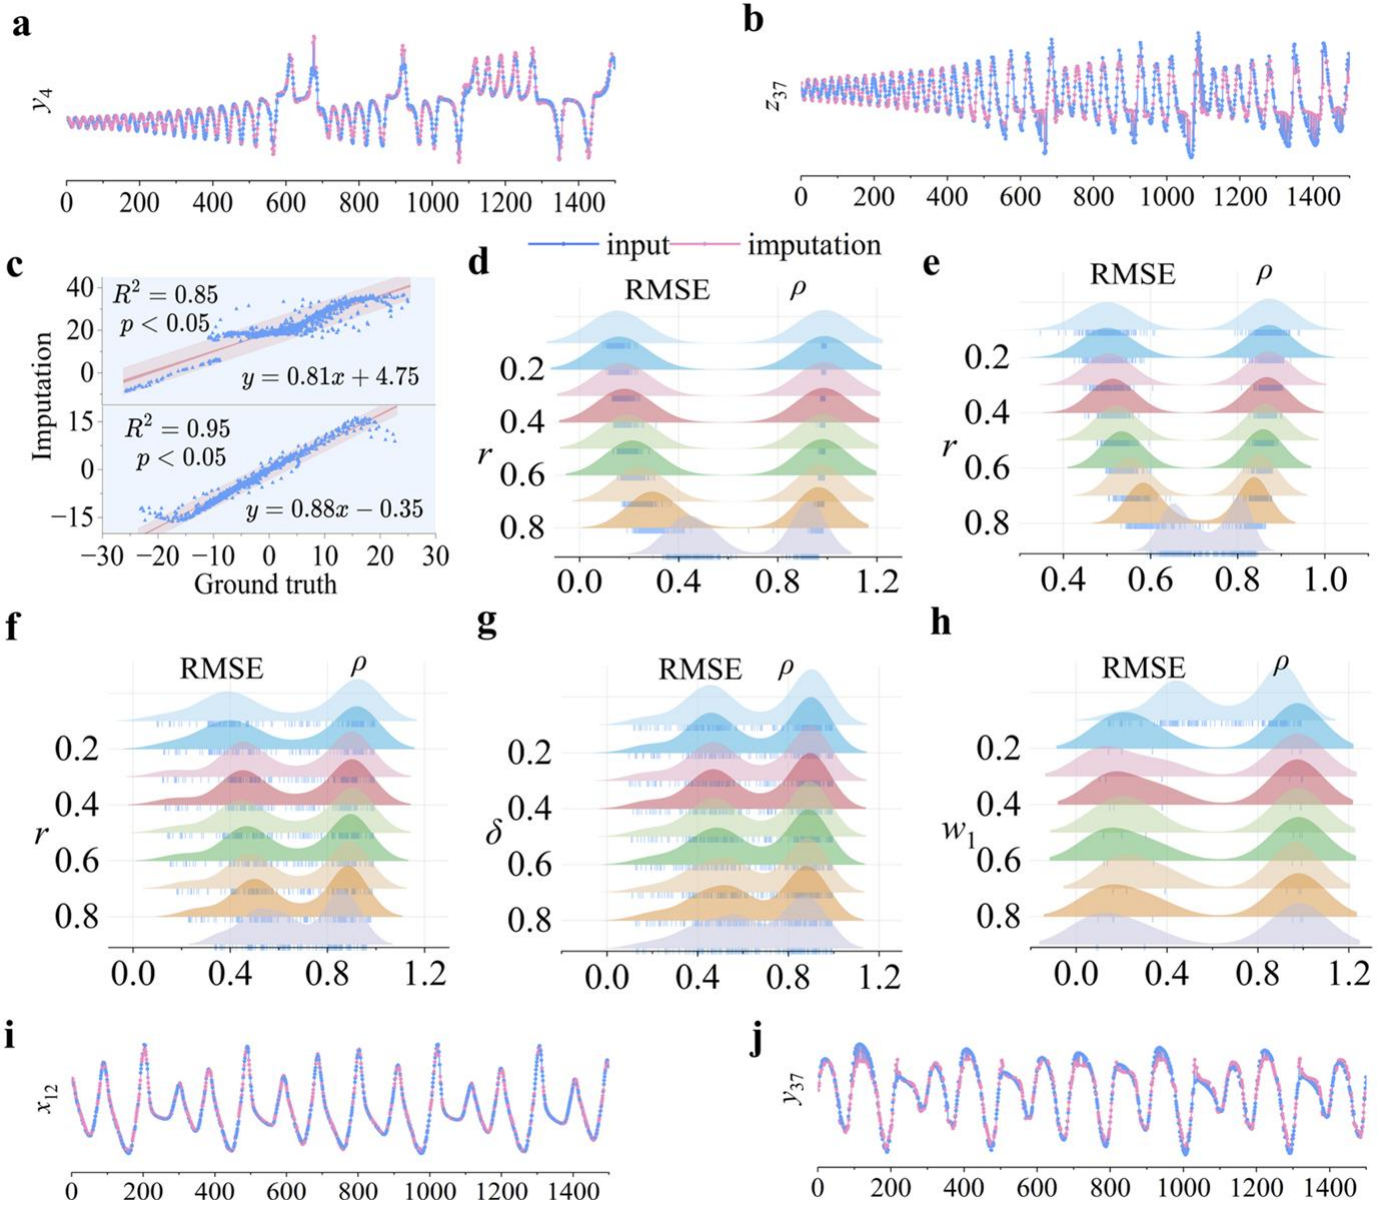
a
y_4
0 200 400 600 800 1000 1200 1400
b
z_{37}
0 200 400 600 800 1000 1200 1400
input imputation
c
$R^2 = 0.85$
$p < 0.05$
$y = 0.81x + 4.75$
$R^2 = 0.95$
$p < 0.05$
$y = 0.88x - 0.35$
Imputation
Ground truth
d
RMSE ρ
r
e
RMSE ρ
r
f
RMSE ρ
r
g
RMSE ρ
δ
h
RMSE ρ
w_1
i
x_{12}
0 200 400 600 800 1000 1200 1400
j
y_{37}
0 200 400 600 800 1000 1200 1400

3.2.1 缺失值

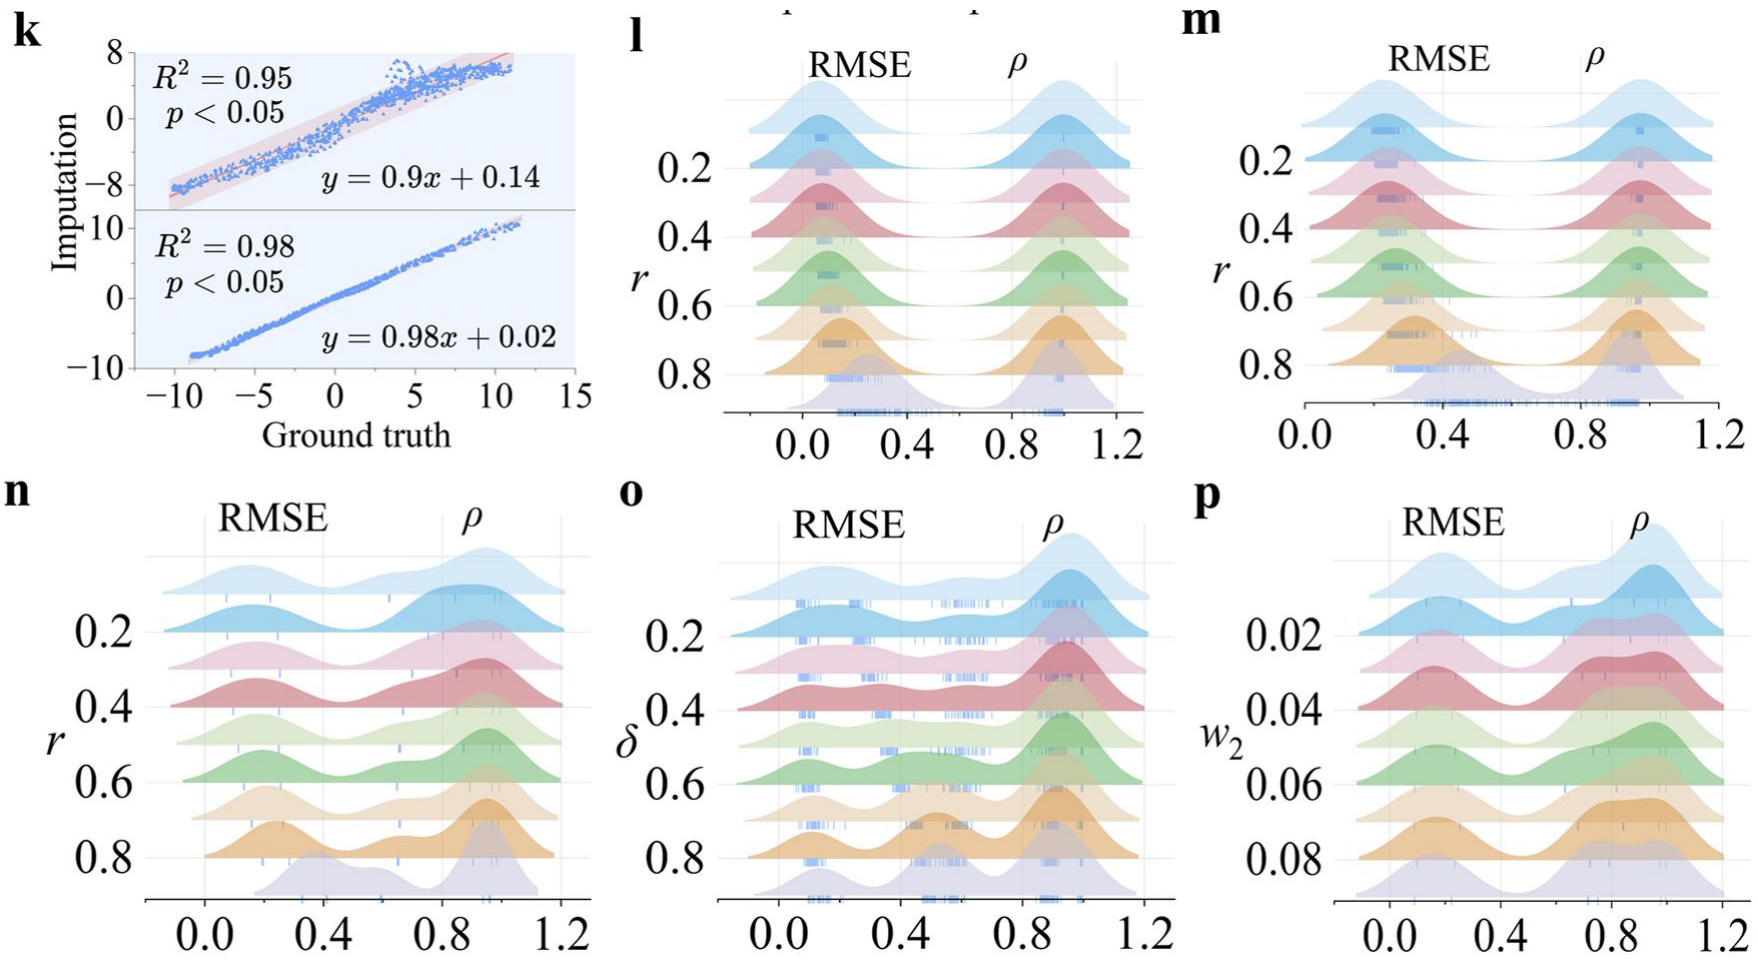
k
$R^2 = 0.95$
$p < 0.05$
$y = 0.9x + 0.14$
$R^2 = 0.98$
$p < 0.05$
$y = 0.98x + 0.02$
Imputation
Ground truth
l
m
n
o
p
RMSE
ρ
r
δ
w_2

3.2.1 缺失值

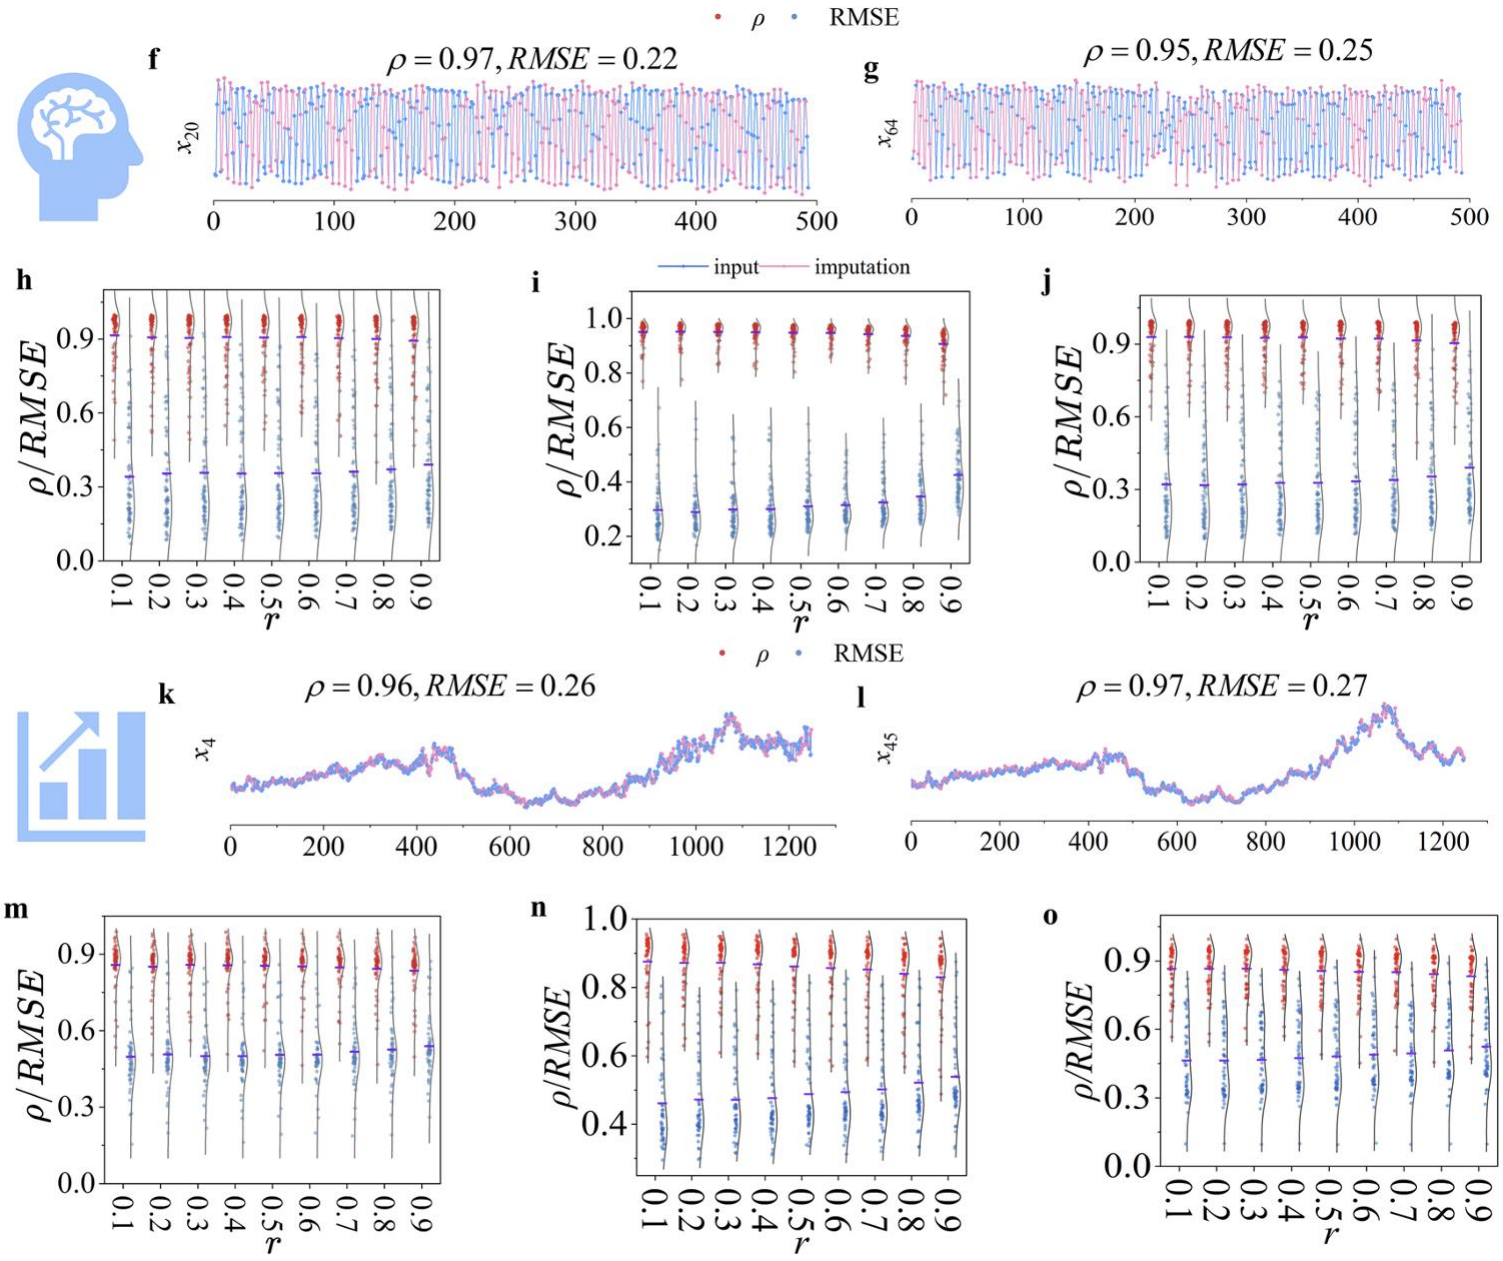
ρ RMSE
f
ρ = 0.97, RMSE = 0.22
x20
g
ρ = 0.95, RMSE = 0.25
x64
input imputation
h
i
j
ρ/RMSE
r
ρ RMSE
k
ρ = 0.96, RMSE = 0.26
x4
l
ρ = 0.97, RMSE = 0.27
x45
m
n
o

3.2.1 缺失值

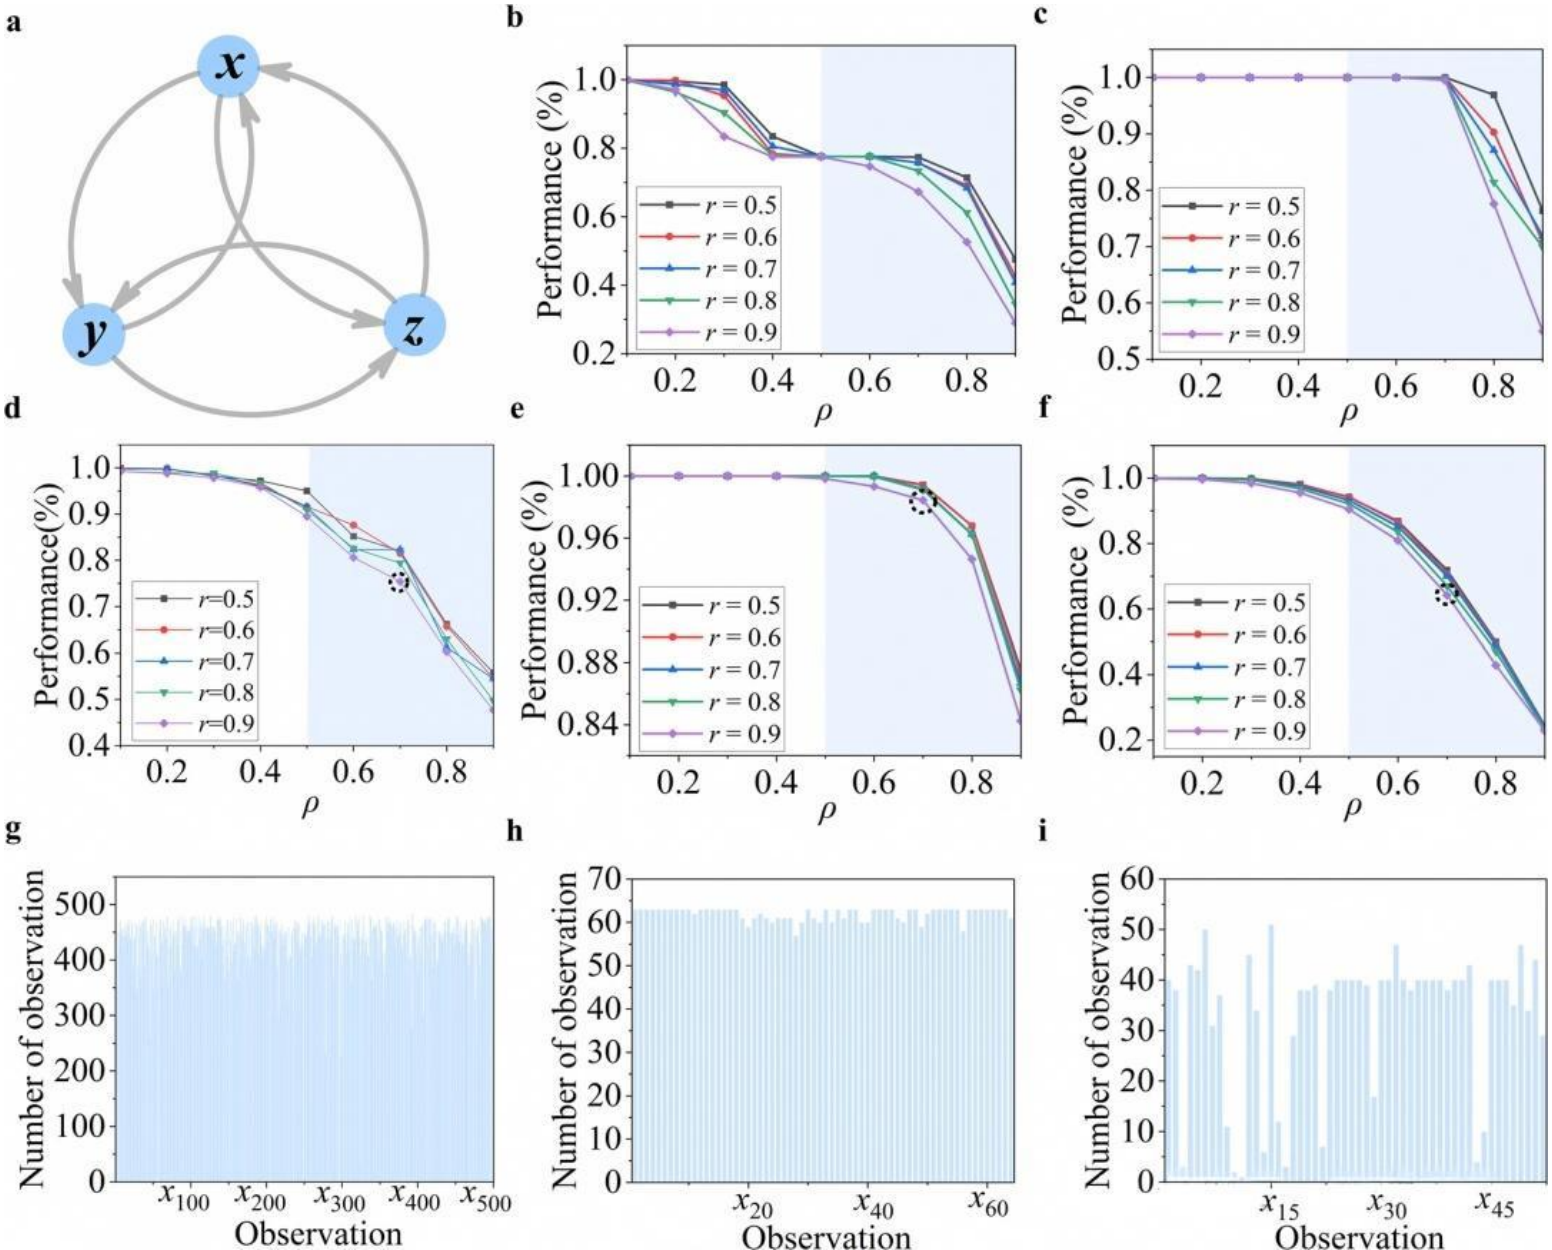
a
x
y
z
b
Performance (%)
ρ
r = 0.5
r = 0.6
r = 0.7
r = 0.8
r = 0.9
c
Performance (%)
ρ
d
Performance(%)
ρ
r=0.5
r=0.6
r=0.7
r=0.8
r=0.9
e
Performance (%)
ρ
f
Performance (%)
ρ
g
Number of observation
Observation
h
Number of observation
Observation
i
Number of observation
Observation

3.2.1 缺失值

如何处理空缺值？

- Niels Ipsen, Pierre-Alexandre Mattei, Jes Frellsen. How to deal with missing data in supervised deep learning? - ICML Workshop on the Art of Learning with Missing Values, 2020.
- Y. Fortuin, D. Baranchuk, G. Rätsch, S. Mandt. GP-VAE: Deep Probabilistic Time Series Imputation - International Conference on Artificial Intelligence and Statistics (AISTATS), 2020.
- Yusuke Tashiro, Jiaming Song, Yang Song, Stefano Ermon. CSDI: Conditional Score-based Diffusion Models for Probabilistic Time Series Imputation - Advances in Neural Information Processing Systems (NeurIPS), 2021.
- Wenjie Du, David Côté, Yan Liu. SAITS: Self-Attention-based Imputation for Time Series - Expert Systems with Applications, Volume 219, Article 119619, 2023.
- Hengrui Zhang, Liancheng Fang, Qitian Wu, Philip S. Yu. DiffPuter: Empowering Diffusion Models for Missing Data Imputation - International Conference on Learning Representations (ICLR), 2025.
- Zeqi Ye, Minshuo Chen. Diffusion Transformers for Imputation: Statistical Efficiency and Uncertainty Quantification - Advances in Neural Information Processing Systems (NeurIPS), 2025.
- Md. Atik Ahamed, Qiang Ye, Qiang Cheng. RefiDiff: Progressive Refinement Diffusion for Efficient Missing Data Imputation - Proceedings of the AAAI Conference on Artificial Intelligence (AAAI), 2026, 40(24), 19551–19559.
- Tao Tong, Xiaofeng Zhu, Jiangzhang Gan. Meta-GAIN for Missing Data Imputation - Proceedings of the AAAI Conference on Artificial Intelligence (AAAI), 2026, 40(31), 25975–25982.

3.2.2 噪声数据

- 噪声：一个测量变量中的随机错误或偏差。
- 引起不正确属性值的原因：
  - 数据收集工具的问题
  - 数据输入错误
  - 数据传输错误
  - 技术限制

3.2.2 噪声数据

如何处理噪声数据?

- 分箱（Binning）
  - 1. 按递增顺序对数据进行排列
  - 2. 分到（等频的）箱子中
  - 3. 使用光滑技术
    - 用箱均值光滑,
    - 用箱中位数光滑,
    - 用箱边界光滑, 等等

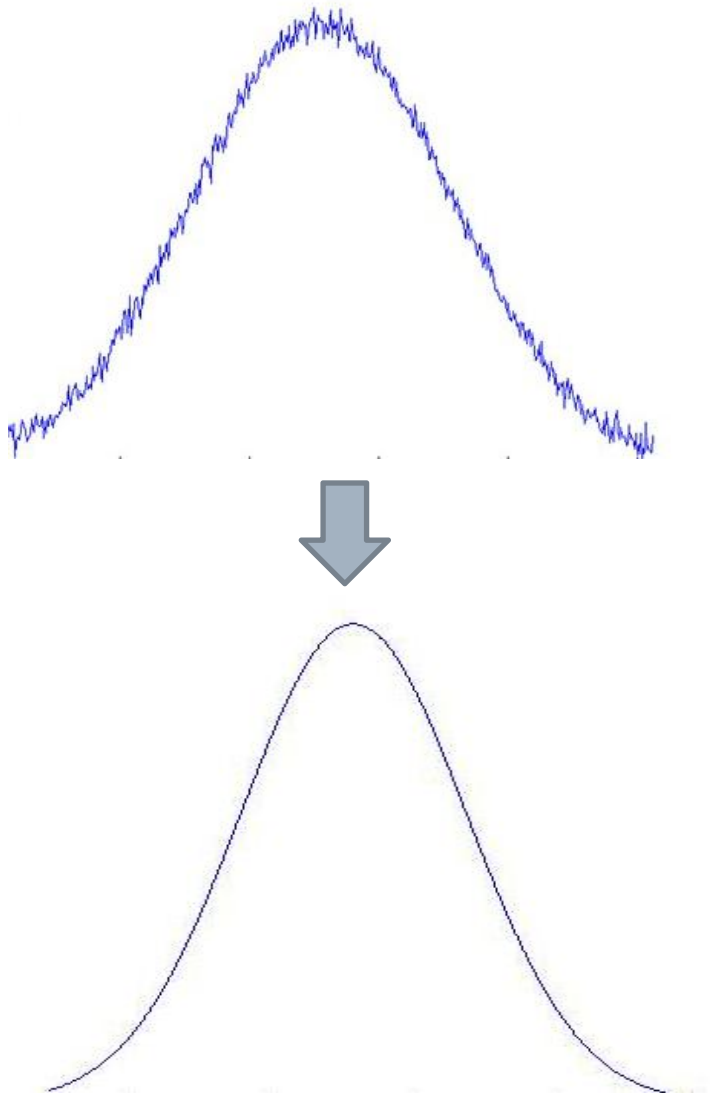

3.2.2 噪声数据

如何处理噪声数据?

- Example: 4, 8, 15, 21, 21, 24, 25, 28, 34
  - 首先排序，并划分到大小为3的等频的箱中（即每个箱包含3个值）

	用箱均值光滑	用箱边界光滑
bin 1: 4, 8, 15;	9 , 9, 9	4, 4, 15
bin 2: 21, 21, 24;	22, 22,22	21,21,24
bin 3: 25, 28, 34	29, 29,29	25, 25,34

3.2.2 噪声数据

离群点是具有与数据集中的大多数其他数据对象有很大不同的特征的数据对象。

离群点不等于异常点。

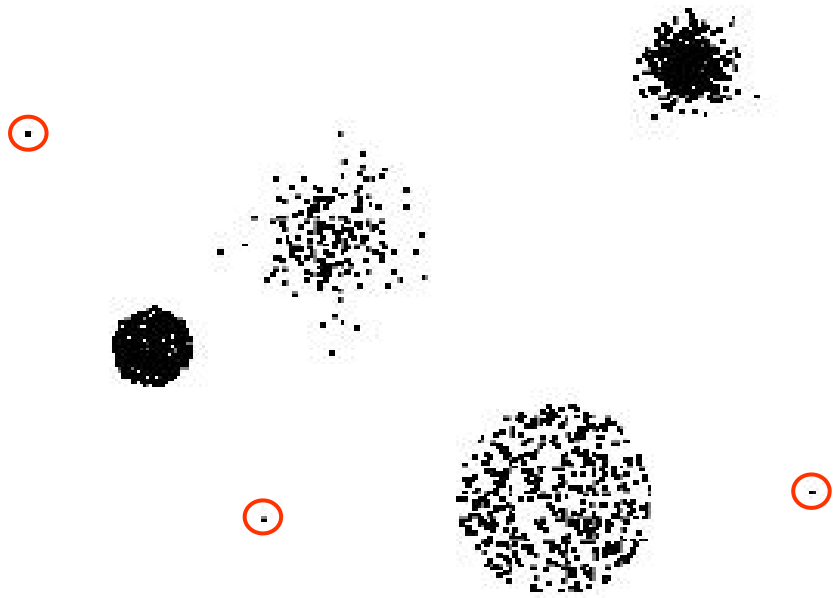

3.2.2 噪声数据

如何处理离群点?

□ 聚类

将联系松散的数据当作离群点，监测并且去除离群点。聚类集合之外的点即为离群点。

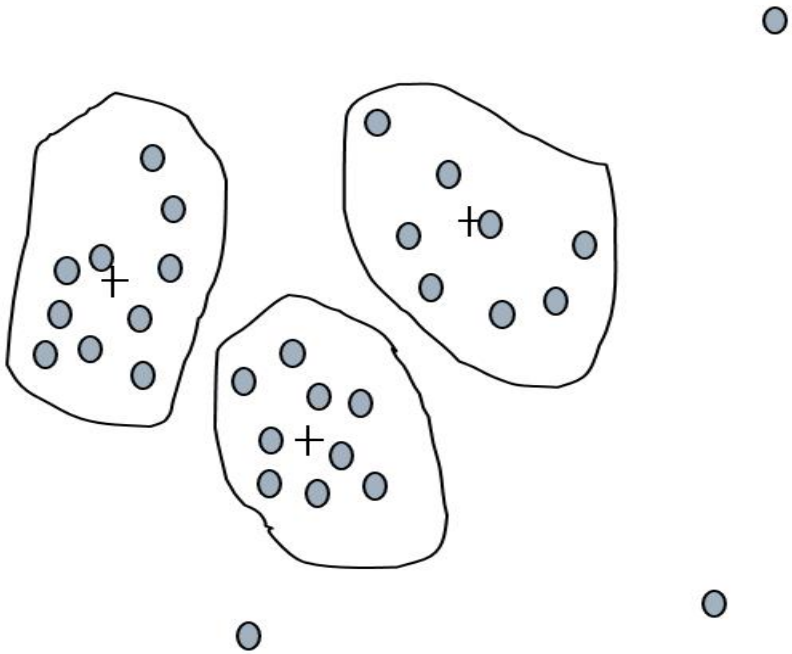

3.2.2 噪声数据

如何处理离群点？

□ 回归

通过让数据适应回归函数来平滑数据（线性回归或非线性回归）。

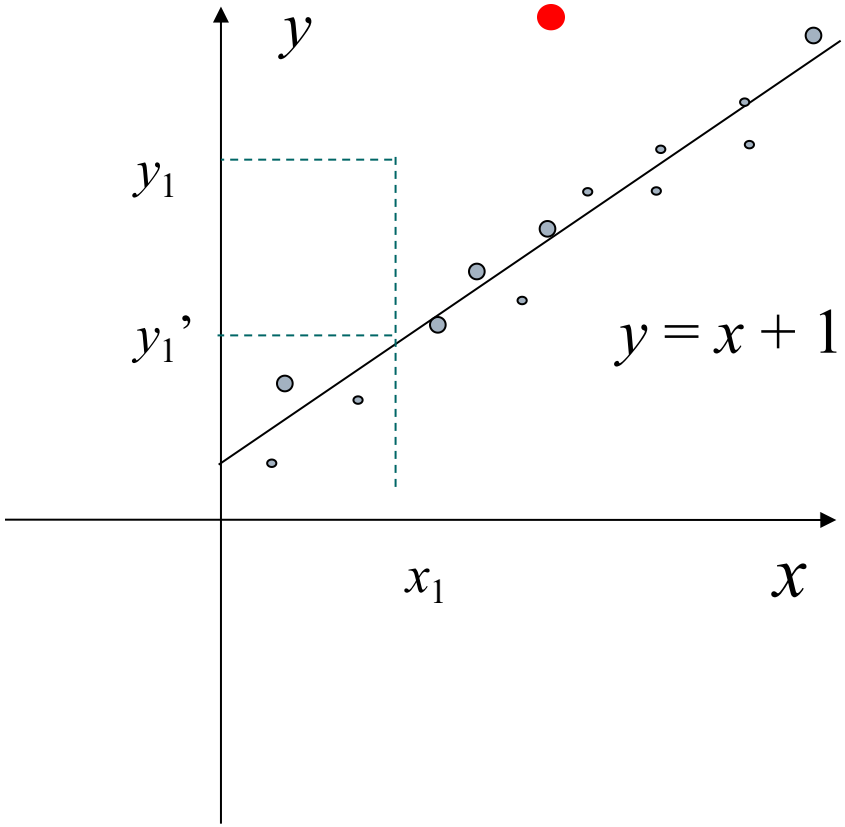

3.2.2 噪声数据

如何处理离群点?

- 盒图

  通过盒图画出离群点。

- 计算机和人工检查结合

  计算机检测可疑数据，然后对它们进行人工判断。

3.2.2 噪声数据

例子： 光滑& 确定离群点

- 年龄:
  13,15,16,16,19,20,20,21,22,22,25,25,25,25,30,33,33,35,
  35,35,35,36,40,45,46,52,70
- 使用大小为3的用箱均值光滑
- 如何确定数据中的离群点？
- 箱线图，四分位范围，1.5*IQR

3.2.2 噪声数据

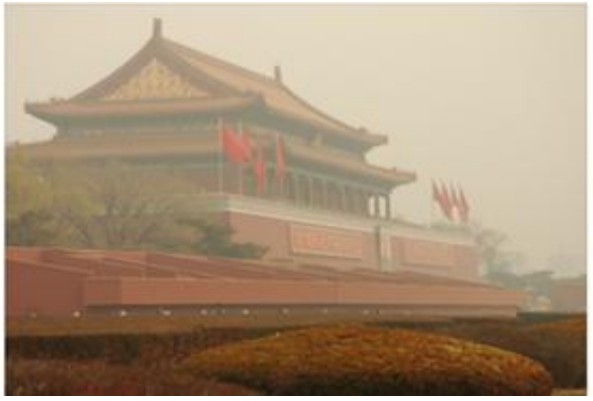
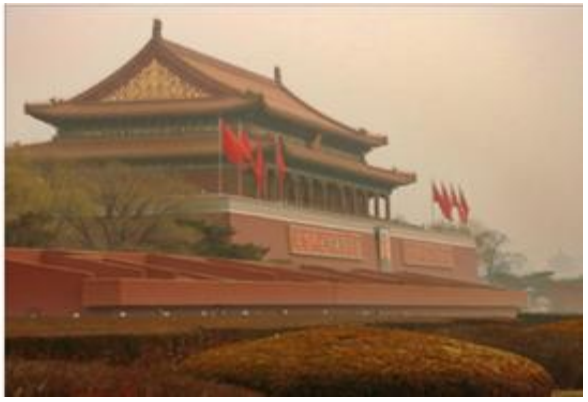

3.2.2 噪声数据

如何处理数据噪声？

图像去噪算法 DnCNN

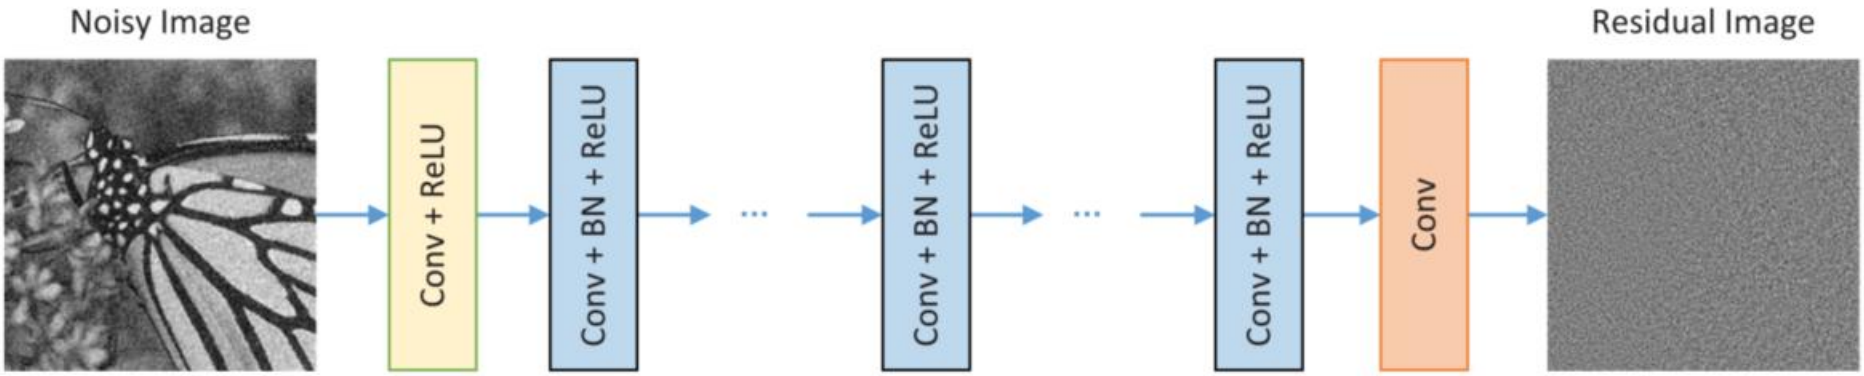

模型的主要任务是，根据噪声图像 y，估计干净图像 x，但是，模型的直接输出并不是 x，而是噪声图像 v，最终干净图的获取过程用公式表达就是 $\mathrm{x}=\mathrm{y}-\mathcal{R}(\mathrm{y})$，这里 $\mathcal{R}$ 就相当于模型，且 $\mathcal{R}(\mathrm{y}) \approx \mathrm{v}$。作者把这种方式称作残差学习（Residual Learning），并通过实验证实了残差学习对于提高训练稳定性和去噪效果的好处。

模型训练时，输出的误差图和真实误差图之间，采用SME损失函数进行约束。对于训练数据 $\{(\mathrm{x}_i, \mathrm{y}_i)\}_{i=1}^{N}$，损失函数定义为

$$l(\theta)=\frac{1}{2N}\|\mathcal{R}(\mathrm{y}_i;\theta)-(\mathrm{y}_i-\mathrm{x}_i)\|$$

这里 θ 实际上就是DnCNN的网络参数，训练集的信息就保存在这里面。模型使用SDG或Adam方式进行模型参数更新。

3.2.2 噪声数据

如何处理数据噪声？

- Zero-shot learning enables instant denoising and super-resolution in optical fluorescence microscopy, Nature Communications, 2024
- Robust self-supervised denoising of voltage imaging data using CellMincer, npj | imaging, 2024
- Statistically unbiased prediction enables accurate denoising of voltage imaging data, nature methods, 2023

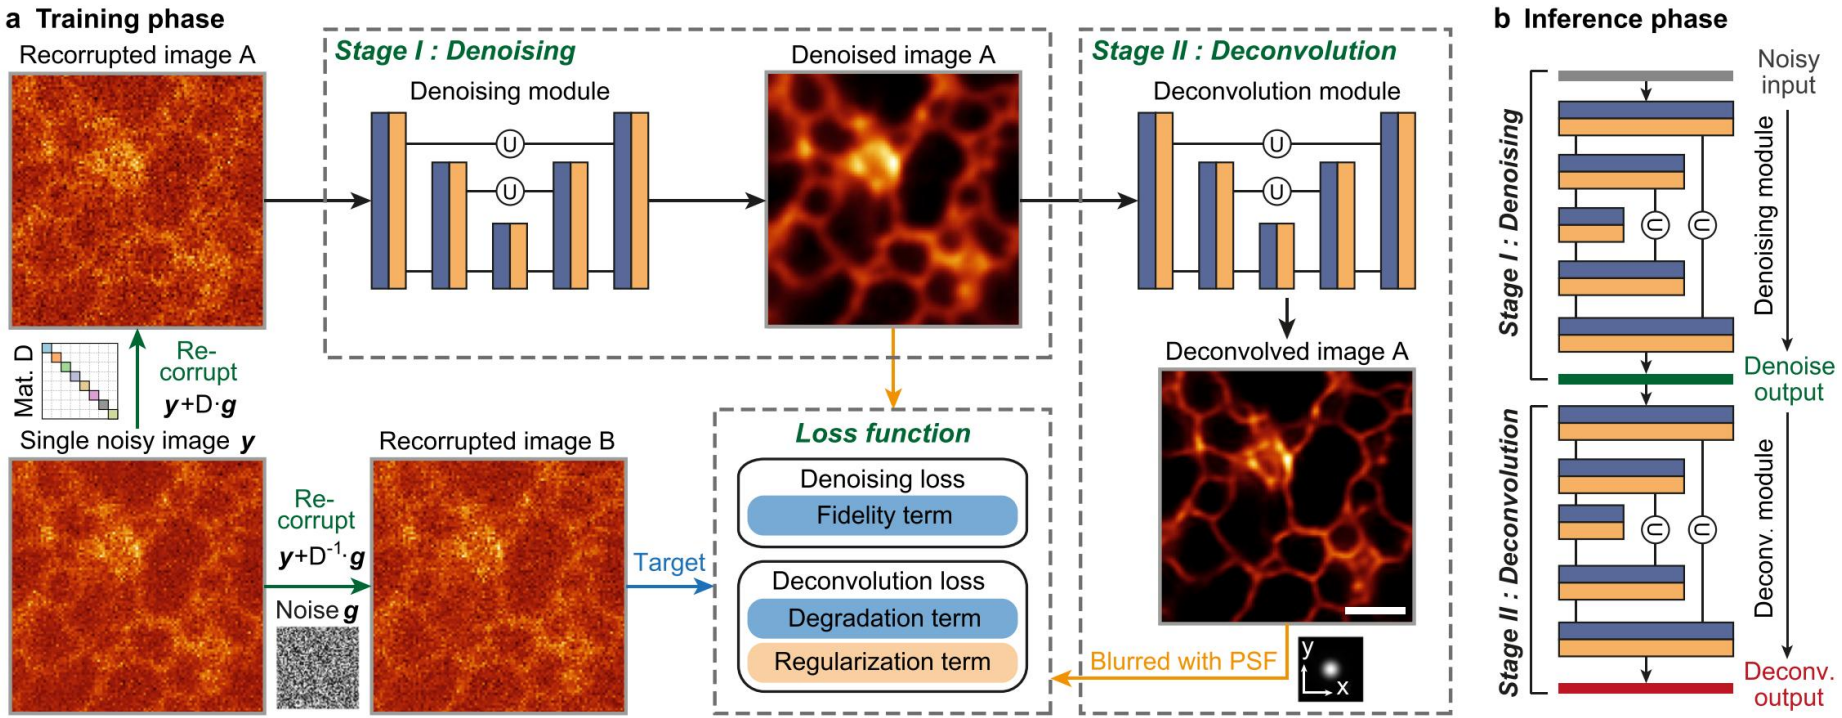

3.2.2 噪声数据

如何处理数据噪声？

- Image Classification with Deep Learning in the Presence of Noisy Labels: A Survey
- A Survey on Deep Learning with Noisy Labels: How to train your model when you cannot trust on the annotations?
- Learning From Noisy Data: An Unsupervised Random Denoising Method for Seismic Data Using Model-Based Deep Learning,2022
- Gaoxia Jiang, Jia Zhang, Xuefei Bai, Wenjian Wang, Deyu Meng. Which Is More Effective in Label Noise Cleaning, Correction or Filtering? - AAAI, 2024.
- Xichen Ye, Yifan Wu, Weizhong Zhang, Xiaoqiang Li, Yifan Chen, Cheng Jin. Optimized Gradient Clipping for Noisy Label Learning - AAAI, 2025.
- Jiye Liang, Yixiao Li, Junbiao Cui. Label Noise Correction via Fuzzy Learning Machine - AAAI, 2025.
- Marzi Heidari, Hanping Zhang, Yuhong Guo. Learning to Clean: Reinforcement Learning for Noisy Label Correction - NeurIPS, 2025.
- Gaoxia Jiang, Fan Lei, Wenjian Wang. A Multi-Model Dynamic Filtering of Label Noise for Regression - Pattern Recognition, Volume 169, Article 111887, 2026.

3 数据预处理

- 3.1 数据预处理: 概述
- 3.2 数据清洗
- 3.3 数据集成
- 3.4 数据归约
- 3.5 数据变换
- 3.6 小结

3.3 数据集成

数据集成:

将多个数据源中的数据合并，存放在一个数据存储中。如放在数据仓库中。

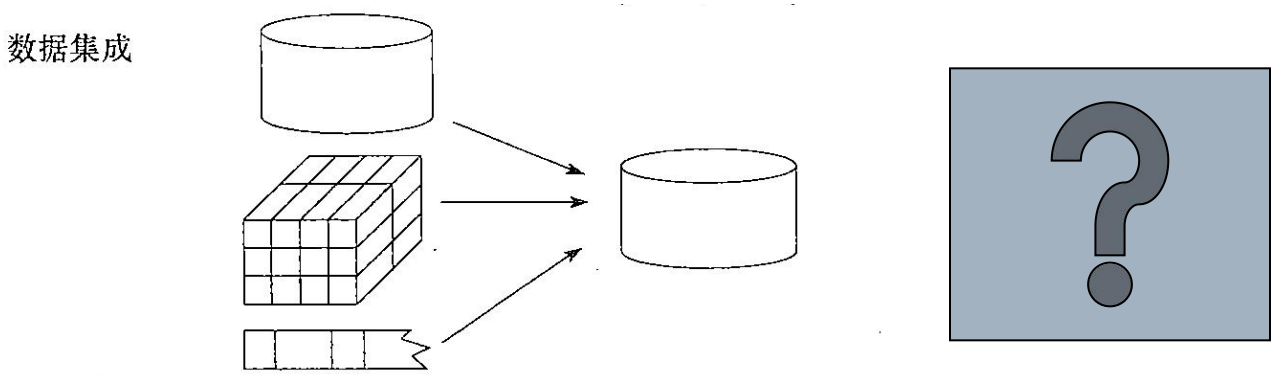

数据集成有助于减少结果数据集的冗余和不一致，提高挖掘过程的准确性和速度。

3.3 数据集成

数据集成存在的问题

- 实体识别问题
- 属性冗余和相关性
- 样本重复
- 数据值冲突的检测与处理

3.3 数据集成

- 从多个数据源识别现实世界的实体, 如：Bill Clinton = William Clinton
- 模式集成和对象匹配可能需要技巧，例如如何让计算机识别customer_id和另外一个数据库的cust_number是同一属性？
- 利用元数据，每个属性的元数据包括名字、含义、数据类型和属性的值的允许范围，以及处理空值的规则。这些元数据可以用来帮助避免模式集成的错误，还有助于变化数据。

3.3 数据集成

Customer (source 1)

CID	*Name*	*Street*	*City*	*Sex*
11	Kristen Smith	2 Hurley Pl	South Fork, MN 48503	0
24	Christian Smith	Hurley St 2	S Fork MN	1

Client (source 2)

Cno	*LastName*	*FirstName*	*Gender*	*Address*	*Phone/Fax*
24	Smith	Christoph	M	23 Harley St, Chicago IL, 60633-2394	333-222-6542 / 333-222-6599
493	Smith	Kris L.	F	2 Hurley Place, South Fork MN, 48503-5998	444-555-6666

Customers (integrated target with cleaned data)

No	*LName*	*FName*	*Gender*	*Street*	*City*	*State*	*ZIP*	*Phone*	*Fax*	*CID*	*Cno*
1	Smith	Kristen L.	F	2 Hurley Place	South Fork	MN	48503-5998	444-555-6666		11	493
2	Smith	Christian	M	2 Hurley Place	South Fork	MN	48503-5998			24	
3	Smith	Christoph	M	23 Harley Street	Chicago	IL	60633-2394	333-222-6542	333-222-6599		24

3.3 数据集成

First	Last	Address	ID	Key
Sal	Stolfo	123 First Street	45678987	STLSAL123FRST456
Sal	Stolfo	123 First Street	45678986	STLSAL123FRST456
Sal	Stolpho	123 First Street	45688987	STLSAL123FRST456
Sal	Stiles	123 Forest Street	45654321	STLSAL123FRST456

3.3 数据集成

数据集成还包含数据值冲突的检测和解析。

- 对于现实世界的同一实体，来自不同数据源的属性值可能不同。
  - 价格的单位：元、千元
  - 表示、尺度或编码不同。如：metric vs. British units
  - 体重属性在一个系统中可能以公制单位存放而在另一个中以英制单位存放。
  - 学校之间交换信息的时候，每个学校有自己的课程设置和等级模式。一个大学可能的等级从A+到F，另一个可能是等级从1到10。很难制定两所大学精确的课程——等级转换规则，交换信息很困难。

3.3 数据集成

- Maroua Masmoudi, Sana Ben Abdallah Ben Lamine, Mohamed Hedi Karray, Bernard Archimede, Hajer Baazaoui Zghal. Semantic Data Integration and Querying: A Survey and Challenges - ACM Computing Surveys, Volume 56, Issue 8, Article 209, 2024.
- Xuanqing Liu, Runhui Wang, Yang Song, Luyang Kong. GRAM: Generative Retrieval Augmented Matching of Data Schemas in the Context of Data Security - KDD, 2024.
- Nabeel Seedat, Mihaela Van Der Schaar. Bootstrapping Self-Improvement of Language Model Programs for Zero-Shot Schema Matching - ICML, 2025.
- Haoteng Yin, Jinha Kim, Prashant Mathur, Krishanu Sarker, Vidit Bansal. How to Talk to Language Models: Serialization Strategies for Structured Entity Matching - Findings of NAACL, 2025.
- Lin-yao Yang, Hongyang Chen, Xiao Wang, Jing Yang, Fei-Yue Wang, Han Liu. Integrating Knowledge from Knowledge Graphs and Large Language Models for Explainable Entity Alignment - Information Fusion, 2026.
- Shivam Chourasia, Hitesh Kapoor, Nilesh Patil. Structure-Guided Entity Resolution: Fine-Tuning LLMs for Robust Name Matching in Complex Linguistic Contexts - ACL, 2026.

3 数据预处理

- 3.1 数据预处理: 概述
- 3.2 数据清洗
- 3.3 数据集成
- 3.4 数据归约
- 3.5 数据变换
- 3.6 小结

3.4 数据归约

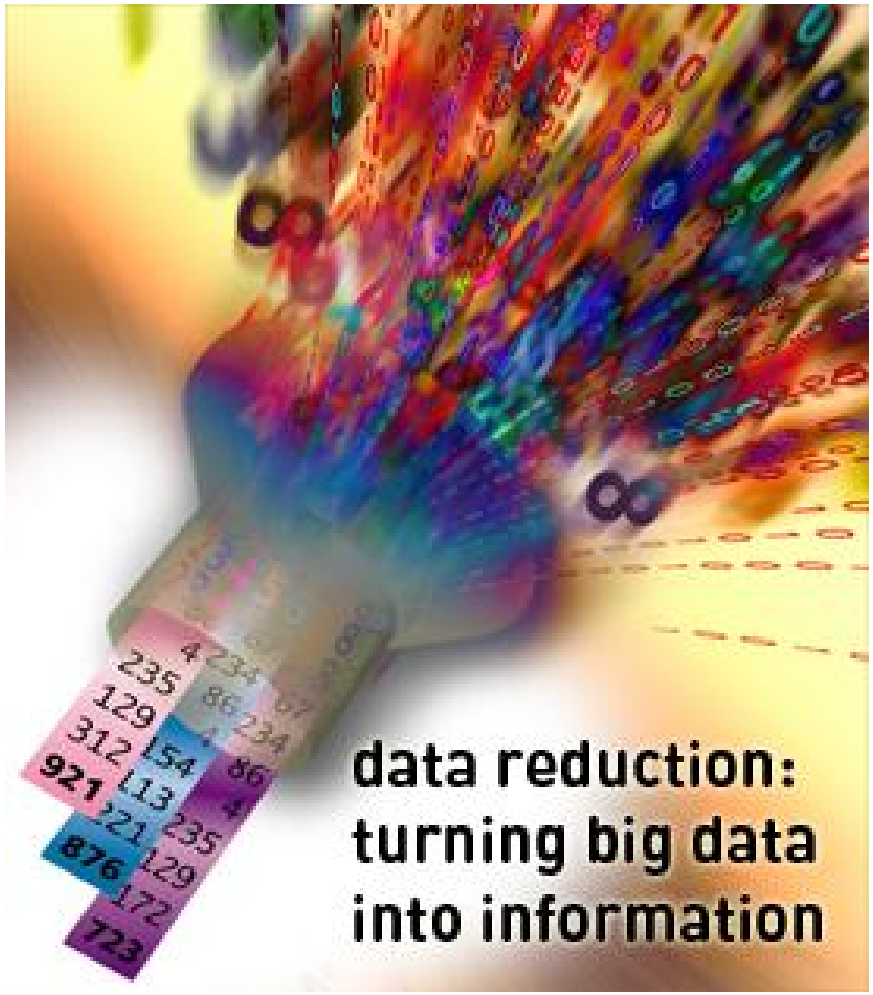

3.4 数据归约

学生膳食结构和缺钙调查表

学生	鸡肉	猪肉	牛肉	羊肉	鱼肉	鸡蛋	青菜	番茄	牛奶	健康情况
1	0	1	1	0	1	0	1	0	1	不缺钙
2	0	0	0	0	1	1	1	1	1	不缺钙
3	1	1	1	1	1	0	1	0	0	缺钙
4	1	1	0	0	1	1	0	0	1	不缺钙
5	1	0	0	1	1	1	0	0	0	缺钙
6	1	1	1	0	0	1	0	1	0	缺钙
7	0	1	0	0	0	1	1	1	1	不缺钙
8	0	1	0	0	1	1	1	1	0	缺钙
9	0	1	0	0	0	1	1	1	1	不缺钙
10	1	0	1	1	1	1	0	1	0	缺钙

3.4 数据归约

决策树

采用不同的属性策略将会生成不同的决策树

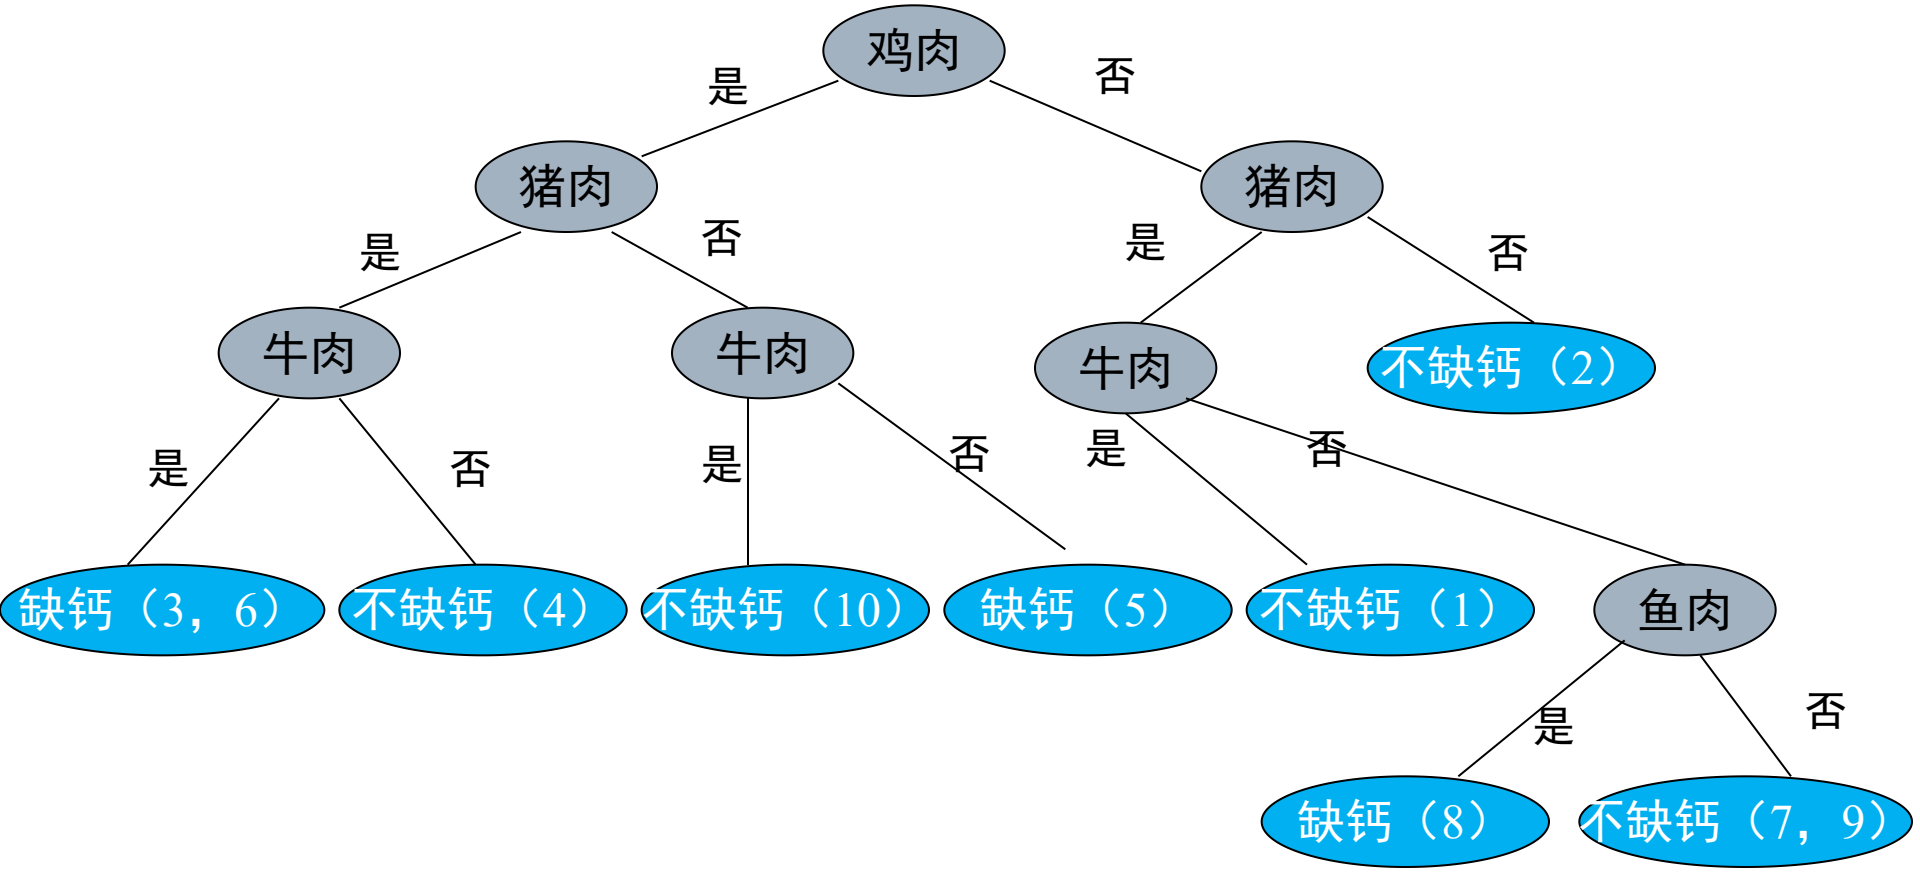

3.4 数据归约

决策树

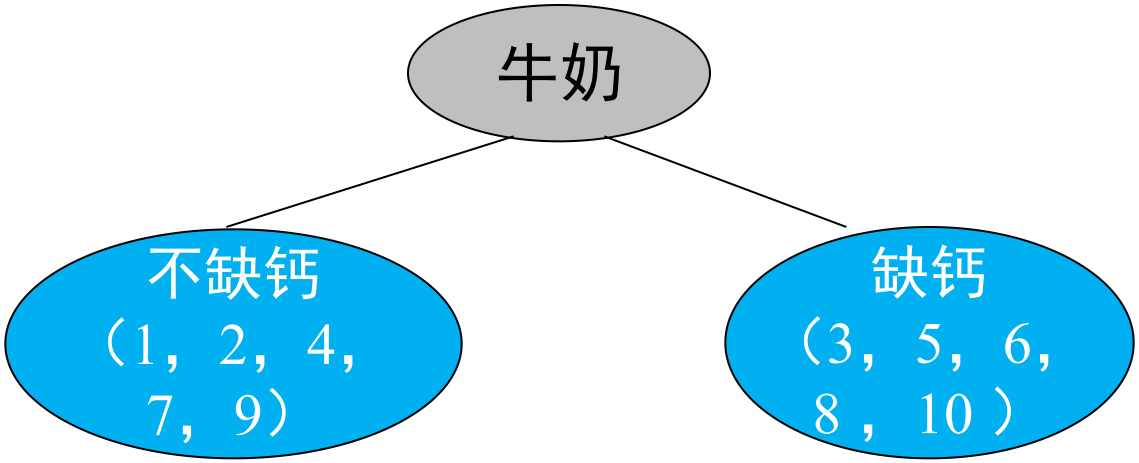

3.4 数据归约

数据归约：用来获得数据集的归约表示。
1) 属性个数更小
2) 对象数量更小
3) 但仍然接近于保持原始数据的完整性

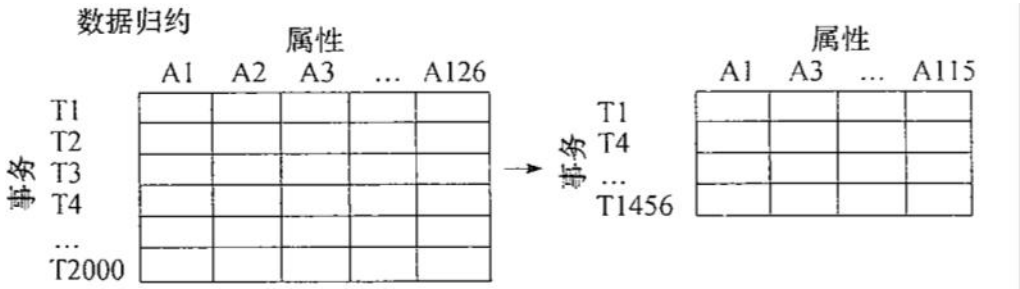

为什么要数据归约呢？维数灾难
存储量
计算量
准确率

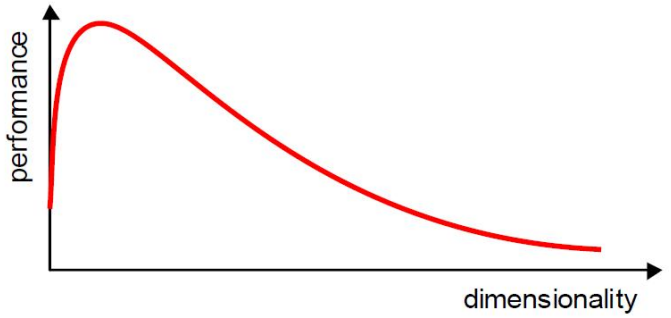

3.4 数据归约

- 3.4.1 数据归约策略的概述

- 3.4.2 属性子集选择　　属性选择
- 3.4.3 主成分分析　　属性重构
- 3.4.4 其他降维方法

属性归约

- 3.4.5 回归模型：参数化数据归约
- 3.4.6 直方图
- 3.4.7 聚类　　非参数化数据归约
- 3.4.8 抽样

数量归约

3.4.1 数据归约策略

属性归约

- 属性子集选择方法：删除不相干的属性(或维)
  - 过滤式选择
  - Wrapper选择
  - 嵌入式选择
- 属性重构方法：对属性进行重构
  - 主成分分析Principal Component Analysis (PCA)
  - 非负矩阵分解Nonnegative Matrix Factorization(NMF)
  - 线性判别分析Linear Discriminant Analysis (LDA)
  - 隐狄利克雷分配 Latent Dirichlet Allocation(LDA)
  - 独立成分分析Independent Component Analysis (ICA)
  - Isomap、Locally Linear Embedding (LLE)、t-SNE

3.4.1 数据归约策略

数量归约

通过删除冗余的对象，减少数据量

- 回归模型
- 直方图
- 聚类
- 抽样

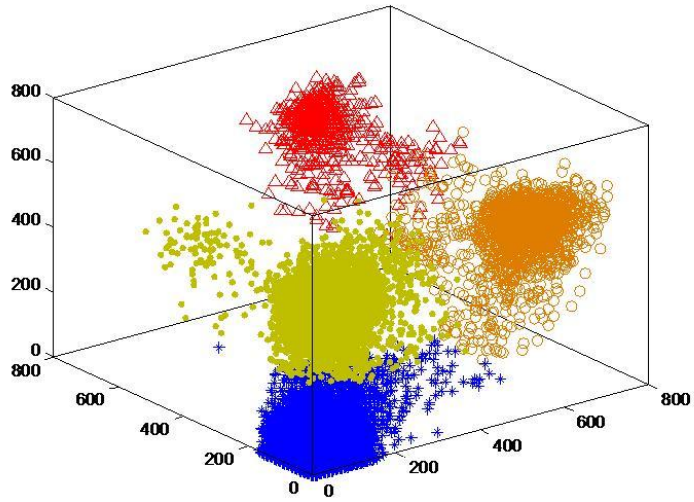

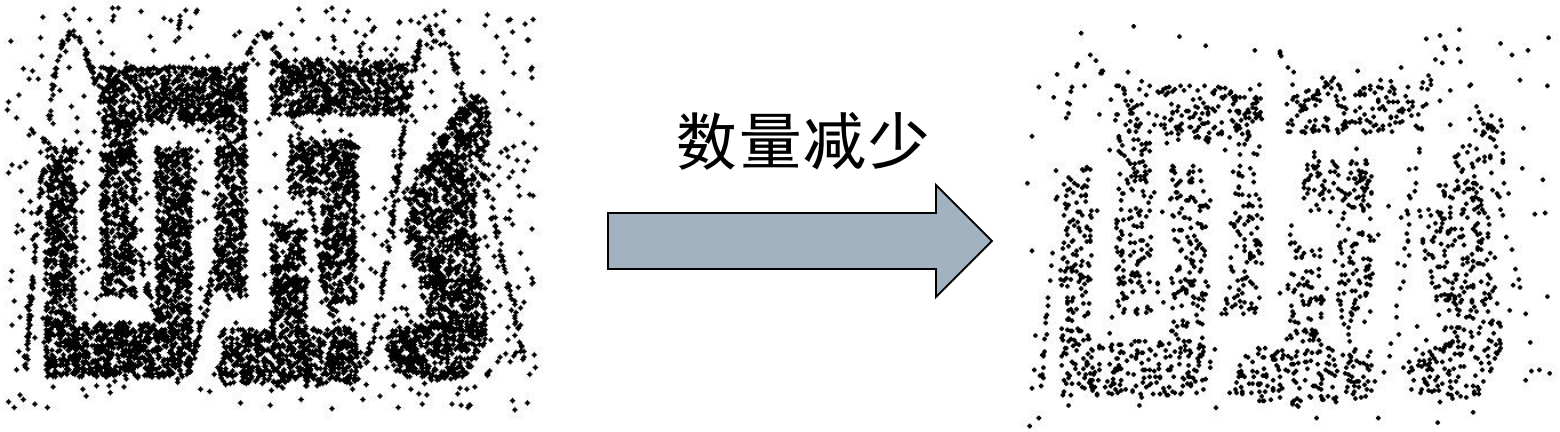

3.4 数据归约

- 3.4.1 数据归约策略的概述

- 3.4.2 属性子集选择
- 3.4.3 主成分分析
- 3.4.4 其他降维方法

属性选择

属性重构

属性归约

- 3.4.5 回归模型：参数化数据归约
- 3.4.6 直方图
- 3.4.7 聚类
- 3.4.8 抽样

非参数化数据归约

数量归约

3.4.2 属性子集选择

- 目标：找出最小属性集，使得数据类别的分布尽可能接近使用所有属性的原始分布。
- 好处：减少属性的数目，使得模式更易于理解。

学生	高数上	高数下	数据挖掘	综合成绩	羊肉	牛肉	鸡蛋	青菜	牛奶	健康情况
1	90	92	80	85	1	1	0	1	1	不缺钙
2	60	65	90	75	1	1	1	1	1	不缺钙
3	95	91	92	93	1	1	0	1	0	缺钙

3.4.2 属性子集选择

- 属性子集选择方法
  - Wrapper选择
  - 过滤式选择
    - 协方差、相关系数、卡方检验、 Relief
  - 嵌入式选择
    - 信息增益、互信息
    - 正则化

3.4.2.1 wapper选择

- 包裹式特征选择直接把最终将要使用的模型的性能作为特征子集的评价标准。
- 包裹式特征选择的目的就是为给定的模型选择最有利于其性能的特征子集。
- 从最终模型的性能来看，包裹式特征选择比过滤式特征选择更好，但需要多次训练模型，因此计算开销较大。

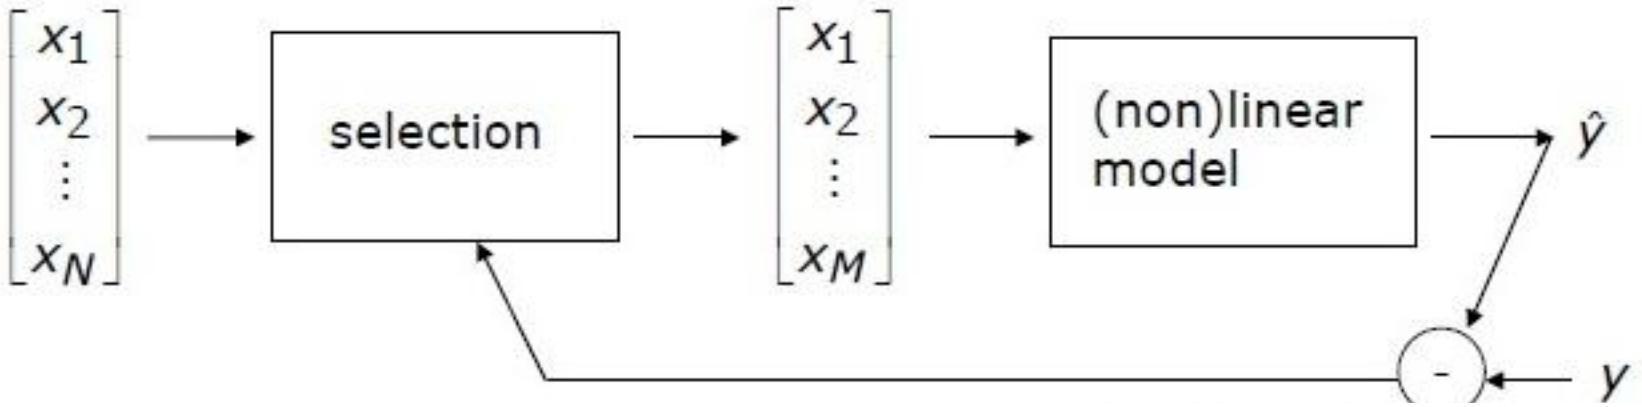

3.4.2.1 wapper选择

- 拉斯维加斯包裹法（Las Vegas Wrapper，LVW）

  从原始特征中随机选择特征子集，经学习器训练后，利用评价函数观察学习器性能，若性能优于之前的，则保留该特征子集，否则重复之前的步骤直至达到停止标准，循环停止，此时的特征子集即为所求。

- 递归特征消除法（Recursive Feature Elimination，RFE）

  利用一个模型训练全部特征，经过一轮训练后将权值系数未达到阈值的特征从特征集中删除，由此生成一个新的特征集，继续对新特征集进行训练直至达到停止标准，此时的特征集就是经过递归特征消除法筛选的特征子集。特征子集被删除的次序即为特征按优先级排序次序。

3.4.2.2 过滤式选择

- 过滤式方法先对数据集进行特征选择，然后再训练模型，特征选择过程与后续模型训练无关
- Filter 方法常用的特征子集评价标准包括：协方差、相关系数、Relief、卡方检验等

M<N

3.4.2.2 过滤式选择——协方差

两个数值型属性A和B，n个样本$\{(a_1,b_1),\ldots(a_n,b_n)\}$。
属性A和属性B的均值，即期望值为：

$$E(A)=\bar{A}=\frac{\sum_{i=1}^{n}a_i}{n} \qquad E(B)=\bar{B}=\frac{\sum_{i=1}^{n}b_i}{n}.$$

则属性A和B的**协方差**为：

$$Cov(A,B)=E((A-\bar{A})(B-\bar{B}))=\frac{\sum_{i=1}^{n}(a_i-\bar{A})(b_i-\bar{B})}{n}.$$

可以看到，

$$Cov(A,B)=E(A\cdot B)-\bar{A}\bar{B}.$$

3.4.2.2 过滤式选择——协方差

对于一起发生变化的属性A和B，如果A大于$\bar{A}$时，B也可能大于$\bar{B}$ 。因此，A和B之间的协方差为正。如果一个属性的值在均值以下时另一个倾向于在均值以上，则协方差为负。

如果A和B相互独立（没有关联），则协方差为0.但反过来并不成立。即一些随机变量对的协方差值为0，但并不独立。只有在一些额外的假设（如数据满足多元正态分布）时协方差为0表明独立性。

3.4.2.2 过滤式选择——协方差

这是一个观察到的5次AllElectronics和Hightech公司的股票价格。如果股票是被同一个公司的趋势影响，那么它们的价格是否一起涨落呢？

Stock Prices for *AllElectronics* and *HighTech*

Time point	*AllElectronics*	*HighTech*
t1	6	20
t2	5	10
t3	4	14
t4	3	5
t5	2	5

3.4.2.2 过滤式选择——协方差

- 计算均值：

$$E(AllElectronics) = \frac{6+5+4+3+2}{5} = \frac{20}{5} = \$4$$

$$E(HighTech) = \frac{20+10+14+5+5}{5} = \frac{54}{5} = \$10.80.$$

- 则协方差为：

$$Cov(A, B) = E(A \cdot B) - \bar{A}\bar{B}.$$

$$Cov(AllElectroncis, HighTech) = \frac{6\times 20+5\times 10+4\times 14+3\times 5+2\times 5}{5} - 4\times 10.80$$

$$= 50.2 - 43.2 = 7.$$

- 协方差值为正，因此，可以说两个公司的股票同时上涨。

3.4.2.2 过滤式选择——相关系数

- 相关系数 $r_{A,B} = \frac{\sum_{i=1}^{n}(a_i - \overline{A})(b_i - \overline{B})}{(n)\sigma_A \sigma_B} = \frac{\sum_{i=1}^{n}(a_i b_i) - n\overline{A}\overline{B}}{(n)\sigma_A \sigma_B}$

  其中，n是样本的个数，$\overline{A}$和 $\overline{B}$ 分别是A和B的均值，$\sigma_{A和}\sigma_B$ 分别是A和B的标准差，而$\Sigma(a_i b_i)$ 是AB叉积和（即对于每个样本，A的值乘以该样本B的值）

- 如果$r_{A,B}$ 大于0，则A和B是正相关的，这意味着A值随B值的增加而增加。该值越大，相关性越强（即每个属性蕴涵另一个的可能性越大）。
- 如果$r_{A,B}$ 等于0，则A和B不存在线性相关关系。
- 如果$r_{A,B}$ 小于0，则A和B是负相关的，一个值随另一个减少而增加。

3.4.2.2 过滤式选择——相关系数

- 在概率理论和统计学中，**相关系数**和**协方差**是评价两个属性是否一起发生变化的两种相似的测量。
- 相关系数（又称皮尔逊积矩系数）

$$r_{A,B} = \frac{Cov(A,B)}{\sigma_A \sigma_B},$$

可以反映两个变量变化时是同向还是反向，如果同向变化就为正，反向变化就为负。

相关系数是标准化后的协方差，它消除了两个变量变化幅度的影响，而只是单纯反应两个变量每单位变化时的相似程度。

3.4.2.2 过滤式选择——相关系数

	obj_1	obj_2	obj_3	obj_4	obj_5	obj_6
Attribute *A*:	11	7	14	11	43	38
Attribute *B*:	11	13	17	13	51	46
Attribute *C*:	9	11	20	9	69	76

$$r_{A,B} = \frac{\sum_{i=1}^{n}(a_i - \overline{A})(b_i - \overline{B})}{(n)\sigma_A\sigma_B} = \frac{\sum_{i=1}^{n}(a_i b_i) - n\overline{A}\,\overline{B}}{(n)\sigma_A\sigma_B}$$

1.0000	0.9928	0.9782
0.9928	1.0000	0.9867
0.9782	0.9867	1.0000

3.4.2.2 过滤式选择——相关系数

散点图可以用来可视化属性之间的关联关系。

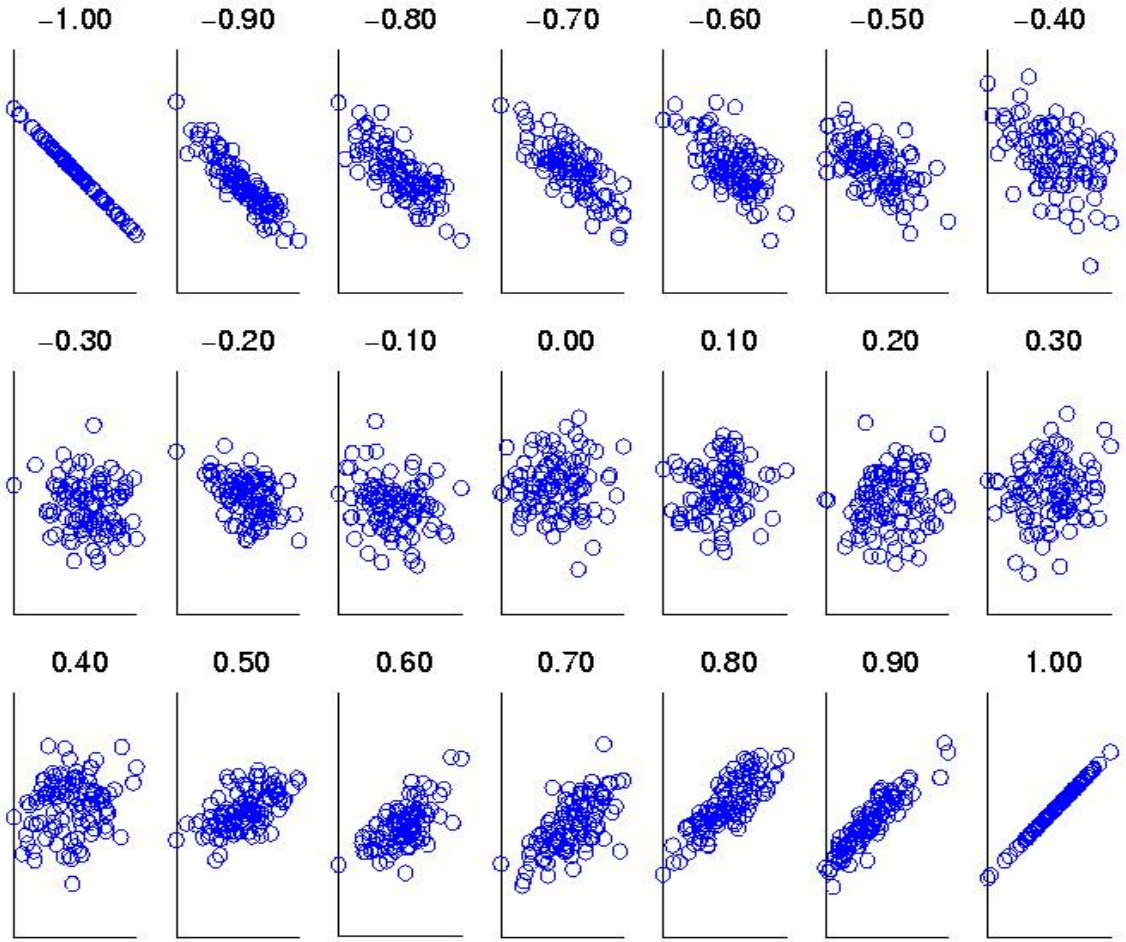

表示从-1到1的相似性的散点图

$r_{A,B}$ = 1:正相关;

$r_{A,B}$ = -1:负相关;

$r_{A,B}$ = 0:

它们之间没有线性关系

3.4.2.3 嵌入式选择

- 嵌入式特征选择是将特征选择过程与学习器训练过程融为一体，两者在同一个优化过程中完成，即在学习器训练过程中自动地进行了特征选择。
  - 决策树：信息增益、互信息
  - 正则化：L_1范数和L_2范数

3.4.2.3 嵌入式选择——信息增益

计算信息增益(举例)

子节点熵 $-\left(\frac{13}{17}\cdot\log_2\frac{13}{17}\right)-\left(\frac{4}{17}\cdot\log_2\frac{4}{17}\right)=0.787$

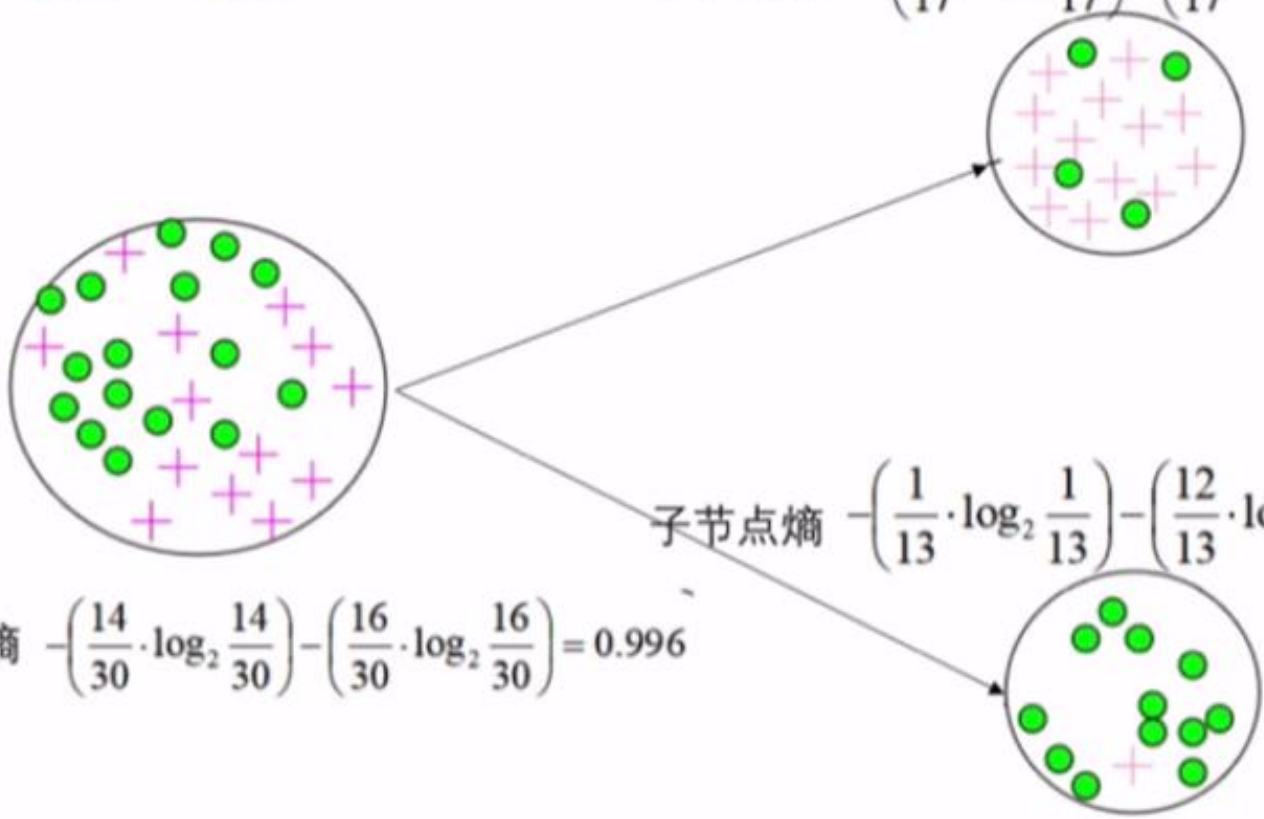

子节点熵 $-\left(\frac{1}{13}\cdot\log_2\frac{1}{13}\right)-\left(\frac{12}{13}\cdot\log_2\frac{12}{13}\right)=0.391$

父节点熵 $-\left(\frac{14}{30}\cdot\log_2\frac{14}{30}\right)-\left(\frac{16}{30}\cdot\log_2\frac{16}{30}\right)=0.996$

条件熵: 子节点加权熵 $\left(\frac{17}{30}\cdot 0.787\right)+\left(\frac{13}{30}\cdot 0.391\right)=0.615$

3.4.2.3 嵌入式选择——信息增益

- 熵：描述数据的不确定性

$$H(X) = -\sum_{i=1}^{n} p(x_i)\log_b p(x_i)$$

$$H(S) = -0.5 \cdot \log_2 0.5 - 0.5 \cdot \log_2 0.5 = 1.0$$

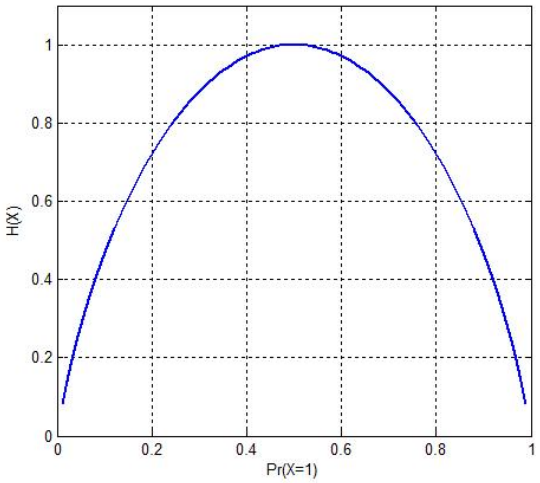

X:{a="喝牛奶";b="不喝牛奶"}

$$H(S|X=a) = -1 * \log_2 1 - 0 * \log_2 0 = 0$$

$$H(S|X=b) = -0 * \log_2 0 - 1 * \log_2 1 = 0$$

$$H(S|X) = 0.5\ H(S|X=a) + 0.5 * H(S|X=b) = 0$$

- 信息增益：引入属性X之后不确定程度减少的程度

$$\text{Gain}(S,X) = H(S) - H(S|X) = 1$$

信息增益IG：如果IG越大，说明消除不确定的程度越大

3.4.2.3 嵌入式选择——信息增益

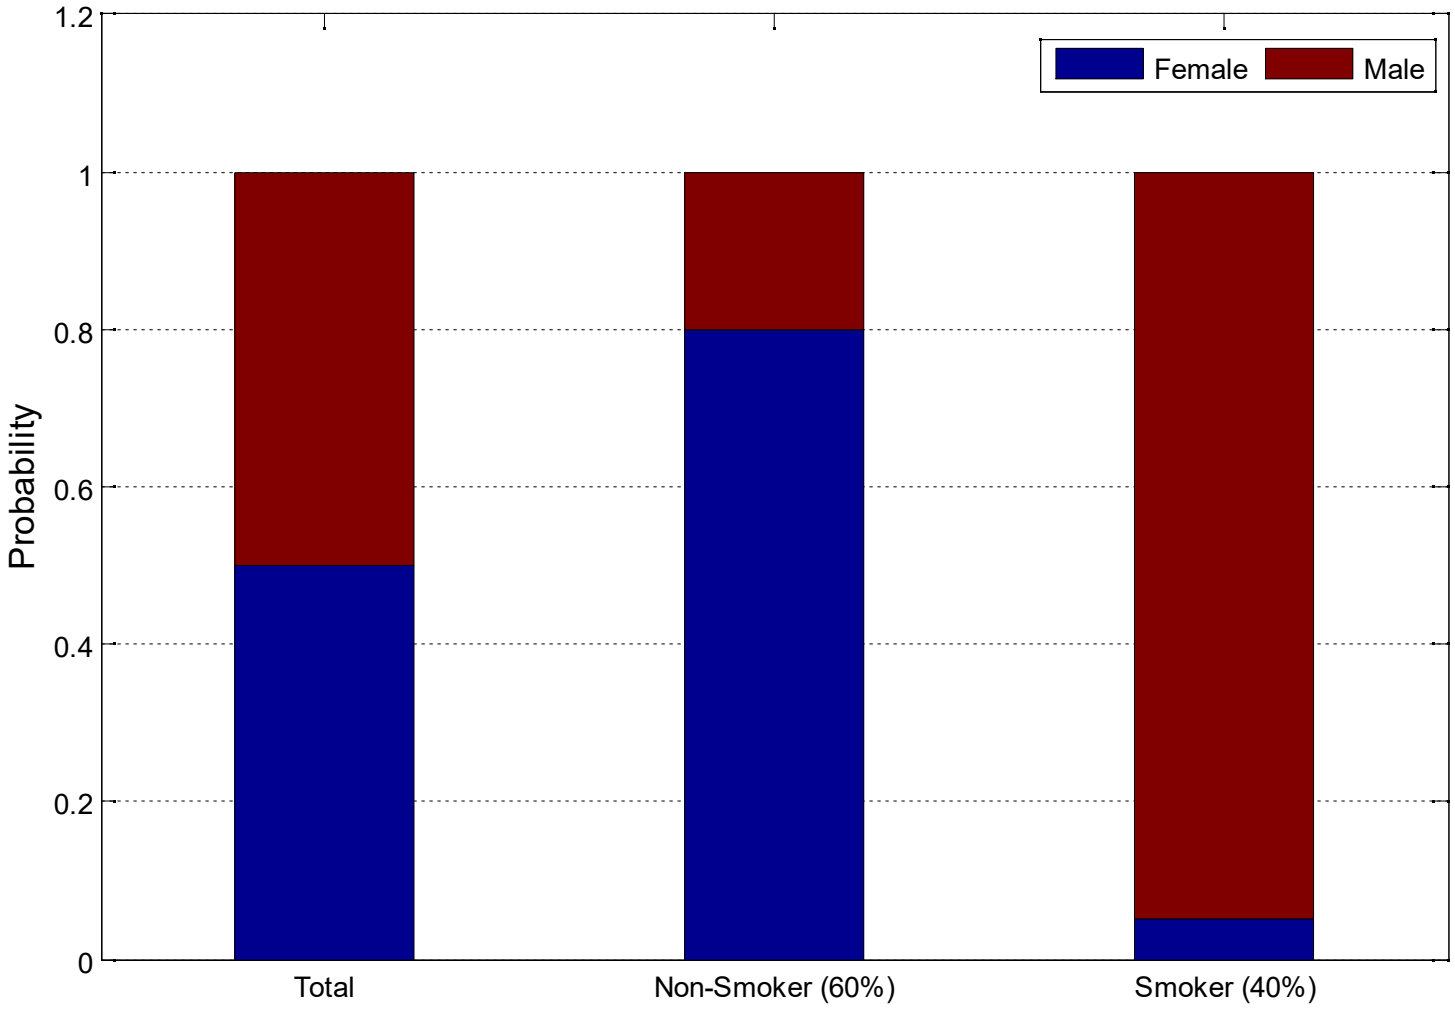

3.4.2.3 嵌入式选择——信息增益

$$H(X) = -\sum_{i=1}^{n} p(x_i)\log_b p(x_i)$$

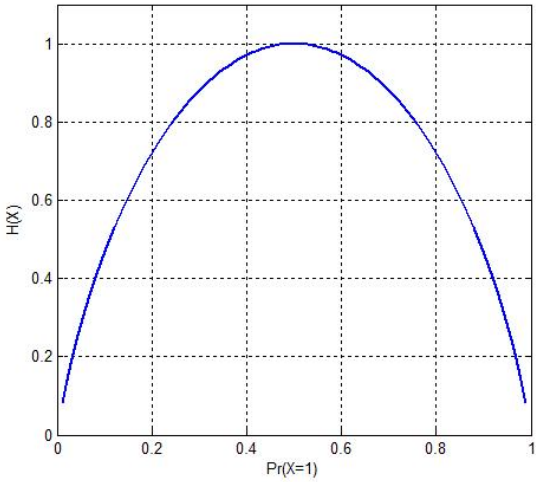

$$H(S) = -0.5 \cdot \log_2 0.5 - 0.5 \cdot \log_2 0.5 = 1.0$$

$$X: \{a = \text{"Non-Smoker"};\quad b = \text{"Smoker"}\}$$

$$H(S \mid X = a) = -0.8 \cdot \log_2 0.8 - 0.2 \cdot \log_2 0.2 = 0.7219$$

$$H(S \mid X = b) = -0.05 \cdot \log_2 0.05 - 0.95 \cdot \log_2 0.95 = 0.2864$$

$$H(S \mid X) = 0.6 \cdot H(S \mid X = a) + 0.4 \cdot H(S \mid X = b) = 0.5477$$

$$Gain(S, X) = H(S) - H(S \mid X) = 0.4523$$

3.4 数据归约

- 3.4.1 数据归约策略的概述

- 3.4.2 属性子集选择 — 属性选择
- 3.4.3 主成分分析 — 属性重构
- 3.4.4 其他降维方法

属性归约

- 3.4.5 回归模型：参数化数据归约
- 3.4.6 直方图
- 3.4.7 聚类
- 3.4.8 抽样

非参数化数据归约

数量归约

3.4.3 主成分分析：PCA

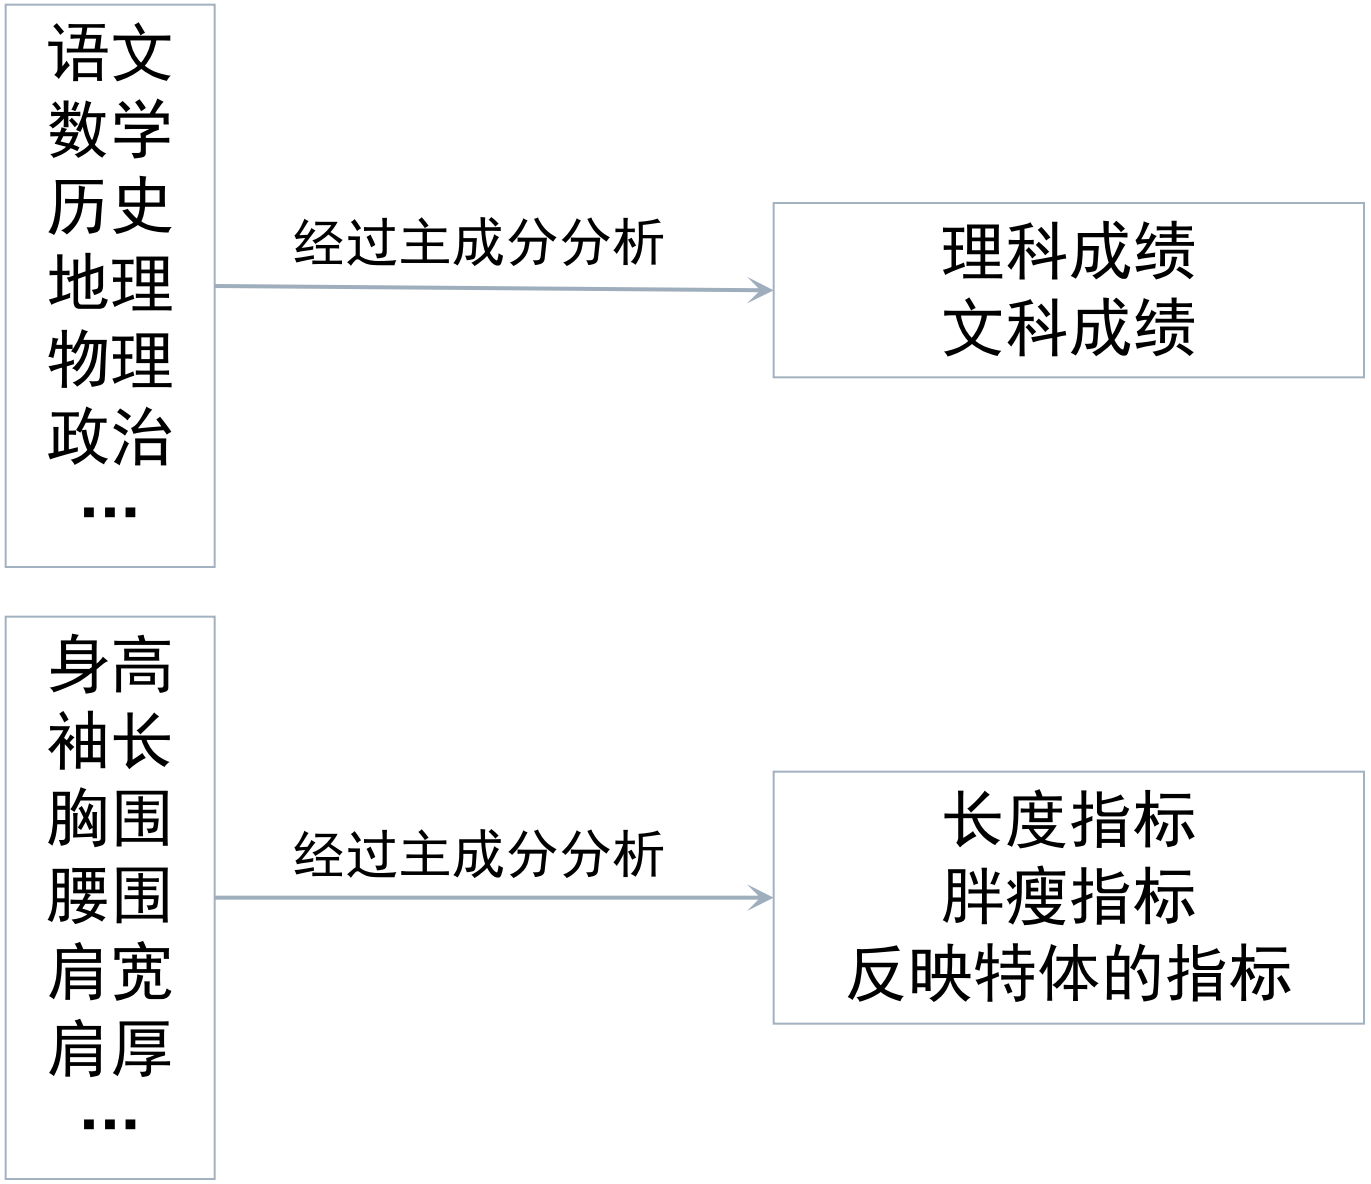

3.4.3 主成分分析：PCA

- 搜索k个最能代表数据的d维正交向量，其中$k<=d$
- 原数据投影到一个更小的空间上，导致属性归约
- 目标是创建一个替换的、较小的变量集“组合”属性

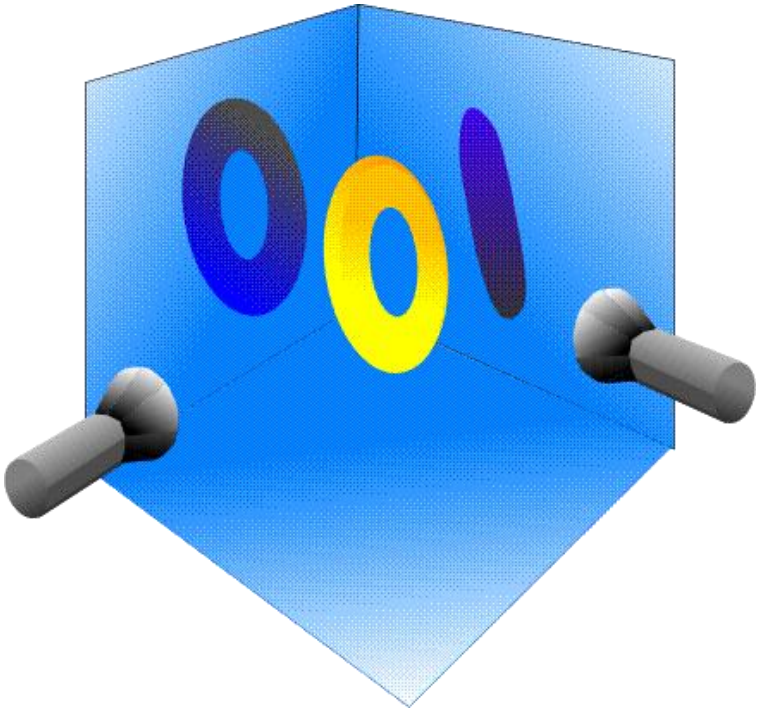

3.4.3 主成分分析：PCA

- 数据：Gaussian分布
- 方差
- 椭圆：长轴与短轴
- 选择与长轴相对应的属性

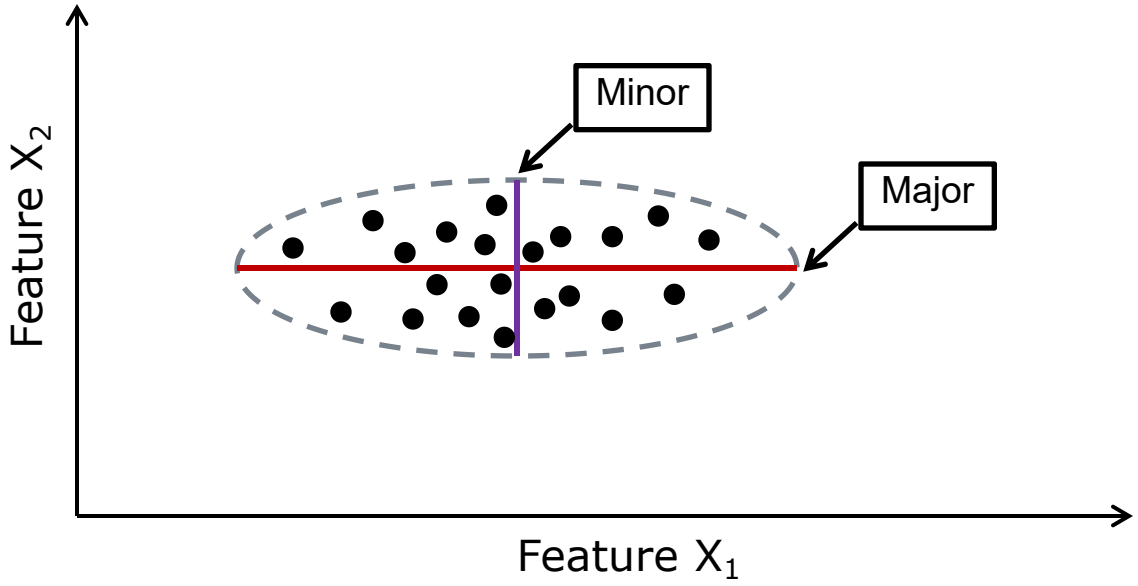

3.4.3 主成分分析：PCA

2D Example

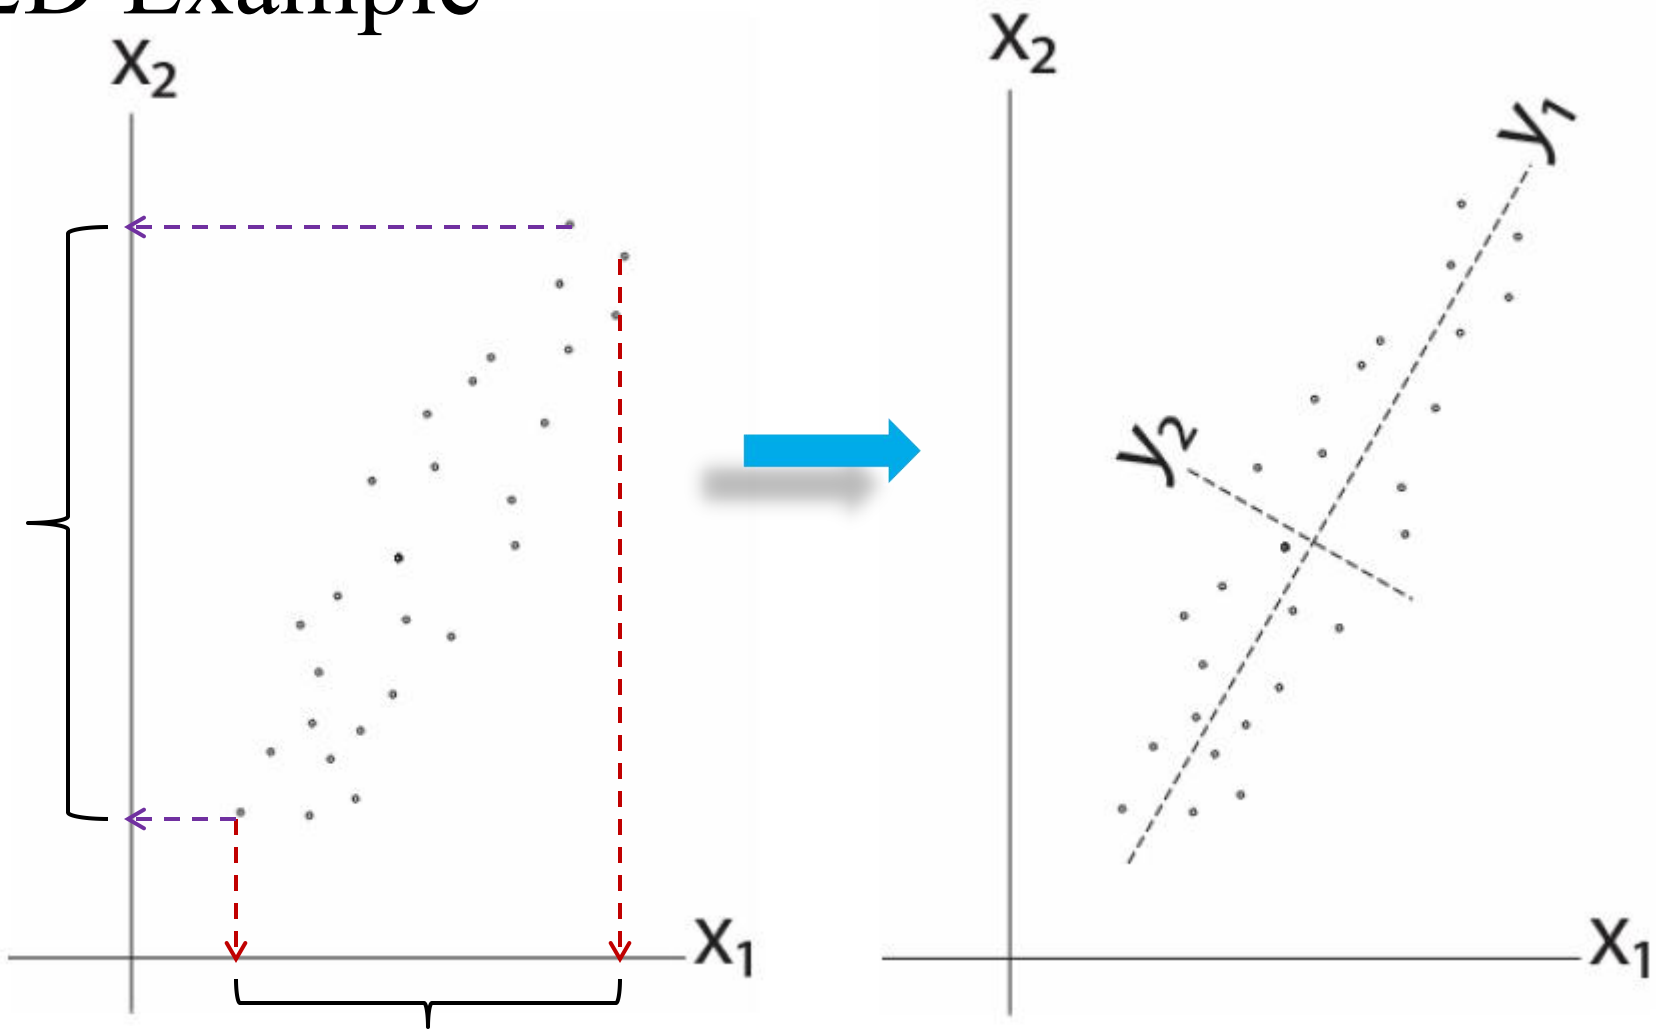

3.4.3 主成分分析：PCA

2D Example

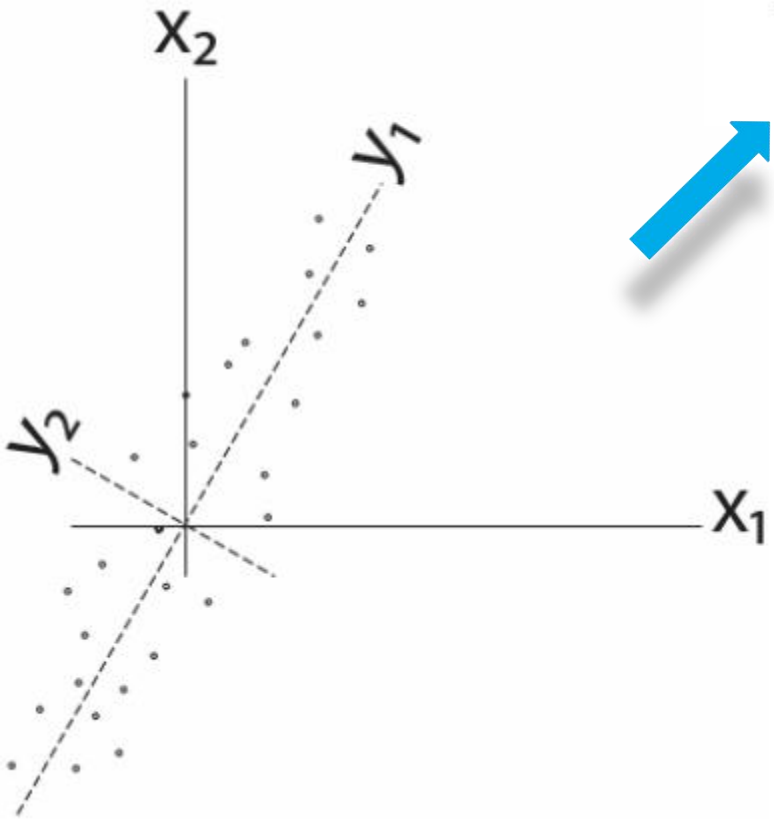

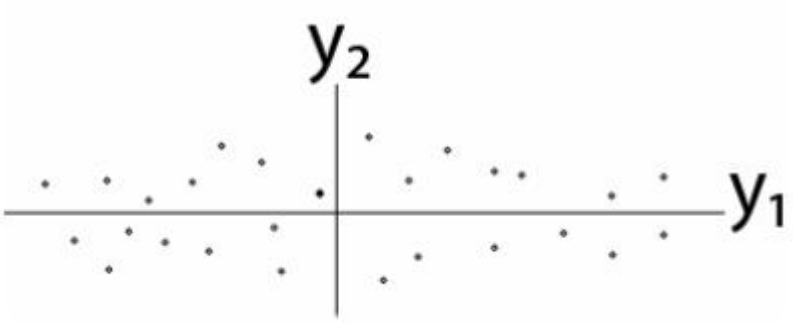

$$S(X)=\frac{1}{n-1}XX^T$$

去除相关性

$$S(Y)=\frac{1}{n-1}YY^T$$

3.4.3 主成分分析：PCA

目标: S(Y)对角线上的项是非零的，且所有非对角线元素均为零

$$Y = PX \Rightarrow S(Y) = \frac{1}{n-1} YY^T \Rightarrow YY^T = (PX)(PX)^T = PXX^TP^T.$$

$$XX^T = QDQ^T \Rightarrow (n-1)S(Y) = PXX^TP^T = PQDQ^TP^T = (PQ)D(PQ)^T \Rightarrow P = Q^T$$

特征分解

3.4 数据归约

- 3.4.1 数据归约策略的概述

属性归约

- 3.4.2 属性子集选择　　属性选择
- 3.4.3 主成分分析　　属性重构
- 3.4.4 其他降维方法

数量归约

- 3.4.5 回归模型：参数化数据归约
- 3.4.6 直方图
- 3.4.7 聚类　　非参数化数据归约
- 3.4.8 抽样

3.4.4.1 线性判别分析LDA

- 线性判别分析（Linear Discriminant Analysis，简称LDA）
  - 经典的有监督数据降维方法。
  - LDA的主要思想是将一个高维空间中的数据投影到一个较低维的空间中，且投影后要保证各个类别的类内方差小而类间均值差别大，这意味着同一类的高维数据投影到低维空间后相同类别的聚在一起，而不同类别之间相距较远。

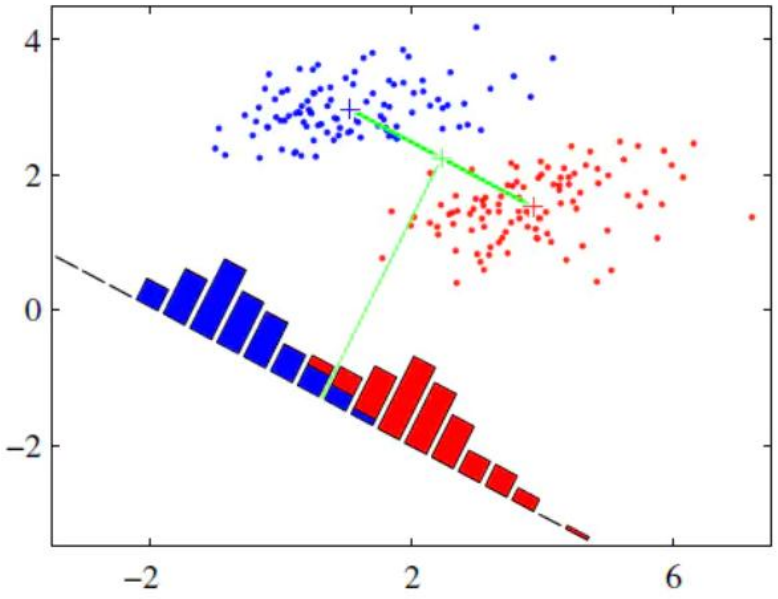

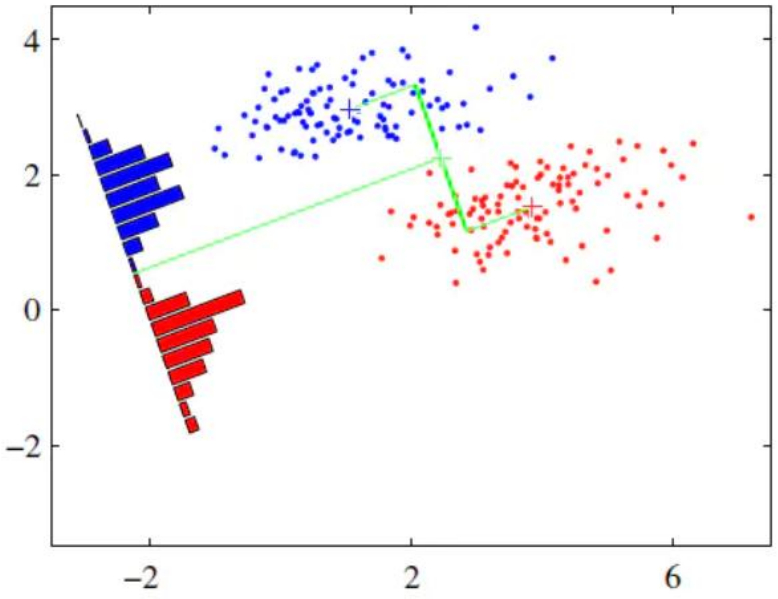

3.4.4.1 线性判别分析LDA

LDA与PCA的异同：

- 相同点：
  - 两者均可以对数据进行降维。
  - 两者在降维时均使用了矩阵特征分解的思想。
  - 两者都假设数据符合高斯分布。
- 不同点：
  - LDA是有监督的降维方法，而PCA是无监督的降维方法。
  - LDA选择分类性能最好的投影方向，而PCA选择样本点投影具有最大方差的方向。

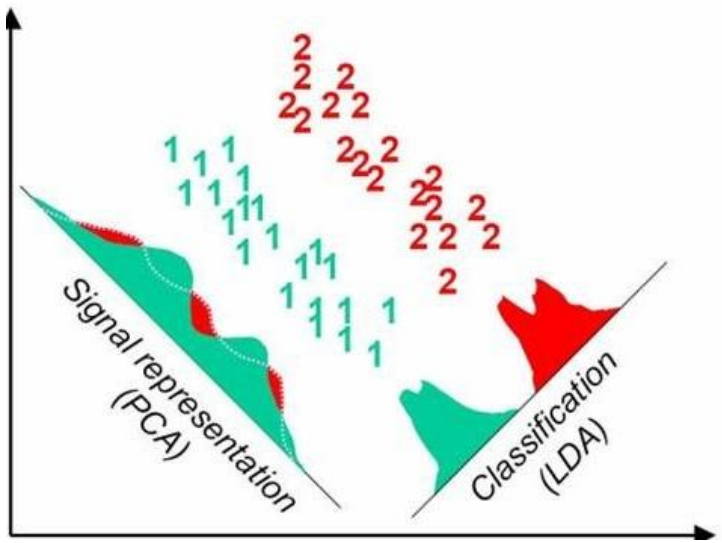

3.4.4.2 隐狄利克雷分配LDA

Latent Dirichlet Allocation**主题模型**
是Blei等人于2003年提出的基于概率模型的主题模型算法，LDA是一种非监督机器学习技术，可以用来识别大规模文档集或语料库中的潜在隐藏的主题信息。该方法假设每个词是由背后的一个潜在隐藏的主题中抽取出来。

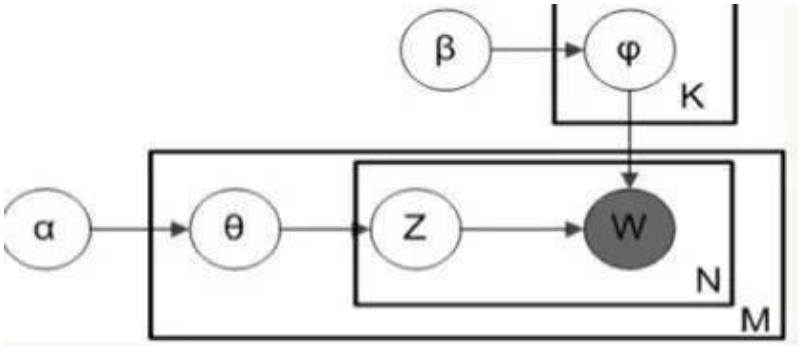

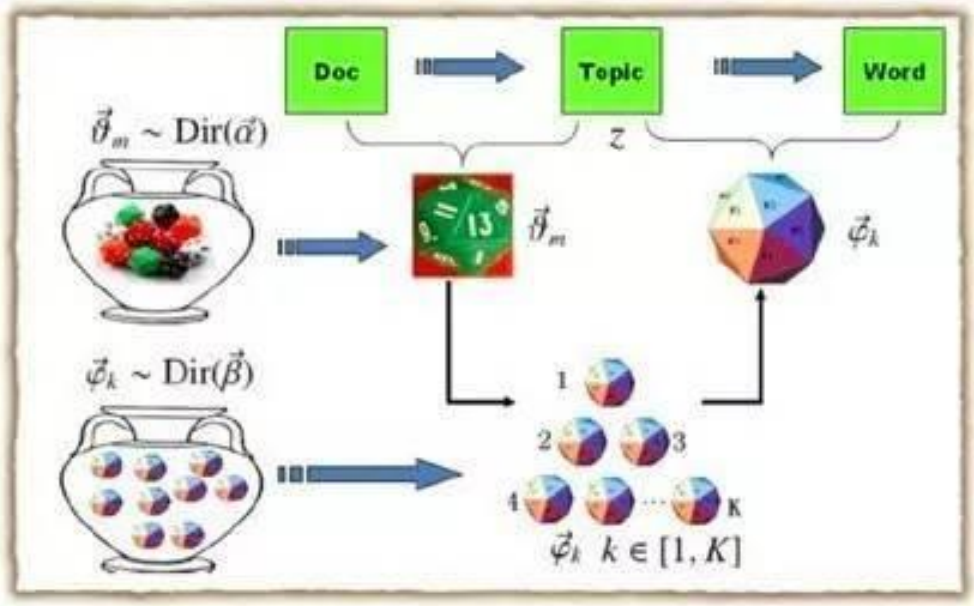

3.4.4.2 隐狄利克雷分配LDA

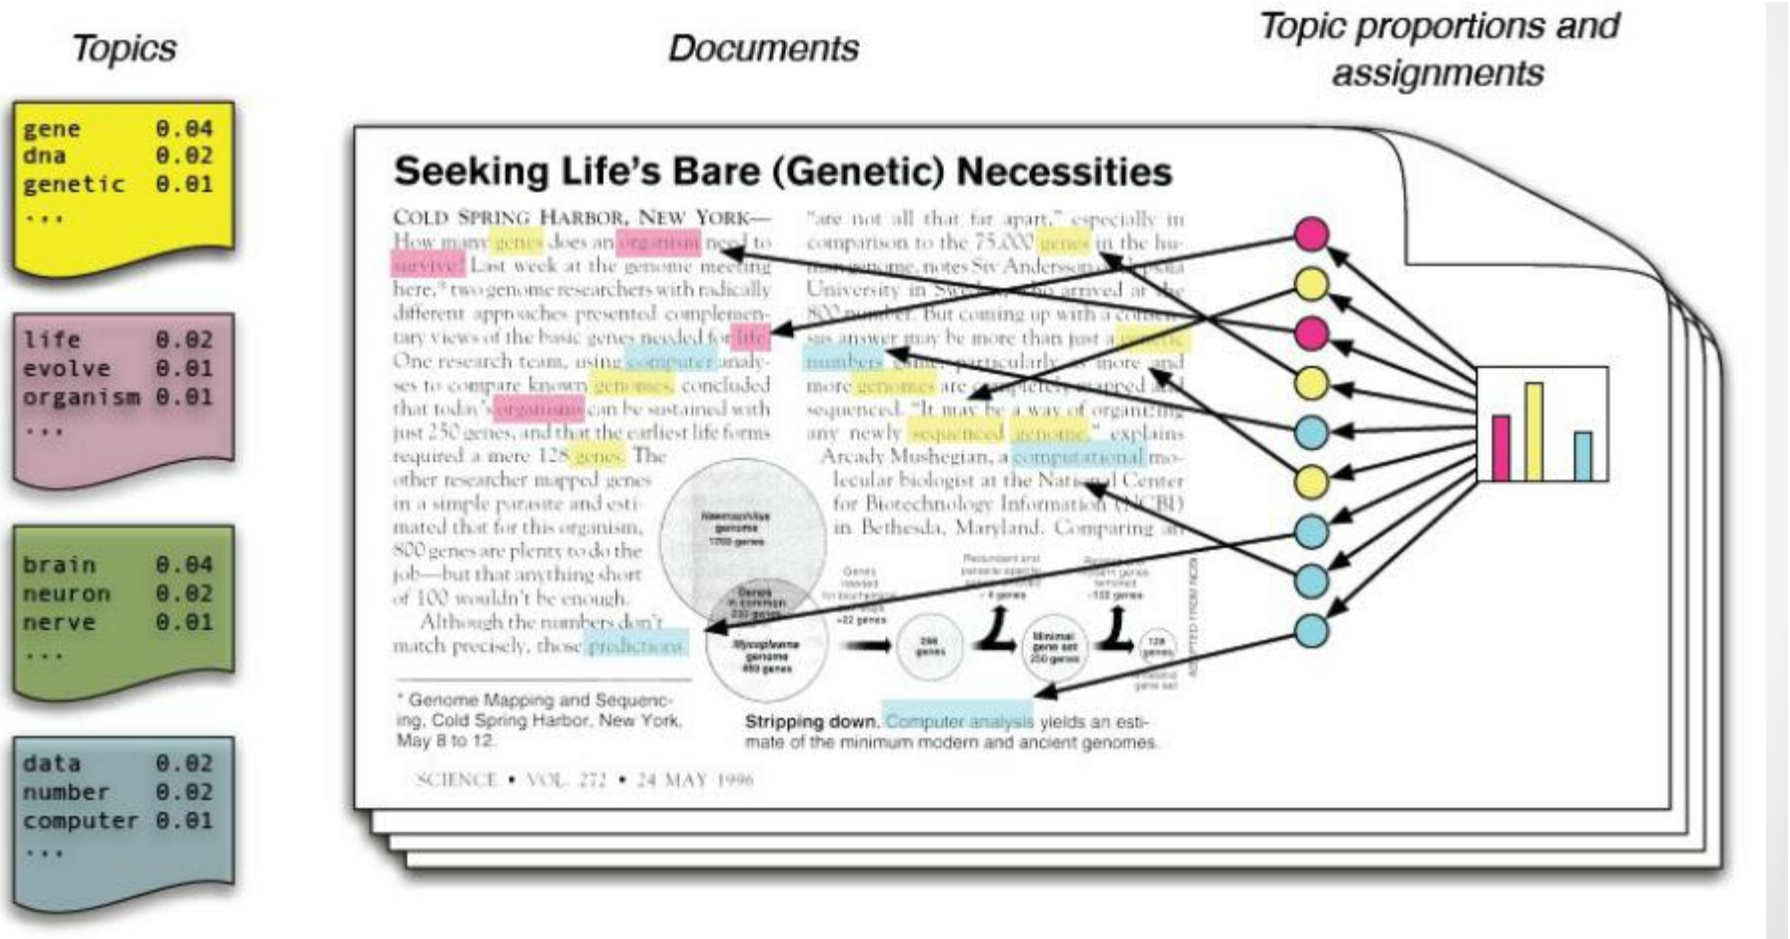

3.4.4.3 NMF

非负矩阵分解(Nonnegative Matrix Factorization)，简称NMF，是由Lee和Seung于1999年在《Nature》上提出的一种矩阵分解方法，它使分解后的所有分量均为非负值(要求纯加性的描述)，并且同时实现非线性的维数约减。

给定数据$X \in R^{M \times N}$ 和非负整数 $k < \min\{M, N\}$

NMF的目标函数是 $\min\limits_{W,H} \quad f(W,H) = \|X - WH\|_F^2$

$$s.t. \quad W \geq 0, H \geq 0$$

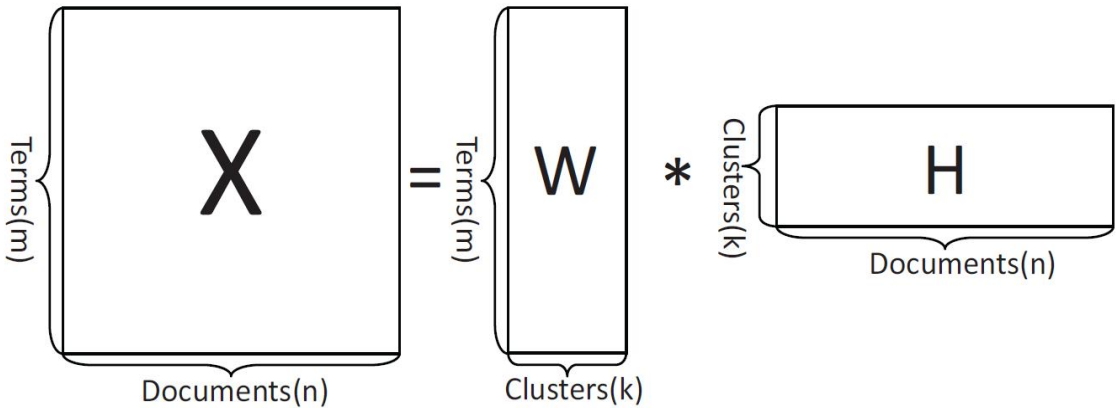

3.4.4.3 NMF

NMF of a set of images

$X = (x_1, x_2, \cdots, x_n)$

Matrix of images

=

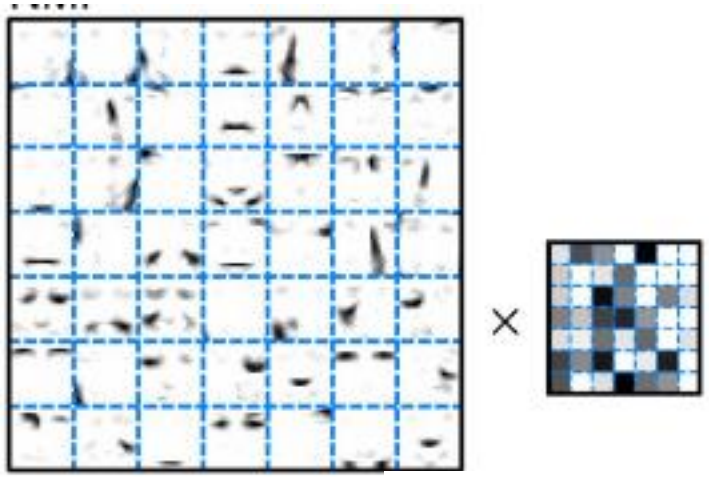

$H=(h_1, h_{2,\ldots}\ h_k)$

$W=(w_1, w_{2,\ldots}\ w_k)$

3.4.4.3 NMF

文本数据的向量空间模型

$$
\begin{array}{c}
 & \mathrm{doc}_1 & \mathrm{doc}_2 & \cdots & \mathrm{doc}_n \\
\mathrm{term}_1 & v_{11} & v_{12} & \cdots & v_{1n} \\
\mathrm{term}_2 & v_{21} & v_{22} & \cdots & v_{2n} \\
\cdots & \cdots & \cdots & v_{ij} & \\
\mathrm{term}_m & v_{m1} & v_{m2} & \cdots & v_{mn}
\end{array}
\quad \Rightarrow \quad v_{ij} \geq 0
$$

非负矩阵分解可以用在数据降维、文本聚类等问题上

3.4.4.4 t-SNE

t 分布随机邻近嵌入（t-Distribution Stochastic Neighbour Embedding）是一种用于降维的机器学习方法，主要的优势就是保持局部结构的能力。

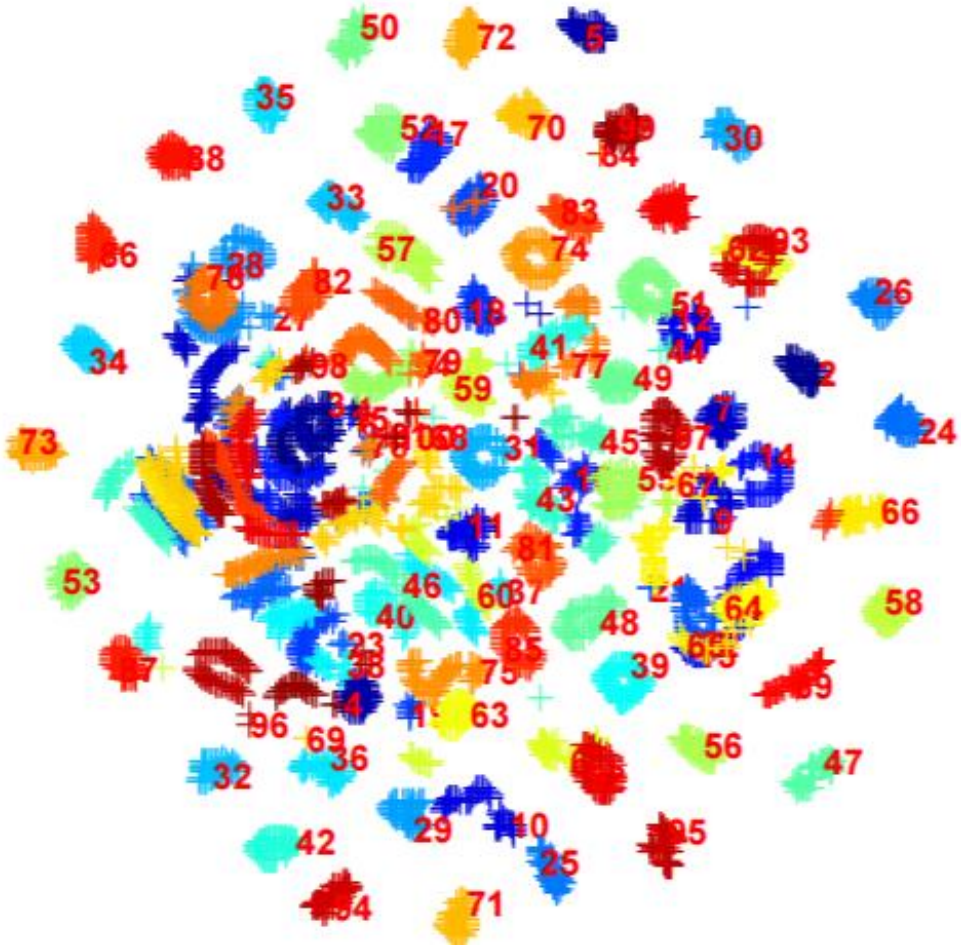

3.4 数据归约

- 3.4.1 数据归约策略的概述

属性归约

- 3.4.2 属性子集选择
- 3.4.3 主成分分析
- 3.4.4 其他降维方法

数量归约

- 3.4.5 回归模型
- 3.4.6 直方图
- 3.4.7 聚类
- 3.4.8 抽样

3.4 数据归约

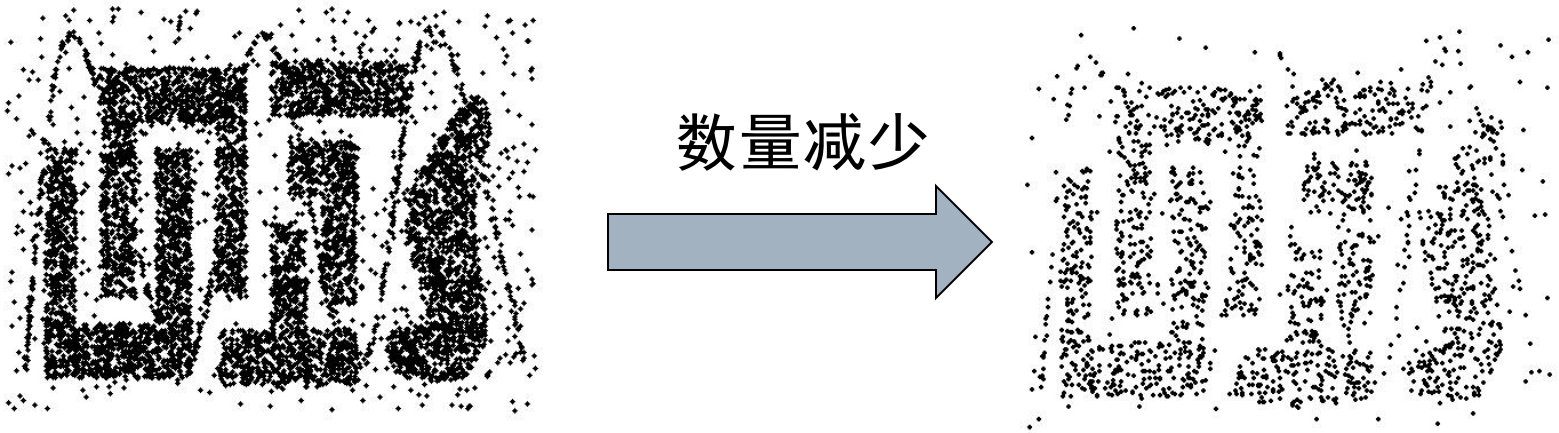

3.4 数据归约

通过选择可选的、更小的数据表示形式来减少数据量

- **参数化方法** (e.g., 回归)
- **非参数化方法**
  - 不需要假设模型
  - 主要有：直方图、聚类、抽样

3.4.5 回归

- 回归模型可以用来近似给定的数据。

1. 假设数据适合某个模型
2. 预测模型参数
3. 只存储参数，并丢弃数据

(可能的异常值除外)

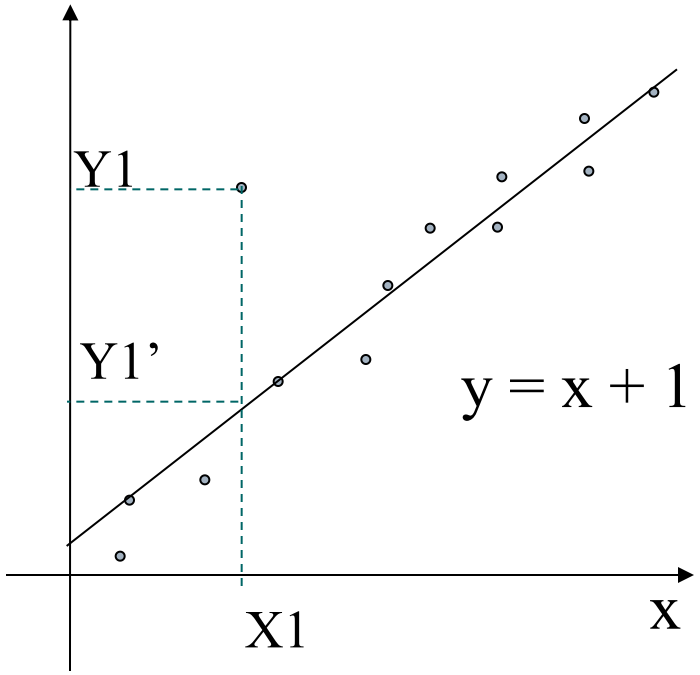

3.4.6 直方图分析

- 直方图使用分箱来近似数据分布
- 划分规则：等宽

  将范围划分为N个大小相等的间隔：均匀网格

1,1,5,5,5,5,5,8,8,10,10,10,10,12,14,14,14,15,15,15,15,15,15,

18,18,18,18,18,18,18,18, 20,20,20,20,20,20,20,21,21,21,21,

25,25,25,25,25,28,28,30,30,30

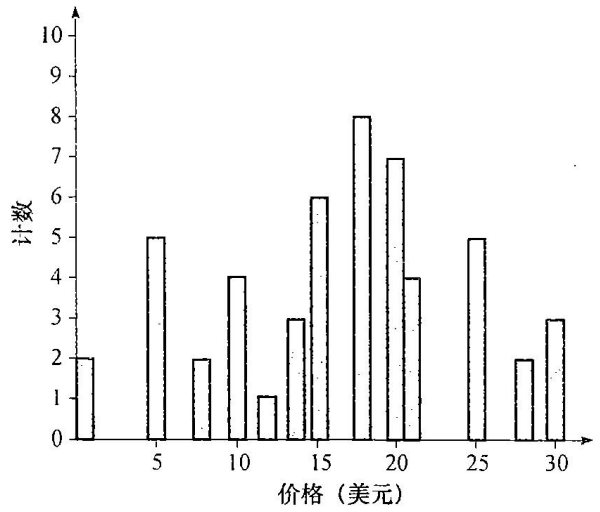

3.4.7 聚类

聚类技术把数据元组看做对象，将对象划分为群或簇，使得在一个簇中的对象相互“相似”，而与其他簇中的对象“相异”。通常，相似性基于距离函数。

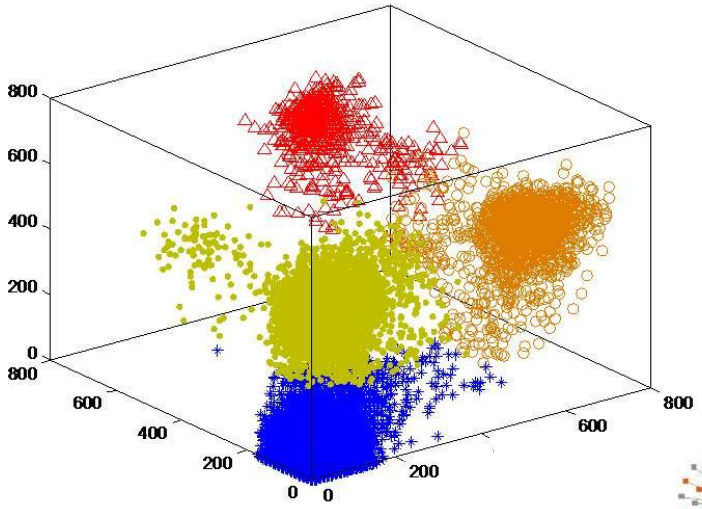

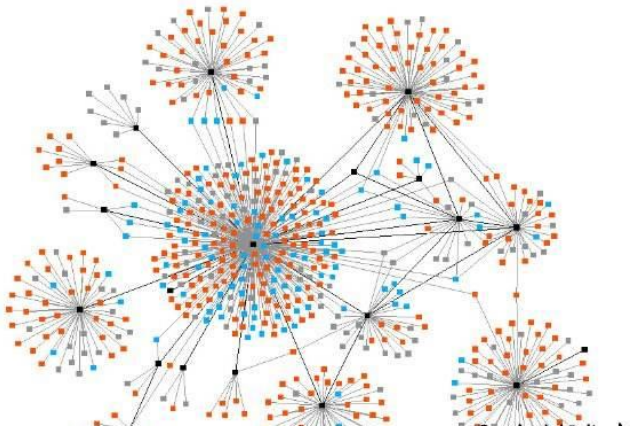

3.4.8 抽样

- 抽样可以作为一种数据归约的技术使用。
- 抽样：允许用数据小得多的随机样本（子集）表示大型数据集。
- 关键原则：选择数据的一个代表性子集

如果样本与原始数据集具有近似相同的（感兴趣的）属性，则该样本具有代表性。

- 简单随机抽样
- 簇抽样
- 分层抽样

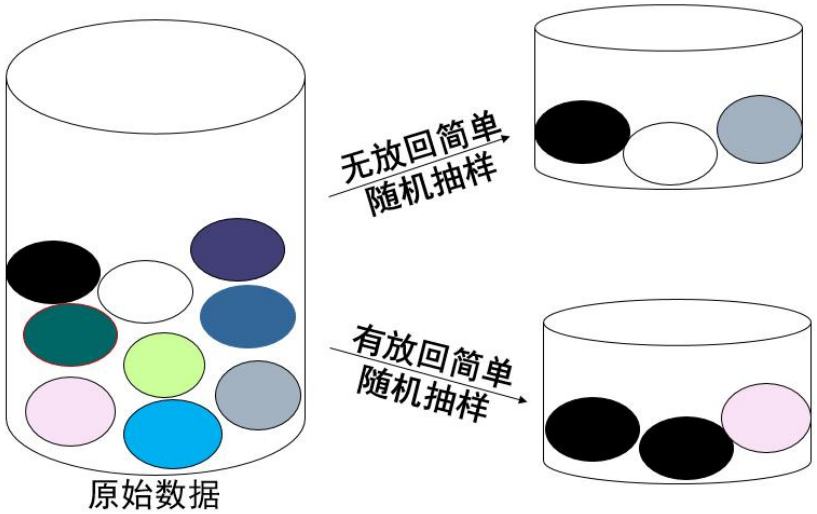

样本大小和数据质量

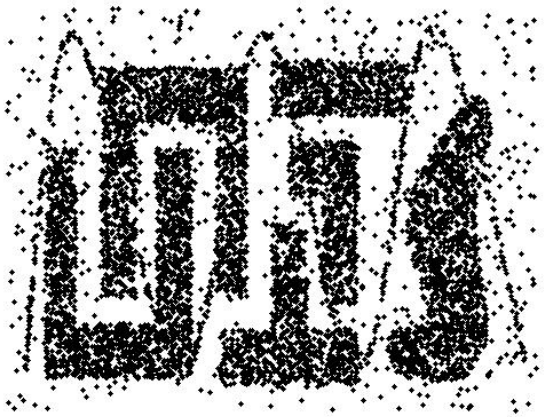

8000 points

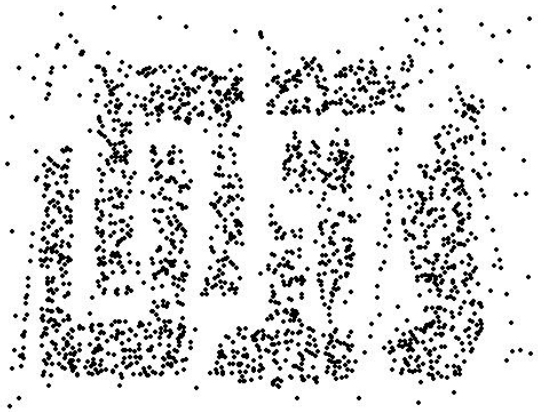

2000 Points

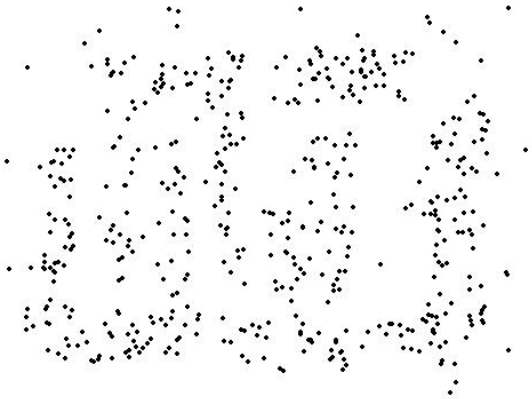

500 Points

需要研究自适应抽样方法

3.4.8 抽样

不均衡数据分布

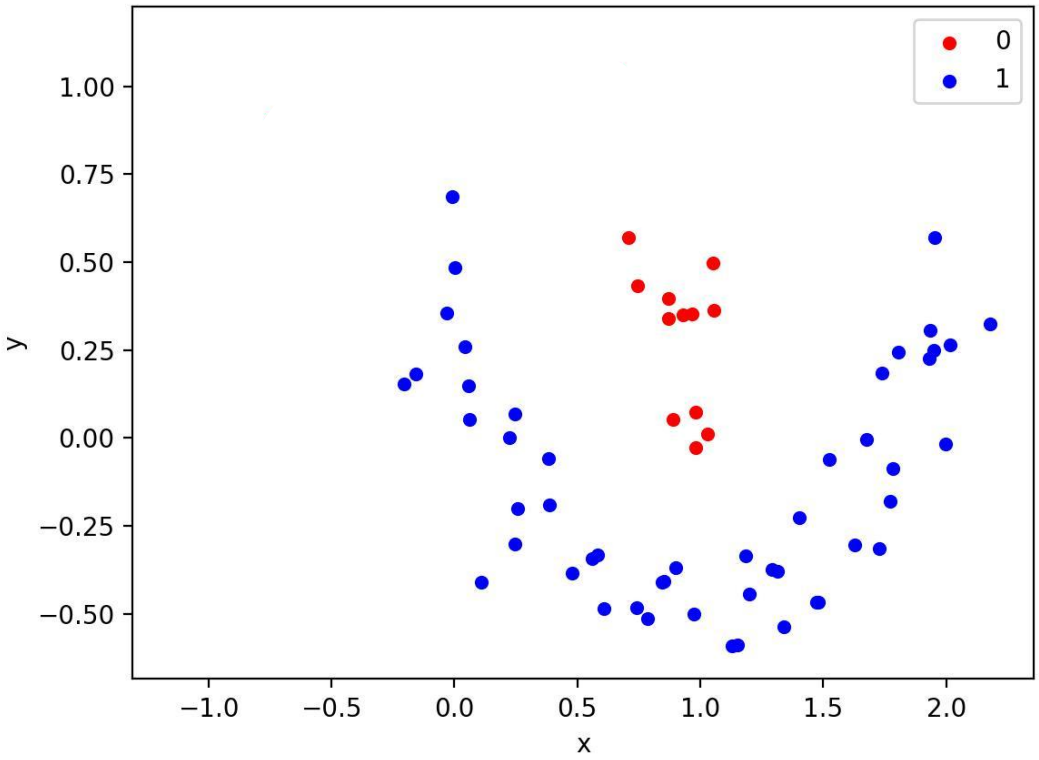

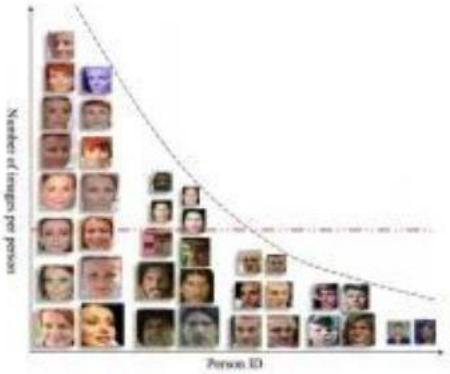

Faces [Zhang et al. 2017]

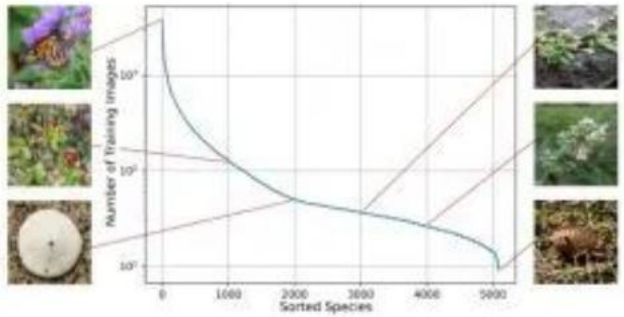

Species [Van Horn et al. 2019]

需要研究不均衡抽样方法

数据降维、轻量化等

- Jayoung Kim, Yehjin Shin, Jeongwhan Choi, Hyowon Wi, Noseong Park. Polynomial-based Self-Attention for Table Representation Learning - ICML, 2024.
- Jing Wu, Suiyao Chen, Qi Zhao, Renat Sergazinov, Chen Li, Shengjie Liu, Chongchao Zhao, Tianpei Xie, Hanqing Guo, Cheng Ji, Daniel Cociorva, Hakan Brunzell. SwitchTab: Switched Autoencoders Are Effective Tabular Learners - AAAI, 2024.
- Myung Jun Kim, Leo Grinsztajn, Gael Varoquaux. CARTE: Pretraining and Transfer for Tabular Learning - ICML, 2024.
- Jiahuan Yan, Bo Zheng, Hongxia Xu, Yiheng Zhu, Danny Chen, Jimeng Sun, Jian Wu, Jintai Chen. Making Pre-trained Language Models Great on Tabular Prediction - ICLR, 2024.
- Moonjung Eo, Kyungeun Lee, Hye-Seung Cho, Dongmin Kim, Ye Seul Sim, Woohyung Lim. Representation Space Augmentation for Effective Self-Supervised Learning on Tabular Data - AAAI, 2025.
- Xinyi He, Yihao Liu, Mengyu Zhou, Yeye He, Haoyu Dong, Shi Han, Zejian Yuan, Dongmei Zhang. TableLoRA: Low-rank Adaptation on Table Structure Understanding for Large Language Models - ACL, 2025.
- Yuchen Zeng, Tuan Dinh, Wonjun Kang, Andreas C. Mueller. TabFlex: Scaling Tabular Learning to Millions with Linear Attention - ICML, 2025.

3 数据预处理

- 3.1 数据预处理: 概述
- 3.2 数据清洗
- 3.3 数据集成
- 3.4 数据归约
- 3.5 数据变换
- 3.6 小结

3.5.1 数据编码

- 标称数据转成one-hot编码

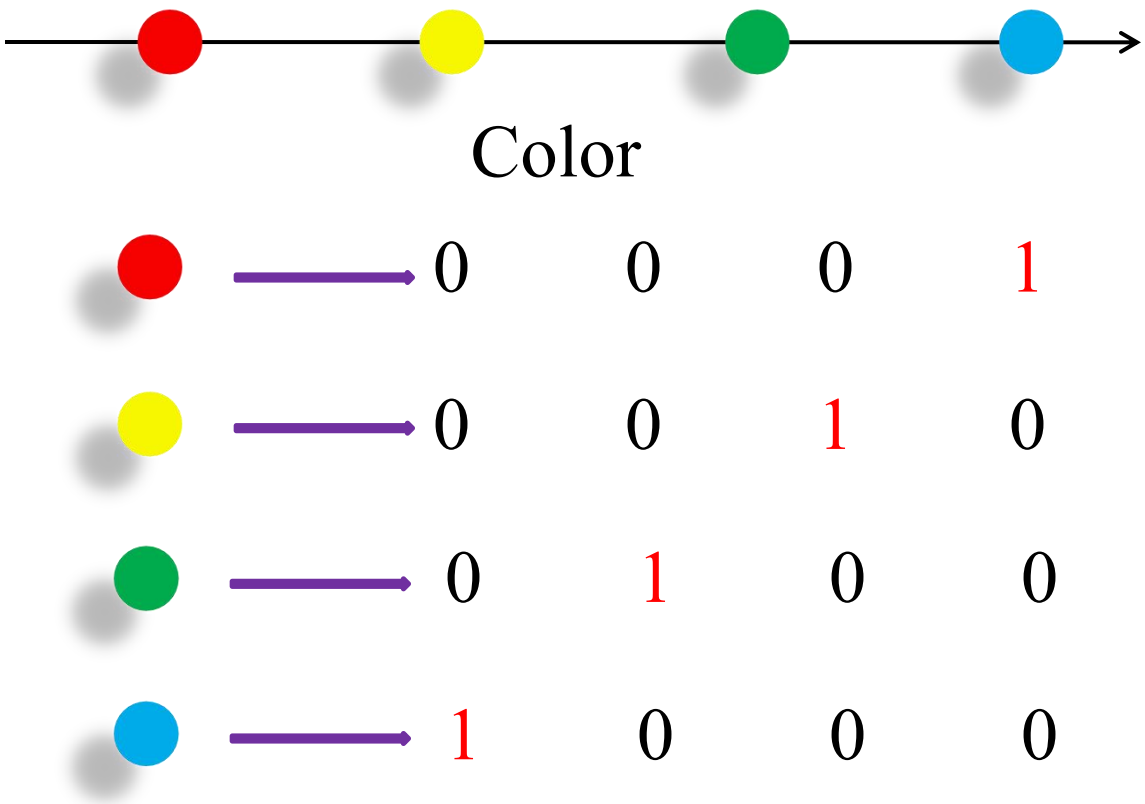

3.5.2 数据规范化

- 由于数据的标准、区间范围差别较大，需要进行数据转换。
- 数据变换是数据从一种表示形式变为另一种表现形式的过程。

身高(m)	体重(kg)
1.65	55
1.75	70
1.72	75
1.60	52
1.83	89

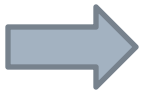

身高	体重
1.65	0.55
1.75	0.70
1.72	0.75
1.60	0.52
1.83	0.89

平时成绩（十分制）	期末成绩（百分制）
5	70
6	60
9	80
10	95

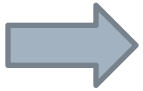

平时成绩（百分制）	期末成绩（百分制）
50	70
60	60
90	80
100	95

3.5.2 数据规范化

最小—最大规范化:对原始数据进行线性变换，使得数据落在new_ maxA, new_minA区间内。

$$v' = \frac{v - min_A}{max_A - min_A}(new_max_A - new_min_A) + new_min_A$$

max_A, min_A :属性A的最大与最小值

new_max_A, new_min_A:属性A变换后区间的最大与最小值

例：（一般映射到[0，1]区间）工资在700~12000之间，则工资7830规范化后为：

V’=（7830-700）/（12000-700）*（1-0）+0=0.7430

最小—最大值标准化保留了原有数据值的关系。如果后来的输入的标准化的数据落在了原有数据区间的外面，将会发生过界的错误。

3.5.2 数据规范化

举例：

	obj1	obj2	obj3	obj4	obj5	obj6
Atrribute 1:	11	7	14	11	43	38
Atrribute 2:	11	13	17	13	51	46
Atrribute 3:	9	11	20	9	69	76

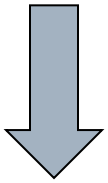

Atrribute 1:	4/36	0	7/36	4/36	1	31/36
Atrribute 2:	0	2/40	6/40	2/40	1	35/40
Atrribute 3:	0	2/67	11/67	0	60/67	1

3.5.2 数据规范化

- **z-score规范化:**基于属性A的平均值和标准差规范化。

$$v' = \frac{v - \overline{A}}{\sigma_A}$$

其中$\overline{A}$和σ_A是属性A的均值和标准差。
这种方法在实际的最小值和最大值未知时很有用，或者离群点主导了最小—最大值的标准化。
标准差可以用均值绝对偏差替换。

- **小数定标规范化：**通过移动属性A的小数点位置进行规范化。

$$v' = \frac{v}{10^j}$$

其中j是使得max（|v'|）<1的最小整数。

3.5.3 数据离散化

原因：

- 易于组织成更高层次的概念
- 某些模型只能使用离散属性

例如：决策树

ID	天气	温度	湿度	刮风	玩
3	overcast	83	86	☐	☑
4	rainny	70	96	☐	☑
5	rainny	68	80	☐	☑
6	rainny	65	70	☑	☐
7	overcast	64	65	☑	☑
8	sunny	72	95	☐	☐

ID	天气	温度	湿度	刮风	玩
3	3	3	2	1	2
4	2	1	2	1	2
5	2	1	1	1	2
6	2	1	1	2	1
7	3	1	1	2	2
8	1	2	2	1	1

3.5.3 数据离散化

- 属性的形式：
  - 离散—标称、二元、序数
  - 连续—数值
- 离散化：将连续属性的范围划分为区间
  - 区间标签可用来替换实际的数据值
  - 通过离散化减少数据取值的个数
- 方法：
  - 分箱：并不使用类信息，是一种非监督的离散化技术。对用户制定的箱个数很敏感，也容易受离群点的影响。
  - 聚类：将数值划分成簇。

3.5.3 数据离散化——分箱

- 按价格排序的数据（美元）：4, 8, 9, 15, 21, 21, 24, 25, 26, 28, 29, 33

分成等频(等深为4)的箱子:

- Bin 1: 4, 8, 9, 15
- Bin 2: 21, 21, 24, 25
- Bin 3: 26, 28, 29, 33

分成等宽(等宽为10)的箱子:

- Bin 1: 4, 8, 9
- Bin 2: 15, 21, 21
- Bin 3: 24, 25, 26, 28, 29, 33

3.5.3 数据离散化（分箱 vs. 聚类）

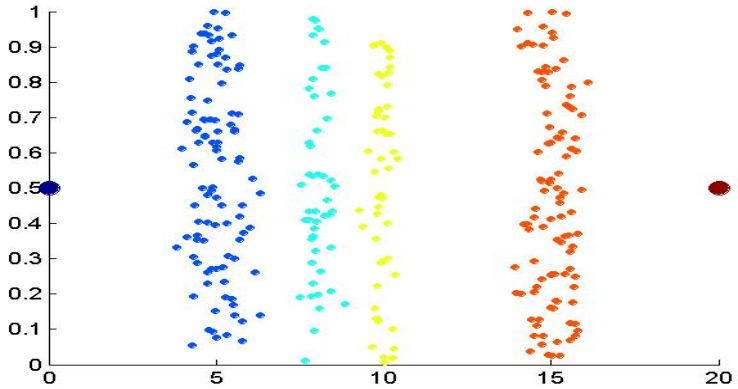

数据

4组
2个离群点
y-axis随机分布

等宽分箱
等频率分箱
K-means聚类

3.5.3 离散化（分箱 vs. 聚类）

问题：在这个数据集上，哪个方法比较好？

等宽分箱

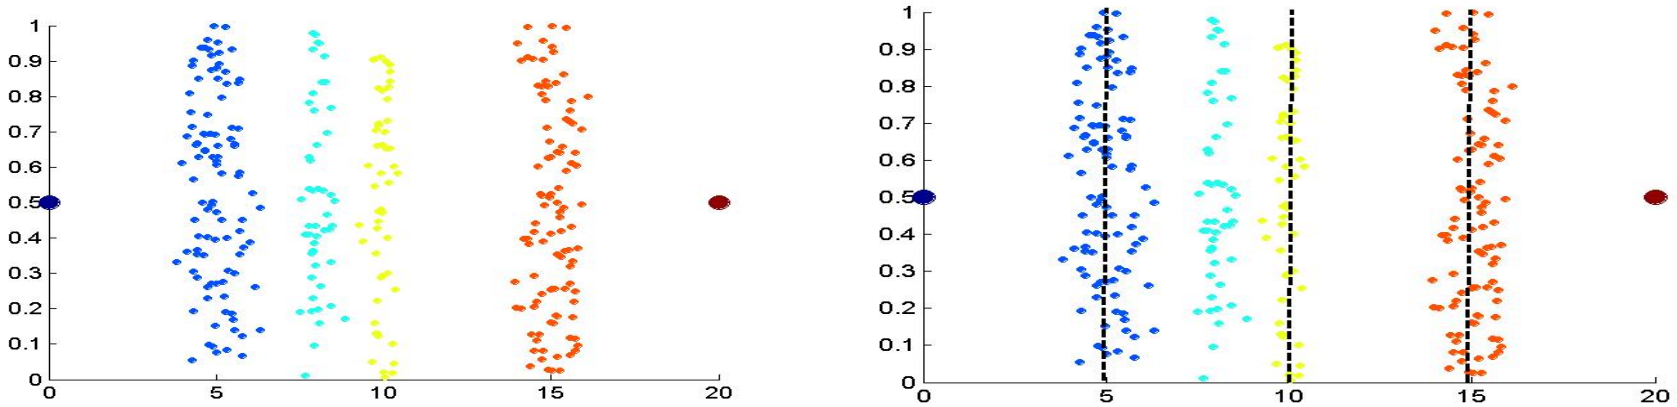

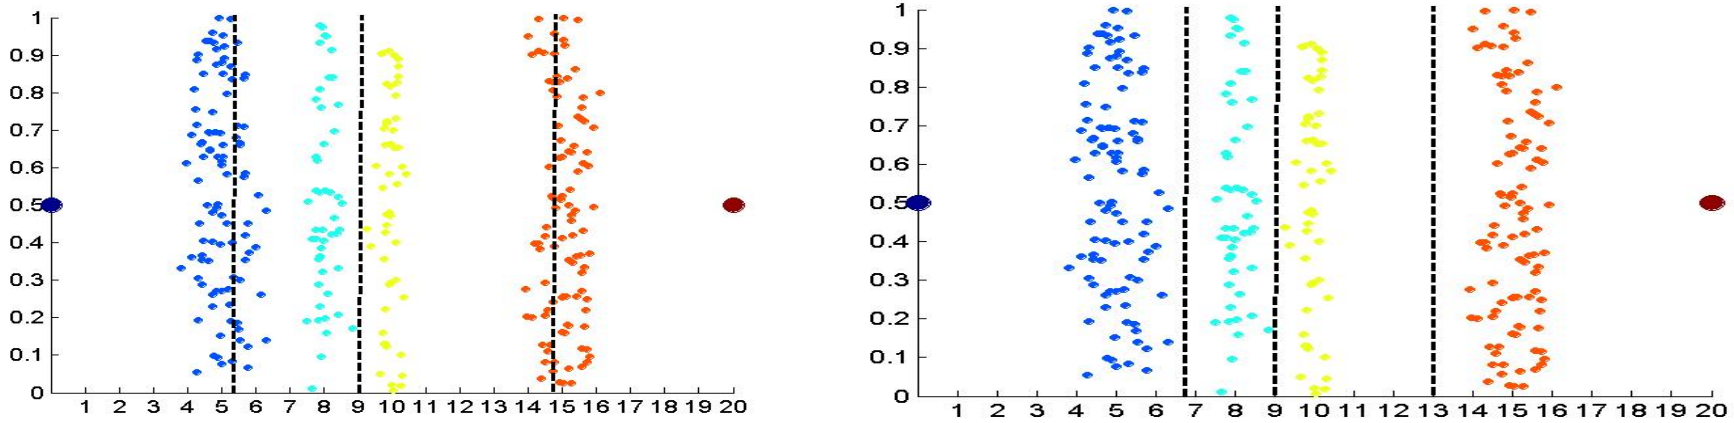

等频率分箱

K-means聚类

3.5.4 数据脱敏

- 某些敏感信息通过脱敏规则进行数据的变形，实现敏感隐私数据的可靠保护。
- 在涉及客户安全数据或者一些商业性敏感数据的情况下，在不违反系统规则条件下，对真实数据进行改造并提供测试使用，如身份证号、手机号、卡号、客户号等个人信息都需要进行数据脱敏。
- 通过数据脱敏产品，可以有效防止企业内部对隐私数据的滥用，防止隐私数据在未经脱敏的情况下从企业流出。满足企业既要保护隐私数据，同时又保持监管合规，满足企业合规性。

3.5.4 数据脱敏

- 替换方法是数据脱敏中最基本的方法之一。它通过将原始数据中的敏感信息替换为虚拟值来保护数据的隐私。以下是几种常见的替换方法：
  - 通用化：是一种常用的替换方法，它将原始数据中的敏感信息替换为通用的占位符，这种方法简单易行，但可能会导致数据的失真。
  - 随机化：是一种更复杂的替换方法，它将原始数据中的敏感信息替换为随机生成的值。这可以有效保护数据的隐私，但需要注意生成的随机值必须在统计上与原始数据相似，以保持数据的有效性。

3.5.4 数据脱敏

- 删除方法是另一种常用的数据脱敏方法，它直接从数据中删除敏感信息。这种方法可以有效保护敏感信息，但也可能导致数据的有效性下降。
  - 整行删除：这是一种极端的方法，它将包含敏感信息的整行数据从数据集中删除。这可以确保敏感信息不会泄露，但也可能损失大量有用的数据。
  - 列删除：是一种更精细的方法，它只删除包含敏感信息的列，而保留其他列。这样可以保留更多的数据，但依然可能导致数据的有效性问题。

3.5.4 数据脱敏

- 掩盖方法是一种将敏感信息部分掩盖或模糊的数据脱敏方法。这样可以保护敏感信息，同时保留数据的有效性。
  - 部分隐藏：将敏感信息的一部分字符替换为占位符，例如将信用卡号的中间数字用星号代替。这种方法可以保护部分敏感信息，但仍然有一定的风险。
  - 模糊化：这是一种将敏感信息进行模糊处理的方法，例如对日期进行模糊化，只保留年份或月份。这可以在一定程度上保护数据，但也可能导致数据的有效性问题。

3.5.4 数据脱敏

- 加密方法是一种将数据转化为密文的数据脱敏方法。只有授权用户能够解密数据，从而保护敏感信息的安全。
  - 对称加密方法：使用相同的密钥来加密和解密数据。这种方法效率高，但需要确保密钥的安全。
  - 非对称加密方法：使用一对密钥，一个用于加密，一个用于解密。这提高了数据的安全性，但也增加了计算开销。

3.5.4 数据脱敏

- 哈希方法是一种将数据转化为固定长度的哈希值的数据脱敏方法。哈希值不可逆，但相同的输入始终产生相同的哈希值。
  - 单向哈希方法：将数据转化为不可逆的哈希值，这可以用于保护密码等敏感信息。但哈希碰撞（多个输入映射到相同的哈希值）可能存在一定风险。
  - 盐值哈希方法：在单向哈希的基础上增加一个随机盐值，以增加哈希值的复杂性。这提高了安全性，但也增加了管理成本。

3.5.5 数据变换最新方法

- Jiahuan Yan, Bo Zheng, Hongxia Xu, Yiheng Zhu, Danny Chen, Jimeng Sun, Jian Wu, Jintai Chen. Making Pre-trained Language Models Great on Tabular Prediction - ICLR, 2024.
- Myung Jun Kim, Leo Grinsztajn, Gael Varoquaux. CARTE: Pretraining and Transfer for Tabular Learning - ICML, 2024.
- Md Mahadi Hasan Nahid, Davood Rafiei. NormTab: Improving Symbolic Reasoning in LLMs Through Tabular Data Normalization - Findings of EMNLP, 2024.
- Jing Wu, Suiyao Chen, Qi Zhao, Renat Sergazinov, Chen Li, Shengjie Liu, Chongchao Zhao, Tianpei Xie, Hanqing Guo, Cheng Ji, Daniel Cociorva, Hakan Brunzell. SwitchTab: Switched Autoencoders Are Effective Tabular Learners - AAAI, 2024.
- Juyong Kim, Chandler Squires, Pradeep Ravikumar. Knowledge-Enriched Machine Learning for Tabular Data - International Conference on Neuro-symbolic Systems, 2025.
- Xinyi He, Yihao Liu, Mengyu Zhou, Yeye He, Haoyu Dong, Shi Han, Zejian Yuan, Dongmei Zhang. TableLoRA: Low-rank Adaptation on Table Structure Understanding for Large Language Models - ACL, 2025.
- K. Xiong, C. A. Huang, M. Wybrow, Y. Wu. TableCanoniser: Interactive Grammar-Powered Transformation of Messy, Non-Relational Tables to Canonical Tables - CHI, 2025.
- Mengshi Chen, Yuxiang Sun, Tengchao Li, Jianwei Wang, Kai Wang, Xuemin Lin, Ying Zhang, Wenjie Zhang. Empowering Tabular Data Preparation with Language Models: Why and How? - ACL, 2026.

3 数据预处理

- 3.1 数据预处理: 概述
- 3.2 数据清洗
- 3.3 数据集成
- 3.4 数据归约
- 3.5 数据变换
- 3.6 小结

3.6 本章小结

- 数据清理：如：空缺值/噪声数据，离群点
- 数据集成：合并多个数据源
- 数据归约：
  - 属性归约
  - 数量归约
- 数据变换：
  - 规范化
  - 离散化
  - 脱敏

天津大学
Tianjin University

THE END

天津大学
Tianjin University

数据挖掘

杨柳

智能与计算学部

yangliuyl@tju.edu.cn

回顾

- 数据清理：如空缺值/噪声数据，离群点
- 数据集成：合并多个数据源
- 数据归约：
  - 属性归约
  - 数量归约
- 数据变换和数据离散化：
  - 规范化
  - 离散化

第 4 章 关联规则

4 关联规则

- 4.1概述
- 4.2Apriori算法
- 4.3FP-growth算法
- 4.4推荐算法
- 4.5小结

4.1 概述

- 关联规则是数据挖掘中最活跃的研究方法之一。
- 目的：发现交易数据库中不同商品之间的关联关系。

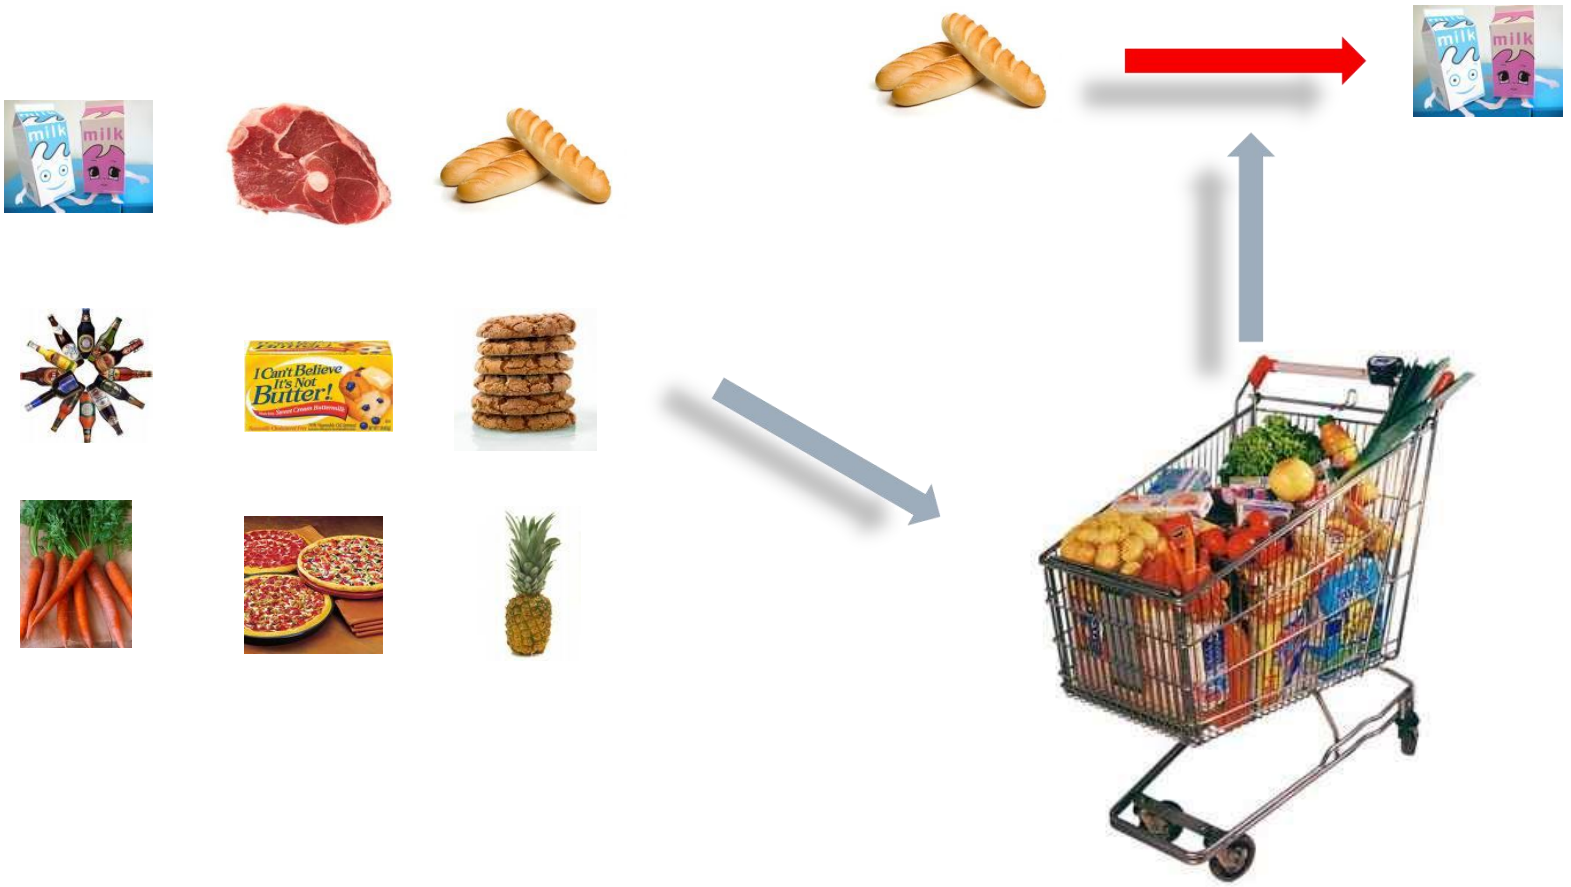

4.1 概述

- 购物篮分析
  - 尿布与啤酒
  - 电子产品
  - 书

4.1 概述

- 关联规则最早是由R.Agrawal(阿格拉沃尔)等人提出的。

- Agrawal R, Imieliński T, Swami A. Mining association rules between sets of items in large databases. *Proceedings of the ACM International Conference on Management of Data, SIGMOD,* 1993, 207. (27526 year2026.9)
- Agrawal R, Srikant R. Fast algorithms for mining association rules. *Proceedings of the 20th International Conference on Very Large Data Bases, VLDB,* 1994, 1215: 487-499. (31205 year 2026.9)

4 关联规则

- 4.1概述
- 4.2Apriori算法
- 4.3FP-growth算法
- 4.4推荐算法
- 4.5小结

4.2.1 基本概念

引例

假定某超市销售的商品包括：bread、beer、cake、cream、milk和tea

交易号TID	顾 客 购 买 商 品Items
T1	bread cream milk tea
T2	bread cream milk
T3	cake milk
T4	milk tea
T5	bread cake milk
T6	bread tea
T7	beer milk tea
T8	bread tea
T9	bread cream milk tea
T10	bread milk tea

4.2.1 基本概念

定义4.1 项目与项集

设$I=\{i_1,i_2,\ldots,i_m\}$是m个不同项目的集合，每个$i_k(k=1，2，\ldots\ldots，m)$称为一个项目(Item)。

项目的集合称为项目集合(Itemset)，简称为项集。其元素个数称为项集的长度，长度为k的项集称为k-项集(k-Itemset)。

交易号	顾客购买商品Items
T1	bread cream milk tea
T2	bread cream milk
T3	cake milk
T4	milk tea
T5	bread cake milk
T6	bread tea
T7	beer milk tea
T8	bread tea
T9	bread cream milk tea
T10	bread milk tea

基本概念中每个商品就是一个项目

项集I={bread, beer, cake, cream, milk, tea}，长度为6，是6-项集

项集X={milk, tea}，2-项集

4.2.1 基本概念

定义4.2 交易

每笔交易T(Transaction)是项集I上的一个非空子集，即$T \subseteq I$，但通常$T \subset I$。
对应每一个交易有一个唯一的标识——交易号，记作TID
交易的全体构成了交易数据库D，或称交易记录集D，简称交易集D。
交易集D中包含交易的个数记为$|D|$。

交易号	顾客购买商品Items
T1	bread cream milk tea
T2	bread cream milk
T3	cake milk
T4	milk tea
T5	bread cake milk
T6	bread tea
T7	beer milk tea
T8	bread tea
T9	bread cream milk tea
T10	bread milk tea

基本概念中包含10笔交易，
因此$|D|$=10。

4.2.1 基本概念

□ 定义4.3 项集的支持度

对于项集X，$X \subseteq I$

绝对支持度（支持度计数）count($X \subseteq T$)为交易集D中包含X的交易数量。

相对支持度项集X出现的概率，从而描述了X的重要性。

交易号	顾客购买商品Items
T1	bread cream milk tea
T2	bread cream milk
T3	cake milk
T4	milk tea
T5	bread cake milk
T6	bread tea
T7	beer milk tea
T8	bread tea
T9	bread cream milk tea
T10	bread milk tea

$$\text{support}(X) = \frac{\text{count}(X \subseteq T)}{|D|}$$

	支持度计数	支持度
X_1={bread}	7	0.7
X_2={bread, milk}	5	0.5
X_3={bread, milk, tea}	3	0.3

子集、超集

4.2.1 基本概念

□ 定义4.4 项集的最小支持度与频繁集

发现关联规则要求项集必须满足的最小支持阈值，称为项集的最小支持度(Minimum Support)，记为min_sup。

从统计意义上讲，它表示用户关心的关联规则必须满足的最低重要性，只有满足最小支持度的项集才能产生关联规则。

支持度大于或等于min_sup的项集称为频繁项集，简称频繁集，反之则称为非频繁集。

对于k-项集，若满足min_sup，称为k-频繁集，记作L_k。

4.2.1 基本概念

交易号	顾客购买商品Items
T1	bread cream milk tea
T2	bread cream milk
T3	cake milk
T4	milk tea
T5	bread cake milk
T6	bread tea
T7	beer milk tea
T8	bread tea
T9	bread cream milk tea
T10	bread milk tea

如果设定min_sup为0.3，

{bread, milk}

支持度是0.5，所以是2-频繁集。

{cake, milk}

支持度是0.2，非频繁集。

4.2.1 基本概念

定义4.5 关联规则

关联规则(Association Rule)可以表示为一个蕴含式：

R：$X \Rightarrow Y$，其中$X \subset I, Y \subset I$，并且$X \cap Y = \Phi$。

关联规则表示若项集X在某一交易中出现，则会导致项集Y按照某一概率也会在同一交易中出现。

可以用两个标准来衡量：支持度和置信度。

定义4.6 关联规则的支持度

对于关联规则R：$X \Rightarrow Y$，规则R的支持度(Support)是交易集中同时包含X和Y的交易数与所有交易数之比。

$$\text{support}(X \Rightarrow Y) = \frac{\text{count}(X \cup Y)}{|D|}$$

联合概率：$p(Y, X)$

4.2.1 基本概念

交易号	顾客购买商品Items
T1	bread cream milk tea
T2	bread cream milk
T3	cake milk
T4	milk tea
T5	bread cake milk
T6	bread tea
T7	beer milk tea
T8	bread tea
T9	bread cream milk tea
T10	bread milk tea

$$\text{support}(X \Rightarrow Y) = \frac{\text{count}(X \cup Y)}{|D|}$$

X={bread, milk}, Y={tea}

0.3

Y={bread, milk}, X={tea}

0.3

X={bread}, Y={tea,cream}

0.2

定义4.7 关联规则的置信度

对于关联规则R：$X \Rightarrow Y$，规则R的置信度(Confidence)是指包含X和Y的交易数与包含X的交易数之比：

$$\text{confidence}\ (X \Rightarrow Y) = \frac{\text{support}(X \cup Y)}{\text{support}(X)} = \frac{\text{count}(X \cup Y)}{\text{count}(X)}$$

置信度反映了若交易中包含X，则交易中同时出现Y的概率。

条件概率：$p(Y|X)$

一般来说，只有支持度和置信度较高的关联规则才是用户感兴趣的。

4.2.1 基本概念

交易号	顾客购买商品Items
T1	bread cream milk tea
T2	bread cream milk
T3	cake milk
T4	milk tea
T5	bread cake milk
T6	bread tea
T7	beer milk tea
T8	bread tea
T9	bread cream milk tea
T10	bread milk tea

$$\text{confidence}\ (X \Rightarrow Y) = \frac{\text{support}(X \cup Y)}{\text{support}(X)}$$

X={bread, milk}, Y={tea}

0.3/0.5

X={tea}, Y={bread, milk}

0.3/0.7

4.2.1 基本概念

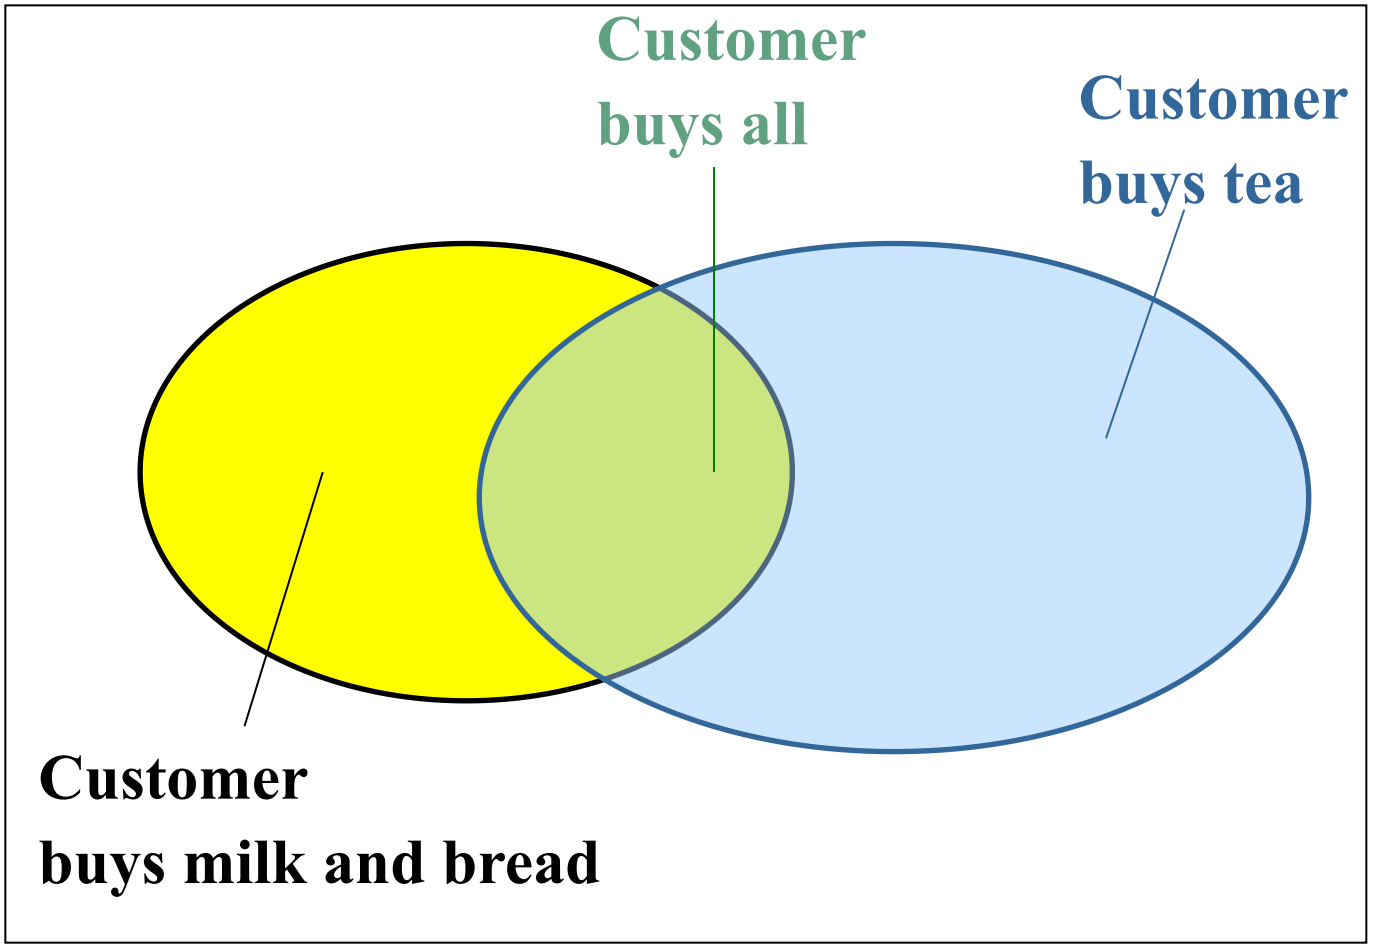
Customer
buys all
Customer
buys tea
Customer
buys milk and bread

4.2.1 基本概念

□ 定义4.8 关联规则的最小支持度和最小置信度

关联规则的最小支持度：衡量频繁集的最小支持度(Minimum Support)，记为min_sup，它是用于衡量规则需要满足的最低重要性。

关联规则的最小置信度(Minimum Confidence)记为min_conf，它表示关联规则需要满足的最低可靠性。

4.2.1 基本概念

□ 定义4.9 强关联规则

如果规则$X \Rightarrow Y$满足：

$\text{support}(X \Rightarrow Y) \geq \text{min_sup}$且$\text{confidence}(X \Rightarrow Y) \geq \text{min_conf}$，

称关联规则$X \Rightarrow Y$为强关联规则，否则为弱关联规则。

在挖掘关联规则时，产生的关联规则要经过min_sup和min_conf的衡量，筛选出来的强关联规则才能用于指导商家的决策。

4.2.1 基本概念

表1：关联规则的简单例子

TID	网球拍	网 球	运动鞋	羽毛球
1	1	1	1	0
2	1	1	0	0
3	1	0	0	0
4	1	0	1	0
5	0	0	1	1
6	1	1	0	0

表1是顾客购买记录的数据库D，包含6个事务。

项集I={网球拍,网球,运动鞋,羽毛球}。

min_sup=0.5， min_conf=0.5

考虑关联规则：网球拍⇒网球，

支持度 $= \frac{3}{6} = 0.5$

置信度 $= \frac{3}{5} = 0.6$

是强关联规则

4.2.2 挖掘策略

- 大多数关联规则挖掘算法通常采用的一种策略是，将关联规则挖掘任务分解为如下两个主要的子任务:
  - 频繁项集产生（Frequent Itemset Generation）
    - 其目标是发现满足最小支持度阈值的所有项集，这些项集称作频繁项集。
  - 规则的产生（Rule Generation）
    - 其目标是从上一步发现的频繁项集中提取所有高支持度和置信度的规则，这些规则称作强规则（strong rule）。找出支持度大于等于 min_sup并且置信度大于等于min_conf的所有规则。

4.2.2 挖掘策略

频繁项集产生（Frequent Itemset Generation）

格结构（lattice structure）

由事务数据集产生的频繁项集的数量可能非常大。

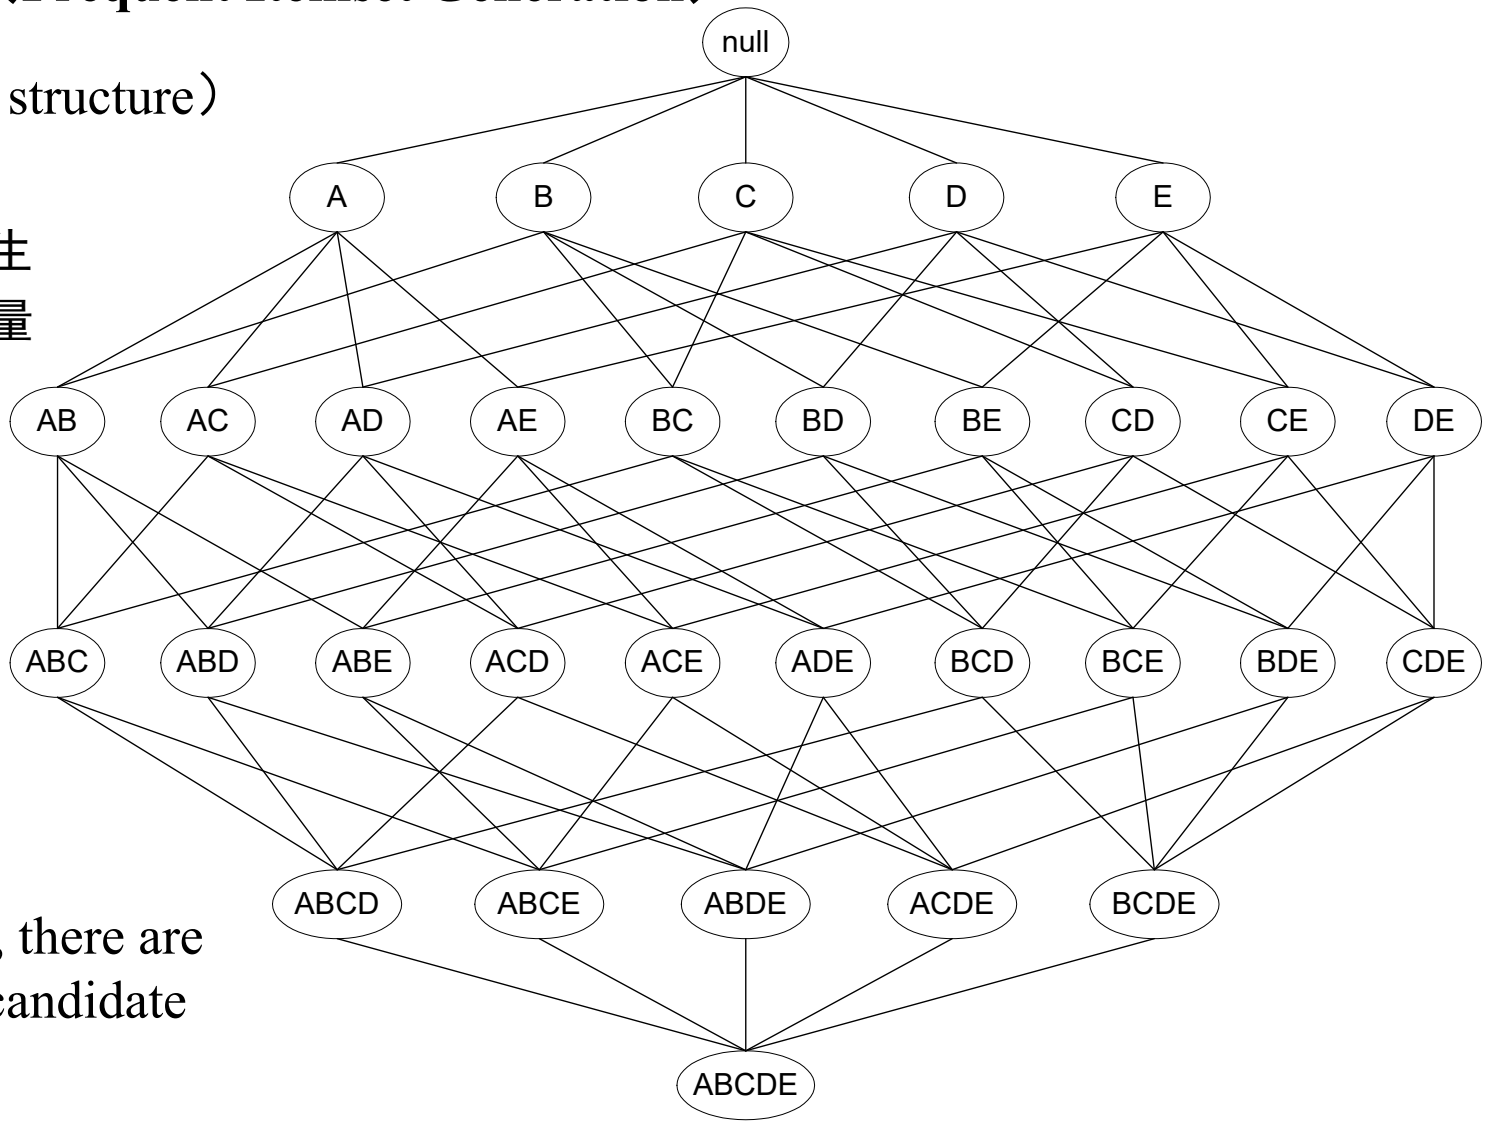

Given d items, there are 2^d-1 possible candidate itemsets

4.2.2 挖掘策略

- 挖掘关联规则的一种原始方法是：Brute-force approach:
  - 计算每个可能规则的支持度和置信度
  - 这种方法计算代价过高，从数据集提取规则的数量达指数级

4.2.2 挖掘策略

- Brute-force 方法:
  - 把格结构中每个项集作为候选项集
  - 将每个候选项集和每个事务进行比较，确定每个候选项集的支持度计数。

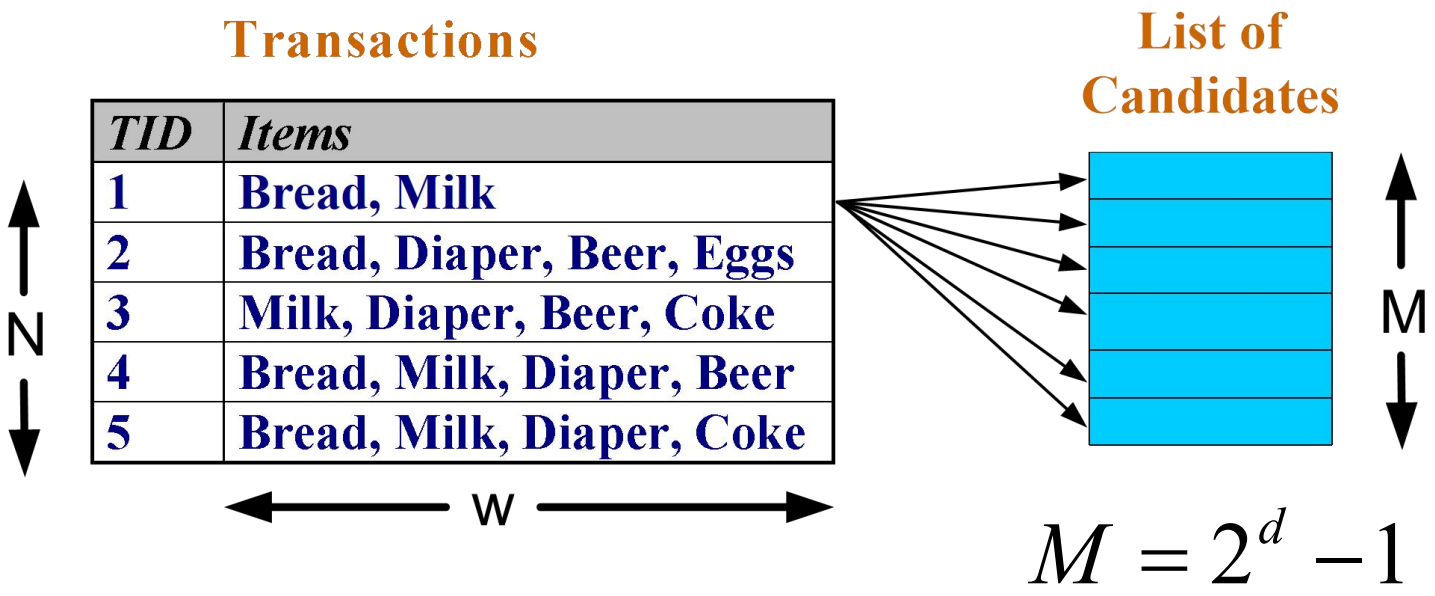

- 时间复杂度 ~ O(*NMW*)，这种方法的开销可能非常大。

4.2.2 挖掘策略

降低产生频繁项集计算复杂度的方法

- 减少候选项集的数量
  - 先验(apriori)原理
- 减少比较的次数
  - 替代将每个候选项集与每个事务相匹配，可以使用更高级的数据结构，或存储候选项集或压缩数据集，来减少比较次数

4.2.3 Apriori算法

Apriori算法是一种最有影响的挖掘关联规则频繁项集的算法。算法名字是缘于算法使用了频繁项集的性质这一先验知识。

- 先验原理：
  - 如果一个项集是频繁的，则它的所有子集一定也是频繁的
  - 相反，如果一个项集是非频繁的，则它的所有超集也一定是非频繁的
- 这种基于支持度度量修剪指数搜索空间的策略称为基于支持度的剪枝（support-based pruning）
- 这种剪枝策略依赖于支持度度量的一个关键性质，即一个项集的支持度决不会超过它的子集的支持度。这个性质也称为支持度度量的反单调性（anti-monotone）

4.2.3 Apriori算法

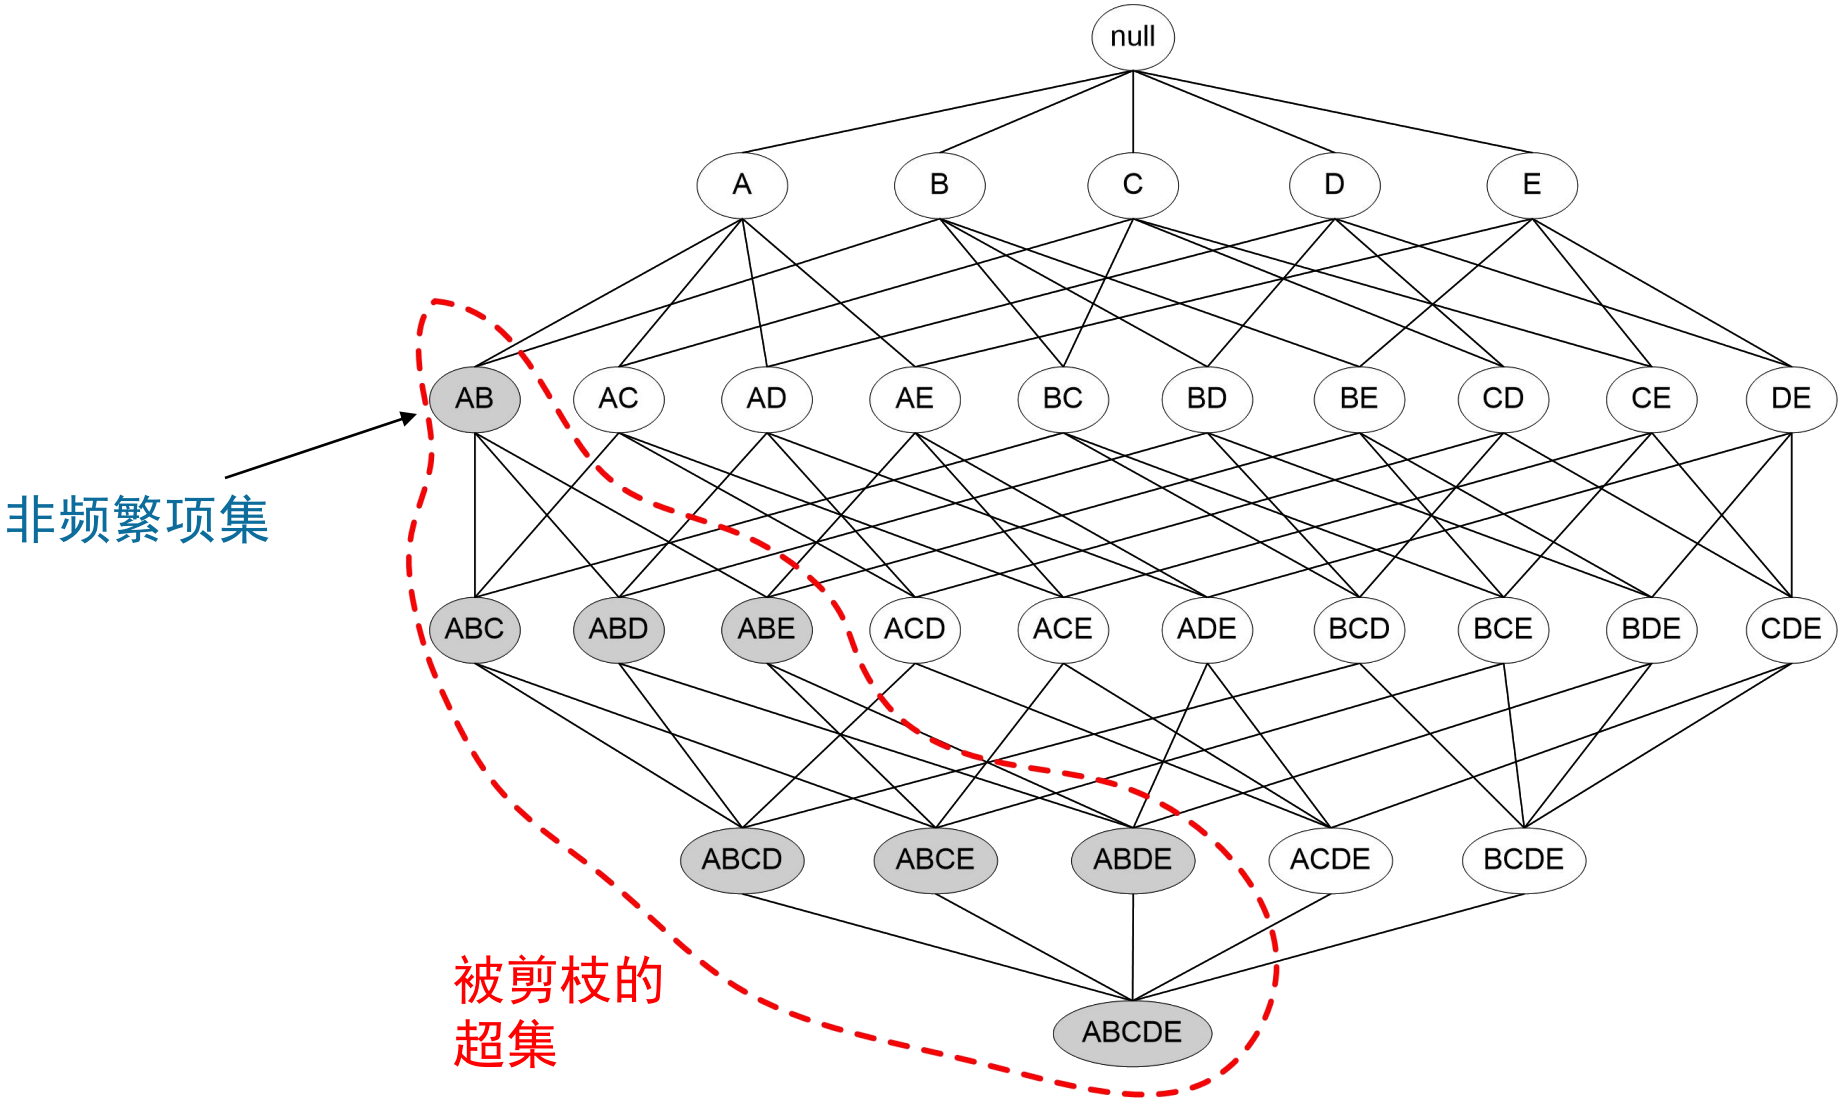

4.2.3 Apriori算法

在Apriori算法中，寻找频繁项集的基本思想是：算法需要对数据集进行多步处理。Apriori 使用了一种称作level-wise搜索的迭代方法。

- 找出频繁1项集，以L_1表示。L_1用来寻找L_2，即频繁2-项集的集合。L_2用来寻找L_3，以此类推，直至没有新的频繁k-项集被发现。每个L_k都要求对数据库作一次完全扫描。
- 使用L_{k-1}找出L_k，由两步组成：
  - 连接步：将L_{k-1}与自身连接产生候选k项集的集合，标记为C_k
  - 剪枝步：剪除不满足最小支持度的候选项集。

4.2.3 Apriori算法

- 下面以图例的方式说明该算法的运行过程： 假设有一个数据库*D*，其中有4个事务记录，预定最小支持度计数min_sup=2，事务记录分别表示为：

TID	Items
T1	I1,I3,I4
T2	I2,I3,I5
T3	I1,I2,I3,I5
T4	I2,I5

4.2.3 Apriori算法

- 扫描D，对每个候选项进行支持度计数得到

TID	Items
T1	I1,I3,I4
T2	I2,I3,I5
T3	I1,I2,I3,I5
T4	I2,I5

项集	支持度计数
{I1}	2
{I2}	3
{I3}	3
{I4}	1
{I5}	3

4.2.3 Apriori算法

- 比较候选项支持度计数与最小支持度min_sup，产生1项集

TID	Items
T1	I1,I3,I4
T2	I2,I3,I5
T3	I1,I2,I3,I5
T4	I2,I5

项集	支持度计数
{I1}	2
{I2}	3
{I3}	3
{I4}	1
{I5}	3

项集	支持度计数
{I1}	2
{I2}	3
{I3}	3
{I5}	3

4.2.3 Apriori算法

- 产生候选项集

项集	支持度计数
{I1}	2
{I2}	3
{I3}	3
{I5}	3

项集
{I1,I2}
{I1,I3}
{I1,I5}
{I2,I3}
{I2,I5}
{I3,I5}

4.2.3 Apriori算法

- 扫描D，对每个候选项集进行支持度计数:

TID	Items
T1	I1,I3,I4
T2	I2,I3,I5
T3	I1,I2,I3,I5
T4	I2,I5

项集
{I1,I2}
{I1,I3}
{I1,I5}
{I2,I3}
{I2,I5}
{I3,I5}

项集	支持度计数
{I1,I2}	1
{I1,I3}	2
{I1,I5}	1
{I2,I3}	2
{I2,I5}	3
{I3,I5}	2

4.2.3 Apriori算法

- 比较候选项支持度计数与最小支持度min_sup，产生2项集

项集	支持度计数
{I1,I2}	1
{I1,I3}	2
{I1,I5}	1
{I2,I3}	2
{I2,I5}	3
{I3,I5}	2

项集	支持度计数
{I1,I3}	2
{I2,I3}	2
{I2,I5}	3
{I3,I5}	2

4.2.3 Apriori算法

- 产生候选项集

项集	支持度计数
{I1,I3}	2
{I2,I3}	2
{I2,I5}	3
{I3,I5}	2

项集
{I2,I3,I5}

4.2.3 Apriori算法

- 比较候选项支持度计数与最小支持度min_sup，产生3项集

TID	Items
T1	I1,I3,I4
T2	I2,I3,I5
T3	I1,I2,I3,I5
T4	I2,I5

项集	支持度计数
{I2,I3,I5}	2

- 算法终止

4.2.3 Apriori算法

- 所有的频繁项集

项集	支持度计数
{I1}	2
{I2}	3
{I3}	3
{I5}	3

项集	支持度计数
{I1,I3}	2
{I2,I3}	2
{I2,I5}	3
{I3,I5}	2

项集	支持度计数
{I2,I3,I5}	2

4.2.3 Apriori算法

算法：(Apriori)利用层次循环发现频繁项集。

输入：交易数据库D，最小支持阈值min_sup；

输出：L_i，D中的频繁项集；

处理流程：

（1）L_1=find_frequent_1_itemset(D);//发现1-项集

（2）for(k=2; $L_{k-1}\neq \varnothing$; k++){

（3）　C_k=apriori_gen(L_{k-1},min_sup);//根据频繁(k-1)-项集产生候选k-项集

（4）　for each $t \in D$　{//扫描数据库，以确定每个候选项集的支持频度

（5）　　C_t=subset(C_k, t);//获得t所包含的候选项集

（6）　　for each $c \in C_t$

（7）　　c.count++;

（8）　}

（9）　$L_k=\{c \in C_k | c.\text{count} > \text{min_sup}\}$;

（10）}

（11）return $L=\bigcup_k L_k$;

Apriori算法的频繁项集产生

TID	*Items*
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

最小支持度计数 = 3

Apriori算法的频繁项集产生

Item	Count
Bread	4
Coke	2
Milk	4
Beer	3
Diaper	4
Eggs	1

Items (1-itemsets)

Itemset	Count
{Bread,Milk}	3
{Bread,Beer}	2
{Bread,Diaper}	3
{Milk,Beer}	2
{Milk,Diaper}	3
{Beer,Diaper}	3

Pairs (2-itemsets)

最小支持度计数 = 3

枚举所有项集将产生
$C_6^1 + C_6^2 + C_6^3 = 41$个候选
而使用先验原理，将较少为
$6 + 6 + 1 = 13$

Triplets (3-itemsets)

Itemset	Count
{Bread,Milk,Diaper}	2

4.2.3 Apriori算法

- Apriori算法的频繁项集产生的部分有两个重要的特点：
  - 它是一个逐层算法。即从频繁1-项集到最长的频繁项集，它每次遍历项集格中的一层。
  - 它使用产生-测试策略来发现频繁项集。在每次迭代，新的候选项集由前一次迭代发现的频繁项集产生，然后对每个候选的支持度进行计数，并与最小支持度阈值进行比较。
- 该算法需要的迭代次数是$k_{\max}$，其中 $k_{\max}$是频繁项集的最大长度

4.2.3 Apriori算法

规则产生

- 忽略那些前件或后件为空的规则，每个频繁k-项集能够产生多达2^k-2个关联规则
- 关联规则的提取：将一个项集 Y划分成两个非空的子集 X 和 Y-X，使得$X \Rightarrow Y$-X满足置信度阈值。
  - 如果 {A,B,C,D} 是频繁项集，候选项集为:

    $ABC \Rightarrow D$, $ABD \Rightarrow C$, $ACD \Rightarrow B$, $BCD \Rightarrow A$,

    $A \Rightarrow BCD$, $B \Rightarrow ACD$, $C \Rightarrow ABD$, $D \Rightarrow ABC$

    $AB \Rightarrow CD$, $AC \Rightarrow BD$, $AD \Rightarrow BC$, $BC \Rightarrow AD$,

    $BD \Rightarrow AC$, $CD \Rightarrow AB$
- 这样的规则必然已经满足支持度阈值，因为它们是由频繁项

4.2.6 Apriori算法复杂度分析

- 把格结构中每个项集作为候选项集
- 将每个候选项集和每个事务进行比较，确定每个候选项集的支持度计数。

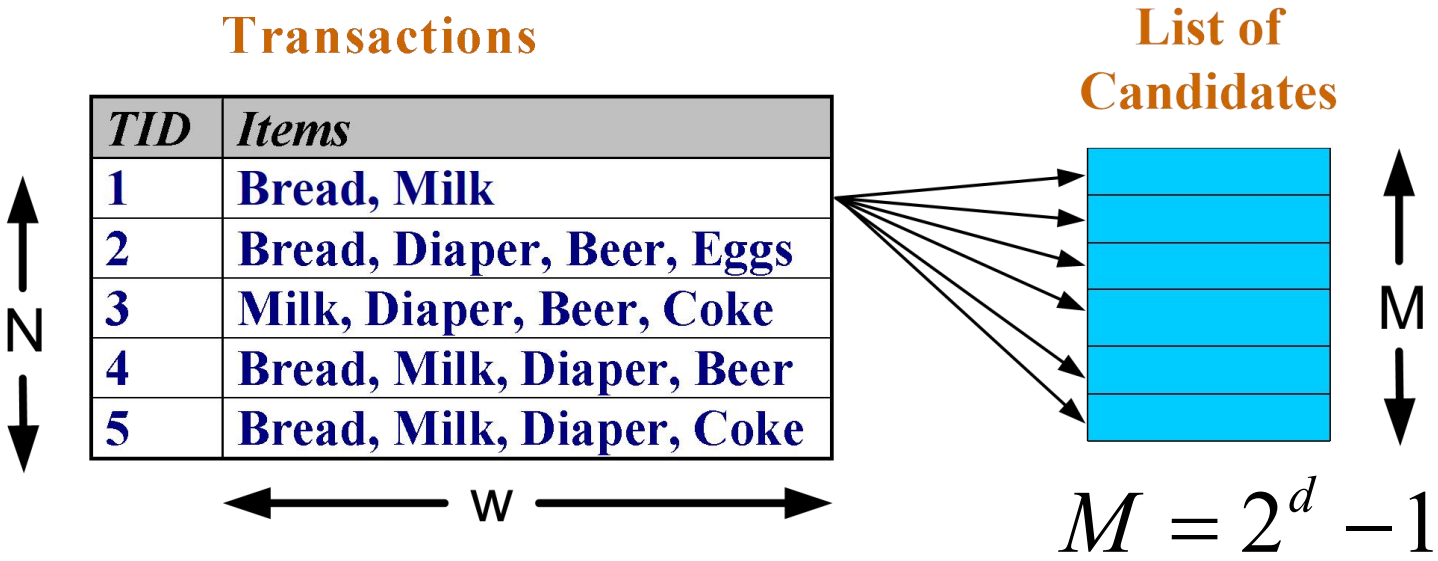

- 时间复杂度 ~ O(*NMW*)，这种方法的开销可能非常大。

4.2.6 Apriori算法复杂性分析

- 支持度阈值
  - 降低支持度阈值通常将导致更多的项集是频繁的，计算复杂度增加
  - 随着支持度阈值的降低，频繁项集的最大长度将增加，导致算法需要扫描数据集的次数也将增多
- 项数
  - 随着项数的增加，需要更多的空间来存储项的支持度计数。如果频繁项集的数目也随着数据项数增加而增长，则由于算法产生的候选项集更多，计算量和I/O开销将增加
- 事务数
  - 由于Apriori算法反复扫描数据集，因此它的运行时间随着事务数增加而增加
- 事务的平均宽度
  - 频繁项集的最大长度随事务平均宽度增加而增加
  - 随着事务宽度的增加，事务中将包含更多的项集，这将增加支持度计数时的遍历次数

4.2.7 Apriori算法优缺点

- Apriori算法的优点：
  - 简单、易理解、数据要求低
- Apriori算法的缺点：
  - 在每一步产生侯选项目集时循环产生的组合过多，没有排除不应该参与组合的元素；
  - 每次计算项集的支持度时，都对数据库D中的全部记录进行了一遍扫描比较，如果是一个大型的数据库的话，这种扫描比较会大大增加计算机系统的I/O开销。而这种代价是随着数据库的记录的增加呈现出几何级数的增加。

4.2.7 Apriori算法优缺点

Apriori算法的瓶颈

- 模式：候选项集——生成——测试
- 主要开销
  - 生成候选项集是高代价的
    - 例如数据库中包含100个项目 $i_1 i_2 ... i_{100}$

      候选项集的数量:

      $$C_{100}^{1} + C_{100}^{2} + ... + C_{100}^{100} = 2^{100}\text{-}1$$
  - 多次重复扫描数据库
- 如何提高生成频繁项集的效率?

4 关联规则

- 4.1概述
- 4.2Apriori算法
- 4.3FP-growth算法
- 4.4推荐算法
- 4.5小结

4.3 FP-growth算法

- 针对Apriori算法的性能瓶颈问题——需要产生大量候选项集和需要重复地扫描数据库。
- 2000年Jiawei Han等人提出了基于FP-树生成频繁项集的FP-growth算法。该算法不同于Apriori算法的“产生-测试”范型，是不生成候选项集的关联规则方法。
- FP-树是一种输入数据的压缩表示，它通过逐个读入事务，并把每个事务映射到FP-树中的一条路径来构造。

Han J, Pei J, Yin Y. Mining frequent patterns without candidate generation[J]. ACM sigmod record, 2000, 29(2): 1-12. (引用次数9724, 2021.9)

Han J, Pei J, Yin Y, et al. Mining frequent patterns without candidate generation: A frequent-pattern tree approach[J]. Data mining and knowledge discovery, 2004, 8(1): 53-87. (引用次数3215, 2021.9)

4.3 FP-growth算法

- FP-growth是一种以自底向上方式探索树，由FP-树产生频繁项集的算法，递归地频繁增长模式，由两个阶段组成：
  - 第一阶段为建立FP-树，即将数据库中的事务构造成一棵FP-树；
  - 第二阶段为挖掘FP-树，即针对FP-树挖掘频繁模式和关联规则。
- 该算法只进行2次数据库扫描且它不使用侯选集，直接压缩数据库成一个频繁模式树，最后通过这棵树生成关联规则。研究表明它比Apriori算法大约快一个数量级。
  - 第一次扫描数据库，得到1维频繁项集；
  - 第二次扫描数据库，利用1维频繁项集过滤数据库中的非频繁项，同时生成FP-树。

4.3 FP-growth算法

定义4.10 FP-树

频繁模式树FP-树是一个树形结构。包括一个频繁项组成的头表，一个标记为“null”的根节点，它的子节点为一个项前缀子树的集合。

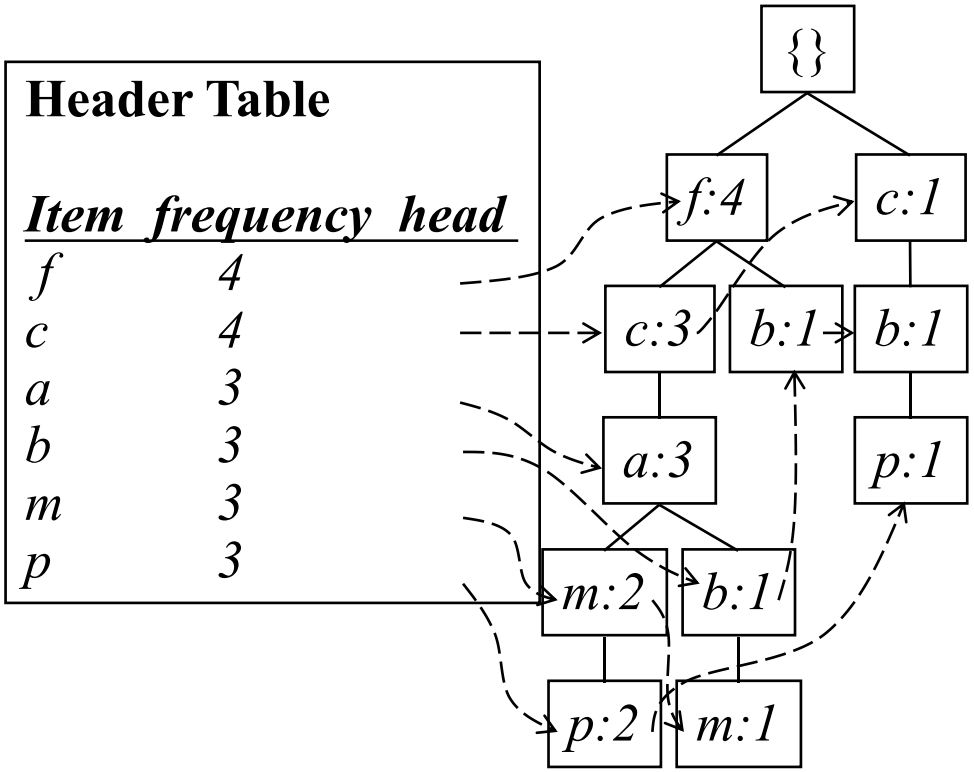

4.3 FP-growth算法

定义4.11 频繁项头表

频繁项头表(Head Table)的每个表项通常由两个域组成：项目名称item-name和指针node_link。node_link指向FP-树中具有与该表项相同item-name的第一个节点。有时也包含每个项目的支持度计数。

定义4.12 项前缀子树

每个项前缀子树(Item Prefix Subtree)的节点有三个域：item-name，count，node_link。item-name记录了该节点所代表的项的名字。count记录了所在路径代表的交易中包含此节点项目的交易个数。node_link指向下一个具有同样的item-name域的节点，要是没有这样一个节点，就为null。

4.3 FP-growth算法

第一阶段：根据一个输入交易记录集建立一棵FP-树。

- 输入：交易记录集D，最小支持度sup_min。
- 输出：FP-树。
  - 扫描数据库D一遍，得到频繁项的集合F和每个频繁项的支持度。把F按支持度递降排序，结果记为L。
  - 创建FP-树的根节点，记为T，并且标记为“null”。
  - 第二次扫描数据库D。每个事务中的项按L中的次序排列，并对每个事务创建分枝。一般地，当为一个事务考虑增加分枝时，沿共同前缀上的每个结点计数增加1，为前缀之后的创建结点和链接。

4.3 FP-growth算法

构造FP-树

min_sup = 2

TID	Items
1	{B,A}
2	{B,D,C}
3	{E,C,D,A}
4	{A,E,D}
5	{C,A,B}
6	{D,B,A,C}
7	{A}
8	{B,A,C}
9	{B,A,D}
10	{B,E,C}

Items	Frequency
A	8
B	7
C	6
D	5
E	3

TID	Items
1	{A,B}
2	{B,C,D}
3	{A,C,D,E}
4	{A,D,E}
5	{A,B,C}
6	{A,B,C,D}
7	{A}
8	{A,B,C}
9	{A,B,D}
10	{B,C,E}

4.3 FP-growth算法

构造FP-树

TID	Items
1	{A,B}
2	{B,C,D}
3	{A,C,D,E}
4	{A,D,E}
5	{A,B,C}
6	{A,B,C,D}
7	{A}
8	{A,B,C}
9	{A,B,D}
10	{B,C,E}

读入事务 TID=1后:

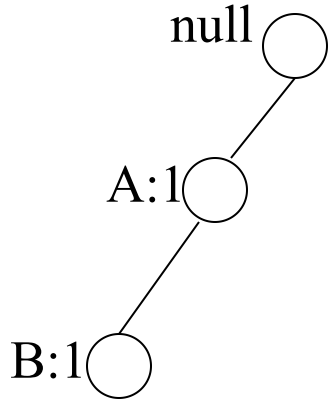

读入事务 TID=2后:

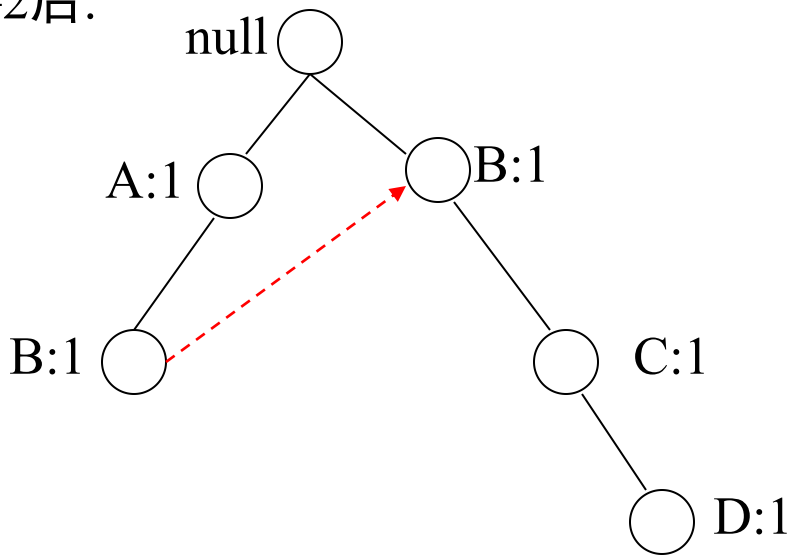

4.3 FP-growth算法

- 第三个事务{A，C，D，E}与第一个事务共享一个共同的前缀项A，所以第三个事务的路径null->A->C->D->E与第一个事务的路径null->A->B部分重叠。因为它们的路径重叠，所以结点A的频度计数增加为2.
- 继续该过程，直到每个事务都映射到FP-树的一条路径。

构造FP-树

TID	Items
1	{A,B}
2	{B,C,D}
3	{A,C,D,E}
4	{A,D,E}
5	{A,B,C}
6	{A,B,C,D}
7	{A}
8	{A,B,C}
9	{A,B,D}
10	{B,C,E}

读入事务 TID=3后:

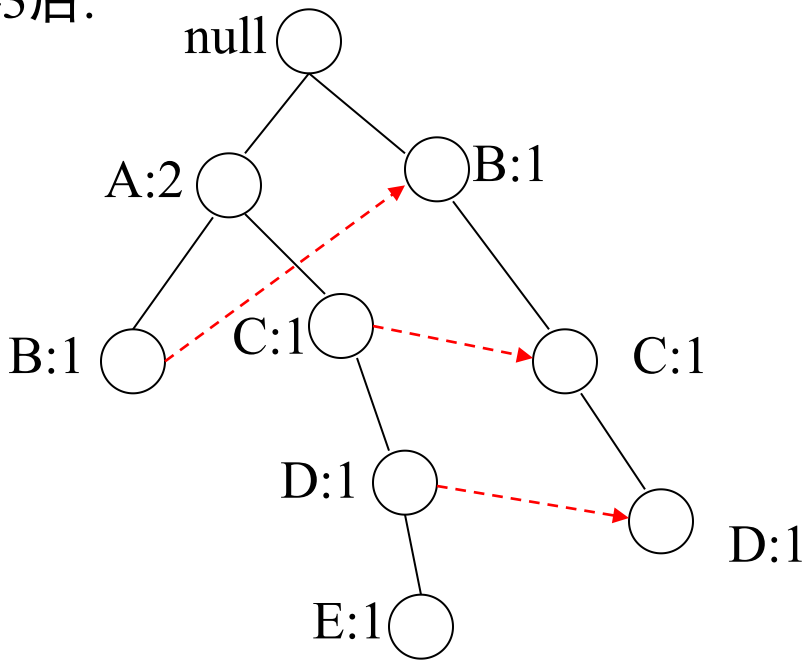

4.3 FP-growth算法

TID	Items
1	{A,B}
2	{B,C,D}
3	{A,C,D,E}
4	{A,D,E}
5	{A,B,C}
6	{A,B,C,D}
7	{A}
8	{A,B,C}
9	{A,B,D}
10	{B,C,E}

构造FP-树

Header Table

Item	frequency	head
A	8	
B	7	
C	6	
D	5	
E	3	

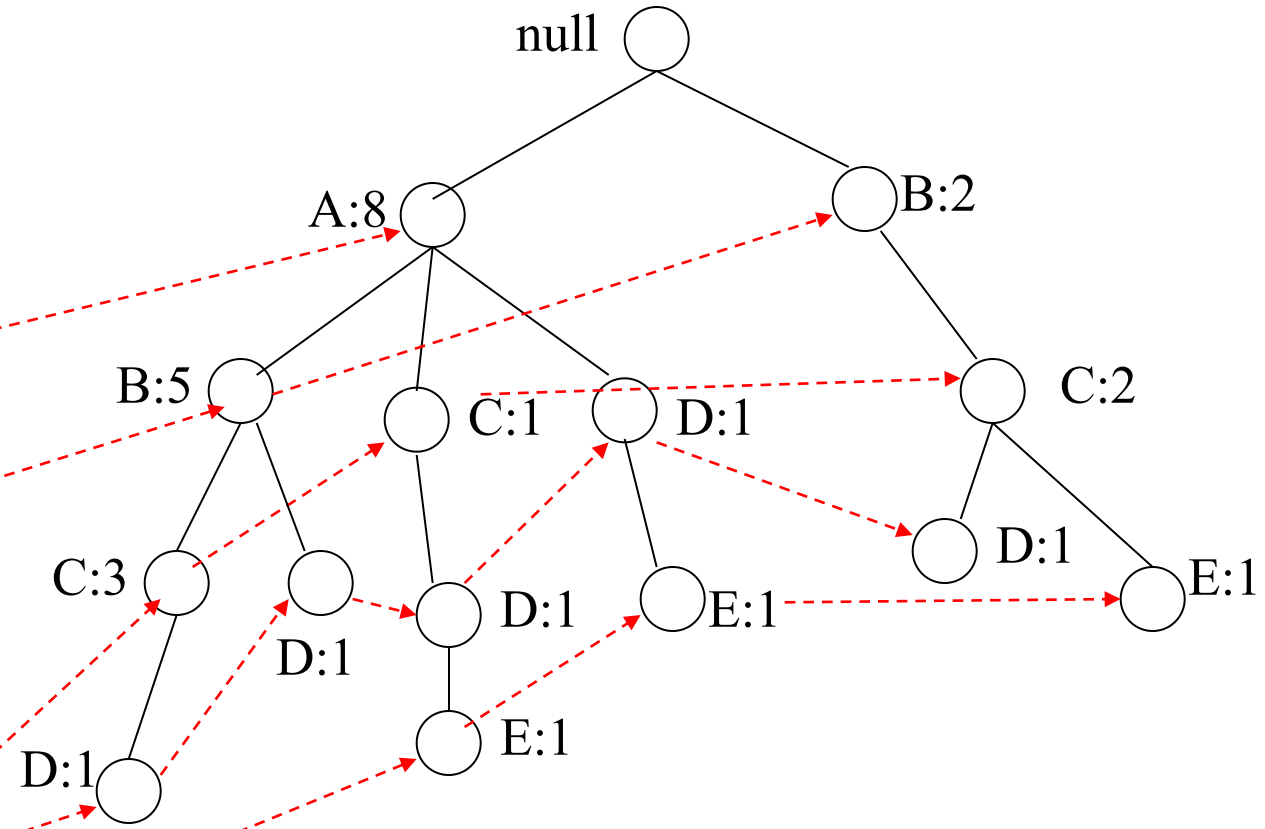

4.3 FP-growth算法

TID	*Items bought*
100	{*f, a, c, d, g, i, m, p*}
200	{*a, b, c, f, l, m, o*}
300	{*b, f, h, j, o, w*}
400	{*b, c, k, s, p*}
500	{*a, f, c, e, l, p, m, n*}

min_sup = 3

4.3 FP-growth算法

由事务数据库构建FP-树

TID	*Items bought*	*(ordered) frequent items*
100	{*f, a, c, d, g, i, m, p*}	{*f, c, a, m, p*}
200	{*a, b, c, f, l, m, o*}	{*f, c, a, b, m*}
300	{*b, f, h, j, o, w*}	{*f, b*}
400	{*b, c, k, s, p*}	{*c, b, p*}
500	{*a, f, c, e, l, p, m, n*}	{*f, c, a, m, p*}

min_sup = 3

1. 扫描DB一次找到频繁1项(单一项模式)
2. 按支持度降序对频繁项排序为 F-list
3. 再次扫描DB，构建FP-树

Header Table

Item	*frequency*	*head*
f	4	
c	4	
a	3	
b	3	
m	3	
p	3	

4.3 FP-growth算法

由事务数据库构建FP-树

TID	*Items bought*	*(ordered) frequent items*
100	{*f, a, c, d, g, i, m, p*}	{*f, c, a, m, p*}
200	{*a, b, c, f, l, m, o*}	{*f, c, a, b, m*}
300	{*b, f, h, j, o, w*}	{*f, b*}
400	{*b, c, k, s, p*}	{*c, b, p*}
500	{*a, f, c, e, l, p, m, n*}	{*f, c, a, m, p*}

min_sup = 3

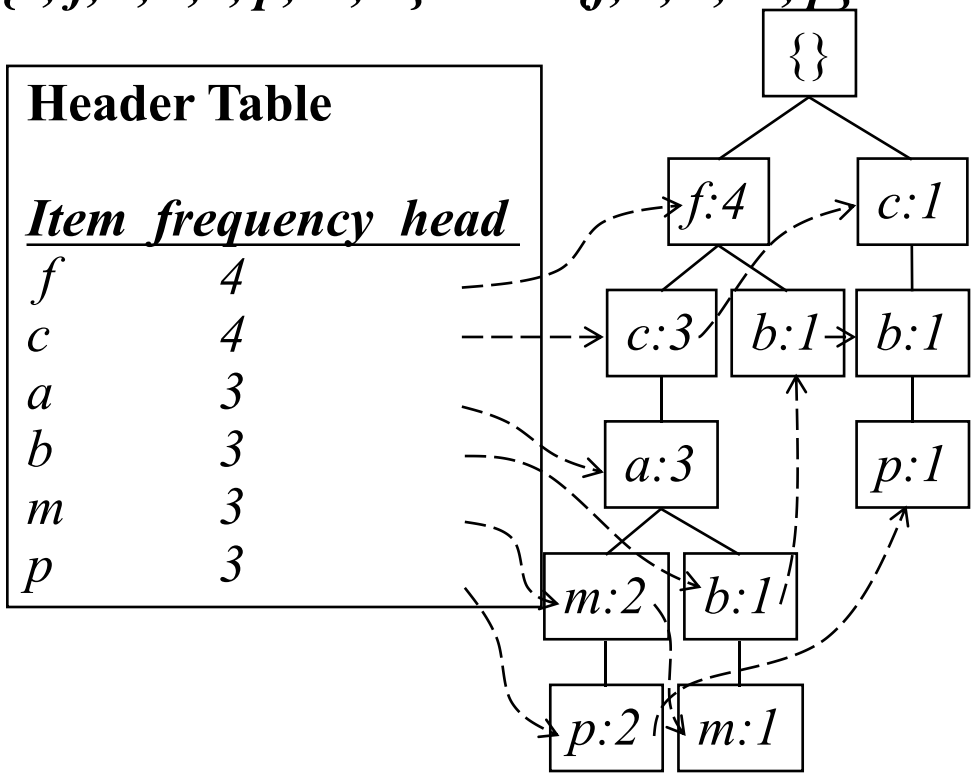

F-list=*f-c-a-b-m-p*

构造FP-树

- 通常，FP-树的大小比未压缩的数据小，因为关联规则的数据中事务常常共享一些共同项。如果共同项较少，FP-树对存储空间的压缩效果将不明显。
- FP-树的大小也依赖于项如何排序。一般按照支持度计数递减序可以导致较小的FP-树。
- FP-树还包含一个连接具有相同项的结点的指针列表。这些指针有助于方便快捷地访问树中的项。

4.3 FP-growth算法

第二阶段为挖掘FP-树

- 输入：FP-树。
- 输出：针对FP-树挖掘频繁模式和关联规则。
- 由于每一个事务都映射到FP-树中的一条路径，因而通过仅考察包含特定结点（例如i）的途径，就可以发现以i结尾的频繁项集。使用与结点i相关联的指针，可以快速访问这些路径。

4.3 FP-growth算法

定义4.13 条件模式基

一个“子数据库”，由FP-树中与该后缀模式一起出现的前缀路径集组成。

定义4.14 条件FP-树

由条件模式基构造的FP-子树

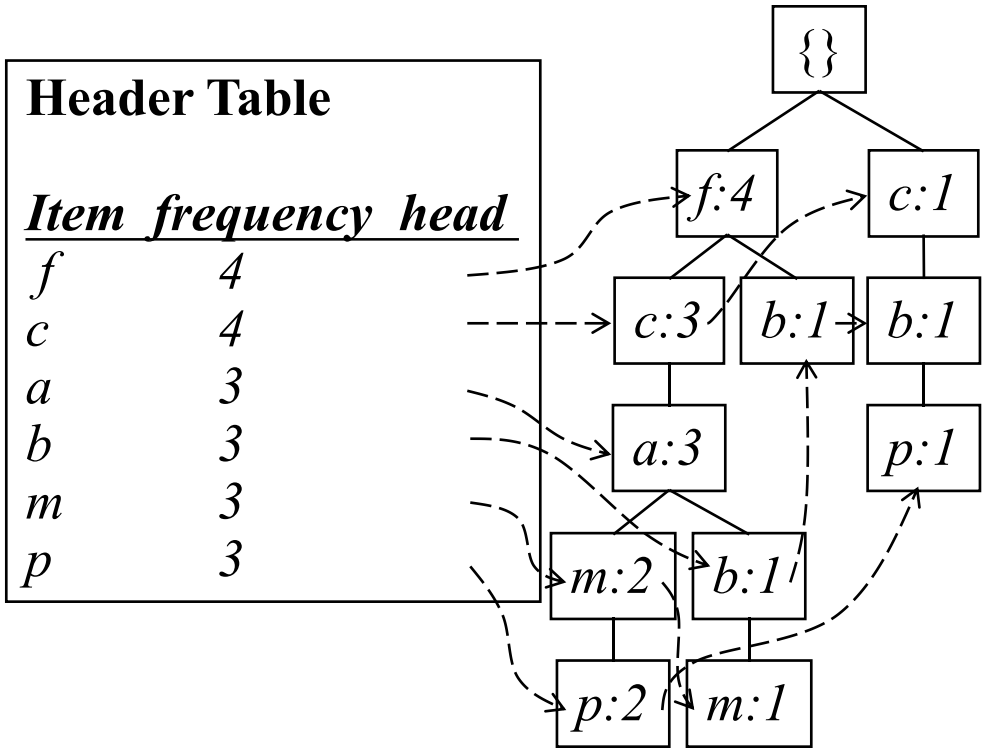

项	条件模式基
c	*f:3*
a	*fc:3*
b	*fca:1, f:1, c:1*
m	*fca:2, fcab:1*
p	*fcam:2, cb:1*

4.3 FP-growth算法

- **Step1**：读取数据库，构造频繁1项集及FP-树
- **Step2**：遍历FP-树的头表，对于每个频繁项i，累积项i的所有前缀路径形成i的条件模式基
- **Step3**：对条件模式基上每一条路径的节点更新计数为i的计数，根据条件模式基构造条件FP-树
- **Step4**：从条件FP-树中找到所有的路径，对该路径上的节点找出所有组合方式，然后合并计数
- **Step5**：将**Step4**中的频繁项集与i合并，得到包含i的频繁项集
- **Step2-5** 循环，直到遍历头表中的所有项

4.3 FP-growth算法

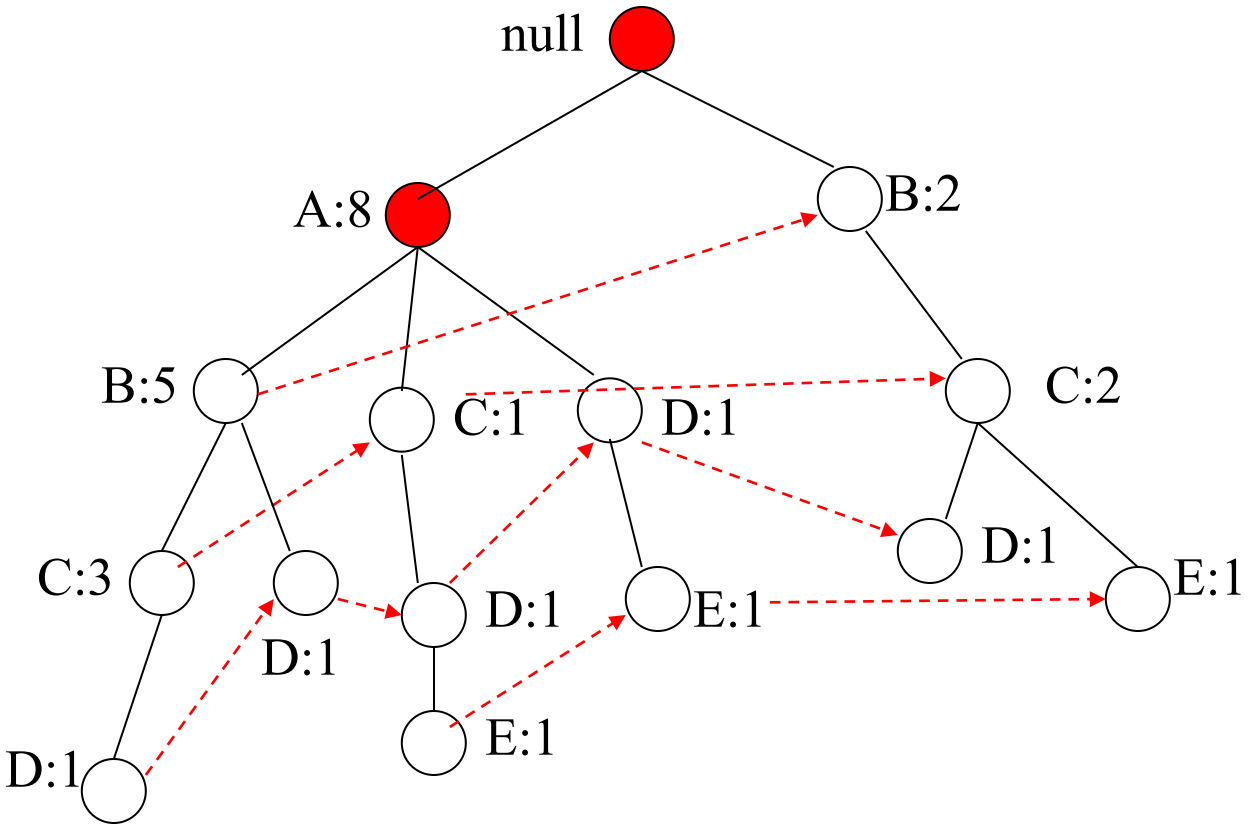

{A}

4.3 FP-growth算法

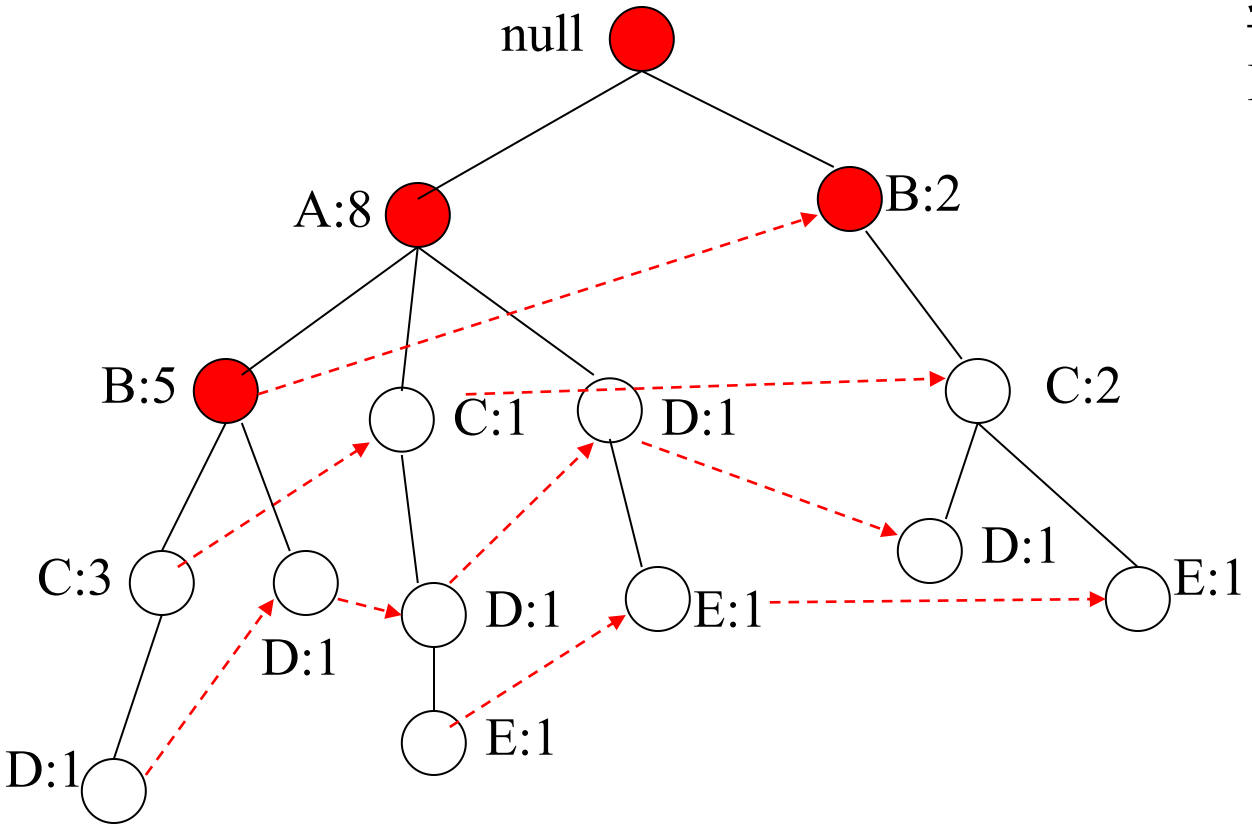

项	条件模式基
B	**A:5**

{B},{A,B}

4.3 FP-growth算法

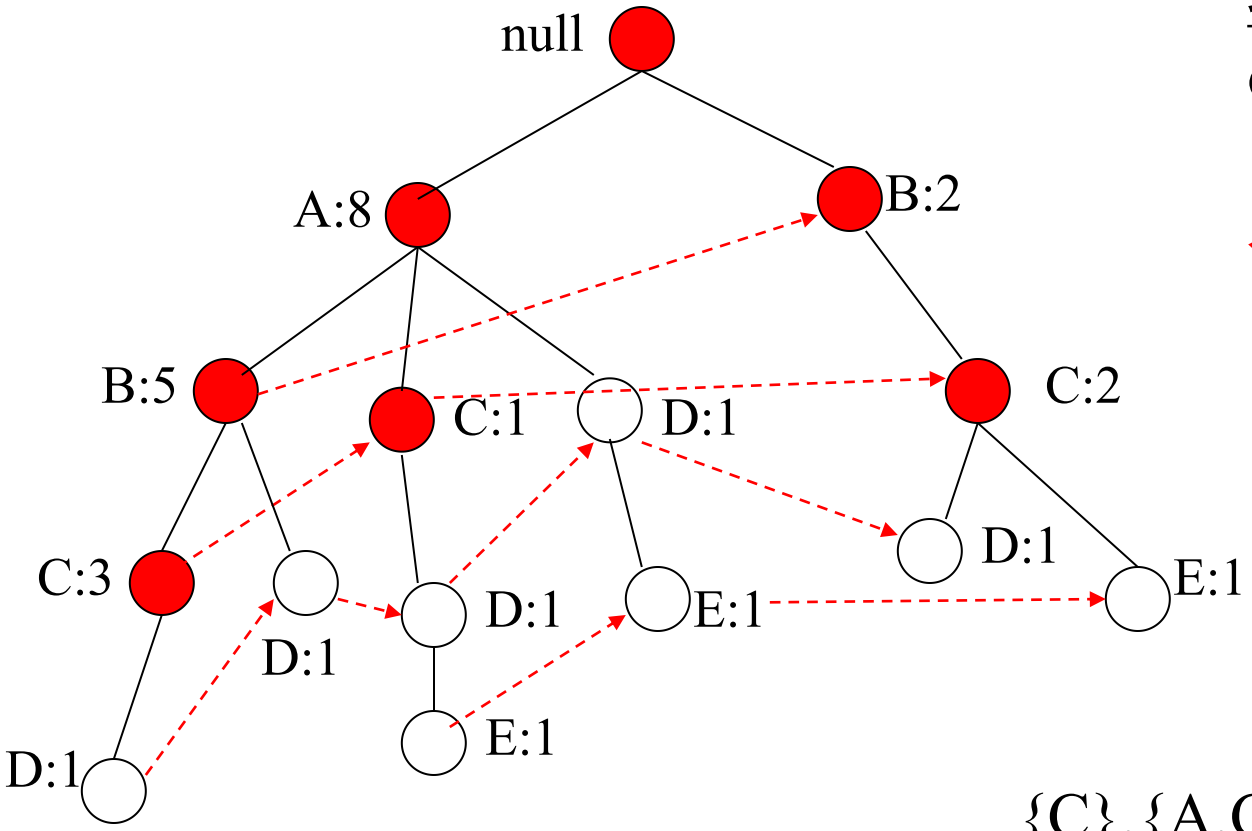

项	条件模式基
C	AB:3,A:1,B:2

合并计数 A:4,B:5,AB:3

{C},{A,C},{B,C},{A,B,C}

4.3 FP-growth算法

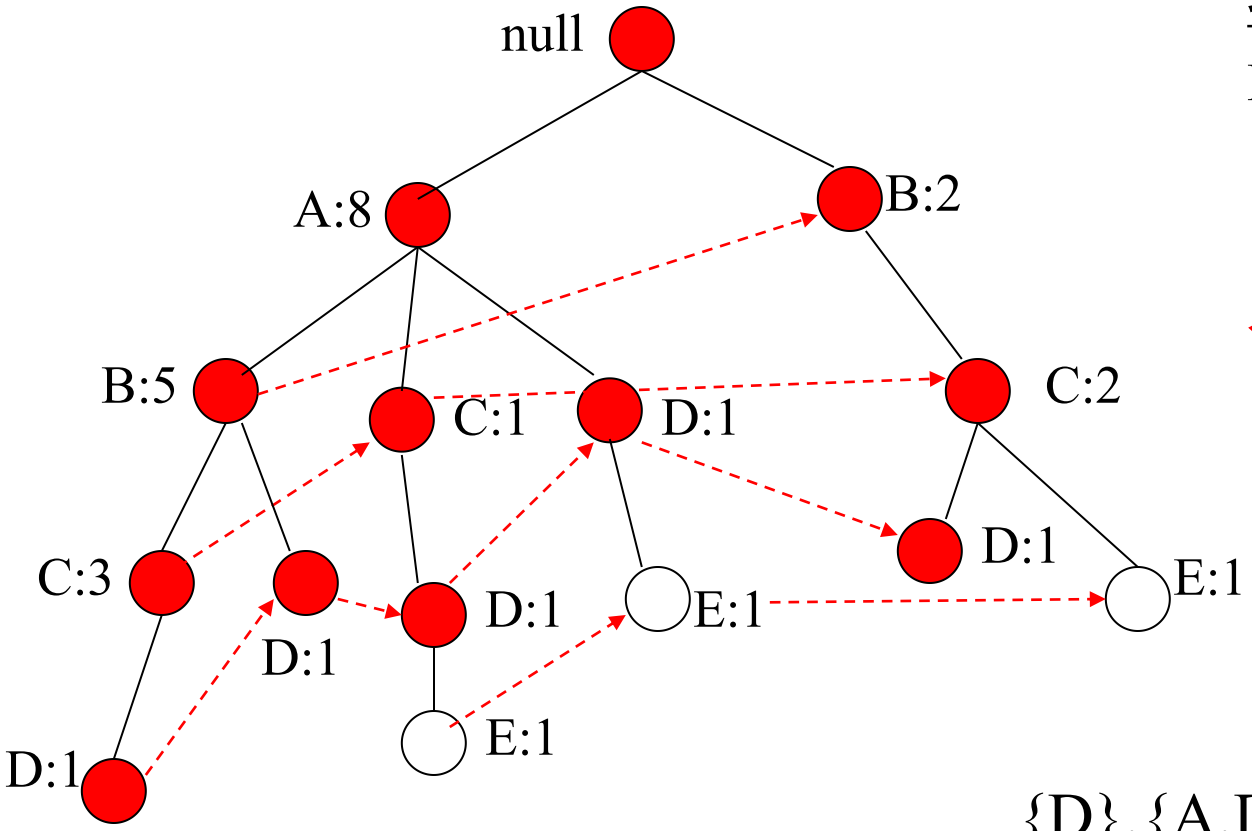

项	条件模式基
D	ABC:1, AB:1, AC:1,A:1,BC:1

合并计数 A:4,B:3,C:3 AB:2,AC:2,BC:2

{D},{A,D},{B,D},{C,D},
{A,B,D},{A,C,D},{B,C,D}

4.3 FP-growth算法

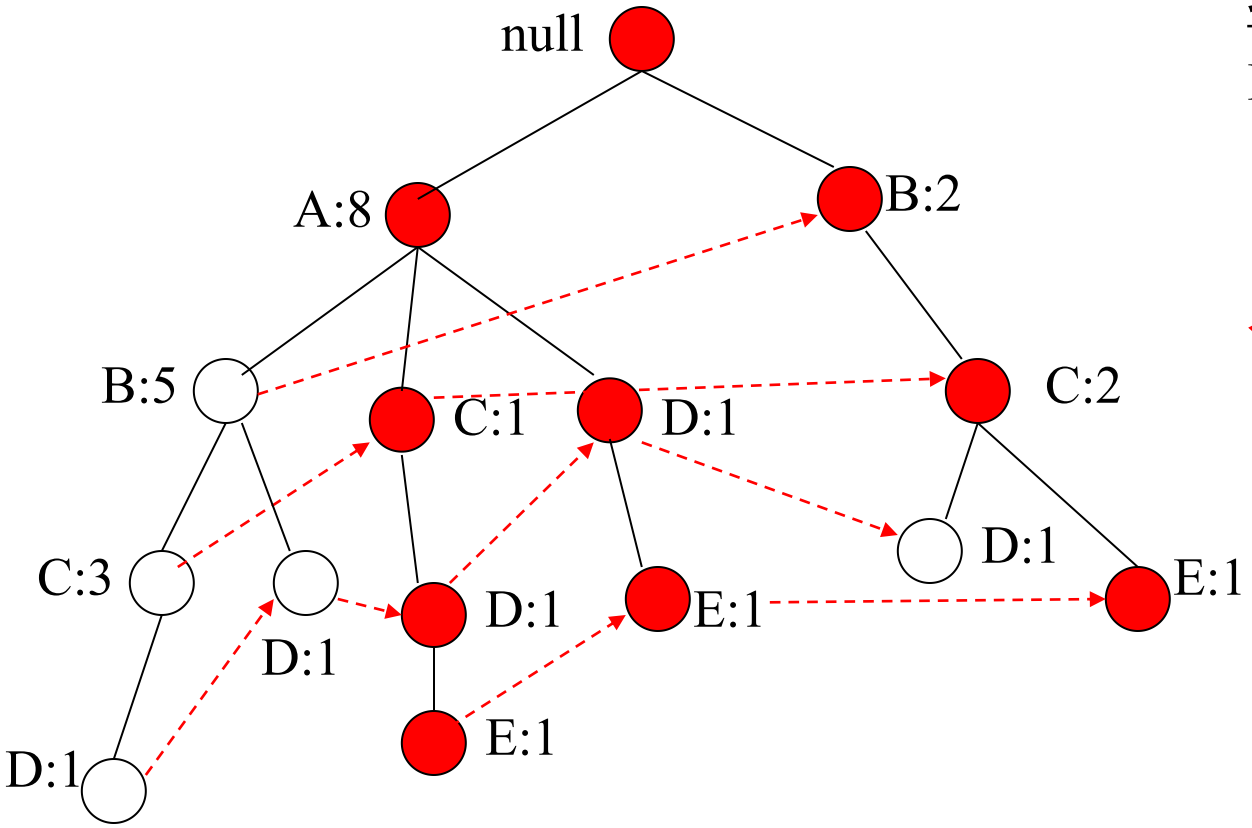

项	条件模式基
E	ACD:1,AD:1
	BC:1

合并计数 A:2,C:2,D:2

AD:2

{E},{A,E},{C,E},{D,E},{A,D,E}

4.3 FP-growth算法

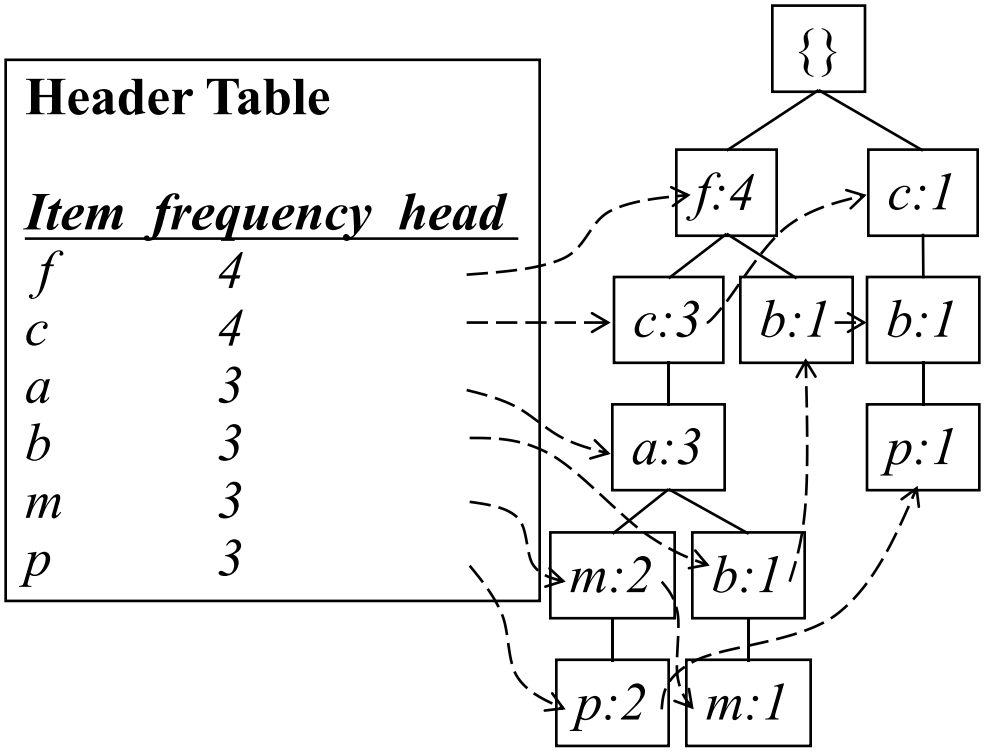

项	条件模式基
c	*f:3*
a	*fc:3*
b	*fca:1, f:1, c:1*
m	*fca:2, fcab:1*
p	*fcam:2, cb:1*

FP-树 结构的优点

- 完整性
  - 保持了频繁项集挖掘的完整信息
- 紧密性
  - 减少不相关的信息，去掉了非频繁的项
  - 项按支持度降序排列：越频繁出现，越可能被共享
  - 不会比原数据库更大 (不计结点链接和计数域)

FP-growth 与 Apriori的比较

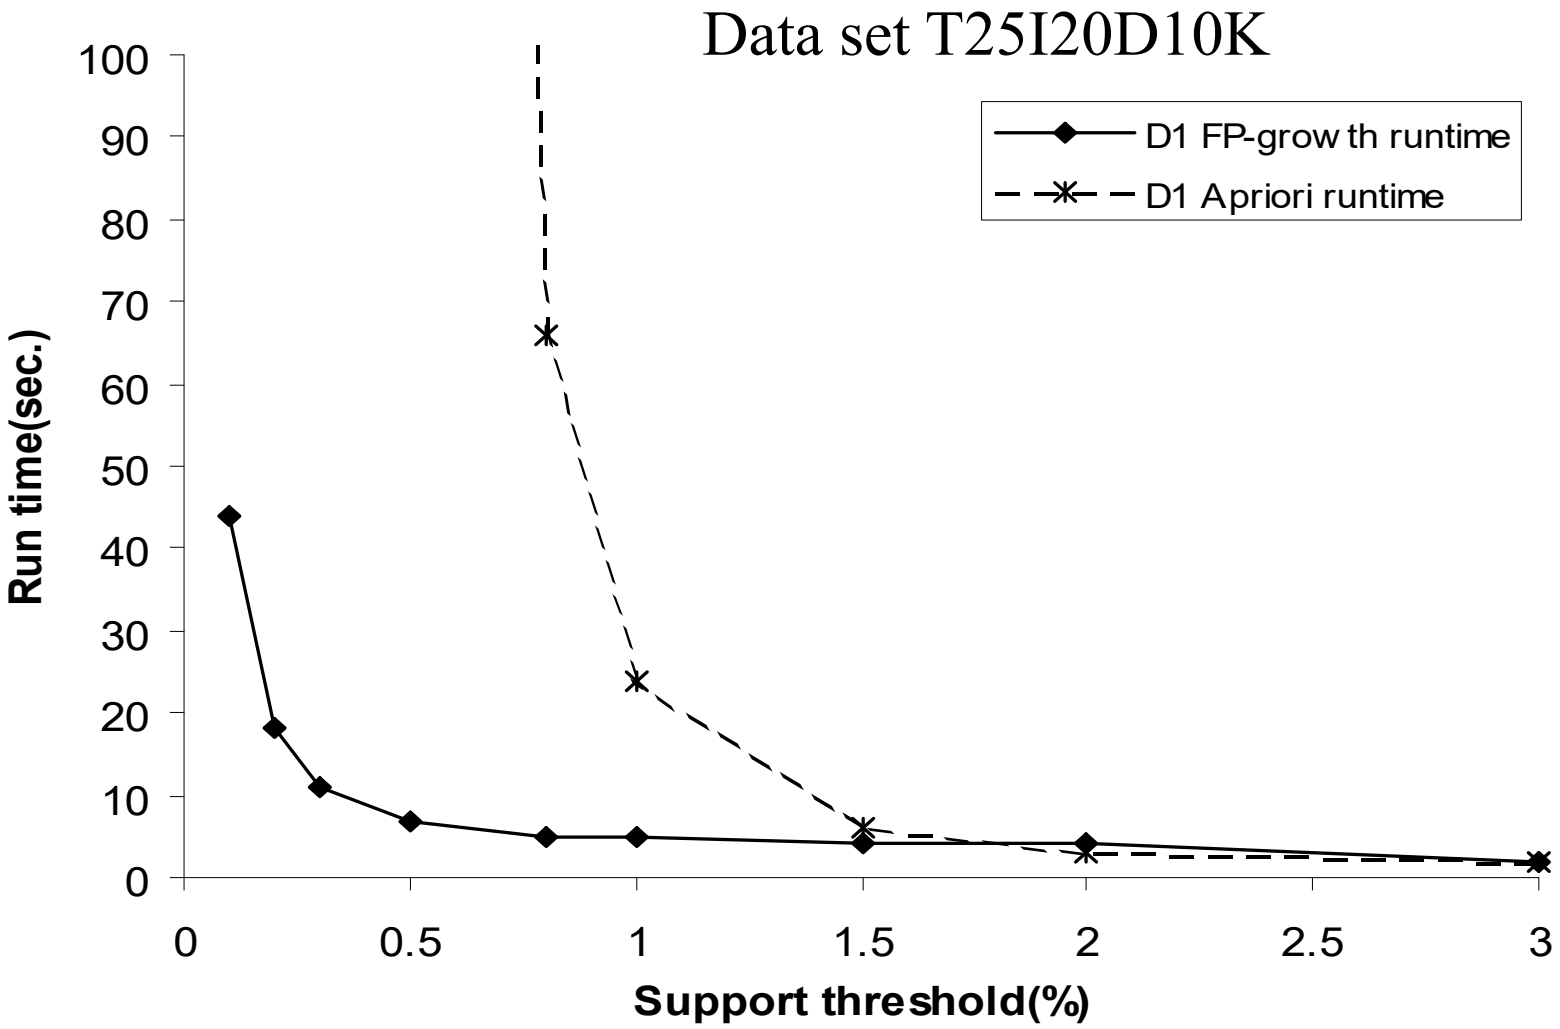

4 关联规则

- 4.1概述
- 4.2Apriori算法
- 4.3FP-growth算法
- 4.4推荐算法
- 4.5小结

4.4 推荐算法

图书 > 政治/军事 > 中国政治 > 中共中央党校出版社 > 习近平的七年知青岁月
习近平的七年知青岁月
单品团购100册以上可致电4006186622
中央党校采访实录编辑室 著
京 东 价 ¥ 49.40 [6.5折] [定价 ¥76.00] 降价通知
增值业务 助力环保，传递知识，旧书换新
配 送 至 天津南开区广开街道 有货
京东物流 京准达 | 211限时达 | 预约送货
由 京东 发货，并提供售后服务. 23:00前下单，预计明天(09月28日)送达
重 量 0.775kg
服务支持 放心购 上门换新 | 破损包退换 | 闪电退款
可配送全球49元免基础运费
选择系列
习近平四省足迹系列
习近平强军思想学习问答（32开）
习近平生态文明思想学习纲要32开
习近平强军思想学习问答
习近平福建足迹
习近平浙江足迹
习近平正定足迹
习近平生态文明思想学习纲要16开
习近平上海足迹
关注
举报
企业批量购书

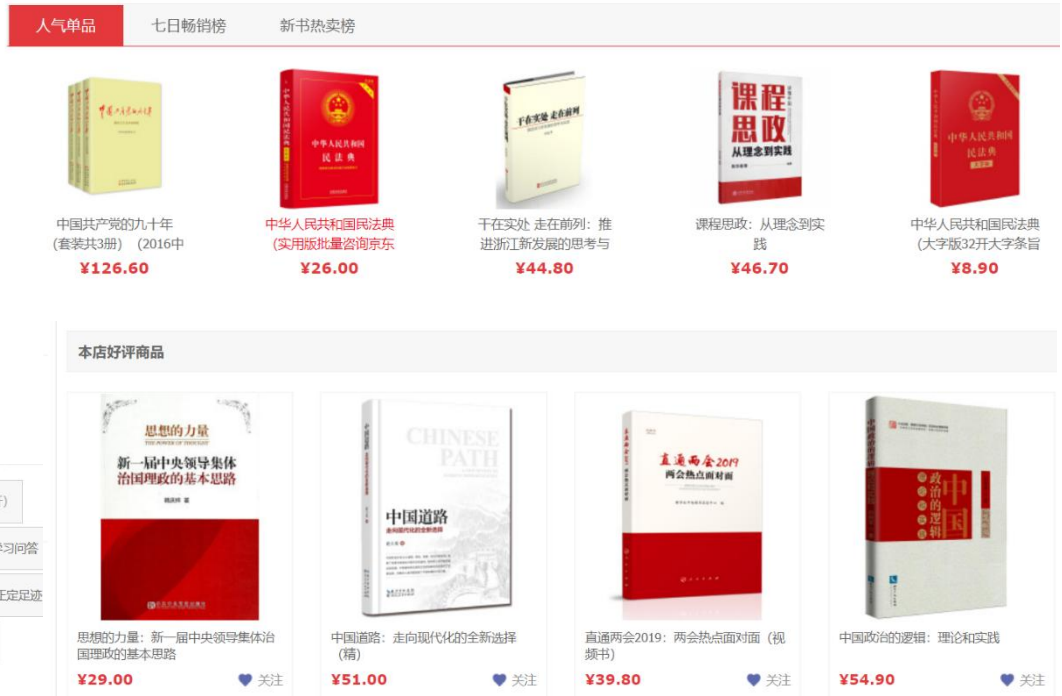
人气单品
七日畅销榜
新书热卖榜
中国共产党的九十年（套装共3册）（2016中
¥126.60
中华人民共和国民法典（实用版批量咨询京东
¥26.00
干在实处 走在前列：推进浙江新发展的思考与
¥44.80
课程思政：从理念到实践
¥46.70
中华人民共和国民法典（大字版32开大字条旨
¥8.90
本店好评商品
思想的力量：新一届中央领导集体治国理政的基本思路
¥29.00 关注
中国道路：走向现代化的全新选择（精）
¥51.00 关注
直通两会2019：两会热点面对面（视频书）
¥39.80 关注
中国政治的逻辑：理论和实践
¥54.90 关注

猜你喜欢
深度学习推荐系统
¥107.80
数据挖掘
¥58.80
深入浅出数据分析
¥87.80
时间序列分析
¥91.00
¥156.40
无人驾驶
¥51.70

4.4 推荐算法

电商

与您浏览过的商品相关的推荐

浏览此商品的顾客也同时浏览

浏览此商品的顾客也同时浏览

4.4 推荐算法

Why：为什么要做推荐？

4.4 推荐算法

长尾挖掘

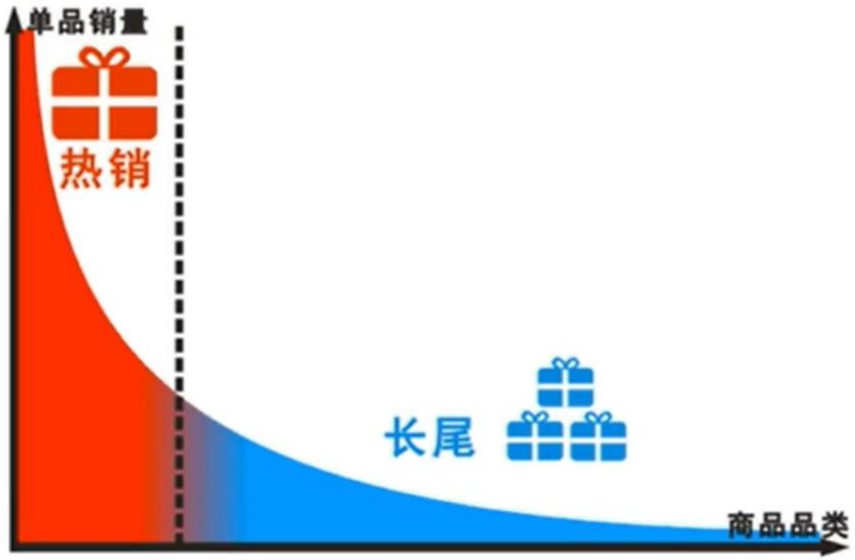

- 实例
  - 商品、服务、广告
- 原因
  - 高斯分布 VS 长尾分布
- 问题
  - 如何找到匹配的长尾商品
- 价值
  - 用户：找到自己想要的商品
  - 平台：提升长尾商品价值

4.4 推荐算法

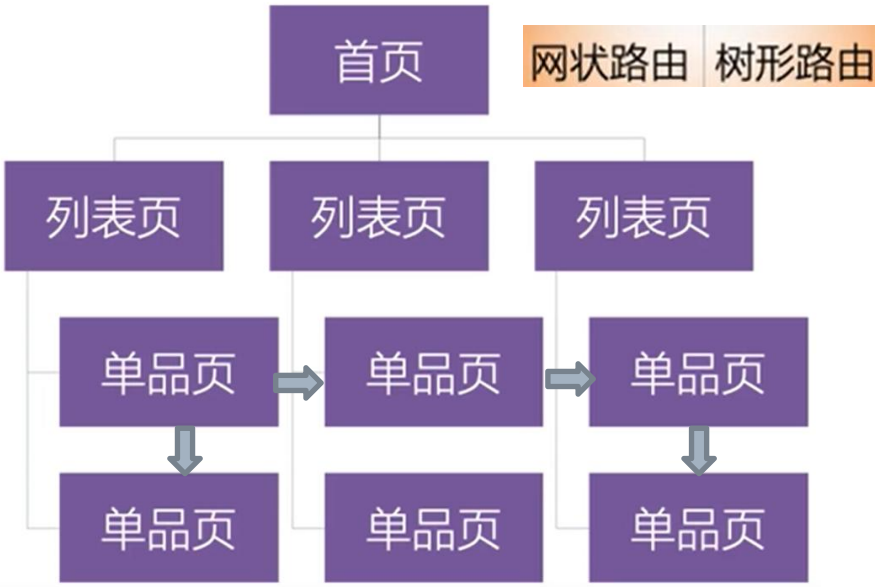
首页
网状路由
树形路由
列表页
列表页
列表页
单品页
单品页
单品页
单品页
单品页
单品页

宝贵的
•外部成本
•内部成本
不确定的
•用户意图
差异化的
•整体用户群
•到达具体页面/位置的用户
稀疏的
•差异化的另一面
•每一"种"用户的数量

人气单品
七日畅销榜
新书热卖榜
MongoDB权威指南 第3版（图灵出品）
¥102.50
剑指大数据——企业级数据仓库项目实战（电商
¥167.80
精益数据分析（图灵出品）
¥60.20
SQL必知必会 第5版(图灵出品)
¥32.90
SQL从入门到精通（微课视频版） sql基础教程进
¥79.80
白话统计(博文视点出品)
¥68.80
人民邮电出版社京东自
进店逛逛
关注店铺
相关分类
辅助设计与工程
网络与通信
办公软件
软件工程及软件
电子商务
计算机安全
计算机控制与仿
IT人文/互联网
编程语言与程序
信息系统
移动开发
大数据与云计算
专用软件
单片机与嵌入式
数据库
新手学电脑
商品介绍
规格与包装
售后保障
商品评价(500+)
本店好评商品
加入购物车
出版社：人民邮电出版社
品牌：iTuring
出版时间：2020-12-01
ISBN：9787115241009
包装：平装
用纸：胶版纸
版次：2
丛书名：图灵计算机科学丛书
页数：463
商品编码：12918545
开本：16开
正文语种：中文
编辑推荐
《数据挖掘导论（完整版）》介绍了数据挖掘，涵盖了五个主题：数据、分类、关联分析、聚类和异常检测。除异常检测外，每个主题具有两章。前一章涵盖基本概念、代表性算法和评估技术，而后一章讨论概念和算法。这样读者在透彻地理解数据挖掘的基础的同时，还能够了解更多重要的主题。《数据挖掘导论（完整版）》是明尼苏达大学和密歇根州立大学数据挖掘课程的教材，由于独具特色，正式出版之前已经被斯坦福大学、得克萨斯大学奥斯汀分校等众多名校采用。《数据挖掘导论（完整版）》特色与许多其他同类图书不同，《数据挖掘导论（完整版）》将重点放在如何用数据挖掘知识解决各种实际问题。
编辑推荐
内容简介
作者简介
目录

用户体验

缩短购物流程

提高"命中率"

给用户惊喜

4.4 推荐算法

	1	2	3	4	5	6
A	4	3			5	
B	5		4		4	
C	4		5	3	4	
D		3				5
E		4				4
F			2	4		5

4.4 推荐算法

技术发展脉络

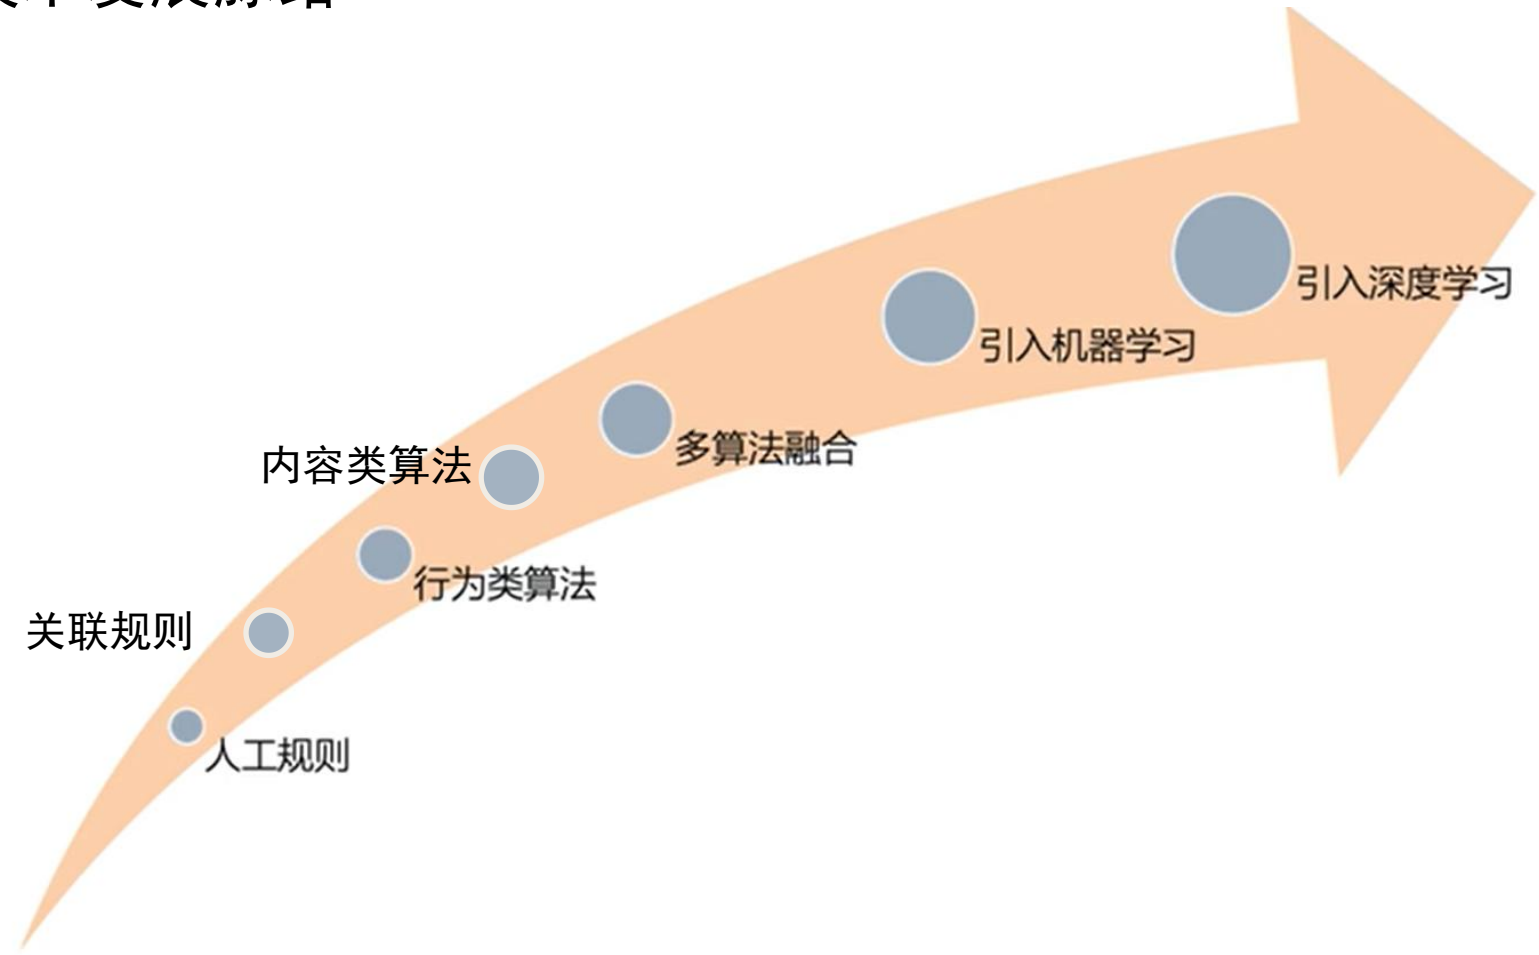

4.4.1 基于流行度的推荐算法

- 比较简单粗暴，主要是对热点商品或者信息的推荐。例如利用分享率、点击量、得票数等数据来按某种热度排序来推荐给用户。
- 优点：简单，适用于刚注册的新用户，能够解决对新用户进行推荐的冷启动问题。
- 缺点：分数是人为设计的，并且无法针对用户提供个性化的推荐。算法可做一些优化，比如加入用户分群的流行度排序，例如把热榜上的体育内容优先推荐给体育迷，把政要热文推给热爱谈论政治的用户。

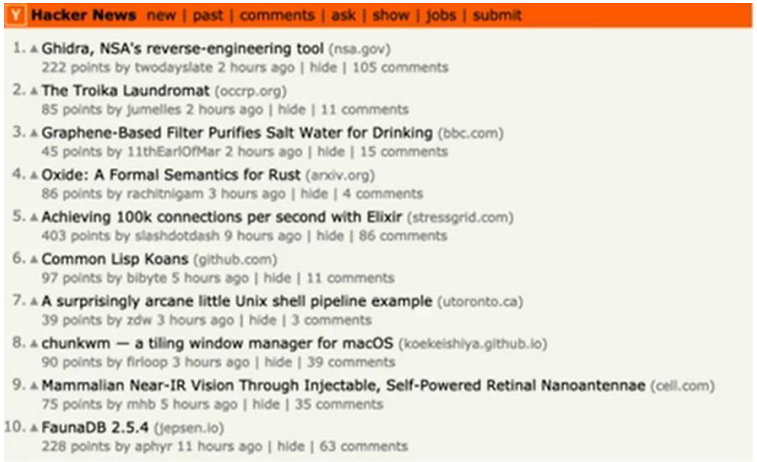

- $\text{score} = \frac{P-1}{(T+2)^G}$
- P：帖子得票数
- T：帖子发布时间
- G：超参数，控制衰减速度

4.4.2 基于关联规则的推荐算法

- 首要目标是挖掘出关联规则，同时被很多用户购买的物品集合，这些集合内的物品可以相互进行推荐。目前关联规则挖掘算法主要从Apriori和FP-Growth两个算法发展演变而来。 基于关联规则的推荐系统一般转化率较高，因为当用户已经购买了频繁集合中的若干项目后，购买该频繁集合中其他项目的可能性更高。
- 缺点：
  - 计算量较大，但是可以离线计算，因此影响不大。
  - 由于采用用户数据，不可避免的存在冷启动和稀疏性问题。
  - 存在热门项目容易被过度推荐的问题。

4.4.3 基于协同过滤的推荐算法

- 协同过滤是一种广泛采用的推荐方法。基于“物以类聚，人以群分”的假设，喜欢相同物品的用户更有可能具有相同的兴趣。
- 一般应用于有用户评分的系统之中，通过分数去刻画用户对于物品的喜好。协同过滤被视为利用集体智慧的典范，不需要对项目进行特殊处理，而是通过用户建立物品与物品之间的联系。
- 主要有两种类型：基于用户(User-based)的推荐和基于物品(Item-based)的推荐。

4.4.3 基于协同过滤的推荐算法

- 基于用户的协同过滤算法：“人以群分”，找到与用户兴趣相同的用户（有过类似的行为），将兴趣相同的用户浏览过物品推荐给用户。
- 基于物品的协同过滤推荐算法：“物以类聚”，如果有很多用户都对某两个物品有相似的偏好，说明这两个物品是“相似”的，通过推荐与用户喜欢过的相似的物品这种方式为用户提供个性化推荐。

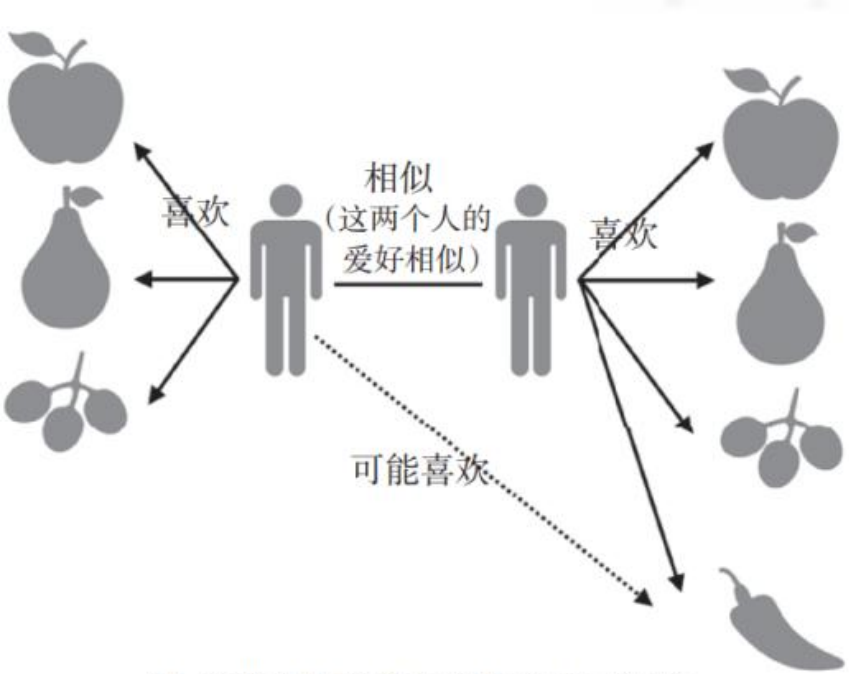

“人以群分”的基于用户的协同过滤

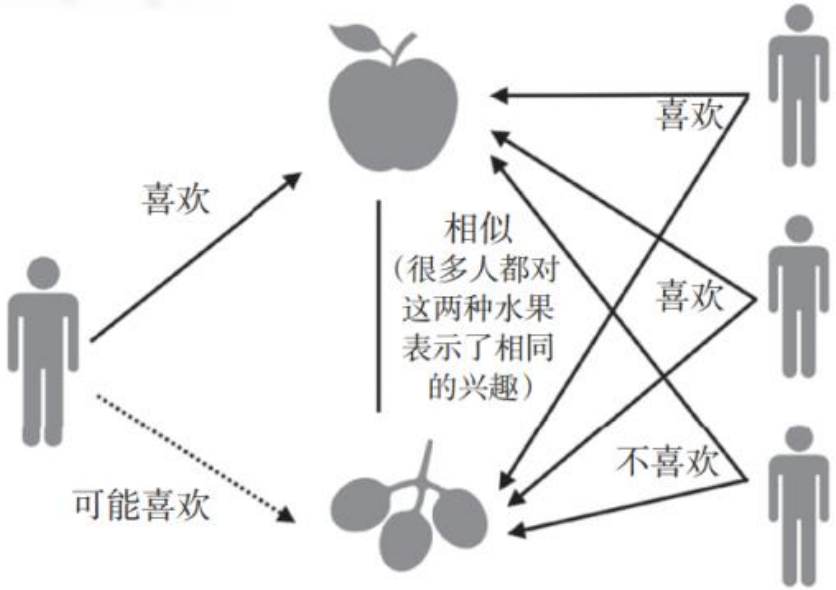

“物以类聚”的基于物品的协同过滤

4.4.3.1 基于用户的推荐算法

	1	2	3	4	5	6
A		4	3			5	
B		5		4		4	
C		4		5	3	4	
D			3				5
E			4				4
F				2	4		5

计算每两个用户间的相似度

4.4.3.1 基于用户的推荐算法

- 根据所有用户对物品或者信息偏好（评分），发现与当前用户口味和偏好相似的“邻居”用户群，在一般应用中是采用计算K近邻的算法；基于这 K个邻居的历史偏好信息，为当前用户进行推荐。
- 优点在于推荐物品之间在内容上可能完全不相关，因此可以发现用户的潜在兴趣，并且针对每个用户生成其个性化的推荐结果。
- 缺点在于一般的Web系统中，用户的增长速度都远远大于物品的增长速度，因此其计算量的增长巨大，系统性能容易成为瓶颈。因此在业界中单纯的使用基于用户的协同过滤系统较少。

4.4.3.1 基于用户的推荐算法

- 基于用户(User-based)的推荐
  - 将用户向量化表示
  - u:[1,1,0,1,…]，每个维度表示一个物品
- 使用向量空间模型(VSM)计算基础相关性

$$sim(u_i, u_j) = \cos\left(\theta_{\{u_i,u_j\}}\right) = \frac{u_i.u_j}{|u_i||u_j|}$$

- 利用基础相关性+用户原始行为计算最终推荐结果

$$rel(user_i, item_j) = \sum_k sim(user_i, user_k) rate(user_k, item_j)$$

4.4.3.1 基于用户的推荐算法

- 是否需要计算每两个用户之间的相似度?
  - 不需要，大量用户间相关性可预判为0
  - [1,2,0]*[0,0,3]，结果必然为0
  - 通过倒排表实现高效筛选
- 是否需要使用一个用户的全部相关用户来计算?
  - 不需要，相关性影响衰减非常快，只需取TopK就可
  - 在哪里去除?用户相关性计算阶段
- 没有rate怎么办?
  - implicit feedback :点击、浏览、购买.....

4.4.3.2 基于物品的推荐算法

- 使用所有用户对物品或者信息的偏好（评分），发现物品和物品之间的相似度，根据用户的历史偏好信息，将类似的物品推荐给用户。
- 可以看作是关联规则推荐的一种退化，但由于协同过滤更多考虑了用户的实际评分，并且只是计算相似度而非寻找频繁集，可以认为基于物品的协同过滤准确率较高并且覆盖率更高。
- 同基于用户的推荐相比，基于物品的推荐应用更为广泛，扩展性和算法性能更好。由于项目的增长速度一般较为平缓，因此性能变化不大。缺点就是无法提供个性化的推荐结果。

4.4.3.2 基于物品的推荐算法

4.4.3.2 基于物品的推荐算法

- 基于物品(Item-based)的推荐
  - 将物品向量化表示
  - *item*:[1,1,0,1,…]，每个维度表示一个用户
- 使用向量空间模型(VSM)计算基础相关性

$$sim(item_i, item_j) = \cos\left(\theta_{\{item_i, item_j\}}\right) = \frac{item_i . item_j}{|item_i||item_j|}$$

- 利用基础相关性+用户原始行为计算最终推荐结果

$$rel(user_i, item_j) = \sum_k sim(item_k, item_j) rate(user_i, item_k)$$

4.4.3.2 基于物品的推荐算法

	1	2	3	4	5	6
1		0.27	0.79	0.32	0.99	0
2	0.27					
3	0.79					
4	0.32					
5	0.99					
6	0					

4.4.3 基于协同过滤的推荐算法

基于用户	基于物品
结果群体化、扩展化	结果个性化、精准化
适用于用户量相对小于物品量的场景，例如新闻推荐系统	适用于物品量相对小于用户量的场景，例如电商平台
对用户新行为敏感度低	对用户新行为敏感度高
对物品新行为敏感度高	对物品新行为敏感度低
推荐理由说服力较弱	推荐理由说服力较强

4.4.3 基于协同过滤的推荐算法

- 优点：
  - 不需要对物品或者用户进行严格的建模，而且不要求物品的描述是机器可以理解的，所以这种方法也是领域无关的。
  - 计算出来的推荐是开放的，可以共用他人的经验，很好地支持用户发现潜在的兴趣偏好。
- 缺点：
  - 核心是基于历史数据，对新物品和新用户都有“冷启动”的问题。
  - 推荐的效果依赖于用户历史偏好数据的多少和准确性。
  - 在大部分的实现中，用户历史偏好是用稀疏矩阵进行存储的，而稀疏矩阵上的计算有些明显的问题，包括可能少部分人的错误偏好会对推荐的准确度有很大的影响等等。
  - 对于一些特殊品味的用户不能给予很好的推荐。
  - 由于以历史数据为基础，抓取和建模用户的偏好后，很难利用获取的用户偏好演变，从而导致这个方法不够灵活。

4.4.4 基于内容的推荐算法

- 多用于一些资讯类的应用上，针对文章（电影音乐）本身抽取一些tag作为该其关键词，继而可以通过这些tag来评价两篇文章的相似度。
- 优点： 易于实现，不需要用户数据因此不存在稀疏性和冷启动问题。 基于物品本身特征推荐，因此不存在过度推荐热门的问题。
- 缺点：
  - 抽取的特征既要保证准确性又要具有一定的实际意义，否则很难保证推荐结果的相关性。豆瓣网采用人工维护tag的策略，依靠用户去维护内容的tag的准确性。
  - 推荐的Item可能会重复，典型的就是新闻推荐，如果你看了一则津云上的新闻，很可能推荐的新闻和你浏览过的，内容一致。

4.4.4 基于内容的推荐算法

Term Frequency (TF)

$$tf(t,d) = \frac{n_{t,d}}{\sum_k n_{k,d}}$$

Inverse Document Frequency (IDF)

$$idf(t,\ D) = \log \frac{|D|}{|\{d \in D: t \in d\}|}$$

TF-IDF

$$tf(t,d)^*\ idf(t,\ D)$$

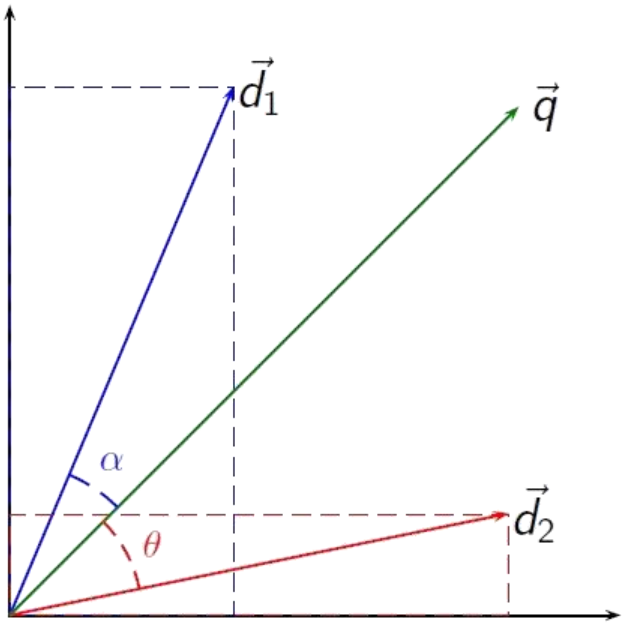

- 把文本表示成一个向量
- 余弦相似度Cosine Similarity

$$sim(p,q) = cos(\theta) = \frac{p \cdot q}{|p| \cdot |q|}$$

4.4.5 基于模型的推荐算法

- 前述方法的缺点
  - 启发式，无明确目标
  - 相对静态，反应慢
  - 考虑维度较少，个性化程度不足
  - 纯手工，改进空间小
- 机器学习的优点
  - 对齐明确目标，成熟的优化方法
  - 时效性灵活，反映可快可慢
  - 特征维度丰富，个性化程度细腻
  - 理论储备丰富，发展空间大

4.4.5 基于模型的推荐算法

基于模型的方法有很多，主要是使用常用的机器学习算法对目标用户建立推荐算法模型，然后对用户的爱好进行预测推荐以及对推荐的结果打分排序等。

- 常用的浅层模型包括LR，GBDT、特征组合等方法
- 半深度模型包括FM、FFM
- 深度模型包括Wide & Deep、embedding、LSTM、ESMM、TDM等

4.4.5 基于模型的推荐算法

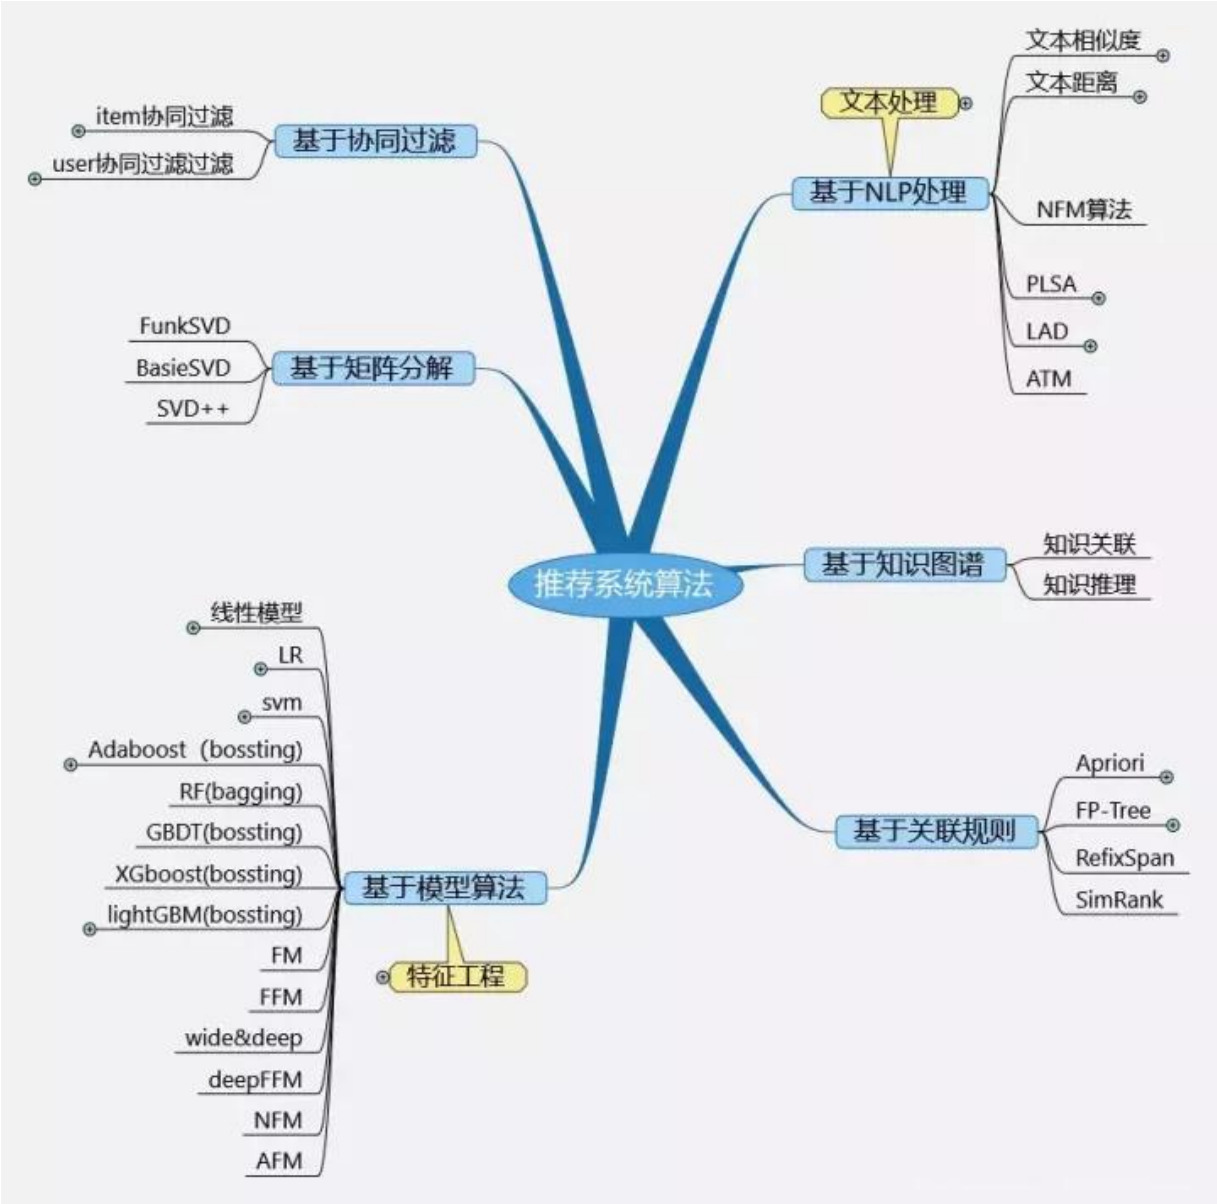

4.4.5 基于模型的推荐算法

nature machine intelligence

Article

https://doi.org/10.1038/s42256-023-00731-4

Human–AI adaptive dynamics drives the emergence of information cocoons

Received: 30 March 2023

Accepted: 6 September 2023

Jinghua Piao[1,3], Jiazhen Liu[1,3], Fang Zhang[2], Jun Su[2] & Yong Li[1]

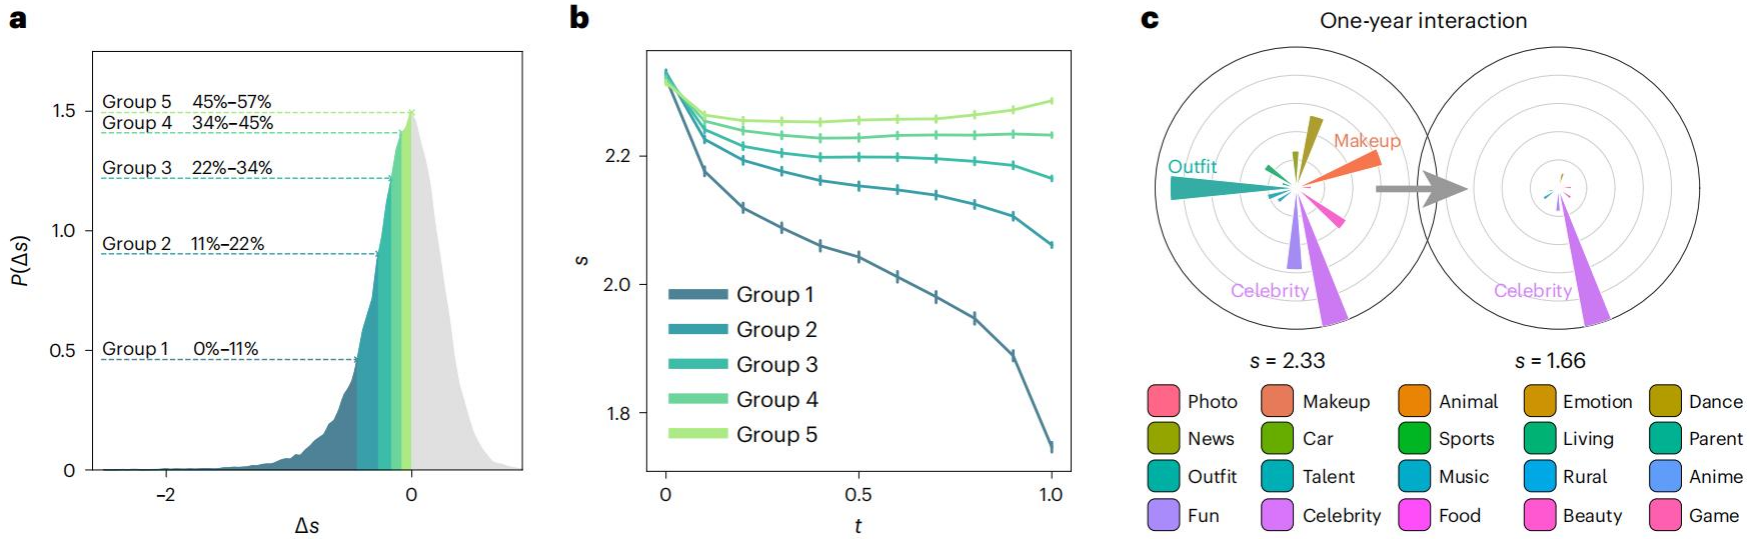

4.4.5 基于模型的推荐算法

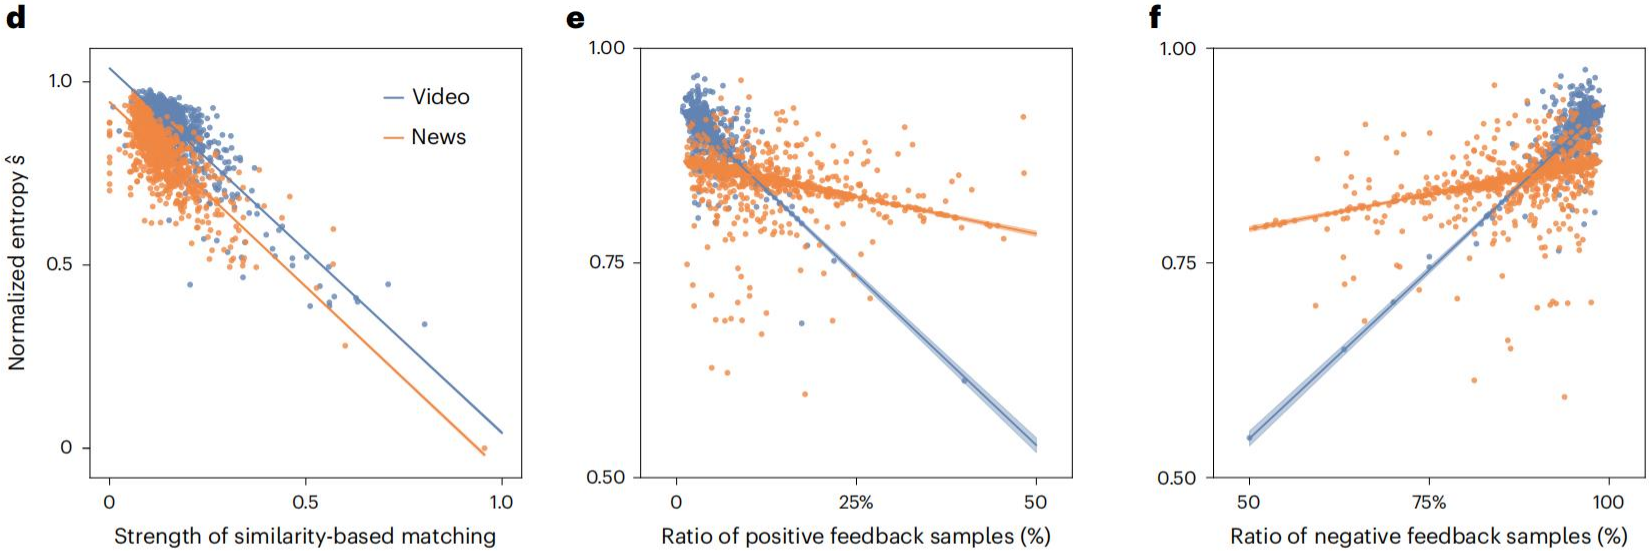

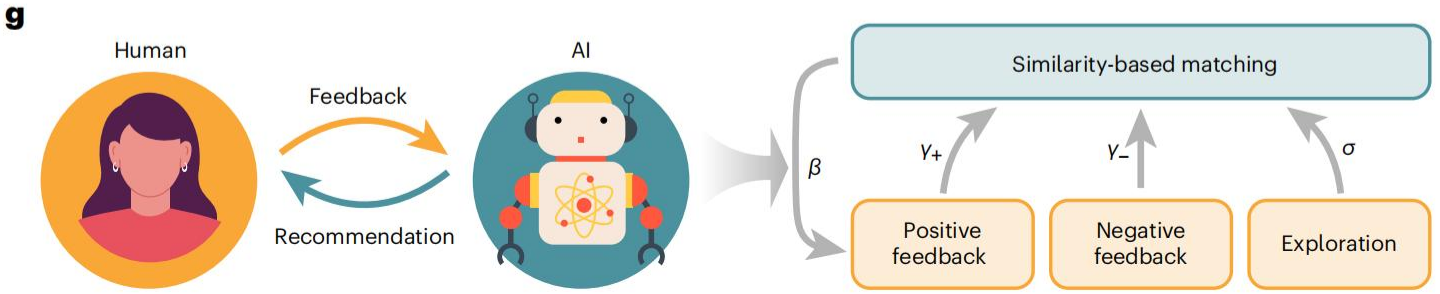

动态的人机交互过程

4.4.6 基于图的推荐算法

随机游走/图排序	PersonalRank, ItemRank, SimRank, RWR	图上的概率传播
图嵌入	DeepWalk, node2vec, LINE, metapath2vec	节点低维向量化
同构 GNN	GCN, GraphSAGE, GAT, PinSage, NGCF, LightGCN	邻域消息聚合
异构图 GNN	HetGNN, HAN, MAGNN, RGCN, HGT	元路径/关系聚合
知识图谱 GNN	RippleNet, MKR, KGCN, KGAT, KGIN	知识图谱增强
社交图 GNN	GraphRec, DiffNet, SocialGCN, MHCN	社交影响传播
会话图 GNN	SR-GNN, GGNN, TAGNN, LESSR	会话序列图建模
图对比学习	SGL, SimGCL, XSimGCL, NCL	自监督对比
图 Transformer/LLM	GraphGPT, LLaGA, GPT4Rec	大模型+图
联邦图推荐	FedPerGNN, FedGraphNN	隐私保护协同训练

从浅层图嵌入走向深度 GNN，从同构二部图走向异构图/知识图谱，从集中式走向联邦与隐私保护，从监督学习走向自监督与对比学习，并开始与大语言模型融合。

4.4.6 基于图的推荐算法

nature communications

Explore content | About the journal | Publish with us

nature > nature communications > articles > article

Article | Open access | Published: 02 June 2022

A federated graph neural network framework for privacy-preserving personalization

Chuhan Wu, Fangzhao Wu, Lingjuan Lyu, Tao Qi, Yongfeng Huang & Xing Xie

Nature Communications **13**, Article number: 3091 (2022) | Cite this article

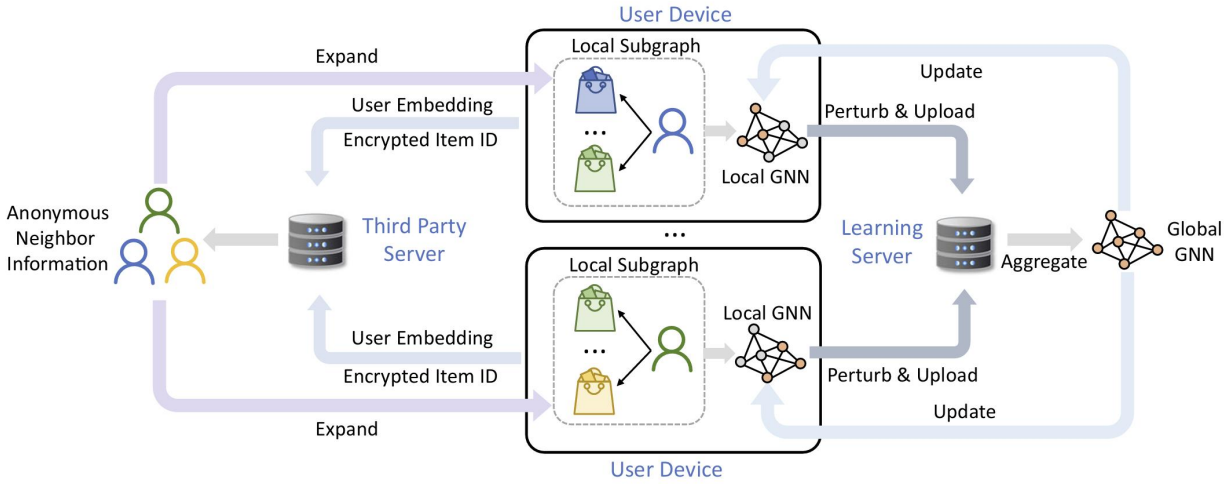

4.4.7 基于大模型的推荐算法

- 多用于大规模、动态兴趣和复杂用户行为的推荐场景，通过 Transformer、生成模型或大语言模型对用户历史行为、物品信息和上下文进行统一建模，并直接生成用户可能感兴趣的 Item 或 Item Token，而不是传统的候选集评分和排序。

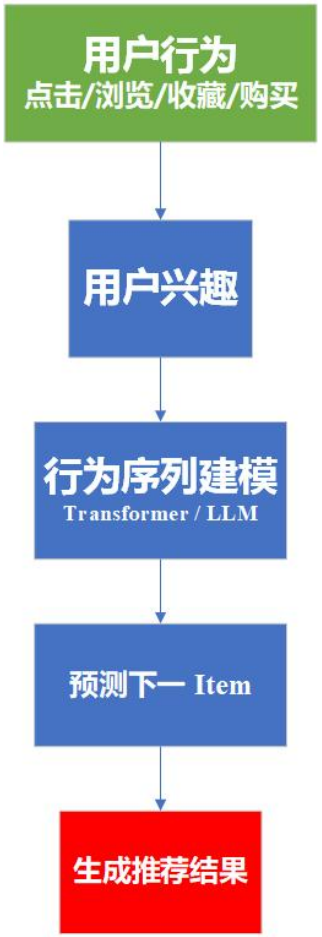

收集点击、浏览、收藏、购买等历史行为

从历史行为中分析用户当前关注的内容

学习“先看什么、后看什么”的行为规律

根据已有行为预测用户下一步可能感兴趣的内容

输出电影、新闻、商品、音乐等个性化内容

4.4.7 基于大模型的推荐算法

范式	核心机制	代表性方法	核心优势	主要挑战
判别式	LLM作为特征编码器	LLMEmb, CEILLM	实现简单，增强现有模型	未充分利用LLM推理能力
生成式	推荐即文本生成	P5, TALLRec, RecLM-cgen	统一框架，可解释性强	幻觉，推理延迟
RAG	检索+生成	CFRAG	引入外部知识，缓解幻觉	检索质量依赖
图/多模态	LLM+结构化/多模态信息	KGGLM, Molar	融合知识图谱与视觉信号	模态对齐复杂
智能体	LLM作为Agent大脑	自主工具学习Agent	多轮交互，主动规划	工程复杂，延迟高

当前趋势是混合与融合：判别式方法为生成式提供高质量的语义表示，RAG为生成式注入实时知识，图结构为LLM补充结构化推理能力。

4.4.7 基于大模型的推荐算法

- 优点：
  - 能够直接建模用户行为序列，捕捉用户兴趣随时间的变化；
  - 可以利用文本、标签等丰富的语义信息；
  - 推荐过程从传统的候选集排序转变为生成推荐结果，能够减少对人工设计特征和候选集的依赖。
- 缺点：
  - 模型结构复杂，训练和推理成本较高；
  - 对于推荐结果的准确性和可控性仍然需要进一步约束。

- 典型方法： Transformer-based Sequential Recommendation、Generative Retrieval、LLM-based Recommendation。

4 关联规则

- 4.1概述
- 4.2Apriori算法
- 4.3FP-growth算法
- 4.4推荐算法
- 4.5小结

4.5 小结

- 经典算法
  - Apriori
  - FP-growth算法
- 推荐算法
  - 基于协同过滤的算法
  - 基于模型的算法
  - 基于图的算法
  - 基于大模型的算法

天津大学
Tianjin University

THE END