天津大学
Tianjin University

数据挖掘

王煜

人工智能学院

wang.yu@tju.edu.cn



回顾

第4章 频繁模式挖掘

- Apriori算法
- FP-growth算法

第 5 章　分类

5 分类

- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.6 评估
- 5.7 长尾分布建模

5.1.1 有监督与无监督

- 有监督：

用于分类或者回归，需要有训练集和测试集。

在已知训练集的前提下，对测试样本根据它的特征，把它与训练集中的样本进行对比，把它分到对应的那类中。



- 无监督：

用于聚类



有一堆数据，将这堆数据按照它们自身内部的相似性，自动地聚成几类。

5.1.2 分类

图像分类示例





苹果







香蕉

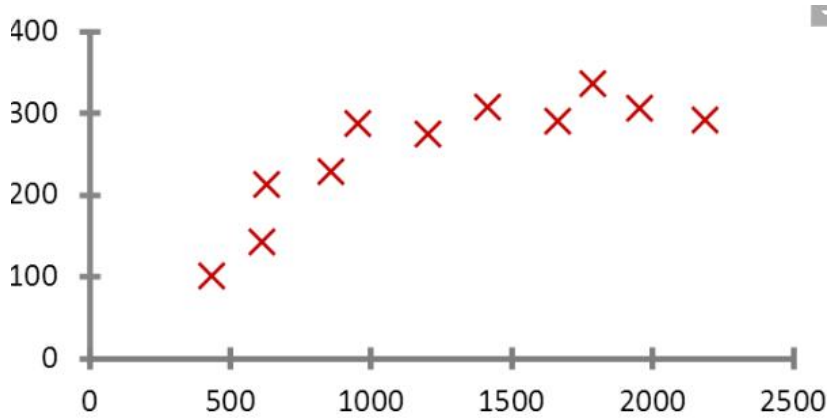
5.1.3 回归

- “回归”一词是1855年由英国生物学家高尔顿（Galton）在研究孩子的身高与他们父母身高关系时提出的。
- 当时他正研究这样一个问题：高个子人生的子女一般偏高，照这样看，各代人在身高分布上将有两级分化的趋势，个子很高和很矮的会越来越多，而处在中间状态的会越来越少。
- 研究发现，父母个子高，其子代一般也高，但不如父母那么高；父母个子矮，其子代一般也矮，但不如父母那么矮。下一代身高有向中间值回归的趋势。这种趋于中间值的趋势被称为“回归效应”，而他提出的这种研究两个数值变量关系的方法称作回归分析。

5.1.3 回归

- 属于有监督学习范畴
- 回归问题的目标是给定D维输入变量x，并且每一个输入矢量x都有对应的值y，要求对于新来的数据预测它对应的连续的目标值t。
- 房屋估值问题
- 股票预测
- 风速预报





5.1.4 分类 VS. 回归

- 分类和回归是两种数据分析形式，用于提取描述重要数据类或预测未来的数据趋势的模型
  - 分类：
    - 预测类对象的分类标号（或离散值）
    - 根据训练数据集和类标号属性，构建模型来分类现有数据，并用来分类新数据
    - 银行贷款员需要分析数据，来弄清哪些贷款申请者是安全的，哪些是有风险的（将贷款申请者分为“安全”和“有风险”两类）
  - 回归：
    - 建立连续函数值模型
    - 比如预测空缺值，或者预测顾客在计算机设备上的花费
    - 银行贷款员需要预测贷给某个顾客多少钱是安全的

5.1.5 聚类

图像聚类








5.1.5 聚类

图像聚类



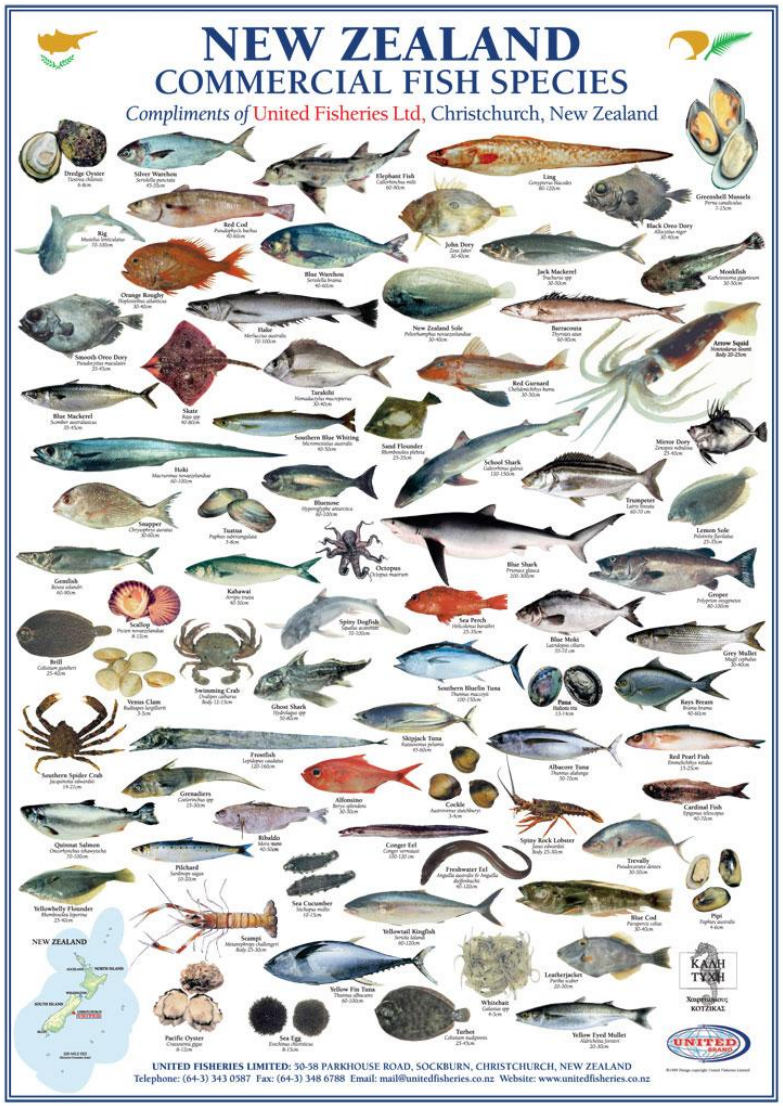


5 分类

- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.5 评估
- 5.6 长尾分布建模

5.2分类的应用案例

“物以类聚，人以群分”，在自然科学和社会科学中，存在着大量的分类问题。







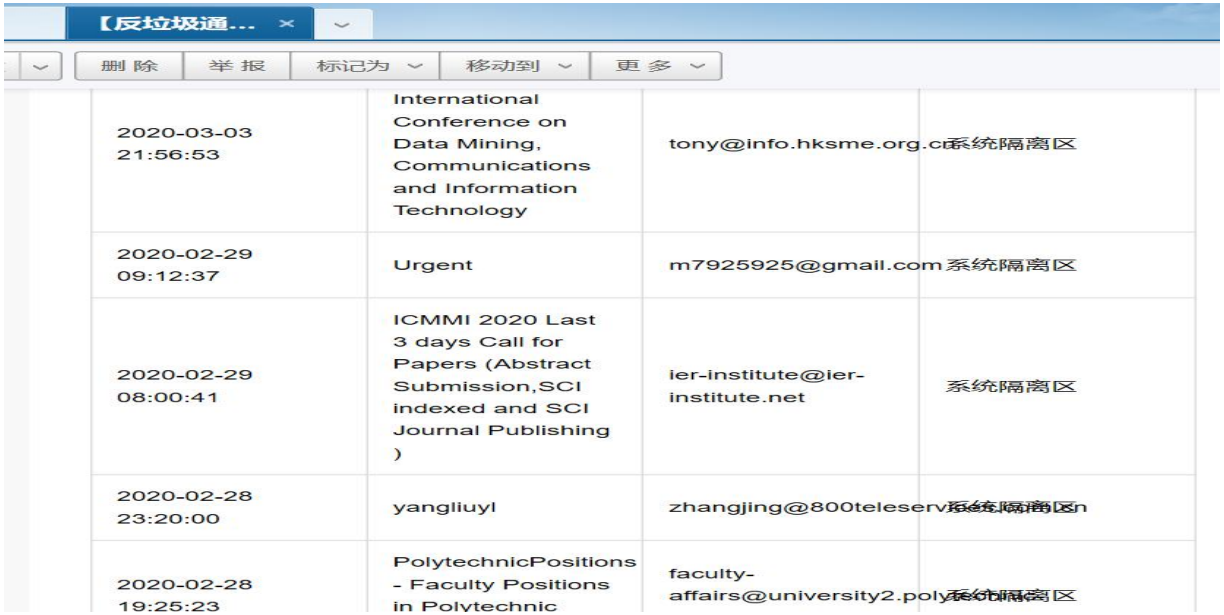




5.2分类的应用案例

垃圾邮件处理

- 案例阐述：对于企业和个人，如何处理垃圾邮件都是很头疼的一件事情。如果没有足够的容量来容纳垃圾邮件，或者没有过滤掉的垃圾邮件仍然会造成糟糕的用户体验。
- 表述问题：如何对每个邮箱中收到的每封邮件进行处理，将有用邮件保留而过滤掉垃圾邮件是用户关心的一大问题。



5.2分类的应用案例

- 解决问题：目前的垃圾邮件过滤方法主要是采用文本挖掘技术(text mining)，作为数据挖掘的重要分支，文本挖掘在数据挖掘传统方法的基础上引入了语义处理等其他学科知识。
- 在垃圾邮件过滤的分类技术中最常见的是贝叶斯分类法。贝叶斯分类法主要是通过对邮件的信封标题，主题和内容进行扫描和判别。
- 因为垃圾邮件发送方式随着各家企业邮箱的开发商的反垃圾技术的提升而变化，通过附件（PDF，图像等）方式发送垃圾邮件的专业户也越来越多，所以扫描的内容又增加了一项检查附件的工作。

5.2分类的应用案例

信用卡分级

- 案例阐述：现如今金融行业的竞争异常激烈。在美国，出现在每一家邮箱里最多的信件恐怕就是信用卡邀请信。如何吸引合适的用户来使用信用卡，以及准确分析申请人的信用风险，是每个商业银行最关注也是最头痛的事情。银行要不惜一切代价吸引低风险高价值的客户，但是对于高风险的信用卡申请者要尽量避免。
- 表述问题：如何把信用卡申请者分类为低、中、高风险。



5.2分类的应用案例

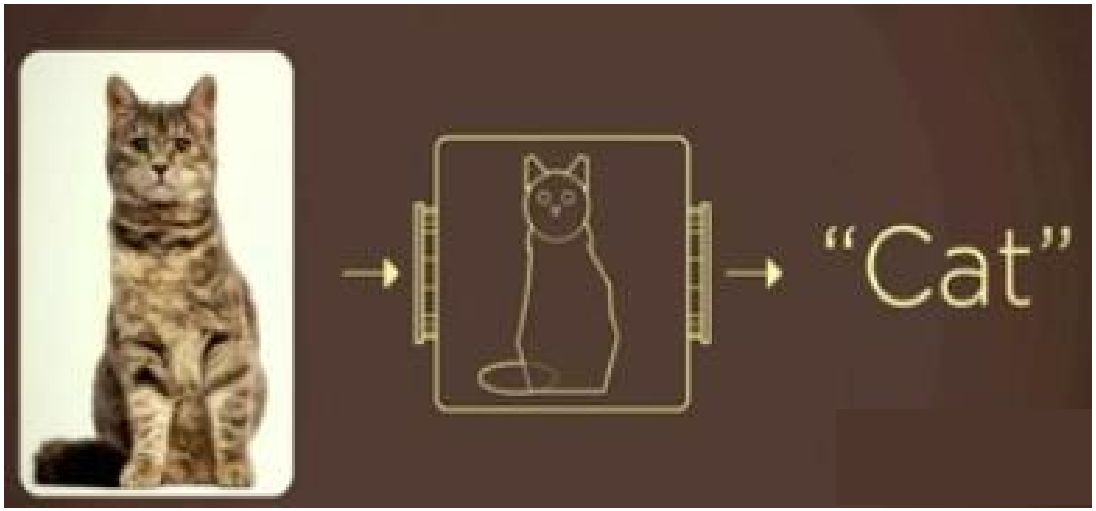
- 解决问题：需要建设客户风险模型来对客户的风险进行分类。因为行业的特殊性，申请表中包含了大量关于用户的个人信息，再加上通常会做的客户信用查询，可以用来参考的数据维度要多一些，所以相对来说建模的精准度也会高不少。

姓名	年龄	收入	学生	信誉	电话	地址	邮编	风险
张三	23	4000	否	良	281-322-0328	2714 Ave. M	77388	中
李四	34	2800	否	优	713-239-7830	5505 Holly Cr	78755	中
王二	50	1000	否	良	281-242-3222	2000 Bell Blvd.	70244	高
赵五	18	900	是	良	281-550-0544	100 Main Street	70244	中
刘兰	34	2500	否	优	713-239-7430	505 Holly Ct	78555	中
杨俊	27	8900	否	优	281-355-7990	233 Rice Blvd.	70388	低
张毅	38	9500	否	优	281-555-0544	399 Sugar Rd.	78244	低
。。。								

5.2分类的应用案例

计算机视觉

- 图像分类：针对给定的图像，利用数据挖掘算法使得计算机具备将其预测为某一类别的能力。



5 分类

- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念 
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.5 评估

5.3.1分类

把数据样本映射到一个事先定义的类中的学习过程，即给定一组输入的属性向量及其对应的类，用机器学习算法得出分类。

描述属性

类别属性

Age	Salary	Class
30	high	c_1
25	high	c_2
21	low	c_2
43	high	c_1
18	low	c_2
33	low	c_1
…	…	…

5.3.1分类

- 描述属性：连续型属性或离散型属性
- 类别属性：离散型属性

- 连续型属性是指在某一个区间或者无穷区间内该属性的取值是连续的。

  例如：属性“Age”
- 离散型属性是指该属性的取值是不连续的。

  例如：属性“Salary”和“Class”

5.3.2分类模式

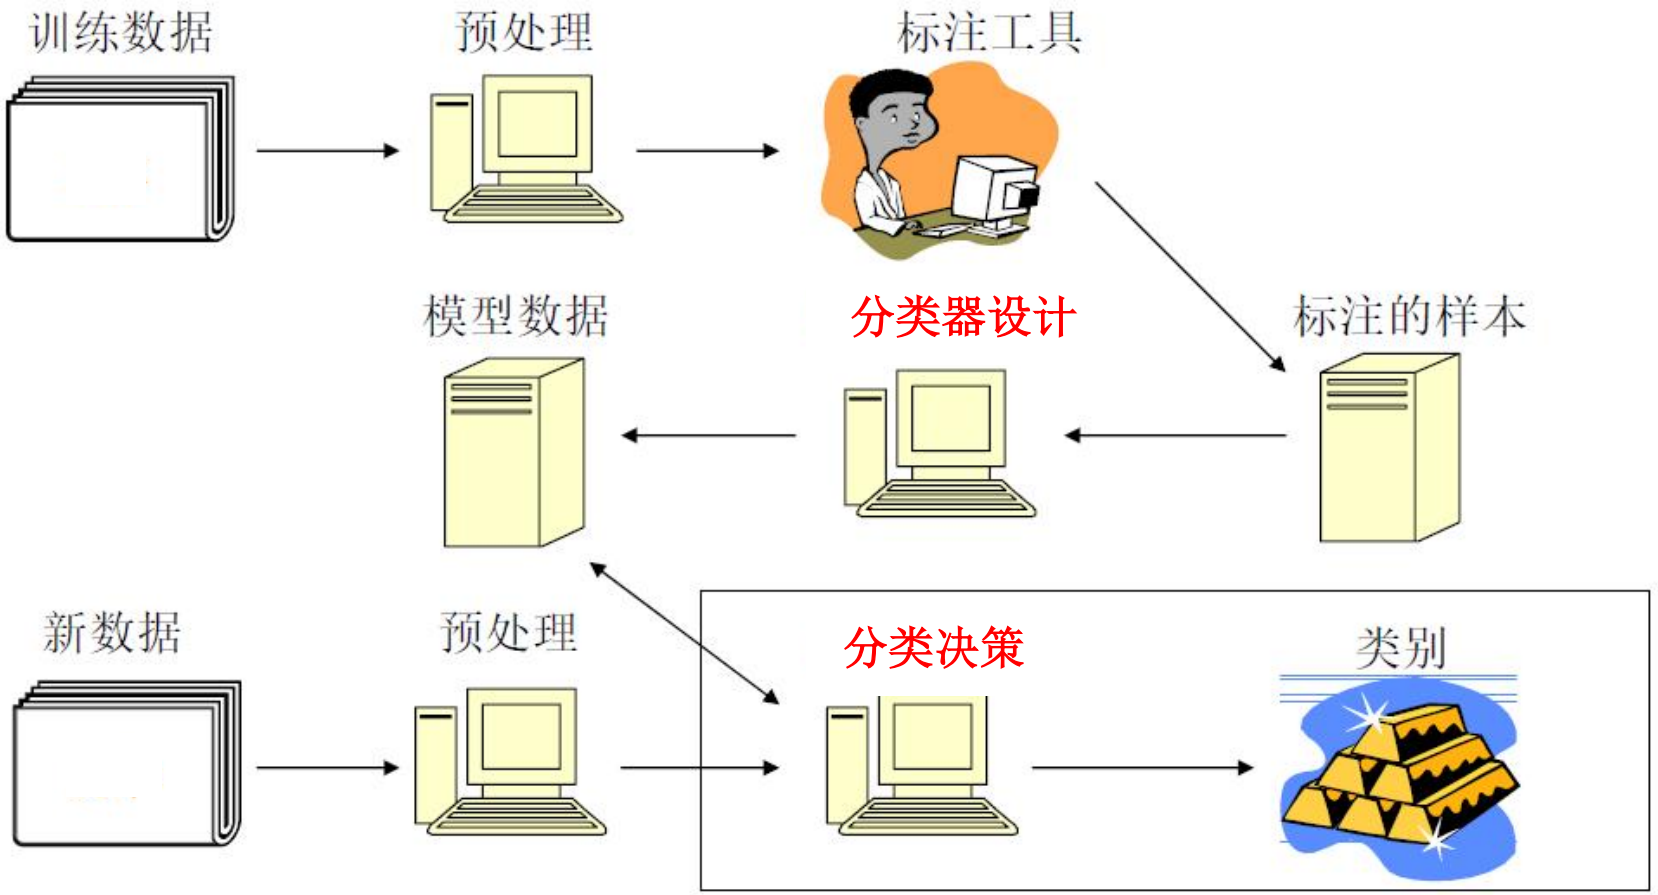
分类模式

- 二类问题，属于或不属于(binary)
- 多类问题，多个类别(multi-class)
- 多标签问题 (multi-label)



- 是（是否风景）
- 海边（海边、市内、高速等多类中的一类）
- 天空、白云、沙滩、树、山

5.3.3 分类过程



5.3.3 分类过程

训练集

Age	Salary	Class
30	high	c_1
25	high	c_2
21	low	c_2
43	high	c_1

x y

测试集

Age	Salary	Class
18	low	
33	low	?
…	…	

5.3.3 分类过程

训练集

NAME	RANK	YEARS	TENURED
Mike	Assistant Prof	3	no
Mary	Assistant Prof	7	yes
Bill	Professor	2	yes
Jim	Associate Prof	7	yes
Dave	Assistant Prof	6	no
Anne	Associate Prof	3	no

x y

测试集

NAME	RANK	YEARS	TENURED
Tom	Assistant Prof	2	
Merlisa	Associate Prof	7	?
George	Professor	5	
Joseph	Assistant Prof	7	

5.3.3 分类过程

关键步骤：

- 获取数据

  输入数据、对数据进行量化

- 预处理
  - 去除噪声数据、对空缺值进行处理
  - 数据集成或者变换
- 学习阶段

  划分数据集、在训练集上构造分类器

- 测试阶段

  对未知类标号的测试数据样本进行分类

5.3.3 分类过程

- 学习阶段：目标是建立描述预先定义的数据类或概念集的分类器
  - 监督学习



Learning

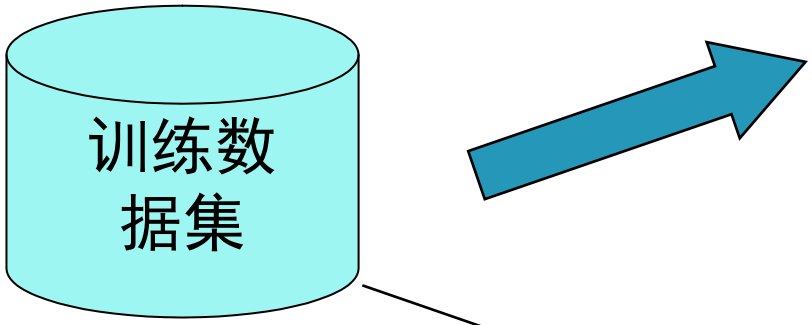




5.3.3 分类过程

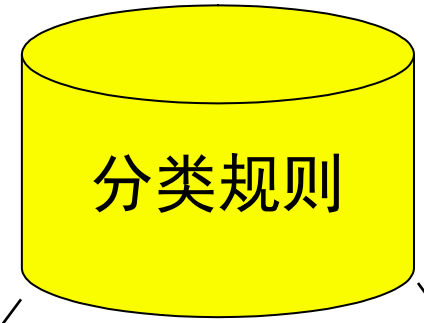
- 学习阶段：目标是建立描述预先定义的数据类或概念集的分类器
  - 监督学习
  - 训练集：由数据样本（用d维属性向量表示）和他们相对应的类标号组成
  - 训练样本：训练数据集中的单个样本；假定每个样本属于一个预定义的类
  - 分类算法通过分析或从训练集“学习”来构造分类器
  - 学习一个映射或函数$y=f(X)$
  - 学习模型可以用分类规则、决策树或数学公式等形式

5.3.3 分类过程



分类算法



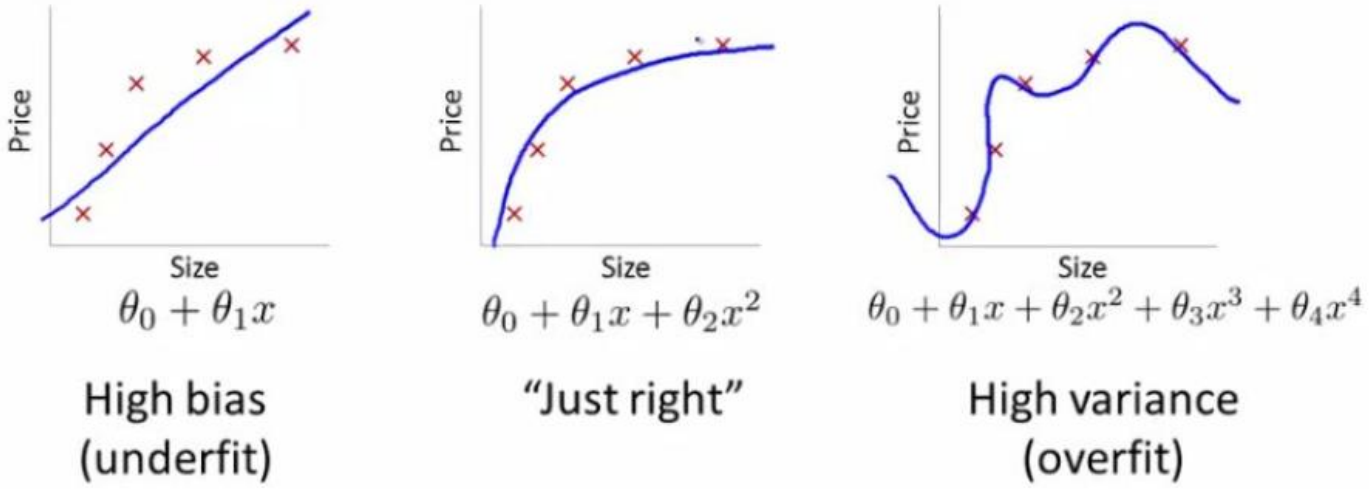


NAME	RANK	YEARS	TENURED
Mike	Assistant Prof	3	no
Mary	Assistant Prof	7	yes
Bill	Professor	2	yes
Jim	Associate Prof	7	yes
Dave	Assistant Prof	6	no
Anne	Associate Prof	3	no

IF rank = ‘professor’
OR years > 6
THEN tenured = ‘yes’

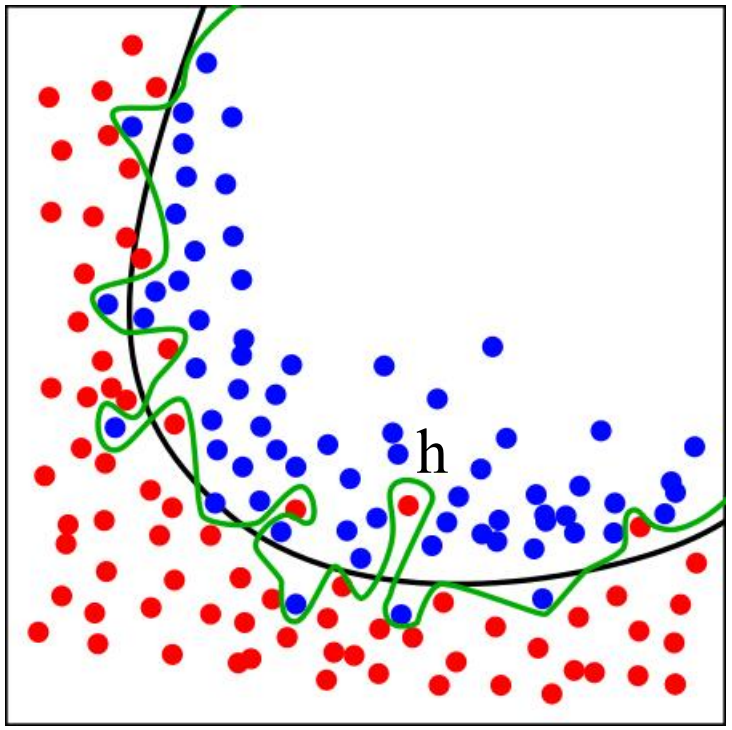
5.3.3 分类过程

- 测试阶段，使用模型，对将来的或未知的对象进行分类
  - 评估模型的预测准确率
    - 对每个测试样本，将已知的类标号和该样本的学习模型类预测比较
    - 准确率是正确被模型分类的测试样本的百分比
  - 测试集要独立于训练样本集，否则会出现“过分拟合”(overfitting)的情况



5.3.3 分类过程

过拟合：给定一个假设空间H，一个假设h属于H，如果存在其他的假设h’属于H，使得在训练样例上h的错误率比h’小，但在整个实例分布上h’比h的错误率小，那么就说假设h过度拟合训练数据。 ——《Machine Learning》Tom M.Mitchell



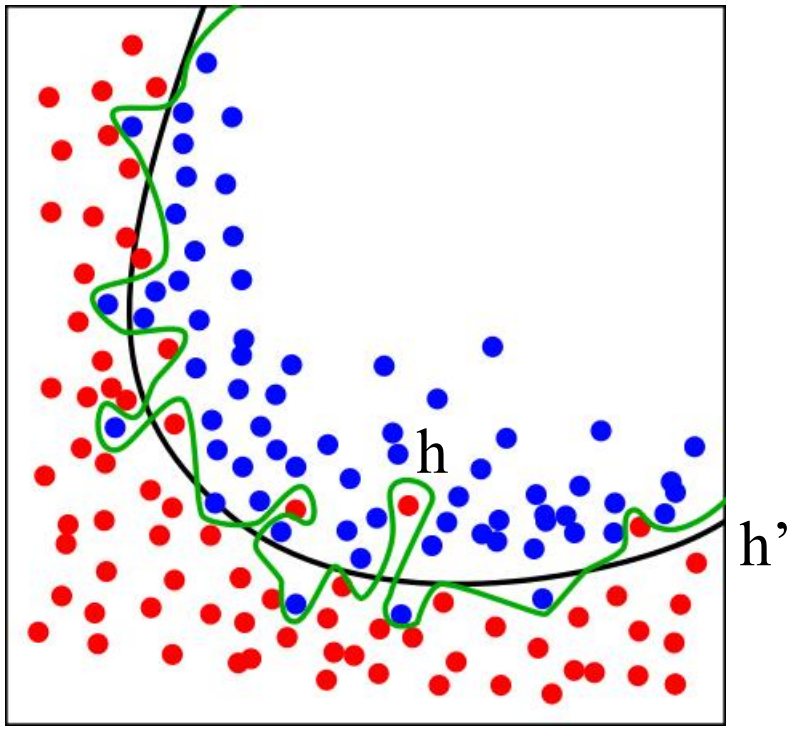
产生原因：

- 建模样本抽取错误，包括样本数量太少，抽样方法错误，抽样时没有足够正确考虑业务场景或业务特点，等等导致抽出的样本数据不能有效足够代表业务逻辑或业务场景；
- 样本里的噪音数据干扰过大，大到模型过分记住了噪音特征，反而忽略了真实的输入输出间的关系；
- 建模时的“逻辑假设”到了模型应用时已经不能成立了。例如假设建模数据与后来的应用数据是相似的等等。
- 参数太多、模型复杂度高。

…

5.3.3 分类过程

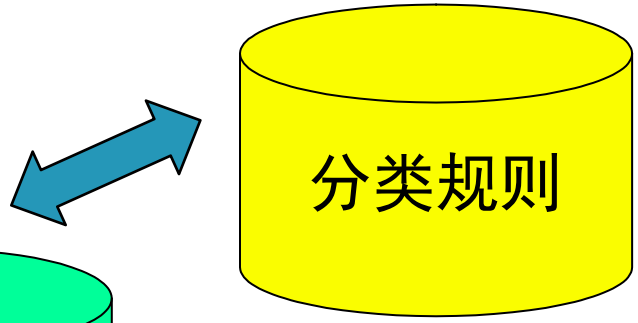
过拟合：给定一个假设空间H，一个假设h属于H，如果存在其他的假设h’属于H，使得在训练样例上h的错误率比h’小，但在整个实例分布上h’比h的错误率小，那么就说假设h过度拟合训练数据。 ——《Machine Learning》Tom M.Mitchell

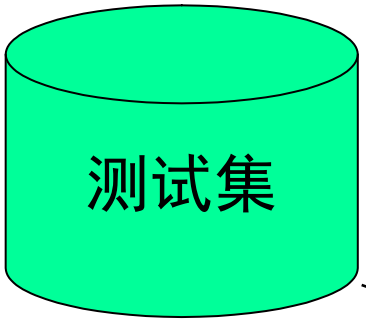


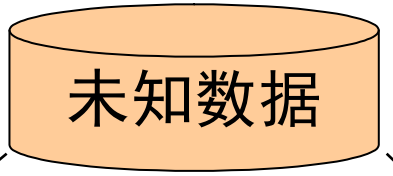
解决方案：

- 交叉验证
- 添加正则项
  - L1正则更加容易产生稀疏解
  - L2正则倾向于让参数w趋向于0
- 针对树模型
  - 在树过于大之前便停止生长
  - 等树生长到足够大之后进行修剪
  - …

5.3.3 分类过程







(George, Professor, 5)

NAME	RANK	YEARS	TENURED
Tom	Assistant Prof	2	no
Merlisa	Associate Prof	7	no
George	Professor	5	yes
Joseph	Assistant Prof	7	yes

Tenured?



Yes

5.3.4分类数学定义

- 给定：

  分类问题中使用的数据集（训练集）$X=\{(\boldsymbol{x}_i,y_i)|i=1,2,\ldots,N\}$

  - $\boldsymbol{x}_i=(x_{i1},x_{i2},\ldots,x_{id})$，其中$x_{i1},x_{i2},\ldots,x_{id}$分别对应$d$个描述属性$A_1,A_2,\ldots,A_d$的具体取值
  - y_i表示数据样本$\boldsymbol{x}_i$的类标号，假设给定数据集包含m个类别，则$y_i\in\{c_1,c_2,\ldots,c_m\}$，其中$c_1,c_2,\ldots,c_m$是类别属性$C$的具体取值

- 确定一个分类函数$y=f(X)$
- 未知类标号的数据样本集（测试集）中的测试样本$\boldsymbol{x}'$用d维特征向量$\boldsymbol{x}'=(x_1,x_2,\ldots,x_d)$表示，得到其所属的类别

5 分类

- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.5 评估
- 5.6 长尾分布建模

5.4 常用的分类方法

分类技术是一种根据输入数据集建立分类模型的系统方法。分类技术一般是用一种学习算法确定分类模型，该模型可以很好地拟合输入数据中类标号和属性集之间的联系。

学习算法得到的模型不仅要很好拟合输入数据，还要能够正确地预测未知样本的类标号。因此，训练算法的主要目标就是要建立具有很好的泛化能力模型，即建立能够准确地预测未知样本类标号的模型。

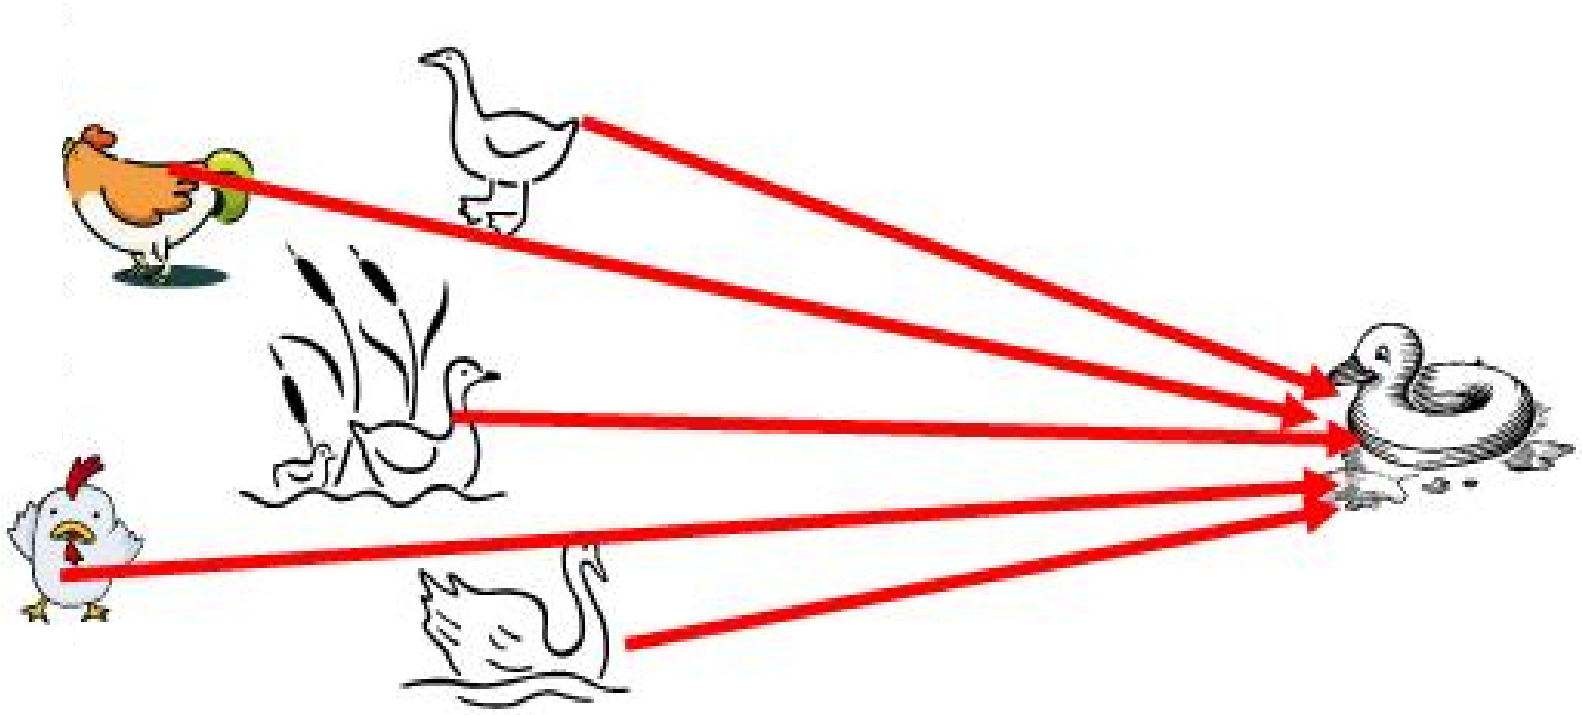
分类方法的实例包括：决策树、支持向量机、神经网络、k-近邻方法、朴素贝叶斯分类方法等。

数据挖掘领域的十大经典算法ICDM'06

- #1: C4.5 (51 votes) (分类)
- #2: K-Means (50 votes) (聚类)
- #3: SVM (58 votes) (分类)
- #4: Apriori (52 votes) (关联规则)
- #5: EM (48 votes)
- #6: PageRank (45 votes)
- #7: AdaBoost (45 votes)
- #7: kNN (45 votes) (分类)
- #7: Naive Bayes (45 votes) (分类)
- #10: CART (34 votes) (分类)

5.4.1 K-近邻

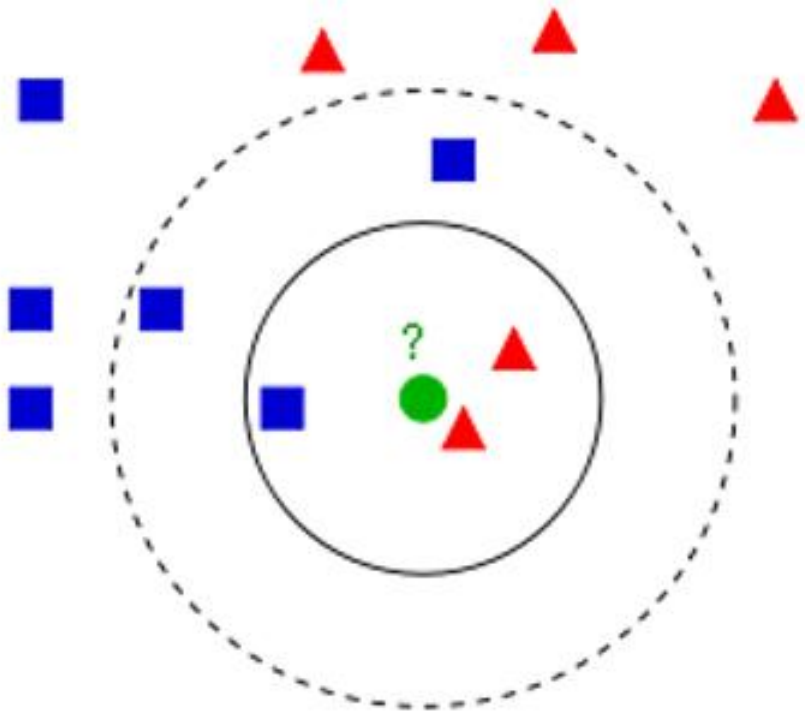
给定一个未知样本，k-最近邻分类法搜索模式空间，找出最接近未知样本的k个训练样本；然后使用k个最临近者中最公共的类来预测当前样本的类标号



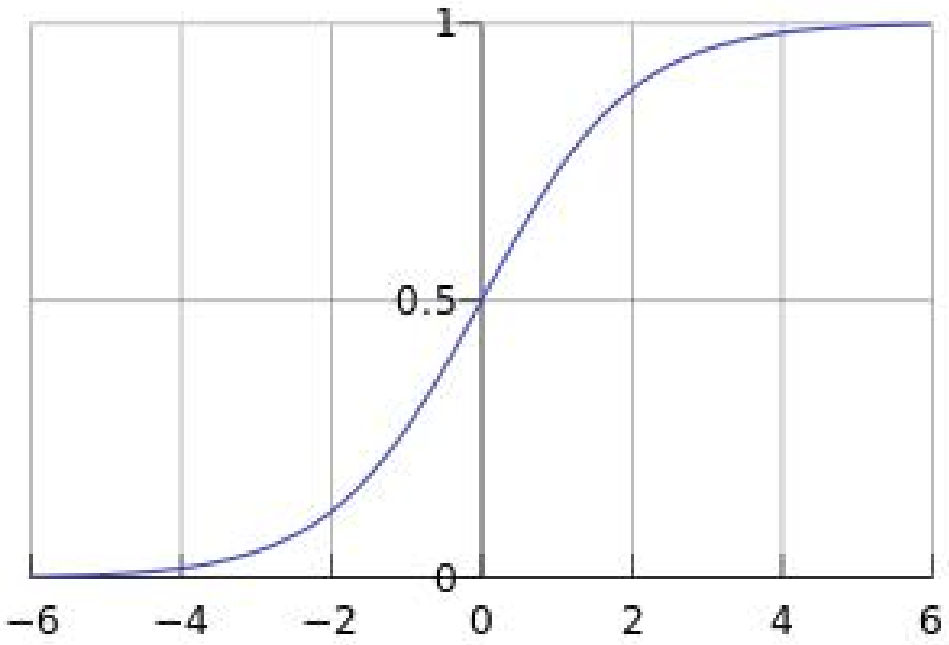
5.4.1 K-近邻

研究点：

- 近邻个数的选取
- 近邻的度量方法



5.4.2 Logistic回归方法



$$\mathcal{L}(\boldsymbol{w}) = \sum_{n=1}^{N} \left[-y^{(n)} \log \pi \left(\boldsymbol{x}^{(n)} \right) - \left(1 - y^{(n)} \right) \log \left(1 - \pi \left(\boldsymbol{x}^{(n)} \right) \right) \right]$$

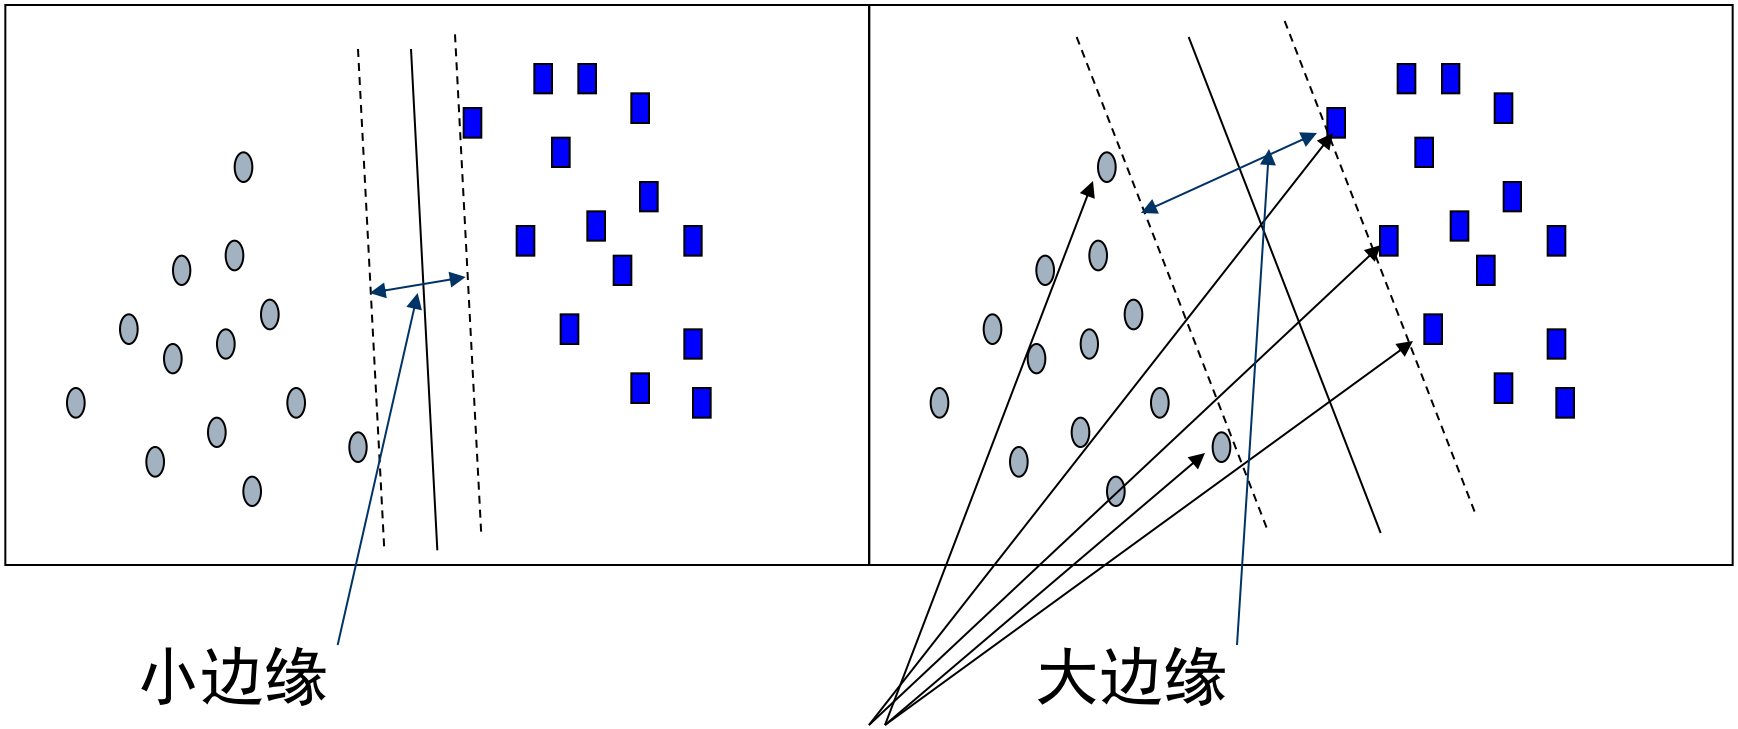
$$= \sum_{n=1}^{N} \left[-y^{(n)} \left(\boldsymbol{w}^T \boldsymbol{x}^{(n)} \right) + \log \left(1 + \exp \left(\boldsymbol{w}^T \boldsymbol{x}^{(n)} \right) \right) \right]$$

5.4.3 支持向量机

- 一个数据被认为是d维向量，数据在这d维向量空间中被分为两类；SVM的目的是找到一个d-1维的超平面，来划分d维向量空间的数据
- 其决策边界是对学习样本求解的最大边距超平面（maximum-margin hyperplane）
- SVM可以通过核方法（kernel method）进行非线性分类，是常见的核学习（kernel learning）方法之一

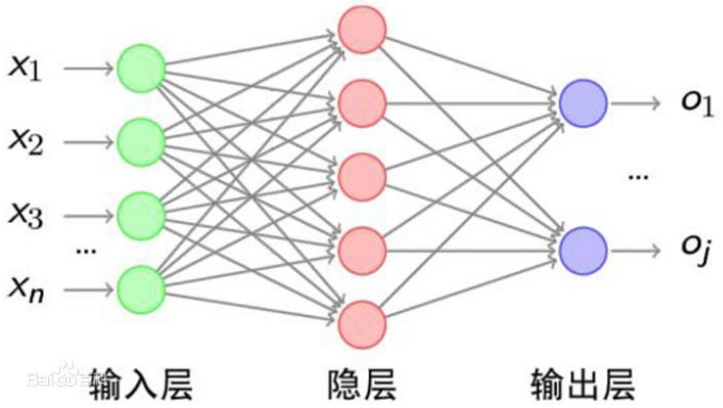
5.4.3 支持向量机

一般原理



5.4.4 神经网络

- 神经网络是一组连接的输入/输出单元，每个连接都与一个权相连。在学习阶段，通过调整神经网络的权，使得能够预测输入样本的正确标号来学习。
- 优点
  - 预测精度总的来说较高
  - 健壮性好，训练样本中包含错误时也可正常工作
  - 输出可能是离散值、连续值或者是离散或量化属性的向量值
- 缺点
  - 训练（学习）时间长
  - 蕴涵在学习的权中的符号含义很难理解
  - 很难结合专业领域知识

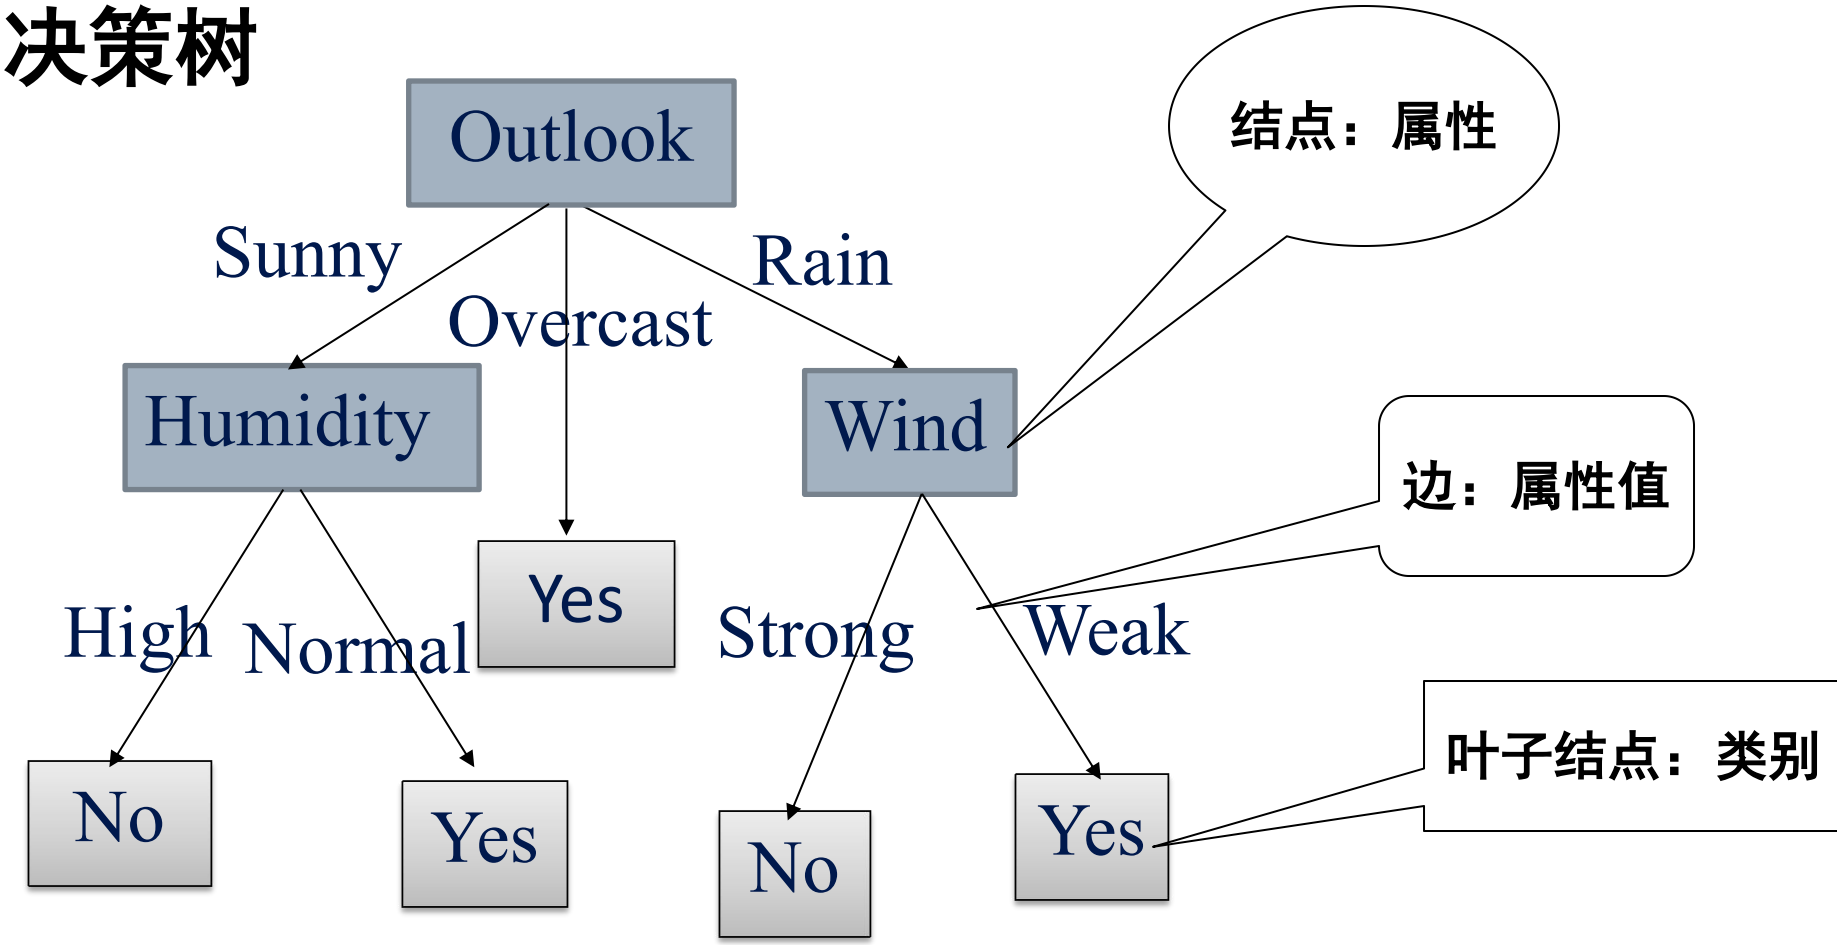


5.4.5 决策树

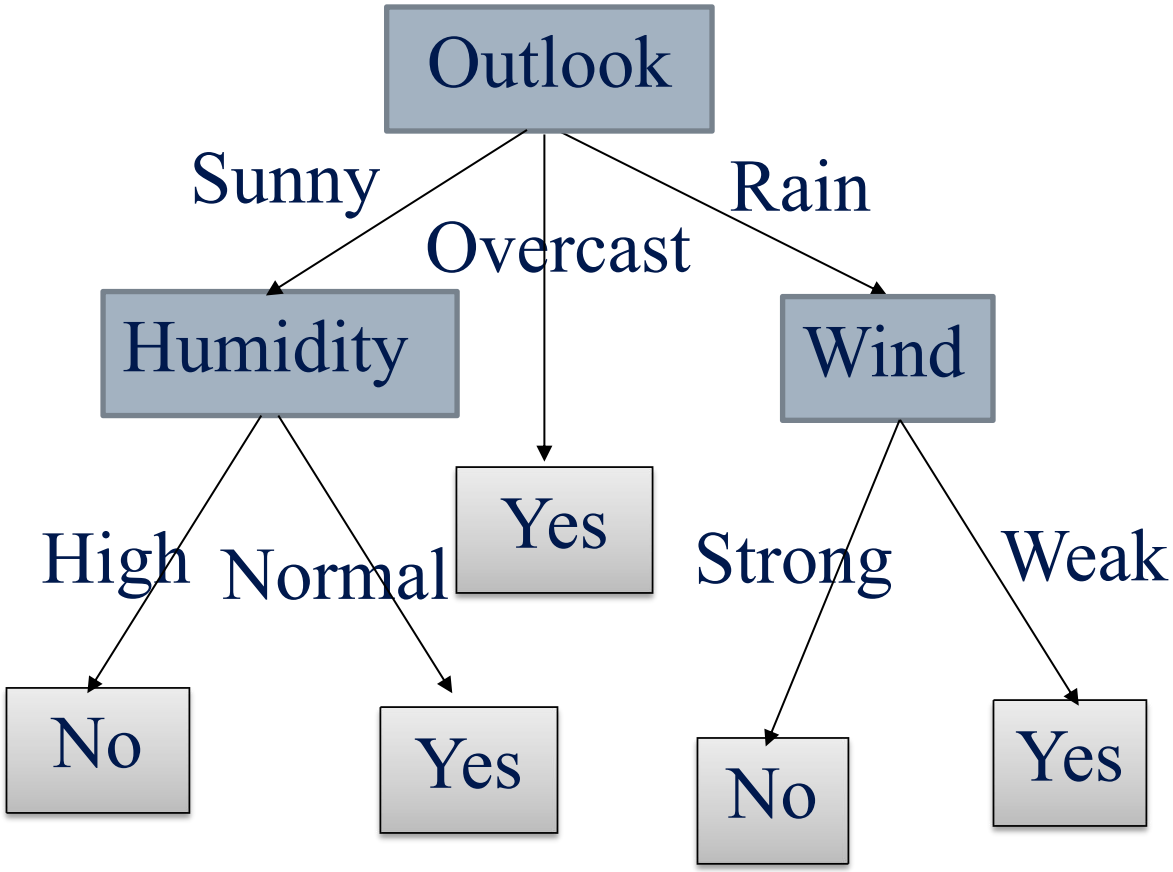
Day	Outlook	Temperature	Humidity	Wind	Play Tennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

5.4.5 决策树

决策树


Outlook
Sunny
Overcast
Rain
Humidity
Yes
Wind
High
Normal
Strong
Weak
No
Yes
No
Yes
结点：属性
边：属性值
叶子结点：类别

5.4.5 决策树



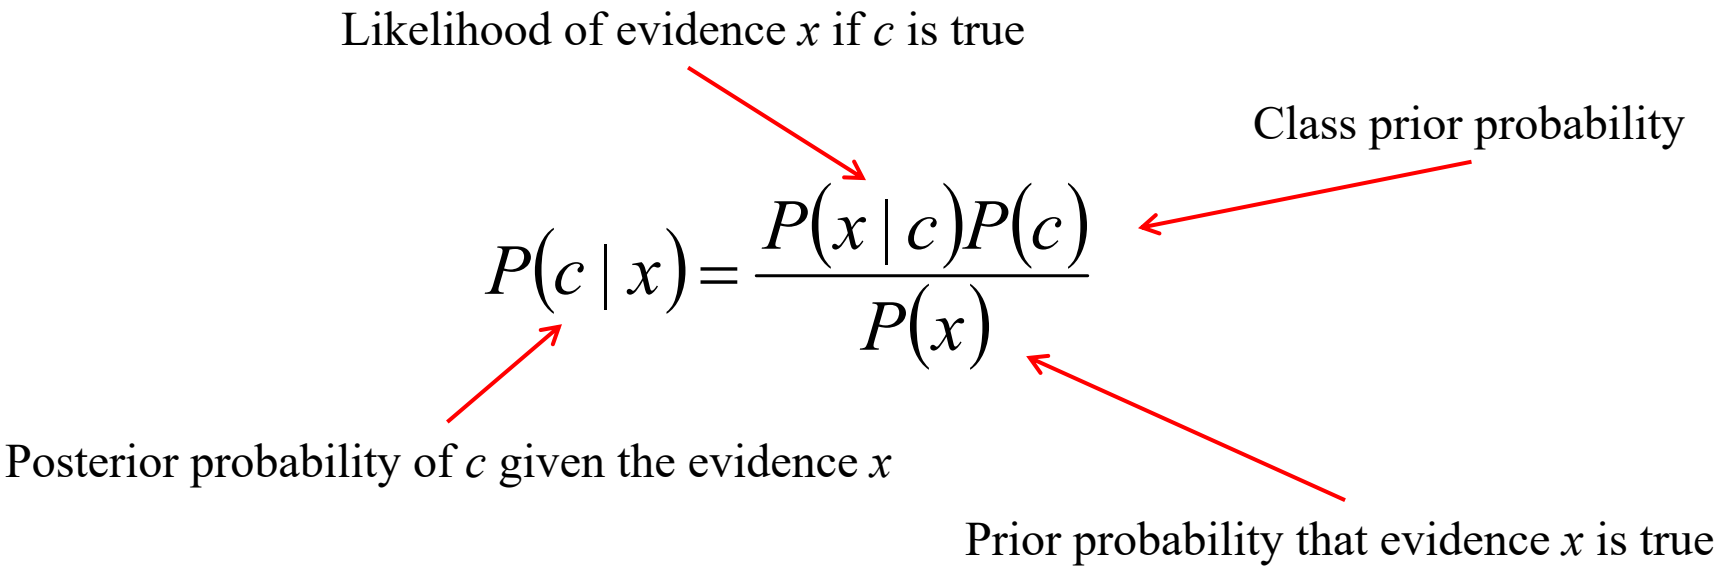
合取的析取表达式

（Outlook=Sunny AND Humidity=Normal) OR (Outlook=Overcast) OR (Outlook=Rain AND Wind=Weak)

关键问题是如何选择属性的顺序，可以采用信息增益、增益率、Gini指标等

5.4.5 贝叶斯分类

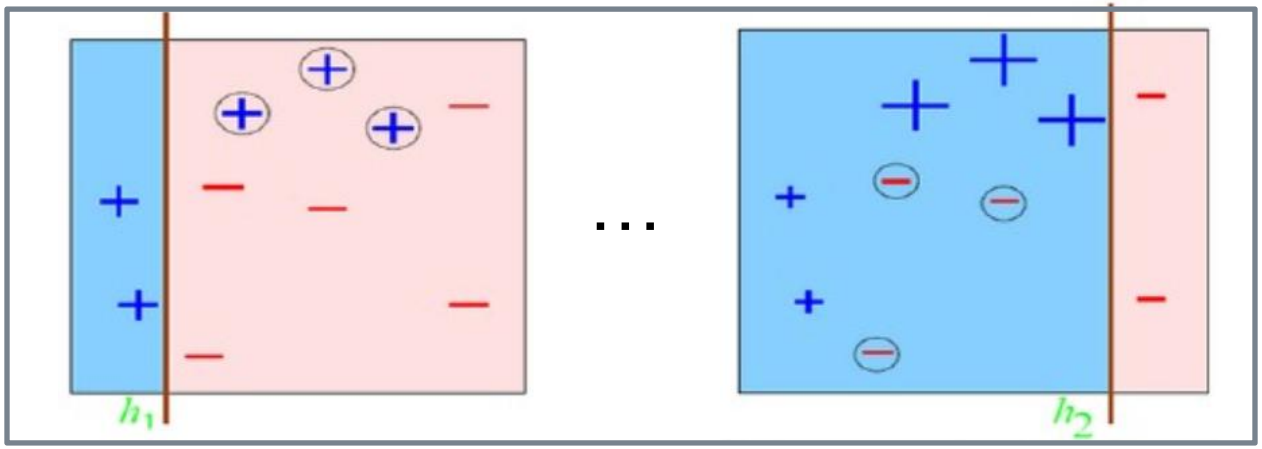
- 贝叶斯分类利用统计学中的贝叶斯定理，来预测类成员的概率，即给定一个样本，计算该样本属于一个特定的类的概率。
- 朴素贝叶斯分类：假设每个属性之间都是相互独立的，并且每个属性对非类问题产生的影响都是一样的。

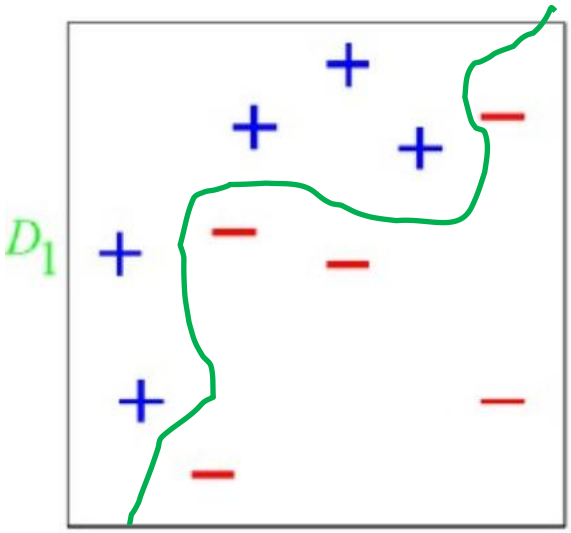


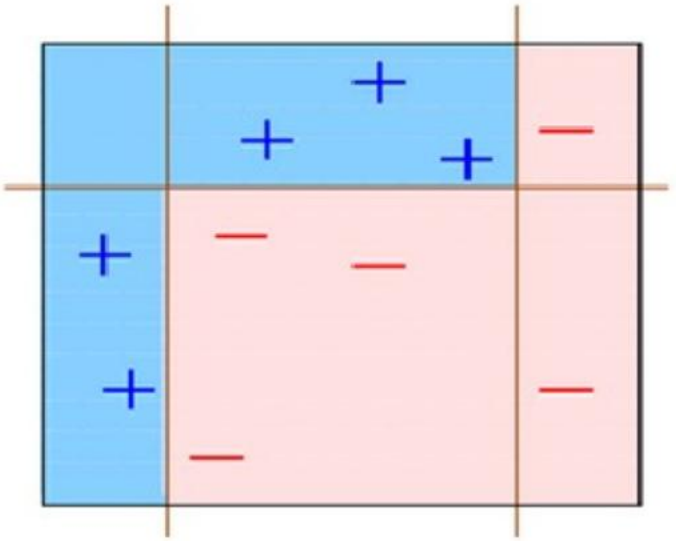
5 分类

- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.5 评估
- 5.6 长尾分布建模

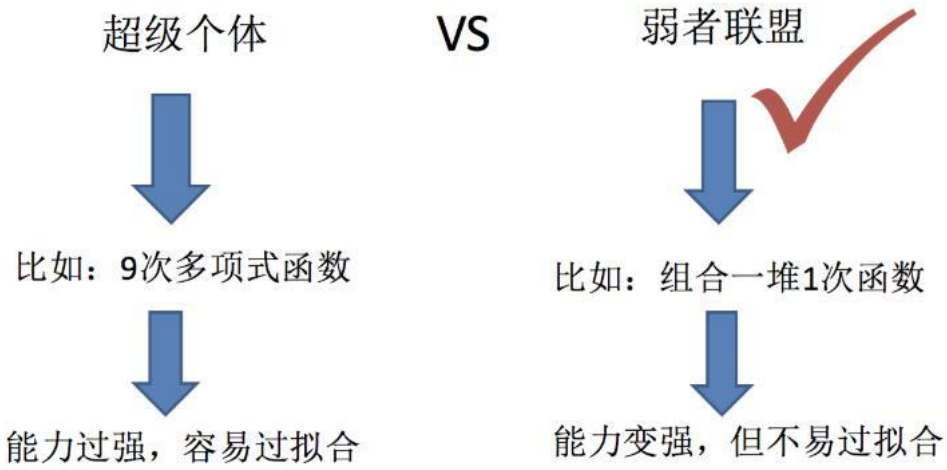
5.5 集成学习

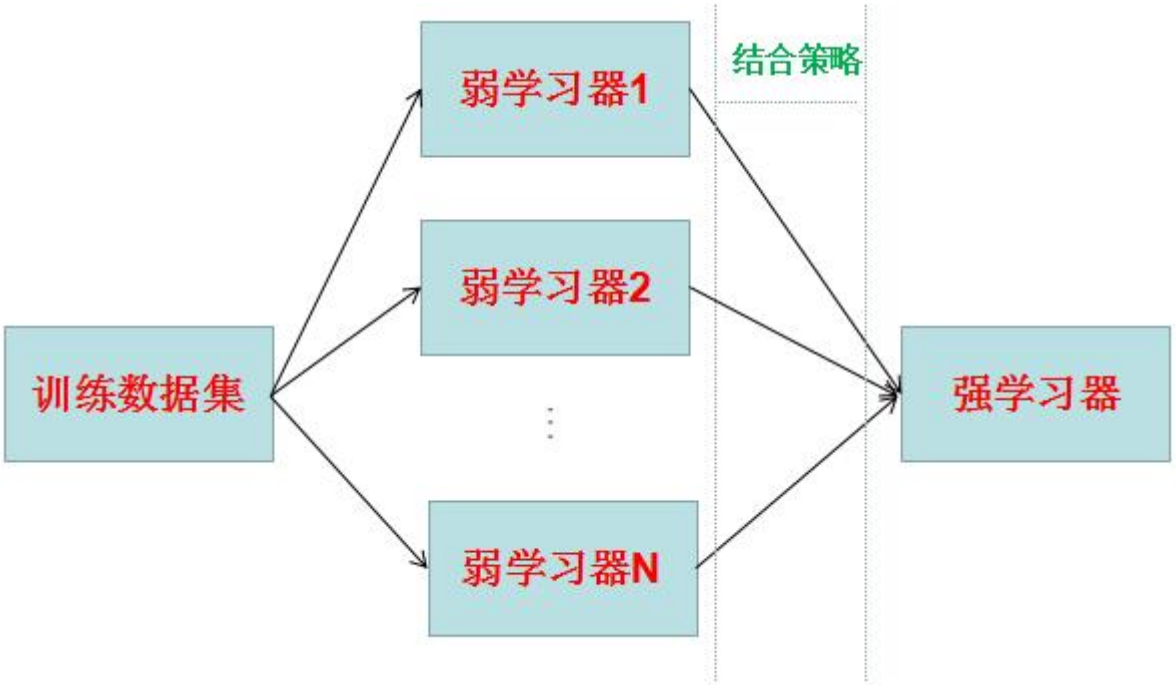




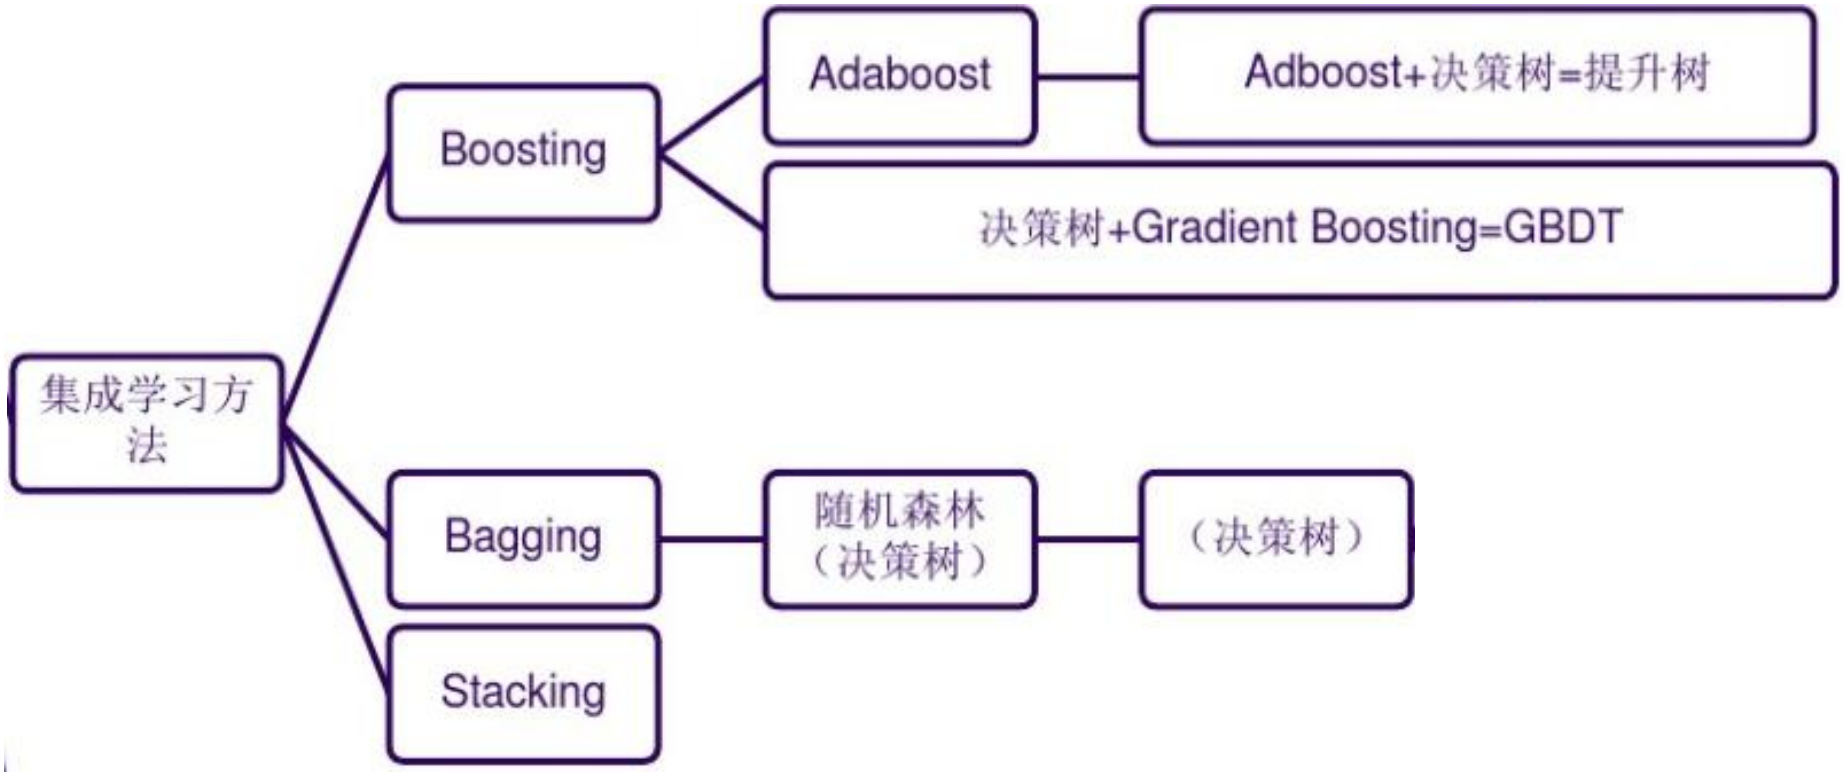


5.5 集成学习

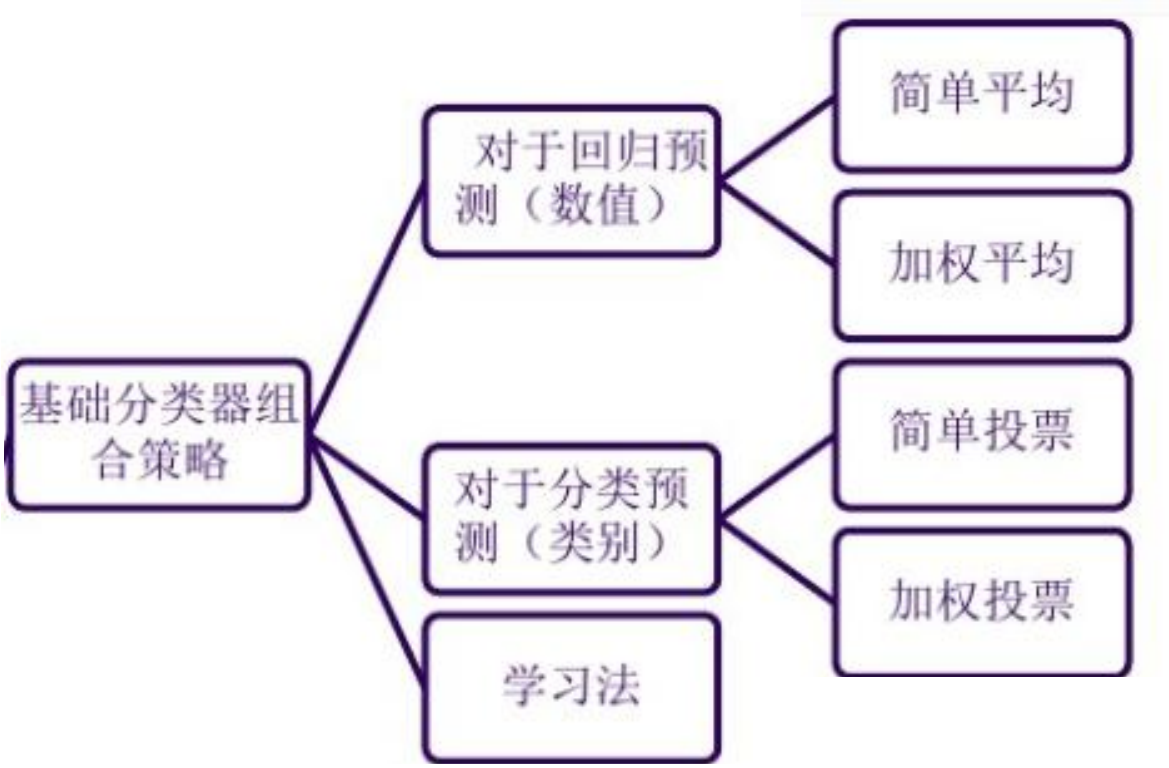

超级个体
VS
弱者联盟
比如：9次多项式函数
比如：组合一堆1次函数
能力过强，容易过拟合
能力变强，但不易过拟合


结合策略
弱学习器1
弱学习器2
弱学习器N
训练数据集
强学习器

5.5 集成学习

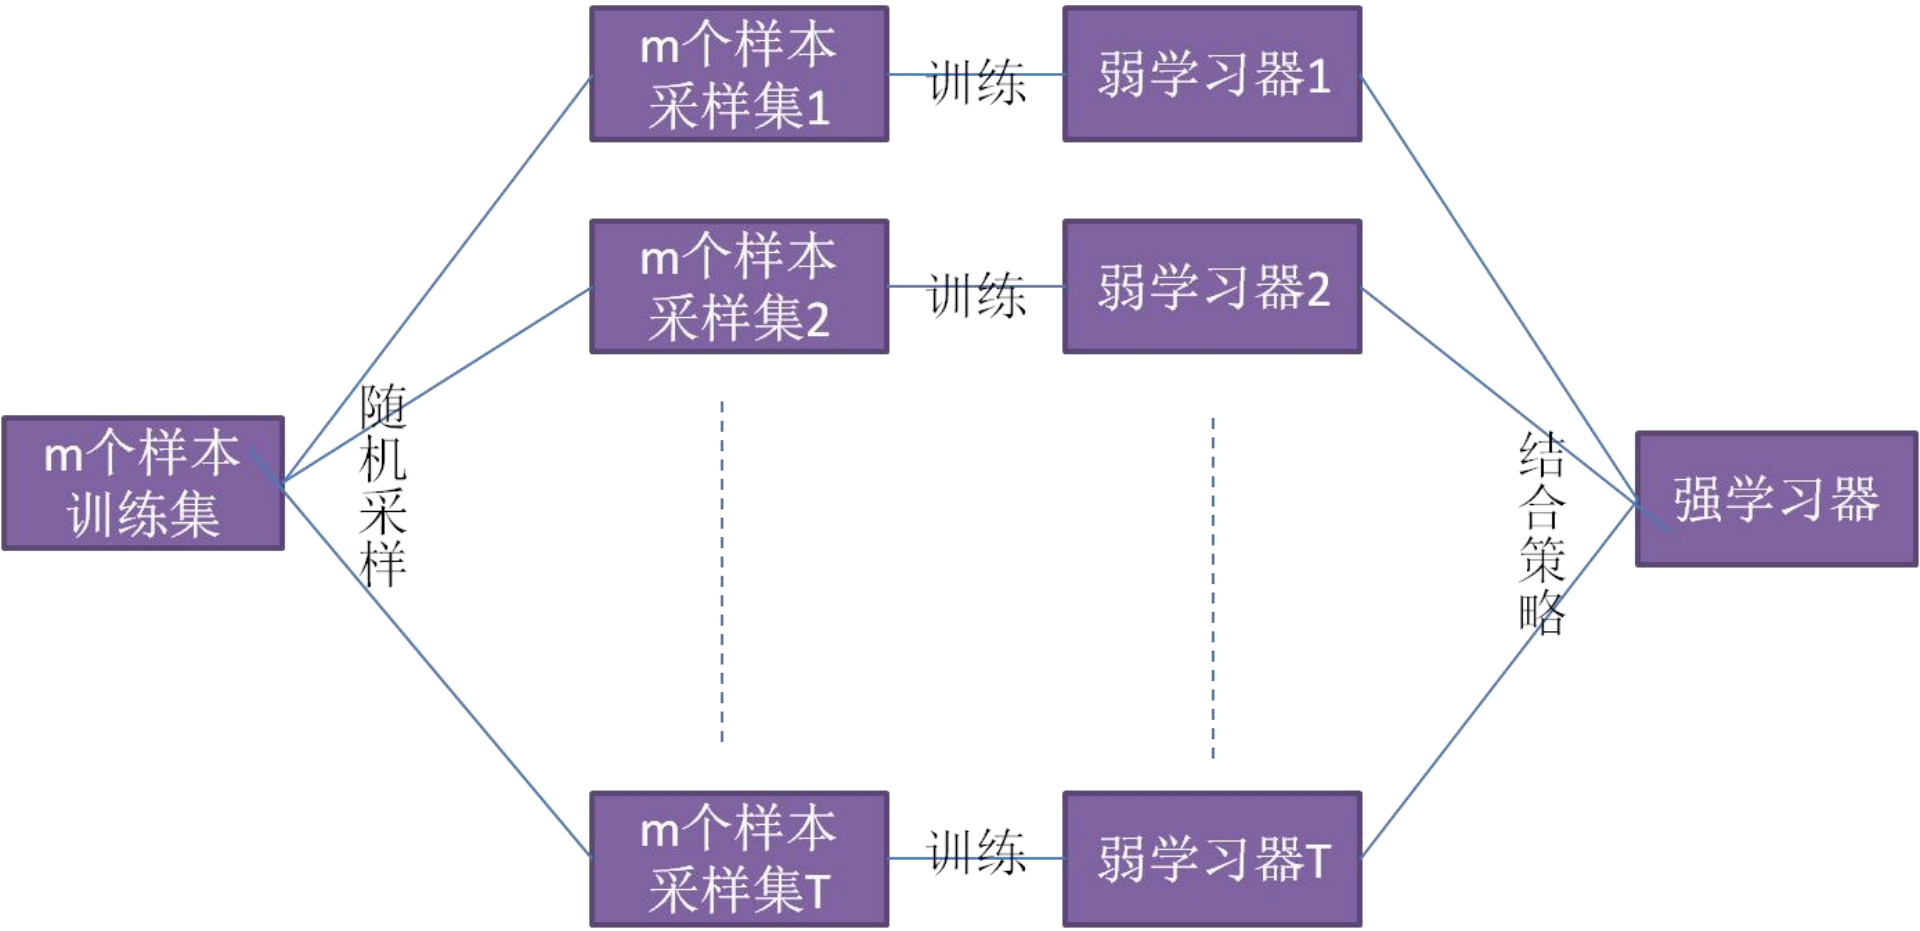

集成学习方法
Boosting
Adaboost
Adboost+决策树=提升树
决策树+Gradient Boosting=GBDT
Bagging
随机森林（决策树）
（决策树）
Stacking

5.5 集成学习



“三个臭皮匠，顶个诸葛亮”

5.5.1 Bagging


m个样本
训练集
随机采样
m个样本
采样集1
m个样本
采样集2
m个样本
采样集T
训练
训练
训练
弱学习器1
弱学习器2
弱学习器T
结合策略
强学习器

5.5.1 Bagging

Bagging即套袋法，算法过程如下：

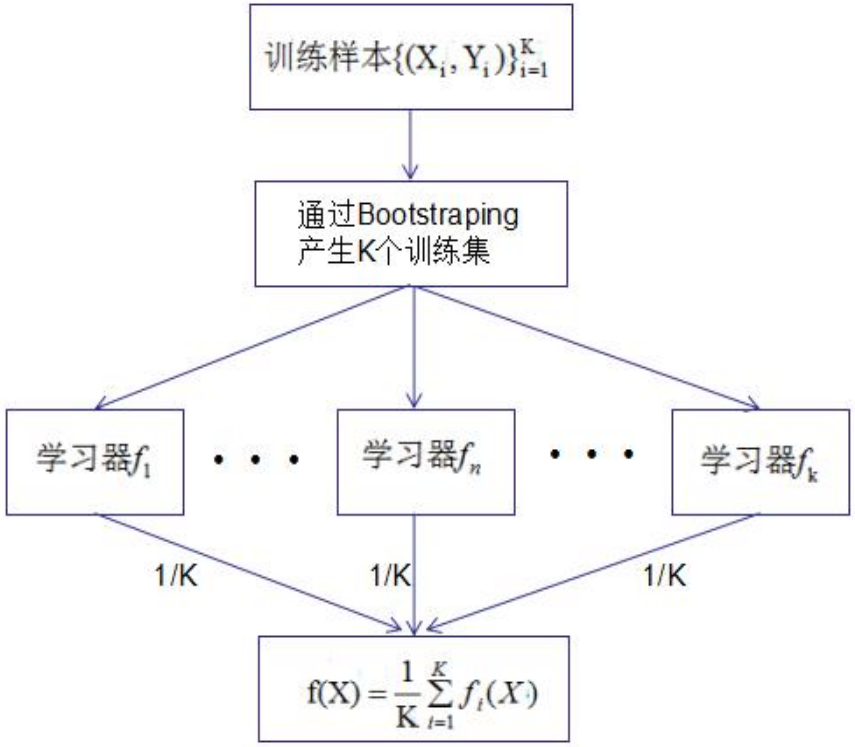
（1） 从训练样本集中随机可放回抽样（Bootstrapping)N次，得到与训练集相同大小的训练集，重复抽样K次，得到K个训练集 。

（2） 每个训练集得到一个最优模型，K个训练集得到K个最优模型。

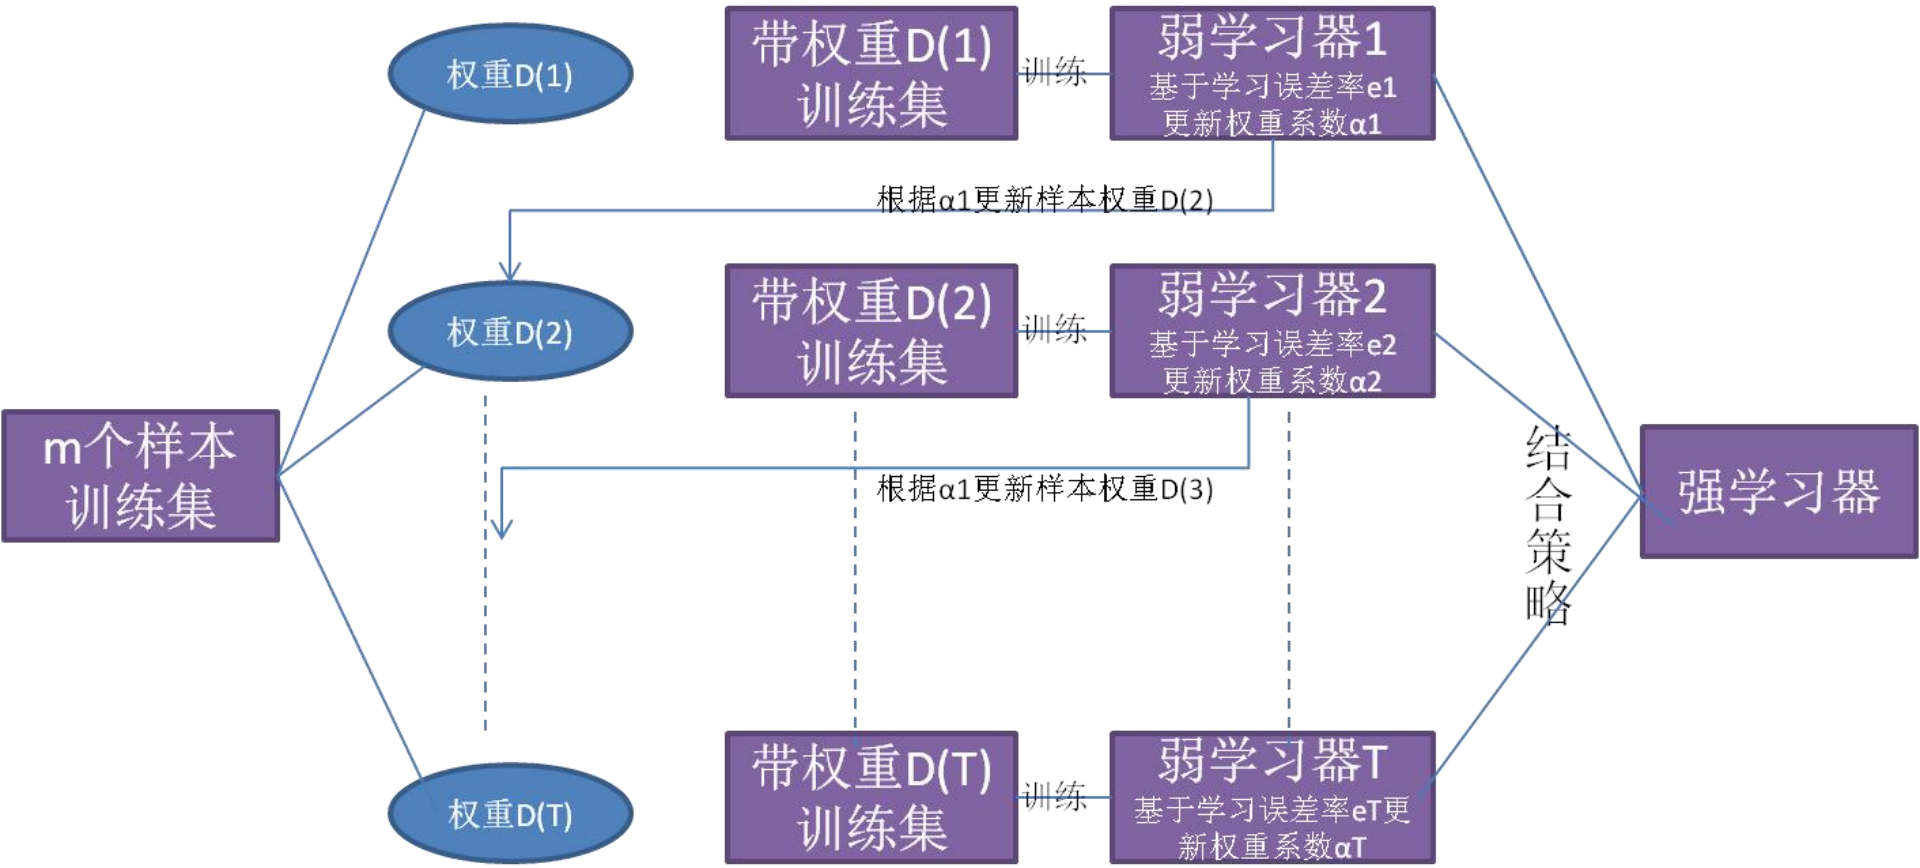
（3） 分类问题：对K个模型采用投票的方式得到分类结果；

回归问题：对K个模型的值求平均得到分类结果。



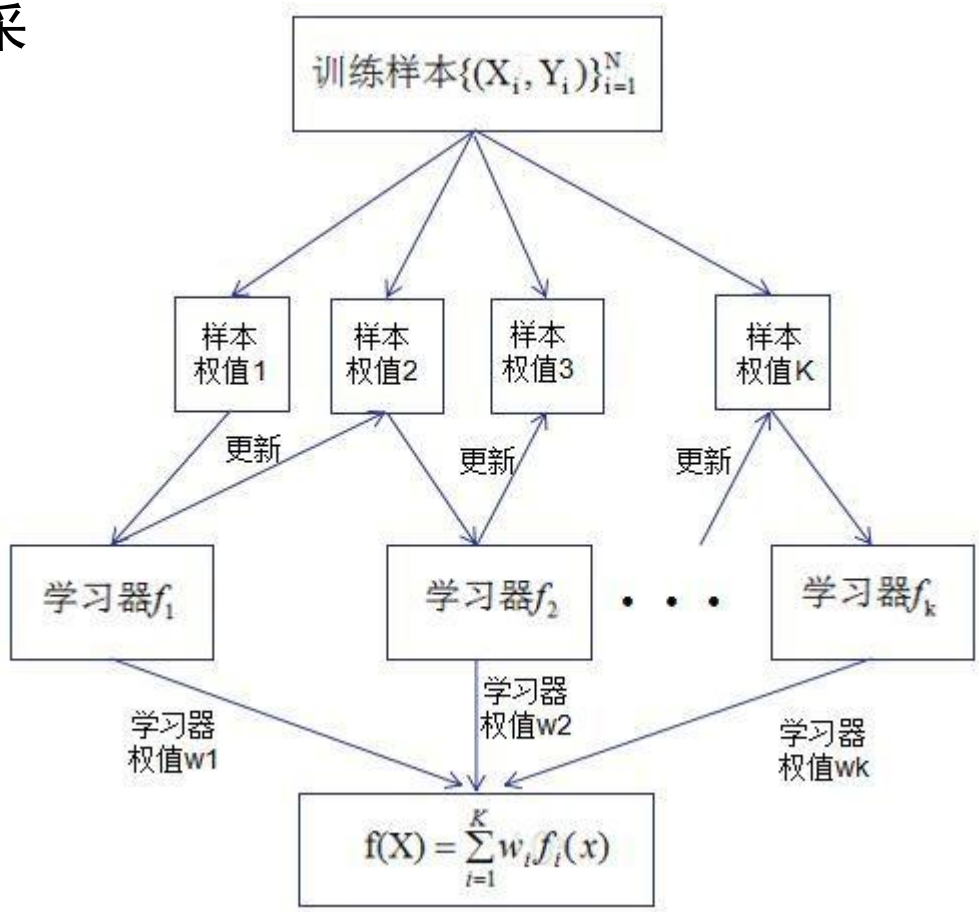


5.5.2 Boosting



5.5.2 Boosting

- Adaboost (Adaptive Boosting) 算法采用调整样本权重的方式来对样本分布进行调整。
- 提高前一轮个体学习器错误分类的样本的权重，而降低那些正确分类的样本的权重，这样就能使得错误分类的样本可以受到更多的关注，从而在下一轮中可以正确分类，使得分类问题被一系列的弱分类器“分而治之”。
- 对于组合方式，AdaBoost采用加权多数表决的方法，加大分类误差率小的若分类器的权值，减小分类误差率大的若分类器的权值，从而调整他们在表决中的作用。



5.5 集成学习

- 训练样本集

Bagging：训练集是有放回抽样，从原始集中选出的K组训练集是相互独立的。

Boosting：每一次迭代的训练集不变。

- 训练样本权重

Bagging：每个训练样本的权重相等，即1/N。

Boosting：根据学习器的错误率不断调整样例的权值，错误率越大，权值越大。

- 预测函数的权重：

Bagging：K组学习器的权重相等，即1/K。

Boosting：学习器性能好的分配较大的权重，学习器性能差的分配较小的权重。

- 并行计算

Bagging：K组学习器模型可以并行生成。

Boosting：K组学习器只能顺序生成，因为后一个模型的样本权值需要前一个学习器模型的结果。

5.5 集成学习

- 常用刷榜算法：
  - 随机森林(前身是bagging或者随机抽样）(并行算法)
  - Adaboost(串行算法)
  - GBDT(gradient boosting decision tree梯度提升树) (串行算法)
  - Xgboost(eXtreme Gradient Boosting)，是经过优化的分布式梯度提升树，旨在高效、灵活且可移植。
- 参考资料：
  - 集成学习基础与算法，周志华，电子工业出版社，2020
  - Introduction to boosted trees, Tianqi Chen
  - Introduction to Boosted Trees — xgboost 1.5.0-dev documentation

5 分类

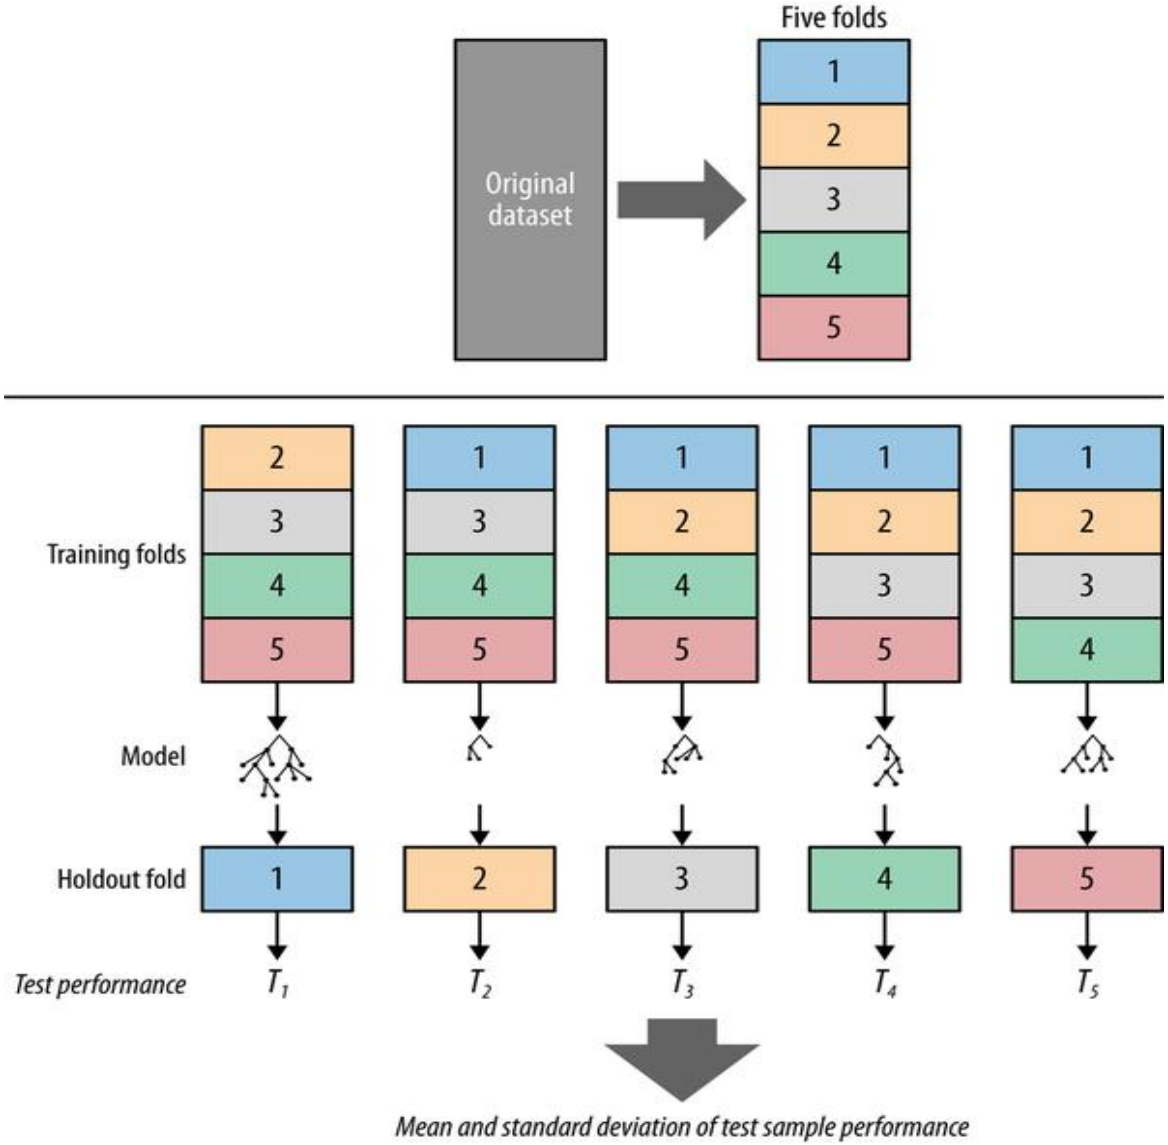
- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.5 评估
- 5.6 长尾分布建模

5.5.1 分类的评价方法

- 训练测试法(training-and-testing)
  - 把数据随机分成训练集和测试：训练集 (e.g., 2/3) 用于模型构建；测试 (e.g., 1/3) 用于评估准确率
- 交叉验证法(cross-validation)
  - 例如，十折交叉验证。即是将数据集分成十份，轮流将其中9份做训练1份做测试，10次的结果的均值作为对算法精度的估计。
  - 一般还需要进行多次10折交叉验证求均值，例如10次10折交叉验证，更精确一点。

5.5.1 分类的评价方法

- 交叉验证法(cross-validation)



5.5.1 分类的评价方法

举例

Outlook	Temperature	Humidity	Windy	Play?
sunny	hot	high	false	No
sunny	hot	high	true	No
overcast	hot	high	false	Yes
rain	mild	high	false	Yes
rain	cool	normal	false	Yes
rain	cool	normal	true	No
overcast	cool	normal	true	Yes
sunny	mild	high	false	No
sunny	cool	normal	false	Yes
rain	mild	normal	false	Yes
sunny	mild	normal	true	Yes
overcast	mild	high	true	Yes
overcast	hot	normal	false	Yes
rain	mild	high	true	No

训练测试法

14*(2/3) （大约10个）用于训练模型；

4 个样本用于测试

随机采样: 可以重复k次，取k次的平均值

十折交叉验证

14/10 equals 1.4

10次取的测试样本的个数分别为

1 1 1 1 2 2 2 2 2；

其余样本组成训练集。

5.5.2 分类的评价准则

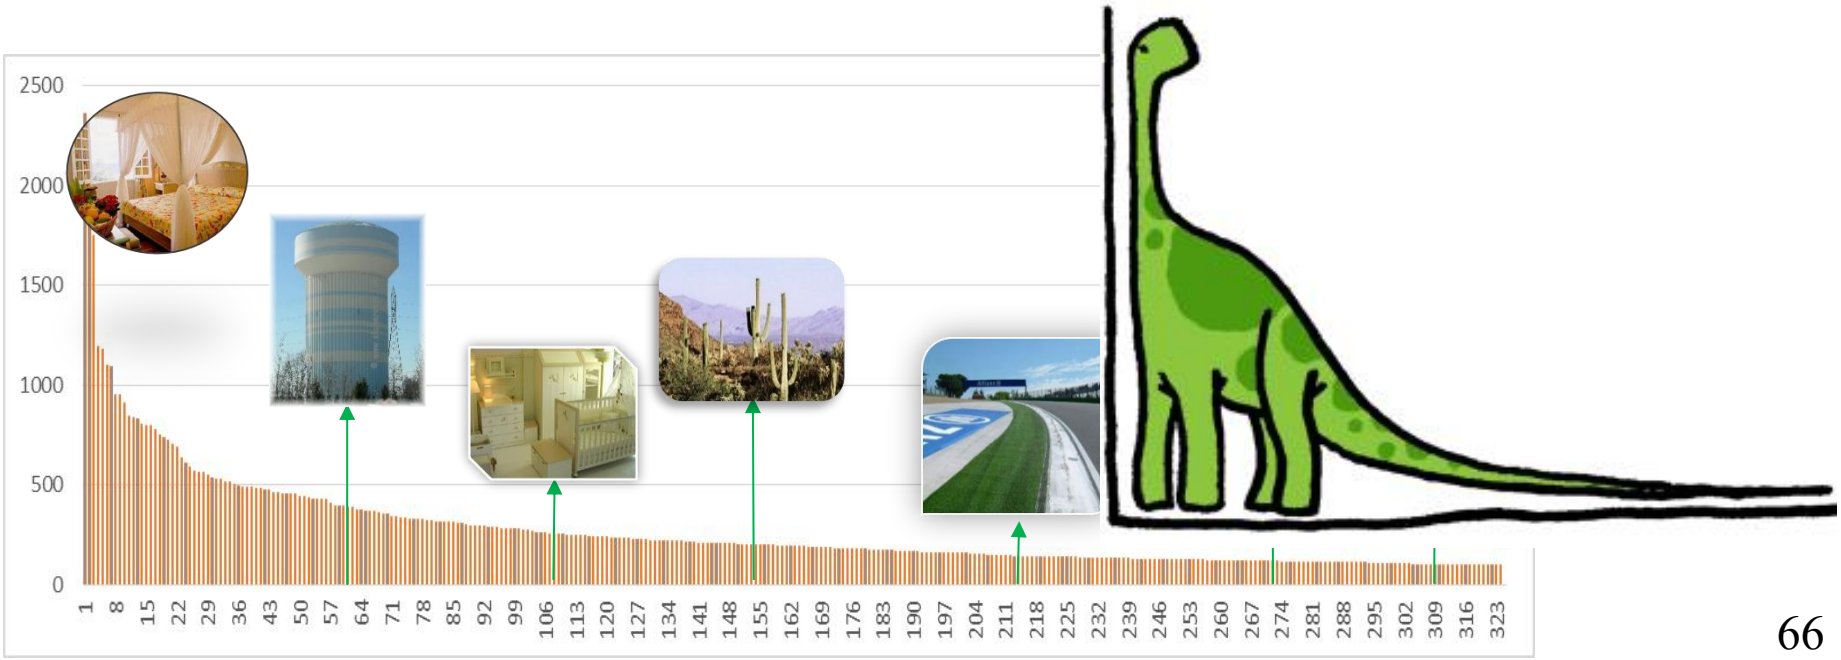
- 准确度：指模型正确地预测新的或先前未见过的数据的类标号的能力。
- 速度：指产生和使用模型的计算花费。
  - 建模的速度
  - 分类的速度
- 鲁棒性：指给定噪声数据或具有缺失值的数据，模型正确分类的能力。
- 可解释性：指模型的解释能力。

5 分类

- 5.1 分类、回归与聚类
- 5.2 分类的应用案例
- 5.3 分类概念
- 5.4 常用的分类方法
- 5.5 集成学习
- 5.5 评估
- 5.6 长尾分布建模 

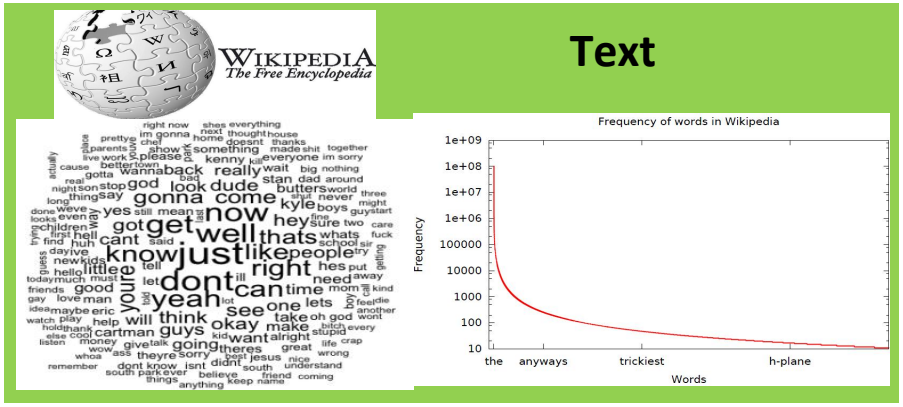
5.6.1 长尾分布定义

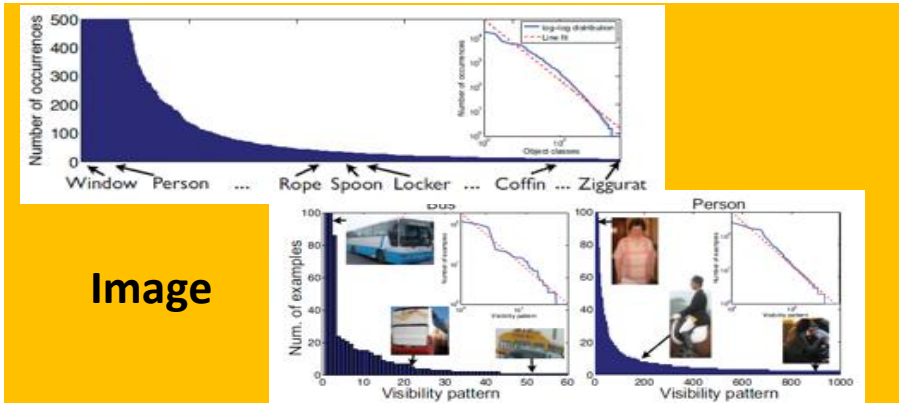
- 现实应用中，一部分类别常常出现，样本众多；更多的类别较为罕见，每个类别样本较少。
- **80/20法则：** 20%的人的掌握着80%的社会财富。
- 80%的样本分布在20%的头部类别上，大量尾部类别样本稀少，呈现一种极端不平衡分布。



5.6.1 长尾分布定义

- 常见场景和数据中均存在长尾分布。







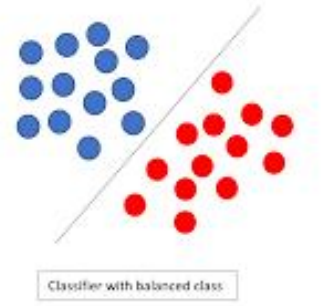


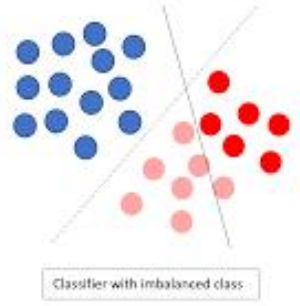
[1] S. Bengio. **The battle against the long tail.** Talk on Workshop on Big Data and Statistical Machine Learning. 1, 2, 2015.
[2] Zhu X, Anguelov D, Ramanan D. **Capturing long-tail distributions of object subcategories.** CVPR, 2014: 915-922.
[3] http://www.phirda.com/newsinfo.aspx?id=14339

5.6.2 长尾分布挑战

- **极度不均衡问题**，传统机器学习模型偏向于头部类别进行建模，尾部类别由于难以学习鲁棒有效的表示造成识别困难的问题
- **尾部类别数量极多**，严重影响任务整体的分类与识别性能
- 某些关键场景（自动驾驶、疾病诊断、科学发现）中**尾部类别重要性更高**







5.6.3 长尾分布建模

- 长尾分布问题本质上是“大多数”和“少数”兼容性上的矛盾
- 当前解决长尾分布问题主要从以下三个思路进行

重采样方法
Re-sampling

- 头部类别欠采样或尾部类别过采样
- 人为形成更均衡的数据分布

重加权方法
Re-weighting

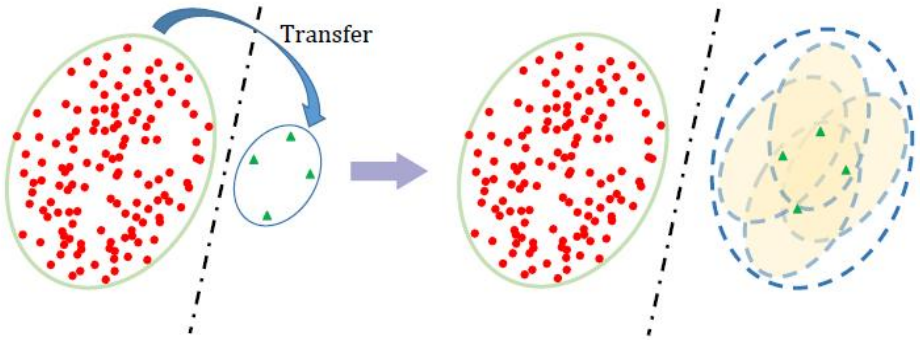
- 减小头部类学习权重，增大尾部类学习权重
- 模型在学习过程中的损失更新更加均衡

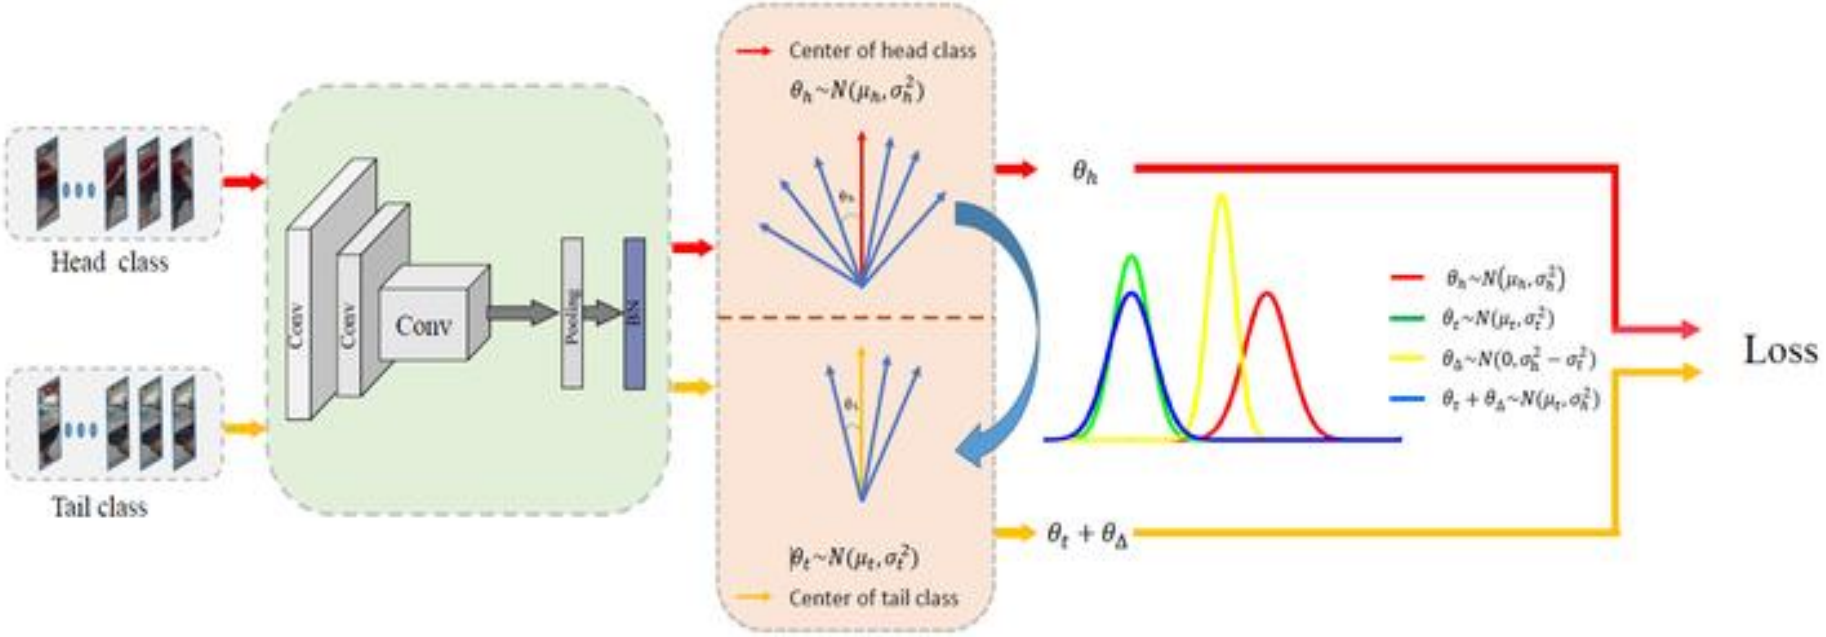
头尾知识迁移
Head-to-tail Transfer

- 迁移头部类别中的知识协助尾部类别的学习
- 尾部类别基于头部提供的先验知识补充学习

5.6.3 长尾分布建模

- **重采样方法：**利用头部数据分布信息生成尾部样本，从而缩小数据量上的头尾差距

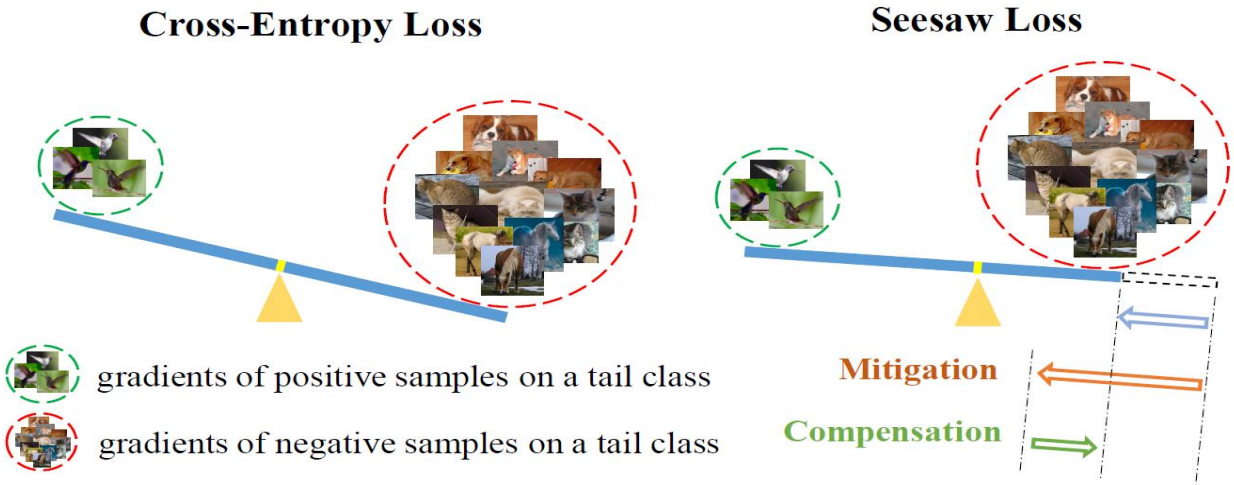


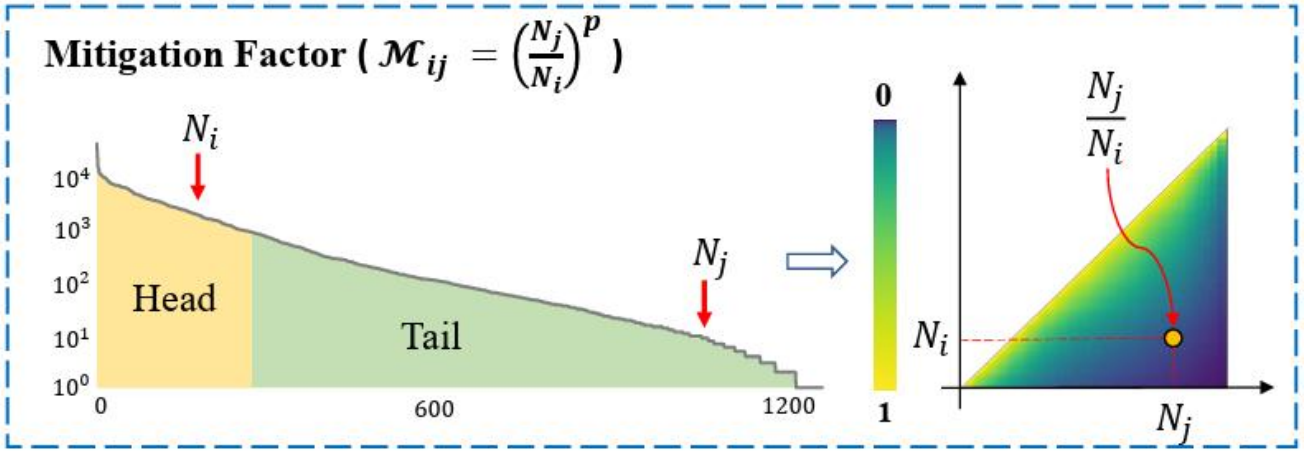


[1] Liu, et al. **Deep Representation Learning on Long-tailed Data: A Learnable Embedding Augmentation Perspective**. CVPR, 2020.

5.6.3 长尾分布建模

- **重加权方法：**学习中减小头部样本权重，增大尾部样本权重

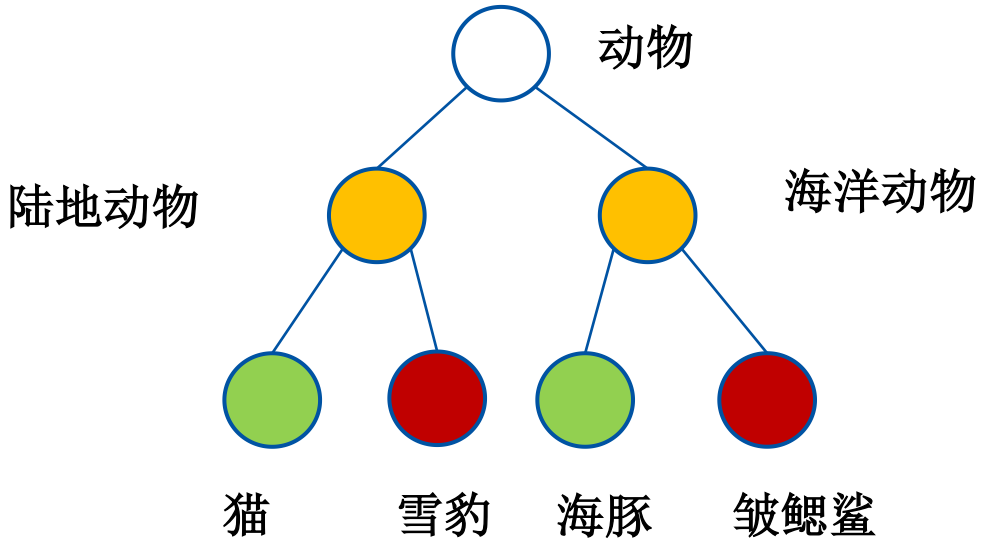




[1] Wang, et al. **DSeesaw Loss for Long-Tailed Instance Segmentation**. CVPR, 2021.

5.6.3 长尾分布建模

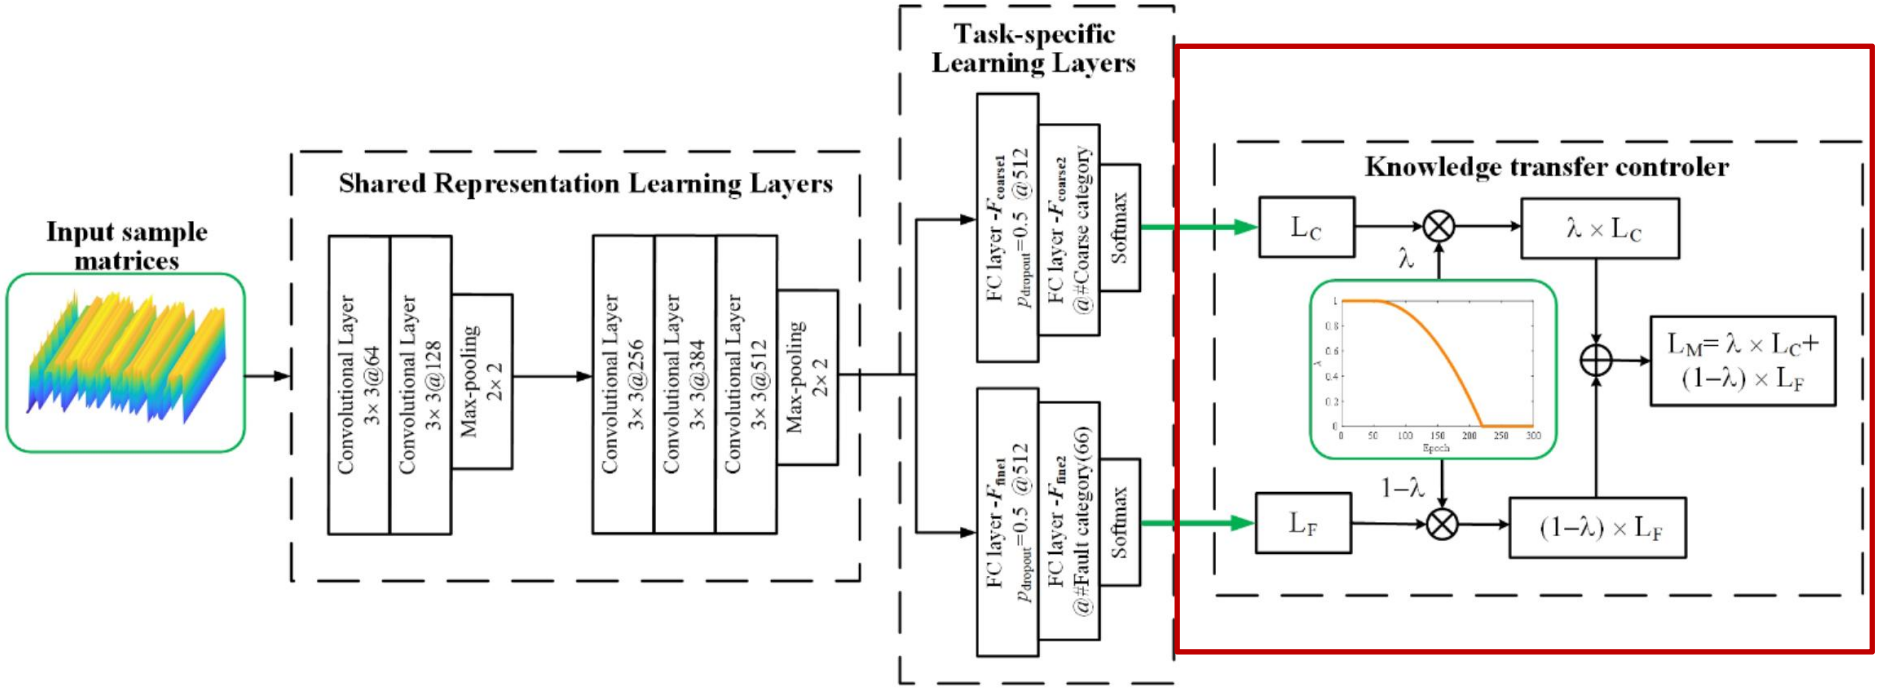
- **头尾知识迁移方法：**利用头部所学习的信息和知识帮助尾部进行建模，从而解决尾部类因数据少造成的建模难问题
- **如何形成知识?**
- **形成知识后如何迁移?**



[1] Yu Wang, et al. **Coarse-to-Fine: Progressive Knowledge Transfer Based Multi-Task Convolutional Neural Network for Intelligent Large-Scale Fault Diagnosis**. IEEE TNNLS, 2023.

5.6.3 长尾分布建模

- **聚类形成分层知识结构：**基于类均值的谱聚类
- **多粒度知识迁移：**上下层异步学习，上层知识逐步迁移到下层，帮助下层更好学习



[1] Yu Wang, et al. **Coarse-to-Fine: Progressive Knowledge Transfer Based Multi-Task Convolutional Neural Network for Intelligent Large-Scale Fault Diagnosis**. IEEE TNNLS, 2023.

天津大学
Tianjin University

THE END



天津大学
Tianjin University

数据挖掘

王煜

人工智能学院

wang.yu@tju.edu.cn



回顾

- 分类、回归与聚类
- 分类的方法
  - k-近邻
  - 支持向量机
  - 神经网络
  - 决策树

回顾

1.分类：

有监督的，需要有训练集和测试集。

在已知训练集的前提下，对测试样本根据它的特征，把它与训练集中的样本进行对比，把它分到对应的那类中。

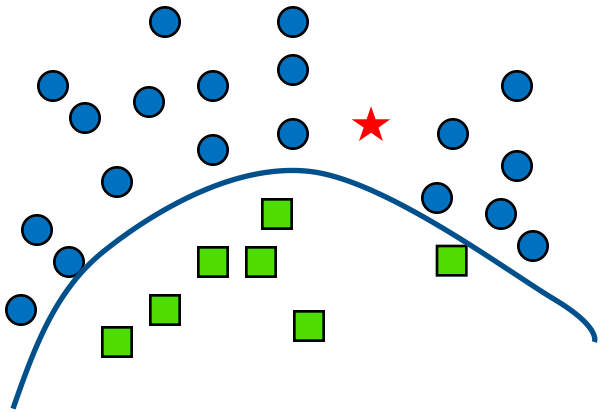
2.聚类：

无监督的

有一堆数据，将这堆数据按照它们自身内部的相似性，自动地聚成几类。

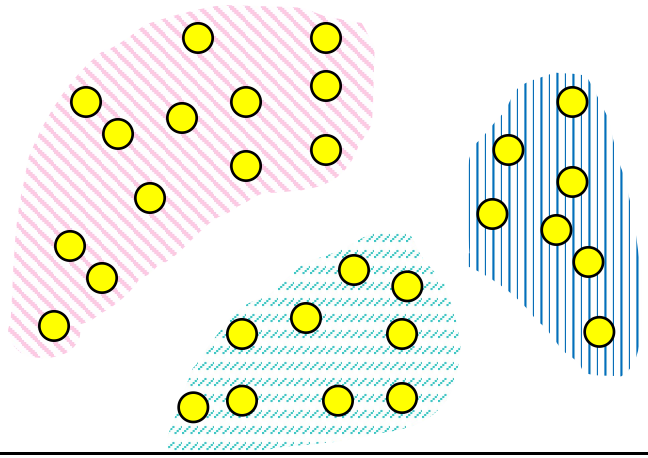
物以类聚、人以群分

分类 vs. 聚类



分类：有监督学习

Learns a method for predicting the instance class from pre-labeled (classified) instances



聚类：无监督学习

Finds “natural” grouping of instances given un-labeled data

没有事先定义的类

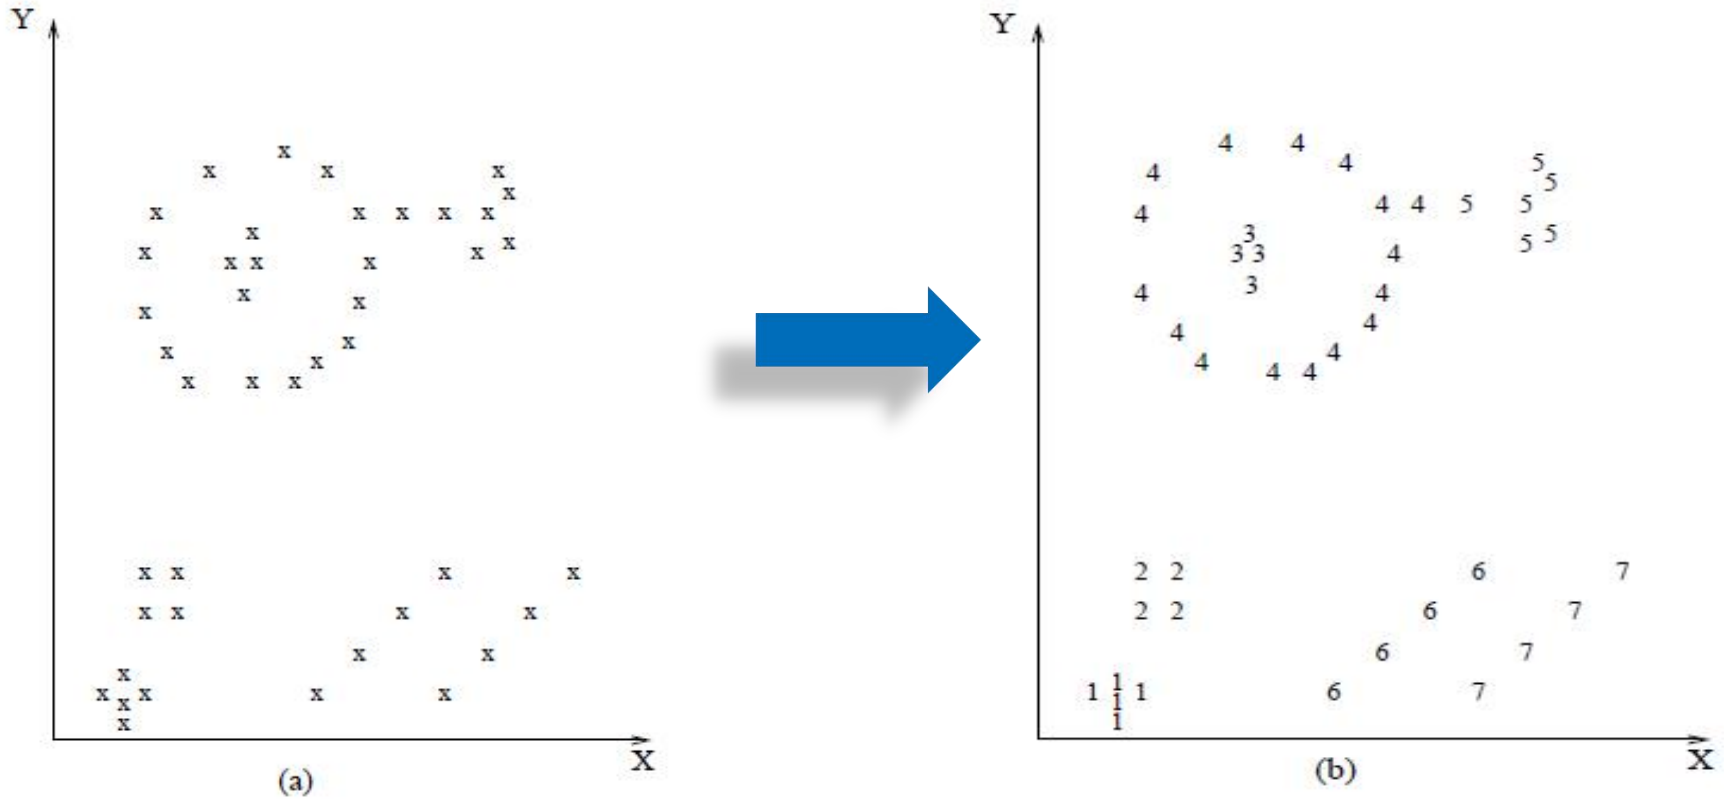
第 7 章　聚类

7 聚类

- 7.1 聚类分析
- 7.2 典型聚类应用
- 7.3 k-means聚类方法
- 7.4 典型聚类方法
- 7.5 评估

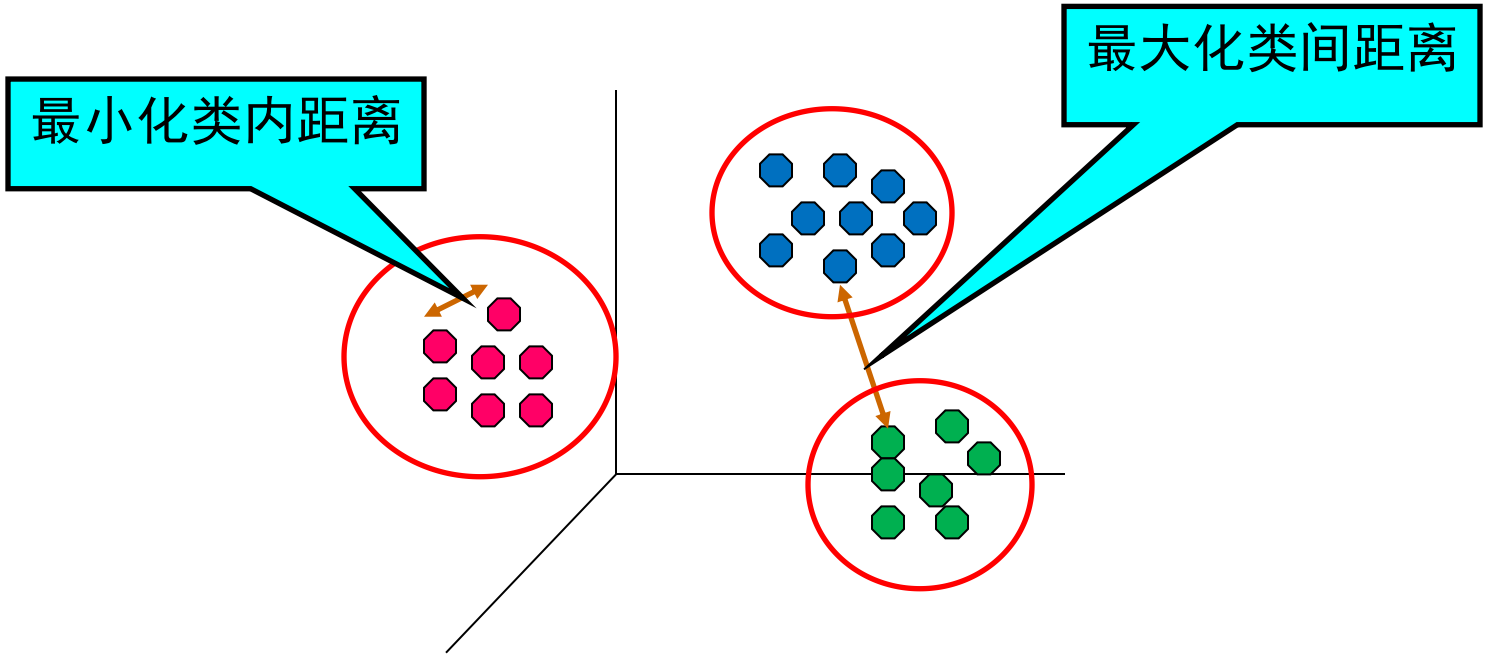
7.1 聚类分析

- 聚类分析Cluster analysis，简称聚类Clustering，是一个把数据对象划分为子集的过程。



7.1 聚类分析

- 簇Cluster：每一个子集是一个簇
  - 在同一个聚类（簇）中的对象彼此相似
  - 不同簇中的对象则相异



7.1 聚类分析

- 聚类是一种无指导的学习：没有预定义的类编号
- 一个好的聚类分析方法会产生高质量的聚类
  - 高类内相似度
  - 低类间相似度
- 聚类方法中主要的因素是距离或相似度
- 聚类分析的数据挖掘功能
  - 作为一个独立的工具来获得数据分布的情况
  - 作为其他算法（如：特征和分类）的预处理步骤

7.1 聚类分析

聚类分析示例数据集

样本序号	描述属性1	描述属性2
x_1	1	3
x_2	1	7.5
x_3	1.5	4
x_4	4.5	7.5
x_5	4	8.5
x_6	5.5	9
x_7	4.5	8

聚类分析的数据集
没有类别属性
没有训练集

7 聚类

- 7.1 聚类分析
- 7.2 典型聚类应用
- 7.3 k-means聚类方法
- 7.4 典型聚类方法
- 7.5 评估

7.2典型聚类应用

图像像素聚类

Original image



$K = 10$



$K = 3$



$K = 2$







7.2典型聚类应用

- 图像数据分析
  - 对相似区域进行聚类，产生主题地图
  - 图像数据集聚类
- 商务数据分析
  - 帮市场分析人员发现不同的顾客群
  - 企业信用等级聚类
- 万维网数据分析
  - 对WEB上的文档进行聚类
  - 对WEB日志的数据进行聚类，以发现相同的用户访问模式

7.2典型聚类应用

经济领域

- 帮助市场分析人员从客户数据库中发现不同的客户群，并且用购买模式来刻画不同的客户群的特征
- 对住宅区进行聚类，确定自动提款机ATM的安放位置
- 股票市场板块分析，找出最具活力的板块龙头股

生物学领域

- 推导植物和动物的分类
- 对基因聚类，获得对种群的认识

数据挖掘领域

- 作为其他数学算法的预处理步骤，获得数据分布状况，集中对特定的类做进一步的研究
- 离群点检测、数据归约

7.2典型聚类应用

- 客户数据集包含10,000条客户数据
- 特征(属性) 分别为:
  - Bank No(银行代码，其值有：004,024,077等)
  - Account num(账户代码)
  - Short Name(客户名字)
  - First Contact Date(第一次接触日期)
  - account open date(账户开户日期)
  - account balance(账户当前余额)
  - account low balance(账户曾经最低余额)
  - account high balance(账户曾经最高余额)
  - balance category(余额类型)
  - Statement Low Balance(最低交易账目，有正有负)
  - ……

7.2典型聚类应用

- 目标
  - 目的是对客户进行分群，从而使银行可以对不同群体的客户提供不同的服务。因此聚类分析是对客户进行自动分群的有效方法。
- 方法
  - k-means算法
- 选取的特征
  - 从31个原始属性值中选取23个属性用作聚类（都是数值型或标称型的）
- 聚类参数
  - 在经过规格化处理后的数据集中，用k-means算法在选定的23个属性上进行聚类，设定聚类数为10。

7.2典型聚类应用

- 各聚类所包含的客户数量如下表

聚类	客户数量
聚类1	145
聚类2	69
聚类3	133
聚类4	6183
聚类5	1985
聚类6	213
聚类7	46
聚类8	446
聚类9	413
聚类10	368

7.2典型聚类应用

对聚类大小的分析

聚类	客户数量
聚类1	145
聚类2	69
聚类3	133
聚类4	6183
聚类5	1985
聚类6	213
聚类7	46
聚类8	446
聚类9	413
聚类10	368

- 各聚类有大有小，且大小悬殊，但也合乎客户关系处理的目的。客户关系管理的往往是找出一小部分的特殊客户（占20%左右）来进行特别地对待。
- 在表中所示的10个聚类中，除去最大的聚类4后其余9个聚类的客户数达3818人，占总客户量的38.18%；除去最大的两个聚类（聚类4和聚类5）后其余8个聚类的客户数达1833人，占总客户量的18.33%。

7.2典型聚类应用

对聚类大小的分析

聚类	客户数量
聚类1	145
聚类2	69
聚类3	133
聚类4	6183
聚类5	1985
聚类6	213
聚类7	46
聚类8	446
聚类9	413
聚类10	368

大聚类可以再继续细分（作为一个数据集再继续进行聚类操作，或直接提高聚类个数）

对各聚类结果的处理

- 聚类后的各聚类结果的数据是规格化处理后的数据的结果，我们要直观地分析各聚类的特点，必须把规格化的数据还原为原始数据。例如，最小值为-10,000，最大值为1,000,000的当前账户余额规格化为[0,1]后就难以理解各账户间存在的巨大差距，只有把它还原为原始的[-10,000, 1,000,0000]才能使人直观地理解其存在的差距。
- 把各聚类的数据集还原为原始数据后，再计算各特征的均值和标准差（数值型的特征）；或者各标称量的数量（标称型的特征）。

聚类结果分析(账户当前余额)

- 下表所示为10个聚类中各聚类的账户当前余额的正负及账户当前余额的均值和标准差

聚类	当前余额正负		当前余额值	
	+	–	均值	标准差
聚类1	145	0	24445.50	73408.73
聚类2	69	0	29164.41	78077.97
聚类3	133	0	152882.48	604633.58
聚类4	6182	1	5571.17	23957.76
聚类5	1985	0	22102.61	64825.42
聚类6	119	94	8432.82	18680.66
聚类7	46	0	2093.91	5798.48
聚类8	380	66	7729.67	33233.11
聚类9	0	413	-24728.68	61844.23
聚类10	368	0	36264.24	93389.14

7.2典型聚类应用

聚类	当前余额正负		当前余额值	
	+	–	均值	标准差
聚类1	145	0	24445.50	73408.73
聚类2	69	0	29164.41	78077.97
聚类3	133	0	152882.48	604633.58
聚类4	6182	1	5571.17	23957.76
聚类5	1985	0	22102.61	64825.42
聚类6	119	94	8432.82	18680.66
聚类7	46	0	2093.91	5798.48
聚类8	380	66	7729.67	33233.11
聚类9	0	413	-24728.68	61844.23
聚类10	368	0	36264.24	93389.14

聚类3的客户群，该聚类的当前余额均值达十五万左右，比其他聚类的当前余额均值高出一个数量级。

初步判断该聚类的客户是存款额高或者说是高收入的客户群。

该聚类当前余额的标准差也很大，这说明在富有的客户群中各客户的收入差距也很大，有的达百万、千万、甚至上亿。

7.2典型聚类应用

聚类	当前余额正负		当前余额值	
	+	–	均值	标准差
聚类1	145	0	24445.50	73408.73
聚类2	69	0	29164.41	78077.97
聚类3	133	0	152882.48	604633.58
聚类4	6182	1	5571.17	23957.76
聚类5	1985	0	22102.61	64825.42
聚类6	119	94	8432.82	18680.66
聚类7	46	0	2093.91	5798.48
聚类8	380	66	7729.67	33233.11
聚类9	0	413	-24728.68	61844.23
聚类10	368	0	36264.24	93389.14

聚类9客户群：该客户群中的413个客户当前账户余额都为负值，且其均值达负两万多元。

可以认定该客户群是高透支的客户群。后面还会分析的透支额、透支次数、透支时间等属性的分析同样可以印证我们这个结论。

7.2典型聚类应用

聚类	当前余额正负		当前余额值	
	+	–	均值	标准差
聚类1	145	0	24445.50	73408.73
聚类2	69	0	29164.41	78077.97
聚类3	133	0	152882.48	604633.58
聚类4	6182	1	5571.17	23957.76
聚类5	1985	0	22102.61	64825.42
聚类6	119	94	8432.82	18680.66
聚类7	46	0	2093.91	5798.48
聚类8	380	66	7729.67	33233.11
聚类9	0	413	-24728.68	61844.23
聚类10	368	0	36264.24	93389.14

聚类4是占61.81%的最大的普通客户群，该客户群中几乎所有的客户的当前余额都为正值，其均值为五千多，标准差为两万多不会太小，说明该庞大的客户群还是可以再继续细分的。

7.2典型聚类应用

聚类	当前余额正负		当前余额值	
	+	–	均值	标准差
聚类1	145	0	24445.50	73408.73
聚类2	69	0	29164.41	78077.97
聚类3	133	0	152882.48	604633.58
聚类4	6182	1	5571.17	23957.76
聚类5	1985	0	22102.61	64825.42
聚类6	119	94	8432.82	18680.66
聚类7	46	0	2093.91	5798.48
聚类8	380	66	7729.67	33233.11
聚类9	0	413	-24728.68	61844.23
聚类10	368	0	36264.24	93389.14

聚类5是占19.85%的第二大客户群，该客户群比最大的客户群聚类4来说它的当前余额均值高很多，可达两万多元。

聚类5是大量普通客户中的中等存款额度的账户（不包括低存款额度账户）。

7.2典型聚类应用

聚类	当前余额正负		当前余额值	
	+	–	均值	标准差
聚类1	145	0	24445.50	73408.73
聚类2	69	0	29164.41	78077.97
聚类3	133	0	152882.48	604633.58
聚类4	6182	1	5571.17	23957.76
聚类5	1985	0	22102.61	64825.42
聚类6	119	94	8432.82	18680.66
聚类7	46	0	2093.91	5798.48
聚类8	380	66	7729.67	33233.11
聚类9	0	413	-24728.68	61844.23
聚类10	368	0	36264.24	93389.14

聚类7是账户当前余额为正值但存款额度较低客户群。

聚类1，2，6，8和10这五个聚类在当前账户余额这一属性上不能发现其明显的特征，我们将在后续的其他属性上的分析发现其聚类特征。

7 聚类

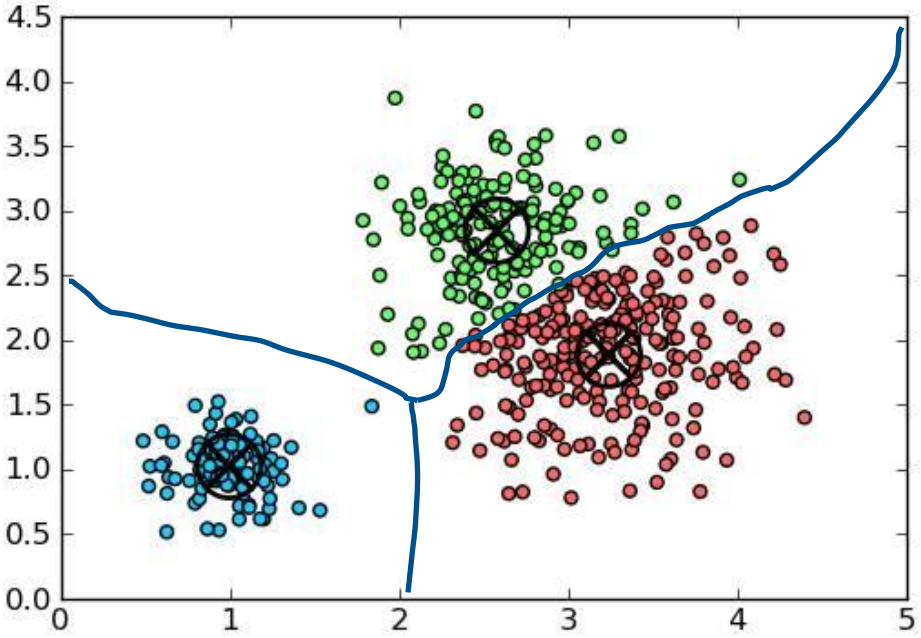
- 7.1 聚类分析
- 7.2 典型聚类应用
- 7.3 k-means聚类方法
- 7.4 典型聚类方法
- 7.5 评估

7.3 k-means聚类方法

- 划分聚类方法
  - 选择合适的初始代表点将数据样本进行初始聚类，之后通过不断迭代的过程对聚类的结果进行不断的调整，直到满足聚类评价的准则为止。
  - 通常通过计算对象间距离进行划分

7.3 k-means聚类方法

- 划分聚类方法
  - 选择合适的初始代表点将数据样本进行初始聚类，之后通过不断迭代的过程对聚类的结果进行不断的调整，直到满足聚类评价的准则为止。
  - 通常通过计算对象间距离进行划分



7.3 k-means聚类方法

- 划分聚类方法
  - 选择合适的初始代表点将数据样本进行初始聚类，之后通过不断迭代的过程对聚类的结果进行不断的调整，直到满足聚类评价的准则为止。
  - 通常通过计算对象间距离进行划分
- 典型的划分方法
  - k-means
  - k-中心点
  - 以上两种方法的变种

7.3 k-means聚类方法

划分聚类方法对数据集聚类时的三个要点

- 选定某种距离作为数据样本间的相似性度量

可以根据实际需要选择欧氏距离、曼哈顿距离或者明考斯基距离中的一种来作为算法的相似性度量，其中最常用的是欧氏距离。

- 选择评价聚类性能的准则函数

误差平方和准则函数表示数据集中的所有样本与相应聚类中心的方差之和，该准则的值达到最优时可以便各个聚类类内尽可能地紧凑，而各个聚类之间则尽可能地分开。

- 选择某个初始分类，之后用迭代方法得到聚类结果，使得评价聚类的准则函数取得最优值

为了得到最优的聚类结果，首先要对给定数据集进行初始划分，通常的做法是事先从数据集中选择各个聚类的代表点，之后把其余的数据样本按照某种方式归类到相应的聚类中去。

数据挖掘领域的十大经典算法ICDM'06

- #1: C4.5 (61 votes) (分类)
- #2: k-means (60 votes) (聚类)
- #3: SVM (58 votes) (分类)
- #4: Apriori (52 votes) (关联规则)
- #5: EM (48 votes)
- #6: PageRank (46 votes)
- #7: AdaBoost (45 votes)
- #7: kNN (45 votes) (分类)
- #7: Naive Bayes (45 votes) (分类)
- #10: CART (34 votes) (分类)

7.3.1 k-means聚类步骤

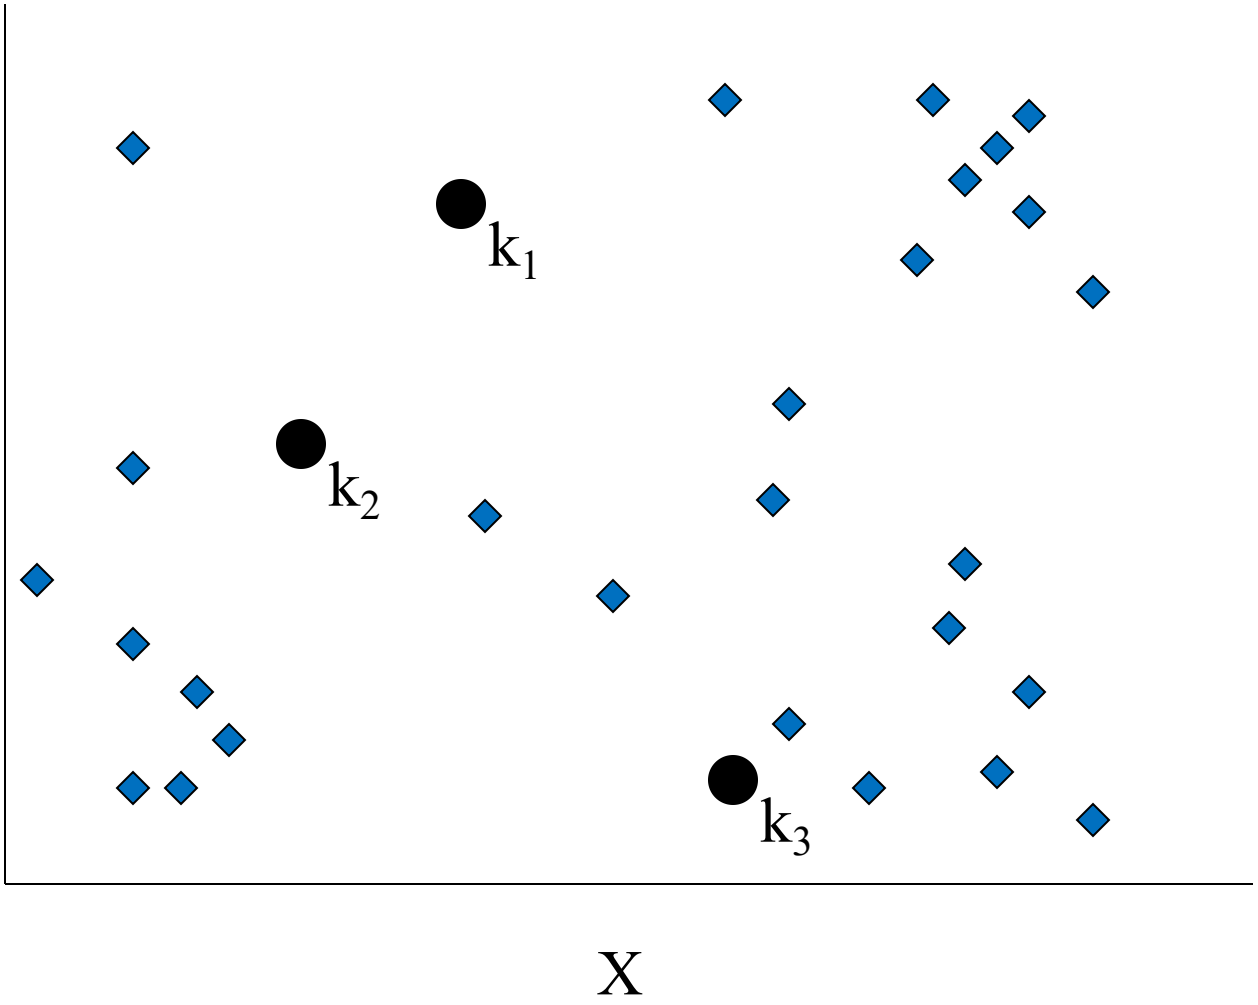
- k-means聚类算法是划分聚类方法中最常用、最流行的经典算法，许多其他的方法都是k-means聚类算法的变种。
- k-means聚类算法将各个聚类子集内的所有数据样本的均值作为该聚类的代表点，算法的主要思想是通过迭代过程把数据集划分为不同的类别，使得评价聚类性能的准则函数达到最优，从而使生成的每个聚类类内紧凑，类间独立。
- k-means聚类算法不适合处理离散型属性，但是对于连续型属性具有较好的聚类效果。

J. MacQueen (1967): Some Methods for Classification and Analysis of Multivariate Observations, *Proceedings of the 5th Berkeley Symposium on Mathematical Statistics and Probability*, vol.1, pp. 281-297. (引用次数32127)

7.3.1 k-means聚类步骤

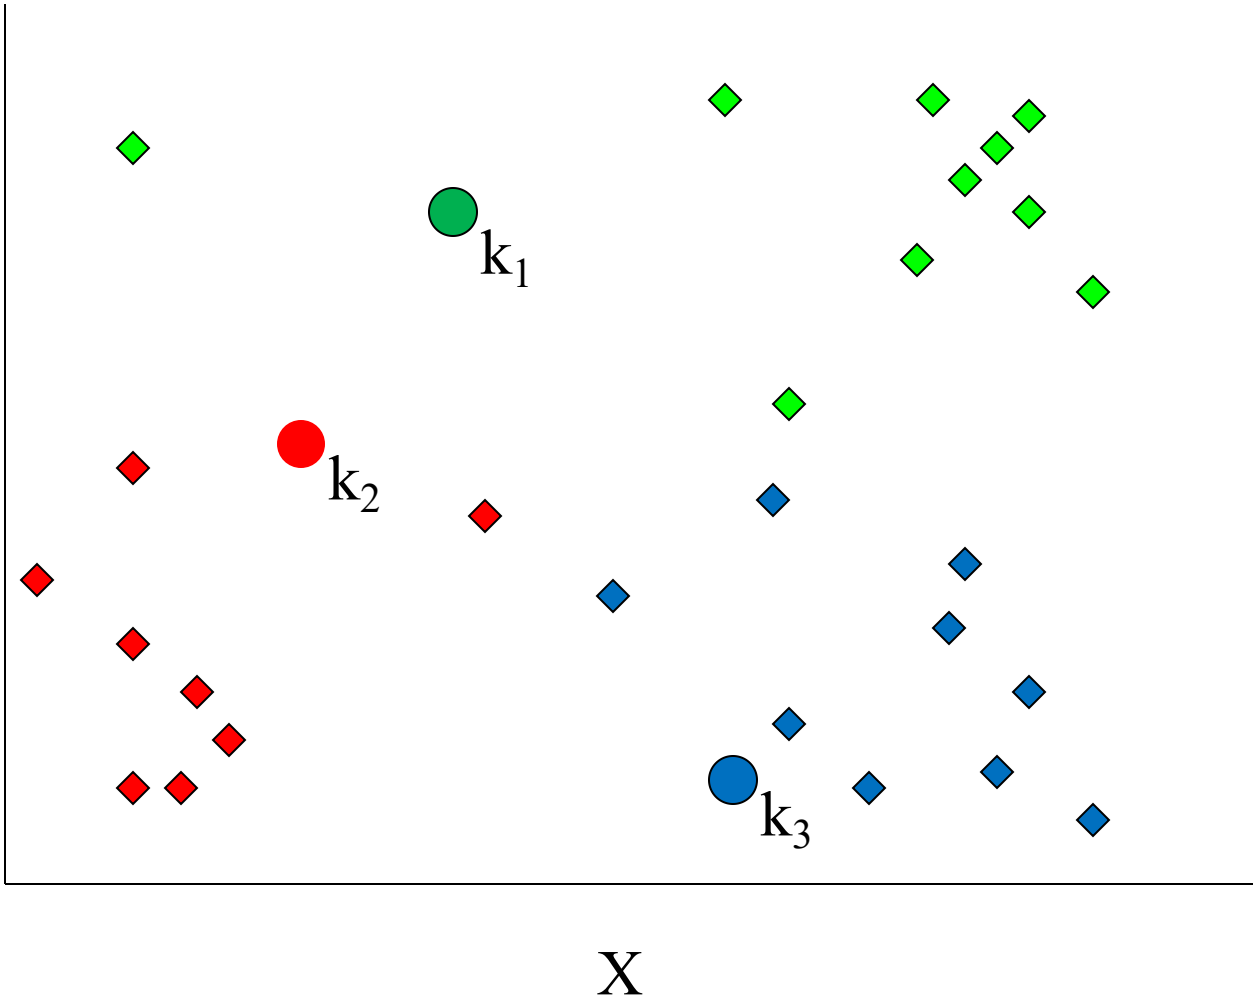
k-means样例, 步骤 1

随机选择3个样本点作为初始的聚类中心



7.3.1 k-means聚类步骤

k-means样例, 步骤 2

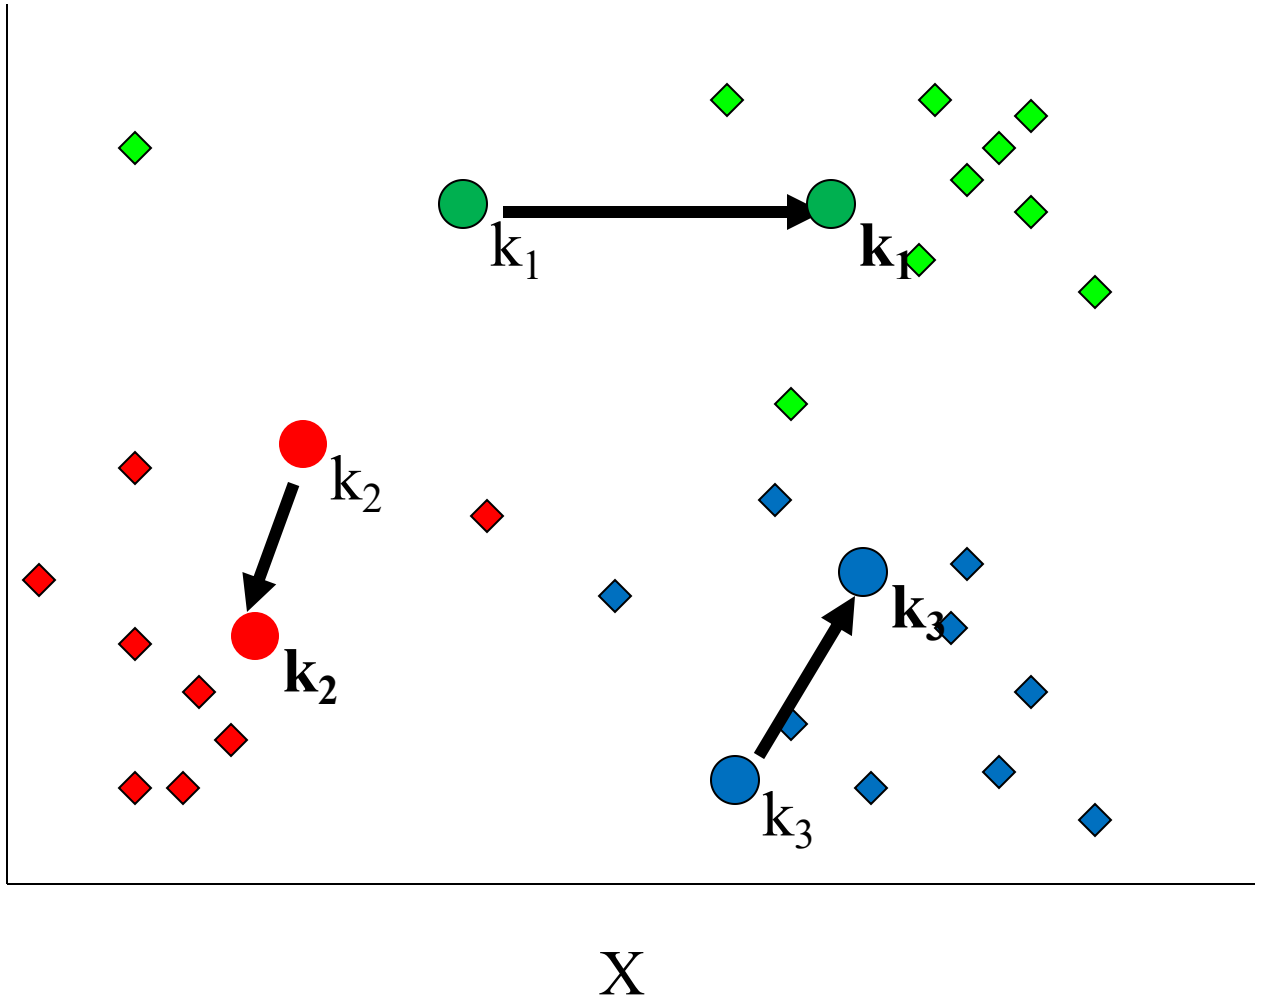


把每个点分到离它最近的类中

7.3.1 k-means聚类步骤

k-means样例, 步骤 3

计算每个类的均值，移动类中心

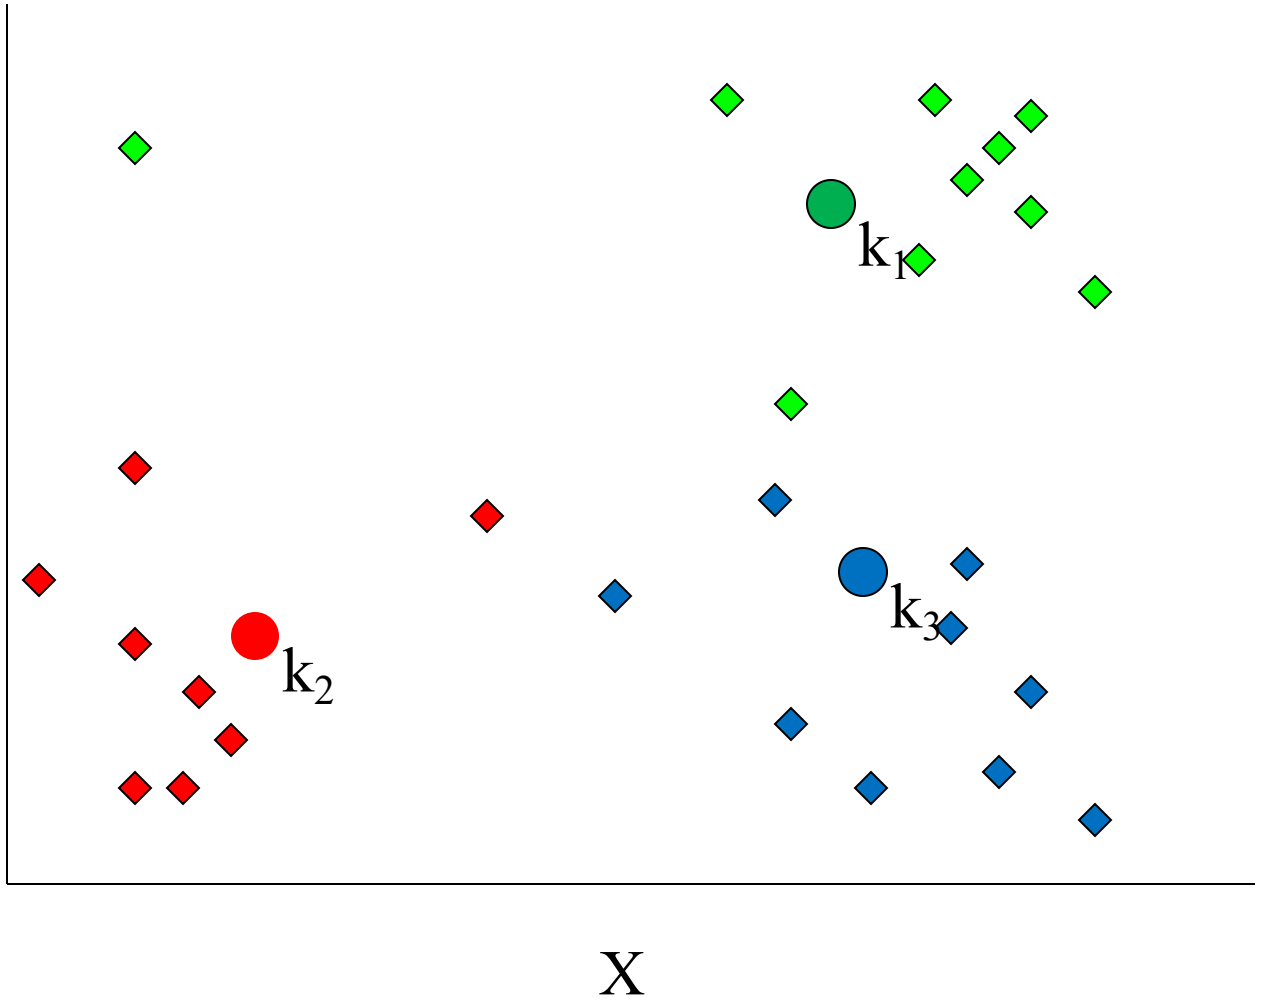


7.3.1 k-means聚类步骤

k-means样例, 步骤 4

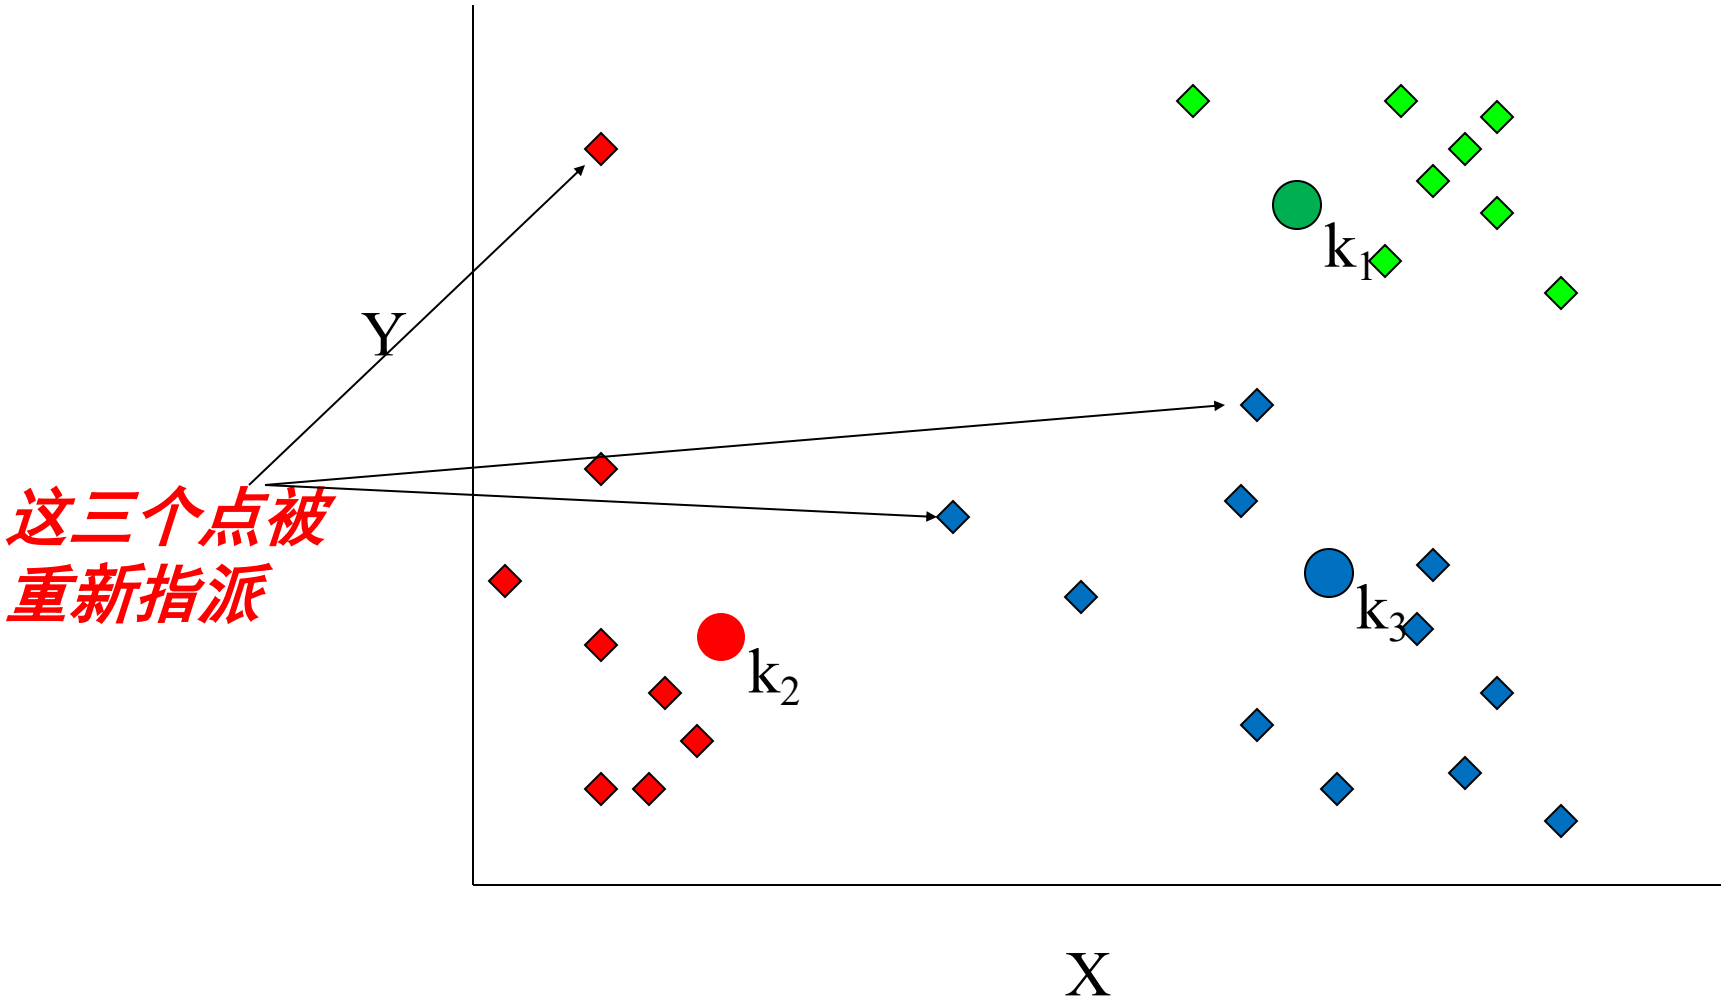
重新给每个样本指派其所属的类别

哪些点被重新分配?



7.3.1 k-means聚类步骤

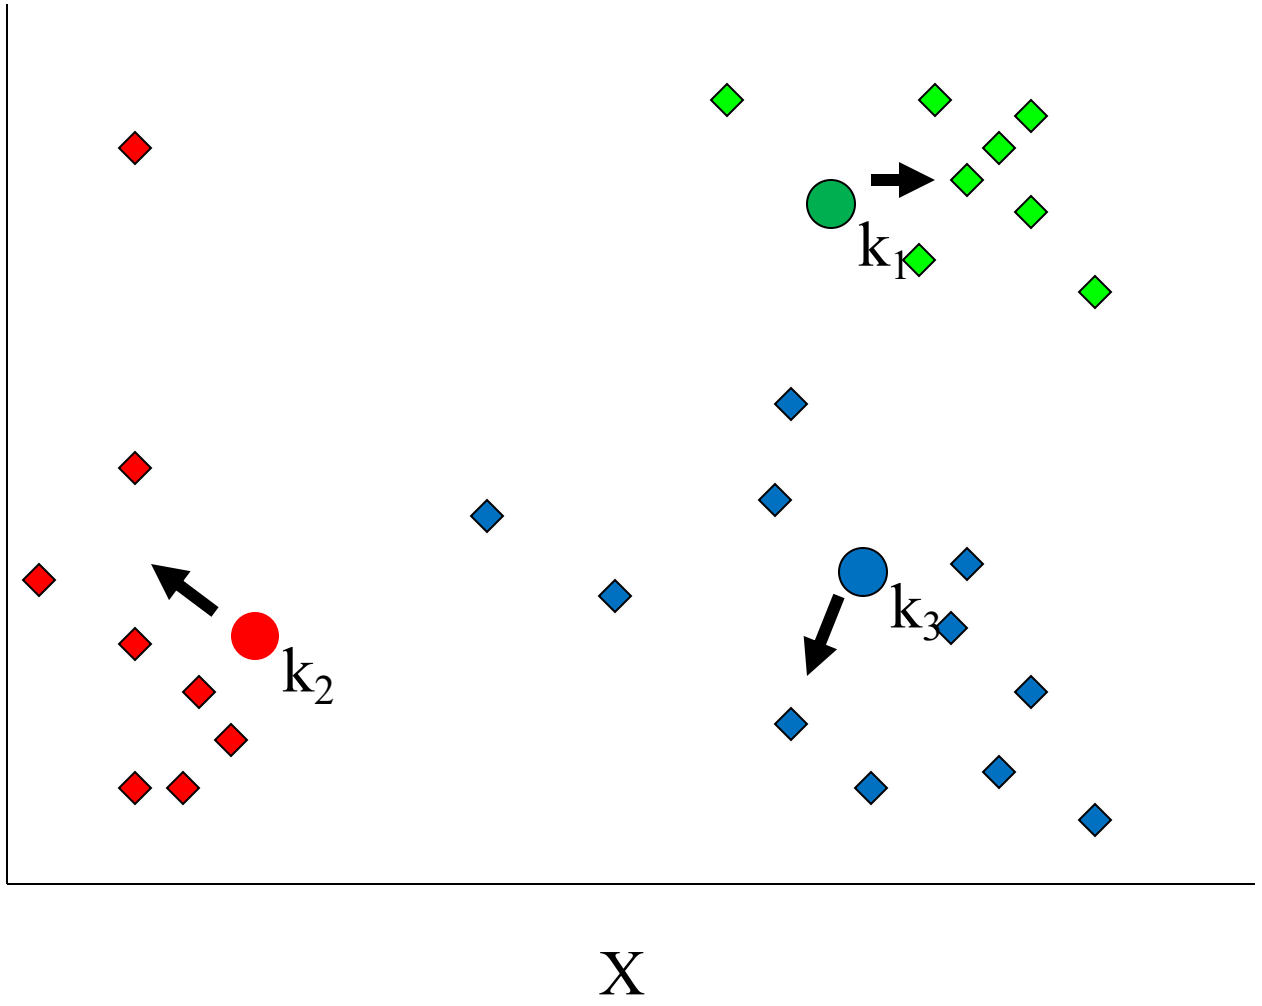
k-means样例, 步骤 4



7.3.1 k-means聚类步骤

k-means样例, 步骤 5

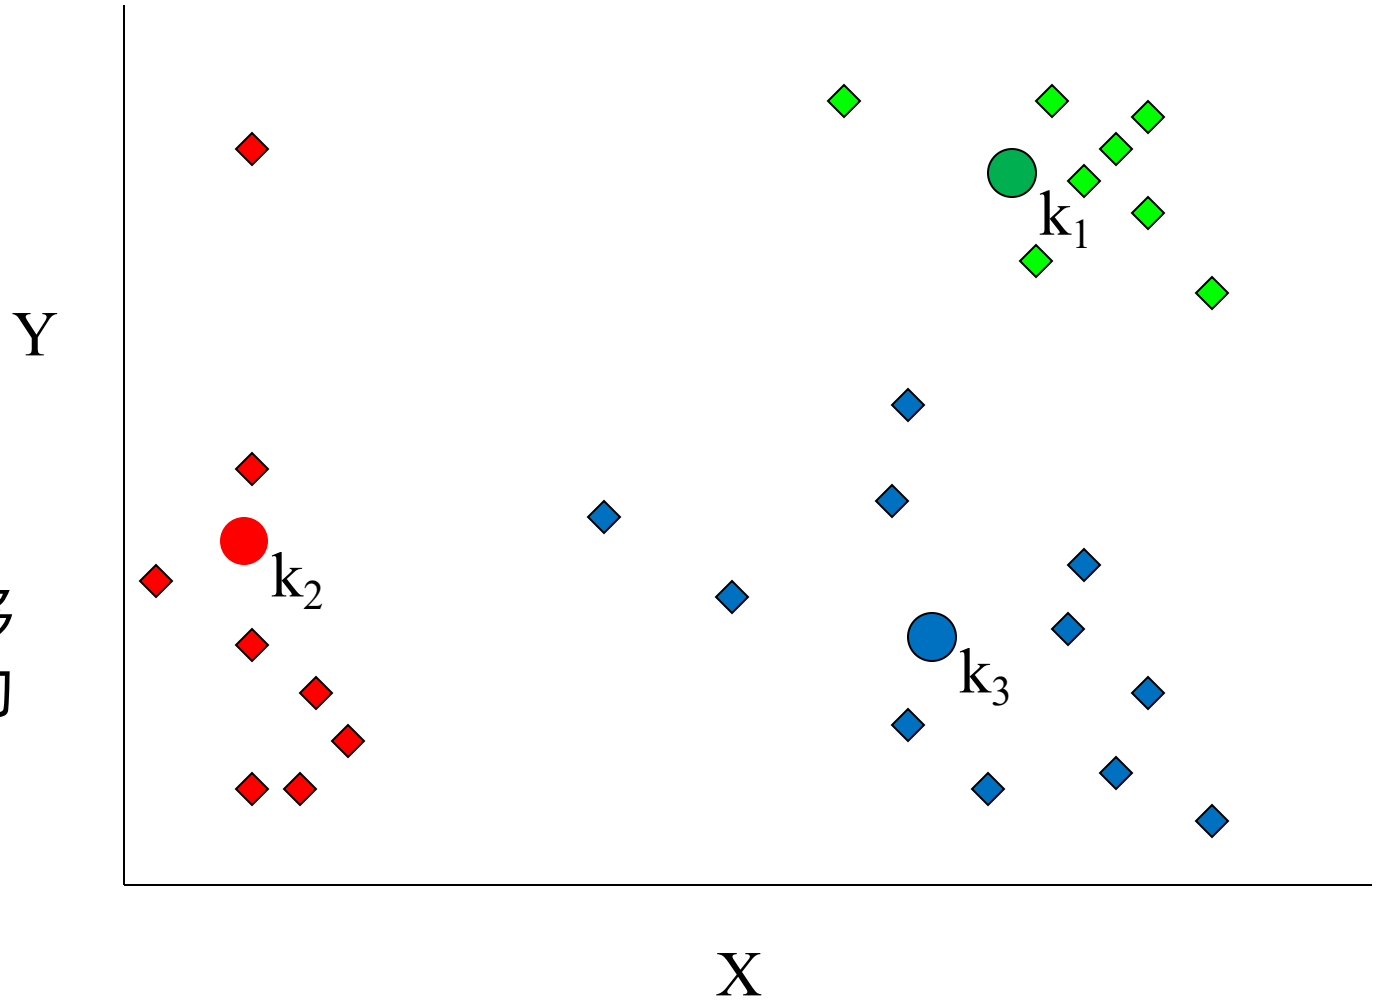
重新计算每一类的均值



7.3.1 k-means聚类步骤

k-means样例, 步骤 5

把类中心移动到均值的位置



7.3.1 k-means聚类步骤

k-means聚类算法的操作步骤

输入：数据集$X=\{\boldsymbol{x}_j|j=1,2,...,\text{total}\}$，其中的数据样本也只包含描述属性，不包含类别属性；聚类个数k。

输出：使误差平方和准则最小的k个聚类。

（1）从数据集X中随机地选择k个数据样本作为聚类的初始代表点，每一个代表点表示一个类别。

（2）对于X中的任一数据样本$\boldsymbol{x}_j$，$(1\leq j\leq \text{total})$，计算它与$k$个初始代表点的距离，并且将它划分到距离最近的初始代表点所表示的类别中。

（3）完成数据样本的划分之后，对于每一个聚类，计算其中所有数据样本的均值，并且将其作为该聚类的新的代表点，由此得到k个均值代表点。

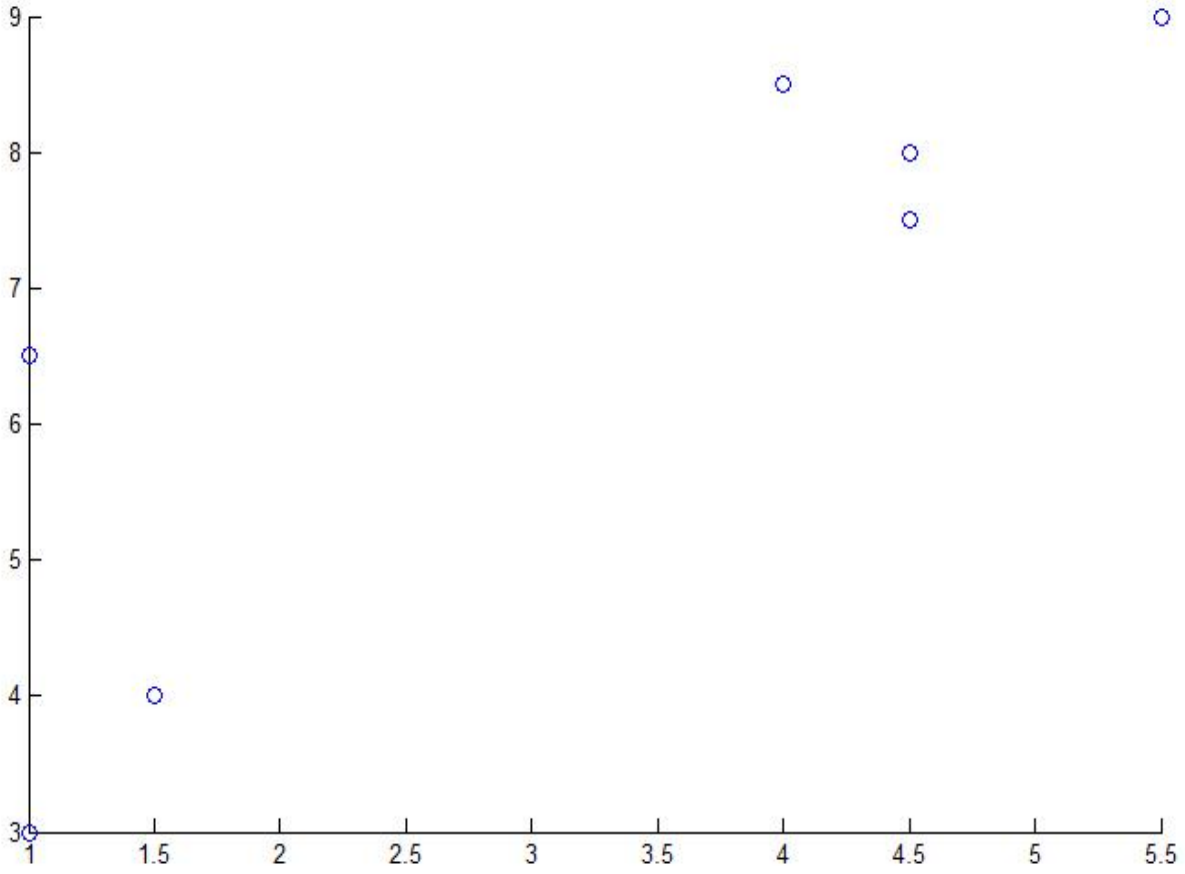
（4）对于X中的任一数据样本$\boldsymbol{x}_j$，$(1\leq j\leq \text{total})$，计算它与$k$个均值代表点的距离，并且将它划分到距离最近的均值代表点所表示的类别中。

（5）重复步骤（3）和（4），直到各个聚类不再发生变化为止，即误差平方和准则函数的值达到最优。

7.3.1 k-means聚类步骤

k-means实例

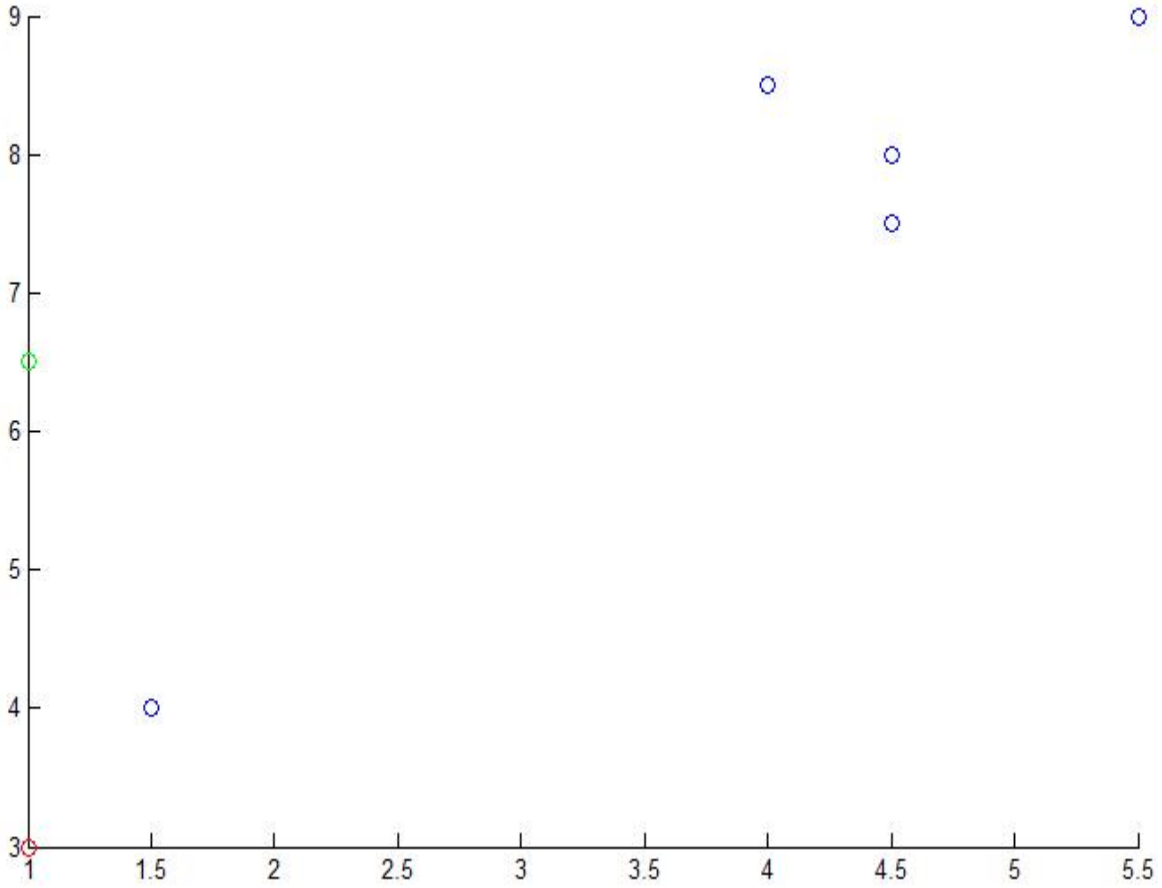
1	3
1	6.5
1.5	4
4.5	7.5
4	8.5
5.5	9
4.5	8



7.3.1 k-means聚类步骤

随机选择初始点

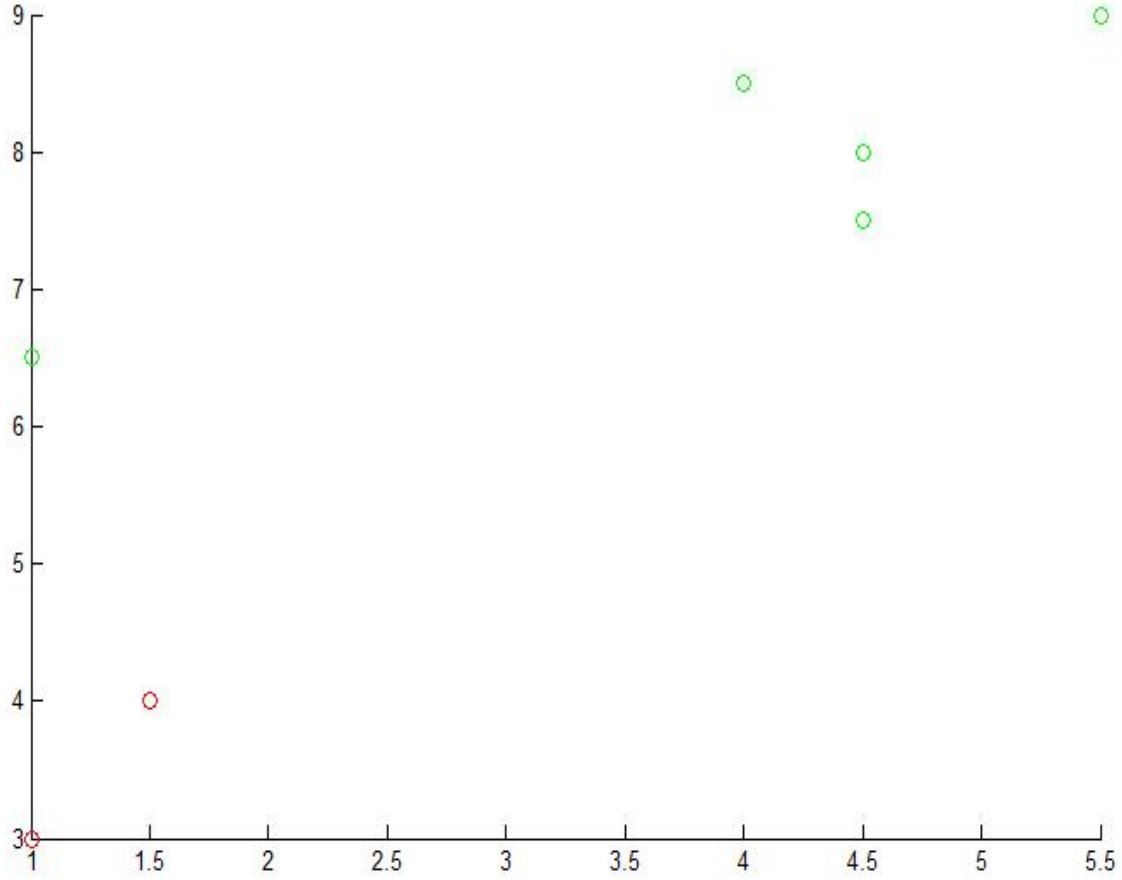
1	3
1	6.5



7.3.1 k-means聚类步骤

计算每个样本到中心的距离，进行指派

0	12.3
12.3	0
1.25	6.5
32.5	13.3
39.3	13
56.3	26.5
37.3	14.5

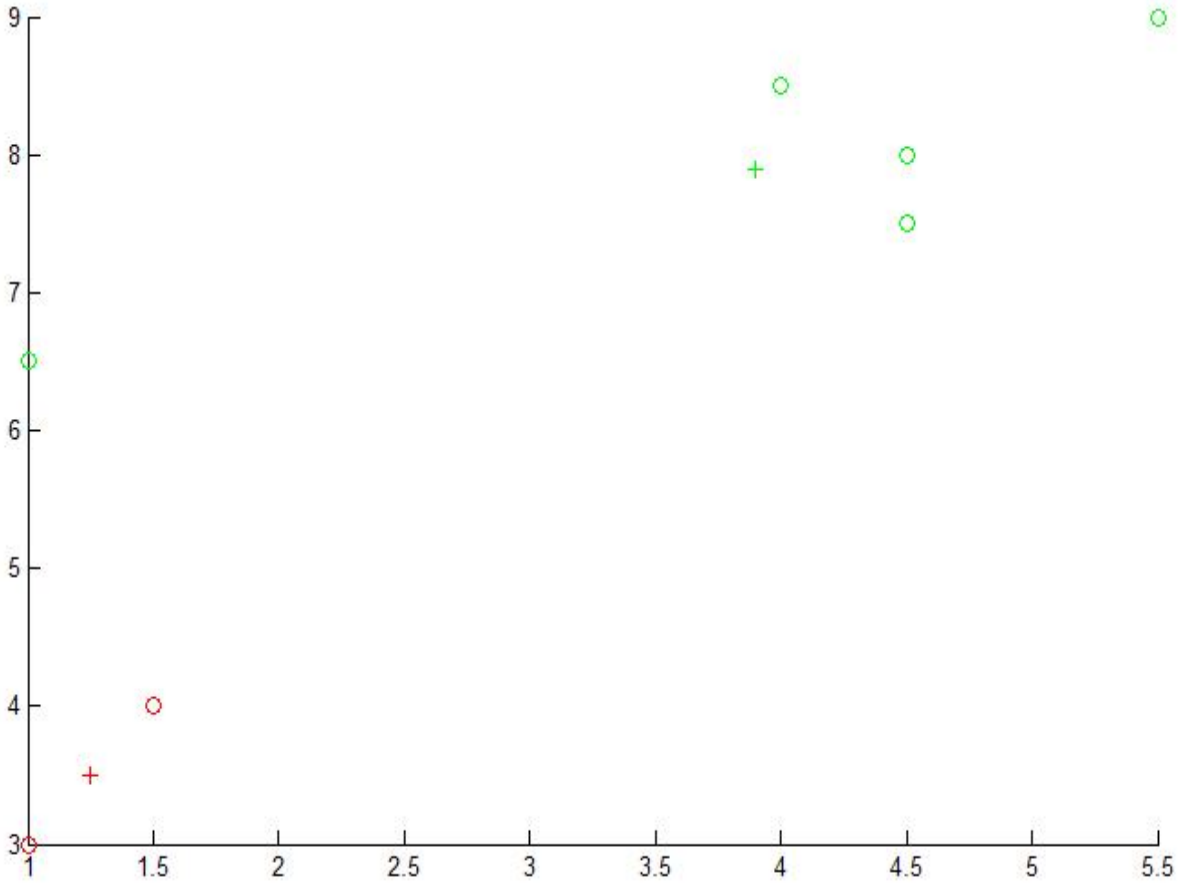


1
2
1
2
2
2
2

7.3.1 k-means聚类步骤

重新计算中心点

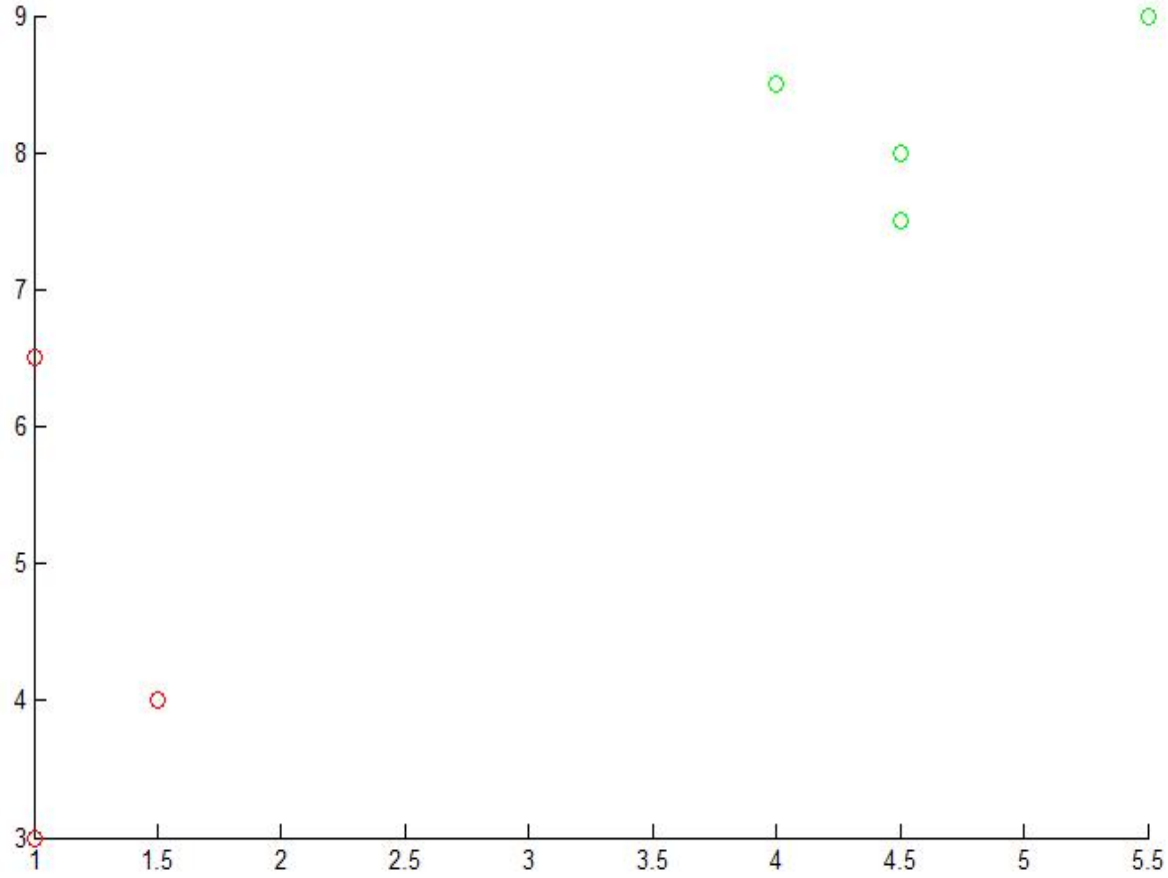
1.25	3.5
3.9	7.9



7.3.1 k-means聚类步骤

计算每个样本到中心的距离，进行指派

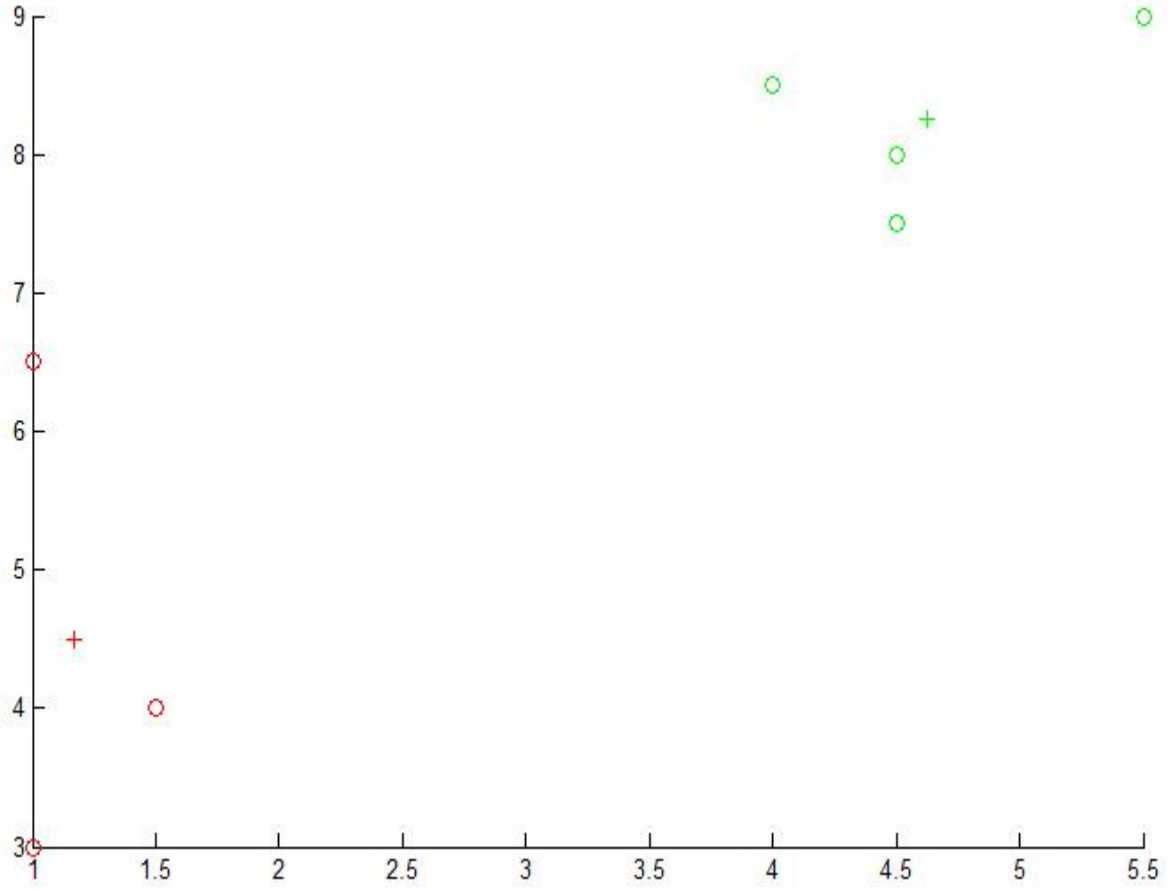
0.31	32.4	1
9.06	10.4	1
0.31	21	1
26.6	0.52	2
32.6	0.37	2
48.3	3.77	2
30.8	0.37	2



7.3.1 k-means聚类步骤

重新计算中心点

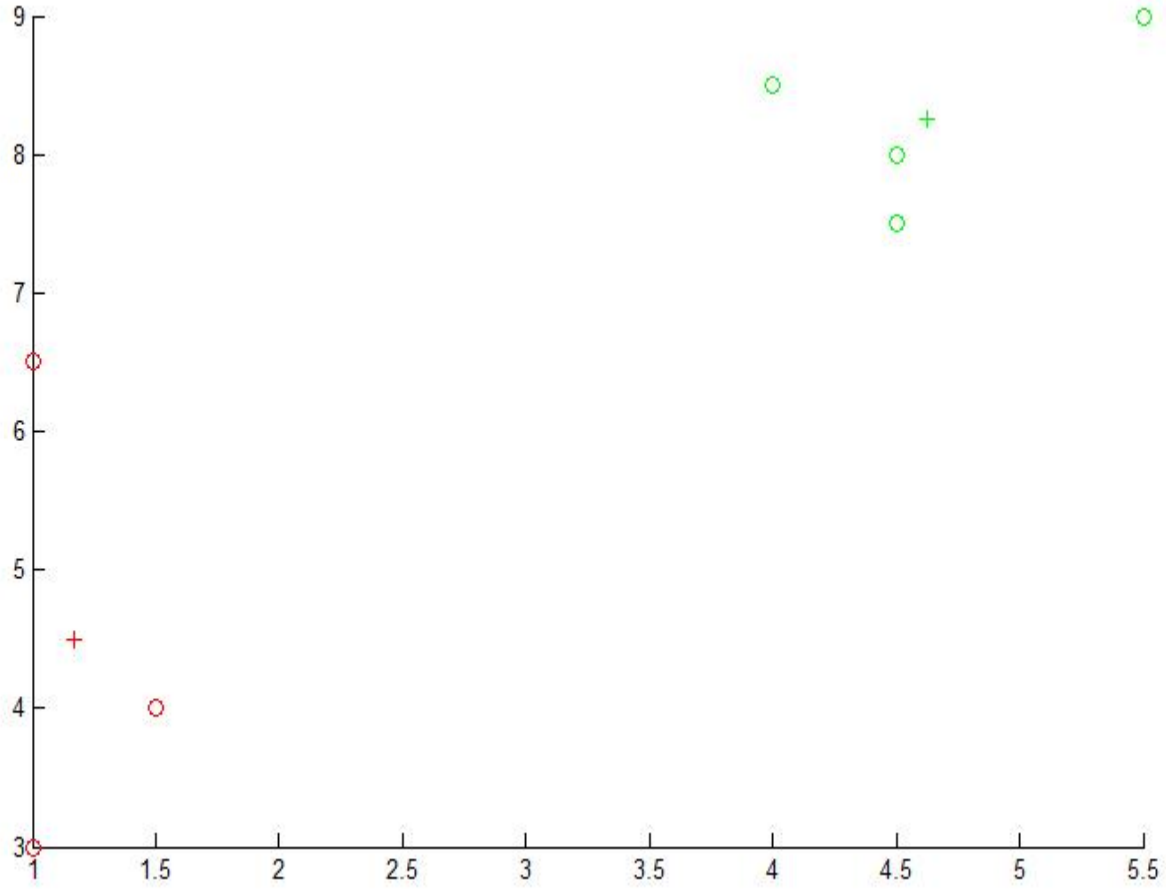
1.17	4.5
4.63	8.25



7.3.1 k-means聚类步骤

计算每个样本到中心的距离，进行指派

2.28	40.7	1
4.03	16.2	1
0.36	27.8	1
20.1	0.58	2
24	0.45	2
39	1.33	2
23.4	0.08	2



7.3.1 k-means聚类步骤

- k-means聚类算法按照数据样本间的相似性把数据集聚类为若干个子集，聚类的结果使评价聚类性能的误差平方和准则函数的值达到最优。

$$J_e = \sum_{i=1}^{c} \sum_{x \in D_i} \left\| x - m_i \right\|^2, \qquad m_i = \frac{1}{n_i} \sum_{x \in D_i} x$$

- 聚类过程中通常使用欧氏距离作为样本间的相似性度量，从而把给定数据集的特征空间划分为若干个子区间，每一个子区间相当于一个聚类。

7.3.2 k-means聚类方法的优点

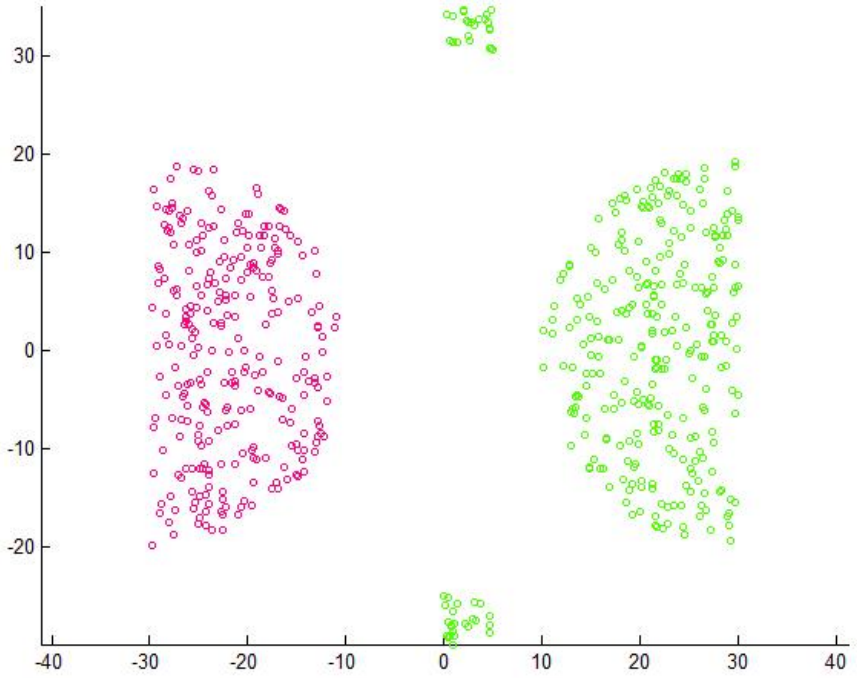
- 与层次聚类相比，k均值可以得到更紧密的簇，尤其是对于球状簇。
- 对大数据集，是可伸缩和高效率的。
- 算法尝试找出使平方误差函数值最小的k个划分。当结果簇是密集的，而簇与簇之间区别明显的时候，效果较好。

7.3.3 k-means聚类方法的缺点

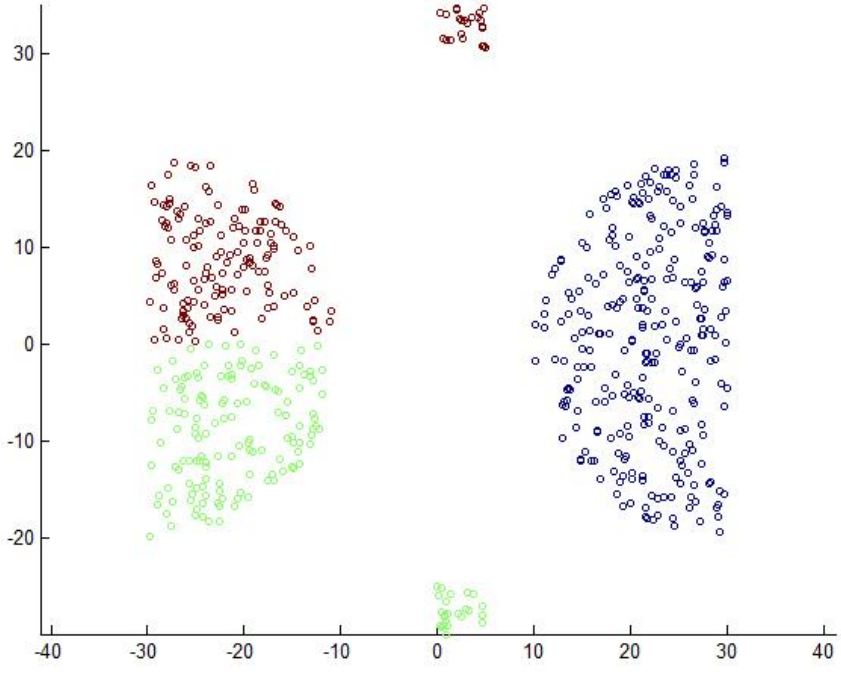
- 1. 聚类的个数
- 2. 对初始值敏感
- 3. 对噪声点非常敏感

7.3.4 k-means聚类的改进方法

1. 聚类的个数



K=2时的聚类结果



K=3时的聚类结果

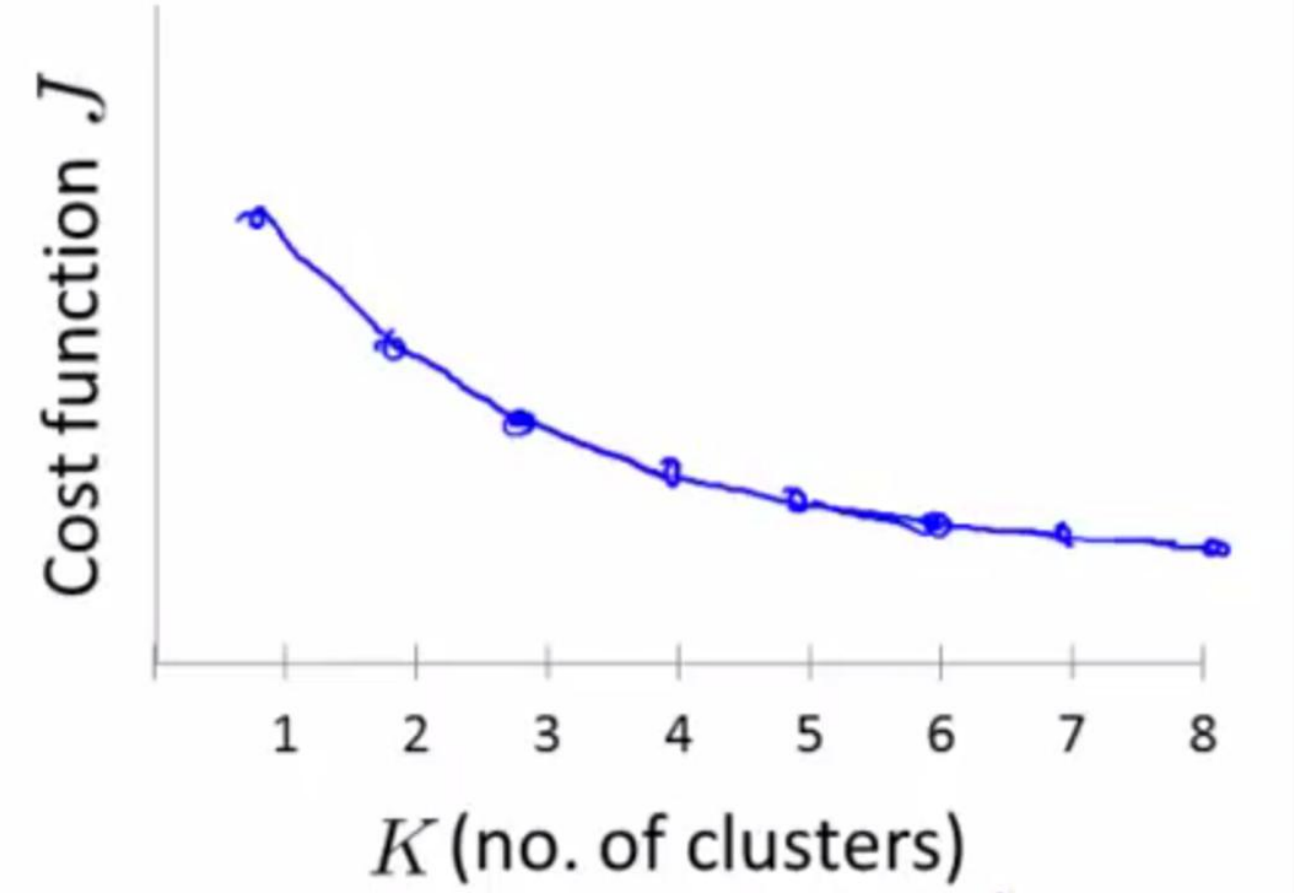
7.3.4 k-means聚类的改进方法

k-means聚类算法中聚类子集的个数k是事先给定的，在此基础上再试图得到一个最优的聚类性能。

- 首先采用层次凝聚算法决定结果簇的数目，并找到一个初始聚类，然后用迭代重定位来改进该聚类。
- 当聚类子集的个数不能确定时，可以对不同的k值使用多次k-means聚类算法，随着k值的增加，评价聚类性能的误差平方和准则函数的值会相应减小。由此，根据k值的变化可以得到一个误差平方和准则函数变化的曲线，从曲线的变化规律，结合实际问题的经验，找到一个相对最合适的聚类个数。

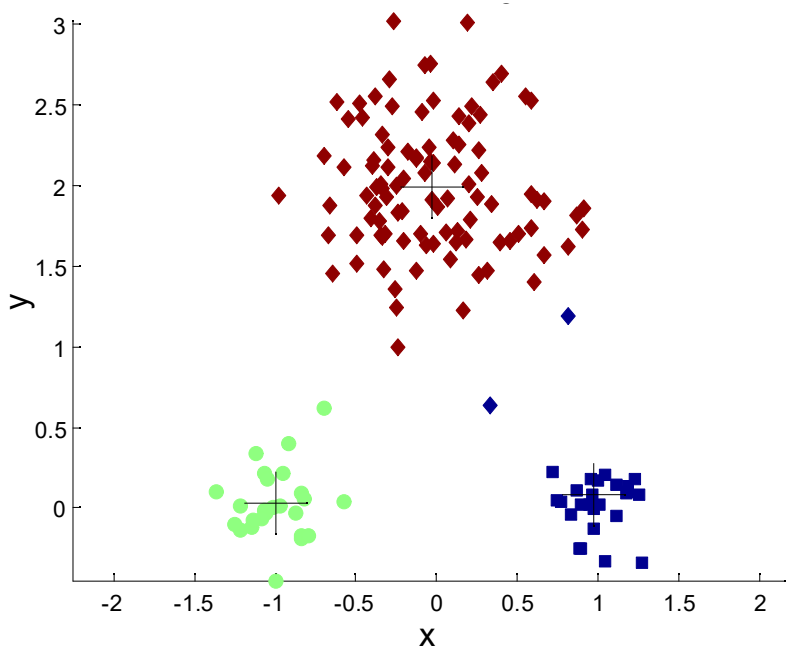
7.3.4 k-means聚类的改进方法

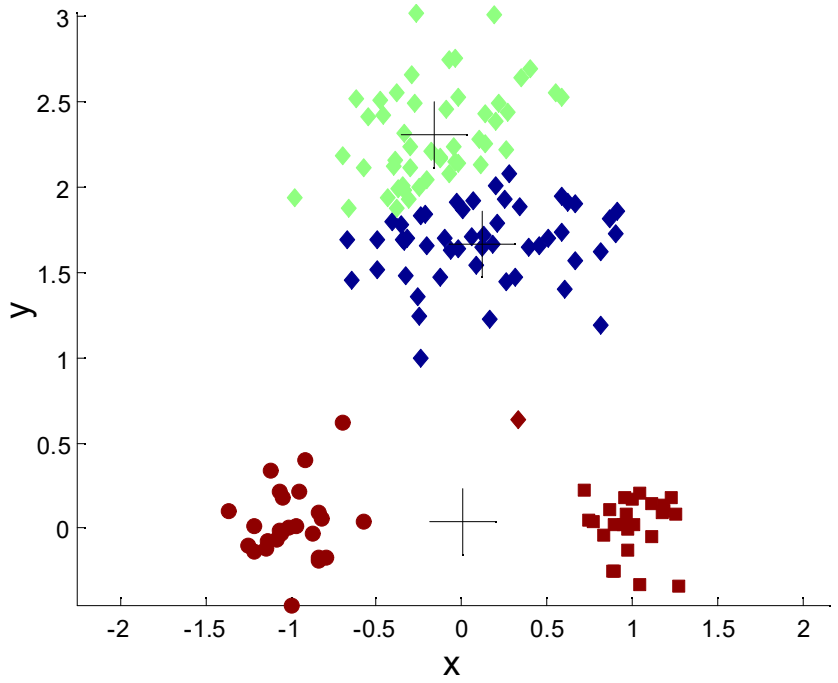
绘制目标函数的损失值对应的质心点数的折线图



7.3.4 k-means聚类的改进方法

2. 对初始值敏感





7.3.4 k-means聚类的改进方法

关于聚类初始代表点的选择，一般有以下几种方法。

- 根据实际问题的特点，按照经验来确定聚类子集的数量，从数据中找出从直观上看来是比较合适的k个聚类的初始代表点。
- 随机地选择k个数据样本作为聚类的初始代表点。
- 将数据集随机地分成k个聚类，之后计算每个聚类的均值，并且将这些均值作为各个聚类的初始代表点。
- 在k-means之前先进行一轮k-means，找到一个初始聚类，然后用迭代重定位来改进该聚类。

聚类初始代表点的选择往往会影响聚类的最终性能，即得到的是局部最优解而不是全局最优解。

7.3.4 k-means聚类的改进方法

3. 对噪声点非常敏感

改进措施：

- 样本数据预处理。计算样本对象两两之间的距离，筛掉与其它所有样本的距离和最大的m个对象。
- 初始聚类中心的选择。如不采用簇中的平均值作为参考点，而选用簇中位置最靠近中心的对象。这样可以避免孤立点的影响。

7.3.4 k-means聚类的改进方法

改进的算法：k-中心点(k-medoids) 方法。选取一个对象叫做mediod来代替上面的中心的作用，这样的一个medoid就标识了这个类。

k-medoids和k-means不一样的地方在于中心点的选取

- 在k-means中，将中心点取为当前cluster中所有数据点的平均值
- 在 k-medoids算法中，将从当前cluster 中选取这样一个点——它到其他所有（当前cluster中的）点的距离之和最小——作为中心点

7 聚类

- 7.1 聚类分析
- 7.2 典型聚类应用
- 7.3 k-means聚类方法
- 7.4 典型聚类方法
- 7.5 评估

数据类型

- 中心型Center-based

  簇的中心通常在簇中所有点的平均值附近



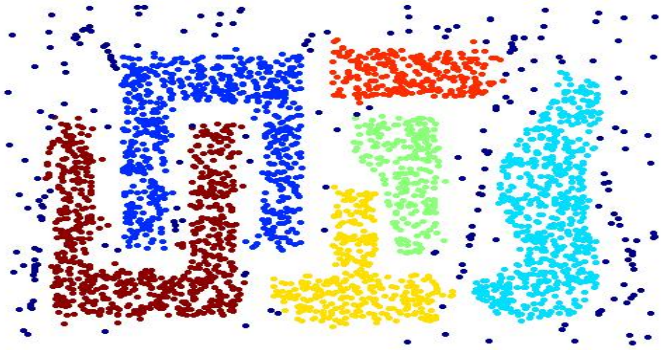
4 center-based clusters

7.4 典型聚类方法

数据类型

- 密度型Density-based
  - A cluster is a dense region of points, which is separated by low-density regions, from other regions of high density.
  - Used when the clusters are irregular or intertwined, and when noise and outliers are present.





数据类型

- 连续型Contiguous Cluster (Nearest neighbor or Transitive)



5 contiguous clusters

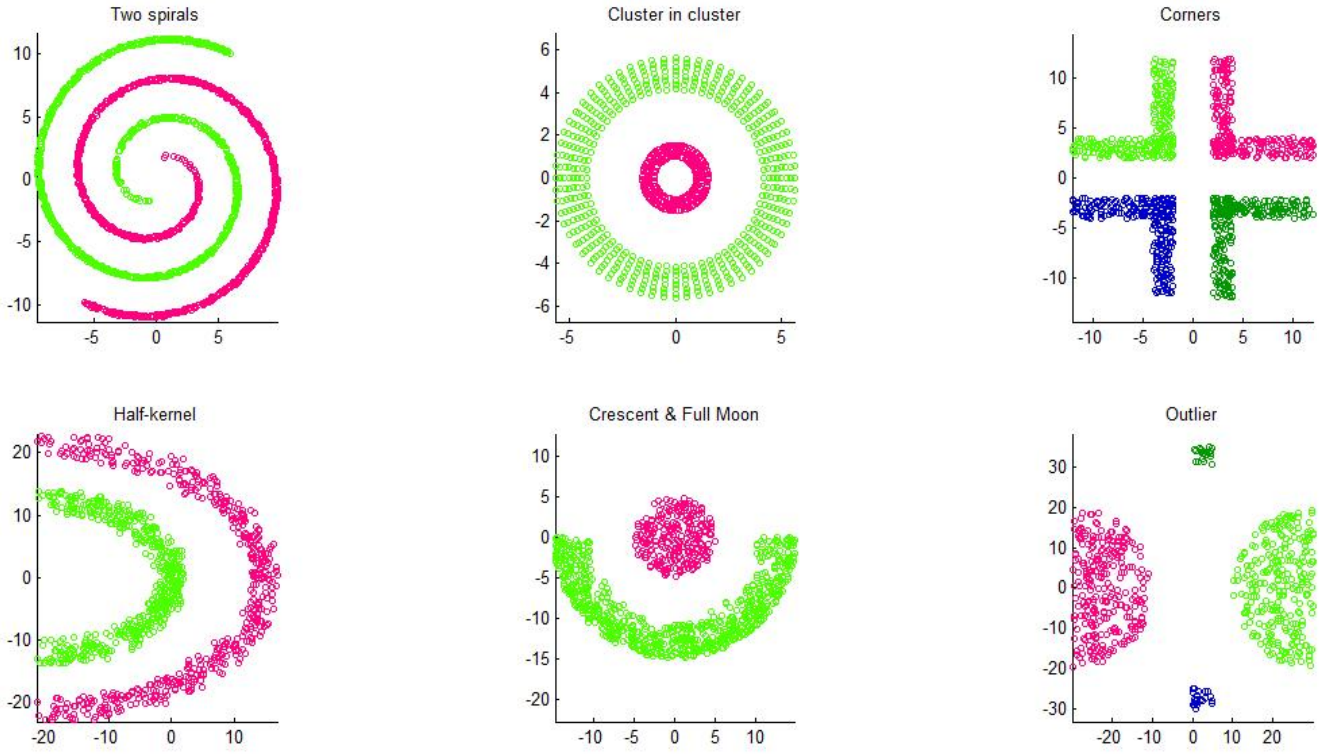
7.4 典型聚类方法

数据挖掘对聚类分析的要求

- 处理不同数据类型的能力
  - 数值型、二元型、标称型、序数型等等
- 发现任意形状的能力
  - 基于距离的聚类算法往往发现的是球形的聚类，其实现实的聚类是任意形状的
- 减小对先验知识和用户自定义参数的依赖性
  - 对于高维数据，参数很难决定，聚类的质量也很难控制
- 处理噪声数据的能力
  - 对空缺值、离群点、数据噪声不敏感
- 可解释性和可用性
  - 聚类要和特定的语义解释和应用相联系

7.4 典型聚类方法

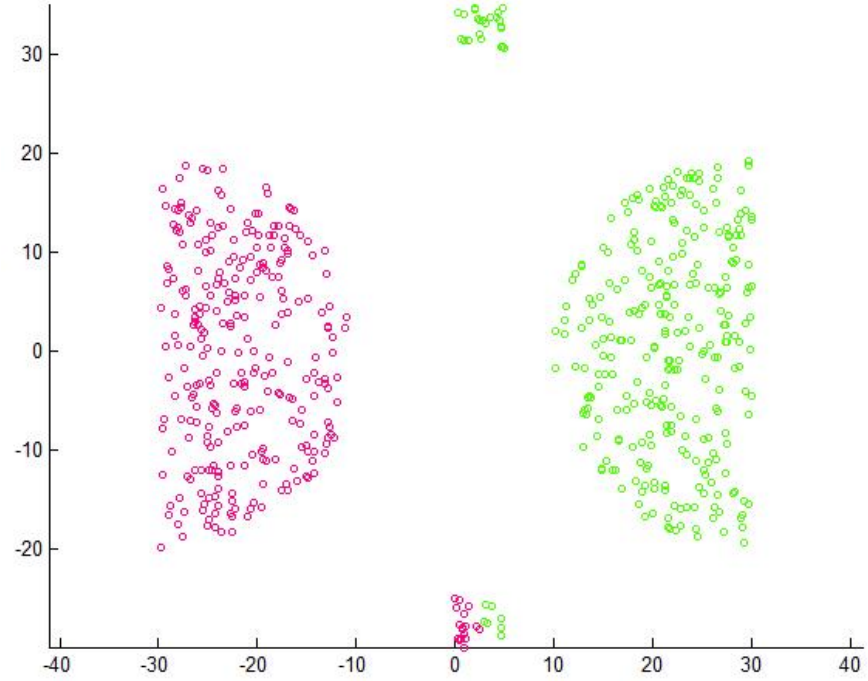
- 数据挖掘技术对聚类分析的要求
  - 发现任意形状聚类的能力

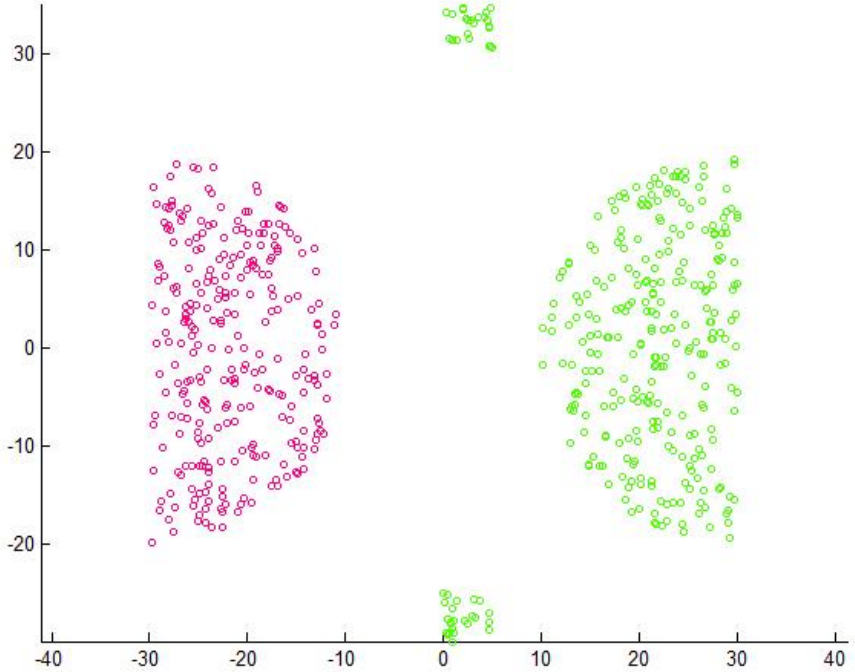


7.4 典型聚类方法

- 数据挖掘技术对聚类分析的要求
  - 减小对先验知识和用户自定义参数的依赖性

初始值

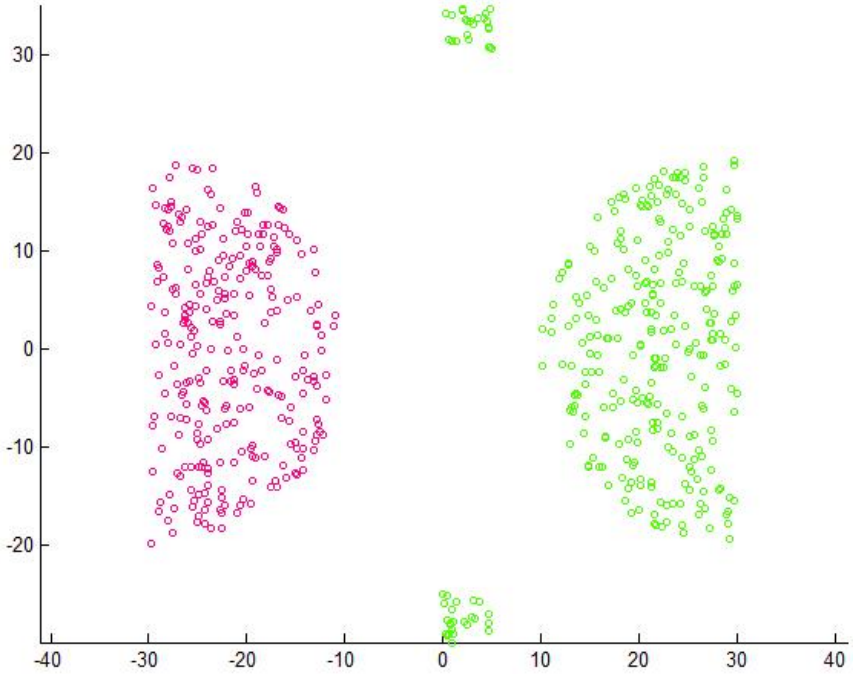


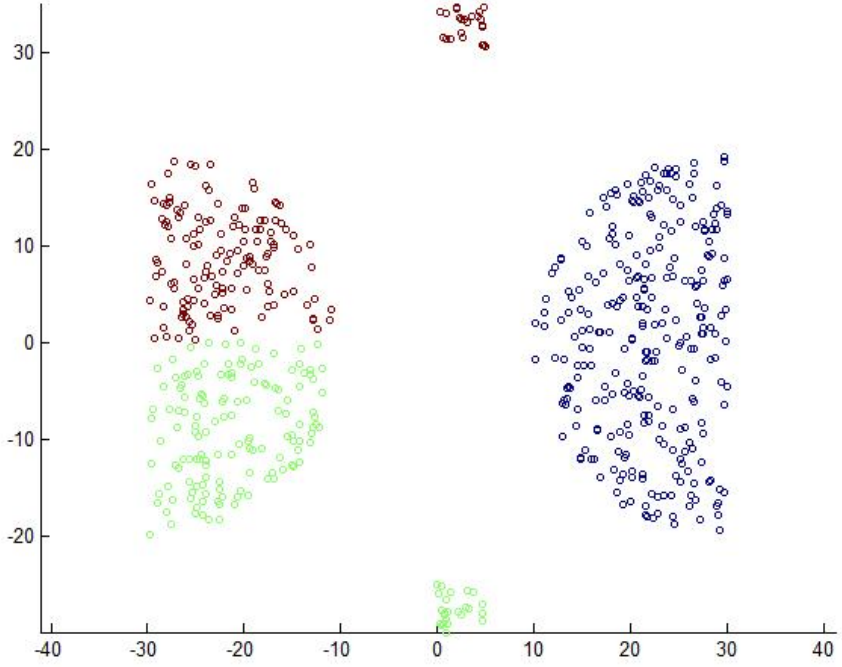


7.4 典型聚类方法

- 数据挖掘技术对聚类分析的要求
  - 减小对先验知识和用户自定义参数的依赖性

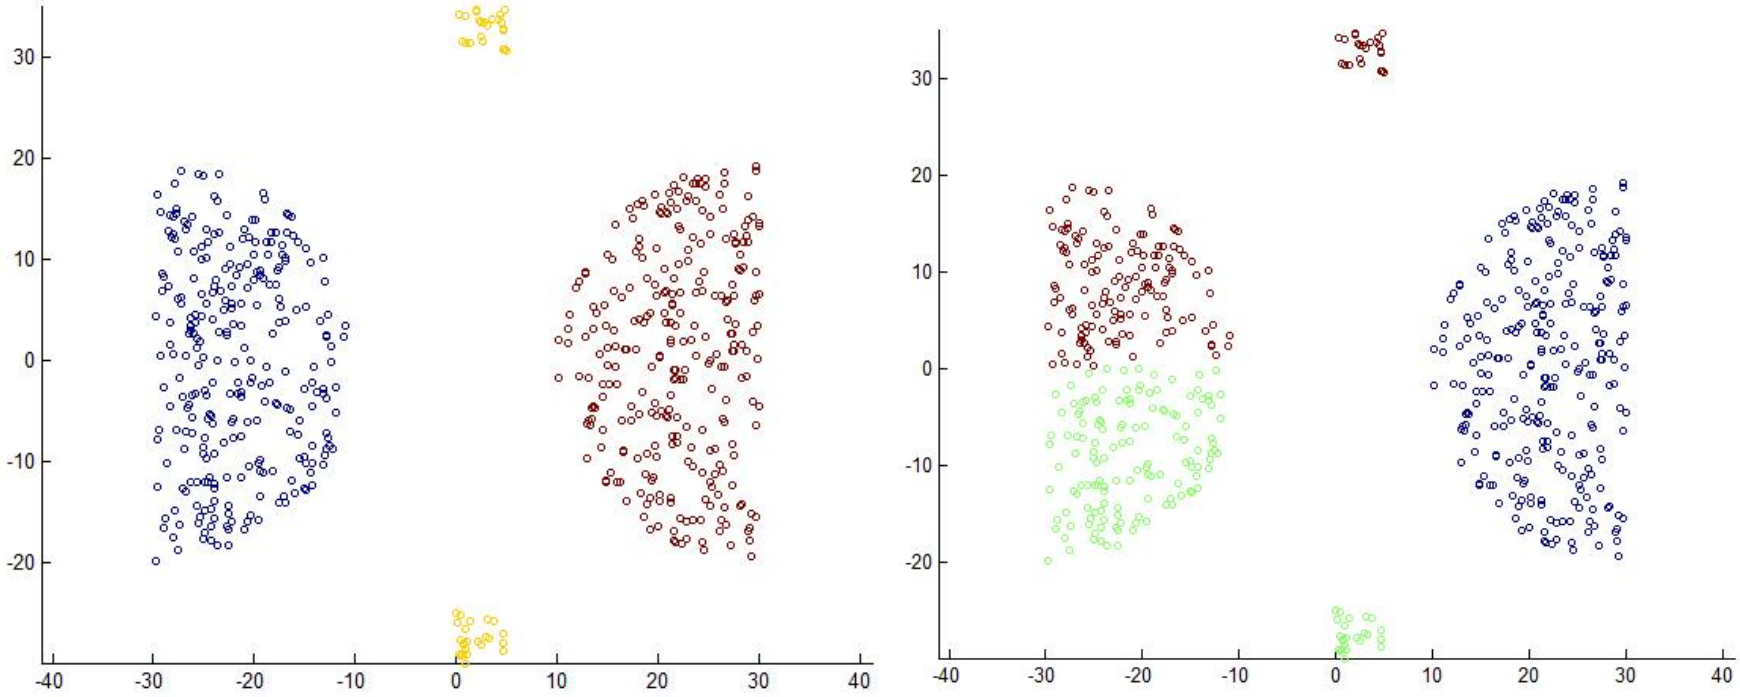
聚类个数





7.4 典型聚类方法

- 数据挖掘技术对聚类分析的要求
  - 处理噪声数据的能力



7.4 典型聚类方法

- 数据挖掘技术对聚类分析的要求
  - 可解释性和实用性

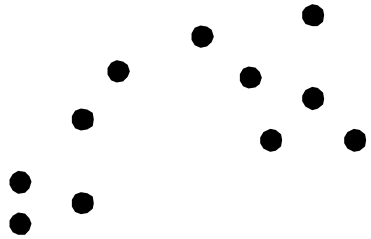
用户往往希望聚类结果是可解释的并且可用的，在低维情况下，可以借助于可视化手段来展示聚类结果，在高维情况下很难被可视化，这时对数据降低维度会有所帮助。根据具体的应用问题，选择合适的聚类算法。

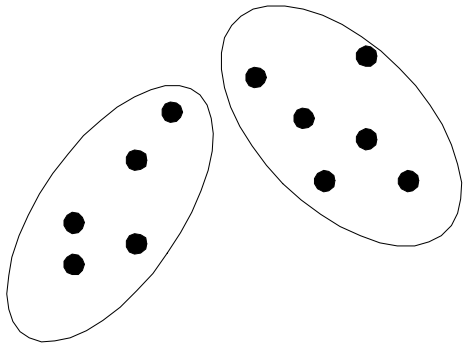
7.4 典型聚类方法

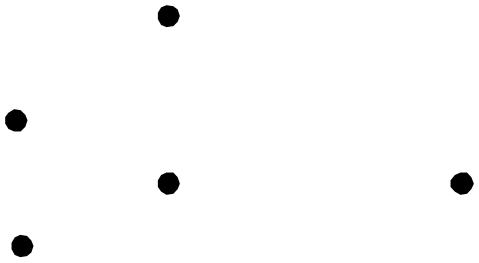
- 7.4.1划分方法
- 7.4.2密度方法
- 7.4.3图的方法
- 7.4.4层次方法

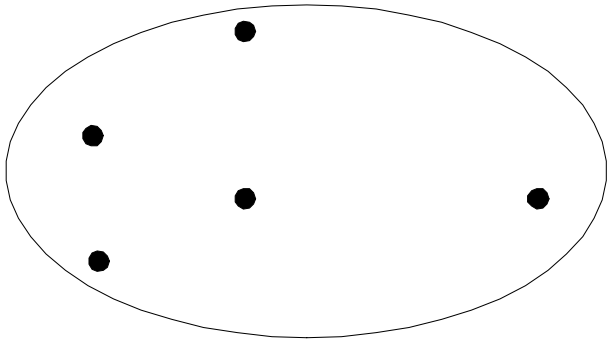
7.4.1 划分聚类方法

- 划分聚类方法







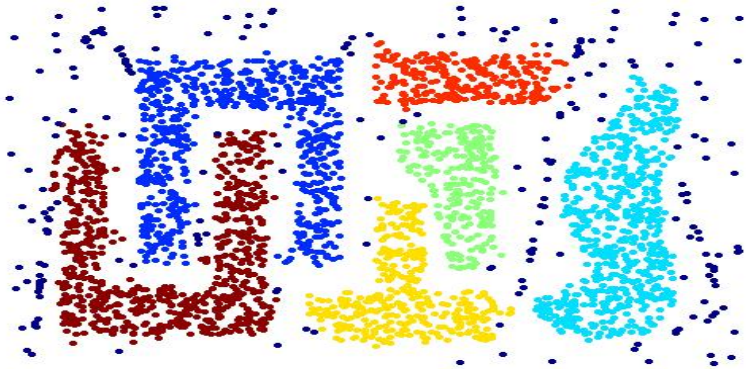


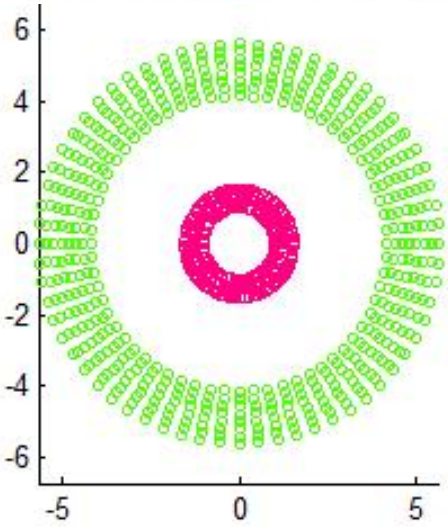
Original Points　　A Partitional Clustering

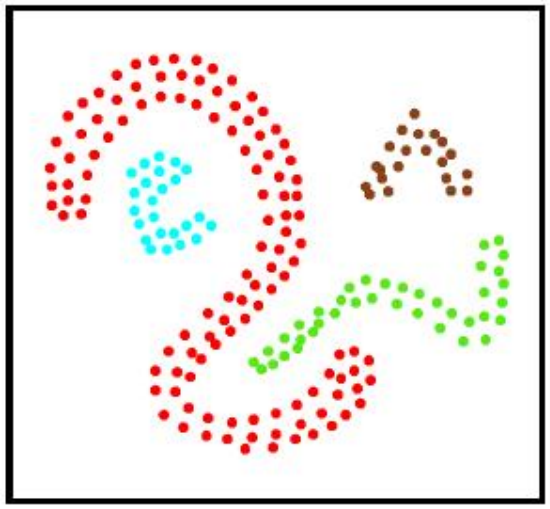
适合发现球形的聚类结构

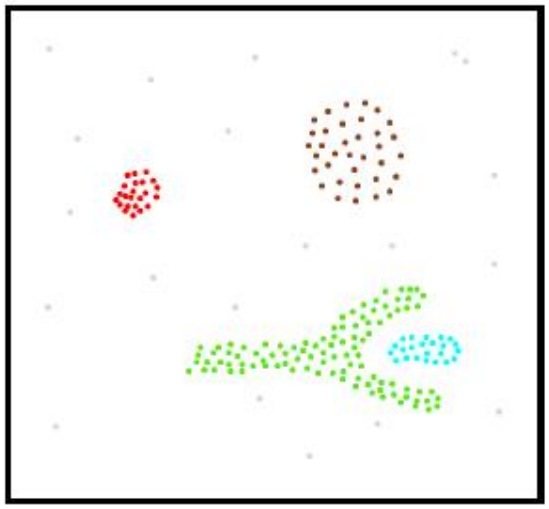
7.4.2 密度聚类方法







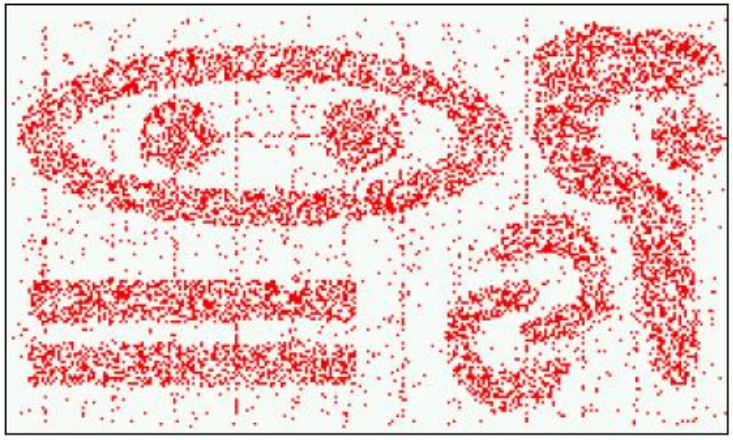




适合发现任意形状的聚类结构

7.4.2 密度聚类方法

- 基于样本之间的距离的聚类方法只能发现球状的簇。
- 密度方法可用来过滤“噪声”孤立点数据，以发现任意形状的簇。
- 主要思想：只要临近区域的密度（样本的数目）超过某个阈值则继续聚类。即对于给定簇中的每个样本，在一个给定范围的区域中必须至少包含某个数目的样本。



7.4.2 密度聚类方法

- 主要特征
  - 可以发现任意形状的簇
  - 可以去除噪声
  - 需要参数作为终止条件
- 主要方法
  - DBSCAN: Ester, et al. (KDD’96)
  - OPTICS: Ankerst, et al (SIGMOD’99).
  - DENCLUE: Hinneburg & D. Keim (KDD’98)
  - CLIQUE: Agrawal, et al. (SIGMOD’98) (more grid-based)

7.4.2 密度聚类方法

- 基于密度的聚类方法以数据集在空间分布上的稠密程度为依据进行聚类，无需预先设定簇的数量，因此特别适合对于未知内容的数据集进行聚类。
- 密度聚类方法的指导思想是，只要一个区域中的点的密度大于某个域值，就把它加到与之相近的聚类中去。对于簇中每个对象，在给定的半径ε的邻域中至少要包含最小数数目（MinPts）个对象。
- 这类算法能克服基于距离的算法只能发现“类圆形”的聚类的缺点，可发现任意形状的聚类，且对噪声数据不敏感。

7.4.2 密度聚类方法

动画演示

7.4.2 密度聚类方法

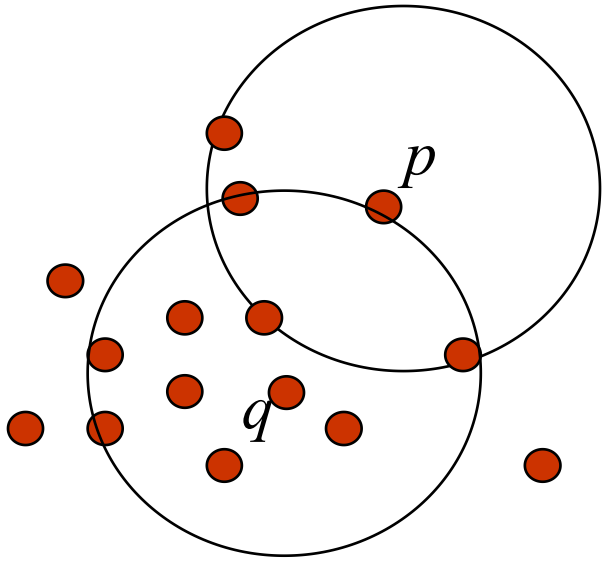
- 优点
  - 能克服基于距离的算法只能发现“类圆形”的聚类的缺点，可发现任意形状的聚类，有效地处理数据集中的噪声数据，数据输入顺序不敏感。
- 缺点
  - 输入参数敏感。确定参数ε，MinPts困难，若选取不当，将造成聚类质量下降。由于在DBSCAN算法中，变量ε，MinPts是全局惟一的， 当空间聚类的密度不均匀、聚类间距离相差很大时，聚类质量较差。
  - 计算密度单元的计算复杂度大，需要建立空间索引来降低计算量，且对数据维数的伸缩性较差。这类方法需要扫描整个数据库，每个数据对象都可能引起一次查询，因此当数据量大时会造成频繁的I/O操作。

DBSCAN

- DBSCAN（Density-Based Spatial Clustering of Applications with Noise）一个比较有代表性的基于密度的聚类算法。与层次聚类方法不同，它将簇定义为密度相连的点的最大集合，能够把具有足够高密度的区域划分为簇，并可在有“噪声”的空间数据库中发现任意形状的聚类。

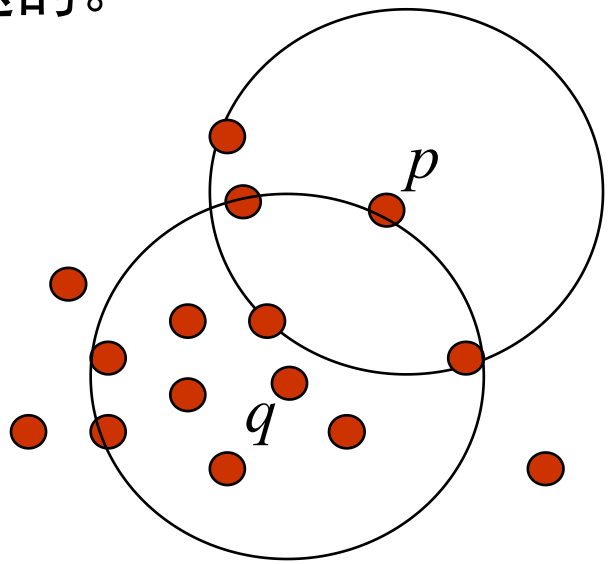
DBSCAN

- 基于中心的密度定义为：
  - 数据集中特定点的密度通过该点ε半径之内的点计数(包括本身)来估计。
  - 密度依赖于半径。



基本术语

- **ε-邻域**：给定对象在半径ε内的区域。
- **核心对象**：如果一个对象的ε-邻域至少包含最小数目MinPts个对象，则称该对象为核心对象。
- **直接密度可达**：给定一个对象集合D，如果p是在q的ε-邻域内，而q是一个核心对象，则对象p从对象q出发是直接密度可达的。



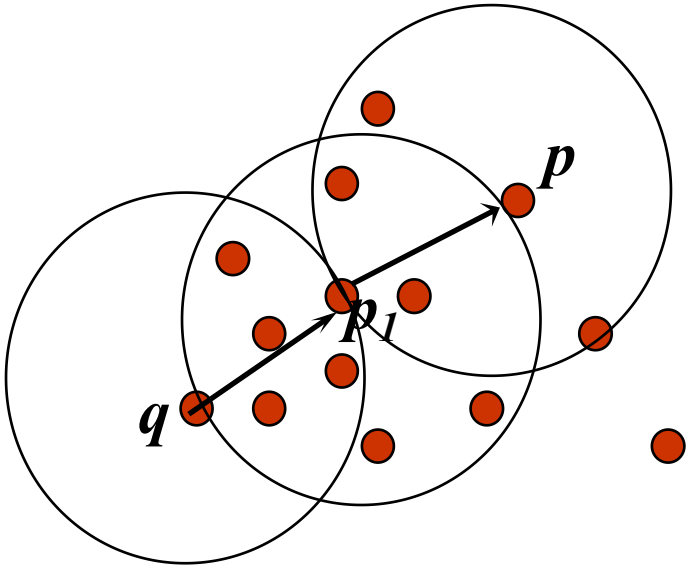
ε=1cm，MinPts=5

q是一个核心对象

对象p从对象q出发是直接密度可达的

基本术语

- **密度可达的**：如果存在一个对象链p_1，p_2，…，p_n，$p_1=q$，$p_n=p$，对$p_i \in D$，（$1<=i<=n$），p_{i+1}是从p_i关于ε和MitPts直接密度可达的，则对象p是从对象q关于ε和MinPts密度可达的。



ε=1cm，MinPts=5

q是一个核心对象

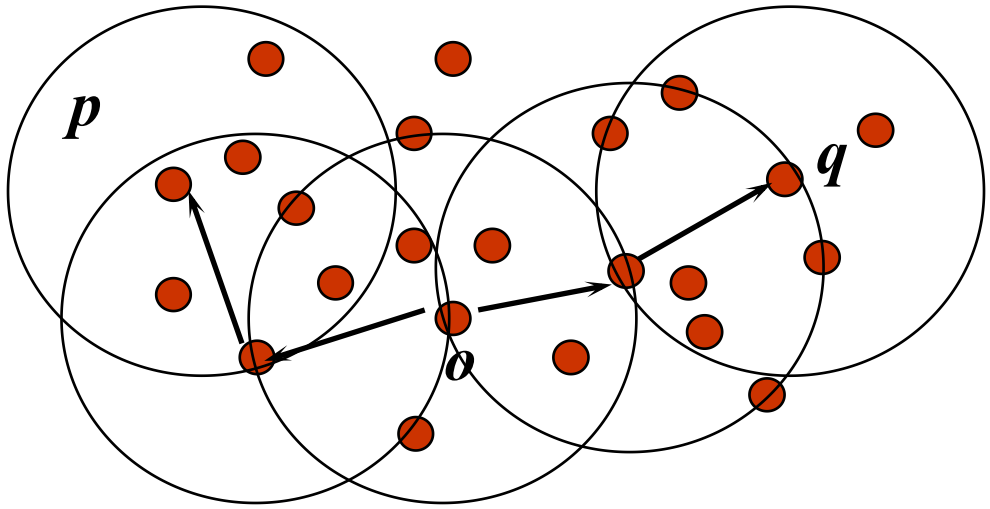
p_1是从q关于ε和MitPts直接密度可达

p是从$p1$关于ε和MitPts直接密度可达

对象p从对象q关于ε和MinPts密度可达的

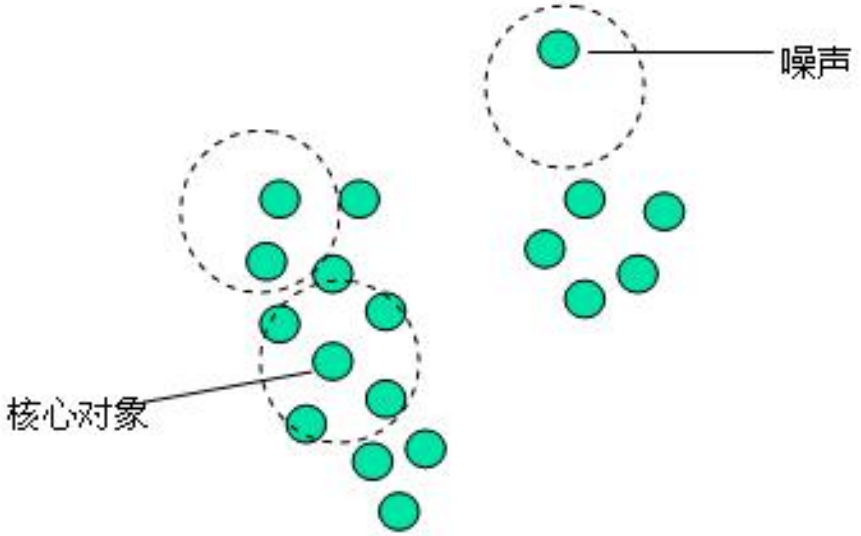
基本术语

- **密度相连的：** 如果对象集合D中存在一个对象o，使得对象p和q是从o关于ε和MinPts密度可达的，那么对象p和q是关于ε和MinPts密度相连的。



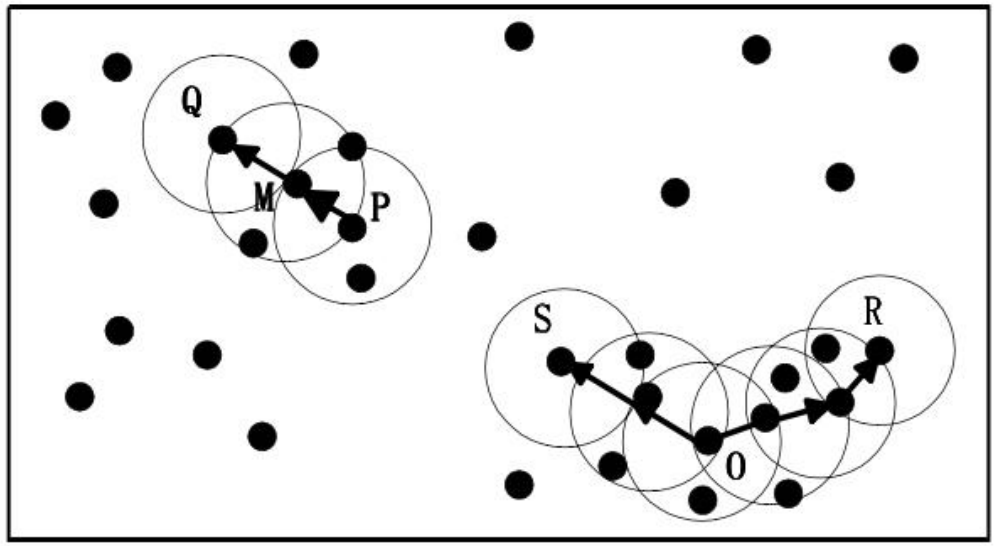
基本术语

- **基于密度的簇**：基于密度可达性的最大的密度相连对象的集合。
- **边界点**：边界点不是核心点，但落在某个核心点的邻域内。
- **噪声**：不包含在任何簇中的对象被认为是“噪声”。噪声就是那些既不是边界点也不是核心点的对象



DBSCAN

- ε 用一个相应的半径表示，设MinPts=3，请分析Q,M,P,S,O,R这5个样本点之间的关系。



由于有标记的各点-M、P、O和R的 ε 近邻均包含3个以上的点，因此它们都是核对象；M-是从P“直接密度可达”；而Q则是从-M“直接密度可达”；基于上述结果，Q是从P“密度可达”；但P从Q无法“密度可达”(非对称)。S和R从O是“密度可达”的；O、R和S均是“密度相连”的。

DBSCAN

- DBSCAN 算法根据以上的定义在数据库中发现簇和噪声。
- 簇可等价于集合D中这个簇核心对象密度可达的所有对象的集合。
- DBSCAN通过检查数据集中每个对象的ε-邻域来寻找聚类。
  - 如果一个点p的ε-邻域包含多于MinPts个对象，则创建一个p作为核心对象的新簇C。
  - 然后，DBSCAN从C中寻找未被处理对象q的ε-邻域，如果q的ε-邻域包含多MinPts个对象，则还未包含在C中的q的邻点被加入到簇中，并且这些点的ε-邻域将在下一步中进行检测。
  - 这个过程反复执行，当没有新的点可以被添加到任何簇时，该过程结束。

DBSCAN

DBSCAN算法描述：

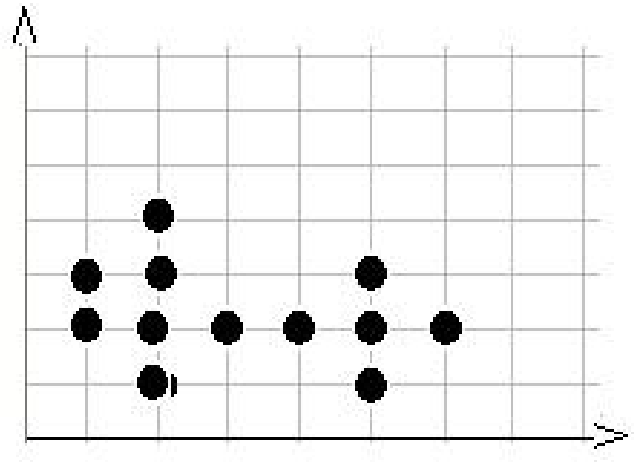
- 输入：包含n个对象的数据库，半径ε，最少数目MinPts。
- 输出：所有生成的簇，达到密度要求。
- 1. REPEAT
- 2. 从数据库中抽取一个未处理过的点；
- 3. IF 抽出的点是核心点 THEN找出所有从该点密度可达的对象，形成一个簇
- 4. ELSE 抽出的点是边缘点(非核心对象)，跳出本次循环，寻找下一点；
- 5. UNTIL 所有点都被处理；

DBSCAN

样本事务数据库

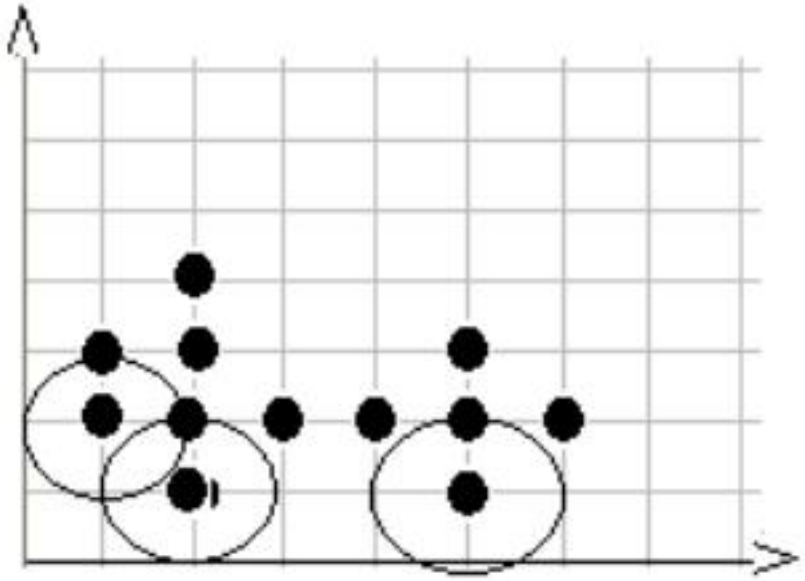
序号	属性 1	属性 2
1	2	1
2	5	1
3	1	2
4	2	2
5	3	2
6	4	2
7	5	2
8	6	2
9	1	3
10	2	3
11	5	3
12	2	4

ε=1， MinPts=4



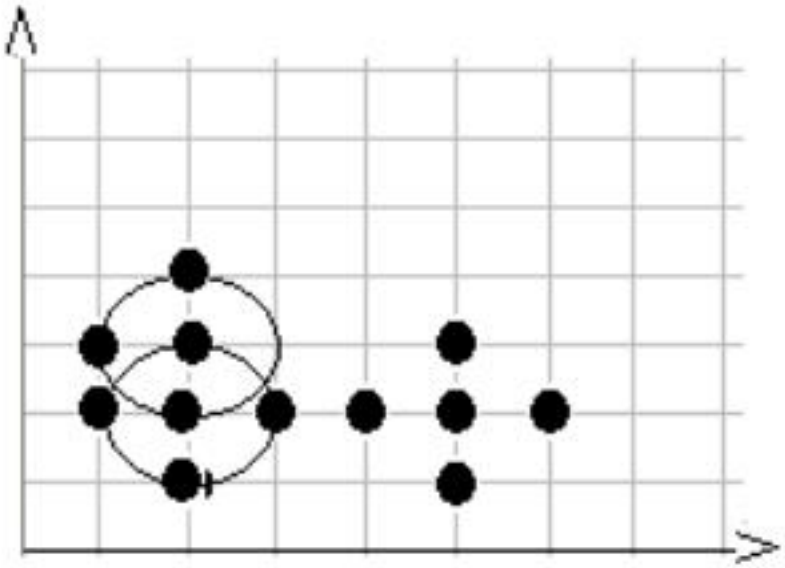
聚类过程

- 第1步，在数据库中选择一点1，由于在以它为圆心的，以1为半径的圆内包含2个点（小于4），因此它不是核心点，选择下一个点。
- 第2步，在数据库中选择一点2，由于在以它为圆心的，以1为半径的圆内包含2个点，因此它不是核心点，选择下一个点。
- 第3步，在数据库中选择一点3，由于在以它为圆心的，以1为半径的圆内包含3个点，因此它不是核心点，选择下一个点。



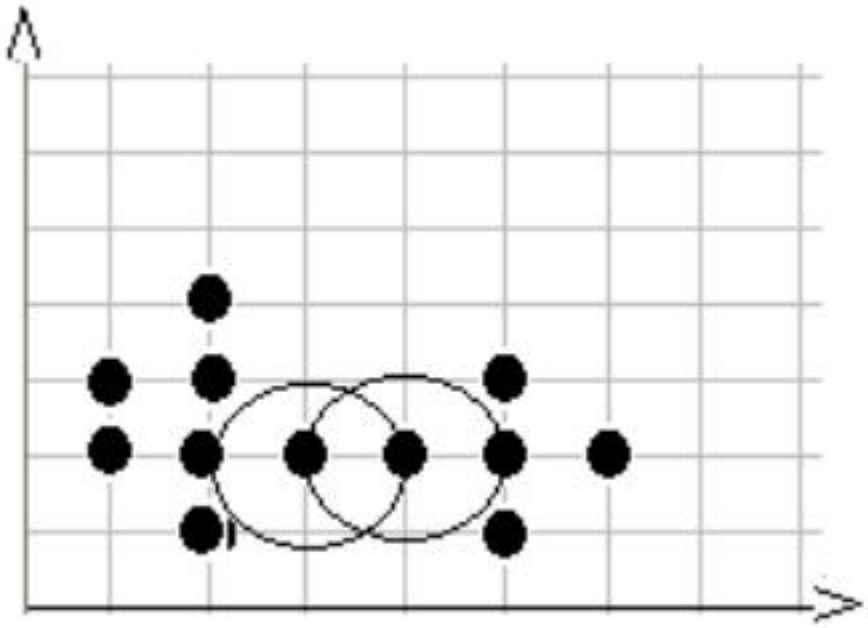
聚类过程

- 第4步，在数据库中选择一点4，由于在以它为圆心的，以1为半径的圆内包含5个点，因此它是核心点，寻找从它出发可达的点（直接可达4个，间接可达2个），聚出的新类{1，3，4，5，9，10，12}，选择下一个点。



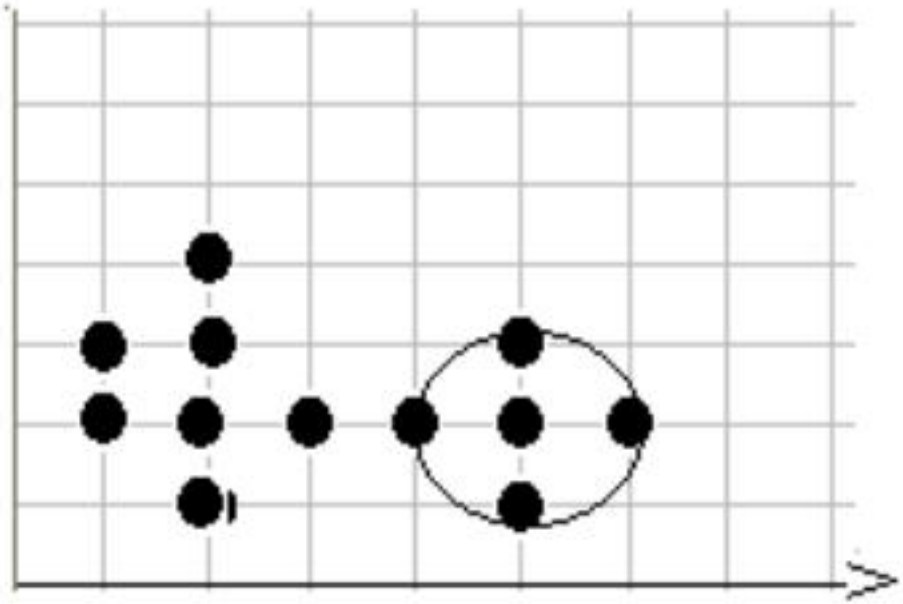
聚类过程

- 第5步，在数据库中选择一点5，已经在簇1中，选择下一个点。
- 第6步，在数据库中选择一点6，由于在以它为圆心的，以1为半径的圆内包含3个点，因此它不是核心点，选择下一个点。



聚类过程

- 第7步，在数据库中选择一点7，由于在以它为圆心的，以1为半径的圆内包含5个点，因此它是核心点，寻找从它出发可达的点，聚出的新类{2，6，7，8，11}，选择下一个点。

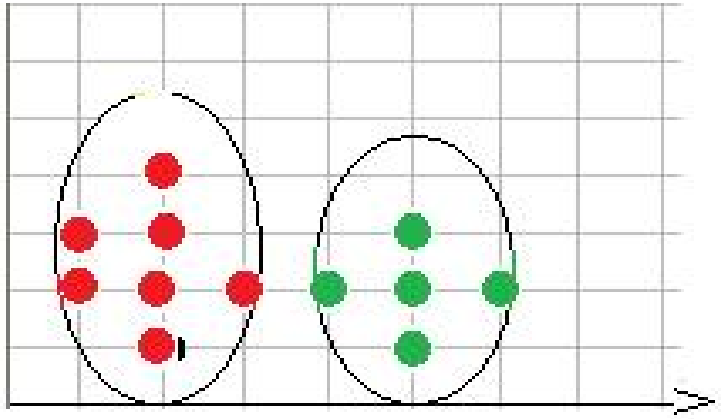


聚类过程

- 第8步，在数据库中选择一点8，已经在簇2中，选择下一个点。
- 第9步，在数据库中选择一点9，已经在簇1中，选择下一个点。
- 第10步，在数据库中选择一点10，已经在簇1中，选择下一个点。
- 第11步，在数据库中选择一点11，已经在簇2中，选择下一个点。
- 第12步，选择12点，已经在簇1中，由于这已经是最后一点所有点都以处理，程序终止。

DBSCAN

步骤	选择的点	在ε中点的个数	通过计算可达点而找到的新簇
1	1	2	无
2	2	2	无
3	3	3	无
4	4	5	簇C_1：{1，3，4，5，9，10，12}
5	5	3	已在一个簇C_1中
6	6	3	无
7	7	5	簇C_2：{2，6，7，8，11}
8	8	2	已在一个簇C_2中
9	9	3	已在一个簇C_1中
10	10	4	已在一个簇C_1中，
11	11	2	已在一个簇C_2中
12	12	2	已在一个簇C_1中



时间复杂度

- DBSCAN算法要对每个数据对象进行邻域检查时间性能较低。
- DBSCAN的基本时间复杂度是 O(N*找出ε领域中的点所需要的时间), N是点的个数。最坏情况下时间复杂度是 O(N^2)
- 在低维空间数据中,有一些数据结构如KD树，使得可以有效的检索特定点给定距离内的所有点，时间复杂度可以降低到O(Nlog$N$)

空间复杂度

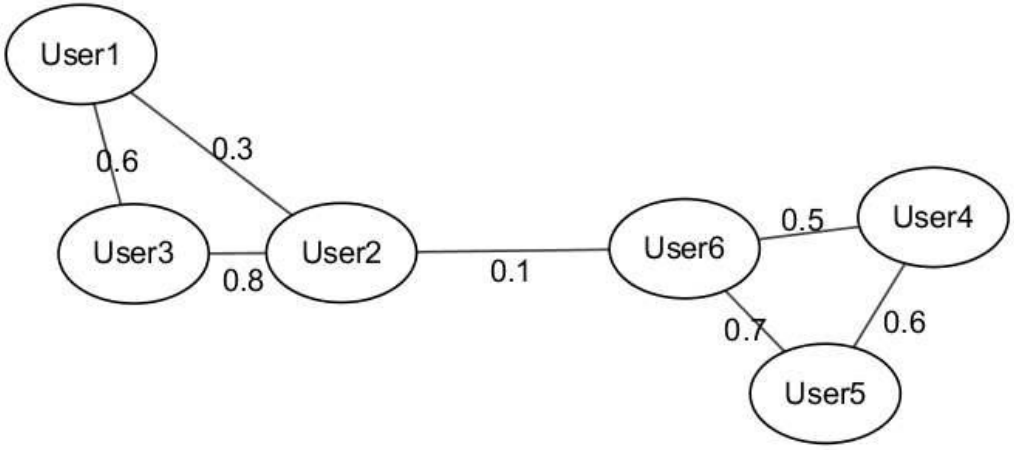
- 在聚类过程中，DBSCAN一旦找到一个核心对象，即以该核心对象为中心向外扩展。此过程中核心对象将不断增多，未处理的对象被保留在内存中。若数据库中存在庞大的聚类，将需要很大的存来存储核心对象信息，其需求难以预料。
- 当数据量增大时，要求较大的内存支持 I/0 消耗也很大；
- 低维或高维数据中，其空间都是O(N)

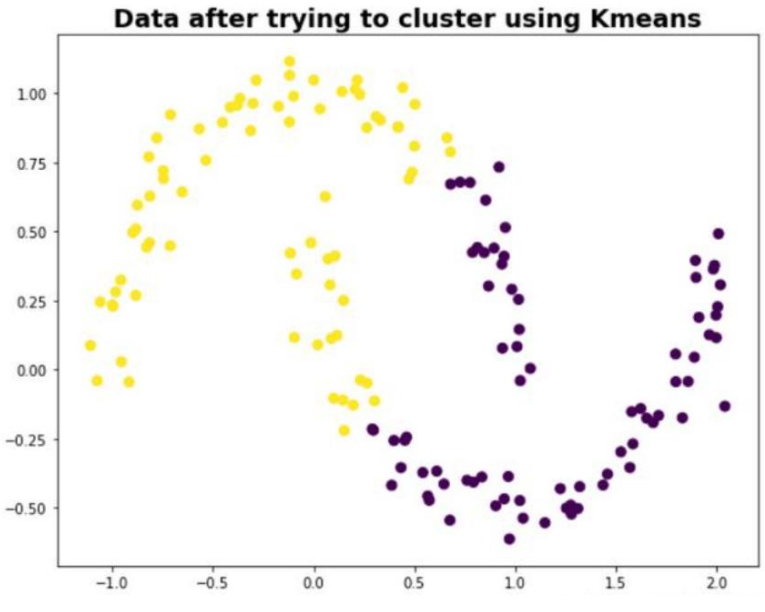
DBSCAN

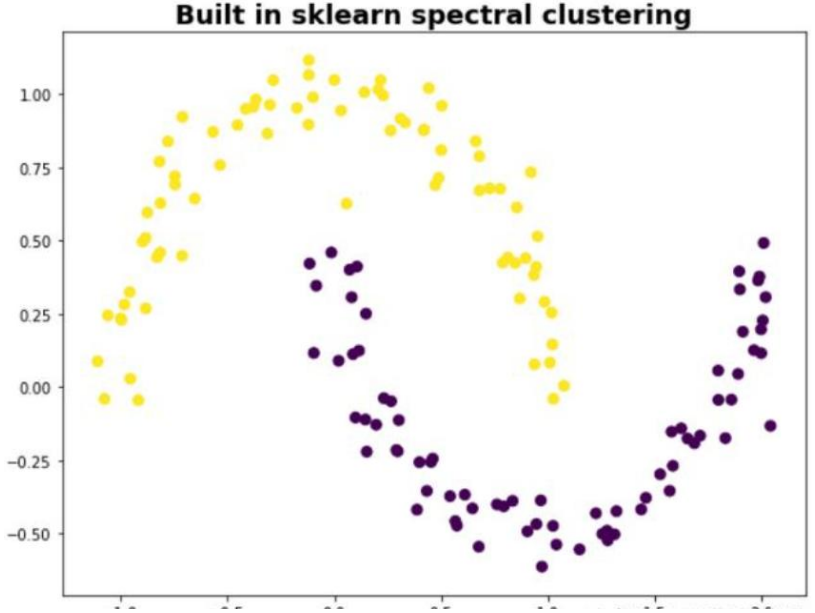
- 优点
  - 能克服基于距离的算法只能发现“类圆形”的聚类的缺点，可发现任意形状的聚类，有效地处理数据集中的噪声数据，数据输入顺序不敏感。
- 缺点
  - 输入参数敏感。确定参数ε，MinPts困难，若选取不当，将造成聚类质量下降。由于在DBSCAN算法中，变量ε，MinPts是全局惟一的， 当空间聚类的密度不均匀、聚类间距离相差很大时，聚类质量较差。
  - 计算密度单元的计算复杂度大，需要建立空间索引来降低计算量，且对数据维数的伸缩性较差。这类方法需要扫描整个数据库，每个数据对象都可能引起一次查询，因此当数据量大时会造成频繁的I/O操作。

7.4.3 图聚类方法

- 基于图的聚类方法







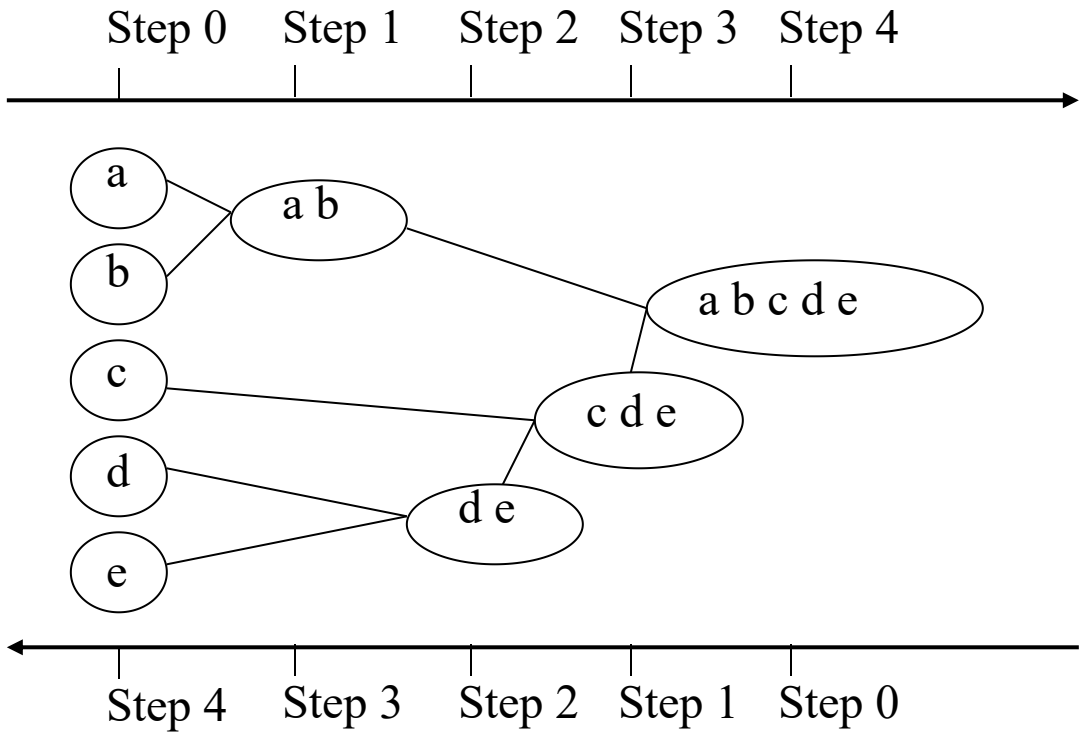
7.4.3 图聚类方法

谱聚类

- 优点：
  - 谱聚类只需要数据之间的相似度矩阵，因此对于处理稀疏数据的聚类很有效。
  - 建立在谱图理论基础上，能在任意形状的样本空间上聚类，适合高维数据的聚类。
- 缺点：
  - 复杂度高。
  - 谱聚类对相似度图的改变和聚类参数的选择非常的敏感。

7.4.4 层次聚类方法

- 对给定数据集分层进行划分，形成一个以各个聚类为结点的树形结构。
- 分成凝聚型和分裂型两种方式。

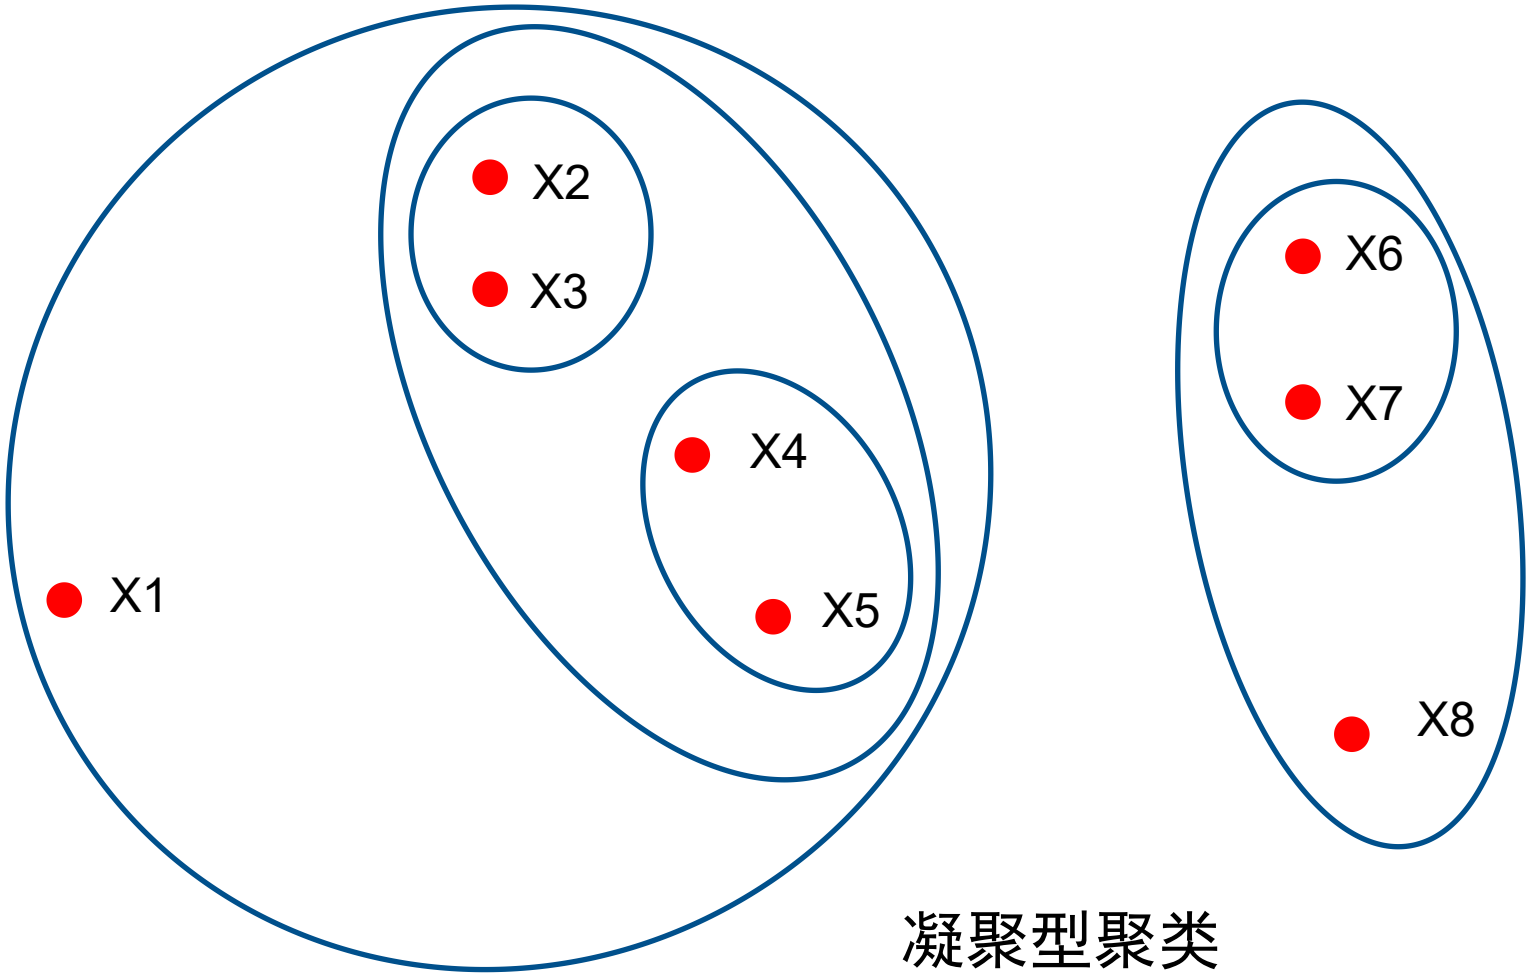


Agglomerative nesting (AGNES)

Divisive analysis (DIANA)

7.4.4 层次聚类方法

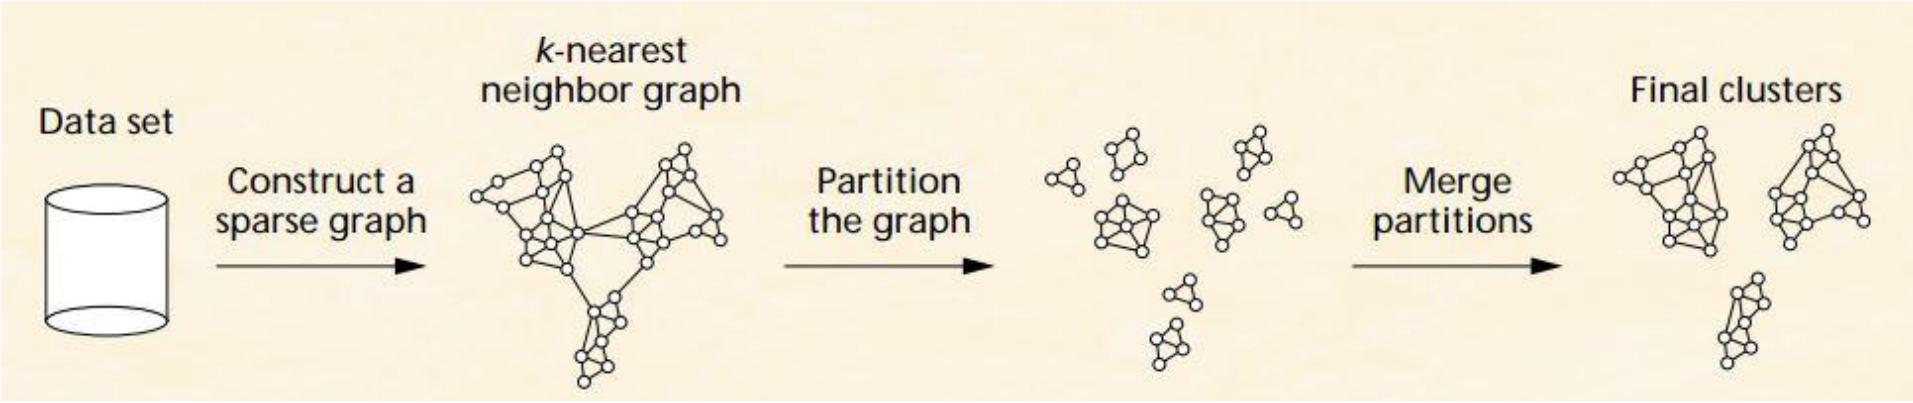
每个样本看成一个类，逐步将样本合并，直到所有样本都在一个类别或者满足终止条件为止



凝聚型聚类

7.4.4 层次聚类方法

- 改进的层次聚类方法：
  - BIRCH利用层次方法的平衡迭代规约和聚类（Balanced Iterative Reducing and Clustering Using Hierarchies）
  - Chameleon（变色龙）多阶段层次聚类



7.4.4 层次聚类方法

- 优点：
  - 简单，易实现，容易理解
- 缺点：
  - 不能纠正错误的合并或者分裂。
  - 不具有很好的可伸缩性，因为合并或分裂的决定需要检查和估算大量的对象或簇。

7 聚类

- 7.1 聚类分析
- 7.2 典型聚类应用
- 7.3 k-means聚类方法
- 7.4 典型聚类方法
- 7.5 评估

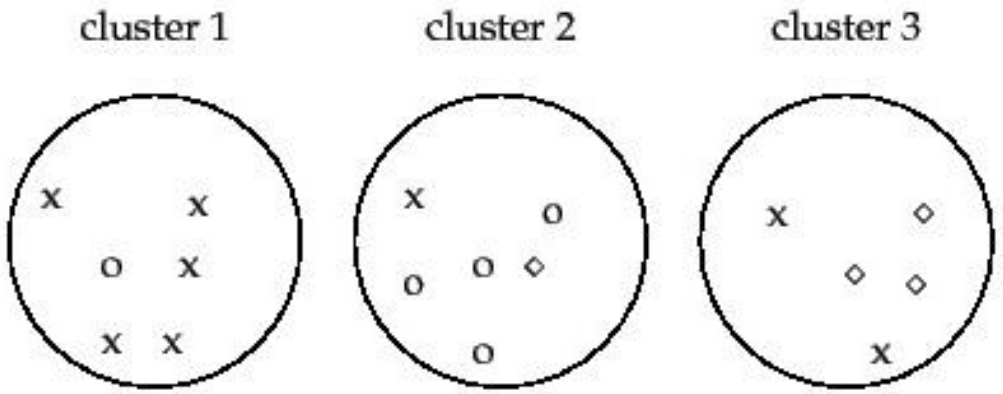
7.5 评估

- 外在方法
  - 当有基准可用时，可以将它与聚类进行比较，评估聚类。
- 内在方法
  - 没有基准可用时，通过考察簇的分离情况和紧凑情况评估聚类。

7.5 评估

纯度purity

purity方法是极为简单的一种聚类评价方法，只需计算正确聚类的样本数占总样本数的比例



$$purity = (3+ 4 + 5) / 17 = 0.71$$

其中第一类正确的有5个，第二个4个，第三个3个，总数17。

purity方法计算简单，值在0～1之间，完全错误的聚类方法值为0，完全正确的方法值为1。

7.5 评估

最小误差

误差平方和准则表示数据集中的所有样本与相应聚类中心的方差之和，该准则的值达到最优时可以便各个聚类类内尽可能地紧凑，而各个聚类之间则尽可能地分开。

Cohesion is measured by the within cluster sum of squares error(SSE)

$$WSS = \sum_{i} \sum_{x \in C_i} (x - m_i)^2$$

Separation is measured by the between cluster sum of squares

$$BSS = \sum_{i} |C_i| (m - m_i)^2$$

Where $|C_i|$ is the size of cluster i , m is the center of all samples.

7.5 评估

- NMI(Normalized Mutual Information) 即归一化互信息
- RI (Rand Index) 将聚类看成是一系列的决策过程
- ARI (Adjusted Rand Index)

小结

- K-means聚类方法
- 典型聚类方法
- 评估

天津大学
Tianjin University

THE END



天津大学
Tianjin University

数据挖掘



有监督 vs 无监督

- 有监督：

用于分类或者回归，需要有训练集和测试集。

在已知训练集的前提下，对测试样本根据它的特征，把它与训练集中的样本进行对比，把它分到对应的那类中。

- 无监督：

用于聚类

有一堆数据，将这堆数据按照它们自身内部的相似性，自动地聚成几类。

第 6 章　回归分析

6 回归分析

- 6.1 回归概述
- 6.2 应用案例
- 6.3 线性回归
- 6.4 非线性回归
- 6.5 Logistic回归
- 6.6 评估

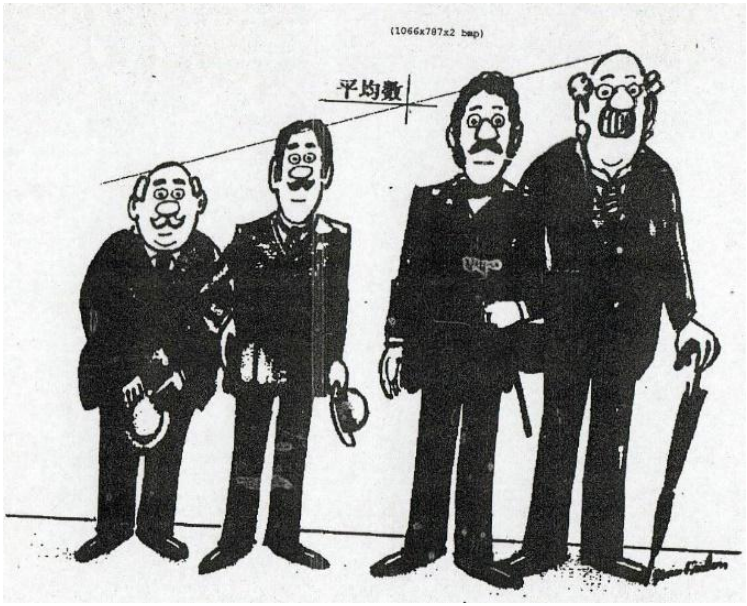
6.1 回归概述

- “回归”一词是1855年由英国生物学家高尔顿（Galton）在研究孩子的身高与他们父母身高关系时提出的。
- 当时他正研究这样一个问题：高个子人生的子女一般偏高，照这样看，各代人在身高分布上将有两级分化的趋势，个子很高和很矮的会越来越多，而处在中间状态的会越来越少。
- 研究发现，父母个子高，其子代一般也高，但不如父母那么高；父母个子矮，其子代一般也矮，但不如父母那么矮。下一代身高有向中间值回归的趋势。这种趋于中间值的趋势被称为“回归效应”，而他提出的这种研究两个数值变量关系的方法称作回归分析。

6.1 回归概述

- 英国高尔顿（Galton）和统计学家 Karl Pearson对上千个家庭的身高、臂长等做了测量，发现：
- 儿子身高（Y，英寸）与父亲身高（X，英寸）存在线性关系

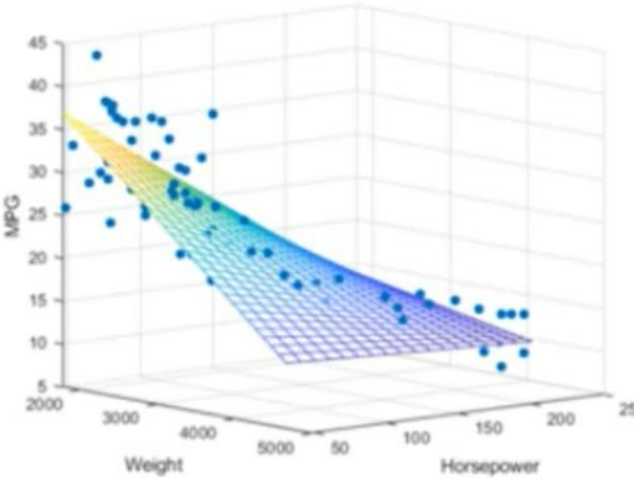
$$\hat{Y} = 33.73 + 0.516X$$

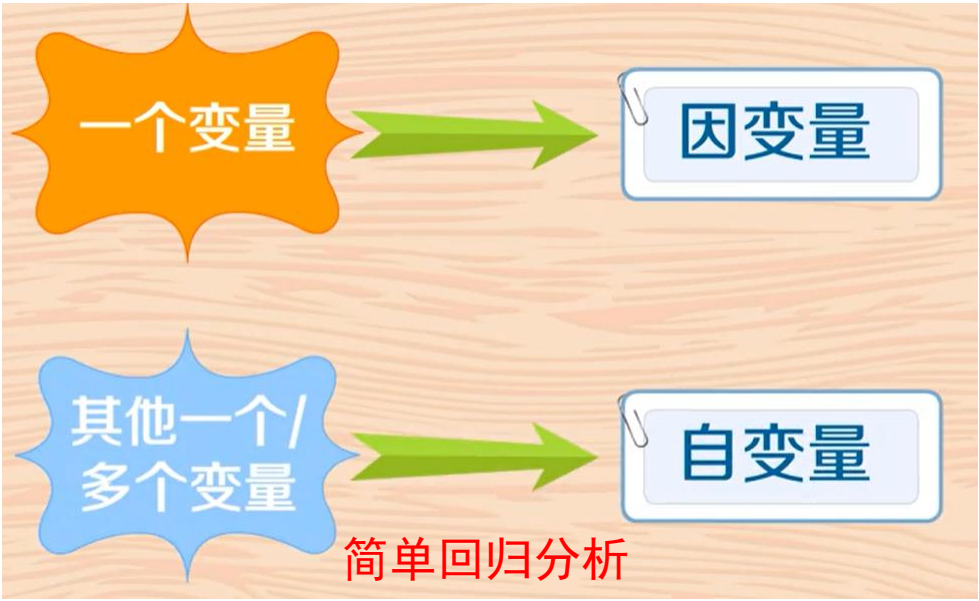


6.1 回归概述

回归分析（regression analysis)指的是确定两种或两种以上变量间相互依赖的定量关系的一种统计分析方法。

- x：自变量
- y：因变量
- 确定y随x的变化情况。





6.1 回归概述

- 按照因变量的多少，可分为简单回归分析和多重回归分析；
- 回归分析按照涉及自变量的多少，分为一元回归和多元回归分析；
- 按照自变量和因变量之间的关系类型，可分为线性回归分析和非线性回归分析。

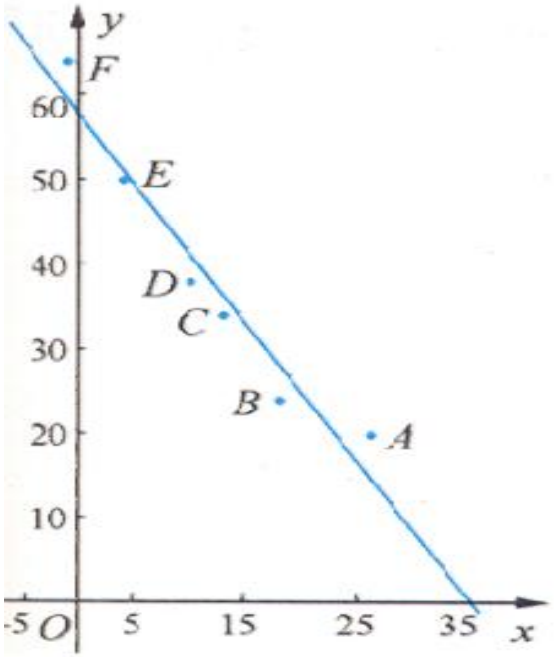
6 回归分析

- 6.1 回归概述
- 6.2 应用案例
- 6.3 线性回归
- 6.4 非线性回归
- 6.5 Logistic回归
- 6.6 评估

6.2 应用案例

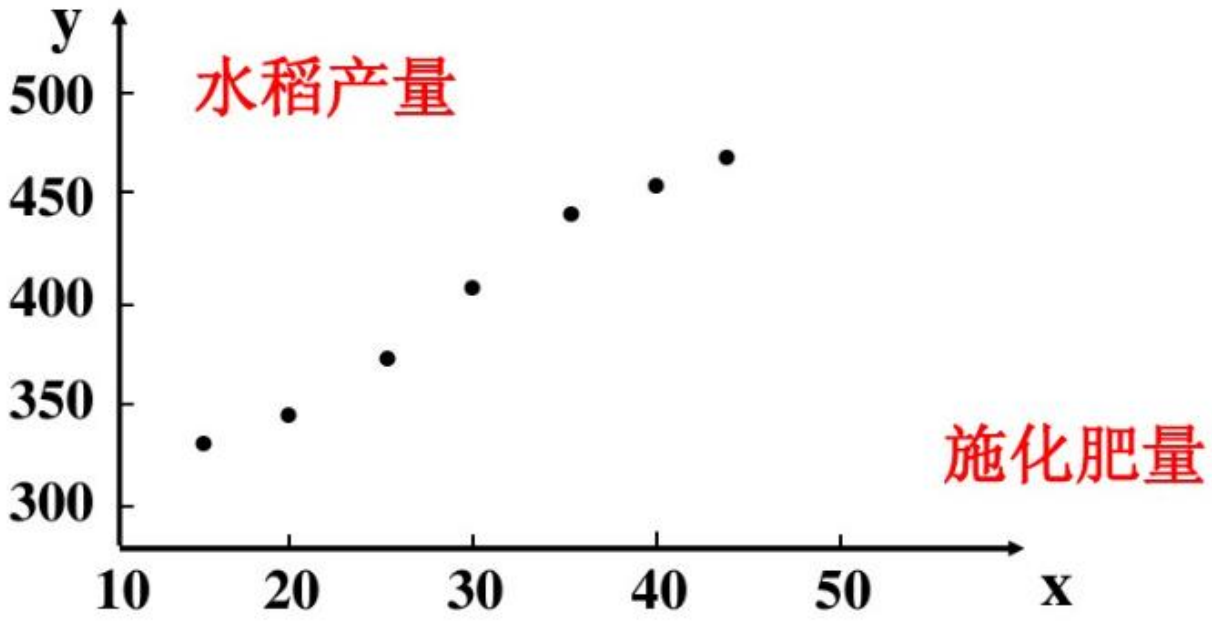
气温与热饮的数据集

气温/^{0}C	26	18	13	10	4	-1
杯数	20	24	34	38	50	64



6.2 应用案例

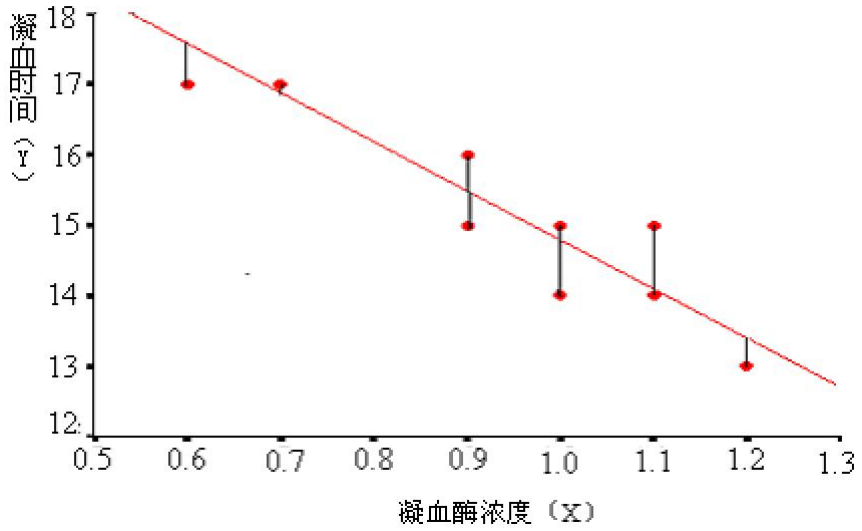
施化肥量x	15	20	25	30	35	40	45
水稻产量y	330	345	365	405	445	450	455



6.2 应用案例

15名健康人凝血酶浓度与凝血时间数据

No.	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
X	1.1	1.2	1.0	0.9	1.2	1.1	0.9	0.6	1.0	0.9	1.1	0.9	1.1	1.0	0.7
Y	14	13	15	15	13	14	16	17	14	16	15	16	14	15	17



6.2 应用案例

年龄预测

通过行为习惯对移动用户人口属性(年龄+性别)进行预测。数据及包含~20万用户数据，分成12组，同时提供了用户行为属性，如:手机品牌、型号、APP的类型等。

device_id	gender	age	group
-8.1E+18	M	35	M32-38
-2.9E+18	M	35	M32-38
-8.3E+18	M	35	M32-38
-4.9E+18	M	30	M29-31
2.45E+17	M	30	M29-31
-1.3E+18	F	24	F24-26
2.37E+17	M	36	M32-38
-8.1E+18	M	38	M32-38
1.77E+17	M	33	M32-38

device_id	phone_brand	device_model
-8.89065E+18	小米	红米
1.27778E+18	小米	MI 2
5.13743E+18	三星	Galaxy S4
3.66946E+18	SUGAR	时尚手机
-5.01928E+18	三星	Galaxy Note 2
3.23801E+18	华为	Mate
-3.88353E+18	小米	MI 2S
-2.9722E+18	华为	G610S
-5.82795E+18	小米	MI One Plus

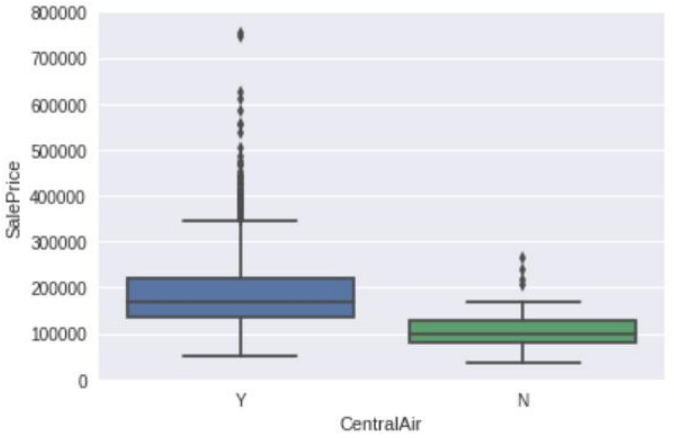
event_id	app_id	is_installed	is_active
2	5.93E+18	1	1
2	-5.7E+18	1	0
2	-1.6E+18	1	0
2	-6.5E+17	1	1
2	8.69E+18	1	1
2	4.78E+18	1	1
2	-8E+18	1	0
2	9.11E+18	1	0
2	-3.7E+18	1	0

6.2 应用案例

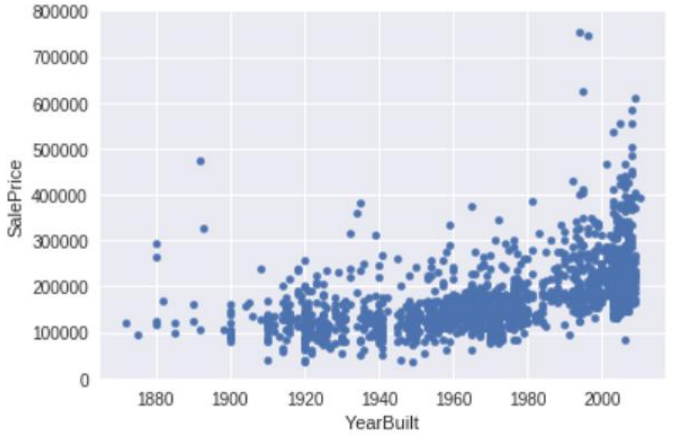
房价预测Kaggle入门项目

https://www.kaggle.com/marsggbo/kaggle/notebook

Variable	Segment	Data Type	Comments
LotArea	1	0	地皮面积
GrLivArea	1	0	生活面积
TotalBsmtSF	1	0	地下室总面积
MiscVal	0	0	其他资产
GarageArea/GarageCars	1	0	车库
YearBuilt	0	1	建造年份
CentralAir	0	1	中央空调
OverallQual	0	1	总体评价
Neighborhood	2	1	地段



中央空调



建造年份

6.2 应用案例

二手车价格预测天池竞赛

https://tianchi.aliyun.com/competition/entrance/231784/information

Field	Description
SaleID	交易ID，唯一编码
name	汽车交易名称，已脱敏
regDate	汽车注册日期，例如20160101，2016年01月01日
model	车型编码，已脱敏
brand	汽车品牌，已脱敏
bodyType	车身类型：豪华轿车：0，微型车：1，厢型车：2，大巴车：3，敞篷车：4，双门汽车：5，商务车：6，搅拌车：7
fuelType	燃油类型：汽油：0，柴油：1，液化石油气：2，天然气：3，混合动力：4，其他：5，电动：6
gearbox	变速箱：手动：0，自动：1
power	发动机功率：范围 [0, 600]
kilometer	汽车已行驶公里，单位万km
notRepairedDamage	汽车有尚未修复的损坏：是：0，否：1
regionCode	地区编码，已脱敏
seller	销售方：个体：0，非个体：1
offerType	报价类型：提供：0，请求：1
creatDate	汽车上线时间，即开始售卖时间
price	二手车交易价格（预测目标）

6.2 应用案例

Kaggle纽约出租车车程用时预测实战

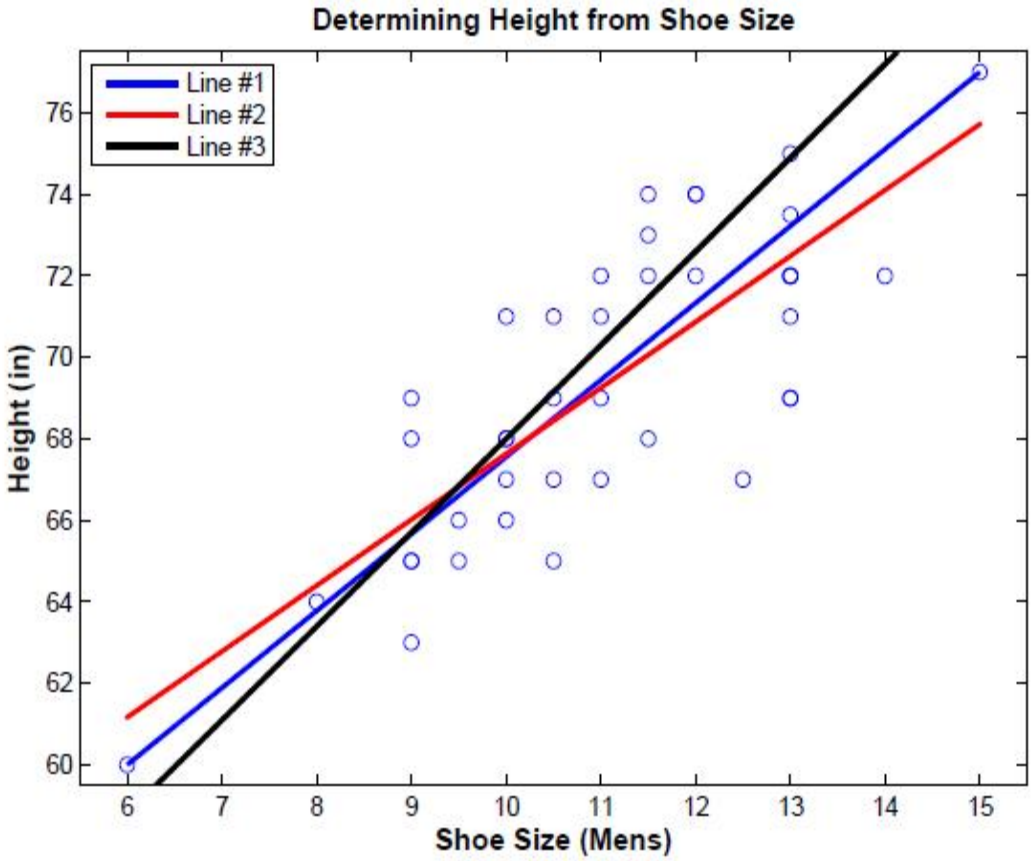
id	vendor_id	pickup_datetime	dropoff_datetime	passenger_	pickup_lon	pickup_lati	dropoff_lo	dropoff_lat	store_and_	trip_duration
id2875421	2	2016/3/14 17:24	2016/3/14 17:32	1	-73.9822	40.76794	-73.9646	40.7656	N	455
id2377394	1	2016/6/12 0:43	2016/6/12 0:54	1	-73.9804	40.73856	-73.9995	40.73115	N	663
id3858529	2	2016/1/19 11:35	2016/1/19 12:10	1	-73.979	40.76394	-74.0053	40.71009	N	2124
id3504673	2	2016/4/6 19:32	2016/4/6 19:39	1	-74.01	40.71997	-74.0123	40.70672	N	429
id2181028	2	2016/3/26 13:30	2016/3/26 13:38	1	-73.9731	40.79321	-73.9729	40.78252	N	435
id0801584	2	2016/1/30 22:01	2016/1/30 22:09	6	-73.9829	40.7422	-73.9921	40.74918	N	443
id1813257	1	2016/6/17 22:34	2016/6/17 22:40	4	-73.969	40.75784	-73.9574	40.7659	N	341
id1324603	2	2016/5/21 7:54	2016/5/21 8:20	1	-73.9693	40.79778	-73.9225	40.76056	N	1551
id1301050	1	2016/5/27 23:12	2016/5/27 23:16	1	-73.9995	40.7384	-73.9858	40.73281	N	255
id0012891	2	2016/3/10 21:45	2016/3/10 22:05	1	-73.981	40.74434	-73.973	40.78999	N	1225
id1436371	2	2016/5/10 22:08	2016/5/10 22:29	1	-73.9827	40.76384	-74.0022	40.73299	N	1274

6 回归分析

- 6.1 回归概述
- 6.2 应用案例
- 6.3 线性回归
- 6.4 非线性回归
- 6.5 Logistic回归
- 6.6 评估

6.3 线性回归

Which line is the *best* estimate?



$$m(x) = \beta_0 + \beta_1 x$$

	β_0	β_1
Line #1	48.6	1.9
Line #2	51.5	1.6
Line #3	45.0	2.3

6.3.1 一元线性回归

$$m(x) = \beta_0 + \beta_1 x$$

RSS残差平方和最小

$$R(\beta_0, \beta_1) = \sum_{i=1}^{n} \left(y_i - \left(\beta_0 + \beta_1 x_i\right)\right)^2$$

$$\frac{\partial R}{\partial \beta_0}\Big|_{=0} \Rightarrow -2\sum_{i=1}^{n}\left(y_i - \left(\beta_0 + \beta_1 x_i\right)\right) = 0$$

$$\Rightarrow \beta_0 = \overline{y} - \beta_1 \overline{x}$$

$$\frac{\partial R}{\partial \beta_1}\Big|_{=0} \Rightarrow -2\sum_{i=1}^{n} x_i\left(y_i - \left(\beta_0 + \beta_1 x_i\right)\right) = 0$$

$$\Rightarrow \sum_{i=1}^{n}\left(x_i y_i - x_i\left(\overline{y} - \beta_1 \overline{x} + \beta_1 x_i\right)\right) = 0$$

$$\Rightarrow \beta_1 = \frac{\sum_{i=1}^{n} x_i y_i - n\overline{x}\,\overline{y}}{\sum_{i=1}^{n} x_i^2 - n\overline{x}^2}$$

6.3.2 多元线性回归

序号	总胆固醇 X_1	甘油三酯 X_2	胰岛素 X_3	糖化血红蛋白 X_4	血糖 Y
1	5.68	1.90	4.53	8.2	11.2
2	3.79	1.64	7.32	6.9	8.8
…	…	…	…	…	…
26	5.84	0.92	8.61	6.4	13.3
27	3.84	1.20	6.45	9.6	10.4

6.3.2 多元线性回归

$$m(x_i) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \ldots + \beta_p x_{id} = \beta_0 + \sum_{k=1}^{d} \beta_k x_{ik}$$

$$\sum_{i}^{n} m(x_i) = \beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + \ldots + \beta_d x_{1d}$$
$$+ \beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + \ldots + \beta_d x_{2d}$$
$$+ \ldots$$
$$+ \beta_0 + \beta_1 x_{n1} + \beta_2 x_{n2} + \ldots + \beta_d x_{nd}$$

$$= \sum_{i=1}^{n} \left(\beta_0 + \sum_{k=1}^{d} \beta_k x_{ik} \right)$$

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1d} \\ 1 & x_{21} & \cdots & x_{2d} \\ \cdots & \cdots & \cdots & \cdots \\ 1 & x_{n2} & \ldots & x_{nd} \end{bmatrix} \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \cdots \\ \beta_d \end{bmatrix}$$

6.3.2 多元线性回归

$$R(\beta)=\left(Y-X\beta\right)^T\left(Y-X\beta\right)$$

$$\frac{\partial R}{\partial \beta}\Big|_{=0} \Rightarrow \frac{\partial}{\partial \beta}\left(Y^TY-Y^TX\beta-\beta^TX^TY+\beta^TX^TX\beta\right)\Big|_{=0}$$

$$\Rightarrow X^TX\beta=X^TY$$

$$\beta=\left(X^TX\right)^{-1}X^TY$$

6.3.2 多元线性回归

$$\beta = \left(X^T X\right)^{-1} X^T Y$$

- $(X^T X)^{-1}$不可逆时无法求出β
- $X^T X$越趋近于0，会使得回归系数趋向于无穷大，此时得到的回归系数是无意义的
  - 岭回归

$$R(\beta) = \left(Y - X\beta\right)^T \left(Y - X\beta\right) + \lambda \left\|\beta\right\|_2$$

  - Lasso回归

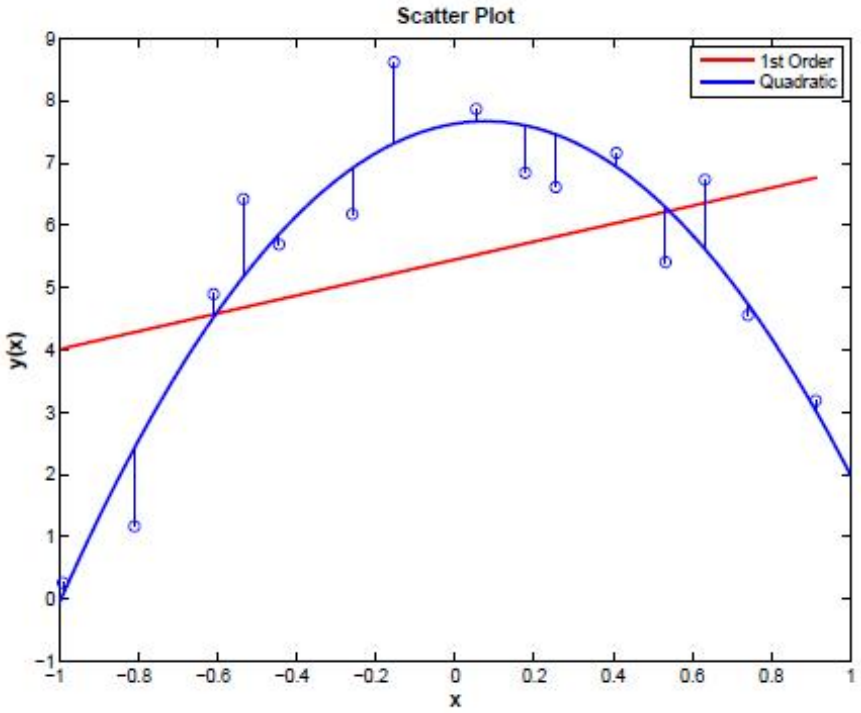
$$R(\beta) = \left(Y - X\beta\right)^T \left(Y - X\beta\right) + \lambda \left\|\beta\right\|_1$$

6.3.3 多项式回归

- 有时候只用一条直线是不充分的。
- 多项式回归Polynomial Regression

$$m(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2^2 + \ldots + \beta_d x_d^d = \beta_0 + \sum_{k=1}^{d} \beta_k x_{ik}^k$$

- 注意过拟合



6.3.3 多项式回归

$$m(x_i) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2}^2 + \ldots + \beta_d x_{id}^d = \beta_0 + \sum_{k=1}^{d} \beta_k x_{ik}^k$$

$$\sum_{i}^{n} m(x_i) = \beta_0 + \beta_1 x_{11} + \beta_2 x_{12}^2 + \ldots + \beta_d x_{1d}^d$$

$$+ \beta_0 + \beta_1 x_{21} + \beta_2 x_{22}^2 + \ldots + \beta_d x_{2d}^d$$

$$+ \ldots$$

$$+ \beta_0 + \beta_1 x_{n1} + \beta_2 x_{n2}^2 + \ldots + \beta_d x_{nd}^d$$

$$= \sum_{i=1}^{n} \left(\beta_0 + \sum_{k=1}^{d} \beta_k x_{ik}^k \right)$$

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad X = \begin{bmatrix} 1 & x_{11} & \ldots & x_{1p}^p \\ 1 & x_{21} & \ldots & x_{2p}^p \\ \ldots & \ldots & \ldots & \ldots \\ 1 & x_{n2} & \ldots & x_{np}^p \end{bmatrix} \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \ldots \\ \beta_d \end{bmatrix}$$

$$R(\beta) = (Y - X\beta)^T (Y - X\beta)$$

6.3.4 如何减少过拟合风险

向量的L1范数与L2范数

L1范数：表示向量中每个元素绝对值的和

$$||x||_1 = \sum_{i=1}^{n} |x_i|$$

L2范数：欧氏距离

$$||x||_2 = \sqrt{\sum_{i=1}^{n} x_i^2}$$

L2范数越小，可以使得w的每个元素都很小，接近于0，但L1范数不同的是他不会让它等于0而是接近于0.

6 回归分析

- 6.1 回归概述
- 6.2 应用案例
- 6.3 线性回归
- 6.4 非线性回归
- 6.5 Logistic回归
- 6.6 评估

6.4 非线性回归

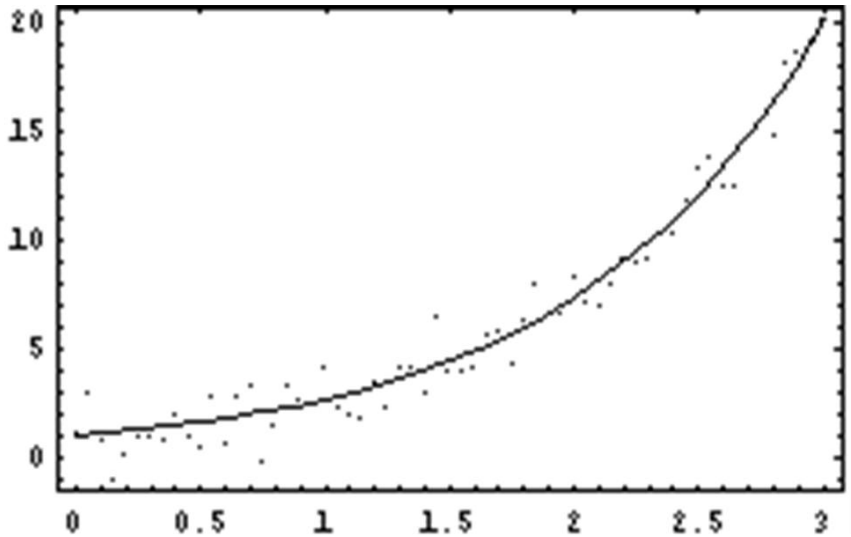
指数函数模型$y_i = ae^{bx_i+u_i}$

对上式等号两侧同取自然对数，得

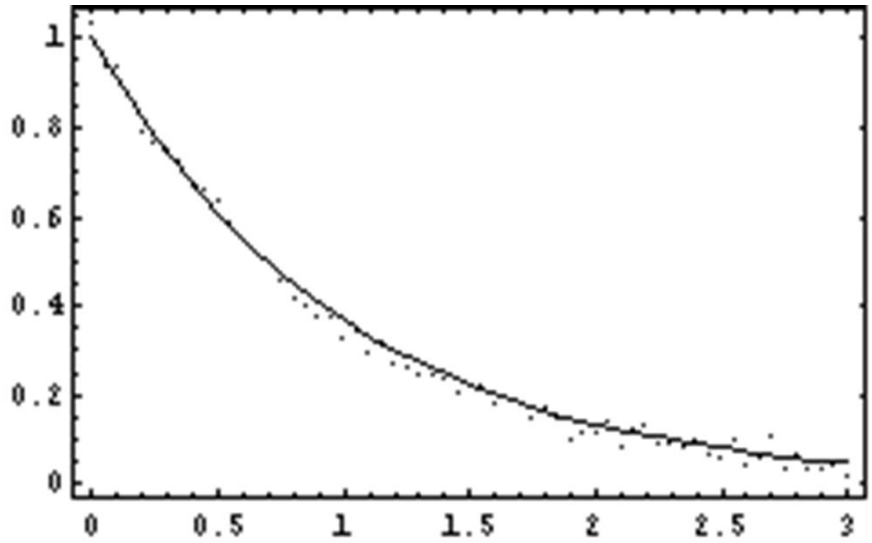
$$\ln y_i = \ln a + bx_i + u_i$$

令$\ln y_i = y_i^*$, $\ln a = a^*$ 则 $y_i^* = a^* + bx_i + u_i$

变量y_i^* 和x_i已变换成为线性关系。其中u_i表示随机误差项。



$b > 0$



$b < 0$

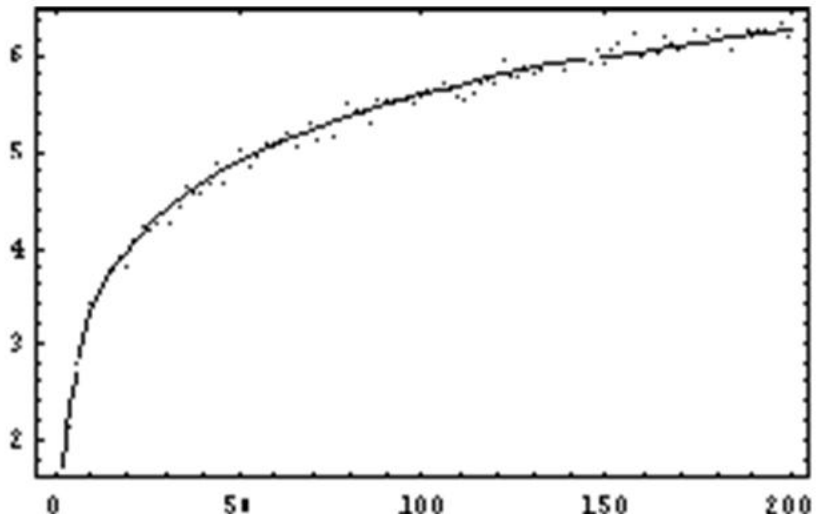
6.4 非线性回归

对数函数模型$y_i = a + \mathrm{b}\ln x_i + u_i$

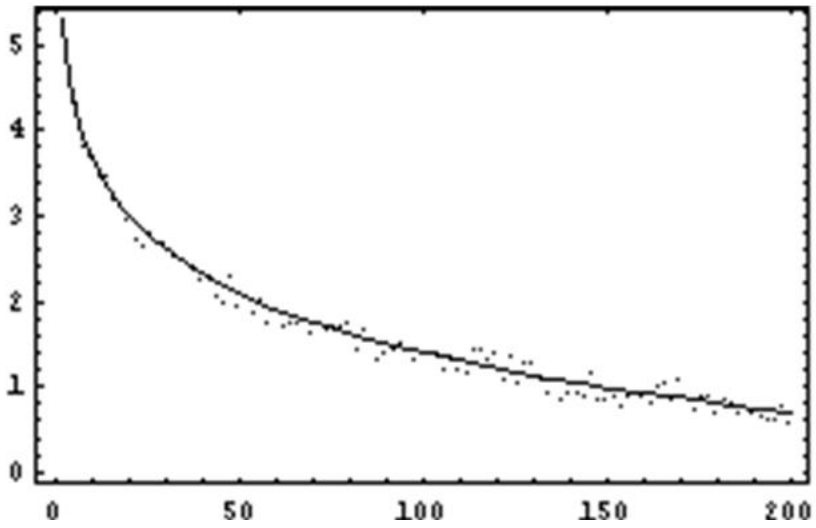
令$x_i^* = \ln x_i$, 则

$$y_i = a + b\,x_i^* + u_i$$

变量y_i 和x_i^* 已变换成为线性关系。



$b > 0$



$b < 0$

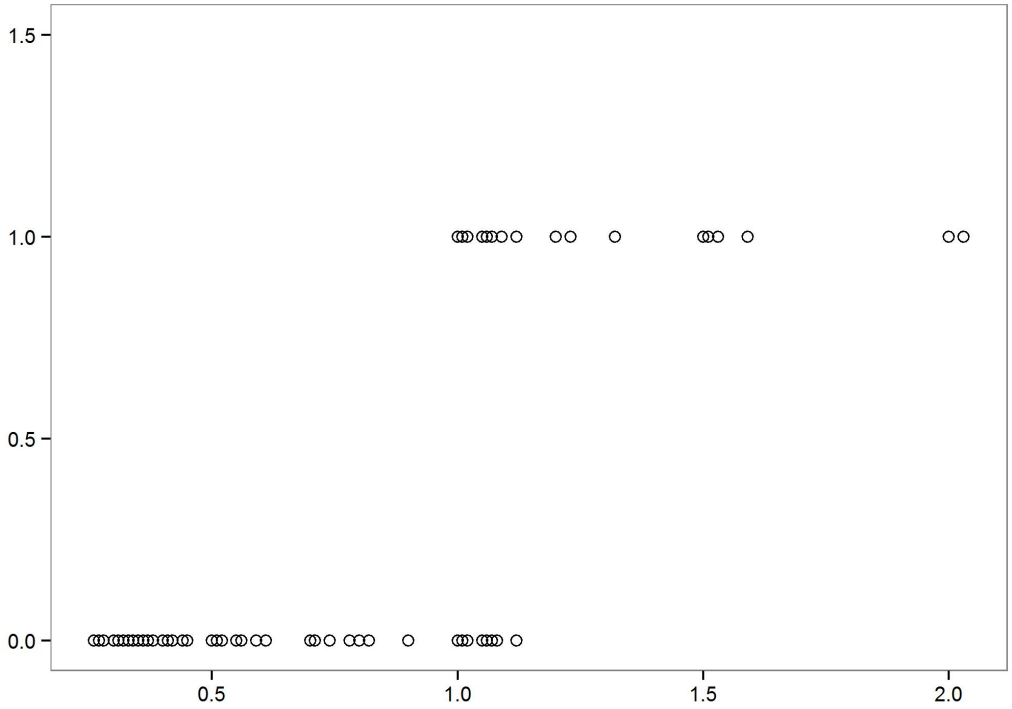
6 回归分析

- 6.1 回归概述
- 6.2 应用案例
- 6.3 线性回归
- 6.4 非线性回归
- 6.5 Logistic回归
- 6.6 评估

6.5 Logistic回归

$$y \in \{0, 1\}$$

$$y \sim \mathbf{X}?$$



6.5 Logistic回归

假设：

$$\begin{cases} P(y=1)=p \\ P(y=0)=1-p \end{cases}$$

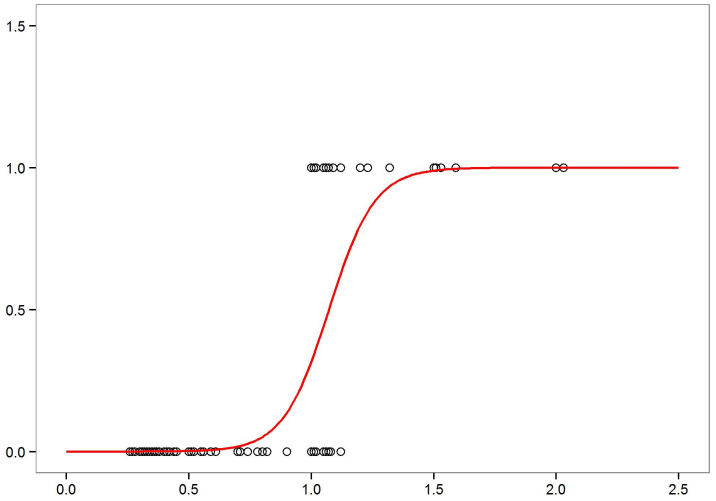
$$p=\frac{1}{1+e^{-(\beta_0+\beta_1 x_1+\beta_2 x_2+\ldots+\beta_d x_d)}}$$

$$\ln\left(\frac{p}{1-p}\right)=\beta_0+\beta_1 x_1+\beta_2 x_2+\ldots+\beta_d x_d$$

对数似然值：

$$L(\boldsymbol{\beta})=\frac{1}{n}\sum_{i=1}^{n}\log p\left(y^{(i)};\boldsymbol{\beta}\right)$$

$$\max(L)$$



6 回归分析

- 6.1 回归概述
- 6.2 应用案例
- 6.3 线性回归
- 6.4 非线性回归
- 6.5 Logistic回归
- 6.6 评估

6.6 评估

- 均方误差：MSE（Mean Squared Error）

$$MSE = \frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2$$

- 均方根误差：RMSE（Root Mean Squared Error）

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(y_i - \hat{y}_i\right)^2}$$

- 平均绝对误差：MAE（Mean Absolute Error）

$$MAE = \frac{1}{n}\sum_{i=1}^{n}\left|y_i - \hat{y}_i\right|$$

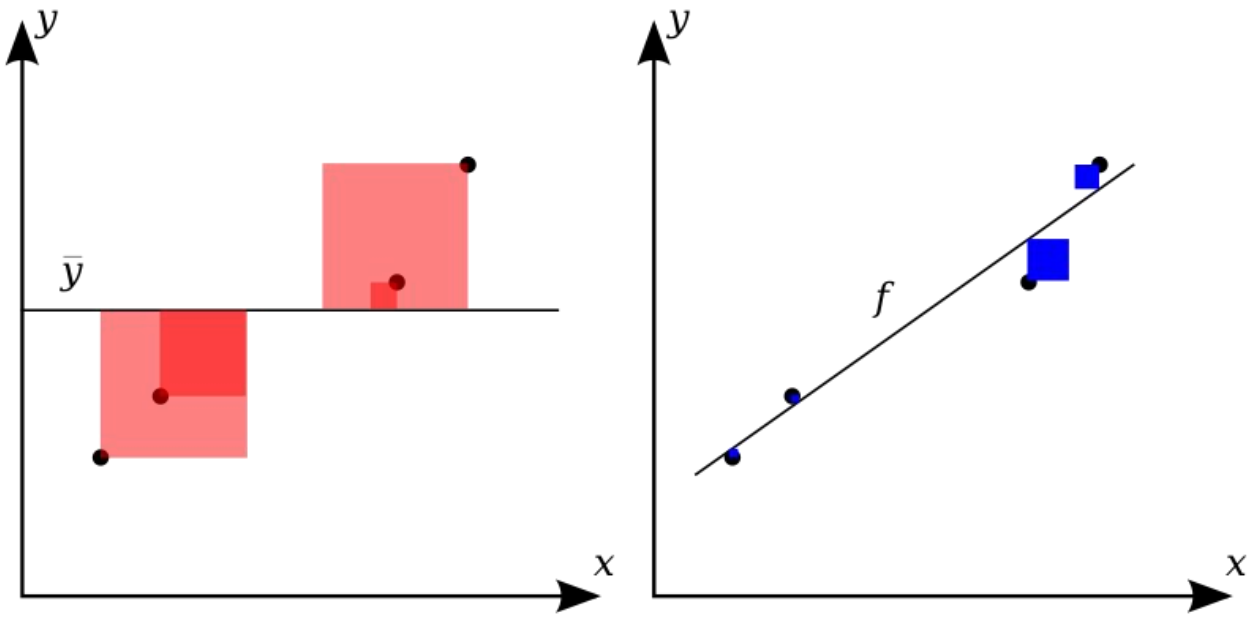
6.6 评估

- 总离差平方和

Sum of Squares Total : $SST = \sum_{i=1}^{n} \left(y_i - \overline{y}\right)^2$

- 回归残差平方和

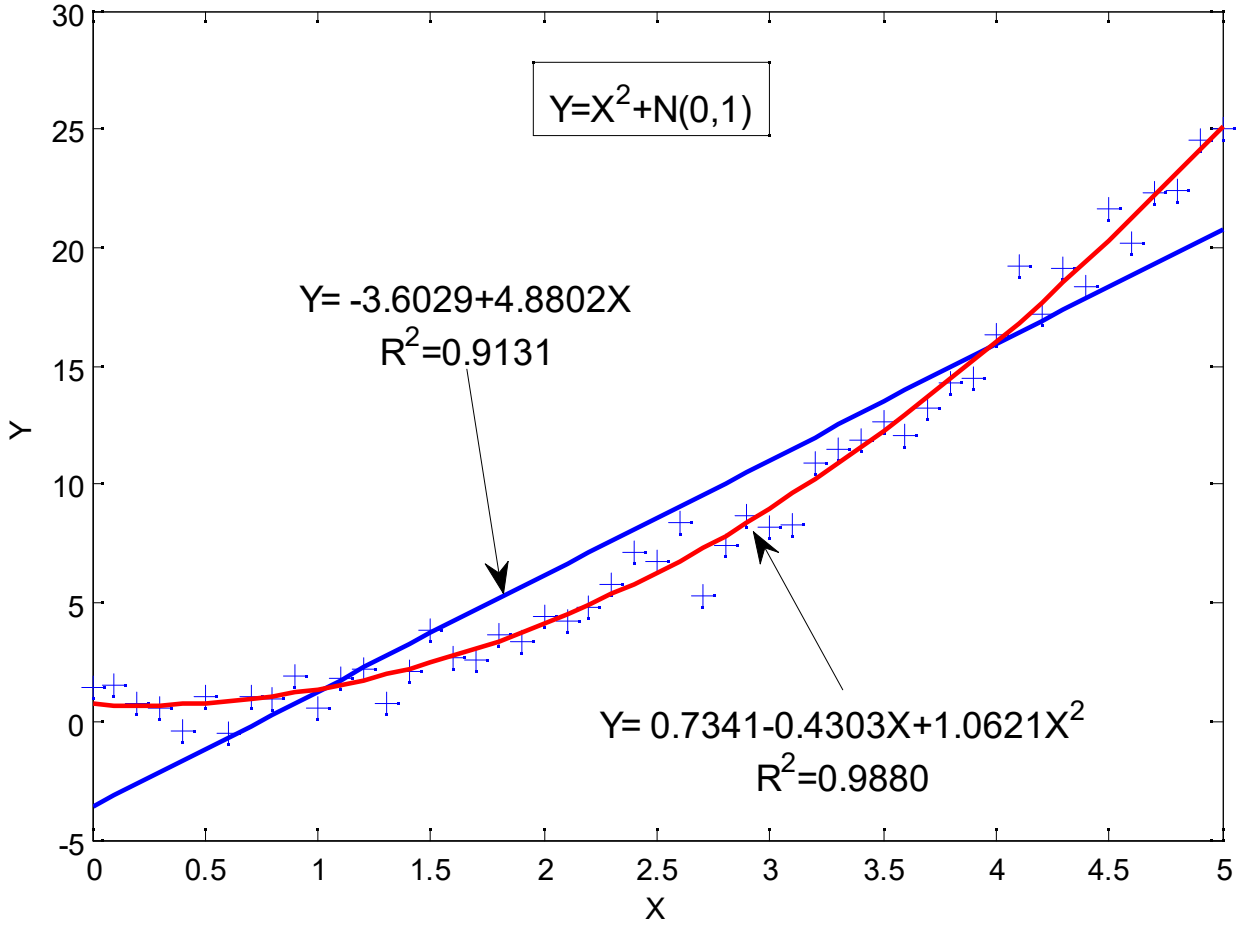
Sum of Squares Error : $SSE = \sum_{i=1}^{n} \left(y_i - \hat{y}_i \right)^2$



6.6 评估

- 决定系数：R^2（R-Square）

$$R^2 = \frac{SST - SSE}{SST} = 1 - \frac{SSE}{SST}$$



天津大学
Tianjin University

THE END

