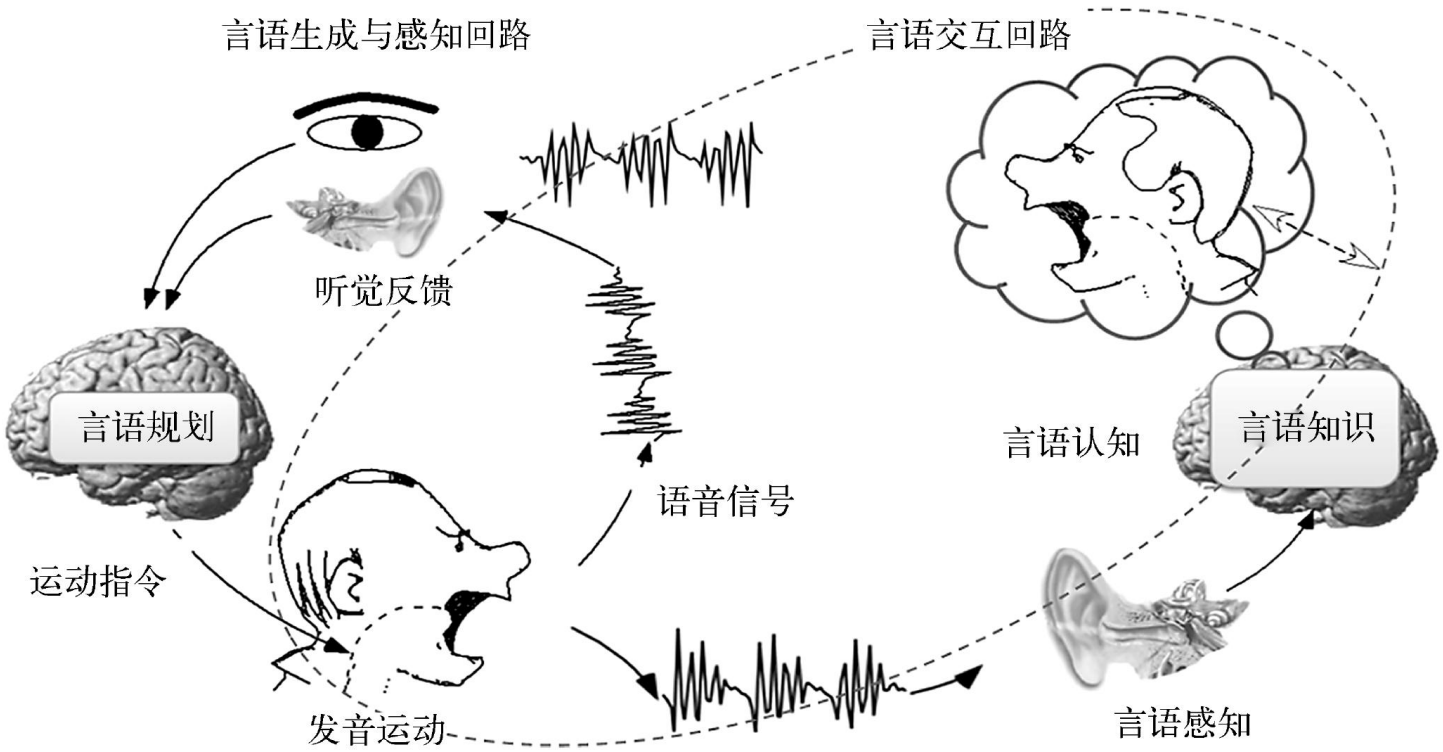
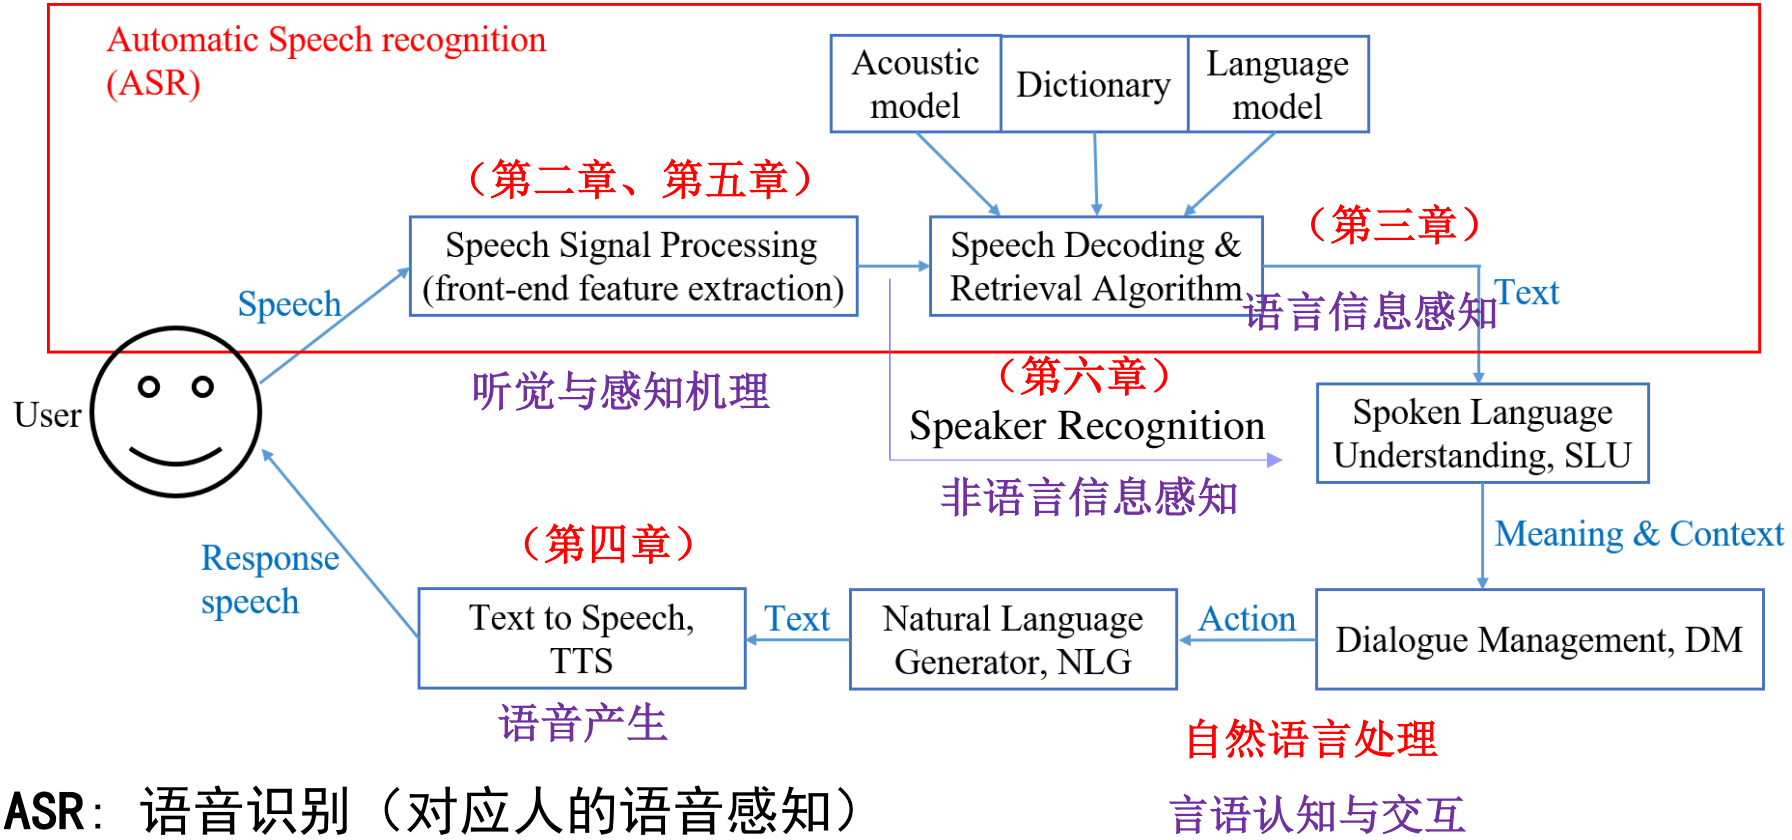
第四章　语音合成

言语链



- 生成感知认知回路和言语交互理解回路在同一知识语境和语言语境下工作。
- 反映了说话人的意图如何以言语的形式编码并传递给听话人。
- 反映了如何在听话人的大脑中解码、再现说话人的意图。

言语链与人机语音交互



ASR：语音识别（对应人的语音感知）

TTS：语音合成（对应人的语音生成）

Speaker Recognition：说话人识别/声纹识别

语音合成思考题（作业）

思考题：

基于深度学习的语音合成已经成为语音合成领域的主流技术。

4.1 简述基于传统神经网络的语音合成与端到端的语音合成的主要流程，并对比二者的优缺点。

4.2 相比于端到端语音合成技术，语音合成大模型为什么能取得更好的效果？语音合成大模型还存在哪些不足？

提交时间：11月2日24点前（回答内容不超过2页A4纸）

语音合成是语音交互中重要的一环

- 基于波形拼接的语音合成技术是20世纪90年代的主流技术。

- 本世纪初，语音合成算法逐步从基于波形拼接算法进展到基于统计模型的算法。2013年之前，基于HMM是语音合成的经典声学模型。2013年前后，深度学习算法在语音合成领域取得巨大成功，DNN逐步替代了HMM。2016年前后，端到端模型受到越来越多的关注。2023前后，基于大模型的语音合成成为研究热点。

- 重点掌握基于隐马尔可夫模型与深度学习算法的统计参数合成算法。

第四章　语音合成

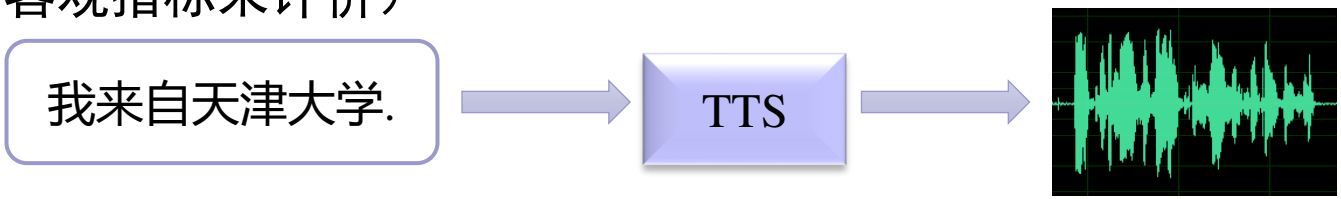
- 4.1 语音合成概述
  - **4.1.1 语音合成的基本概念**（基本概念）
  - 4.1.2 语音合成的方法回顾（了解）
  - 4.1.3 语音合成的典型应用（了解）
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

第四章　语音合成

- 4.1 语音合成概述
  - **4.1.1 语音合成的基本概念**
  - 4.1.2 语音合成的方法回顾
  - 4.1.3 语音合成的典型应用
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

什么是语音合成？

- 定义：
  - 语音合成（Speech Synthesis）：通过机械的、电子的方法产生人造语音的技术。
  - Text-to-Speech (TTS)：自动将文本转换为声音。
- 目标　　还有哪些目标？
  - Intelligibility（可懂度）
    - ✓ 可懂度是指语音中有意义的语言单元（如单词、单句等）内容的可识别（可被理解）的程度。（可以通过人工或ASR系统来测评）
  - Naturalness（自然度）
    - ✓ 自然度描述合成语音与人类语音听起来的接近程度。（尚未有唯一的客观指标来评价）



广义的语音合成

- 广义的语音合成研究内容包括：
  - 语音转换(Voice Transformation/Conversion)

    说话人转换

    语音到歌唱转换(Speech to Singing)

    情感转换

    口音转换

  - 歌唱合成(Singing Synthesis)

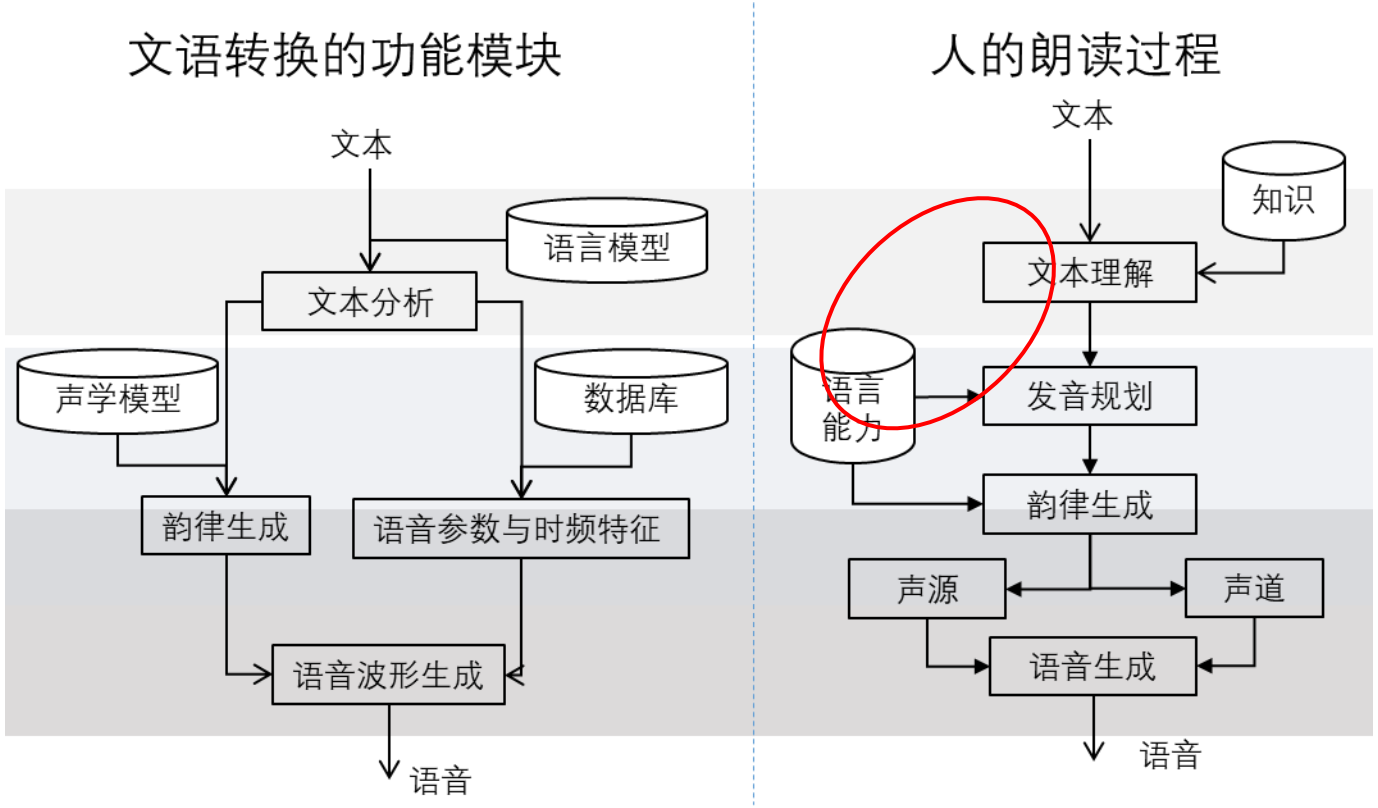
    文本到歌唱转换(Text/Lyric to Singing)

  - 可视语音合成(Visual Speech Synthesis)



日本虚拟歌姬
使用了Yamaha的VOCALOID 2语音合成引擎

TTS流程与人的朗读过程的对比



可以看出TTS包括了人的朗读过程的主要要素，但没有考虑两个最重要的要素：上下文理解和意图表达（speech skill）

语音合成的评价指标

- 主观指标
  - 绝对值：MOS (Mean Opinion Score, 1 - 5 or 0 - 100)
  - 相对值：CMOS (Comparative MOS, -3 -- 3)
    - ✓ (CMOS) 测试中，测试人员每次都会收听两个音频（两组需要对比的音频，具有相同的文本），并使用 [−3, 3] 中的分数评估后者与前者相比的感觉，间隔为 1，3代表远优于，-3代表远差于，0代表二者无差别。
  - 相对值：ABX Test
    - ✓ 与CMOS类似，AB两组音频进行对比，选取AB两种音频中音质较好的音频（A/B），或认为两组音频无差别(X)。
- 实验流程注意事项
  - 足够的、合理的测听人员与人数
  - 测听设备：不同测听设备的主观感觉不同
  - 测听安排：是否做测听人员培训？
  - 每个测听session的时间安排
  - 统计有效性：Significant test

语音合成的评价指标（续）

- 主观指标
  - 绝对值：MOS (Mean Opinion Score, 1-5 or 0-100)

一种由CCITT推荐的主观评价方法：

MOS分值	等级	语音质量
5	优	流畅自然，无瑕疵
4	良	失真不明显，不注意听感觉不到
3	一般	明显失真，但自然度和清晰度尚可忍受，听起来没有疲劳感
2	差	严重的失真、不自然，听起来有疲劳感
1	劣	语音质量极差，听觉无法忍受

MOS指标的不足点？

语音合成的评价指标（续）

- 客观指标
  - 和真实音频(Ground Truth)之间的距离度量
  - 根据信号的特性，常用指标有：
    1. 梅尔倒谱失真：Mel-Cepstral Distortion (MCD)

$$\mathrm{MCD}_K = \frac{1}{T}\sum_{t=0}^{T-1}\sqrt{\sum_{k=1}^{K}\left(c_{t,k}-c'_{t,k}\right)^2}$$

    2. F0均方根误差：Root Mean Square Error (RMSE) of F0
    3. 时长均方根误差：RMSE of Duration
    4. …

语音识别与语音合成客观指标的异同点？

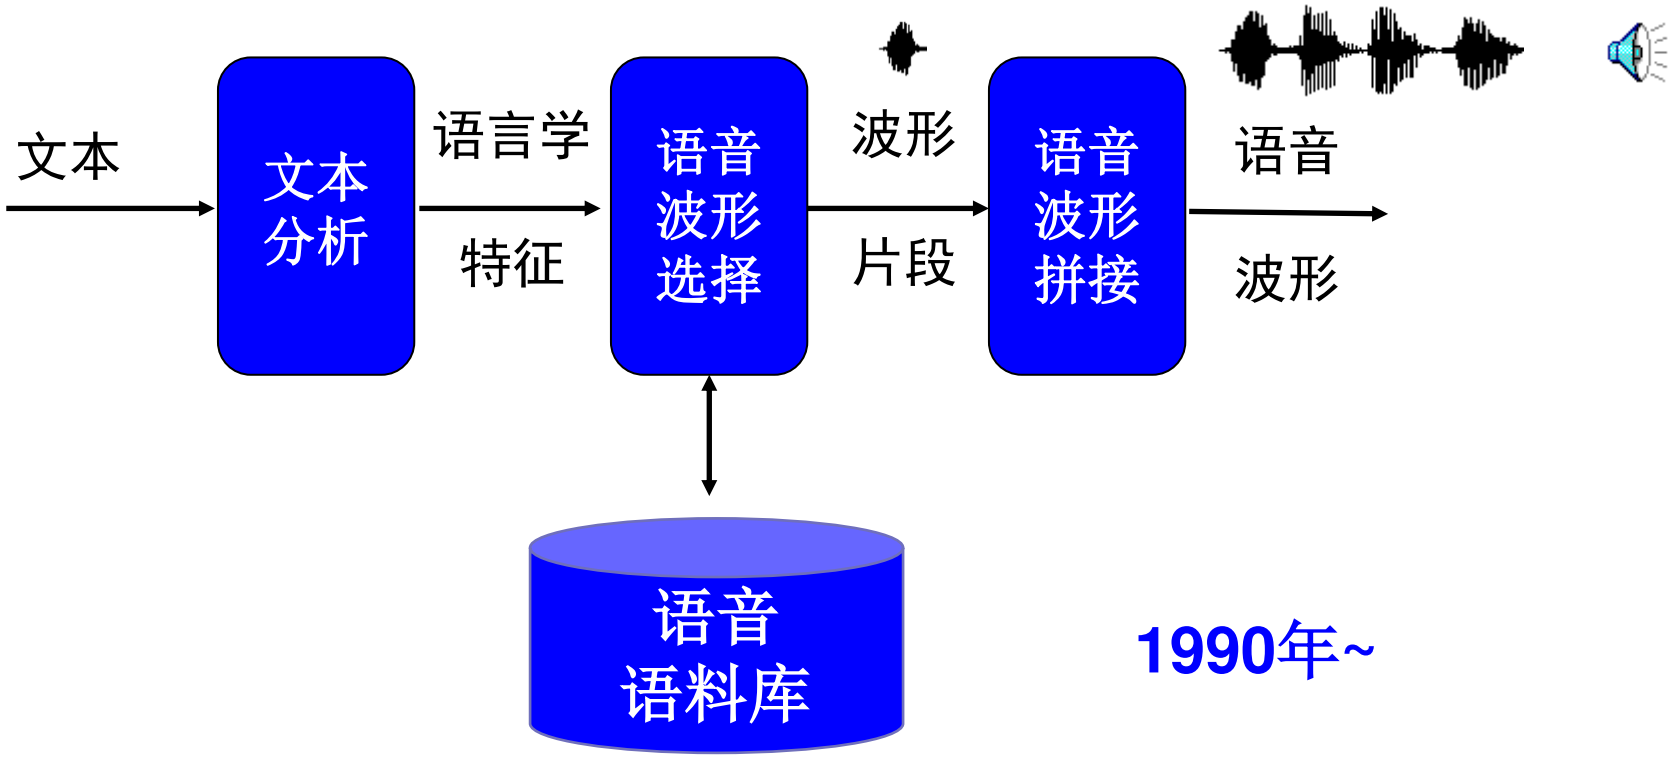
语音合成客观指标的不足点？

第四章　语音合成

- 4.1 语音合成概述
  - 4.1.1 语音合成的基本概念
  - **4.1.2 语音合成的方法回顾**
  - 4.1.3 语音合成的典型应用
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

基于波形拼接的语音合成 --- 整体框架（基本概念）

波形拼接语音合成：先从自然语音中的词或句子抽取语音基元并按一定规律组成语料库，合成语音时根据合成文本的要求，从语料库中查找出合适的基元，通过拼接、韵律修饰，最终得到合成的语音。



1990年~

波形拼接合成的框架图

基于波形拼接的语音合成 --- 问题

- 需要大规模的精心设计的语音数据库
- 语音数据库中没有类似音素样例时合成质量差
- 不易控制韵律
- 可扩展性差、不易于维护



如何解决波形拼接合成的问题？

统计参数语音合成（基本概念）

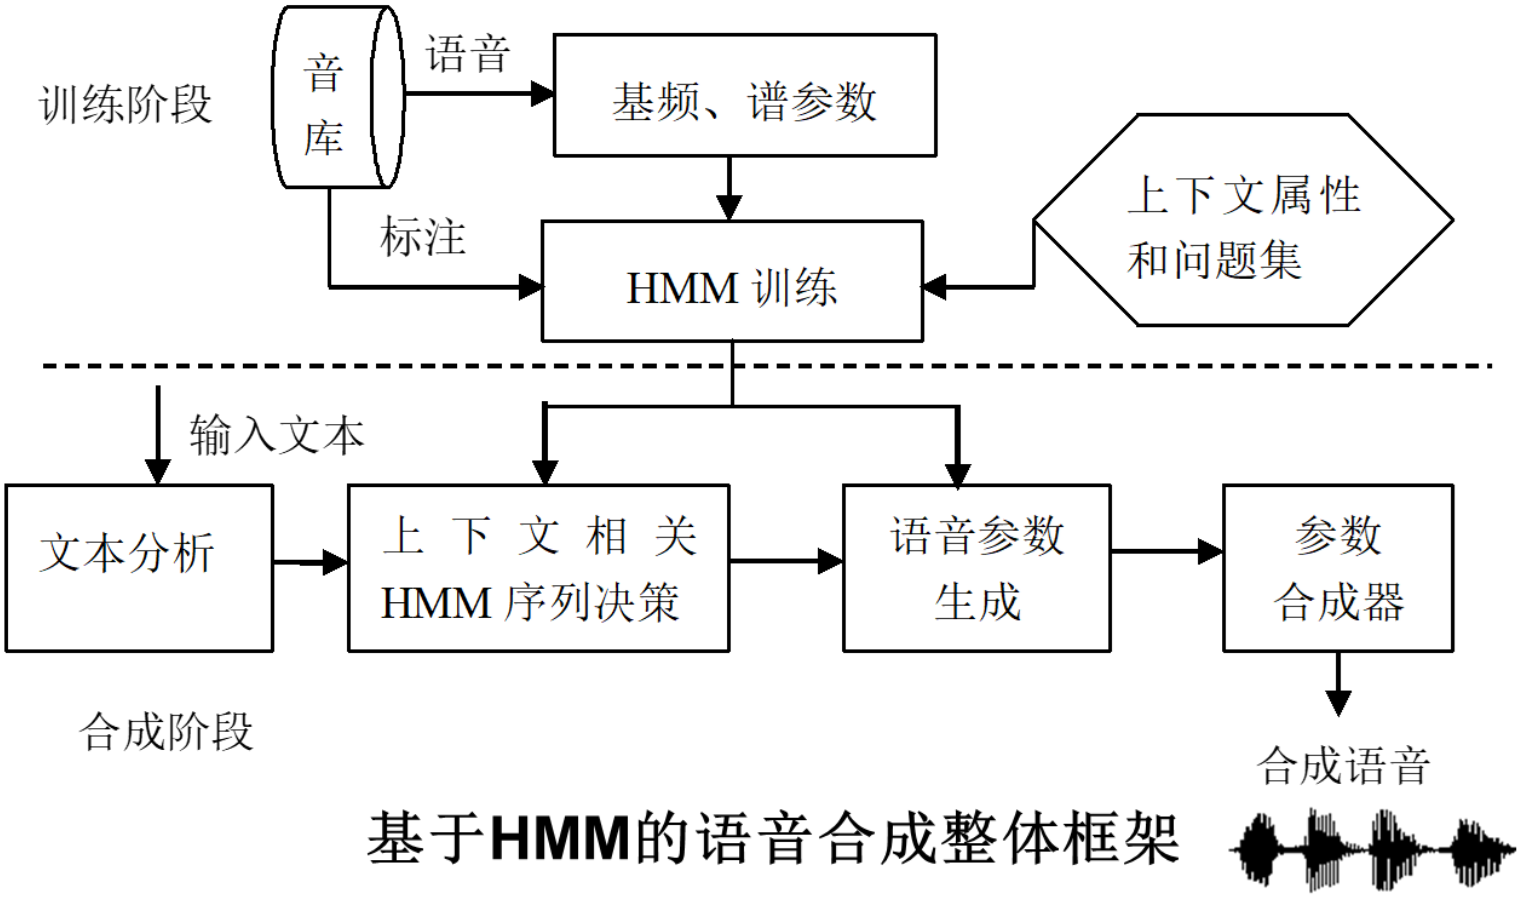
统计参数语音合成（Statistical Parametric Speech Synthesis，SPSS）：对输入的语音进行参数化表征，然后基于统计模型进行声学参数建模，并以训练得到的模型为基础构建语音合成系统。

优点：

- 无需大规模的精心设计的语音数据库
- 合成语音的质量稳定
- 可以控制韵律
- 可扩展性好易于维护

统计参数语音合成（续） （基本概念）

- 基于HMM的语音合成



基于HMM的语音合成整体框架

- 基于DNN的语音合成

第四章　语音合成

- 4.1 语音合成概述
  - 4.1.1 语音合成的基本概念
  - 4.1.2 语音合成的方法回顾
  - **4.1.3 语音合成的典型应用**
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

第四章　语音合成

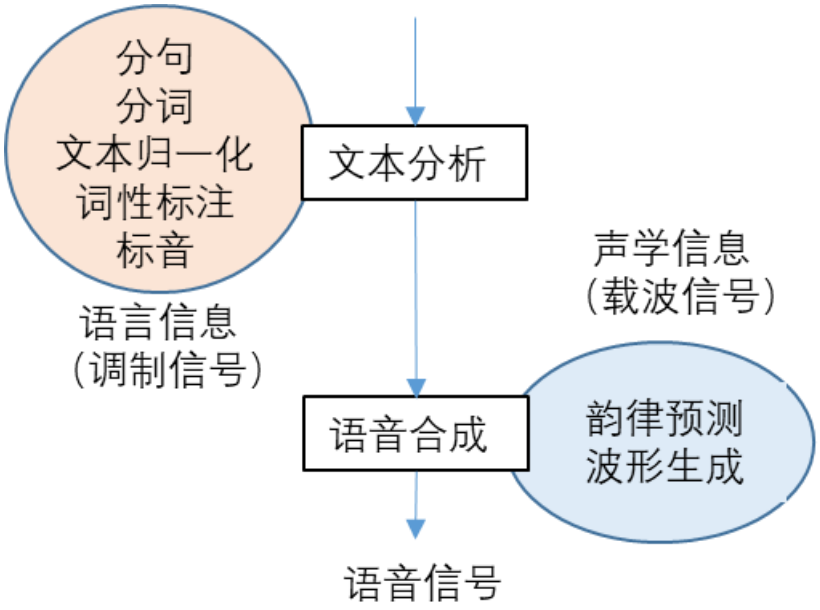
- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

第四章　语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
  - **4.2.1 语音合成的整体框架**（掌握）
  - 4.2.2 语音合成的文本分析（了解）
  - 4.2.3 语音合成的韵律分析（基本概念、了解）
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

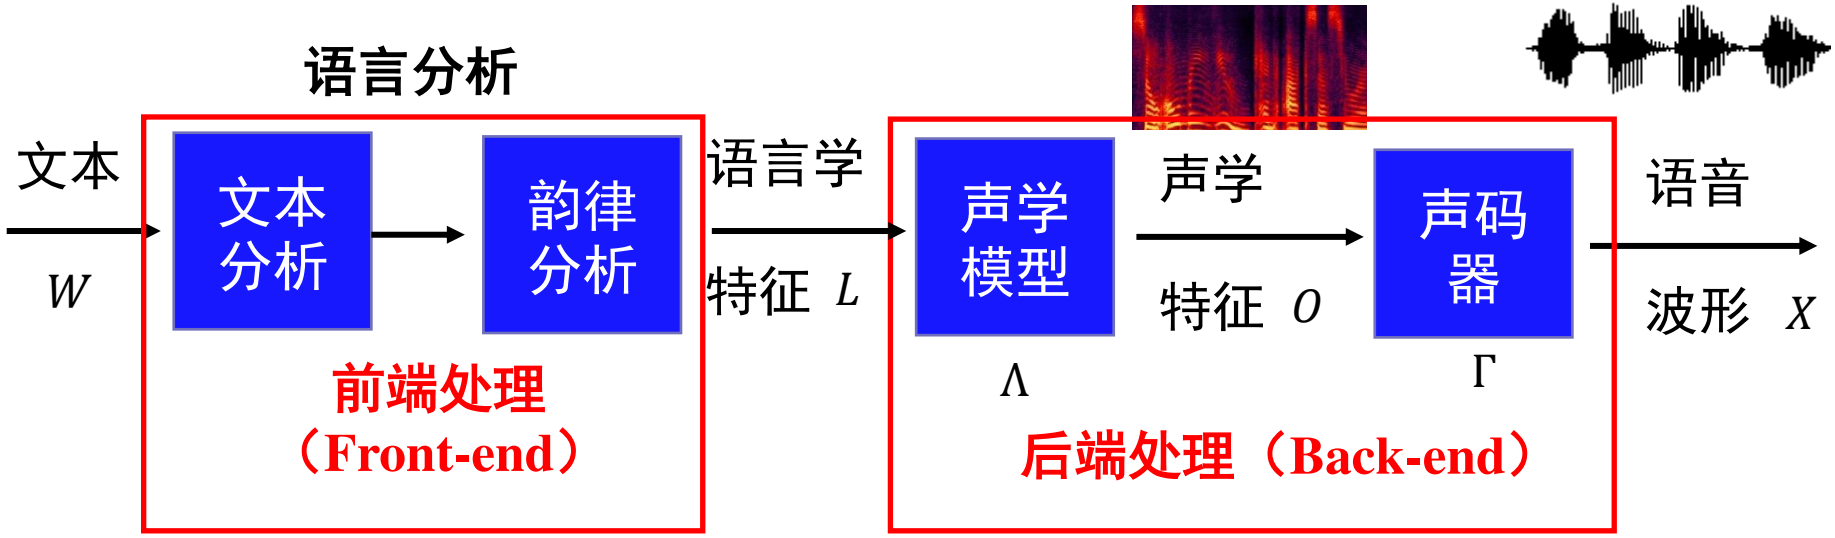
语音合成的主要流程

- 语音是一种通过语言调制由人类发声器官产生的声学信号。
- 文本转换语音合成的目标是将输入文本转换为自然语音。因此，语音合成的原理是实现将语言信息调制到声学信号上。
- 语言处理过程包括：句词切分，文本归一化等。
- 声音处理方面包括：韵律参数预测和声音波形生成。



一些研究把文本分析和韵律预测（分析）阶段合并在一起称为语言分析

统计参数语音合成的主要流程



语音合成的框架图

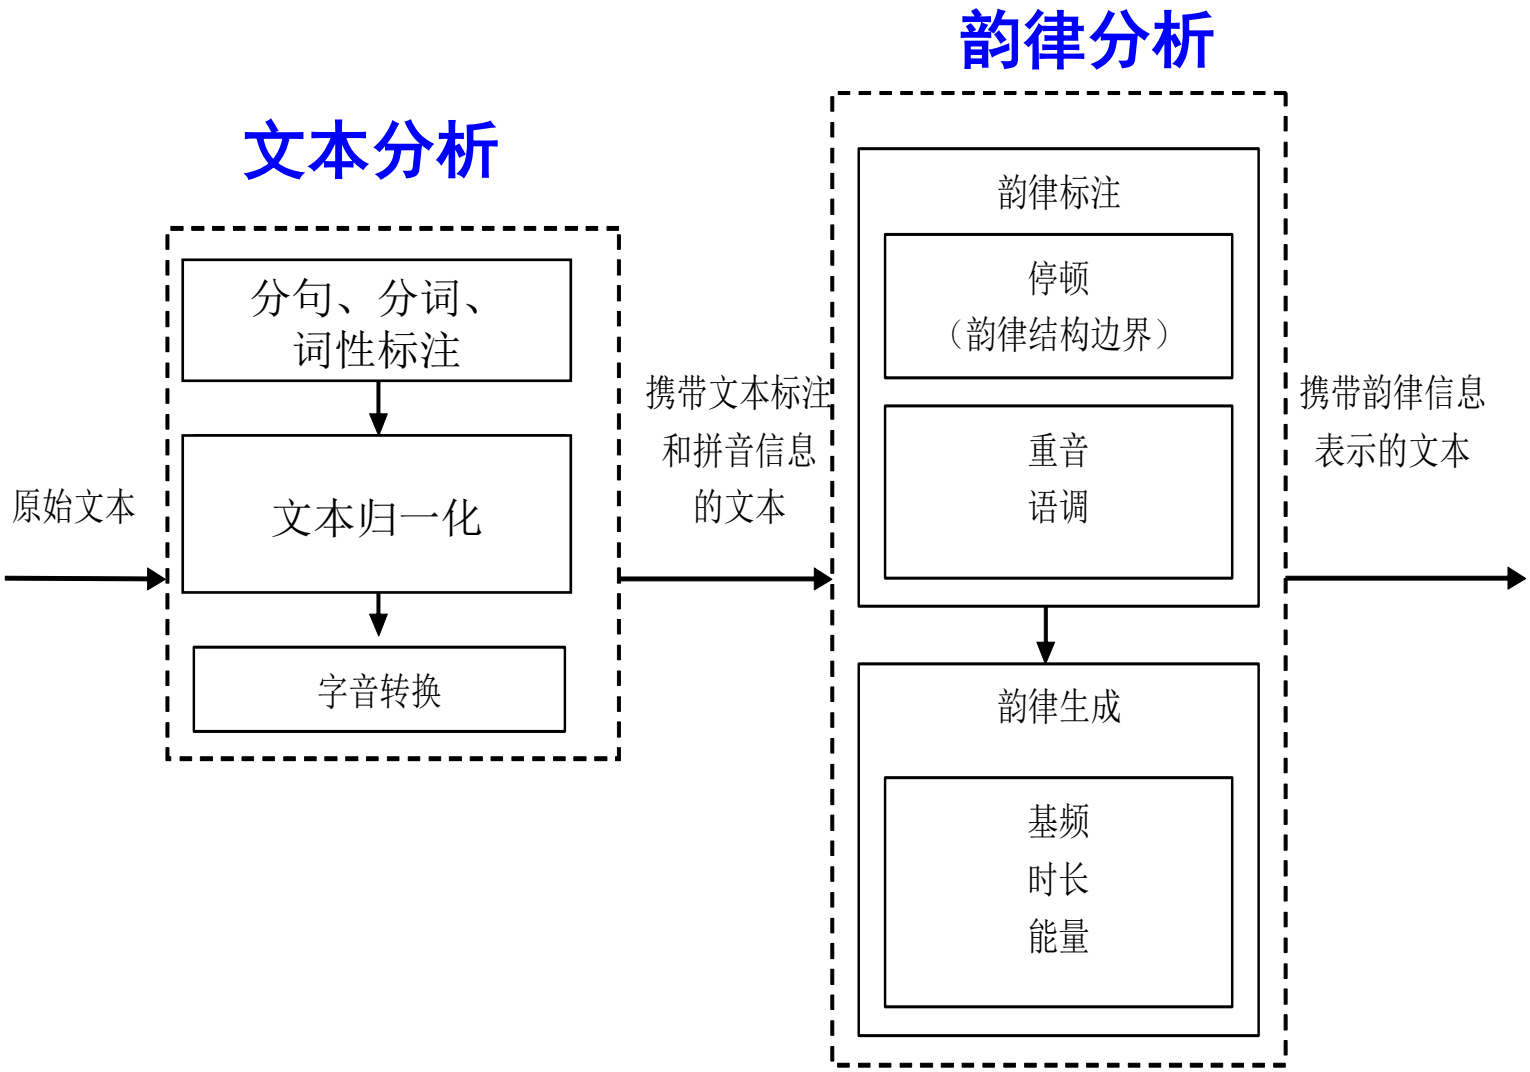
- 前端处理：从原始文本提取多种可以被声学模型所识别的语言学特征，亦即在音标和韵律信息方面提供了文本的符号语言表征。
- 后端处理：将语言学特征转换成声学特征，进一步转换成语音波形。

语音合成与语音识别主要流程的异同点有哪些？

第四章　语音合成

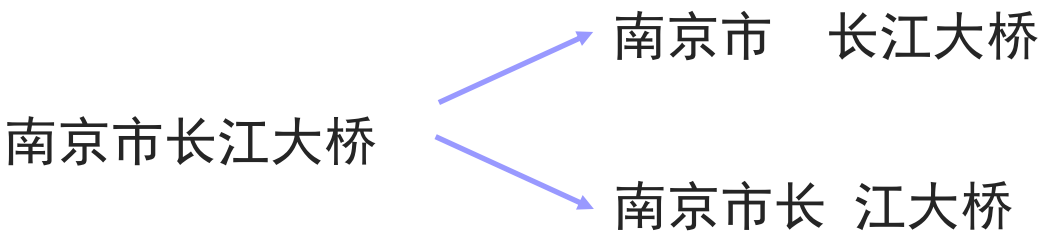
- 4.1 语音合成概述
- 4.2 语音合成的原理
  - 4.2.1 语音合成的整体框架
  - **4.2.2 语音合成的文本分析**
  - 4.2.3 语音合成的韵律分析
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

前端处理基本框架（基本概念）



分词与词性标注（基本概念）

- 目的：标注词语边界、词语词性。
  - 分词就是将句子（中文：连续的汉字序列）按照一定的规范重新组合成词序列的过程。
  - 通过分词明确标注词语边界，以便进一步确认词性、韵律边界、发音等。不正确的分词结果还会影响合成语音的自然度。
  - 词性标注为分词结果中的每个单词标注一个正确的词性的程序，也即确定每个词是名词、动词、形容词或其他词性的过程，词性可以用于预测韵律边界和多音字消岐。



文本归一化（基本概念）

- 文本中除了正常的单词，还会经常出现简略词、日期、公式、号码等文本信息，需要通过文本规范化（文本归一化），对这些文本块进行处理，否则合成出的语音就会出现语法错误、语义不完整等情况，从而导致语音合成效果的降低。

- 目的：转换非标准词为发音明确的口语单词
  - 前方120M ： 前方一百二十米
  - 拨打120 ： 拨打幺二零

- 方法：
  - 基于规则转换
  - 规则转换与深度学习结合

字音转换（基本概念）

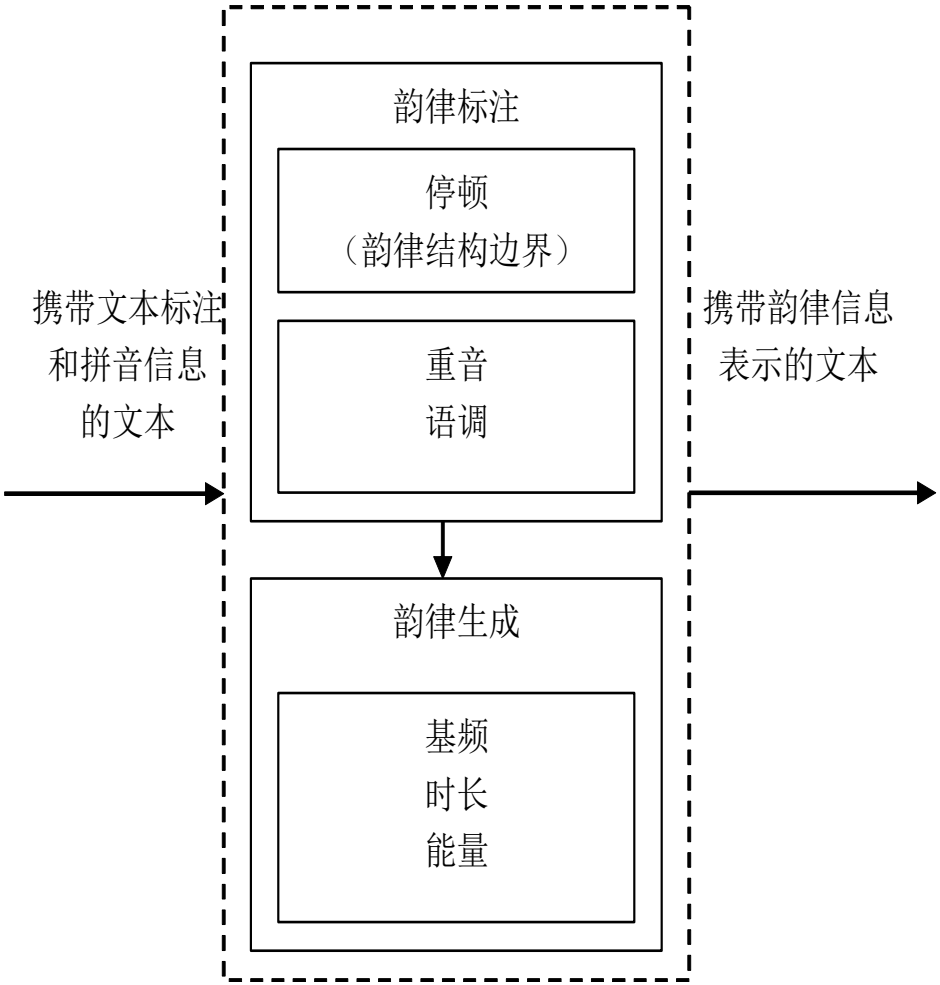
- 字音转换（标音）：给出每一个字符（比如中文）对应的发音，在此基础上进一步给出协同发音，**多音字消岐**，儿化音标注，变调等任务。
  - 古都{du1}，都{dou1}有
  - 理解{li2 jie3}

- 方法
  - 基于字典
  - HMM
  - 基于神经网络

第四章　语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
  - 4.2.1 语音合成的整体框架
  - 4.2.2 语音合成的文本分析
  - **4.2.3 语音合成的韵律分析**
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望

韵律分析基本框架（基本概念）



韵律结构通常被分为了三个层级：韵律词、中间短语（韵律短语）、语调短语。

语调（intonation），即说话的腔调，就是一句话里快慢轻重的配置和变化，体现说话人的态度或口气。

声调（tone）又叫字调，是指语言的音调的变化。普通话有四个声调：阴平，阳平，上声，去声。

重音也叫重读。在口语表达中，它有强调重点、突出主要情感的作用。

韵律的特征（基本概念）

- 从语音信号的角度来看，韵律是超音段的声音物理属性信息，例如音高，音长，和强度。
- 从语用功能的角度来看，韵律编码了多种类型的语音意图。韵律表达了信息的焦点，对话的连贯性，言语行为的类型，以及说话人的态度和情感状态。
- 韵律是句法和发音的接口，其受例如多种要素的影响，例如语气的类型，词汇的语义或句法的关联，组合的节奏，以及篇章的连贯性。
- 在语音感知中，韵律反映了节奏，强调，语音速率等。
- 在语音生成中，通过音高（F0），持续时间，能量等的变化实现。

基频、时长、能量的生成（基本概念）

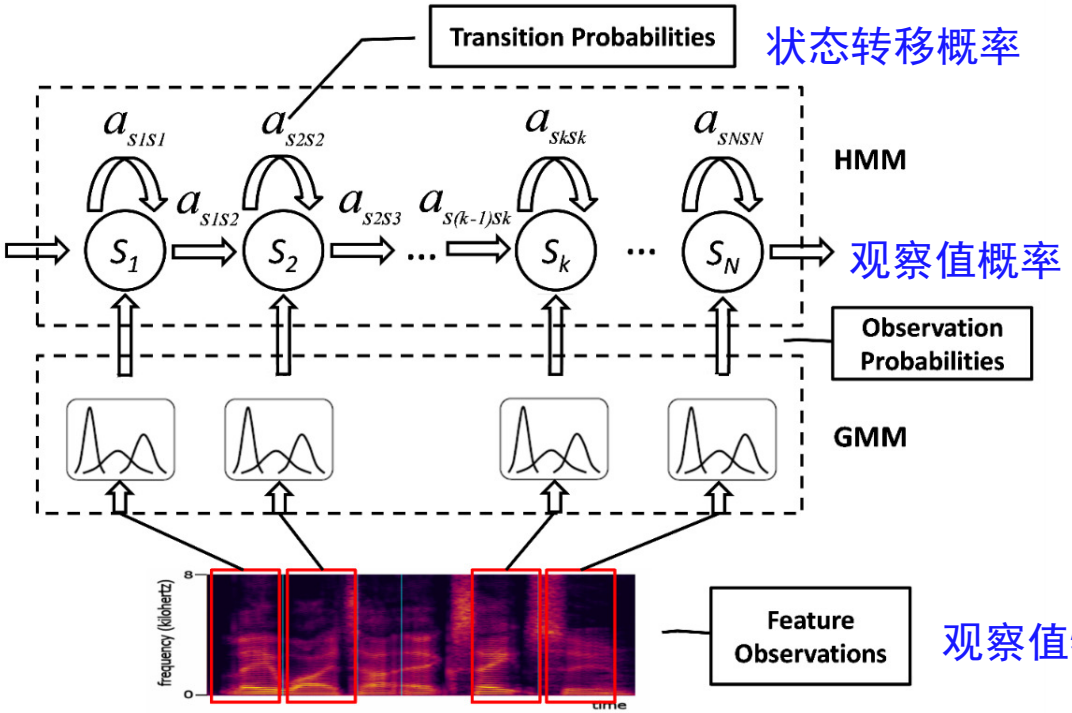
- 语调调型被隐含于基频模型，句子的基频曲线根据当前音节的拼音、声调与上下文环境，由语料库中的基频统计模型得到，其语调可以认为是语料库中语调的平均。
- 时长与能量也是重要的韵律信息。
- 基频、时长、能量的生成方法
  - 基于规则
  - 基于数据（传统统计模型、深度神经网络等）

第四章　语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
  - 4.3.1 基于HMM的语音合成（基本概念）
  - 4.3.2 基于神经网络的语音合成（了解）
  - 4.3.3 声码器（了解）
- 4.4 语音合成的技术展望

为什么是HMM？

状态转移概率矩阵A
观察值概率矩阵B
状态集合S



状态S不可见
观察值O可见

基于HMM的语音识别声学模型　20世纪80年代中期~

受HMM在语音识别领域成功的启发：
HMM适合于为时序信号建模



为什么是HMM？（续）

受HMM在语音识别领域成功的启发：
HMM适合于为时序信号建模

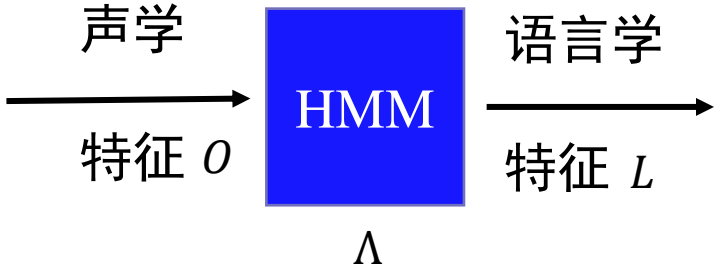


- 语音的产生可以理解为一个双重随机过程，一个是气流的经由过程，是无法观测的；而另一个发出的语音，是直接听到也就是说可观测的。

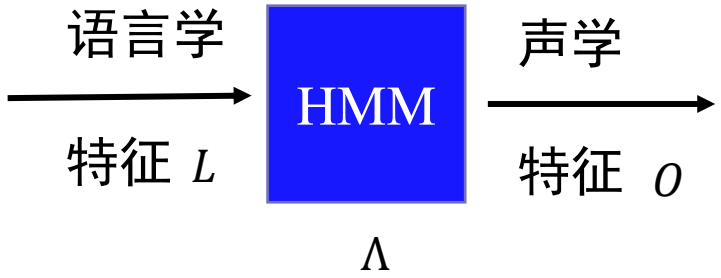
- 相应的，HMM与该发音过程一样，同样是双重随机过程，一个是隐马尔可夫链的输出状态序列（无法观测）；另一个是随机过程输出观察序列（可观测）。

基于HMM的语音识别与语音合成（掌握）

语音识别



语音合成



训练阶段

$$\hat{\Lambda} = \arg\max_{\Lambda} P(L|\mathrm{O},\Lambda)$$

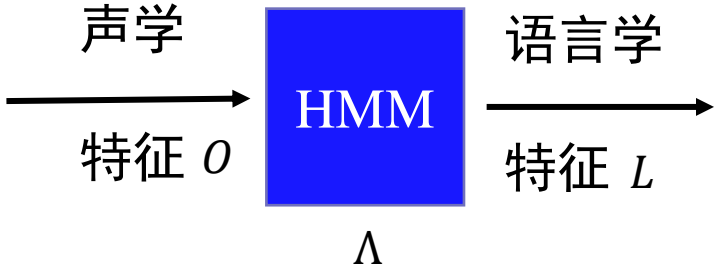
$$\hat{\Lambda} = \arg\max_{\Lambda} P(\mathrm{O}|L,\Lambda)$$

O：声学特征；L：文本信息

HMM的模型训练（Baum-Welch算法: 最大期望算法的快速实现）：
参考4.2节（语音识别-HMM声学模型）

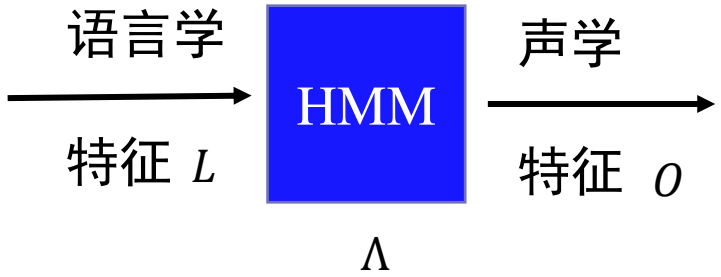
基于HMM的语音识别与语音合成（续）（掌握）

语音识别



识别、生成

语音合成



合成、生成

解码阶段

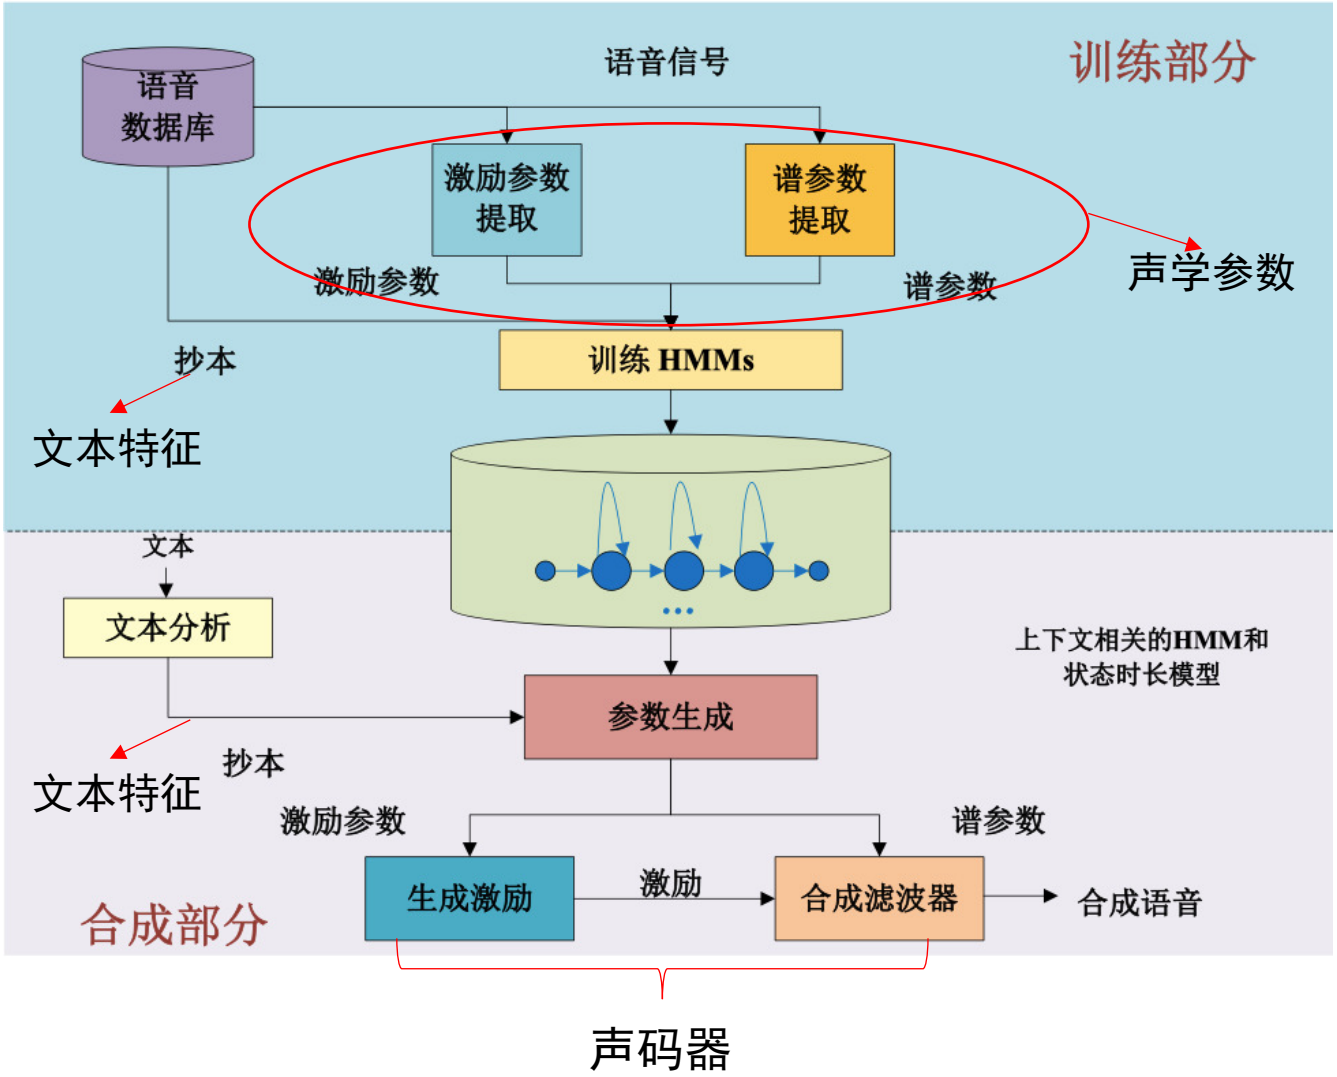
$$\hat{L} = \arg\max_{L} P(\mathrm{O} = o|L, \Lambda)$$

$$\hat{O} = \arg\max_{O} P(\mathrm{O}|L = l, \Lambda)$$

HMM的解码算法（基于动态规划算法的Viterbi算法）：

参考（语音识别-HMM声学模型）

基于HMM语音合成系统框架（掌握）



- 训练流程
1. 数据处理，提取文本特征与声学参数
2. 模型训练
   训练数据：
   <*文本特征，声学参数*>
   训练过程：
   a) 单音素训练
   b) 上下文相关HMM训练
   c) 决策树聚类
   d) 聚类后模型训练

- 合成部分
1. 文本处理，得到输入文本特征
2. 基于似然最大化准则通过HMM生成声学参数
3. 利用声码器将声学参数转换为最终语音

文本特征提取

文本经过前端处理，生成文本特征，进而处理得到语言学特征，才能被声学模型所利用。

文本特征包括诸多因素：

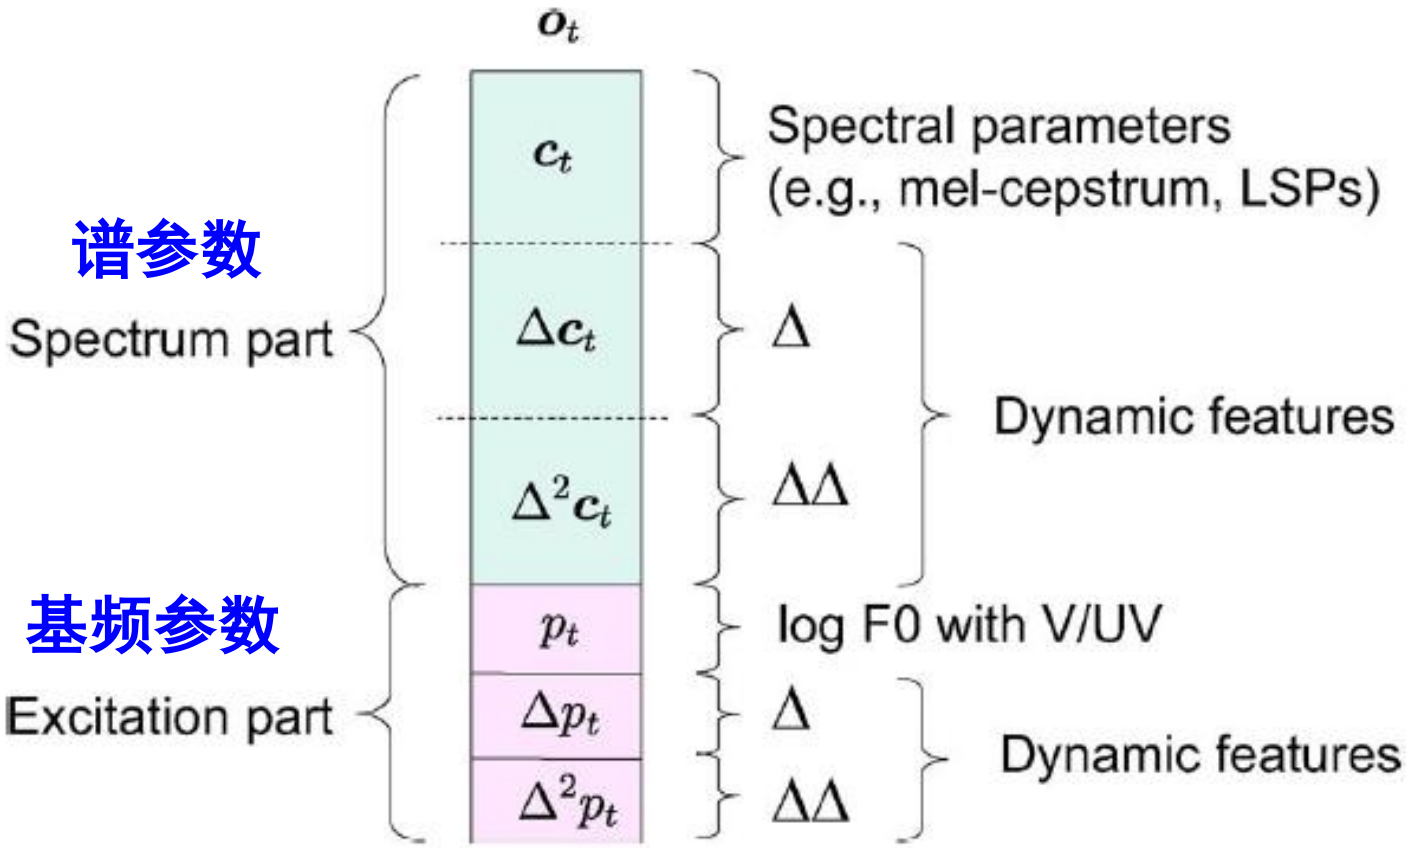
- **音素 ：** 音素包含了发音信息。
- **时长信息 ：** 包含了当前音素发音时长。
- **声调信息 ：** 记录韵母的声调。
- **音节信息 ：** 记录当前音节在词语、短语、语句中的位置信息，数目信息等。
- **词性、韵律词、韵律短语信息：** 主要记录韵律相关信息。
- **上下文信息 ：** 除了记录当前音素的上述特征之外，还需要记录当前音素临近音素的对应特征。上下文特征包含了音素系统发音、变调、韵律结构等丰富的信息，是语言学特征中及其重要的部分。

文本特征提取（续）

除此之外，对于特定的语音合成系统，语音合成前端还需要负责生成对应的特殊文本特征：

- 对于情感合成，需要标注整句文本的情感以及句中各短语对应的情感特征。
- 对于风格合成，需要标注文本对应的重读，倾向等等。

声学特征（谱、基频参数特征）

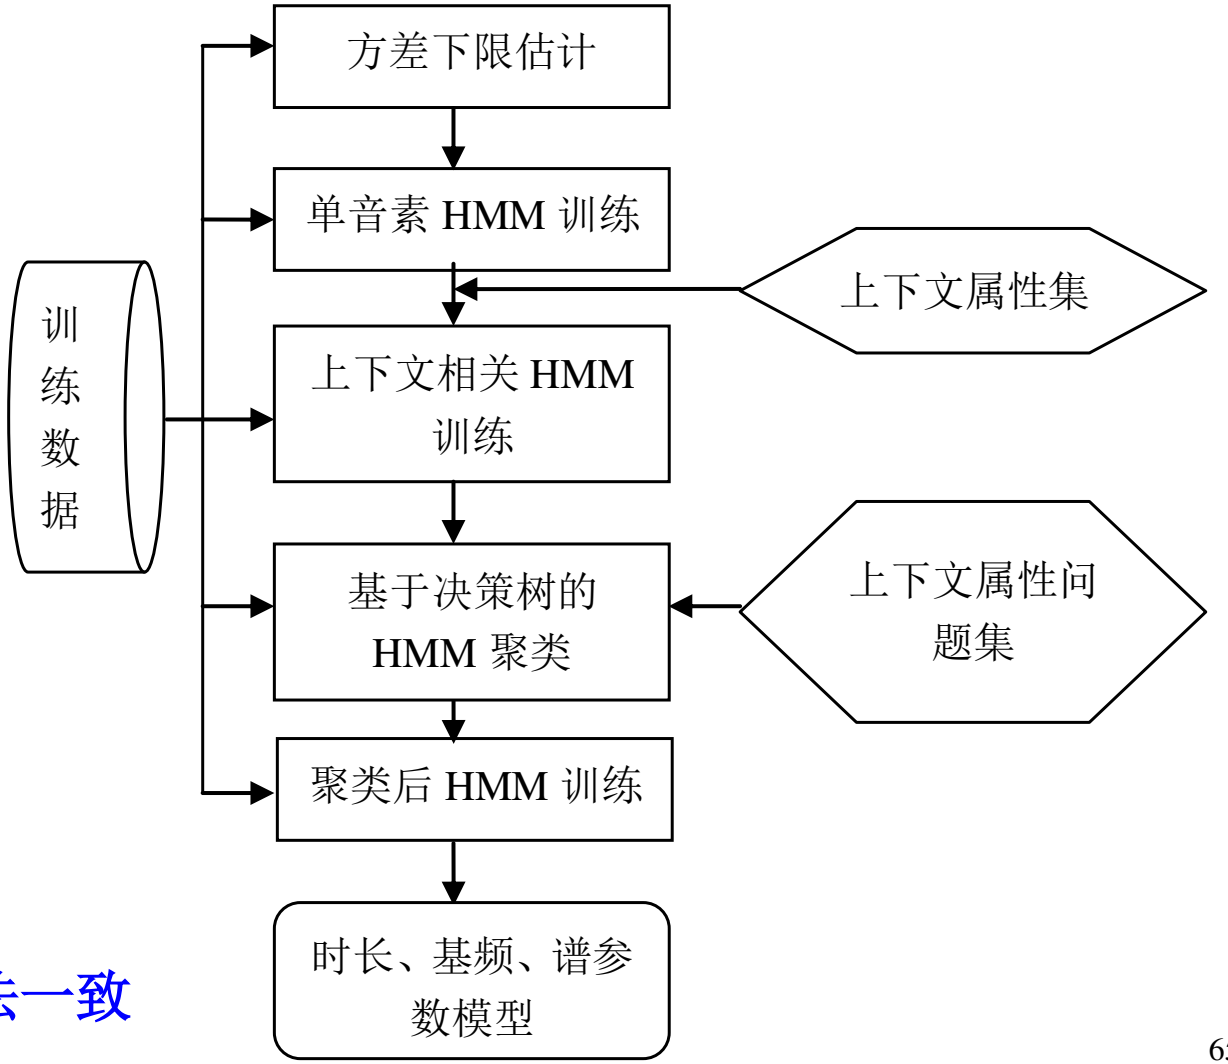


HMM语音合成的训练阶段

简单模型
（数据充足）

复杂模型
（数据不足）

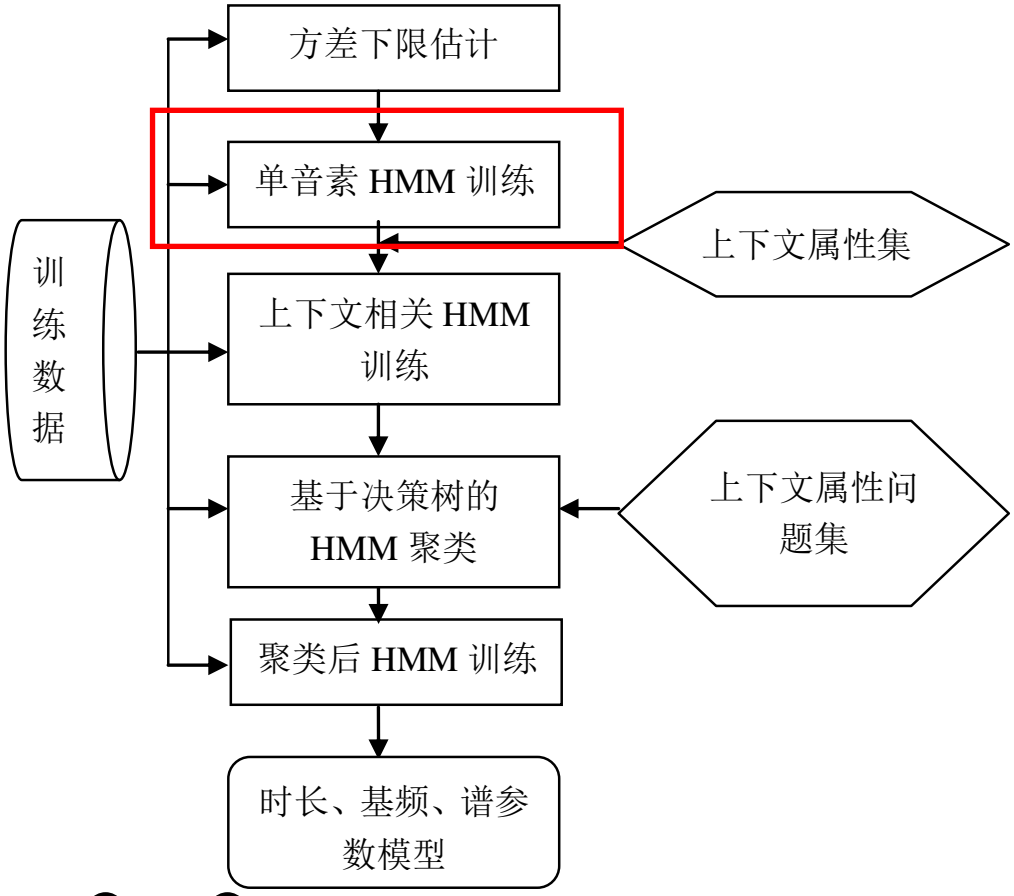
聚类复杂模型
（解决过拟合）

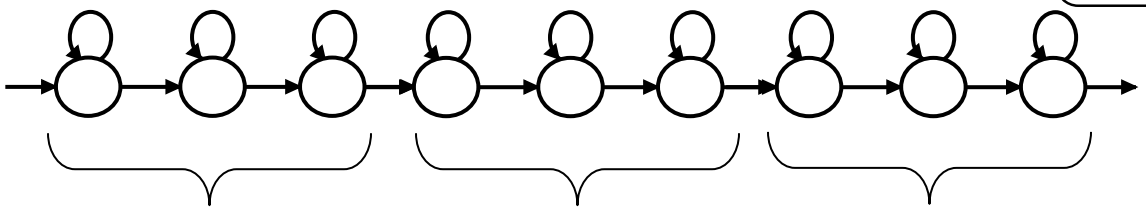


HMM的训练算法一致

单音素模型训练

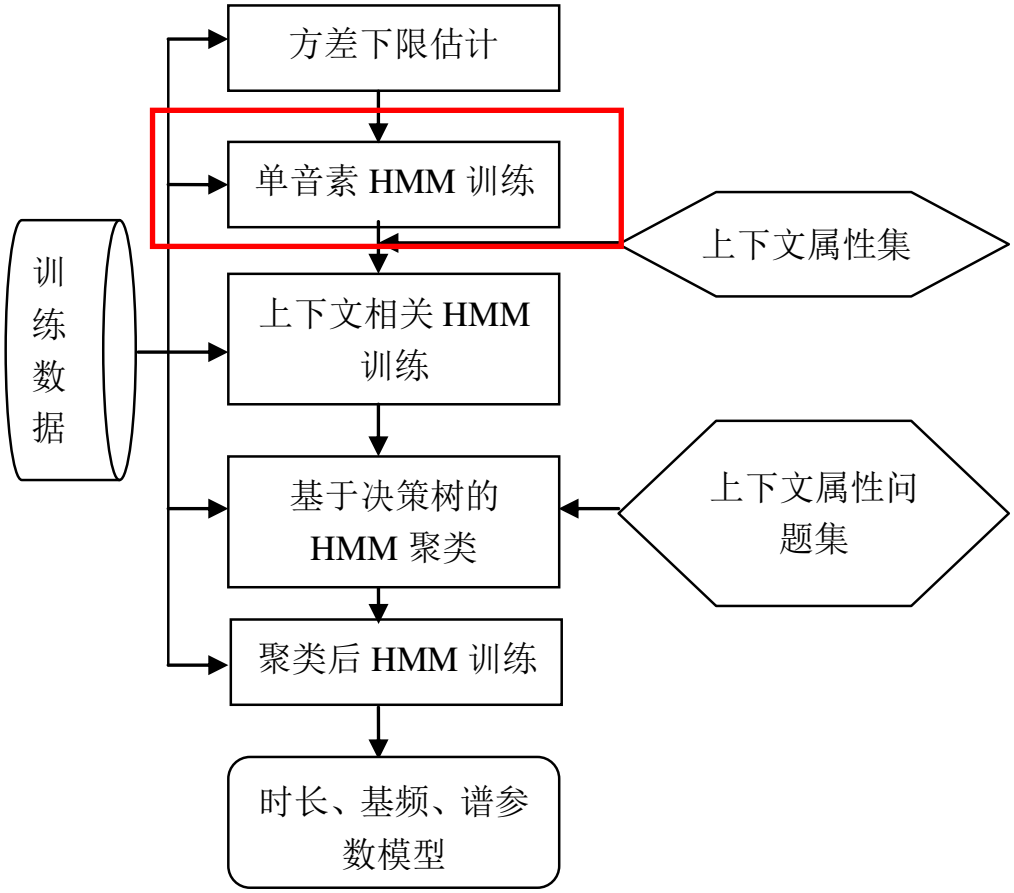
- 对所有的单音素HMM进行初始化和训练。
- 得到的模型用于进行上下文相关模型的扩展和初始化。





单音素模型训练（续）

- 模型训练方法：Baum-Welch算法。
- Baum-Welch算法的理论基础是EM算法。
- 与语音识别相同。

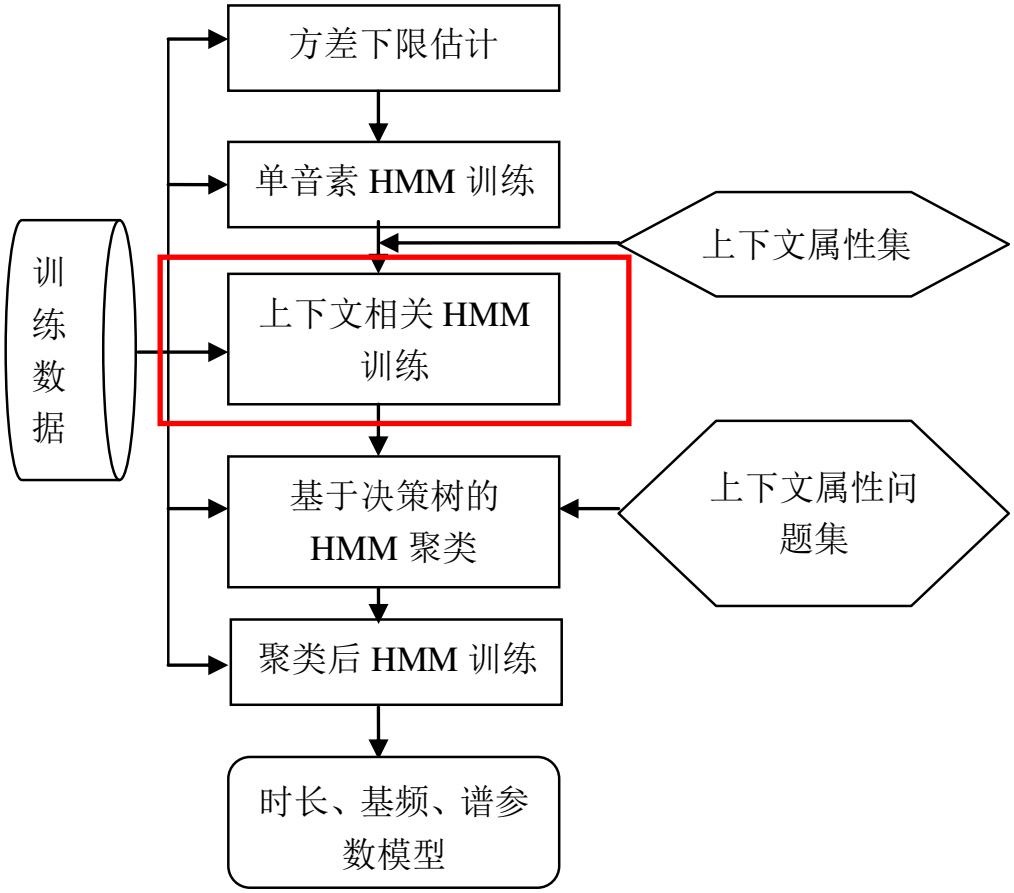


定义辅助函数

$$Q(\bar{\lambda},\lambda)=\sum_{Q}P(Q,O|\lambda)\log P(Q,O|\bar{\lambda}).$$

上下文相关HMM训练

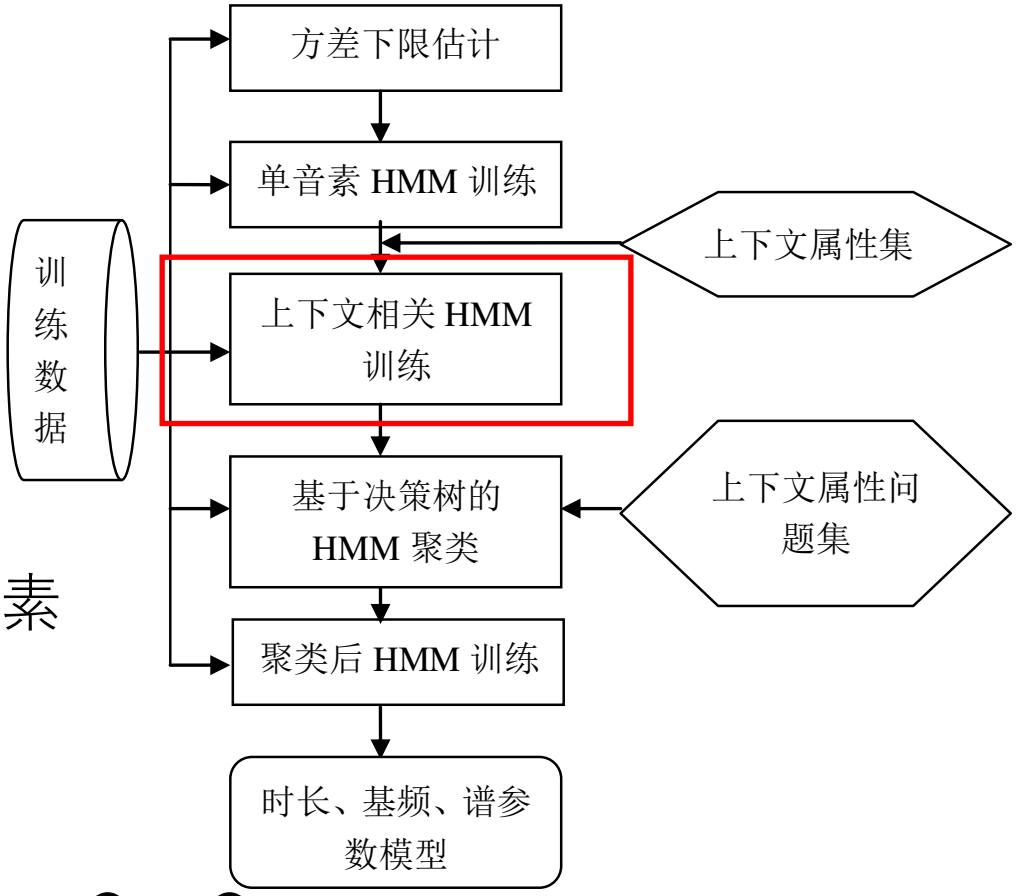
- 考虑不同的上下文对语音合成的影响。
- 上下文环境：
  - 前后音素
  - 韵律边界（词、短语、句子）

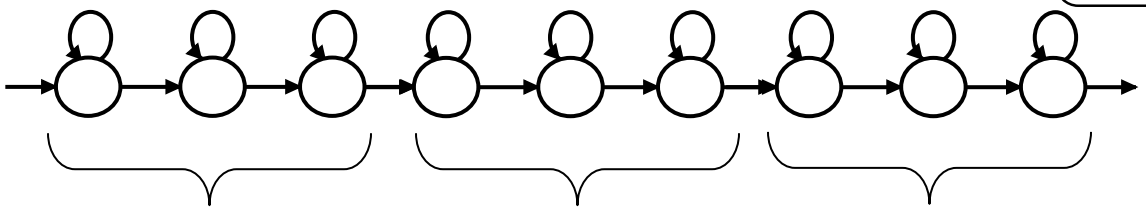


上下文相关HMM训练（续）

- 考虑前后音素的上下文

/l-c+r/表示：
左边音素-中间音素+右边音素

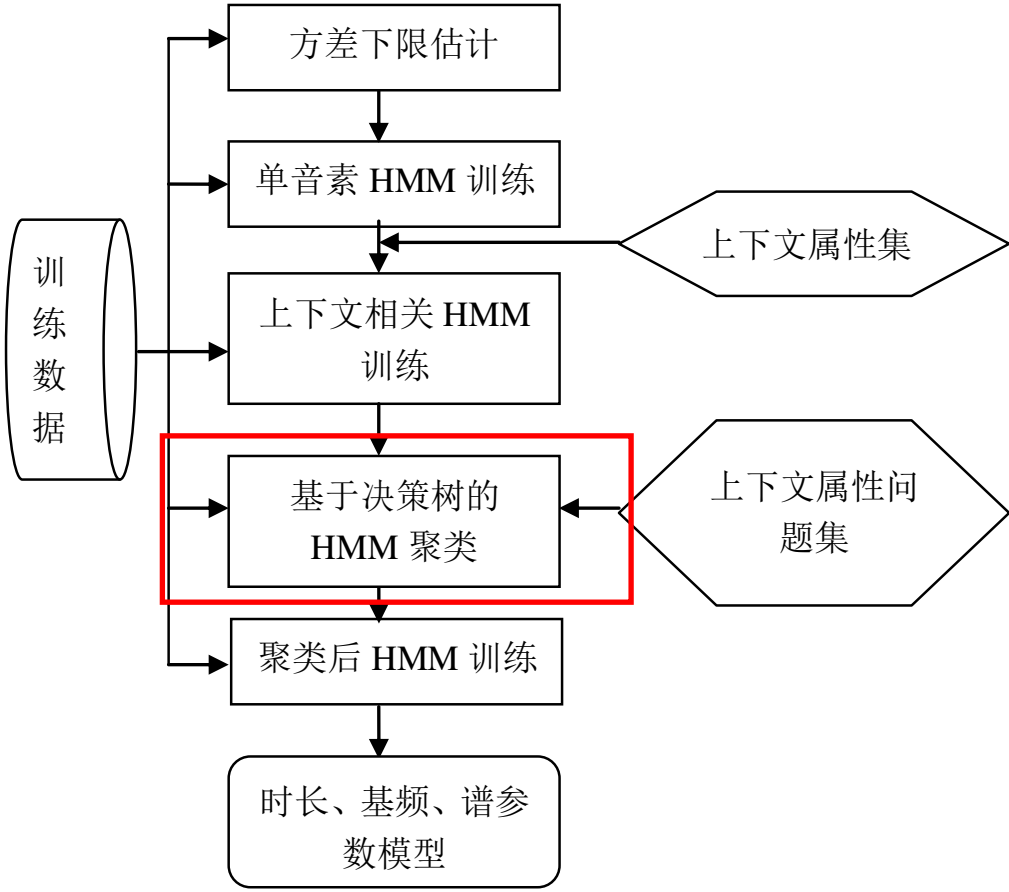




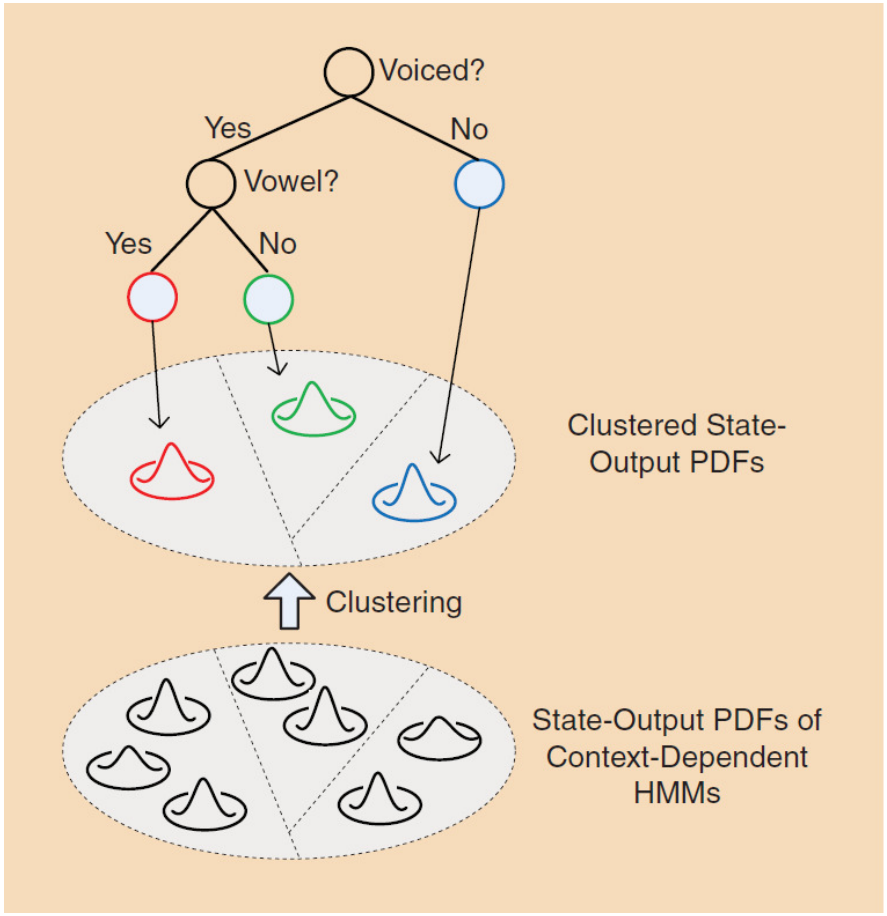
/#-c+a/ /c-a+t/ /a-t+#/

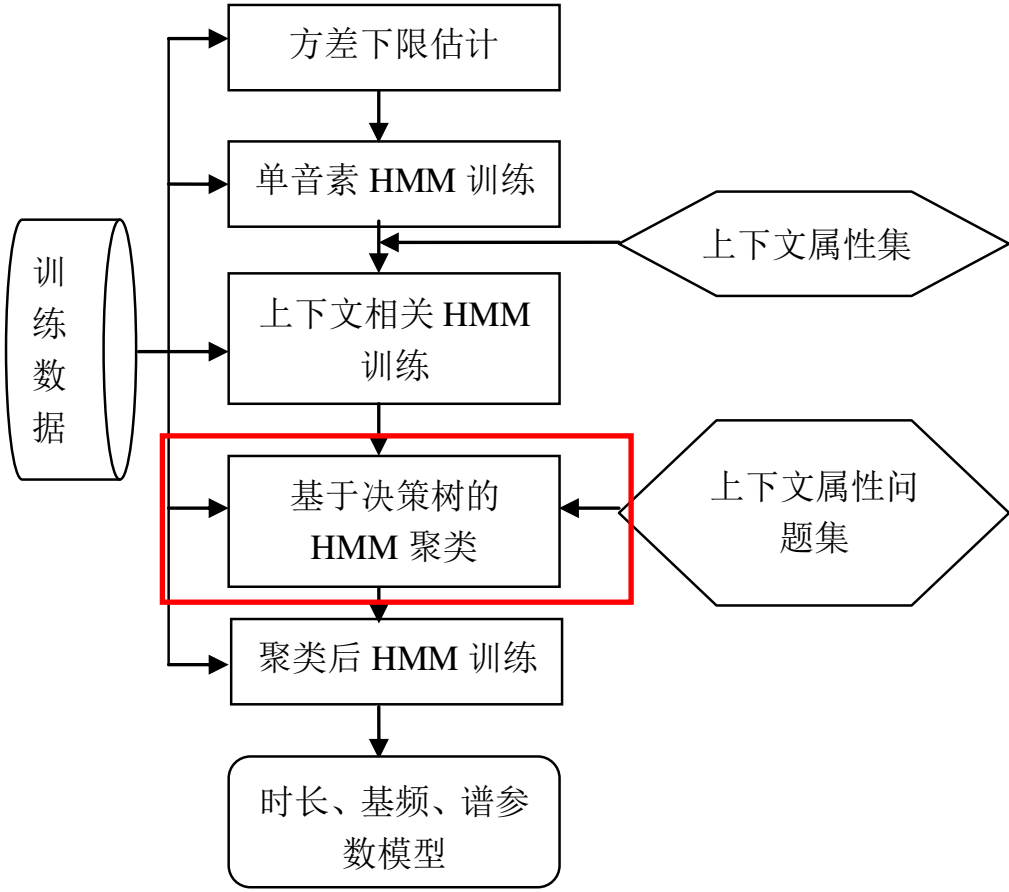
基于决策树的HMM聚类

- 模型的参数在训练后产生过拟合现象。
- 为了消除样本过少的问题，使得HMM的鲁棒性与数据量达到一个均衡状态。



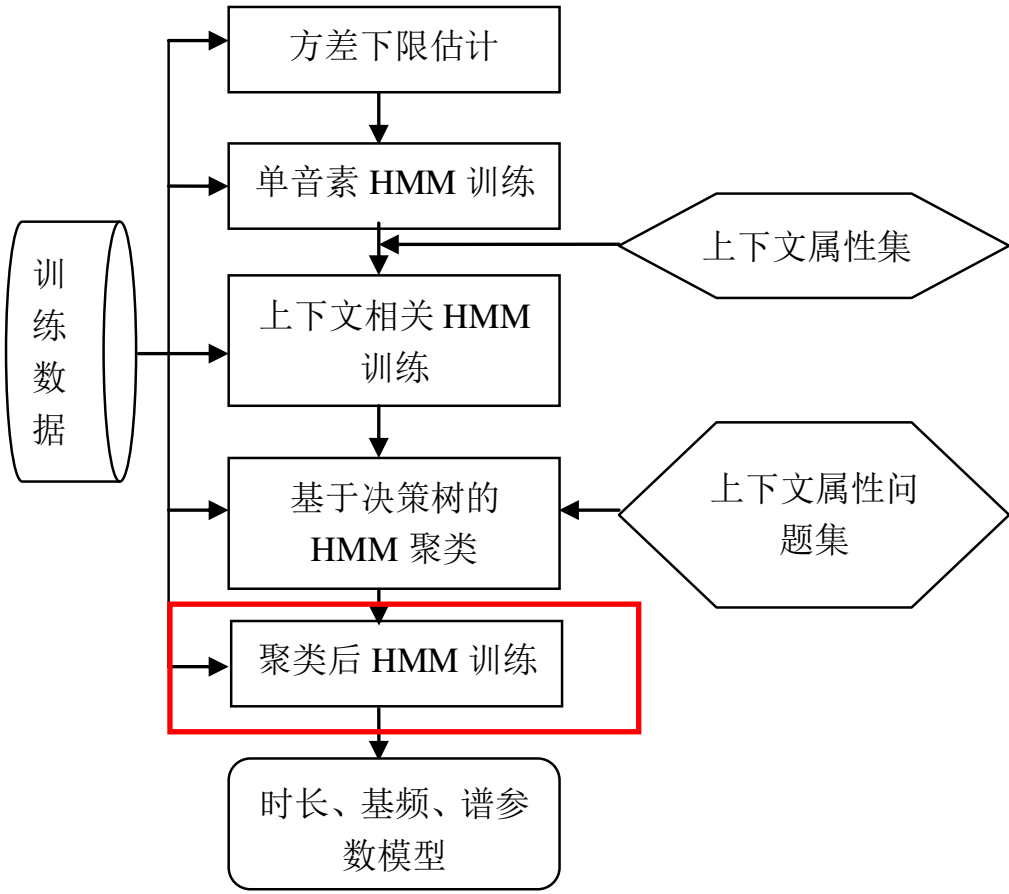
基于决策树的HMM聚类





聚类后HMM训练

- 与单音素HMM、上下文相关HMM训练相同。
- 基于Baum-Welch算法。



HMM的缺陷

- HMM合成的过平滑问题导致合成效果平淡，音质不好
  - HMM基于建模，假设各状态之间独立，状态参数分布是统计平均的结果；
  - 决策树作为浅层线性模型无法建模复杂的映射关系，对输入特征和数据空间的线性分割会降低模型泛化能力。

第四章　语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
  - 4.3.1 基于HMM的语音合成
  - **4.3.2 基于神经网络的语音合成**
  - 4.3.3 声码器
- 4.4 语音合成的技术展望

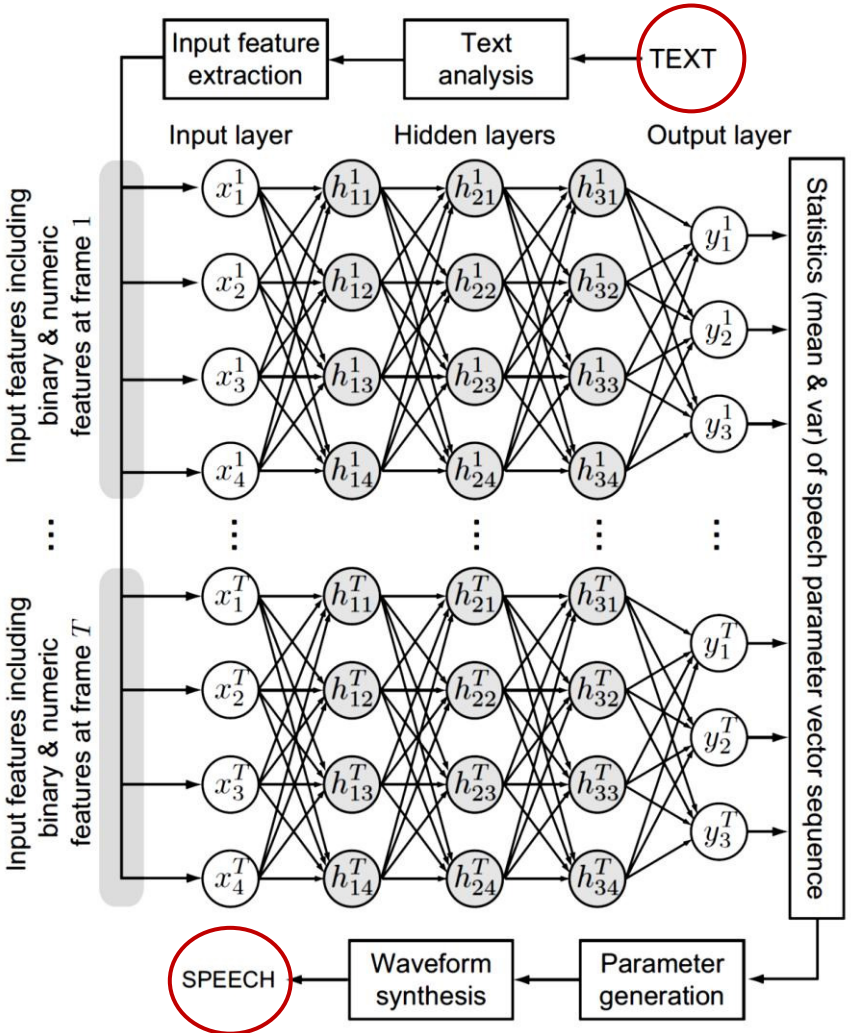
基于DNN的语音合成（基本概念）

右图显示了基于DNN的语音合成的基本框架和过程。

文本被转换为输入特征序列$\{x_n^t\}$，x_n^t 代表对应语音第t帧的第n个输入特征。输入特征包括上下文特征和音节持续时间等参数。它们与传统统计参数相同。

经由DNN前向传播，输入特征被映射到输出特征$\{y_m^t\}$，y_m^t 是语音第t帧的第m维特征。这些输出特征包括语谱参数和激励参数。

DNN的训练使用训练数据中抽取的上下文特征和语音特征的数据对，随后模型的参数可以被连续地更新。



(Zen et al, 2013)

第四章　语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
  - 4.3.1 基于HMM的语音合成
  - 4.3.2 基于神经网络的语音合成
  - 4.3.3 声码器
- 4.4 语音合成的技术展望

第四章　语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- **4.4 语音合成的技术展望**

第四章　语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望
  - 4.4.1 **端到端的语音合成**（了解）
  - 4.4.2 语音合成前沿任务（了解）

端到端语音合成（基本概念）

- 端到端(E2E)的TTS拥有直接读取文本作为输入并且不使用任何中间表示，直接输出语音波形。他的优化目标是整个系统而不是一个个子系统，从而减少了由人工假设和多阶段建模导致的性能损失。
- 端到端语音合成模型有两种类型：前端和后端的端到端模型。
- 前端的端到端模型：将韵律预测模型，持续时长模型和语音特征模型统合到一个模型里，从而直接读取上下文无关的符号预测语音特征(因此得名端到端语音模型)。
- 后端的端到端模型：读取语音特征作为输入，直接产生声音波形。因此，也被称为神经声码器。
- Tacotron 2 (Shen, et al, 2018)是经典的端到端语音合成方法，其把前端的端到端模型(Tacotron)和后端的端到端模型(WaveNet)结合在一起。
- 这里，我们将以Tacotron2及其相关工作为例解释端到端语音模型部分和声码器部分，并解释目前研究的难点和热点。

第四章　语音合成

- 4.1 语音合成概述
- 4.2 语音合成的原理
- 4.3 语音合成的主流技术
- 4.4 语音合成的技术展望
  - 4.4.1　端到端的语音合成
  - 4.4.2　语音合成前沿任务

基于预训练模型的语音生成方法-(VALL-E)（基本概念）

同样得益于预训练模型的**离散编码表示**，微软提出了VALL-E（ Wang , et al, 2023），将语音合成看作为**条件语言模型建模**任务，而不是连续信号的回归预测任务，利用60k小时的数据进行训练，VALL-E具有了一定的上下文学习能力，对于训练集中未见过的说话人，只需**3秒的音频的提示**就可以合成出具有高相似度和高音质的音频。

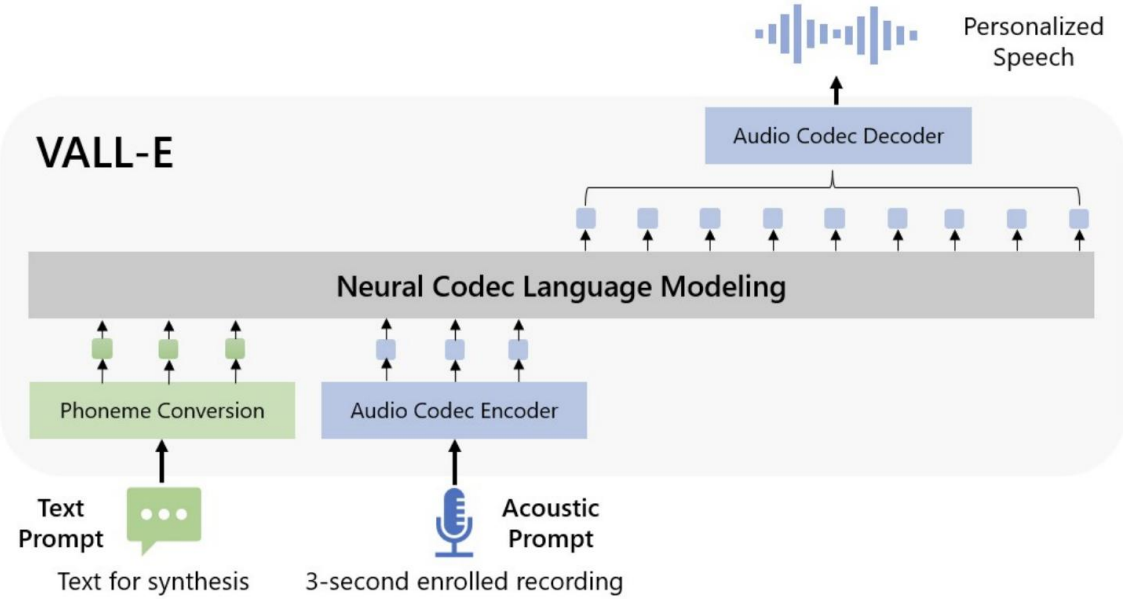
- **条件语言模型**

给定文本序列X和语音提示序列$\tilde{C}_{:,1}$，最终离散编码c的预测可以用以下语言模型表示 $p(c|X,\tilde{c};\theta) = p\left(c_{:,1}\middle|\tilde{C}_{:,1},X;\theta_{AR}\right)\prod_{j=2}^{8}p(c_{:,j}|c_{:,<j},X,\tilde{C};\theta_{NAR})$

- **自回归和非自回归**

1）预训练模型EnCodec的语音编码的码本是**层次化**的，因此预测每一个码本都用自回归（AR）会比较慢。

2）第一个码本的离散编码采用AR预测，剩余的码本采用非自回归(NAR)预测。



VALL-E模型框架图

10月31日理论课

内容：声纹识别
时间：10月31日（周六）10：25-12：00
教室：45-B207

期末考试

时间：11月11日（周三） 15:25-17:25
考场：3022244110-3024244236（46-A110）
3024244238之后及其他 （46-A120）
方式：闭卷