第五章 语音增强

第五章　语音增强

- 5.1 语音增强的概述
  - 5.1.1 语音增强的基本概念（基本概念）
  - 5.1.2 语音增强方法的回顾（了解）
- 5.2 单通道语音增强
- 5.3 多通道语音增强
- 5.4 语音增强技术的展望

多说话人的现实复杂场景（鸡尾酒会问题）

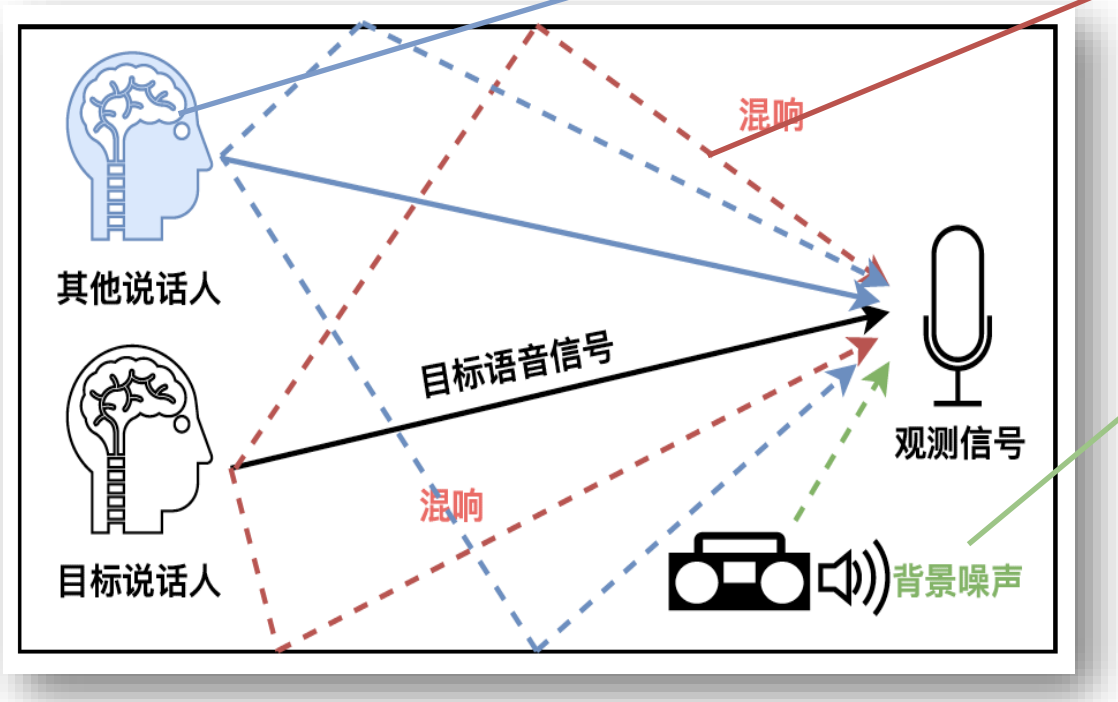
干扰说话人

由干扰说话人引起

混响

障碍物反射引起的声音持续传播

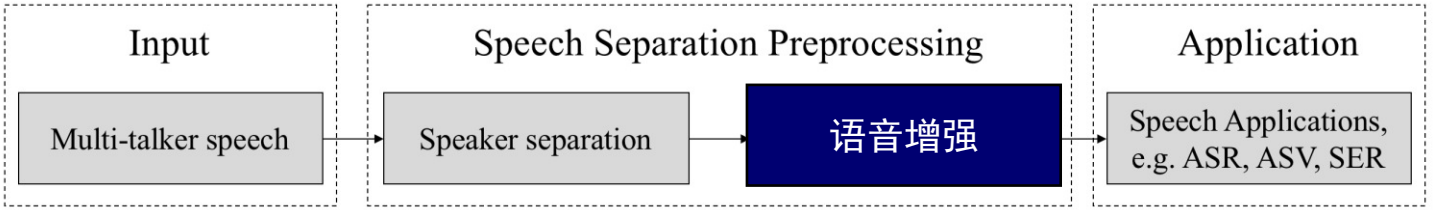
背景噪声



语音分离与语音增强

为什么需要语音分离？

- 定义：
  - 语音分离（Speech separation）：语音分离是将目标语音从背景干扰中分离出来的任务。
  - 语音信息处理的核心算法之一。



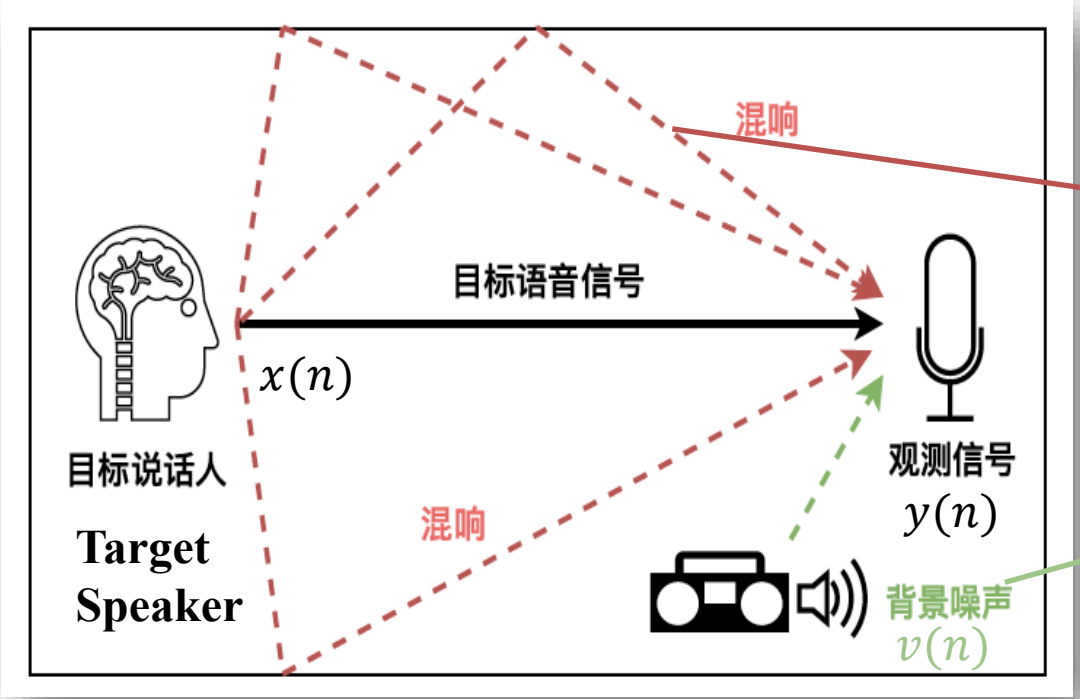
语音应用中多说话人语音分离/增强的流程图

- 根据背景干扰的类型，语音分离通常分为三类：
  - 语音去噪（Noise reduction）：语音 & 非语音分离（狭义的语音增强）
  - 语音去混响（Dereverberation）：语音混响分离
  - 说话人分离（Speaker separation）：多说话人分离（狭义的语音分离）

广义的语音增强 (Speech enhancement) 本章的重点

单说话人的现实复杂场景

- 本章主要聚焦单说话人场景下的语音增强



混响

障碍物反射引起的声音持续传播

$v(n)$

背景噪声

受损语音(Distorted speech)： $y(n) = x(n) * h(n) + v(n)$

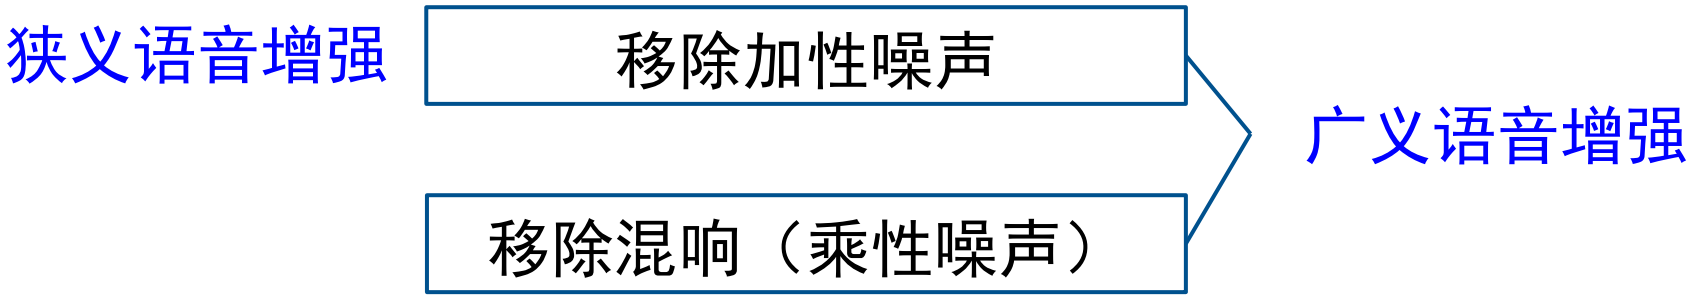
$h(n)$: 物体反射所形成的房间脉冲响应 (Room Impulse Response：RIR)

什么是语音增强?

- 定义：
  - 语音增强（Speech enhancement）：语音增强是将受损语音中的背景噪声和混响去除得到目标干净语音的任务。
  - 主要目标：提升受损语音的质量以及可懂度。可懂度也称为语言清晰度（speech intelligibility），听者能听懂通过一定传声系统传递的语音信号的百分率。不少语音增强技术在减少环境噪声的同时，也会引入语音的失真，进而损伤了语音的可懂度。

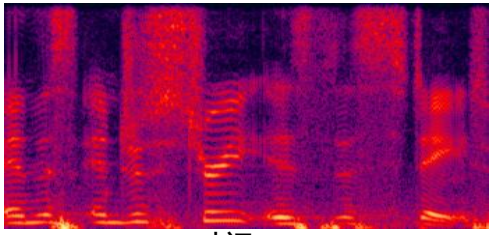
$$y(n) = x(n) * h(n) + v(n)$$

从被观测的受损语音$y(n)$中恢复干净语音 $x(n)$



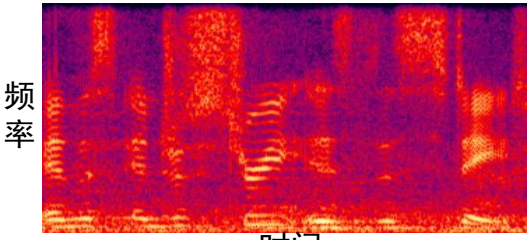
背景噪声和混响

背景噪声



干净语音

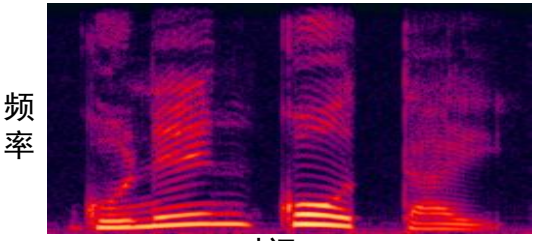




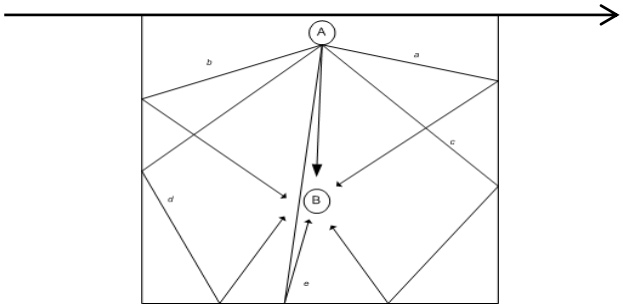
含噪语音

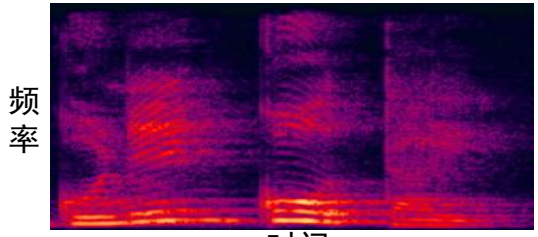
背景噪声与干净语音有相关性更低

混响



干净语音



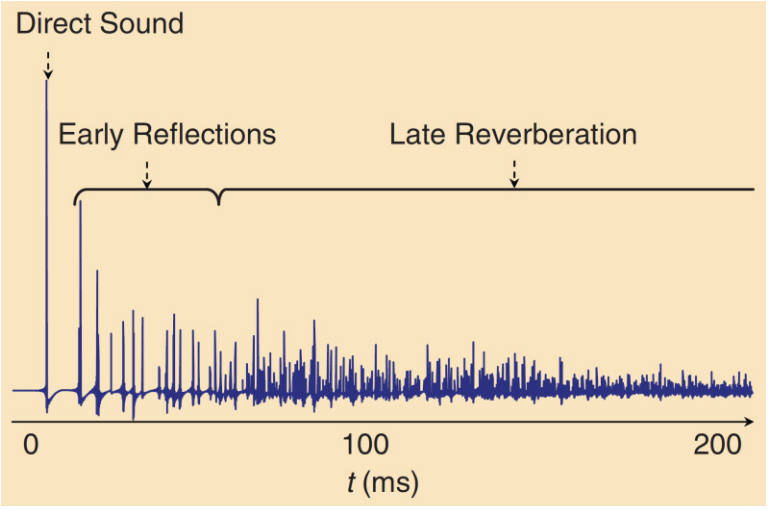


混响语音

混响语音与干净语音的相关性更高

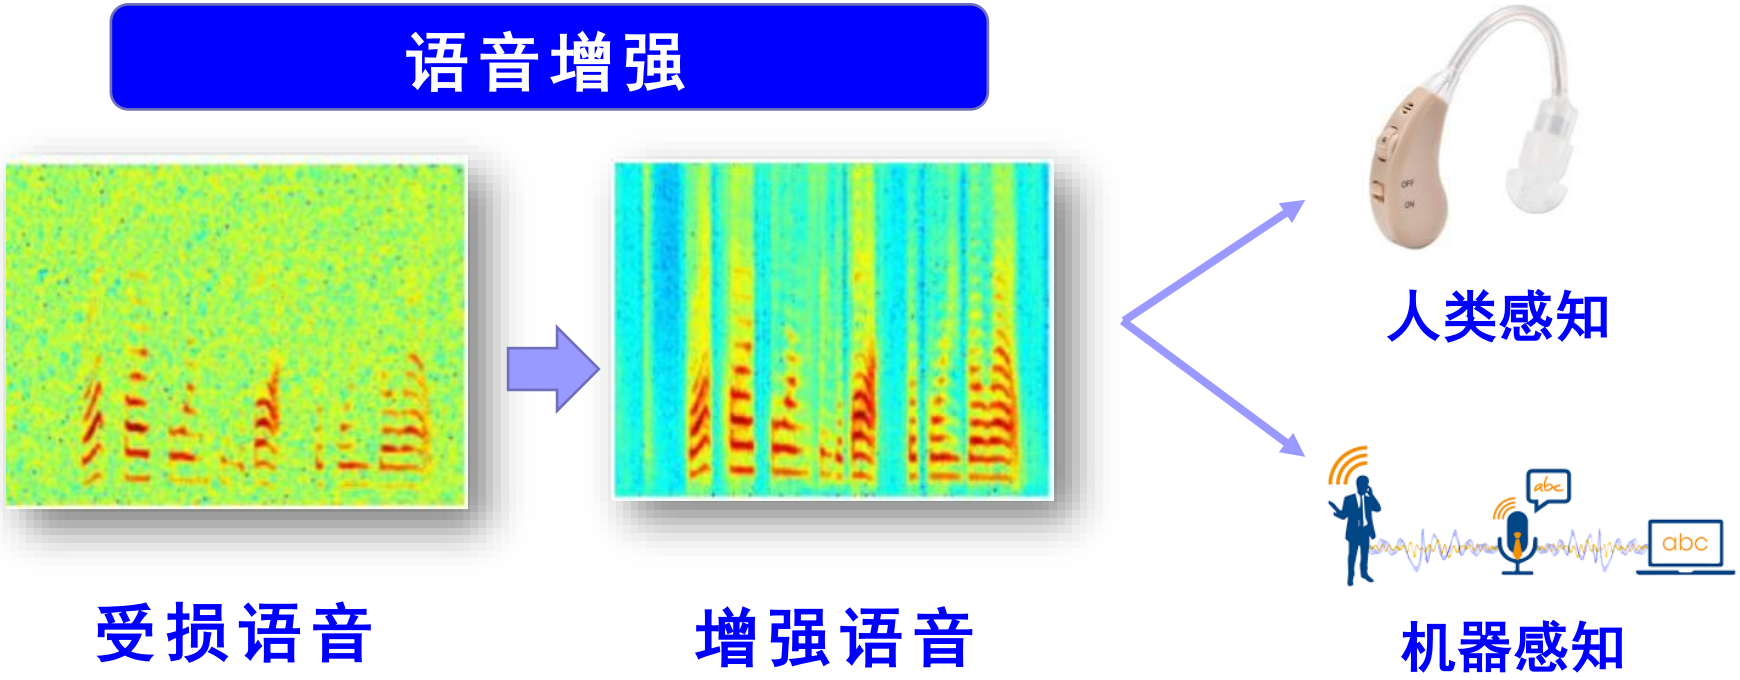
混响

- 定义：
  - 混响（Reverberation）：混响是一种室内声学现象，声音从声源发出后，在空气中传播，在传播过程中，在房间界面上产生反射、吸收、扩散、透射、干涉、衍射等波动效应，形成复杂的室内声场，使人产生混响感。当室内声场稳定时，声源停止发声，声音由于多次反射或散射而继续发出，这称为混响。



语音增强的目的

能否同时做好人类感知与机器感知？



- 目的
  - 提高语音可懂度，使人听起来更清晰
  - 提高语音识别（包括自动语音识别、说话人识别等）的性能

语音增强的类型

- 通道数
  - 单通道语音增强
  - 多通道语音增强
- 方法类型
  - 基于信号处理的语音增强
  - 基于神经网络的语音增强
- 处理域
  - 时域语音增强
  - 频域语音增强

语音增强的类型（续）

- 噪声类型
  - 语音去噪（加性噪声）
  - 语音去混响（乘性噪声）
  - 语音去噪 & 语音去混响

- 目的
  - 用于机器感知
    - 语音识别（ASR）、说话人识别（Speaker recognition）等
  - 用于人类感知
    - 助听器、会议系统等

语音增强度量指标（续）

- 信噪比 （SNR）:
  - 含噪语音中语音和噪声的比值取对数

$$SNR = 10\log_{10}(\frac{P_S}{P_N})$$

P_S: 信号功率，P_N: 噪声功率

- 分段信噪比 （Segmental SNR）:
  - 由于语音信号是一个缓慢变化的短期稳定信号，不同时间段的信噪比应该不同。为了改善上述问题，可以使用分段信噪比。

语音增强度量指标（续）

- 倒谱距离
  - 计算倒谱之间的距离并取对数

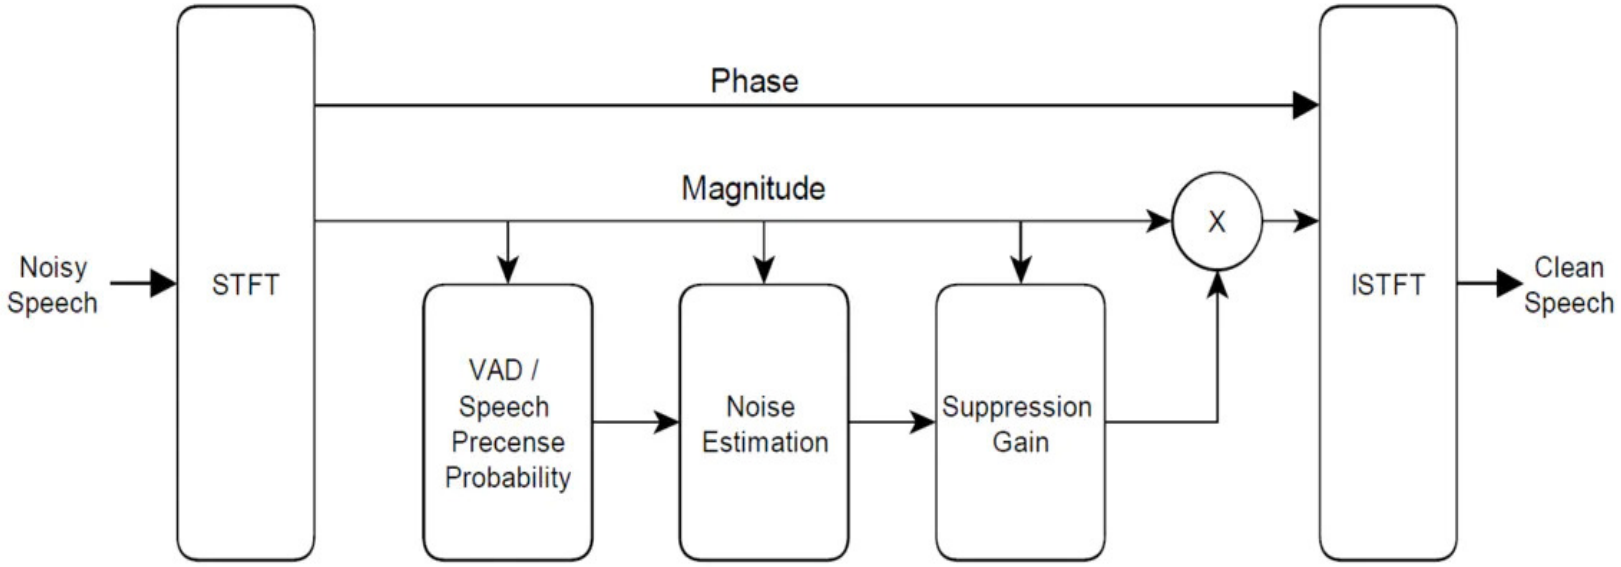
$$CD = 10/\log_{10}\sqrt{2\sum_{i=1}^{p}\{C_x(i) - C_y(i)\}^2}$$

其中，$C_x(i)$ 和 $C_y(i)$ 是干净语音和失真语音的倒谱系数（LPCC或MFCC），p是系数的维数。

第五章　语音增强

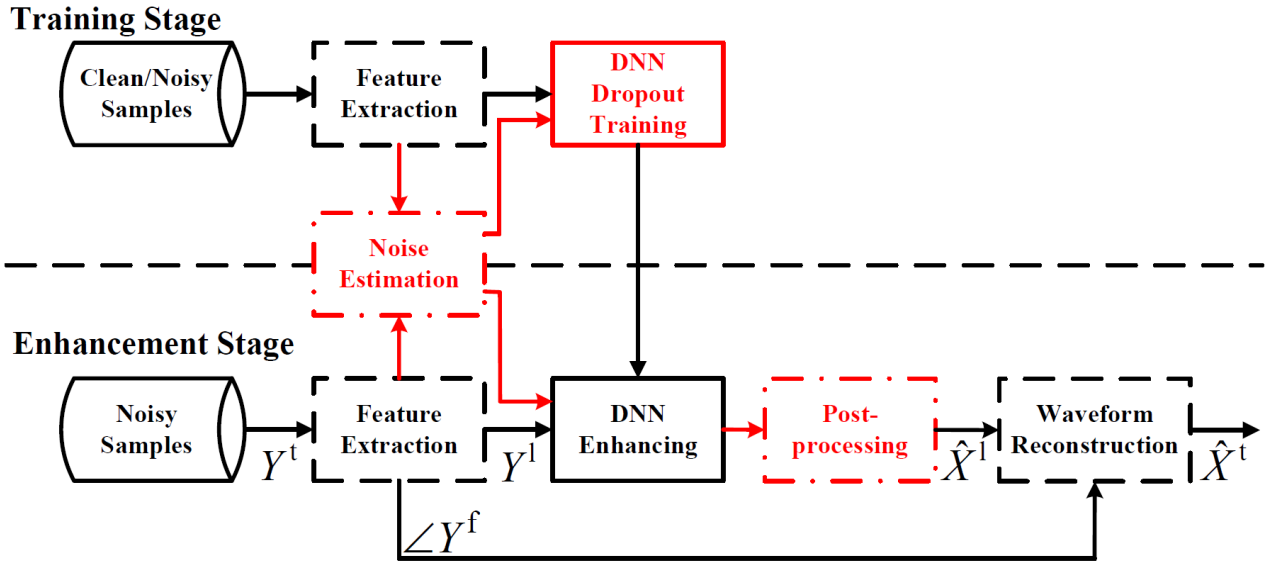
- 5.1 语音增强的概述
  - 5.1.1 语音增强的基本概念
  - 5.1.2 语音增强方法的回顾
- 5.2 单通道语音增强
- 5.3 多通道语音增强
- 5.4 语音增强技术的展望

基于传统信号处理的语音增强算法流程（掌握）



- 基于传统信号处理的语音增强系统的目标就是抑制增益，而抑制增益依赖于两个核心步骤：静音检测（VAD）和噪声估计模块。只有准确估计噪声谱才有可能准确估计抑制增益，通常会利用VAD来进行噪声估计。

基于深度学习的语音增强算法流程（基本概念）



- 需要分为训练阶段和增强阶段。
- 训练：利用大规模数据训练深度学习模型的参数。
- 增强：利用深度学习模型进行语音增强。
- 性能佳，但是计算量大，容易过拟合。

第五章　语音增强

- 5.1 语音增强的概述
- 5.2 单通道语音增强
  - 5.2.1 基于传统信号处理的语音增强（基本概念）
  - 5.2.2 基于深度学习的语音增强
    （掌握、基本概念、了解）
- 5.3 多通道语音增强
- 5.4 语音增强技术的展望

单通道语音增强的主要方法

- 基于传统信号处理的语音增强
  - 基于信号处理的方法（最重要的是噪声估计）。
  - 该方法计算量小，通用性强。
  - 典型算法：谱减法、维纳滤波器等。
- 基于神经网络的语音增强
  - 深度神经网络具有很强的回归能力。
  - 该方法具有较高的性能，但计算量大，泛化能力差。
  - 典型方法：DNN、LSTM等

谱减法的定义

- 定义：
  - 谱减法：用带噪信号的频谱减去噪声信号的频谱得到干净信号频谱的估计。
  - 噪声估计
    - 当语音信号不存在时，可以估计和更新噪声谱。一般都假设输入的一段语音中前n帧作为静音时间。
    - 假设噪声是平稳的或缓慢变化的过程，并且噪声谱在更新周期之间没有显著变化。
  - 增强信号是通过计算估计信号频谱的离散傅里叶逆变换得到的。

受损语音信号的时频表示

- **受损语音$y(n)$的时域表示：**

$$y(n) = x(n) * h(n) + v(n)$$

$x(n)$ 是干净语音信号，$h(n)$与$v(n)$分别为房间脉冲响应与加性噪声。本章节只考虑加性噪声，因此将语音信号用以下数学模型表示：

$$\mathrm{y}(n) = x(n) + v(n)$$

- **受损语音的频域表示：**

$$Y(\omega) = X(\omega) + V(\omega) = |Y(\omega)|e^{j\theta_y(\omega)}$$

$Y(\omega)$：受损（带噪）语音的频谱；$X(\omega)$：干净语音的频谱；

$V(\omega)$：噪声的频谱；$\theta_y(\omega)$：含噪语音的相位。

谱减法的思路

- 假设干净语音$x(n)$和噪声$v(n)$ 是不相关的，

$$|Y(\omega)|^2 = |X(\omega)|^2 + |V(\omega)|^2$$

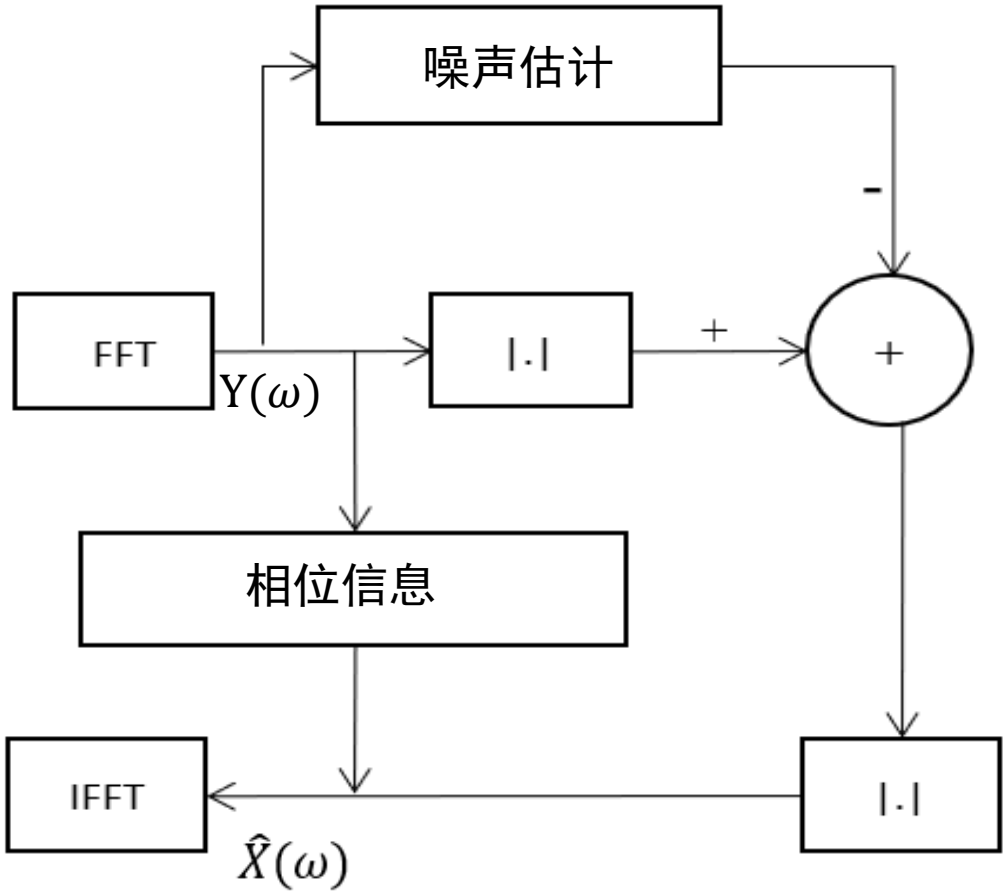
- 带噪语音的功率谱减去噪声的功率谱得到干净语音功率谱的估计值，从而得到语音振幅谱的估计$\left|\hat{X}(\omega)\right|$以及干净语谱的估计值$\hat{X}(\omega)$，

$$\left|\hat{X}(\omega)\right| = (|Y(\omega)|^2 - \left|\hat{V}(\omega)\right|^2)^{1/2}$$

$$\hat{X}(\omega) = \left|\hat{X}(\omega)\right| \; e^{j\theta_y(\omega)}$$

干净语音估计值的相位谱可以用带噪语音的相位谱$\theta_y(\omega)$来进行粗略表示，这是由于在一定程度上，相位不会严重影响语音质量。

谱减法流程图



广义谱减法

- 从含噪语音的功率谱减去噪声语音的功率谱估计值可能产生负的功率谱值。为了避免这一现象，以及对功率谱或者振幅谱进行一般化操作，广义谱减法的公式如下所示：

$$\left|\hat{X}(\omega)\right|^{2n} = \max(|Y(\omega)|^{2n} - \alpha \cdot \left|\hat{V}(\omega)\right|^{2n}, \beta \cdot |Y(\omega)|^{2n})$$

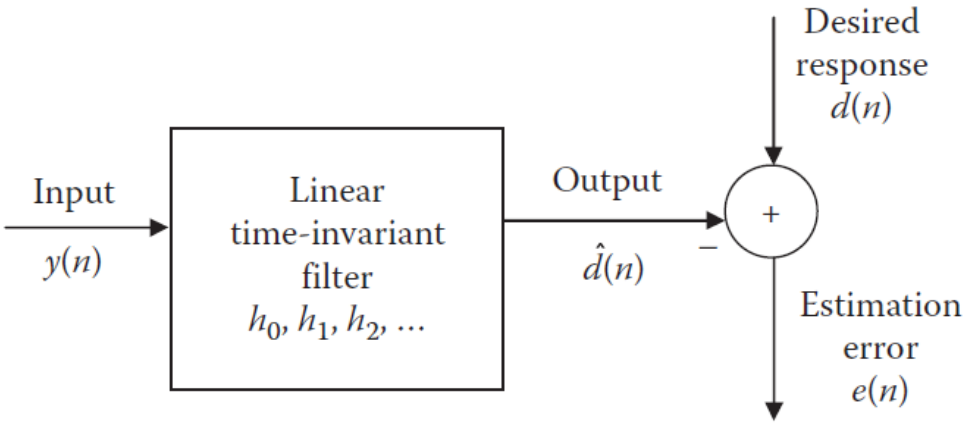
- α：噪声超估计因子
- β：频谱下限系数，用于防止产生负的频谱结果
- n：任意指数参数
  （n=1：power SS；n=0.5：magnitude SS）

谱减法的优缺点

- 优点：
  - 简单，只需要正反傅立叶变换，且实时实现较容易。
- 缺点：
  - 适用的信噪比范围较窄，在信噪比较低时对语音的可懂度损伤较大。所以实际应用时除了要降低噪声外，还要兼顾语音的可懂度和自然度。
  - 由于频谱直接相减会使增强后的语音产生“音乐噪声”，它具有一定的节奏性，听上去类似音乐声。

维纳滤波器的基本原理

- 滤波器的定义：
  - 从连续的(或离散的)输入数据中滤除噪声和干扰以提取有用信息的过程称为滤波，而相应的装置称为滤波器。
- 基本原理：
  - 维纳滤波语音增强的目标就是寻找系数为实数的线性滤波器，使得滤波偶信号与原干净语音信号之间的均方误差最小（直接估计干净语音信号），也称最小二乘滤波器或最小平方滤波器。



传统的维纳滤波器是基于VAD（静音检测）等算法进行噪声估计进而对滤波器进行设计

维纳滤波的简单实现

- 含噪语音信号经线性滤波后提高其信噪比，以得到降噪信号的方法。主要依据维纳滤波器来降噪，维纳滤波器的传输函数为，

$$H(\omega)=\frac{\hat{X}(\omega)}{Y(\omega)}=\frac{P_x(\omega)}{P_x(\omega)+P_v(\omega)}$$

- 在短时平稳的假设下，$X(\omega)$与$V(\omega)$的功率谱密度分别为：

$$P_x(\omega)=E[|X(\omega)|^2] \qquad P_v(\omega)=E[|V(\omega)|^2]$$

$X(\omega)$、$Y(\omega)$与$V(\omega)$ 分别为干净语音、噪声及带噪语音的频谱；

$\hat{X}(\omega)$为干净语谱的估计值；

E[·]指对[·]内的频谱求统计平均。

- 对于平稳噪声而言，一般假设每帧信号的噪声功率已知，即由该帧前面的“静”时段可以估计出噪声功率谱。

传统的语音增强方法的总结

- 常见的传统语音增强算法有谱减法和维纳滤波等。
- 谱减法虽然实现简单，运算量小，但效果比较差，容易出现刺耳的“音乐噪声”。
- 维纳滤波虽然原理较复杂，运算量也相对较大，比谱减法有更好的性能，极大消减“音乐噪声”。
- 但是，基于传统信号处理的语音增强算法的效果与干净语音还有较大差距。

频谱减法和维纳滤波器的主要问题

- 不擅长处理非线性噪声（混响等乘性、卷积噪声）
- 不擅长处理非平稳噪声（时变噪声） 为什么？
- 引入“音乐噪音”
- 性能不佳，噪声消除不干净



如何进一步提升语音增强的性能？

第五章　语音增强

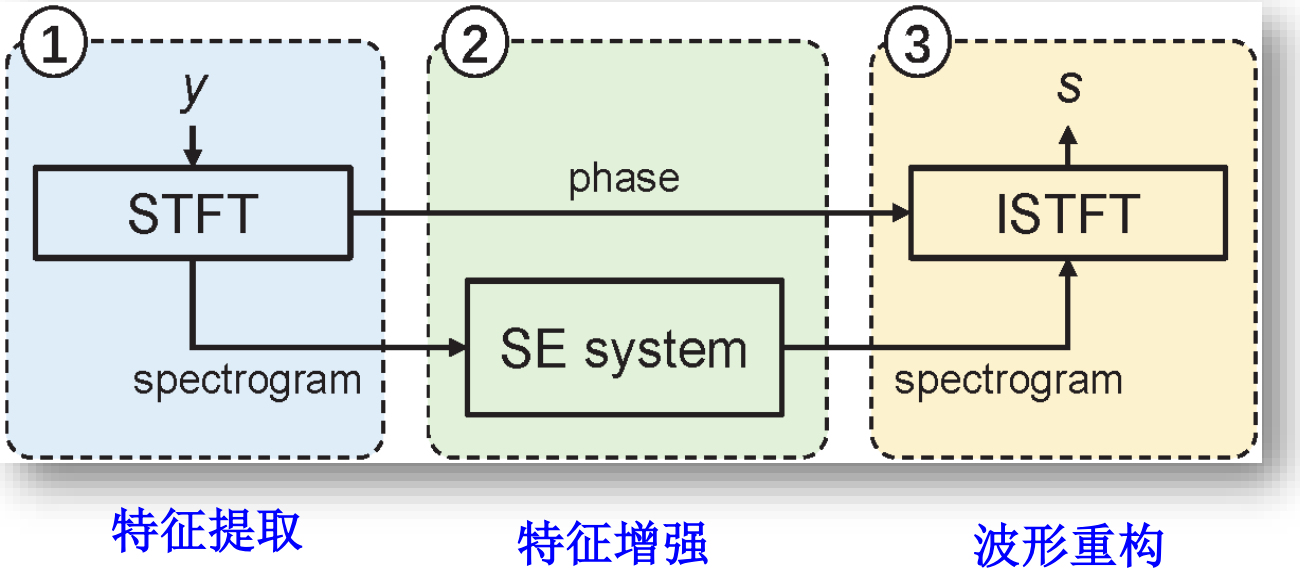
- 5.1 语音增强的概述
- 5.2 单通道语音增强
  - 5.2.1 基于传统信号处理的语音增强
  - 5.2.2 基于深度学习的语音增强
- 5.3 多通道语音增强
- 5.4 语音增强的前景与展望

为什么需要基于深度学习的语音增强？（基本概念）

- 深度学习的优势
  - 非线性变换能力
  - 强大的回归能力
  - 擅长处理非平稳噪声
  - 增强后的语音更自然，没有音乐噪声

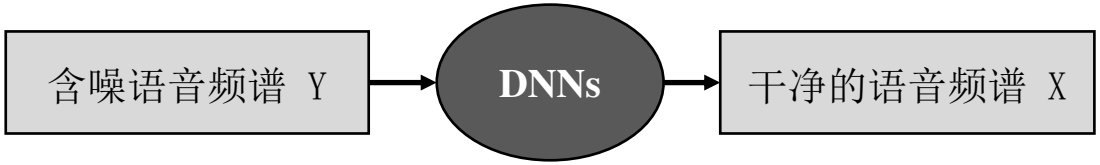
频域语音增强的流程（掌握）

- 频域语音增强常用的流程:
  - **特征提取：**将时域信号转换为频域特征
  - **特征增强：**利用神经网络增强频谱图的振幅
  - **波形重构：**将增强的频谱图振幅和噪声相位信息转换（重构）为时域波形信号



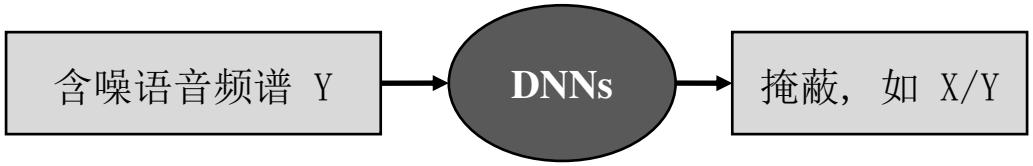
基于DNN的语音增强（掌握）

- 基于映射（mapping）的框架（Xu et al., 2015）
  - 将语音增强视为多变量回归问题，其中非线性回归函数由DNN参数化。



基于映射的框架

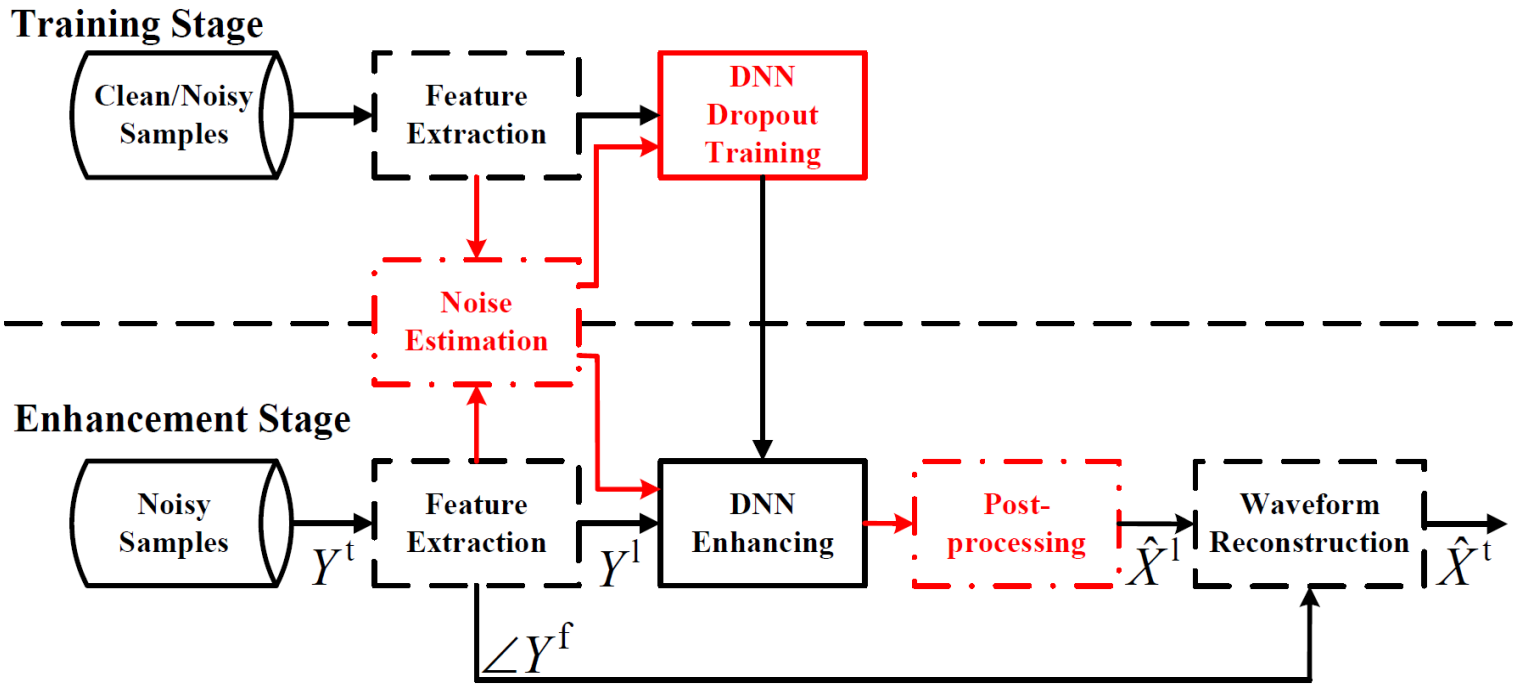
- 基于掩蔽（mask）的框架（Wang et al., 2017）
  - 受听觉掩蔽现象和听觉场景分析的启发，该框架以掩蔽为主要目标。



基于掩蔽的框架

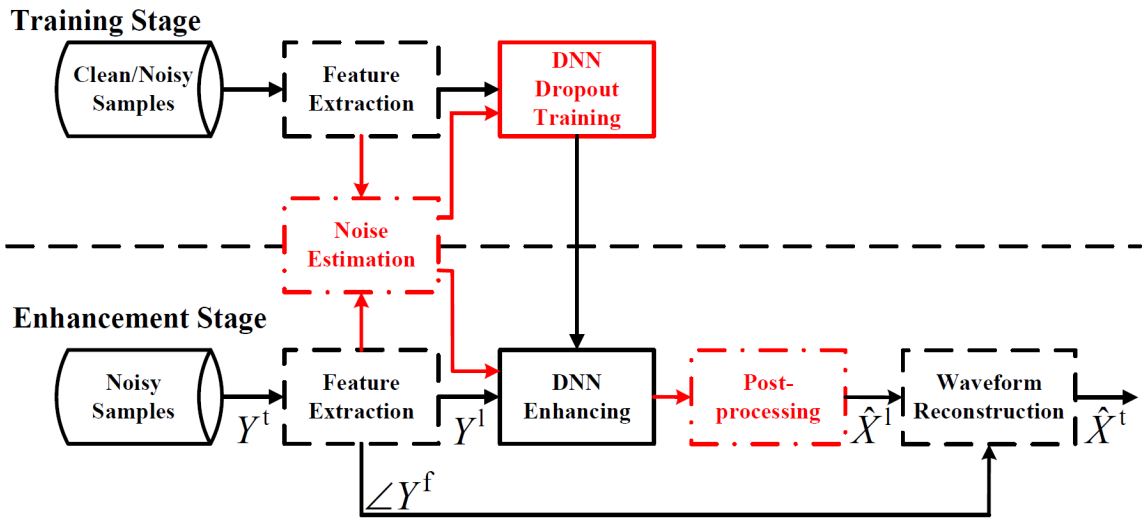
基于映射的语音增强的框架（掌握）

- 基于映射的语音增强
  - 相对传统的谱减法、维纳滤波器等方法效果有了极大的提升
  - 对非平稳噪声有很好的抑制作用



基于映射的语音增强系统示意图

基于映射的语音增强的主要步骤（掌握）



- 训练：利用STFT将含噪音频和干净音频提取语谱图特征，前者为训练的输入后者为训练的目标。利用深度学习进行含噪语谱图到干净语谱图的非线性映射，训练非线性函数并保存模型。

- 增强：将含噪音频的语谱图输入到训练好的模型，可以得到干净音频特征。将干净的语谱图和原始的相位进行ISTFT变换得到重建后的去噪后的音频。

基于映射的语音增强的主要步骤（掌握）

- 训练：
  - 特征提取：利用STFT将含噪音频和干净音频提取语谱图特征，前者为训练的输入后者为训练的目标。
  - 模型训练：利用深度学习进行含噪语谱图到干净语谱图的非线性映射，训练非线性函数并保存模型。

- 增强：
  - 特征提取：利用STFT提取含噪音频的语谱图特征。
  - 特征增强：将含噪音频的语谱图输入到训练好的语音增强模型，估计干净音频特征。
  - 信号重构：将干净语音语谱图的估计值和原始的相位进行ISTFT变换得到重建后的增强语音。

基于映射的语音增强的训练（续） （基本概念）

- 基于映射的语音增强的训练损失函数
  - 均方误差（MSE）准则：

语音识别的训练损失函数是什么？

$$J_{\mathrm{MSE}}(\mathbf{W},\mathbf{b};\mathbb{S})=\frac{1}{M}\sum_{m=1}^{M}J_{\mathrm{MSE}}(\mathbf{W},\mathbf{b};\mathbf{o}^m,\mathbf{y}^m)$$

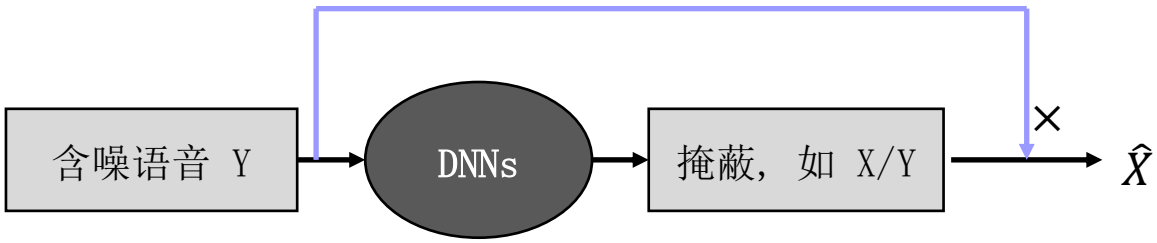
$$J_{\mathrm{MSE}}(\mathbf{W},\mathbf{b};\mathbf{o},\mathbf{y})=\frac{1}{2}\left\|\mathbf{v}^L-\mathbf{y}\right\|^2=\frac{1}{2}\left(\mathbf{v}^L-\mathbf{y}\right)^{\mathrm{T}}\left(\mathbf{v}^L-\mathbf{y}\right).$$

{W, b}是模型参数，o是观察向量，y是相应的输出向量。

- 通过最小化损失函数进行训练
  - 学习方法：误差反向传播（BP）算法

基于掩蔽的语音增强的框架（掌握）

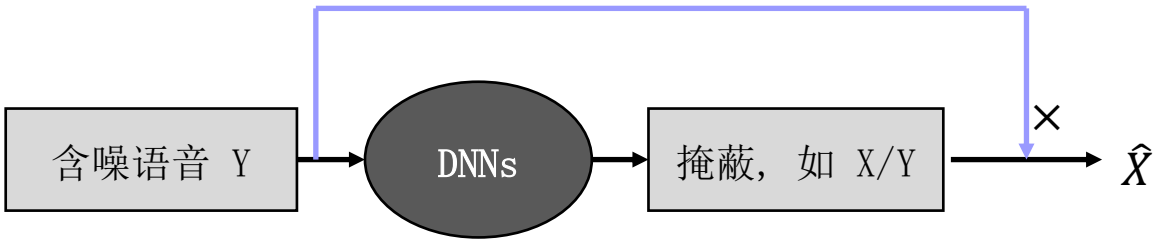
- 基于掩蔽的语音增强
  - 相对传统的维纳滤波器等方法效果有了极大的提升
  - 对非平稳噪声有很好的抑制作用
  - 广泛应用于语音降噪、多说话人分离等任务



基于掩蔽的语音增强系统示意图

基于掩蔽的语音增强的主要步骤（掌握）

- 训练：
  - 特征提取：利用STFT提取含噪音频和干净音频的语谱图特征。
  - 计算掩蔽值：计算从含噪音频到干净语音的掩蔽值（label）。
  - 模型参数更新：利用深度学习进行含噪语谱图到掩蔽值的非线性映射，训练非线性函数并保存模型。
- 增强：
  - 特征提取：利用STFT提取含噪音频和干净音频的语谱图特征。
  - 计算掩蔽值：将含噪音频的语谱图输入到模型，可以得到掩蔽值。
  - 将含噪语音的语谱图和掩蔽值相乘，得到干净语音的语谱图的估值值。
  - 信号重构：将干净语谱图的估计值和原始的带噪语音的相位进行ISTFT变换得到重建后的增强语音。



基于掩蔽的语音增强的训练损失函数（基本概念）

理想二进制掩码(IBM)

- 该定义基于噪声信号的二维时频表示：

$$IBM = \begin{cases} 1, & if\ SNR(t,f) > threshold \\ 0, & otherwise \end{cases}$$

- IBM将每个T-F bin标记为目标主导型或干扰主导型。
- IBM评估中常用的损失函数是**交叉熵（CE）**。

为什么用交叉熵损失函数？

基于掩蔽的语音增强的训练损失函数（续）
（基本概念）

理想比率掩码 (IRM)

- 理想的比率掩码可以看作是IBM的**软版本**：

$$IRM = \left(\frac{|X(t,f)|^2}{|X(t,f)|^2 + |V(t,f)|^2} \right)^{\beta}$$

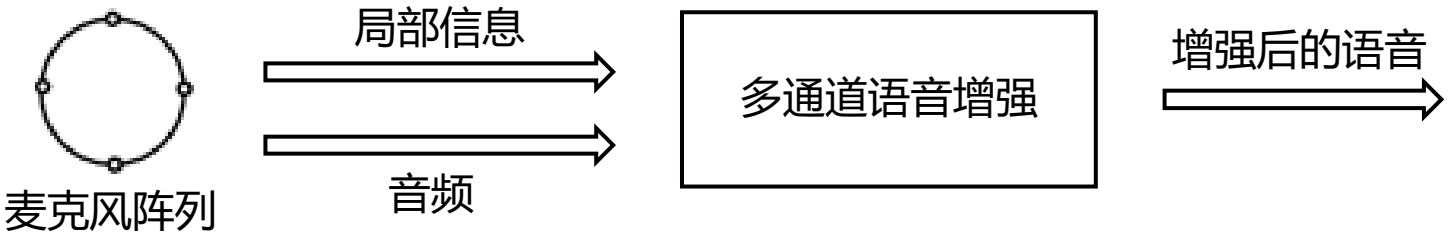
- $X(t,f)^2$和$V(t,f)^2$分别表示T-F bin的信号和噪声能量
- β是一个可调参数，一般选取0.5
- 适用于附加噪声，但不适用于混响　为什么？
- **MSE**通常用作IRM估计中的损失函数

第五章　语音增强

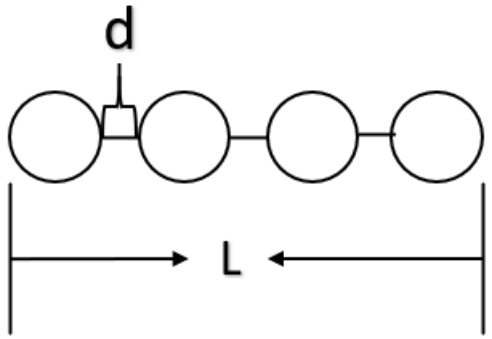
- 5.1 语音增强的概述
- 5.2 单通道语音增强
- 5.3 多通道语音增强
  - 5.3.1 固定波束形成（基本概念）
  - 5.3.2 自适应波束形成（了解）
- 5.4 语音增强技术的展望

多通道语音增强

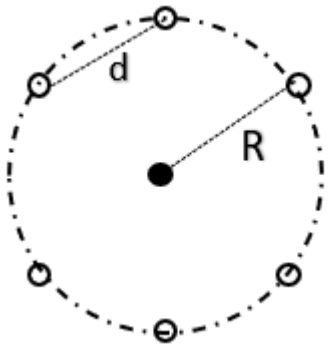
- 多通道语音增强是一种处理多通道语音（使用麦克风阵列录制的音频）的增强方法。
- 优点：多通道语音增强考虑了音频通道与声源位置信息之间的信息差，因此具有更好的抑制方向性噪声的能力。



线性阵列和圆形阵列



均匀线性阵列



均匀圆形阵列

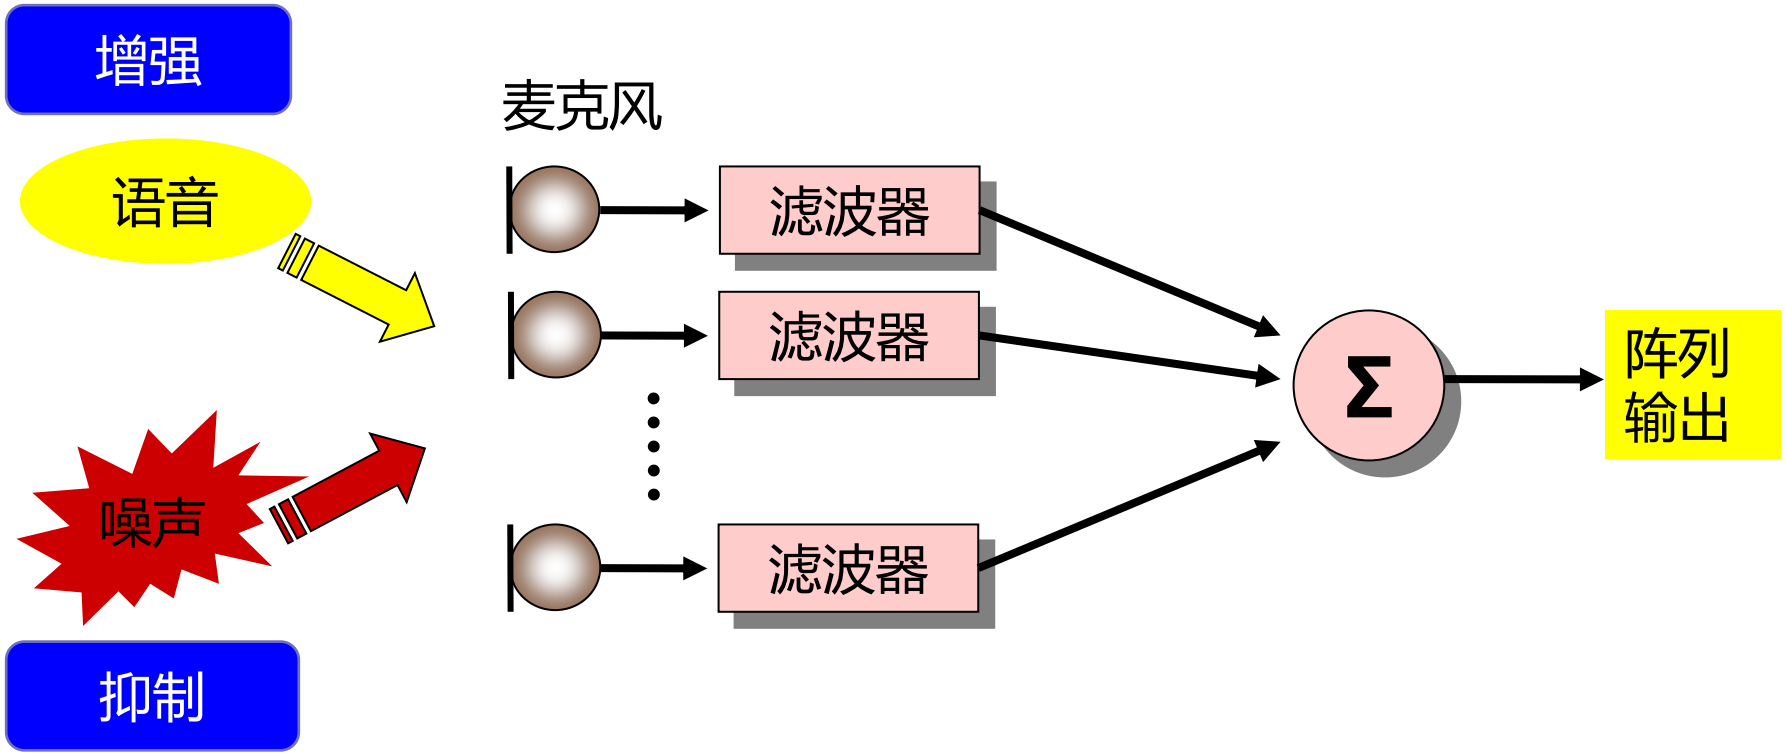
L：阵列长度
d：相邻麦克风间距

R：圆形麦克风阵列的半径
d：实际的相邻麦克风直线间距

- 波束形成(Beamforming)技术是主要的阵列处理技术之一。波束形成技术成熟较早，在早期该技术主要应用于雷达等定位系统。

波束形成的基本思路（掌握）

- 对各个麦克风单元接收到的语音信号进行加权求和，该加权系数决定了语音增强的效果。
- 通过调整加权系数，达到对目标声源方向的增强以及对其他干扰方向的抑制的效果，使得整个麦克风阵列对目标方向形成聚焦。

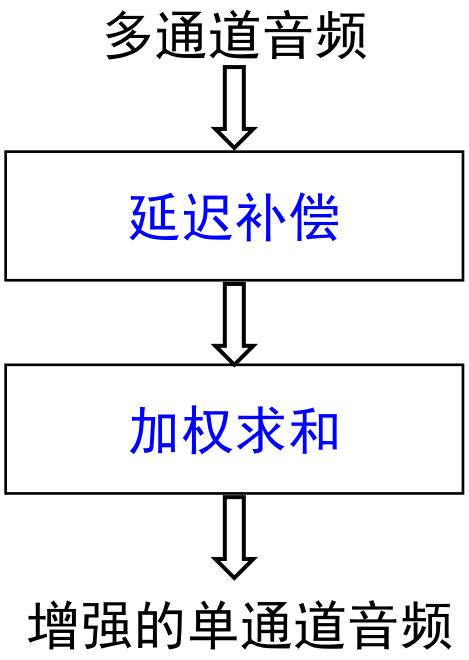


固定波束形成与自适应波束形成

- 根据加权系数是否能够随着接收信号的统计特性进行自我调整，可以将波束形成方法划分为固定波束形成(Fixed Beamforming)和自适应波束形成(Adaptive Beamforming)。
- 固定波束形成：一旦设计好滤波器后，加权系数就不再改变。
  - 优点：计算简单，容易实现；
  - 缺点：环境适应性差，对噪声不具有自适应性；
  - 经典算法：
    - 延迟求和波束形成（DSB: Delay-and-Sum Beamforming） 本章重点
    - 滤波求和波束形成（FSB: Filter-and-Sum Beamforming）

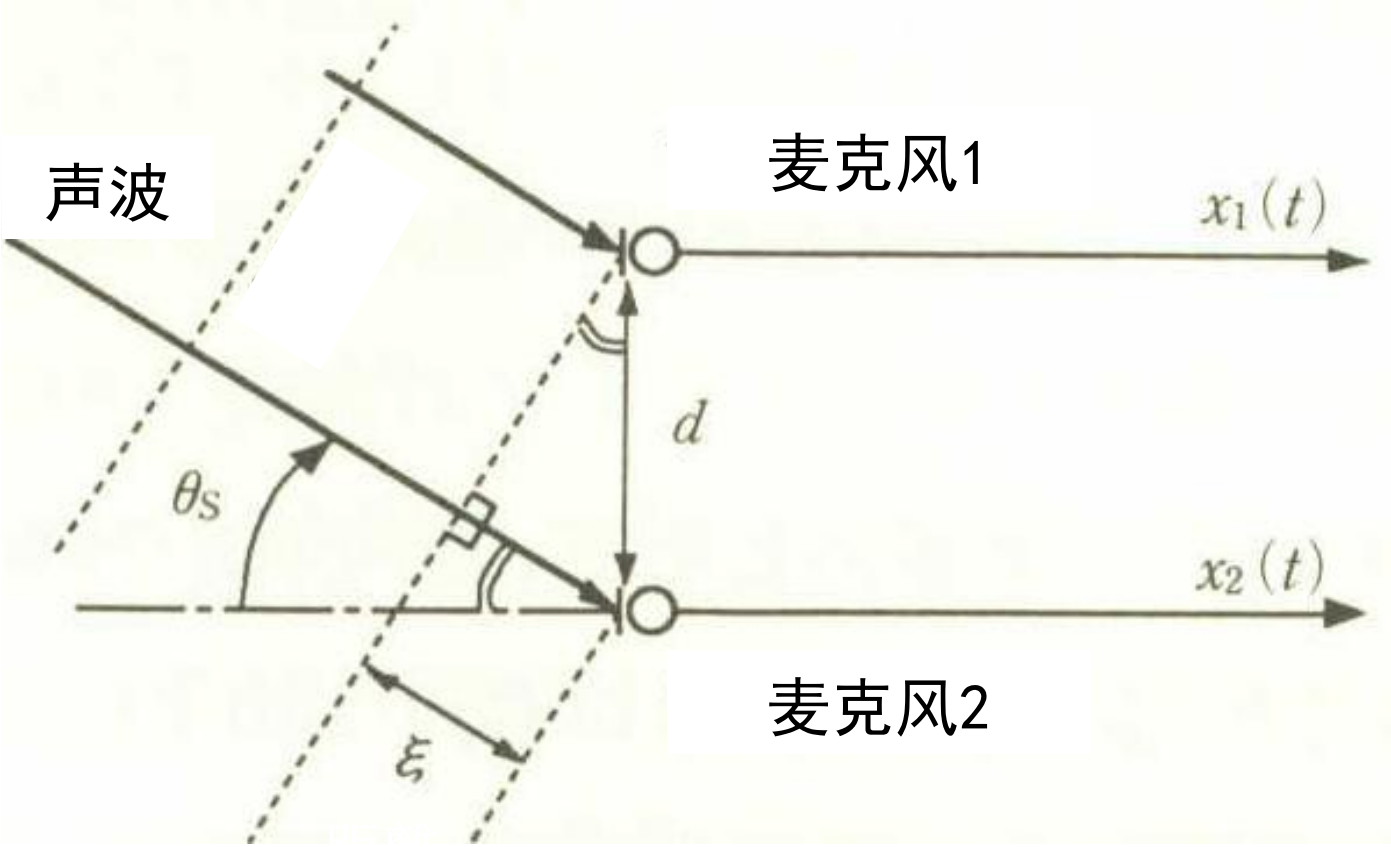
延迟求和波束形成基本思路（掌握）

- 迟延求和波束形成是一种经典和简单的固定波束形成方法，主要包含迟延补偿与加权求和处理。



- 延迟补偿使得每个麦克风信号在时间上对齐。
- 经过加权求和，得到增强后的输出信号。

麦克风语音信号（掌握）



$$\xi = \mathrm{d}\sin\theta_s$$

$$x_2(t) = x_1(t - \tau_s)$$

$$\tau_s = \xi/\mathrm{c} = (\mathrm{d}\sin\theta_s)/\mathrm{c}$$

c：声速
d：麦克风间隔
τ_s：到达时间差（TDOA）
θ_s：到达方向（DOA）

TDOA的计算（掌握）

- 如何计算到达时间差（TDOA）τ_s?
  - 利用两个信号之间的互相关与自相关特性

$$\begin{aligned}\phi_{12}(\tau)&=\mathrm{E}[x_1(t)\cdot x_2(t+\tau)]\\&=\mathrm{E}[x_1(t)\cdot x_1(t+\tau-\tau_s)]\\&=\phi_{11}(\tau-\tau_s)\end{aligned}$$

$\phi_{12}(\tau)$：$x_1(t)$ 和 $x_2(t)$的互相关函数

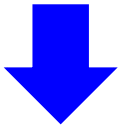
$\phi_{11}(\tau)$：$x_1(t)$的自相关函数

TDOA的计算（续）（掌握）

$$\begin{aligned}\phi_{12}(\tau)&=\mathrm{E}[x_1(t)\cdot x_2(t+\tau)]\\&=\mathrm{E}[x_1(t)\cdot x_1(t+\tau-\tau_s)]\\&=\phi_{11}(\tau-\tau_s)\end{aligned}$$

- 延迟为零（$\tau-\tau_s=0$）时，自相关函数$\phi_{11}(\tau-\tau_s)$的值最大。

$$\hat{\tau}_s=\underset{\tau}{\operatorname{argmax}}\,\phi_{12}(\tau)=\underset{\tau}{\operatorname{argmax}}\,\phi_{11}(\tau-\tau_s)$$



到达方向（DOA）：$\hat{\theta}_s=\sin^{-1}(c\hat{\tau}_s/d)$

增强从方向$\hat{\theta}_s$上到来的语音信号。

延迟求和波束成形的特点

- 一旦设计了滤波器，加权系数就不会改变。
- 优点：计算简单，易于实现。
- 缺点：环境适应性差，对噪音没有适应性。
- 希望找到一种能够自动适应不同环境的波束形成方法。

第五章　语音增强

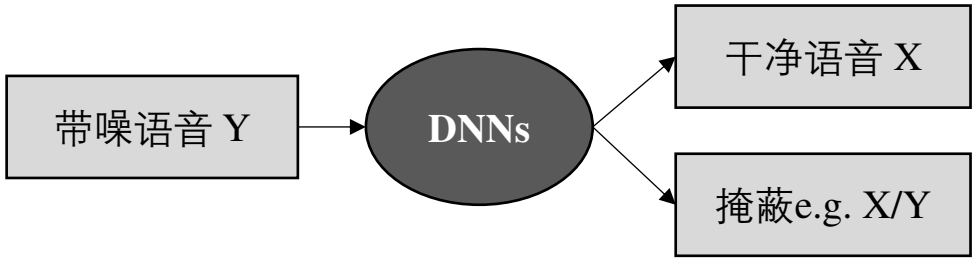
- 5.1 语音增强的概述
- 5.2 单通道语音增强
- 5.3 多通道语音增强
  - 5.3.1 固定波束形成
  - 5.3.2 自适应波束形成
- 5.4 语音增强技术的展望

第五章　语音增强

- 5.1 语音增强的概述
- 5.2 单通道语音增强
- 5.3 多通道语音增强
- 5.4 语音增强技术的展望
  - 5.4.1 语音增强的前沿深度学习模型（了解）
  - 5.4.2 说话人分离（了解）

语音增强的技巧：多目标训练（掌握）

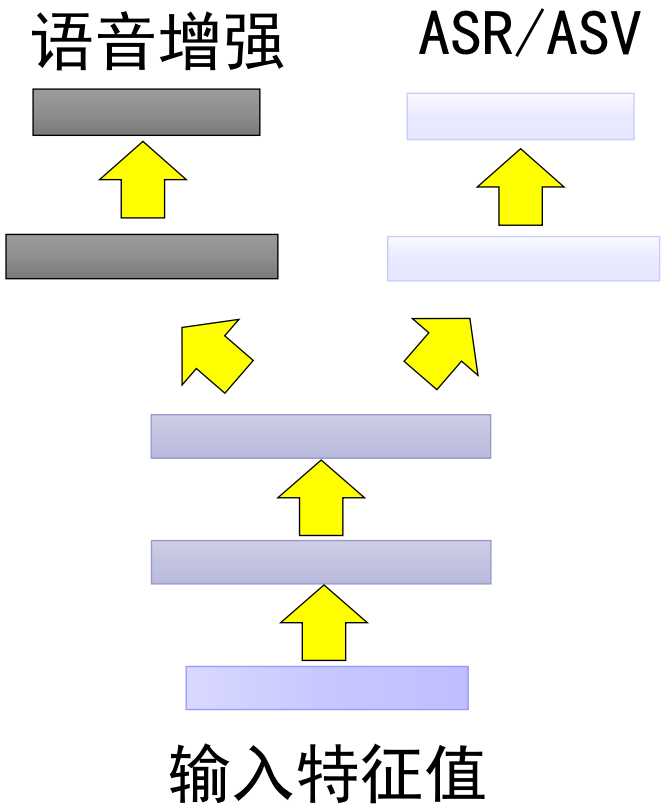
- 很难断定那种方法(基于映射或基于掩蔽)更好，尤其在噪音脚本不可见的情况下。
- 在不同的的SNR水平下，映射和掩蔽框架之间有很强的互补性。



多目标训练结构示意图

基于多任务学习的语音增强（掌握）

- 语音的其他任务可以作为增强任务的互补信息，为其提供丰富的语义或者说话人信息。
- 多任务学习能够利用不同任务的信息进行语音增强。
- 增强的语音对语音识别、说话人识别（ASV: Automatic Speaker Verification）或者其他任务的性能提升也有帮助。



多任务学习示意图

第五章　语音增强

- 5.1 语音增强的概述
- 5.2 单通道语音增强
- 5.3 多通道语音增强
- 5.4 语音增强技术的展望
  - 5.4.1 语音增强的前沿深度学习模型
  - 5.4.2 说话人分离

多说话人的现实复杂场景（回顾）

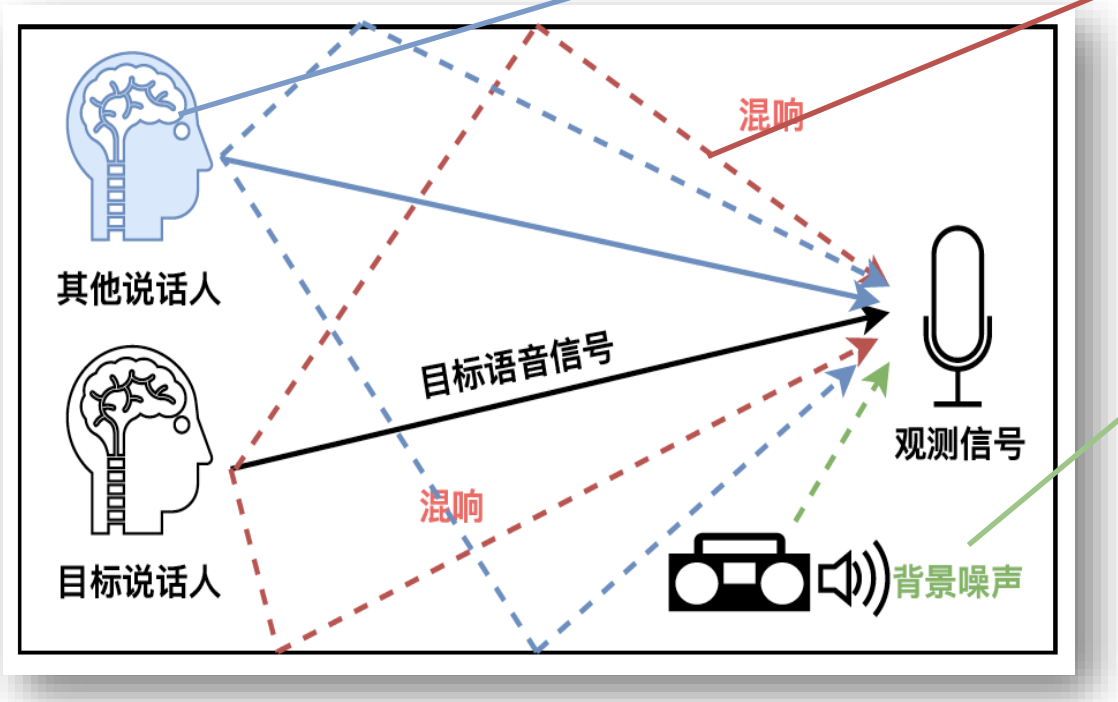
干扰说话人

由干扰说话人引起

混响

障碍物反射引起的声音持续传播

背景噪声



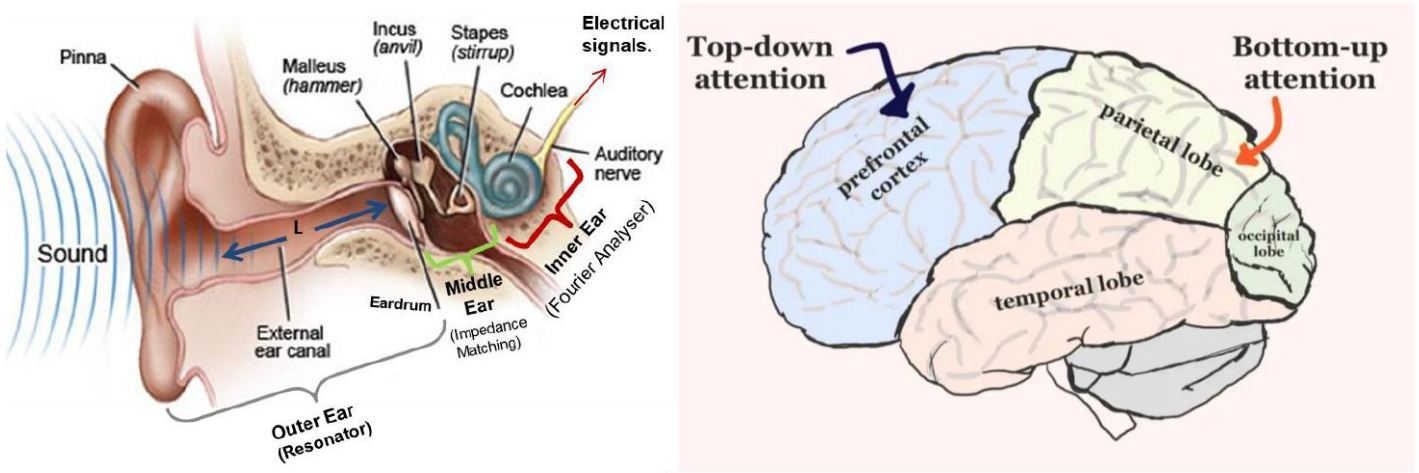
$$y(n) = \sum_{i}^{M} \left(x_i(n) * h_i(n) \right) + v(n)$$

M：说话人数量

复杂听觉场景下的耳和脑机制（基本概念）

- 人的听觉系统具有惊人的能力来解析复杂听觉场景。人类依靠**耳蜗**的活动机制对声音频谱进行最初的分析，并通过**大脑**自下而上刺激驱动和自上而下任务驱动的组合来对特定听觉物体进行选择。

- **自下而上刺激驱动：被动**接收听觉刺激，通过声源间的差异进行分离。
- **自上而下任务驱动：主动**选择性倾听特定声音，聚焦注意特定声源。

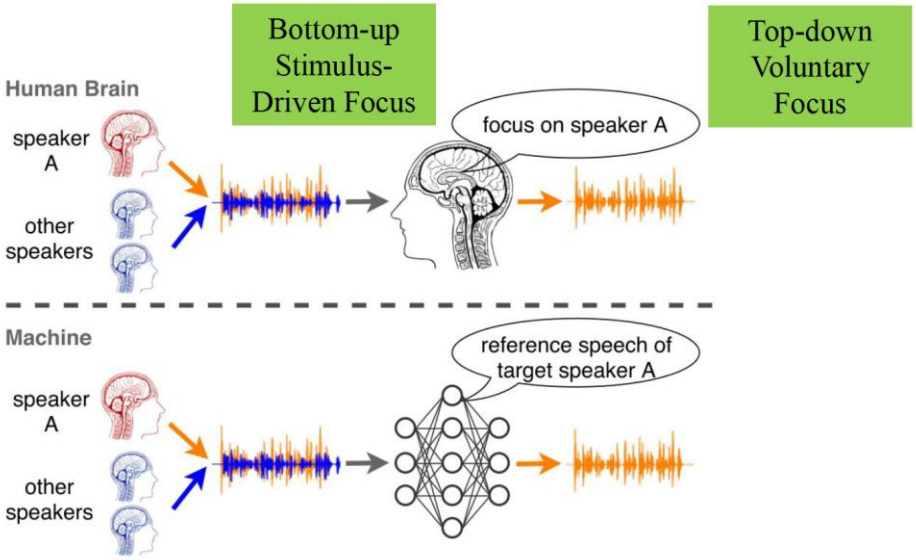


听觉场景下的耳与脑机制的示意图

复杂听觉场景下的耳和脑机制（续）（基本概念）

- 人的听觉系统具有惊人的能力来解析复杂听觉场景。人类依靠**耳蜗**的活动机制对声音频谱进行最初的分析，并通过**大脑**自下而上刺激驱动和自上而下任务驱动的组合来对特定听觉物体进行选择。

- **自下而上刺激驱动：被动**接收听觉刺激，通过声源间的差异进行分离。
- **自上而下任务驱动：主动**选择性倾听特定声音，聚焦注意特定声源。



机器模仿人脑机制的示意图