第六章　声纹识别

第六章　声纹识别

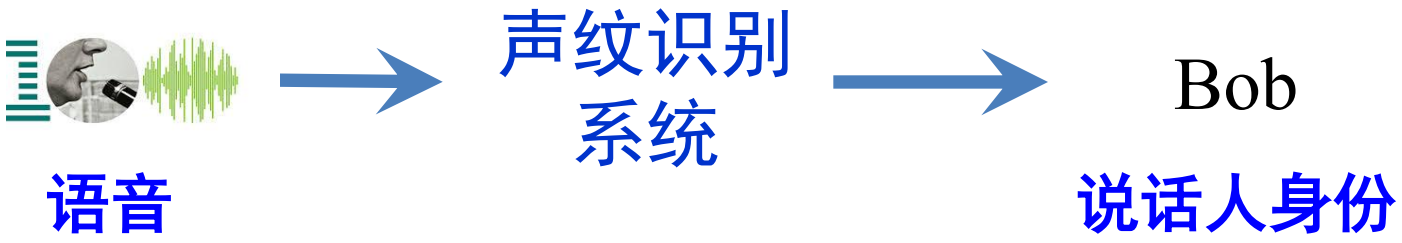
- 6.1 声纹识别概述
- 6.2 传统声纹识别算法（GMM-UBM）
- 6.3 基于深度学习的声纹识别算法
- 6.4 声纹识别技术的展望

第六章　声纹识别

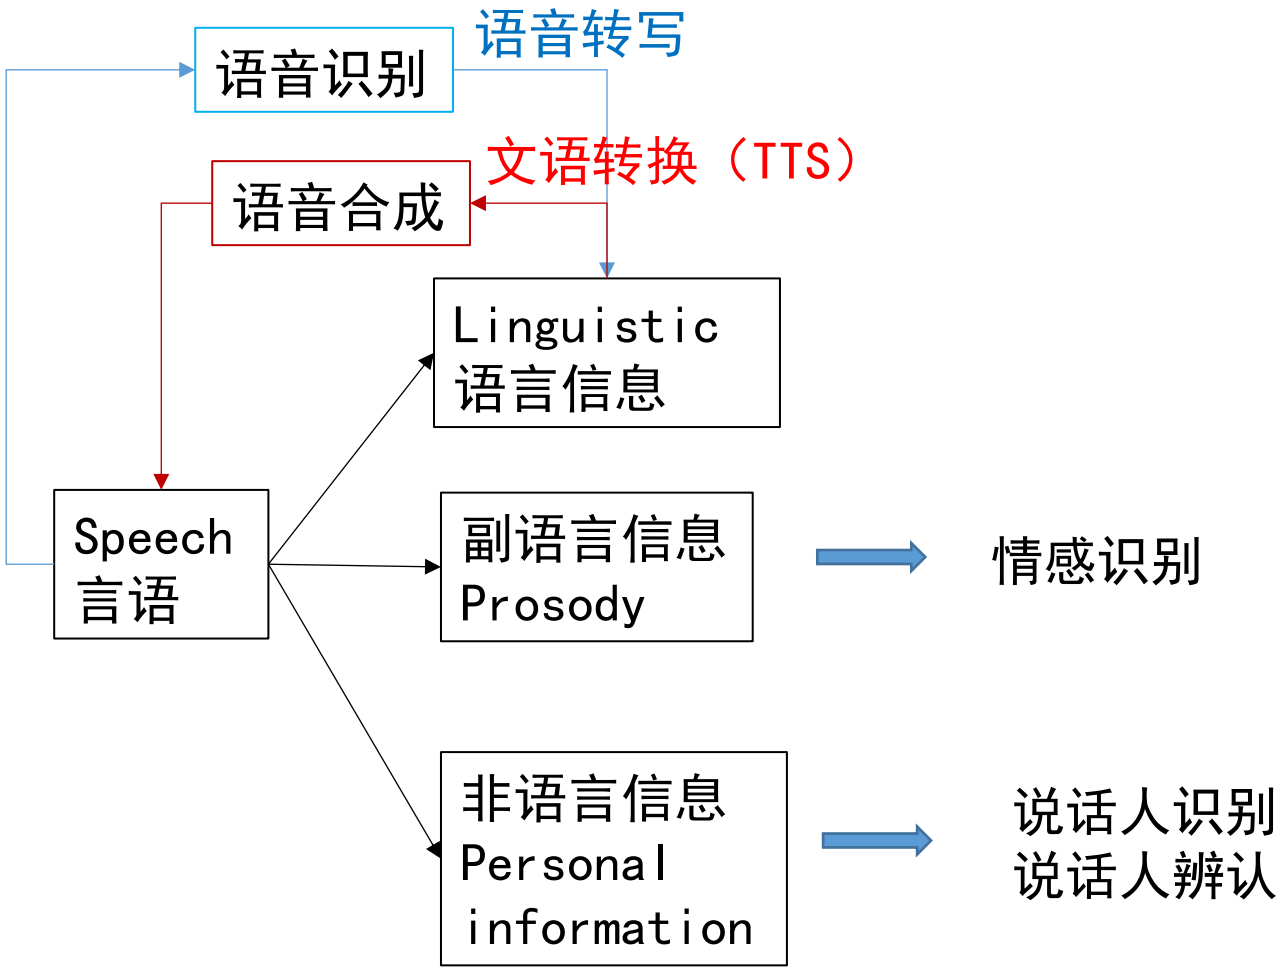
- 6.1 声纹识别概述
  - 6.1.1 声纹识别的基本概念（基本概念）
  - 6.1.2 声纹识别方法的回顾（了解、基本概念）
  - 6.1.3 声纹识别的典型应用（了解）
- 6.2 传统声纹识别算法（GMM-UBM）
- 6.3 基于深度学习的声纹识别算法
- 6.4 声纹识别技术的展望

什么是声纹识别？

- 定义：
  - 声纹识别（说话人识别）作为生物识别（指纹识别、掌纹识别、人脸识别和虹膜识别等）的一种，是根据说话人的声音特性进行身份辨识的任务。
  - 输入：语音
  - 输出：说话人身份

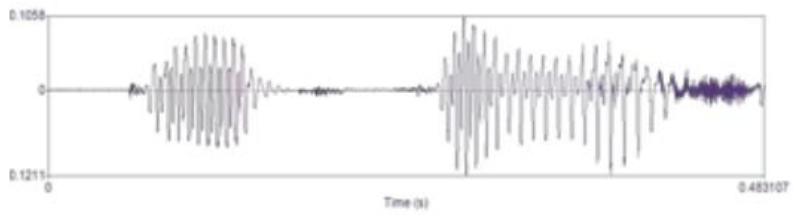


语音中语言、副语言和非语言信息的感知（回顾）



与其他语音处理方法的区别

- 语音识别：输出语音携带的文本信息；
- 情感识别：输出语音携带的情感信息；
- 语种识别：输出语音所属的语种；
- 语音合成：由文本输出语音；
- 声纹识别：输出语音携带的说话人身份信息。



"I am Bob"

Identity: Bob

Message: "I am Bob"

English, Male, Happy,
Middle age, etc.

说话人身份信息相关的语音属性

- 低级属性：与发声器官的生理方面相关
  - 声道频谱；
  - 共振峰轨迹。
- 高级属性：与说话方式的行为差异相关
  - 韵律；
  - 口音；
  - 话语中词的选择。

声纹识别的分类

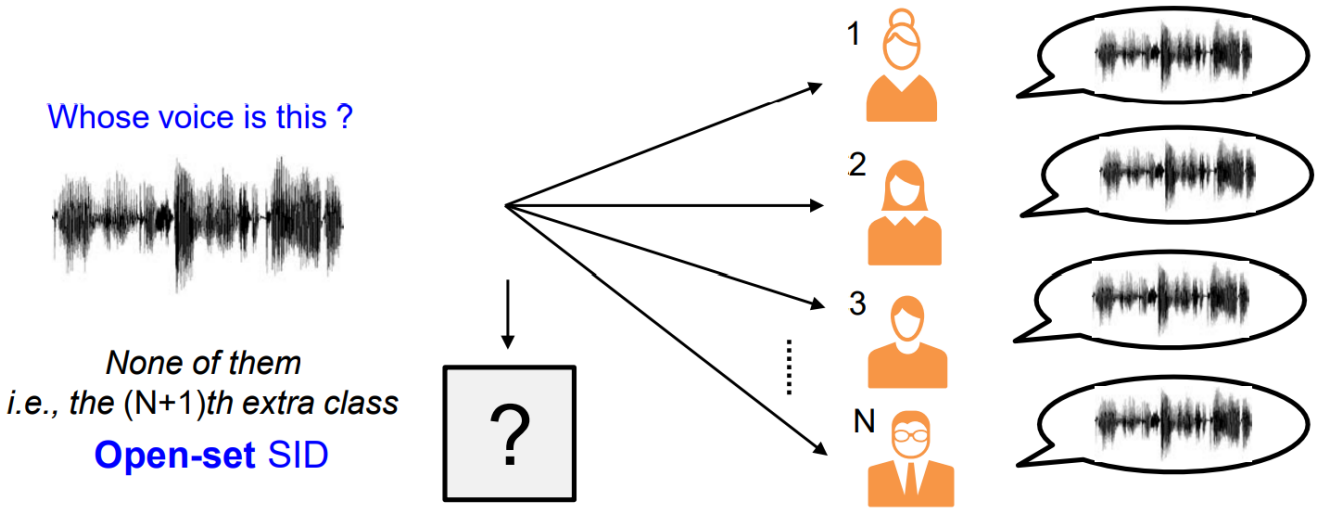
- 按照输入的模式
  - 文本相关的说话人识别（Text-dependent）
    - 注册和测试话语共享（至少部分）相同的内容；
    - 目的是分析给定语音语境下的说话人特征；
    - 更高的性能。
  - 文本无关的说话人识别（Text-independent）
    - 注册和测试话语可以使用任意文本（甚至不同的语言）；
    - 不使用关于口语内容的先验信息；
    - 更高的便利性。

声纹识别的分类（续）

- 按照输出的模式
  - 说话人辨认（Speaker Identification）
    - 判定待识别说话人来自注册集中的哪个说话人；
    - 1：N 语音的对比。
  - 说话人确认（Speaker Verification）
    - 判定待识别语音是否来自注册集中的某个说话人；
    - 成对或1：1语音的对比。

声纹识别的分类（续）

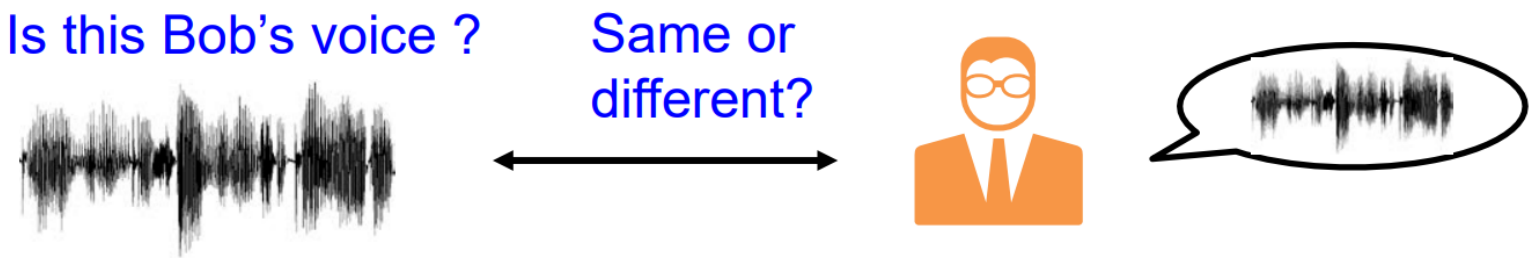
- 说话人辨认（Speaker Identification）
  - 判定待识别说话人来自注册集中的哪个说话人；
  - 来自未知说话者的语音样本与一组标记样本进行比较，未知说话人被识别为语音与输入语音样本最匹配的说话人。



确定未知说话人是否是一组人中的特定人

声纹识别的分类（续）

- 说话人确认（Speaker Verification）
  - 判断说话人身份是否与其声明的身份相符；
  - 由未知说话人提出身份声明。来自说话人的语音样本与声称身份的注册样本进行比较。如果匹配足够好（即通过给定的阈值），则系统接受身份声明。
  - 辨认任务可以分解为N对说话人的比较。验证任务更为基础。



声纹识别评价指标

- 等错误率（Equal Error Rate）
  - 调整阈值，使得误拒绝率(False Rejection Rate，FRR)等于误接受率 (False Acceptance Rate，FAR)，此时的FAR与FRR的值称为等错误率。
  - 误拒绝率(False Rejection Rate，FRR)：
    - 被错误拒绝的有效身份声明的比例。

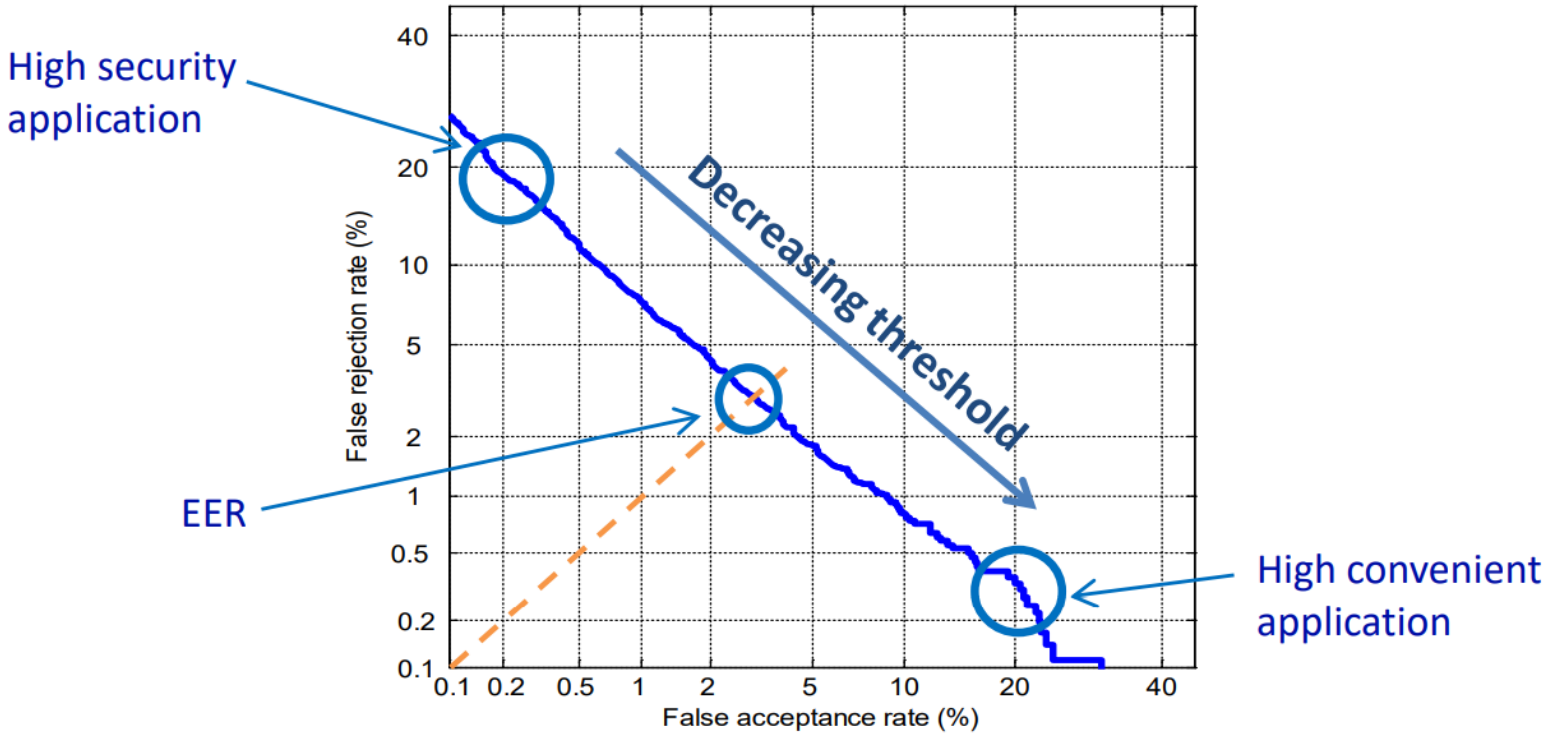
$$FRR = \frac{\text{本该匹配成功却被判匹配失败的次数}}{\text{总的匹配成功次数}}$$

  - 误接受率 (False Acceptance Rate，FAR)：
    - 错误接受冒名顶替者身份声明的比例。

$$FAR = \frac{\text{本该匹配失败却被判匹配成功的次数}}{\text{总的匹配失败次数}}$$

声纹识别评价指标（续）

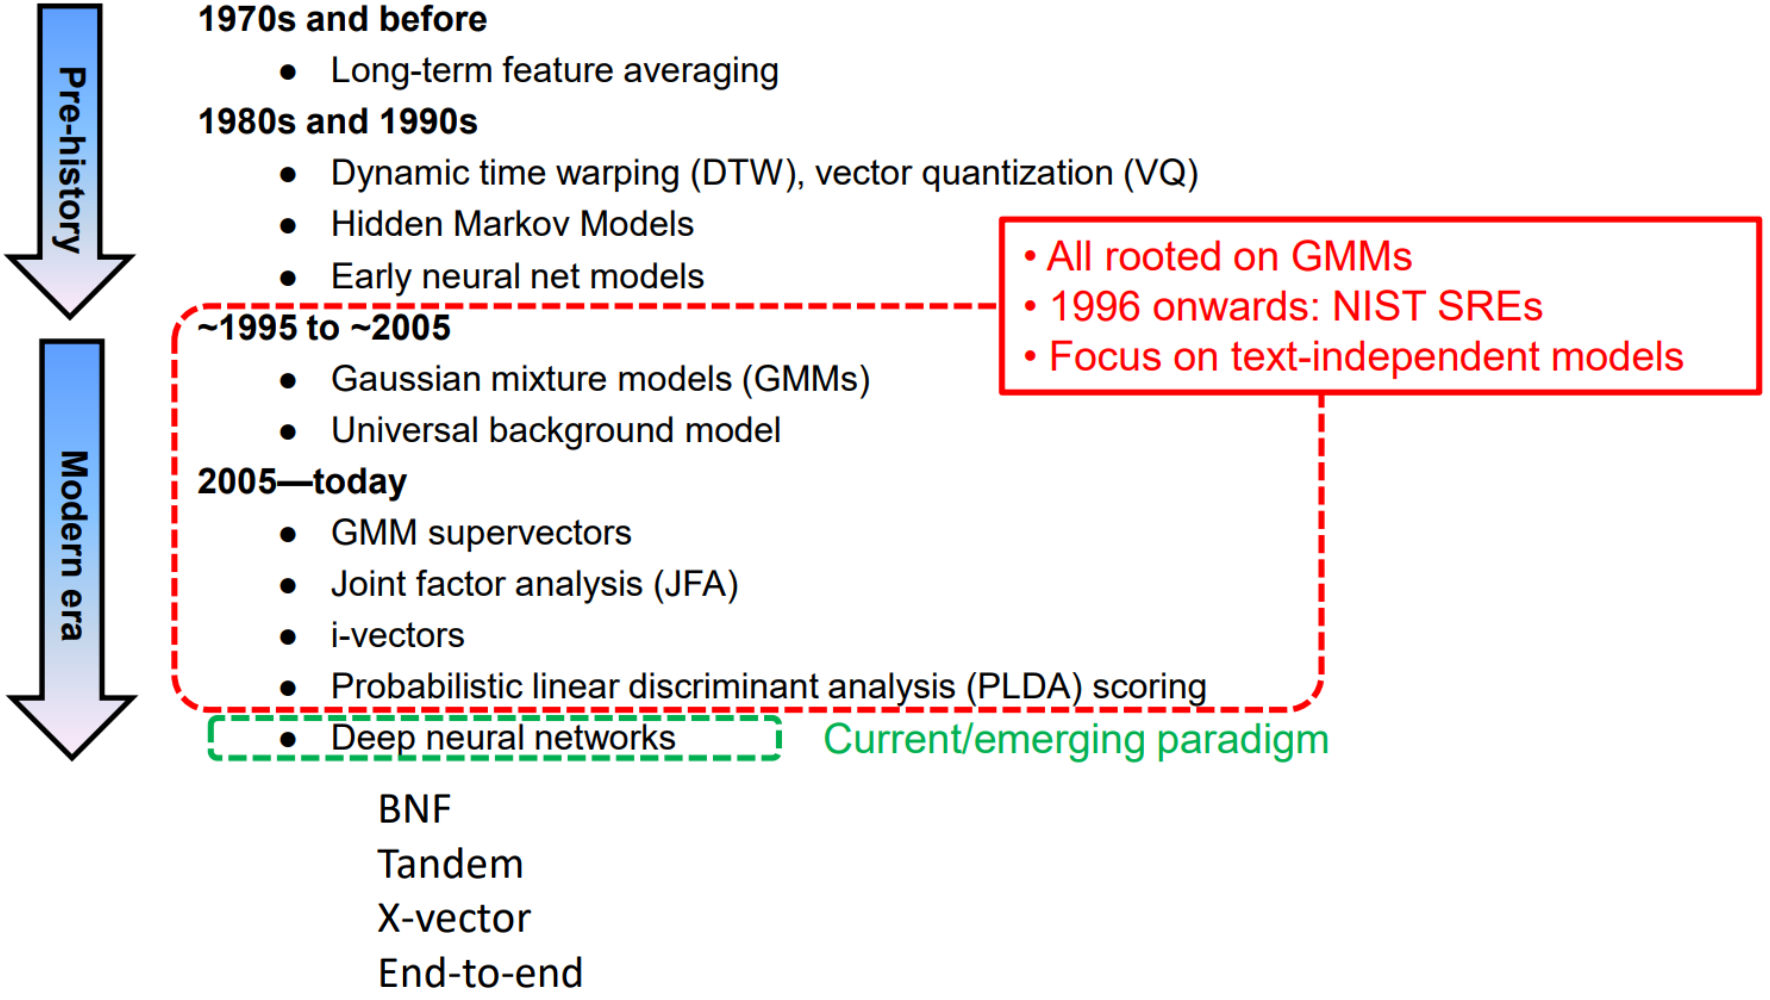
- 等错误率（Equal Error Rate）
- 检测-错误-均衡曲线（Detection Error Tradeoff: DET）



第六章　声纹识别

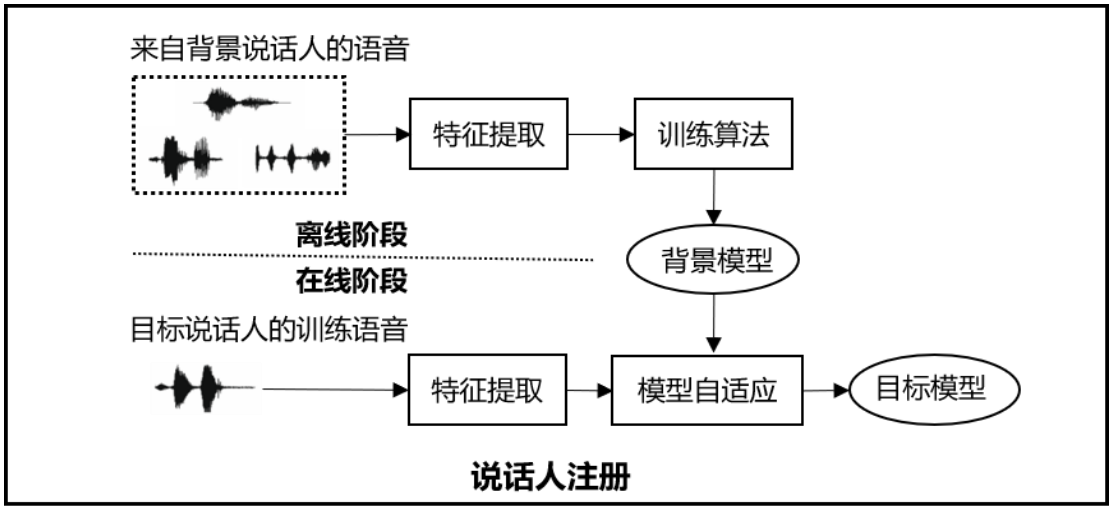
- 6.1 声纹识别概述
  - 6.1.1 声纹识别的基本概念
  - 6.1.2 声纹识别方法的回顾
  - 6.1.3 声纹识别的典型应用
- 6.2 传统声纹识别算法（GMM-UBM）
- 6.3 基于深度学习的声纹识别算法
- 6.4 声纹识别技术的展望

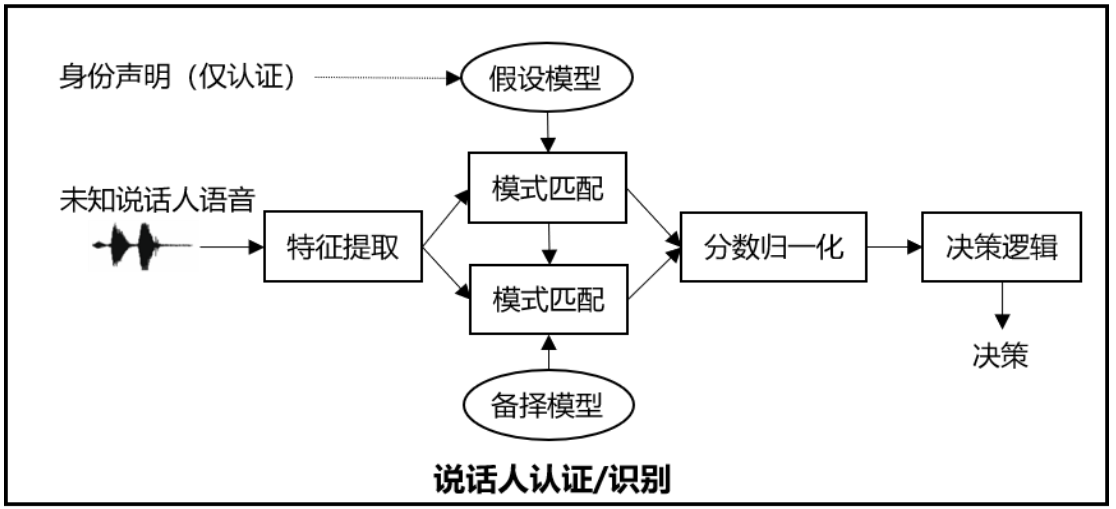
声纹识别技术的演化（了解）



声纹识别系统基本框架（掌握）

- 特征提取
  - 将原始语音信号转换为包含说话人信息为主的特征向量序列。
- 注册
  - 用以与测试段对照，判断访问者是否与其声明身份相符。
- 测试
  - 从待测语音中提取特征向量，并与每个注册说话者的存储模型进行比较。
  - 根据相似度（或似然度）值做出识别决策。





GMM-UBM （基本概念）

- Gaussian mixture model (GMM)
  - 为目标说话人的声纹特征建模；
  - GMM将空间分布的概率密度用多个高斯概率密度函数的加权来拟合，可以平滑地逼近任意形状的概率密度函数；
  - 是一个易于处理的参数模型，对实际数据具备较强的表征能力。

$$P(\mathbf{x}|\theta) = \sum_{m=1}^{M} c_m N(\mathbf{x}|\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m)$$

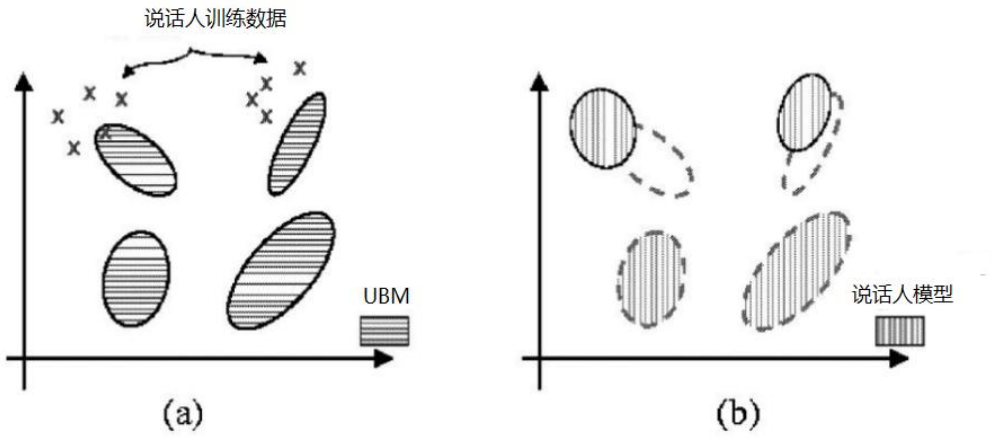
$$N(\mathbf{x}|\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m) = \frac{1}{(2\pi)^{D/2}(\boldsymbol{\Sigma}_m)^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_m)^T \boldsymbol{\Sigma}_m{}^{-1}(\mathbf{x}-\boldsymbol{\mu}_m)\right\}$$

GMM-UBM（续） （基本概念）

- Universal Background Model (UBM)
  - 实际场景中每一个说话人的语音数据很少，导致无法训练出高效的GMM模型；
  - 在复杂的声学环境和信道场景下，训练GMM模型的语音与测试语音存在失配的情况；
  - 为解决上述问题：
    - 使用EM算法对说话人无关的领域模型或通用背景模型(UBM)进行训练；
    - 基于UBM通过自适应算法（如最大后验概率：MAP）来得到目标说话人模型。

GMM-UBM（续） （基本概念）

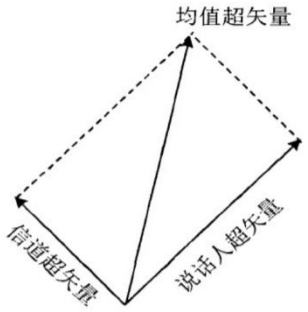
- 使用MAP的原因
  - UBM是初始模型，可以减少注册新说话人所需的语音发生的持续时间/数量（导出依赖于说话人的GMM参数）；
  - 由于说话人相关的GMM和说话人无关的UBM具有相同的模型复杂度，因此可以计算更好的对数似然分数；
  - 使用高斯选择可以更快。



MAP算法自适应

联合因子分析（Joint factor analysis：JFA）（了解）

- 目的
  - 在GMM超向量空间中进行信道补偿。
- 实现
  - GMM 超向量$\mathbf{m}_r$被建模为说话人和信道分量的总和。



均值超矢量分解示意图

$$\mathbf{m}_r = \mathbf{m}_o + \mathbf{U}\mathbf{x}_r + \mathbf{V}\mathbf{y}_r + \mathbf{D}\mathbf{z}_r = \mathbf{m}_o + \underbrace{\mathbf{V}\mathbf{y}_r + \mathbf{D}\mathbf{z}}_{\text{Speaker supervector}} + \underbrace{\mathbf{U}\mathbf{x}_r}_{\text{Channel supervector}}$$

UBM supervector　　Residual variability

联合因子分析（续） （了解）

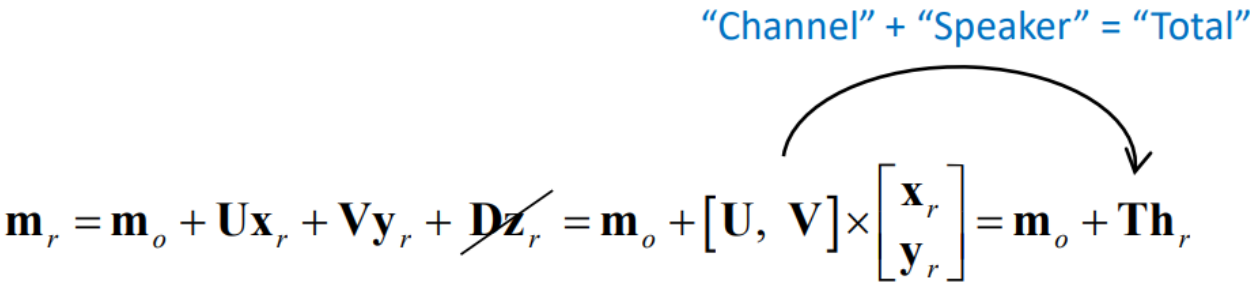
- 注册
  - 联合估计说话人因子$\mathbf{y}_r$和信道因子$\mathbf{x}_r$以及残差$\mathbf{z}_r$。
  - 信道补偿通过丢弃信道分量$\mathbf{U}\mathbf{x}_r$来实现。
- 测试
  - 从测试段估计信道因子z_{test}
  - 计算说话人验证分数

Channel supervector discarded

$$s = \left(\mathbf{V}\mathbf{y}_r + \mathbf{D}\mathbf{z}_r\right)^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} \left(\mathbf{F}_{\text{test}} - \mathbf{N}_{\text{test}}\mathbf{m}_o - \mathbf{N}_{\text{test}}\mathbf{U}\mathbf{x}_{\text{test}}\right)$$

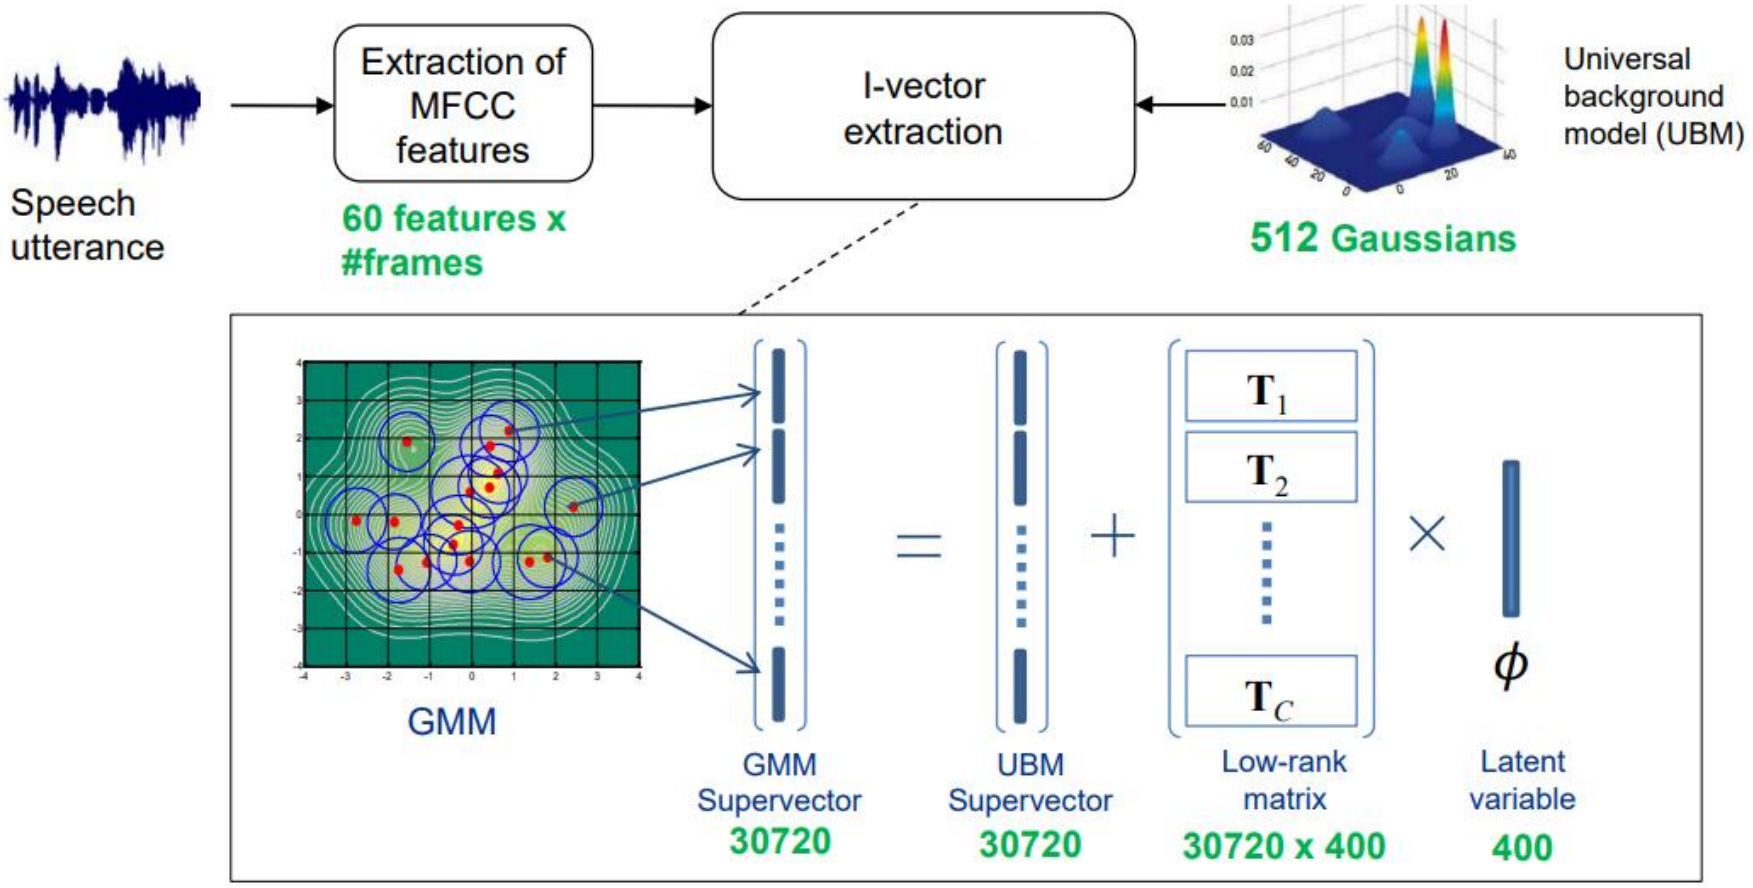
Identity vector (i-vector)（了解）

- 目的
  - 为了解决JFA估算出来的说话人子空间与信道子空间存在互相掩盖的问题，不严格区分说话人空间以及信道空间
- 简化版本的JFA



  - 信道和说话人子空间形成一个总的可变空间
  - I-vector包含人的语音特征（来自说话人子空间）和信道因子（来自信道子空间）

Identity vector (i-vector) （了解）

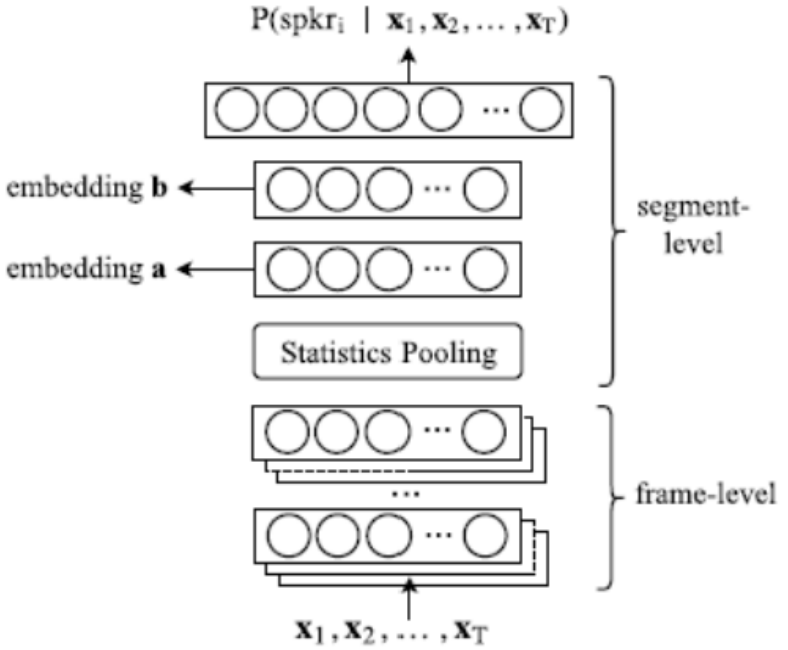


1. 通过EM算法迭代计算全局差异空间矩阵T；
2. 利用T计算$\mathbf{h}_r$的后验分布的均值（i-vector）。

X-vector （基本概念）

- 目的
  - 使用监督方式训练的深度神经网络导出句子级别的嵌入表示。

- X-vector提取器
  - TDNN：经过训练以在输出层区分说话人；
  - 统计池化层：计算均值和标准差；
  - 段的统计信息被传递到另一个隐层以产生嵌入；
  - 数据增广是必要的。



[Source: Snyder et al, 2017]

Probabilistic LDA (PLDA)简介（了解）

- PLDA定义
  - 嵌入表示（例如i-vector和x-vector）中既包含了说话人信息，也包含了信道信息。
  - PLDA根据说话人身份和信道效应解释观察到的嵌入表示，以实现对说话人因子的“提纯”。
  - 可以看作是 LDA 的概率形式。

$$\boldsymbol{\eta}_{ij} = \boldsymbol{\mu} + \boldsymbol{V}\boldsymbol{y}_i + \boldsymbol{U}\boldsymbol{x}_{ij} + \boldsymbol{\varepsilon}_{ij}$$

$\boldsymbol{\eta}_{ij}$代表第i个说话人的第j段语音的嵌入表示；$\boldsymbol{\mu}$为所有嵌入表示的全局均值；$\boldsymbol{V}$是说话人空间矩阵(Eigen Voice)，用于描述说话人的特征；$\boldsymbol{U}$是信道空间矩阵(Eigen Channel)，用于描述信道的特征；$\mathbf{y}_i$与$\mathbf{x}_{ij}$是其对应子空间内的因子，服从高斯分布；$\boldsymbol{\varepsilon}$是残差项，服从协方差矩阵为对角阵的高斯分布。

Probabilistic LDA (PLDA)简介（了解）

- 训练：
  - PLDA的模型参数一个有4个，分别是i-vector/x-vecto均值**μ**，空间特征矩阵**V**和**U**，**ε**噪声协方差。由于模型含有隐变量，模型的训练过程采用经典的EM算法迭代求解。
- 测试：
  - 对于说话人确认任务，每组试验都需要一个目标说话人和一个测试说话人。分别提取目标说话人和测试说话人的i-vector/x-vector，使用PLDA模型计算它们之间的似然度评分。

第六章　声纹识别

- 6.1 声纹识别概述
  - 6.1.1 声纹识别的基本概念
  - 6.1.2 声纹识别方法的回顾
  - 6.1.3 声纹识别的典型应用
- 6.2 传统声纹识别算法（GMM-UBM）
- 6.3 基于深度学习的声纹识别算法
- 6.4 声纹识别技术的展望

访问控制

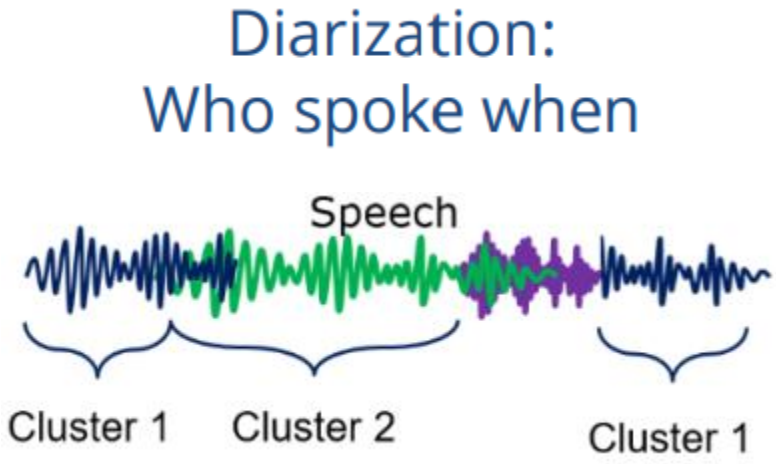
- 访问房间、建筑物和物理资产
- 身份和凭证认证



Lenovo A586
[Lee at al, SLTC News Letter, 2013]

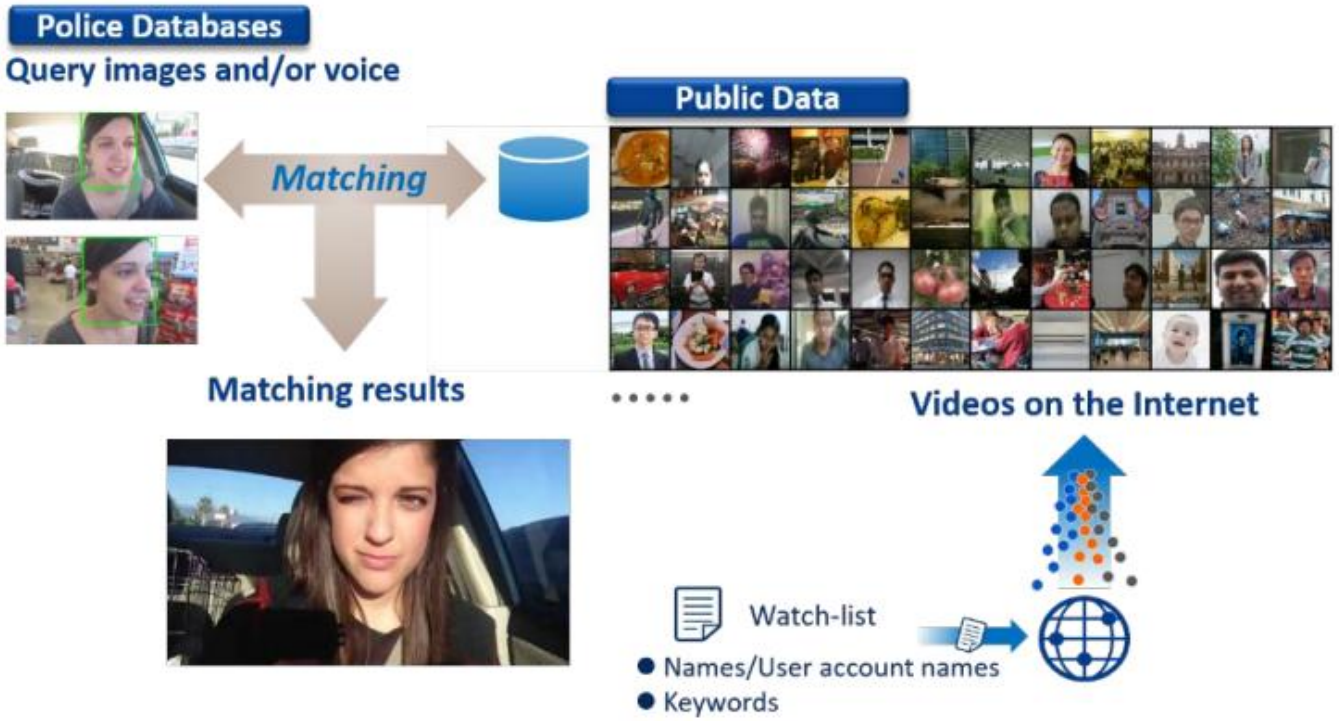
说话人日志

- 谁在什么时候说话
- 会议转录
- 会议分析（不同会议参与者的积极性）



搜索/索引

- 索引多媒体档案
- 情报、反恐



第六章　声纹识别

- 6.1 声纹识别概述
  - 6.1.1 声纹识别的基本概念
  - 6.1.2 声纹识别方法的回顾
  - 6.1.3 声纹识别的典型应用
- 6.2 传统声纹识别算法（GMM-UBM）
  （基本概念）
- 6.3 基于深度学习的声纹识别算法
- 6.4 声纹识别技术的展望

特征提取

- 目的
  - 保留说话人信息；
  - 去除噪声和其他干扰信息。
- 声学特征
  - 梅尔频率倒谱系数（MFCC）
  - 线性预测倒谱系数（LPCC）
- 完整的特征提取前端还包括
  - 语音活动检测（丢弃非语音帧）
  - 后处理（Cepstral Mean Normalization等）

基于GMM的说话人建模

- 注册
  - 说话人模型通过来自该说话人的注册语音构建；
  - 每个注册语音X是一个由特征提取前端生成的特征向量序列$\{\mathbf{x}_t\}_{t=1}^{T}$。

$$p(\mathbf{x}|\theta)=\sum_{k=1}^{K} w_k \mathrm{N}\left(\mathbf{x}|\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k\right)$$

  - 其中， K表示高斯分量的数量；
  - 集合$\theta=\{\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k,w_k\}_{k=1}^{K}$表示分布的参数；
  - 权重w_k，对于所有的k值，其和总为1。

GMM的期望最大化算法（EM）（了解）

- 给定注册数据$\{\mathbf{x}_t\}_{t=1}^{T}$，$\theta = \{\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k, w_k\}_{k=1}^{K}$的最大似然估计可以使用EM算法获得。

- 从一些随机初始化开始迭代更新参数。

GMM的期望最大化算法（EM）（了解）

- E-step
  - 计算每个特征向量属于第k个高斯分布的程度。

$$\lambda_k(\mathbf{x}_t) = \frac{\mathrm{N}(\mathbf{x}_t \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \cdot w_k}{\sum_{i=1}^{K} \mathrm{N}(\mathbf{x}_t \mid \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \cdot w_i} \qquad \sum_{k=1}^{K} \lambda_k(\mathbf{x}_t) = 1$$

- M-step
  - 基于每个帧的$\lambda_k(\mathbf{x}_k)$更新均值$\boldsymbol{\mu}_k$、协方差矩阵$\boldsymbol{\Sigma}_k$和权重w_k。

Soft membership

$$w_k = \frac{1}{T} \underbrace{\sum_{t=1}^{T} \lambda_k(\mathbf{x}_t)}_{n_k} \qquad \boldsymbol{\mu}_k = \frac{1}{n_k} \times \sum_{t=1}^{T} \lambda_k(\mathbf{x}_t) \cdot \mathbf{x}_t \qquad \boldsymbol{\Sigma}_k = \frac{1}{n_k} \times \sum_{t=1}^{T} \lambda_k(\mathbf{x}_t) \cdot (\mathbf{x}_t - \boldsymbol{\mu}_k)(\mathbf{x}_t - \boldsymbol{\mu}_k)^{\mathrm{T}}$$

Total number of frames aligned to the *k*-th Gaussian component

识别（辨认或确认）

- 测试语音与说话人模型的匹配程度被视为平均对数似然，如下所示：

$$s(Y|\theta)=\frac{1}{T}\sum_{t=1}^{T}\log p(\mathbf{y}_t|\theta)$$

- 对于辨认（Identification）任务，选择得分最高的说话人模型。
- 对于验证（Verification）任务，决策基于以下形式的对数似然比

$$\Lambda(Y)=s(Y|\theta)-s(Y|\theta_{bg})$$

最大后验（MAP）自适应

- 调整来自 UBM 的所有参数（权重、均值向量和协方差矩阵）。
  - 计算语音帧到混合高斯分量的相似度：

$$\lambda_k(\mathbf{x}_t) = \frac{\mathrm{N}(\mathbf{x}_t \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \cdot w_k}{\sum_{i=1}^{K} \mathrm{N}(\mathbf{x}_t \mid \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \cdot w_i}$$

  - 计算零阶和一阶统计量：

$$N_k = \sum_{t=1}^{T} \lambda_k(\mathbf{x}_t) \qquad F_k = \sum_{t=1}^{T} \lambda_k(\mathbf{x}_t) \cdot \mathbf{x}_t$$

  - 调整参数（如平均向量$\boldsymbol{\mu}_k$）：

$$\boldsymbol{\mu}'_k = \alpha_k \left(\frac{1}{N_k} F_k \right) + (1 - \alpha_k) \boldsymbol{\mu}_k$$

New information　　UBM mean vector

最大后验（MAP）自适应（续）（了解）

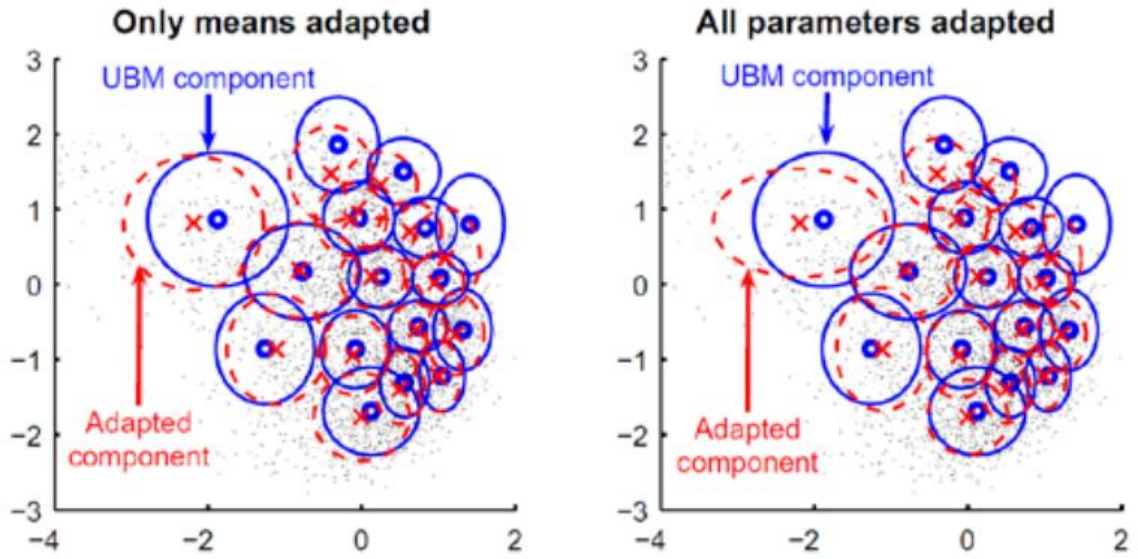
- 适应系数

$$\alpha_k = \frac{N_k}{N_k + r}$$

  - a_k始终在$0 < a_k < 1$范围内；
  - 控制新信息和旧参数之间的平衡；
  - 每个高斯分量不同，它取决于与特定混合对齐的帧总数（即零阶统计数据）和相关因子r（通常取0-20）。

最大后验（MAP）自适应（续）（了解）

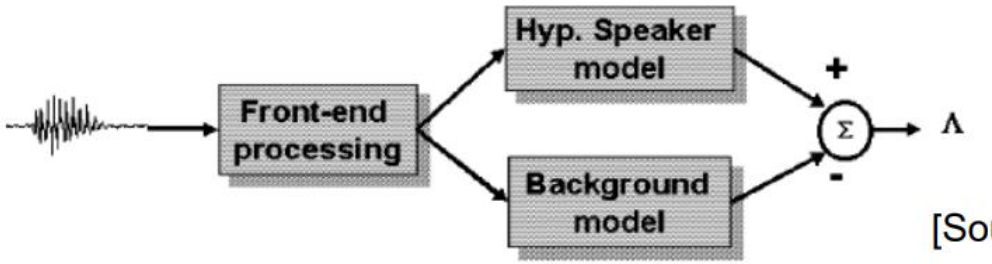
- 二维向量空间中MAP自适应图示
  - 平均适应（Mean adaptation）导致高斯分量偏移;
  - 协方差适应（Covariance adaptation）导致高斯分量的大小（不确定性）发生变化。



GMM-UBM识别（掌握）

- 说话人验证（Verification）任务可以被转换为以下两项的似然比测试：
  - 零假设，H0：测试段Y来自假设说话人;
  - 备择假设，H1：测试段Y不是来自假设说话人。

$$\Lambda(Y)=\log\frac{p(Y|H_0)}{p(Y|H_1)}\approx\log\frac{p(Y|\theta_{\text{spk}})}{p(Y|\theta_{\text{UBM}})}=s(Y|\theta_{\text{spk}})-s(Y|\theta_{\text{UBM}})$$



[Source: Reynolds et al, 2000]

GMM-UBM识别（续）（掌握）

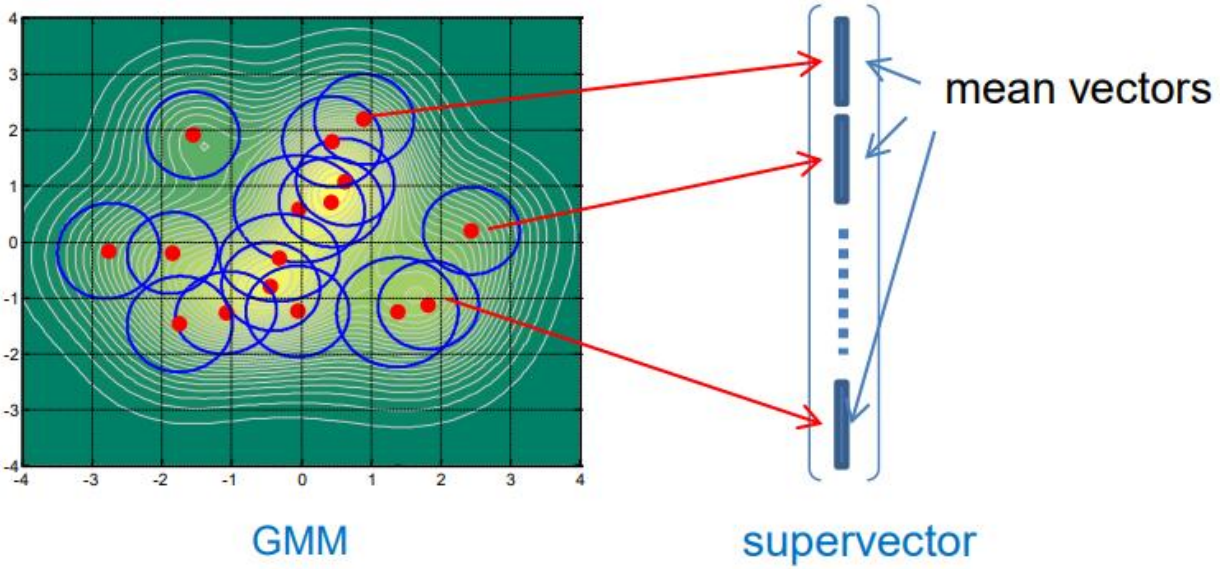
- 给定测试段和说话人模型θ的对数似然相似度：

Speaker GMM or UBM

$$s(Y|\theta)=\frac{1}{T}\sum_{t=1}^{T}\log p(\mathbf{y}_t|\theta)=\frac{1}{T}\sum_{t=1}^{T}\log\sum_{k=1}^{K}w_k\mathrm{N}\left(\mathbf{y}_t|\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k\right)$$

GMM超向量

- GMM-UBM范式
  - 对于每个说话者，基于相同的 UBM 估计说话者相关的 GMM；
  - 说话人相关的 GMM 由均值向量唯一表示，方法是仅调整均值向量，而权重和协方差矩阵保持与 UBM 相同。

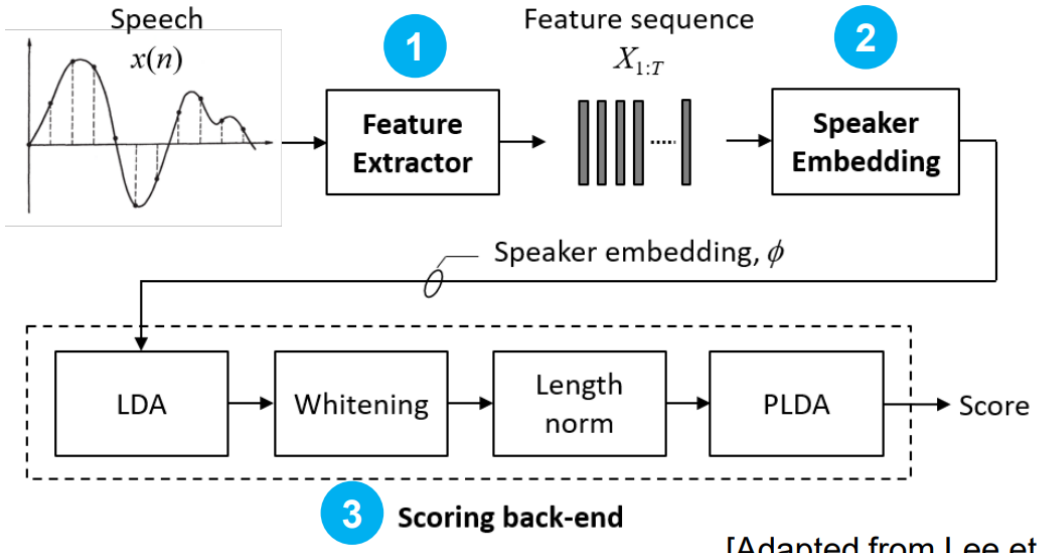


第六章　声纹识别

- 6.1 声纹识别概述
  - 6.1.1 声纹识别的基本概念
  - 6.1.2 声纹识别方法的回顾
  - 6.1.3 声纹识别的典型应用
- 6.2 传统声纹识别算法（GMM-UBM）
- 6.3 基于深度学习的声纹识别算法（基本概念）
- 6.4 声纹识别技术的展望

现代声纹识别系统

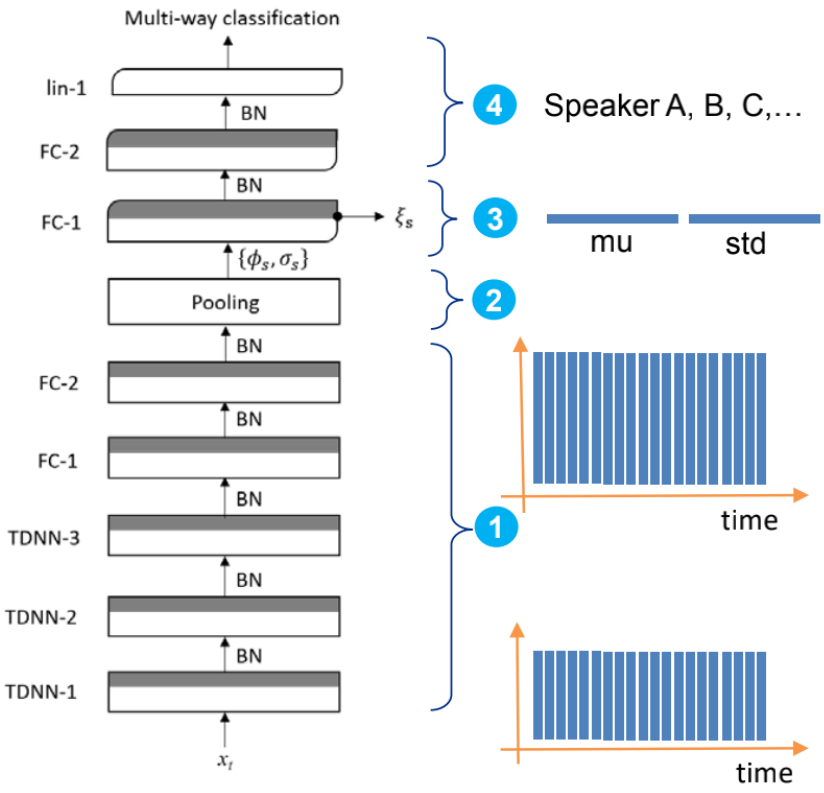
- 现代声纹识别系统主要基于说话人嵌入，包括：
  - 特征提取；
  - 说话人嵌入；
  - 打分。



[Adapted from Lee et al, CSL 2020]

基于x-vector的深度说话人嵌入（掌握）

- x-vector是一个包含四个函数块的深度神经网络
  - 使用多层神经网络实现帧处理器用以提取深度特征，例如延时神经网络(TDNN)
  - 池化层
  - 嵌入提取
  - 基于判别性损失的说话人分类



x-vector提取器的总体架构（掌握）

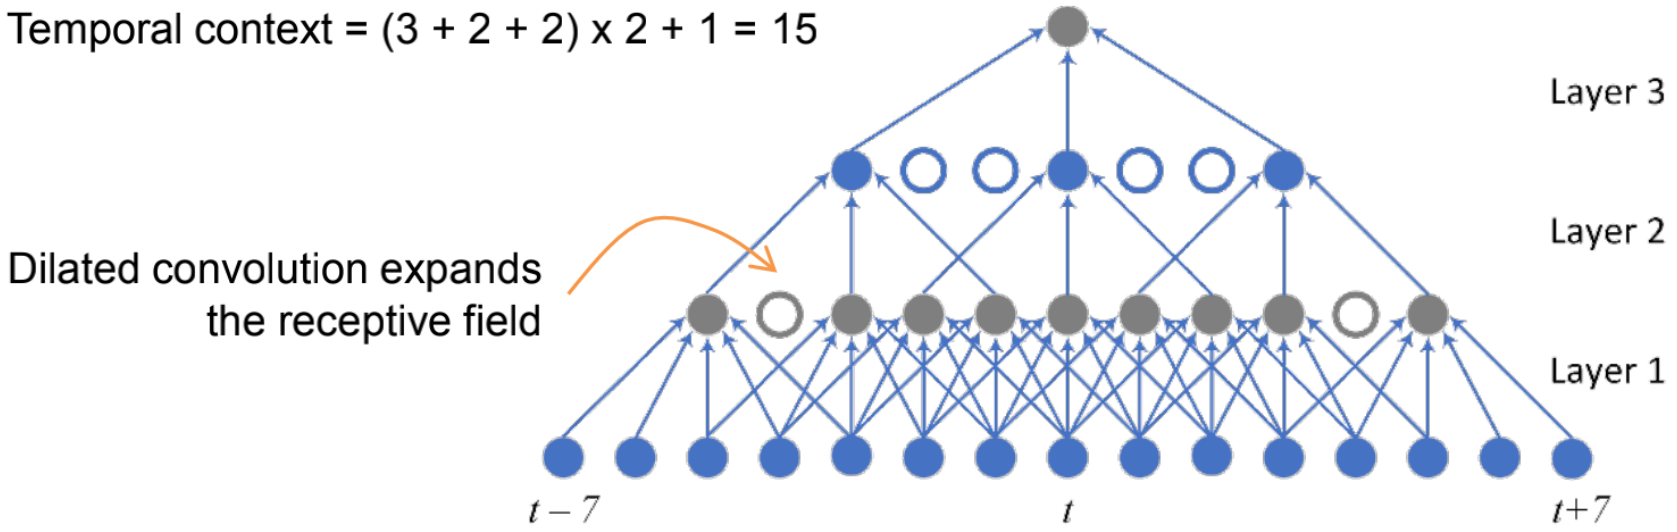
- 深度特征提取
  - 获取一系列声学特征，例如MFCC或对数mel-filterbank系数；
  - 采用多层深度神经网络从声学特征中提取深度说话人特征。
- 时间池化
  - 将特征向量序列转换为单个固定维向量；
  - 时间池化（Temporal pooling）（取特征向量的均值和标准差）是最常见的池化方式；

x-vector提取器的总体架构（续） （掌握）

- 嵌入提取
  - 由若干个相互连接的网络层组成；
  - 其中一层被设计为瓶颈层（Bottleneck layer）；
  - 瓶颈层的输出（非线性层之前）就是x-vector说话人嵌入。
- 说话人分类
  - 根据说话人标签对训练音频进行分类。

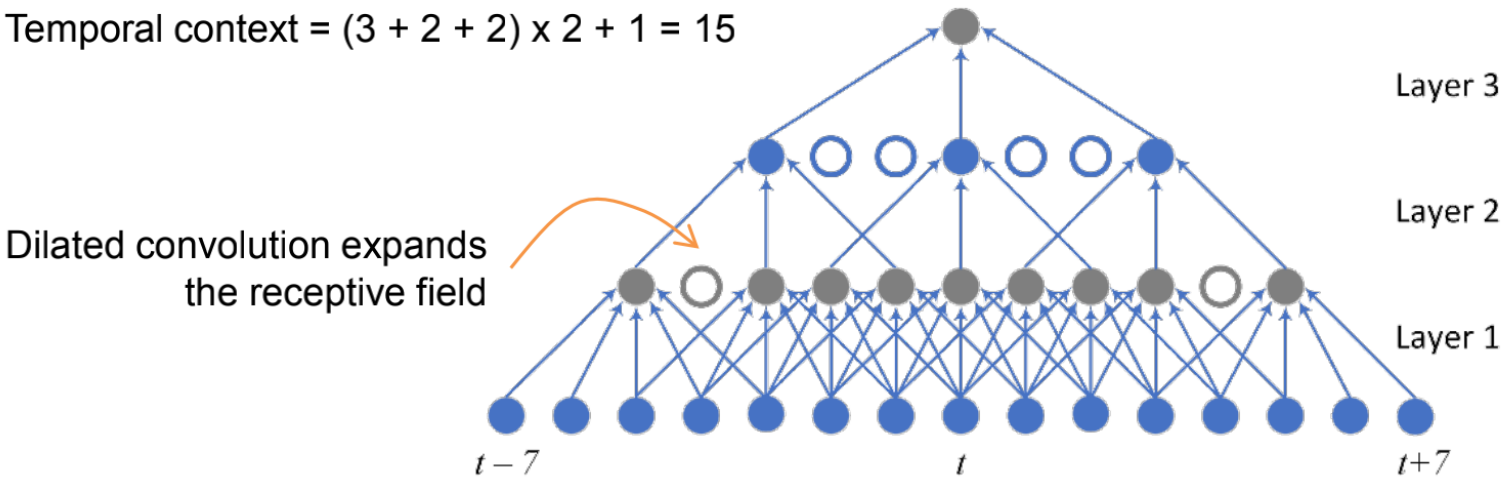
TDNN中的时间上下文

- TDNN对时间上下文信息的提取取决于感受野的宽度
  - 感受野：影响网络特定单元的输入空间区域。



TDNN中的时间上下文（续）

- 更广泛的时间上下文视野：
  - 空洞卷积（通过以一定的步长跳过输入值）；
  - 堆叠更多的空洞一维卷积层。



池化层

- 说话人嵌入通过特征的池化来形成固定长度的表征。
- 时间池化通过平均实现的（计算均值和标准差）。

$$\boldsymbol{\mu} = \frac{1}{T}\sum_{t=1}^{T}\mathbf{h}_t \qquad \sigma = \sqrt{\frac{1}{T}\sum_{t=1}^{T}\mathbf{h}_t \odot \mathbf{h}_t - \boldsymbol{\mu}\odot\boldsymbol{\mu}}$$

$$\mathbf{h}_t = g\left(\mathbf{W}^{\mathrm{T}}\mathbf{f}_t + \mathbf{b}\right)$$

- $\mathbf{h}_t$ – 在第t时刻步变换的特征向量
- $\mathbf{f}_t$ – 前馈层的输入，后跟非线性激活函数$g(\cdot)$
- $\mathbf{W}$ – 权重矩阵
- $\mathbf{b}$ – 偏差向量

池化层（续） （了解）

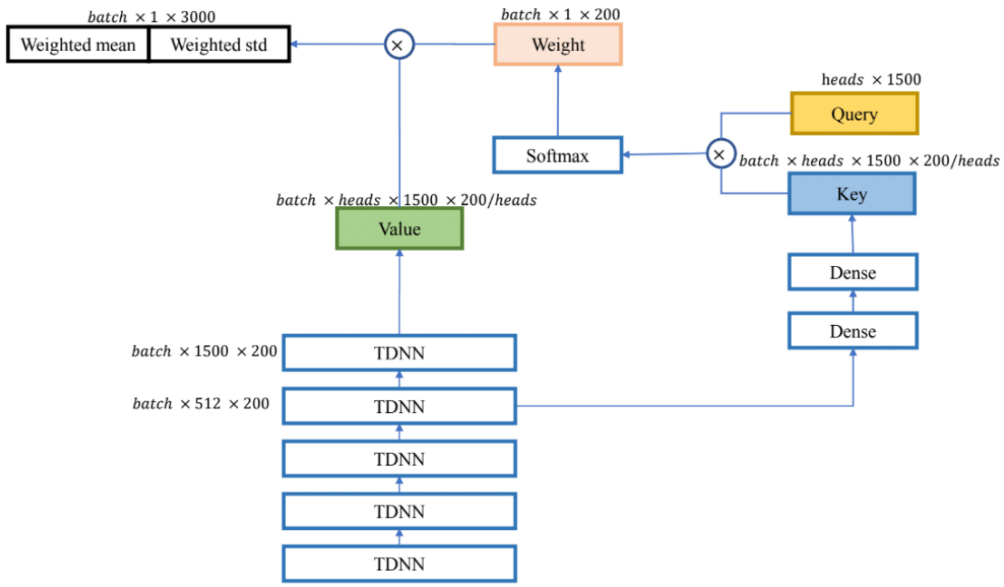
- 基于注意力机制的池化：
  - 通过加权平均令模型更多地关注对说话人识别任务更重要的帧。

$$\boldsymbol{\mu} = \frac{1}{T}\sum_{t=1}^{T}\mathbf{h}_t = \sum_{t=1}^{T}\left(\frac{1}{T}\right)\cdot\mathbf{h}_t = \sum_{t=1}^{T}\alpha_t\cdot\mathbf{h}_t$$

$$\sigma = \sqrt{\frac{1}{T}\sum_{t=1}^{T}\mathbf{h}_t\odot\mathbf{h}_t - \boldsymbol{\mu}\odot\boldsymbol{\mu}} = \sqrt{\frac{1}{T}\sum_{t=1}^{T}\left(\frac{1}{T}\right)\cdot\mathbf{h}_t\odot\mathbf{h}_t - \boldsymbol{\mu}\odot\boldsymbol{\mu}} = \sqrt{\frac{1}{T}\sum_{t=1}^{T}\alpha_t\cdot\mathbf{h}_t\odot\mathbf{h}_t - \boldsymbol{\mu}\odot\boldsymbol{\mu}}$$

池化层（续） （了解）

- 自注意力池化：
  - 找到一组权重，每个帧对应一个权重，加权求和；
  - 类似于Transformer中基于{query，key，value}的自注意力池。

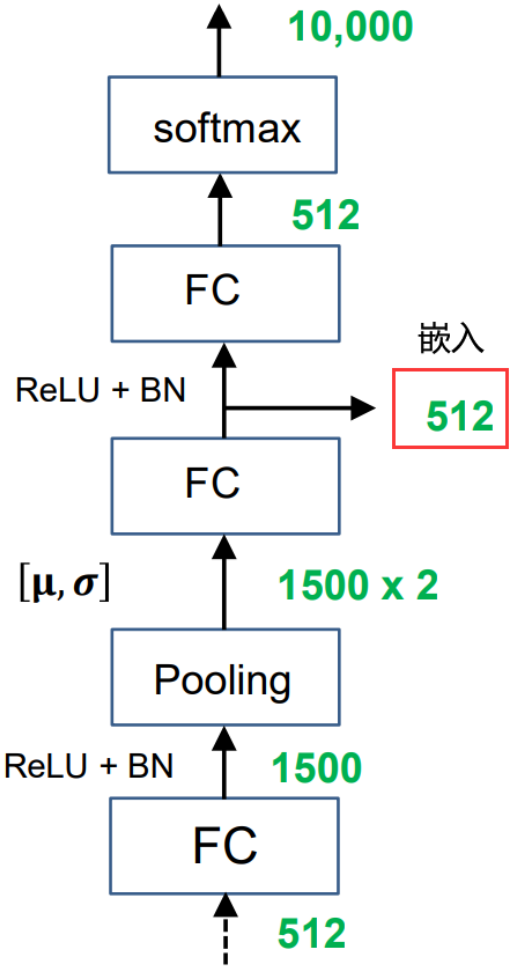


嵌入提取

- 说话人嵌入表征是一个固定长度的向量，它捕捉说话人的长期声纹特征；
- 聚合特征通过若干个全连接层进行处理；
- 将第一个线性层的输出作为嵌入表征。

$$\boldsymbol{\phi} = \mathbf{W}^{\mathrm{T}}[\boldsymbol{\mu}, \sigma]$$

$$\boldsymbol{\mu} = \frac{1}{T}\sum_{t=1}^{T}\mathbf{h}_t \qquad \sigma = \sqrt{\frac{1}{T}\sum_{t=1}^{T}\mathbf{h}_t \odot \mathbf{h}_t - \boldsymbol{\mu}\odot\boldsymbol{\mu}}$$

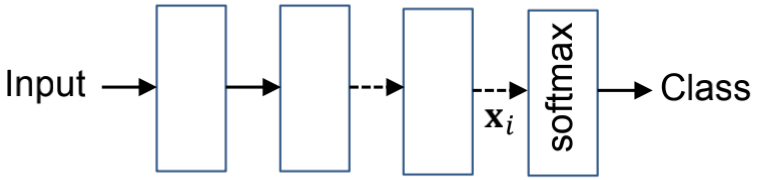


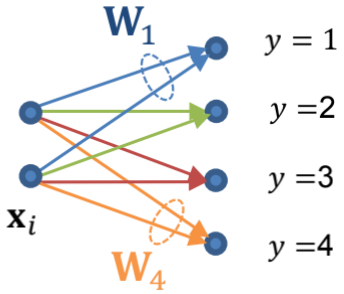
多类分类

- 神经网络的输出层被构造为每个节点代表一个类，其中 $y \in \{1,2,\ldots,C\}$，C 表示训练集中说话人的数量；
- 使用 softmax 函数（归一化指数函数）激活输出层。

$$l_j(\mathbf{x}_i;\mathbf{W},\mathbf{b}) = \frac{\exp\left(\mathbf{W}_j^{\mathrm{T}}\mathbf{x}_i + b_j\right)}{\sum_{c=1}^{C}\exp\left(\mathbf{W}_c^{\mathrm{T}}\mathbf{x}_i + b_c\right)}$$

- $\mathbf{x}_i$ – 第i个训练样本的深度特征
- $\mathbf{W}_j$ – 权重矩阵$\mathbf{W}$（输出前馈层）的第j列





交叉熵损失

- 交叉熵损失用于衡量网络输出和标签之间的差异：

$$L = -\frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{C} 1\{y_i = j\} \cdot \log l_j(\mathbf{x}_i; \mathbf{W}, \mathbf{b})$$

$$= -\frac{1}{N}\sum_{i=1}^{N} \log l_{y_i}(\mathbf{x}_i; \mathbf{W}, \mathbf{b})$$

  - $\mathbf{x}_i$ – 第i个训练样本的深度特征
  - $\mathbf{W}_j$ – 权重矩阵$\mathbf{W}$（输出前馈层）的第j列
  - y_i – 第i个样本的类标签
  - C – 类的数量
  - N – 批量大小
  - $1\{y_i = j\}$ – 指示函数。如果第i个样本属于第j个说话者则取值为1，否则为0。

改进的softmax 函数（了解）

- 传统的softmax输出层的学习嵌入仅针对类间分离进行了优化，而未考虑类内紧凑性。
- 可以修改 Softmax 函数以促进类内紧凑性，例如，angular softmax和additive-margin softmax。

- Let the bias $b_j = 0$,
- Weight normalization $\|\mathbf{W}_j\| = 1$
- Feature normalization $\|\mathbf{x}_i\| = s$
- The cross-entropy loss becomes:

$$\mathbf{W}_j^{\mathrm{T}}\mathbf{x}_i = \|\mathbf{W}_j\|\|\mathbf{x}_i\| \cdot \cos\theta_{y_i}$$

$$L = -\frac{1}{N}\sum_{i=1}^{N}\log\frac{\exp\left(s \cdot \cos\theta_{y_i}\right)}{\sum_{c=1}^{C}\exp\left(s \cdot \cos\theta_{y_c}\right)}$$

数据增广（了解）

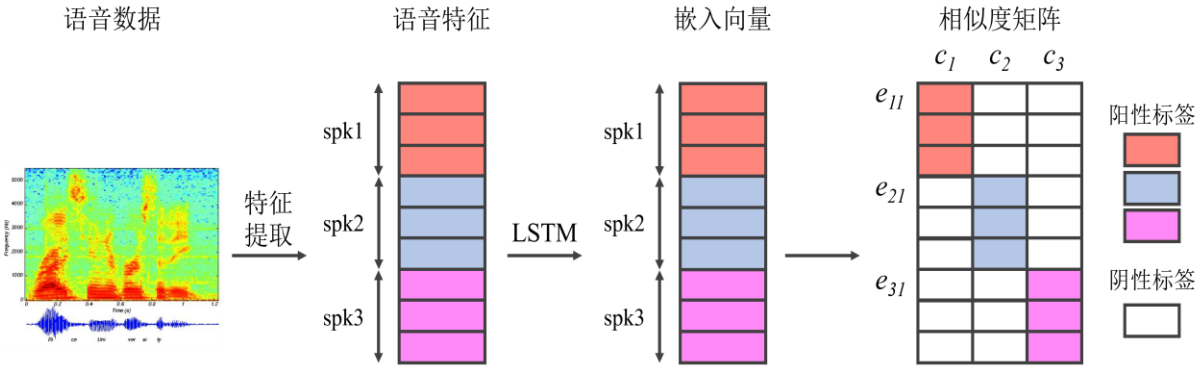
- 添加噪音和混响
  - 使用增广数据集（例如：MUSAN等）和房间脉冲响应
  - MUSAN数据集（来自12种语言的噪音、音乐、语音）
- 语音编码
- 说话人增强
  - 音频速度扰动
  - 使用速度因子α，$x(\alpha^t)$的时间扭曲

第六章　声纹识别

- 6.1 声纹识别概述
  - 6.1.1 声纹识别的基本概念
  - 6.1.2 声纹识别方法的回顾
  - 6.1.3 声纹识别的典型应用
- 6.2 传统声纹识别算法（GMM-UBM）
- 6.3 基于深度学习的声纹识别算法
- 6.4 声纹识别技术的展望（了解）

端到端声纹识别

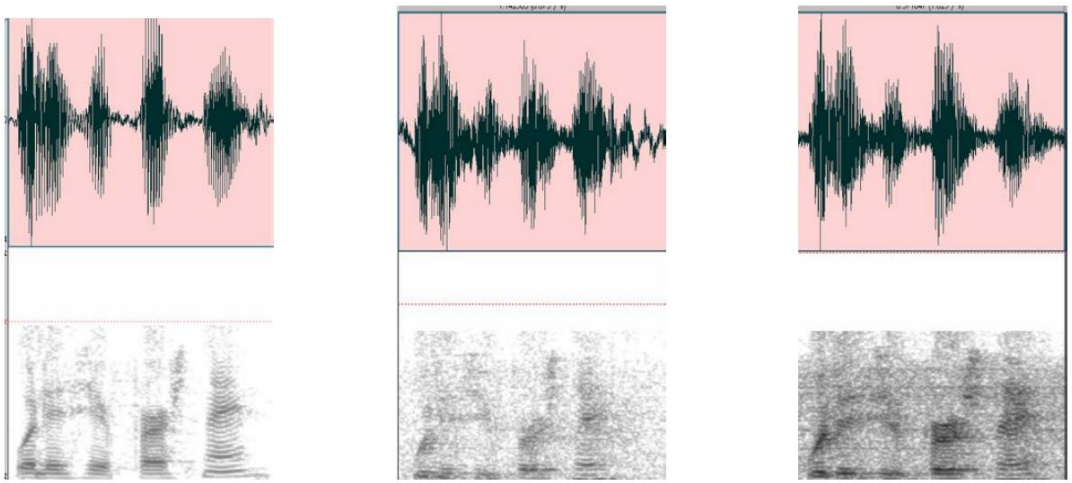
- Generalized End-to-End（GE2E）
  - 分别提取不同说话人的多条语音的嵌入向量；
  - 计算不同嵌入向量间的相似度，并进行线性变换，来构造相似度矩阵。在相似度矩阵中，同说话人语音嵌入间的相似度要尽可能大，不同说话人语音嵌入间的相似度要尽可能小。以此为依据可以设计损失函数来优化模型参数。



基于GE2E的声纹识别模型示例

挑战 --- 跨信道

- 跨信道会严重降低声纹识别的性能
- 信道变量类型
  - 采录设备
  - 传输信道
  - 采录位置
  - ……

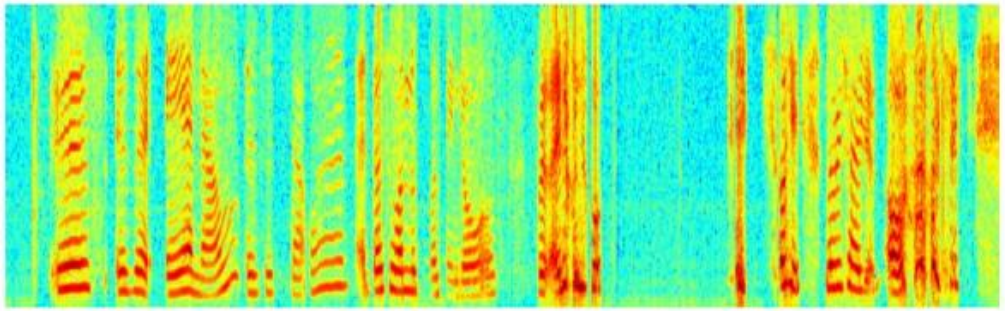


不同设备（相同原始语音）的语谱图

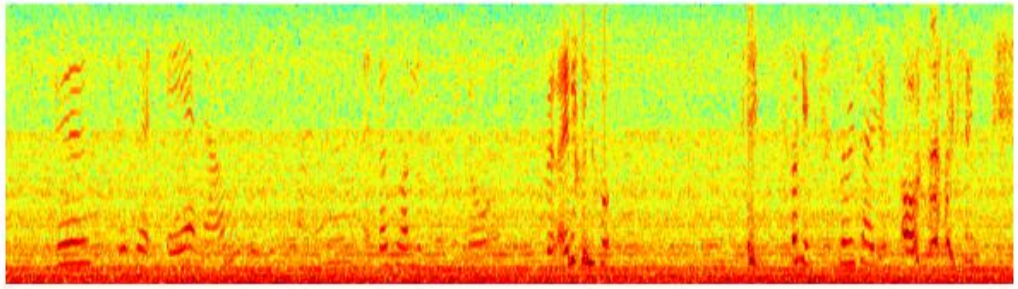
挑战 --- 复杂声学场景

- 加性噪声
  - 音乐
  - 杂音
  - 白噪声
  - ……
- 混响

Original utterance

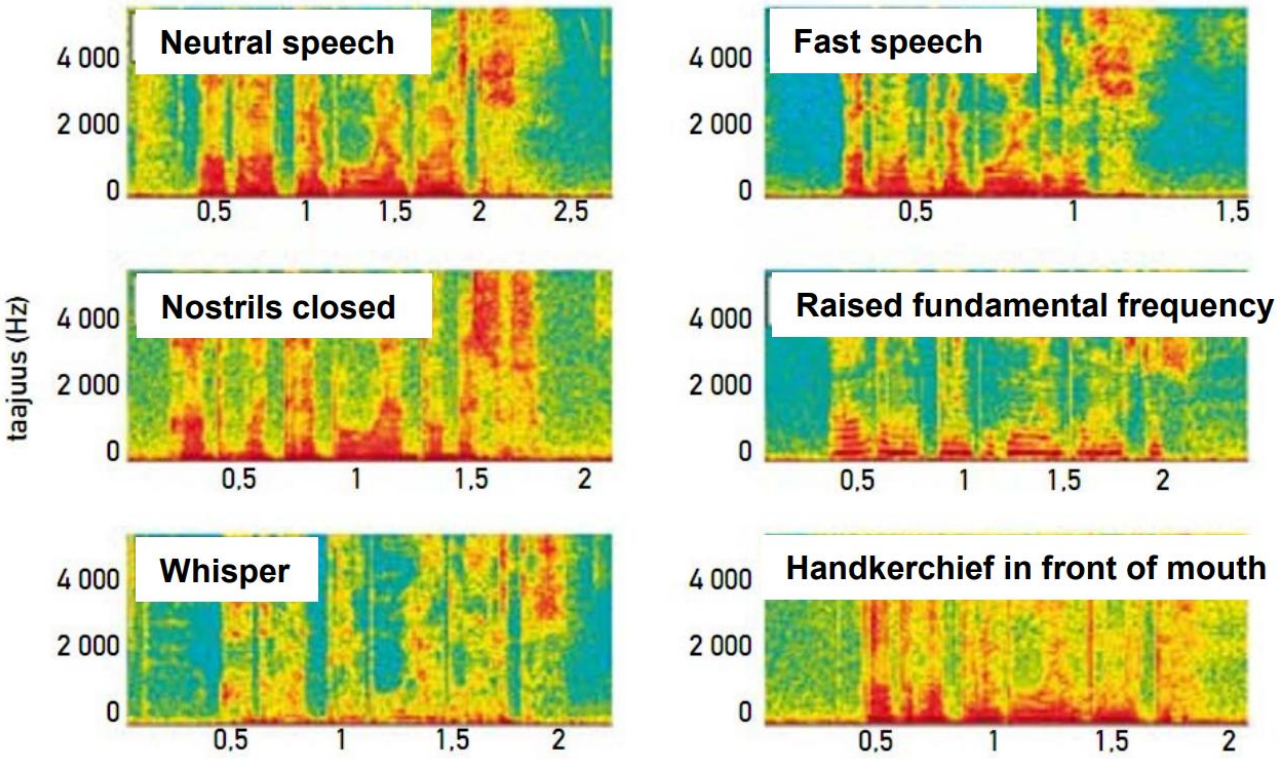


Simulated additive noise, signal-to-noise-ratio (SNR) = 6 dB



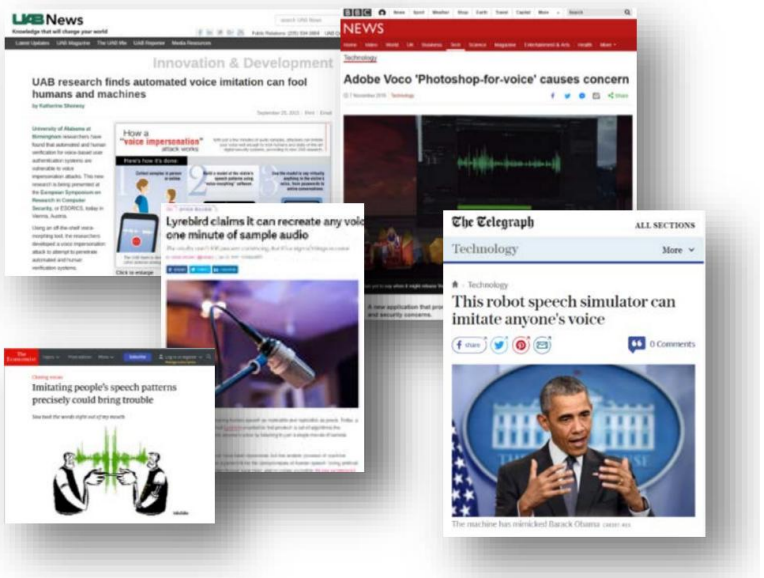
挑战 --- 时变及说话风格

- 相同的说话人和相同的内容，由于说话风格、健康状况、发声器官等变化可能产生高度不同的声学特征。

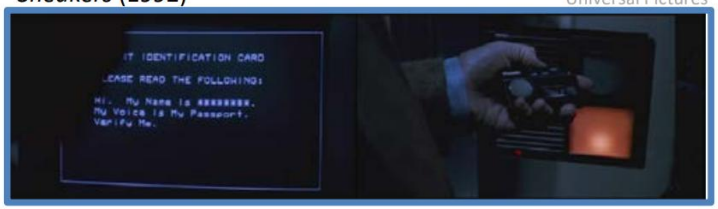


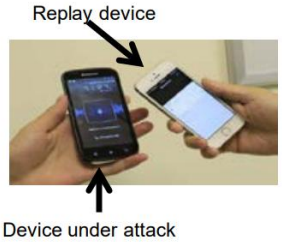
挑战 --- 声纹欺诈攻击

- 语音合成
- 语音转换
- 录音重放
- ……



Sneakers (1992) Universal Pictures





声纹识别前沿研究（1/3）

2023年“声纹识别研究与应用学术研讨会日程安排

大会主席：　天津大学教授　王龙标
　　科院声学所研究员　张鹏远

2023年10月21日　周六8：30–18：00

08:30–09:00	登记报道	地点:天津海河假日酒店5层宴会厅
09:00–09:10	开幕式	地点:天津海河假日酒店5层宴会厅

Session 1　主持人：王龙标

09:10–09:40	主旨报告	报告人：党建武　天津大学 教授 慧言科技（天津）有限公司　首席科学家 主题：说话人语音特征的编解码与识别
09:40–10:10	主旨报告	报告人：山世光　中国科学院计算技术研究所 主题：视觉讲话人检测与唇语识别研究
10:10–10:30	邀请报告	报告人：李明　昆山杜克大学 副教授 主题：时变与非言语语音声纹识别

声纹识别机理

多模态生物特征识别

声纹识别前沿研究（2/4）

2024“声纹识别研究与应用学术研讨会”日程安排

Session 1：说话人识别 1　主席：钱彦旻				
1	9:20-9:40	何亮	清华大学/新疆大学	大规模高精度可解释的声纹识别
2	9:40-10:00	王东	清华大学	Neural Scoring, Not Embedding
3	10:00-10:20	王帅	深圳市大数据研究院	说话人建模在目标语音提取中的应用
10:20-11:20　学生 POSTER1、合影、茶歇				
Session 2：说话人日志 主席：杜俊				
4	11:20-11:40	杜俊	中国科学技术大学	质量感知的音视频说话人日志
5	11:40-12:00	张超	清华大学	基于序列化输出神经聚类的端到端说话人标识语音识别
6	12:00-12:20	程高峰	中国科学院声学研究所	多人对话场景中短语音说话人日志技术研究

声纹识别前沿研究（3/4）

Session 3：机器声纹 主席：张卫强				
7	13:30-13:50	张卫强	清华大学	从语音声纹到机器声纹
8	13:50-14:10	钱彦旻	上海交通大学	Recent Advances in Machine Voiceprint for Robust Machine Anomalous Sound Detection
9	14:10-14:30	关键	哈尔滨工程大学	无监督工业异音检测难点与挑战及研究进展
10	14:30-14:50	马萍	新疆大学	基于声纹检测技术的机械设备故障诊断研究

Session 5：圆桌论坛 主席：王龙标

时间：16:30-17:30

主题：大模型时代下的声纹处理技术的机遇和挑战

学术界嘉宾：何亮、李明、钱彦旻

工业界嘉宾：李科、穆向禹、张晴晴

声纹识别前沿研究（4/4）

Session 6：说话人识别 2 主席：何亮 日期：2024.10.20				
13	8:30-8:50	李明	昆山杜克大学	面向时间漂移、预训练模型和自监督学习的鲁邦声纹识别
14	8:50-9:10	洪青阳	厦门大学	自监督预训练声纹特征提取研究
15	9:10-9:30	张晓雷	西北工业大学	鲁棒声纹识别的对抗防御
9:30-10:00 茶歇				
Session 7：说话人匿名化及伪造检测 主席：李明				
16	10:00-10:20	王龙标	天津大学	基于信息解耦的言语交互意图理解大模型
17	10:20-10:40	武执政	香港中文大学（深圳）	语音虚假信息检测
18	10:40-11:00	苗晓晓	新加坡理工大学	从说话人匿名化技术到隐私友好的合成语音数据集

语音信息处理的技术展望



- 深度意图理解的语音/文本多模态人机交互
- 低资源语言的性能瓶颈
- 具身听觉智能/具身多模态智能
- 低能耗的通用语音交互智能

期末考试

时间：11月11日（周三） 15:25-17:25
考场：3022244110-3024244236（46-A110）
3024244238之后及其他 （46-A120）
方式：闭卷