第六章　声纹识别

第六章　声纹识别

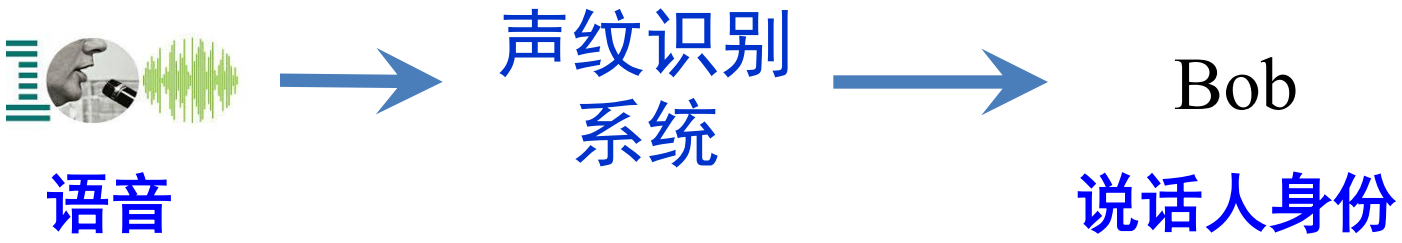
- 6.1 声纹识别概述
- 6.2 传统声纹识别算法（GMM-UBM）
- 6.3 基于深度学习的声纹识别算法
- 6.4 声纹识别技术的展望

第六章　声纹识别

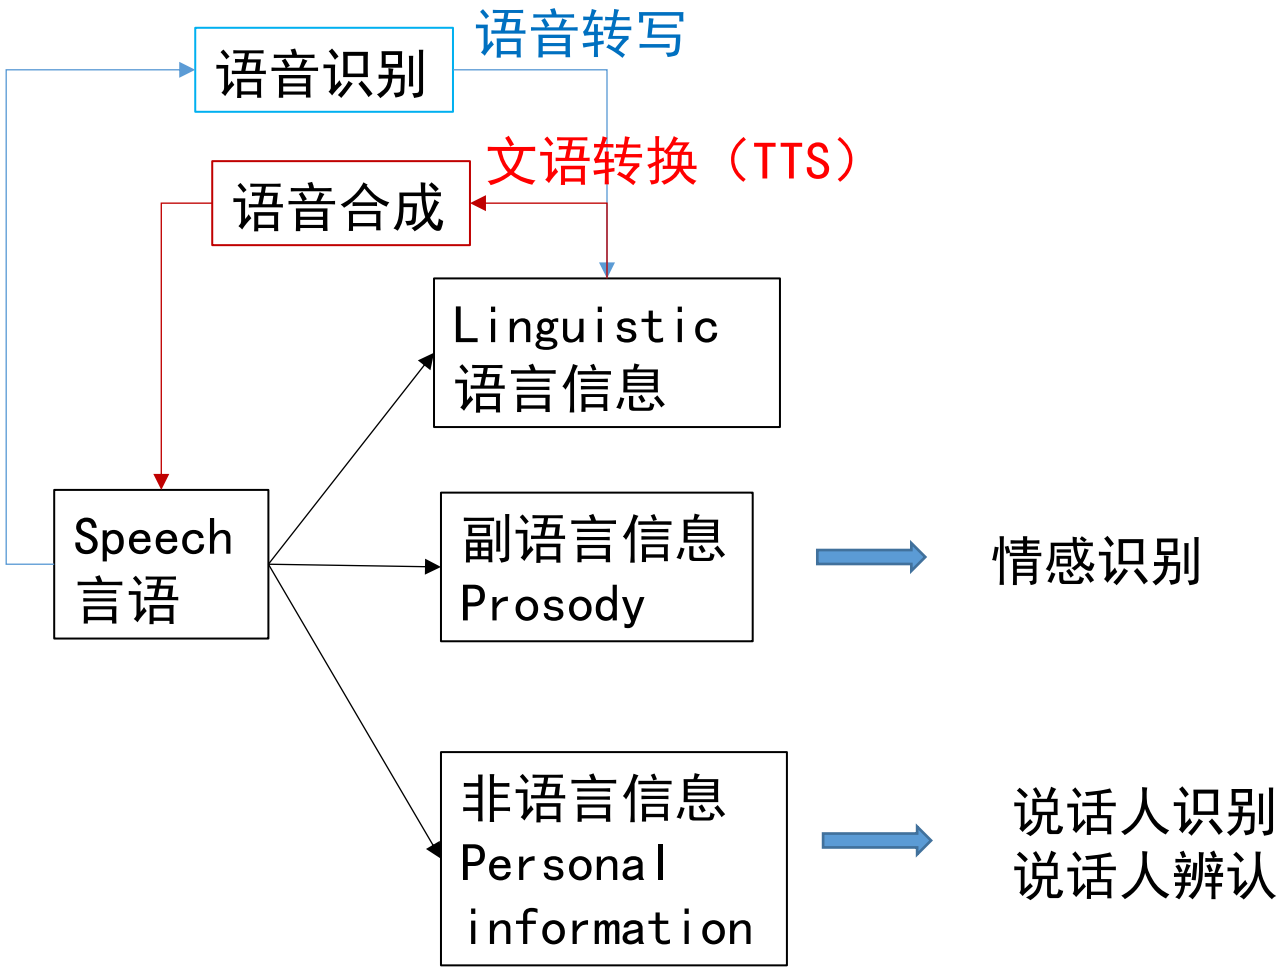
- 6.1 声纹识别概述
  - 6.1.1 声纹识别的基本概念（基本概念）
  - 6.1.2 声纹识别方法的回顾（了解、基本概念）
  - 6.1.3 声纹识别的典型应用（了解）
- 6.2 传统声纹识别算法（GMM-UBM）
- 6.3 基于深度学习的声纹识别算法
- 6.4 声纹识别技术的展望

什么是声纹识别？

- 定义：
  - 声纹识别（说话人识别）作为生物识别（指纹识别、掌纹识别、人脸识别和虹膜识别等）的一种，是根据说话人的声音特性进行身份辨识的任务。
  - 输入：语音
  - 输出：说话人身份

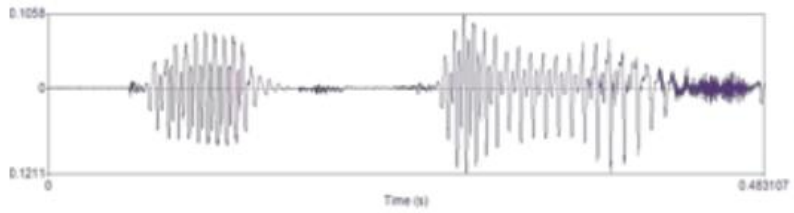


语音中语言、副语言和非语言信息的感知（回顾）



与其他语音处理方法的区别

- 语音识别：输出语音携带的文本信息；
- 情感识别：输出语音携带的情感信息；
- 语种识别：输出语音所属的语种；
- 语音合成：由文本输出语音；
- 声纹识别：输出语音携带的说话人身份信息。



"I am Bob"

Identity: Bob

Message: "I am Bob"

English, Male, Happy, Middle age, etc.

说话人身份信息相关的语音属性

- 低级属性：与发声器官的生理方面相关
  - 声道频谱；
  - 共振峰轨迹。
- 高级属性：与说话方式的行为差异相关
  - 韵律；
  - 口音；
  - 话语中词的选择。

声纹识别的分类

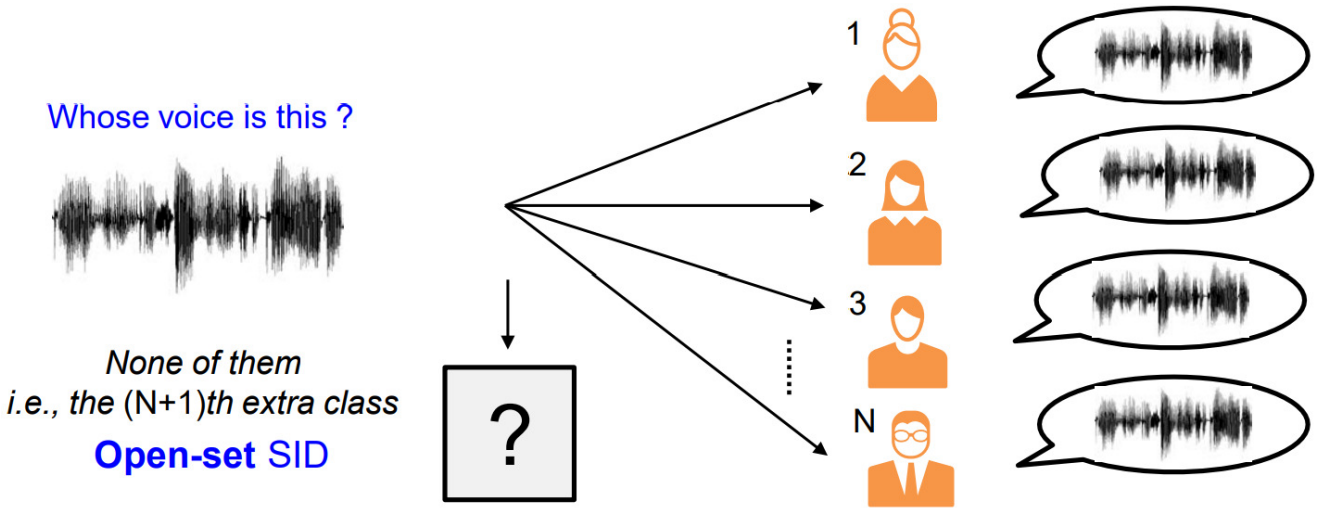
- 按照输入的模式
  - 文本相关的说话人识别（Text-dependent）
    - 注册和测试话语共享（至少部分）相同的内容；
    - 目的是分析给定语音语境下的说话人特征；
    - 更高的性能。
  - 文本无关的说话人识别（Text-independent）
    - 注册和测试话语可以使用任意文本（甚至不同的语言）；
    - 不使用关于口语内容的先验信息；
    - 更高的便利性。

声纹识别的分类（续）

- 按照输出的模式
  - 说话人辨认（Speaker Identification）
    - 判定待识别说话人来自注册集中的哪个说话人；
    - 1：N 语音的对比。
  - 说话人确认（Speaker Verification）
    - 判定待识别语音是否来自注册集中的某个说话人；
    - 成对或1：1语音的对比。

声纹识别的分类（续）

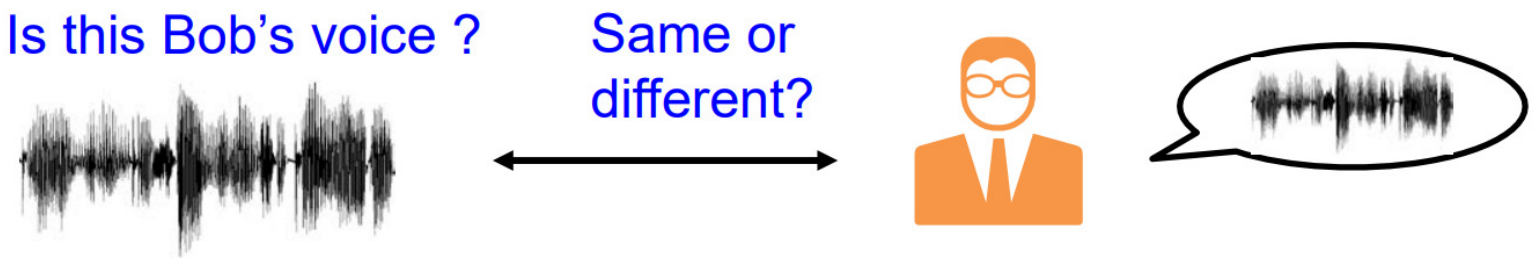
- 说话人辨认（Speaker Identification）
  - 判定待识别说话人来自注册集中的哪个说话人；
  - 来自未知说话者的语音样本与一组标记样本进行比较，未知说话人被识别为语音与输入语音样本最匹配的说话人。



确定未知说话人是否是一组人中的特定人

声纹识别的分类（续）

- 说话人确认（Speaker Verification）
  - 判断说话人身份是否与其声明的身份相符；
  - 由未知说话人提出身份声明。来自说话人的语音样本与声称身份的注册样本进行比较。如果匹配足够好（即通过给定的阈值），则系统接受身份声明。
  - 辨认任务可以分解为N对说话人的比较。验证任务更为基础。



声纹识别评价指标

- 等错误率（Equal Error Rate）
  - 调整阈值，使得误拒绝率(False Rejection Rate，FRR)等于误接受率 (False Acceptance Rate，FAR)，此时的FAR与FRR的值称为等错误率。
  - 误拒绝率(False Rejection Rate，FRR)：
    - 被错误拒绝的有效身份声明的比例。

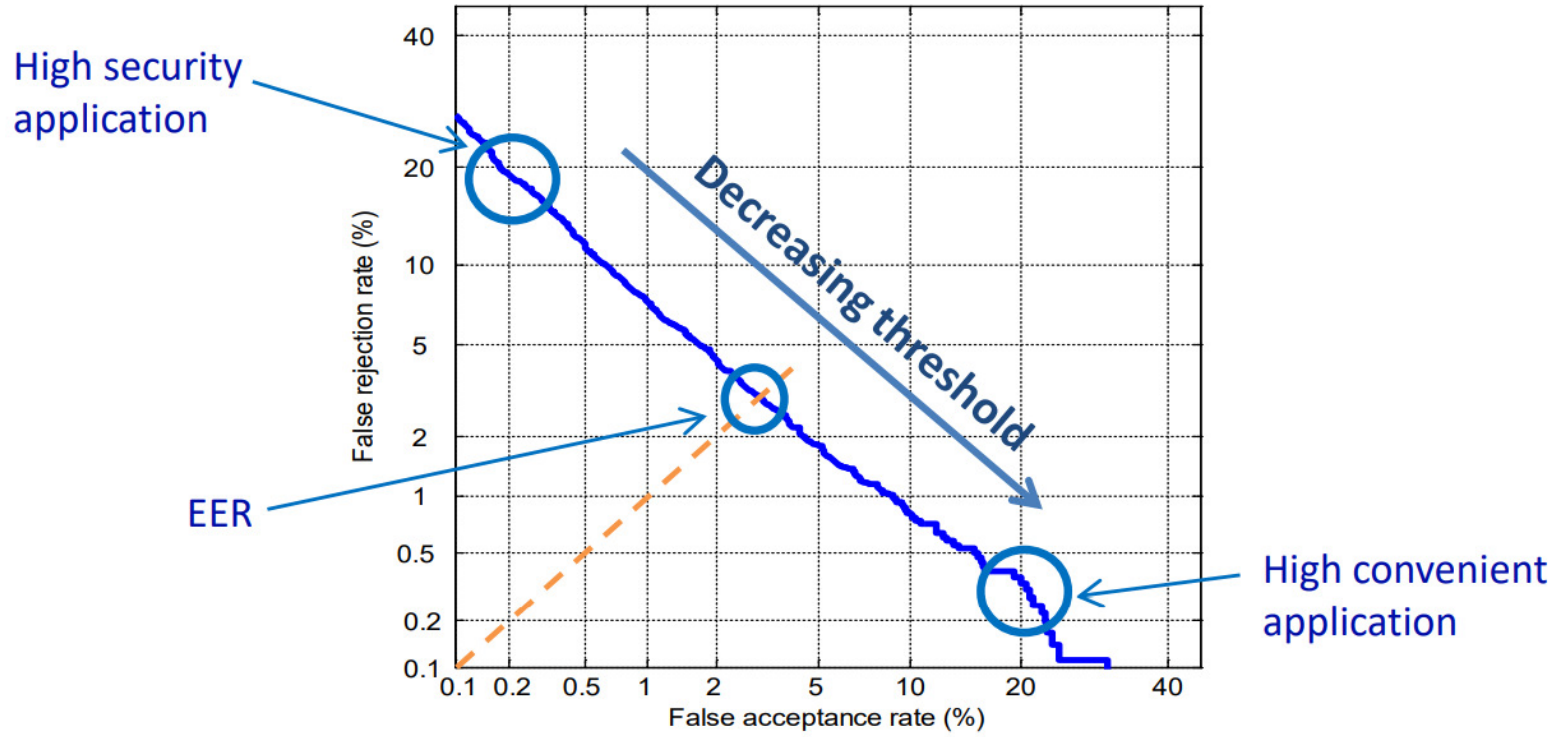
$$FRR = \frac{\text{本该匹配成功却被判匹配失败的次数}}{\text{总的匹配成功次数}}$$

  - 误接受率 (False Acceptance Rate，FAR)：
    - 错误接受冒名顶替者身份声明的比例。

$$FAR = \frac{\text{本该匹配失败却被判匹配成功的次数}}{\text{总的匹配失败次数}}$$

声纹识别评价指标（续）

- 等错误率（Equal Error Rate）
- 检测-错误-均衡曲线（Detection Error Tradeoff: DET）

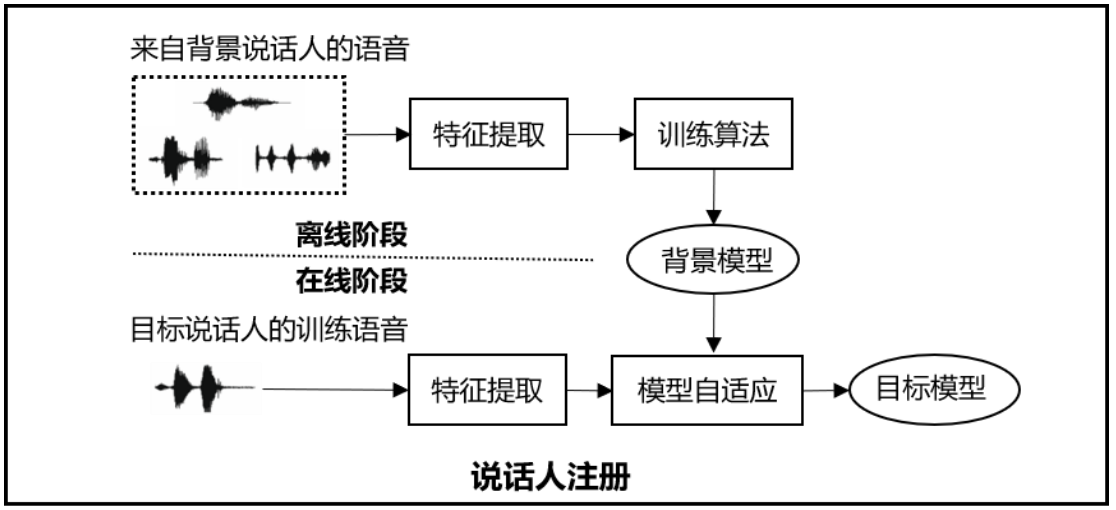


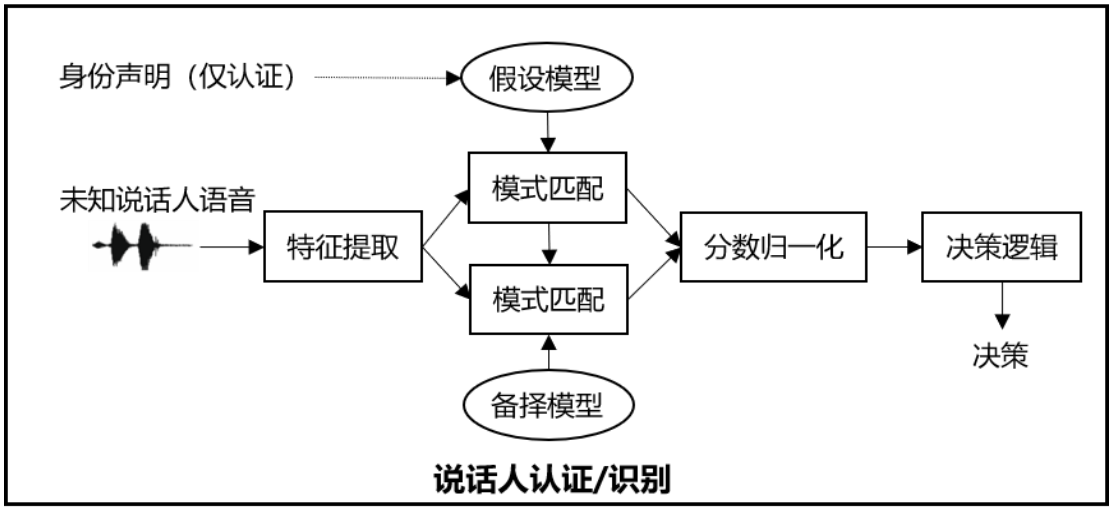
第六章　声纹识别

- 6.1 声纹识别概述
  - 6.1.1 声纹识别的基本概念
  - 6.1.2 声纹识别方法的回顾
  - 6.1.3 声纹识别的典型应用
- 6.2 传统声纹识别算法（GMM-UBM）
- 6.3 基于深度学习的声纹识别算法
- 6.4 声纹识别技术的展望

声纹识别系统基本框架（掌握）

- 特征提取
  - 将原始语音信号转换为包含说话人信息为主的特征向量序列。
- 注册
  - 用以与测试段对照，判断访问者是否与其声明身份相符。
- 测试
  - 从待测语音中提取特征向量，并与每个注册说话者的存储模型进行比较。
  - 根据相似度（或似然度）值做出识别决策。





GMM-UBM （基本概念）

- Gaussian mixture model (GMM)
  - 为目标说话人的声纹特征建模；
  - GMM将空间分布的概率密度用多个高斯概率密度函数的加权来拟合，可以平滑地逼近任意形状的概率密度函数；
  - 是一个易于处理的参数模型，对实际数据具备较强的表征能力。

$$P(\mathbf{x}|\theta) = \sum_{m=1}^{M} c_m N(\mathbf{x}|\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m)$$

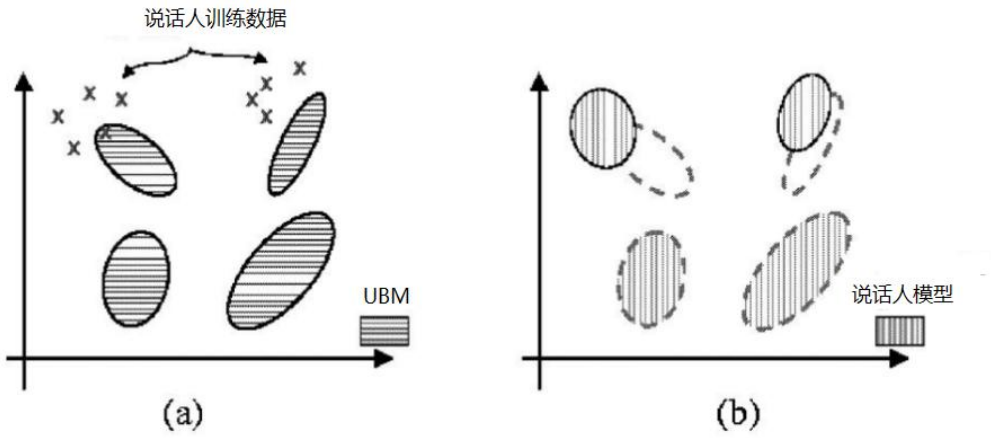
$$N(\mathbf{x}|\boldsymbol{\mu}_m, \boldsymbol{\Sigma}_m) = \frac{1}{(2\pi)^{D/2}(\boldsymbol{\Sigma}_m)^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_m)^T \boldsymbol{\Sigma}_m{}^{-1}(\mathbf{x}-\boldsymbol{\mu}_m)\right\}$$

GMM-UBM（续） （基本概念）

- Universal Background Model (UBM)
  - 实际场景中每一个说话人的语音数据很少，导致无法训练出高效的GMM模型；
  - 在复杂的声学环境和信道场景下，训练GMM模型的语音与测试语音存在失配的情况；
  - 为解决上述问题：
    - 使用EM算法对说话人无关的领域模型或通用背景模型(UBM)进行训练；
    - 基于UBM通过自适应算法（如最大后验概率：MAP）来得到目标说话人模型。

GMM-UBM（续） （基本概念）

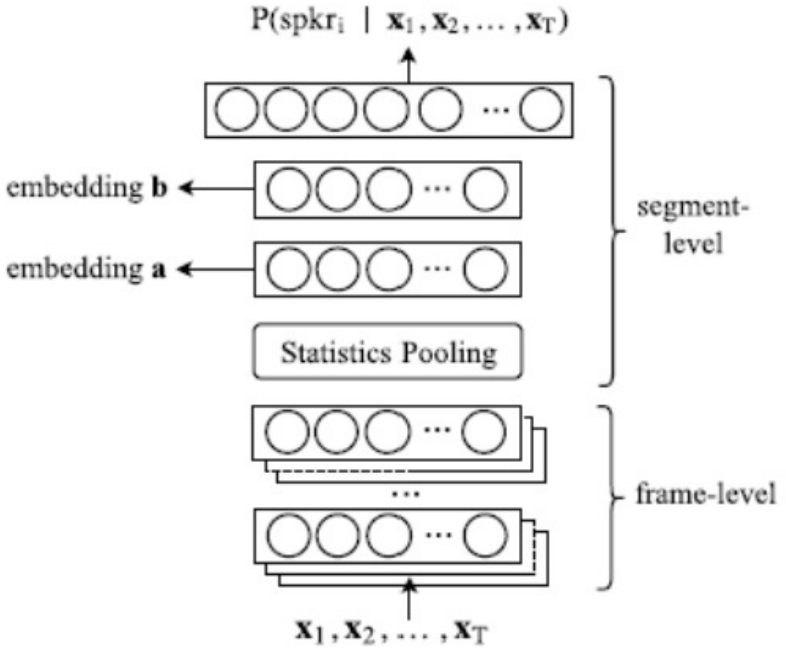
- 使用MAP的原因
  - UBM是初始模型，可以减少注册新说话人所需的语音发生的持续时间/数量（导出依赖于说话人的GMM参数）；
  - 由于说话人相关的GMM和说话人无关的UBM具有相同的模型复杂度，因此可以计算更好的对数似然分数；
  - 使用高斯选择可以更快。



MAP算法自适应

X-vector （基本概念）

- 目的
  - 使用监督方式训练的深度神经网络导出句子级别的嵌入表示。
- X-vector提取器
  - TDNN：经过训练以在输出层区分说话人；
  - 统计池化层：计算均值和标准差；
  - 段的统计信息被传递到另一个隐层以产生嵌入；
  - 数据增广是必要的。



[Source: Snyder et al, 2017]

第六章　声纹识别

- 6.1 声纹识别概述
  - 6.1.1 声纹识别的基本概念
  - 6.1.2 声纹识别方法的回顾
  - 6.1.3 声纹识别的典型应用
- 6.2 传统声纹识别算法（GMM-UBM）
- 6.3 基于深度学习的声纹识别算法
- 6.4 声纹识别技术的展望

第六章　声纹识别

- 6.1 声纹识别概述
  - 6.1.1 声纹识别的基本概念
  - 6.1.2 声纹识别方法的回顾
  - 6.1.3 声纹识别的典型应用
- 6.2 传统声纹识别算法（GMM-UBM）
  （基本概念）
- 6.3 基于深度学习的声纹识别算法
- 6.4 声纹识别技术的展望

特征提取

- 目的
  - 保留说话人信息；
  - 去除噪声和其他干扰信息。
- 声学特征
  - 梅尔频率倒谱系数（MFCC）
  - 线性预测倒谱系数（LPCC）
- 完整的特征提取前端还包括
  - 语音活动检测（丢弃非语音帧）
  - 后处理（Cepstral Mean Normalization等）

基于GMM的说话人建模

- 注册
  - 说话人模型通过来自该说话人的注册语音构建；
  - 每个注册语音X是一个由特征提取前端生成的特征向量序列$\{\mathbf{x}_t\}_{t=1}^{T}$。

$$p(\mathbf{x}|\theta)=\sum_{k=1}^{K} w_k \mathrm{N}\left(\mathbf{x}|\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k\right)$$

  - 其中， K表示高斯分量的数量；
  - 集合$\theta=\{\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k,w_k\}_{k=1}^{K}$表示分布的参数；
  - 权重w_k，对于所有的k值，其和总为1。

识别（辨认或确认）

- 测试语音与说话人模型的匹配程度被视为平均对数似然，如下所示：

$$s(Y|\theta)=\frac{1}{T}\sum_{t=1}^{T}\log p(\mathbf{y}_t|\theta)$$

- 对于辨认（Identification）任务，选择得分最高的说话人模型。
- 对于验证（Verification）任务，决策基于以下形式的对数似然比

$$\Lambda(Y)=s(Y|\theta)-s(Y|\theta_{bg})$$

最大后验（MAP）自适应

- 调整来自 UBM 的所有参数（权重、均值向量和协方差矩阵）。
  - 计算语音帧到混合高斯分量的相似度：

$$\lambda_k(\mathbf{x}_t) = \frac{\mathrm{N}(\mathbf{x}_t \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \cdot w_k}{\sum_{i=1}^{K} \mathrm{N}(\mathbf{x}_t \mid \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \cdot w_i}$$

  - 计算零阶和一阶统计量：

$$N_k = \sum_{t=1}^{T} \lambda_k(\mathbf{x}_t) \qquad F_k = \sum_{t=1}^{T} \lambda_k(\mathbf{x}_t) \cdot \mathbf{x}_t$$

  - 调整参数（如平均向量$\boldsymbol{\mu}_k$）：

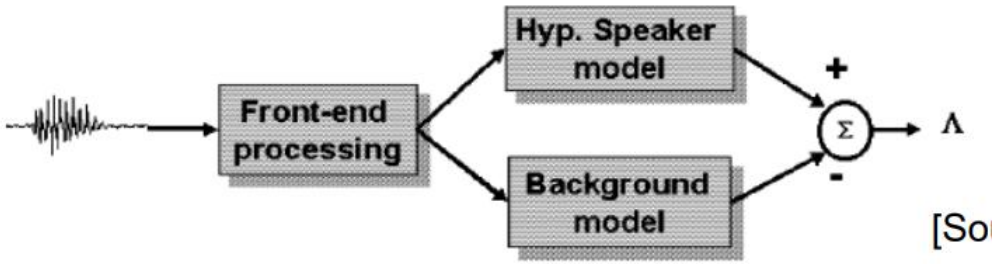
$$\boldsymbol{\mu}'_k = \alpha_k \left(\frac{1}{N_k} F_k \right) + (1 - \alpha_k) \boldsymbol{\mu}_k$$

New information　　UBM mean vector

GMM-UBM识别（掌握）

- 说话人验证（Verification）任务可以被转换为以下两项的似然比测试：
  - 零假设，H0：测试段Y来自假设说话人;
  - 备择假设，H1：测试段Y不是来自假设说话人。

$$\Lambda(Y)=\log\frac{p(Y|H_0)}{p(Y|H_1)}\approx\log\frac{p(Y|\theta_{\text{spk}})}{p(Y|\theta_{\text{UBM}})}=s(Y|\theta_{\text{spk}})-s(Y|\theta_{\text{UBM}})$$



[Source: Reynolds et al, 2000]

GMM-UBM识别（续）（掌握）

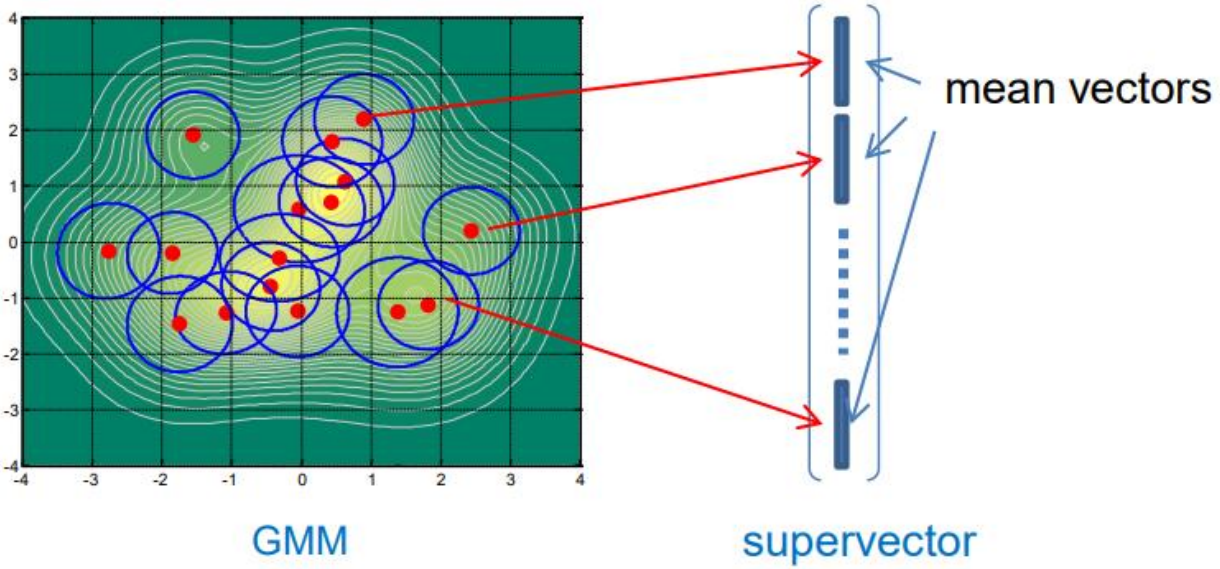
- 给定测试段和说话人模型θ的对数似然相似度：

Speaker GMM or UBM

$$s(Y|\theta)=\frac{1}{T}\sum_{t=1}^{T}\log p(\mathbf{y}_t|\theta)=\frac{1}{T}\sum_{t=1}^{T}\log\sum_{k=1}^{K}w_k\mathrm{N}\left(\mathbf{y}_t|\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k\right)$$

GMM超向量

- GMM-UBM范式
  - 对于每个说话者，基于相同的 UBM 估计说话者相关的 GMM；
  - 说话人相关的 GMM 由均值向量唯一表示，方法是仅调整均值向量，而权重和协方差矩阵保持与 UBM 相同。

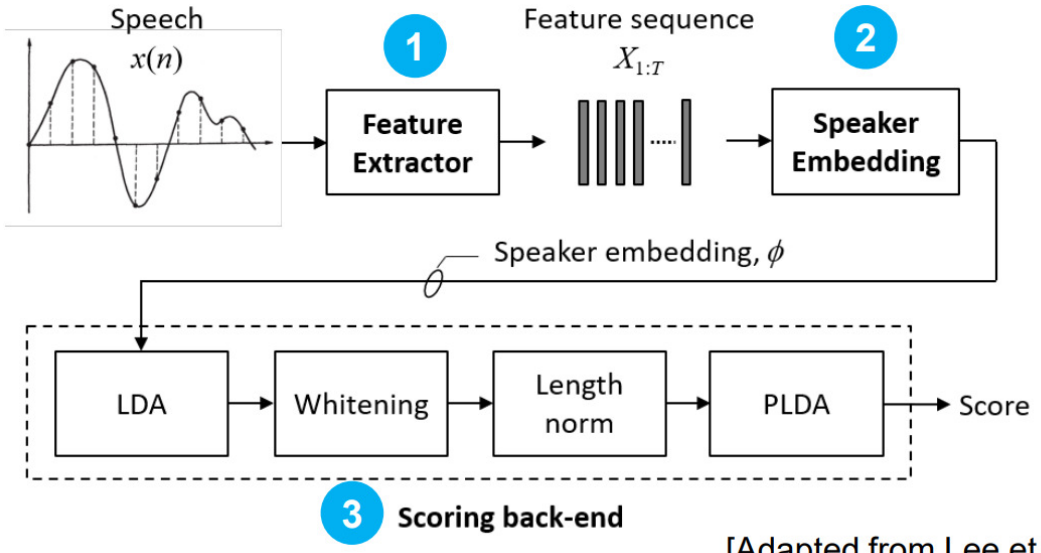


第六章　声纹识别

- 6.1 声纹识别概述
  - 6.1.1 声纹识别的基本概念
  - 6.1.2 声纹识别方法的回顾
  - 6.1.3 声纹识别的典型应用
- 6.2 传统声纹识别算法（GMM-UBM）
- 6.3 基于深度学习的声纹识别算法（基本概念）
- 6.4 声纹识别技术的展望

现代声纹识别系统

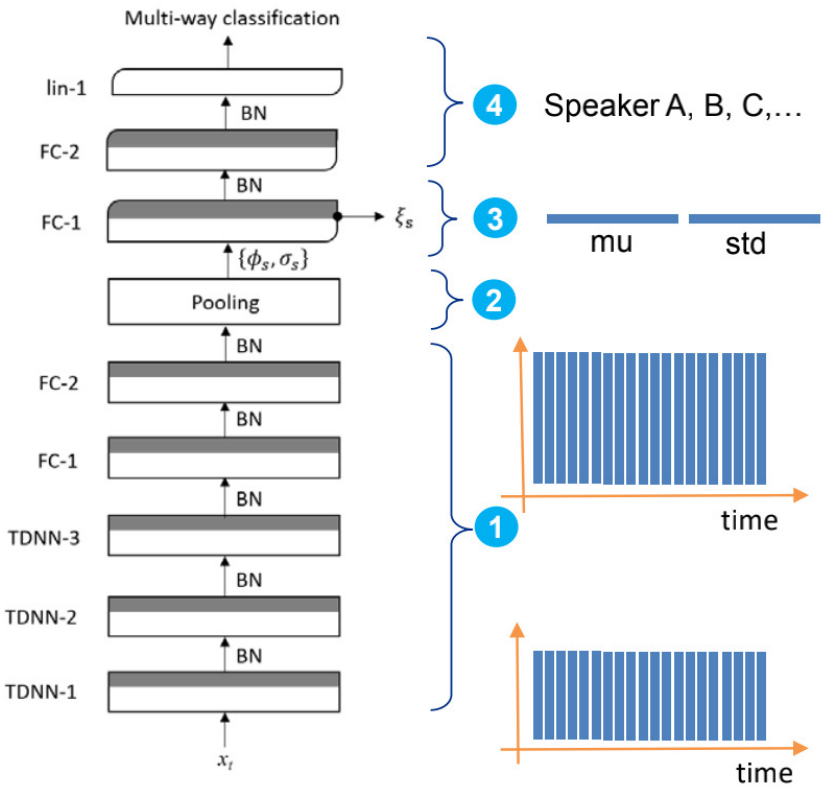
- 现代声纹识别系统主要基于说话人嵌入，包括：
  - 特征提取；
  - 说话人嵌入；
  - 打分。



[Adapted from Lee et al, CSL 2020]

基于x-vector的深度说话人嵌入（掌握）

- x-vector是一个包含四个函数块的深度神经网络
  - 使用多层神经网络实现帧处理器用以提取深度特征，例如延时神经网络(TDNN)
  - 池化层
  - 嵌入提取
  - 基于判别性损失的说话人分类



x-vector提取器的总体架构（掌握）

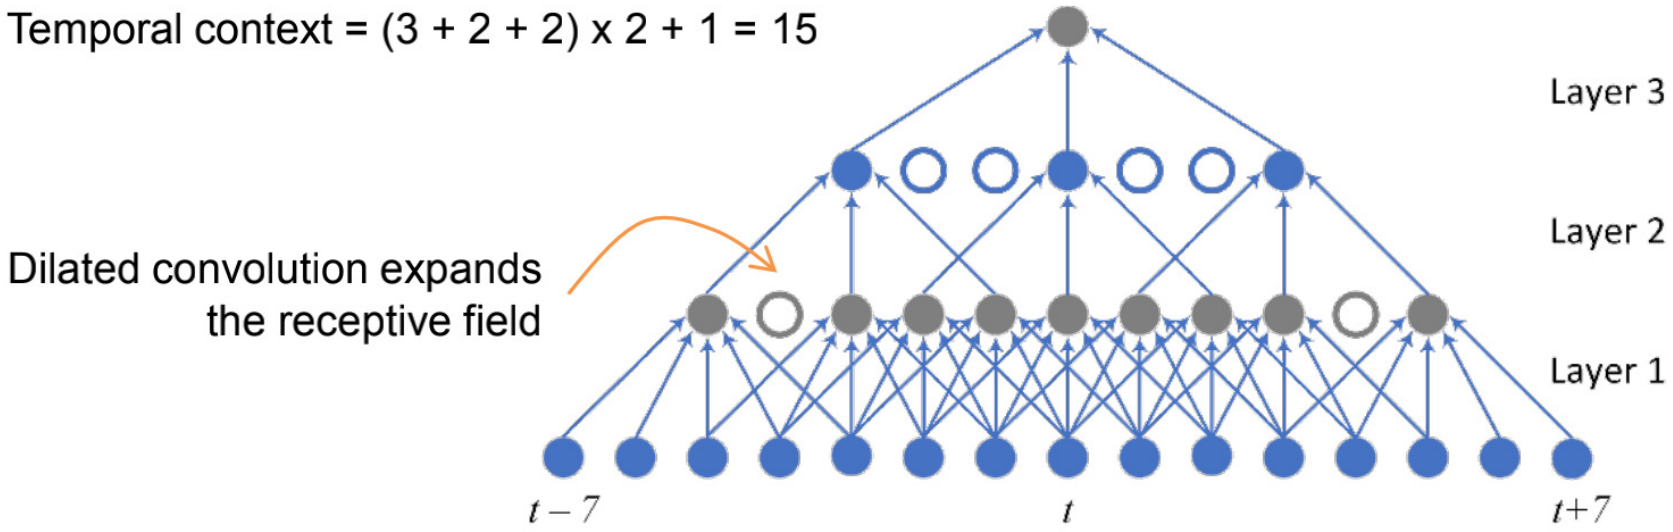
- 深度特征提取
  - 获取一系列声学特征，例如MFCC或对数mel-filterbank系数；
  - 采用多层深度神经网络从声学特征中提取深度说话人特征。
- 时间池化
  - 将特征向量序列转换为单个固定维向量；
  - 时间池化（Temporal pooling）（取特征向量的均值和标准差）是最常见的池化方式；

x-vector提取器的总体架构（续） （掌握）

- 嵌入提取
  - 由若干个相互连接的网络层组成；
  - 其中一层被设计为瓶颈层（Bottleneck layer）；
  - 瓶颈层的输出（非线性层之前）就是x-vector说话人嵌入。
- 说话人分类
  - 根据说话人标签对训练音频进行分类。

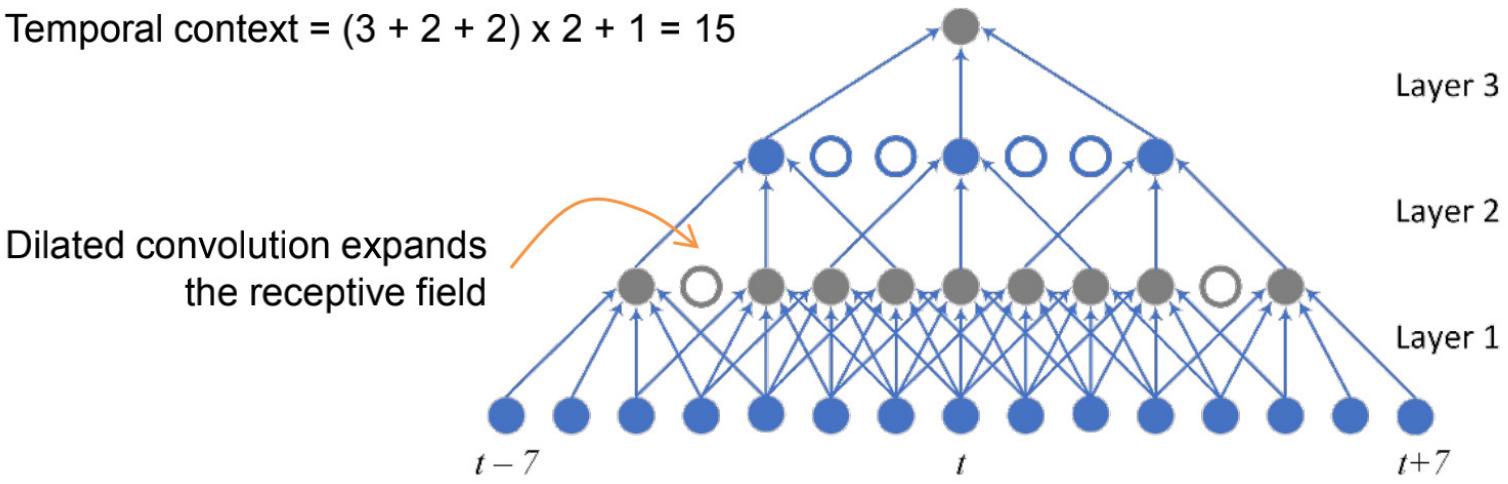
TDNN中的时间上下文

- TDNN对时间上下文信息的提取取决于感受野的宽度
  - 感受野：影响网络特定单元的输入空间区域。



TDNN中的时间上下文（续）

- 更广泛的时间上下文视野：
  - 空洞卷积（通过以一定的步长跳过输入值）；
  - 堆叠更多的空洞一维卷积层。



池化层

- 说话人嵌入通过特征的池化来形成固定长度的表征。
- 时间池化通过平均实现的（计算均值和标准差）。

$$\boldsymbol{\mu} = \frac{1}{T}\sum_{t=1}^{T}\mathbf{h}_t \qquad \sigma = \sqrt{\frac{1}{T}\sum_{t=1}^{T}\mathbf{h}_t \odot \mathbf{h}_t - \boldsymbol{\mu}\odot\boldsymbol{\mu}}$$

$$\mathbf{h}_t = g\left(\mathbf{W}^{\mathrm{T}}\mathbf{f}_t + \mathbf{b}\right)$$

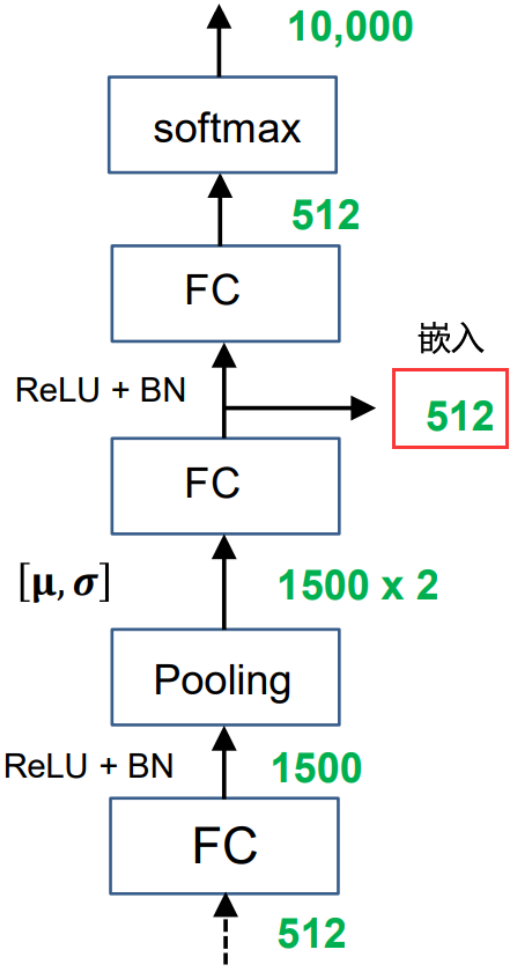
- $\mathbf{h}_t$ – 在第t时刻步变换的特征向量
- $\mathbf{f}_t$ – 前馈层的输入，后跟非线性激活函数$g(\cdot)$
- $\mathbf{W}$ – 权重矩阵
- $\mathbf{b}$ – 偏差向量

嵌入提取

- 说话人嵌入表征是一个固定长度的向量，它捕捉说话人的长期声纹特征；
- 聚合特征通过若干个全连接层进行处理；
- 将第一个线性层的输出作为嵌入表征。

$$\boldsymbol{\phi} = \mathbf{W}^{\mathrm{T}}[\boldsymbol{\mu}, \sigma]$$

$$\boldsymbol{\mu} = \frac{1}{T}\sum_{t=1}^{T}\mathbf{h}_t \qquad \sigma = \sqrt{\frac{1}{T}\sum_{t=1}^{T}\mathbf{h}_t \odot \mathbf{h}_t - \boldsymbol{\mu}\odot\boldsymbol{\mu}}$$

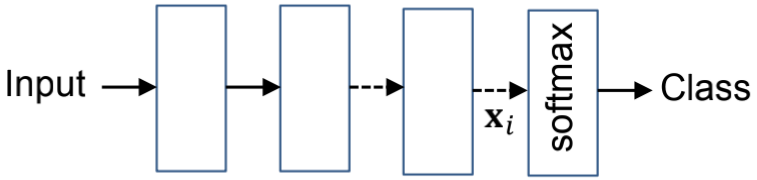


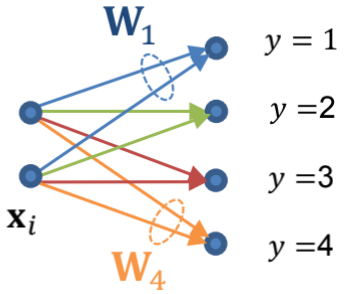
多类分类

- 神经网络的输出层被构造为每个节点代表一个类，其中 $y \in \{1,2,\ldots,C\}$，C 表示训练集中说话人的数量；
- 使用 softmax 函数（归一化指数函数）激活输出层。

$$l_j(\mathbf{x}_i;\mathbf{W},\mathbf{b}) = \frac{\exp\left(\mathbf{W}_j^{\mathrm{T}}\mathbf{x}_i + b_j\right)}{\sum_{c=1}^{C}\exp\left(\mathbf{W}_c^{\mathrm{T}}\mathbf{x}_i + b_c\right)}$$

- $\mathbf{x}_i$ – 第i个训练样本的深度特征
- $\mathbf{W}_j$ – 权重矩阵$\mathbf{W}$（输出前馈层）的第j列





交叉熵损失

- 交叉熵损失用于衡量网络输出和标签之间的差异：

$$L = -\frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{C} 1\{y_i = j\} \cdot \log l_j(\mathbf{x}_i; \mathbf{W}, \mathbf{b})$$

$$= -\frac{1}{N}\sum_{i=1}^{N} \log l_{y_i}(\mathbf{x}_i; \mathbf{W}, \mathbf{b})$$

  - $\mathbf{x}_i$ – 第i个训练样本的深度特征
  - $\mathbf{W}_j$ – 权重矩阵$\mathbf{W}$（输出前馈层）的第j列
  - y_i – 第i个样本的类标签
  - C – 类的数量
  - N – 批量大小
  - $1\{y_i = j\}$ – 指示函数。如果第i个样本属于第j个说话者则取值为1，否则为0。

第六章　声纹识别

- 6.1 声纹识别概述
  - 6.1.1 声纹识别的基本概念
  - 6.1.2 声纹识别方法的回顾
  - 6.1.3 声纹识别的典型应用
- 6.2 传统声纹识别算法（GMM-UBM）
- 6.3 基于深度学习的声纹识别算法
- 6.4 声纹识别技术的展望（了解）

语音信息处理的技术展望



- 深度意图理解的语音/文本多模态人机交互
- 低资源语言的性能瓶颈
- 具身听觉智能/具身多模态智能
- 低能耗的通用语音交互智能

期末考试

时间：11月11日（周三） 15:25-17:25
考场：3022244110-3024244236（46-A110）
3024244238之后及其他 （46-A120）
方式：闭卷