思考题：语音合成的两条技术路线与大模型

4.1 传统神经网络语音合成与端到端语音合成

4.1.1 传统神经网络语音合成（多阶段、参数化）

本质是"文本 → 语言学特征 → 声学参数 → 波形"的分段流水线，每一段单独建模、单独训练：

1. 文本分析（前端）：文本规整（数字、缩写、符号转写）→ 分词与词性 → 字音转换（G2P）得到音素序列 → 结合上下文做上下文相关标注（三音素、词内位置、词性、韵律层级），形成问题集特征。
2. 时长模型：输入音素级特征，预测每个音素（及其状态）的时长。
3. 声学参数生成模型：按预测时长把音素展开成帧级序列，DNN 逐帧回归声学参数（倒谱/MCC、F_0、清浊、能量、非周期成分）；常以最小生成误差训练以缓解过平滑。
4. 声码器：基于源—滤波器模型，把声学参数还原成激励与声道滤波，合成波形（STRAIGHT/WORLD，或神经声码器）。合成音质很大程度取决于声码器。
5. 训练与调优：各模块目标独立（时长、谱参数、声码器分别最优），依赖 HMM/强制对齐提供帧—音素对应。

4.1.2 端到端语音合成

端到端路线是"文本（音素）→ 梅尔谱 → 波形"，或用 VITS 一类模型直接"文本 → 波形"，用整句目标优化整个系统：

1. 文本前端（保留但简化）：规整 + G2P 输出音素/字符序列，一般不再需要精细的上下文标注与独立时长模块。
2. 序列到序列声学模型：Tacotron 2 用编码器 + 位置敏感注意力 + 自回归解码器预测梅尔谱帧与结束标记；FastSpeech 改为非自回归，用时长预测器 + 长度规整利用文本与语音的单调对齐并行生成，解决自回归"慢、跳词重复、不可控"三问题。
3. 声码器：梅尔谱 → 波形（WaveNet/WaveGlow/HiFi-GAN 等神经声码器）。
4. 统一建模：VITS 用后验编码器（线性谱）+ 先验编码器 + Flow + 对抗训练，把声学模型与声码器合成一个网络，直接文本出波形，避免共用梅尔谱带来的信息瓶颈。
5. 训练：以整句似然（或对抗损失）端到端优化，对齐由注意力/单调对齐搜索自动学习，属弱监督。

4.1.3 优缺点对比

维度	传统神经网络合成（多阶段）	端到端合成
中间表示	显式声学参数（谱 + F_0 + 时长）	隐式梅尔谱（VITS 进一步去掉）
对齐来源	依赖强制对齐 / HMM 状态对齐	注意力或单调对齐自动学习
优化目标	各模块分别最优，误差逐级累积	整句目标，全局最优，减少人工假设
可控性	强：时长、韵律、F_0 可显式干预	弱；FastSpeech 靠时长预测器部分找回
可解释性	强，错误可定位到某一模块	弱，黑盒，端到端调优
数据需求	小，几小时单说话人语料即可	较大；但省去精细标注
自然度	受参数化与声码器限制，易过平滑、发闷、机械感	显著更高，接近真人；VITS 尤佳
鲁棒性	稳定、不幻觉；前端错误可局部修正	自回归易跳词/重复/不收敛；FastSpeech 缓解
速度部署	链路长、模块多；声码器是瓶颈	Tacotron 2 自回归慢；FastSpeech/VITS 可实时

拆开建模让传统路线可控、可调试、也不幻觉，误差却会逐级累积，谱参数化又带来过平滑。端到端把整句当成一个优化目标，自然度上去了；黑盒难调、可控性弱，自回归还容易跳词。

4.2 语音合成大模型

4.2.1 为什么效果更好

1. 范式转变，从回归到"续写"：大模型把合成视为条件语言模型，用神经编解码器（EnCodec/SoundStream 一类 RVQ 多码本）把语音离散成 token，于是 TTS 变成"给定文本 token 与语音提示，预测后续语音 token"，与 LLM 共享 next-token 预测范式、架构与训练技巧，可随参数/数据/算力直接规模化。
2. 数据规模与多样性：在海量多说话人、多语种、多风格、多信道数据上预训练，覆盖远比单说话人系统宽的音色、口音、情感与录音环境分布，泛化能力来自数据而非人工规则。
3. 上下文学习带来零样本克隆：VALL-E 一类模型给出 3 秒语音提示即可合成未见说话人的语音，且能延续提示中的音色、韵律、情感甚至声学环境，无需为目标说话人重新训练——这是传统与常规端到端系统做不到的。
4. 表征更充分：离散 codec token 保留了梅尔谱丢失的细节；第一码本自回归保证全局一致，其余码本非自回归并行补齐，兼顾质量与效率；同时文本理解与语音生成可共享语义空间，利于多语种、语码混用与指令控制。
5. 统一与可控：同一框架可覆盖 TTS、语音翻译、语音编辑与对话；用自然语言指令或提示控制情感、语速、风格；长上下文建模改善篇章级韵律一致性。
6. 弱监督、免精细对齐：不再依赖强制对齐与复杂前端标注，对多语种、生僻组合更友好。

4.2.2 还存在哪些不足

1. 保真与稳定性：自回归误差累积导致漏字、重复、乱读、跨语种串音，长文本尤甚；缺少"逐字读对"的硬约束，数字、专名、多音字仍依赖文本前端。
2. 可控性与可解释性弱：难以像参数化系统那样精确约束时长、停顿与音高曲线；出错难以定位，难以满足播报、配音的严格规范。
3. 效率与部署：参数量大、自回归解码慢、显存占用高，端侧与低延迟流式场景受限，需要蒸馏、量化、非自回归化改造。
4. 数据合规与安全：训练语料版权、音色克隆被滥用（诈骗、伪造），说话人隐私与人格权风险，需要授权机制、水印与鉴伪技术配套。
5. 评测困难：仍以主观 MOS 为主，成本高、方差大；缺乏统一客观指标与跨域基准，对表现力与长文本稳定性的评测不足。
6. 资源不均与成本：低资源语言、方言、情感语音数据稀缺，效果明显落后；训练与推理成本高。
7. 表现力上限：歌唱、细腻情感变化、多人对话（轮次衔接、重叠语音）仍有差距；长时合成中的音色漂移与一致性尚待改进。

小结

这条线可以用"减少人工分解、扩大数据与模型规模"来概括：波形拼接 → 统计参数（HMM/DNN，显式可控但过平滑）→ 端到端（整体优化、自然度高）→ 大模型（条件语言模型 + 离散 token，零样本泛化）。每换一代，可控与可解释都让位给自然度与泛化。所以现在更难的部分在稳定性、可控性与合规，而不在"像不像"。