



天津大学
Tianjin University

数据挖掘

杨柳

智能与计算学部

yangliuyl@tju.edu.cn



自我介绍

- 邮箱: yangliuyl@tju.edu.cn
- 实验室: 机器学习与数据挖掘
- 方向: 社会化机器学习
- 国创赛（互联网+）、挑战杯指导教师
- 办公室: 55楼B513

课程相关信息

- 40学时（24学时授课，16学时上机实验）
- 4-11周（杨柳4-7周，王煜8-11周）
- 平时成绩：考勤、平时作业、实验报告等
- 智慧树：k1001726
- 答疑时间：55楼B513、B519（提前预约）、微信随时

应用场景



	1	2	3	4	5	6
						
A		4	3			5
B		5		4		4
C		4		5	3	4
D			3			5
E			4			4
F				2	4	5

智能推荐

应用场景

移动设备用户年龄和性别预测

特征字段	字段描述
device_id	用户对应设备号，唯一表示，无重复
gender	用户性别，0为男性，1为女性
age	用户年龄
phone_brand	手机品牌
device_model	手机型号
event_id	事件id
app_id	应用程序id
is_installed	是否安装
is_active	是否激活
tag_list	应用程序的标签列表
date	事件发生日期

 sample_submit
 test
 test_app_events
 train
 train_app_events

device_id	gender	age	phone_brand	device_model
0	0	35	0	0
1	1	37	1	1
2	0	32	1	2
3	1	28	1	2
4	0	75	2	3
5	0	25	0	4
6	0	27	3	5

event_id	app_id	is_installed	is_active	device_id	tag_list	date
280934	224	1	0	1	[1012]	4
280934	375	1	1	1	[713, 704, 548, 756, 761, 777, 782, 787, 25]	4
280934	1	1	1	1	[713, 704, 548]	4
280934	458	1	1	1	[549, 713, 724, 548, 704, 130]	4
280934	2	1	0	1	[549, 710, 704, 548, 172]	4

应用场景

增强子与 RNA 表达的数据预处理

DRAKES / Gosai 数据案例：200 bp DNA 序列与三种细胞的 MPRA 表达活性

735,156 条原始输入记录



原始 ID	染色体	DNA 序列 (前 24 bp, 完整长度 200 bp)	HepG2	K562	SK-N-SH
0	chr7	CCTGGTCTTTCTTGCTAAATAAAC...	0.2336	0.0608	0.0472
1	chr1	CATAAAGATGAGGCTTGGCAAAGA...	0.0046	0.3796	-0.2444
2	chr1	CATAAAGCCAATCACTGAGATGAC...	0.3845	0.0367	-0.0046
3	chr15	CATAAAGGCAGTGTAGACCCCAAAC...	4.1165	4.5088	3.0402

特征字段	字段描述
source_row_id	原始记录编号，用于追溯来源；对应原始文件中无列名的第一列
chrom	序列所在染色体，如 chr1、chr7
seq	完整 DNA 序列，长度为 200 bp
hepg2	序列在 HepG2 细胞中的 MPRA 活性，以 log2FC 表示
k562	序列在 K562 细胞中的 MPRA 活性，以 log2FC 表示
sknsh	序列在 SK-N-SH 细胞中的 MPRA 活性，以 log2FC 表示
gc_fraction	G、C 碱基占序列的比例，预处理新增
k3_AAA ~ k3_TTT	64 种三核苷酸组合的频率，共 64 列，预处理新增

数据来源：Gosai et al. RegLM, Nature, 2024；项目与方法来源：Wang et al. Drakes, ICLR, 2025


应用场景

BCI（非侵入式脑机接口）情感预测



No.	Emotion label	Film clips sources
1	negative	Tangshan Earthquake
2	negative	Back to 1942
3	positive	Lost in Thailand
4	positive	Flirting Scholar
5	positive	Just Another Pandora's Box
6	neutral	World Heritage in China

情感和刺激来源图



电极位置分布图

应用场景

基于交易图的金融反欺诈与反洗钱

Elliptic 数据案例：比特币交易节点、资金流关系与合法 / 非法标签

203,769 笔交易 · 234,355 条资金流 · 49 个时间步


图数据对象	规模	主要内容	挖掘作用
交易节点	203,769	时间、输入输出数、手续费、金额	待识别主体
资金流边	234,355	BTC 从一笔交易流向下一笔	刻画账户关联
节点特征	166 维	94 个局部特征 + 72 个邻域聚合特征	风险分类输入
交易标签	约 2% 非法	合法约 21%，其余为未知标签	监督学习目标

关键字段

- local_features 交易时间、输入输出数、手续费、转账金额等 94 个局部特征
- aggregated_features 对一跳邻居统计最大值、最小值、标准差等，共 72 个特征
- label licit、illicit、unknown，用于训练交易风险分类模型



挖掘流程

- ①交易清洗 ②构建资金流图 ③提取局部与邻域特征 ④分类并人工复核



交易图可视化：红色为非法交易，蓝色为合法交易

教材



数据挖掘概念与技术（第3版），Jiawei Han等著. 范明等译，机械工业出版社，2012

斯坦福数据挖掘教程（第3版），Jure Leskovec等著. 王斌等译，中国工信出版集团，2021


数据挖掘导论，Pang-Ning Tan等著. 范明等译，人民邮电出版社，2020

数据挖掘科学家

世界顶尖1000名计算机科学家排名

韩家炜是唯一一位进入Top5的华人学者，他是美国伊利诺伊大学香槟分校计算机系教授，IEEE和ACM会士，2009年获得了麦克道尔奖，这是IEEE颁发的最高技术奖。

在数据挖掘领域，韩家炜教授认为要想将现有的无结构的大数据变成有用的知识，首先要做的就是将数据结构化，因为杰出贡献而被冠以「数据挖掘领头人」。



Anil K. Jain

Michigan State University
United States



Yoshua Bengio

University of Montreal
Canada



Herbert Simon

Carnegie Mellon University
United States



Jiawei Han

University of Illinois at Urbana-Champaign
United States



Michael I. Jordan

University of California, Berkeley
United States



David Haussler

University of California, Santa Cruz
United States



Philip S. Yu

University of Illinois at Chicago
United States



Takeo Kanade

Carnegie Mellon University
United States

学习资源

□ <https://www.bilibili.com/video/BV154411Q7mG?p=1>

清华大学深圳研究生院-袁博老师-国家级精品课

□ Some lecture notes are adopted from:

■ Jiawei Han (UIUC)

<http://hanj.cs.illinois.edu/bk3/>

■ Pang-Ning Tan, Michigan State University

<https://www-users.cs.umn.edu/~kumar001/dmbook/index.php>

学习资源——数据库/数据挖掘

ACM Transactions on Database Systems	TODS	期刊
ACM Transactions on Information Systems	TOIS	期刊
IEEE Transactions on Knowledge and Data Engineering	TKDE	期刊
The VLDB Journal	VLDBJ	期刊
ACM Conference on Management of Data	SIGMOD	会议
ACM Knowledge Discovery and Data Mining	SIGKDD	会议
IEEE International Conference on Data Engineering	ICDE	会议
International Conference on Research on Development in Information Retrieval	SIGIR	会议
International Conference on Very Large Data Bases	VLDB	会议

学习资源——人工智能

Artificial Intelligence	AI	期刊
IEEE Trans on Pattern Analysis and Machine Intelligence	TPAMI	期刊
International Journal of Computer Vision	IJCV	期刊
Journal of Machine Learning Research	JMLR	期刊
AAAI Conference on Artificial Intelligence	AAAI	会议
Annual Conference on Neural Information Processing Systems	NeurIPS	会议
Annual Meeting of the Association for Computational Linguistics	ACL	会议
IEEE Conference on Computer Vision and Pattern Recognition	CVPR	会议
International Conference on Computer Vision	ICCV	会议
International Conference on Machine Learning	ICML	会议
International Joint Conference on Artificial Intelligence	IJCAI	会议

学习资源



kaggle



阿里云 | TIANCHI 天池




数据挖掘领域的十大经典算法ICDM'06

- #1: C4.5 (61 votes) (分类)
- #2: K-Means (60 votes) (聚类)
- #3: SVM (58 votes) (分类)
- #4: Apriori (52 votes) (关联规则)
- #5: EM (48 votes)
- #6: PageRank (46 votes)
- #7: AdaBoost (45 votes)
- #7: kNN (45 votes) (分类)
- #7: Naive Bayes (45 votes) (分类)
- #10: CART (34 votes) (分类)

常用的工具

Kaggle 发布了数据科学和机器学习工具调查结果



Python成为使用最多的工具，并逐年稳步增长

目标

□ 课程目标

基本概念与方法

数据分析的完整流程（what, why, how）

实施和使用数据挖掘方法的经验

□ 学习目标

能够实现和应用数据挖掘技术来解决问题

了解数据挖掘的主要问题和核心问题

掌握数据挖掘的研究思路和实践

□ 结课目标

对数据挖掘领域有深入了解

有效沟通的能力

独立性和团队精神

第 1 章 概述

主要目标

重点掌握：

- 数据挖掘的概念
- 数据挖掘的任务
- 挖掘过程

1 概述

- 1.1 背景 
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.1 背景

- 二十世纪末以来，**全球信息量以惊人的速度急剧增长**——据估计，每二十个月将增加一倍。许多组织机构的IT系统中都收集了大量的数据（信息）。
- 数据的爆炸性增长：从TB到PB
 - 数据的收集和数据的可获得性
 - 自动数据收集工具、数据库系统、WEB、计算机化的社会
 - 丰富数据的来源
 - 商业：WEB、电子商务、交易数据、股市...
 - 科学：遥感、生物信息学、科学模拟
 - 社会及每个人：新闻、数码相机、微信、抖音
- **数据库系统**虽然可以高效地实现数据的录入、查询、统计等功能，但**无法发现数据中存在的关系和规则**，无法根据现有的数据预测未来的发展趋势。

1.1 背景

- 我们被数据所淹没，但却渴望知识
- 为了充分利用现有信息资源，从海量数据中找出隐藏的知识，数据挖掘技术应运而生并显示出强大的生命力。
- 数据挖掘：海量数据的自动分析技术



1 概述

- 1.1 背景
- 1.2 基本概念 
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.2.1 数据相关的基本概念

□ 1.2.1 数据相关的基本概念

- 数据
- 信息
- 知识
- 智慧

□ 1.2.2 数据挖掘定义


1.2.1 数据相关的基本概念

□ 数据


□ 信息

□ 知识


□ 智慧



1.2.1 数据相关的基本概念



数据



信息



知识



智能



CD player, CD, music book
CD, CD player
CD, music book
CD player, CD, food
Food, Clothes
CD player, CD

If buy CD
players,
then likely buy
CDs

sale on CD players,
raise the sell of CDs

1.2.1.1 数据



HUAWEI




1.2.1.1 数据

文本



视频



记录

TID	Items
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

event_id	app_id	is_installed	is_active	device_id	tag_list	c
280934	224	1	0	1	[1012]	
280934	375	1	1	1	[713, 704, 548, 756, 761, 777, 782, 787, 25]	
280934	1	1	1	1	[713, 704, 548]	
280934	458	1	1	1	[549, 713, 724, 548, 704, 130]	
280934	2	1	0	1	[549, 710, 704, 548, 172]	
280934	3	1	1	1	[548, 549]	
280934	48	1	0	1	[178]	
280934	764	1	0	1	[717, 721, 548, 704]	
280934	6	1	1	1	[302, 303]	

1.2.1.1 数据

□ 数据

- 数据是指对客观事件进行记录并可以鉴别的符号，是对客观事物的性质、状态以及相互关系等进行记载的物理符号或这些物理符号的组合。
- 数据可能存储在数据库、数据仓库和其他信息资料库中。


□ 类型

- 连续型：数值
- 离散型：标称、二元
- 符号、字符



□ 主要问题

- 不一致、错误、缺失 等



1.2.1.2 信息

- 信息是具有**时效性**的，有一定**含义**的，有**逻辑**的、经过**加工处理**的、对决策有**价值**的数据流。

	Data	Information
Meaning	Data is raw, unorganized facts that need to be processed. Data can be something simple and seemingly random and useless until it is organized.	When data is processed, organized, structured or presented in a given context so as to make it useful, it is called information.
Example	Each student's <u>test score</u> is one piece of data.	The <u>average score</u> of a class or of the entire school is information that can be derived from the given data.
Etymology	"Data" comes from a singular Latin word, datum, which originally meant "something given." Its early usage dates back to the 1600s. Over time "data" has become the plural of datum.	"Information" is an older word that dates back to the 1300s and has Old French and Middle English origins. It has always referred to "the act of informing," usually in regard to education, instruction, or other knowledge communication.

1.2.1.3 知识

- 人们实践经验的结晶且为新的实践所证实的；是关于事物运动的状态和状态变化的规律；是对信息加工提炼所获得的抽象化产物。
- 知识的形式可能是模式、关联、变化、异常以及其他有意义的结构。
- 知识：把**有关信息**关联在一起所形成的信息结构。
- 知识反映了客观世界中事物之间的关系，不同事物或者相同事物间的不同关系形成了不同的知识。

例如：


“雪是白色的” —— **事实**

“如果头痛且流涕，则有可能患了感冒” —— **规则**

1.2.1.4 智慧

- 智慧是人类基于已有的知识，针对物质世界运动过程中产生的问题根据获得的信息进行分析、对比、演绎找出解决方案的能力。
- 这种能力运用的结果是将信息的有价值部分挖掘出来并使之成为知识架构的一部分。

1.2.1 数据相关的基本概念



- 数据经过处理和加工，变成了信息。
- 信息之间产生了联系，形成了知识。
- 通过现有知识，发现了一些知识之间的新关系，并且串联起来，形成了智慧。

1.2.2 数据挖掘定义

□ 技术角度的定义

- 数据挖掘 (Data Mining)是从大量的、不完全的、有噪声的、模糊的、随机的实际应用数据中，提取隐含在其中的、人们事先不知道的、但又是潜在有用的信息和知识的过程。
- 定义中包括的含义：
 - 数据源是真实的、海量的、含噪声的；
 - 发现的是用户感兴趣的知识；发现的知识要可接受、可理解、可运用；
 - 并不要求发现放之四海皆准的知识，仅支持特定的发现问题。

1.2.2 数据挖掘定义

数据挖掘与传统数据分析方法区别

- 海量数据
 - 算法有高度的可扩展性，以有效处理TB级数据
- 高维数据
 - 可高达数万个不同的维
- 数据的高度复杂性、非结构化的
 - 文本、图像、视频和WEB数据
 - 时序数据
 - 图、社会网络、多关系数据
 - 异构数据
- 噪声数据

1.2.2 数据挖掘定义

并非所有和数据相关的任务都是数据挖掘

□ 以下不是数据挖掘系统

- 数据库系统

- 信息系统

- 数据统计分析系统

□ 相比于上述系统，数据挖掘系统关注更广的范围，是一个多学科的融合

□ 数据挖掘是要发现那些不能靠直觉发现的信息或知识，甚至是违背直觉的信息或知识，挖掘出的信息越是出乎意料，就可能越有价值。

1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史 
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.3 发展历史

进化阶段	商业问题	支持技术	厂家	产品特点
数据访问 (20世纪80年代)	“在天津去年三月的销售额是多少？”	关系数据库（RDBMS），结构化查询语言（SQL），ODBC Oracle、Sybase、Informix、IBM、Microsoft	Oracle、Sybase、Informix、IBM、Microsoft	在记录级提供历史性的、动态数据信息
数据仓库 (20世纪90年代)	“在天津去年三月的销售额是多少？据此可得出什么结论？”	联机分析处理（OLAP）、多维数据库、数据仓库	Pilot、Comshare、Arbor、Cognos、Microstrategy	在各种层次上提供回溯的、动态的数据信息
大数据分布式处理 (21 世纪 00 年代)	"如何处理社交媒体、移动设备产生的海量异构数据，挖掘用户行为规律？"	Hadoop、NoSQL、分布式存储、MapReduce	Apache、Cloudera、AWS、阿里云	支持 PB 级海量异构数据的分布式批处理，兼容非结构化数据
深度学习与智能自动化 (21 世纪 10 年代)	"如何自动识别海量数据中的复杂模式，实现精准预测与多模态识别？"	深度学习、GPU 加速、流计算、AutoML	Google、NVIDIA、Databricks、Microsoft	自动特征工程，支持文本 / 图像多模态数据，分析精度大幅提升
AI 原生与数据智能 (21 世纪 20 年代至今)	"如何用自然语言直接查询数据，让业务人员无需技术知识就能获取洞察？"	大语言模型、向量数据库、MLOps、湖仓一体	OpenAI、Snowflake、Databricks、Anthropic	自然语言交互，自助式分析，统一数据与 AI 工作流，实现智能决策

1.3 发展历史


- 1989年8月，在美国底特律召开的第11届国际人工智能联合会议的专题讨论会上首次出现数据库中的知识发现（Knowledge Discovery in Database, KDD）这一术语。
- 在1991年、1993年和1994年都举行KDD专题讨论会，汇集来自各个领域的研究人员和应用开发者，集中讨论数据统计、海量数据分析算法、知识表示、知识运用等问题。最初，数据挖掘是作为KDD中利用算法处理数据的一个步骤，其后逐渐演变成KDD的同义词。
- 现在，人们往往不加区别地使用“数据挖掘”和“KDD”。KDD常常被称为数据挖掘（Data Mining）。

1.3 发展历史

□ 大模型

用于从大规模数据中提取有用的信息和知识。
大模型可以通过学习更复杂的模式和关系，
从而更准确地进行预测和分类。

@斌叔NextEdu  沃尔玛利用了大语言模型（PaLM-2）生成的嵌入式表示来改进他们的DLRM，从而提高了[网页链接](#)网站上的产品搜索效果。由于结果非常好，他们即将在其实时网站上推出这项改进。



大模型	数据挖掘
文本挖掘	通过分析大量的文本数据，提取出关键词、主题、情感等信息。例如，可以用于舆情监测、产品评论分析等。
图像挖掘	通过分析大量的图像数据，提取出特征、模式和规律。例如，可以用于人脸识别、物体识别、图像搜索等。
社交网络分析	通过分析大规模的社交网络数据，提取出用户之间的关系、社群结构、影响力等信息。例如，可以用于推荐系统、广告投放、市场调研等。
时间序列预测	通过分析大量的时间序列数据，预测未来的趋势和变化。例如，可以用于股票市场预测、气象预报、销售预测等。

1.3 发展历史

▣ LDM (Large Data Model) , 即结构化数据基础模型, 其瞄准的是生产侧的核心痛点, 即如何让基础模型直接学习不同结构化数据中的变量关系、条件关系和生成机制。

• TabPFN-3.5: 德国软件SAP发布的面向结构化数据的新一代表格基础模型。经过大规模预训练后, 可直接完成分类、回归、时间序列预测和异常检测, 大幅减少人工调参与特征工程。直接处理缺失值、异常值、类别变量、高基数特征和文本字段; 其原生支持的数据规模已经扩展至百万行级别。

1.3 发展历史

▣LDM（Large Data Model），即结构化数据基础模型，其瞄准的是生产侧的核心痛点，即如何让基础模型直接学习不同结构化数据中的变量关系、条件关系和生成机制。

•LimiX-2：国内首个结构化数据通用大模型，清华博士组成的团队，用一个400M参数的结构化数据基础模型。把面向变量关系建模前置为核心目标，学习跨变量、跨样本的联合依赖结构。自建了一套高质量自动化数据合成引擎，先让模型见过足够复杂的数据世界，再去处理真实任务。特别适合初期快速建立高质量基线，也可以与 CatBoost、LightGBM 等模型进行概率加权，形成更强的融合结果。

1.3 发展历史

■ 自动化机器学习 (AutoML)：可以自动化数据处理、模型选择、超参数优化等步骤，目标在于简化复杂的机器学习流程，使得从数据中提取洞察和构建智能系统变得更加快速和容易。主要算法包括神经架构搜索(NAS)、贝叶斯优化算法、遗传算法、强化学习算法，以及各种元学习算法。

- AutoGluon：自动训练多种模型，并通过 Bagging、Stacking 和加权集成获得稳定的预测结果。同时组合 CatBoost、LightGBM、XGBoost、神经网络和表格基础模型；相比只调一个模型，集成方案更容易获得稳定的交叉验证成绩。

- 使用建议：初期使用默认配置快速建立强基线；后期增加训练时间、折数和堆叠层数，并将 AutoGluon 的预测结果与人工模型进行二次融合。

1.3 发展历史

▣ 自动化特征工程（AutoFE）：进行特征选择、生成和转换，以提取对于问题建模有用的特征。特征化是AutoML工作流中数据预处理的一部分。

- 开源自动化特征工程库：如Featuretools、AutoFeat、TSFresh等，适合中小型团队或科研场景，支持Python接口调用，算法丰富但集成能力有限。
- 商用低代码自动化平台：如帆软FineDataLink、阿里云DataWorks、腾讯云DataExplorer等，面向企业级场景，强调数据集成、实时同步、可视化开发。
- 一站式数据治理与特征处理平台：如FDL、Databricks、Snowflake等，支持多源数据融合、数仓建设、特征自动处理及调度，适合大型企业复杂场景。

1.3 发展历史

▣自动化特征工程（AutoFE）：进行特征选择、生成和转换，以提取对于问题建模有用的特征。特征化是AutoML工作流中数据预处理的一部分。

工具类型	优势	劣势	典型案例
Featuretools等开源	算法丰富、灵活	集成能力弱、无可视化	数据科学实验
商用低代码平台	集成强、可视化、支持实时同步	算子库有限、扩展性需关注	企业级数据分析
一站式平台（FDL）	算法丰富、数据融合、数仓建设能力强	成本略高、需专业团队运维	金融科技项目


1.3 发展历史

▣ 自动化特征工程（AutoFE）：进行特征选择、生成和转换，以提取对于问题建模有用的特征。特征化是AutoML工作流中数据预处理的一部分。

处理环节	自动化能力	算法支持	平台实践（FDL）
特征提取	多表、整库自动同步	分类、数值、时间	支持多源异构数据
特征转换	自动编码、归一化	One-Hot、标准化	低代码组件
特征选择	自动相关性分析	PCA、筛选算法	算子库丰富
特征交互	自动生成交互特征	分箱、聚合	DAG调度、可视化

1.3 发展历史

□ AI数据科学代理：从“辅助写代码”到“自动迭代实验”



1.3 发展历史

AI数据科学代理：从“辅助写代码”到“自动迭代实验”

2024年11月


2025年7月

2026年3月

Nature 2024

Autonomous mobile robots for exploratory synthetic chemistry


智能实验室实现自动化执行



Nature 2025

The Virtual Lab of AI agents designs new SARS-CoV-2 nanobodies


多智能体协作完成复杂科学探索



Nature 2026

Towards end-to-end automation of AI research

端到端自动化完成科研全过程



1.3 发展历史

□ AI数据科学代理：从“辅助写代码”到“自动迭代实验”

nature

[Explore content](#) [About the journal](#) [Publish with us](#)

[nature](#) > [articles](#) > article

Article | [Open access](#) | Published: 19 May 2026

Accelerating scientific discovery with Co-Scientist

[Juraj Gottweis](#), [Wei-Hung Weng](#), [Alexander Daryin](#), [Tao Tu](#), [Petar Sirkovic](#), [Artiom Myaskovsky](#), [Grzegorz Glowaty](#), [Felix Weissenberger](#), [Alessio Orlandi](#), [Dan Popovici](#), [Anil Palepu](#), [Keran Rong](#), [Ryutaro Tanno](#), [Khaled Saab](#), [Fan Zhang](#), [Jacob Blum](#), [Andrew Carroll](#), [Kavita Kulkarni](#), [Nenad Tomašev](#), [Dina Zverinski](#), [Ivor Rendulic](#), [Elahe Vedadi](#), [Florian Hasler](#), [Luka Rimanic](#), ... [Vivek Natarajan](#) [✉](#) [+ Show authors](#)

[Nature](#) **655**, 487–496 (2026) | [Cite this article](#)

nature

[Explore content](#) [About the journal](#) [Publish with us](#)


[nature](#) > [articles](#) > article

Article | [Open access](#) | Published: 19 May 2026

A multi-agent system for automating scientific discovery

[Ali E. Ghareeb](#), [Benjamin Chang](#), [Ludovico Mitchener](#), [Angela Yiu](#), [Caralyn J. Szostkiewicz](#), [Dmytro Shved](#), [Gavin J. Gyimesi](#), [Jon M. Laurent](#), [Samantha M. Wright](#), [Muhammed T. Razzak](#), [Andrew D. White](#) [✉](#), [Silvia C. Finnemann](#), [Michaela M. Hinks](#) [✉](#) & [Samuel G. Rodrigues](#) [✉](#)


[Nature](#) **655**, 497–505 (2026) | [Cite this article](#)



1.3 发展历史

□ AI数据科学代理：从“辅助写代码”到“自动迭代实验”


• AutoGen是微软发布的智能体协作框架，旨在帮助开发者创建基于大语言模型的复杂应用程序，通过多个智能体之间的协作与交互，实现更加智能和灵活的任务处理。



1.3 发展历史

▣ AI数据科学代理：从“辅助写代码”到“自动迭代实验”


•LangGraph专注于自然语言处理的框架，它通过循环控制、状态管理和人机交互等技术，帮助开发者构建复杂的AI Agent。适用于多种应用场景，如智能客服、智能投资顾问等。



1.3 发展历史

□ AI数据科学代理：从“辅助写代码”到“自动迭代实验”

• Phidata是一个基于Python的框架，能够将大型语言模型转化为AI产品中的Agent。



1.3 发展历史

▣ AI数据科学代理：从“辅助写代码”到“自动迭代实验”


- 数据科学代理通过迭代规划和验证DS-STAR：谷歌 AI 研究团队采用“数据分析—顺序规划—结果验证—方案修正”的循环机制，适合处理多个表格、文本和异构文件组成的复杂数据分析任务。
- 合理定位：AI代理适合自动生成基线、排查报错和批量执行实验，但数据泄漏检查、验证集设计和最终提交仍应由人工审核。

1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程 
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.4 挖掘过程

1. **数据清理** (消除噪音或不一致的数据)
2. **数据集成** (多种数据源组合到一起)
3. **数据选择**
(从数据库中提取与分析任务相关的数据)
4. **数据变换**
(变换或统一成合适挖掘的形式)
5. **挖掘算法设计**
(使用智能方法提取数据模式, 关联规则及机器学习的分类、聚类、回归)
6. **性能评估**
(根据某种兴趣程度度量识别提供知识的真正有趣的模式)
7. **知识表示**
(向用户提供挖掘的知识)



1.4 挖掘过程

□ 从KDD对数据挖掘的定义中可以看到当前研究领域对数据挖掘的广义认识

1. 数据清理 (这个可能要占全过程60%的工作量)

2. 数据集成

3. 数据选择

4. 数据变换

数据预处理

5. 挖掘算法设计 (适当的算法找到感兴趣的模式或者预测结果)

6. 性能评估

7. 知识表示

1.4 挖掘过程

□ 数据预处理

- KDD的处理对象是大量的数据，这些数据一般存储在数据库系统中，是长期积累的结果。但往往不合适直接在这些数据上进行知识挖掘，需要做一些准备工作，也就数据的预处理。
- 数据预处理包括数据的选择（选择相关数据）、净化（消除噪音、冗余数据）、推测（推算缺值数据）、转换（离散型数据与连续型数据之间的转换）、数据缩减（减少数据量）等。
- 数据预处理是KDD的第一个步骤，也是比较重要的一个步骤。数据准备得好坏将直接影响数据挖掘的效率和准确度以及最终模式的有效性。

1.4 挖掘过程

□ 挖掘算法设计

- 挖掘算法设计是最为关键的步骤，它根据KDD的目标，选取相应算法的参数，分析数据，得到可能形成知识的模式或者模型。
- 目前采用较多的算法有关联规则、决策树、SVM、神经网络、kmeans、线性回归等。

1.4 挖掘过程

□ 性能评估

通过上面步骤所得到的模式或者预测结果，需要进行性能评估，大部分模式是用数学手段描述的表达式，很难被人理解，还需要将其解释成可理解的方式以呈现给用户。

1.4 挖掘过程

□ 知识表示


知识表示的主要目的是为了运用，如何使知识能被运用也是KDD的步骤之一。

运用知识有两种方法：一种是只需看知识本身所描述的关系或结果，就可以对决策提供支持；另一种是要求对新的数据运用知识，由此可能产生新的问题，而需要对知识做进一步的优化。

KDD过程可能需要多次的循环反复，每一个步骤一旦与预期目标不符，都要回到前面的步骤，重新调整，重新执行。

1.4 挖掘过程

典型数据挖掘系统的体系结构



1 概述


- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务 
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战

1.5 主要任务

宏观上的两大类任务

- Prediction Methods 预测性方法
 - 利用已知变量的信息**预测**未知或未来的其它变量
 - 解释变量 → 目标变量
- Description Methods 描述性方法
 - 找到人类**可理解的模式**来描述数据



— View from 20,000 feet:



1.5 主要任务

从挖掘模式上数据挖掘可分为：


- 关联分析-----推荐系统
- 分类-----长尾分布
- 聚类分析-----离群点分析
- 回归-----时间序列分析



1.5 主要任务

1. 推荐系统（Recommendation system）

- 利用用户的一些行为，通过一些数学算法，推测出用户可能喜欢的东西



1.5 主要任务

1. 推荐系统（Recommendation system）

关联分析（Association Analysis）

- 从一个项目集中发现关联规则，该规则显示了给定数据集中经常一起出现的属性-值条件元组。
- 例如：关联规则 $X \Rightarrow Y$ 所表达的含义是满足X的数据库元组很可能满足Y。关联分析在交易数据分析、支持定向市场、商品目录设计和其他业务决策等方面有着广泛的应用。

Association Rules





<u>Rule</u>	<u>Support</u>	<u>Confidence</u>
$A \Rightarrow D$	2/5	2/3
$C \Rightarrow A$	2/5	2/4
$A \Rightarrow C$	2/5	2/3
$B \& C \Rightarrow D$	1/5	1/3

1.5 主要任务

2. 分类 (Classification)

- 分类指通过分析一个类别已知的数据集的特征来建立一组模型，该模型可用于预测类别未知的数据项的类别。
- 该分类模型可以表现为多种形式：分类规则（IF-THEN），决策树，神经网络。




1.5 主要任务

2. 分类 (Classification)

长尾分布 (Long-tailed distribution)

- **80/20法则**: 20%的人的掌握着80%的社会财富。
- 80%的样本分布在20%的头部类别上, 大量尾部类别样本稀少, 呈现一种极端不平衡分布。



1.5 主要任务

3. 聚类分析 (Clustering Analysis)

- 聚类分析又称为“同质分组”或者“无监督的分类”，指把一组数据分成不同的“簇”，每簇中的数据相似而不同簇间的数据则距离较远。相似性可以由用户或者专家定义的距离函数加以度量。
- 好的聚类方法应保证不同类间数据的相似性尽可能地小，而类内数据的相似性尽可能地大。

Original image



$K = 10$



$K = 3$



$K = 2$



1.5 主要任务

3. 聚类分析（Clustering Analysis）



离群点分析

- 离群点：一些与数据的一般行为或模型不一致的孤立数据
- 通常孤立点被作为“噪音”或异常被丢弃，但在欺骗检测中却可以通过对罕见事件进行孤立点分析而得到结论。
- 应用
 - 信用卡欺诈检测
 - 移动电话欺诈检测
 - 客户划分
 - 医疗分析（异常）

1.5 主要任务

4. 回归 (Regression)

- 回归与分类类似，只不过它要预测的不是类别，而是一个连续的数值。




1.5 主要任务

4. 回归 (Regression)

时间序列分析 (Time-Series Analysis)

通过对大量时间序列数据的分析找到特定的规则和感兴趣的特性，包括搜索相似序列或者子序列，挖掘序列模式、周期性、趋势和偏差。预测的目的是对未来的情况作出估计。

1.5 主要任务




Clustering

Data


Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes
11	No	Married	60K	No
12	Yes	Divorced	220K	No
13	No	Single	85K	Yes
14	No	Married	75K	No
15	No	Single	90K	Yes

Association Rules



Predictive Modeling

Anomaly Detection




1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系 
- 1.7 应用
- 1.8 研究热点与挑战

1.6 与其他学科的关系

- 数据挖掘作为一门交叉学科，涉及数据库系统、统计学、机器学习、可视化、信息检索和高性能计算等诸多领域。
- 此外，还与深度学习、模式识别、空间数据分析、图像处理、自然语言处理、信号处理、概率论、图论和归纳逻辑等等领域关系密切。

1.6 与其他学科的关系



1.6 与其他学科的关系


数据挖掘与数据库的关系

- 数据库主要关注数据建模、查询语言、查询处理与优化方法、数据存储以及索引和存取，处理相对结构化的数据集，可以为数据挖掘提供数据管理技术。
- 数据挖掘任务可以进行分析和预测，扩充已有数据库系统的能力，满足高端用户复杂的数据分析需求。

1.6 与其他学科的关系

数据挖掘与机器学习的关系

- 数据挖掘可以认为是数据库技术与机器学习的交叉
 - 它利用数据库技术来管理海量的数据。
 - 机器学习和统计学为数据挖掘提供数据分析技术。
- 作为一个独立的学科，数据挖掘也有其独特的东西，即：关联分析。



1.6 与其他学科的关系

数据挖掘与统计学的关系

□ 关联：

统计学为数据挖掘一些算法设计提供了指导思想，应用统计学对数据挖掘的结果进行评估和验证。

□ 共同点：

发现数据中的结构、隐藏的内在规律。

□ 不同点：

- 统计学是抽样样本的研究，从小样本数据分析，推测总体的特征。数据挖掘通常是从海量的数据集中挖掘知识。
- 统计分析在预测中的应用常表现为一个或一组函数关系式；而数据挖掘在预测应用中的重点在于预测的结果，很多时候并不会从结果中产生明确的函数关系式，有时候甚至不知道到底是哪些变量在起作用，又是如何起作用的。

1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用 
- 1.8 研究热点与挑战

1.7 应用

- 数据挖掘技术的产生本身就具有其强烈的应用需求背景，在市场分析、业务管理、决策支持等方面有广泛的应用，是实现CRM和BI的重要手段之一。
 - 客户信用评分
 - 逾期行为预测
 - 客户流失分析
 - 欺诈甄别
 - 客户群体划分

1.7 应用

□ 消费者人群画像——智能信用评分

中国移动提供的样本数据，包括客户的各类通信支出、欠费情况、出行情况、消费场所、社交、个人兴趣等丰富的多维度数据，运用机器学习和深度学习算法，准确评估用户消费信用分值。

```
Data columns (total 30 columns):
```

#	Column	Non-Null Count	Dtype
0	用户编码	100000 non-null	object
1	用户实名制是否通过核实	100000 non-null	int64
2	用户年龄	100000 non-null	int64
3	是否大学生客户	100000 non-null	int64
4	是否黑名单客户	100000 non-null	int64
5	是否4G不健康客户	100000 non-null	int64
6	用户网龄（月）	100000 non-null	int64
7	用户最近一次缴费距今时长（月）	100000 non-null	int64
8	缴费用户最近一次缴费金额（元）	100000 non-null	float64
9	用户近6个月平均消费值（元）	100000 non-null	float64
10	用户账单当月总费用（元）	100000 non-null	float64
11	用户当月账户余额（元）	100000 non-null	int64
12	缴费用户当前是否欠费缴费	100000 non-null	int64
13	用户话费敏感度	100000 non-null	int64
14	当月通话交往圈人数	100000 non-null	int64
15	是否经常逛商场的人	100000 non-null	int64



1.7 应用

□ 用户逾期行为预测：

通过分析信贷用户的其他行为，来判断用户是否逾期。

	A	B
1	名称	标签
2	CUST_ID	客户号
3	OPEN_ORG_NUM	开户机构
4	IDF_TYP_CD	证件类型
5	GENDER	性别
6	bad_good	个贷是否逾期
7	LAST_OPEN_TENURE_DAYS	信用卡最近开户时长
8	G_OS_PRCP_SUM	贷款账户月余额
9	OS_PRCP_SUM_THREE	三个月内贷款账户月均余额



1.7 应用

有数据的地方，就可能需要数据挖掘技术。

Data Mining Applications in 2008 [107 voters]		
CRM/ consumer analytics (41)		38.3%
Banking (34)		31.8%
Fraud Detection (21)		19.6%
Finance (18)		16.8%
Direct Marketing/ Fundraising (15)		14.0%
Other (14)		13.1%
Investment / Stocks (14)		13.1%
Credit Scoring (14)		13.1%
Telecom / Cable (13)		12.1%
Retail (13)		12.1%
Advertising (13)		12.1%
Biotech/Genomics (12)		11.2%
Science (11)		10.3%
Insurance (11)		10.3%
Health care/ HR (10)		9.3%
Manufacturing (9)		8.4%
e-Commerce (8)		7.5%
Web usage mining (8)		7.5%
Social Policy/Survey analysis (8)		7.5%
Medical/ Pharma (8)		7.5%
Security / Anti-terrorism (6)		5.6%

1 概述

- 1.1 背景
- 1.2 基本概念
- 1.3 发展历史
- 1.4 挖掘过程
- 1.5 主要任务
- 1.6 与其他学科的关系
- 1.7 应用
- 1.8 研究热点与挑战 

1.8 研究热点与挑战

□ 大语言模型与数据挖掘的深度融合

语义增强的传统挖掘：将 LLMs 集成到关联规则挖掘中，利用其语义理解能力克服传统方法对符号共现模式的“语义脆弱性”，实现无需本体（Ontology-Free）的语义泛化。

自动化数据探索与分析：LLMs 被用于自动化探索性数据分析（EDA），通过自然语言或 SQL 接口，帮助用户从复杂表格和数据湖中发现关系、生成洞察。

智能数据发现代理：多智能体框架结合 LLMs 的上下文推理能力，用于高效地发现数据湖中可连接（Joinable）的列关系。

1.8 研究热点与挑战

□ 图基础模型与图神经网络（GNNs）的演进

应对真实世界挑战：针对图数据中普遍存在的不平衡、噪声、隐私和分布外（OOD）问题，设计更鲁棒的 GNN 架构。

图与 LLM 的协同：探索如何利用 LLMs 增强图挖掘，以及如何将图结构知识注入 LLMs，形成一个双向增强的循环。

边缘感知图学习：在图学习中更精细地建模边缘（关系）的属性与影响，以捕获更复杂的依赖关系。

1.8 研究热点与挑战

□ 可信与负责任的数据挖掘

可解释性（XAI）：研究重点从简单的“事后解释”转向内在可解释的模型设计（如可解释的决策树集成、概念瓶颈模型），并建立标准化的基准来量化“准确率-透明度”的权衡。

隐私保护：隐私保护数据挖掘（PPDM）持续演进，重点包括联邦学习（FL）、分割学习（SL）与差分隐私（DP）等技术的融合，以在分布式和边缘环境中平衡数据效用与隐私安全。

公平性：公平性感知数据挖掘（Fairness-Aware Data Mining）致力于开发能检测和缓解算法偏见的技术，确保数据挖掘结果不加剧社会不平等。

1.8 研究热点与挑战

□ 新兴交叉与融合方向

多模态数据挖掘：整合文本、图像、音频等多种模态的数据，采用基于注意力机制和 Transformer 的早期融合策略成为主流，重点解决跨模态对齐和知识融合问题。

数据挖掘与区块链：两者的结合是一个新兴趋势，旨在利用区块链的安全、透明和不可篡改特性，解决数据挖掘中的信任、隐私和分布式决策问题。

因果推断与数据挖掘的融合：研究正从“预测”走向“干预”。因果机器学习被应用于精准医疗、社会学等领域，致力于在复杂、高维的观测数据中识别异质性处理效应，并构建可解释的因果模型。

小结

- 数据挖掘：从大量的、不完全的、有噪声的、模糊的、随机的实际应用数据中，提取隐含在其中的、人们事先不知道的、但又是潜在有用的信息和知识的过程
- 挖掘过程：数据清理、数据集成、数据选择、数据变换、挖掘算法设计、性能评估、知识表示
- 数据挖掘的任务：关联规则，分类，聚类，回归等
- 应用：where there are data, there are data mining applications



天津大学
Tianjin University

THE END

